

Capítulo 3

Análisis en Componentes Principales

3.1 Introducción

El Análisis en Componentes Principales constituye la técnica de base en Análisis Multivariado de Datos. Su principal objetivo es el de encontrar, a partir de una tabla de datos con variables cuantitativas, un conjunto de variables sintéticas cuya información sea lo más parecida a la de las variables originales. Es por lo tanto, una técnica de *reducción de las dimensiones* de un problema puesto que de un conjunto inicial de variables, que pueden ser muchas, se trata de encontrar un conjunto reducido de variables que contengan prácticamente la misma información que las variables originales.

En general, las tablas de datos definen nubes de puntos en espacios vectoriales con dimensiones muy grandes, por lo que la visualización de las relaciones entre los puntos es imposible cuando la dimensión del espacio es mayor que 3; el ojo humano sólo es capaz de “ver” en dimensión menor o igual a 3. Así, en los casos multivariados el Análisis en Componentes Principales (en adelante abreviado A.C.P.) es una herramienta muy útil para la descripción de las relaciones entre las variables, pero también para la descripción del comportamiento multidimensional de los individuos respecto a todas las variables en su conjunto.

Por otra parte, el A.C.P. también sirve para definir otras técnicas de Análisis de Datos, como el Análisis de Correspondencias y el Análisis Factorial Discriminante, o el método Statist —todas ellas vistas como casos particulares del A.C.P.— ya que se trata de plantear una matriz a diagonalizar con el fin de hacer una proyección de los individuos en un espacio de dimensiones reducidas.

Finalmente, el A.C.P. puede ser usado como herramienta en técnicas donde se necesite una tabla de datos con variables no correlacionadas. En efecto, las componentes principales que se obtienen en el A.C.P. son no correlacionadas entre ellas y son combinación lineal de las variables originales. En Regresión Lineal Múltiple y en Análisis Factorial Discriminante, la alta correlación que pueden tener las variables provoca que haya problemas numéricos para calcular la solución, ya que se debe invertir una matriz de covarianzas; pero el problema se resuelve si las variables explicativas se sustituyen por las componentes principales, las cuales eliminan ese problema numérico de mal condicionamiento de la matriz a invertir.

Si bien es cierto que los principios del A.C.P. fueron planteados desde principios del Siglo XX por K. Pearson (para el caso de 2 variables), no fue sino Hotelling que obtuvo la solución general en 1933 dentro de un marco de variables aleatorias normales o gaussianas. A principios de los años 1970, fue J.P. Pagès quien logró obtener la solución conocida hoy día en el marco del Álgebra Lineal, sin necesidad de plantear hipótesis sobre las distribuciones probabilidad de las variables, cuyas ideas seguimos en este texto.

3.2 Objetivo del A.C.P.

Supóngase que se está en presencia de n individuos $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ sobre los que se han medido p variables cuantitativas $\mathbf{x}^1, \mathbf{x}^2, \dots, \mathbf{x}^p$. Por lo tanto se define una tabla de datos $\mathbf{X}$, con n filas y p columnas. Como vimos anteriormente, cada fila de la matriz se puede ver como un punto de $\mathbb{R}^p$, así el conjunto de n individuos define una nube de n puntos en $\mathbb{R}^p$, denotada $\mathcal{N} = (\mathbf{X}, \mathbf{M}, \mathbf{D}_p)$, con $\mathbf{M}$ la métrica $p \times p$ sobre el espacio de individuos y $\mathbf{D}_p$ la métrica de pesos (matriz diagonal $n \times n$) sobre el espacio de variables.

Supondremos en este capítulo que las variables $\mathbf{x}^j$ están centradas.

Esto significa que el centro de gravedad de la nube de los n puntos en $\mathbb{R}^p$ está en el origen de coordenadas: $\mathbf{g} = \mathbf{0}$.

El A.C.P. se plantea como una técnica de reducción de la dimensión del problema: se busca un espacio de dimensión q , menor que p , de manera que las posiciones relativas de los puntos-individuos sean lo más similares posibles a sus posiciones en el espacio $\mathbb{R}^p$. Esto significa que hay una pérdida mínima de información al proyectar los n individuos sobre un espacio de dimensión menor; de esta forma, su dispersión en el espacio proyectado $\mathbb{R}^q$ debe ser máxima, de manera que la forma de la nube se asemeje lo mejor posible a su forma original. Por esta razón, más adelante plantearemos el objetivo del A.C.P. como el de encontrar un subespacio de inercia máxima.

Se puede plantear de otra forma el objetivo del A.C.P., esta vez desde el punto de vista de las variables. Dada la tabla de datos $\mathbf{X}$, se busca un conjunto de q variables sintéticas $\mathbf{c}^1, \mathbf{c}^2, \dots, \mathbf{c}^q$, donde $q < p$, que más adelante se llamarán *componentes principales*, tal que:

1. Cada componente principal $\mathbf{c}^k$ debe ser combinación lineal de las variables originales $\mathbf{x}^j$; esto significa que la información contenida en las $\mathbf{x}^j$ también está reflejada en las $\mathbf{c}^k$.
2. Las componentes principales deben ser no correlacionadas dos a dos; esto significa que las $\mathbf{c}^k$ no tienen información redundante.
3. Las componentes principales deben tener varianza máxima; esto significa que contendrán el máximo de información posible.

Las tres condiciones anteriores se probarán como propiedades del A.C.P. que deduciremos del objetivo inicial, de reducción de la dimensión del espacio de individuos.

Ejemplo 1 *Considérese la tabla de datos de notas escolares mostrada en la Tabla 3.1, que contiene las notas obtenidas por 10 estudiantes en cinco materias. Todas las notas están en la escala de 0 a 10.*

Puede observarse que los estudiantes son vectores en $\mathbb{R}^5$, por lo que para el ojo humano no es posible observar la configuración de los 10 puntos en $\mathbb{R}^5$. Se quiere obtener una síntesis de la tabla anterior que muestre:

Estudiante	Matemáticas	Ciencias	Español	Historia	Ed. Física
Lucía	7.0	6.5	9.2	8.6	8.0
Pedro	7.5	9.4	7.3	7.0	7.0
Inés	7.6	9.2	8.0	8.0	7.5
Luis	5.0	6.5	6.5	7.0	9.0
Andrés	6.0	6.0	7.8	8.9	7.3
Ana	7.8	9.6	7.7	8.0	6.5
Carlos	6.3	6.4	8.2	9.0	7.2
José	7.9	9.7	7.5	8.0	6.0
Sonia	6.0	6.0	6.5	5.5	8.7
María	6.8	7.2	8.7	9.0	7.0

Tabla 3.1: Tabla de datos de las notas escolares.

- *Las principales relaciones entre los individuos, es decir, cuales se parecen más que otros, y cuales se diferencian de los demás.*
- *Las principales relaciones entre las variables, es decir, cuales tienen un comportamiento similar sobre los individuos, cuales tienen un comportamiento opuesto y cuales no tienen ninguna relación entre sí.*
- *Explicar las relaciones entre individuos y variables.*

El análisis anterior lo queremos hacer de forma global, es decir, tomando en cuenta a todas las variables al mismo tiempo. Esta es una característica esencial del Análisis Multivariado.

3.3 Solución del A.C.P.

La solución del Análisis en Componentes Principales se obtiene al diagonalizar la matriz de correlaciones $\mathbf{R}$, es decir, el cálculo de sus valores y vectores propios. En esta sección veremos cómo se obtiene este resultado, mientras que en la sección 3.9 haremos la deducción de la solución para el caso general, cuando se puede usar una métrica arbitraria.

Llamaremos A.C.P. normado el caso en que se usan los datos centrados y estandarizados, lo que corresponde a usar la métrica de los inversos de las varianzas, en cuyo caso la solución se obtiene al diagonalizar $\mathbf{R}$, y

llamaremos A.C.P. general cuando la métrica $\mathbf{M}$ es cualquiera, en cuyo caso la solución se obtiene al diagonalizar $\mathbf{VM}$, producto de la métrica y la matriz de varianzas-covarianzas.

3.3.1 A.C.P. normado

Dada la tabla de datos $\mathbf{X}$, procedemos a centrar y estandarizar las variables, de forma que en adelante todas tienen media cero y varianza 1. Así, estamos en presencia de la nube de puntos $\mathcal{N} = (\mathbf{X}, \mathbf{I}_p, \mathbf{D}_p)$, donde $\mathbf{I}_p$ es la identidad $p \times p$ y $\mathbf{D}_p$ es la métrica diagonal de pesos. En este contexto, la matriz de covarianzas $\mathbf{V}$ y la matriz de correlaciones $\mathbf{R}$ coinciden.

Según se probó en el ejercicio 2 del capítulo 2 para cuando se tienen las variables centradas y estandarizadas, la inercia de $\mathcal{N}$ es igual a la traza de $\mathbf{V}$, es decir, es igual a la suma de las varianzas. En este caso, esta suma es exactamente p .

Se busca el subespacio H de $\mathbb{R}^p$ tal que la proyección de los individuos quede lo mejor representada posible en H . Esto significa que la inercia de la nube de los puntos proyectados debe ser máxima¹. Cualquier individuo $\mathbf{x}_i$ en $\mathbb{R}^p$ puede ser presentado como $\mathbf{x}_i = \text{Pr}_H(\mathbf{x}_i) + \text{Pr}_{H^\perp}(\mathbf{x}_i) = \mathbf{a}_i + \mathbf{b}_i$, donde $\mathbf{a}_i = \text{Pr}_H(\mathbf{x}_i) \in H$ y $\mathbf{b}_i = \text{Pr}_{H^\perp}(\mathbf{x}_i) \in H^\perp$ (es decir, $\mathbf{a}_i \perp \mathbf{b}_i$), como se ilustra en la Figura 3.1.

En vista de la perpendicularidad entre $\mathbf{a}_i$ y $\mathbf{b}_i$, por el teorema de Pitágoras se tiene que:

$$\|\mathbf{x}_i\|^2 = \|\mathbf{a}_i\|^2 + \|\mathbf{b}_i\|^2$$

y luego

$$p_i \|\mathbf{x}_i\|^2 = p_i \|\mathbf{a}_i\|^2 + p_i \|\mathbf{b}_i\|^2,$$

de donde

$$\sum_{i=1}^n p_i \|\mathbf{x}_i\|^2 = \sum_{i=1}^n p_i \|\mathbf{a}_i\|^2 + \sum_{i=1}^n p_i \|\mathbf{b}_i\|^2.$$

Si definimos la proximidad entre $\mathcal{N}$ y el subespacio H como

$$I_H(\mathcal{N}) = \sum_{i=1}^n p_i \|\mathbf{x}_i - \mathbf{a}_i\|^2 = \sum_{i=1}^n p_i \|\mathbf{b}_i\|^2$$

¹Para simplificar, el lector puede pensar en H como un espacio de dimensión dos, es decir, un plano.




Figura 3.1: Proyección de un punto-individuo sobre un subespacio y su complemento ortogonal.

entonces el objetivo del A.C.P. será encontrar H tal que $I_H(\mathcal{N})$ sea mínima. Poniendo $I_{H^\perp}(\mathcal{N}) = \sum_{i=1}^n p_i \|a_i\|^2$, entonces es claro que

$$I(\mathcal{N}) = I_H(\mathcal{N}) + I_{H^\perp}(\mathcal{N}), \quad (3.1)$$

por lo que $I_{H^\perp}(\mathcal{N})$ es máxima cuando $I_H(\mathcal{N})$ es mínima.

En la sección 3.9 se prueba el teorema de inclusión: el espacio óptimo de dimensión k está contenido en el espacio óptimo de dimensión $k+1$. Esto permite seguir como estrategia la búsqueda del espacio óptimo de dimensión uno, enseguida del espacio óptimo de dimensión dos que contenga al anterior. Para ello, será suficiente hallar el espacio óptimo de dimensión uno, ortogonal al primer espacio encontrado, y así se genera el espacio óptimo de dimensión 2, mediante la suma directa de los dos espacios encontrados.

Es sabido que un espacio de dimensión uno es generado por un vector: ponemos $\Delta_{\mathbf{u}}$ el espacio generado por el vector $\mathbf{u}$. Para fijar las ideas, tomaremos los vectores que generan estos espacios, de norma 1.

Ahora bien, en virtud de la igualdad (3.1), $I_{\Delta_{\mathbf{u}}}(\mathcal{N})$ es mínima si $I_{\Delta_{\mathbf{u}}^\perp}(\mathcal{N})$ es máxima. Según la proposición 3.1, que mostraremos enseguida, es operativamente más fácil el cálculo de $I_{\Delta_{\mathbf{u}}^\perp}(\mathcal{N})$. Por lo tanto, se buscará el vector $\mathbf{u}$ de norma 1 tal que $I_{\Delta_{\mathbf{u}}^\perp}(\mathcal{N})$ sea máxima.

Así, podemos decir que buscamos:

1. El vector $\mathbf{u}_1$ tal que $\|\mathbf{u}_1\| = 1$ e $I_{\Delta_{\mathbf{u}_1}^\perp}(\mathcal{N})$ sea máxima.
2. El vector $\mathbf{u}_2$ tal que $\|\mathbf{u}_2\| = 1$, $\mathbf{u}_1 \perp \mathbf{u}_2$ e $I_{\Delta_{\mathbf{u}_2}^\perp}(\mathcal{N})$ sea máxima.
3. El vector $\mathbf{u}_3$ tal que $\|\mathbf{u}_3\| = 1$, $\mathbf{u}_1 \perp \mathbf{u}_3$, $\mathbf{u}_2 \perp \mathbf{u}_3$ e $I_{\Delta_{\mathbf{u}_3}^\perp}(\mathcal{N})$ sea máxima.
4. Etc.

Proposición 3.1 *Si $\mathbf{u}$ es un vector de $\mathbb{R}^p$ con norma 1, entonces*

$$I_{\Delta_{\mathbf{u}}^\perp}(\mathcal{N}) = \mathbf{u}^t \mathbf{R} \mathbf{u}.$$

DEMOSTRACIÓN:

Sea $\mathbf{x}_i$ un individuo, es decir, una fila de la tabla de datos $\mathbf{X}$. Sean $\mathbf{a}_i = \text{Pr}_{\Delta_{\mathbf{u}}}(\mathbf{x}_i)$ su proyección sobre $\Delta_{\mathbf{u}}$ y $\mathbf{b}_i = \text{Pr}_{\Delta_{\mathbf{u}}^\perp}(\mathbf{x}_i)$ su proyección sobre $\Delta_{\mathbf{u}}^\perp$, de manera que $\mathbf{x}_i = \mathbf{a}_i + \mathbf{b}_i$.

Como $\mathbf{a}_i$ es la proyección sobre la recta generada por $\mathbf{u}$, entonces existe un coeficiente c_i tal que $\mathbf{a}_i = c_i \mathbf{u}$. Es más, se sabe que

$$c_i = \langle \mathbf{x}_i, \mathbf{u} \rangle = \mathbf{x}_i^t \mathbf{u}$$

ya que la métrica es la identidad $\mathbf{I}_p$ y $\|\mathbf{u}\| = 1$. Por lo tanto

$$\begin{aligned}
 I_{\Delta_{\mathbf{u}}^\perp}(\mathcal{N}) &= \sum_{i=1}^n p_i \|\mathbf{a}_i\|^2 \\
 &= \sum_{i=1}^n p_i \|c_i \mathbf{u}\|^2 \\
 &= \sum_{i=1}^n p_i c_i^2 \\
 &= \sum_{i=1}^n p_i \mathbf{x}_i^t \mathbf{u} \mathbf{x}_i^t \mathbf{u} \\
 &= \mathbf{u}^t \left(\sum_{i=1}^n p_i \mathbf{x}_i^t \mathbf{x}_i \right) \mathbf{u} \\
 &= \mathbf{u}^t \mathbf{X}^t \mathbf{D}_p \mathbf{X} \mathbf{u} \\
 &= \mathbf{u}^t \mathbf{R} \mathbf{u}. \quad \blacksquare
 \end{aligned}$$

El primer eje

El primer eje que se busca, $\mathbf{u}_1$, genera la recta $\Delta_{\mathbf{u}_1}$ tal que $\|\mathbf{u}_1\| = 1$ e $I_{\Delta_{\mathbf{u}_1}^\perp}(\mathcal{N}) = \mathbf{u}_1^t \mathbf{R} \mathbf{u}_1$ es máxima.

Para ello, se plantea el problema de maximización con restricciones:

$$\begin{array}{ll} \text{Maximizar} & F(\mathbf{u}) = I_{\Delta_{\mathbf{u}}^\perp}(\mathcal{N}) = \mathbf{u}^t \mathbf{R} \mathbf{u} \\ \text{sueto a} & \|\mathbf{u}\|^2 = \mathbf{u}^t \mathbf{u} = 1. \end{array}$$

Usando la técnica de multiplicadores de Lagrange, si

$$\begin{aligned} L(\mathbf{u}, \lambda) &= F(\mathbf{u}) - \lambda(\|\mathbf{u}\|^2 - 1) \\ &= \mathbf{u}^t \mathbf{R} \mathbf{u} - \lambda(\mathbf{u}^t \mathbf{u} - 1), \end{aligned}$$

entonces

$$\frac{\partial L}{\partial \mathbf{u}} = 2\mathbf{R} \mathbf{u} - 2\lambda \mathbf{u} = \mathbf{0},$$

por lo que

$$\mathbf{R} \mathbf{u} = \lambda \mathbf{u}.$$

Esto significa que $\mathbf{u}$ es vector propio² de $\mathbf{R}$, asociado al valor propio λ .

Es más,

$$F(\mathbf{u}) = \mathbf{u}^t \mathbf{R} \mathbf{u} = \mathbf{u}^t (\lambda \mathbf{u}) = \lambda \mathbf{u}^t \mathbf{u} = \lambda.$$

Por lo tanto, F se maximiza cuando λ es máximo.

Al vector propio $\mathbf{u}_1$ asociado al mayor valor propio λ_1 de $\mathbf{R}$ se le llama el **primer eje** del A.C.P. de la nube $\mathcal{N}$.

Segundo eje

El segundo eje buscado, $\mathbf{u}_2$, debe combinarse con $\mathbf{u}_1$ y formar un subespacio de dimensión 2 (es decir, un plano), tal que la inercia proyectada de la nube $\mathcal{N}$ sea máxima. Por el teorema de inclusión, como ya tenemos el espacio óptimo $\Delta_{\mathbf{u}_1}$ de dimensión 1 y sabemos que éste está incluido en el

²Recuérdese que un escalar λ se llama *valor propio* de una matriz $\mathbf{A}$ si existe un vector $\mathbf{v} \neq \mathbf{0}$ tal que $\mathbf{A} \mathbf{v} = \lambda \mathbf{v}$; al vector $\mathbf{v}$ se le llama *vector propio* de $\mathbf{A}$ asociado a λ . Al proceso de obtener todos los valores y vectores propios de una matriz se le llama *diagonalización* de la matriz.

espacio óptimo de dimensión 2, entonces basta con encontrar el vector $\mathbf{u}$ —ortogonal a $\mathbf{u}_1$ — con $I_{\Delta_{\mathbf{u}}^\perp}(\mathcal{N})$ máxima. Esto es,

$$\begin{aligned} &\text{Maximizar} && F(\mathbf{u}) = I_{\Delta_{\mathbf{u}}^\perp}(\mathcal{N}) = \mathbf{u}^t \mathbf{R} \mathbf{u} \\ &\text{sujeto a} && \|\mathbf{u}\|^2 = \mathbf{u}^t \mathbf{u} = 1, \\ &&& \mathbf{u}_1 \perp \mathbf{u}. \end{aligned}$$

Por ello, planteamos el problema de optimización con multiplicadores de Lagrange en que buscamos el vector $\mathbf{u}$ que maximiza L :

$$\begin{aligned} L(\mathbf{u}, \lambda, \mu) &= F(\mathbf{u}) - \lambda(\|\mathbf{u}\|^2 - 1) - \mu(\langle \mathbf{u}_1, \mathbf{u} \rangle = 0) \\ &= \mathbf{u}^t \mathbf{R} \mathbf{u} - \lambda(\mathbf{u}^t \mathbf{u} - 1) - \mu \mathbf{u}_1^t \mathbf{u}, \end{aligned}$$

de donde

$$\frac{\partial L}{\partial \mathbf{u}} = 2\mathbf{R}\mathbf{u} - 2\lambda\mathbf{u} - \mu\mathbf{u}_1 = \mathbf{0}. \quad (3.2)$$

Premultiplicando por $\mathbf{u}_1^t$:

$$\mathbf{u}_1^t \mathbf{R} \mathbf{u} = \lambda \mathbf{u}_1^t \mathbf{u} + \mu \mathbf{u}_1^t \mathbf{u}_1$$

y como

$$\mathbf{u}_1^t \mathbf{R} \mathbf{u} = \mathbf{u}^t \mathbf{R} \mathbf{u}_1 = \mathbf{u}^t (\lambda \mathbf{u}_1),$$

entonces

$$\lambda_1 \mathbf{u}_1^t \mathbf{u} = 0 + \mu,$$

de donde $\mu = 0$, ya que $\mathbf{u}_1^t \mathbf{u} = 0$. Por lo tanto, en la ecuación (3.2) se debe cumplir

$$2\mathbf{R}\mathbf{u} - 2\lambda\mathbf{u} = \mathbf{0}$$

es decir

$$\mathbf{R}\mathbf{u} = \lambda\mathbf{u}.$$

Esto significa que $\mathbf{u}$ también es vector propio de $\mathbf{R}$.

Como de nuevo $F(\mathbf{u}) = I_{\Delta_{\mathbf{u}}^\perp}(\mathcal{N}) = \lambda$ y este valor debe ser máximo, entonces λ es el segundo valor propio de $\mathbf{R}$ (dados en orden decreciente), denotado λ_2 . Así, el **segundo eje** del A.C.P. de $\mathcal{N}$ es el vector propio $\mathbf{u}_2$ de $\mathbf{R}$ asociado a λ_2 .

El **primer plano principal** H_1 está generado por los dos primeros ejes principales:

$$H_1 = \Delta_{\mathbf{u}_1} \oplus \Delta_{\mathbf{u}_2}$$

y tiene inercia $I_{H_1^\perp}(\mathcal{N}) = \lambda_1 + \lambda_2$.

Ejes siguientes

En general, siguiendo el mismo procedimiento anterior, los ejes principales del A.C.P. de la nube $\mathcal{N} = (\mathbf{X}, \mathbf{I}_p, \mathbf{D}_p)$ están generados por los vectores propios de la matriz de correlaciones $\mathbf{R}$ asociados a los valores propios de ésta, dados en orden decreciente:

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$$

asociados respectivamente a $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_p$. Seleccionando cualquier par de ejes principales, se puede generar un plano principal.

3.3.2 Diagonalización de $\mathbf{R}$

Obsérvese que la matriz $\mathbf{R}$ es simétrica y positiva, por lo que tiene p valores propios reales. Como es semidefinida positiva, estos valores propios son mayores o iguales que cero, pero su suma es p .

La solución al problema del A.C.P. se obtiene al diagonalizar la matriz $\mathbf{R}$. A continuación veremos esto con detalle sobre un ejemplo y daremos otros elementos importantes que se deben tener en cuenta.

Ejemplo 2 *Para el análisis de las notas escolares, estandarizaremos las variables (es decir, las materias), ya que a pesar de que todas están en la misma escala de 0 a 10, el nivel de dificultad de cada materia es diferente y es posible que cada profesor tenga distintos criterios de evaluación. La matriz de correlaciones de esta tabla es dada en la Tabla 3.2.*

	Matem.	Ciencias	Español	Historia	Educ. Fís.
Matemáticas	1.00	0.85	0.38	0.21	-0.79
Ciencias	0.85	1.00	-0.02	-0.02	-0.69
Español	0.38	-0.02	1.00	0.82	-0.37
Historia	0.21	-0.02	0.82	1.00	-0.51
Educ. Fís.	-0.79	-0.69	-0.37	-0.51	1.00

Tabla 3.2: Correlaciones entre las materias de la tabla de notas escolares.

Esta matriz de correlaciones tiene 5 valores propios positivos, que son:

$$\lambda_1 = 2.89, \lambda_2 = 1.63, \lambda_3 = 0.35, \lambda_4 = 0.12, \lambda_5 = 0.01.$$

3.3.3 Vectores principales

Al calcular los q valores propios mayores de la matriz $\mathbf{R}$, denotados $\lambda_1, \lambda_2, \dots, \lambda_q$ (ordenados en orden decreciente), se obtienen los llamados *vectores principales* $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_q$, donde

- $\mathbf{u}_1$ es un vector propio normado de $\mathbf{R}$ asociado al valor propio λ_1 ,
- $\mathbf{u}_2$ es un vector propio normado de $\mathbf{R}$ asociado al valor propio λ_2 ,
- $\vdots$
- $\mathbf{u}_k$ es un vector propio normado de $\mathbf{R}$ asociado al valor propio λ_k .

3.3.4 Componentes principales

Las componentes principales serán las variables asociadas a estos ejes principales. Así, en el A.C.P. normado se define:

- $\mathbf{c}^1 = \mathbf{X}\mathbf{u}_1$ la *primera componente principal*,
- $\mathbf{c}^2 = \mathbf{X}\mathbf{u}_2$ la *segunda componente principal*,
- $\vdots$
- $\mathbf{c}^k = \mathbf{X}\mathbf{u}_k$ la *k-ésima componente principal*, etc.

Por su definición, es claro que las componentes principales son combinación lineal de las variables originales (que son las columnas de $\mathbf{X}$). Por esta razón, su media también es cero.

Ejemplo 3 *El cálculo de las dos primeras componentes principales de la tabla de notas escolares da como resultado las componentes mostradas en la Tabla 3.3. Puede observarse que se trata efectivamente de nuevas variables, puesto que tienen valores para todos los estudiantes.*

3.3.5 Propiedades de las componentes principales

Las componentes principales tienen las siguientes propiedades:

1. Son centradas: $\bar{\mathbf{c}}^k = 0$, para todo $k = 1, \dots, p$.
2. $\mathbf{c}^k$ tiene varianza λ_k : $\text{var}(\mathbf{c}^k) = \lambda_k$, para todo $k = 1, \dots, p$.
3. Cada pareja de ellas tiene correlación cero: $\forall k, l : r(\mathbf{c}^k, \mathbf{c}^l) = 0$, para todo $k, l = 1, \dots, p$.

	Primera componente $\mathbf{c}^1$	Segunda componente $\mathbf{c}^2$
Lucía	-0.32	-1.77
Pedro	-0.67	1.64
Inés	-1.00	0.52
Luis	3.17	0.26
Andrés	0.49	-1.37
Ana	-1.71	1.02
Carlos	-0.07	-1.46
José	-2.01	1.28
Sonia	3.04	1.25
María	-0.92	-1.37

Tabla 3.3: Dos primeras componentes principales para la tabla de notas escolares.

La demostración de estas propiedades se deja para el ejercicio 1.

Ejemplo 4 *El lector puede comprobar que, efectivamente, para las componentes $\mathbf{c}^1$ y $\mathbf{c}^2$ de la Tabla 3.3, éstas tienen media cero y que tienen correlación nula. Además, que la varianza de $\mathbf{c}^1$ es 2.89 y la de $\mathbf{c}^2$ es 1.63, que también son los dos primeros valores propios de la matriz de correlaciones.*

3.4 Representaciones gráficas

Uno de los mayores usos que tiene el A.C.P. es a través de sus representaciones gráficas, pues las componentes principales permiten hacer una representación en pocas dimensiones de los hechos más sobresalientes de una tabla de datos.

Se obtendrán dos representaciones gráficas:

- los **planos principales**, formados por las coordenadas de los individuos en las componentes principales; aquí se pueden apreciar las principales agrupaciones y dispersiones de los individuos;

- los **círculos de correlaciones**, obtenidos a partir de las correlaciones entre las variables originales y las componentes principales normalizadas; aquí se pueden apreciar las agrupaciones de variables y su comportamiento respecto de las componentes principales.

Los dos gráficos anteriores son complementarios. En efecto, el círculo de correlaciones permite interpretar las posiciones relativas de los individuos. Así mismo, se puede apreciar para qué individuos las variables tienen grandes valores (por encima del promedio).

En cualquier interpretación de los gráficos, siempre debe tenerse presente que éstos no son más que simplificaciones de los hechos observados, por lo tanto cualquier hipótesis o conclusión que quiera formularse debe ser examinada a la vista de los datos originales para verificarla o descartarla.

3.4.1 Planos principales

El plano definido por $\mathbf{c}^1, \mathbf{c}^2$ es llamado el *primer plano principal*. En general, cualquier plano definido por dos componentes principales es llamado un *plano principal*.

También llamaremos *espacio principal* a un espacio generado por un cierto número de componentes principales.

Las coordenadas de un individuo sobre un plano principal se obtienen por la proyección del individuo sobre ese plano. El valor de esta proyección es dado precisamente por los valores correspondientes al individuo en las componentes principales. Entonces un individuo i se coloca en el plano principal por las coordenadas (c_i^1, c_i^2) donde $c_i^1 = \mathbf{x}_i^t \mathbf{u}_1$ y $c_i^2 = \mathbf{x}_i^t \mathbf{u}_2$ (donde el vector $\mathbf{x}_i$ está centrado y estandarizado para cada variable.)

Ejemplo 5 *En el ejemplo de las notas escolares, el primer plano principal está generado por $\mathbf{c}^1$ y $\mathbf{c}^2$ dados en la Tabla 3.3. El plano principal es dado en la Figura 3.2. En la Tabla 3.3 se puede ver que las coordenadas de Pedro son -0.67 y 1.64 , y las de Sonia son 3.04 y 1.25 , que son los valores usados para representarlos en el plano principal.*




Figura 3.2: Primer plano principal para la tabla de notas escolares, generado por las dos primeras componentes principales.

3.4.2 Círculos de correlaciones

Por su parte, la construcción del círculo de correlaciones se obtiene calculando el coeficiente de correlación lineal entre cada $\mathbf{x}^j$ y la componente principal $\mathbf{c}^k$ correspondiente:

Coordenada de la variable $\mathbf{x}^j$ en $\mathbf{c}^k$: $r(\mathbf{x}^j, \mathbf{c}^k)$.

En un plano, se puede entonces graficar como puntos las parejas de coordenadas calculadas de la forma anterior. Puede verse que ninguno de estos valores puede sobrepasar 1, ya que se trata de correlaciones. Por ello, en este plano se traza un círculo de radio 1. Además, cuanto más cercano a la circunferencia esté uno de los puntos mejor representada estará la variable correspondiente.

Ejemplo 6 *En la tabla de notas escolares, las correlaciones entre las variables originales y las dos primeras componentes principales son:*

	Componente 1 $\mathbf{c}^1$	Componente 2 $\mathbf{c}^2$
<i>Matemáticas</i>	−0.90	0.35
<i>Ciencias</i>	−0.72	0.65
<i>Español</i>	−0.61	−0.72
<i>Historia</i>	−0.60	−0.75
<i>Educación Física</i>	0.91	−0.12

Si siguiendo el procedimiento descrito anteriormente, se obtiene el círculo de correlaciones en la Figura 3.3. La interpretación del círculo y los resultados parciales que siguen, se hace en la página 60.

3.5 Índices de calidad

3.5.1 Calidad global

La proyección de los individuos sobre el plano principal da una imagen aproximada de las posiciones relativas de los puntos-individuos.

En vista de que las componentes principales son no correlacionadas, entonces son (geométricamente) perpendiculares, u ortogonales. Esto quiere decir que al calcular la inercia de la nube de puntos basta con sumar las varianzas de las componentes principales.

Ejemplo 7 *En la tabla de notas escolares, centrada y estandarizada, la inercia de la nube de puntos es 5 puesto que:*

$$\lambda_1 + \lambda_2 + \cdots + \lambda_5 = 5$$

En general, cuando se tenga una tabla centrada y estandarizada con p variables, entonces la inercia total de la nube de puntos es p , lo cual también coincide con la suma de los valores propios de la matriz de correlaciones.




Figura 3.3: Círculo de correlaciones para la tabla de notas escolares generado por las dos primeras componentes principales.

Ahora bien, la inercia de la nube proyectada sobre el primer plano principal se calculará usando las coordenadas de los puntos en ese plano. Si se hace el cálculo de esta inercia se puede comprobar que es igual a la suma de los valores propios correspondientes a las componentes principales.

Ejemplo 8 *La inercia de la nube de puntos-estudiantes proyectada en el primer plano principal es:*

$$\lambda_1 + \lambda_2 = 2.89 + 1.63 = 4.52$$

Así, la calidad de la representación de la nube de puntos sobre el primer plano principal se puede medir, en forma de porcentaje, por el cociente de

la inercia de la nube proyectada entre la inercia total:

$$\text{Calidad global: } \frac{\lambda_1 + \lambda_2}{I(\mathcal{N})} \times 100$$

donde $I(\mathcal{N})$ es la inercia total de la nube, que es igual a la suma de todos los valores propios de V . En el caso estandarizado, vimos que esta inercia total vale p , el número de variables observadas.

En particular, el porcentaje de inercia explicado por una sola componente principal $\mathbf{c}^k$ es:

$$\frac{\lambda_k}{I(\mathcal{N})}$$

Más generalmente, si se retienen q componentes principales, ellas resumen un porcentaje de inercia dado por:

$$\frac{\lambda_1 + \lambda_2 + \dots + \lambda_q}{I(\mathcal{N})} \times 100$$

de la inercia total de la nube de puntos.

Ejemplo 9 *En la tabla de notas escolares, el porcentaje de inercia explicado por cada eje principal es (indicamos entre paréntesis el porcentaje acumulado):*

	Valor propio	Porcentaje de inercia	Inercia acumulada
1	2.89	57.86%	(57.86%)
2	1.63	32.57%	(90.44%)
3	0.35	6.93%	(97.37%)
4	0.12	2.45%	(99.82%)
5	0.01	0.18%	(100.00%)

Así, el porcentaje de inercia explicado por el primer plano principal es de 90.44%.

3.5.2 Calidad particular

Calidad de representación de cada individuo

Las coordenadas de los individuos representados en el plano principal se obtienen por proyección. Por lo tanto, es de esperar que esa proyección sea

una fiel representación del individuo si “no se pierde mucho” al proyectar, es decir, si la distancia entre el punto original y el punto proyectado es pequeña.

En la Figura 3.4 ilustramos esta situación. Se tienen dos puntos en la nube original, los puntos **a** y **b**. Estos se proyectan sobre el plano principal en los puntos $\text{Pr}(\mathbf{a})$ y $\text{Pr}(\mathbf{b})$, respectivamente. En la figura se puede apreciar que $\text{Pr}(\mathbf{a})$ y **a** están relativamente cercanos, por lo que $\text{Pr}(\mathbf{a})$ puede considerarse como una buena representación de **a**. Sin embargo, $\text{Pr}(\mathbf{b})$ y **b** son muy diferentes, por lo que la representación $\text{Pr}(\mathbf{b})$ de **b** es mala.




Figura 3.4: Proyección de dos puntos individuos en el plano principal.

Esta buena o mala representación se puede cuantificar fácilmente con la ayuda de los cosenos de los ángulos formados por ciertos vectores. En efecto, el ángulo α entre el vector **a** y el vector $\text{Pr}(\mathbf{a})$ es pequeño, por lo que su coseno es cercano a 1. Por su parte, el ángulo β entre el vector **b** y el vector $\text{Pr}(\mathbf{b})$ es muy abierto, casi de 90 grados, por lo que su coseno es cercano a 0.

Estos cosenos servirán entonces para medir la calidad de la representación de un individuo sobre el plano principal. Así, siguiendo la no-

tación de la Figura 3.4 tenemos:

$$\cos \alpha = \frac{\|\text{Pr}(\mathbf{a})\|}{\|\mathbf{a}\|}$$

Elevando al cuadrado:

$$\cos^2 \alpha = \frac{\|\text{Pr}(\mathbf{a})\|^2}{\|\mathbf{a}\|^2} \quad (3.3)$$

Pero aún hay más: el cálculo del coseno al cuadrado del ángulo formado entre un vector individuo y su representación en un espacio principal se puede calcular sumando los cosenos al cuadrado que forma ese vector individuo con cada una de las componentes principales que forman el espacio principal. En efecto, debido al teorema de Pitágoras, si $\text{Pr}_{\mathbf{c}^1}(\mathbf{a})$ es la proyección de $\mathbf{a}$ sobre la componente $\mathbf{c}^1$ y $\text{Pr}_{\mathbf{c}^2}(\mathbf{a})$ es la proyección de $\mathbf{a}$ sobre la componente $\mathbf{c}^2$, entonces $\|\text{Pr}(\mathbf{a})\|^2 = \|\text{Pr}_{\mathbf{c}^1}(\mathbf{a})\|^2 + \|\text{Pr}_{\mathbf{c}^2}(\mathbf{a})\|^2$, por lo que:

$$\cos^2 \alpha = \frac{\|\text{Pr}_{\mathbf{c}^1}(\mathbf{a})\|^2 + \|\text{Pr}_{\mathbf{c}^2}(\mathbf{a})\|^2}{\|\mathbf{a}\|^2}$$

Si α_1 es el ángulo que forma $\mathbf{a}$ con $\mathbf{c}^1$ y α_2 el que forma con $\mathbf{c}^2$, entonces:

$$\begin{aligned} \cos^2 \alpha_1 &= \frac{\|\text{Pr}_{\mathbf{c}^1}(\mathbf{a})\|^2}{\|\mathbf{a}\|^2} \\ \cos^2 \alpha_2 &= \frac{\|\text{Pr}_{\mathbf{c}^2}(\mathbf{a})\|^2}{\|\mathbf{a}\|^2} \end{aligned}$$

De esta forma, se obtiene la siguiente descomposición para el coseno cuadrado de α (ver Figura 3.5):

$$\cos^2 \alpha = \cos^2 \alpha_1 + \cos^2 \alpha_2. \quad (3.4)$$

Según la igualdad (3.4), se puede medir la calidad de la representación en cada componente principal y sumarlas para obtener la calidad total en un plano principal. Este mismo tipo de suma se puede hacer para obtener la calidad de la representación de los individuos en un espacio principal de dimensión mayor que 2.

Ejemplo 10 *Para la tabla de notas escolares, en la Tabla 3.4 se muestran los cosenos cuadrados de los ángulos entre los puntos-individuos en el espacio $\mathbb{R}^5$ con su representación en el primer plano principal.*




Figura 3.5: Descomposición del coseno cuadrado según el teorema de Pitágoras.

Calidad de representación de cada variable

La calidad de la representación de una variable sobre el círculo de correlaciones, será también medida con el cuadrado del coseno del ángulo entre la variable y su proyección. Ahora bien, recuérdese que entre variables, el coseno es igual a una correlación, por lo que serán las correlaciones las que midan la calidad de la representación de las variables:

$$\|\text{Pr}(\mathbf{x})\|^2 = r^2(\mathbf{x}, \mathbf{c}^1) + r^2(\mathbf{x}, \mathbf{c}^2).$$

Esta suma de correlaciones al cuadrado se conoce con el nombre de *comunalidad*.

3.5.3 Número de componentes principales

Un asunto delicado es el de la decisión del número de componentes principales, o ejes, que se deben escoger en un A.C.P. Para ello hay algunos criterios que el usuario puede seguir para tomar la decisión. Estos criterios son:

- El usuario fija un porcentaje de inercia P que considera como mínimo para que el A.C.P. sea satisfactorio, entonces tomará el número

	$\cos^2 1$	$\cos^2 2$	Calidad plano (1,2)
Lucía	2.23	67.04	69.27
Pedro	13.99	84.84	98.83
Inés	51.45	13.61	65.06
Luis	93.69	0.64	94.33
Andrés	8.41	65.64	74.05
Ana	73.27	26.20	99.47
Carlos	0.19	88.61	88.80
José	67.36	27.09	94.45
Sonia	80.88	13.76	94.64
María	30.86	67.79	98.65

Tabla 3.4: Cosenos cuadrados y calidad de la representación para la tabla de notas escolares.

de ejes que sea necesario hasta que la inercia explicada por ellos sobrepase P . Por ejemplo, este porcentaje puede ser fijado en $P = 70\%$, o en $P = 80\%$.

- Si los datos están estandarizados, entonces se sugiere guardar todas las componentes principales asociadas a valores propios mayores o iguales a 1. En efecto, una componente principal tiene por varianza el valor propio correspondiente, y las variables originales -en el caso estandarizado- tienen varianza 1. Este criterio entonces dice que se deben guardar aquellos ejes cuya varianza sea más importante que la varianza de las variables originales.

Ejemplo 11 *Para la tabla de notas escolares se escogerán 2 ejes, en vista de que se han estandarizado los datos y solamente los dos primeros valores propios son mayores que 1.*

3.6 Interpretación de los resultados

El asunto más importante de un Análisis en Componentes Principales es la interpretación de los resultados. A pesar de que, como en toda técnica estadística, en la interpretación hay mucho de arte y la experiencia juega

un papel importante, se pueden sugerir algunas directrices que pueden ayudar a encontrar los hechos más sobresalientes en los resultados.

En primer lugar, se debe tratar de *etiquetar* a las componentes principales. Para ello, se usarán las medidas de calidad de representación de los individuos y de las variables. Se usan generalmente dos criterios:

- Un eje tendrá mucha relación con aquellos individuos cuyo coseno cuadrado sea superior o igual al 50%. Estos individuos están particularmente bien representados sobre ese eje.
- Una componente principal puede ser interpretada a partir de las variables originales que tengan con ella una correlación mayor o igual a 0.7.

Interpretación de los resultados para la tabla de notas escolares

Consulta de las correlaciones Puede apreciarse que todas las variables excepto Educación Física tienen correlación negativa con la primera componente principal; además todas las correlaciones con esta componente son relativamente altas en valor absoluto, especialmente para Matemática y Educación Física. Por lo tanto, parece ser que esta primera componente opone a las variables “de estudio” a la variable de “esfuerzo físico”. Esta oposición se aprecia claramente sobre el círculo de correlaciones (Figura 3.3).

Por su parte, la segunda componente principal tiene altas correlaciones (en valor absoluto) únicamente con las variables “de estudio”, y esta correlación es positiva con las “científicas” (Matemática y Ciencias) y negativa con las “humanísticas” (Historia y Español). Por lo tanto, esta segunda componente parece oponer a las variables científicas de las humanísticas, como puede apreciarse sobre el círculo de correlaciones.

Podemos por lo tanto etiquetar a la primera componente principal como “naturaleza de la materia” y la segunda “tipo de materias”.

Examen de las agrupaciones en el plano Sobre el primer plano principal podemos observar al lado derecho a los estudiantes (Sonia y Luis) que tienen buenas notas en Educación Física pero muy malas notas en

las otras materias (ver la tabla de datos, Tabla 3.1). Estos estudiantes están del lado que corresponde, en el círculo de correlaciones, precisamente a Educación Física, lado que es opuesto a las materias académicas. Esto significa que estos estudiantes tienen notas encima del promedio en Educación Física, y por debajo del promedio en las demás materias.

En el segundo cuadrante están Pedro, Inés, Ana y José, que son los estudiantes con mejores notas en Ciencias y Matemáticas. Este cuadrante corresponde al sector del círculo de correlaciones en que se encuentran precisamente las variables Ciencias y Matemáticas. Por ello, se puede decir que son los estudiantes con notas superiores al promedio en esas materias. Además, están en una posición “perpendicular” a las materias humanísticas, por lo que se puede decir que en las materias de Historia y Español tienen notas como el promedio.

En la parte inferior del plano están María, Lucía, Carlos y Andrés, que tienen las mejores notas en Español e Historia, con notas cerca o por debajo del promedio en las científicas; los tres últimos están además cerca del eje vertical lo que se explica porque sus notas en Educación Física son cercanas al promedio general en esa materia (7.42), siendo que ésta está muy correlacionada con la primera componente principal.

Los comentarios anteriores son coherentes con lo observado sobre el círculo de correlaciones.

Examen de los cosenos cuadrados Los cosenos cuadrados de los individuos sobre los dos ejes muestran que todos tienen una muy buena representación sobre el plano principal (representaciones superiores al 69%).

Los estudiantes más importantes para la explicación de la primera componente principal son: Luis y Sonia (debido a su fuerte nota en Educación Física), y en menor grado Inés, Ana y José (los “científicos”, con notas bajas en Ed. Física). Los estudiantes que mejor explican a la segunda componente principal son: Lucía, Pedro, Andrés, Carlos y María, que tienen buenas notas en las materias académicas (Pedro en las científicas, y los demás en las Humanísticas), y que además tienen una nota promedio en Educación Física.

Al lector interesado en una guía completa para la interpretación de los resultados de un A.C.P., se le sugiere consultar el capítulo 9 del libro de

B. Escofier & J. Pagès [29].

La interpretación de los ejes también puede ser completada con la ayuda de los elementos suplementarios, como se explica en la siguiente sección.

3.7 Elementos suplementarios

3.7.1 Individuos suplementarios

El A.C.P. permite graficar también individuos que no intervienen en el análisis, llamados *individuos suplementarios*. Por alguna razón, uno puede desear tener la representación en el plano principal de algún individuo que no participa de los cálculos, ya sea porque los datos para él son incompletos, o bien porque viene de otro contexto pero puede ser interesante proyectarlo (técnicamente, puede ponerse peso cero). Puede por ejemplo tratarse de un punto atípico, o de naturaleza ligeramente diferente a los demás. Entonces la matriz de correlaciones se calcula sin que los individuos suplementarios participen del cálculo de esas correlaciones.

Su proyección sobre el plano principal puede hacerse ya que está en la tabla **X**. En caso de que sea un individuo calculado (por ejemplo, un punto promedio para alguna modalidad), entonces la proyección puede ser determinada usando los ejes principales.

Sea $\mathbf{x}_i$ el individuo suplementario que se quiere proyectar. Antes de calcular sus coordenadas, se debe hacer la operación de centraje y estandarización sobre este vector. Esto es, a cada componente se le debe restar la media calculada para las variables, tomando en cuenta que esta media es únicamente para los individuos que participaron activamente en el análisis; luego se divide cada componente entre la desviación estándar, de nuevo calculada con las variables activas. Así, el nuevo vector centrado y estandarizado $\mathbf{x}_i$ se proyecta sobre el plano principal (1, 2) de la siguiente manera, siendo $\mathbf{u}_1$ y $\mathbf{u}_2$ los dos primeros vectores propios de **R**:

$$\text{Pr}_{\mathbf{u}_1}(\mathbf{x}_i)\mathbf{x}_i^t\mathbf{u}_1, \quad \text{Pr}_{\mathbf{u}_2}(\mathbf{x}_i)\mathbf{x}_i^t\mathbf{u}_2.$$

Ejemplo 12 *El uso de individuos suplementarios en A.C.P. es muy común*

en las encuestas donde se entrevista a la gente, y se quiere tener por ejemplo la representación del “hombre” promedio y de la “mujer” promedio. Se podrá ver una aplicación de este concepto en el ejemplo mostrado en la página 80.

3.7.2 Variables suplementarias

De manera análoga, uno puede desear la representación sobre el círculo de correlaciones de *variables suplementarias*, que no participen del análisis (no forman parte de la matriz $\mathbf{V}$). Como pertenecen al espacio de variables $\mathbb{R}^n$, basta con calcular su correlación con las componentes principales normalizadas para obtener su representación sobre el círculo de correlaciones.

3.8 Casos de aplicación

3.8.1 Análisis de la concentración de CO_2

Descripción del problema

Se dispone de un conjunto de mediciones de la radiación solar en una serie de estaciones meteorológicas. Cada estación está descrita por su latitud, ya sea Norte o Sur. Se supone que los polos reciben la menor radiación, y el Ecuador la mayor cantidad en promedio. Ahora bien, los hemisferios geográficos son asimétricos, por lo que se habla de hemisferios climáticos, siendo el Hemisferio Sur mucho más grande que el Hemisferio Norte. La línea que delimita la frontera entre ambos hemisferios está asociada a la Zona de Convergencia Intertropical, la cual tiene un comportamiento anual en función de la longitud. Mientras el Hemisferio Sur se caracteriza por poseer enormes superficies acuosas y criosféricas, el Hemisferio Norte posee mayores superficies continentales. En el Hemisferio Norte, se tiene una mayor concentración de CO_2 , sobre todo debido a la influencia del ser humano.

A continuación se analiza la concentración de CO_2 en 35 estaciones de observación, de distintos lugares del mundo, a lo largo de 5 años (de 1988 a 1992). La información es recogida mes a mes, por lo que se tienen 60

medidas para cada estación [2]. Los datos fueron suministrados por *Carbon Dioxide Information Analysis Center*, Oak Ridge (Tennessee, U.S.A). A los datos originales les llamaremos *datos sin filtrado*, para distinguirlos de los *datos filtrados* que se producen después de un proceso que consiste en eliminar el efecto de crecimiento observado en la concentración de CO_2 ; este efecto de crecimiento es la tendencia calculada mediante una regresión lineal simple, la cual es restada al valor observado.

Resultados

ACP de los datos sin filtrado. Se aplicará el Análisis en Componentes Principales (ACP) para obtener una proyección en pocas dimensiones de la tabla de datos 60×35 que se analiza, con el fin de ver mejor las principales asociaciones entre estaciones, entre los distintos instantes, así como estudiar las principales relaciones que pueden existir entre las estaciones y las épocas de medición.

Los dos primeros ejes del ACP con los datos sin filtrado contienen el 89% de la varianza total de los datos. En la Figura 3.6 se muestra la posición de los instantes en el plano principal que generan las dos primeras componentes principales. El primer cuadrante agrupa los datos de los años 88 y 89, y se opone por el origen al tercer cuadrante que agrupa principalmente a los datos de los años 92 y 91. Los datos del año 90 son intermedios. El segundo cuadrante y el cuarto contienen una componente ficticia que opone los meses de valores altos (en el segundo cuadrante: febrero, marzo, abril, mayo) a los meses de valores bajos (en el cuarto cuadrante: agosto, setiembre, octubre).

La Figura 3.7 muestra el círculo de correlaciones generado por las dos primeras componentes principales del ACP. Las coordenadas de los puntos son las correlaciones con las componentes principales, por lo que el gráfico muestra aproximadamente las correlaciones entre todas las estaciones de observación al mismo tiempo. Se debe tomar en cuenta que cada punto genera un vector desde el origen hasta él, de modo que la correlación entre dos estaciones se interpreta como el coseno del ángulo que hay entre los dos vectores correspondientes. Esta figura muestra un claro efecto de talla: la primera componente principal está fuertemente correlacionada con las estaciones que tienen mayor concentración de CO_2 . De hecho, todas las estaciones tienen el mismo signo de correlación con la primera




Figura 3.6: Plano principal generado por las dos primeras componentes principales del ACP de los datos sin filtrado.

componente principal, mientras que es la segunda componente la que hace la diferencia entre las estaciones ubicadas en el hemisferio norte y en el hemisferio sur, con una zona intermedia que corresponde a las estaciones más cercanas al Ecuador. De este comportamiento general, únicamente escapan las estaciones 47.28 y 47.55, y más ligeramente -04.40 .

Aún si no mostramos la figura que contiene a la tercera componente principal, ésta muestra claramente la oposición que existe entre ciertos meses (abril, mayo, junio por un lado, y setiembre, octubre, noviembre, por el otro), para todos los años. Sin embargo, también esta tercera componente revela el comportamiento diferente que poseen las estaciones 47.55 y 47.28, quienes tienen tendencia a presentar mayores concentraciones de CO_2 en los meses de setiembre a noviembre que el resto de las estaciones.

En vista de que este primer ACP mostró que en gran parte la varianza es explicada por el transcurso de los años, lo cual es lógico simplemente porque la concentración en general crece conforme pasa el tiempo, se decidió filtrar los datos realizando una regresión lineal simple para cada estación y restar a los datos crudos la estimación con esa regresión; este procedimiento tiene como fin eliminar la tendencia creciente que presentan todos los datos a través del tiempo. Al resultado de este procedimiento le llamaremos *datos filtrados*.

ACP de los datos con filtrado. Con los datos filtrados se efectuó entonces un segundo ACP. Los primeros tres valores propios de la matriz de correlaciones son 21.1, 4.5 y 3.7, explicando entre ellos el 84% de la inercia total:

Componente	Valor propio	Inercia explicada	Inercia acumulada
1	21.1	60%	60%
2	4.5	13%	73%
3	3.7	11%	84%
4	1.3	4%	88%

En la Figura 3.8 se muestra el círculo de correlaciones generado por las dos primeras componentes principales. La primera componente principal hace una clara oposición entre el hemisferio norte (junto con algunos puntos ecuatoriales) al lado derecho del círculo de correlaciones, y el hemisferio sur, al lado izquierdo. Es curiosa la posición de -07.55 , que es casi ecuatorial, pero que aparece junto al polo sur.




Figura 3.7: Círculo de correlaciones generado por las dos primeras componentes principales del ACP de los datos sin filtrado.




Figura 3.8: Círculo de correlaciones generado por las dos primeras componentes principales del ACP de los datos filtrados.

Las posiciones relativas de los puntos en el círculo de correlaciones (Figura 3.8) y el plano principal (Figura 3.9) anteriores, muestran que en el hemisferio norte hay una fuerte concentración de CO_2 en los meses del final del invierno e inicio de la primavera boreal, mientras que esta fuerte concentración se da en el hemisferio sur en las respectivas estaciones australes. El comportamiento particular de los meses de May-88, Abr-88, Ene-89 y Feb-89, se debe a una concentración anormalmente alta en enero y febrero de 1989 en las estaciones -10.00 , -14.15 y -15.00 , y más bien baja en los meses de abril y mayo de 1988 en esas estaciones.

La tercera componente principal, no graficada aquí, muestra de nuevo el comportamiento particular de las estaciones 47.28 y 47.55, las cuales se distinguen de todo el resto de estaciones. Estas estaciones parecen tener un comportamiento singular en los meses de enero y febrero, durante los años 89, 90 y 91. El comportamiento ligeramente diferente de la estación -04.40 aparece de nuevo (esta estación tiende a parecerse a 47.28 y 47.55, más que el resto de las estaciones).

3.8.2 Análisis de fabes asturianas

Se ha estudiado la variabilidad genética de diversos tipos de fabes asturianas (frijol blanco de la región española Asturias). Un estudio preliminar [71] basado en 98 variedades locales de fabes asturianas, seleccionó cinco variedades:

1. V95: Címera,
2. V100: Seronda,
3. V105: Bomafema,
4. V136: Collacia, y
5. V143: Andecha.

De las 49 variables originalmente medidas, se escogieron las siguientes 18 —todas cuantitativas excepto las dos últimas que son ordinales— debido a que presentaban mayor variabilidad [72]:

- Dur Flor: Duración de floración (días)

- LFOL: Longitud de foliolo (cms)
- AFOL: Ancho de foliolo (cms)
- LFLO: Longitud de flor (cms)
- LBRA: Longitud de bractia (cms)
- LOCA: Longitud de cáliz (cms)
- LINF: Longitud de inflorescencia (cms)
- LOPE: Longitud del peciolo (cms)
- NF/I: Número de flores por inflorescencia
- NV/P: Número de vainas por planta
- NG/V: Número de granos por vaina
- LSE: Longitud de semilla (cms)
- ASE: Ancho de semilla (cms)
- LVA: Longitud de vaina (cms)
- AVA: Ancho de vaina (cms)
- colhoj: Color de hoja (escala de 1 a 5, con 1: claro, 5: oscuro)
- hebr: La hebra de la vaina (escala de 0 a 3, con 0: nada, 3: mucha)
- DITA: Diámetro del tallo (cms).

Para cada variedad se seleccionan 10 ejemplares, y para cada uno de ellos se toma un caracter vegetativo, reproductivo o de estructura, según sea el caso (flor, hoja, vaina,...) En la Tabla 3.5 se presenta la tabla de los promedios para cada variedad, promedios calculados para los 10 ejemplares de cada variedad. La Tabla 3.6 muestra las estadísticas descriptivas básicas para las fabes asturianas.

Al calcular las correlaciones entre las variables, se obtiene la matriz presentada en la Tabla 3.7.

Al efectuar el Análisis en Componentes Principales normado sobre la tabla de datos estandarizada, se obtienen cuatro valores propios mayores

Variable	Variedad				
	V95	V100	V105	V136	V143
DurFlor	23.00	21.00	21.00	22.00	25.00
LFOL	13.49	13.46	10.33	13.27	10.98
AFOL	10.69	11.23	8.17	10.58	8.93
LFLO	2.12	2.02	2.00	2.35	2.33
LBRA	0.77	0.72	0.7	0.74	0.71
LOCA	0.59	0.54	0.51	0.68	0.6
LINF	8.16	6.81	6.59	6.37	5.6
LOPE	1.23	0.69	1.35	1.11	1.18
NF/I	5.26	4.18	4.43	4.67	3.6
NV/P	23.3	22.90	17.1	32.2	24.2
NG/V	4.11	4.00	2.9	3.8	3.5
LSE	2.26	2.27	2.33	2.2	2.23
ASE	1	0.98	1.01	0.97	0.96
LVA	18.55	19.63	17.67	18.48	18.66
AVA	1.54	1.46	1.47	1.49	1.38
colhoj	2.8	2.3	2.4	3.5	2.6
hebr	5.8	6.8	6.8	6.5	6.8
DITA	0.98	0.89	0.85	0.86	0.9

Tabla 3.5: Tabla de datos para las fabes asturianas.

Variable	Media	Desv. Est.	Varianza	CV	Max	Min
Dur Flor	22.40	1.50	2.24	0.07%	25.00	21.00
LFOL	12.31	1.37	1.87	0.11%	13.49	10.33
AFOL	9.92	1.17	1.36	0.12%	11.23	8.17
LFLO	2.16	0.15	0.02	0.07%	2.35	2.00
LBRA	0.73	0.02	0.00	0.03%	0.77	0.70
LOCA	0.58	0.06	0.00	0.10%	0.68	0.51
LINF	6.71	0.83	0.69	0.12%	8.16	5.60
LOPE	1.11	0.23	0.05	0.20%	1.35	0.69
NF/I	4.43	0.55	0.30	0.12%	5.26	3.60
NV/P	23.94	4.83	23.31	0.20%	32.20	17.10
NG/V	3.66	0.43	0.19	0.12%	4.11	2.90
LSE	2.26	0.04	0.00	0.02%	2.33	2.20
ASE	0.98	0.02	0.00	0.02%	1.01	0.96
LVA	18.60	0.62	0.39	0.03%	19.63	17.67
AVA	1.47	0.05	0.00	0.04%	1.54	1.38
colhoj	2.72	0.43	0.18	0.16%	3.50	2.30
hebr	6.54	0.39	0.15	0.06%	6.80	5.80
DITA	0.90	0.05	0.00	0.05%	0.98	0.85

Tabla 3.6: Principales estadísticas univariadas para las fabes asturianas.

	Dur Flor	LFOL	AFOL	LFLO	LBRA	LOCA	LINF	LOPE	NF/I
Dur Flor	1.00	-0.19	-0.20	0.68	0.13	0.40	-0.30	0.30	-0.34
LFOL	-0.19	1.00	0.98	0.06	0.77	0.44	0.56	-0.59	0.54
AFOL	-0.20	0.98	1.00	0.03	0.67	0.37	0.48	-0.72	0.41
LFLO	0.68	0.06	0.03	1.00	0.17	0.89	-0.49	0.16	-0.23
LBRA	0.13	0.77	0.67	0.17	1.00	0.49	0.77	0.02	0.81
LOCA	0.40	0.44	0.37	0.89	0.49	1.00	-0.15	0.04	0.16
LINF	-0.30	0.56	0.48	-0.49	0.77	-0.15	1.00	0.03	0.88
LOPE	0.30	-0.59	-0.72	0.16	0.02	0.04	0.03	1.00	0.24
NF/I	-0.34	0.54	0.41	-0.23	0.81	0.16	0.88	0.24	1.00
NV/P	0.22	0.58	0.54	0.80	0.45	0.96	-0.16	-0.23	0.11
NG/V	0.12	0.94	0.94	0.17	0.78	0.43	0.50	-0.58	0.38
LSE	-0.51	-0.49	-0.47	-0.89	-0.41	-0.94	0.25	0.21	0.07
ASE	-0.56	-0.15	-0.22	-0.79	0.10	-0.63	0.66	0.39	0.61
LVA	0.01	0.65	0.77	-0.01	0.17	0.07	0.04	-0.94	-0.22
AVA	-0.48	0.59	0.47	-0.33	0.76	0.09	0.89	0.11	0.99
colhoj	0.14	0.40	0.28	0.74	0.51	0.93	-0.01	0.21	0.39
hebr	-0.17	-0.56	-0.43	-0.04	-0.95	-0.31	-0.84	-0.27	-0.85
DITA	0.43	0.46	0.41	-0.04	0.77	0.06	0.70	0.04	0.47
	NV/P	NG/V	LSE	ASE	LVA	AVA	colhoj	hebr	DITA
Dur Flor	0.22	0.12	-0.51	-0.56	0.01	-0.48	0.14	-0.17	0.43
LFOL	0.58	0.94	-0.49	-0.15	0.65	0.59	0.40	-0.56	0.46
AFOL	0.54	0.94	-0.47	-0.22	0.77	0.47	0.28	-0.43	0.41
LFLO	0.80	0.17	-0.89	-0.79	-0.01	-0.33	0.74	-0.04	-0.04
LBRA	0.45	0.78	-0.41	0.10	0.17	0.76	0.51	-0.95	0.77
LOCA	0.96	0.43	-0.94	-0.63	0.07	0.09	0.93	-0.31	0.06
LINF	-0.16	0.50	0.25	0.66	0.04	0.89	-0.01	-0.84	0.70
LOPE	-0.23	-0.58	0.21	0.39	-0.94	0.11	0.21	-0.27	0.04
NF/I	0.11	0.38	0.07	0.61	-0.22	0.99	0.39	-0.85	0.47
NV/P	1.00	0.54	-0.94	-0.68	0.29	0.09	0.87	-0.20	-0.03
NG/V	0.54	1.00	-0.57	-0.30	0.74	0.40	0.29	-0.58	0.65
LSE	-0.94	-0.57	1.00	0.83	-0.36	0.12	-0.75	0.18	-0.12
ASE	-0.68	-0.30	0.83	1.00	-0.50	0.63	-0.34	-0.33	0.14
LVA	0.29	0.74	-0.36	-0.50	1.00	-0.13	-0.18	0.07	0.26
AVA	0.09	0.40	0.12	0.63	-0.13	1.00	0.33	-0.78	0.41
colhoj	0.87	0.29	-0.75	-0.34	-0.18	0.33	1.00	-0.38	-0.05
hebr	-0.20	-0.58	0.18	-0.33	0.07	-0.78	-0.38	1.00	-0.82
DITA	-0.03	0.65	-0.12	0.14	0.26	0.41	-0.05	-0.82	1.00

Tabla 3.7: Matriz de correlaciones para las fabes asturianas.

que uno, como se muestra en la Tabla 3.8 junto con la inercias explicadas y los porcentajes de inercia de cada valor propio. La Tabla 3.9 muestra las cuatro primeras componentes principales. Las correlaciones entre las variables del análisis y las primeras cuatro componentes principales se muestran en la Tabla 3.10.

Componente	Valor propio	% inercia	% inercia acumulada
1	7.37	40.9%	40.9%
2	5.56	30.9%	71.9%
3	3.29	18.3%	90.1%
4	1.78	9.9%	100.0%
5	0.00	0.0%	100.0%

Tabla 3.8: Valores propios y porcentajes de inercia para las fabes asturianas.

	Componente principal				Cosenos cuadrados			
	c^1	c^2	c^3	c^4	c^1	c^2	c^3	c^4
V95	3.20	2.82	0.99	1.26	0.49	0.88	0.92	1.00
V100	0.23	0.40	-3.59	-0.32	0.00	0.02	0.99	1.00
V105	-4.25	2.16	1.07	-0.81	0.74	0.93	0.97	1.00
V136	2.43	-2.13	1.16	-1.87	0.39	0.68	0.77	1.00
V143	-1.62	-3.24	0.37	1.75	0.16	0.80	0.81	1.00

Tabla 3.9: Fabes asturianas: cuatro primeras componentes principales y cosenos cuadrados de los individuos.

La tabla 3.9 muestra además, en una segunda sección, los cosenos cuadrados acumulados de las variedades con las cuatro componentes principales, valor conocido como *comunalidad*. Puede verse que las dos primeras componentes principales representan muy bien a las variedades V95, V105, V136 y V143, pero que es necesaria la tercera componente principal para representar a V100.

El plano principal entre la primera y la segunda componentes principales, así como el círculo de correlaciones asociado, se muestran en la Figura 3.10. Puede notarse que la primera componente principal hace una oposición entre las variedades V95 y V136 con V105, mientras que la segunda componente está fuertemente asociada a V143, que junto con V136 se opone a V95. Los grandes valores de semilla para V105 y su bajo rendimiento explican en parte esto.

	c^1	c^2	c^3	c^4
DurFlor	0.12	-0.54	0.34	0.76
LFOL	0.91	0.11	-0.36	-0.15
AFOL	0.85	0.05	-0.51	-0.13
LFLO	0.35	-0.83	0.42	0.07
LBRA	0.92	0.30	0.21	0.15
LOCA	0.67	-0.61	0.38	-0.18
LINF	0.54	0.83	0.02	0.11
LOPE	-0.28	0.17	0.93	0.14
NF/I	0.61	0.68	0.34	-0.21
NV/P	0.71	-0.62	0.12	-0.31
NG/V	0.91	0.00	-0.38	0.18
LSE	-0.66	0.74	-0.11	0.00
ASE	-0.22	0.95	0.20	-0.12
LVA	0.43	-0.23	-0.86	0.17
AVA	0.59	0.72	0.20	-0.30
colhoj	0.62	-0.38	0.54	-0.41
hebr	-0.75	-0.48	-0.38	-0.27
DITA	0.59	0.37	0.04	0.72

Tabla 3.10: Fabes asturianas: correlaciones principales (con negrita se han destacado los valores mayores para cada componente principal).

En la Figura 3.11 se muestran el plano principal y el círculo de correlaciones entre la primera y la tercera componentes principales. Se aprecia en el círculo una fuerte contraposición entre las longitudes de peciolo y vaina, siendo la V100 la que más explica esta relación con gran longitud de vaina y corta longitud de peciolo.

En la Figura 3.12 se muestran el plano principal y el círculo de correlaciones entre la primera y la cuarta componentes principales. En el círculo se observa la asociación de las duración de la flor y diámetro del tallo con la cuarta componente principal, con grandes valores para V95.

Con base en los resultados anteriores, podemos interpretar las componentes principales de la siguiente forma:

- La primera componente principal, con un 40.9% de inercia, es un componente de *Rendimientos* y *foliolos* muy correlacionados con los tamaños de los foliolos y de longitud de brateola, y negativamente con el tamaño de semilla y el número de hebras.

- La segunda componente principal (con 30.9% de la inercia) trata del tamaño de semilla, asociado con la longitud de inflorescencia y el ancho de vaina, y negativamente con la longitud de flor.
- La tercera componente principal (con 18.3% de la inercia) opone la longitud de pedicelo con la longitud de vaina.
- La cuarta componente explica cerca del 10% de la inercia y se refiere a estructura y ciclo, y presenta cierta relación con el rendimiento.

El A.C.P. muestra la variabilidad existente entre las cinco variedades utilizadas como base para la denominación específica de Faba Granja Asturiana. El A.C.P. permitió resumir las 18 variables en solo 4 componentes: 1) rendimiento y foliolos, 2) tamaño de semilla, 3) longitud de pedicelo y vaina, y 4) estructura y ciclo.




Figura 3.10: Fabes asturianas: plano principal y círculo de correlaciones 1-2.




Figura 3.11: Fabes asturianas: plano principal y círculo de correlaciones 1-3.




Figura 3.12: Fabes asturianas: plano principal y círculo de correlaciones 1-4.

3.8.3 Encuestas de opinión pública

El A.C.P. también puede aplicarse al caso en que se tengan solamente variables cualitativas ordinales. El caso típico es el de las encuestas, en que se tienen las siguientes modalidades a las preguntas formuladas: totalmente de acuerdo, de acuerdo, indeciso, en desacuerdo, totalmente en desacuerdo.

En efecto, en este caso las modalidades se pueden condicionar del 1 al 5 y entonces se pueden calcular las correlaciones entre las distintas variables.

Puede consultarse un tratamiento exhaustivo de este tipo de tablas de datos, en [64], así como en los artículos de J.P. Pagès [62], C. Arce, N. Garita y M. López en las Memorias del V y VI Simposios de Métodos Matemáticos Aplicados a las Ciencias, Revista de Ciencia y Tecnología, U.C.R., Vol. XIII, Nos. 1 y 2, 1989, y en los artículos de O. Prieto y M. López en las Memorias del VII y VIII Simposios de Métodos Matemáticos Aplicados a las Ciencias, Editorial de la Universidad de Costa Rica, San Pedro, 1995. Más recientemente, se estudia la estabilidad de la opinión pública en Costa Rica en [34].

3.8.4 Opinión sobre un servicio de comedor

Como parte de un proyecto para la carrera de Ingeniería en Producción Industrial, se hizo un estudio sobre la opinión de usuarios del servicio de comedor, o soda, del Instituto Tecnológico de Costa Rica (I.T.C.R.)³. Las 9 preguntas de opinión, todas ordinales, fueron:

1. ¿Cómo califica usted la rapidez del servicio?
2. ¿Cómo califica usted la higiene de las instalaciones en general?
3. ¿Cómo califica usted la higiene de los productos?
4. La variedad de los alimentos es:
5. Usted considera que la calidad de los productos ofrecidos es:
6. Usted considera que los precios de los alimentos son:

³Los datos fueron recopilados por la Ing. Edith Guevara y su grupo de compañeros, en el segundo semestre de 2004.

7. El tamaño de las porciones servidas en la Soda-Comedor son:
8. La atención que se le brinda a los clientes por parte de nuestro personal es:
9. En general, usted considera que el servicio de la Soda-Comedor es:

Las preguntas 1 a 5, y la 8 y la 9, tienen cinco modalidades: Muy Malo, Malo, Regular, Bueno y Muy Bueno. La pregunta 6 tiene las modalidades Muy altos, Altos, Regular, Bajos, Muy Bajos. La pregunta 7 tiene las categorías: Muy Pequeñas, Pequeñas, Adecuadas, Grandes, Muy grandes. Se puede entonces reagrupar las modalidades en tres categorías de opinión: Negativa, Neutra, Positiva.

Además, se preguntó “Usted asiste a la soda comedor principalmente por:” con las categorías: Comodidad, Precio, Variedad, Excelente atención, Otro. La primera categoría fue seleccionada por 58.5% de los entrevistados, pero no quedaba claro qué significaba “comodidad”, por lo que esta variable no se usó como activa. Las últimas dos categorías no fueron escogidas. Esta variable la llamaremos “principal razón”, en el sentido de que es la razón para acudir al comedor.

Finalmente, se tiene también la siguiente información, que junto con la variable principal razón serán tomadas como variables de señalización:

- Edad: en años cumplidos.
- Sexo: femenino (F), masculino (M).
- Ocupación: estudiante (E), docente (D), administrativo (A).

Se dispone entonces de una matriz con 147 filas y 13 columnas. Haremos un Análisis en Componentes Principales normado sobre las primeras 9 variables ordinales, y utilizaremos las otras como variables suplementarias.

Al calcular las frecuencias de las modalidades de las variables activas, se obtienen los valores mostrados en la Tabla 3.11. Las frecuencias de las variables llamadas de señalización se muestran en la Tabla 3.12, donde se ha categorizado la edad en 4 segmentos.

Al efectuar el A.C.P. con las 9 variables activas, se obtienen 2 valores propios significativos (véase la Tabla 3.13).

	Opinión		
	Negativa	Neutra	Positiva
Rapidez	7.5	45.6	46.9
Higiene Instalaciones	8.2	52.4	39.4
Higiene Producto	3.4	32.7	63.9
Variedad de alimentos	7.5	50.3	42.2
Calidad de productos	2.7	29.3	68.0
Precios	0.0	80.3	19.7
Tamaño de las porciones	12.2	64.6	23.2
Atención	7.5	76.9	15.6
Servicio en general	0.0	23.1	76.9

Tabla 3.11: Frecuencias relativas de las categorías en el estudio de opinión sobre el comedor del I.T.C.R.

El círculo de correlaciones con los ejes 1 y 2, en el que se ha proyectado la variable suplementaria “Edad” (tomada como cuantitativa, con el valor original observado), se muestra en la Figura 3.13. Puede verse que la primera componente principal está fuertemente asociada al concepto de higiene y servicio, mientras que la segunda a la atención y el tamaño de las porciones. Por su parte, se puede graficar los planos principales de varias maneras. Por ejemplo, con las etiquetas originales de los individuos (de 1 a 147) no tiene mucho sentido, porque esa etiqueta no nos aporta mucha información. Sin embargo, se podría graficar con las etiquetas correspondientes —para cada individuo— de las variables de señalización: sexo, ocupación, categoría de edad, así como la principal razón para acudir al comedor del I.T.C.R. Ahora bien, hemos calculado las proyecciones de los puntos promedio para cada una de las modalidades de estas variables y las hemos proyectado como individuos suplementarios en el primer plano principal mostrado en la parte baja de la Figura 3.13. Podemos notar que el sector administrativo, con 36 a 45 años y mayoritariamente femenino, muestra una opinión positiva respecto a la atención que se le brinda a los clientes, contrario al público masculino y estudiantil. Por su parte, los docentes —si bien es cierto que se comportan un poco como el promedio— tienden a valorar el tamaño de las porciones sin importarle un alto precio, lo cual se contrapone lógicamente a los que dan como principal razón para acudir al comedor los precios favorables, la calidad y la variedad, quienes además consideran apropiada la higiene.

Variable	Modalidades	Frecuencias	Porcentaje
Edad	Menor de 26 años	95	65%
	Entre 26 y 35 años	17	11%
	Entre 36 y 45 años	26	18%
	Mayor de 46 años	9	6%
Sexo	Femenino	57	39%
	Masculino	90	61%
Ocupación	Estudiante	97	66%
	Docente	19	13%
	Administrativo	31	21%
Principal Razón	Comodidad	86	59%
	Precio	49	33%
	Variedad	12	8%

Tabla 3.12: Comedor del I.T.C.R.: frecuencias de las variables de señalización.

	Valor Propio	% Inercia Total	% Inercia acumulada
1	2.84	31.55	31.55
2	1.50	16.64	48.19
3	0.99	11.00	59.19
4	0.93	10.29	69.49
5	0.75	8.30	77.79
6	0.63	7.05	84.84
7	0.57	6.36	91.20
8	0.47	5.20	96.40
9	0.32	3.60	100.00

Tabla 3.13: Comedor del I.T.C.R.: valores propios del A.C.P.




Figura 3.13: Círculo de correlaciones y proyección de las modalidades de señalización como individuos suplementarios en el primer plano principal para los datos del comedor del I.T.C.R.

3.9 El A.C.P. general

En esta sección veremos el caso general del A.C.P.: cuando el espacio de individuos está provisto de una métrica cualquiera $\mathbf{M}$. Además, probaremos dos resultados que hemos usado para deducir la solución del A.C.P. normado: primero, que el cálculo de los ejes principales de inercia se pueden hacer *uno a uno*, y segundo que ellos provienen de la diagonalización de la matriz $\mathbf{VM}$ (en el caso normal se trata de la matriz de correlaciones $\mathbf{R}$). Ambos resultados tienen su justificación matemática que damos a continuación.

Recordemos que tenemos una nube de n puntos en $\mathbb{R}^p$ denotada $\mathcal{N} = (\mathbf{X}, \mathbf{M}, \mathbf{D}_p)$, con $\mathbf{X}$ una matriz $n \times p$ asociada a p variables cuantitativas centradas, $\mathbf{M}$ una métrica sobre el espacio de individuos $\mathbb{R}^p$ (con una matriz asociada $p \times p$), y $\mathbf{D}_p$ la métrica de pesos sobre el espacio de variables $\mathbb{R}^n$ (con una matriz diagonal asociada $n \times n$ con los pesos p_i).

Ya hemos definido la inercia de una nube de puntos respecto a un punto $\mathbf{a}$ y respecto al centro de gravedad. Veamos ahora la expresión de la inercia respecto a un subespacio vectorial. Si H es un subespacio vectorial de $\mathbb{R}^p$, entonces existe un subespacio de $\mathbb{R}^p$ denotado $H^\perp$ y llamado el complemento ortogonal de H , tal que $\mathbb{R}^p = H \oplus H^\perp$; se cumple que para todo $\mathbf{h} \in H$ y todo $\bar{\mathbf{h}} \in H^\perp$: $\mathbf{M}(\mathbf{h}, \bar{\mathbf{h}}) = \langle \mathbf{h}, \bar{\mathbf{h}} \rangle_{\mathbf{M}} = 0$. Por lo tanto, para todo $\mathbf{x}_i \in E$, existen $\mathbf{a}_i \in H, \mathbf{b}_i \in H^\perp$ tales que $\mathbf{x}_i = \mathbf{a}_i + \mathbf{b}_i$, y esta descomposición es única. Recuérdesse la Figura 3.1 en la página 44.

Se define la inercia de la nube $\mathcal{N}$ respecto a H como:

$$I_H(\mathcal{N}) = \sum_{i=1}^n p_i \|\mathbf{b}_i\|^2$$

Así mismo, la inercia de $\mathcal{N}$ respecto a $H^\perp$ es:

$$I_{H^\perp}(\mathcal{N}) = \sum_{i=1}^n p_i \|\mathbf{a}_i\|^2$$

Esto es, $I_{H^\perp}(\mathcal{N})$ es la inercia de la nube proyectada sobre el espacio H . Cuando H está generado por un vector unitario $\mathbf{v}$, es decir $H = \Delta_{\mathbf{v}}$ con $\|\mathbf{v}\| = 1$, entonces se tiene $\mathbf{a}_i = \langle \mathbf{v}, \mathbf{x}_i \rangle_{\mathbf{M}} \mathbf{v} = (\mathbf{v}^t \mathbf{M} \mathbf{x}_i) \mathbf{v}$, por lo tanto

$$I_{\Delta_{\mathbf{v}}}(\mathcal{N}) = \sum_{i=1}^n p_i \|\mathbf{a}_i\|^2 = \sum_{i=1}^n p_i (\mathbf{v}^t \mathbf{M} \mathbf{x}_i)^2 \|\mathbf{v}\|^2 = \sum_{i=1}^n p_i \mathbf{v}^t \mathbf{M} \mathbf{x}_i \mathbf{x}_i^t \mathbf{M} \mathbf{v}$$

y se tiene que

$$I_{\Delta_{\mathbf{v}}^{\perp}}(\mathcal{N}) = \mathbf{v}^t \mathbf{M} \left(\sum_{i=1}^n p_i \mathbf{x}_i \mathbf{x}_i^t \right) \mathbf{M} \mathbf{v} = \mathbf{v}^t \mathbf{M} \mathbf{V} \mathbf{M} \mathbf{v}$$

Debido a que $E = H \oplus H^{\perp}$ y al teorema de Pitágoras, se tiene la importante relación (recordar la igualdad 3.1 en la página 44):

$$I(\mathcal{N}) = I_H(\mathcal{N}) + I_{H^{\perp}}(\mathcal{N})$$

Recuérdese que el objetivo en A.C.P. es obtener un subespacio de $\mathbb{R}^p$ de dimensión q , con $q < p$ y que denotaremos E_q , tal que la inercia $I_{E_q^{\perp}}(\mathcal{N})$ de la nube proyectada sobre ese espacio sea máxima (lo que es equivalente a pedir que la inercia $I_{E_q}(\mathcal{N})$ sea mínima).

El siguiente resultado es llamado el *Teorema de inclusión*.

Teorema 3.1 (De inclusión) *Si E_{k-1} es un subespacio vectorial óptimo de $\mathbb{R}^p$ de dimensión $k-1$, entonces el subespacio vectorial óptimo de $\mathbb{R}^p$ de dimensión k contiene a E_{k-1} .*

DEMOSTRACIÓN:

Sea F_k un subespacio vectorial de $\mathbb{R}^p$ de dimensión k y denotemos $H = F_k + E_{k-1}^{\perp}$.

Si $F_k \cap E_{k-1}^{\perp} = \{\mathbf{0}\}$ entonces se tendría $H = F_k \oplus E_{k-1}^{\perp}$ y $\dim(H) = k + (p - (k - 1)) = p + 1$, lo cual es absurdo pues $H \subseteq \mathbb{R}^p$.

Por lo tanto existe un vector no nulo $\mathbf{v} \in F_k \cap E_{k-1}^{\perp}$ y denotemos $\Delta_{\mathbf{v}}$ el eje (espacio vectorial de dimensión uno) generado por $\mathbf{v}$.

Sea G el espacio suplementario M -ortogonal a $\Delta_{\mathbf{v}}$ en F_k : es decir, tal que $F_k = G \oplus \Delta_{\mathbf{v}}$; y sea E_k la suma directa $E_k = E_{k-1} \oplus \Delta_{\mathbf{v}}$.

Debido a la ortogonalidad entre G y $\Delta_{\mathbf{v}}$ se tiene

$$I_{F_k}(\mathcal{N}) = I_G(\mathcal{N}) + I_{\Delta_{\mathbf{v}}}(\mathcal{N})$$

y a la ortogonalidad entre E_{k-1} y $\Delta_{\mathbf{v}}$ se tiene

$$I_{E_k}(\mathcal{N}) = I_{E_{k-1}}(\mathcal{N}) + I_{\Delta_{\mathbf{v}}}(\mathcal{N}).$$

Sin embargo, por hipótesis E_{k-1} es óptimo entre los subespacios vectoriales de dimensión $k-1$, esto es $I_{E_{k-1}}(\mathcal{N}) \leq I_G(\mathcal{N})$, por lo tanto $I_{E_k}(\mathcal{N}) \leq I_{F_k}(\mathcal{N})$ y entonces E_k es óptimo entre los subespacios vectoriales de $\mathbb{R}^p$ de dimensión k .

Como E_{k-1} es subespacio de E_k , por la forma de definir E_k , entonces se tiene el resultado. ■

Proposición 3.2 *Sea E_{k-1} un subespacio vectorial de $\mathbb{R}^p$ óptimo de dimensión $k-1$. Si el vector $\mathbf{v}$ genera un eje $\Delta_{\mathbf{v}}$ $\mathbf{M}$ -ortogonal a E_{k-1} tal que $I_{\Delta_{\mathbf{v}}}(\mathcal{N})$ es mínima, entonces el espacio $E_k = E_{k-1} \oplus \Delta_{\mathbf{v}}$ minimiza la inercia proyectada de $\mathcal{N}$ sobre todos los subespacios de $\mathbb{R}^p$ de dimensión k .*

DEMOSTRACIÓN:

Sea $\mathbf{v} \in \mathbb{R}^p$ tal que $\Delta_{\mathbf{v}} \perp E_{k-1}$, entonces sea $E_k = E_{k-1} \oplus \Delta_{\mathbf{v}}$.

Luego, por el teorema de Pitágoras, $I_{E_k}(\mathcal{N}) = I_{E_{k-1}}(\mathcal{N}) + I_{\Delta_{\mathbf{v}}}(\mathcal{N})$.

Como $I_{E_{k-1}}(\mathcal{N})$ es constante, minimizar $I_{E_k}(\mathcal{N})$ se reduce a minimizar $I_{\Delta_{\mathbf{v}}}(\mathcal{N})$. ■

Los dos resultados anteriores permiten seguir la siguiente estrategia para obtener la solución del A.C.P.:

1. Buscar el eje $E_1 = \Delta_{\mathbf{v}_1}$ con inercia mínima, $\mathbf{v}_1$ es un vector unitario que genera a $\Delta_{\mathbf{v}_1}$.
2. Buscar el eje $\Delta_{\mathbf{v}_2}$, $\mathbf{M}$ -ortogonal a $\Delta_{\mathbf{v}_1}$ y con inercia mínima; sea $E_2 = \Delta_{\mathbf{v}_1} \oplus \Delta_{\mathbf{v}_2}$, E_2 es un subespacio óptimo de dimensión 2.
- k. Buscar un eje $\Delta_{\mathbf{v}_k}$, $\mathbf{M}$ -ortogonal a E_{k-1} y con inercia mínima; sea $E_k = E_{k-1} \oplus \Delta_{\mathbf{v}_k}$, E_k es un subespacio óptimo de dimensión k .

Se tiene entonces $E_k = \Delta_{\mathbf{v}_1} \oplus \Delta_{\mathbf{v}_2} \oplus \dots \oplus \Delta_{\mathbf{v}_k}$. Los ejes $\Delta_{\mathbf{v}_1}, \Delta_{\mathbf{v}_2}, \dots$ son llamados los ejes factoriales.

Recuérdese que $\mathbf{M}$ es una matriz simétrica definida positiva y que $\mathbf{V}$ es simétrica positiva. Además, $\mathbf{VM}$ es $\mathbf{M}$ -simétrica, esto es⁴, $(\mathbf{VM})^t \mathbf{M} = \mathbf{M}(\mathbf{VM})$. Por lo tanto deducimos que los valores propios de $\mathbf{VM}$ son

⁴Una matriz $\mathbf{A}$ es $\mathbf{M}$ -simétrica si $\mathbf{A}^t \mathbf{M} = \mathbf{M} \mathbf{A}$.

reales, positivos o nulos, y que existe una base $\mathbf{M}$ -ortonormada de $\mathbb{R}^p$ formada por vectores propios de $\mathbf{VM}$. Denotemos $\lambda_1, \lambda_2, \dots, \lambda_p$ los valores propios de $\mathbf{VM}$ ordenados de mayor a menor, y denotemos $\{\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_p\}$ una base de vectores propios asociados respectivamente a los λ_j .

Según la estrategia deducida del teorema de inclusión y de la proposición 3.2, para obtener la solución del A.C.P. se comienza por buscar el eje $\Delta_{\mathbf{v}_1}$ que minimice la inercia $I_{\Delta_{\mathbf{v}_1}}(\mathcal{N})$ con $\|\mathbf{v}_1\|_{\mathbf{M}} = 1$, luego el eje $\Delta_{\mathbf{v}_2}$ que minimice la inercia $I_{\Delta_{\mathbf{v}_2}}(\mathcal{N})$ con $\|\mathbf{v}_2\|_{\mathbf{M}} = 1$ y $\mathbf{M}$ -ortogonal a $\mathbf{v}_1$, y así sucesivamente:

1. Se quiere encontrar $\mathbf{v}_1$ tal que maximice $I_{\Delta_{\mathbf{v}_1}}(\mathcal{N}) = \mathbf{v}_1^t \mathbf{M} \mathbf{V} \mathbf{M} \mathbf{v}_1$ con la restricción $\|\mathbf{v}_1\|_{\mathbf{M}}^2 = \mathbf{v}_1^t \mathbf{M} \mathbf{v}_1 = 1$.
Sea $\{\mathbf{u}_1, \dots, \mathbf{u}_p\}$ la base de vectores propios de $\mathbf{VM}$, el vector $\mathbf{v}_1$ tiene una expresión en esta base de la forma:

$$\mathbf{v}_1 = \sum_{j=1}^p \alpha_j \mathbf{u}_j.$$

Luego, la restricción $\|\mathbf{v}_1\|_{\mathbf{M}}^2 = 1$ se escribe:

$$\begin{aligned} 1 = \mathbf{v}_1^t \mathbf{M} \mathbf{v}_1 &= \left(\sum_{j=1}^p \alpha_j \mathbf{u}_j \right)^t \mathbf{M} \left(\sum_{k=1}^p \alpha_k \mathbf{u}_k \right) \\ &= \sum_{j=1}^p \sum_{k=1}^p \alpha_j \alpha_k \mathbf{u}_j^t \mathbf{M} \mathbf{u}_k \\ &= \sum_{j=1}^p \sum_{k=1}^p \alpha_j \alpha_k \delta_{jk} \end{aligned}$$

donde $\delta_{jk} = 1$ si $j = k$ y es cero si no, pues la base de vectores propios de $\mathbf{VM}$ es ortonormada. Luego, la restricción se traduce en:

$$\|\mathbf{v}_1\|^2 = \sum_{j=1}^p \alpha_j^2 = 1,$$

por lo tanto se tiene:

$$\mathbf{v}_1^t \mathbf{M} \mathbf{V} \mathbf{M} \mathbf{v}_1 = \left\langle \sum_{j=1}^p \alpha_j \mathbf{u}_j, \mathbf{V} \mathbf{M} \left(\sum_{k=1}^p \alpha_k \mathbf{u}_k \right) \right\rangle_{\mathbf{M}}$$

$$= \left\langle \sum_{j=1}^p \alpha_j \mathbf{u}_j, \sum_{k=1}^p \lambda_k \alpha_k \mathbf{u}_k \right\rangle_{\mathbf{M}},$$

de donde $\mathbf{v}_1^t \mathbf{M} \mathbf{V} \mathbf{M} \mathbf{v}_1 = \sum_{j=1}^p \lambda_j \alpha_j^2$.

Se debe por lo tanto maximizar $\sum_{j=1}^p \lambda_j \alpha_j^2$ bajo la restricción $\sum_{j=1}^p \alpha_j^2 = 1$.

Debido a que los λ_j están ordenados de manera decreciente, se tiene

$$\sum_{j=1}^p \lambda_j \alpha_j^2 \leq \lambda_1 \sum_{j=1}^p \alpha_j^2 = \lambda_1.$$

Basta por lo tanto tomar $\alpha_1 = 1$ y $\alpha_j = 0$ para todo $j \geq 2$.

Así, si $\mathbf{v}_1 = \mathbf{u}_1$, entonces se alcanza el valor λ_1 que mayoriza el criterio a maximizar, por lo que se toma el vector propio unitario de $\mathbf{V} \mathbf{M}$ asociado al mayor valor propio λ_1 .

2. Se quiere encontrar $\mathbf{v}_2$ tal que maximice $I_{\Delta_{\mathbf{v}_2}^\perp}(\mathcal{N}) = \mathbf{v}_2^t \mathbf{M} \mathbf{V} \mathbf{M} \mathbf{v}_2$ con las restricciones $\|\mathbf{v}_2\|^2 = \mathbf{v}_2^t \mathbf{M} \mathbf{v}_2 = 1$ y $\mathbf{v}_2^t \mathbf{M} \mathbf{u}_1 = 0$.

A partir de la escritura $\mathbf{v}_2 = \sum_{j=1}^p \alpha_j \mathbf{u}_j$ con $\sum_{j=1}^p \alpha_j^2 = 1$ de $\mathbf{v}_2$ en la base de vectores propios de $\mathbf{V} \mathbf{M}$, se muestra que la primera restricción es $\sum_{j=1}^p \alpha_j^2 = 1$, mientras que la segunda restricción lleva a:

$$\begin{aligned} 0 = \mathbf{v}_2^t \mathbf{M} \mathbf{v}_1 &= \left(\sum_{j=1}^p \alpha_j \mathbf{u}_j \right)^t \mathbf{M} \mathbf{u}_1 \\ &= \sum_{j=1}^p \alpha_j \mathbf{u}_j^t \mathbf{M} \mathbf{u}_1 \\ &= \alpha_1 \mathbf{u}_1^t \mathbf{M} \mathbf{u}_1 = \alpha_1 \end{aligned}$$

Es decir, $\mathbf{v}_2 = \sum_{j=2}^p \alpha_j \mathbf{u}_j$ pues $\alpha_1 = 0$. Luego,

$$I_{\Delta_{\mathbf{v}_2}^\perp}(\mathcal{N}) = \mathbf{v}_2^t \mathbf{M} \mathbf{V} \mathbf{M} \mathbf{v}_2 = \sum_{j=2}^p \lambda_j \alpha_j^2 \leq \lambda_2 \sum_{j=2}^p \alpha_j^2 = \lambda_2.$$

Así, el valor a maximizar se encuentra mayorado por λ_2 , y este valor se alcanza cuando $\alpha_2 = 1$ y $\alpha_j = 0$ para todo $j \geq 3$; esto es, cuando $\mathbf{v}_2 = \mathbf{u}_2$, por lo que una solución es tomar el vector propio de $\mathbf{V} \mathbf{M}$ asociado al segundo valor propio más grande de $\mathbf{V} \mathbf{M}$.

- k. La búsqueda del k -ésimo eje factorial $\Delta_{\mathbf{v}_k}$ se hace análogamente y se encuentra que $\mathbf{v}_k = \mathbf{u}_k$.

Obsérvese que los vectores $\mathbf{u}_k$ que definen los ejes principales $\Delta_{\mathbf{u}_k}$ pertenecen al espacio de individuos a $\mathbb{R}^p$, mientras que las componentes principales $\mathbf{c}^k = \mathbf{X}\mathbf{M}\mathbf{u}_k$ pertenecen al espacio de variables $\mathbb{R}^n$, y que son las *proyecciones por dualidad* de los primeros (ver Figura 3.14), esto es, la transformación mediante $\mathbf{X}\mathbf{M}$ de $\mathbb{R}^p$ en $\mathbb{R}^n$.




Figura 3.14: Esquema de dualidad en el caso del A.C.P. general.

En el ejercicio 2, página 91 se pide probar que $\lambda_1 = I_{\Delta_{\mathbf{u}_1}^\perp}(\mathcal{N})$, es decir es la inercia de la nube proyectada sobre el primer eje principal.

Se tiene que:

- $\frac{\lambda_1}{\text{tr}(\mathbf{VM})}$ es la parte de inercia explicada por el primer eje principal.
- $\frac{\lambda_1 + \lambda_2}{\text{tr}(\mathbf{VM})}$ es la parte de inercia explicada por el primer plano principal generado por $\mathbf{u}_1$ y $\mathbf{u}_2$.
- $\frac{\lambda_1 + \lambda_2 + \dots + \lambda_k}{\text{tr}(\mathbf{VM})}$ es la parte de inercia explicada por el subespacio principal E_k de dimensión k generado por $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_k$, donde $E_k = \Delta_{\mathbf{u}_1} \oplus \Delta_{\mathbf{u}_2} \oplus \dots \oplus \Delta_{\mathbf{u}_k}$.

3.10 Ejercicios

1. Pruebe que las componentes principales del A.C.P. general de la nube $\mathcal{N} = (\mathbf{X}, \mathbf{M}, \mathbf{D}_p)$ tiene las siguientes propiedades:

(a) Son centradas:

$$\bar{\mathbf{c}}^k = 0.$$

(b) $\mathbf{c}^k$ tiene varianza λ_k :

$$\text{var}(\mathbf{c}^k) = \lambda_k.$$

(c) Cada par de ellas tiene correlación cero:

$$\forall k, l : r(\mathbf{c}^k, \mathbf{c}^l) = 0.$$

2. Para un A.C.P. general, sean λ_1 el mayor valor propio de $\mathbf{VM}$ y $\mathbf{u}_1$ un vector propio unitario asociado. Probar que $\lambda_1 = I_{\Delta_{\mathbf{u}_1}^\perp}(\mathcal{N})$.
3. Sea $\mathbf{u}_k$ un eje principal del A.C.P. de la nube $\mathcal{N} = (\mathbf{X}, \mathbf{M}, \mathbf{D}_p)$ con valor propio λ_k . Si definimos $\mathbf{v}_k = \mathbf{Mu}_k$ pruebe que entonces $\mathbf{v}_k$ es vector propio de $\mathbf{MV}$ asociado al mismo valor propio λ_k . Se llama a $\mathbf{v}_k$ un *factor principal*. Pruebe además que los factores principales son ortogonales respecto de los productos internos definidos por las métricas $\mathbf{V}$ y $\mathbf{M}^{-1}$ en el dual $(\mathbb{R}^p)^*$.
4. Pruebe que la matriz de datos $\mathbf{X}$ se puede expresar como $\mathbf{X} = \sum_{j=1}^p \mathbf{c}^j \mathbf{u}_j^t$, donde $\mathbf{c}^j$ son las componentes principales y $\mathbf{u}_j$ los ejes principales del ACP general de $\mathcal{N} = (\mathbf{X}, \mathbf{M}, \mathbf{D}_p)$. Esta expresión es conocida como *fórmula de reconstitución de los datos*. (Sugerencia: en vista de que los $\mathbf{u}_j$ forman una base ortonormada de $\mathbb{R}^p$, el i -ésimo individuo puede expresarse como $\mathbf{x}_i = \sum_{j=1}^p c_{ij} \mathbf{u}_j$).
5. Sea $\mathbf{X}$ una tabla de datos asociada a p variables cuantitativas centradas y denotemos $\mathbf{W} = \mathbf{XMX}^t$, con $\mathbf{M}$ la métrica sobre el espacio de individuos. Pruebe que las componentes principales $\mathbf{c}^k$ son vectores propios de $\mathbf{WD}_p$ asociados a los valores propios λ_k (Sugerencia: ver el esquema de dualidad para el A.C.P. general, Figura 2.4 página 37).
6. Considérese que se ha observado el crecimiento de 20 novillos, midiéndose el peso al nacimiento ($\mathbf{x}$), a los 50 días ($\mathbf{y}$) y a los 100 días

($\mathbf{z}$), obteniéndose la matriz de covarianzas $\mathbf{V}$ (para pesos iguales de los individuos):

$$\mathbf{V} = \begin{pmatrix} 17.56 & 31.09 & 47.69 \\ 31.09 & 91.29 & 140.39 \\ 47.69 & 140.39 & 267.08 \end{pmatrix}$$

i) Determine la matriz de correlaciones $\mathbf{R}$.

Suponga que se hace un Análisis en Componentes Principales normado.

ii) Probar que los vectores $\mathbf{v}_1 = \begin{pmatrix} 0.5496 \\ 0.5995 \\ 0.5818 \end{pmatrix}$ y $\mathbf{v}_2 = \begin{pmatrix} 0.8160 \\ -0.2360 \\ -0.5276 \end{pmatrix}$ son vectores propios de la matriz a diagonalizar en el A.C.P. y determine los valores propios a los que están asociados. ¿Cuánto vale el tercer valor propio?

iii) Mostrar que $\mathbf{v}_1$ y $\mathbf{v}_2$ son ortogonales, y que son de norma 1.

iv) Calcule la inercia de la nube de puntos; calcule el porcentaje de inercia explicada por el primer eje factorial, y el porcentaje de inercia explicada por el segundo eje factorial.

v) Las correlaciones entre las variables originales y las dos primeras componentes principales son:

	$\mathbf{c}^1$	$\mathbf{c}^2$
$\mathbf{x}$	0.751	0.438
$\mathbf{y}$	0.949	0.309
$\mathbf{z}$	0.997	-0.115

Dibuje el círculo de correlaciones y represente en él a las tres variables originales.

7. Considérese la siguiente tabla de datos, que muestra las notas obtenidas por 8 estudiantes en 4 quices:

	quiz 1	quiz 2	quiz 3	quiz 4
Inés	90	88	56	77
Jorge	80	85	67	82
Lina	50	65	40	63
Franco	85	82	80	87
Cecilia	75	78	60	75
Raúl	56	43	48	33
Eugenia	92	75	77	86
Juan	100	85	80	100

Haremos un Análisis en Componentes Principales normado de la tabla anterior. Obsérvese que la matriz a diagonalizar es la matriz de correlaciones:

	quiz 1	quiz 2	quiz 3	quiz 4
quiz 1	1.00	0.78	0.86	0.84
quiz 2	0.78	1.00	0.60	0.90
quiz 3	0.86	0.60	1.00	0.80
quiz 4	0.84	0.90	0.80	1.00

Como todas las correlaciones entre las variables son positivas y relativamente altas, es de esperarse que se presente el efecto talle en el círculo de correlaciones.

- Se obtienen los siguientes valores propios de $\mathbf{R}$: $\lambda_2 = 0.44$, $\lambda_3 = 0.13$ y $\lambda_4 = 0.04$. ¿Cuánto vale el primer valor propio λ_1 ?
- Calcule la inercia total de la nube de puntos y el porcentaje de inercia explicado por cada eje principal.
- Determine la calidad global del primer plano principal.
- Las correlaciones entre las variables originales (notas de los quices) y las dos primeras componentes principales son:

	$\mathbf{c}^1$	$\mathbf{c}^2$
quiz 1	-0.95	0.15
quiz 2	-0.89	-0.44
quiz 3	-0.88	0.44
quiz 4	-0.96	-0.15

Dibuje el círculo de correlaciones y represente en él a las cuatro variables originales.

- (e) Las componentes principales están dadas en la tabla siguiente, así como los cosenos cuadrados (por cien) de la proyección de los individuos sobre ellas:

	$\mathbf{c}^1$	$\mathbf{c}^2$	$\cos^2 1$	$\cos^2 2$
Inés	-0.60	-0.83	21.85%	42.57%
Jorge	-0.69	-0.36	68.78	19.11
Lina	2.38	-0.88	84.23	11.52
Franco	-1.32	0.41	81.75	7.78
Cecilia	0.14	-0.35	12.85	81.09
Raúl	3.52	0.99	92.04	7.31
Eugenia	-1.17	0.71	71.82	26.47
Juan	-2.26	0.32	96.37	1.93

Determine la calidad de la representación de cada estudiante sobre el plano principal.

- (f) Represente los individuos en el plano principal.
- (g) Interprete los resultados del Análisis en Componentes Principales.
8. Considere la siguiente tabla de notas escolares (de 0 a 20), con 9 individuos con pesos iguales:

	Mate	Física	Francés	Latín	Deportes
Jean	6	6	5	5.5	8
Alain	8	8	8	8	9
Anne	6	7	11	9.5	11
Monique	14.5	14.5	15.5	15	8
Didier	14	14	12	12.5	10
André	11	10	5.5	7	13
Pierre	5.5	7	14	11.5	10
Brigitte	13	12.5	8.5	9.5	12
Evelyne	9	9.5	12.5	12	18

Haga un Análisis en Componentes Principales normado de la tabla anterior. Comente sus resultados.

9. Considere la Tabla 3.14 de los peces de Amiard [12]; se trata de 24 peces que estuvieron en tres peceras, cada una con distinto grado de radioactividad. Los primeros 8 peces pertenecen a la primera pecera

(con poca radiación), los peces 9 a 16 a la segunda (con radiación mediana), y los restantes a la tercera (con mucha radiación); de estos últimos, el pez número 17 murió antes del final del experimento y por ello no aparece en la tabla. Las variables tienen el siguiente significado:

- x^1 : radiación en los ojos
- x^2 : radiación en las branquias
- x^3 : radiación en los opérculos
- x^4 : radiación en las aletas
- x^5 : radiación en el hígado
- x^6 : radiación en el tubo digestivo
- x^7 : radiación en los riñones
- x^8 : radiación en las escamas
- x^9 : radiación en los músculos
- x^{10} : peso
- x^{11} : longitud
- x^{12} : longitud estándar
- x^{13} : ancho de la cabeza
- x^{14} : ancho
- x^{15} : ancho del hocico
- x^{16} : diámetro de los ojos.

La variable x^7 no se pudo medir en la segunda pecera, por lo que el investigador decidió sustituir su valor por el promedio medido sobre el resto de los peces, es decir, colocó el valor 9 para todos los peces de la segunda pecera.

Realice un A.C.P. sobre esta tabla. ¿Cuántos ejes deben guardarse?

Repita el análisis sin la variable x^7 , pero proyétela como variable suplementaria en el círculo de correlaciones. ¿Qué diferencias se notan con respecto al primer análisis?

10. Considérese la Tabla de datos 3.15 [69]⁵ Se trata de estadísticas que conciernen, para diferentes países occidentales, las causas de muerte

	x^1	x^2	x^3	x^4	x^5	x^6	x^7	x^8	x^9	x^{10}	x^{11}	x^{12}	x^{13}	x^{14}	x^{15}	x^{16}
1	10	65	65	107	7	76	16	142	1	132	214	197	54	47	18	11
2	9	43	39	67	29	113	10	99	2	122	220	198	49	44	16	10
3	6	47	71	95	11	192	9	121	2	129	220	198	49	45	17	11
4	7	70	40	66	8	310	10	90	2	133	225	199	52	48	15	11
5	8	59	67	100	14	289	4	244	1	57	168	149	37	37	9	9
6	8	46	55	112	17	115	8	153	1	59	178	160	38	35	11	9
7	7	47	36	87	16	100	4	162	1	59	176	156	40	36	11	9
8	11	79	46	95	20	106	10	141	4	47	176	165	39	31	10	8
9	13	80	64	155	42	192	9	169	3	72	182	164	40	39	12	10
10	21	150	115	146	49	229	9	233	5	79	200	179	45	38	12	9
11	12	91	84	138	22	590	9	220	2	80	185	163	43	41	12	11
12	14	120	76	125	21	309	9	617	5	72	175	158	40	39	13	10
13	14	142	86	135	34	523	9	211	11	75	189	169	42	39	18	10
14	23	92	80	132	49	459	9	197	2	52	164	147	36	35	12	9
15	13	85	64	124	20	318	9	191	4	86	195	175	41	39	16	10
16	14	106	67	110	31	115	9	248	6	87	210	170	46	40	17	10
18	32	224	260	314	36	107	13	461	3	72	181	164	41	36	13	9
19	22	162	218	318	25	884	5	590	2	63	175	160	38	35	12	9
20	31	195	208	350	73	109	5	809	11	49	170	154	39	33	12	8
21	15	127	119	197	23	99	7	157	2	107	204	185	47	45	15	11
22	22	160	256	282	12	102	11	690	3	83	190	176	42	44	14	9
23	24	160	231	308	19	1031	17	558	2	82	194	168	42	39	14	10
24	19	64	163	229	48	109	8	345	1	91	190	172	44	42	13	11

Tabla 3.14: Los datos de los peces de Amiard.

que son características del estado de salud mental de la sociedad. Las tasas están calculadas para cada 100.000 habitantes.

Las variables analizadas son las siguientes:

- x^1 : Suicidio
- x^2 : Homicidio
- x^3 : Accidente de ruta
- x^4 : Accidente industrial
- x^5 : Otro accidente
- x^6 : Cirrosis del hígado

Efectúe un A.C.P. de la tabla anterior e interprete los resultados.

11. Se dispone en la Tabla 3.16, de la estimación del consumo promedio de proteínas, en gramos, por persona y por día, en Europa (datos del año 1981). Se considera el consumo para:

⁵Los datos originales provienen de E. Todd (1979) *Le fou et le prolétaire*, anexo 2, p.283).

País	x^1	x^2	x^3	x^4	x^5	x^6
Alemania Fed.	210	12	230	21	198	169
Austria	241	16	330	43	363	325
Bélgica	156	10	260	13	367	144
Dinamarca	241	6	168	11	230	107
Escocia	82	15	155	18	342	59
España	40	4	136	17	237	225
Estados Unidos	121	102	220	26	273	158
Finlandia	251	26	180	29	387	55
Francia	156	9	225	10	535	328
Holanda	89	7	169	10	218	47
Inglaterra-Gales	79	10	130	14	203	36
Irlanda del Norte	40	136	215	18	320	43
Islandia	101	5	179	23	380	9
Italia	54	11	219	19	224	319
Noruega	38	7	182	32	314	37
Rep. Irlanda	38	7	182	32	314	47
Portugal	85	19	349	7	281	345
Suecia	194	11	151	13	384	122
Suiza	225	9	195	26	276	128

Tabla 3.15: Datos sobre las causas de muerte en algunos países occidentales.

- x^1 : carnes de animales rumiantes (RUMI)
- x^2 : carnes de cerdo y aves de corral (AVES)
- x^3 : huevos (HUEV)
- x^4 : leche (LECH)
- x^5 : carne de pescado (PESC)
- x^6 : cereales (CERE)
- x^7 : comidas almidonadas (ALMI)
- x^8 : semillas oleaginosas y semillas secas (LEGU)
- x^9 : frutas y verduras frescas (VERD)

Haga un A.C.P. de esta tabla de datos. Para la interpretación de los resultados, se le aconseja consultar un mapa de Europa.

País	x^1	x^2	x^3	x^4	x^5	x^6	x^7	x^8	x^9
Albania	10.1	1.4	0.5	8.9	0.2	42.3	0.6	5.5	1.7
Austria	8.9	14.0	4.3	19.9	2.1	28.0	3.6	1.3	4.3
Bélgica	13.5	9.3	4.1	17.5	4.5	26.6	5.7	2.1	4.0
Bulgaria	7.8	6.0	1.6	8.3	1.2	56.7	1.1	3.7	4.2
Checoslovaquia	9.7	11.4	2.8	12.5	2.0	34.3	5.0	1.1	4.0
Dinamarca	10.6	10.8	3.7	25.0	9.9	21.9	4.8	0.7	2.4
Alemania Or.	8.4	11.6	3.7	11.1	5.4	24.6	6.5	0.8	3.6
Finlandia	9.5	4.9	2.7	33.7	5.8	26.3	5.1	1.0	1.4
Francia	18.0	9.9	3.3	19.5	5.7	28.1	4.8	2.4	6.5
Grecia	10.2	3.0	2.8	17.6	5.9	41.7	2.2	7.8	6.5
Hungría	5.3	12.4	2.9	9.7	0.3	40.1	4.0	5.4	4.2
Irlandia	13.9	10.0	4.7	25.8	2.2	24.0	6.2	1.6	2.9
Italia	9.0	5.1	2.9	13.7	3.4	36.8	2.1	4.3	6.7
Holanda	9.5	13.6	3.6	23.4	2.5	22.4	4.2	1.8	3.7
Noruega	9.4	4.7	2.7	23.3	9.7	23.0	4.6	1.6	2.7
Polonia	6.9	10.2	2.7	19.3	3.0	36.1	5.9	2.0	6.6
Portugal	6.2	3.7	1.1	4.9	14.2	27.0	5.9	4.7	7.9
Rumania	6.2	6.3	1.5	11.1	1.0	49.6	3.1	5.3	2.8
España	7.1	3.4	3.1	8.6	7.0	29.2	5.7	5.9	7.2
Suecia	9.9	7.8	3.5	24.7	7.5	19.5	3.7	1.4	2.0
Suiza	13.1	10.1	3.1	23.8	2.3	25.6	2.8	2.4	4.9
Reino Unido	17.4	5.7	4.7	20.6	4.3	24.3	4.7	3.4	3.3
URSS	9.3	4.6	2.1	16.6	3.0	43.6	6.4	3.4	2.9
Alemania Occ.	11.4	12.5	4.1	18.8	3.4	18.6	5.2	1.5	3.8
Yugoslavia	4.4	5.0	1.2	9.5	0.6	55.9	3.0	5.7	3.2

Tabla 3.16: Datos sobre el consumo de proteínas en Europa en 1981.

12. Considérese la Tabla de datos 3.17, que contiene las importaciones hechas por los países centroamericanos, provenientes de México, entre 1979 y 1988.

Efectúe el A.C.P. de esta tabla. ¿Cuántos ejes es suficiente considerar? En el plano principal, se pueden trazar líneas entre los puntos que corresponden a años consecutivos. ¿Qué puede interpretar de estas trayectorias?

Año	C.Rica	E.Salv.	Guat.	Hond.	Nica.	Pana.
1979	44.4	27.2	45.6	20.0	6.0	14.1
1980	75.5	11.8	58.9	22.6	17.8	14.4
1981	110.7	50.6	128.3	17.2	119.4	118.5
1982	80.3	70.6	102.2	15.2	154.9	146.1
1983	81.6	82.3	89.0	35.1	169.4	127.1
1984	76.4	97.4	185.0	51.0	75.5	129.0
1985	32.0	89.5	195.3	31.1	33.4	110.2
1986	55.5	63.1	66.3	24.4	9.7	66.7
1987	74.3	72.6	76.3	28.1	11.2	110.7
1988	84.5	76.2	80.1	29.5	11.8	110.2

Tabla 3.17: Importaciones provenientes de México de los países de Centroamérica, entre 1979 y 1988.