




UNIVERSIDAD DE SANTIAGO DE CHILE

ANÁLISIS DE DATOS

INTRODUCCIÓN

SEBASTIAN CHAVEZ ORELLANA
MAX CHACÓN PACHECO

INGENIERÍA CIVIL BIOMÉDICA

PRIMER SEMESTRE 2026



Prefacio

Apuntes realizados en base al material de clases del **Dr. Max Chacón** [1] durante el curso de Análisis Inteligente de Datos, primer semestre 2024 para la carrera de Ingeniería Civil Biomédica en la Universidad de Santiago de Chile [2], actualizado al primer semestre 2026 para el curso de Análisis de Datos.

Al final de las secciones clave, se presentan preguntas diseñadas para facilitar una comprensión profunda de los conceptos abordados.



Índice

1. Definiciones	4
1.1. Bases para Decisiones Informadas	5
2. Contexto Histórico	7
2.1. Touring	7
2.2. La Máquina de Turing	7
2.3. El Test de Turing	8
2.4. Regla Delta (Adelaine)	9
2.5. Retropropagación del Error	10
2.6. Redes Neuronales Profundas	11
2.6.1. Funcionamiento de las Redes Neuronales Profundas	11
2.7. Bonus: Deep learning, perspectiva de LeCun, Bengio y Hinton	12
2.8. Preguntas de Comprensión	15
3. Aprendizaje Automático y Codificación de Datos	16
3.1. Tipos de Inteligencia Artificial	16
3.1.1. Inteligencia Específica o Débil	16
3.1.2. Inteligencia Fuerte	16
3.1.3. IA Generalizable	16
3.2. Análisis del Aprendizaje Automático como Herramienta Cognitiva	17
4. Modelo de Sistema de Información Operacional	18
5. Estructura del Proceso de Obtención de Conocimiento	19
5.1. Pre-Procesamiento	19
5.2. Minería de Datos	19
5.3. Visualización y Generación de Informes	20
5.4. Preguntas de Comprensión	21
6. Proceso de Obtención de Conocimiento con Data Warehouse	22
6.1. Pre-Procesamiento	22
6.2. Data Warehouse	22
6.3. Minería de Datos y Visualización	22
7. Etapas de Preprocesamiento en la Minería de Datos	23
7.1. Selección de Datos	24
7.2. Limpieza de Datos	24
7.2.1. Filtrado y Limpieza de Datos	24
7.3. Enriquecimiento de Datos	25
7.4. Codificación	25
7.4.1. Completar Registros Faltantes	25
7.5. Preguntas de Comprensión	27
8. Hipótesis del Aprendizaje Automático	28
8.1. Problema Sesgo vs. Varianza	28
8.1.1. Modelo Lineal	28
8.2. Errores de la Regresión	29



8.3. Preguntas de Comprensión	32
9. Modelo No Lineal	33
9.1. Función No Lineal a Estimar	33
9.2. Problemas con el Ajuste Lineal	33
9.3. Error en Ajuste Polinomial	33
9.4. Error y Varianza	33
9.4.1. Sesgo	33
9.4.2. Varianza	34
9.5. Aproximador No Lineal	36
9.6. Aproximación Polinómica	36
9.7. Selección de Modelo	36
9.8. Evaluación de Error	36
9.9. Sesgo y Varianza	37
9.10. Preguntas de Comprensión	39
10. Procedimiento de ajuste de complejidad	40
11. Validación Cruzada	41
11.1. Procedimiento de la Validación Cruzada	41
11.2. Cálculo del Error	41
11.3. Intervalo de Confianza	42
12. Proceso de Regularización	42
12.1. Preguntas de Comprensión	43
13. La Navaja de Occam	44
13.1. Longitud de Descripción Mínima	45
13.2. Preguntas de Comprensión	46
14. Bases de Datos Analíticas (Data Warehouse)	47
14.1. Limitaciones de las BD Operacionales	47
14.2. Características de un DW	47
14.3. Data Marts	47
14.4. Análisis y Minería de Datos	47
14.5. Arquitectura para Decisiones en Tiempo Real	48
14.6. Estructuras Multidimensionales	48
14.7. Preguntas de Comprensión	49

1. Definiciones

Algunas definiciones* importantes que se profundizaran más adelante:

★ **Análisis de datos:**

Proceso de examinar, organizar, transformar e interpretar datos con el fin de extraer información útil, identificar regularidades y apoyar la comprensión de un fenómeno o la toma de decisiones.

★ **Algoritmos de aprendizaje:**

Procedimientos computacionales mediante los cuales un sistema mejora su desempeño a partir de la experiencia, ajustando sus parámetros, su representación o su comportamiento con base en datos, ejemplos o retroalimentación del entorno.

★ **Aprendizaje basado en ejemplos:**

Paradigma de aprendizaje en el que un sistema generaliza a partir de ejemplos específicos, normalmente pares de entrada-salida, para inducir una función, clasificación o regla que permita tratar correctamente casos no vistos.

★ **Aprendizaje de máquinas (Machine Learning):**

Subcampo de la inteligencia artificial que estudia la capacidad de un sistema para mejorar su desempeño basándose en la experiencia. En este sentido, una máquina aprende cuando usa datos u observaciones para modificar su conducta futura de manera que actúe mejor en una tarea.

★ **Minería de datos (Data Mining):**

Proceso de descubrimiento de patrones, regularidades, relaciones o conocimiento potencialmente valioso a partir de grandes conjuntos de datos, usualmente mediante técnicas estadísticas, de aprendizaje automático y de reconocimiento de patrones.

★ **Inteligencia Computacional:**

Rama de la inteligencia artificial que incluye técnicas como redes neuronales, algoritmos genéticos y sistemas difusos, diseñada para resolver problemas específicos mediante la simulación del comportamiento y procesamiento cognitivo humano.

★ **Inteligencia Artificial (IA):**

Disciplina que estudia y construye agentes capaces de percibir su entorno y actuar de manera que alcancen el mejor resultado esperado; en la formulación moderna del campo, la IA se entiende como el estudio de sistemas que hacen lo correcto en función de sus objetivos y de la información disponible.

*La mayoría de las definiciones presentadas en esta sección fueron elaboradas basadas en el trabajo de Russell y Norvig [3].

1.1. Bases para Decisiones Informadas

★ Datos:

Representan hechos brutos o medidas sin procesar que describen características de objetos, eventos o personas. Los datos son la materia prima utilizada para la creación de información. Pueden estar en forma estructurada o no estructurada y requieren de procesamiento y análisis para convertirse en útiles.

★ Información:

Resultado del procesamiento de datos, organizados de manera que representen un significado relevante para el usuario. La información es datos procesados que han sido contextualizados dentro de un marco que les da estructura y significado, facilitando la toma de decisiones o el aumento del entendimiento.

★ Conocimiento:

Comprensión obtenida a través del análisis e interpretación de la información. El conocimiento implica la integración de la información en un contexto que permite evaluar su relevancia y aplicarla a decisiones o acciones. Incluye no solo datos e información, sino también la comprensión y la experiencia acumulada que se utilizan para interpretar, filtrar y tomar decisiones más informadas.

★ Meta Conocimiento:

Conocimiento sobre el conocimiento. Incluye las reglas, las estrategias y las metodologías utilizadas para manejar y organizar el conocimiento existente. El meta conocimiento permite a los individuos y organizaciones comprender cómo se obtiene, se valida, se utiliza y se conserva el conocimiento, facilitando su gestión eficaz.




Figura 1: Estructura piramidal que representa una reducción en cantidad.

★ Descubrimiento de Conocimiento en Bases de Datos (KDD)

Es un proceso general y completo que incluye la selección de datos, su limpieza, el incremento con datos adicionales, su transformación, la minería de datos, la interpretación y la evaluación de los patrones encontrados en los datos. La minería de datos es solo una parte de este proceso, la cual implica el uso de algoritmos específicos para extraer patrones y modelos a partir de grandes conjuntos de datos.

La confusión surge porque la minería de datos, siendo la parte más visible y técnica del proceso, a menudo se destaca más y puede ser mal entendida como el proceso completo de KDD. Sin embargo, la minería de datos por sí sola no garantiza el descubrimiento de conocimiento útil si no está precedida y seguida por las otras etapas necesarias que garantizan que los datos sean correctos, relevantes y presentados de una manera que pueda apoyar la toma de decisiones.

El punto clave es que el proceso completo de KDD es necesario para transformar los datos crudos en conocimiento que pueda ser utilizado estratégicamente, mientras que la minería de datos es una etapa importante, pero no la única, dentro de ese proceso mayor.

2. Contexto Histórico

Linea de tiempo del Paradigma Conexionista:

- ★ **1940s - McCulloch y Pitts:** Modelos iniciales de neuronas artificiales.
- ★ **1950 - Turing Test:** Propuesto por Alan Turing para evaluar la capacidad de una máquina de exhibir inteligencia indistinguible de la de un humano.
- ★ **1960 - Regla Delta:** Introducida por Widrow y Hoff, fundamental para el aprendizaje de redes neuronales.
- ★ **1986 - Retropropagación del error:** Desarrollada por Rumelhart, Hinton y Williams, crucial para el entrenamiento de redes neuronales multicapa.
- ★ **2010 - Redes profundas:** Popularización del aprendizaje profundo gracias a investigadores como Hinton, LeCun y Bengio.




Figura 2: Linea de tiempo del Paradigma Conexionista

2.1. Touring

Alan Turing fue un matemático y lógico británico cuyas teorías y contribuciones tuvieron un profundo impacto en el desarrollo de la computación moderna y el campo de la inteligencia artificial.

2.2. La Máquina de Turing

La Máquina de Turing (1936) es un concepto teórico fundamental en la teoría de la computación. Turing ideó un modelo matemático de una máquina hipotética capaz de ejecutar cálculos al manipular símbolos en una tira de cinta según un conjunto de reglas o un “programa”. Este modelo sirve como el fundamento de lo que hoy consideramos un algoritmo y se convirtió en la base para la teoría de lo que se puede calcular. Es crucial para el aprendizaje automático y la inteligencia artificial, ya que establece los límites de lo que un algoritmo computacional puede hacer y hasta qué punto las máquinas podrían “aprender” o simular inteligencia.

2.3. El Test de Turing

El Test de Turing, propuesto en su artículo “Computing Machinery and Intelligence” [4], es un criterio para evaluar la inteligencia de una máquina. Según Turing, una máquina se puede considerar inteligente si es capaz de mantener una conversación con un humano sin que este último pueda distinguir si está interactuando con una máquina o con otro ser humano. Este test sigue siendo un punto de referencia conceptual en el campo de la IA, para debatir y analizar la capacidad de las máquinas para imitar el pensamiento humano. En la práctica, ha inspirado muchas competencias y ha llevado a importantes avances en áreas como el procesamiento del lenguaje natural y los chatbots.

Propuesta para la explicación del test:

I. Preparación:

Imagina que estás en una sala con dos terminales de computadora. Uno está conectado a un ser humano en una sala separada y el otro a una máquina (como una computadora programada para responder preguntas).

II. Interacción Anónima:

A través de los terminales, puedes conversar por escrito con ambos, el ser humano y la máquina. Puedes hacer cualquier pregunta o comentar cualquier cosa, desde preguntas técnicas hasta chistes.

III. Evaluación:

Tu tarea es decidir cuál terminal está conectado al ser humano y cuál a la máquina. La máquina intenta responder de manera que se asemeje lo más posible a cómo lo haría un ser humano.

IV. Juicio:

Después de un tiempo interactuando con ambos (por lo general se establece un tiempo determinado para la prueba), debes adivinar cuál de los interlocutores es la máquina.

V. Resultados:

Si no puedes hacer una distinción clara entre la máquina y el ser humano, o si te equivocas en la identificación, entonces se dice que **la máquina ha pasado el Test de Turing**, demostrando una forma de inteligencia artificial.

★ Para un ingeniero biomédico, es útil pensar en el Test de Turing como una analogía de los ensayos clínicos para dispositivos médicos. Como un dispositivo debe demostrar que funciona de manera indistinguible de un estándar de referencia (o en algunos casos, mejor que la ausencia de tratamiento) en un ensayo clínico, la máquina en el Test de Turing debe demostrar que puede imitar el comportamiento inteligente a un nivel que sea indistinguible de un ser humano.

Desde una mirada profesional, ambas contribuciones de Turing son fundamentales para entender los principios de la computación y la inteligencia artificial. La Máquina de Turing nos ayuda a comprender la lógica subyacente a los sistemas de aprendizaje automático, mientras que el Test de Turing sigue provocando debates sobre la naturaleza de la inteligencia y el aprendizaje. Estos conceptos subrayan la intersección entre la tecnología y la filosofía, animándonos a considerar no solo cómo las máquinas pueden imitar la inteligencia, sino también qué significa ser inteligente.

2.4. Regla Delta (Adelaine)

La **Regla Delta**, también conocida como la regla de aprendizaje de Widrow-Hoff, fue introducida en la década de 1960 y representa un método fundamental en el entrenamiento de perceptrones, una forma temprana y simple de red neuronal artificial. Se basa en la idea de ajustar los pesos de las conexiones neuronales de manera iterativa para minimizar el error entre la salida predicha por la red y la salida esperada (valor real). Este método puede ser aplicado tanto en máquinas de cómputo analógicas como digitales.

La regla delta actualiza los pesos siguiendo la ecuación:

$$w_i(n+1) = w_i(n) + \eta(y - \hat{y})x_i$$

donde w_i es el peso del i -ésimo elemento de entrada, η es la tasa de aprendizaje, y es la salida deseada, $\hat{y}$ es la salida producida por la perceptrona y x_i es el valor del i -ésimo elemento de entrada.




Figura 3: Estructura de una neurona biológica y su correspondencia conceptual en redes neuronales. La imagen muestra el cuerpo celular y las dendritas, los cuales representan la entrada de información, y el axón, que transmite la señal resultante.




Figura 4: Diagrama de una neurona artificial en una red neuronal. Cada entrada X_i es ponderada por un peso w_i , se suman todas las entradas ponderadas, y se aplica una función de activación para producir la salida Y .

Sin embargo, Marvin Minsky en su libro *"Perceptrons: An Introduction to Computational Geometry"* [5] demostró las limitaciones de los perceptrones, particularmente su incapacidad para resolver problemas que no son linealmente separables, como la función XOR. Esta crítica fue un factor significativo en la reducción de interés y financiamiento en la investigación de redes neuronales durante la era conocida como el *"invierno de la IA"*.

2.5. Retropropagación del Error

Introducida en 1986, la **retropropagación del error** es un algoritmo central para entrenar redes neuronales artificiales, particularmente aquellas con múltiples capas ocultas. Este algoritmo es una extensión de la *Regla Delta*, mejorando su capacidad para trabajar con redes profundas y funciones no lineales.

La retropropagación efectivamente entrena el aproximador de función no lineal de una red neuronal ajustando los pesos sinápticos en función del error calculado entre la salida obtenida y la salida esperada. Este ajuste se realiza en sentido inverso: desde la salida hacia la entrada, a través de todas las capas intermedias, de ahí su nombre.

El proceso implica dos pasos fundamentales:

- ★ **Propagación hacia adelante:** Cada entrada de la red se pasa a través de las capas sucesivamente para generar una salida.
- ★ **Retropropagación del error:** El error de la salida (la diferencia entre la salida esperada y la obtenida) se propaga hacia atrás desde la salida, actualizando los pesos de cada conexión para minimizar el error en futuras predicciones.

El ajuste de los pesos se realiza utilizando la regla de descenso de gradiente, la cual se define como:

$$W_{ij}^{(new)} = W_{ij}^{(old)} - \eta \frac{\partial E}{\partial W_{ij}}$$

donde W_{ij} representa el peso entre la neurona i en una capa y la neurona j en la siguiente capa, η es la tasa de aprendizaje, y $\frac{\partial E}{\partial W_{ij}}$ es el gradiente de la función de error respecto al peso W_{ij} .

La habilidad de la retropropagación para ajustar pesos en redes multicapa la hace poderosa para el aprendizaje de características jerárquicas en datos complejos, lo que es un pilar fundamental del aprendizaje profundo actual.




Figura 5: Red con capas ocultas

2.6. Redes Neuronales Profundas

A partir de 2010, las **redes neuronales profundas** empezaron a ganar notoriedad significativa dentro de la comunidad científica y tecnológica debido a sus capacidades mejoradas para modelar y procesar datos con estructuras complejas. Estas redes son extensiones de las redes neuronales tradicionales que incluyen múltiples capas ocultas, lo que les permite aprender representaciones de datos a múltiples niveles de abstracción.

Las redes neuronales profundas están inspiradas en las estructuras cerebrales avanzadas y utilizan una arquitectura en capas para el procesamiento de información. Cada capa de la red puede considerarse como un nivel de procesamiento, donde los datos de entrada son transformados de manera progresiva a través de funciones no lineales aplicadas por neuronas artificiales. El número de capas y la complejidad de las conexiones entre ellas permiten que estas redes realicen tareas de reconocimiento de patrones y clasificación con una eficacia sin precedentes.

2.6.1. Funcionamiento de las Redes Neuronales Profundas

El funcionamiento de las redes neuronales profundas se basa en los siguientes pasos:

- ★ **Propagación hacia adelante:** Los datos de entrada se procesan capa por capa, desde la entrada hasta la salida. En cada capa, las neuronas suman sus entradas ponderadas y aplican una función de activación no lineal para producir una salida.
- ★ **Retropropagación y ajuste de pesos:** Después de calcular la salida, el error (la diferencia entre la salida esperada y la obtenida) se propaga de vuelta a través de la red para ajustar los pesos de las conexiones, minimizando el error en predicciones futuras mediante el algoritmo de descenso del gradiente.

La profundidad de estas redes, que puede incluir desde algunas hasta cientos de capas, permite la extracción automática y jerárquica de características, aprendiendo desde los detalles más simples en las primeras capas hasta los patrones más abstractos y complejos en las capas más profundas.

La introducción de técnicas innovadoras como las funciones de activación mejoradas, la inicialización de pesos optimizada y los métodos avanzados para combatir el sobreajuste, como el *dropout*, ha permitido que las redes neuronales profundas transformen radicalmente campos como la visión por computadora, el procesamiento del lenguaje natural y el análisis predictivo.

2.7. Bonus: Deep learning, perspectiva de LeCun, Bengio y Hinton

★ Aunque los aspectos desarrollados en esta subsección no formen parte del contenido central del curso, resultan valiosos como complemento conceptual para quienes deseen profundizar en los fundamentos matemáticos y operativos del *deep learning*.

En su influyente revisión sobre *deep learning* [6], Yann LeCun, Yoshua Bengio y Geoffrey Hinton presentan una síntesis clara del principio que hizo posible el entrenamiento efectivo de redes neuronales profundas: la combinación entre representaciones multicapa y el algoritmo de retropropagación. La Figura 6 resume esta idea desde dos perspectivas complementarias: por una parte, muestra cómo una red multicapa transforma progresivamente el espacio de representación hasta facilitar la separación de clases, por otra, expone el fundamento matemático que permite ajustar sus pesos mediante la regla de la cadena y el cálculo del gradiente del error.




Figura 6: Funcionamiento de una red neuronal multicapa y el principio matemático de la retropropagación [6].

(a) Una red neuronal multicapa puede transformar el espacio de entrada de modo que clases de datos originalmente no separables de forma lineal pasen a ser separables linealmente en una representación interna. En el ejemplo mostrado, una rejilla regular en el espacio de entrada se deforma al pasar por las unidades ocultas. Se

trata de un caso ilustrativo con 2 unidades de entrada, 2 unidades ocultas y 1 unidad de salida.

(b) Se representa la *regla de la cadena* para derivadas. Un pequeño cambio Δx en x produce un cambio Δy en y , dado por

$$\Delta y = \frac{\partial y}{\partial x} \Delta x.$$

A su vez, el cambio en y induce un cambio Δz en z :

$$\Delta z = \frac{\partial z}{\partial y} \Delta y.$$

Sustituyendo la primera expresión en la segunda, se obtiene

$$\Delta z = \frac{\partial z}{\partial y} \frac{\partial y}{\partial x} \Delta x,$$

y por tanto

$$\frac{\partial z}{\partial x} = \frac{\partial z}{\partial y} \frac{\partial y}{\partial x}.$$

Este mismo principio se extiende al caso en que x , y y z son vectores, donde las derivadas se expresan mediante matrices jacobianas.

(c) Se muestran las ecuaciones del *paso hacia adelante* (*forward pass*) en una red con dos capas ocultas y una capa de salida. Para cada unidad, primero se calcula la entrada total z como suma ponderada de las salidas de la capa anterior y luego se aplica una función no lineal $f(\cdot)$:

$$z_j = \sum_i w_{ij} x_i, \quad y_j = f(z_j),$$

$$z_k = \sum_j w_{jk} y_j, \quad y_k = f(z_k),$$

$$z_l = \sum_k w_{kl} y_k, \quad y_l = f(z_l).$$

En la figura se omiten los términos de sesgo. Entre las funciones de activación indicadas están:

$$f(z) = \max(0, z) \quad (\text{ReLU}),$$

$$f(z) = \frac{\exp(z) - \exp(-z)}{\exp(z) + \exp(-z)} \quad (\text{tangente hiperbólica}),$$

$$f(z) = \frac{1}{1 + \exp(-z)} \quad (\text{función logística}).$$

(d) Se muestran las ecuaciones del *paso hacia atrás* (*backward pass*). En cada capa oculta se calcula primero la derivada del error respecto de la salida de cada unidad como suma ponderada de las derivadas del error de la capa superior:

$$\frac{\partial E}{\partial y_k} = \sum_{l \in \text{out}} w_{kl} \frac{\partial E}{\partial z_l}, \quad \frac{\partial E}{\partial y_j} = \sum_{k \in H2} w_{jk} \frac{\partial E}{\partial z_k}.$$

Luego, dichas derivadas se transforman en derivadas respecto de la entrada total de cada unidad multiplicando por la derivada de la activación:

$$\frac{\partial E}{\partial z_k} = \frac{\partial E}{\partial y_k} \frac{\partial y_k}{\partial z_k}, \quad \frac{\partial E}{\partial z_j} = \frac{\partial E}{\partial y_j} \frac{\partial y_j}{\partial z_j}.$$

En la capa de salida, la derivada del error respecto de la salida se obtiene derivando la función de costo. Si para la unidad l se usa

$$E = \frac{1}{2}(y_l - t_l)^2,$$

entonces

$$\frac{\partial E}{\partial y_l} = y_l - t_l.$$

Finalmente, una vez conocido $\partial E / \partial z_k$, la derivada del error respecto del peso w_{jk} asociado a la conexión desde la unidad j de la capa inferior hacia la unidad k es

$$\frac{\partial E}{\partial w_{jk}} = y_j \frac{\partial E}{\partial z_k}.$$

2.8. Preguntas de Comprensión

- ★ ¿Cuál es la importancia del modelo de neurona artificial propuesto por McCulloch y Pitts en la década de 1940, y cómo influyó en el desarrollo de las redes neuronales?
- ★ ¿Qué es la Máquina de Turing y por qué se considera un pilar en la teoría de la computación y los fundamentos de la inteligencia artificial?
- ★ Explique en qué consiste el Test de Turing y cómo evalúa la capacidad de una máquina para demostrar inteligencia comparable a la humana. ¿Qué relevancia tiene este test en la actualidad?
- ★ ¿Cómo funciona la Regla Delta de Widrow y Hoff en el aprendizaje de una red neuronal y cuál es su papel en la adaptación de los pesos de una red para reducir el error?
- ★ Describa el proceso de retropropagación del error en redes neuronales. ¿Por qué este algoritmo fue crucial para el avance de las redes neuronales multicapa?

3. Aprendizaje Automático y Codificación de Datos

El **Aprendizaje Automático (AA)** es una rama de la inteligencia artificial que permite a las máquinas aprender de los datos y mejorar su desempeño sin estar explícitamente programadas para tareas específicas. Este aprendizaje se realiza a través de la codificación de datos y el ajuste de modelos.

¿Cómo aprenden palabras estas máquinas?

Las máquinas aprenden palabras mediante la codificación de las mismas en formatos numéricos que pueden ser procesados. Esto generalmente implica convertir cada palabra en un vector en un espacio de alta dimensión, donde cada dimensión representa una característica lingüística o contextual única. Esta técnica se conoce como *word embedding*.

¿Cómo aprenden imágenes estas máquinas?

Similar a las palabras, las máquinas aprenden imágenes codificando las características visuales de las imágenes en la entrada. Esto se logra utilizando *Redes Neuronales Convolucionales (CNN)* que son capaces de extraer patrones jerárquicos en los datos visuales, como bordes, texturas y formas, que se combinan en capas superiores para representar objetos más complejos.

3.1. Tipos de Inteligencia Artificial

3.1.1. Inteligencia Específica o Débil

La mayoría de los sistemas de AA actuales generan lo que se denomina **inteligencia específica** o **inteligencia débil**. Estos sistemas están diseñados para realizar tareas muy específicas o resolver problemas limitados. No poseen consciencia ni comprensión general del mundo, sino que operan bajo un conjunto limitado de contextos y reglas.

Un ejemplo en la industria es el desarrollo de modelos como los de Meta y LeCun.

Ejemplo: ChatGPT

es una IA específica diseñada para generar texto de manera coherente y contextualmente relevante. Su impacto se justifica porque puede pasar pruebas como el Test de Turing, donde se evalúa su capacidad para imitar el lenguaje humano hasta el punto de ser indistinguible de un humano en conversaciones textuales.

3.1.2. Inteligencia Fuerte

Es una forma hipotética de inteligencia artificial que supone igualar o superar la inteligencia humana en todas las áreas, incluyendo el razonamiento general, la resolución de problemas y la adaptación a nuevos contextos. Actualmente, esto es más un concepto teórico que una realidad.

3.1.3. IA Generalizable

Entre la inteligencia específica y la fuerte, existen iniciativas en el desarrollo de la **IA generalizable**. Estos sistemas están diseñados para realizar múltiples tareas y transferir conocimiento entre ellas, mostrando una flexibilidad mucho mayor en comparación con la IA específica.

3.2. Análisis del Aprendizaje Automático como Herramienta Cognitiva

El **aprendizaje automático** es una de las herramientas más novedosas y potentes que la ciencia y la tecnología han desarrollado para la humanidad. A diferencia de las herramientas tradicionales que facilitan tareas físicas o repetitivas, el aprendizaje automático actúa como una *herramienta cognitiva*, capaz de interpretar, aprender de los datos y tomar decisiones de manera autónoma, lo que lo distingue significativamente de los desarrollos tecnológicos anteriores.

4. Modelo de Sistema de Información Operacional

Un **Sistema de Información (SI)** es una representación estructurada de los datos generados a partir de diversas medidas de fenómenos físicos como imágenes, voces, textos y procesos industriales.

La estructura de un SI se puede describir como una 4-tupla de la forma:

$$SI = \langle U, Q, V, f \rangle$$

donde:

- ★ U es un universo cerrado: un conjunto finito, no vacío, de n objetos, $\{x_1, x_2, \dots, x_n\}$.
- ★ Q es un conjunto finito, no vacío, de p atributos $\{q_1, q_2, \dots, q_p\}$.
- ★ $V = \bigcup_{q \in Q} V_q$ es un conjunto de dominios de los atributos, donde V_q es el dominio (valor) de los atributos q .
- ★ $f : U \times Q \rightarrow V$ es una función de decisión llamada función de información, tal que $f(x, q) \in V_q$ para cualquier $q \in Q, x \in U$.
- ★ Un par (q, v) donde $q \in Q$ y $v \in V_q$ es llamado descriptor en un sistema de información SI.

El SI puede ser representado por una tabla finita de datos, donde las columnas están indicadas por los atributos, las filas por los objetos y la entrada para la columna q y la fila x_i resulta en la instancia de la función de información $f(x_i, q)$.

Ej: Descripción de automóviles

Objeto		Atributos	
U	Potencia	Caja Vel.	Tipo
x_1	140 HP	4	Sedan
x_2	120 HP	5	Hashback
x_3	100 HP	Autom.	SW
x_4	120 HP	Autom.	Sedan
x_5	100 HP	5	Hashback
x_6	140 HP	5	SW

Donde:

- ★ $U = \{x_1, x_2, x_3, x_4, x_5, x_6\}$
- ★ $Q = \{\text{Potencia, Caja Velocidades, Tipo}\}$
- ★ $V_{\text{potencia}} = \{100, 120, 140\}, V_{\text{c.v.}} = \{4, 5, \text{Automático}\}, V_{\text{tipo}} = \{\text{Sedan, Hashback, SW}\}$
- ★ $f(x_3, \text{Tipo}) = \text{SW}$.

En general este sistema se denomina:

★ **Sistema de Información Operacional o Base de Datos Operacional** pues está destinado a la realización de consultas (tipo SQL) que tienen que ver con la operación normal del proceso que apoya, desde el punto de vista informático.

5. Estructura del Proceso de Obtención de Conocimiento

La definición clásica de **Obtención de Conocimiento de Bases de Datos o Knowledge Discovery in Databases (KDD)**, la describe como el:

“proceso no trivial de identificación válido, novedoso, potencialmente útil, y esencialmente entendible de obtención de patrones de los datos”

5.1. Pre-Procesamiento

Incluye técnicas para la limpieza y preparación de los datos, asegurando que la minería de datos se realice sobre información precisa y relevante.

La preparación de los datos para su análisis se subdivide en:

- ★ Selección de los datos relevantes.
- ★ Limpieza de datos, que incluye la eliminación de errores o datos incompletos.
- ★ Enriquecimiento de datos, donde se pueden agregar nuevas fuentes de datos para mejorar la calidad de la información.
- ★ Codificación de datos, transformándolos a un formato adecuado para su procesamiento posterior.

5.2. Minería de Datos

Aplicación de algoritmos específicos para extraer patrones y modelos a partir de los datos procesados.

Se atribuye a un grupo de investigadores compuesto por Gregory Piatetsky-Shapiro, William Frawley y otros, quienes estaban entre los primeros en articular y definir formalmente el campo de la minería de datos. El año 1989 es significativo porque marca uno de los primeros usos documentados del término “Minería de Datos” en la literatura científica.

Esta definición resalta varias características clave de lo que la minería de datos implica:

- ★ No trivial: Se refiere a que los patrones que se descubren no son obvios o inmediatos; requieren un proceso de búsqueda y análisis profundo.
- ★ Identificación válido: Los patrones encontrados deben ser estadísticamente significativos y no el resultado de ruido o variaciones aleatorias en los datos.

- ★ Novedoso: Los patrones deben proporcionar información nueva y no conocida previamente.
- ★ Potencialmente útil: Los resultados deben tener aplicabilidad práctica y la capacidad de ser aplicados en un contexto real para resolver problemas o mejorar procesos.
- ★ Esencialmente entendible: A pesar de la complejidad de los métodos y algoritmos utilizados, los patrones descubiertos deben ser presentados de tal manera que sean comprensibles y accionables por los humanos.

Este enfoque de proceso distinto y riguroso, fue fundamental para establecer el campo y diferenciarlo de otras actividades analíticas menos estructuradas.

5.3. Visualización y Generación de Informes

Representación gráfica de los resultados y comunicación de los hallazgos de una manera entendible y accesible.

Esta secuencia de pasos (Figura 7) resalta cómo los datos crudos se transforman en información comprensible y conocimiento útil.




Figura 7: Proceso de análisis de datos.

5.4. Preguntas de Comprensión

- ★ ¿Qué se entiende por Obtención de Conocimiento de Bases de Datos (KDD) y cuáles son sus características principales?
- ★ ¿Cuáles son las etapas del pre-procesamiento de datos?
- ★ ¿Qué papel juega la minería de datos en el proceso de obtención de conocimiento?
- ★ ¿Por qué es importante la visualización y generación de informes en el proceso de obtención de conocimiento?
- ★ ¿Qué distingue a la minería de datos de otras actividades analíticas menos estructuradas?

6. Proceso de Obtención de Conocimiento con Data Warehouse

Una forma general de presentar el proceso de obtención de conocimiento en el campo del análisis de datos comienza con la construcción de un **Data Warehouse (DW)** tras realizar una serie de operaciones de pre-procesamiento. El DW actúa como un repositorio centralizado donde los datos se almacenan de manera coherente y unificada, facilitando así el análisis y la extracción de conocimiento a través de la minería de datos.

6.1. Pre-Procesamiento

El pre-procesamiento es un conjunto de procedimientos aplicados a los datos crudos para prepararlos para el análisis. Estos sub-procesos incluyen:

- ★ Selección de datos relevantes para el problema o la consulta.
- ★ Limpieza de datos para corregir o eliminar datos incorrectos o incompletos.
- ★ Enriquecimiento de datos, añadiendo información de otras fuentes para mejorar los conjuntos de datos existentes.
- ★ Codificación y transformación de datos en formatos adecuados para el análisis.

A menudo, se utiliza SQL (Structured Query Language) para interactuar con bases de datos durante el pre-procesamiento para extraer y manipular el conjunto de datos necesario para el DW.

6.2. Data Warehouse

Una vez que los datos están pre-procesados, se transfieren al DW. El DW es un sistema que recopila, almacena y gestiona grandes cantidades de datos provenientes de diferentes fuentes. Su estructura está diseñada para facilitar consultas y análisis complejos, lo que lo hace ideal para el proceso de minería de datos.

6.3. Minería de Datos y Visualización

La etapa final es la minería de datos, que implica aplicar algoritmos y técnicas estadísticas para descubrir patrones, tendencias y correlaciones en los datos almacenados en el DW. Los hallazgos se presentan luego a través de la visualización, usando gráficos, tablas y otros medios para comunicar el conocimiento obtenido de manera efectiva.

Es importante destacar que el pre-procesamiento es una disciplina en sí misma, con técnicas que, aunque compartidas con la minería de datos, no se consideran minería de datos como tal. Su objetivo principal es preparar los datos para el análisis, no necesariamente extraer conocimiento de ellos.




Figura 8: Flujo del Proceso de Obtención de Conocimiento.

7. Etapas de Preprocesamiento en la Minería de Datos




Figura 9: Flujo de Proceso en la Gestión y Análisis de Datos

Para ilustrar las diferentes fases de la etapa de preprocesamiento, consideremos una base de datos operacional de una librería que realiza ventas por internet de distintos géneros de libros, como naturaleza, arquitectura, computación, arte, educación, medicina, música, ficción, entre otros. Los objetivos de la minería de datos en este contexto pueden ser variados, incluyendo:

- ★ Análisis de requerimientos del departamento de marketing para el diseño de catálogos.
- ★ Creación del perfil de un lector típico de libros de computación.
- ★ Investigación de la correlación entre el interés de los lectores en libros de computación y de ficción.

7.1. Selección de Datos

La selección de datos se realiza generalmente desde una base de datos operacional. Para facilitar el proceso, los datos suelen copiarse en otra base de datos, a menudo denominada base de datos analítica. El principal objetivo es seleccionar datos que contengan la información o conocimiento que se desea obtener. Este proceso requiere conocimiento experto en el dominio de interés, así como habilidades en muestreo estadístico.

7.2. Limpieza de Datos

Diversos tipos de limpieza o filtrado de datos pueden ser aplicados en esta etapa. Sin embargo, es común que algunos problemas en los datos solo se detecten en las etapas de codificación o de minería de datos propiamente dicha. Algunos de los problemas más comunes detectados durante la limpieza de datos incluyen:

- ★ Duplicación de registros.
- ★ Fechas fuera de rango.
- ★ Registros incompletos o con falta de campos.
- ★ Registros diferentes que comparten los mismos campos.

Preprocesamiento de Datos en una Librería Online

Consideremos una librería que realiza ventas a través de internet. La base de datos de clientes puede tener la siguiente estructura:

Tabla 1: Ejemplo: Librería que realiza ventas por INTERNET

Cliente N°	Nombre	Dirección	Fecha Compra	Tipo
54011	Johnson	12 road street 20, USA	25/12/98	Arte
54012	Pacheco	359 Maipu, AR	01/01/01	Musica
54013	Stabros	129 Liking, GR	29/06/95	Edu.
54014	Martinez	2 Plaza, SP	05/11/97	Ficción
54015	Matuz	25 Av. Terra, SP	11/11/11	Arte
54016	Müller	134 Lutero, GR	15/12/98	Edu.

La detección visual o intuitiva de problemas en los datos no siempre es suficiente. En muchos casos, se requieren métodos automáticos de detección que incorporen cierto grado de inteligencia. El filtrado o limpieza de datos, si bien es una disciplina diferente de la minería de datos, comparte muchas técnicas con ella.

7.2.1. Filtrado y Limpieza de Datos

Los algoritmos de reconocimiento de patrones se utilizan tanto en la minería de datos como en la limpieza de datos. Pueden ayudar a identificar y corregir problemas comunes, como registros duplicados, fechas fuera de rango o campos faltantes.

7.3. Enriquecimiento de Datos

El enriquecimiento de datos implica agregar información que aumente el valor de los datos existentes. Por ejemplo, se puede enriquecer la base de datos de clientes con:

- La ciudad correspondiente a cada dirección.
- La distancia desde la ciudad del cliente hasta los centros de distribución.

Este enriquecimiento puede conectar con la próxima etapa de codificación, utilizando conocimiento adicional para transformar la información semántica en cuantitativa.

Semántica → Cuantitativa

Tabla 2: Base de datos de clientes de una librería en Internet

Cliente Nº	Nombre	Edad	Dirección	País/ Ciudad	Fecha Compra	Tipo
54011	Johnson	54	12 road street 20	USA/NY	25/12/98	Arte
54012	Pacheco	23	13 Lasalle	AR/Bu.Ai.	01/01/01	Música
54013	Stabros	43	129 Liking	GR/Colo.	29/06/95	Edu.
54014	Martinez	33	2 Plaza	SP/Bilbao	05/11/97	Ficción
54015	Matuz	27	25 Av. Terra	SP/Madrid	11/11/11	Arte y Edu.
54016	Müller	19	134 Lutero	GR/Berl.	15/12/98	Edu.

7.4. Codificación

Durante esta etapa en el proceso de preparación de datos para la minería de datos, enfrentamos el desafío de cómo manejar los registros incompletos o inconsistentes. Las etapas anteriores, como la selección y la limpieza de datos, a menudo pueden manejarse con sentencias SQL. Sin embargo, la codificación requiere decisiones estratégicas adicionales:

- ★ **Registros con Información Faltante:** Una opción común es eliminar registros con información faltante, especialmente si el conjunto de datos es lo suficientemente grande como para mantener la consistencia estadística sin ellos.
- ★ **Registros con Información Inconsistente:** De manera similar, los registros inconsistentes a menudo se descartan para preservar la integridad de los análisis de MD.

Es crucial ser cauteloso durante este proceso, ya que la eliminación de estos registros puede llevar a la pérdida de información valiosa. En algunos casos, la información que falta o es inconsistente puede indicar problemas subyacentes, como fraude o errores sistemáticos, y puede revelar patrones que son significativos para el análisis.

7.4.1. Completar Registros Faltantes

Cuando los registros son escasos y cada punto de datos es valioso, podemos emplear técnicas para completar la información faltante:

- ★ **Imputación Simple:** Llenar los datos faltantes con medidas de tendencia central como la media o la mediana para datos numéricos, o la moda para datos categóricos.

- ★ **Imputación Múltiple:** Una técnica más sofisticada que considera la incertidumbre en la imputación y utiliza múltiples conjuntos de valores posibles para los datos faltantes.
- ★ **Algoritmos Predictivos:** Utilizar modelos estadísticos o de aprendizaje automático para predecir y reemplazar los valores faltantes basados en otros datos disponibles en el conjunto de datos.

El objetivo es mantener la calidad y la utilidad del conjunto de datos para análisis posteriores, asegurando que la información utilizada para la MD sea lo más completa y precisa posible.

Cuando una variable es de tipo cualitativo (de cardinalidad n), es común utilizar una representación con n variables binarias, conocida como *flattening*.

★ Flattening

Hace referencia al proceso de convertir una estructura de datos multidimensional en una estructura unidimensional. Este proceso es crucial en varias etapas del preprocesamiento de datos, especialmente cuando se preparan los datos para algoritmos de aprendizaje automático que requieren entradas en forma de vectores lineales.

Aplicaciones:

- **Procesamiento de imágenes:** Puede implicar convertir los datos de una imagen 2D (una matriz de píxeles) en un vector 1D.
- **Codificación de categorías de datos cualitativos:** Puede referirse a la creación de variables binarias (dummies) para cada categoría posible.

★ El proceso de *flattening* es un paso fundamental en el preprocesamiento, ya que los datos de entrada a menudo deben ser transformados en un formato compatible con las técnicas de modelado estadístico y aprendizaje automático.

7.5. Preguntas de Comprensión

- ★ ¿Cuál es el propósito de un *Data Warehouse (DW)* en el proceso de obtención de conocimiento?
- ★ ¿Cuáles son las principales etapas del pre-procesamiento en el contexto de un DW, y por qué son importantes?
- ★ ¿Cómo se utiliza SQL durante el pre-procesamiento de datos en un DW?
- ★ ¿Qué rol desempeña la visualización en la etapa final del proceso de obtención de conocimiento?
- ★ ¿Qué es el proceso de *flattening* y por qué es importante en el pre-procesamiento de datos?

8. Hipótesis del Aprendizaje Automático

Se entiende que un programa computacional aprende de una experiencia ε para realizar una tarea τ , con una medida de eficiencia ρ , si su rendimiento en τ , medido por ρ , mejora con la experiencia ε . Estas tareas suelen incluir:

- Identificación de grupos o clusters.
- Clasificación de datos.
- Determinación de funciones desconocidas para hacer predicciones.

8.1. Problema Sesgo vs. Varianza

En el contexto del aprendizaje automático, el problema de sesgo vs. varianza es un dilema clave en la selección de modelos. Se refiere a la compensación entre la complejidad del modelo y su capacidad para generalizar a partir de datos de entrenamiento.

8.1.1. Modelo Lineal

Consideremos el modelo lineal, donde la predicción $\hat{y}$ se puede expresar como:

$$\hat{y} = \mathbf{E}[\mu_i] = \beta_0 + \sum_{i=1}^p x_i \beta_i = \vec{\beta}^T \vec{x}$$

Donde:

- $\mathbf{E}[\mu_i]$ representa la esperanza matemática o el valor esperado de la variable respuesta μ_i , es decir, el promedio de la variable respuesta que esperaríamos observar si pudiéramos repetir el experimento un número infinito de veces.
- β_0 es el término de intercepción, que representa el valor esperado de $\hat{y}$ cuando todos los predictores x_i son cero.
- β_i son los coeficientes asociados a cada predictor x_i , los cuales indican la magnitud y la dirección del efecto que el predictor x_i tiene sobre la variable respuesta $\hat{y}$.
- $\vec{\beta}^T \vec{x}$ es el producto punto del vector transpuesto de coeficientes $\vec{\beta}$ y el vector de predictores $\vec{x}$. Esta operación matemática combina los valores de los predictores con sus respectivos coeficientes para dar una estimación lineal de la variable respuesta.
- p es el número de predictores en el modelo. Esto define la dimensión del vector de coeficientes β y del vector de predictores $\vec{x}$.




Figura 10: Gráfico de regresión lineal en un plano 2D, donde se muestran los puntos de datos y la línea de mejor ajuste obtenida mediante un modelo de regresión lineal. La línea de regresión tiene una pendiente b_1 y un intercepto b_0 , indicando la relación lineal entre la variable independiente x y la variable dependiente y .




Figura 11: Gráfico de regresión en un plano 3D, donde los puntos de datos están representados en el espacio tridimensional definido por las variables x_1 , x_2 y y . Las proyecciones de los puntos al plano muestran cómo se relacionan las dos variables independientes x_1 y x_2 con la variable respuesta y , destacando la aproximación del modelo en el espacio tridimensional.

8.2. Errores de la Regresión

La descomposición de la variabilidad en un modelo de regresión lineal se puede explicar con las siguientes fórmulas y definiciones:

★ **SCT** (*Suma Total de Cuadrados*):

$$\text{SCT} = \sum_{i=1}^n (y_i - \bar{y})^2 = (n - 1) \cdot \text{var}(y) = (n - 1) \cdot \hat{\sigma}_y^2$$

- n : Número total de observaciones.
- y_i : Valor de la i -ésima observación de la variable dependiente.
- $\bar{y}$: Media de todos los valores de la variable dependiente.
- $\text{var}(y)$: Varianza de la variable dependiente.
- $\hat{\sigma}_y^2$: Estimación de la varianza de la variable dependiente.
- $\hat{y}_i$: Valor predicho por el modelo de regresión para la i -ésima observación.

Representa la variabilidad total de los datos respecto a la media. Se calcula como la suma de los cuadrados de las diferencias entre cada observación y_i y la media $\bar{y}$.

★ **SCR** (*Suma de Cuadrados de la Regresión*):

$$\text{SCR} = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

Representa la variabilidad explicada por el modelo de regresión. Es la suma de los cuadrados de las diferencias entre los valores ajustados $\hat{y}_i$ y la media $\bar{y}$.

★ **SCE** (*Suma de Cuadrados del Error*):

$$\text{SCE} = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Representa la variabilidad no explicada por el modelo de regresión. Se calcula como la suma de los cuadrados de los residuos, que son las diferencias entre cada observación y_i y su valor ajustado $\hat{y}_i$.

La relación entre estas tres cantidades se expresa en la ecuación fundamental de la descomposición de la varianza en un modelo de regresión lineal:

$$\underbrace{\sum_{i=1}^n (y_i - \bar{y})^2}_{\text{SCT}} = \underbrace{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}_{\text{SCR}} + \underbrace{\sum_{i=1}^n (y_i - \hat{y}_i)^2}_{\text{SCE}}$$




Figura 12: Errores de la regresión

★ La **SCT** también se puede expresar en términos de la varianza muestral ($\text{var}(y)$) y el número de observaciones (n):

$$\text{SCT} = (n - 1) \text{var}(y) = (n - 1) \hat{\sigma}_y^2$$

★ Varianza y Desviación Estándar

La varianza y la desviación estándar son medidas de dispersión estadística que indican cuán esparcidos están los datos alrededor de una media. La principal diferencia entre las versiones poblacional y muestral de estas medidas está en cómo se calculan y en qué contexto se utilizan.

La desviación estándar representa la dispersión de los datos en la misma escala de medida que los datos originales.

★ Varianza Muestral

La varianza muestral (s^2) se define como:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

donde:

- x_i representa cada valor individual en la muestra.
- $\bar{x}$ es la media muestral, el promedio de todos los valores de la muestra.
- n es el tamaño de la muestra, el número total de observaciones.
- $n - 1$ son los grados de libertad, utilizados en el denominador para proporcionar una estimación insesgada de la varianza poblacional.

La varianza muestral es un estimador insesgado de la varianza poblacional cuando los datos provienen de una distribución con una varianza definida.

★ Varianza Poblacional

La varianza poblacional (σ^2) se define como:

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (X_i - \mu)^2$$

donde:

- X_i es cada valor en la población.
- μ es la media poblacional.
- N es el tamaño de la población.

La varianza poblacional se utiliza cuando se considera la totalidad de la población.

8.3. Preguntas de Comprensión

- ★ ¿Cómo se define el concepto de aprendizaje en un contexto de aprendizaje automático y cuáles son los elementos clave que se deben identificar?
- ★ Explique el dilema de *sesgo vs. varianza* en el aprendizaje automático y cómo afecta la capacidad de generalización de un modelo.
- ★ En el modelo lineal, ¿qué representa el término β_0 y cómo afecta a la predicción de la variable respuesta $\hat{y}$?
- ★ ¿Cuál es la relación entre la Suma Total de Cuadrados (SCT), la Suma de Cuadrados de la Regresión (SCR) y la Suma de Cuadrados del Error (SCE) en un modelo de regresión, y qué indica esta relación?
- ★ ¿Cuál es la diferencia entre la varianza muestral y la varianza poblacional, y en qué situaciones se utiliza cada una?

9. Modelo No Lineal

En estadística y ciencia de datos, un modelo no lineal es aquel en el que la relación entre las variables independientes y la variable dependiente no se ajusta a una línea recta. En otras palabras, la relación no puede ser descrita simplemente por una ecuación lineal.

9.1. Función No Lineal a Estimar

Una función no lineal tiene la forma:

$$y = f(x, \beta)$$

donde f es una función no lineal en términos de x y β representa los parámetros del modelo.

9.2. Problemas con el Ajuste Lineal

Si intentamos realizar un ajuste lineal a datos que en realidad se ajustan a un modelo no lineal, es probable que incurramos en un error significativo. El punto desconocido (x_0, y_0) puede estar lejos de la línea ajustada, lo que resulta en una predicción inexacta.

9.3. Error en Ajuste Polinomial

Incluso si ajustamos un polinomio a todos los datos, aún podemos tener un error debido al fenómeno conocido como *overfitting*, donde el modelo se ajusta demasiado a los datos de muestra y no generaliza bien a datos no vistos.

9.4. Error y Varianza

El error total de un modelo puede descomponerse en dos componentes principales: Sesgo y Varianza.

Sesgo y Varianza en Modelos Estadísticos

9.4.1. Sesgo

El sesgo (*bias*) es una medida de cuán lejos están las predicciones promedio de un modelo de los valores verdaderos. Un modelo con alto sesgo es aquel que hace muchas suposiciones sobre la forma de la función objetivo, lo que puede conducir a un error sistemático en las predicciones. Esto generalmente resulta en un ajuste insuficiente (*underfitting*).

$$\text{Sesgo}^2 = \frac{1}{n} \sum_{i=1}^n (f(x_i) - y_i)^2$$

donde $f(x_i)$ es la función que representa el modelo, y_i son los valores verdaderos y n es el número de puntos de datos.

El **sesgo** es el error que se introduce al aproximar un problema complejo, como uno no lineal, con un modelo demasiado simple.

9.4.2. Varianza

La varianza se refiere a cuánto varían las predicciones de un modelo cuando se le proporcionan diferentes conjuntos de datos de entrenamiento. Una varianza alta significa que el modelo es muy sensible a las fluctuaciones en el conjunto de datos de entrenamiento, lo que puede resultar en un sobreajuste (*overfitting*).

$$\text{Varianza} = \frac{1}{n} \sum_{i=1}^n (\hat{f}(x_i) - \bar{y})^2$$

Aquí, $\hat{f}(x_i)$ son las predicciones del modelo, y $\bar{y}$ es la media de las respuestas observadas en el conjunto de datos.

★ La **varianza** se refiere a la cantidad que las predicciones del modelo $\hat{f}(x)$ varían alrededor de su media. Esto mide qué tan sensible es el modelo a las fluctuaciones en el conjunto de datos de entrenamiento.

★ Compensación Sesgo-Varianza

Es un fenómeno por el cual al disminuir el sesgo de un modelo (haciéndolo más complejo), a menudo aumentamos su varianza, y viceversa. Encontrar el equilibrio correcto entre estos dos es clave para desarrollar modelos precisos y robustos.




Figura 13: Ilustración gráfica de sesgo y varianza.




Figura 14: La variación del sesgo y la varianza con la complejidad del modelo. Esto es similar al concepto de sobreajuste y desajuste. Los modelos más complejos se ajustan demasiado, mientras que los modelos más simples no se ajustan bien.




Figura 15: Ilustración gráfica de sesgo y varianza más acorde.

9.5. Aproximador No Lineal

El aprendizaje en máquinas se enfrenta al reto de aproximar funciones no lineales a partir de un conjunto de muestras. Esto implica la creación de un modelo que pueda representar las complejidades inherentes a los datos no lineales.

9.6. Aproximación Polinómica

Una forma común de abordar la aproximación de funciones no lineales es mediante polinomios. Dada una función objetivo $f(x)$ y un conjunto de puntos $\{(x_1, y_1), \dots, (x_n, y_n)\}$, una aproximación polinómica intenta encontrar un polinomio $p(x)$ que se ajuste bien a estos puntos.

El polinomio de interpolación de Lagrange, por ejemplo, es un polinomio que pasa exactamente por n puntos dados. El grado del polinomio necesario para pasar exactamente por n puntos es $n - 1$. Por lo tanto, si tenemos 7 puntos, podríamos encontrar un polinomio de grado 6 que ajuste perfectamente a esos puntos:

$$p(x) = a_0 + a_1x + a_2x^2 + a_3x^3 + a_4x^4 + a_5x^5 + a_6x^6$$

9.7. Selección de Modelo

Es esencial equilibrar la complejidad del modelo con su capacidad de generalización. Esto implica ajustar polinomios de varios grados y seleccionar el mejor basado en su rendimiento con un conjunto de datos de validación.

9.8. Evaluación de Error

La evaluación del error utilizando puntos adicionales que no se incluyeron en el ajuste del modelo puede proporcionar información sobre la calidad de la aproximación.

Para evaluar qué tan bien un polinomio se ajusta a un conjunto de datos, utilizamos un conjunto de datos de prueba para calcular el error. Supongamos que usamos polinomios desde grado 1 hasta grado 8 para aproximar una función no lineal en 8 puntos. Luego, utilizamos otros 8 puntos para evaluar el error de cada polinomio. Podríamos calcular el error cuadrático medio (MSE) o cualquier otra métrica de error para comparar los diferentes ajustes polinomiales:

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - p(x_i))^2$$




Figura 16: Conjunto de puntos de muestra junto con una curva no lineal suave que ilustra una posible función de interpolación o aproximación ajustada a los datos observados.




Figura 17: Conjunto de puntos de muestra utilizados como datos de entrenamiento para construir una aproximación de una función no lineal.

9.9. Sesgo y Varianza

Un aspecto crucial al considerar aproximadores polinomiales es el balance entre el sesgo y la varianza. Un polinomio de bajo grado podría no ajustarse bien a los datos (alto sesgo), mientras que un polinomio de alto grado podría ajustarse demasiado bien a los puntos de entrenamiento pero mal a nuevos datos (alta varianza). Este es un ejemplo clásico del dilema sesgo-varianza en aprendizaje automático.

★ Usar aproximadores no lineales como los polinomios puede ser muy poderoso para modelar relaciones complejas en los datos. Sin embargo, es fundamental elegir el grado del polinomio cuidadosamente para evitar problemas como el sobreajuste y asegurar que el modelo generalice bien a nuevos datos.

- ★ Como ya se explico anteriormente, el compromiso entre el sesgo-varianza es un concepto fundamental que describe la relación entre la complejidad del modelo y su capacidad para generalizar bien a partir de los datos de entrenamiento.
- ★ El sesgo se refiere a los supuestos realizados por un modelo para facilitar su aprendizaje del objetivo.
- ★ Un modelo con alto sesgo simplifica demasiado el problema, lo que puede llevar a un sub-ajuste (*underfitting*), donde el modelo no captura la complejidad subyacente en los datos y por lo tanto tiene un rendimiento pobre.
- ★ Por otro lado, la varianza mide cuánto varía el rendimiento del modelo con diferentes conjuntos de datos de entrenamiento; un modelo con alta varianza es demasiado complejo y sigue el ruido en los datos, resultando en un sobre-ajuste (*overfitting*), donde el modelo aprende características específicas del conjunto de datos de entrenamiento que no se generalizan a nuevos datos.

9.10. Preguntas de Comprensión

- ★ ¿Cuál es la diferencia fundamental entre un modelo lineal y un modelo no lineal en términos de su capacidad para capturar relaciones complejas entre variables? ¿Por qué un modelo no lineal podría ser preferido en ciertos casos?
- ★ Explique cómo el fenómeno de *overfitting* afecta el rendimiento de un modelo no lineal, como un polinomio de alto grado, al aplicar la descomposición sesgo-varianza. ¿Qué sugiere este análisis sobre la selección del grado del polinomio?
- ★ ¿Cómo se interpreta el término de sesgo en el contexto de un modelo no lineal, y qué impacto tiene en la capacidad del modelo para aprender relaciones complejas en los datos?
- ★ ¿Qué rol cumple la varianza en el ajuste de modelos no lineales, y cómo influye en la decisión de qué tan complejo debería ser un modelo? Proporcione un ejemplo.
- ★ En la aproximación polinómica, ¿cómo se utiliza el error cuadrático medio (MSE) para seleccionar el modelo óptimo, y qué nos indica sobre el desempeño del modelo con datos nuevos?

10. Procedimiento de ajuste de complejidad

Para lograr un equilibrio entre el sesgo y la varianza y obtener un modelo bien ajustado, se puede utilizar un conjunto de datos de validación para ajustar la complejidad del modelo. Este conjunto es disjunto del conjunto de entrenamiento y se utiliza para validar el rendimiento del modelo. El procedimiento es el siguiente:

- I. Iniciar con un modelo de baja complejidad y aumentar la complejidad gradualmente.
- II. Para cada nivel de complejidad, evaluar el modelo con el conjunto de validación.
- III. Observar el rendimiento del modelo en términos de error de validación.
- IV. Seleccionar la complejidad que minimiza el error de validación sin aumentar significativamente el error de entrenamiento.

Este proceso ayuda a prevenir tanto el sub-ajuste como el sobre-ajuste y se asegura de que el modelo sea capaz de generalizar a partir de los datos no vistos.

En la **Figura 18**, La curva de error de entrenamiento, mostrada en un color sólido, decrece exponencialmente, indicando que a medida que la complejidad del modelo aumenta, el modelo se ajusta mejor a los datos de entrenamiento, reduciendo el error de entrenamiento. Sin embargo, esta mejora en el ajuste puede no ser beneficiosa si consideramos la generalización del modelo a nuevos datos.




Figura 18: Dos curvas que representan el error de entrenamiento y el error de validación en relación con la complejidad del modelo en el eje horizontal.

La curva de error de validación, representada con una línea discontinua, inicialmente disminuye a medida que la complejidad aumenta, reflejando una mejora en la capacidad del modelo de capturar la verdadera relación subyacente en los datos. No obstante, más allá de cierto punto, la curva de error de validación comienza a ascender, lo que indica que el modelo está comenzando a sobreajustar los datos de entrenamiento y perder su capacidad de generalizar bien a nuevos datos.

La línea vertical punteada marca el punto óptimo de complejidad del modelo, donde el error de validación es mínimo y antes de que el modelo comience a sobreajustar. Este punto es crucial ya que representa el equilibrio ideal entre sesgo y varianza, minimizando el error de validación sin incurrir en un error de entrenamiento significativamente alto.

11. Validación Cruzada

Para garantizar que un modelo de aprendizaje automático es robusto y generaliza bien a datos nuevos, se utiliza un conjunto de datos de prueba, a menudo denominado “publication set”. Este conjunto es disjunto tanto del conjunto de entrenamiento como del de validación.

La *validación cruzada* es una técnica para evaluar la capacidad de generalización de un modelo. Se utiliza para asegurar que el rendimiento del modelo no es sólo específico para un único conjunto de datos de entrenamiento.

11.1. Procedimiento de la Validación Cruzada

Dado un conjunto de n datos, la validación cruzada consiste en:

- ★ Dividir el conjunto en k grupos (o “folds”) de forma aleatoria.
- ★ Para cada iteración, mantener un grupo como conjunto de prueba y el resto como conjunto de entrenamiento.
- ★ Entrenar el modelo con $k - 1$ grupos y evaluarlo con el grupo restante.
- ★ Repetir el proceso k veces, con cada uno de los k grupos utilizado exactamente una vez como conjunto de prueba.




Figura 19: Validación cruzada

11.2. Cálculo del Error

El error se calcula para cada uno de los grupos de prueba y luego se promedia para obtener una estimación más robusta del rendimiento del modelo.

$$\bar{\delta} = \frac{1}{k} \sum_{i=1}^k \delta_i$$

Donde δ_i es el error cometido en el i -ésimo grupo de prueba.

Para estimar la desviación estándar del error promedio, utilizamos la siguiente fórmula:

$$\hat{\sigma}_{\delta} = \sqrt{\frac{1}{k(k-1)} \sum_{i=1}^k (\delta_i - \bar{\delta})^2}$$

11.3. Intervalo de Confianza

Con estos valores, es posible estimar un intervalo de confianza para el error medio. Dado un nivel de confianza $1 - \alpha$, el intervalo de confianza es:

$$\bar{\delta} \pm t_{(k-1), \alpha/2} \hat{\sigma}_{\bar{\delta}}$$

Es importante que el tamaño de cada grupo sea suficientemente grande, idealmente mayor que 30, para justificar la aproximación de la distribución normal.

$$\frac{n}{k} > 30$$

A medida que el número de grupos crece, el tamaño del intervalo de confianza disminuye y la distribución t tiende a la normal.

12. Proceso de Regularización

El proceso de regularización en el aprendizaje automático es una técnica utilizada para prevenir el sobreajuste y mejorar la generalización de los modelos. La regularización se logra mediante la modificación de la función de error para incluir un término adicional que penaliza la complejidad del modelo.

El objetivo es minimizar la siguiente función de error regularizada:

$$\varepsilon = (\text{error de los datos}) + \lambda(\text{complejidad del modelo})$$

Donde λ es un parámetro que controla el grado de penalización. Un valor grande de λ favorece modelos más simples.

12.1. Preguntas de Comprensión

- ★ ¿Cuál es el objetivo principal de la validación cruzada en el contexto de evaluación de modelos de aprendizaje automático y cómo contribuye a su robustez?
- ★ Explique cómo se calcula el error promedio en la validación cruzada y por qué es relevante incluir una estimación de la desviación estándar del error.
- ★ ¿Qué rol cumple el parámetro λ en el proceso de regularización, y cómo afecta a la complejidad del modelo?

13. La Navaja de Occam

Este principio sugiere que entre varias hipótesis que explican igualmente bien un fenómeno, se debe seleccionar la más simple. Esto se conoce como el principio de parsimonia.

★ Occanismo

Si se tienen dos o más hipótesis, lo más razonable es aceptar la más simple; o sea la que presenta menos supuestos no probados.

Principio parsimonia

Si hay dos o mas explicaciones en igualdad de condiciones, no hay que tener en cuenta una explicación complicada si existe una más simple.

★ “No significa que la que la explicación más simple sea la más correcta, sino que existen más probabilidades que sea cierta y que es preferible elegirla hasta que haya razones bien fundamentadas para adoptar una alternativa más compleja”



Figura 20: Las posibles explicaciones pueden llegar a ser innecesariamente complejas. Podría ser coherente, por ejemplo, añadir la participación de los duendes a cualquier explicación, pero la navaja de Occam impediría tales añadidos a menos que fueran necesarios [7].

13.1. Longitud de Descripción Mínima

En la teoría de la complejidad, se considera que la mejor explicación es aquella que requiere la menor cantidad de información para ser descrita. La Longitud de Descripción Mínima (MDL) es una **formalización de la navaja de Occam** basada en la teoría de la información y la complejidad de Kolmogorov.

★ **Alfonso X “el sabio”:**

Si Dios Nuestro Señor me hubiera consultado antes de crear el mundo, le hubiera recomendado que hiciera algo más sencillo.

La MDL de un vector $\vec{x} = [x_1, x_2, \dots, x_n]$ utilizando p parámetros $\vec{\theta} = [\theta_1, \theta_2, \dots, \theta_n]$ se define como:

$$\text{MDL}(p) = -\log(P(\vec{x}|\hat{\theta})) + \pi(\hat{\theta}) + \frac{p}{2}\log(n) + O(p)$$

donde cada término se interpreta de la siguiente manera:

- ★ $\vec{x}$: El vector de observaciones o datos.
- ★ p : El número de parámetros en el modelo.
- ★ $\vec{\theta}$: El vector de parámetros del modelo.
- ★ $\hat{\theta}$: El estimador de máxima verosimilitud de los parámetros.
- ★ $P(\vec{x}|\hat{\theta})$: La probabilidad de los datos dados los parámetros estimados, también conocida como la verosimilitud de los datos.
- ★ $\pi(\hat{\theta})$: La penalización por la complejidad del modelo, que a menudo se refiere a la complejidad de la codificación de los parámetros.
- ★ $O(p)$: Un término que representa el coste de codificación de los parámetros adicionales.
- ★ n : El número de observaciones en el conjunto de datos.

13.2. Preguntas de Comprensión

- ★ ¿Qué implica el principio de la navaja de Occam en el contexto de selección de modelos en ciencia de datos, y cómo podría afectar la elección entre dos modelos con rendimientos similares?
- ★ Explique cómo la Longitud de Descripción Mínima (MDL) formaliza el principio de la navaja de Occam en términos de la teoría de la información y la complejidad de Kolmogorov. ¿Cuál es el propósito de cada término en la fórmula de MDL?
- ★ ¿Cómo puede interpretarse la cita de Alfonso X “el sabio” en el contexto del principio de parsimonia y la teoría de modelos? ¿Qué sugiere acerca de la simplicidad en el diseño de modelos?

14. Bases de Datos Analíticas (Data Warehouse)

Las Bases de Datos (BD) operacionales están diseñadas para gestionar las operaciones diarias de una organización y no están optimizadas para el análisis de datos. Por su parte, los *Data Warehouses* (DW) están especializados en la acumulación y organización de datos para la toma de decisiones estratégicas y el análisis analítico.

14.1. Limitaciones de las BD Operacionales

Las sentencias SQL en BD operacionales no están optimizadas para las consultas complejas requeridas para la obtención de conocimiento profundo, donde la mejor aproximación se logra a través de consultas de tipo estadísticas descriptivas.

14.2. Características de un DW

Para realizar trabajo analítico se recurre a DW, los cuales:

- ★ Integran datos de múltiples BD operacionales.
- ★ Facilitan la ejecución de consultas complejas y análisis de datos.
- ★ Requieren diseño especializado que involucra conocimiento en bases de datos, redes y hardware.
- ★ Utilizan diseño espacial para permitir un acceso de alta velocidad.

14.3. Data Marts

Además de los Data Warehouses, existen estructuras denominadas *Data Marts*, que son subconjuntos del DW diseñados para satisfacer las necesidades de análisis de datos específicas de diferentes departamentos o unidades de negocio dentro de la organización. Mientras que un DW puede contener toda la información corporativa, un Data Mart se enfoca en un segmento particular, lo que permite un análisis más eficiente y especializado.




Figura 21: Data Marts

14.4. Análisis y Minería de Datos

El DW permite la extracción y procesamiento de datos en servidores locales con herramientas especializadas en minería de datos, satisfaciendo requerimientos analíticos específicos del usuario.

14.5. Arquitectura para Decisiones en Tiempo Real

El DW puede requerir trabajar con un número elevado de tablas y grandes volúmenes de datos, lo que implica la necesidad de sistemas con alto rendimiento y procesos bien optimizados.

14.6. Estructuras Multidimensionales

Una de las estructuras más comunes en un DW es el *hipercubo*, que permite representar datos de manera multidimensional, facilitando el análisis y la toma de decisiones.

Ejemplo

Producto	Lugar	Fecha Compra	Unidades
CD	Santiago1	Mes 1	1500
Libro	Linares	Mes 1	150
Revista	Temuco1	Mes 1	506
CD	Santiago2	Mes 2	1020
CD	Santiago3	Mes 3	1567

Tabla 4: Análisis de una librería con tiendas a nivel nacional.




Figura 22: Estructura multidimensional

14.7. Preguntas de Comprensión

- ★ ¿Cuál es la diferencia fundamental entre una Base de Datos (BD) operacional y un Data Warehouse (DW), y por qué es esencial esta distinción para el análisis de datos en una organización?
- ★ Explique el concepto de un Data Mart y cómo complementa la funcionalidad de un Data Warehouse en una organización. ¿Cuáles son las ventajas de utilizar Data Marts?
- ★ ¿Qué ventaja ofrece la estructura de hipercubo en el contexto de un Data Warehouse y cómo facilita el proceso de análisis y toma de decisiones?

Referencias

- [1] DIINF, “Max chacón pacheco - diinf,” Diinf, 03 2022. [Online]. Available: <https://informatica.usach.cl/academico/max-chacon-pacheco>
- [2] M. Chacón Pacheco, *Análisis de Datos Capítulo I “Introducción”*. USACH, 2024.
- [3] S. J. Russell and P. Norvig, *Artificial Intelligence: a Modern Approach*, 4th ed. Pearson, 2021.
- [4] A. M. TURING, “I.—COMPUTING MACHINERY AND INTELLIGENCE,” *Mind*, vol. LIX, no. 236, pp. 433–460, 10 1950. [Online]. Available: <https://doi.org/10.1093/mind/LIX.236.433>
- [5] M. Minsky and S. A. Papert, *Perceptrons*. The MIT Press, 1969.
- [6] Y. LeCun, Y. Bengio, and G. Hinton, “Deep learning,” *Nature*, vol. 521, no. 7553, pp. 436–444, 2015. [Online]. Available: <https://doi.org/10.1038/nature14539>
- [7] W. Contributors, “Occam’s razor,” Wikipedia, 06 2019. [Online]. Available: https://en.wikipedia.org/wiki/Occam%27s_razor