



Guía de ejercicios Capítulo IV

Reglas de Asociación

1. Objetivos de la Unidad

#	Descripción	Preguntas
1.	Comprender el entorno de problemas y la génesis de las reglas de asociación.	
2.	Conocer las definiciones formales de las reglas de asociación.	
3.	Comprender y manipular los parámetros necesarios para evaluar en forma cualitativa una regla.	
4.	Comprender los problemas combinatorios subyacentes a la búsqueda de relaciones frecuentes.	
5.	Evaluar las diferentes medidas de calidad de una regla de asociación.	
6.	Dominar los algoritmos para la búsqueda de reglas frecuentes.	



2. Preguntas

P1.

Expresé la siguiente medida de calidad en la forma probabilística más simple e interpretarla ¿a qué medida conocida se parece?

$$X = n \frac{\text{conf}(A \rightarrow B)}{\text{sop}(A \rightarrow B)} \left[1 - \frac{\text{sop}(A \rightarrow B) \text{conf}(A \rightarrow B)}{\text{sop}(A \rightarrow B)} \right]$$

P2.

Una parte de la medida Gini para evaluar reglas de asociación está definida como:

$$\text{gini}(a \rightarrow b) = p(a) \left[[1 - (p(b/a))]^2 + [1 - (p(b/a))]^2 \right]$$

Determine su monotonidad (monótona o anti-monótona) para el caso del soporte (con confianza constante) y para el caso de confianza (con soporte constante).

P3.

Un médico especialista en enfermedades broncopulmonares infantiles tiene la convicción de que la estacionalidad del clima en Santiago influye fuertemente en el agravamiento de los infantes alérgicos. Para evaluar su hipótesis ha recolectado datos de los infantes con **síntomas alérgicos** e **infantes normales** y ha constatado sus **ingresos a salas IRA** (infección respiratoria aguda) de la ciudad de Santiago. Muestre una base de datos codificada para la aplicación del método de reglas de asociación, que tenga la particularidad de que cuando se agrega la **variable estacionalidad (importa la instancia invierno)** la confianza aumenta.

P4.

Un analista de marketing tiene la hipótesis que existe una fuerte relación (más del 50%) entre personas que están suscritas al diario *El Mercurio* y *Estrategia*, con las personas que toman sus vacaciones en el extranjero y en el sur del país. Para comprobar esta hipótesis posee las bases de datos de las suscripciones a los periódicos y de la empresa *Latam*.

Construya una base de datos de no más de 10 ejemplos que compruebe la hipótesis. Considerando un soporte de más del 10%, cuando el universo está constituido por las personas comunes a las tres bases de datos.

3. Respuestas

P1.

Dada la siguiente expresión (fórmula original):



$$X = n \frac{\text{conf}(A \rightarrow B)}{\text{sop}(A \rightarrow B)} \left[1 - \frac{\text{sop}(A \rightarrow B) \text{conf}(A \rightarrow B)}{\text{sop}(A \rightarrow B)} \right]$$

Simplificamos la expresión:

$$X = n \cdot \frac{\text{conf}(A \Rightarrow B)}{\text{sop}(A \Rightarrow B)} \cdot (1 - \text{conf}(A \Rightarrow B))$$

Recordando que:

- Confianza: $\text{conf}(A \Rightarrow B) = P(B|A) = \frac{P(A \cap B)}{P(A)}$
- Soporte: $\text{sop}(A \Rightarrow B) = P(A \cap B)$

Entonces:

$$X = n \cdot \frac{\frac{P(A \cap B)}{P(A)}}{\frac{P(A \cap B)}{1}} \left[1 - \frac{P(A \cap B)}{P(A)} \right]$$

Simplificamos:

$$X = n \cdot \frac{1}{P(A)} \left[1 - \frac{P(A \cap B)}{P(A)} \right]$$

En forma de probabilidades:

$$X = n \cdot \frac{1}{P(A)} [1 - P(B|A)]$$

$$X = n \cdot \frac{1 - P(B|A)}{P(A)}$$

Si reemplazamos:

$$x = \frac{n}{\text{Sop}(A)} [1 - \text{Conf}(A \Rightarrow B)]$$

Respuesta: Se parece conceptualmente a varias medidas de calidad inversas o de error en reglas de asociación.

$$\text{Convicción}(A \Rightarrow B) = \frac{n - \text{Sop}(B)}{n[1 - \text{Conf}(A \Rightarrow B)]}$$



P2.

$$R = P(A)[1 - (P(B/A))]^2 + [1 - (P(B/A))]^2$$

$$sopn(A)[1 - (sop(A \Rightarrow B)/sop(A))]^2 / n + [1 - (sop(A \Rightarrow B)/sop(A))]^2$$

$$(sopn(A + 1)[1 - \frac{sopn(A \Rightarrow B)}{sopn(A)}])^2$$

$$(sopn(A) + 1)[1 - confn(A \Rightarrow B)]^2$$

Confianza constante: Considerando una confianza constante, el lado derecho de la ecuación siempre será positivo constante, mientras que el izquierdo, al tener el soporte de A, sería anti monótona.

$$confn(A \Rightarrow B) = 0,5 \quad || \quad sopn(A) = 0,2$$

$$(0,2 + 1) [1 - 0,5]^2 = 0,3$$

$$confn(A \Rightarrow B) = 0,5 \quad || \quad sopn(A) = 0,1$$

$$(0,1 + 1) [1 - 0,5]^2 = 0,275$$

Soporte constante: Considerando un soporte constante, dado que cuando la confianza tome valores entre 0 y 1, se perdería la monotonicidad (cuando la *conf* es 1, el lado derecho vale 0, cuando la *conf* es 0, el lado derecho es 1, cuando la confianza es 0.5, el lado derecho en 0.25).

$$confn(A \Rightarrow B) = 0,5 \quad || \quad sopn(A) = 0,2$$

$$(0,2 + 1) [1 - 0,5]^2 = 0,3$$

$$confn(A \Rightarrow B) = 0,4 \quad || \quad sopn(A) = 0,2$$

$$(0,2 + 1)[1 - 0,4]^2 = 0,432$$

$$confn(A \Rightarrow B) = 0,3 \quad || \quad sopn(A) = 0,2$$

$$(0,2 + 1)[1 - 0,3]^2 = 0,588$$



P3.

Hipótesis: El invierno está asociado a un mayor ingreso de niños alérgicos a salas IRA.

Variable	Codificación
Alergia	ALERG (1 = alérgico)
Ingreso a sala IRA	IRA (1 = ingresó)
Estación: Invierno	INVIERNO (1 = es invierno)

BD en formato tipo “market basket” donde cada fila representa un paciente y las variables son codificadas como atributos binarios (1=presente, 0=ausente).

ID	ALERG	IRA	INVIERNO
1	1	1	1
2	1	1	1
3	1	0	0
4	0	0	0
5	1	0	0
6	1	1	1
7	0	0	1
8	1	1	1
9	0	0	0
10	1	1	1

Sin considerar estación:

$$\text{Confianza}(\text{ALERG} \rightarrow \text{IRA}) = P(\text{IRA}|\text{ALERG}) = \frac{P(\text{ALERG} \cap \text{IRA})}{P(\text{ALERG})} = \frac{5}{7} \approx 71\%$$

Considerando invierno:

$$\text{Confianza}(\text{ALERG}, \text{INVIERNO} \rightarrow \text{IRA}) = P(\text{IRA} | \text{ALERG} \wedge \text{INVIERNO}) = \frac{5}{5} \approx 100\%$$

Esta base simula correctamente la hipótesis del médico: *todos los alérgicos en invierno ingresan a sala IRA, pero no todos los alérgicos en otras estaciones lo hacen, por lo tanto, la confianza aumenta al agregar la variable INVIERNO.*



P4. Hipótesis: Existe una relación fuerte (más del 50%) entre personas que están suscritas a El Mercurio y Estrategia, y aquellas que toman vacaciones en el extranjero o en el sur con un soporte mayor al 10%.

$H_0: Conf(A, B) \leq 50\%$

$H_A: Conf(A, B) > 50\%$

Universo: personas comunes a las tres bases (suscripción El Mercurio, Estrategia y datos de viajes de Latam).

Soporte mínimo: 10% $\rightarrow$ mínimo 1 persona debe cumplir una regla para que sea considerada significativa.

Confianza esperada de la regla (de acuerdo la hipótesis): más del 50%.

Variable	Codificación
Suscripción a El Mercurio	MERCURIO
Suscripción a Estrategia	ESTRATEGIA
Vacaciones en el extranjero	EXTRANJERO
Vacaciones en el sur de Chile	SUR

ID	MERCURIO	ESTRATEGIA	EXTRANJERO	SUR
1	1	1	1	1
2	1	1	1	0
3	1	1	0	1
4	1	1	1	1
5	1	1	0	0
6	1	0	1	1
7	0	1	0	0
8	0	0	0	1
9	1	1	1	1
10	0	0	0	0

Regla evaluada: $MERCURIO \wedge ESTRATEGIA \rightarrow EXTRANJERO \vee SUR$

Total con $MERCURIO \wedge ESTRATEGIA$: 6 personas



De esas 6 personas, 5 tienen vacaciones en el extranjero o sur:

$$\text{Confianza}(\text{MERCURIO}, \text{ESTRATEGIA} \rightarrow \text{EXTRANJERO} \vee \text{SUR}) = \frac{5}{6} \approx 83\%$$

$$\text{Soporte}(\text{MERCURIO}, \text{ESTRATEGIA}) = \frac{5}{10} = 100\%$$

Resultado

Cumple ambas condiciones: Confianza > 50% y Soporte > 10%