

Universidad de Santiago de Chile
Facultad de Ingeniería
Depto. de Ingeniería Informática



Inteligencia Computacional

Capítulo VI

“Clasificación Bayesiana”

Profesor: Dr. Max Chacón.

Objetivos

- Cuantificar probabilidad a priori.
- Comprender el costo del error de clasificar basado en probabilidad a priori.
- Cuantificar el riesgo condicional.
- Usar los conceptos anteriores para obtener un método de clasificación a mínimo riesgo condicional para un problema multivariado.
- Analizar clasificador Bayesiano simple.
- Obtener un clasificador mediante criterio distribuido, usando el concepto de redes de clasificación.



5.1. Clasificación a priori

Supongamos que se requiere clasificar pacientes que recurren al médico con dolor pectoral, en pacientes que han sufrido un infarto cardiaco y los que su dolor es por otra causa.

De un número grande de observaciones n , se puede obtener que una fracción de ellos n_1 pertenece a la clase c_1 (pacientes con infarto) y la fracción n_2 pertenece a la clase c_2 (pacientes sin infarto)

Con: $n=n_1+n_2$



La *probabilidad a priori* $p(c_i)$ será la probabilidad de que el próximo paciente se clasifique en la clase c_i .

$$p(c_i) = \lim_{n \rightarrow \infty} \frac{n_i}{n} \quad \text{con } i=1,2.$$

Para un número grande de observaciones se puede estimar $p(c_i)$ por:

$$\hat{p}(c_i) = \frac{n_i}{n}$$



Las probabilidades $p(c_1)$ y $p(c_2)$ representan el conocimiento *a priori* (en términos estadísticos) de que un paciente tenga infarto o no, antes de que exista el nuevo paciente a clasificar.



Suponiendo que, basado en estas probabilidades (pequeño conocimiento) se quiere clasificar un nuevo paciente, la mejor elección será aquella que asigna el paciente a la clase que tenga mayor probabilidad *a priori*.

Asignar paciente a la clase c_2 si $p(c_2) > p(c_1)$
En otro caso asignar a c_1 .

Para un sujeto en particular, la probabilidad de error de la clasificación será:



$$p(\text{error de clasificación}) = \begin{cases} p(c_2) & \text{si se decide } C = c_1 \\ p(c_1) & \text{si se decide } C = c_2 \end{cases}$$

Se observa que el error de clasificación es minimizado si se elige c_2 y $p(c_2) > p(c_1)$.

4.2. Clasificación condicionada


Para tomar una decisión más informada es necesario usar alguna característica relevante del paciente que permita distinguir su enfermedad.

Considérese que el médico tratante solicita examen *CKMB*, que la fracción *MB* del nivel *Sérico* de la enzima *Creatinin Fosfokinasa CK* para detectar infarto al miocardio.

Considere x la fracción del nivel sérico de la enzima. El valor de x debe ser considerado como una variable aleatoria que puede ser expresada en términos probabilísticos (también influye el tiempo).



El interés será contar con funciones de densidad de probabilidad condicionales $p(x/c_i)$, con $i=1,2$. Sea c_1 paciente con infarto, c_2 sin infarto



$p(x/c_1)$ es la función de densidad de probabilidad para un valor de x dado que el paciente presenta infarto.



Esta función de densidad de probabilidad es llamada *Verosimilitud* de la clase c_1 con respecto a x y refleja el conocimiento que se tiene de la aplicación de esta función, la cual sugiere que la *verosimilitud* de que un paciente pertenezca a la clase c_1 es grande si $p(x/c_1)$ es grande.

Nota: si las dos funciones de distribución están superpuestas, significa que el conocimiento de la variable x no discrimina entre sano y enfermo.

Para clasificar el paciente en la clase c_i se requiere reunir el conocimiento a priori $p(c_i)$ y el conocimiento de los valores de x para los pacientes que pertenecen a las clases c_i , $p(x/c_i)$.



Para clasificar un paciente dado se requiere la probabilidad a posteriori $p(c_i/x)$, la cual especifica la probabilidad de que el sujeto pertenezca a la clase c_i dado que el valor del nivel sérico es x .

Tener el valor de x dependerá del hecho posterior de que la variable de características x sea medida.

Para dos clases se tiene:
$$\sum_{i=1}^2 p(c_i / x) = 1$$

Para obtener el valor de $p(c_i/x)$, se requiere conocer las relaciones de probabilidades condicionales.



Sea: $p(c_i; x)$ la función de densidad de probabilidad conjunta, $p(c_i \cap x)$ que es interpretada como la probabilidad de que un paciente pertenezca a la clase c_i y tenga un nivel sérico x .

De la definición de probabilidad condicional:

$$p(c_i; x) = p(c_i / x) p(x) \quad \text{con } i = 1, 2.$$

$$p(c_i; x) = p(x / c_i) P(c_i) \quad \text{con } i = 1, 2.$$

$p(x)$ es la probabilidad incondicional de la variable x .

$$p(x) = \sum_{i=1}^2 p(x / c_i) P(c_i)$$



Usando las definiciones anteriores se tiene el *Teorema de Bayes*;

$$p(c_i / x) = \frac{p(x / c_i) P(c_i)}{\sum_{i=1}^2 p(x / c_i) P(c_i)}$$

Por lo tanto para conocer $p(c_i/x)$ se requiere el conocimiento a priori y el conocimiento de la verosimilitud de las clases c_i respecto a x .



5.3. Minimización del Riesgo Condicional

“Un nuevo paciente al cual se han practicado el examen CKMB con un resultado x , se asigna a la clase c_i que tenga el mayor valor de $P(c_i/x)$ ”.

A esta regla se le denomina Maximización de la Probabilidad (o hipótesis) a Posteriori (MAP).

$$O \text{ Clase}_{MAP} = \arg \max_{c_i} \{p(c_i / x)\}$$

$$\text{Clase}_{MAP} = \arg \max \{p(x / c_i) p(c_i)\}$$

En otras palabras: La regla de clasificación estadística indica que la mejor clasificación será aquella que minimice la probabilidad de error en la clasificación (*Regla de Clasificación Bayesiana*).



Se decide por la clase c_1 si:

$$p(c_1/x) > p(c_2/x) \Rightarrow \frac{p(x/c_1)P(c_1)}{p(x)} > \frac{p(x/c_2)P(c_2)}{p(x)}$$


$$p(x/c_1)P(c_1) > p(x/c_2)P(c_2)$$

Se decide por la clase c_2 si:

$$p(x/c_2)P(c_2) > p(x/c_1)P(c_1)$$

Usando la función de distribución de probabilidad a posteriori se puede observar el punto óptimo de discriminación.





Se denomina **Función Discriminante** a:

Si se tienen múltiples (m) clases

$$d_i(x) = P(c_i / x) = \frac{p(x / c_i)P(c_i)}{P(x)} \quad \text{con: } i=1,2,\dots,m$$

Como $d_i(x)$ se compara con los otros $d_j(x)$, $j=1,2,\dots,m$, el factor de escala $p(x)$ no necesita ser considerado.

$$d_i(x) = p(x/c_i)P(c_i)$$

En general $d_i(x)$ es una función monótona respecto de x y se puede usar $\ln(d_i(x))=L_i(x)$ obteniendo los mismos resultados.

$$L_i(x) = \ln p(x/c_i) + \ln p(c_i)$$

La elección de la clase se realiza maximizando la probabilidad a posteriori (MAP).

$$Clase_{MAP} = \arg \max_{c_i} \{ \ln(p(x/c_i)) + \ln(p(c_i)) \}$$



Ej: Considere un paciente que recibe un examen CKMB con valor 15% (<10% normal, a las 7 horas) y se quiere saber si realmente tiene infarto. De las bases de datos del hospital se sabe que:

- De los pacientes que consultan por dolor agudo al pecho y se les envía a realizar el examen CKMB, el 60% tuvo infarto realmente.

- Además se sabe que el 1% de los pacientes con infarto tenía un valor de 15% de la fracción CKMB y que solo el 0,3% de los que no tuvo infarto tenían un valor de 15% de la encima.

Determine si el paciente tiene o no infarto realmente.



Sol: $P(I)=0,6$; $P(\bar{I})=0,4$;

$p(x=15\%/I)=0,01$;

$p(x=15\%/\bar{I})=0,003$.

$\arg \max \{p(I/x=15\%); p(\bar{I}/x=15\%)\}=$

$\arg \max \{p(x=15\%/I)P(I); p(x=15\%/\bar{I})P(\bar{I})\}=$

$\arg \max \{0,006; 0,0012\}=\arg \{0,006\}= \text{clase } I$

$\therefore$ El paciente tiene infarto.



5.4. Clasificación Multivariada

Se tienen n pacientes portadores de diferentes enfermedades y se requiere clasificarlos en m clases $c_1, c_2, \dots, c_m$ (enfermedades y caso normal) las cuales se dan en proporciones a priori $p(c_1), p(c_2), \dots, p(c_m)$, y se poseen p características de los pacientes representadas en el vector de valores reales $\bar{x} = [x_1, x_2, \dots, x_p]$.

Si la muestra utilizada es significativa, se puede suponer que la distribución de las variables aleatorias $\bar{x}$ es una distribución normal multivariada.



En este caso, la probabilidad de obtener un paciente con características $\bar{x}$ que pertenezca a la clase c_i es:

$$p(\bar{x}/c_i) = \frac{1}{(2\pi)^{p/2} |\Sigma_i|^{1/2}} e^{-\frac{1}{2} (\bar{x} - \tilde{\mu})^T \Sigma_i^{-1} (\bar{x} - \tilde{\mu})}$$

donde: $\tilde{\mu}$ = estimación del vector de medias de las p características de la clase c_i .

Σ_i : Matriz de varianzas-covarianzas de la clase c_i .



Considerando el estudio univariado, lo que se requiere es:

Dado un paciente que posee un vector de características $\bar{x}$, determinar la clase a la cual pertenece el paciente, $p(c_i/\bar{x})$.

$$Clase_{MAP} = \arg \max_{c_i} \{p(\bar{x}/c_i)p(c_i)\}$$

Definiendo la probabilidad a como la función discriminante $d_i(\bar{x}) = p(\bar{x}/c_i)P(c_i)$ y su logaritmo $L_i(\bar{x}) = \ln d_i(\bar{x})$

$$L_i(\bar{x}) = \ln \{ p(\bar{x}/c_i)P(c_i) \}$$



Considerando la función densidad de probabilidad como una normal multivariada, se tiene:

$$L_i(\bar{x}) = \frac{p}{2} \ln(2\pi) \ln\{p(c_i)\} - \frac{1}{2} \ln(|\Sigma_i|) - \frac{1}{2} (\bar{x} - \tilde{\mu}_i)^T \Sigma_i^{-1} (\bar{x} - \tilde{\mu}_i)$$

La clase se obtiene por MAP como:

$$Clase_{MAP} = \arg \max_{c_i} \left\{ \frac{p}{2} \ln(2\pi) \ln\{p(c_i)\} - \frac{1}{2} \ln(|\Sigma_i|) - \frac{1}{2} (\bar{x} - \tilde{\mu}_i)^T \Sigma_i^{-1} (\bar{x} - \tilde{\mu}_i) \right\}$$

Por lo tanto, se asigna el paciente representado por $\bar{x}$ a la clase c_i donde se alcanza mayor valor de $L_i(\bar{x})$.

Esta función de decisión es de tipo cuadrática.

MAP indica elegir la probabilidad a posteriori, $p(c_i/\bar{x})$ de asignar el paciente $\bar{x}$ a la clase elegida, la cual, dado el criterio de decisión, corresponde a la que tiene una mayor probabilidad a posteriori.



5.5. Calificador Bayesiano Ingenuo (“Naive”).



El clasificador Bayesiano óptimo obtenido por MAP en la sección anterior supone los atributos $\bar{x}$ reales y dependientes entre sí.

En un caso mas general se pueden considerar diferentes tipos de atributos $\{a_1, a_2, \dots, a_p\}$ que pueden ser reales, nominales o binarios y el clasificador óptimo será determinado por:

$$Clase_{MAP} = \arg \max_{c_i} \{p(c_i / a_1, a_2, \dots, a_p)\}$$

o al usar la verosimilitud y la probabilidad a priori:

$$Clase_{MAP} = \arg \max_{c_i} \{p(a_1, a_2, \dots, a_p / c_i) p(c_i)\}$$

El problema que presenta este acercamiento al problema de clasificación es que se requiere determinar la verosimilitud de cada uno de los p atributos (conjuntamente) con respecto a las m clases c_i .

Lo cual es una probabilidad muy difícil de obtener, pues se requiere una cantidad muy grande de datos para obtener todas las posibilidades.

Si se consideran todos los a_j ($j=1..p$) reales y que la distribución de la verosimilitud es normal, se obtiene el caso anterior.

La Clasificación Bayesiana Ingenua realiza una suposición simple: todas las probabilidades de los atributos son condicionalmente independientes para una clase dada.



Esto significa que dada una clase, la probabilidad de observar la conjunción de los $\{a_1, a_2, \dots, a_p\}$ corresponde al producto de las probabilidades individuales de los atributos. Esto es:

$$p(a_1, a_2, \dots, a_p / c_i) = \prod_{j=1}^p P(a_j / c_i)$$

Sustituyendo esto en el clasificador Bayesiano óptimo obtenido por MAP, se tiene el clasificador Bayesiano ingenuo:

$$Clase_{NBC} = \arg \max_{c_i} \left\{ p(c_i) \prod_{j=1}^p P(a_j / c_i) \right\}$$

Se puede observar que en este caso es muy fácil estimar los $p(a_i/c_j)$ del conjunto de datos.



• Para el caso de atributos nominales:

Ej: Suponiendo que a_j puede tomar 4 valores $k \in \{0, 1, 2, 3\}$ entonces:

$$\hat{p}(a_j = k / c_i) = \frac{\text{Nº casos en que } a_j = k \text{ en la clase } c_i}{\text{Total de casos de la clase } i}$$

• Para el caso de atributos reales se puede usar una distribución normal.

Ej: Se estima la media $\bar{a}_j$ y la varianza $\hat{\sigma}_{a_j}$ del atributo y se obtiene la estimación de la probabilidad como:

$$\hat{p}(a_j / c_i) = \frac{1}{\hat{\sigma}_{a_j} \sqrt{2\pi}} e^{-\frac{(a_j - \bar{a}_j)^2}{2\hat{\sigma}_{a_j}^2}}$$



El método se aplica primero con un conjunto de datos de los cuales se estiman las probabilidades a priori $p(c_i)$ y las verosimilitudes $p(a_j/c_i)$ para todas las clases i .

Esto se puede considerar la etapa de entrenamiento o aprendizaje del método.

Cuando se presenta una nueva instancia $a_j = k$, de un conjunto desconocido de datos, se determina la clase donde el producto de las probabilidades a priori y verosimilitudes es máxima.

