

Universidad de Santiago de Chile

Facultad de Ingeniería

Departamento de Ingeniería Informática.

Guía de Ejercicios Inteligencia Computacional (2017)

Profesor : Max Chacón Pacheco
Ayudante : Felipe-Andrés Bello Robles

CONCEPTOS

1. De ejemplos de las preguntas realizadas por el usuario para describir la Minería de Datos Indirecta, Minería de Datos Inductiva y Refinamiento.
2. Explique las diferencias entre Data Warehouse (Base de datos analíticas) y Data Marts.
3. Indique cuales son los tipos de muestreo para diseñar un Data Warehouse
4. ¿Cuanta información existe en la Internet?
- 5.Cuál es la diferencia entre datos y metadatos
6. ¿Qué es OLAP?
7. Explique las diferencias entre datos, información y conocimiento.
8. ¿A qué se le denomina meta conocimiento?
9. Explique qué procesos se realizan antes de la codificación. Además muestre la clasificación de la representación de datos en el proceso de codificación.
10. Explique la diferencia entre el proceso de KDD y la Minería de Datos. Clasifique además, la minería de datos en niveles de generalidad de la información, relacionado con la pregunta realizada para la obtención del conocimiento.
11. Muestre el modelo general de KDD y presente algún ejemplo para las etapas de limpieza y enriquecimiento de datos.

Ejercicios

1. Se requiere construir un DW (Data Warehouse) para un laboratorio de medicamentos que lleve la información de sus visitantes médicos. Considerando que el DW es de interés para conocer la penetración territorial y de productos, tome como elemento de evaluación las visitas realizadas a los médicos y las muestras entregadas a cada facultativo.

Identifique dimensiones y las medidas, realice un esquema gráfico y presente un ejemplo de dato atómico.

2. Muestre la estructura de datos más usada en los DW, presente un ejemplo para una empresa distribuidora de calzado que presenta diferentes tiendas en el país, donde se quiere almacenar el stock de productos y las ventas.

3. Presente un ejemplo para un base de datos analítica (indicando claramente las dimensiones y medidas) para una empresa de crianzas de salmones que tiene plantas en diferentes lugares de Chiloé (cada planta tiene varios criadores). Se requiere medir la generación de especies por metro cúbico en diferentes periodos y la producción vendidas en toneladas de carne congelada en diferentes periodos.

4. Muestre la estructura más usada en los DW, presente un ejemplo indicando dimensiones y medidas para una empresa forestal que tiene bosques en diferentes lugares de Chile, donde se mide la generación de Biomasa por hectáreas al año y la producción de madera al mes.

5. Una empresa que distribuye materiales de construcción, requiere diseñar un DW y posee los siguientes datos:

- Productos divididos en: categoría de productos, grupos de familia, familia, subfamilia y producto.
- Ventas en dinero: Ventas facturadas, ventas a crédito y ventas a débito.
- Volúmenes de ventas: Ventas facturadas, ventas en depósito, ventas pendientes.

Utilice la estructura más usada en los DW para modelar este problema. Identifique dimensiones y medidas. Presente un ejemplo de dato atómico.

6. En un hospital, de 1000 pacientes que tenían asma, 300 fueron diagnosticados erróneamente, mientras que de 1500 pacientes que tenían otra enfermedad 350 fueron diagnosticados con asma.

- a. Calcule la frecuencia de asma con los resultados positivos que tiene el hospital
- b. Calcule la frecuencia de otras enfermedades con los resultados negativos que tiene el hospital
- c. Obtenga el valor real de la frecuencia de asma con resultados positivo si se sabe que solo el 10% de la población tiene asma.

7. Considere un clasificador clínico diseñado para clasificar pacientes según una determinada patología. La tabla de contingencia es la siguiente

		Enfermedad	
		Presente	Ausente
Clasificador	T+ Enfermo	950	10
	T- No enfermo	50	990

- Determine sensibilidad, especificidad, valor predictivo positivo y negativo
- Modifique este valor para “prevalencia de enfermedad” $C=1/100$ y $C=1/1000$. Concluya respecto a los resultados.

8. En un sistema de vigilancia epidemiológica (SVE) se tiene 1258 pacientes victimarios identificados de los cuales 68 fueron erróneamente identificados, mientras otras 210 personas que no eran victimarios fueron juzgados incorrectamente.

- Calcule la frecuencia de victimarios identificados del SVE
- Calcule el valor real de victimarios con resultados positivos si se sabe que solo un 35% de los victimarios están identificados

9. Se dispone de 15 alumnos a los cuales se les mide las calificaciones de primer año de enseñanza media, en las siguientes asignaturas: Castellano (C), Matemática (M), Física (Fi), Inglés (I), Filosofía (F), Historia (H), Química (Q) y Gimnasia (G).

Se posee además, una tabla que relaciona los alumnos con los colegios donde realizaron la enseñanza básica.

Para un análisis de componentes principales se tienen los siguientes resultados:


Valores propios: $\lambda_1=3,71$; $\lambda_2= 2,86$; $\lambda_3= 0,5$

Asignatura	Colegios Básicos
Alumno 1	Colegio Suizo
Alumno 2	Colegio Alemán
Alumno 3	E. Pública Maipú
Alumno 4	E. Pública de la Pintana
Alumno 5	E. Pública Est. Central
Alumno 6	E. Pública Est. Central
Alumno 7	Scuola Italiana
Alumno 8	Liceo Francés
Alumno 9	E. Pública 1 Santiago
Alumno 10	Green House
Alumno 11	Wessex School
Alumno 12	San Gabriel School
Alumno 13	Grange School
Alumno 14	Santiago College
Alumno 15	Sant George School

Vectores propios:

Asignatura	Comp 1	Comp 2	Comp 3
C	0,500	0,085	-0,028
M	-0,113	0,555	0,133
Fi	-0,052	0,575	0,076
I	0,499	0,037	-0,005
F	0,450	0,122	-0,303
H	0,493	0,064	-0,011
Q	-0,073	0,574	-0,021
G	0,187	-0,069	0,940

Al aplicar la matriz de transformación (para las primeras 2 componentes) a los datos originales se tiene la siguiente distribución de sujetos en el plano principal.



- Determine la validez del análisis.
- Ubique las asignaturas en el plano principal de las dos primeras componentes
- Caracterice las dos primeras componentes.
- Usando la matriz de transformación, analice y caracterice la tercera componente.
- Utilizando la tabla que relaciona alumnos con colegios y suponiendo que la habilidad de cada estudiante está dada por su formación básica, identifique las fortalezas de los colegios de enseñanza básica.

10. Para caracterizar billetes falsos los bancos suizos realizaron un análisis que consistía en tomar medidas de los billetes. Para el análisis tenía tres grupos diferente de billetes. Originales de papel, originales de plástico y billetes falsos. Cada billete fue caracterizado por las siguientes variables:

Lon: Longitud del billete

LD: Largo de la Diagonal del billete

Al: Ancho Izquierdo del billete

AD: Ancho Derecho del billete

AMI: Ancho Margen Inferior del billete

AMS: Ancho Margen Superior del billete.


A continuación, se realizó un análisis de componentes principales con los siguientes resultados:

Valores propios: 2,58; 1,34; 0,76; 0,56; 0,50; 0,26.

Vectores propios para las dos primeras componentes.

	CP1	CP2
Lon	0,395	0,799
LD	0,207	0,345
AI	0,445	-0,263
AD	0,411	-0,375
AMI	0,347	-0,072
AMS	0,560	-0,163

La distribución de los diferentes tipos de billetes se muestra en la figura (originales de papel en círculos, originales de plástico en cuadrados y falsos en triángulos):



Se realizó un trabajo similar con monedas midiendo 6 variables de tamaño de éstas y los valores propios del análisis fueron los siguientes: 1,96; 1,54; 1,09; 0,73; 0,40; 0,28. - Determine el porcentaje de validez del análisis.

- Interprete cada una de las componentes
- Identifique las principales características de los billetes originales.
- Determine si existen diferencias entre las falsificaciones


11. Un estudio del consumo de diferentes familias francesas intenta una caracterización mediante análisis de componentes principales. Las familias (sujetos) se caracterizan por su condición socio-económica, clasificando el tipo de trabajo de los jefes de hogar, y por sus tamaños considerando el número de hijos. Los jefes de hogar tienen las siguientes características: (MA#) trabajador manual, (EM#) empleado, (PF#) profesional. Donde el símbolo # puede tomar los valores 2, 3, 4 o 5 y representa el número de hijos de las familias. Se mide el consumo promedio de los siguientes productos (atributos o variables originales x_1): Pan, Legumbres, Frutas, Carnes, Aves, Lácteos y Vinos. La matriz de correlación de los productos es la siguiente:

	Pan	Legumbres	Frutas	Carnes	Aves	Lácteos	Vinos
Pan	1						
Legumbres	0,59	1					
Frutas	0,2	0,87	1				
Carnes	0,32	0,89	0,96	1			
Aves	0,25	0,83	0,93	0,98	1		
Lácteos	0,86	0,66	0,33	0,37	0,23	1	
Vinos	0,3	-0,35	-0,49	-0,44	-0,4	-0,4	1

Después de realizar un análisis de componentes principales, los valores propios para las dos primeras componentes son $\lambda_1=4,339$ y $\lambda_2=1,829$, los vectores propios se muestran en la siguiente tabla.

	Componente 1	Componente 2
Pan	-0,497	0,841
Legumbres	-0,972	0,131
Frutas	-0,931	-0,277
Carnes	-0,963	-0,19
Aves	-0,912	-0,265
Lácteos	-0,584	0,707
Vinos	0,425	0,649

La distribución de los grupos familiares en el espacio de las dos primeras componentes principales se muestra en la siguiente figura:



- Determine el porcentaje de información que se pierde en el estudio con solo las dos primeras componentes.
- Intente una caracterización de las componentes inspeccionando sólo la distribución de las familias en el plano de las dos componentes.
- Dibuje en forma aproximada los productos consumidos (atributos o variables originales) en el espacio de las componentes.
- Asocie cada componentes a los productos consumidos.
- Intente relacionar los productos consumidos por las familias y sus condiciones socio-económicas y/o tamaños.

12. En un estado venezolano se utilizó ACP para analizar la situación del sector lechero. Las variables utilizadas fueron: SUP: Superficie total de la hacienda; VACA: Número total de vacas; SANI: Índice sanitario; INST: índice de las instalaciones; MAQ: Índice de maquinarias; PROM: Promedio de la Leche/vaca

Los resultados del ACP fue el siguiente:


Valores propios: $\lambda_1=1,794$; $\lambda_2= 1,341$;

Vector propios ponderados por la raíz de cada valor propio

	Componente 1	Componente 2
SUP	0,79	0,10
VACA	0,76	0,40
SANI	0,44	-0,48
INST	0,32	-0,48
MAQ	0,53	-0,26
PROM	-0,01	-0,80

Determine una caracterización de las componentes principales, al examinar la relación con las variables originales.

Al graficar las haciendas en el plano de las dos primeras componentes principales se pueden caracterizar 8 tipos de haciendas con problemas particulares., como se muestra en la figura. Utilice esta información para identificar los tipos de haciendas. Determine además el porcentaje de validez del estudio.



13. La siguiente tabla recoge las valoraciones medias que han concedido los encuestados a cada una de las marcas de automóviles en las tres características consideradas. Así la marca A tiene una calificación media de 2 en la característica elegante, de 3 en comodidad y 6 en deportivo.

Marca	Características		
	Elegancia	Comodidad	Deportivo
A	2	3	6
B	3	2	4
C	4	5	4
D	5	5	4
E	8	9	6
F	9	7	7

La matriz de correlación resulta ser:

		Elegancia	Comodidad	Deportivo
Correlación	Elegancia	1,000	,892	,585
	Comodidad	,892	1,000	,519
	Deportivo	,585	,519	1,000

Los valores propios son $\lambda_1=2,345$; $\lambda_2=0,551$; $\lambda_3=0,105$.

La matriz de los componentes para los dos primeros es la siguiente:

	Componente	
	1	2
Elegancia	,948	-,215
Comodidad	,925	-,311
Deportivo	,769	,639

Al aplicar la matriz de transformación a la primera tabla se obtienen los siguientes coordenadas

	A	B	C	D	E	F
CP1	-0,60	-1,10	-0,51	-0,40	1,20	1,30
CP2	1,60	-0,01	-0,81	-0,95	-0,55	0,61

Determine la validez del análisis, Obtenga conclusiones de las correlaciones. Grafique las características en el plano de las CP e intente una caracterización de las componentes. Intente una clasificación de marcas.

14. Un estudio del Hospital de Andalucía en España analizó 22.486 ingresos para intentar caracterizar los diferentes servicios (o unidades) del Hospital. Los servicios analizados fueron los siguientes: Medicina Interna, Ginecología, Pediatría, Cirugía, Traumatología, Urología, Digestivo, Otorrino-laringología, Cardiología, Neurología, Hematología, Oftalmología y Psiquiatría. Para caracterizar los servicios se midieron 7 variables:

NI: Número de Ingresos;

MO: Índice de Mortalidad;

RE: Número de Reingresos al servicio (por el mismo diagnóstico);

NE: Número de consultas externas al servicio;

ICM: Índice promedio de la complejidad de los pacientes admitidos;

ES: Número de Estancias por servicio (promedio de días cama usados en cada servicio);

IF: Índice de Funcionalidad (representa la eficiencia del servicio).

El resultado del análisis de componentes principales muestra los siguientes resultados para las dos primeras componentes.

CP1: $\lambda_1=2,558$. Vec. Pr. [0,860; 0,421; -0,406 ; -0,25; -0,562 ; 0,820; 0,663]

CP 2: $\lambda_2=1,829$. Vec. Pr. [-0,066; 0,747; 0,670 ; 0,388; 0,635; 0,508; 0,078].


Determine la validez del análisis.

Ubique las variables medidas en el plano de las dos primeras componentes.

Interprete cada componente.

Clasifique los servicios, según la interpretación de cada componente.

Seleccione los servicios con mayor carga de trabajo cualitativa y cuantitativa, determine los más eficientes (máximo 2 por categoría).



Medidas de Calidad

1. Una parte de la medida de calidad usada para evaluar reglas de asociación está dada por la función L , que depende de las siguientes probabilidades:

$$L(A \Rightarrow B) = p(\bar{A}) \left(1 - p(B / \bar{A})^2 + [1 - p(B / \bar{A})]^2 \right)$$

Determine la monotonidad (monótona o anti-monótona) de L para el caso del soporte (con confianza constante) y para el caso de la confianza (con soporte constante).

2. Una parte de la medida de calidad usada para evaluar reglas de asociación está dada por la función $GINI$, que depende de las siguientes probabilidades:

$$GINI(A \Rightarrow B) = p(A) \left(1 - [p(B / A)^2 + [1 - p(B / A)]^2] \right)$$

Determine la monotonidad (monótona o anti-monótona) de L para el caso del soporte (con confianza constante) y para el caso de la confianza (con soporte constante).

3. Expresé la siguiente medida de calidad en la forma probabilística más simple e interpretarla. ¿a que medida conocida se parece?

$$x = n \frac{\text{conf}(A \Rightarrow B)}{\text{sop}(A \Rightarrow B)} \left[1 - \frac{\text{sop}(\bar{A} \Rightarrow B \text{conf}(B \Rightarrow A))}{\text{sop}(A \Rightarrow B)} \right]$$

4. Un médico especialista en enfermedades Broncopulmonares infantiles tiene la convicción de que la estacionalidad del clima en Santiago influye fuertemente en el agravamiento de los infantes alérgicos. Para evaluar su hipótesis ha recolectado datos de los infantes con síntomas alérgicos e infantes normales y ha constatado sus ingresos a salas IRA (Infección Respiratoria Aguda) de la ciudad de Santiago. Muestre una base de datos codificada para la aplicación del método de reglas de asociación, que tenga la particularidad de que cuando se agrega la variable estacionalidad (importa la instancia invierno) la confianza aumenta.

MÉTODOS BAYESIANOS

5. Diseñe un clasificador Bayesiano ingenuo para el siguiente problema.

Una compañía de seguros, especializada en pólizas de automóviles, se requiere tener un modelo que determina si el postulante a un seguro tendrá o no accidente, basado en las variables sexo y el tipo de auto que conduce (Particular=P o de Trabajo=T). Para diseñar el clasificador se cuenta con la siguiente BD, donde se indica si el cliente ha tenido accidentes previamente.

	Sexo	Tipo	Accidente
1	M	P	Si
2	F	P	No
3	M	P	Si
4	F	T	No
5	M	T	No
6	F	P	No
7	M	T	Si
8	F	P	Si

6. Para saber si un determinado tipo de gen puede ser expresado se tienen dos características principales:

- El tipo de nucleótido (base) de su inicio (A: amina, T: tiamina, C: citosina, G: guanina).
- El tipo de aminoácido que se encuentra al final del gen que pueden ser de tres tipos (His (H): Histidina, Met (M): metionina, Lys (L): Lisina).

Usando la BD de la tabla 1, obtenga la expresión de genes, mediante un clasificador Bayesiano ingenuo, para todos los casos que comienzan con el nucleótido amina. Identifique las combinaciones que no poseen ejemplos. Mencione una alternativa para obtener las probabilidades de este tipo de casos.

Núcleo-tido	Amino-ácido	Expresión
A	L	Si
C	H	No
T	H	No
A	M	Si
T	H	No
A	L	Si
T	H	No
A	H	No
C	L	Si
T	M	No
T	M	No
C	L	Si
A	H	No
G	H	Si
A	H	No
G	H	No
A	H	No
C	M	No
A	M	No
T	M	No

7. Estime las diferentes probabilidades para diseñar un Clasificador Bayesiano Ingenuo, que clasifica pacientes según su riesgo, usando la edad y el tipo de cirugía, de acuerdo a la tabla adjunta.

Usando el clasificador determine si los pacientes de 25 años con cirugía tipo 2 son riesgosos o no

Edad Paciente	Tipo de cirugía	Riesgo
15	3	Riesgoso
55	1	No Riesgoso
36	1	No Riesgoso
20	2	Riesgoso
40	1	No Riesgoso
17	3	Riesgoso
33	1	No Riesgoso
18	1	No Riesgoso
62	3	Riesgoso
26	2	No Riesgoso
38	2	No Riesgoso
57	3	Riesgoso
22	3	No Riesgoso
70	1	Riesgoso
16	1	No Riesgoso
72	1	No Riesgoso
24	1	No Riesgoso
45	2	No Riesgoso
15	2	No Riesgoso
26	2	No Riesgoso

8. Para determinar si un gen se expresa (G) se utiliza un índice de expresión (Ie) y la presencia de cajas de regulación (CR). La expresión del gen se ha determinado midiendo la fluorescencia (f) del gen en un micro arreglo y se dispone de las verosimilitudes para cada gen. Considerando que el 40% de los genes son expresados, para el conjunto de datos de entrenamiento mostrado, determine, basado en las verosimilitudes, cuales casos son expresados. Luego diseñe un clasificador Bayesiano Ingenuo que determine si un gen es expresado de acuerdo a las variables Ie y CR . Calcule si un gen es expresado cuando el índice (Ie) es 18, luego 36 y en ambos casos existe caja de regulación ($CR=Si$). Muestre las expresiones literales antes de calcular.

<i>Ie</i>	<i>CR</i>	Verosimilitud de f con $\bar{G}$	Verosimilitud de f con G
40	Si	0,006	0,16
20	Si	0,072	0,004
28	No	0,043	0,04
47	No	0,005	0,17
37	Si	0,024	0,1
32	No	0,03	0,072
41	Si	0,006	0,017
38	No	0,023	0,105
15	Si	0,12	0,0016
27	Si	0,042	0,04
38	No	0,025	0,11
42	No	0,005	0,16

9. La SIAT de Carabineros de Chile posee una reducida base de datos - como se muestra en la tabla adjunta - para predecir la probabilidad de accidentes, basado sólo en las variables edad del conductor y el estado del camino. Estime las funciones o proporciones de probabilidades para diseñar un clasificador Bayesiano Ingenuo que permita estimar si un conductor tendrá accidente al circular por un determinado camino. Determine además si un conductor con 25 años y transitando por un camino en buen estado producirá accidente ?

Edad	Estado camino	Accidente
40	malo	Si
20	malo	No
28	bueno	No
47	bueno	Si
37	malo	Si
32	bueno	Si
41	malo	Si
38	bueno	Si
15	malo	No
27	malo	No
38	bueno	Si
42	bueno	Si

Arboles de decisión (Quinlan)

10. Para la siguiente base de datos muestre los cálculos de la razón de ganancia propuestos por Quinlan, para seleccionar el atributo estudiante que presenta mejor discriminación de la clase.

	A	B	Clase
1	0	0	si
2	0	0	no
3	0	1	no
4	0	1	si
5	1	0	si
6	1	1	si
7	1	0	si
8	1	1	si
9	2	0	no
10	2	0	no
11	2	1	si
12	2	1	si

11. La BD de la tabla muestra dos variables seleccionadas por un banco, para clasificar clientes. *Salario* y si tiene *hijos*.

Usando el método de máxima entropía propuesto por Quinlan, determine cuál de las dos variables discrimina mejor si es un buen cliente.

Salario	hijos	Buen cliente
alto	Si	si
alto	Si	no
alto	No	no
alto	No	si
medio	Si	si
medio	No	si
medio	Si	si
medio	No	si
bajo	Si	no
bajo	Si	no
bajo	No	si
bajo	No	si

12. En genética es muy importante determinar si un gen está expresado en un organismo particular. Una forma de averiguar si el gen está expresado o no es saber si existe un *promotor* en antes del gen. La existencia de un determinado *promotor* se puede medir por la existencia de aminoácidos en el inicio y final del *promotor*. Para el caso de un organismo específico se sabe en el inicio del *promotor* existen dos posibilidades Glicina (G) y Prolina (P) y para el fin del *promotor* existen tres alternativas Histidina (H), Metionina (M) y Lisina (L).

Usando el método de máxima entropía propuesto por Quinlan, determine cuál de las dos posiciones (inicio o fin) del *promotor* discrimina mejor su existencia

Inicio	fin	Promotor
G	H	si
G	H	no
P	H	si
G	M	si
P	L	si
P	M	si
P	H	no
G	M	si
G	L	no
G	L	no
P	M	si
P	L	si

13. Se requiere determinar entre las características: Depresión de segmento ST e Inclinación del segmento ST, la que clasifica mejor la patología (Isquemia). Se cuenta con 1.000 casos para la Depresión del segmento y 800 para el caso de Inclinación, como se muestra en las siguientes tablas. Exprese sus cálculos antes en literales.

	Con Isquemia	Sin Isquemia
Sin depresión ST	200	400
Con depresión ST	200	200

	Con Isquemia	Sin Isquemia
Sin Inclinación ST	48	552
Sin Inclinación ST	200	0

14. La SIAT de Carabineros de Chile posee una reducida base de datos - como se muestra en la tabla adjunta - para predecir la probabilidad de accidentes en las variables edad del conductor y el estado del camino. Además, considere que en los conductores se reconocen tres comportamientos según su edad, a saber: desde adolescentes a 26 años, de los 27 a los 37 y los mayores a 38 otro comportamiento. Utilice el método de árboles de decisión para determinar que atributo es más eficiente para clasificar accidentes.

Edad	Estado camino	Accidente
40	malo	Si
20	malo	No
28	bueno	No
47	bueno	Si
37	malo	Si
32	bueno	Si
41	malo	Si
38	bueno	Si
15	malo	No
27	malo	No
38	bueno	Si
42	bueno	Si