



Guía de ejercicios Capítulo III

Análisis de Agrupamientos

a) Objetivos de la Unidad

#	Descripción	Preguntas
1.	Establecer diferencias entre agrupamientos jerárquicos y no jerárquicos.	
2.	Comprender los conceptos de similaridad en espacios n-dimensionales como un concepto de distancia.	
3.	Comprender la estructuración de un agrupamiento jerárquico.	
4.	Cuantificar las medidas de similaridad y su aplicación a la agrupación.	
5.	Comprender los algoritmos básicos de los agrupamientos.	
6.	Comprender las medidas de calidad para evaluar agrupamientos.	



b) Preguntas

P1. Agrupamiento de genes

En una gran variedad de problemas de bioinformática, se requiere determinar grupos de genes que intervienen en una determinada enfermedad. Los genes están formados por un alfabeto básico que contiene 4 letras (bases) A, G, C, T. Muchas veces con un trozo de gen (aproximadamente 8 bases “letras”) es posible caracterizar un gen. Para la siguiente tabla determine:


- Un método para medir distancia entre genes.
- Construya una matriz de distancia entre los genes.
- Determine el dendrograma que caracteriza este conjunto de genes.
- Determine 2, 3 o 4 grupos según corresponda.

Gen 1	G	A	T	A	C	A	T	T
Gen 2	G	A	T	A	C	A	T	A
Gen 3	G	A	T	A	C	T	A	C
Gen 4	C	T	A	A	G	G	G	G
Gen 5	C	T	C	A	G	G	G	G
Gen 6	G	A	T	T	T	C	C	G
Gen 7	G	A	T	T	A	C	C	G



P2. Matriz de distancias y dendrograma

Para la siguiente distribución de casos determine la matriz de distancias y el árbol Jerárquico (dendrograma) en forma aproximada.





P3. Catálogo de obras

Para confeccionar un catálogo de obras de arte se requería agrupar las diferentes obras. Se reunió a un grupo de 16 expertos que clasificaron las obras por pares en forma binaria ('1'=parecidas, '0'=diferentes). La matriz de similaridad se compone de las sumas de las votaciones '1' de los expertos. Use un método de agrupamiento jerárquico para obtener el dendrograma resultante y entregue dos conjuntos que cada uno de ellos representen obras similares.

	X1	X2	X3	X4	X5	X6
X1	16	15	15	3	15	6
X2		16	1	15	3	15
X3			16	15	3	15
X4				16	15	6
X5					16	15
X6						16



P4. Agrupamiento Jerárquico

Aproxime a valores enteros los centros de los centroides y dibuje el dendrograma resultante al aplicar un agrupamiento jerárquico a la siguiente matriz.

	X1	X2	X3	X4	X5	X6
X1	0	1,2	2,3	8,2	8,3	8,4
X2		0	2,1	8,1	8,2	8,2
X3			0	8,3	8,2	8,2
X4				0	3,3	3,2
X5					0	2,3
X6						0



2. Respuestas

P1. Agrupamiento de genes


- a) Rpta: Un método para medir la distancia entre genes es cuantificar las disimilitudes de las cuatro bases nitrogenadas (A, G, C, T) entre genes (1 al 7) para construir una matriz de distancia de Hamming.

$$D(x, y) = \sum_{i=1}^n \mathbf{1}(x_i \neq y_i)$$

- b) Rpta:

	Gen 1	Gen 2	Gen 3	Gen 4	Gen 5	Gen 6	Gen 7
Gen 1	0	1	3	7	7	5	5
Gen 2		0	3	7	7	5	5
Gen 3			0	7	7	5	5
Gen 4				0	1	7	7
Gen 5					0	7	7
Gen 6						0	1
Gen 7							0

- c) y d) Dendrograma y grupos.



Se pueden obtener tres grupos al cortar en 4. Grupo 1 G1, G2, G3. Grupo 2 G4 y G5. Grupo 3 G6 y G7.



P2. Matriz de distancias y dendrograma

a) Coordenadas en el plano:

	X	Y
X1	-4,5	2
X2	-1,5	2,5
X3	-4,5	4
X4	-1,5	3,5
X5	5	3
X6	5	2


$$d(P, Q) = \sqrt{(X_Q - X_P)^2 + (Y_Q - Y_P)^2}$$

Distancia euclidiana

La siguiente matriz muestra las distancias euclidianas entre cada par de puntos (X1 a X6).

X0	X1	X2	X3	X4	X5	X6
X1	0,0000	3,0414	2,0000	3,3541	9,5525	9,5000
X2		0,0000	3,3541	1,0000	6,5192	6,5192
X3			0,0000	3,0414	9,5525	9,7082
X4				0,0000	6,5192	6,6708
X5					0,0000	1,0000
X6						0,0000

b) Árbol Jerárquico (dendrograma). X1 y X3 están a distancia ≈ 2.0 , X2 y X4 están a distancia ≈ 1.12 . Finalmente, X5 y X6 están a distancia 1.0, por lo que son el par más cercano.






P3. Catálogo de obras

Se calcula la matriz de distancia (disimilitud) $Disimilitud_{ij} = 16 - Similaridad_{ij}$

	X1	X2	X3	X4	X5	X6
X1	0	1	1	13	1	10
X2		0	15	1	13	1
X3			0	1	13	1
X4				0	1	10
X5					0	1
X6						0

a) Árbol Jerárquico (dendrograma).



b) Dos conjuntos que representen obras iguales al dividir en $\approx 6,5$:

Conjunto 1: X1, X2.

Conjunto 2: X3, X4, X5, X6.