



Guía de ejercicios Capítulo II

Análisis de Componentes Principales

1. Objetivos de la Unidad

#	Descripción	Preguntas
1.	Describir los fundamentos matemáticos del modelo <i>Análisis de Componentes Principales</i> (PCA).	Todas
2.	Aplicar el modelo PCA en un conjunto de datos perteneciente a un problema específico.	Todas



2. Preguntas

P1. Comportamiento de consumo alimenticio

Un estudio del consumo de diferentes familias francesas intenta una caracterización mediante análisis de componentes principales. Las familias (sujetos) se caracterizan por su condición socioeconómica, clasificando el tipo de trabajo de los jefes de hogar, y por sus tamaños considerando el número de hijos. Los jefes de hogar tienen las siguientes características: (MA#) trabajador manual, (EM#) empleado, (PF#) profesional. Donde el símbolo # puede tomar los valores 2, 3, 4 o 5 y representa el número de hijos de las familias. Se mide el consumo promedio de los siguientes productos (atributos o variables originales x_i): Pan, Verduras, Frutas, Carnes, Aves, Lácteos y Vinos.

La matriz de correlación de los productos es la siguiente:

	Pan	Verduras	Frutas	Carnes	Aves	Lácteos	Vinos
Pan	1,00						
Verduras	0,59	1,00					
Frutas	0,20	0,87	1,00				
Carnes	0,32	0,89	0,96	1,00			
Aves	0,25	0,83	0,93	0,98	1,00		
Lácteos	0,86	0,66	0,33	0,37	0,23	1,00	
Vinos	0,30	-0,35	-0,49	-0,44	-0,40	-0,40	1,00

Después de realizar un análisis de componentes principales, los valores propios para las componentes son $\lambda_1=4,339$; $\lambda_2=1,829$; $\lambda_3=0,625$; $\lambda_4=0,502$; $\lambda_5=0,393$; $\lambda_6=0,099$; $\lambda_7=0,083$


Los vectores propios las dos primeras componentes se muestran en la siguiente tabla:

	Componente 1	Componente 2
Pan	-0,497	0,841
Verduras	-0,972	0,131
Frutas	-0,931	-0,277
Carnes	-0,963	-0,19
Aves	-0,912	-0,265



Lácteos	-0,584	0,707
Vinos	0,425	0,649

La distribución de los grupos familiares en el espacio de las dos primeras componentes principales se muestra en la siguiente figura:



- Determine el porcentaje de información que se pierde en el estudio con solo las dos primeras componentes.
- Intente una caracterización de las componentes inspeccionando sólo la distribución de las familias en el plano de las dos componentes.
- Dibuje en forma aproximada los productos consumidos (atributos o variables originales) en el espacio de las componentes.
- Asocie cada componente a los productos consumidos.
- Intente relacionar los productos consumidos por las familias y sus condiciones socioeconómicas y/o tamaños.



P2. Caracterización billetes falsos

Para caracterizar billetes falsos los bancos suizos realizaron un análisis que consistía en tomar medidas de los billetes. Para el análisis tenía tres grupos diferentes de billetes. Originales de papel, originales de plástico y billetes falsos. Cada billete fue caracterizado por las siguientes variables:


- LON : Longitud del billete.
- LD : Largo de la Diagonal del billete.
- AI : Ancho Izquierdo del billete.
- AD : Ancho Derecho del billete.
- AMI : Ancho Margen Inferior del billete
- AMS : Ancho Margen Superior del billete.

A continuación, se realizó un análisis de componentes principales con los siguientes resultados:

- Valores propios: 2,58; 1,34; 0,76; 0,56; 0,50; 0,26.
- Vectores propios para las dos primeras componentes:

	Componente 1	Componente 2
LON	0,395	0,799
LD	0,207	0,345
AI	0,445	-0,263
AD	0,411	-0,375
AMI	0,347	-0,072
AMS	0,560	-0,163

La distribución de los diferentes tipos de billetes se muestra en la siguiente figura (originales de papel en círculos, originales de plástico en cuadrados y falsos en triángulos):



Se realizó un trabajo similar con monedas midiendo 6 variables de tamaño de éstas y los valores propios del análisis fueron los siguientes: 1,96; 1,54; 1,09; 0,73; 0,40; 0,28.

- Determine el porcentaje de validez del análisis.
- Interprete cada una de las componentes
- Identifique las principales características de los billetes originales.
- Determine si existen diferencias entre las falsificaciones.
- Para el análisis de las monedas, ¿se logrará tener una precisión similar a la de los billetes?



P3. Caracterización servicios hospitalarios

Un estudio del Hospital de Andalucía (España) analizó 22.846 ingresos para intentar caracterizar los diferentes servicios (o unidades) del hospital. Los servicios analizados fueron los siguientes: Medicina Interna, Ginecología, Pediatría, Cirugía, Traumatología, Urología, Digestivo, Otorrinolaringología, Cardiología, Neurología, Hematología, Oftalmología y Psiquiatría. Para caracterizar los servicios se midieron 7 variables:

NI : Número de ingresos.

MO : Índice de mortalidad.

RE : Número de reingresos al servicio (por el mismo diagnóstico).

NE : Número de consultas externas al servicio.

ICM : índice promedio de la complejidad de los pacientes admitidos.

ES : Número de estancias por servicio (promedio de días cama usados en cada servicio).

IF : Índice de funcionalidad (representa la eficiencia del servicio)


El resultado del análisis de componentes principales muestra los siguientes resultados para las dos primeras componentes:

Valor propio 1: 2,558

Valor propio 2: 1,829

Vector propio 1: [0,860; 0,421; -0,406; -0,250; -0,562; 0,820; 0,663]

Vector propio 2: [-0,066; 0,747; 0,670; 0,388; 0,635; 0,508; 0,078]



- Determine la validez del análisis.
- Ubique las variables medidas en el plano de las dos primeras componentes.
- Interprete cada componente.
- Clasifique los servicios según la interpretación de cada componente.
- Seleccione los servicios con mayor carga de trabajo cualitativa y cuantitativa.
- Determine los servicios más eficientes.



P4. Análisis sector lechero

En un estado venezolano se utilizó ACP para analizar la situación del sector lechero. Las variables utilizadas fueron: SUP: superficie total de la hacienda; VACA: número total de vacas; SANI: índice sanitario; INST: índice de las instalaciones; MAQ: índice de maquinarias; PROM: Promedio de la lecha/vaca. Los resultados del ACP fueron los siguientes:


Valores propios: 1,794; 1,341.

Vectores propios ponderados por la raíz de cada valor propio:

	Componente 1	Componente 2
SUP	0,79	0,10
VACA	0,76	0,40
SANI	0,44	-0,48
INST	0,32	-0,48
MAQ	0,53	-0,26
PROM	-0,01	-0,80

Determine una caracterización de las componentes principales, al examinar la relación con las variables originales.

Al graficar las haciendas en el plano de las dos primeras componentes principales se pueden caracterizar 8 tipos de haciendas con problemas particulares, como se muestra en la figura. Utilice esta información para identificar los tipos de haciendas. Determine además el porcentaje de validez del estudio.





Facultad de Ingeniería
Departamento de Ingeniería
Informática

INTELIGENCIA COMPUTACIONAL

Guía de ejercicios Capítulo II


Análisis de Componentes Principales



Respuestas


P1. Comportamiento de consumo alimenticio

- a) Rpta.: 21,6%
- b) Rpta.: Al caracterizar los componentes a partir de las distribuciones de los sujetos en el plano, es posible apreciar que en cuadrante I (rango de valores CP1 y CP2 positivos) predominan los trabajadores manuales (#MA), y en menor número los empleados (#EM). El cuadrante II (rango de valores CP1 negativos y CP2 positivos) se sitúan en menor cantidad empleados (#EM) y trabajadores manuales (#MA) por igual, siendo estos últimos los sujetos con los valores más altos de CP2 de todo el análisis. En cuadrante III (rango de valores CP1 y CP2 negativos) se sitúan sólo sujetos profesionales (#PF). Finalmente, el cuadrante IV (con rango de valores CP1 positivos y CP2 negativos) es el más heterogéneo dado que se encuentran los tres tipos de jefes de hogares predominando los empleados. Data la homogeneidad de las muestras en los cuadrantes I y III, al suponer un orden de ingresos decreciente de los tres tipos de jefes de hogares ($\#MA < \#EM < \#PF$), relacionamos valores positivos de ambos componentes a sujetos con menores ingresos, y los negativos a mayores ingresos. También, podemos visualizar una separación lineal entre los 3 tipos de jefes de hogares de acuerdo a su consumo, por rectas con pendientes negativas.



Dado que el análisis se basa en el consumo de distintos productos alimenticios, a priori se presume que la dirección de los vectores propios correspondientes a los alimentos más caros como las carnes apuntarán al cuadrante IV.

- c) Rpta.:



- d) Rpta.: De acuerdo con la visualización de los vectores propios y componentes, los vectores correspondientes a carnes, aves, fruta, y verduras tienen una mayor proximidad al rango de valores negativos del componente 1. Los lácteos y el pan se ubican en el cuadrante III (valores CP1 negativos y CP2 positivos). De acuerdo con la evaluación previa, se situaría como productos de valor medio. Finalmente los vinos se relacionan a los valores positivos de ambos componentes.
- e) Rpta.: A partir del plano podemos inferir que los Profesionales (jefes de familia con mayores ingresos) consumen carne, aves, verduras y frutas. Los empleados representan el segmento con más hijos menores dado el consumo de leche y pan, y los trabajadores manuales consumen en mayor cantidad vino.




P2. Caracterización billetes falsos

a) Varianza explicada =
$$\frac{\text{Sum}(\text{TopXValoresPropios})}{\text{sum}(\text{TodosValoresPropios}) * 100}$$

$$= \frac{2,58 + 1,34}{(2,58 + 1,34 + 0,76 + 0,56 + 0,50 + 0,26) * 100} = 65,33333333\%$$

- b) Componente 1: Forma del billete / Márgenes internos (AMI + AMS)
Componente 2: Tamaño del billete (LON + LD)



- c) Se podría decir que los billetes originales tienen mayores márgenes internos. Así, los billetes de papel tienen menos márgenes que los de plástico. Por otro lado, los billetes de papel son considerablemente más grandes que los billetes de plástico
- d) Considerando el análisis que se hizo para los billetes originales y las componentes (forma - tamaño), es posible apreciar como entre los billetes falsos se tienen claras diferencias de tamaño. Esto se podría interpretar como que los billetes falsos que se encuentran arriba del eje CP1 podrían buscar imitar a los de papel, mientras los que se encuentran debajo del mismo eje, podrían buscar imitar a los de plástico.

e) Varianza explicada =
$$\frac{1,96 + 1,54}{(1,96 + 1,54 + 1,09 + 0,73 + 0,40 + 0,28) * 100} = 58,83\%$$




Dado que para el análisis con las monedas se tiene un 58,83% de la varianza explicada, versus un 65,33% en los billetes, se podría indicar que se tiene un 6.5% menos de esta varianza para las monedas. Dependiendo de la importante y rigurosidad de la investigación, esto podría ser un margen importante, pero, aun así, se podría decir que se tendría una precisión similar.



P3. Caracterización servicios hospitalarios

a) Rpta.: XX %

b) Rpta.:



c) Rpta.: El componente 1 se relaciona con los servicios hospitalarios de mayor demanda; mientras que el componente 2 en su rango de valores positivos se relaciona con los servicios hospitalarios con mayor probabilidad de hospitalización, en forma contraria sus valores negativos se asocian a prestaciones ambulatorias.

d) Rpta.: De acuerdo con el análisis de componentes Medicina Interna es el servicio más demandado con mayor hospitalización; Cirugía posee menor demanda y grado de hospitalización; Traumatología, Urología, son servicios ambulatorios con menor demanda que Ginecología, Pediatría. El servicio Digestivo posee una baja demanda, pero una alta probabilidad de mortandad; Otorrinolaringología, Cardiología, Oftalmología son servicios con menor demanda y riesgo; mientras que los servicios de Psiquiatría, Neurología, Hematología, poseen baja demanda pero un alto nivel de complejidad y reingreso número de consultas externas.

e) Rpta.: Los servicios con mayor carga de trabajo cualitativa, y cuantitativa son Medicina Interna, Ginecología y Pediatría.

f) Rpta.: Los servicios más eficientes corresponden a Cirugía y Traumatología.




P4. Análisis sector lechero

a) Características Componentes:

CP1: Área utilizada por vaca

CP2: Nivel industrialización



b) Tipos de haciendas:

A y C = Haciendas matadero

B = Haciendas lechera

D y E = Haciendas multipropósito

H y G = Haciendas muy pequeñas

F = Haciendas Crianza, pastoreo y engorde

c) Faltan algunos valores propios (?)