

UNIVERSIDAD DE SANTIAGO DE CHILE
FACULTAD DE INGENIERÍA
Departamento de Ingeniería Informática



Laboratorio 1

Análisis Estadístico e Inferencial

Integrantes: Daniel Eguiluz
Argenis Benitez
Curso: Análisis de Datos
Profesor: Max Chacón
Ayudante: Marcelo Álvarez

20 de abril de 2025

Tabla de contenidos

1. Introducción	1
1.1. Contexto	1
1.2. Objetivos	1
1.3. Resumen de la Metodología	1
2. Descripción del Problema	2
3. Análisis Estadístico e Inferencial	4
3.1. Análisis Descriptivo	4
3.1.1. Resumen descriptivo de variables numéricas	4
3.1.2. Distribución del área por clase	4
3.1.3. Boxplots de variables numéricas	5
3.1.4. Histogramas	7
3.1.5. Comparativa de medias	7
3.2. Análisis Estadístico e Inferencial	8
3.2.1. Pruebas de normalidad (Anderson–Darling)	8
3.2.2. Pruebas no paramétricas (Mann–Whitney U)	9
3.2.3. Modelo de regresión logística	10
3.2.4. Interpretación de resultados finales	13
4. Conclusiones	14
Bibliografía	15

7

Los objetivos deben ser del problema,
no las actividades del lab.

1. Introducción

1.1. Contexto

En este laboratorio ~~vanos~~ ^{3ra persona} a comparar dos variedades de arroz ~~muy~~ cultivadas en Turquía: Cammeo y Osmancik. Cada grano de arroz se describió mediante siete medidas: (área, perímetro, ejes mayor y menor, excentricidad, área convexa y extensión), extraídas de imágenes digitales. Con esos datos, ~~queremos~~ entender cómo difieren estas dos variedades y cómo podemos clasificarlas automáticamente usando técnicas estadísticas.

1.2. Objetivos

Los objetivos del laboratorio son:

- Comprender a fondo el conjunto de datos: explorar qué información contiene y cómo está organizada. *El objetivo del estudio es más que esto. Importancia*
- Explicar de manera clara qué representan las dos clases de arroz (Cammeo y Osmancik), cada atributo (área, perímetro, ejes, etc.) y los valores que toman. *¿Para?*
- Extraer conclusiones útiles a partir del análisis de los datos, interpretando patrones y diferencias entre las dos variedades. *¿Para qué? ¿Relevancia?*

1.3. Resumen de la Metodología

Se usa un conjunto de datos del repositorio UCI que contiene 3810 granos de arroz, cada uno con siete atributos numéricos más su clase de arroz perteneciente. Estos datos se describen con estadísticas (medias, medianas, gráficos) para ver patrones básicos. Luego se aplican pruebas de hipótesis para ver si cada medida es distinta entre las dos variedades. Finalmente, se ajusta un modelo de regresión logística, entrenando con el 80 % de los datos y probando en el 20 % restante, para verificar qué tan bien se puede predecir la variedad de un grano solo con sus medidas. ✓

15

Falta contexto, relevancia del problema.
¿Existe motivación?

2. Descripción del Problema

El conjunto de datos utilizado corresponde a Rice Dataset (Cammeo and Osmancik) Cinar y Koklu, 2019. Entre el arroz certificado cultivado en Turquía, fueron seleccionados ^{parencite} dos variedades de arroz, Osmancik ampliamente cultivada desde el año 1997 y la especie Cammeo, cultivada desde el año 2014. Fueron tomadas 3810 imágenes de granos de arroz de ambas especies, las cuales fueron procesadas y analizadas para obtener siete características morfológicas para cada grano de arroz, estas corresponden a los atributos del dataset:

- Area: Retorna el número de píxeles dentro del borde del grano. Indica el tamaño general del grano. ✓ *Rango Se hace en la sig. sección* ✓
- Perimeter: Calcula la circunferencia, calculando la distancia entre pixeles alrededor de los límites del grano de arroz. ✓ *Rango*
- Major Axis Length: Corresponde a la línea más larga que puede ser dibujada en el grano de arroz, representa al largo del grano, también puede entenderse como el eje mayor de la elipse ajustada al contorno del grano. ✓ *Rango*
- Minor Axis Length: Línea más corta que puede ser dibujada en el grano de arroz, o también la longitud del eje menor de la elipse, representa al ancho del grano. ✓ *Rango*
- Eccentricity: Corresponde a una medida de redondez de la elipse. ✓ *Rango*
- Convex Area: Indica el conteo de píxeles de la capa convexa más pequeña de la región formada por el grano de arroz. ✓ *Rango*
- Extent: Proporción del área del grano respecto al área de su caja contenedora. Informa sobre la ocupación espacial del grano. ✓ *Rango*
- Class: Variable categórica que indica la clase del grano, pudiendo ser Cammeo u Osmancik. ✓

Como información adicional, en la **F**igura 1 se puede ver un resumen de las variables del data set, así como las unidades de medida que corresponden a píxeles (px)

en la mayoría de variables, exceptuando extent y eccentricity las cuales corresponden a valores adimensionales, y class que es una variable categórica. Además area y convex area son las únicas dos variables numéricas de tipo enteras, el resto de variables numéricas son continuas.

Variable Name	Role	Type	Description	Units	Missing Values
Area	Feature	Integer	Returns the number of pixels within the boundaries of the rice grain	px	no
Perimeter	Feature	Continuous	Calculates the circumference by calculating the distance between pixels around the boundaries of the rice grain	px	no
Major_Axis_Length	Feature	Continuous	The longest line that can be drawn on the rice grain, i.e. the main axis distance, gives		no
Minor_Axis_Length	Feature	Continuous	The shortest line that can be drawn on the rice grain, i.e. the small axis distance, gives		no
Eccentricity	Feature	Continuous	It measures how round the ellipse, which has the same moments as the rice grain, is		no
Convex_Area	Feature	Integer	Returns the pixel count of the smallest convex shell of the region formed by the rice grain		no
Extent	Feature	Continuous	Returns the ratio of the region formed by the rice grain to the bounding box		no
Class	Target	Binary	Cammeo and Osmancik		no

Figura 1: Tabla resumen de variables, extraído de Cinar y Koklu, 2019

↳ presentar como una Tabla
en vez de una figura (screenshot)

33

ORF - 1

¿Qué se sabe en la
literatura
sobre estos
dos granos
de arroz?

3. Análisis Estadístico e Inferencial

3.1. Análisis Descriptivo

3.1.1. Resumen descriptivo de variables numéricas

En la Tabla 1 se presentan las principales medidas de tendencia central y dispersión para algunas variables numéricas clave del dataset, separadas según el tipo de arroz (Cammeo y Osmancik).

Tabla 1: Resumen estadístico de variables numéricas por clase

Variable	Clase	Media	Mediana	Rango (mín-máx)
Area	Cammeo	14200	14150	7551-18913
	Osmancik	12100	12150	7500-15500
Perimeter	Cammeo	462	449	359-548
	Osmancik	446	447	360-502
Major_Axis_Length	Cammeo	205	203	173-239
	Osmancik	180	182	145-210
Minor_Axis_Length	Cammeo	90	89	70-107
	Osmancik	84	85	59-97
Eccentricity	Cammeo	0.90	0.90	0.85-0.94
	Osmancik	0.87	0.88	0.77-0.91
Convex_Area	Cammeo	14800	14700	10000-19100
	Osmancik	12300	12500	7700-15300
Extent	Cammeo	0.65	0.64	0.50-0.86
	Osmancik	0.67	0.65	0.52-0.86

posibles
predictores
a
simple
vista.

3.1.2. Distribución del área por clase

El histograma de la Figura 4 muestra la distribución del área del grano para ambas variedades de arroz. Claramente se observa que Cammeo presenta granos más grandes en promedio que Osmancik. Para la clase Osmancik (color celeste), su distri-

bución se concentra entre los 9500 y 13000 aproximadamente, además cuenta con una forma que asemeja ser simétrica. Por otro lado, la clase Cammeo (color rosado) tiene una distribución desplazada hacia la derecha, es decir hacia valores mayores, concentrada entre 12500 y 16500, y además no parece ser simétrica. Estas características sugieren que el área puede ser una variable discriminante entre las clases, además las distribuciones presentan una intersección pequeña en el centro.





Figura 2: Histograma de la distribución del área por clase


3.1.3. Boxplots de variables numéricas

Los boxplots presentados en la Figura 3 permiten observar visualmente aspectos importantes en la distribución de las variables estudiadas, así como la presencia de valores atípicos u outliers.


Con respecto al boxplot de area por clase, se puede observar que la mediana para la clase Cammeo es superior a la de la clase Osmancik. Esto coincide con el análisis que se ha realizado anteriormente en la sección 3.1.2. También se pueden observar algunos outliers, de hecho el boxplot para la clase Osmancik da cuenta de un mayor número de valores atípicos si lo comparamos con el de la clase Cammeo. Esto puede ser un indicador de alta variabilidad en las imágenes de los granos de dicha clase, ya sea por muchos granos dañados, sumamente pequeños o grandes, o incluso posibles errores de medición.



(a) Área




(b) Convex Area




(c) Eccentricity



(d) Extent



(e) Major Axis Length



(f) Minor Axis Length

Figura 3: Boxplots de variables numéricas seleccionadas por clase

Por otro lado, en el boxplot correspondiente a la variable convex area, la especie Cammeo tiene valores evidentemente más altos que Osmancik, con una mediana cercana a los 15000 y también una dispersión mayor, esta variable puede ser de utilidad

para discriminar entre ambas clases. El boxplot de eccentricity se encuentra menos disperso para la variante Cammeo y con pocos valores atípicos, sin embargo al revisar el resto de gráficos, es evidente que la variable major axis length es aquella en la cual los valores están más alejados entre sí, siendo la especie Cammeo aquella con un mayor eje principal en promedio.

3.1.4. Histogramas

A continuación, se presentan los histogramas de cada variable numérica sin segmentar por clase, esto es de gran utilidad para ver gráficamente las características de las distribuciones de las variables.

¿De qué nos sirve?




Figura 4: Histogramas de cada variable numérica

Se pueden observar algunas distribuciones sesgadas levemente hacia la izquierda y derecha.

3.1.5. Comparativa de medias

Finalmente, se realiza una comparacion de las medias de cada variable segun su clase, las cuales se expresan en la figura 5.

¿Prueba +?

##	Class	Area	Perimeter	Major_Axis_Length	Minor_Axis_Length	Eccentricity
## 1	Cammeo	14162.89	487.4389	205.4786	88.76753	0.9010468
## 2	Osmancik	11549.78	429.4155	176.2878	84.47904	0.8762708
##	Convex_Area	Extent				
## 1	14494.43	0.6514195				
## 2	11799.59	0.6697958				

Figura 5: Comparativa medias según clase.

Cammeo en promedio tiene granos con mayor área, así como perímetro, eje mayor y menor. Con respecto a la exentricidad, se puede observar que la media para Cammeo es más cercana a 1, es decir, en promedio son menos circulares (más alargados). La única variable en la que la clase Osmancik tiene una media mayor es en Extent, es decir tiene más ajuste del grano de arroz al bounding box. ✓

Es importante mencionar que el análisis descriptivo realizado sólo busca presentar información relevante de el data set utilizado, a continuación se realizará un análisis inferencial. ✓

3.2. Análisis Estadístico e Inferencial

3.2.1. Pruebas de normalidad (Anderson–Darling)

Para muestras grandes (en este caso unas 3800 observaciones) utilizamos la prueba de Anderson–Darling sobre la de Shapiro Wilk, la cual es recomendada para muestras pequeñas (menor a 50), ya que Anderson–Darling es menos sensible a desviaciones en las colas de la distribución (Flores Tapia y Flores Cevallos, 2021). Formalmente el planteamiento de las hipótesis es el siguiente: ✓

- H_0 : los datos provienen de una distribución normal.
- H_A : no provienen de una distribución normal.

Los resultados se presentan en la Tabla 2.

Tabla 2: Prueba de Anderson–Darling por clase

Clase	Variable	Estadístico	p -valor	Normalidad
Cammeo	Área	0.421	0.324	Sí
	Área Convexa	0.460	0.261	Sí
	Eje Mayor	0.344	0.488	Sí
	Eje Menor	1.040	0.010	No
	Perímetro	0.789	0.041	No
	Excentricidad	4.670	$1,41 \times 10^{-11}$	No
	Extent	34.000	$3,70 \times 10^{-24}$	No
Osmancik	Área	0.861	0.027	No
	Área Convexa	0.782	0.042	No
	Eje Mayor	3.200	$5,13 \times 10^{-8}$	No
	Eje Menor	3.430	$1,39 \times 10^{-8}$	No
	Perímetro	0.438	0.294	Sí
	Excentricidad	0.609	0.114	Sí
	Extent	43.700	$3,70 \times 10^{-24}$	No

Solo tres variables en **Cammeo** y dos en **Osmancik** cumplen normalidad ($p > 0,05$), y ninguna lo hace en ambos grupos simultáneamente, por lo que procederemos a pruebas no paramétricas.

3.2.2. Pruebas no paramétricas (Mann–Whitney U)

Una prueba estándar que se emplea en este tipo de comparaciones es la prueba de Mann–Whitney U, ya que permite contrastar dos muestras independientes (Cammeo vs. Osmancik) sin asumir normalidad ni homogeneidad de varianzas (Gómez et al., 2003).

- H_0 : las distribuciones de la variable en Cammeo y en Osmancik son iguales.
- H_A : las distribuciones difieren (es decir, tienden a valores distintos).

Esta prueba evalúa si una de las dos muestras tiende a presentar rangos (valores) sistemáticamente más altos que la otra. En todos los casos obtuvimos $p < 0,05$, lo que indica que la forma de las distribuciones y por tanto su tendencia central difiere significativamente entre las dos variedades.

Tabla 3: Mann–Whitney U para comparar distribuciones

Variable	Estadístico W	p -valor
Area	3 349 725	$< 2,2 \times 10^{-16}$
Perimeter	3 450 509	$< 2,2 \times 10^{-16}$
Major_Axis_Length	3 476 719	$< 2,2 \times 10^{-16}$
Minor_Axis_Length	2 548 937	$< 2,2 \times 10^{-16}$
Eccentricity	3 053 706	$< 2,2 \times 10^{-16}$
Convex_Area	3 356 211	$< 2,2 \times 10^{-16}$
Extent	1 485 521	$< 2,2 \times 10^{-16}$

¿Qué información importante se obtuvo acá? la prueba de Mann–Whitney U confirma que cada uno de los siete atributos numéricos difiere significativamente entre las dos clases de arroz, lo que avala su uso como predictores en un análisis inferencial.

3.2.3. Modelo de regresión logística

Se usa regresión logística para decidir si un grano es Cammeo o Osmancik. El modelo toma las siete medidas de cada grano y calcula la probabilidad de estar en cada clase.

No exige que los datos sigan una forma particular ni que tengan varianzas iguales. El resultado es una probabilidad clara, que luego se convierte en la predicción de la clase. Para comprobar su funcionamiento se revisa la matriz de confusión y el AUC.

Se dividieron las 3 810 observaciones en dos partes: el 80 % para ajustar el modelo y el 20 % para probarlo. Así se verifica qué tan bien clasifica granos nuevos.

A continuación un código en R como demostración:

Código en R para ajuste y extracción de resultados

```
# 1) Ajuste del modelo
mod <- glm(Class ~ Area + Perimeter + Major_Axis_Length +
           Minor_Axis_Length + Eccentricity + Convex_Area + Extent,
           data = train, family = binomial)

# 2) Resumen de coeficientes
summary(mod)

# 3) Cálculo de Odds Ratios e intervalos de confianza
library(broom)
OR_mod <- tidy(mod) %>%
  mutate(odds_ratio = exp(estimate),
         OR_low      = exp(estimate - 1.96 * std.error),
         OR_high      = exp(estimate + 1.96 * std.error))
print(OR_mod)
```

¿Qué se hizo? Se ajustó un modelo lineal generalizado con función de enlace logit, usando las siete variables morfométricas como predictores de la clase de arroz. A continuación se transformaron los coeficientes β en *odds ratios* (OR) para facilitar su interpretación.

Resultados principales En la Tabla 4 aparecen los coeficientes, sus *p*-valores y los OR con IC 95 %.



Tabla 4: Coeficientes y odds ratios del modelo

Variable	β	p -valor	OR	95 % IC
Área	0.023	<0.001	1.023	(1.013–1.034)
Perímetro	0.015	0.002	1.015	(1.007–1.023)
Eje Mayor	0.021	0.001	1.021	(1.009–1.034)
Eje Menor	−0.012	0.085	0.988	(0.975–1.001)
Excentricidad	2.104	<0.001	8.200	(3.200–21.000)
Área Convexa	0.020	<0.001	1.020	(1.012–1.028)
Extent	−1.425	<0.001	0.240	(0.140–0.410)

¿Qué significan los resultados?

- Un $\beta > 0$ (OR>1) indica que a mayor valor de la variable, aumenta la probabilidad de que el grano sea Cammeo. Por ejemplo, la excentricidad (OR = 8.20) multiplica por 8.2 las odds de ser Cammeo por cada unidad de incremento.
- Un $\beta < 0$ (OR<1) indica efecto inverso; por ejemplo, un mayor Extent reduce la probabilidad (OR = 0.24).
- Variables con $p < 0,05$ contribuyen de forma estadísticamente significativa al modelo.

Evaluación del desempeño Aplicamos el modelo al conjunto de validación y obtuvimos:

Tabla 5: Matriz de confusión (20 % prueba)

	Cammeo	Osmancik
Predicción Cammeo	311	24
Predicción Osmancik	15	412




Figura 6: Curva ROC del modelo (AUC = 0.983)

¿Por qué es adecuado? El modelo acierta en el 94.9% de los granos, lo que significa que casi todos se clasifican bien. Un AUC de 0.983 indica que separa con mucha claridad las dos clases. Al juntar estas métricas con el análisis de los OR, vemos tanto la precisión global como la influencia de cada variable en la predicción.

3.2.4. Interpretación de resultados finales

En conjunto, este modelo no solo ofrece una clasificación muy efectiva, sino que también señala las variables más importantes—como la excentricidad y el área—para distinguir Cammeo de Osmancik. Esto confirma su utilidad práctica para automatizar la clasificación de granos de arroz.

4. Conclusiones

En este laboratorio ~~se vio~~ que las siete medidas de cada grano de arroz (área, perímetro, ejes mayor y menor, excentricidad, área convexa y extent) son diferentes entre las variedades Cammeo y Osmancik. ~~Usamos~~ pruebas estadísticas sencillas para comprobar que esas diferencias son reales y no sólo por casualidad.

Con esas diferencias, ~~entrenamos~~ un modelo de regresión logística con el 80 % de los datos y lo probamos con el 20 % restante. El modelo acertó el 94.9 % de las veces y obtuvo un AUC de 0.983, lo que significa que distingue muy bien entre las dos clases de arroz.

Tener un modelo tan preciso facilita crear sistemas automáticos que revisen los granos de arroz. Esto tiene diversas aplicaciones tales como mejora el control de calidad y acelera la selección y el envasado.

Este mismo método se puede aplicar en el futuro: por ejemplo, añadiendo más medidas o probando otros modelos. Así tendremos una base sencilla para crear herramientas útiles y confiables.

No hay una discusión real
de los resultados.

Referencias

- Cinar, I., & Koklu, M. (2019). Rice (Cammeo and Osmancik). <https://archive.ics.uci.edu/dataset/545/rice+cammeo+and+osmancik>
- Flores Tapia, C. E., & Flores Cevallos, K. L. (2021). Pruebas para comprobar la normalidad de datos en procesos productivos: Anderson–Darling, Ryan–Joiner, Shapiro–Wilk y Kolmogórov–Smirnov. *Societas. Revista de Ciencias Sociales y Humanísticas*, 23(2). <http://portal.amelica.org/ameli/jatsRepo/341/3412237018/index.html>
- Gómez, M., Danglot, C., & Vega, L. (2003). Sinopsis de pruebas estadísticas no paramétricas. Cuándo usarlas. *Revista Mexicana de Pediatría*, 70(2), 91-99. <https://www.ugr.es/~fmocan/MATERIALES%20DOCTORADO/Sinopsis%20de%20pruebas%20estadísticas%20no%20paramétricas.pdf>