





INTELIGÊNCIA COMPUTACIONAL

Fundamentos e aplicações

Alexandre G. Evsukoff



INTELIGÊNCIA COMPUTACIONAL

Fundamentos e aplicações

Alexandre G. Evsukoff

INTELIGÊNCIA COMPUTACIONAL

Fundamentos e aplicações

Alexandre G. Evsukoff

Rio de Janeiro, 2020


 **e-papers**

INTELIGENCIA A COMPUTAC IONAL

Fundamentos e aplicações
Alexandre G. Evangelista

Rio de Janeiro, 2020

 e-papers



Este trabalho está licenciado sob a Licença Atribuição-NãoComercial-SemDerivações 4.0 Internacional Creative Commons. Para visualizar uma cópia desta licença, visite <http://creativecommons.org/licenses/by-nc-nd/4.0/> ou mande uma carta para Creative Commons, PO Box 1866, Mountain View, CA 94042, USA.

ISBN 978-65-87065-02-1

Ilustração de capa

Matriz de correlação do conjunto de dados Sonar, elaborada pelo autor

Diagramação

Ana Claudia Ribeiro

Revisão

Rodrigo Reis

Disponível no site da Editora E-papers

<http://www.e-papers.com.br>

Avenida das Américas, 3.200 bloco 1 sala 138

Barra da Tijuca – Rio de Janeiro – Brasil

CEP 22.640-102

CIP-Brasil. Catalogação na fonte
Sindicato Nacional dos Editores de Livros, RJ

E94i

Evsukoff, Alexandre

Inteligência computacional : Fundamentos e aplicações [recurso eletrônico] / Alexandre Evsukoff. - 1. ed. - Rio de Janeiro : E-papers, 2020.
recurso digital : il. ; 20 MB

Formato: eletrônico

Requisitos do sistema:

Modo de acesso: world wide web

Inclui bibliografia


ISBN 978-65-87065-02-1 (recurso eletrônico)

1. Inteligência computacional. 2. Redes neurais (Computação). 3. Livros eletrônicos. I. Título.

20-64566

CDD: 006.3

CDU: 004.8



Esta obra está bajo una licencia Creative Commons Atribución-NoComercial-SinDerivadas 4.0 Internacional. Para ver una copia de esta licencia, visite <http://creativecommons.org/licenses/by-nc-nd/4.0/> o envíe una carta a Creative Commons, PO Box 1866, Mountain View, CA 94042, EE. UU.

ISBN 978-65-87065-02-1

Ilustração de capa

Matriz de correlación del conjunto de datos Sonar, creada por el autor

Diagramação

Ana Cláudia Ribeiro

Revisão

Rodrigo Reyes

Disponível em o site web de a Editora E-papers
<http://www.e-papers.com.br> Avenida das Américas,
3.200 quadra 1 habitação 138

Barra da Tijuca – Rio de Janeiro – Brasil C
EP 22.640-102

CIP-Brasil. Catalogación en fuente Unificada
Nacional de Editores de Libros, RJ

E94i Evsukoff, Alexandre Inteligencia computacional: fundamentos y aplicaciones [recurso electrónico] / Alexandre Evsukoff. - 1ª ed. - Río de Janeiro: E-papers, 2020. recurso digital: il. ; 20 MB Formato: electrónico Requisitos del sistema: Modo de acceso: world wide web Incluye bibliografía ISBN 978-65-87065-02-1 (recurso electrónico) 1. Inteligencia computacional. 2. Redes neuronales (Informática). 3. Libros electrónicos. I. Título. 20-64566 CDD: 006.3 CDU: 004.8

Sumário

APRESENTAÇÃO	8
1 INTRODUÇÃO	9
1.1 CIÊNCIA DE DADOS	12
1.2 TIPOS DE MODELOS	15
1.2.1 Regressão.....	16
1.2.2 Classificação.....	18
1.2.3 Análise de agrupamentos	20
1.3 RECURSOS COMPLEMENTARES	21
1.3.1 Bibliografia de referência	21
1.3.2 Recursos na internet.....	23
1.3.3 Softwares	26
1.4 COMENTÁRIOS FINAIS	29
2 PRÉ-PROCESSAMENTO	30
2.1 CONJUNTOS DE DADOS	30
2.2 CARACTERIZAÇÃO ESTATÍSTICA	33
2.2.1 Análise monovariável	34
2.2.2 Análise multivariada	40
2.2.3 Matriz de distâncias e similaridades.....	44
2.3 LIMPEZA DE DADOS	47
2.3.1 Padronização de variáveis.....	48
2.3.2 Detecção de outliers.....	49
2.3.3 Valores ausentes.....	53
2.4 TRANSFORMAÇÕES LINEARES.....	56
2.4.1 Análise de componentes principais	57
2.4.2 Decomposição em valores singulares	62
2.4.3 Análise discriminante linear	63
2.4.4 Análise de correlação canônica	66
2.5 APLICAÇÕES	69
2.5.1 Padrões de mobilidade	69
2.5.2 Equações de paridade	72
2.6 COMENTÁRIOS FINAIS	76

Resumen

PRESENTACIÓN	8
1 INTRODUCCIÓN	9
1.2	20
1.3 RECURSOS C	
1.3.1 Bibliografía de referencia	21
1.3.2 Recursos de Internet	21
1.3.3 Software	23
1.4 COMENTARIOS FINALES	26
29	
2 PREPROCESAMIENTO	30
2.1 CONJUNTOS DE DATOS	30
2.2 CARACTERIZACIÓN ESTADÍSTICA	33
2.2.1 Análisis de una sola variable	34
2.2.2 Análisis multivariado	40
2.2.3 Distancias y distancias de la mat	
riz de datos similitudes	44
2.3 LIMP	
IEZA DE DATOS	47
2.3.1 Estandarización de variables	48
2.3.2 Detección de valores atípicos	49
2.3.3 Valores faltantes	53
2.4 TRANSFORMACIONES LINEALES	56
2.4.1 Análisis de componentes principales ..	
2.4.2 Descomposición de valores s	
ingulares	62
2.4.3 Análisis discriminante linea	
l	63
2.4.4 Análisis de correlación ca	
nónica	66
2.5 APLICACI	
ONES	69
2.5.1 Patrones de movilidad	69
2.5.2 Ecuaciones de paridad	72
2.6 COMENTARIOS FINALES	76

3	REGRESSÃO LINEAR	78
3.1	O PROBLEMA DE REGRESSÃO.....	79
3.1.1	O Modelo linear	81
3.1.2	Método dos mínimos quadrados	82
3.1.3	Interpretação geométrica	84
3.1.4	Exemplo sintético	86
3.2	REGULARIZAÇÃO	89
3.2.1	Bias e variância.....	90
3.2.2	Regularização de Tikhonov.....	93
3.2.3	Regularização por componentes principais	97
3.3	VALIDAÇÃO DE MODELOS	98
3.3.1	Estatísticas de validação	99
3.3.2	Validação cruzada	104
3.4	APLICAÇÕES	106
3.4.1	Conjunto de dados Pollution	106
3.4.2	Previsão da elevação adiabática de temperatura do concreto.....	110
3.5	COMENTÁRIOS FINAIS	114
4	MODELOS DINÂMICOS	116
4.1	AUTOVARIÂNCIA E AUTOCORRELAÇÃO.....	117
4.2	MODELOS DE SÉRIES TEMPORAIS	121
4.2.1	Modelo AR.....	122
4.2.2	Modelo MA.....	126
4.2.3	Estruturas mistas	129
4.3	SISTEMAS DINÂMICOS LINEARES	131
4.3.1	Modelo ARX.....	133
4.3.2	Modelo ARMAX.....	135
4.3.3	Modelo OE.....	136
4.3.4	Modelo Box & Jenkins.....	138
4.3.5	Equações de estado	139
4.4	APLICAÇÕES	140
4.4.1	Wolf's sunspot numbers.....	140
4.4.2	Modelo chuva-vazão	142
4.5	COMENTÁRIOS FINAIS	146
5	CLASSIFICAÇÃO	148
5.1	CLASSIFICAÇÃO BAYESIANA	149
5.1.1	Decisão bayesiana	149
5.1.2	Classificador bayesiano simples	155
5.1.3	Classificador bayesiano quadrático.....	160

3 REGRESIÓN LINEAL	78
3.1 EL PROBLEMA DE LA REGRESIÓN	
..... 79 3.1.1 El modelo lineal	
..... 81 3.1.2 Método de mínimos cuadrados	
..... 82 3.1.3 Interpretación geométrica	
..... 84 3.1.4 Ejemplo sintético	
..... 86 3.2 REGULARIZACIÓN	
..... 89 3.2.1 Sesgo y varianza	
..... 90 3.2.2 Regularización de Tikhonov	
..... 93 3.2.3 Regularización por	
componentes principales	97} 3.5

4 MODELOS DINÁMICOS	116
126 4.2.3 Estructuras mixtas	
..... 129 4.3 SISTEMAS DINÁMICOS LINEALES	
..... 131 4.3.1 Modelo ARX	
..... 133 4.3.2 Modelo ARMAX	
..... 135 140 4,5	

5 CLASIFICACIÓN	148
149	

5.2	MODELOS LINEARES DE CLASSIFICAÇÃO.....	164
5.2.1	Mínimos quadrados.....	164
5.2.2	Mínimos quadrados ponderados.....	166
5.2.3	Regressão logística	168
5.3	AVALIAÇÃO DE CLASSIFICADORES.....	171
5.3.1	Estatísticas de validação	172
5.3.2	Espaço ROC e AUC.....	175
5.4	APLICAÇÕES	179
5.4.1	Testes benchmark.....	179
5.4.2	Análise de cancelamento em telefonia.....	183
5.5	COMENTÁRIOS FINAIS	187
6	ANÁLISE DE AGRUPAMENTOS	189
6.1	O PROBLEMA DE ANÁLISE DE AGRUPAMENTOS.....	190
6.2	MÉTODOS DE PARTIÇÃO	194
6.2.1	Algoritmo k-médias.....	194
6.2.2	Exemplos.....	198
6.3	MÉTODOS HIERÁRQUICOS	201
6.3.1	Algoritmos aglomerativos	202
6.3.2	Exemplos.....	203
6.4	PARTICIONAMENTO DE GRAFOS.....	204
6.4.1	Algoritmos de agrupamento espectral	210
6.4.2	Exemplos.....	216
6.5	VALIDAÇÃO DE GRUPOS	218
6.5.1	Medidas externas.....	218
6.5.2	Medidas internas	220
6.5.3	Medidas relativas	222
6.6	APLICAÇÕES	227
6.6.1	Segmentação de imagens de satélite	227
6.6.2	Agrupamento de documentos.....	230
6.7	COMENTÁRIOS FINAIS	234
7	MODELOS LINEARES LOCAIS.....	236
7.1	APRENDIZADO DE MÁQUINAS.....	237
7.2	MODELOS DE BASE RADIAL (RBF)	241
7.2.1	Aproximação de funções	242
7.2.2	Modelos RBF.....	246
7.2.3	Ajuste de parâmetros	250
7.3	MÁQUINAS DE VETOR DE SUPORTE	253
7.3.1	Funções de núcleo.....	253
7.3.2	Minimização do risco estrutural.....	258

5.2 MODELOS DE CLASIFICACIÓN LINEAL	164
..... 5.2.1 Mínimos cuadrados	164
..... 5.2.2 Mínimos cuadrados ponderados	166
..... 5.2.3 Regresión logística	168
5.3 EVALUACIÓN DE CLASIFICADORES	171
..... 5.3.1 Estadísticas de validación	172
..... 5.3.2 Espacio ROC y AUC	175
5.4 APLICACIONES	179
..... 5.4.1 Pruebas de referencia	179
..... 5.4.2 Análisis de la cancelación en telefonía	183
5.5 COMENTARIOS FINALES	187
6 ANÁLISIS DE CLÚSTER	189
6.1 EL PROBLEMA DEL ANÁLISIS DE CLÚSTER	190
6.2 MÉTODOS DE PARTICIÓN	194
..... 6.2.1 Algoritmo K-medias	194
..... 6.2.2 Ejemplos	198
6.3 HÉRICO MÉTODOS	201
..... 6.3.1 Algoritmos aglomerativos	202
..... 6.3.2 Ejemplos	203
6.4 PAR TIONAMIENTO DE GRÁFICOS	204
..... 6.4.1 Algoritmos de agrupamiento espectral	210
..... 6.4.2 Ejemplos	216
6.5 VALIDACIÓN DE GRUPO	218
..... 6.5.1 Medidas externas.....	218
..... 6.6.2 Agrupación de documentos.....	230
6.7 COMENTARIOS FINALE S.....	234
7 MODELOS LINEALES LOCALES	236
7.1 APRENDIZAJE MÁQUINA	237
7.2 MODELOS DE BASE RADIAL (RBF)	241
..... 7.2.1 Aproximación de funciones	242
..... 7.2.2 Modelos RBF	246
..... 7.2.3 Ajuste de parámetros	250
7.3 MÁQUINAS DE VECTO RES DE SOPORTE	253
..... 7.3.1 Funciones principales	253
..... 7.3.2 Minimización de riesgos estructurales	258

7.3.3	Classificadores de máxima margem.....	262
7.4	APLICAÇÕES	273
7.4.1	Testes benchmark.....	273
7.4.2	Algoritmo da decomposição espectral.....	274
7.5	COMENTÁRIOS FINAIS	278
8	SISTEMAS FUZZY	280
8.1	CONJUNTOS FUZZY	282
8.1.1	Funções de pertinência.....	285
8.1.2	Operadores fuzzy.....	289
8.1.3	Relações fuzzy.....	293
8.2	MODELOS DE REGRAS FUZZY	294
8.2.1	Variáveis linguísticas.....	295
8.2.2	Cálculo de regras fuzzy	298
8.2.3	Sistemas fuzzy simbólicos	304
8.3	ALGORITMOS PARA CIÊNCIA DE DADOS	313
8.3.1	Fuzzy c-médias	313
8.3.2	Fuzzy pattern matching.....	317
8.3.3	Algoritmo de Wang & Mendel.....	322
8.3.4	Modelo fuzzy-RBF	326
8.4	APLICAÇÕES	329
8.4.1	Testes benchmark.....	329
8.4.2	Diagnóstico de falhas.....	331
8.4.3	Classificação espacial.....	336
8.4.4	Modelo chuva-vazão	339
8.5	COMENTÁRIOS FINAIS	344
9	REDES NEURAIIS	346
9.1	REDES NEURAIIS LINEARES.....	350
9.1.1	Perceptron e ADALINE.....	352
9.1.2	Método do gradiente.....	356
9.1.3	Gradiente estocástico	360
9.2	REDES NEURAIIS NÃO LINEARES	362
9.2.1	Perceptron de Múltiplas Camadas (MLP).....	362
9.2.2	Avaliação pelo máximo da verossimilhança.....	368
9.2.3	Algoritmo da retropropagação.....	374
9.3	REDES NEURAIIS PROFUNDAS.....	388
9.3.1	Redes neurais convolucionais	391
9.3.2	Redes neurais recorrentes	411
9.3.3	Aprendizado da representação	439
9.4	APLICAÇÕES	452

7.5 COMENTARIOS FINALES	278
8 SISTEMAS FUZZY	280
8.1 CONJUNTOS <i>Fuzzy</i>	
..... 282 8.1.1 Funciones de membresía	
..... 285 8.1.2 Operadores difusos	
..... 289 8.1.3 Relaciones difusas	
..... 293 8.2 REGLA MODELOS <i>Fuzzy</i>	
..... 294 8.2.1 Variables lingüísticas	
..... 295 8.2.2 Cálculo de reglas d	
ifusas	298
8.2.3 Sistemas	
difusos simbólicos.....	304
8.3 ALGORITMO	
S PARA CIENCIA DE DATOS	
..... 313 8.3.1 C-medias difusas	
..... 313 8.3.2 Coincidencia de patrones difusos	
..... 317 8.3.3 Algoritmo de Wang y Mendel	
..... 322 8.3.4 Modelo RBF difuso	
..... 326 8.4 APLICACIONES	
..... 329 8.4.1 Pruebas de referencia	
..... 329 8.4.2 Diagnóstico de f	
allos	331
8.4.3 C	
lasificación espacial	3
36 8.4.4 Modelo lluvia-escorrentía	
..... 339 8.5 COMENTARIOS FINALES	
..... 344	
9 REDES NEURALES	346
9.1 REDES NEURALES LINEALES	
..... 350 9.1.1 Perceptrón y ADALINE	
..... 352 9.1.2 Método del gradiente	
..... 356 9.1.3 Gradiente estocástico	
..... 360 9.2 REDES NEURALES NO LINEALES	
..... 362 9.2.1 Perceptrón multicapa (MLP)	
..... 362 9.2.2 Evaluación de máxima verosimilitud	
..... 368 9.2.3 Algoritmo de retropropagación	
..... 374 9.3 REDES NEURALES PROFUNDAS	
..... 388 9.3.1 Redes neuronales	
convolucionales	391
9.3.2	
Redes neuronales recurrentes	
.... 411 9.3.3 Aprendizaje de representación	
..... 439 9.4 APLICACIONES	
..... 452	

9.4.1	Previsão de inadimplência	452
9.4.2	Previsão de emissões de combustível	455
9.4.3	Previsão de demanda de energia elétrica.....	458
9.4.4	Previsão de mercado financeiro	465
9.5	COMENTÁRIOS FINAIS	470
REFERÊNCIAS BIBLIOGRÁFICAS.....		471
REFERÊNCIAS NA INTERNET.....		521

9.5 COMENTARIOS FINALES	
.....	470
REFERENCIAS BIBLIOGRÁFICAS	471
REFERENCIAS EN INTERNET.....	521

Apresentação

A **inteligência computacional** é um conjunto de paradigmas computacionais para o desenvolvimento e aplicação de sistemas inteligentes em problemas complexos do mundo real. A **ciência de dados** reúne o conhecimento de matemática, estatística, computação e engenharia com o conhecimento do domínio de cada aplicação.

A ubiquidade dos dados na era digital faz a ciência de dados ter aplicações em todas as áreas de engenharia e, cada vez mais, em ciências naturais, biológicas e humanas. Este livro apresenta uma introdução às principais técnicas e modelos de inteligência computacional em aplicações de ciência de dados. O livro aborda os fundamentos para a preparação de dados, ajustes de modelos preditivos e descritivos e apresenta aplicações em engenharia, resultados dos projetos realizados na Coppe/UFRJ. O material pode ser utilizado como livro-texto em disciplinas de graduação e pós-graduação.

O livro é dividido em nove capítulos. Os cinco primeiros contêm uma introdução às técnicas de estatística através da apresentação dos principais métodos de regressão linear, sistemas dinâmicos, classificação e análise de agrupamentos. O Capítulo 7 discute teoricamente o problema de aproximação de funções e apresenta os modelos de função de base radial (RBF) e máquinas de vetor de suporte (SVM). O Capítulo 8 apresenta os sistemas *fuzzy* e o Capítulo 9, os modelos de redes neurais com uma introdução aos modelos recentes de redes neurais profundas.

Presentación

La inteligencia computacional es un conjunto de paradigmas computacionales para el desarrollo y aplicación de sistemas inteligentes a problemas complejos del mundo real. La ciencia de datos reúne conocimientos de matemáticas, estadística, informática e ingeniería con conocimientos de dominio de cada aplicación.

La ubicuidad de los datos en la era digital significa que la ciencia de datos tiene aplicaciones en todas las áreas de la ingeniería y, cada vez más, en las ciencias naturales, biológicas y humanas. Este libro presenta una introducción a las principales técnicas y modelos de inteligencia computacional en aplicaciones de ciencia de datos. El libro cubre los fundamentos para la preparación de datos, ajustes de modelos predictivos y descriptivos y presenta aplicaciones en ingeniería, resultados de proyectos realizados en la Coppe/UFRJ. El material puede utilizarse como libro de texto en cursos de pregrado y posgrado.

El libro está dividido en nueve capítulos. Los cinco primeros contienen una introducción a las técnicas estadísticas a través de la presentación de los principales métodos de regresión lineal, sistemas dinámicos, clasificación y análisis de conglomerados. El Capítulo 7 analiza teóricamente el problema de aproximación de funciones y presenta los modelos de función de base radial (RBF) y máquinas de vectores de soporte (SVM). El Capítulo 8 presenta sistemas *fuzzy* y el Capítulo 9, modelos de redes neuronales con una introducción a los modelos recurrentes de redes neuronales profundas.

1 INTRODUÇÃO

A capacidade de uma máquina exibir um comportamento inteligente foi objeto de reflexão filosófica durante muito tempo. Na década de 1920, Wittgenstein abordou o tema a partir da questão “pode uma máquina pensar?” A sua conclusão foi que, assim como a consciência, pensar é uma capacidade inerentemente humana [483]. Em 1950, tendo em vista a dificuldade de definir “pensar” e “inteligência”, Alan Turing propôs um teste para verificar se um computador pode exibir um comportamento inteligente [529]. O teste de Turing¹ é proposto como um jogo em que um avaliador isolado numa sala é colocado em contato com um interlocutor em outra sala, que pode ser humano ou computador. Se o avaliador não puder identificar se o interlocutor é um computador, então pode-se concluir que o computador tem um comportamento inteligente.

A inteligência artificial como área de pesquisa surgiu alguns anos mais tarde, como uma proposta de integração de lógica, ciência da computação e neurofisiologia para o desenvolvimento de máquinas inteligentes. No início da década de 1960, as duas principais correntes para o desenvolvimento de inteligência artificial eram chamadas de simbolistas e conexionistas. A corrente simbolista era formada por lógicos matemáticos que desenvolveram os primeiros provadores de teoremas. Na corrente conexionista, o objetivo era simular o processamento cerebral com neurônios artificiais. Os resultados iniciais do algoritmo de aprendizado do Perceptron [457] geraram grande expectativa com a possibilidade de construção de cérebros artificiais, mas sua limitação como classificador linear não permitia o ajuste de modelos mais complexos.

1 INTRODUCCIÓN

La capacidad de una máquina para exhibir un comportamiento inteligente ha sido objeto de reflexión filosófica durante mucho tiempo. En la década de 1920, Wittgenstein abordó el tema basándose en la pregunta “¿puede pensar una máquina?” Su conclusión fue que, al igual que la conciencia, el pensamiento es una capacidad inherentemente humana [483]. En 1950, ante la dificultad de definir “pensamiento” e “inteligencia”, Alan Turing propuso una prueba para verificar si una computadora puede exhibir un comportamiento inteligente [529]. El test de Turing¹ se plantea como un juego en el que un evaluador aislado en una habitación se pone en contacto con un interlocutor en otra habitación, que puede ser humano o informático. Si el evaluador no puede identificar si el interlocutor es una computadora, entonces se puede concluir que la computadora se comporta de manera inteligente.

La inteligencia artificial como área de investigación surgió unos años después, como una propuesta de integrar la lógica, la informática y la neurofisiología para el desarrollo de máquinas inteligentes. A principios de la década de 1960, las dos principales corrientes para el desarrollo de la inteligencia artificial fueron denominadas simbolistas y conexionistas. La corriente simbolista estuvo formada por lógicos matemáticos que desarrollaron los primeros demostradores de teoremas. En la corriente conexionista el objetivo era simular el procesamiento cerebral con neuronas artificiales. Los resultados iniciales del algoritmo de aprendizaje Perceptron [457] generaron grandes expectativas respecto a la posibilidad de construir cerebros artificiales, pero su limitación como clasificador lineal no permitió el ajuste de modelos más complejos.

Ao longo da década de 1970, os computadores *mainframe* se difundiram como produtos para a automação do processamento de dados em organizações. Os provadores de teorema evoluíram para os sistemas especialistas, que continham um motor de raciocínio que processava o conhecimento representado por um conjunto de regras e fatos. Logo ficou claro que a aquisição do conhecimento dos especialistas não era uma tarefa trivial, o que fomentou o interesse por técnicas de **aprendizado de máquina** (*machine learning*) para sínteses de modelos diretamente a partir de dados. O algoritmo ID3 de indução de árvores de decisão foi apresentado em 1986 por Quinlan. O ID3 tinha a capacidade de abstrair um conjunto de regras lógicas a partir de dados de variáveis nominais. O artigo inaugurou a revista *Machine Learning* [445].

Os modelos conexionistas retornariam com grande impacto em 1986 a partir da publicação de artigo na revista *Nature* [464] que apresentava um algoritmo de treinamento de redes neurais de múltiplas camadas baseado na retropropagação do erro através das camadas. Os resultados mostravam a capacidade do método na solução de problemas complexos de reconhecimento de padrões, como a identificação de dígitos manuscritos. As redes neurais se desenvolveram rapidamente devido a sua capacidade de ajuste de modelos não lineares computacionalmente robustos, com bons resultados em diversas aplicações. Na década de 1980, a introdução do IBM PC marca o início da difusão de computadores pessoais para o grande público e empresas de pequeno porte.

Nas décadas de 1980 e 1990, houve grande avanço na área de inteligência artificial, com o desenvolvimento de novos paradigmas computacionais como os sistemas *fuzzy*, redes neurais e máquinas de vetor de suporte. A integração destes modelos em abordagens híbridas, incluindo a utilização de algoritmos evolucionários para otimização, foi chamada de computação macia (*soft computing*) ou **inteligência computacional** (*computational intelligence*). Atualmente, a inteligência computacional inclui também métodos estatísticos e de aprendizado de máquina.²

Na década de 1990, os computadores pessoais já haviam se tornado um produto de uso comum e, na virada para o ano 2000, aproximadamente 30% da população dos EUA e da Europa estava conectada à internet.³ A expectativa com o desenvolvimento da internet foi enorme no final da década de 1990, o que resultou na chamada bolha da internet,⁴ que estourou em 2000 e provocou a queda das cotações das ações negociadas na bolsa de tecnologia NASDAQ. A partir da bolha “.com”, a competição ficou mais intensa e a internet se tornou um mercado mais maduro, dominado por grandes *players*.

A lo largo de la década de 1970, las computadoras *mainframe* se difundieron como productos para automatizar el procesamiento de datos en las organizaciones. Los demostradores de teoremas evolucionaron hasta convertirse en sistemas expertos, que contenían un motor de razonamiento que procesaba el conocimiento representado por un conjunto de reglas y hechos. Pronto quedó claro que adquirir conocimientos de expertos no era una tarea trivial, lo que alimentó el interés en las técnicas de aprendizaje automático (*machine learning*) para sintetizar modelos directamente a partir de datos. El algoritmo de inducción del árbol de decisión ID3 fue presentado en 1986 por Quinlan. ID3 tenía la capacidad de abstraer un conjunto de reglas lógicas a partir de datos de variables nominales. El artículo inauguró la revista *Machine Learning* [445].

Los modelos conexionistas regresarían con gran impacto en 1986 tras la publicación de un artículo en la revista *Nature* [464] que presentaba un algoritmo de entrenamiento de redes neuronales multicapa basado en la retropropagación del error a través de las capas. Los resultados mostraron la capacidad del método para resolver problemas complejos de reconocimiento de patrones, como la identificación de dígitos escritos a mano. Las redes neuronales se han desarrollado rápidamente debido a su capacidad para ajustar modelos no lineales computacionalmente robustos, con buenos resultados en varias aplicaciones. En la década de 1980, la introducción del IBM PC marca el comienzo de la difusión de los ordenadores personales entre el público en general y las pequeñas empresas.

En las décadas de 1980 y 1990 se produjeron grandes avances en el área de la inteligencia artificial, con el desarrollo de nuevos paradigmas computacionales como sistemas *fuzzy*, redes neuronales y máquinas de vectores de soporte. La integración de estos modelos en enfoques híbridos, incluido el uso de algoritmos evolutivos para la optimización, se denominó computación blanda (*soft computing*) o inteligencia computacional (*computational intelligence*). Actualmente, la inteligencia computacional también incluye métodos estadísticos y de aprendizaje automático.²

En los años 1990, los ordenadores personales ya se habían convertido en un producto de uso común y, a principios del año 2000, aproximadamente el 30% de la población de EE.UU. y Europa estaba conectada a Internet.³ Las expectativas sobre el desarrollo de Internet eran enormes a finales de los años 1990, lo que dio lugar a la llamada burbuja de Internet,⁴ que estalló en 2000 y provocó la caída del precio de las acciones negociadas en el mercado. Bolsa de tecnología NASDAQ. Desde la burbuja “.com”, la competencia se ha vuelto más intensa e Internet se ha convertido en un mercado más maduro, dominado por grandes empresas *players*.

Ao longo da década de 1990, o termo **mineração de dados** (*data mining*) começou a se difundir como um conjunto de técnicas que incluem estatística, aprendizado de máquina, inteligência computacional, bancos de dados, entre outras, para o desenvolvimento de modelos a partir de dados. Em 1997, surgiu a primeira plataforma de código livre de mineração de dados, o Weka,⁵ desenvolvido na Universidade de Waikato, Nova Zelândia, tornando-se uma referência no mundo acadêmico. A partir de 2000, cada vez mais *softwares* comerciais e bibliotecas oferecem novos algoritmos.⁶ Ao longo da década de 2000, as plataformas começaram a se apresentar no mercado como soluções de inteligência analítica [329], com foco em análise de dados e alinhamento dos resultados com os objetivos do negócio.

A redução de custos de armazenamento, o desenvolvimento dos processadores e a internet alavancaram o processo de coleta e armazenamento de bases de dados. O começo do século XXI marca o início da predominância do armazenamento de dados em formato digital sobre as tecnologias analógicas. O tráfego de dados na internet aumentou exponencialmente com a disseminação de dispositivos móveis a partir de 2007. Em 2010, o termo *big data* aparece como uma *buzzword* para definir o conjunto de tecnologias para coletar, armazenar, processar, analisar e visualizar grandes bases de dados.

A internet permite a oferta de produtos e serviços a um número virtualmente ilimitado de usuários numa rede livre de escala [29]. Nos últimos anos, novos modelos de negócios ou novas versões de negócios tradicionais escaláveis globalmente mudaram a vida de milhares de pessoas. Empresas como IBM, Apple, Microsoft, Google, Amazon e Facebook utilizam extensivamente algoritmos de inteligência computacional em seus negócios. Novos negócios prosperam rapidamente em todas as áreas com a evolução da tecnologia de sensores e o desenvolvimento da internet das coisas.

A partir de 2012 modelos de redes neurais profundas* [212][333] têm obtido excelentes resultados em problemas complexos de reconhecimento de padrões. Os modelos são processados em hardware massivamente paralelo com unidades de processamento gráfico (GPUs), que têm alta capacidade de processamento e baixo consumo de energia em relação aos processadores convencionais (CPUs). Modelos de redes neurais profundas em problemas de visão computacional e processamento de linguagem natu-

* *Deep neural networks.*

A lo largo de la década de 1990, el término minería de datos (*data mining*) comenzó a difundirse como un conjunto de técnicas que incluyen estadística, aprendizaje automático, inteligencia computacional, bases de datos, entre otras, para desarrollar modelos a partir de datos. En 1997 apareció la primera plataforma de minería de datos de código abierto, Weka, ⁵ desarrollada en la Universidad de Waikato, Nueva Zelanda, convirtiéndose en un referente en el mundo académico. A partir del año 2000, cada vez más *softwares* comerciales y bibliotecas ofrecían nuevos algoritmos.⁶ A lo largo de la década de 2000, las plataformas comenzaron a presentarse en el mercado como soluciones de inteligencia analítica [329], centrándose en el análisis de datos y alineando los resultados con los objetivos de negocio.

La reducción de los costos de almacenamiento, el desarrollo de procesadores e internet han impulsado el proceso de recopilación y almacenamiento de bases de datos. El comienzo del siglo XXI marca el comienzo del predominio del almacenamiento de datos en formato digital sobre las tecnologías analógicas. El tráfico de datos en Internet aumentó exponencialmente con la proliferación de dispositivos móviles a partir de 2007. En 2010, el término *big data* aparece como *buzzword* para definir el conjunto de tecnologías para recopilar, almacenar, procesar, analizar y visualizar grandes bases de datos.

Internet permite ofrecer productos y servicios a un número prácticamente ilimitado de usuarios en una red sin escala [29]. En los últimos años, nuevos modelos de negocio o nuevas versiones de negocios tradicionales escalables globalmente han cambiado la vida de miles de personas. Empresas como IBM, Apple, Microsoft, Google, Amazon y Facebook utilizan ampliamente algoritmos de inteligencia computacional en sus negocios. Nuevos negocios están prosperando rápidamente en todas las áreas con la evolución de la tecnología de sensores y el desarrollo del Internet de las cosas.

Desde 2012, los modelos de redes neuronales profundas* [212][333] han obtenido excelentes resultados en problemas complejos de reconocimiento de patrones. Los modelos se procesan en hardware masivamente paralelo con unidades de procesamiento gráfico (GPU), que tienen una alta capacidad de procesamiento y un bajo consumo de energía en comparación con los procesadores convencionales (CPU). Modelos de redes neuronales profundas en problemas de visión por computadora y procesamiento del lenguaje natural.

* *Deep neural networks.*

ral têm obtido resultados comparáveis, e até superiores, aos de humanos. Estes resultados têm gerado grande expectativa em relação ao potencial de inteligência computacional para ciência de dados. O assunto é vasto e tem se expandido rapidamente. Este livro corresponde a uma formação básica no tema incluindo aplicações desenvolvidas em diferentes áreas.

Este capítulo apresenta uma introdução dos principais tipos de problemas em aplicações reais que serão abordados no livro. A seguir, um resumo da bibliografia e das principais ferramentas disponíveis, tanto comerciais como de código aberto.

1.1 Ciência de Dados

No método científico clássico, hipóteses teóricas levam ao desenvolvimento de modelos, que devem ser verificados pela observação do fenômeno. Nas ciências exatas, o modelo é representado por fórmulas matemáticas que codificam o conhecimento sobre o fenômeno [451]. O notável desenvolvimento da computação no século XX permitiu a modelagem e simulação de fenômenos altamente complexos, gerando enormes avanços na representação da realidade e na sua utilização para a tomada de decisões.

Os parâmetros dos modelos devem ser ajustados por dados observados para que o modelo seja efetivamente a representação da realidade. No entanto, esses dados, mesmo quando obtidos em condições experimentais controladas, contêm erros e incertezas devidos a imperfeições nos instrumentos e, principalmente, à dificuldade ou impossibilidade da observação do fenômeno modelado [419].

A realidade, muitas vezes, é bem mais complexa que qualquer teoria e, em alguns casos, não há um modelo físico capaz de descrever adequadamente um determinado fenômeno. A ciência de dados é um conjunto de métodos para coleta, armazenamento, processamento, análise e visualização de dados. O objetivo é o desenvolvimento de modelos diretamente a partir de dados, sem hipóteses teóricas. Em geral, os dados são obtidos de forma não controlada, sem o planejamento de experimentos ou o conhecimento da representatividade da amostra.

Os dados observados correspondem sempre a uma amostra do processo, obtida em condições específicas que determinam a sua validade. Um modelo obtido a partir de

ral han obtenido resultados comparables e incluso superiores a los de los humanos. Estos resultados han generado grandes expectativas respecto al potencial de la inteligencia computacional para la ciencia de datos. El tema es amplio y se ha ido expandiendo rápidamente. Este libro corresponde a una formación básica sobre el tema incluyendo aplicaciones desarrolladas en diferentes áreas.

Este capítulo presenta una introducción a los principales tipos de problemas en aplicaciones reales que se cubrirán en el libro. A continuación se muestra un resumen de la bibliografía y las principales herramientas disponibles, tanto comerciales como de código abierto.

1.1 Ciencia de datos

En el método científico clásico, las hipótesis teóricas conducen al desarrollo de modelos, que deben verificarse mediante la observación del fenómeno. En las ciencias exactas, el modelo está representado por fórmulas matemáticas que codifican el conocimiento sobre el fenómeno [451]. El notable desarrollo de la informática en el siglo XX permitió el modelado y simulación de fenómenos de alta complejidad, generando enormes avances en la representación de la realidad y su uso para la toma de decisiones.

Los parámetros del modelo deben ajustarse según los datos observados para que el modelo sea efectivamente una representación de la realidad. Sin embargo, estos datos, incluso cuando se obtienen en condiciones experimentales controladas, contienen errores e incertidumbres debido a imperfecciones en los instrumentos y, principalmente, a la dificultad o imposibilidad de observar el fenómeno modelado [419].

La realidad suele ser mucho más compleja que cualquier teoría y, en algunos casos, no existe ningún modelo físico capaz de describir adecuadamente un fenómeno determinado. La ciencia de datos es un conjunto de métodos para recopilar, almacenar, procesar, analizar y visualizar datos. El objetivo es desarrollar modelos directamente a partir de datos, sin hipótesis teóricas. Por lo general, los datos se obtienen de forma no controlada, sin planificar experimentos ni conocer la representatividad de la muestra.

Los datos observados siempre corresponden a una muestra del proceso, obtenidos bajo condiciones específicas que determinan su validez. Un modelo obtenido de

uma amostra é uma representação dos dados da amostra e, portanto, uma representação indireta do processo real que produziu os dados. A validade do modelo é sempre limitada pela qualidade da amostra.

A **ciência de dados** (*data science*) se situa na intercessão do conhecimento de matemática, estatística, computação e engenharia com o conhecimento do domínio e dos dados de cada aplicação. A ubiquidade dos dados na era digital faz a ciência de dados ter aplicações em todos os setores, além de ser utilizada cada vez mais em problemas de ciências humanas, naturais e biológicas [295].

A integração de diversas disciplinas necessárias para lidar com grandes bases de dados era chamada de mineração de dados durante a década de 1990, mas passou a ser conhecida como ciência de dados principalmente a partir de 2010. Os dois termos são utilizados frequentemente com o significado similar. Podemos considerar que ciência de dados se refere ao conhecimento necessário, enquanto mineração de dados se refere ao processo de desenvolvimento de modelos a partir de dados.

A descoberta de conhecimento de bases de dados (KDD)*, ou simplesmente, mineração de dados, é um processo cíclico, de forma que, se os objetivos não forem atingidos, uma nova iteração deve ser realizada, refinando os resultados ou utilizando novos dados/ferramentas. A Figura 1.1 ilustra o processo de mineração de dados com seus possíveis ciclos e iterações.




Figura 1.1: O processo de mineração de dados.

* *Knowledge Discovering in Databases*

una muestra es una representación de los datos de la muestra y, por lo tanto, una representación indirecta del proceso real que produjo los datos. La validez del modelo siempre está limitada por la calidad de la muestra.

La ciencia de datos (*data science*) se ubica en la intersección del conocimiento de matemáticas, estadística, informática e ingeniería con el conocimiento del dominio y los datos de cada aplicación. La ubicuidad de los datos en la era digital significa que la ciencia de datos tiene aplicaciones en todos los sectores, además de ser cada vez más utilizada en problemas de las ciencias humanas, naturales y biológicas [295].

La integración de varias disciplinas necesarias para trabajar con grandes bases de datos se llamó minería de datos durante la década de 1990, pero pasó a ser conocida como ciencia de datos principalmente desde 2010. Los dos términos se utilizan a menudo con significados similares. Podemos considerar que la ciencia de datos se refiere al conocimiento necesario, mientras que la minería de datos se refiere al proceso de desarrollo de modelos a partir de datos.

Database Knowledge Discovery (KDD)*, o simplemente, minería de datos, es un proceso cíclico, de modo que, si no se logran los objetivos, se debe realizar una nueva iteración, afinando los resultados o utilizando nuevos datos/herramientas. La Figura 1.1 ilustra el proceso de minería de datos con sus posibles ciclos e iteraciones.




Figura 1.1: El proceso de minería de datos.

* *Knowledge Discovering in Databases*

A coleta e o armazenamento de dados, que aparece condensada na Figura 1.1, é um elemento extremamente importante do processo, principalmente para grandes corporações, que têm uma infraestrutura complexa de tecnologia da informação (TI). O processo começa com a seleção de um subconjunto de dados para ser utilizado para o ajuste de modelos. Esse conjunto de dados, chamado de conjunto de treinamento, é uma amostra considerada válida, podendo ser, dependendo do caso, a própria base de dados. Os dados do conjunto de treinamento são utilizados para o desenvolvimento do modelo. Durante o processo de construção do modelo, o conjunto de dados é particionado para o ajuste de parâmetros e a validação dos resultados.

A etapa de seleção de dados inclui o importante processo de escolha/seleção de variáveis, que pode ser feita a partir do conhecimento de especialistas ou de forma automática. Uma base de dado frequentemente possui valores ausentes e valores extremos ou outliers, que devem ser removidos para não prejudicar o ajuste do modelo.

O entendimento da aplicação e a clareza nos objetivos finais a serem atingidos são fundamentais para o sucesso de uma aplicação e a participação de especialistas do domínio é muito importante. O cientista de dados deve identificar os requisitos da aplicação, desenvolver e avaliar os resultados dos modelos, escolher o(s) modelo(s) mais adequado e coordenar a sua implantação.

O entendimento dos dados é realizado a partir da caracterização estatística e de técnicas de visualização. Esta etapa é importante para o desenvolvimento do modelo e será discutida no Capítulo 2. O pré-processamento dos dados com as principais técnicas de transformação linear também são apresentadas no Capítulo 2.

A principal etapa da mineração de dados é a geração dos modelos. Grande parte do conteúdo deste livro é orientada para o desenvolvimento e a análise dos resultados de modelos. Nos Capítulos 3 ao 6 são abordados os fundamentos estatísticos dos problemas de regressão, classificação e análise de agrupamentos. Os Capítulos 7 a 9 apresentam os principais métodos não lineares de inteligência computacional.

É importante avaliar corretamente o desempenho do modelo antes que a solução seja implantada. A qualidade dos modelos é avaliada através de estatísticas de validação, cujo objetivo é verificar se os requisitos da modelagem foram atingidos. Diversas estatísticas evidenciam diferentes características dos modelos e serão discutidas na parte de fundamentos.

La recopilación y el almacenamiento de datos, que aparecen condensados en la Figura 1.1, es un elemento extremadamente importante del proceso, especialmente para las grandes corporaciones, que tienen una infraestructura de tecnología de la información (TI) compleja. El proceso comienza con la selección de un subconjunto de datos que se utilizarán para el ajuste del modelo. Este conjunto de datos, denominado conjunto de entrenamiento, es una muestra considerada válida y puede ser, según el caso, la propia base de datos. Los datos del conjunto de entrenamiento se utilizan para el desarrollo del modelo. Durante el proceso de construcción del modelo, el conjunto de datos se divide para ajustar los parámetros y validar los resultados.

La etapa de selección de datos incluye el importante proceso de elección/selección de variables, el cual puede realizarse con base en el conocimiento de expertos o de forma automática. Una base de datos a menudo tiene valores faltantes y valores extremos o atípicos, que deben eliminarse para no dañar el ajuste del modelo.

Comprender la aplicación y la claridad en los objetivos finales a alcanzar son fundamentales para el éxito de una aplicación y la participación de expertos en el dominio es muy importante. El científico de datos debe identificar los requisitos de la aplicación, desarrollar y evaluar los resultados del modelo, elegir el modelo más apropiado y coordinar su implementación.

La comprensión de los datos se logra mediante técnicas de caracterización y visualización estadística. Este paso es importante para el desarrollo del modelo y se discutirá en el Capítulo 2. El preprocesamiento de datos con las principales técnicas de transformación lineal también se presenta en el Capítulo 2.

El paso principal en la minería de datos es la generación de modelos. Gran parte del contenido de este libro está orientado al desarrollo y análisis de resultados de modelos. Los capítulos 3 a 6 cubren los fundamentos estadísticos de los problemas de regresión, clasificación y análisis de conglomerados. Los capítulos 7 a 9 presentan los principales métodos no lineales de inteligencia computacional.

Es importante evaluar adecuadamente el rendimiento del modelo antes de implementar la solución. La calidad de los modelos se evalúa a través de estadísticas de validación, cuyo objetivo es verificar si se cumplieron los requisitos del modelado. Varias estadísticas resaltan diferentes características de los modelos y se discutirán en la parte de fundamentos.

A próxima seção apresenta os principais tipos de modelos que serão tratados neste livro. Na prática os problemas nem sempre se apresentam de forma clara. É importante entender corretamente as características dos problemas típicos para poder desenvolver uma solução específica num caso mais complexo.

1.2 Tipos de Modelos

A palavra “modelo” é utilizada em diversas áreas com conceitos diferentes e é importante definir claramente o que se entende por um modelo. O dicionário *Aurélio*⁷ define modelo como algo “que serve como objeto de imitação” ou, no contexto matemático, como uma “representação matemática de um fenômeno”. Neste livro, um modelo é uma representação simplificada de um sistema ou processo real obtida a partir dos dados da amostra. Os modelos de ciência de dados representam apenas a porção do processo que foi capturada pelos dados. Essa constatação, apesar de óbvia, é muito importante pois o modelo pode não ser capaz de prever corretamente o comportamento que não está representado nos dados de treinamento.

Um modelo, entendido como representação matemática de um processo real, pode ser classificado segundo a natureza do conhecimento empregado para a sua construção como **modelo de conhecimento** ou **modelo de comportamento**. Nos modelos de conhecimento (ou analíticos), as relações que descrevem o comportamento do sistema são escritas a partir das leis fundamentais da física ou do conhecimento humano. Nos modelos de comportamento (ou de entrada/saída), as relações que descrevem o comportamento do sistema são obtidas diretamente através da observação dos dados de entrada e saída. Os modelos de ciência de dados são essencialmente modelos de comportamento, embora o conhecimento do especialista do domínio e o conhecimento do analista sejam essenciais para o desenvolvimento de bons modelos.

As aplicações em ciência de dados são orientadas a problemas preditivos ou descritivos. Os problemas preditivos utilizam dados observados em variáveis de saída (variáveis dependentes), cujos valores são preditos pelo modelo a partir das variáveis de entrada (variáveis independentes). Nesse caso, o modelo realiza uma aproximação do mapeamento de entrada e saída observado. Nos problemas descritivos não há variáveis de saída e o objetivo do modelo é uma representação dos dados de entrada. Os modelos preditivos são ajustados por algoritmos de **aprendizado supervisionado**, enquanto

La siguiente sección presenta los principales tipos de modelos que se tratarán en este libro. En la práctica, los problemas no siempre se presentan con claridad. Es importante comprender correctamente las características de los problemas típicos para poder desarrollar una solución específica en un caso más complejo.

1.2 Tipos de modelos

La palabra “modelo” se utiliza en varias áreas con diferentes conceptos y es importante definir claramente qué se entiende por modelo. El diccionario *Aurélio*⁷ define un modelo como algo “que sirve como objeto de imitación” o, en el contexto matemático, como una “representación matemática de un fenómeno”. En este libro, un modelo es una representación simplificada de un sistema o proceso real obtenido a partir de datos de muestra. Los modelos de ciencia de datos representan solo la parte del proceso que ha sido capturada por los datos. Este hallazgo, aunque obvio, es muy importante ya que es posible que el modelo no pueda predecir correctamente un comportamiento que no esté representado en los datos de entrenamiento.

Un modelo, entendido como una representación matemática de un proceso real, puede clasificarse según la naturaleza del conocimiento utilizado para su construcción como modelo de conocimiento o modelo de comportamiento. En los modelos de conocimiento (o analíticos), las relaciones que describen el comportamiento del sistema se escriben con base en las leyes fundamentales de la física o del conocimiento humano. En los modelos de comportamiento (o de entrada/salida), las relaciones que describen el comportamiento del sistema se obtienen directamente mediante la observación de los datos de entrada y salida. Los modelos de ciencia de datos son esencialmente modelos de comportamiento, aunque el conocimiento experto en el dominio y el conocimiento de los analistas son esenciales para desarrollar buenos modelos.

Las aplicaciones de la ciencia de datos están orientadas a problemas predictivos o descriptivos. Los problemas predictivos utilizan datos observados en las variables de salida (variables dependientes), cuyos valores son predichos por el modelo en función de las variables de entrada (variables independientes). En este caso, el modelo realiza una aproximación del mapeo de entrada y salida observado. En los problemas descriptivos no hay variables de salida y el objetivo del modelo es una representación de los datos de entrada. Los modelos predictivos se ajustan mediante algoritmos de aprendizaje supervisados, mientras que

modelos descritivos são ajustados por algoritmos de **aprendizado não supervisionado**. Há também algoritmos de **aprendizado por reforço**, em que o modelo é ajustado diretamente através de sua interação com o ambiente. Esta abordagem é muito utilizada em problemas de controle e para o treinamento de agentes inteligentes.

Os problemas preditivos usuais são a classificação e a regressão. Na classificação, também chamada de classificação supervisionada ou reconhecimento de padrões, a variável de saída é uma classe, em geral uma variável discreta e não ordenada. Na regressão, a variável de saída é numérica, em geral um número real. Os dois problemas são, na verdade, similares e os modelos de inteligência computacional podem ser utilizados para a solução de ambos.

Em problemas descritivos, o objetivo do modelo é realizar uma descrição do conjunto de dados. Os principais problemas descritivos são análise de agrupamentos e regras de associação. A análise de agrupamentos, também chamada de classificação não supervisionada ou segmentação, utiliza diversos algoritmos para encontrar grupos de registros similares em grandes bases de dados. Algoritmos de regras de associação são muito utilizados em problemas descritivos cujo objetivo é encontrar itens que se relacionam na base de dados, como na análise de cestas de mercado e sistemas de recomendação. Recentemente, novos algoritmos de aprendizado não supervisionado têm surgido como **aprendizado da representação** em que o objetivo do modelo é produzir uma representação da entrada.

As técnicas de combinação de modelos, chamadas de *ensemble*, permitem o aumento do desempenho de modelos [150][475][604]. Em problemas preditivos, os melhores resultados do Prêmio Netflix⁸ e outras competições de ciência de dados⁹ são obtidos com *ensembles*.

A seguir, apresentamos uma descrição sucinta dos problemas que serão tratados neste livro, mostrando alguns exemplos de conjuntos de dados bastante conhecidos.

1.2.1 Regressão

O objetivo da regressão ou aproximação de funções é um modelo de sistema ou processo capaz de realizar uma estimativa do valor da variável de saída numérica a partir das variáveis de entrada. A regressão é uma tarefa preditiva e a avaliação da precisão

Los modelos descriptivos se ajustan mediante algoritmos de aprendizaje no supervisados. También existen algoritmos de aprendizaje por refuerzo, en los que el modelo se ajusta directamente a través de su interacción con el entorno. Este enfoque se utiliza ampliamente en problemas de control y para entrenar agentes inteligentes.

Los problemas predictivos habituales son la clasificación y la regresión. En la clasificación, también llamada clasificación supervisada o reconocimiento de patrones, la variable de salida es una clase, generalmente una variable discreta y desordenada. En la regresión, la variable de salida es numérica, generalmente un número real. De hecho, los dos problemas son similares y se pueden utilizar modelos de inteligencia computacional para resolverlos.

En problemas descriptivos, el objetivo del modelo es proporcionar una descripción del conjunto de datos. Los principales problemas descriptivos son el análisis de conglomerados y las reglas de asociación. El análisis de conglomerados, también llamado clasificación o segmentación no supervisada, utiliza varios algoritmos para encontrar grupos de registros similares en grandes bases de datos. Los algoritmos de reglas de asociación son ampliamente utilizados en problemas descriptivos cuyo objetivo es encontrar elementos que estén relacionados en la base de datos, como en el análisis de cestas de la compra y sistemas de recomendación. Recientemente han surgido nuevos algoritmos de aprendizaje no supervisado como aprendizaje de representación en los que el objetivo del modelo es producir una representación de la entrada.

Las técnicas de combinación de modelos, denominadas *ensemble*, permiten aumentar el rendimiento del modelo [150][475][604]. En problemas de predicción, los mejores resultados en el Premio Netflix⁸ y otros concursos de ciencia de datos⁹ se obtienen con *ensembles*.

A continuación, presentamos una breve descripción de los problemas que se abordarán en este libro, mostrando algunos ejemplos de conjuntos de datos conocidos.

1.2.1 Regresión

El objetivo de la regresión o aproximación de funciones es un modelo de sistema o proceso capaz de estimar el valor de la variable numérica de salida en función de las variables de entrada. La regresión es una tarea predictiva y la evaluación de la precisión.

é feita em função do erro de predição, ou seja, a diferença entre o valor predito e o valor correto. O erro de predição é utilizado para o ajuste do modelo.

O problema de regressão linear é clássico na estatística, com diversas aplicações em engenharia e ciências. Na regressão linear, a variável de saída é calculada como uma combinação linear das variáveis de entrada ou de funções das variáveis de entrada chamadas de “**regressores**” ou de **características** (*features*). Além de eficiente, o modelo linear permite a análise de diversas características do problema. A regressão linear é explorada no Capítulo 3, sua extensão para a modelagem de séries temporais e sistemas dinâmicos é apresentada no Capítulo 4.

A Figura 1.2 mostra um exemplo de problema de regressão linear monovariável. O modelo (em vermelho) é ajustado a partir dos dados da amostra (em azul) e deve ser o mais próximo possível da relação alvo (em preto). Em geral, não se conhece precisamente o comportamento estatístico do processo além dos dados da amostra, de modo que não se pode afirmar se o modelo ajustado representa o processo (relação alvo) ou é apenas um modelo daquela amostra.




Figura 1.2: Problema de regressão linear.

Em muitos processos reais, o relacionamento entre as variáveis de entrada e saída é não linear. Nesse caso, o modelo é válido para as condições em que a amostra foi realizada. Se o processo tem um comportamento muito instável, como, por exemplo, o mercado financeiro, a validade de um modelo expira rapidamente e um modelo ajustado com dados históricos não consegue prever adequadamente o futuro. No caso de modelos não lineares, a predição de um valor muito diferente dos dados de entrada-saída

Se realiza de acuerdo con el error de predicción, es decir, la diferencia entre el valor predicho y el valor correcto. El error de predicción se utiliza para ajustar el modelo.

El problema de regresión lineal es clásico en estadística, con varias aplicaciones en ingeniería y ciencia. En la regresión lineal, la variable de salida se calcula como una combinación lineal de variables de entrada o funciones de variables de entrada llamadas "regresores" o características (*features*). Además de ser eficiente, el modelo lineal permite el análisis de diversas características del problema. La regresión lineal se explora en el Capítulo 3, su extensión al modelado de series temporales y sistemas dinámicos se presenta en el Capítulo 4.

La figura 1.2 muestra un ejemplo de un problema de regresión lineal con una sola variable. El modelo (en rojo) se ajusta a partir de los datos de muestra (en azul) y debe estar lo más cerca posible de la relación objetivo (en negro). En general, el comportamiento estadístico del proceso no se conoce con precisión más allá de los datos de la muestra, por lo que no se puede decir si el modelo ajustado representa el proceso (relación objetivo) o es sólo un modelo de esa muestra.




Figura 1.2: Problema de regresión lineal.

En muchos procesos reales, la relación entre las variables de entrada y salida no es lineal. En este caso, el modelo es válido para las condiciones bajo las cuales se realizó la muestra. Si el proceso tiene un comportamiento muy inestable, como por ejemplo el mercado financiero, la validez de un modelo caduca rápidamente y un modelo ajustado con datos históricos no puede predecir adecuadamente el futuro. En el caso de modelos no lineales, la predicción de un valor muy diferente de los datos de entrada-salida

utilizados no conjunto de treinamento pode resultar em valores incorretos, pois o modelo foi ajustado para a amostra, que representa um determinado domínio.

Os problemas de regressão e de classificação têm muitas características em comum, uma vez que um modelo de classificação pode ser visto como um modelo de aproximação de funções discriminantes, como descrito a seguir.

1.2.2 Classificação

O objetivo da classificação é um modelo, chamado de classificador, capaz de classificar uma observação em uma das diferentes classes predefinidas a partir de valores das variáveis de entrada, que representam as características ou atributos da observação. O modelo representa o relacionamento entre os atributos e a classe, que é a variável de saída. A classificação é uma tarefa preditiva, pois o modelo deve ser capaz de prever a classe para um novo registro previamente desconhecido, isto é, um registro não utilizado no conjunto de treinamento. A avaliação de um modelo de classificação é realizada principalmente em função da sua precisão na predição da classe correta.

O conjunto de dados das flores Iris é certamente o exemplo mais conhecido e estudado em ciência de dados. O problema consiste em prever a categoria de flores Iris, mostradas na Figura 1.3, a partir dos valores de comprimento e largura das pétalas e sépalas. O conjunto de dados tem, portanto, quatro variáveis numéricas de entrada e uma variável de saída, cujos valores são as três classes possíveis. O conjunto de dados apresenta 50 instâncias para cada classe e foi utilizado pela primeira vez por Fisher em 1936 [183] como exemplo de funções discriminantes lineares.




Figura 1.3: Flores Iris: (a) *Iris setosa*; (b) *Iris versicolor*; (c) *Iris virginica*.

utilizado en el conjunto de entrenamiento puede dar como resultado valores incorrectos, ya que el modelo se ajustó a la muestra, que representa un determinado dominio.

Los problemas de regresión y clasificación tienen muchas características en común, ya que un modelo de clasificación puede verse como un modelo de aproximación de funciones discriminantes, como se describe a continuación.

1.2.2 Clasificación

El objetivo de la clasificación es un modelo, llamado clasificador, capaz de clasificar una observación en una de diferentes clases predefinidas en función de los valores de las variables de entrada, que representan las características o atributos de la observación. El modelo representa la relación entre los atributos y la clase, que es la variable de salida. La clasificación es una tarea predictiva, ya que el modelo debe poder predecir la clase de un registro nuevo previamente desconocido, es decir, un registro que no se utiliza en el conjunto de entrenamiento. La evaluación de un modelo de clasificación se lleva a cabo principalmente en función de su precisión para predecir la clase correcta.

El conjunto de datos de la flor Iris es sin duda el ejemplo más conocido y estudiado en la ciencia de datos. El problema consiste en predecir la categoría de las flores de Iris, mostrada en la Figura 1.3, en base a los valores de largo y ancho de los pétalos y sépalos. Por tanto, el conjunto de datos tiene cuatro variables numéricas de entrada y una variable de salida, cuyos valores son las tres clases posibles. El conjunto de datos presenta 50 instancias para cada clase y fue utilizado por primera vez por Fisher en 1936 [183] como ejemplo de funciones discriminantes lineales.




Figura 1.3: Flores de iris: (a) *Iris setosa*; (b) *Iris versicolor*; (c) *Iris virginica*.

O problema de classificação pode ser visto como uma busca por funções discriminantes (lineares ou não lineares) capazes de dividir o espaço das variáveis de entrada em regiões e associar cada região a uma classe (cf. Figura 1.4).




Figura 1.4: Problema de classificação: (a) conjunto de treinamento; (b) conjunto de testes.

Em situações em que é possível separar todos os registros de uma classe por uma função linear, diz-se que a classe é linearmente separável. Quando os registros de uma classe podem ser separados por uma função não linear, a classe é dita separável não linearmente. Na prática, na maioria dos casos, os registros não podem ser separados completamente por alguma função linear ou não linear. Nesse caso, as classes são ditas não separáveis uma vez que a informação coletada pelas variáveis de entrada não é suficiente para separar completamente as classes e, em consequência, o erro de classificação não pode ser nulo, por melhor que seja o modelo. O problema é explorado em detalhes no Capítulo 5, onde mostramos que é possível estabelecer um limite teórico do erro de um classificador. Os modelos lineares locais e os modelos de sistemas fuzzy e redes neurais podem tratar tanto problemas de classificação como problemas de regressão e serão apresentados no Capítulos 7, 8 e 9 respectivamente.

O problema de classificação tem sido estudado desde muito antes do surgimento das técnicas de inteligência computacional. Em estatística, o problema de classificação é chamado de reconhecimento de padrões [146]. As abordagens modernas para o problema reúnem técnicas estatísticas clássicas e técnicas de inteligência computacional [146]. Esse tipo de problema encontra inúmeras aplicações nos mais variados campos de negócio, como, por exemplo, diagnóstico médico, análise de crédito, classificação de documentos, classificação de imagens, bioinformática, entre outros.

El problema de clasificación puede verse como una búsqueda de funciones discriminantes (lineales o no lineales) capaces de dividir el espacio de variables de entrada en regiones y asociar cada región con una clase (cf. Figura 1.4).




Figura 1.4: Problema de clasificación: (a) conjunto de entrenamiento; (b) articulación de pruebas.

En situaciones en las que es posible separar todos los registros de una clase mediante una función lineal, se dice que la clase es linealmente separable. Cuando los registros de una clase no pueden separarse mediante una función no lineal, se dice que la clase es no linealmente separable. En la práctica, en la mayoría de los casos, los registros no pueden separarse completamente mediante alguna función lineal o no lineal. En este caso se dice que las clases son no separables ya que la información recogida por las variables de entrada no es suficiente para separar completamente las clases y, en consecuencia, el error de clasificación no puede ser nulo por muy bueno que sea el modelo. El problema se explora en detalle en el Capítulo 5, donde mostramos que es posible establecer un límite teórico al error de un clasificador. Los modelos lineales locales, los modelos de sistemas difusos y las redes neuronales pueden manejar tanto problemas de clasificación como de regresión y se presentarán en los Capítulos 7, 8 y 9 respectivamente.

El problema de la clasificación se ha estudiado mucho antes de la aparición de las técnicas de inteligencia computacional. En estadística, el problema de clasificación se llama reconocimiento de patrones [146]. Los enfoques modernos del problema combinan técnicas estadísticas clásicas y técnicas de inteligencia computacional [146]. Este tipo de problemas encuentra numerosas aplicaciones en los más variados campos empresariales, como por ejemplo, diagnóstico médico, análisis crediticio, clasificación de documentos, clasificación de imágenes, bioinformática, entre otros.

1.2.3 Análise de agrupamentos

O objetivo da análise de agrupamentos é encontrar grupos de registros semelhantes no conjunto de dados. Na análise de agrupamentos, também chamada de classificação não supervisionada, não existe uma variável de saída ou variável alvo. O conjunto de dados contém, assim, apenas registros das variáveis de entrada.




Figura 1.5: Problema de agrupamento: (a) conjunto de dados; (b) agrupamento.

Há diversas aplicações da análise de agrupamentos nos mais variados campos, como bioinformática, *marketing*, processamento de imagens etc. Uma das aplicações mais conhecidas é a segmentação de clientes, muito útil na definição de estratégias de relacionamento [530]. Nesse caso, as variáveis do conjunto de dados são características dos clientes em função das quais se deseja a análise.

Empresas com grandes bases de clientes, como operadoras de telefonia, utilizam análise de agrupamentos para segmentação de clientes, em que as variáveis representam a utilização dos serviços. Grupos de clientes podem ser alvo de campanhas de retenção ou promoções diferenciadas.

Um problema crítico na análise de agrupamentos é a avaliação da qualidade do resultado do agrupamento, pois a inexistência de uma variável de saída dificulta a definição de uma estatística de desempenho. Paradoxalmente, a definição do número de grupos é um dado de entrada para a maioria dos algoritmos. Há na literatura diversos índices que se propõem a realizar uma avaliação da qualidade do agrupamento. Entretanto, os índices refletem características geométricas desejáveis de um bom agrupamento e seu resultado deve ser interpretado por um analista. A experiência do analista e a participação do especialista do domínio são fundamentais para a análise de agrupamentos.

1.2.3 Análise de agrupamentos

El propósito del análisis de conglomerados es encontrar grupos de registros similares en el conjunto de datos. En el análisis de conglomerados, también llamado clasificación no supervisada, no existe una variable de salida ni una variable objetivo. Por tanto, el conjunto de datos sólo contiene registros de las variables de entrada.




Figura 1.5: Problema de agrupación: (a) conjunto de datos; (b) agrupación.

Existen diversas aplicaciones del análisis de clusters en los más variados campos, como la bioinformática, *marketing*, el procesamiento de imágenes, etc. Una de las aplicaciones más conocidas es la segmentación de clientes, que resulta de gran utilidad para definir estrategias de relación [530]. En este caso, las variables del conjunto de datos son características de los clientes en función de las cuales se desea realizar el análisis.

Las empresas con grandes bases de clientes, como los operadores telefónicos, utilizan el análisis de conglomerados para segmentar a los clientes, en el que las variables representan el uso de los servicios. Se pueden dirigir campañas de retención o promociones diferenciadas a grupos de clientes.

Un problema crítico en el análisis de conglomerados es la evaluación de la calidad del resultado del conglomerado, ya que la falta de una variable de salida dificulta la definición de estadísticas de desempeño. Paradójicamente, la definición del número de grupos es un insumo para la mayoría de los algoritmos. Hay varios índices en la literatura que tienen como objetivo evaluar la calidad del cluster. Sin embargo, los índices reflejan características geométricas deseables de un buen grupo y sus resultados deben ser interpretados por un analista. La experiencia del analista y la participación del experto en el dominio son fundamentales para el análisis de conglomerados.

O problema de análise de agrupamentos possui diversas abordagens diferentes e um grande número de algoritmos. Há livros inteiros focados no assunto [573][194] e uma abordagem completa do problema foge ao escopo deste livro. As abordagens principais são discutidas no Capítulo 6.

Uma variante do problema de análise de agrupamento é chamada de classificação semi supervisionada [82], no qual um pequeno subconjunto dos dados anotados, que deve ser utilizado para a classificação de um conjunto maior de dados. A questão é tratada como um problema de agrupamentos em que os registros categorizados são utilizados para ajudar a ajustar o modelo.

1.3 Recursos Complementares

Esta seção apresenta um conjunto de recursos relacionados com o conteúdo deste livro e com a ciência de dados em geral.

1.3.1 Bibliografia de referência

A literatura na área de inteligência computacional com aplicação em ciência de dados é bastante diversificada. A abordagem estatística para a construção de modelos de dados está fartamente descrita em diversas referências. Um enfoque bastante completo que apresenta tanto os métodos mais avançados quanto dos métodos estatísticos clássicos é apresentado por Hastie, Tibshirani e Friedman¹⁰ [238].

O livro *Pattern Classification*,¹¹ de Duda e Hart [146], é um clássico em métodos estatísticos de classificação. O livro tem um volume correspondente com rotinas Matlab dos principais algoritmos [507]. O livro de Theodoris e Koutroumbas¹² [521], é outra referência em métodos estatísticos de classificação e análise de agrupamentos, que também tem um volume com rotinas em Matlab [522]. O livro de Bishop¹³ [52] é uma referência importante em método estatísticos e de inteligência computacional, trazendo um capítulo sobre métodos variacionais. Uma referência adicional para métodos estatísticos de classificação é o livro de Webb [553].

Em problemas de regressão, Montgomery [399] é uma referência clássica, em sua quarta edição. O clássico de modelos estatísticos de séries temporais e sistemas dinâmicos é o livro de Box, Jenkins e Reinsel [59], que também está na quarta edição. Outra obra de referência para o desenvolvimento de modelos dinâmicos de sistemas lineares

El problema del análisis de conglomerados tiene varios enfoques diferentes y una gran cantidad de algoritmos. Hay libros completos centrados en el tema [573][194] y un enfoque completo del problema está más allá del alcance de este libro. Los enfoques principales se analizan en el Capítulo 6.

Una variante del problema de análisis de conglomerados se denomina clasificación semisupervisada [82], en la que se anota un pequeño subconjunto de datos, que se utilizará para clasificar un conjunto más grande de datos. El problema se trata como un problema de agrupación en el que se utilizan registros categorizados para ayudar a ajustar el modelo.

1.3 Recursos adicionales

Esta sección presenta un conjunto de recursos relacionados con el contenido de este libro y la ciencia de datos en general.

1.3.1 Bibliografía de referencia

La literatura en el área de la inteligencia computacional con aplicación en la ciencia de datos es bastante diversa. El enfoque estadístico para construir modelos de datos se describe ampliamente en varias referencias. Hastie, Tibshirani y Friedman¹⁰ [238] presentan un enfoque muy completo que presenta los métodos estadísticos más avanzados y clásicos.

El libro *Pattern Classification*,¹¹ de Duda y Hart [146], es un clásico en los métodos de clasificación estadística. El libro tiene un volumen correspondiente con rutinas Matlab de los principales algoritmos [507]. El libro de Theodoris y Koutroumbas¹² [521], es otra referencia sobre métodos estadísticos de clasificación y análisis de conglomerados, que también tiene un volumen con rutinas en Matlab [522]. El libro de Bishop¹³ [52] es una referencia importante en métodos estadísticos e inteligencia computacional y contiene un capítulo sobre métodos variacionales. Una referencia adicional para los métodos de clasificación estadística es el libro de Webb [553].

Sobre problemas de regresión, Montgomery [399] es una referencia clásica, en su cuarta edición. El clásico de los modelos estadísticos de series temporales y sistemas dinámicos es el libro de Box, Jenkins y Reinsel [59], que también va por su cuarta edición. Otra obra de referencia para el desarrollo de modelos dinámicos de sistemas lineales.

é o livro de Ljung¹⁴ [352], que serviu de base para o desenvolvimento da biblioteca *System Identification Toolbox*¹⁵ do Matlab. Schabenberger e Gotway [472] apresentam uma visão bastante abrangente sobre análise de dados espaciais.

Há diversas referências clássicas sobre as principais técnicas de inteligência computacional, como o livro de Haykin¹⁶[240][241] sobre redes neurais e os livros de Pedrycz e Gomide [432][433] sobre a teoria de conjuntos *fuzzy*. A obra de referência sobre máquinas de vetores de suporte e métodos baseados em funções de núcleo (*kernel*) é o livro de Schölkopf e Smola¹⁷[478], que apresenta uma abordagem completa dos métodos e suas formulações matemáticas e ainda inclui uma discussão sobre temas correlatos como regularização e otimização. Taylor e Cristianini¹⁸ [485], Huang, Kecman e Kopriva¹⁹ [269], e Kulkarni e Harman [326] apresentam uma excelente introdução à teoria de aprendizado estatístico. A obra de Vapnik [532]-[534] é a referência teórica mais completa. Em seu livro mais recente, Vapnik [533] traz uma apresentação simplificada dos principais conceitos da teoria.

O problema de construção de modelos a partir de dados é muito bem descrito por Cherkassky e Mulier [98], com uma abordagem que ressalta os pontos em comum dos vários algoritmos de inteligência computacional. Kecman²⁰ [301] apresenta os principais algoritmos de inteligência computacional, em que os métodos estatísticos clássicos são condensados no primeiro capítulo. A maioria dos livros de inteligência computacional é focada em sistemas *fuzzy*, redes neurais e algoritmos genéticos [152][318][520].

Há diversos livros sobre mineração de dados, o primeiro com este título foi editado por Fayyad e Piatetsky-Shapiro em 1996 [177]. O trabalho de Han e Kamber, publicado em três edições [232]-[234], também é uma referência importante e tem uma apresentação bastante completa. Han também participa em edições sobre a mineração de dados geográficos [386][387] e sobre mineração de dados em grafos [582]. O livro de Tan, Steinbach e Kumar²¹ [516] é outra referência clássica em mineração de dados. O livro escrito pelos autores do Weka²² [561] apresenta os principais algoritmos do *software*.

Um livro de Zaki e Meira [593] apresenta uma visão bem atual e completa do assunto com os principais algoritmos, além de mostrar aplicações em problemas complexos como mineração de grafos e sequências. O livro de Aggarwal [5] é uma referência mais completa e atualizada na área de ciência de dados, apresentando os fundamentos, técnicas e aplicações. Em suas 700 páginas, aborda o assunto de forma bem abrangente,

es el libro de Ljung¹⁴ [352], que sirvió de base para el desarrollo de la biblioteca Matlab *System Identification Toolbox*¹⁵. Schabenberger y Gotway [472] presentan una visión muy completa del análisis de datos espaciales.

Existen varias referencias clásicas sobre las principales técnicas de inteligencia computacional, como el libro de Haykin¹⁶[240][241] sobre redes neuronales y los libros de Pedrycz y Gomide [432][433] sobre teoría de conjuntos *fuzzy*. La obra de referencia sobre máquinas de vectores de soporte y métodos basados en funciones del núcleo (*kernel*) es el libro de Schölkopf y Smola¹⁷[478], que presenta una aproximación completa a los métodos y sus formulaciones matemáticas y también incluye una discusión sobre temas relacionados como la regularización y la optimización. Taylor y Cristianini¹⁸ [485], Huang, Kecman y Kopriva¹⁹ [269], y Kulkarni y Harman [326] presentan una excelente introducción a la teoría del aprendizaje estadístico. El trabajo de Vapnik [532]-[534] es la referencia teórica más completa. En su libro más reciente, Vapnik [533] ofrece una presentación simplificada de los conceptos principales de la teoría.

El problema de construir modelos a partir de datos está muy bien descrito por Cherkassky y Mulier [98], con un enfoque que destaca los puntos comunes de los distintos algoritmos de inteligencia computacional. Kecman²⁰ [301] presenta los principales algoritmos de inteligencia computacional, en los que los métodos estadísticos clásicos se condensan en el primer capítulo. La mayoría de los libros de inteligencia computacional se centran en sistemas *fuzzy*, redes neuronales y algoritmos genéticos [152][318][520].

Existen varios libros sobre minería de datos, el primero con este título fue editado por Fayyad y Piatetsky-Shapiro en 1996 [177]. El trabajo de Han y Kamber, publicado en tres ediciones [232]-[234], es también una referencia importante y tiene una presentación muy completa. Han también participa en temas sobre minería de datos geográficos [386][387] y minería de datos gráficos [582]. El libro de Tan, Steinbach y Kumar²¹ [516] es otra referencia clásica sobre minería de datos. El libro escrito por los autores de Weka²² [561] presenta los principales algoritmos de *software*.

Un libro de Zaki y Meira [593] presenta una visión muy actual y completa del tema con los principales algoritmos, además de mostrar aplicaciones en problemas complejos como minería de gráficos y secuencias. El libro de Aggarwal [5] es una referencia más completa y actualizada en el área de la ciencia de datos, presentando los fundamentos, técnicas y aplicaciones. En sus 700 páginas aborda el tema de forma muy completa,

considerando o pré-processamento, detecção de *outliers*, mineração de dados estruturados, dados espaciais, séries temporais, sequências e dados não estruturados como textos e mineração da *web* e de redes sociais.

Mitchel²³ [392] é a referência clássica de aprendizado de máquinas. O livro de Murphy de 2012 [406] apresenta uma abordagem bem completa do tema sob a ótica probabilística. Alguns livros de aprendizado de máquina apresentam uma abordagem de mineração de dados [14][370] ou de análise inteligente de dados [44][45].

O livro *Deep Learning*,²⁴ de Googfellow, Bengio e Courville [212], publicado em 2016, é a referência atual sobre algoritmos de aprendizado profundo. O livro é bem completo e aborda desde os princípios básicos de álgebra linear, teoria das probabilidades e técnicas clássicas de aprendizado de máquinas até os mais avançados modelos que estão sendo utilizados atualmente em aplicações de inteligência artificial.

Liu²⁵ [348] é uma referência em problemas relacionados à internet. Os algoritmos de inteligência computacional têm sido utilizados em problemas com dados não estruturados como texto, grafos [1][43][178][502] e redes sociais [4][376]. Outras aplicações importantes são a bioinformática e sistemas financeiros[295].

Na literatura nacional, o livro editado por Solange Rezende em 2002 [451] reúne métodos de inteligência computacional, mineração de dados e aprendizado de máquina. A obra, assinada por 10 autores com a participação de vários colaboradores, permanece atual e inclui, além dos conceitos teóricos, uma série de aplicações práticas dos métodos apresentados. Alguns trabalhos na área de ciência de dados e inteligência computacional escritos em português apareceram recentemente [61][173][193][345]. Os modelos de redes neurais estão bem descritos na tradução do livro de Haykin [241] e no livro de Braga, Carvalho e Ludermir [62].

1.3.2 Recursos na internet

Em 2011, a Universidade de Stanford iniciou seu programa de oferta de cursos *online* gratuitos pela internet com três cursos de ciência da computação: banco de dados, aprendizado de máquina e inteligência artificial. Os mesmos cursos oferecidos aos alunos de Stanford foram disponibilizados livremente na internet, onde qualquer um poderia se inscrever e seguir aulas em vídeo. A grande diferença entre essa iniciativa e outras formas de educação *online* é que alunos inscritos podem responder perguntas,

considerando preprocesamiento, detección *outliers*, minería de datos estructurados, datos espaciales, series de tiempo, secuencias y datos no estructurados como textos y minería de *web* y redes sociales.

Mitchel²³ [392] es la referencia clásica del aprendizaje automático. El libro de Murphy de 2012 [406] presenta un enfoque muy completo del tema desde una perspectiva probabilística. Algunos libros sobre aprendizaje automático presentan un enfoque de minería de datos [14] [370] o análisis inteligente de datos [44][45].

El libro *Deep Learning*,²⁴ de Goodfellow, Bengio y Courville [212], publicado en 2016, es la referencia actual sobre algoritmos de aprendizaje profundo. El libro es muy completo y cubre desde los principios básicos del álgebra lineal, la teoría de la probabilidad y las técnicas clásicas de aprendizaje automático hasta los modelos más avanzados que se utilizan actualmente en aplicaciones de inteligencia artificial.

Liu²⁵ [348] es una referencia en temas relacionados con Internet. Los algoritmos de inteligencia computacional se han utilizado en problemas con datos no estructurados como texto, gráficos [1][43][178][502] y redes sociales [4][376]. Otras aplicaciones importantes son la bioinformática y los sistemas financieros[295].

En la literatura nacional, el libro editado por Solange Rezende en 2002 [451] reúne métodos de inteligencia computacional, minería de datos y aprendizaje automático. El trabajo, escrito por 10 autores con la participación de varios colaboradores, se mantiene vigente e incluye, además de conceptos teóricos, una serie de aplicaciones prácticas de los métodos presentados. Recientemente han aparecido algunos trabajos en el área de ciencia de datos e inteligencia computacional escritos en portugués [61][173][193][345]. Los modelos de redes neuronales están bien descritos en la traducción del libro de Haykin [241] y en el libro de Braga, Carvalho y Ludermir [62].

1.3.2 Recursos en Internet

En 2011, la Universidad de Stanford inició su programa ofreciendo cursos *online* gratuitos a través de Internet con tres cursos de informática: bases de datos, aprendizaje automático e inteligencia artificial. Los mismos cursos ofrecidos a los estudiantes de Stanford estaban disponibles gratuitamente en Internet, donde cualquiera podía registrarse y seguir clases en video. La gran diferencia entre esta iniciativa y otras formas de educación *online* es que los estudiantes registrados pueden responder preguntas,

realizar exercícios propostos e exames (dentro do mesmo ambiente computacional) e, ao final, desde que obtenham rendimento adequado, receber um certificado de participação assinado pelo professor. Os cursos atraíram mais de 100 mil inscritos em todo o mundo. A iniciativa gerou a criação de diversos repositórios de cursos *online* em universidades como Stanford²⁶ e MIT²⁷, além de empresas como Coursera²⁸ e Udacity²⁹, fundadas no início de 2012, que exploram este mercado. O curso de Machine Learning do Coursera,³⁰ apresentado por Andrew Ng, de Stanford, cobre a maioria dos assuntos tratados neste livro.

Aulas e conferências em vídeo também podem ser encontradas no VideoLectures³¹, que é uma espécie de YouTube acadêmico e contém vídeos sobre diversos assuntos. No VideoLectures é possível assistir a seminários sobre os temas de interesse apresentados pelos maiores especialistas da área. O Slide Share³² e o Scribd³³ também são repositórios de conteúdo geral, o primeiro no formato de *slides* de apresentações e o segundo no formato de documentos.

O principal portal de recursos de ciência de dados na internet é o KDnuggets,³⁴ que contém *links* para diversos recursos, como *softwares*, repositórios de dados, cursos etc., além de ofertas de empregos e também muita publicidade. O KDnuggets foi criado em 1997 e é mantido por Piatetsky-Shapiro, um dos principais pesquisadores da área e coeditor do primeiro livro de mineração de dados [177].

O repositório de dados que é referência em diversos trabalhos de ciência de dados é o UCI Machine Learning Repository,³⁵ mantido pela Universidade da Califórnia em Irvine. O UCI contém um acervo bastante completo de conjuntos de dados *benchmark* para avaliação de algoritmos. O UCI tem uma seção especial dedicada aos concursos de ciência de dados KDD Cup propostos nas edições do congresso Knowledge Discovery in Databases (KDD).³⁶ Atualmente, competições de algoritmos de ciência de dados se tornaram comuns através do *site* Kaggle.³⁷

O *site* do *software* de código aberto KEEL,³⁸ desenvolvido por um consórcio de seis grupos de pesquisa espanhóis, disponibiliza, além do próprio *software*, alguns conjuntos de dados *benchmark*. Os dados encontrados no *site* do KEEL são essencialmente os mesmos disponíveis no UCI, mas no KEEL eles podem ser encontrados em partições predefinidas, o que permite a comparação direta entre algoritmos. O *site* KEEL também

realizar los ejercicios y exámenes propuestos (dentro del mismo entorno informático) y, al finalizar, siempre que obtengan un rendimiento adecuado, recibir un certificado de participación firmado por el profesor. Los cursos atrajeron a más de 100.000 inscritos en todo el mundo. La iniciativa generó la creación de varios repositorios de cursos *online* en universidades como Stanford²⁶ y MIT²⁷, además de empresas como Coursera²⁸ y Udacity²⁹, fundadas a principios de 2012, que exploran este mercado. El curso de aprendizaje automático de Coursera,³⁰ presentado por Andrew Ng de Stanford, cubre la mayoría de los temas tratados en este libro.

También se pueden encontrar videoclases y conferencias en VideoLectures³¹, que es una especie de YouTube académico y contiene videos sobre diversos temas. En VideoLectures podrás ver seminarios sobre temas de interés presentados por los mayores expertos en la materia. Slide Share³² y Scribd³³ también son repositorios de contenido general, el primero en formato de presentación *slides* y el segundo en formato de documento.

El principal portal de recursos de ciencia de datos en Internet es KDnuggets,³⁴ que contiene *links* para diversos recursos, como *softwares*, repositorios de datos, cursos, etc., además de ofertas de trabajo y mucha publicidad. KDnuggets fue creado en 1997 y es mantenido por Piatetsky-Shapiro, uno de los principales investigadores en el campo y coeditor del primer libro sobre minería de datos [177].

El repositorio de datos que es referencia en varios trabajos de ciencia de datos es el UCI Machine Learning Repository,³⁵ mantenido por la Universidad de California en Irvine. La UCI contiene una colección muy completa de conjuntos de datos *benchmark* para evaluar algoritmos. La UCI tiene una sección especial dedicada a las competencias de ciencia de datos de la Copa KDD propuestas en las ediciones de la conferencia Knowledge Discovery in Databases (KDD).³⁶ Actualmente, las competencias de algoritmos de ciencia de datos se han vuelto comunes a través de *site* Kaggle.³⁷

La *site* del código abierto KEEL *software*,³⁸ desarrollada por un consorcio de seis grupos de investigación españoles, pone a disposición, además de la propia *software*, algunos conjuntos de datos *benchmark*. Los datos encontrados en *site* de KEEL son esencialmente los mismos que los disponibles en UCI, pero en KEEL se pueden encontrar en particiones predefinidas, lo que permite la comparación directa entre algoritmos. La QUILLA *site* también

disponibiliza uma grande variedade de publicações e *links* para outros repositórios ligados à área de inteligência computacional.

Os resultados recentes nas áreas de inteligência computacional e ciência de dados são publicados em periódicos de circulação internacional. No Brasil, graças ao Portal de Periódicos Capes³⁹, o estudante de pós-graduação tem acesso aos principais periódicos científicos em todas as áreas. Na área de inteligência computacional e ciência de dados, os principais portais são o Science Direct⁴⁰ (Elsevier), o IEEEExplore⁴¹ (IEEE), o *site* da Springer⁴² e o portal da ACM Digital Library.⁴³ Os principais periódicos da área de ciência de dados estão listados no portal KDnuggets.⁴⁴

Pesquisadores da área de ciência de dados organizam anualmente diversos congressos internacionais sobre o tema. Os congressos mais importantes na área são o KDD, organizado pelo SIGKDD⁴⁵ e o ICDM,⁴⁶ organizado pelo IEEE. Na área de aprendizado de máquinas os congressos mais importantes são o NIPS⁴⁷ (NeurIPS a partir de 2018) e o ICML⁴⁸. Na área de inteligência computacional, os congressos mais importantes são organizados por especialidade. A cada quatro anos, é organizado o WCCI,⁴⁹ que reúne os principais congressos da área organizados pelo IEEE: FUZZ-IEEE de sistemas *fuzzy*; IJCNN de redes neurais; e IEEE CEC de computação evolutiva. Outras informações sobre eventos e publicações da área podem ser obtidas no *site* da Sociedade de Inteligência Computacional do IEEE.⁵⁰ No Brasil, a Associação Brasileira de Inteligência Computacional (ABRICOM),⁵¹ organiza o Congresso Brasileiro de Inteligência Computacional (CBIC), a cada dois anos.

Atualmente, é possível participar de discussões sobre diversos assuntos em *blogs*⁵² e perfis no Twitter⁵³ relacionados à área de ciência de dados. Há também diversos grupos de discussão em redes sociais,⁵⁴ principalmente no Facebook e no LinkedIn.

O desenvolvimento de modelos de inteligência computacional, principalmente redes neurais profundas, tem se beneficiado bastante de um ecossistema aberto, com *softwares* livres e linguagens de programação abertas, repositórios de artigos científicos como o arXiv⁵⁵ e repositórios de códigos como GitHub.⁵⁶

Finalmente, há na internet repositórios de conteúdo genérico que contêm material de diversos assuntos, incluindo tópicos relacionados à inteligência computacional e ciência de dados. É importante lembrar que artigos na internet não têm nenhum tipo de avaliação da qualidade da informação e devem ser consultados com cautela.

proporciona una amplia variedad de publicaciones y *links* para otros repositorios vinculados al área de inteligencia computacional.

Resultados recientes en las áreas de inteligencia computacional y ciencia de datos se publican en revistas de circulación internacional. En Brasil, gracias al Portal de Revistas Capes³⁹, los estudiantes de posgrado tienen acceso a las principales revistas científicas de todas las áreas. En el área de inteligencia computacional y ciencia de datos, los principales portales son Science Direct⁴⁰ (Elsevier), IEEEExplore⁴¹ (IEEE), Springer's *site*⁴² y el portal ACM Digital Library.⁴³ Las principales revistas en el área de ciencia de datos se encuentran listadas en el portal KDnuggets.⁴⁴

Investigadores del campo de la ciencia de datos organizan cada año varias conferencias internacionales sobre el tema. Los congresos más importantes del área son KDD, organizado por SIGKDD⁴⁵ e ICDM,⁴⁶ organizado por IEEE. En el área de aprendizaje automático, las conferencias más importantes son NIPS⁴⁷ (NeurIPS de 2018) e ICML⁴⁸. En el área de inteligencia computacional los congresos más importantes se organizan por especialidad. Cada cuatro años se organiza el WCCI,⁴⁹ que reúne los principales congresos del área organizados por el IEEE: sistemas FUZZ-IEEE *fuzzy*; IJCNN de redes neuronales; e IEEE CEC para informática evolutiva. Se puede obtener más información sobre eventos y publicaciones en el área en *site* de la IEEE Computational Intelligence Society.⁵⁰ En Brasil, la Asociación Brasileña de Inteligencia Computacional (ABRICOM),⁵¹ organiza el Congreso Brasileño de Inteligencia Computacional (CBIC), cada dos años.

Actualmente es posible participar en discusiones sobre diversos temas en *blogs*⁵² y perfiles de Twitter⁵³ relacionados con el área de ciencia de datos. También existen varios grupos de discusión en las redes sociales,⁵⁴ principalmente en Facebook y LinkedIn.

El desarrollo de modelos de inteligencia computacional, principalmente redes neuronales profundas, se ha beneficiado enormemente de un ecosistema abierto, con lenguajes de programación gratuitos *softwares* y abiertos, repositorios de artículos científicos como arXiv⁵⁵ y repositorios de código como GitHub.⁵⁶

Finalmente, existen repositorios de contenido genérico en Internet que contienen material sobre una variedad de temas, incluidos temas relacionados con la inteligencia computacional y la ciencia de datos. Es importante recordar que los artículos en internet no tienen ningún tipo de valoración sobre la calidad de la información y deben consultarse con precaución.

1.3.3 Softwares

Os *softwares* comerciais mais utilizados são o SAS (Statistical Analysis Software), o SPSS (Statistical Package for the Social Sciences) e o Statistica. Estes *softwares* foram desenvolvidos inicialmente como pacotes estatísticos que depois incorporaram outros módulos. O pacote de mineração de dados do SAS⁵⁷ fornece suporte para todo o processo, incluindo limpeza, transformações de dados e modelos. O SAS ainda tem uma customização de seus módulos para diversos setores de negócios. O IBM SPSS Modeler⁵⁸ (ex-PASW, ex-Clementine) e tem características similares ao concorrente SAS. O SAS e o SPSS oferecem uma solução integrada, considerando todas as etapas do processo, desde a aquisição de dados até a implantação dos modelos. A aquisição da SPSS pela IBM mostra claramente essa tendência. O Statistica Data Miner⁵⁹ também é integrado aos módulos de estatística e tem uma variedade maior de algoritmos, permitindo otimizar modelos para um problema específico. Os resultados dos modelos do Statistica também podem ser exportados em C, Java, Visual Basic e PMML. Os três pacotes oferecem, como módulos adicionais, funcionalidades de mineração de textos.

O Oracle Data Mining e o Microsoft SQL Server Data Mining são bibliotecas de mineração de dados que rodam dentro dos respectivos bancos de dados. A vantagem desse tipo de solução é que os modelos são desenvolvidos diretamente no banco de dados, podendo ser integrados à plataforma operacional. Os produtos da Oracle e da Microsoft oferecem uma variedade limitada de algoritmos, alguns proprietários que não são completamente explicados na documentação. Esses *softwares* têm poucos recursos nativos para visualização e caracterização estatística dos dados. A vantagem do Oracle Data Mining é sua presença no mercado e a integração com os outros produtos da Oracle e a possibilidade de ser diretamente integrado a programas Java e à linguagem PLSQL do Oracle. O Microsoft SQL Server Data Mining também tem a vantagem de ser totalmente integrado à plataforma .NET da Microsoft e o seu custo é bem inferior. Nas versões mais recentes, as duas plataformas têm recursos para mineração de textos.

O desenvolvimento de *softwares* comerciais segue a tendência crescente de oferta de serviços na nuvem. Nesse sentido, a plataforma Microsoft Azure Machine Learning⁶⁰ permite o desenvolvimento e o *deploy* de modelos de ciência de dados diretamente a partir da nuvem. O produto Amazon Machine Learning⁶¹ também segue essa tendência na plataforma de nuvem Amazon Web Services. A Prediction API⁶² da plataforma de nuvem do Google também é uma iniciativa nessa linha.

1.3.3 Softwares

Los *softwares* comerciales más utilizados son SAS (Software de Análisis Estadístico), SPSS (Paquete Estadístico para las Ciencias Sociales) y Statistica. Estos *softwares* fueron desarrollados inicialmente como paquetes estadísticos que luego incorporaron otros módulos. El paquete de minería de datos SAS⁵⁷ brinda soporte para todo el proceso, incluida la limpieza, las transformaciones de datos y los modelos. SAS también cuenta con personalización de sus módulos para diferentes sectores empresariales. IBM SPSS Modeler⁵⁸ (ex-PASW, ex-Clementine) tiene características similares a las de su competidor SAS. SAS y SPSS ofrecen una solución integrada, considerando todas las etapas del proceso, desde la adquisición de datos hasta la implementación del modelo. La adquisición de SPSS por parte de IBM muestra claramente esta tendencia. Statistica Data Miner⁵⁹ también está integrado con módulos de estadísticas y tiene una mayor variedad de algoritmos, lo que le permite optimizar modelos para un problema específico. Los resultados de los modelos Statistica también se pueden exportar en C, Java, Visual Basic y PMML. Los tres paquetes ofrecen, como módulos adicionales, funcionalidades de minería de textos.

Oracle Data Mining y Microsoft SQL Server Data Mining son bibliotecas de minería de datos que se ejecutan dentro de sus respectivas bases de datos. La ventaja de este tipo de solución es que los modelos se desarrollan directamente en la base de datos y se pueden integrar en la plataforma operativa. Los productos de Oracle y Microsoft ofrecen una variedad limitada de algoritmos, algunos de ellos propietarios que no se explican completamente en la documentación. Estos *softwares* tienen pocas características nativas para la visualización y caracterización estadística de datos. La ventaja de Oracle Data Mining es su presencia en el mercado y la integración con otros productos de Oracle y la posibilidad de integrarse directamente con programas Java y el lenguaje PL/SQL de Oracle. Microsoft SQL Server Data Mining también tiene la ventaja de estar completamente integrado con la plataforma .NET de Microsoft y su costo es mucho menor. En las versiones más recientes, ambas plataformas cuentan con capacidades de minería de texto.

El desarrollo de *softwares* comercial sigue la creciente tendencia de ofrecer servicios en la nube. En este sentido, la plataforma Microsoft Azure Machine Learning⁶⁰ permite el desarrollo y *deploy* de modelos de ciencia de datos directamente desde la nube. El producto Amazon Machine Learning⁶¹ también sigue esta tendencia en la plataforma en la nube de Amazon Web Services. La API de Predicción⁶² en la plataforma en la nube de Google también es una iniciativa en esta línea.

Para grandes corporações que atuam em mercados altamente competitivos e lidam com grandes massas de dados, o ganho potencial dos resultados obtidos com modelos de ciência de dados supera o custo de aquisição e manutenção de pacotes comerciais [439]. Para pequenas e médias empresas e, principalmente, o mundo acadêmico, o custo de uma licença de um pacote comercial como os mencionados pode ser proibitivo. Há no mercado outros *softwares* comerciais com custos mais acessíveis como o PolyAnalyst,⁶³ e sua variante para análises de textos TextAnalyst⁶⁴.

Há *softwares* livres que podem ser utilizados para o desenvolvimento de soluções sem uma linguagem de programação. O primeiro *software* livre de mineração de dados, desenvolvido em 1997 na Universidade de Waikato, foi o Weka.⁶⁵ Codificado em Java, o Weka tem código-fonte aberto, embora a documentação não seja das mais claras. O Weka contém uma variedade enorme de algoritmos, com diversas variedades de algoritmos de indução de árvores e regras de decisão. O Weka também tem uma interface gráfica intuitiva de fácil utilização. Em 2006, o Projeto Weka foi adquirido pela Pentaho⁶⁶ para ser integrado ao pacote de inteligência de negócios da empresa. O Weka continua sendo desenvolvido como projeto de *software* livre.

O RapidMiner⁶⁷ utiliza o mesmo modelo de negócios da Pentaho, fornecendo *softwares* livres para oferecer serviços de consultoria e treinamento. O RapidMiner também é desenvolvido em Java e incorpora algoritmos de outros *softwares* livres, como o Weka e o LibSVM. O RapidMiner tem recursos elaborados de visualização de dados e de resultados de modelos, além de permitir o desenvolvimento de *workflows* de modelagem complexos, com otimização de modelos por algoritmos genéticos. O KNIME⁶⁸ também é desenvolvido em Java e incorpora algoritmos de outros *softwares* livres, como o Weka e o LibSVM, numa interface gráfica de fácil utilização. O KNIME tem recursos de visualização melhores que o Weka, mas é equivalente em termos de algoritmos.

Uma alternativa ao padrão Java, utilizado pelos *softwares* livres citados anteriormente, é o Orange,⁶⁹ desenvolvido em C++ e Python. O Orange é um projeto acadêmico e apresenta uma boa variedade de algoritmos numa interface gráfica agradável e com bons recursos de visualização. O Orange é desenvolvido a partir de uma biblioteca que é fornecida junto com o *software*, permitindo o desenvolvimento de aplicações pelo usuário.

A utilização de *softwares* livres e linguagens de programação abertas têm impulsionado o desenvolvimento da ciência de dados. As principais bibliotecas do Python para

Para las grandes corporaciones que operan en mercados altamente competitivos y manejan grandes masas de datos, la ganancia potencial de los resultados obtenidos con modelos de ciencia de datos excede el costo de adquirir y mantener paquetes comerciales [439]. Para las pequeñas y medianas empresas y, principalmente, el mundo académico, el coste de una licencia para un paquete comercial como los mencionados puede resultar prohibitivo. Existen en el mercado otros comerciales *softwares* con costes más asequibles, como PolyAnalyst,⁶³ y su variante de análisis de texto TextAnalyst⁶⁴.

Hay *softwares* gratuitos que se pueden utilizar para desarrollar soluciones sin un lenguaje de programación. El primer *software* sin minería de datos, desarrollado en 1997 en la Universidad de Waikato, fue Weka.⁶⁵ Codificado en Java, Weka es de código abierto, aunque la documentación no es la más clara. Weka contiene una gran variedad de algoritmos, con varias variedades de algoritmos de inducción de árboles y reglas de decisión. Weka también cuenta con una interfaz gráfica intuitiva y fácil de usar. En 2006, Pentaho⁶⁶ adquirió el Proyecto Weka para integrarlo en el paquete de inteligencia empresarial de la empresa. Weka continúa desarrollándose como un proyecto *software* gratuito.

RapidMiner⁶⁷ utiliza el mismo modelo de negocio que Pentaho, proporcionando *softwares* gratuito para ofrecer servicios de consultoría y capacitación. RapidMiner también está desarrollado en Java e incorpora algoritmos de otros gratuitos *softwares*, como Weka y LibSVM. RapidMiner tiene capacidades elaboradas de visualización de datos y resultados de modelos, además de permitir el desarrollo de modelados complejos *workflows*, con optimización de modelos mediante algoritmos genéticos. KNIME⁶⁸ también está desarrollado en Java e incorpora algoritmos de otros *softwares* gratuitos, como Weka y LibSVM, en una interfaz gráfica fácil de usar. KNIME tiene mejores capacidades de visualización que Weka, pero es equivalente en términos de algoritmos.

Una alternativa al estándar Java, utilizado por el *software* gratuito mencionado anteriormente, es Orange,⁶⁹ desarrollado en C++ y Python. Orange es un proyecto académico y presenta una buena variedad de algoritmos en una interfaz gráfica agradable y con buenos recursos de visualización. Orange se desarrolla a partir de una biblioteca que se proporciona junto con *software*, permitiendo el desarrollo de aplicaciones por parte del usuario.

El uso de software libre y lenguajes de programación abiertos ha impulsado el desarrollo de la ciencia de datos. Las principales bibliotecas de Python para

ciência de dados são o Pandas⁷⁰ e o Scikit Learn,⁷¹ que utilizam outras bibliotecas de referência do Python como NumPy e SciPy. O Python é desenvolvido por uma comunidade motivada e suas bibliotecas permitem o acesso a diversos algoritmos. Há uma grande variedade de recursos em Python na internet.⁷²

A linguagem R⁷³ é um projeto de *software* livre da comunidade estatística com um ambiente computacional e bibliotecas com uma grande variedade de rotinas para tratamento, processamento e visualização de dados. As rotinas são organizadas em pacotes para cada assunto e podem ser acessadas por uma linguagem de programação simples, que também é ser utilizada para o desenvolvimento de novos algoritmos. Há diversas extensões e interfaces gráficas para a linguagem, assim como empresas⁷⁴ que fornecem extensões e consultoria. A linguagem R tem sido incorporada em *softwares* comerciais como o SAS e em bancos de dados como Oracle.

O site KDnuggets realiza regularmente uma enquete com o objetivo de determinar os *softwares* mais utilizados pelos usuários do portal. Nos últimos anos, as linguagens R e Python têm se destacado como linguagens mais utilizadas.

Um ambiente computacional importante na área de engenharia é o Matlab.⁷⁵ O Matlab é um *software* comercial que tem um núcleo central, basicamente a janela de comando e bibliotecas numéricas básicas. Os recursos avançados do Matlab são comercializados como pacotes, chamados *Toolbox*, que contêm rotinas para as mais diversas áreas, como biologia, finanças, sistemas de controle etc. Uma configuração adequada para a área de inteligência computacional e ciência de dados deve conter essencialmente os pacotes de estatística,⁷⁶ redes neurais⁷⁷ e algoritmos genéticos.⁷⁸ Pacotes adicionais, como o de otimização⁷⁹ e de identificação de sistemas,⁸⁰ também são importantes. O pacote de programação paralela,⁸¹ que permite a execução de *scripts* Matlab em máquinas com processadores de múltiplos núcleos e *clusters*, pode ser necessário em aplicações computacionalmente intensivas. Os programas desenvolvidos em Matlab podem ser integrados a *softwares* corporativos através de compiladores para as plataformas .NET,⁸² Java⁸³ e Excel.⁸⁴ Além dos pacotes mantidos e desenvolvidos pela Mathworks, existe uma comunidade de usuários ativa que desenvolve rotinas e pacotes para o Matlab, organizados no repositório Matlab Central.⁸⁵ Há mais de 1200 livros escritos sobre o Matlab ou sobre aplicações utilizando o ambiente computacional.⁸⁶ As figuras neste livro foram geradas com Matlab.

ciencia de datos son Pandas⁷⁰ y Scikit Learn⁷¹, que utilizan otras bibliotecas de referencia de Python como NumPy y SciPy. Python es desarrollado por una comunidad motivada y sus bibliotecas permiten el acceso a diferentes algoritmos. Hay una amplia variedad de recursos de Python en Internet.⁷²

El lenguaje R⁷³ es un proyecto *software* gratuito de la comunidad estadística con un entorno computacional y bibliotecas con una amplia variedad de rutinas para procesar, procesar y visualizar datos. Las rutinas están organizadas en paquetes para cada tema y se puede acceder a ellas a través de un lenguaje de programación simple, que también se puede utilizar para desarrollar nuevos algoritmos. Existen varias extensiones e interfaces gráficas para el lenguaje, así como empresas ⁷⁴ que brindan extensiones y consultoría. El lenguaje R se ha incorporado a *softwares* comerciales como SAS y bases de datos como Oracle.

site KDnuggets realiza periódicamente una encuesta con el objetivo de determinar los *softwares* más utilizados por los usuarios del portal. En los últimos años los lenguajes R y Python han destacado como los lenguajes más utilizados.

Un entorno informático importante en el área de la ingeniería es Matlab. ⁷⁵ Matlab es un *software* comercial que tiene un núcleo central, básicamente la ventana de comandos y bibliotecas numéricas básicas. Las funciones avanzadas de Matlab se venden como paquetes, denominados *Toolbox*, que contienen rutinas para las más diversas áreas, como biología, finanzas, sistemas de control, etc. Una configuración adecuada para el área de inteligencia computacional y ciencia de datos debe contener esencialmente los paquetes estadísticos,⁷⁶ redes neuronales⁷⁷ y algoritmos genéticos.⁷⁸ También son importantes paquetes adicionales, como optimización⁷⁹ e identificación de sistemas,⁸⁰. El paquete de programación paralela,⁸¹ que permite la ejecución de *scripts* Matlab en máquinas con procesadores multinúcleo y *clusters*, puede ser necesario en aplicaciones computacionalmente intensivas. Los programas desarrollados en Matlab se pueden integrar en la *softwares* corporativa a través de compiladores para las plataformas .NET,⁸² Java⁸³ y Excel.⁸⁴ Además de los paquetes mantenidos y desarrollados por Mathworks, existe una comunidad de usuarios activa que desarrolla rutinas y paquetes para Matlab, organizados en el repositorio central de Matlab.⁸⁵ Hay más de 1 200 libros escritos sobre Matlab o aplicaciones que lo utilizan computacionalmente. entorno.⁸⁶ Las figuras de este libro se generaron con Matlab.

1.4 Comentários Finais

Neste capítulo foram apresentados os conceitos iniciais inteligência computacional para ciência de dados e uma introdução dos assuntos abordados no livro. Os recursos bibliográficos representam um apanhado das principais fontes que podem servir de apoio a um estudo mais aprofundado nesses temas. É provável que alguma referência importante não tenha sido incluída e é provável que alguma informação esteja desatualizada, principalmente as referências da internet e *softwares*.

1.4 Comentarios finales

Este capítulo presenta los conceptos iniciales de inteligencia computacional para la ciencia de datos y una introducción a los temas tratados en el libro. Los recursos bibliográficos representan un resumen de las principales fuentes que pueden apoyar un estudio más profundo de estos temas. Es probable que alguna referencia importante no haya sido incluida y es probable que alguna información esté desactualizada, especialmente internet y referencias *softwares*.

2 PRÉ-PROCESSAMENTO

O pré-processamento inclui a seleção, limpeza e transformação de dados. O objetivo dessa etapa é a preparação do conjunto de dados que será utilizado para o ajuste do modelo, chamado de **conjunto de treinamento**. Em geral, a etapa de pré-processamento consome de 60% a 80% do tempo de todo o processo de mineração de dados e fornece informações importantes que vão orientar a análise e o ajuste dos modelos.

Este capítulo introduz os conjuntos de dados encontrados em aplicações de ciência de dados. A seguir, são apresentados os principais conceitos estatísticos de métodos exploratórios necessários para o entendimento dos dados e, principalmente, para a interpretação adequada dos resultados da visualização. As técnicas de limpeza de dados e as transformações lineares mais importantes são apresentadas na sequência. Algumas aplicações que utilizam os conceitos discutidos no capítulo são apresentadas no final.

2.1 Conjuntos de Dados

Há uma diferença entre dado, informação e conhecimento [451]. Dado é o registro de um fato, informação é o fato analisado no seu contexto e conhecimento, característica inerentemente humana, é a interpretação da informação num contexto específico visando à sua aplicação. Por exemplo, o preço de uma ação num determinado instante na bolsa de valores é um dado; a variação do preço da ação é uma informação; e a interpretação dessa informação no contexto da conjuntura econômica do momento para a tomada de decisão de investimento é o conhecimento.

2 PREPROCESAMIENTO

El preprocesamiento incluye selección, limpieza y transformación de datos. El objetivo de este paso es preparar el conjunto de datos que se utilizará para ajustar el modelo, llamado conjunto de entrenamiento. En general, la etapa de preprocesamiento consume del 60% al 80 % del tiempo de todo el proceso de minería de datos y proporciona información importante que guiará el análisis y ajuste de los modelos.

Este capítulo presenta los conjuntos de datos que se encuentran en las aplicaciones de ciencia de datos. A continuación, se presentan los principales conceptos estadísticos de los métodos exploratorios necesarios para la comprensión de los datos y, principalmente, para la adecuada interpretación de los resultados de la visualización. A continuación se presentan las técnicas de limpieza de datos y transformaciones lineales más importantes. Al final se presentan algunas aplicaciones que utilizan los conceptos discutidos en el capítulo.

2.1 Conjuntos de datos

Existe una diferencia entre datos, información y conocimiento [451]. Los datos son el registro de un hecho, la información es el hecho analizado en su contexto y el conocimiento, característica inherentemente humana, es la interpretación de la información en un contexto específico con vistas a su aplicación. Por ejemplo, el precio de una acción en un momento determinado en bolsa son datos; el cambio en el precio de las acciones es información; y la interpretación de esta información en el contexto de la situación económica actual para la toma de decisiones de inversión es conocimiento.

Uma metáfora bem-humorada que enfatiza a importância da apresentação da informação é mostrada na Figura 2.1.




Figura 2.1: *Data Cake*. Fonte: epigraphics.com.⁸⁷

Os dados utilizados numa aplicação podem ser estruturados ou não estruturados. Dados estruturados são aqueles organizados em tabelas, nas quais as linhas são os **registros** que representam as observações e as colunas, as **variáveis** ou as características observadas em cada registro, frequentemente chamadas de **atributos**. Os dados não estruturados são aqueles que, na sua forma bruta, não são tabulados. Exemplos de dados não estruturados são imagens, sons, textos, estruturas gráficas etc. Neste livro serão considerados principalmente os modelos de dados estruturados. Modelos de dados não estruturados, principalmente de textos e de estruturas na forma de grafos (redes), têm sido cada vez mais importantes em ciência de dados [295].

Os dados estruturados são armazenados em bases de dados, de onde são selecionados para o ajuste dos modelos. Em sistemas corporativos, os dados podem estar armazenados em diversas bases diferentes. Nesse caso, a extração de dados pode se tornar extremamente complexa e é realizada por processos chamados ETL (*extract, transform and load*). Em ambientes mais simples, a seleção é feita diretamente a partir da base de dados e o conjunto de dados se apresenta na forma de uma tabela ou arquivo de dados.

En la Figura 2.1 se muestra una metáfora humorística que enfatiza la importancia de presentar información.




Figura 2.1: *Data Cake*. Fuente: epigraphics.com.87

Los datos utilizados en una aplicación pueden ser estructurados o no estructurados. Los datos estructurados son aquellos organizados en tablas, en las que las filas son los registros que representan las observaciones y las columnas, las variables o características observadas en cada registro, muchas veces llamados atributos. Los datos no estructurados son datos que, en su forma original, no están tabulados. Ejemplos de datos no estructurados son imágenes, sonidos, textos, estructuras gráficas, etc. En este libro, se considerarán principalmente modelos de datos estructurados. Los modelos de datos no estructurados, principalmente textos y estructuras en forma de gráficos (redes), han ido adquiriendo cada vez más importancia en la ciencia de datos [295].

Los datos estructurados se almacenan en bases de datos, desde donde se seleccionan para ajustar los modelos. En los sistemas corporativos, los datos se pueden almacenar en varias bases de datos diferentes. En este caso, la extracción de datos puede volverse extremadamente compleja y se realiza mediante procesos llamados ETL (*extract, transform and load*). En entornos más simples, la selección se realiza directamente desde la base de datos y el conjunto de datos se presenta en forma de tabla o archivo de datos.

Num conjunto de dados estruturados, cada linha ou registro contém os valores observados de um conjunto de variáveis. As variáveis podem ser contínuas, discretas ordenadas ou discretas não ordenadas. As variáveis contínuas armazenam valores numéricos do tipo real; as variáveis discretas ordenadas armazenam valores do tipo inteiro; enquanto as variáveis discretas não ordenadas armazenam valores categóricos ou nominais. As variáveis binárias são um tipo especial de variáveis discretas que tem apenas dois valores. Tipicamente, um conjunto de dados pode conter variáveis de diversos tipos. A maioria dos algoritmos de estatística e inteligência computacional trabalha com variáveis numéricas. Nesse caso, as variáveis categóricas são transformadas num conjunto de variáveis binárias chamadas variáveis indicadoras (ou *dummy*).^{*} Há algoritmos especializados em modelos de variáveis nominais – em geral, essa área é conhecida com aprendizado simbólico [392][451].

Neste livro, para facilitar o tratamento matemático dos algoritmos, as variáveis são consideradas numéricas (contínuas ou discretas) e as variáveis nominais são transformadas em variáveis indicadoras binárias no pré-processamento.

Um conjunto de dados é representado por $\mathcal{T} = \{(\mathbf{x}(t), \mathbf{y}(t)), t = 1 \dots N\}$. Cada registro é formado pelo par ordenado $(\mathbf{x}(t), \mathbf{y}(t))$, onde $\mathbf{x}(t)$ é o vetor[†] que contém os valores das variáveis de entrada e $\mathbf{y}(t)$, o vetor contendo os valores das variáveis alvo ou de saída. Sem perda de generalidade, os vetores de variáveis de entrada e saída são escritos como $\mathbf{x}(t) \in \mathcal{R}^p$ e $\mathbf{y}(t) \in \mathcal{R}^q$, onde p e q são, respectivamente, o número de variáveis de entrada e de saída. As variáveis nominais são codificadas como variáveis indicadoras que, assim como as variáveis inteiras, são um subconjunto das variáveis reais.

Problemas de saídas múltiplas ($q > 1$) podem ser representados como múltiplos problemas de saída simples se as variáveis de saída forem desacopladas, ou seja, o valor de uma saída não interfere no valor de outra. Nesse caso, um modelo independente é desenvolvido para cada saída. Em problemas descritivos, não há variáveis de saída e o conjunto de dados contém apenas variáveis de entrada.

^{*} Uma variável nominal com n valores é codificada com n variáveis binárias chamadas variáveis indicadoras, em que cada variável indica a observação de um valor nominal da variável original.

[†] Vetores e matrizes são grafados em negrito, vetores em letras minúsculas e matrizes em letras maiúsculas. Valores escalares são grafados em itálico. Letras maiúsculas gravadas em cursiva, como $\mathcal{A}, \mathcal{B}$ etc., indicam conjuntos. Letras gregas serão usadas para indicar parâmetros de modelos.

En un conjunto de datos estructurados, cada línea o registro contiene los valores observados de un conjunto de variables. Las variables pueden ser continuas, discretas ordenadas o discretas desordenadas. Las variables continuas almacenan valores numéricos del tipo real; las variables discretas ordenadas almacenan valores enteros; mientras que las variables discretas desordenadas almacenan valores categóricos o nominales. Las variables binarias son un tipo especial de variables discretas que tienen sólo dos valores. Normalmente, un conjunto de datos puede contener variables de diferentes tipos. La mayoría de los algoritmos estadísticos y de inteligencia computacional trabajan con variables numéricas. En este caso, las variables categóricas se transforman en un conjunto de variables binarias llamadas variables indicadoras (o *dummy*).^{*} Existen algoritmos especializados en modelos de variables nominales; en general, esta área se conoce como aprendizaje simbólico [392][451].

En este libro, para facilitar el tratamiento matemático de los algoritmos, las variables se consideran numéricas (continuas o discretas) y las variables nominales se transforman en variables indicadoras binarias en el preprocesamiento.

Un conjunto de datos está representado por $\mathcal{T} = \{(\mathbf{x}(t), \mathbf{y}(t)), t = 1 \dots N\}$. Cada registro está formado por el par ordenado $(\mathbf{x}(t), \mathbf{y}(t))$, donde $\mathbf{x}(t)$ es el vector [†] que contiene los valores de las variables de entrada y $\mathbf{y}(t)$, el vector que contiene los valores de las variables objetivo o de salida. Sin pérdida de generalidad, los vectores de variables de entrada y salida se escriben como $\mathbf{x}(t) \in \mathcal{R}^p$ y $\mathbf{y}(t) \in \mathcal{R}^q$, donde p y q son, respectivamente, el número de variables de entrada y salida. Las variables nominales se codifican como variables indicadoras que, al igual que las variables enteras, son un subconjunto de variables reales.

Los problemas de salida múltiple ($q > 1$) se pueden representar como problemas de salida simples múltiples si las variables de salida están desacopladas, es decir, el valor de una salida no interfiere con el valor de otra. En este caso, se desarrolla un modelo independiente para cada salida. En los problemas descriptivos, no hay variables de salida y el conjunto de datos contiene solo variables de entrada.

^{*} Uma variável nominal com n valores é codificada com n variáveis binárias chamadas variáveis indicadoras, em que cada variável indica a observação de um valor nominal da variável original.

[†] Vetores e matrizes são grafados em negrito, vetores em letras minúsculas e matrizes em letras maiúsculas. Valores escalares são grafados em itálico. Letras maiúsculas gravadas em cursiva, como $\mathcal{A}, \mathcal{B}$ etc., indicam conjuntos. Letras gregas serão usadas para indicar parâmetros de modelos.

Alguns problemas apresentam características especiais que interferem na interpretação do conjunto de dados. Em problemas dinâmicos, existe uma dependência intrínseca entre uma observação e as observações precedentes. Nesse caso, as variáveis são séries temporais em que os registros são apresentados em sequência e o índice $t = 1 \dots N$ representa um instante de tempo. Os problemas em que a ordem das observações não é relevante são chamados estáticos e, nesse caso, qualquer permutação dos registros no conjunto de dados produz o mesmo resultado. Em problemas georreferenciados, existe uma dependência espacial entre as observações e cada registro está associado a duas (ou três) variáveis que representam as coordenadas da observação. Os problemas chamados espaço-temporais combinam essas duas características: contêm variáveis espaciais e os registros são armazenados em sequência. Este livro não aborda especificamente problemas espaciais ou espaço-temporais, apenas a modelagem de sistemas dinâmicos lineares no Capítulo 4.

Para a apresentação matemática dos algoritmos, o conjunto de dados é representado por matrizes. A matriz (de variáveis) de entrada é a matriz $\mathbf{X}$, de dimensão $N \times p$, e a matriz (de variáveis) de saída é a matriz $\mathbf{Y}$, de dimensão $N \times q$. As dimensões das matrizes indicam que os registros estão organizados em linhas e, para cada registro, os vetores* de variáveis de entrada e saída.

A notação apresentada anteriormente será utilizada ao longo do livro. Essa notação unificada facilita o entendimento dos algoritmos e a transposição de conceitos de modelos lineares para os modelos não lineares.

A próxima seção apresenta a primeira etapa na exploração de dados: a caracterização e visualização de dados.

2.2 Caracterização Estatística

A caracterização estatística de dados é uma das etapas mais importantes na ciência de dados. Essa fase permite o entendimento dos dados e facilita a análise dos resultados dos algoritmos.

* Matematicamente, um vetor é uma lista de valores e pode ser tratado como linha ou coluna na multiplicação com matrizes. Neste livro são utilizados vetores linha.

Algunos problemas presentan características especiales que interfieren con la interpretación del conjunto de datos. En problemas dinámicos, existe una dependencia intrínseca entre una observación y las observaciones precedentes. En este caso las variables son series de tiempo en las que los registros se presentan en secuencia y el índice $t = 1 \dots N$ representa un instante de tiempo. Los problemas en los que el orden de las observaciones no es relevante se denominan estáticos, en cuyo caso cualquier permutación de los registros en el conjunto de datos produce el mismo resultado. En los problemas georreferenciados existe una dependencia espacial entre las observaciones y cada registro está asociado a dos (o tres) variables que representan las coordenadas de observación. Los llamados problemas espaciotemporales combinan estas dos características: contienen variables espaciales y los registros se almacenan en secuencia. Este libro no aborda específicamente problemas espaciales o espaciotemporales, sólo el modelado de sistemas dinámicos lineales en el Capítulo 4.

Para la presentación matemática de los algoritmos, el conjunto de datos se representa mediante matrices. La matriz de entrada (de variables) es la matriz $\mathbf{X}$, de dimensión $N \times p$, y la matriz de salida (de variables) es la matriz $\mathbf{Y}$, de dimensión $N \times q$. Las dimensiones de las matrices indican que los registros están organizados en líneas y, para cada registro, los vectores * de variables de entrada y salida.

La notación presentada anteriormente se utilizará a lo largo del libro. Esta notación unifica y facilita la comprensión de algoritmos y la transposición de conceptos de modelos lineales a modelos no lineales.

La siguiente sección presenta el primer paso en la exploración de datos: caracterización y visualización de datos.

2.2 Caracterización estadística

La caracterización estadística de los datos es uno de los pasos más importantes en la ciencia de datos. Esta fase permite la comprensión de los datos y facilita el análisis de los resultados de los algoritmos.

* Matematicamente, um vetor é uma lista de valores e pode ser tratado como linha ou coluna na multiplicação com matrizes. Neste livro são utilizados vetores linha.

Estatisticamente, um conjunto de dados é tratado como uma amostra de um processo estocástico, ou seja, um processo cujo comportamento é imprevisível, mas pode ser descrito estatisticamente através de uma função de distribuição de probabilidades. O conceito de amostra é muito importante em ciência de dados, uma vez que os modelos serão ajustados a partir de uma amostra e não o processo estocástico. Essa é uma diferença importante entre a abordagem de inteligência computacional e a abordagem estatística, na qual em geral se busca a modelagem do processo [98], a partir de uma hipótese sobre a distribuição de probabilidades.

A maioria dos algoritmos de ciência de dados pressupõe implicitamente que o processo que gerou a amostra representada pelo conjunto de dados é estacionário, ou seja, não varia com o tempo. Dessa forma, podemos utilizar um conjunto de dados coletados num determinado instante para realizar previsões em outro momento uma vez que o processo permanece o mesmo entre o tempo de coleta da amostra e a realização da previsão. Entretanto, essa hipótese pode não ser verdadeira e, nesse caso, os modelos não terão bons resultados de previsão. Esse é tipicamente o caso da modelagem de processos altamente complexos como o mercado financeiro. A caracterização e modelagem de problemas dinâmicos será abordada no Capítulo 4. Neste capítulo, é apresentada a caracterização e visualização de dados de problemas estáticos.

2.2.1 Análise monovariável

O primeiro passo na caracterização estatística de uma amostra é o cálculo de estatísticas das variáveis. Uma estatística é qualquer função obtida a partir de uma amostra. As estatísticas da amostra, em geral, são calculadas para as variáveis de entrada do conjunto de dados, mas podem ser calculadas também para as variáveis de saída. As principais estatísticas são:

- **média**, uma medida do valor central da amostra:

$$\mu \approx \bar{x}_i = \frac{1}{N} \sum_{t=1}^N x_i(t), i = 1 \dots p \quad (2.1)$$

Estadísticamente, un conjunto de datos se trata como una muestra de un proceso estocástico, es decir, un proceso cuyo comportamiento es impredecible, pero que puede describirse estadísticamente mediante una función de distribución de probabilidad. El concepto de muestra es muy importante en la ciencia de datos, ya que los modelos se ajustarán en función de una muestra y no del proceso estocástico. Esta es una diferencia importante entre el enfoque de inteligencia computacional y el enfoque estadístico, en el que generalmente se busca el modelado del proceso [98], basado en una hipótesis sobre la distribución de probabilidades.

La mayoría de los algoritmos de ciencia de datos asumen implícitamente que el proceso que generó la muestra representada por el conjunto de datos es estacionario, es decir, no varía con el tiempo. De esta forma, podemos utilizar un conjunto de datos recopilados en un momento determinado para hacer predicciones en otro momento, ya que el proceso sigue siendo el mismo entre el momento de la recopilación de la muestra y la predicción. Sin embargo, esta hipótesis puede no ser cierta y, en este caso, los modelos no tendrán buenos resultados de predicción. Este suele ser el caso cuando se modelan procesos altamente complejos, como los mercados financieros. La caracterización y modelado de problemas dinámicos se cubrirán en el Capítulo 4. En este capítulo, se presenta la caracterización y visualización de datos de problemas estáticos.

2.2.1 Análisis de una sola variable

El primer paso en la caracterización estadística de una muestra es el cálculo de las estadísticas de las variables. Un estadístico es cualquier función obtenida de una muestra. Las estadísticas de muestra, en general, se calculan para las variables de entrada del conjunto de datos, pero también se pueden calcular para las variables de salida. Las principales estadísticas son:

media, una medida del valor central de la muestra:

$$\mu \approx \bar{x}_i = \frac{1}{N} \sum_{t=1}^N x_i(t), i = 1 \dots p \quad (2.1)$$

- **variância**, uma medida da dispersão da amostra:

$$Var(x_i) \approx \hat{\sigma}_i^2 = \frac{1}{N-1} \sum_{t=1}^N (x_i(t) - \bar{x}_i)^2, i = 1 \dots p \quad (2.2)$$

O **desvio padrão** estimado da variável $\hat{\sigma}_i \approx \sqrt{Var(x_i)}$ é comumente utilizado para a caracterização da dispersão de uma variável, pois seu valor tem a escala da variável.

Em amostras muito grandes de processos estacionários, a média da amostra é uma boa estimativa da média do processo. Esse resultado é conhecido na estatística como a “lei dos grandes números”. Da mesma forma, a variância da amostra converge para a variância do processo com o aumento do número de registros da amostra. Em conjuntos de dados pequenos, deve-se tomar cuidado ao utilizar essas estatísticas como estimativas de suas correspondentes do processo.

A média e a variância são os parâmetros que definem a função de densidade de probabilidades normal $N(\mu, \sigma^2)$, calculada como:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \quad (2.3)$$

A Figura 2.2a apresenta exemplos da distribuição normal com diversos valores de média e desvio padrão (σ). Quanto maior o desvio padrão, maior a dispersão dos dados e, conseqüentemente, menor a probabilidade da média. Na Figura 2.2b, as funções de distribuição de probabilidades cumulativa dos exemplos mostrados na Figura 2.2a.




Figura 2.2: Distribuição normal: (a) função de densidade de probabilidades; (b) função de probabilidades cumulativa. Fonte: Wikipédia.⁸⁸

varianza, una medida de la dispersión de la muestra:

$$Var(x_i) \approx \hat{\sigma}_i^2 = \frac{1}{N-1} \sum_{t=1}^N (x_i(t) - \bar{x}_i)^2, i = 1 \dots p \quad (2.2)$$

La desviación estándar estimada de la variable $\hat{\sigma}_i \approx \sqrt{Var(x_i)}$ se utiliza comúnmente para caracterizar la dispersión de una variable, ya que su valor tiene la escala de la variable.

En muestras muy grandes de procesos estacionarios, la media muestral es una buena estimación de la media del proceso. Este resultado se conoce en estadística como la “ley de los grandes números”. Asimismo, la varianza de la muestra converge a la varianza del proceso con el aumento en el número de registros de muestra. En conjuntos de datos pequeños, se debe tener cuidado al utilizar estas estadísticas como estimaciones de sus contrapartes de proceso.

La media y la varianza son los parámetros que definen la función de densidad de probabilidad normal $N(\mu, \sigma^2)$, calculada como:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \quad (2.3)$$

La Figura 2.2a presenta ejemplos de distribución normal con diferentes valores de media y desviación estándar (σ). Cuanto mayor es la desviación estándar, mayor es la dispersión de los datos y, en consecuencia, menor es la probabilidad de la media. En la Figura 2.2b, las funciones de distribución de probabilidad acumulada de los ejemplos que se muestran en la Figura 2.2a.




Figura 2.2: Distribución normal: (a) función de densidad de probabilidad; (b) función de probabilidad acumulada. Fuente: Wikipedia.88

A função de distribuição de probabilidades normal, ou simplesmente distribuição normal, é muito importante na estatística. Um dos principais resultados envolvendo a distribuição normal é o teorema central do limite. O teorema estabelece que a distribuição da média de amostras de processos estacionários gerados com qualquer distribuição, de média e variância constantes, converge para uma distribuição normal com a média do processo.

A distribuição normal é representada matematicamente por uma função gaussiana que possui diversas propriedades e é utilizada em inúmeras aplicações. Em inteligência computacional, a função gaussiana aparece como uma função de base para o desenvolvimento de vários tipos de modelos, como será apresentado no Capítulo 7.

Outras estatísticas importantes para a caracterização de dados são:

- valores extremos: **mínimo** e **máximo**;
- a **mediana**: é o valor que divide o conjunto de dados em subconjuntos iguais, ou seja, 50% dos registros são maiores que a mediana, 50% são menores que a mediana. A mediana é o percentil 50 da amostra;
- o **percentil P** é o valor que divide o conjunto de dados de forma que $P\%$ dos registros são menores ou iguais a esse valor;
- a **faixa interquartil** é o intervalo compreendido entre o percentil 25 e o percentil 75, respectivamente chamados de primeiro quartil ($Q1$) e terceiro quartil ($Q3$), sendo a mediana o segundo quartil ($Q2$);
- a **moda**, calculada apenas para variáveis discretas, é o valor observado com maior frequência.

A mediana é uma medida de centralidade da amostra que é insensível a distribuições assimétricas. A média pode dar uma ideia equivocada do valor central de um conjunto de dados na presença de valores aberrantes (*outliers*) ou distribuições assimétricas. A comparação entre a média e a mediana permite detectar facilmente assimetrias na distribuição dos dados. Distribuições assimétricas podem gerar modelos tendenciosos. Da mesma forma, as medidas de dispersão dependem da forma da distribuição. A variância da amostra só tem sentido em distribuições simétricas; no caso de distribuições assimétricas, deve-se utilizar a faixa interquartil.

A Tabela 2.1 apresenta o resultado das estatísticas para as variáveis de entrada do conjunto de dados das flores Iris. Pela comparação entre os valores de média e mediana

La función de distribución de probabilidad normal, o simplemente distribución normal, es muy importante en estadística. Uno de los principales resultados de la distribución normal es el teorema del límite central. El teorema establece que la distribución de la media de muestras de procesos estacionarios generadas con cualquier distribución, con media y varianza constantes, converge a una distribución normal con la media del proceso.

La distribución normal está representada matemáticamente por una función gaussiana que tiene varias propiedades y se utiliza en innumerables aplicaciones. En inteligencia computacional, la función gaussiana aparece como una función base para el desarrollo de varios tipos de modelos, como se presentará en el Capítulo 7.

Otras estadísticas importantes para la caracterización de datos son:

valores extremos: mínimo y máximo; la mediana: es el valor que divide el conjunto de datos en subconjuntos iguales, es decir, el 50% de los registros son mayores que la mediana, el 50% son menores que la mediana. La mediana es el percentil 50 de la muestra; el percentil P es el valor que divide el conjunto de datos de modo que $P\%$ de los registros sean menores o iguales a este valor; el rango intercuartil es el intervalo entre el percentil 25 y el percentil 75, denominados respectivamente primer cuartil ($Q1$) y tercer cuartil ($Q3$), siendo la mediana el segundo cuartil ($Q2$); la moda, calculada sólo para variables discretas, es el valor observado con mayor frecuencia.

La mediana es una medida de centralidad muestral que es insensible a distribuciones asimétricas. La media puede dar una idea engañosa del valor central de un conjunto de datos en presencia de valores atípicos (*outliers*) o distribuciones sesgadas. La comparación entre la media y la mediana permite detectar fácilmente asimetrías en la distribución de los datos. Las distribuciones asimétricas pueden generar modelos sesgados. Asimismo, las medidas de dispersión dependen de la forma de la distribución. La varianza muestral sólo tiene sentido en distribuciones simétricas; en el caso de distribuciones asimétricas se debe utilizar el rango intercuartil.

La Tabla 2.1 presenta los resultados de las estadísticas para las variables de entrada del conjunto de datos de la flor Iris. Comparando los valores medio y mediano

(percentil 50), percebe-se uma assimetria na distribuição da variável x_3 . Ao avaliar as estatísticas, é importante observar a escala das variáveis. No caso das Flores Íris, todas as variáveis representam uma medida em centímetros e, portanto, é possível realizar a comparação direta de valores de diferentes variáveis. No caso geral, em que as variáveis representam medidas distintas, recomenda-se que a análise seja feita sobre as variáveis padronizadas (cf. seção 2.3.1).

Tabela 2.1: Estatísticas básicas do problema Íris

	x_1	x_2	x_3	x_4
Mínimos	43,0	20,0	10,0	1,0
Máximos	79,0	44,0	69,0	25,0
Médias	58,4	30,6	37,6	12,0
Desvios	8,3	4,4	17,7	7,6
Percentil 25	51,0	28,0	16,0	3,0
Percentil 50	58,0	30,0	43,5	13,0
Percentil 75	64,0	33,0	51,0	18,0

Em problemas de classificação, é interessante avaliar as variáveis por classe. O **gráfico de linhas** permite que se faça uma avaliação visual das diferenças entre os registros de cada variável por classe e pode ajudar a identificar as variáveis mais relevantes para a separação das classes. No gráfico de linhas, cada variável é um valor no eixo horizontal e cada registro é uma linha ligando as variáveis em seu valor correspondente. A Figura 2.3 mostra um exemplo de gráfico de linhas para o conjunto de dados Íris com variáveis padronizadas (cf. seção 2.3.1). Podemos observar que as classes podem ser mais bem separadas no plano formado pelas variáveis x_3 e x_4 . Essa mesma conclusão será confirmada por outros tipos de gráficos mostrados.




Figura 2.3: Gráficos de linha do problema Íris.

(percentil 50), se nota una asimetría en la distribución de la variable x_3 . Al evaluar las estadísticas, es importante tener en cuenta la escala de las variables. En el caso de Iris Flowers, todas las variables representan una medida en centímetros y, por tanto, es posible comparar directamente los valores de diferentes variables. En el caso general, cuando las variables representan medidas diferentes, se recomienda que el análisis se realice sobre variables estandarizadas (cf. sección 2.3.1).

Tabla 2.1: Estadísticas básicas del problema Iris

	x_1	x_2	x_3	x_4
Mínimos	43,0	20,0	10,0	1,0
Máximos	79,0	44,0	69,0	25,0
Médias	58,4	30,6	37,6	12,0
Desvios	8,3	4,4	17,7	7,6
Percentil 25	51,0	28,0	16,0	3,0
Percentil 50	58,0	30,0	43,5	13,0
Percentil 75	64,0	33,0	51,0	18,0

En problemas de clasificación es interesante evaluar variables por clase. El gráfico de líneas permite una evaluación visual de las diferencias entre los registros de cada variable por clase y puede ayudar a identificar las variables más relevantes para la separación de clases. En el gráfico de líneas, cada variable es un valor en el eje horizontal y cada registro es una línea que conecta las variables en su valor correspondiente. La Figura 2.3 muestra un ejemplo de un gráfico de líneas para el conjunto de datos Iris con variables estandarizadas (consulte la sección 2.3.1). Podemos observar que las clases se pueden separar mejor en el plano formado por las variables x_3 y x_4 . Esta misma conclusión será confirmada por otros tipos de gráficos mostrados.




Figura 2.3: Gráficos lineales del problema del iris.

Há várias funções de distribuição de probabilidades⁸⁹, com aplicações em diversas áreas. A distribuição de cada variável pode ser avaliada qualitativamente através de **histogramas** ou diagramas de frequência. Um histograma é uma representação gráfica da distribuição de probabilidade da variável (cf. Figura 2.4). Há diversos métodos estatísticos para o ajuste da função de distribuição de probabilidades [146][238], bem como livros inteiros dedicados ao assunto [482][490].




Figura 2.4: Histogramas e ajuste de distribuições.

As técnicas de inteligência computacional geralmente não levam em conta hipóteses sobre a distribuição de probabilidades que gerou a amostra. Entretanto, a análise dos histogramas é fundamental para o entendimento dos dados e para dar suporte à análise dos resultados do modelo. A avaliação visual dos histogramas pode revelar características indesejáveis na distribuição dos dados, como assimetria e distribuições multimodais (cf. Figura 2.5). Nesses casos, as estimativas de média e desvio padrão podem perder completamente o sentido.




Figura 2.5: Histogramas: (a) distribuição assimétrica; (b) distribuição multimodal.

Existen varias funciones de distribución de probabilidad⁸⁹, con aplicaciones en diferentes áreas. La distribución de cada variable se puede evaluar cualitativamente mediante histogramas o diagramas de frecuencia. Un histograma es una representación gráfica de la distribución de probabilidad de la variable (cf. Figura 2.4). Existen varios métodos estadísticos para ajustar la función de distribución de probabilidad [146][238], así como libros completos dedicados al tema [482][490].




Figura 2.4: Histogramas y ajuste de distribución.

Las técnicas de inteligencia computacional generalmente no toman en cuenta hipótesis sobre la distribución de probabilidad que generó la muestra. Sin embargo, el análisis de histogramas es esencial para comprender los datos y respaldar el análisis de los resultados del modelo. La evaluación visual de los histogramas puede revelar características indeseables en la distribución de datos, como asimetría y distribuciones multimodales (cf. Figura 2.5). En estos casos, las estimaciones de la media y la desviación estándar pueden perder completamente su significado.




Figura 2.5: Histogramas: (a) distribución asimétrica; (b) distribución multimodal.

Em problemas de classificação, os histogramas podem ser calculados por classe, o que permite a análise da distribuição de cada classe no universo da variável. Os histogramas separados por classes das variáveis no conjunto de dados Íris são mostrados na Figura 2.6. Nesse exemplo, os dados são mais misturados nas variáveis x_1 e x_2 que nas variáveis x_3 e x_4 , como observado no gráfico de linhas da Figura 2.3. As variáveis x_3 e x_4 apresentam um comportamento multimodal. Entretanto, ao separar por classes, verifica-se que cada concentração de dados corresponde a uma classe, o que pode ser bastante útil para a construção de classificadores.




Figura 2.6: Histogramas das distribuições das variáveis por classe no problema Íris.

É possível verificar qualitativamente se uma amostra foi gerada por um processo de distribuição normal através do gráfico de probabilidade normal. Nesse tipo de gráfico, se a amostra foi gerada por um processo de distribuição normal, os pontos aparecem alinhados; no caso de uma distribuição não normal, há uma curvatura no gráfico. A Figura 2.7 apresenta os histogramas de uma amostra de duas variáveis e os respectivos gráficos de distribuição normal. As Figura 2.7a e 2.7c mostram a distribuição de uma

En problemas de clasificación se pueden calcular histogramas por clase, lo que permite analizar la distribución de cada clase en el universo de la variable. Los histogramas separados por clases de las variables en el conjunto de datos Iris se muestran en la Figura 2.6. En este ejemplo, los datos están más mezclados en las variables x_1 y x_2 que en las variables x_3 y x_4 , como se ve en el gráfico lineal de la Figura 2.3. Las variables x_3 y x_4 presentan un comportamiento multimodal. Sin embargo, al separar por clases se verifica que cada concentración de datos corresponde a una clase, lo que puede ser de gran utilidad para construir clasificadores.




Figura 2.6: Histogramas de distribuciones de variables por clase en el problema Iris.

Es posible comprobar cualitativamente si una muestra fue generada mediante un proceso de distribución normal a través del gráfico de probabilidad normal. En este tipo de gráfico, si la muestra fue generada por un proceso de distribución normal, los puntos aparecen alineados; en el caso de una distribución no normal, hay una curvatura en el gráfico. La Figura 2.7 presenta los histogramas de una muestra de dos variables y las respectivas gráficas de distribución normal. Las figuras 2.7a y 2.7c muestran la distribución de una