




INTELIGÊNCIA COMPUTACIONAL

Fundamentos e aplicações


Alexandre G. Evsukoff

INTELIGENCIA A COMPUTAC IONAL

Fundamentos e aplicações
Alexandre G. Evangelista

Rio de Janeiro, 2020

 e-papers



Esta obra está bajo una licencia Creative Commons Atribución-NoComercial-SinDerivadas 4.0 Internacional. Para ver una copia de esta licencia, visite <http://creativecommons.org/licenses/by-nc-nd/4.0/> o envíe una carta a Creative Commons, PO Box 1866, Mountain View, CA 94042, EE. UU.

ISBN 978-65-87065-02-1

Ilustração de capa

Matriz de correlación del conjunto de datos Sonar, creada por el autor

Diagramação

Ana Cláudia Ribeiro

Revisão

Rodrigo Reyes

Disponível em o site web de a Editora E-papers
<http://www.e-papers.com.br> Avenida das Américas,
3.200 quadra 1 habitação 138

Barra da Tijuca – Rio de Janeiro – Brasil C
EP 22.640-102

CIP-Brasil. Catalogación en fuente Unificada
Nacional de Editores de Libros, RJ

E94i Evsukoff, Alexandre Inteligencia computacional: fundamentos y aplicaciones [recurso electrónico] / Alexandre Evsukoff. - 1ª ed. - Río de Janeiro: E-papers, 2020. recurso digital: il. ; 20 MB Formato: electrónico Requisitos del sistema: Modo de acceso: world wide web Incluye bibliografía ISBN 978-65-87065-02-1 (recurso electrónico) 1. Inteligencia computacional. 2. Redes neuronales (Informática). 3. Libros electrónicos. I. Título. 20-64566 CDD: 006.3 CDU: 004.8

Resumen

PRESENTACIÓN	8
1 INTRODUCCIÓN	9
1.2	20
1.3 RECURSOS C	
1.3.1 Bibliografía de referencia	21
1.3.2 Recursos de Internet	21
1.3.3 Software	23
1.4 COMENTARIOS FINALES	26
29	
2 PREPROCESAMIENTO	30
2.1 CONJUNTOS DE DATOS	30
2.2 CARACTERIZACIÓN ESTADÍSTICA	33
2.2.1 Análisis de una sola variable	34
2.2.2 Análisis multivariado	40
2.2.3 Distancias y distancias de la mat	
riz de datos similitudes	44
2.3 LIMP	
IEZA DE DATOS	47
2.3.1 Estandarización de variables	48
2.3.2 Detección de valores atípicos	49
2.3.3 Valores faltantes	53
2.4 TRANSFORMACIONES LINEALES	56
2.4.1 Análisis de componentes principales ..	
2.4.2 Descomposición de valores s	
ingulares	62
2.4.3 Análisis discriminante linea	
l	63
2.4.4 Análisis de correlación ca	
nónica	66
2.5 APLICACI	
ONES	69
2.5.1 Patrones de movilidad	69
2.5.2 Ecuaciones de paridad	72
2.6 COMENTARIOS FINALES	76

3 REGRESIÓN LINEAL	78
3.1 EL PROBLEMA DE LA REGRESIÓN	
..... 79 3.1.1 El modelo lineal	
..... 81 3.1.2 Método de mínimos cuadrados	
..... 82 3.1.3 Interpretación geométrica	
..... 84 3.1.4 Ejemplo sintético	
..... 86 3.2 REGULARIZACIÓN	
..... 89 3.2.1 Sesgo y varianza	
..... 90 3.2.2 Regularización de Tikhonov	
..... 93 3.2.3 Regularización por	
componentes principales	97} 3.5

4 MODELOS DINÁMICOS	116
126 4.2.3 Estructuras mixtas	
..... 129 4.3 SISTEMAS DINÁMICOS LINEALES	
..... 131 4.3.1 Modelo ARX	
..... 133 4.3.2 Modelo ARMAX	
..... 135 140 4,5	

5 CLASIFICACIÓN	148
149	

5.2 MODELOS DE CLASIFICACIÓN LINEAL	164
..... 5.2.1 Mínimos cuadrados	164
..... 5.2.2 Mínimos cuadrados ponderados	166
..... 5.2.3 Regresión logística	168
5.3 EVALUACIÓN DE CLASIFICADORES	171
..... 5.3.1 Estadísticas de validación	172
..... 5.3.2 Espacio ROC y AUC	175
5.4 APLICACIONES	179
..... 5.4.1 Pruebas de referencia	179
..... 5.4.2 Análisis de la cancelación en telefonía	183
5.5 COMENTARIOS FINALES	187
6 ANÁLISIS DE CLÚSTER	189
6.1 EL PROBLEMA DEL ANÁLISIS DE CLÚSTER	190
6.2 MÉTODOS DE PARTICIÓN	194
..... 6.2.1 Algoritmo K-medias	194
..... 6.2.2 Ejemplos	198
6.3 HÉRICO MÉTODOS	201
..... 6.3.1 Algoritmos aglomerativos	202
..... 6.3.2 Ejemplos	203
6.4 PAR TIONAMIENTO DE GRÁFICOS	204
..... 6.4.1 Algoritmos de agrupamiento espectral	210
..... 6.4.2 Ejemplos	216
6.5 VALIDACIÓN DE GRUPO	218
..... 6.5.1 Medidas externas.....	218
..... 6.6.2 Agrupación de documentos.....	230
6.7 COMENTARIOS FINALE S.....	234
7 MODELOS LINEALES LOCALES	236
7.1 APRENDIZAJE MÁQUINA	237
7.2 MODELOS DE BASE RADIAL (RBF)	241
..... 7.2.1 Aproximación de funciones	242
..... 7.2.2 Modelos RBF	246
..... 7.2.3 Ajuste de parámetros	250
7.3 MÁQUINAS DE VECTO RES DE SOPORTE	253
..... 7.3.1 Funciones principales	253
..... 7.3.2 Minimización de riesgos estructurales	258

7.5 COMENTARIOS FINALES	278
8 SISTEMAS FUZZY	280
8.1 CONJUNTOS <i>Fuzzy</i>	
..... 282 8.1.1 Funciones de membresía	
..... 285 8.1.2 Operadores difusos	
..... 289 8.1.3 Relaciones difusas	
..... 293 8.2 REGLA MODELOS <i>Fuzzy</i>	
..... 294 8.2.1 Variables lingüísticas	
..... 295 8.2.2 Cálculo de reglas d	
ifusas	298
8.2.3 Sistemas	
difusos simbólicos.....	304
8.3 ALGORITMO	
S PARA CIENCIA DE DATOS	
..... 313 8.3.1 C-medias difusas	
..... 313 8.3.2 Coincidencia de patrones difusos	
..... 317 8.3.3 Algoritmo de Wang y Mendel	
..... 322 8.3.4 Modelo RBF difuso	
..... 326 8.4 APLICACIONES	
..... 329 8.4.1 Pruebas de referencia	
..... 329 8.4.2 Diagnóstico de f	
allos	331
8.4.3 C	
lasificación espacial	3
36 8.4.4 Modelo lluvia-escorrentía	
..... 339 8.5 COMENTARIOS FINALES	
..... 344	
9 REDES NEURALES	346
9.1 REDES NEURALES LINEALES	
..... 350 9.1.1 Perceptrón y ADALINE	
..... 352 9.1.2 Método del gradiente	
..... 356 9.1.3 Gradiente estocástico	
..... 360 9.2 REDES NEURALES NO LINEALES	
..... 362 9.2.1 Perceptrón multicapa (MLP)	
..... 362 9.2.2 Evaluación de máxima verosimilitud	
..... 368 9.2.3 Algoritmo de retropropagación	
..... 374 9.3 REDES NEURALES PROFUNDAS	
..... 388 9.3.1 Redes neuronales	
convolucionales	391
9.3.2	
Redes neuronales recurrentes	
.... 411 9.3.3 Aprendizaje de representación	
..... 439 9.4 APLICACIONES	
..... 452	

9.5 COMENTARIOS FINALES	
.....	470
REFERENCIAS BIBLIOGRÁFICAS	471
REFERENCIAS EN INTERNET.....	521

Presentación

La inteligencia computacional es un conjunto de paradigmas computacionales para el desarrollo y aplicación de sistemas inteligentes a problemas complejos del mundo real. La ciencia de datos reúne conocimientos de matemáticas, estadística, informática e ingeniería con conocimientos de dominio de cada aplicación.

La ubicuidad de los datos en la era digital significa que la ciencia de datos tiene aplicaciones en todas las áreas de la ingeniería y, cada vez más, en las ciencias naturales, biológicas y humanas. Este libro presenta una introducción a las principales técnicas y modelos de inteligencia computacional en aplicaciones de ciencia de datos. El libro cubre los fundamentos para la preparación de datos, ajustes de modelos predictivos y descriptivos y presenta aplicaciones en ingeniería, resultados de proyectos realizados en la Coppe/UFRJ. El material puede utilizarse como libro de texto en cursos de pregrado y posgrado.

El libro está dividido en nueve capítulos. Los cinco primeros contienen una introducción a las técnicas estadísticas a través de la presentación de los principales métodos de regresión lineal, sistemas dinámicos, clasificación y análisis de conglomerados. El Capítulo 7 analiza teóricamente el problema de aproximación de funciones y presenta los modelos de función de base radial (RBF) y máquinas de vectores de soporte (SVM). El Capítulo 8 presenta sistemas *fuzzy* y el Capítulo 9, modelos de redes neuronales con una introducción a los modelos recurrentes de redes neuronales profundas.

1 INTRODUCCIÓN

La capacidad de una máquina para exhibir un comportamiento inteligente ha sido objeto de reflexión filosófica durante mucho tiempo. En la década de 1920, Wittgenstein abordó el tema basándose en la pregunta “¿puede pensar una máquina?” Su conclusión fue que, al igual que la conciencia, el pensamiento es una capacidad inherentemente humana [483]. En 1950, ante la dificultad de definir “pensamiento” e “inteligencia”, Alan Turing propuso una prueba para verificar si una computadora puede exhibir un comportamiento inteligente [529]. El test de Turing¹ se plantea como un juego en el que un evaluador aislado en una habitación se pone en contacto con un interlocutor en otra habitación, que puede ser humano o informático. Si el evaluador no puede identificar si el interlocutor es una computadora, entonces se puede concluir que la computadora se comporta de manera inteligente.

La inteligencia artificial como área de investigación surgió unos años después, como una propuesta de integrar la lógica, la informática y la neurofisiología para el desarrollo de máquinas inteligentes. A principios de la década de 1960, las dos principales corrientes para el desarrollo de la inteligencia artificial fueron denominadas simbolistas y conexionistas. La corriente simbolista estuvo formada por lógicos matemáticos que desarrollaron los primeros demostradores de teoremas. En la corriente conexionista el objetivo era simular el procesamiento cerebral con neuronas artificiales. Los resultados iniciales del algoritmo de aprendizaje Perceptron [457] generaron grandes expectativas respecto a la posibilidad de construir cerebros artificiales, pero su limitación como clasificador lineal no permitió el ajuste de modelos más complejos.

A lo largo de la década de 1970, las computadoras *mainframe* se difundieron como productos para automatizar el procesamiento de datos en las organizaciones. Los demostradores de teoremas evolucionaron hasta convertirse en sistemas expertos, que contenían un motor de razonamiento que procesaba el conocimiento representado por un conjunto de reglas y hechos. Pronto quedó claro que adquirir conocimientos de expertos no era una tarea trivial, lo que alimentó el interés en las técnicas de aprendizaje automático (*machine learning*) para sintetizar modelos directamente a partir de datos. El algoritmo de inducción del árbol de decisión ID3 fue presentado en 1986 por Quinlan. ID3 tenía la capacidad de abstraer un conjunto de reglas lógicas a partir de datos de variables nominales. El artículo inauguró la revista *Machine Learning* [445].

Los modelos conexionistas regresarían con gran impacto en 1986 tras la publicación de un artículo en la revista *Nature* [464] que presentaba un algoritmo de entrenamiento de redes neuronales multicapa basado en la retropropagación del error a través de las capas. Los resultados mostraron la capacidad del método para resolver problemas complejos de reconocimiento de patrones, como la identificación de dígitos escritos a mano. Las redes neuronales se han desarrollado rápidamente debido a su capacidad para ajustar modelos no lineales computacionalmente robustos, con buenos resultados en varias aplicaciones. En la década de 1980, la introducción del IBM PC marca el comienzo de la difusión de los ordenadores personales entre el público en general y las pequeñas empresas.

En las décadas de 1980 y 1990 se produjeron grandes avances en el área de la inteligencia artificial, con el desarrollo de nuevos paradigmas computacionales como sistemas *fuzzy*, redes neuronales y máquinas de vectores de soporte. La integración de estos modelos en enfoques híbridos, incluido el uso de algoritmos evolutivos para la optimización, se denominó computación blanda (*soft computing*) o inteligencia computacional (*computational intelligence*). Actualmente, la inteligencia computacional también incluye métodos estadísticos y de aprendizaje automático.²

En los años 1990, los ordenadores personales ya se habían convertido en un producto de uso común y, a principios del año 2000, aproximadamente el 30% de la población de EE.UU. y Europa estaba conectada a Internet.³ Las expectativas sobre el desarrollo de Internet eran enormes a finales de los años 1990, lo que dio lugar a la llamada burbuja de Internet,⁴ que estalló en 2000 y provocó la caída del precio de las acciones negociadas en el mercado. Bolsa de tecnología NASDAQ. Desde la burbuja “.com”, la competencia se ha vuelto más intensa e Internet se ha convertido en un mercado más maduro, dominado por grandes empresas *players*.

A lo largo de la década de 1990, el término minería de datos (*data mining*) comenzó a difundirse como un conjunto de técnicas que incluyen estadística, aprendizaje automático, inteligencia computacional, bases de datos, entre otras, para desarrollar modelos a partir de datos. En 1997 apareció la primera plataforma de minería de datos de código abierto, Weka,⁵ desarrollada en la Universidad de Waikato, Nueva Zelanda, convirtiéndose en un referente en el mundo académico. A partir del año 2000, cada vez más *softwares* comerciales y bibliotecas ofrecían nuevos algoritmos.⁶ A lo largo de la década de 2000, las plataformas comenzaron a presentarse en el mercado como soluciones de inteligencia analítica [329], centrándose en el análisis de datos y alineando los resultados con los objetivos de negocio.

La reducción de los costos de almacenamiento, el desarrollo de procesadores e internet han impulsado el proceso de recopilación y almacenamiento de bases de datos. El comienzo del siglo XXI marca el comienzo del predominio del almacenamiento de datos en formato digital sobre las tecnologías analógicas. El tráfico de datos en Internet aumentó exponencialmente con la proliferación de dispositivos móviles a partir de 2007. En 2010, el término *big data* aparece como *buzzword* para definir el conjunto de tecnologías para recopilar, almacenar, procesar, analizar y visualizar grandes bases de datos.

Internet permite ofrecer productos y servicios a un número prácticamente ilimitado de usuarios en una red sin escala [29]. En los últimos años, nuevos modelos de negocio o nuevas versiones de negocios tradicionales escalables globalmente han cambiado la vida de miles de personas. Empresas como IBM, Apple, Microsoft, Google, Amazon y Facebook utilizan ampliamente algoritmos de inteligencia computacional en sus negocios. Nuevos negocios están prosperando rápidamente en todas las áreas con la evolución de la tecnología de sensores y el desarrollo del Internet de las cosas.

Desde 2012, los modelos de redes neuronales profundas* [212][333] han obtenido excelentes resultados en problemas complejos de reconocimiento de patrones. Los modelos se procesan en hardware masivamente paralelo con unidades de procesamiento gráfico (GPU), que tienen una alta capacidad de procesamiento y un bajo consumo de energía en comparación con los procesadores convencionales (CPU). Modelos de redes neuronales profundas en problemas de visión por computadora y procesamiento del lenguaje natural.

* *Deep neural networks.*

ral han obtenido resultados comparables e incluso superiores a los de los humanos. Estos resultados han generado grandes expectativas respecto al potencial de la inteligencia computacional para la ciencia de datos. El tema es amplio y se ha ido expandiendo rápidamente. Este libro corresponde a una formación básica sobre el tema incluyendo aplicaciones desarrolladas en diferentes áreas.

Este capítulo presenta una introducción a los principales tipos de problemas en aplicaciones reales que se cubrirán en el libro. A continuación se muestra un resumen de la bibliografía y las principales herramientas disponibles, tanto comerciales como de código abierto.

1.1 Ciencia de datos

En el método científico clásico, las hipótesis teóricas conducen al desarrollo de modelos, que deben verificarse mediante la observación del fenómeno. En las ciencias exactas, el modelo está representado por fórmulas matemáticas que codifican el conocimiento sobre el fenómeno [451]. El notable desarrollo de la informática en el siglo XX permitió el modelado y simulación de fenómenos de alta complejidad, generando enormes avances en la representación de la realidad y su uso para la toma de decisiones.

Los parámetros del modelo deben ajustarse según los datos observados para que el modelo sea efectivamente una representación de la realidad. Sin embargo, estos datos, incluso cuando se obtienen en condiciones experimentales controladas, contienen errores e incertidumbres debido a imperfecciones en los instrumentos y, principalmente, a la dificultad o imposibilidad de observar el fenómeno modelado [419].

La realidad suele ser mucho más compleja que cualquier teoría y, en algunos casos, no existe ningún modelo físico capaz de describir adecuadamente un fenómeno determinado. La ciencia de datos es un conjunto de métodos para recopilar, almacenar, procesar, analizar y visualizar datos. El objetivo es desarrollar modelos directamente a partir de datos, sin hipótesis teóricas. Por lo general, los datos se obtienen de forma no controlada, sin planificar experimentos ni conocer la representatividad de la muestra.

Los datos observados siempre corresponden a una muestra del proceso, obtenidos bajo condiciones específicas que determinan su validez. Un modelo obtenido de

una muestra es una representación de los datos de la muestra y, por lo tanto, una representación indirecta del proceso real que produjo los datos. La validez del modelo siempre está limitada por la calidad de la muestra.

La ciencia de datos (*data science*) se ubica en la intersección del conocimiento de matemáticas, estadística, informática e ingeniería con el conocimiento del dominio y los datos de cada aplicación. La ubicuidad de los datos en la era digital significa que la ciencia de datos tiene aplicaciones en todos los sectores, además de ser cada vez más utilizada en problemas de las ciencias humanas, naturales y biológicas [295].

La integración de varias disciplinas necesarias para trabajar con grandes bases de datos se llamó minería de datos durante la década de 1990, pero pasó a ser conocida como ciencia de datos principalmente desde 2010. Los dos términos se utilizan a menudo con significados similares. Podemos considerar que la ciencia de datos se refiere al conocimiento necesario, mientras que la minería de datos se refiere al proceso de desarrollo de modelos a partir de datos.

Database Knowledge Discovery (KDD)*, o simplemente, minería de datos, es un proceso cíclico, de modo que, si no se logran los objetivos, se debe realizar una nueva iteración, afinando los resultados o utilizando nuevos datos/herramientas. La Figura 1.1 ilustra el proceso de minería de datos con sus posibles ciclos e iteraciones.




Figura 1.1: El proceso de minería de datos.

* *Knowledge Discovering in Databases*

La recopilación y el almacenamiento de datos, que aparecen condensados en la Figura 1.1, es un elemento extremadamente importante del proceso, especialmente para las grandes corporaciones, que tienen una infraestructura de tecnología de la información (TI) compleja. El proceso comienza con la selección de un subconjunto de datos que se utilizarán para el ajuste del modelo. Este conjunto de datos, denominado conjunto de entrenamiento, es una muestra considerada válida y puede ser, según el caso, la propia base de datos. Los datos del conjunto de entrenamiento se utilizan para el desarrollo del modelo. Durante el proceso de construcción del modelo, el conjunto de datos se divide para ajustar los parámetros y validar los resultados.

La etapa de selección de datos incluye el importante proceso de elección/selección de variables, el cual puede realizarse con base en el conocimiento de expertos o de forma automática. Una base de datos a menudo tiene valores faltantes y valores extremos o atípicos, que deben eliminarse para no dañar el ajuste del modelo.

Comprender la aplicación y la claridad en los objetivos finales a alcanzar son fundamentales para el éxito de una aplicación y la participación de expertos en el dominio es muy importante. El científico de datos debe identificar los requisitos de la aplicación, desarrollar y evaluar los resultados del modelo, elegir el modelo más apropiado y coordinar su implementación.

La comprensión de los datos se logra mediante técnicas de caracterización y visualización estadística. Este paso es importante para el desarrollo del modelo y se discutirá en el Capítulo 2. El preprocesamiento de datos con las principales técnicas de transformación lineal también se presenta en el Capítulo 2.

El paso principal en la minería de datos es la generación de modelos. Gran parte del contenido de este libro está orientado al desarrollo y análisis de resultados de modelos. Los capítulos 3 a 6 cubren los fundamentos estadísticos de los problemas de regresión, clasificación y análisis de conglomerados. Los capítulos 7 a 9 presentan los principales métodos no lineales de inteligencia computacional.

Es importante evaluar adecuadamente el rendimiento del modelo antes de implementar la solución. La calidad de los modelos se evalúa a través de estadísticas de validación, cuyo objetivo es verificar si se cumplieron los requisitos del modelado. Varias estadísticas resaltan diferentes características de los modelos y se discutirán en la parte de fundamentos.

La siguiente sección presenta los principales tipos de modelos que se tratarán en este libro. En la práctica, los problemas no siempre se presentan con claridad. Es importante comprender correctamente las características de los problemas típicos para poder desarrollar una solución específica en un caso más complejo.

1.2 Tipos de modelos

La palabra “modelo” se utiliza en varias áreas con diferentes conceptos y es importante definir claramente qué se entiende por modelo. El diccionario *Aurélio*⁷ define un modelo como algo “que sirve como objeto de imitación” o, en el contexto matemático, como una “representación matemática de un fenómeno”. En este libro, un modelo es una representación simplificada de un sistema o proceso real obtenido a partir de datos de muestra. Los modelos de ciencia de datos representan solo la parte del proceso que ha sido capturada por los datos. Este hallazgo, aunque obvio, es muy importante ya que es posible que el modelo no pueda predecir correctamente un comportamiento que no esté representado en los datos de entrenamiento.

Un modelo, entendido como una representación matemática de un proceso real, puede clasificarse según la naturaleza del conocimiento utilizado para su construcción como modelo de conocimiento o modelo de comportamiento. En los modelos de conocimiento (o analíticos), las relaciones que describen el comportamiento del sistema se escriben con base en las leyes fundamentales de la física o del conocimiento humano. En los modelos de comportamiento (o de entrada/salida), las relaciones que describen el comportamiento del sistema se obtienen directamente mediante la observación de los datos de entrada y salida. Los modelos de ciencia de datos son esencialmente modelos de comportamiento, aunque el conocimiento experto en el dominio y el conocimiento de los analistas son esenciales para desarrollar buenos modelos.

Las aplicaciones de la ciencia de datos están orientadas a problemas predictivos o descriptivos. Los problemas predictivos utilizan datos observados en las variables de salida (variables dependientes), cuyos valores son predichos por el modelo en función de las variables de entrada (variables independientes). En este caso, el modelo realiza una aproximación del mapeo de entrada y salida observado. En los problemas descriptivos no hay variables de salida y el objetivo del modelo es una representación de los datos de entrada. Los modelos predictivos se ajustan mediante algoritmos de aprendizaje supervisados, mientras que

Los modelos descriptivos se ajustan mediante algoritmos de aprendizaje no supervisados. También existen algoritmos de aprendizaje por refuerzo, en los que el modelo se ajusta directamente a través de su interacción con el entorno. Este enfoque se utiliza ampliamente en problemas de control y para entrenar agentes inteligentes.

Los problemas predictivos habituales son la clasificación y la regresión. En la clasificación, también llamada clasificación supervisada o reconocimiento de patrones, la variable de salida es una clase, generalmente una variable discreta y desordenada. En la regresión, la variable de salida es numérica, generalmente un número real. De hecho, los dos problemas son similares y se pueden utilizar modelos de inteligencia computacional para resolverlos.

En problemas descriptivos, el objetivo del modelo es proporcionar una descripción del conjunto de datos. Los principales problemas descriptivos son el análisis de conglomerados y las reglas de asociación. El análisis de conglomerados, también llamado clasificación o segmentación no supervisada, utiliza varios algoritmos para encontrar grupos de registros similares en grandes bases de datos. Los algoritmos de reglas de asociación son ampliamente utilizados en problemas descriptivos cuyo objetivo es encontrar elementos que estén relacionados en la base de datos, como en el análisis de cestas de la compra y sistemas de recomendación. Recientemente han surgido nuevos algoritmos de aprendizaje no supervisado como aprendizaje de representación en los que el objetivo del modelo es producir una representación de la entrada.

Las técnicas de combinación de modelos, denominadas *ensemble*, permiten aumentar el rendimiento del modelo [150][475][604]. En problemas de predicción, los mejores resultados en el Premio Netflix⁸ y otros concursos de ciencia de datos⁹ se obtienen con *ensembles*.

A continuación, presentamos una breve descripción de los problemas que se abordarán en este libro, mostrando algunos ejemplos de conjuntos de datos conocidos.

1.2.1 Regresión

El objetivo de la regresión o aproximación de funciones es un modelo de sistema o proceso capaz de estimar el valor de la variable numérica de salida en función de las variables de entrada. La regresión es una tarea predictiva y la evaluación de la precisión.

Se realiza de acuerdo con el error de predicción, es decir, la diferencia entre el valor predicho y el valor correcto. El error de predicción se utiliza para ajustar el modelo.

El problema de regresión lineal es clásico en estadística, con varias aplicaciones en ingeniería y ciencia. En la regresión lineal, la variable de salida se calcula como una combinación lineal de variables de entrada o funciones de variables de entrada llamadas "regresores" o características (*features*). Además de ser eficiente, el modelo lineal permite el análisis de diversas características del problema. La regresión lineal se explora en el Capítulo 3, su extensión al modelado de series temporales y sistemas dinámicos se presenta en el Capítulo 4.

La figura 1.2 muestra un ejemplo de un problema de regresión lineal con una sola variable. El modelo (en rojo) se ajusta a partir de los datos de muestra (en azul) y debe estar lo más cerca posible de la relación objetivo (en negro). En general, el comportamiento estadístico del proceso no se conoce con precisión más allá de los datos de la muestra, por lo que no se puede decir si el modelo ajustado representa el proceso (relación objetivo) o es sólo un modelo de esa muestra.




Figura 1.2: Problema de regresión lineal.

En muchos procesos reales, la relación entre las variables de entrada y salida no es lineal. En este caso, el modelo es válido para las condiciones bajo las cuales se realizó la muestra. Si el proceso tiene un comportamiento muy inestable, como por ejemplo el mercado financiero, la validez de un modelo caduca rápidamente y un modelo ajustado con datos históricos no puede predecir adecuadamente el futuro. En el caso de modelos no lineales, la predicción de un valor muy diferente de los datos de entrada-salida

utilizado en el conjunto de entrenamiento puede dar como resultado valores incorrectos, ya que el modelo se ajustó a la muestra, que representa un determinado dominio.

Los problemas de regresión y clasificación tienen muchas características en común, ya que un modelo de clasificación puede verse como un modelo de aproximación de funciones discriminantes, como se describe a continuación.

1.2.2 Clasificación

El objetivo de la clasificación es un modelo, llamado clasificador, capaz de clasificar una observación en una de diferentes clases predefinidas en función de los valores de las variables de entrada, que representan las características o atributos de la observación. El modelo representa la relación entre los atributos y la clase, que es la variable de salida. La clasificación es una tarea predictiva, ya que el modelo debe poder predecir la clase de un registro nuevo previamente desconocido, es decir, un registro que no se utiliza en el conjunto de entrenamiento. La evaluación de un modelo de clasificación se lleva a cabo principalmente en función de su precisión para predecir la clase correcta.

El conjunto de datos de la flor Iris es sin duda el ejemplo más conocido y estudiado en la ciencia de datos. El problema consiste en predecir la categoría de las flores de Iris, mostrada en la Figura 1.3, en base a los valores de largo y ancho de los pétalos y sépalos. Por tanto, el conjunto de datos tiene cuatro variables numéricas de entrada y una variable de salida, cuyos valores son las tres clases posibles. El conjunto de datos presenta 50 instancias para cada clase y fue utilizado por primera vez por Fisher en 1936 [183] como ejemplo de funciones discriminantes lineales.




Figura 1.3: Flores de iris: (a) *Iris setosa*; (b) *Iris versicolor*; (c) *Iris virginica*.

El problema de clasificación puede verse como una búsqueda de funciones discriminantes (lineales o no lineales) capaces de dividir el espacio de variables de entrada en regiones y asociar cada región con una clase (cf. Figura 1.4).




Figura 1.4: Problema de clasificación: (a) conjunto de entrenamiento; (b) articulación de pruebas.

En situaciones en las que es posible separar todos los registros de una clase mediante una función lineal, se dice que la clase es linealmente separable. Cuando los registros de una clase no pueden separarse mediante una función no lineal, se dice que la clase es no linealmente separable. En la práctica, en la mayoría de los casos, los registros no pueden separarse completamente mediante alguna función lineal o no lineal. En este caso se dice que las clases son no separables ya que la información recogida por las variables de entrada no es suficiente para separar completamente las clases y, en consecuencia, el error de clasificación no puede ser nulo por muy bueno que sea el modelo. El problema se explora en detalle en el Capítulo 5, donde mostramos que es posible establecer un límite teórico al error de un clasificador. Los modelos lineales locales, los modelos de sistemas difusos y las redes neuronales pueden manejar tanto problemas de clasificación como de regresión y se presentarán en los Capítulos 7, 8 y 9 respectivamente.

El problema de la clasificación se ha estudiado mucho antes de la aparición de las técnicas de inteligencia computacional. En estadística, el problema de clasificación se llama reconocimiento de patrones [146]. Los enfoques modernos del problema combinan técnicas estadísticas clásicas y técnicas de inteligencia computacional [146]. Este tipo de problemas encuentra numerosas aplicaciones en los más variados campos empresariales, como por ejemplo, diagnóstico médico, análisis crediticio, clasificación de documentos, clasificación de imágenes, bioinformática, entre otros.

1.2.3 Análise de agrupamentos

El propósito del análisis de conglomerados es encontrar grupos de registros similares en el conjunto de datos. En el análisis de conglomerados, también llamado clasificación no supervisada, no existe una variable de salida ni una variable objetivo. Por tanto, el conjunto de datos sólo contiene registros de las variables de entrada.




Figura 1.5: Problema de agrupación: (a) conjunto de datos; (b) agrupación.

Existen diversas aplicaciones del análisis de clusters en los más variados campos, como la bioinformática, *marketing*, el procesamiento de imágenes, etc. Una de las aplicaciones más conocidas es la segmentación de clientes, que resulta de gran utilidad para definir estrategias de relación [530]. En este caso, las variables del conjunto de datos son características de los clientes en función de las cuales se desea realizar el análisis.

Las empresas con grandes bases de clientes, como los operadores telefónicos, utilizan el análisis de conglomerados para segmentar a los clientes, en el que las variables representan el uso de los servicios. Se pueden dirigir campañas de retención o promociones diferenciadas a grupos de clientes.

Un problema crítico en el análisis de conglomerados es la evaluación de la calidad del resultado del conglomerado, ya que la falta de una variable de salida dificulta la definición de estadísticas de desempeño. Paradójicamente, la definición del número de grupos es un insumo para la mayoría de los algoritmos. Hay varios índices en la literatura que tienen como objetivo evaluar la calidad del cluster. Sin embargo, los índices reflejan características geométricas deseables de un buen grupo y sus resultados deben ser interpretados por un analista. La experiencia del analista y la participación del experto en el dominio son fundamentales para el análisis de conglomerados.

El problema del análisis de conglomerados tiene varios enfoques diferentes y una gran cantidad de algoritmos. Hay libros completos centrados en el tema [573][194] y un enfoque completo del problema está más allá del alcance de este libro. Los enfoques principales se analizan en el Capítulo 6.

Una variante del problema de análisis de conglomerados se denomina clasificación semisupervisada [82], en la que se anota un pequeño subconjunto de datos, que se utilizará para clasificar un conjunto más grande de datos. El problema se trata como un problema de agrupación en el que se utilizan registros categorizados para ayudar a ajustar el modelo.

1.3 Recursos adicionales

Esta sección presenta un conjunto de recursos relacionados con el contenido de este libro y la ciencia de datos en general.

1.3.1 Bibliografía de referencia

La literatura en el área de la inteligencia computacional con aplicación en la ciencia de datos es bastante diversa. El enfoque estadístico para construir modelos de datos se describe ampliamente en varias referencias. Hastie, Tibshirani y Friedman¹⁰ [238] presentan un enfoque muy completo que presenta los métodos estadísticos más avanzados y clásicos.

El libro *Pattern Classification*,¹¹ de Duda y Hart [146], es un clásico en los métodos de clasificación estadística. El libro tiene un volumen correspondiente con rutinas Matlab de los principales algoritmos [507]. El libro de Theodoris y Koutroumbas¹² [521], es otra referencia sobre métodos estadísticos de clasificación y análisis de conglomerados, que también tiene un volumen con rutinas en Matlab [522]. El libro de Bishop¹³ [52] es una referencia importante en métodos estadísticos e inteligencia computacional y contiene un capítulo sobre métodos variacionales. Una referencia adicional para los métodos de clasificación estadística es el libro de Webb [553].

Sobre problemas de regresión, Montgomery [399] es una referencia clásica, en su cuarta edición. El clásico de los modelos estadísticos de series temporales y sistemas dinámicos es el libro de Box, Jenkins y Reinsel [59], que también va por su cuarta edición. Otra obra de referencia para el desarrollo de modelos dinámicos de sistemas lineales.

es el libro de Ljung¹⁴ [352], que sirvió de base para el desarrollo de la biblioteca Matlab *System Identification Toolbox*¹⁵. Schabenberger y Gotway [472] presentan una visión muy completa del análisis de datos espaciales.

Existen varias referencias clásicas sobre las principales técnicas de inteligencia computacional, como el libro de Haykin¹⁶[240][241] sobre redes neuronales y los libros de Pedrycz y Gomide [432][433] sobre teoría de conjuntos *fuzzy*. La obra de referencia sobre máquinas de vectores de soporte y métodos basados en funciones del núcleo (*kernel*) es el libro de Schölkopf y Smola¹⁷[478], que presenta una aproximación completa a los métodos y sus formulaciones matemáticas y también incluye una discusión sobre temas relacionados como la regularización y la optimización. Taylor y Cristianini¹⁸ [485], Huang, Kecman y Kopriva¹⁹ [269], y Kulkarni y Harman [326] presentan una excelente introducción a la teoría del aprendizaje estadístico. El trabajo de Vapnik [532]-[534] es la referencia teórica más completa. En su libro más reciente, Vapnik [533] ofrece una presentación simplificada de los conceptos principales de la teoría.

El problema de construir modelos a partir de datos está muy bien descrito por Cherkassky y Mulier [98], con un enfoque que destaca los puntos comunes de los distintos algoritmos de inteligencia computacional. Kecman²⁰ [301] presenta los principales algoritmos de inteligencia computacional, en los que los métodos estadísticos clásicos se condensan en el primer capítulo. La mayoría de los libros de inteligencia computacional se centran en sistemas *fuzzy*, redes neuronales y algoritmos genéticos [152][318][520].

Existen varios libros sobre minería de datos, el primero con este título fue editado por Fayyad y Piatetsky-Shapiro en 1996 [177]. El trabajo de Han y Kamber, publicado en tres ediciones [232]-[234], es también una referencia importante y tiene una presentación muy completa. Han también participa en temas sobre minería de datos geográficos [386][387] y minería de datos gráficos [582]. El libro de Tan, Steinbach y Kumar²¹ [516] es otra referencia clásica sobre minería de datos. El libro escrito por los autores de Weka²² [561] presenta los principales algoritmos de *software*.

Un libro de Zaki y Meira [593] presenta una visión muy actual y completa del tema con los principales algoritmos, además de mostrar aplicaciones en problemas complejos como minería de gráficos y secuencias. El libro de Aggarwal [5] es una referencia más completa y actualizada en el área de la ciencia de datos, presentando los fundamentos, técnicas y aplicaciones. En sus 700 páginas aborda el tema de forma muy completa,

considerando preprocesamiento, detección *outliers*, minería de datos estructurados, datos espaciales, series de tiempo, secuencias y datos no estructurados como textos y minería de *web* y redes sociales.

Mitchel²³ [392] es la referencia clásica del aprendizaje automático. El libro de Murphy de 2012 [406] presenta un enfoque muy completo del tema desde una perspectiva probabilística. Algunos libros sobre aprendizaje automático presentan un enfoque de minería de datos [14] [370] o análisis inteligente de datos [44][45].

El libro *Deep Learning*,²⁴ de Goodfellow, Bengio y Courville [212], publicado en 2016, es la referencia actual sobre algoritmos de aprendizaje profundo. El libro es muy completo y cubre desde los principios básicos del álgebra lineal, la teoría de la probabilidad y las técnicas clásicas de aprendizaje automático hasta los modelos más avanzados que se utilizan actualmente en aplicaciones de inteligencia artificial.

Liu²⁵ [348] es una referencia en temas relacionados con Internet. Los algoritmos de inteligencia computacional se han utilizado en problemas con datos no estructurados como texto, gráficos [1][43][178][502] y redes sociales [4][376]. Otras aplicaciones importantes son la bioinformática y los sistemas financieros[295].

En la literatura nacional, el libro editado por Solange Rezende en 2002 [451] reúne métodos de inteligencia computacional, minería de datos y aprendizaje automático. El trabajo, escrito por 10 autores con la participación de varios colaboradores, se mantiene vigente e incluye, además de conceptos teóricos, una serie de aplicaciones prácticas de los métodos presentados. Recientemente han aparecido algunos trabajos en el área de ciencia de datos e inteligencia computacional escritos en portugués [61][173][193][345]. Los modelos de redes neuronales están bien descritos en la traducción del libro de Haykin [241] y en el libro de Braga, Carvalho y Ludermir [62].

1.3.2 Recursos en Internet

En 2011, la Universidad de Stanford inició su programa ofreciendo cursos *online* gratuitos a través de Internet con tres cursos de informática: bases de datos, aprendizaje automático e inteligencia artificial. Los mismos cursos ofrecidos a los estudiantes de Stanford estaban disponibles gratuitamente en Internet, donde cualquiera podía registrarse y seguir clases en video. La gran diferencia entre esta iniciativa y otras formas de educación *online* es que los estudiantes registrados pueden responder preguntas,

realizar los ejercicios y exámenes propuestos (dentro del mismo entorno informático) y, al finalizar, siempre que obtengan un rendimiento adecuado, recibir un certificado de participación firmado por el profesor. Los cursos atrajeron a más de 100.000 inscritos en todo el mundo. La iniciativa generó la creación de varios repositorios de cursos *online* en universidades como Stanford²⁶ y MIT²⁷, además de empresas como Coursera²⁸ y Udacity²⁹, fundadas a principios de 2012, que exploran este mercado. El curso de aprendizaje automático de Coursera,³⁰ presentado por Andrew Ng de Stanford, cubre la mayoría de los temas tratados en este libro.

También se pueden encontrar videoclases y conferencias en VideoLectures³¹, que es una especie de YouTube académico y contiene videos sobre diversos temas. En VideoLectures podrás ver seminarios sobre temas de interés presentados por los mayores expertos en la materia. Slide Share³² y Scribd³³ también son repositorios de contenido general, el primero en formato de presentación *slides* y el segundo en formato de documento.

El principal portal de recursos de ciencia de datos en Internet es KDnuggets,³⁴ que contiene *links* para diversos recursos, como *softwares*, repositorios de datos, cursos, etc., además de ofertas de trabajo y mucha publicidad. KDnuggets fue creado en 1997 y es mantenido por Piatetsky-Shapiro, uno de los principales investigadores en el campo y coeditor del primer libro sobre minería de datos [177].

El repositorio de datos que es referencia en varios trabajos de ciencia de datos es el UCI Machine Learning Repository,³⁵ mantenido por la Universidad de California en Irvine. La UCI contiene una colección muy completa de conjuntos de datos *benchmark* para evaluar algoritmos. La UCI tiene una sección especial dedicada a las competencias de ciencia de datos de la Copa KDD propuestas en las ediciones de la conferencia Knowledge Discovery in Databases (KDD).³⁶ Actualmente, las competencias de algoritmos de ciencia de datos se han vuelto comunes a través de *site* Kaggle.³⁷

La *site* del código abierto KEEL *software*,³⁸ desarrollada por un consorcio de seis grupos de investigación españoles, pone a disposición, además de la propia *software*, algunos conjuntos de datos *benchmark*. Los datos encontrados en *site* de KEEL son esencialmente los mismos que los disponibles en UCI, pero en KEEL se pueden encontrar en particiones predefinidas, lo que permite la comparación directa entre algoritmos. La QUILLA *site* también

proporciona una amplia variedad de publicaciones y *links* para otros repositorios vinculados al área de inteligencia computacional.

Resultados recientes en las áreas de inteligencia computacional y ciencia de datos se publican en revistas de circulación internacional. En Brasil, gracias al Portal de Revistas Capes³⁹, los estudiantes de posgrado tienen acceso a las principales revistas científicas de todas las áreas. En el área de inteligencia computacional y ciencia de datos, los principales portales son Science Direct⁴⁰ (Elsevier), IEEEExplore⁴¹ (IEEE), Springer's *site*⁴² y el portal ACM Digital Library.⁴³ Las principales revistas en el área de ciencia de datos se encuentran listadas en el portal KDnuggets.⁴⁴

Investigadores del campo de la ciencia de datos organizan cada año varias conferencias internacionales sobre el tema. Los congresos más importantes del área son KDD, organizado por SIGKDD⁴⁵ e ICDM,⁴⁶ organizado por IEEE. En el área de aprendizaje automático, las conferencias más importantes son NIPS⁴⁷ (NeurIPS de 2018) e ICML⁴⁸. En el área de inteligencia computacional los congresos más importantes se organizan por especialidad. Cada cuatro años se organiza el WCCI,⁴⁹ que reúne los principales congresos del área organizados por el IEEE: sistemas FUZZ-IEEE *fuzzy*; IJCNN de redes neuronales; e IEEE CEC para informática evolutiva. Se puede obtener más información sobre eventos y publicaciones en el área en *site* de la IEEE Computational Intelligence Society.⁵⁰ En Brasil, la Asociación Brasileña de Inteligencia Computacional (ABRICOM),⁵¹ organiza el Congreso Brasileño de Inteligencia Computacional (CBIC), cada dos años.

Actualmente es posible participar en discusiones sobre diversos temas en *blogs*⁵² y perfiles de Twitter⁵³ relacionados con el área de ciencia de datos. También existen varios grupos de discusión en las redes sociales,⁵⁴ principalmente en Facebook y LinkedIn.

El desarrollo de modelos de inteligencia computacional, principalmente redes neuronales profundas, se ha beneficiado enormemente de un ecosistema abierto, con lenguajes de programación gratuitos *softwares* y abiertos, repositorios de artículos científicos como arXiv⁵⁵ y repositorios de código como GitHub.⁵⁶

Finalmente, existen repositorios de contenido genérico en Internet que contienen material sobre una variedad de temas, incluidos temas relacionados con la inteligencia computacional y la ciencia de datos. Es importante recordar que los artículos en internet no tienen ningún tipo de valoración sobre la calidad de la información y deben consultarse con precaución.

1.3.3 Softwares

Los *softwares* comerciales más utilizados son SAS (Software de Análisis Estadístico), SPSS (Paquete Estadístico para las Ciencias Sociales) y Statistica. Estos *softwares* fueron desarrollados inicialmente como paquetes estadísticos que luego incorporaron otros módulos. El paquete de minería de datos SAS⁵⁷ brinda soporte para todo el proceso, incluida la limpieza, las transformaciones de datos y los modelos. SAS también cuenta con personalización de sus módulos para diferentes sectores empresariales. IBM SPSS Modeler⁵⁸ (ex-PASW, ex-Clementine) tiene características similares a las de su competidor SAS. SAS y SPSS ofrecen una solución integrada, considerando todas las etapas del proceso, desde la adquisición de datos hasta la implementación del modelo. La adquisición de SPSS por parte de IBM muestra claramente esta tendencia. Statistica Data Miner⁵⁹ también está integrado con módulos de estadísticas y tiene una mayor variedad de algoritmos, lo que le permite optimizar modelos para un problema específico. Los resultados de los modelos Statistica también se pueden exportar en C, Java, Visual Basic y PMML. Los tres paquetes ofrecen, como módulos adicionales, funcionalidades de minería de textos.

Oracle Data Mining y Microsoft SQL Server Data Mining son bibliotecas de minería de datos que se ejecutan dentro de sus respectivas bases de datos. La ventaja de este tipo de solución es que los modelos se desarrollan directamente en la base de datos y se pueden integrar en la plataforma operativa. Los productos de Oracle y Microsoft ofrecen una variedad limitada de algoritmos, algunos de ellos propietarios que no se explican completamente en la documentación. Estos *softwares* tienen pocas características nativas para la visualización y caracterización estadística de datos. La ventaja de Oracle Data Mining es su presencia en el mercado y la integración con otros productos de Oracle y la posibilidad de integrarse directamente con programas Java y el lenguaje PLSQL de Oracle. Microsoft SQL Server Data Mining también tiene la ventaja de estar completamente integrado con la plataforma .NET de Microsoft y su costo es mucho menor. En las versiones más recientes, ambas plataformas cuentan con capacidades de minería de texto.

El desarrollo de *softwares* comercial sigue la creciente tendencia de ofrecer servicios en la nube. En este sentido, la plataforma Microsoft Azure Machine Learning⁶⁰ permite el desarrollo y *deploy* de modelos de ciencia de datos directamente desde la nube. El producto Amazon Machine Learning⁶¹ también sigue esta tendencia en la plataforma en la nube de Amazon Web Services. La API de Predicción⁶² en la plataforma en la nube de Google también es una iniciativa en esta línea.

Para las grandes corporaciones que operan en mercados altamente competitivos y manejan grandes masas de datos, la ganancia potencial de los resultados obtenidos con modelos de ciencia de datos excede el costo de adquirir y mantener paquetes comerciales [439]. Para las pequeñas y medianas empresas y, principalmente, el mundo académico, el coste de una licencia para un paquete comercial como los mencionados puede resultar prohibitivo. Existen en el mercado otros comerciales *softwares* con costes más asequibles, como PolyAnalyst,⁶³ y su variante de análisis de texto TextAnalyst⁶⁴.

Hay *softwares* gratuitos que se pueden utilizar para desarrollar soluciones sin un lenguaje de programación. El primer *software* sin minería de datos, desarrollado en 1997 en la Universidad de Waikato, fue Weka.⁶⁵ Codificado en Java, Weka es de código abierto, aunque la documentación no es la más clara. Weka contiene una gran variedad de algoritmos, con varias variedades de algoritmos de inducción de árboles y reglas de decisión. Weka también cuenta con una interfaz gráfica intuitiva y fácil de usar. En 2006, Pentaho⁶⁶ adquirió el Proyecto Weka para integrarlo en el paquete de inteligencia empresarial de la empresa. Weka continúa desarrollándose como un proyecto *software* gratuito.

RapidMiner⁶⁷ utiliza el mismo modelo de negocio que Pentaho, proporcionando *softwares* gratuito para ofrecer servicios de consultoría y capacitación. RapidMiner también está desarrollado en Java e incorpora algoritmos de otros gratuitos *softwares*, como Weka y LibSVM. RapidMiner tiene capacidades elaboradas de visualización de datos y resultados de modelos, además de permitir el desarrollo de modelados complejos *workflows*, con optimización de modelos mediante algoritmos genéticos. KNIME⁶⁸ también está desarrollado en Java e incorpora algoritmos de otros *softwares* gratuitos, como Weka y LibSVM, en una interfaz gráfica fácil de usar. KNIME tiene mejores capacidades de visualización que Weka, pero es equivalente en términos de algoritmos.

Una alternativa al estándar Java, utilizado por el *software* gratuito mencionado anteriormente, es Orange,⁶⁹ desarrollado en C++ y Python. Orange es un proyecto académico y presenta una buena variedad de algoritmos en una interfaz gráfica agradable y con buenos recursos de visualización. Orange se desarrolla a partir de una biblioteca que se proporciona junto con *software*, permitiendo el desarrollo de aplicaciones por parte del usuario.

El uso de software libre y lenguajes de programación abiertos ha impulsado el desarrollo de la ciencia de datos. Las principales bibliotecas de Python para

ciencia de datos son Pandas⁷⁰ y Scikit Learn⁷¹, que utilizan otras bibliotecas de referencia de Python como NumPy y SciPy. Python es desarrollado por una comunidad motivada y sus bibliotecas permiten el acceso a diferentes algoritmos. Hay una amplia variedad de recursos de Python en Internet.⁷²

El lenguaje R⁷³ es un proyecto *software* gratuito de la comunidad estadística con un entorno computacional y bibliotecas con una amplia variedad de rutinas para procesar, procesar y visualizar datos. Las rutinas están organizadas en paquetes para cada tema y se puede acceder a ellas a través de un lenguaje de programación simple, que también se puede utilizar para desarrollar nuevos algoritmos. Existen varias extensiones e interfaces gráficas para el lenguaje, así como empresas ⁷⁴ que brindan extensiones y consultoría. El lenguaje R se ha incorporado a *softwares* comerciales como SAS y bases de datos como Oracle.

site KDnuggets realiza periódicamente una encuesta con el objetivo de determinar los *softwares* más utilizados por los usuarios del portal. En los últimos años los lenguajes R y Python han destacado como los lenguajes más utilizados.

Un entorno informático importante en el área de la ingeniería es Matlab. ⁷⁵ Matlab es un *software* comercial que tiene un núcleo central, básicamente la ventana de comandos y bibliotecas numéricas básicas. Las funciones avanzadas de Matlab se venden como paquetes, denominados *Toolbox*, que contienen rutinas para las más diversas áreas, como biología, finanzas, sistemas de control, etc. Una configuración adecuada para el área de inteligencia computacional y ciencia de datos debe contener esencialmente los paquetes estadísticos,⁷⁶ redes neuronales⁷⁷ y algoritmos genéticos.⁷⁸ También son importantes paquetes adicionales, como optimización⁷⁹ e identificación de sistemas,⁸⁰. El paquete de programación paralela,⁸¹ que permite la ejecución de *scripts* Matlab en máquinas con procesadores multinúcleo y *clusters*, puede ser necesario en aplicaciones computacionalmente intensivas. Los programas desarrollados en Matlab se pueden integrar en la *softwares* corporativa a través de compiladores para las plataformas .NET,⁸² Java⁸³ y Excel.⁸⁴ Además de los paquetes mantenidos y desarrollados por Mathworks, existe una comunidad de usuarios activa que desarrolla rutinas y paquetes para Matlab, organizados en el repositorio central de Matlab.⁸⁵ Hay más de 1 200 libros escritos sobre Matlab o aplicaciones que lo utilizan computacionalmente. entorno.⁸⁶ Las figuras de este libro se generaron con Matlab.

1.4 Comentarios finales

Este capítulo presenta los conceptos iniciales de inteligencia computacional para la ciencia de datos y una introducción a los temas tratados en el libro. Los recursos bibliográficos representan un resumen de las principales fuentes que pueden apoyar un estudio más profundo de estos temas. Es probable que alguna referencia importante no haya sido incluida y es probable que alguna información esté desactualizada, especialmente internet y referencias *softwares*.

2 PREPROCESAMIENTO

El preprocesamiento incluye selección, limpieza y transformación de datos. El objetivo de este paso es preparar el conjunto de datos que se utilizará para ajustar el modelo, llamado conjunto de entrenamiento. En general, la etapa de preprocesamiento consume del 60% al 80 % del tiempo de todo el proceso de minería de datos y proporciona información importante que guiará el análisis y ajuste de los modelos.

Este capítulo presenta los conjuntos de datos que se encuentran en las aplicaciones de ciencia de datos. A continuación, se presentan los principales conceptos estadísticos de los métodos exploratorios necesarios para la comprensión de los datos y, principalmente, para la adecuada interpretación de los resultados de la visualización. A continuación se presentan las técnicas de limpieza de datos y transformaciones lineales más importantes. Al final se presentan algunas aplicaciones que utilizan los conceptos discutidos en el capítulo.

2.1 Conjuntos de datos

Existe una diferencia entre datos, información y conocimiento [451]. Los datos son el registro de un hecho, la información es el hecho analizado en su contexto y el conocimiento, característica inherentemente humana, es la interpretación de la información en un contexto específico con vistas a su aplicación. Por ejemplo, el precio de una acción en un momento determinado en bolsa son datos; el cambio en el precio de las acciones es información; y la interpretación de esta información en el contexto de la situación económica actual para la toma de decisiones de inversión es conocimiento.

En la Figura 2.1 se muestra una metáfora humorística que enfatiza la importancia de presentar información.




Figura 2.1: *Data Cake*. Fuente: epigraphics.com.87

Los datos utilizados en una aplicación pueden ser estructurados o no estructurados. Los datos estructurados son aquellos organizados en tablas, en las que las filas son los registros que representan las observaciones y las columnas, las variables o características observadas en cada registro, muchas veces llamados atributos. Los datos no estructurados son datos que, en su forma original, no están tabulados. Ejemplos de datos no estructurados son imágenes, sonidos, textos, estructuras gráficas, etc. En este libro, se considerarán principalmente modelos de datos estructurados. Los modelos de datos no estructurados, principalmente textos y estructuras en forma de gráficos (redes), han ido adquiriendo cada vez más importancia en la ciencia de datos [295].

Los datos estructurados se almacenan en bases de datos, desde donde se seleccionan para ajustar los modelos. En los sistemas corporativos, los datos se pueden almacenar en varias bases de datos diferentes. En este caso, la extracción de datos puede volverse extremadamente compleja y se realiza mediante procesos llamados ETL (*extract, transform and load*). En entornos más simples, la selección se realiza directamente desde la base de datos y el conjunto de datos se presenta en forma de tabla o archivo de datos.

En un conjunto de datos estructurados, cada línea o registro contiene los valores observados de un conjunto de variables. Las variables pueden ser continuas, discretas ordenadas o discretas desordenadas. Las variables continuas almacenan valores numéricos del tipo real; las variables discretas ordenadas almacenan valores enteros; mientras que las variables discretas desordenadas almacenan valores categóricos o nominales. Las variables binarias son un tipo especial de variables discretas que tienen sólo dos valores. Normalmente, un conjunto de datos puede contener variables de diferentes tipos. La mayoría de los algoritmos estadísticos y de inteligencia computacional trabajan con variables numéricas. En este caso, las variables categóricas se transforman en un conjunto de variables binarias llamadas variables indicadoras (o *dummy*).^{*} Existen algoritmos especializados en modelos de variables nominales; en general, esta área se conoce como aprendizaje simbólico [392][451].

En este libro, para facilitar el tratamiento matemático de los algoritmos, las variables se consideran numéricas (continuas o discretas) y las variables nominales se transforman en variables indicadoras binarias en el preprocesamiento.

Un conjunto de datos está representado por $\mathcal{T} = \{(\mathbf{x}(t), \mathbf{y}(t)), t = 1 \dots N\}$. Cada registro está formado por el par ordenado $(\mathbf{x}(t), \mathbf{y}(t))$, donde $\mathbf{x}(t)$ es el vector [†] que contiene los valores de las variables de entrada y $\mathbf{y}(t)$, el vector que contiene los valores de las variables objetivo o de salida. Sin pérdida de generalidad, los vectores de variables de entrada y salida se escriben como $\mathbf{x}(t) \in \mathcal{R}^p$ y $\mathbf{y}(t) \in \mathcal{R}^q$, donde p y q son, respectivamente, el número de variables de entrada y salida. Las variables nominales se codifican como variables indicadoras que, al igual que las variables enteras, son un subconjunto de variables reales.

Los problemas de salida múltiple ($q > 1$) se pueden representar como problemas de salida simples múltiples si las variables de salida están desacopladas, es decir, el valor de una salida no interfiere con el valor de otra. En este caso, se desarrolla un modelo independiente para cada salida. En los problemas descriptivos, no hay variables de salida y el conjunto de datos contiene solo variables de entrada.

^{*} Uma variável nominal com n valores é codificada com n variáveis binárias chamadas variáveis indicadoras, em que cada variável indica a observação de um valor nominal da variável original.

[†] Vetores e matrizes são grafados em negrito, vetores em letras minúsculas e matrizes em letras maiúsculas. Valores escalares são grafados em itálico. Letras maiúsculas gravadas em cursiva, como $\mathcal{A}, \mathcal{B}$ etc., indicam conjuntos. Letras gregas serão usadas para indicar parâmetros de modelos.

Algunos problemas presentan características especiales que interfieren con la interpretación del conjunto de datos. En problemas dinámicos, existe una dependencia intrínseca entre una observación y las observaciones precedentes. En este caso las variables son series de tiempo en las que los registros se presentan en secuencia y el índice $t = 1 \dots N$ representa un instante de tiempo. Los problemas en los que el orden de las observaciones no es relevante se denominan estáticos, en cuyo caso cualquier permutación de los registros en el conjunto de datos produce el mismo resultado. En los problemas georreferenciados existe una dependencia espacial entre las observaciones y cada registro está asociado a dos (o tres) variables que representan las coordenadas de observación. Los llamados problemas espaciotemporales combinan estas dos características: contienen variables espaciales y los registros se almacenan en secuencia. Este libro no aborda específicamente problemas espaciales o espaciotemporales, sólo el modelado de sistemas dinámicos lineales en el Capítulo 4.

Para la presentación matemática de los algoritmos, el conjunto de datos se representa mediante matrices. La matriz de entrada (de variables) es la matriz $\mathbf{X}$, de dimensión $N \times p$, y la matriz de salida (de variables) es la matriz $\mathbf{Y}$, de dimensión $N \times q$. Las dimensiones de las matrices indican que los registros están organizados en líneas y, para cada registro, los vectores * de variables de entrada y salida.

La notación presentada anteriormente se utilizará a lo largo del libro. Esta notación unifica y facilita la comprensión de algoritmos y la transposición de conceptos de modelos lineales a modelos no lineales.

La siguiente sección presenta el primer paso en la exploración de datos: caracterización y visualización de datos.

2.2 Caracterización estadística

La caracterización estadística de los datos es uno de los pasos más importantes en la ciencia de datos. Esta fase permite la comprensión de los datos y facilita el análisis de los resultados de los algoritmos.

* Matematicamente, um vetor é uma lista de valores e pode ser tratado como linha ou coluna na multiplicação com matrizes. Neste livro são utilizados vetores linha.

Estadísticamente, un conjunto de datos se trata como una muestra de un proceso estocástico, es decir, un proceso cuyo comportamiento es impredecible, pero que puede describirse estadísticamente mediante una función de distribución de probabilidad. El concepto de muestra es muy importante en la ciencia de datos, ya que los modelos se ajustarán en función de una muestra y no del proceso estocástico. Esta es una diferencia importante entre el enfoque de inteligencia computacional y el enfoque estadístico, en el que generalmente se busca el modelado del proceso [98], basado en una hipótesis sobre la distribución de probabilidades.

La mayoría de los algoritmos de ciencia de datos asumen implícitamente que el proceso que generó la muestra representada por el conjunto de datos es estacionario, es decir, no varía con el tiempo. De esta forma, podemos utilizar un conjunto de datos recopilados en un momento determinado para hacer predicciones en otro momento, ya que el proceso sigue siendo el mismo entre el momento de la recopilación de la muestra y la predicción. Sin embargo, esta hipótesis puede no ser cierta y, en este caso, los modelos no tendrán buenos resultados de predicción. Este suele ser el caso cuando se modelan procesos altamente complejos, como los mercados financieros. La caracterización y modelado de problemas dinámicos se cubrirán en el Capítulo 4. En este capítulo, se presenta la caracterización y visualización de datos de problemas estáticos.

2.2.1 Análisis de una sola variable

El primer paso en la caracterización estadística de una muestra es el cálculo de las estadísticas de las variables. Un estadístico es cualquier función obtenida de una muestra. Las estadísticas de muestra, en general, se calculan para las variables de entrada del conjunto de datos, pero también se pueden calcular para las variables de salida. Las principales estadísticas son:

media, una medida del valor central de la muestra:

$$\mu \approx \bar{x}_i = \frac{1}{N} \sum_{t=1}^N x_i(t), i = 1 \dots p \quad (2.1)$$

varianza, una medida de la dispersión de la muestra:

$$Var(x_i) \approx \hat{\sigma}_i^2 = \frac{1}{N-1} \sum_{t=1}^N (x_i(t) - \bar{x}_i)^2, i = 1 \dots p \quad (2.2)$$

La desviación estándar estimada de la variable $\hat{\sigma}_i \approx \sqrt{Var(x_i)}$ se utiliza comúnmente para caracterizar la dispersión de una variable, ya que su valor tiene la escala de la variable.

En muestras muy grandes de procesos estacionarios, la media muestral es una buena estimación de la media del proceso. Este resultado se conoce en estadística como la “ley de los grandes números”. Asimismo, la varianza de la muestra converge a la varianza del proceso con el aumento en el número de registros de muestra. En conjuntos de datos pequeños, se debe tener cuidado al utilizar estas estadísticas como estimaciones de sus contrapartes de proceso.

La media y la varianza son los parámetros que definen la función de densidad de probabilidad normal $N(\mu, \sigma^2)$, calculada como:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \quad (2.3)$$

La Figura 2.2a presenta ejemplos de distribución normal con diferentes valores de media y desviación estándar (σ). Cuanto mayor es la desviación estándar, mayor es la dispersión de los datos y, en consecuencia, menor es la probabilidad de la media. En la Figura 2.2b, las funciones de distribución de probabilidad acumulada de los ejemplos que se muestran en la Figura 2.2a.




Figura 2.2: Distribución normal: (a) función de densidad de probabilidad; (b) función de probabilidad acumulada. Fuente: Wikipedia.88

La función de distribución de probabilidad normal, o simplemente distribución normal, es muy importante en estadística. Uno de los principales resultados de la distribución normal es el teorema del límite central. El teorema establece que la distribución de la media de muestras de procesos estacionarios generadas con cualquier distribución, con media y varianza constantes, converge a una distribución normal con la media del proceso.

La distribución normal está representada matemáticamente por una función gaussiana que tiene varias propiedades y se utiliza en innumerables aplicaciones. En inteligencia computacional, la función gaussiana aparece como una función base para el desarrollo de varios tipos de modelos, como se presentará en el Capítulo 7.

Otras estadísticas importantes para la caracterización de datos son:

valores extremos: mínimo y máximo; la mediana: es el valor que divide el conjunto de datos en subconjuntos iguales, es decir, el 50% de los registros son mayores que la mediana, el 50% son menores que la mediana. La mediana es el percentil 50 de la muestra; el percentil P es el valor que divide el conjunto de datos de modo que $P\%$ de los registros sean menores o iguales a este valor; el rango intercuartil es el intervalo entre el percentil 25 y el percentil 75, denominados respectivamente primer cuartil ($Q1$) y tercer cuartil ($Q3$), siendo la mediana el segundo cuartil ($Q2$); la moda, calculada sólo para variables discretas, es el valor observado con mayor frecuencia.

La mediana es una medida de centralidad muestral que es insensible a distribuciones asimétricas. La media puede dar una idea engañosa del valor central de un conjunto de datos en presencia de valores atípicos (*outliers*) o distribuciones sesgadas. La comparación entre la media y la mediana permite detectar fácilmente asimetrías en la distribución de los datos. Las distribuciones asimétricas pueden generar modelos sesgados. Asimismo, las medidas de dispersión dependen de la forma de la distribución. La varianza muestral sólo tiene sentido en distribuciones simétricas; en el caso de distribuciones asimétricas se debe utilizar el rango intercuartil.

La Tabla 2.1 presenta los resultados de las estadísticas para las variables de entrada del conjunto de datos de la flor Iris. Comparando los valores medio y mediano

(percentil 50), se nota una asimetría en la distribución de la variable x_3 . Al evaluar las estadísticas, es importante tener en cuenta la escala de las variables. En el caso de Iris Flowers, todas las variables representan una medida en centímetros y, por tanto, es posible comparar directamente los valores de diferentes variables. En el caso general, cuando las variables representan medidas diferentes, se recomienda que el análisis se realice sobre variables estandarizadas (cf. sección 2.3.1).

Tabla 2.1: Estadísticas básicas del problema Iris

	x_1	x_2	x_3	x_4
Mínimos	43,0	20,0	10,0	1,0
Máximos	79,0	44,0	69,0	25,0
Médias	58,4	30,6	37,6	12,0
Desvios	8,3	4,4	17,7	7,6
Percentil 25	51,0	28,0	16,0	3,0
Percentil 50	58,0	30,0	43,5	13,0
Percentil 75	64,0	33,0	51,0	18,0

En problemas de clasificación es interesante evaluar variables por clase. El gráfico de líneas permite una evaluación visual de las diferencias entre los registros de cada variable por clase y puede ayudar a identificar las variables más relevantes para la separación de clases. En el gráfico de líneas, cada variable es un valor en el eje horizontal y cada registro es una línea que conecta las variables en su valor correspondiente. La Figura 2.3 muestra un ejemplo de un gráfico de líneas para el conjunto de datos Iris con variables estandarizadas (consulte la sección 2.3.1). Podemos observar que las clases se pueden separar mejor en el plano formado por las variables x_3 y x_4 . Esta misma conclusión será confirmada por otros tipos de gráficos mostrados.




Figura 2.3: Gráficos lineales del problema del iris.

Existen varias funciones de distribución de probabilidad⁸⁹, con aplicaciones en diferentes áreas. La distribución de cada variable se puede evaluar cualitativamente mediante histogramas o diagramas de frecuencia. Un histograma es una representación gráfica de la distribución de probabilidad de la variable (cf. Figura 2.4). Existen varios métodos estadísticos para ajustar la función de distribución de probabilidad [146][238], así como libros completos dedicados al tema [482][490].




Figura 2.4: Histogramas y ajuste de distribución.

Las técnicas de inteligencia computacional generalmente no toman en cuenta hipótesis sobre la distribución de probabilidad que generó la muestra. Sin embargo, el análisis de histogramas es esencial para comprender los datos y respaldar el análisis de los resultados del modelo. La evaluación visual de los histogramas puede revelar características indeseables en la distribución de datos, como asimetría y distribuciones multimodales (cf. Figura 2.5). En estos casos, las estimaciones de la media y la desviación estándar pueden perder completamente su significado.




Figura 2.5: Histogramas: (a) distribución asimétrica; (b) distribución multimodal.

En problemas de clasificación se pueden calcular histogramas por clase, lo que permite analizar la distribución de cada clase en el universo de la variable. Los histogramas separados por or clases de las variables en el conjunto de datos Iris se muestran en la Figura 2.6. En este ejemplo, los datos están más mezclados en las variables x_1 y x_2 que en las variables x_3 y x_4 , como se ve en el gráfico lineal de la Figura 2.3. Las variables x_3 y x_4 presentan un comportamiento multimodal. Sin embargo, al separar por clases se verifica que cada concentración de datos corresponde a una clase, lo que puede ser de gran utilidad para construir clasificadores.




Figura 2.6: Histogramas de distribuciones de variables por clase en el problema Iris.

Es posible comprobar cualitativamente si una muestra fue generada mediante un proceso de distribución normal a través del gráfico de probabilidad normal. En este tipo de gráfico, si la muestra fue generada por un proceso de distribución normal, los puntos aparecen alineados; en el caso de una distribución no normal, hay una curvatura en el gráfico. La Figura 2.7 presenta los histogramas de una muestra de dos variables y las respectivas gráficas de distribución normal. Las figuras 2.7a y 2.7c muestran la distribución de una