




INTELIGÊNCIA COMPUTACIONAL

Fundamentos e aplicações

Alexandre G. Evsukoff


INTELIGÊNCIA COMPUTACIONAL

Fundamentos e aplicações

Alexandre G. Evsukoff

Rio de Janeiro, 2020

 **e-papers**



Este trabalho está licenciado sob a Licença Atribuição-NãoComercial-SemDerivações 4.0 Internacional Creative Commons. Para visualizar uma cópia desta licença, visite <http://creativecommons.org/licenses/by-nc-nd/4.0/> ou mande uma carta para Creative Commons, PO Box 1866, Mountain View, CA 94042, USA.

ISBN 978-65-87065-02-1

Ilustração de capa

Matriz de correlação do conjunto de dados Sonar, elaborada pelo autor

Diagramação

Ana Claudia Ribeiro

Revisão

Rodrigo Reis

Disponível no site da Editora E-papers

<http://www.e-papers.com.br>

Avenida das Américas, 3.200 bloco 1 sala 138

Barra da Tijuca – Rio de Janeiro – Brasil

CEP 22.640-102

CIP-Brasil. Catalogação na fonte
Sindicato Nacional dos Editores de Livros, RJ

E94i

Evsukoff, Alexandre

Inteligência computacional : Fundamentos e aplicações [recurso eletrônico] / Alexandre Evsukoff. - 1. ed. - Rio de Janeiro : E-papers, 2020.
recurso digital : il. ; 20 MB

Formato: eletrônico

Requisitos do sistema:

Modo de acesso: world wide web

Inclui bibliografia

ISBN 978-65-87065-02-1 (recurso eletrônico)

1. Inteligência computacional. 2. Redes neurais (Computação). 3. Livros eletrônicos. I. Título.

20-64566

CDD: 006.3

CDU: 004.8

Sumário

APRESENTAÇÃO	8
1 INTRODUÇÃO	9
1.1 CIÊNCIA DE DADOS	12
1.2 TIPOS DE MODELOS	15
1.2.1 Regressão.....	16
1.2.2 Classificação.....	18
1.2.3 Análise de agrupamentos	20
1.3 RECURSOS COMPLEMENTARES	21
1.3.1 Bibliografia de referência	21
1.3.2 Recursos na internet.....	23
1.3.3 Softwares	26
1.4 COMENTÁRIOS FINAIS	29
2 PRÉ-PROCESSAMENTO	30
2.1 CONJUNTOS DE DADOS	30
2.2 CARACTERIZAÇÃO ESTATÍSTICA	33
2.2.1 Análise monovariável	34
2.2.2 Análise multivariada	40
2.2.3 Matriz de distâncias e similaridades.....	44
2.3 LIMPEZA DE DADOS	47
2.3.1 Padronização de variáveis.....	48
2.3.2 Detecção de outliers.....	49
2.3.3 Valores ausentes.....	53
2.4 TRANSFORMAÇÕES LINEARES.....	56
2.4.1 Análise de componentes principais	57
2.4.2 Decomposição em valores singulares	62
2.4.3 Análise discriminante linear	63
2.4.4 Análise de correlação canônica	66
2.5 APLICAÇÕES	69
2.5.1 Padrões de mobilidade	69
2.5.2 Equações de paridade	72
2.6 COMENTÁRIOS FINAIS	76

3	REGRESSÃO LINEAR	78
3.1	O PROBLEMA DE REGRESSÃO.....	79
3.1.1	O Modelo linear	81
3.1.2	Método dos mínimos quadrados	82
3.1.3	Interpretação geométrica	84
3.1.4	Exemplo sintético	86
3.2	REGULARIZAÇÃO	89
3.2.1	Bias e variância.....	90
3.2.2	Regularização de Tikhonov.....	93
3.2.3	Regularização por componentes principais	97
3.3	VALIDAÇÃO DE MODELOS	98
3.3.1	Estatísticas de validação	99
3.3.2	Validação cruzada	104
3.4	APLICAÇÕES	106
3.4.1	Conjunto de dados Pollution	106
3.4.2	Previsão da elevação adiabática de temperatura do concreto.....	110
3.5	COMENTÁRIOS FINAIS	114
4	MODELOS DINÂMICOS	116
4.1	AUTOCOVARIÂNCIA E AUTOCORRELAÇÃO.....	117
4.2	MODELOS DE SÉRIES TEMPORAIS	121
4.2.1	Modelo AR.....	122
4.2.2	Modelo MA.....	126
4.2.3	Estruturas mistas	129
4.3	SISTEMAS DINÂMICOS LINEARES	131
4.3.1	Modelo ARX.....	133
4.3.2	Modelo ARMAX.....	135
4.3.3	Modelo OE.....	136
4.3.4	Modelo Box & Jenkins.....	138
4.3.5	Equações de estado	139
4.4	APLICAÇÕES	140
4.4.1	Wolf's sunspot numbers.....	140
4.4.2	Modelo chuva-vazão	142
4.5	COMENTÁRIOS FINAIS	146
5	CLASSIFICAÇÃO	148
5.1	CLASSIFICAÇÃO BAYESIANA	149
5.1.1	Decisão bayesiana	149
5.1.2	Classificador bayesiano simples	155
5.1.3	Classificador bayesiano quadrático.....	160

5.2	MODELOS LINEARES DE CLASSIFICAÇÃO.....	164
5.2.1	Mínimos quadrados.....	164
5.2.2	Mínimos quadrados ponderados.....	166
5.2.3	Regressão logística	168
5.3	AVALIAÇÃO DE CLASSIFICADORES.....	171
5.3.1	Estatísticas de validação	172
5.3.2	Espaço ROC e AUC.....	175
5.4	APLICAÇÕES	179
5.4.1	Testes benchmark.....	179
5.4.2	Análise de cancelamento em telefonia.....	183
5.5	COMENTÁRIOS FINAIS	187
6	ANÁLISE DE AGRUPAMENTOS	189
6.1	O PROBLEMA DE ANÁLISE DE AGRUPAMENTOS.....	190
6.2	MÉTODOS DE PARTIÇÃO	194
6.2.1	Algoritmo k-médias.....	194
6.2.2	Exemplos.....	198
6.3	MÉTODOS HIERÁRQUICOS	201
6.3.1	Algoritmos aglomerativos	202
6.3.2	Exemplos.....	203
6.4	PARTICIONAMENTO DE GRAFOS.....	204
6.4.1	Algoritmos de agrupamento espectral	210
6.4.2	Exemplos.....	216
6.5	VALIDAÇÃO DE GRUPOS	218
6.5.1	Medidas externas.....	218
6.5.2	Medidas internas	220
6.5.3	Medidas relativas	222
6.6	APLICAÇÕES	227
6.6.1	Segmentação de imagens de satélite	227
6.6.2	Agrupamento de documentos.....	230
6.7	COMENTÁRIOS FINAIS	234
7	MODELOS LINEARES LOCAIS.....	236
7.1	APRENDIZADO DE MÁQUINAS.....	237
7.2	MODELOS DE BASE RADIAL (RBF)	241
7.2.1	Aproximação de funções	242
7.2.2	Modelos RBF.....	246
7.2.3	Ajuste de parâmetros	250
7.3	MÁQUINAS DE VETOR DE SUPORTE	253
7.3.1	Funções de núcleo.....	253
7.3.2	Minimização do risco estrutural.....	258

7.3.3	Classificadores de máxima margem.....	262
7.4	APLICAÇÕES	273
7.4.1	Testes benchmark.....	273
7.4.2	Algoritmo da decomposição espectral.....	274
7.5	COMENTÁRIOS FINAIS	278
8	SISTEMAS FUZZY	280
8.1	CONJUNTOS FUZZY	282
8.1.1	Funções de pertinência.....	285
8.1.2	Operadores fuzzy.....	289
8.1.3	Relações fuzzy.....	293
8.2	MODELOS DE REGRAS FUZZY	294
8.2.1	Variáveis linguísticas.....	295
8.2.2	Cálculo de regras fuzzy	298
8.2.3	Sistemas fuzzy simbólicos	304
8.3	ALGORITMOS PARA CIÊNCIA DE DADOS	313
8.3.1	Fuzzy c-médias	313
8.3.2	Fuzzy pattern matching.....	317
8.3.3	Algoritmo de Wang & Mendel.....	322
8.3.4	Modelo fuzzy-RBF	326
8.4	APLICAÇÕES	329
8.4.1	Testes benchmark.....	329
8.4.2	Diagnóstico de falhas.....	331
8.4.3	Classificação espacial.....	336
8.4.4	Modelo chuva-vazão	339
8.5	COMENTÁRIOS FINAIS	344
9	REDES NEURAIIS	346
9.1	REDES NEURAIIS LINEARES.....	350
9.1.1	Perceptron e ADALINE.....	352
9.1.2	Método do gradiente.....	356
9.1.3	Gradiente estocástico	360
9.2	REDES NEURAIIS NÃO LINEARES	362
9.2.1	Perceptron de Múltiplas Camadas (MLP).....	362
9.2.2	Avaliação pelo máximo da verossimilhança.....	368
9.2.3	Algoritmo da retropropagação.....	374
9.3	REDES NEURAIIS PROFUNDAS.....	388
9.3.1	Redes neurais convolucionais	391
9.3.2	Redes neurais recorrentes	411
9.3.3	Aprendizado da representação	439
9.4	APLICAÇÕES	452

9.4.1	Previsão de inadimplência	452
9.4.2	Previsão de emissões de combustível	455
9.4.3	Previsão de demanda de energia elétrica.....	458
9.4.4	Previsão de mercado financeiro	465
9.5	COMENTÁRIOS FINAIS	470
REFERÊNCIAS BIBLIOGRÁFICAS.....		471
REFERÊNCIAS NA INTERNET.....		521

Apresentação

A **inteligência computacional** é um conjunto de paradigmas computacionais para o desenvolvimento e aplicação de sistemas inteligentes em problemas complexos do mundo real. A **ciência de dados** reúne o conhecimento de matemática, estatística, computação e engenharia com o conhecimento do domínio de cada aplicação.

A ubiquidade dos dados na era digital faz a ciência de dados ter aplicações em todas as áreas de engenharia e, cada vez mais, em ciências naturais, biológicas e humanas. Este livro apresenta uma introdução às principais técnicas e modelos de inteligência computacional em aplicações de ciência de dados. O livro aborda os fundamentos para a preparação de dados, ajustes de modelos preditivos e descritivos e apresenta aplicações em engenharia, resultados dos projetos realizados na Coppe/UFRJ. O material pode ser utilizado como livro-texto em disciplinas de graduação e pós-graduação.

O livro é dividido em nove capítulos. Os cinco primeiros contêm uma introdução às técnicas de estatística através da apresentação dos principais métodos de regressão linear, sistemas dinâmicos, classificação e análise de agrupamentos. O Capítulo 7 discute teoricamente o problema de aproximação de funções e apresenta os modelos de função de base radial (RBF) e máquinas de vetor de suporte (SVM). O Capítulo 8 apresenta os sistemas *fuzzy* e o Capítulo 9, os modelos de redes neurais com uma introdução aos modelos recentes de redes neurais profundas.

1 INTRODUÇÃO

A capacidade de uma máquina exibir um comportamento inteligente foi objeto de reflexão filosófica durante muito tempo. Na década de 1920, Wittgenstein abordou o tema a partir da questão “pode uma máquina pensar?” A sua conclusão foi que, assim como a consciência, pensar é uma capacidade inerentemente humana [483]. Em 1950, tendo em vista a dificuldade de definir “pensar” e “inteligência”, Alan Turing propôs um teste para verificar se um computador pode exibir um comportamento inteligente [529]. O teste de Turing¹ é proposto como um jogo em que um avaliador isolado numa sala é colocado em contato com um interlocutor em outra sala, que pode ser humano ou computador. Se o avaliador não puder identificar se o interlocutor é um computador, então pode-se concluir que o computador tem um comportamento inteligente.

A inteligência artificial como área de pesquisa surgiu alguns anos mais tarde, como uma proposta de integração de lógica, ciência da computação e neurofisiologia para o desenvolvimento de máquinas inteligentes. No início da década de 1960, as duas principais correntes para o desenvolvimento de inteligência artificial eram chamadas de simbolistas e conexionistas. A corrente simbolista era formada por lógicos matemáticos que desenvolveram os primeiros provadores de teoremas. Na corrente conexionista, o objetivo era simular o processamento cerebral com neurônios artificiais. Os resultados iniciais do algoritmo de aprendizado do Perceptron [457] geraram grande expectativa com a possibilidade de construção de cérebros artificiais, mas sua limitação como classificador linear não permitia o ajuste de modelos mais complexos.

Ao longo da década de 1970, os computadores *mainframe* se difundiram como produtos para a automação do processamento de dados em organizações. Os provadores de teorema evoluíram para os sistemas especialistas, que continham um motor de raciocínio que processava o conhecimento representado por um conjunto de regras e fatos. Logo ficou claro que a aquisição do conhecimento dos especialistas não era uma tarefa trivial, o que fomentou o interesse por técnicas de **aprendizado de máquina** (*machine learning*) para sínteses de modelos diretamente a partir de dados. O algoritmo ID3 de indução de árvores de decisão foi apresentado em 1986 por Quinlan. O ID3 tinha a capacidade de abstrair um conjunto de regras lógicas a partir de dados de variáveis nominais. O artigo inaugurou a revista *Machine Learning* [445].

Os modelos conexionistas retornariam com grande impacto em 1986 a partir da publicação de artigo na revista *Nature* [464] que apresentava um algoritmo de treinamento de redes neurais de múltiplas camadas baseado na retropropagação do erro através das camadas. Os resultados mostravam a capacidade do método na solução de problemas complexos de reconhecimento de padrões, como a identificação de dígitos manuscritos. As redes neurais se desenvolveram rapidamente devido a sua capacidade de ajuste de modelos não lineares computacionalmente robustos, com bons resultados em diversas aplicações. Na década de 1980, a introdução do IBM PC marca o início da difusão de computadores pessoais para o grande público e empresas de pequeno porte.

Nas décadas de 1980 e 1990, houve grande avanço na área de inteligência artificial, com o desenvolvimento de novos paradigmas computacionais como os sistemas *fuzzy*, redes neurais e máquinas de vetor de suporte. A integração destes modelos em abordagens híbridas, incluindo a utilização de algoritmos evolucionários para otimização, foi chamada de computação macia (*soft computing*) ou **inteligência computacional** (*computational intelligence*). Atualmente, a inteligência computacional inclui também métodos estatísticos e de aprendizado de máquina.²

Na década de 1990, os computadores pessoais já haviam se tornado um produto de uso comum e, na virada para o ano 2000, aproximadamente 30% da população dos EUA e da Europa estava conectada à internet.³ A expectativa com o desenvolvimento da internet foi enorme no final da década de 1990, o que resultou na chamada bolha da internet,⁴ que estourou em 2000 e provocou a queda das cotações das ações negociadas na bolsa de tecnologia NASDAQ. A partir da bolha “.com”, a competição ficou mais intensa e a internet se tornou um mercado mais maduro, dominado por grandes *players*.

Ao longo da década de 1990, o termo **mineração de dados** (*data mining*) começou a se difundir como um conjunto de técnicas que incluem estatística, aprendizado de máquina, inteligência computacional, bancos de dados, entre outras, para o desenvolvimento de modelos a partir de dados. Em 1997, surgiu a primeira plataforma de código livre de mineração de dados, o Weka,⁵ desenvolvido na Universidade de Waikato, Nova Zelândia, tornando-se uma referência no mundo acadêmico. A partir de 2000, cada vez mais *softwares* comerciais e bibliotecas oferecem novos algoritmos.⁶ Ao longo da década de 2000, as plataformas começaram a se apresentar no mercado como soluções de inteligência analítica [329], com foco em análise de dados e alinhamento dos resultados com os objetivos do negócio.

A redução de custos de armazenamento, o desenvolvimento dos processadores e a internet alavancaram o processo de coleta e armazenamento de bases de dados. O começo do século XXI marca o início da predominância do armazenamento de dados em formato digital sobre as tecnologias analógicas. O tráfego de dados na internet aumentou exponencialmente com a disseminação de dispositivos móveis a partir de 2007. Em 2010, o termo *big data* aparece como uma *buzzword* para definir o conjunto de tecnologias para coletar, armazenar, processar, analisar e visualizar grandes bases de dados.

A internet permite a oferta de produtos e serviços a um número virtualmente ilimitado de usuários numa rede livre de escala [29]. Nos últimos anos, novos modelos de negócios ou novas versões de negócios tradicionais escaláveis globalmente mudaram a vida de milhares de pessoas. Empresas como IBM, Apple, Microsoft, Google, Amazon e Facebook utilizam extensivamente algoritmos de inteligência computacional em seus negócios. Novos negócios prosperam rapidamente em todas as áreas com a evolução da tecnologia de sensores e o desenvolvimento da internet das coisas.

A partir de 2012 modelos de redes neurais profundas* [212][333] têm obtido excelentes resultados em problemas complexos de reconhecimento de padrões. Os modelos são processados em hardware massivamente paralelo com unidades de processamento gráfico (GPUs), que têm alta capacidade de processamento e baixo consumo de energia em relação aos processadores convencionais (CPUs). Modelos de redes neurais profundas em problemas de visão computacional e processamento de linguagem natu-

* *Deep neural networks.*

ral têm obtido resultados comparáveis, e até superiores, aos de humanos. Estes resultados têm gerado grande expectativa em relação ao potencial de inteligência computacional para ciência de dados. O assunto é vasto e tem se expandido rapidamente. Este livro corresponde a uma formação básica no tema incluindo aplicações desenvolvidas em diferentes áreas.

Este capítulo apresenta uma introdução dos principais tipos de problemas em aplicações reais que serão abordados no livro. A seguir, um resumo da bibliografia e das principais ferramentas disponíveis, tanto comerciais como de código aberto.

1.1 Ciência de Dados

No método científico clássico, hipóteses teóricas levam ao desenvolvimento de modelos, que devem ser verificados pela observação do fenômeno. Nas ciências exatas, o modelo é representado por fórmulas matemáticas que codificam o conhecimento sobre o fenômeno [451]. O notável desenvolvimento da computação no século XX permitiu a modelagem e simulação de fenômenos altamente complexos, gerando enormes avanços na representação da realidade e na sua utilização para a tomada de decisões.

Os parâmetros dos modelos devem ser ajustados por dados observados para que o modelo seja efetivamente a representação da realidade. No entanto, esses dados, mesmo quando obtidos em condições experimentais controladas, contêm erros e incertezas devidos a imperfeições nos instrumentos e, principalmente, à dificuldade ou impossibilidade da observação do fenômeno modelado [419].

A realidade, muitas vezes, é bem mais complexa que qualquer teoria e, em alguns casos, não há um modelo físico capaz de descrever adequadamente um determinado fenômeno. A ciência de dados é um conjunto de métodos para coleta, armazenamento, processamento, análise e visualização de dados. O objetivo é o desenvolvimento de modelos diretamente a partir de dados, sem hipóteses teóricas. Em geral, os dados são obtidos de forma não controlada, sem o planejamento de experimentos ou o conhecimento da representatividade da amostra.

Os dados observados correspondem sempre a uma amostra do processo, obtida em condições específicas que determinam a sua validade. Um modelo obtido a partir de

uma amostra é uma representação dos dados da amostra e, portanto, uma representação indireta do processo real que produziu os dados. A validade do modelo é sempre limitada pela qualidade da amostra.

A **ciência de dados** (*data science*) se situa na intercessão do conhecimento de matemática, estatística, computação e engenharia com o conhecimento do domínio e dos dados de cada aplicação. A ubiquidade dos dados na era digital faz a ciência de dados ter aplicações em todos os setores, além de ser utilizada cada vez mais em problemas de ciências humanas, naturais e biológicas [295].

A integração de diversas disciplinas necessárias para lidar com grandes bases de dados era chamada de mineração de dados durante a década de 1990, mas passou a ser conhecida como ciência de dados principalmente a partir de 2010. Os dois termos são utilizados frequentemente com o significado similar. Podemos considerar que ciência de dados se refere ao conhecimento necessário, enquanto mineração de dados se refere ao processo de desenvolvimento de modelos a partir de dados.

A descoberta de conhecimento de bases de dados (KDD)*, ou simplesmente, mineração de dados, é um processo cíclico, de forma que, se os objetivos não forem atingidos, uma nova iteração deve ser realizada, refinando os resultados ou utilizando novos dados/ferramentas. A Figura 1.1 ilustra o processo de mineração de dados com seus possíveis ciclos e iterações.




Figura 1.1: O processo de mineração de dados.

* *Knowledge Discovering in Databases*

A coleta e o armazenamento de dados, que aparece condensada na Figura 1.1, é um elemento extremamente importante do processo, principalmente para grandes corporações, que têm uma infraestrutura complexa de tecnologia da informação (TI). O processo começa com a seleção de um subconjunto de dados para ser utilizado para o ajuste de modelos. Esse conjunto de dados, chamado de conjunto de treinamento, é uma amostra considerada válida, podendo ser, dependendo do caso, a própria base de dados. Os dados do conjunto de treinamento são utilizados para o desenvolvimento do modelo. Durante o processo de construção do modelo, o conjunto de dados é particionado para o ajuste de parâmetros e a validação dos resultados.

A etapa de seleção de dados inclui o importante processo de escolha/seleção de variáveis, que pode ser feita a partir do conhecimento de especialistas ou de forma automática. Uma base de dado frequentemente possui valores ausentes e valores extremos ou outliers, que devem ser removidos para não prejudicar o ajuste do modelo.

O entendimento da aplicação e a clareza nos objetivos finais a serem atingidos são fundamentais para o sucesso de uma aplicação e a participação de especialistas do domínio é muito importante. O cientista de dados deve identificar os requisitos da aplicação, desenvolver e avaliar os resultados dos modelos, escolher o(s) modelo(s) mais adequado e coordenar a sua implantação.

O entendimento dos dados é realizado a partir da caracterização estatística e de técnicas de visualização. Esta etapa é importante para o desenvolvimento do modelo e será discutida no Capítulo 2. O pré-processamento dos dados com as principais técnicas de transformação linear também são apresentadas no Capítulo 2.

A principal etapa da mineração de dados é a geração dos modelos. Grande parte do conteúdo deste livro é orientada para o desenvolvimento e a análise dos resultados de modelos. Nos Capítulos 3 ao 6 são abordados os fundamentos estatísticos dos problemas de regressão, classificação e análise de agrupamentos. Os Capítulos 7 a 9 apresentam os principais métodos não lineares de inteligência computacional.

É importante avaliar corretamente o desempenho do modelo antes que a solução seja implantada. A qualidade dos modelos é avaliada através de estatísticas de validação, cujo objetivo é verificar se os requisitos da modelagem foram atingidos. Diversas estatísticas evidenciam diferentes características dos modelos e serão discutidas na parte de fundamentos.

A próxima seção apresenta os principais tipos de modelos que serão tratados neste livro. Na prática os problemas nem sempre se apresentam de forma clara. É importante entender corretamente as características dos problemas típicos para poder desenvolver uma solução específica num caso mais complexo.

1.2 Tipos de Modelos

A palavra “modelo” é utilizada em diversas áreas com conceitos diferentes e é importante definir claramente o que se entende por um modelo. O dicionário *Aurélio*⁷ define modelo como algo “que serve como objeto de imitação” ou, no contexto matemático, como uma “representação matemática de um fenômeno”. Neste livro, um modelo é uma representação simplificada de um sistema ou processo real obtida a partir dos dados da amostra. Os modelos de ciência de dados representam apenas a porção do processo que foi capturada pelos dados. Essa constatação, apesar de óbvia, é muito importante pois o modelo pode não ser capaz de prever corretamente o comportamento que não está representado nos dados de treinamento.

Um modelo, entendido como representação matemática de um processo real, pode ser classificado segundo a natureza do conhecimento empregado para a sua construção como **modelo de conhecimento** ou **modelo de comportamento**. Nos modelos de conhecimento (ou analíticos), as relações que descrevem o comportamento do sistema são escritas a partir das leis fundamentais da física ou do conhecimento humano. Nos modelos de comportamento (ou de entrada/saída), as relações que descrevem o comportamento do sistema são obtidas diretamente através da observação dos dados de entrada e saída. Os modelos de ciência de dados são essencialmente modelos de comportamento, embora o conhecimento do especialista do domínio e o conhecimento do analista sejam essenciais para o desenvolvimento de bons modelos.

As aplicações em ciência de dados são orientadas a problemas preditivos ou descritivos. Os problemas preditivos utilizam dados observados em variáveis de saída (variáveis dependentes), cujos valores são preditos pelo modelo a partir das variáveis de entrada (variáveis independentes). Nesse caso, o modelo realiza uma aproximação do mapeamento de entrada e saída observado. Nos problemas descritivos não há variáveis de saída e o objetivo do modelo é uma representação dos dados de entrada. Os modelos preditivos são ajustados por algoritmos de **aprendizado supervisionado**, enquanto

modelos descritivos são ajustados por algoritmos de **aprendizado não supervisionado**. Há também algoritmos de **aprendizado por reforço**, em que o modelo é ajustado diretamente através de sua interação com o ambiente. Esta abordagem é muito utilizada em problemas de controle e para o treinamento de agentes inteligentes.

Os problemas preditivos usuais são a classificação e a regressão. Na classificação, também chamada de classificação supervisionada ou reconhecimento de padrões, a variável de saída é uma classe, em geral uma variável discreta e não ordenada. Na regressão, a variável de saída é numérica, em geral um número real. Os dois problemas são, na verdade, similares e os modelos de inteligência computacional podem ser utilizados para a solução de ambos.

Em problemas descritivos, o objetivo do modelo é realizar uma descrição do conjunto de dados. Os principais problemas descritivos são análise de agrupamentos e regras de associação. A análise de agrupamentos, também chamada de classificação não supervisionada ou segmentação, utiliza diversos algoritmos para encontrar grupos de registros similares em grandes bases de dados. Algoritmos de regras de associação são muito utilizados em problemas descritivos cujo objetivo é encontrar itens que se relacionam na base de dados, como na análise de cestas de mercado e sistemas de recomendação. Recentemente, novos algoritmos de aprendizado não supervisionado têm surgido como **aprendizado da representação** em que o objetivo do modelo é produzir uma representação da entrada.

As técnicas de combinação de modelos, chamadas de *ensemble*, permitem o aumento do desempenho de modelos [150][475][604]. Em problemas preditivos, os melhores resultados do Prêmio Netflix⁸ e outras competições de ciência de dados⁹ são obtidos com *ensembles*.

A seguir, apresentamos uma descrição sucinta dos problemas que serão tratados neste livro, mostrando alguns exemplos de conjuntos de dados bastante conhecidos.

1.2.1 Regressão

O objetivo da regressão ou aproximação de funções é um modelo de sistema ou processo capaz de realizar uma estimativa do valor da variável de saída numérica a partir das variáveis de entrada. A regressão é uma tarefa preditiva e a avaliação da precisão

é feita em função do erro de predição, ou seja, a diferença entre o valor predito e o valor correto. O erro de predição é utilizado para o ajuste do modelo.

O problema de regressão linear é clássico na estatística, com diversas aplicações em engenharia e ciências. Na regressão linear, a variável de saída é calculada como uma combinação linear das variáveis de entrada ou de funções das variáveis de entrada chamadas de “**regressores**” ou de **características** (*features*). Além de eficiente, o modelo linear permite a análise de diversas características do problema. A regressão linear é explorada no Capítulo 3, sua extensão para a modelagem de séries temporais e sistemas dinâmicos é apresentada no Capítulo 4.

A Figura 1.2 mostra um exemplo de problema de regressão linear monovariável. O modelo (em vermelho) é ajustado a partir dos dados da amostra (em azul) e deve ser o mais próximo possível da relação alvo (em preto). Em geral, não se conhece precisamente o comportamento estatístico do processo além dos dados da amostra, de modo que não se pode afirmar se o modelo ajustado representa o processo (relação alvo) ou é apenas um modelo daquela amostra.




Figura 1.2: Problema de regressão linear.

Em muitos processos reais, o relacionamento entre as variáveis de entrada e saída é não linear. Nesse caso, o modelo é válido para as condições em que a amostra foi realizada. Se o processo tem um comportamento muito instável, como, por exemplo, o mercado financeiro, a validade de um modelo expira rapidamente e um modelo ajustado com dados históricos não consegue prever adequadamente o futuro. No caso de modelos não lineares, a predição de um valor muito diferente dos dados de entrada-saída

utilizados no conjunto de treinamento pode resultar em valores incorretos, pois o modelo foi ajustado para a amostra, que representa um determinado domínio.

Os problemas de regressão e de classificação têm muitas características em comum, uma vez que um modelo de classificação pode ser visto como um modelo de aproximação de funções discriminantes, como descrito a seguir.

1.2.2 Classificação

O objetivo da classificação é um modelo, chamado de classificador, capaz de classificar uma observação em uma das diferentes classes predefinidas a partir de valores das variáveis de entrada, que representam as características ou atributos da observação. O modelo representa o relacionamento entre os atributos e a classe, que é a variável de saída. A classificação é uma tarefa preditiva, pois o modelo deve ser capaz de prever a classe para um novo registro previamente desconhecido, isto é, um registro não utilizado no conjunto de treinamento. A avaliação de um modelo de classificação é realizada principalmente em função da sua precisão na predição da classe correta.

O conjunto de dados das flores Iris é certamente o exemplo mais conhecido e estudado em ciência de dados. O problema consiste em prever a categoria de flores Iris, mostradas na Figura 1.3, a partir dos valores de comprimento e largura das pétalas e sépalas. O conjunto de dados tem, portanto, quatro variáveis numéricas de entrada e uma variável de saída, cujos valores são as três classes possíveis. O conjunto de dados apresenta 50 instâncias para cada classe e foi utilizado pela primeira vez por Fisher em 1936 [183] como exemplo de funções discriminantes lineares.




Figura 1.3: Flores Iris: (a) *Iris setosa*; (b) *Iris versicolor*; (c) *Iris virginica*.

O problema de classificação pode ser visto como uma busca por funções discriminantes (lineares ou não lineares) capazes de dividir o espaço das variáveis de entrada em regiões e associar cada região a uma classe (cf. Figura 1.4).




Figura 1.4: Problema de classificação: (a) conjunto de treinamento; (b) conjunto de testes.

Em situações em que é possível separar todos os registros de uma classe por uma função linear, diz-se que a classe é linearmente separável. Quando os registros de uma classe podem ser separados por uma função não linear, a classe é dita separável não linearmente. Na prática, na maioria dos casos, os registros não podem ser separados completamente por alguma função linear ou não linear. Nesse caso, as classes são ditas não separáveis uma vez que a informação coletada pelas variáveis de entrada não é suficiente para separar completamente as classes e, em consequência, o erro de classificação não pode ser nulo, por melhor que seja o modelo. O problema é explorado em detalhes no Capítulo 5, onde mostramos que é possível estabelecer um limite teórico do erro de um classificador. Os modelos lineares locais e os modelos de sistemas fuzzy e redes neurais podem tratar tanto problemas de classificação como problemas de regressão e serão apresentados no Capítulos 7, 8 e 9 respectivamente.

O problema de classificação tem sido estudado desde muito antes do surgimento das técnicas de inteligência computacional. Em estatística, o problema de classificação é chamado de reconhecimento de padrões [146]. As abordagens modernas para o problema reúnem técnicas estatísticas clássicas e técnicas de inteligência computacional [146]. Esse tipo de problema encontra inúmeras aplicações nos mais variados campos de negócio, como, por exemplo, diagnóstico médico, análise de crédito, classificação de documentos, classificação de imagens, bioinformática, entre outros.

1.2.3 Análise de agrupamentos

O objetivo da análise de agrupamentos é encontrar grupos de registros semelhantes no conjunto de dados. Na análise de agrupamentos, também chamada de classificação não supervisionada, não existe uma variável de saída ou variável alvo. O conjunto de dados contém, assim, apenas registros das variáveis de entrada.




Figura 1.5: Problema de agrupamento: (a) conjunto de dados; (b) agrupamento.

Há diversas aplicações da análise de agrupamentos nos mais variados campos, como bioinformática, *marketing*, processamento de imagens etc. Uma das aplicações mais conhecidas é a segmentação de clientes, muito útil na definição de estratégias de relacionamento [530]. Nesse caso, as variáveis do conjunto de dados são características dos clientes em função das quais se deseja a análise.

Empresas com grandes bases de clientes, como operadoras de telefonia, utilizam análise de agrupamentos para segmentação de clientes, em que as variáveis representam a utilização dos serviços. Grupos de clientes podem ser alvo de campanhas de retenção ou promoções diferenciadas.

Um problema crítico na análise de agrupamentos é a avaliação da qualidade do resultado do agrupamento, pois a inexistência de uma variável de saída dificulta a definição de uma estatística de desempenho. Paradoxalmente, a definição do número de grupos é um dado de entrada para a maioria dos algoritmos. Há na literatura diversos índices que se propõem a realizar uma avaliação da qualidade do agrupamento. Entretanto, os índices refletem características geométricas desejáveis de um bom agrupamento e seu resultado deve ser interpretado por um analista. A experiência do analista e a participação do especialista do domínio são fundamentais para a análise de agrupamentos.

O problema de análise de agrupamentos possui diversas abordagens diferentes e um grande número de algoritmos. Há livros inteiros focados no assunto [573][194] e uma abordagem completa do problema foge ao escopo deste livro. As abordagens principais são discutidas no Capítulo 6.

Uma variante do problema de análise de agrupamento é chamada de classificação semi supervisionada [82], no qual um pequeno subconjunto dos dados anotados, que deve ser utilizado para a classificação de um conjunto maior de dados. A questão é tratada como um problema de agrupamentos em que os registros categorizados são utilizados para ajudar a ajustar o modelo.

1.3 Recursos Complementares

Esta seção apresenta um conjunto de recursos relacionados com o conteúdo deste livro e com a ciência de dados em geral.

1.3.1 Bibliografia de referência

A literatura na área de inteligência computacional com aplicação em ciência de dados é bastante diversificada. A abordagem estatística para a construção de modelos de dados está fartamente descrita em diversas referências. Um enfoque bastante completo que apresenta tanto os métodos mais avançados quanto dos métodos estatísticos clássicos é apresentado por Hastie, Tibshirani e Friedman¹⁰ [238].

O livro *Pattern Classification*,¹¹ de Duda e Hart [146], é um clássico em métodos estatísticos de classificação. O livro tem um volume correspondente com rotinas Matlab dos principais algoritmos [507]. O livro de Theodoris e Koutroumbas¹² [521], é outra referência em métodos estatísticos de classificação e análise de agrupamentos, que também tem um volume com rotinas em Matlab [522]. O livro de Bishop¹³ [52] é uma referência importante em método estatísticos e de inteligência computacional, trazendo um capítulo sobre métodos variacionais. Uma referência adicional para métodos estatísticos de classificação é o livro de Webb [553].

Em problemas de regressão, Montgomery [399] é uma referência clássica, em sua quarta edição. O clássico de modelos estatísticos de séries temporais e sistemas dinâmicos é o livro de Box, Jenkins e Reinsel [59], que também está na quarta edição. Outra obra de referência para o desenvolvimento de modelos dinâmicos de sistemas lineares

é o livro de Ljung¹⁴ [352], que serviu de base para o desenvolvimento da biblioteca *System Identification Toolbox*¹⁵ do Matlab. Schabenberger e Gotway [472] apresentam uma visão bastante abrangente sobre análise de dados espaciais.

Há diversas referências clássicas sobre as principais técnicas de inteligência computacional, como o livro de Haykin¹⁶[240][241] sobre redes neurais e os livros de Pedrycz e Gomide [432][433] sobre a teoria de conjuntos *fuzzy*. A obra de referência sobre máquinas de vetores de suporte e métodos baseados em funções de núcleo (*kernel*) é o livro de Schölkopf e Smola¹⁷[478], que apresenta uma abordagem completa dos métodos e suas formulações matemáticas e ainda inclui uma discussão sobre temas correlatos como regularização e otimização. Taylor e Cristianini¹⁸ [485], Huang, Kecman e Kopriva¹⁹ [269], e Kulkarni e Harman [326] apresentam uma excelente introdução à teoria de aprendizado estatístico. A obra de Vapnik [532]-[534] é a referência teórica mais completa. Em seu livro mais recente, Vapnik [533] traz uma apresentação simplificada dos principais conceitos da teoria.

O problema de construção de modelos a partir de dados é muito bem descrito por Cherkassky e Mulier [98], com uma abordagem que ressalta os pontos em comum dos vários algoritmos de inteligência computacional. Kecman²⁰ [301] apresenta os principais algoritmos de inteligência computacional, em que os métodos estatísticos clássicos são condensados no primeiro capítulo. A maioria dos livros de inteligência computacional é focada em sistemas *fuzzy*, redes neurais e algoritmos genéticos [152][318][520].

Há diversos livros sobre mineração de dados, o primeiro com este título foi editado por Fayyad e Piatetsky-Shapiro em 1996 [177]. O trabalho de Han e Kamber, publicado em três edições [232]-[234], também é uma referência importante e tem uma apresentação bastante completa. Han também participa em edições sobre a mineração de dados geográficos [386][387] e sobre mineração de dados em grafos [582]. O livro de Tan, Steinbach e Kumar²¹ [516] é outra referência clássica em mineração de dados. O livro escrito pelos autores do Weka²² [561] apresenta os principais algoritmos do *software*.

Um livro de Zaki e Meira [593] apresenta uma visão bem atual e completa do assunto com os principais algoritmos, além de mostrar aplicações em problemas complexos como mineração de grafos e sequências. O livro de Aggarwal [5] é uma referência mais completa e atualizada na área de ciência de dados, apresentando os fundamentos, técnicas e aplicações. Em suas 700 páginas, aborda o assunto de forma bem abrangente,

considerando o pré-processamento, detecção de *outliers*, mineração de dados estruturados, dados espaciais, séries temporais, sequências e dados não estruturados como textos e mineração da *web* e de redes sociais.

Mitchel²³ [392] é a referência clássica de aprendizado de máquinas. O livro de Murphy de 2012 [406] apresenta uma abordagem bem completa do tema sob a ótica probabilística. Alguns livros de aprendizado de máquina apresentam uma abordagem de mineração de dados [14][370] ou de análise inteligente de dados [44][45].

O livro *Deep Learning*,²⁴ de Googfellow, Bengio e Courville [212], publicado em 2016, é a referência atual sobre algoritmos de aprendizado profundo. O livro é bem completo e aborda desde os princípios básicos de álgebra linear, teoria das probabilidades e técnicas clássicas de aprendizado de máquinas até os mais avançados modelos que estão sendo utilizados atualmente em aplicações de inteligência artificial.

Liu²⁵ [348] é uma referência em problemas relacionados à internet. Os algoritmos de inteligência computacional têm sido utilizados em problemas com dados não estruturados como texto, grafos [1][43][178][502] e redes sociais [4][376]. Outras aplicações importantes são a bioinformática e sistemas financeiros[295].

Na literatura nacional, o livro editado por Solange Rezende em 2002 [451] reúne métodos de inteligência computacional, mineração de dados e aprendizado de máquina. A obra, assinada por 10 autores com a participação de vários colaboradores, permanece atual e inclui, além dos conceitos teóricos, uma série de aplicações práticas dos métodos apresentados. Alguns trabalhos na área de ciência de dados e inteligência computacional escritos em português apareceram recentemente [61][173][193][345]. Os modelos de redes neurais estão bem descritos na tradução do livro de Haykin [241] e no livro de Braga, Carvalho e Ludermir [62].

1.3.2 Recursos na internet

Em 2011, a Universidade de Stanford iniciou seu programa de oferta de cursos *online* gratuitos pela internet com três cursos de ciência da computação: banco de dados, aprendizado de máquina e inteligência artificial. Os mesmos cursos oferecidos aos alunos de Stanford foram disponibilizados livremente na internet, onde qualquer um poderia se inscrever e seguir aulas em vídeo. A grande diferença entre essa iniciativa e outras formas de educação *online* é que alunos inscritos podem responder perguntas,

realizar exercícios propostos e exames (dentro do mesmo ambiente computacional) e, ao final, desde que obtenham rendimento adequado, receber um certificado de participação assinado pelo professor. Os cursos atraíram mais de 100 mil inscritos em todo o mundo. A iniciativa gerou a criação de diversos repositórios de cursos *online* em universidades como Stanford²⁶ e MIT²⁷, além de empresas como Coursera²⁸ e Udacity²⁹, fundadas no início de 2012, que exploram este mercado. O curso de Machine Learning do Coursera,³⁰ apresentado por Andrew Ng, de Stanford, cobre a maioria dos assuntos tratados neste livro.

Aulas e conferências em vídeo também podem ser encontradas no VideoLectures³¹, que é uma espécie de YouTube acadêmico e contém vídeos sobre diversos assuntos. No VideoLectures é possível assistir a seminários sobre os temas de interesse apresentados pelos maiores especialistas da área. O Slide Share³² e o Scribd³³ também são repositórios de conteúdo geral, o primeiro no formato de *slides* de apresentações e o segundo no formato de documentos.

O principal portal de recursos de ciência de dados na internet é o KDnuggets,³⁴ que contém *links* para diversos recursos, como *softwares*, repositórios de dados, cursos etc., além de ofertas de empregos e também muita publicidade. O KDnuggets foi criado em 1997 e é mantido por Piatetsky-Shapiro, um dos principais pesquisadores da área e coeditor do primeiro livro de mineração de dados [177].

O repositório de dados que é referência em diversos trabalhos de ciência de dados é o UCI Machine Learning Repository,³⁵ mantido pela Universidade da Califórnia em Irvine. O UCI contém um acervo bastante completo de conjuntos de dados *benchmark* para avaliação de algoritmos. O UCI tem uma seção especial dedicada aos concursos de ciência de dados KDD Cup propostos nas edições do congresso Knowledge Discovery in Databases (KDD).³⁶ Atualmente, competições de algoritmos de ciência de dados se tornaram comuns através do *site* Kaggle.³⁷

O *site* do *software* de código aberto KEEL,³⁸ desenvolvido por um consórcio de seis grupos de pesquisa espanhóis, disponibiliza, além do próprio *software*, alguns conjuntos de dados *benchmark*. Os dados encontrados no *site* do KEEL são essencialmente os mesmos disponíveis no UCI, mas no KEEL eles podem ser encontrados em partições predefinidas, o que permite a comparação direta entre algoritmos. O *site* KEEL também

disponibiliza uma grande variedade de publicações e *links* para outros repositórios ligados à área de inteligência computacional.

Os resultados recentes nas áreas de inteligência computacional e ciência de dados são publicados em periódicos de circulação internacional. No Brasil, graças ao Portal de Periódicos Capes³⁹, o estudante de pós-graduação tem acesso aos principais periódicos científicos em todas as áreas. Na área de inteligência computacional e ciência de dados, os principais portais são o Science Direct⁴⁰ (Elsevier), o IEEEExplore⁴¹ (IEEE), o *site* da Springer⁴² e o portal da ACM Digital Library.⁴³ Os principais periódicos da área de ciência de dados estão listados no portal KDnuggets.⁴⁴

Pesquisadores da área de ciência de dados organizam anualmente diversos congressos internacionais sobre o tema. Os congressos mais importantes na área são o KDD, organizado pelo SIGKDD⁴⁵ e o ICDM,⁴⁶ organizado pelo IEEE. Na área de aprendizado de máquinas os congressos mais importantes são o NIPS⁴⁷ (NeurIPS a partir de 2018) e o ICML⁴⁸. Na área de inteligência computacional, os congressos mais importantes são organizados por especialidade. A cada quatro anos, é organizado o WCCI,⁴⁹ que reúne os principais congressos da área organizados pelo IEEE: FUZZ-IEEE de sistemas *fuzzy*; IJCNN de redes neurais; e IEEE CEC de computação evolutiva. Outras informações sobre eventos e publicações da área podem ser obtidas no *site* da Sociedade de Inteligência Computacional do IEEE.⁵⁰ No Brasil, a Associação Brasileira de Inteligência Computacional (ABRICOM),⁵¹ organiza o Congresso Brasileiro de Inteligência Computacional (CBIC), a cada dois anos.

Atualmente, é possível participar de discussões sobre diversos assuntos em *blogs*⁵² e perfis no Twitter⁵³ relacionados à área de ciência de dados. Há também diversos grupos de discussão em redes sociais,⁵⁴ principalmente no Facebook e no LinkedIn.

O desenvolvimento de modelos de inteligência computacional, principalmente redes neurais profundas, tem se beneficiado bastante de um ecossistema aberto, com *softwares* livres e linguagens de programação abertas, repositórios de artigos científicos como o arXiv⁵⁵ e repositórios de códigos como GitHub.⁵⁶

Finalmente, há na internet repositórios de conteúdo genérico que contêm material de diversos assuntos, incluindo tópicos relacionados à inteligência computacional e ciência de dados. É importante lembrar que artigos na internet não têm nenhum tipo de avaliação da qualidade da informação e devem ser consultados com cautela.

1.3.3 Softwares

Os *softwares* comerciais mais utilizados são o SAS (Statistical Analysis Software), o SPSS (Statistical Package for the Social Sciences) e o Statistica. Estes *softwares* foram desenvolvidos inicialmente como pacotes estatísticos que depois incorporaram outros módulos. O pacote de mineração de dados do SAS⁵⁷ fornece suporte para todo o processo, incluindo limpeza, transformações de dados e modelos. O SAS ainda tem uma customização de seus módulos para diversos setores de negócios. O IBM SPSS Modeler⁵⁸ (ex-PASW, ex-Clementine) e tem características similares ao concorrente SAS. O SAS e o SPSS oferecem uma solução integrada, considerando todas as etapas do processo, desde a aquisição de dados até a implantação dos modelos. A aquisição da SPSS pela IBM mostra claramente essa tendência. O Statistica Data Miner⁵⁹ também é integrado aos módulos de estatística e tem uma variedade maior de algoritmos, permitindo otimizar modelos para um problema específico. Os resultados dos modelos do Statistica também podem ser exportados em C, Java, Visual Basic e PMML. Os três pacotes oferecem, como módulos adicionais, funcionalidades de mineração de textos.

O Oracle Data Mining e o Microsoft SQL Server Data Mining são bibliotecas de mineração de dados que rodam dentro dos respectivos bancos de dados. A vantagem desse tipo de solução é que os modelos são desenvolvidos diretamente no banco de dados, podendo ser integrados à plataforma operacional. Os produtos da Oracle e da Microsoft oferecem uma variedade limitada de algoritmos, alguns proprietários que não são completamente explicados na documentação. Esses *softwares* têm poucos recursos nativos para visualização e caracterização estatística dos dados. A vantagem do Oracle Data Mining é sua presença no mercado e a integração com os outros produtos da Oracle e a possibilidade de ser diretamente integrado a programas Java e à linguagem PLSQL do Oracle. O Microsoft SQL Server Data Mining também tem a vantagem de ser totalmente integrado à plataforma .NET da Microsoft e o seu custo é bem inferior. Nas versões mais recentes, as duas plataformas têm recursos para mineração de textos.

O desenvolvimento de *softwares* comerciais segue a tendência crescente de oferta de serviços na nuvem. Nesse sentido, a plataforma Microsoft Azure Machine Learning⁶⁰ permite o desenvolvimento e o *deploy* de modelos de ciência de dados diretamente a partir da nuvem. O produto Amazon Machine Learning⁶¹ também segue essa tendência na plataforma de nuvem Amazon Web Services. A Prediction API⁶² da plataforma de nuvem do Google também é uma iniciativa nessa linha.

Para grandes corporações que atuam em mercados altamente competitivos e lidam com grandes massas de dados, o ganho potencial dos resultados obtidos com modelos de ciência de dados supera o custo de aquisição e manutenção de pacotes comerciais [439]. Para pequenas e médias empresas e, principalmente, o mundo acadêmico, o custo de uma licença de um pacote comercial como os mencionados pode ser proibitivo. Há no mercado outros *softwares* comerciais com custos mais acessíveis como o PolyAnalyst,⁶³ e sua variante para análises de textos TextAnalyst⁶⁴.

Há *softwares* livres que podem ser utilizados para o desenvolvimento de soluções sem uma linguagem de programação. O primeiro *software* livre de mineração de dados, desenvolvido em 1997 na Universidade de Waikato, foi o Weka.⁶⁵ Codificado em Java, o Weka tem código-fonte aberto, embora a documentação não seja das mais claras. O Weka contém uma variedade enorme de algoritmos, com diversas variedades de algoritmos de indução de árvores e regras de decisão. O Weka também tem uma interface gráfica intuitiva de fácil utilização. Em 2006, o Projeto Weka foi adquirido pela Pentaho⁶⁶ para ser integrado ao pacote de inteligência de negócios da empresa. O Weka continua sendo desenvolvido como projeto de *software* livre.

O RapidMiner⁶⁷ utiliza o mesmo modelo de negócios da Pentaho, fornecendo *softwares* livres para oferecer serviços de consultoria e treinamento. O RapidMiner também é desenvolvido em Java e incorpora algoritmos de outros *softwares* livres, como o Weka e o LibSVM. O RapidMiner tem recursos elaborados de visualização de dados e de resultados de modelos, além de permitir o desenvolvimento de *workflows* de modelagem complexos, com otimização de modelos por algoritmos genéticos. O KNIME⁶⁸ também é desenvolvido em Java e incorpora algoritmos de outros *softwares* livres, como o Weka e o LibSVM, numa interface gráfica de fácil utilização. O KNIME tem recursos de visualização melhores que o Weka, mas é equivalente em termos de algoritmos.

Uma alternativa ao padrão Java, utilizado pelos *softwares* livres citados anteriormente, é o Orange,⁶⁹ desenvolvido em C++ e Python. O Orange é um projeto acadêmico e apresenta uma boa variedade de algoritmos numa interface gráfica agradável e com bons recursos de visualização. O Orange é desenvolvido a partir de uma biblioteca que é fornecida junto com o *software*, permitindo o desenvolvimento de aplicações pelo usuário.

A utilização de *softwares* livres e linguagens de programação abertas têm impulsionado o desenvolvimento da ciência de dados. As principais bibliotecas do Python para

ciência de dados são o Pandas⁷⁰ e o Scikit Learn,⁷¹ que utilizam outras bibliotecas de referência do Python como NumPy e SciPy. O Python é desenvolvido por uma comunidade motivada e suas bibliotecas permitem o acesso a diversos algoritmos. Há uma grande variedade de recursos em Python na internet.⁷²

A linguagem R⁷³ é um projeto de *software* livre da comunidade estatística com um ambiente computacional e bibliotecas com uma grande variedade de rotinas para tratamento, processamento e visualização de dados. As rotinas são organizadas em pacotes para cada assunto e podem ser acessadas por uma linguagem de programação simples, que também é ser utilizada para o desenvolvimento de novos algoritmos. Há diversas extensões e interfaces gráficas para a linguagem, assim como empresas⁷⁴ que fornecem extensões e consultoria. A linguagem R tem sido incorporada em *softwares* comerciais como o SAS e em bancos de dados como Oracle.

O site KDnuggets realiza regularmente uma enquete com o objetivo de determinar os *softwares* mais utilizados pelos usuários do portal. Nos últimos anos, as linguagens R e Python têm se destacado como linguagens mais utilizadas.

Um ambiente computacional importante na área de engenharia é o Matlab.⁷⁵ O Matlab é um *software* comercial que tem um núcleo central, basicamente a janela de comando e bibliotecas numéricas básicas. Os recursos avançados do Matlab são comercializados como pacotes, chamados *Toolbox*, que contêm rotinas para as mais diversas áreas, como biologia, finanças, sistemas de controle etc. Uma configuração adequada para a área de inteligência computacional e ciência de dados deve conter essencialmente os pacotes de estatística,⁷⁶ redes neurais⁷⁷ e algoritmos genéticos.⁷⁸ Pacotes adicionais, como o de otimização⁷⁹ e de identificação de sistemas,⁸⁰ também são importantes. O pacote de programação paralela,⁸¹ que permite a execução de *scripts* Matlab em máquinas com processadores de múltiplos núcleos e *clusters*, pode ser necessário em aplicações computacionalmente intensivas. Os programas desenvolvidos em Matlab podem ser integrados a *softwares* corporativos através de compiladores para as plataformas .NET,⁸² Java⁸³ e Excel.⁸⁴ Além dos pacotes mantidos e desenvolvidos pela Mathworks, existe uma comunidade de usuários ativa que desenvolve rotinas e pacotes para o Matlab, organizados no repositório Matlab Central.⁸⁵ Há mais de 1200 livros escritos sobre o Matlab ou sobre aplicações utilizando o ambiente computacional.⁸⁶ As figuras neste livro foram geradas com Matlab.

1.4 Comentários Finais

Neste capítulo foram apresentados os conceitos iniciais inteligência computacional para ciência de dados e uma introdução dos assuntos abordados no livro. Os recursos bibliográficos representam um apanhado das principais fontes que podem servir de apoio a um estudo mais aprofundado nesses temas. É provável que alguma referência importante não tenha sido incluída e é provável que alguma informação esteja desatualizada, principalmente as referências da internet e *softwares*.

2 PRÉ-PROCESSAMENTO

O pré-processamento inclui a seleção, limpeza e transformação de dados. O objetivo dessa etapa é a preparação do conjunto de dados que será utilizado para o ajuste do modelo, chamado de **conjunto de treinamento**. Em geral, a etapa de pré-processamento consome de 60% a 80% do tempo de todo o processo de mineração de dados e fornece informações importantes que vão orientar a análise e o ajuste dos modelos.

Este capítulo introduz os conjuntos de dados encontrados em aplicações de ciência de dados. A seguir, são apresentados os principais conceitos estatísticos de métodos exploratórios necessários para o entendimento dos dados e, principalmente, para a interpretação adequada dos resultados da visualização. As técnicas de limpeza de dados e as transformações lineares mais importantes são apresentadas na sequência. Algumas aplicações que utilizam os conceitos discutidos no capítulo são apresentadas no final.

2.1 Conjuntos de Dados

Há uma diferença entre dado, informação e conhecimento [451]. Dado é o registro de um fato, informação é o fato analisado no seu contexto e conhecimento, característica inerentemente humana, é a interpretação da informação num contexto específico visando à sua aplicação. Por exemplo, o preço de uma ação num determinado instante na bolsa de valores é um dado; a variação do preço da ação é uma informação; e a interpretação dessa informação no contexto da conjuntura econômica do momento para a tomada de decisão de investimento é o conhecimento.

Uma metáfora bem-humorada que enfatiza a importância da apresentação da informação é mostrada na Figura 2.1.




Figura 2.1: *Data Cake*. Fonte: epigraphics.com.⁸⁷

Os dados utilizados numa aplicação podem ser estruturados ou não estruturados. Dados estruturados são aqueles organizados em tabelas, nas quais as linhas são os **registros** que representam as observações e as colunas, as **variáveis** ou as características observadas em cada registro, frequentemente chamadas de **atributos**. Os dados não estruturados são aqueles que, na sua forma bruta, não são tabulados. Exemplos de dados não estruturados são imagens, sons, textos, estruturas gráficas etc. Neste livro serão considerados principalmente os modelos de dados estruturados. Modelos de dados não estruturados, principalmente de textos e de estruturas na forma de grafos (redes), têm sido cada vez mais importantes em ciência de dados [295].

Os dados estruturados são armazenados em bases de dados, de onde são selecionados para o ajuste dos modelos. Em sistemas corporativos, os dados podem estar armazenados em diversas bases diferentes. Nesse caso, a extração de dados pode se tornar extremamente complexa e é realizada por processos chamados ETL (*extract, transform and load*). Em ambientes mais simples, a seleção é feita diretamente a partir da base de dados e o conjunto de dados se apresenta na forma de uma tabela ou arquivo de dados.

Num conjunto de dados estruturados, cada linha ou registro contém os valores observados de um conjunto de variáveis. As variáveis podem ser contínuas, discretas ordenadas ou discretas não ordenadas. As variáveis contínuas armazenam valores numéricos do tipo real; as variáveis discretas ordenadas armazenam valores do tipo inteiro; enquanto as variáveis discretas não ordenadas armazenam valores categóricos ou nominais. As variáveis binárias são um tipo especial de variáveis discretas que tem apenas dois valores. Tipicamente, um conjunto de dados pode conter variáveis de diversos tipos. A maioria dos algoritmos de estatística e inteligência computacional trabalha com variáveis numéricas. Nesse caso, as variáveis categóricas são transformadas num conjunto de variáveis binárias chamadas variáveis indicadoras (ou *dummy*).^{*} Há algoritmos especializados em modelos de variáveis nominais – em geral, essa área é conhecida com aprendizado simbólico [392][451].

Neste livro, para facilitar o tratamento matemático dos algoritmos, as variáveis são consideradas numéricas (contínuas ou discretas) e as variáveis nominais são transformadas em variáveis indicadoras binárias no pré-processamento.

Um conjunto de dados é representado por $\mathcal{T} = \{(\mathbf{x}(t), \mathbf{y}(t)), t = 1 \dots N\}$. Cada registro é formado pelo par ordenado $(\mathbf{x}(t), \mathbf{y}(t))$, onde $\mathbf{x}(t)$ é o vetor[†] que contém os valores das variáveis de entrada e $\mathbf{y}(t)$, o vetor contendo os valores das variáveis alvo ou de saída. Sem perda de generalidade, os vetores de variáveis de entrada e saída são escritos como $\mathbf{x}(t) \in \mathcal{R}^p$ e $\mathbf{y}(t) \in \mathcal{R}^q$, onde p e q são, respectivamente, o número de variáveis de entrada e de saída. As variáveis nominais são codificadas como variáveis indicadoras que, assim como as variáveis inteiras, são um subconjunto das variáveis reais.

Problemas de saídas múltiplas ($q > 1$) podem ser representados como múltiplos problemas de saída simples se as variáveis de saída forem desacopladas, ou seja, o valor de uma saída não interfere no valor de outra. Nesse caso, um modelo independente é desenvolvido para cada saída. Em problemas descritivos, não há variáveis de saída e o conjunto de dados contém apenas variáveis de entrada.

^{*} Uma variável nominal com n valores é codificada com n variáveis binárias chamadas variáveis indicadoras, em que cada variável indica a observação de um valor nominal da variável original.

[†] Vetores e matrizes são grafados em negrito, vetores em letras minúsculas e matrizes em letras maiúsculas. Valores escalares são grafados em itálico. Letras maiúsculas gravadas em cursiva, como $\mathcal{A}, \mathcal{B}$ etc., indicam conjuntos. Letras gregas serão usadas para indicar parâmetros de modelos.

Alguns problemas apresentam características especiais que interferem na interpretação do conjunto de dados. Em problemas dinâmicos, existe uma dependência intrínseca entre uma observação e as observações precedentes. Nesse caso, as variáveis são séries temporais em que os registros são apresentados em sequência e o índice $t = 1 \dots N$ representa um instante de tempo. Os problemas em que a ordem das observações não é relevante são chamados estáticos e, nesse caso, qualquer permutação dos registros no conjunto de dados produz o mesmo resultado. Em problemas georreferenciados, existe uma dependência espacial entre as observações e cada registro está associado a duas (ou três) variáveis que representam as coordenadas da observação. Os problemas chamados espaço-temporais combinam essas duas características: contêm variáveis espaciais e os registros são armazenados em sequência. Este livro não aborda especificamente problemas espaciais ou espaço-temporais, apenas a modelagem de sistemas dinâmicos lineares no Capítulo 4.

Para a apresentação matemática dos algoritmos, o conjunto de dados é representado por matrizes. A matriz (de variáveis) de entrada é a matriz $\mathbf{X}$, de dimensão $N \times p$, e a matriz (de variáveis) de saída é a matriz $\mathbf{Y}$, de dimensão $N \times q$. As dimensões das matrizes indicam que os registros estão organizados em linhas e, para cada registro, os vetores* de variáveis de entrada e saída.

A notação apresentada anteriormente será utilizada ao longo do livro. Essa notação unificada facilita o entendimento dos algoritmos e a transposição de conceitos de modelos lineares para os modelos não lineares.

A próxima seção apresenta a primeira etapa na exploração de dados: a caracterização e visualização de dados.

2.2 Caracterização Estatística

A caracterização estatística de dados é uma das etapas mais importantes na ciência de dados. Essa fase permite o entendimento dos dados e facilita a análise dos resultados dos algoritmos.

* Matematicamente, um vetor é uma lista de valores e pode ser tratado como linha ou coluna na multiplicação com matrizes. Neste livro são utilizados vetores linha.

Estatisticamente, um conjunto de dados é tratado como uma amostra de um processo estocástico, ou seja, um processo cujo comportamento é imprevisível, mas pode ser descrito estatisticamente através de uma função de distribuição de probabilidades. O conceito de amostra é muito importante em ciência de dados, uma vez que os modelos serão ajustados a partir de uma amostra e não o processo estocástico. Essa é uma diferença importante entre a abordagem de inteligência computacional e a abordagem estatística, na qual em geral se busca a modelagem do processo [98], a partir de uma hipótese sobre a distribuição de probabilidades.

A maioria dos algoritmos de ciência de dados pressupõe implicitamente que o processo que gerou a amostra representada pelo conjunto de dados é estacionário, ou seja, não varia com o tempo. Dessa forma, podemos utilizar um conjunto de dados coletados num determinado instante para realizar previsões em outro momento uma vez que o processo permanece o mesmo entre o tempo de coleta da amostra e a realização da previsão. Entretanto, essa hipótese pode não ser verdadeira e, nesse caso, os modelos não terão bons resultados de previsão. Esse é tipicamente o caso da modelagem de processos altamente complexos como o mercado financeiro. A caracterização e modelagem de problemas dinâmicos será abordada no Capítulo 4. Neste capítulo, é apresentada a caracterização e visualização de dados de problemas estáticos.

2.2.1 Análise monovariável

O primeiro passo na caracterização estatística de uma amostra é o cálculo de estatísticas das variáveis. Uma estatística é qualquer função obtida a partir de uma amostra. As estatísticas da amostra, em geral, são calculadas para as variáveis de entrada do conjunto de dados, mas podem ser calculadas também para as variáveis de saída. As principais estatísticas são:

- **média**, uma medida do valor central da amostra:

$$\mu \approx \bar{x}_i = \frac{1}{N} \sum_{t=1}^N x_i(t), i = 1 \dots p \quad (2.1)$$

- **variância**, uma medida da dispersão da amostra:

$$Var(x_i) \approx \hat{\sigma}_i^2 = \frac{1}{N-1} \sum_{t=1}^N (x_i(t) - \bar{x}_i)^2, i = 1 \dots p \quad (2.2)$$

O **desvio padrão** estimado da variável $\hat{\sigma}_i \approx \sqrt{Var(x_i)}$ é comumente utilizado para a caracterização da dispersão de uma variável, pois seu valor tem a escala da variável.

Em amostras muito grandes de processos estacionários, a média da amostra é uma boa estimativa da média do processo. Esse resultado é conhecido na estatística como a “lei dos grandes números”. Da mesma forma, a variância da amostra converge para a variância do processo com o aumento do número de registros da amostra. Em conjuntos de dados pequenos, deve-se tomar cuidado ao utilizar essas estatísticas como estimativas de suas correspondentes do processo.

A média e a variância são os parâmetros que definem a função de densidade de probabilidades normal $N(\mu, \sigma^2)$, calculada como:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \quad (2.3)$$

A Figura 2.2a apresenta exemplos da distribuição normal com diversos valores de média e desvio padrão (σ). Quanto maior o desvio padrão, maior a dispersão dos dados e, conseqüentemente, menor a probabilidade da média. Na Figura 2.2b, as funções de distribuição de probabilidades cumulativa dos exemplos mostrados na Figura 2.2a.




Figura 2.2: Distribuição normal: (a) função de densidade de probabilidades; (b) função de probabilidades cumulativa. Fonte: Wikipédia.⁸⁸

A função de distribuição de probabilidades normal, ou simplesmente distribuição normal, é muito importante na estatística. Um dos principais resultados envolvendo a distribuição normal é o teorema central do limite. O teorema estabelece que a distribuição da média de amostras de processos estacionários gerados com qualquer distribuição, de média e variância constantes, converge para uma distribuição normal com a média do processo.

A distribuição normal é representada matematicamente por uma função gaussiana que possui diversas propriedades e é utilizada em inúmeras aplicações. Em inteligência computacional, a função gaussiana aparece como uma função de base para o desenvolvimento de vários tipos de modelos, como será apresentado no Capítulo 7.

Outras estatísticas importantes para a caracterização de dados são:

- valores extremos: **mínimo** e **máximo**;
- a **mediana**: é o valor que divide o conjunto de dados em subconjuntos iguais, ou seja, 50% dos registros são maiores que a mediana, 50% são menores que a mediana. A mediana é o percentil 50 da amostra;
- o **percentil P** é o valor que divide o conjunto de dados de forma que $P\%$ dos registros são menores ou iguais a esse valor;
- a **faixa interquartil** é o intervalo compreendido entre o percentil 25 e o percentil 75, respectivamente chamados de primeiro quartil ($Q1$) e terceiro quartil ($Q3$), sendo a mediana o segundo quartil ($Q2$);
- a **moda**, calculada apenas para variáveis discretas, é o valor observado com maior frequência.

A mediana é uma medida de centralidade da amostra que é insensível a distribuições assimétricas. A média pode dar uma ideia equivocada do valor central de um conjunto de dados na presença de valores aberrantes (*outliers*) ou distribuições assimétricas. A comparação entre a média e a mediana permite detectar facilmente assimetrias na distribuição dos dados. Distribuições assimétricas podem gerar modelos tendenciosos. Da mesma forma, as medidas de dispersão dependem da forma da distribuição. A variância da amostra só tem sentido em distribuições simétricas; no caso de distribuições assimétricas, deve-se utilizar a faixa interquartil.

A Tabela 2.1 apresenta o resultado das estatísticas para as variáveis de entrada do conjunto de dados das flores Iris. Pela comparação entre os valores de média e mediana

(percentil 50), percebe-se uma assimetria na distribuição da variável x_3 . Ao avaliar as estatísticas, é importante observar a escala das variáveis. No caso das Flores Íris, todas as variáveis representam uma medida em centímetros e, portanto, é possível realizar a comparação direta de valores de diferentes variáveis. No caso geral, em que as variáveis representam medidas distintas, recomenda-se que a análise seja feita sobre as variáveis padronizadas (cf. seção 2.3.1).

Tabela 2.1: Estatísticas básicas do problema Íris

	x_1	x_2	x_3	x_4
Mínimos	43,0	20,0	10,0	1,0
Máximos	79,0	44,0	69,0	25,0
Médias	58,4	30,6	37,6	12,0
Desvios	8,3	4,4	17,7	7,6
Percentil 25	51,0	28,0	16,0	3,0
Percentil 50	58,0	30,0	43,5	13,0
Percentil 75	64,0	33,0	51,0	18,0

Em problemas de classificação, é interessante avaliar as variáveis por classe. O **gráfico de linhas** permite que se faça uma avaliação visual das diferenças entre os registros de cada variável por classe e pode ajudar a identificar as variáveis mais relevantes para a separação das classes. No gráfico de linhas, cada variável é um valor no eixo horizontal e cada registro é uma linha ligando as variáveis em seu valor correspondente. A Figura 2.3 mostra um exemplo de gráfico de linhas para o conjunto de dados Íris com variáveis padronizadas (cf. seção 2.3.1). Podemos observar que as classes podem ser mais bem separadas no plano formado pelas variáveis x_3 e x_4 . Essa mesma conclusão será confirmada por outros tipos de gráficos mostrados.




Figura 2.3: Gráficos de linha do problema Íris.

Há várias funções de distribuição de probabilidades⁸⁹, com aplicações em diversas áreas. A distribuição de cada variável pode ser avaliada qualitativamente através de **histogramas** ou diagramas de frequência. Um histograma é uma representação gráfica da distribuição de probabilidade da variável (cf. Figura 2.4). Há diversos métodos estatísticos para o ajuste da função de distribuição de probabilidades [146][238], bem como livros inteiros dedicados ao assunto [482][490].




Figura 2.4: Histogramas e ajuste de distribuições.

As técnicas de inteligência computacional geralmente não levam em conta hipóteses sobre a distribuição de probabilidades que gerou a amostra. Entretanto, a análise dos histogramas é fundamental para o entendimento dos dados e para dar suporte à análise dos resultados do modelo. A avaliação visual dos histogramas pode revelar características indesejáveis na distribuição dos dados, como assimetria e distribuições multimodais (cf. Figura 2.5). Nesses casos, as estimativas de média e desvio padrão podem perder completamente o sentido.




Figura 2.5: Histogramas: (a) distribuição assimétrica; (b) distribuição multimodal.

Em problemas de classificação, os histogramas podem ser calculados por classe, o que permite a análise da distribuição de cada classe no universo da variável. Os histogramas separados por classes das variáveis no conjunto de dados Íris são mostrados na Figura 2.6. Nesse exemplo, os dados são mais misturados nas variáveis x_1 e x_2 que nas variáveis x_3 e x_4 , como observado no gráfico de linhas da Figura 2.3. As variáveis x_3 e x_4 apresentam um comportamento multimodal. Entretanto, ao separar por classes, verifica-se que cada concentração de dados corresponde a uma classe, o que pode ser bastante útil para a construção de classificadores.




Figura 2.6: Histogramas das distribuições das variáveis por classe no problema Íris.

É possível verificar qualitativamente se uma amostra foi gerada por um processo de distribuição normal através do gráfico de probabilidade normal. Nesse tipo de gráfico, se a amostra foi gerada por um processo de distribuição normal, os pontos aparecem alinhados; no caso de uma distribuição não normal, há uma curvatura no gráfico. A Figura 2.7 apresenta os histogramas de uma amostra de duas variáveis e os respectivos gráficos de distribuição normal. As Figura 2.7a e 2.7c mostram a distribuição de uma