

Resumen — Capítulo 1: Introducción

Inteligencia Computacional: Fundamentos y Aplicaciones

Alexandre G. Evsukoff (E-papers, 2020)

1. Contexto histórico y definición

La **inteligencia computacional** (IC) se define como un conjunto de paradigmas computacionales destinados al desarrollo y aplicación de sistemas inteligentes para resolver problemas complejos del mundo real. Su historia está vinculada a la de la inteligencia artificial (IA): desde las reflexiones filosóficas sobre la mente y el lenguaje hasta el *test de Turing* (1950). En términos metodológicos se distinguen dos corrientes principales: la corriente *simbolista* (sistemas expertos, lógica) y la corriente *conexionista* (redes neuronales, iniciadas con el Perceptron de Rosenblatt, 1958). La incapacidad del Perceptron para resolver problemas no linealmente separables llevó a una fase de estancamiento hasta que, en 1986, la técnica de *retropropagación del error* (Rumelhart, Hinton y Williams) revitalizó las redes neuronales multicapa. Paralelamente, Quinlan introdujo el algoritmo **ID3** para árboles de decisión, consolidando el aprendizaje automático simbólico.

Durante las décadas de 1980 y 1990 surgieron otros paradigmas (lógica difusa, algoritmos evolutivos, máquinas de soporte vectorial). La integración de estas técnicas recibió nombres como *soft computing* o **inteligencia computacional**. Desde 2010 el término *big data* ganó relevancia, y a partir de 2012 las **redes neuronales profundas** (*deep learning*) ejecutadas en GPUs lograron rendimientos comparables o superiores al humano en tareas como visión computacional y procesamiento de lenguaje natural.

2. Ciencia de datos y el proceso KDD

La **ciencia de datos** se sitúa en la intersección entre matemática, estadística, informática, ingeniería y conocimiento de dominio. A diferencia del método científico clásico, en ciencia de datos los modelos se construyen a partir de los datos observados en vez de partir de hipótesis teóricas predefinidas. El autor subraya que todo modelo es una representación parcial del fenómeno real y que su validez depende de la calidad y representatividad de la muestra.

El proceso de **descubrimiento de conocimiento en bases de datos (KDD)** —también llamado minería de datos— es cíclico y comprende las etapas:

1. **Selección** — elegir subconjuntos y variables relevantes (conjunto de entrenamiento).
2. **Limpieza** — tratar valores ausentes y *outliers*.
3. **Preprocesamiento** — normalizaciones y transformaciones (p.ej., ACP/PCA).
4. **Modelado** — ajuste de modelos y parámetros sobre los datos de entrenamiento.
5. **Evaluación** — validación estadística de los resultados.

Participación del experto en dominio es esencial en todas las fases.

3. Tipos de modelos

Un modelo es una representación simplificada del proceso real. Según su origen, se distinguen **modelos de conocimiento** (basados en leyes o relaciones físicas) y **modelos de comportamiento** (input-output, ajustados a partir de datos), siendo la mayoría de las técnicas de IC parte de esta segunda categoría.

Según su propósito, los problemas se dividen en **predictivos** y **descriptivos**: los primeros buscan predecir variables objetivo (aprendizaje supervisado), y los segundos describir estructuras o patrones sin variable objetivo (aprendizaje no supervisado). Existe además el *aprendizaje por reforzamiento*, donde un agente aprende mediante interacción y retroalimentación del entorno.

Regresión. Predicción de una variable numérica a partir de atributos de entrada. La regresión lineal es el punto de partida y se extiende a modelos para series temporales y sistemas dinámicos. La evaluación suele basarse en medidas de error de predicción.

Clasificación. Asignación de una etiqueta discreta a partir de atributos; se busca una función discriminante que separe las clases en el espacio de entrada. Las clases pueden ser linealmente separables o no, lo que determina la complejidad del modelo requerido. Aplicaciones típicas: diagnóstico médico, evaluación crediticia, bioinformática y clasificación de documentos e imágenes.

Clustering (agrupamiento). Identificación de grupos de objetos similares sin una variable objetivo. Evaluar la calidad de un clustering es complejo; existen medidas internas y externas, y en muchos métodos el número de grupos es un parámetro de entrada. Usos frecuentes: segmentación de clientes, análisis genómico y visión por computador.

Se mencionan también otros tópicos: *reglas de asociación*, aprendizaje de representaciones, clasificación semisupervisada y métodos de *ensemble*, muy útiles en competencias de ciencia de datos.

4. Recursos complementarios

Bibliografía. Para fundamentos estadísticos y de aprendizaje: Hastie, Tibshirani y Friedman (*The Elements of Statistical Learning*); Bishop (*Pattern Recognition and Machine Learning*); Duda & Hart; Theodoridis & Koutroumbas. Para redes neuronales: Haykin; para lógica difusa: Pedrycz & Gomide; para SVM: Schölkopf & Smola y Vapnik. En minería de datos: Han & Kamber, Tan et al., Aggarwal y Witten & Frank. En *deep learning*: Goodfellow, Bengio & Courville.

Recursos en línea. Portales y repositorios: KDnuggets, UCI Machine Learning Repository, KEEL y Kaggle. Cursos abiertos (Coursera, Stanford), preprints en arXiv y código en GitHub. Conferencias relevantes: KDD, ICDM, NeurIPS, ICML, entre otras.

Software. Comerciales: SAS, IBM SPSS Modeler, Statistica; en entorno libre: Weka, RapidMiner, KNIME, Orange. Lenguajes y bibliotecas: Python (pandas, scikit-learn, NumPy, SciPy), R y Matlab. KDnuggets muestra el liderazgo de R y Python entre practicantes.

5. Síntesis y relevancia para el curso

El Capítulo 1 establece el vocabulario y el marco conceptual requerido para el resto del libro: diferencia entre dato/información/conocimiento, el ciclo KDD, y la taxonomía de modelos (predictivos vs. descriptivos; supervisado vs. no supervisado). Se destaca la idea crítica de que todo modelo depende de la muestra y de las suposiciones del proceso de muestreo.

Este planteamiento coincide con la **Unidad 1 (Introducción)** del programa de Inteligencia Computacional del Magíster USACH (Prof. Max Chacón) y prepara para los temas evaluados en la PEP1 (ACP, reglas de asociación, clustering) y las unidades posteriores (clasificación bayesiana, árboles de decisión, paradigma conexionista).

Fuente: Evsukoff, A. G. *Inteligencia Computacional: Fundamentos y Aplicaciones*. Rio de Janeiro: E-papers, 2020 (Presentación y Capítulo 1, pp. 8–29). Resumen elaborado para fines académicos en el contexto del curso de Inteligencia Computacional del Magíster en Ingeniería, Universidad de Santiago de Chile (USACH).