

Resumo — Capítulo 1: Introdução

Inteligência Computacional: Fundamentos e Aplicações

Alexandre G. Evsukoff (E-papers, 2020)

1. Contexto histórico e definição

A **inteligência computacional** (IC) é definida pelo autor como um conjunto de paradigmas computacionais para o desenvolvimento e aplicação de sistemas inteligentes em problemas complexos do mundo real. Sua história está entrelaçada com a da inteligência artificial (IA): da reflexão filosófica de Wittgenstein (década de 1920) e do *teste de Turing* (1950), passando pela divisão entre as correntes *simbolista* (provedores de teoremas, sistemas especialistas) e *conexionista* (Perceptron de Rosenblatt, 1958). A limitação do Perceptron como classificador linear levou a uma estagnação até 1986, quando o algoritmo de *retropropagação do erro* (Rumelhart, Hinton e Williams, *Nature*) reabilitou as redes neurais multicamadas, e o algoritmo **ID3** de Quinlan inaugurou o *aprendizado de máquina* simbólico via árvores de decisão.

Nas décadas de 1980–90 surgiram novos paradigmas (sistemas *fuzzy*, redes neurais, máquinas de vetor de suporte, algoritmos evolucionários). Sua integração foi batizada de *soft computing* ou **inteligência computacional**, hoje englobando também métodos estatísticos e de aprendizado de máquina. A partir de 2010 consolida-se o termo *big data* e, desde 2012, as **redes neurais profundas** (*deep learning*) executadas em GPUs alcançam desempenho comparável — ou superior — ao humano em visão computacional e processamento de linguagem natural.

2. Ciência de dados e o processo KDD

A **ciência de dados** situa-se na intersecção de matemática, estatística, computação, engenharia e o conhecimento do domínio da aplicação. Diferencia-se do método científico clássico porque os modelos são construídos *diretamente a partir dos dados observados*, sem partir de hipóteses teóricas. O autor enfatiza que qualquer modelo é uma representação *indireta* do processo real: sua validade está limitada pela qualidade e representatividade da amostra.

O processo de **descoberta de conhecimento em bases de dados (KDD)**, ou *mineração de dados*, é cíclico e compreende as etapas:

1. **Seleção** — escolha do subconjunto e das variáveis (*conjunto de treinamento*).
2. **Limpeza** — tratamento de *outliers* e valores ausentes.
3. **Pré-processamento** — normalização, transformações lineares (e.g. PCA).
4. **Modelagem** — ajuste de parâmetros sobre o conjunto de treinamento.
5. **Avaliação** — estatísticas de validação dos resultados.

A participação do especialista do domínio é fundamental em todas as fases.

3. Tipos de modelos

Um modelo é uma representação simplificada de um processo real. Quanto à origem do conhecimento, distingue-se entre **modelos de conhecimento** (analíticos, baseados em leis físicas) e **modelos de comportamento** (entrada/saída, ajustados por dados) — categoria à qual pertencem essencialmente os modelos de IC.

Quanto ao objetivo, divide-se em problemas **preditivos** e **descritivos**, ajustados respectivamente por algoritmos de *aprendizado supervisionado* e *não supervisionado*; existe ainda o *aprendizado por reforço*, no qual o modelo se ajusta pela interação com o ambiente.

Regressão. Estimativa de uma variável de saída numérica a partir das variáveis de entrada (regressores ou *features*). A regressão linear é o ponto de partida (Cap. 3) e estende-se para séries temporais e sistemas dinâmicos (Cap. 4). A avaliação utiliza o erro de predição.

Classificação. Predição de uma classe discreta a partir dos atributos. Pode ser entendida como busca de *funções discriminantes* que particionam o espaço de entrada. Classes podem ser linearmente separáveis, separáveis não linearmente ou *não separáveis* (caso geral, com erro irreduzível). O conjunto clássico das flores Iris (Fisher, 1936) ilustra o problema. Aplicações: diagnóstico médico, análise de crédito, bioinformática, classificação de documentos e imagens.

Análise de agrupamentos (*clustering*, classificação não supervisionada). Busca grupos de registros similares quando não há variável-alvo. A avaliação da qualidade é difícil — existem medidas externas, internas e relativas, mas o número de grupos costuma ser uma entrada do algoritmo. Aplicações típicas: segmentação de clientes, bioinformática, processamento de imagens.

Outros temas mencionados: *regras de associação*, *aprendizado da representação*, *classificação semi-supervisionada* e *ensembles* (essenciais em competições de ciência de dados como o Prêmio Netflix).

4. Recursos complementares

Bibliografia. Como fundamentação estatística, destacam-se Hastie, Tibshirani e Friedman (*Elements of Statistical Learning*); Bishop (*Pattern Recognition and Machine Learning*); Duda & Hart; Theodoridis & Koutroumbas. Em séries temporais, Box, Jenkins & Reinsel e Ljung. Em IC: Haykin (redes neurais); Pedrycz & Gomide (*fuzzy*); Schölkopf & Smola e Vapnik (SVM e teoria de aprendizado estatístico). Em mineração de dados: Han & Kamber, Tan, Steinbach & Kumar, Aggarwal e Witten & Frank (Weka). Em *deep learning*: Goodfellow, Bengio & Courville. Em português: Rezende (org.), Braga, Carvalho & Ludermir e a tradução de Haykin.

Internet. O *KDnuggets* é o portal de referência. Repositórios de dados: *UCI Machine Learning Repository*, KEEL e plataforma de competições *Kaggle*. Cursos abertos (MOOCs) em Coursera, Udacity, Stanford e MIT — com destaque para o *Machine Learning* de Andrew Ng. Pré-prints em *arXiv* e código em *GitHub*. Conferências principais: KDD, ICDM, NeurIPS, ICML, WCCI (FUZZ-IEEE, IJCNN, IEEE CEC) e, no Brasil, o CBIC da ABRICOM.

Softwares. *Comerciais*: SAS, IBM SPSS Modeler, Statistica, Oracle Data Mining, Microsoft SQL Server Data Mining e plataformas em nuvem (Azure ML, Amazon ML). *Livres*: Weka, RapidMiner, KNIME, Orange. *Linguagens*: Python (pandas, scikit-learn, NumPy, SciPy), R e Matlab (toolboxes de estatística, redes neurais, otimização). Nas enquetes recentes do KDnuggets, R e Python lideram.

5. Síntese e relevância para o curso

O Capítulo 1 fornece o vocabulário mínimo para o restante do livro: distinção entre dado / informação / conhecimento, ciclo KDD, taxonomia de modelos (preditivos vs. descritivos; supervisionado vs. não supervisionado), e a noção crítica de que todo modelo é função da amostra utilizada. Este enquadramento corresponde diretamente à **Unidade 1 (Introdução)** do programa de Inteligência Computacional do Magister USACH (Prof. Max Chacón) e prepara o terreno para os tópicos avaliados na PEP1 (análise de componentes principais, regras de associação, análise de agrupamentos) e nas unidades posteriores sobre classificação bayesiana, árvores de decisão e o paradigma conexionista.

Fonte: Evsukoff, A. G. *Inteligência Computacional: Fundamentos e Aplicações*. Rio de Janeiro: E-papers, 2020 (Apresentação e Capítulo 1, pp. 8–29). ISBN 978-65-87065-02-1. Resumo elaborado para fins acadêmicos no contexto

do curso de Inteligência Computacional do Magíster em Engenharia, Universidade de Santiago de Chile (USACH).