

2 PRÉ-PROCESSAMENTO

O pré-processamento inclui a seleção, limpeza e transformação de dados. O objetivo dessa etapa é a preparação do conjunto de dados que será utilizado para o ajuste do modelo, chamado de **conjunto de treinamento**. Em geral, a etapa de pré-processamento consome de 60% a 80% do tempo de todo o processo de mineração de dados e fornece informações importantes que vão orientar a análise e o ajuste dos modelos.

Este capítulo introduz os conjuntos de dados encontrados em aplicações de ciência de dados. A seguir, são apresentados os principais conceitos estatísticos de métodos exploratórios necessários para o entendimento dos dados e, principalmente, para a interpretação adequada dos resultados da visualização. As técnicas de limpeza de dados e as transformações lineares mais importantes são apresentadas na sequência. Algumas aplicações que utilizam os conceitos discutidos no capítulo são apresentadas no final.

2.1 Conjuntos de Dados

Há uma diferença entre dado, informação e conhecimento [451]. Dado é o registro de um fato, informação é o fato analisado no seu contexto e conhecimento, característica inerentemente humana, é a interpretação da informação num contexto específico visando à sua aplicação. Por exemplo, o preço de uma ação num determinado instante na bolsa de valores é um dado; a variação do preço da ação é uma informação; e a interpretação dessa informação no contexto da conjuntura econômica do momento para a tomada de decisão de investimento é o conhecimento.

Uma metáfora bem-humorada que enfatiza a importância da apresentação da informação é mostrada na Figura 2.1.




Figura 2.1: *Data Cake*. Fonte: epigraphics.com.⁸⁷

Os dados utilizados numa aplicação podem ser estruturados ou não estruturados. Dados estruturados são aqueles organizados em tabelas, nas quais as linhas são os **registros** que representam as observações e as colunas, as **variáveis** ou as características observadas em cada registro, frequentemente chamadas de **atributos**. Os dados não estruturados são aqueles que, na sua forma bruta, não são tabulados. Exemplos de dados não estruturados são imagens, sons, textos, estruturas gráficas etc. Neste livro serão considerados principalmente os modelos de dados estruturados. Modelos de dados não estruturados, principalmente de textos e de estruturas na forma de grafos (redes), têm sido cada vez mais importantes em ciência de dados [295].

Os dados estruturados são armazenados em bases de dados, de onde são selecionados para o ajuste dos modelos. Em sistemas corporativos, os dados podem estar armazenados em diversas bases diferentes. Nesse caso, a extração de dados pode se tornar extremamente complexa e é realizada por processos chamados ETL (*extract, transform and load*). Em ambientes mais simples, a seleção é feita diretamente a partir da base de dados e o conjunto de dados se apresenta na forma de uma tabela ou arquivo de dados.

Num conjunto de dados estruturados, cada linha ou registro contém os valores observados de um conjunto de variáveis. As variáveis podem ser contínuas, discretas ordenadas ou discretas não ordenadas. As variáveis contínuas armazenam valores numéricos do tipo real; as variáveis discretas ordenadas armazenam valores do tipo inteiro; enquanto as variáveis discretas não ordenadas armazenam valores categóricos ou nominais. As variáveis binárias são um tipo especial de variáveis discretas que tem apenas dois valores. Tipicamente, um conjunto de dados pode conter variáveis de diversos tipos. A maioria dos algoritmos de estatística e inteligência computacional trabalha com variáveis numéricas. Nesse caso, as variáveis categóricas são transformadas num conjunto de variáveis binárias chamadas variáveis indicadoras (ou *dummy*).^{*} Há algoritmos especializados em modelos de variáveis nominais – em geral, essa área é conhecida com aprendizado simbólico [392][451].

Neste livro, para facilitar o tratamento matemático dos algoritmos, as variáveis são consideradas numéricas (contínuas ou discretas) e as variáveis nominais são transformadas em variáveis indicadoras binárias no pré-processamento.

Um conjunto de dados é representado por $\mathcal{T} = \{(\mathbf{x}(t), \mathbf{y}(t)), t = 1 \dots N\}$. Cada registro é formado pelo par ordenado $(\mathbf{x}(t), \mathbf{y}(t))$, onde $\mathbf{x}(t)$ é o vetor[†] que contém os valores das variáveis de entrada e $\mathbf{y}(t)$, o vetor contendo os valores das variáveis alvo ou de saída. Sem perda de generalidade, os vetores de variáveis de entrada e saída são escritos como $\mathbf{x}(t) \in \mathcal{R}^p$ e $\mathbf{y}(t) \in \mathcal{R}^q$, onde p e q são, respectivamente, o número de variáveis de entrada e de saída. As variáveis nominais são codificadas como variáveis indicadoras que, assim como as variáveis inteiras, são um subconjunto das variáveis reais.

Problemas de saídas múltiplas ($q > 1$) podem ser representados como múltiplos problemas de saída simples se as variáveis de saída forem desacopladas, ou seja, o valor de uma saída não interfere no valor de outra. Nesse caso, um modelo independente é desenvolvido para cada saída. Em problemas descritivos, não há variáveis de saída e o conjunto de dados contém apenas variáveis de entrada.

^{*} Uma variável nominal com n valores é codificada com n variáveis binárias chamadas variáveis indicadoras, em que cada variável indica a observação de um valor nominal da variável original.

[†] Vetores e matrizes são grafados em negrito, vetores em letras minúsculas e matrizes em letras maiúsculas. Valores escalares são grafados em itálico. Letras maiúsculas gravadas em cursiva, como $\mathcal{A}, \mathcal{B}$ etc., indicam conjuntos. Letras gregas serão usadas para indicar parâmetros de modelos.

Alguns problemas apresentam características especiais que interferem na interpretação do conjunto de dados. Em problemas dinâmicos, existe uma dependência intrínseca entre uma observação e as observações precedentes. Nesse caso, as variáveis são séries temporais em que os registros são apresentados em sequência e o índice $t = 1 \dots N$ representa um instante de tempo. Os problemas em que a ordem das observações não é relevante são chamados estáticos e, nesse caso, qualquer permutação dos registros no conjunto de dados produz o mesmo resultado. Em problemas georreferenciados, existe uma dependência espacial entre as observações e cada registro está associado a duas (ou três) variáveis que representam as coordenadas da observação. Os problemas chamados espaço-temporais combinam essas duas características: contêm variáveis espaciais e os registros são armazenados em sequência. Este livro não aborda especificamente problemas espaciais ou espaço-temporais, apenas a modelagem de sistemas dinâmicos lineares no Capítulo 4.

Para a apresentação matemática dos algoritmos, o conjunto de dados é representado por matrizes. A matriz (de variáveis) de entrada é a matriz $\mathbf{X}$, de dimensão $N \times p$, e a matriz (de variáveis) de saída é a matriz $\mathbf{Y}$, de dimensão $N \times q$. As dimensões das matrizes indicam que os registros estão organizados em linhas e, para cada registro, os vetores* de variáveis de entrada e saída.

A notação apresentada anteriormente será utilizada ao longo do livro. Essa notação unificada facilita o entendimento dos algoritmos e a transposição de conceitos de modelos lineares para os modelos não lineares.

A próxima seção apresenta a primeira etapa na exploração de dados: a caracterização e visualização de dados.

2.2 Caracterização Estatística

A caracterização estatística de dados é uma das etapas mais importantes na ciência de dados. Essa fase permite o entendimento dos dados e facilita a análise dos resultados dos algoritmos.

* Matematicamente, um vetor é uma lista de valores e pode ser tratado como linha ou coluna na multiplicação com matrizes. Neste livro são utilizados vetores linha.

Estatisticamente, um conjunto de dados é tratado como uma amostra de um processo estocástico, ou seja, um processo cujo comportamento é imprevisível, mas pode ser descrito estatisticamente através de uma função de distribuição de probabilidades. O conceito de amostra é muito importante em ciência de dados, uma vez que os modelos serão ajustados a partir de uma amostra e não o processo estocástico. Essa é uma diferença importante entre a abordagem de inteligência computacional e a abordagem estatística, na qual em geral se busca a modelagem do processo [98], a partir de uma hipótese sobre a distribuição de probabilidades.

A maioria dos algoritmos de ciência de dados pressupõe implicitamente que o processo que gerou a amostra representada pelo conjunto de dados é estacionário, ou seja, não varia com o tempo. Dessa forma, podemos utilizar um conjunto de dados coletados num determinado instante para realizar previsões em outro momento uma vez que o processo permanece o mesmo entre o tempo de coleta da amostra e a realização da previsão. Entretanto, essa hipótese pode não ser verdadeira e, nesse caso, os modelos não terão bons resultados de previsão. Esse é tipicamente o caso da modelagem de processos altamente complexos como o mercado financeiro. A caracterização e modelagem de problemas dinâmicos será abordada no Capítulo 4. Neste capítulo, é apresentada a caracterização e visualização de dados de problemas estáticos.

2.2.1 Análise monovariável

O primeiro passo na caracterização estatística de uma amostra é o cálculo de estatísticas das variáveis. Uma estatística é qualquer função obtida a partir de uma amostra. As estatísticas da amostra, em geral, são calculadas para as variáveis de entrada do conjunto de dados, mas podem ser calculadas também para as variáveis de saída. As principais estatísticas são:

- **média**, uma medida do valor central da amostra:

$$\mu \approx \bar{x}_i = \frac{1}{N} \sum_{t=1}^N x_i(t), i = 1 \dots p \quad (2.1)$$

- **variância**, uma medida da dispersão da amostra:

$$Var(x_i) \approx \hat{\sigma}_i^2 = \frac{1}{N-1} \sum_{t=1}^N (x_i(t) - \bar{x}_i)^2, i = 1 \dots p \quad (2.2)$$

O **desvio padrão** estimado da variável $\hat{\sigma}_i \approx \sqrt{Var(x_i)}$ é comumente utilizado para a caracterização da dispersão de uma variável, pois seu valor tem a escala da variável.

Em amostras muito grandes de processos estacionários, a média da amostra é uma boa estimativa da média do processo. Esse resultado é conhecido na estatística como a “lei dos grandes números”. Da mesma forma, a variância da amostra converge para a variância do processo com o aumento do número de registros da amostra. Em conjuntos de dados pequenos, deve-se tomar cuidado ao utilizar essas estatísticas como estimativas de suas correspondentes do processo.

A média e a variância são os parâmetros que definem a função de densidade de probabilidades normal $N(\mu, \sigma^2)$, calculada como:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \quad (2.3)$$

A Figura 2.2a apresenta exemplos da distribuição normal com diversos valores de média e desvio padrão (σ). Quanto maior o desvio padrão, maior a dispersão dos dados e, conseqüentemente, menor a probabilidade da média. Na Figura 2.2b, as funções de distribuição de probabilidades cumulativa dos exemplos mostrados na Figura 2.2a.




Figura 2.2: Distribuição normal: (a) função de densidade de probabilidades; (b) função de probabilidades cumulativa. Fonte: Wikipédia.⁸⁸

A função de distribuição de probabilidades normal, ou simplesmente distribuição normal, é muito importante na estatística. Um dos principais resultados envolvendo a distribuição normal é o teorema central do limite. O teorema estabelece que a distribuição da média de amostras de processos estacionários gerados com qualquer distribuição, de média e variância constantes, converge para uma distribuição normal com a média do processo.

A distribuição normal é representada matematicamente por uma função gaussiana que possui diversas propriedades e é utilizada em inúmeras aplicações. Em inteligência computacional, a função gaussiana aparece como uma função de base para o desenvolvimento de vários tipos de modelos, como será apresentado no Capítulo 7.

Outras estatísticas importantes para a caracterização de dados são:

- valores extremos: **mínimo** e **máximo**;
- a **mediana**: é o valor que divide o conjunto de dados em subconjuntos iguais, ou seja, 50% dos registros são maiores que a mediana, 50% são menores que a mediana. A mediana é o percentil 50 da amostra;
- o **percentil P** é o valor que divide o conjunto de dados de forma que $P\%$ dos registros são menores ou iguais a esse valor;
- a **faixa interquartil** é o intervalo compreendido entre o percentil 25 e o percentil 75, respectivamente chamados de primeiro quartil ($Q1$) e terceiro quartil ($Q3$), sendo a mediana o segundo quartil ($Q2$);
- a **moda**, calculada apenas para variáveis discretas, é o valor observado com maior frequência.

A mediana é uma medida de centralidade da amostra que é insensível a distribuições assimétricas. A média pode dar uma ideia equivocada do valor central de um conjunto de dados na presença de valores aberrantes (*outliers*) ou distribuições assimétricas. A comparação entre a média e a mediana permite detectar facilmente assimetrias na distribuição dos dados. Distribuições assimétricas podem gerar modelos tendenciosos. Da mesma forma, as medidas de dispersão dependem da forma da distribuição. A variância da amostra só tem sentido em distribuições simétricas; no caso de distribuições assimétricas, deve-se utilizar a faixa interquartil.

A Tabela 2.1 apresenta o resultado das estatísticas para as variáveis de entrada do conjunto de dados das flores Iris. Pela comparação entre os valores de média e mediana

(percentil 50), percebe-se uma assimetria na distribuição da variável x_3 . Ao avaliar as estatísticas, é importante observar a escala das variáveis. No caso das Flores Íris, todas as variáveis representam uma medida em centímetros e, portanto, é possível realizar a comparação direta de valores de diferentes variáveis. No caso geral, em que as variáveis representam medidas distintas, recomenda-se que a análise seja feita sobre as variáveis padronizadas (cf. seção 2.3.1).

Tabela 2.1: Estatísticas básicas do problema Íris

	x_1	x_2	x_3	x_4
Mínimos	43,0	20,0	10,0	1,0
Máximos	79,0	44,0	69,0	25,0
Médias	58,4	30,6	37,6	12,0
Desvios	8,3	4,4	17,7	7,6
Percentil 25	51,0	28,0	16,0	3,0
Percentil 50	58,0	30,0	43,5	13,0
Percentil 75	64,0	33,0	51,0	18,0

Em problemas de classificação, é interessante avaliar as variáveis por classe. O **gráfico de linhas** permite que se faça uma avaliação visual das diferenças entre os registros de cada variável por classe e pode ajudar a identificar as variáveis mais relevantes para a separação das classes. No gráfico de linhas, cada variável é um valor no eixo horizontal e cada registro é uma linha ligando as variáveis em seu valor correspondente. A Figura 2.3 mostra um exemplo de gráfico de linhas para o conjunto de dados Íris com variáveis padronizadas (cf. seção 2.3.1). Podemos observar que as classes podem ser mais bem separadas no plano formado pelas variáveis x_3 e x_4 . Essa mesma conclusão será confirmada por outros tipos de gráficos mostrados.




Figura 2.3: Gráficos de linha do problema Íris.

Há várias funções de distribuição de probabilidades⁸⁹, com aplicações em diversas áreas. A distribuição de cada variável pode ser avaliada qualitativamente através de **histogramas** ou diagramas de frequência. Um histograma é uma representação gráfica da distribuição de probabilidade da variável (cf. Figura 2.4). Há diversos métodos estatísticos para o ajuste da função de distribuição de probabilidades [146][238], bem como livros inteiros dedicados ao assunto [482][490].




Figura 2.4: Histogramas e ajuste de distribuições.

As técnicas de inteligência computacional geralmente não levam em conta hipóteses sobre a distribuição de probabilidades que gerou a amostra. Entretanto, a análise dos histogramas é fundamental para o entendimento dos dados e para dar suporte à análise dos resultados do modelo. A avaliação visual dos histogramas pode revelar características indesejáveis na distribuição dos dados, como assimetria e distribuições multimodais (cf. Figura 2.5). Nesses casos, as estimativas de média e desvio padrão podem perder completamente o sentido.




Figura 2.5: Histogramas: (a) distribuição assimétrica; (b) distribuição multimodal.

Em problemas de classificação, os histogramas podem ser calculados por classe, o que permite a análise da distribuição de cada classe no universo da variável. Os histogramas separados por classes das variáveis no conjunto de dados Íris são mostrados na Figura 2.6. Nesse exemplo, os dados são mais misturados nas variáveis x_1 e x_2 que nas variáveis x_3 e x_4 , como observado no gráfico de linhas da Figura 2.3. As variáveis x_3 e x_4 apresentam um comportamento multimodal. Entretanto, ao separar por classes, verifica-se que cada concentração de dados corresponde a uma classe, o que pode ser bastante útil para a construção de classificadores.




Figura 2.6: Histogramas das distribuições das variáveis por classe no problema Íris.

É possível verificar qualitativamente se uma amostra foi gerada por um processo de distribuição normal através do gráfico de probabilidade normal. Nesse tipo de gráfico, se a amostra foi gerada por um processo de distribuição normal, os pontos aparecem alinhados; no caso de uma distribuição não normal, há uma curvatura no gráfico. A Figura 2.7 apresenta os histogramas de uma amostra de duas variáveis e os respectivos gráficos de distribuição normal. As Figura 2.7a e 2.7c mostram a distribuição de uma

variável que pode ser representada por um processo de distribuição normal; as Figura 2.7b e 2.7d mostram a distribuição de uma variável gerada por um processo que não corresponde à distribuição normal.




Figura 2.7: Histogramas e gráficos de probabilidade normal: (a) e (c) amostra gerada por distribuição normal; (b) e (d) amostra gerada por distribuição não normal.

2.2.2 Análise multivariada

A análise das características de cada variável é importante, mas é preciso também considerar igualmente as características multivariadas do processo.

A principal estatística multivariada estimada a partir de uma amostra é a **matriz de covariâncias** $\hat{\Sigma} \in \mathcal{R}^{p \times p}$, cujos elementos $\hat{\sigma}_{ij}^2 = Cov(x_i, x_j)$ são calculados como:

$$Cov(x_i, x_j) \approx \hat{\Sigma} = \frac{1}{N-1} \sum_{t=1}^N (x_i(t) - \bar{x}_i)(x_j(t) - \bar{x}_j), i = 1 \dots p, j = 1 \dots p \quad (2.4)$$

onde $\bar{x}_i$ e $\bar{x}_j$ são, respectivamente, as médias calculadas para cada variável.

A estimativa da matriz de covariâncias pode ser calculada diretamente pela expressão vetorial:

$$\hat{\Sigma} = \frac{1}{N-1} \sum_{t=1}^N (\mathbf{x}(t) - \bar{\mathbf{x}})^T (\mathbf{x}(t) - \bar{\mathbf{x}}) \quad (2.5)$$

onde $\bar{\mathbf{x}} \in \mathcal{R}^p$ é o vetor de médias das variáveis em que cada componente é a média de cada variável definida pela equação (2.1).

Assim como a variância, a matriz de covariâncias da amostra converge para a matriz de covariâncias do processo quando o número de registros da amostra aumenta. A matriz de covariâncias é simétrica ($\hat{\sigma}_{ij}^2 = \hat{\sigma}_{ji}^2$) e definida positiva;* os elementos na diagonal da matriz de covariâncias correspondem às variâncias das variáveis correspondentes, isto é, $\hat{\sigma}_{ii}^2 = \hat{\sigma}_i^2$, onde $\hat{\sigma}_i^2$ é calculado pela equação (2.2).

A matriz de covariâncias Σ e o vetor de médias das variáveis μ são os parâmetros que determinam a função de **distribuição normal multivariada** do processo:

$$f(\mathbf{x}) = \frac{1}{\sqrt{2\pi|\Sigma|}} \exp\left(-\frac{1}{2}(\mathbf{x} - \mu)\Sigma^{-1}(\mathbf{x} - \mu)^T\right) \quad (2.6)$$

onde $|\Sigma|$ é o determinante da matriz de covariâncias. Na prática, a distribuição normal é calculada pela equação (2.6) com a matriz de covariâncias estimadas $\hat{\Sigma}$ e o vetor de médias estimadas $\bar{\mathbf{x}}$.

A matriz de covariâncias indica o grau de acoplamento de cada par de variáveis. Caso as variáveis sejam estatisticamente independentes, ou seja, a variação de uma variável não influencia na variação da outra, os termos fora da diagonal da matriz de covariâncias são nulos, isto é, $\hat{\sigma}_{ij}^2 = 0$, para $i \neq j$. Quando há dependência linear entre as variáveis, os elementos $\hat{\sigma}_{ij}^2 > 0$ indicam a dependência linear positiva, quando as variações são no mesmo sentido, e $\hat{\sigma}_{ij}^2 < 0$ indicam dependência linear negativa, quando as variações ocorrem em sentidos opostos.

A matriz de covariâncias depende da escala das variáveis e, em geral, é mais apropriado utilizar valores padronizados. O coeficiente de correlação de Pearson, ou simplesmente

* Uma matriz $\mathbf{A}$ é definida positiva se $\mathbf{x}\mathbf{A}\mathbf{x}^T > 0, \forall \mathbf{x}$.

coeficiente de correlação, é uma medida padronizada da covariância de duas variáveis e é calculado como:

$$\text{Corr}(x_i, x_j) \approx \hat{\rho}_{ij} = \frac{\text{Cov}(x_i, x_j)}{\sqrt{\text{Var}(x_i)\text{Var}(x_j)}} \quad (2.7)$$

O coeficiente de correlação varia no intervalo $[-1, 1]$ e quanto mais o valor absoluto é próximo de 1, mais as variáveis são correlacionadas, positiva ou negativamente. A **matriz de correlação** é a matriz cujos elementos são os coeficientes de correlação $\hat{\rho}_{ij}$.

Os gráficos de projeção, mostrados na Figura 2.8, ilustram o aspecto de variáveis independentes com correlação positiva ou negativa.




Figura 2.8: Gráfico de projeção das variáveis: (a) $\hat{\rho}_{ij} = 0$; (b) $\hat{\rho}_{ij} > 0$; (c) $\hat{\rho}_{ij} < 0$.

O coeficiente de correlação representa uma medida da redundância entre duas variáveis. Variáveis totalmente correlacionadas (positiva ou negativamente) representam essencialmente a mesma informação e uma delas poderia ser descartada. Entretanto, exceto no caso de correlação total, não é possível decidir sobre qual variável remover apenas a partir da informação de correlação. A análise de componentes principais (ACP), apresentada na seção 2.4.1, tem como objetivo projetar o conjunto de dados num espaço de menor dimensão de variáveis independentes.

É importante observar que o coeficiente de correlação mede apenas a dependência linear, portanto um resultado $\hat{\rho}_{ij} = 0$ não representa que não há relação entre as variáveis, apenas que a relação não é linear.

A correlação entre as variáveis também pode ser visualizada através dos **gráficos de projeção** das variáveis nos planos bidimensionais formados pela combinação de todas

as variáveis duas a duas. Esse gráfico, também chamado de matriz *scatter plot*, apresenta os histogramas na diagonal.

O gráfico de projeção do conjunto de dados Íris é apresentado na Figura 2.9, na qual as cores indicam as classes. O gráfico apresenta uma informação redundante uma vez que os gráficos da diagonal superior são os mesmos da diagonal inferior com os eixos trocados. O gráfico de projeção também confirma que as classes estão mais separadas no plano formado pelas variáveis x_3 e x_4 .




Figura 2.9: Gráfico de projeção do conjunto de dados Íris.

Os gráficos de projeção são uma importante ferramenta de visualização, mas sua utilização requer precauções. Inicialmente, é importante observar que cada gráfico apresenta uma projeção do espaço das variáveis num plano bidimensional. Dessa forma, os dados, principalmente em problemas de classificação, aparecem mais misturados do que são na realidade. Em problemas com um número muito grande de variáveis, a visualização do gráfico de projeção torna-se muito difícil. Em problemas desse tipo, é mais indicado utilizar uma visualização qualitativa da matriz de correlação, como mostra a Figura 2.10 para o caso do problema Ionosphere,⁹⁰ que tem $p = 32$ variáveis.




Figura 2.10: Visualização qualitativa da matriz de correlação no problema Ionosphere.

2.2.3 Matriz de distâncias e similaridades

A análise multivariada previamente apresentada é realizada principalmente a partir do cálculo da matriz de correlação entre as variáveis. A correlação entre duas variáveis pode ser entendida como uma medida de similaridade entre elas. A avaliação da similaridade (ou distância) entre os registros pode revelar características importantes do conjunto de dados, como a presença de *outliers*, por exemplo. As medidas de distância também são utilizadas para preenchimento de valores ausentes (cf. seção 2.3.3) e pela maioria dos algoritmos de análise de agrupamentos. Nesta seção, apresentamos uma introdução às métricas de distância no caso de variáveis numéricas.

Uma função de distância é uma métrica $dist: \mathcal{R}^p \times \mathcal{R}^p \rightarrow \mathcal{R}$ se satisfaz as seguintes propriedades [516]:

a) **não negatividade:**

$$dist(\mathbf{v}, \mathbf{u}) \geq 0, \forall \mathbf{v}, \mathbf{u} \in \mathcal{R}^p,$$

$$dist(\mathbf{v}, \mathbf{u}) = 0, \forall \mathbf{v} = \mathbf{u};$$

b) **simetria:**

$$dist(\mathbf{v}, \mathbf{u}) = dist(\mathbf{u}, \mathbf{v}), \forall \mathbf{v}, \mathbf{u} \in \mathcal{R}^p;$$

c) **desigualdade triangular:**

$$dist(\mathbf{v}, \boldsymbol{\xi}) \leq dist(\mathbf{v}, \mathbf{u}) + dist(\mathbf{u}, \boldsymbol{\xi}), \forall \mathbf{v}, \mathbf{u}, \boldsymbol{\xi} \in \mathcal{R}^p.$$

As funções de similaridade também são utilizadas em algoritmos de agrupamento e análise de *outliers*. Uma função de similaridade $sim: \mathcal{R}^p \times \mathcal{R}^p \rightarrow [0,1]$ satisfaz a propriedade de não negatividade, sendo que $sim(\mathbf{v}, \mathbf{u}) = 1$, apenas se $\mathbf{v} = \mathbf{u}$, e a propriedade

de simetria. Entretanto nem todas as funções de similaridade satisfazem a propriedade de desigualdade triangular, não podendo ser consideradas como métricas.

Diversas funções distância são utilizadas em ciência de dados. As mais importantes são:

- distância **euclidiana** (ou norma L^2): é a extensão da fórmula clássica da geometria para p dimensões:

$$dist_E(\mathbf{v}, \mathbf{u}) = \|\mathbf{v} - \mathbf{u}\| = \sqrt{\sum_{i=1}^p (v_i - u_i)^2} \quad (2.8)$$

- distância de **Mahalanobis**: é a distância geométrica ponderada pelo inverso da matriz de covariâncias estimada no conjunto de dados:

$$dist_{\Sigma}(\mathbf{v}, \mathbf{u}) = \sqrt{(\mathbf{v} - \mathbf{u})^T \hat{\Sigma}^{-1} (\mathbf{v} - \mathbf{u})} \quad (2.9)$$

- distância de **Minkowski**: é uma generalização da distância euclidiana:

$$dist_r(\mathbf{v}, \mathbf{u}) = \left(\sum_{i=1}^p |v_i - u_i|^r \right)^{\frac{1}{r}} \quad (2.10)$$

- distância de **Manhattan** (norma L^1): é um caso particular da distância de Minkowski com $r = 1$:

$$dist_1(\mathbf{v}, \mathbf{u}) = \sum_{i=1}^p |v_i - u_i| = \sum_{i=1}^p \text{abs}(v_i - u_i) \quad (2.11)$$

- distância de **Chebyshev** (norma L^∞): é a distância de Minkowski com $r \rightarrow \infty$:

$$dist_\infty(\mathbf{v}, \mathbf{u}) = \lim_{r \rightarrow \infty} \left(\sum_{i=1}^p |v_i - u_i|^r \right)^{\frac{1}{r}} = \max_i (|v_i - u_i|) \quad (2.12)$$

As funções de similaridade mais comumente empregadas são:

- similaridade do **cosseno**:

$$sim_c(\mathbf{v}, \mathbf{u}) = \frac{\langle \mathbf{v}, \mathbf{u} \rangle}{\|\mathbf{v}\| \|\mathbf{u}\|} \quad (2.13)$$

onde $\langle \mathbf{v}, \mathbf{v} \rangle = \mathbf{v}\mathbf{v}^T = \sum_{i=1}^p v_i v_i$ é o produto escalar e $\|\mathbf{v}\| = \sqrt{\langle \mathbf{v}, \mathbf{v} \rangle}$ é a norma quadrática (L^2) de $\mathbf{v}$;

- similaridade **gaussiana**:

$$sim_G(\mathbf{v}, \mathbf{v}) = \exp\left(-\frac{\|\mathbf{v} - \mathbf{v}\|^2}{2\sigma^2}\right) \quad (2.14)$$

onde σ é um parâmetro de dispersão.

Para cada função de distância (ou similaridade) é possível calcular uma matriz de distâncias (ou similaridades) do conjunto de dados. Em geral, apenas as variáveis de entrada são utilizadas para detecção de *outliers*, preenchimento de valores ausentes ou análise de agrupamento. Dessa forma, a matriz de distâncias calculada sobre o conjunto de treinamento $\mathcal{T} = \{\mathbf{x}(t), t = 1 \dots N\}$ é a matriz $\mathbf{D} \in \mathcal{R}^{N \times N}$, na qual cada elemento $d_{ij} = dist(\mathbf{x}(i), \mathbf{x}(j))$. Analogamente, a matriz de similaridades $\mathbf{A} \in [0,1]^{N \times N}$ e cada elemento $a_{ij} = sim(\mathbf{x}(i), \mathbf{x}(j))$.

Tendo em vista que a matriz de distâncias (ou similaridades) é simétrica, o cálculo dos elementos da matriz triangular envolve $N(N-1)/2$ operações. A complexidade computacional $\mathcal{O}(N^2)$ pode ser um problema no caso de N muito grande.

A visualização da matriz de similaridades (ou distâncias) permite uma análise de todo o conjunto de dados, independentemente do número de variáveis. O gráfico, chamado de **data image**, é uma matriz da dimensão do número de registros em que cada elemento é um valor numa escala de cores que representa a distância ou similaridade entre os registros correspondentes. O *data image* é empregado para detecção de *outliers* [365] e para avaliação da qualidade de agrupamentos [239].

A Figura 2.11 apresenta um exemplo de visualização do conjunto de dados Íris utilizando a distância euclidiana e a similaridade gaussiana. O conjunto de dados contém 50 registros de cada classe e todos os registros são ordenados pela classe. Observa-se na Figura 2.11 a presença de três grupos de registros fortemente similares entre si, representados pelos três quadrados azuis (vermelhos) na Figura 2.11a (Figura 2.11b), representando valores baixos (altos) de distâncias (similaridades). Observando o gráfico de projeção da Figura 2.9, é possível verificar que, no problema Íris, a classe 1 (*Iris setosa*) é separada das demais e que a classe 2 (*Iris versicolor*) e a classe 3 (*Iris virginica*)

são mais próximas entre si. O mesmo efeito pode ser verificado nos gráficos da Figura 2.11, em que as classes 2 e 3 formam praticamente um grupo de dados.




Figura 2.11: *Data image*. (a) Distância euclidiana; (b) similaridade gaussiana.

Há outros gráficos que permitem a análise de um conjunto de dados. Na verdade, a visualização de dados é uma área de pesquisa em grande atividade [490].

Após a caracterização estatística, o conjunto de dados deve ser pré-processado para formar o conjunto de treinamento para o ajuste dos modelos, como descrito a seguir.

2.3 Limpeza de Dados

O processo de mineração de dados (cf. Figura 1.1) começa com a seleção do conjunto de dados brutos da base de dados. O conjunto de dados brutos não é adequado para o ajuste dos modelos pois pode conter variáveis irrelevantes, valores espúrios (*outliers*) ou ausentes, variáveis redundantes ou algum outro tipo de problema específico.

Uma análise preliminar do conjunto de dados pode identificar se alguma variável de entrada não interfere no problema por ter todos os valores idênticos ($\hat{\sigma}_i = 0$). Nesse caso, essa variável (na verdade, uma constante) deve ser eliminada. Outro problema comum é a presença de uma variável que simplesmente identifica os registros, o que também não contribui para o modelo, de forma que deve ser descartada.

Nesta seção, apresentamos alguns procedimentos genéricos que são empregados como prática padrão em ciência de dados. Processamentos mais específicas podem ser necessárias dependendo da aplicação.

2.3.1 Padronização de variáveis

O conjunto de dados brutos frequentemente contém variáveis expressas em escalas diferentes, o que pode interferir nos resultados dos algoritmos. A padronização é uma transformação cujo objetivo é produzir variáveis de mesma escala.

Há diversas técnicas de padronização. No caso mais simples, os valores da variável são escalados no intervalo $[0,1]$, pelos valores de máximo e de mínimo:

$$\hat{x}_i(t) = \frac{x_i(t) - \min_{t=1\dots N}(x_i(t))}{\max_{t=1\dots N}(x_i(t)) - \min_{t=1\dots N}(x_i(t))} \quad (2.15)$$

Esse tipo de padronização, no entanto, não deve ser utilizado na presença de *outliers*, pois o máximo ou mínimo de alguma variável pode estar muito distante dos demais valores, gerando uma distorção na escala de valores padronizados. Na presença de *outliers*, o máximo e mínimo podem ser substituídos pelos valores do 95º percentil e do 5º percentil, respectivamente, ou por outros valores mais adequados para representar os limites superior e inferior da escala.

Há outros tipos de padronização que são robustas a *outliers*. A padronização pela estimativa do *z-score* é muito utilizada e calculada como:

$$\hat{x}_i(t) = \frac{x_i(t) - \bar{x}_i}{\hat{\sigma}_i} \quad (2.16)$$

Nesse caso, a variável padronizada tem média nula e desvio padrão unitário. Em alguns casos, partindo-se da hipótese de que a distribuição da variável pode ser modelada pela distribuição normal (2.3), aplica-se $3\hat{\sigma}_i$ no denominador. Com isso, caso a distribuição seja realmente normal, 99,7% dos valores da variável padronizada estarão dentro do intervalo $[-1, +1]$. Essa padronização é robusta a *outliers*, mas em distribuições altamente assimétricas pode gerar uma distorção de escala, pois utiliza as estatísticas de média e desvio padrão, que são mais apropriadas para distribuições simétricas.

Em distribuições assimétricas, como a da Figura 2.5a, é comum a aplicação da transformação pelo logaritmo para obtenção de uma distribuição simétrica, que é mais adequada para o desenvolvimento de modelos. A transformação pelo logaritmo não pode ser aplicada se a variável contém valores negativos ou nulos. Nesse caso, basta adicionar uma constante maior que o valor mínimo da variável a todos os valores.

As equações (2.15) e (2.16) são lineares e podem ser invertidas se necessário. Há fórmulas não lineares de padronização que não podem ser invertidas.

2.3.2 Detecção de *outliers*

A detecção e remoção de valores espúrios (*outliers*) é um procedimento importante uma vez que esses valores podem prejudicar o desempenho dos modelos. Entretanto, em problemas de detecção de anomalias, como fraudes [54], por exemplo, a descoberta de *outliers* é a solução do problema. Dessa forma, o analista deve avaliar a aplicação e verificar quando os *outliers* são realmente indesejados.

Há diversos métodos para a detecção de *outliers* e a literatura no assunto é extensa [54][270]. Nesta seção, são exploradas duas abordagens principais: a abordagem baseada em distribuições e a baseada em distâncias. A abordagem baseada em distribuições é a abordagem clássica da estatística, que requer uma hipótese sobre a função de distribuição de probabilidades para a amostra para a determinação dos *outliers*. Na abordagem baseada em distâncias, utiliza-se uma função de distância ou similaridade para determinar os registros mais afastados do conjunto de dados, sem considerações sobre a distribuição que gerou a amostra. A abordagem baseada em distribuição é geralmente empregada sobre cada variável independentemente. A abordagem baseada em distâncias considera todas variáveis, mas envolve o custo computacional do cálculo da matriz de distâncias.

A abordagem mais simples para detecção de *outliers* é estimar uma distribuição normal para cada variável. A validade da hipótese de distribuição normal pode ser verificada a partir de gráficos de distribuição normal (cf. Figura 2.7). Caso a hipótese seja confirmada, sabe-se que, numa distribuição normal, 99,7% dos registros encontram-se dentro do intervalo $[\mu - 3\sigma, \mu + 3\sigma]$. Os *outliers* são identificados como os registros contendo valores fora desse intervalo.

No caso de a distribuição das variáveis ser diferente da distribuição normal, pode-se utilizar a ferramenta gráfica conhecida como **box-plot** para a detecção de possíveis *outliers* a partir dos valores de percentil. O gráfico *box-plot* é formado por caixas, como mostra a Figura 2.12, que são calculadas para cada variável. A caixa representa a chamada distância interquartil (IRQ), que é a diferença entre o valor do 75º percentil ou terceiro quartil ($Q3$) e o valor do 25º percentil ou primeiro quartil ($Q1$). A distância

interquartil representa o intervalo de valores da variável em que se encontram 50% dos registros. A linha vermelha no interior da caixa representa a mediana (50º percentil) e permite identificar distribuições assimétricas caso não esteja localizada no centro da caixa. A linha à direita da caixa representa o intervalo $[Q3, Q3 + 1,5IRQ]$ e a linha à esquerda, o intervalo $[Q1 - 1,5IRQ, Q1]$. Pode acontecer que o maior (ou menor) valor observado seja inferior (ou superior) ao limite dos intervalos e as linhas à esquerda e à direita fiquem desiguais. Valores fora desses intervalos são assinalados em vermelho e podem ser considerados *outliers* para a variável correspondente. Dependendo do *software*, as caixas podem aparecer na vertical ou na horizontal e ainda com todas as variáveis no mesmo gráfico ou um gráfico para cada variável.




Figura 2.12: Valores para a construção do *box-plot*.

O *box-plot* depende da escala das variáveis e se o problema contém variáveis em escalas diferentes, é preferível sua avaliação após a padronização. A Figura 2.13 apresenta o *box-plot* do problema Íris antes e após a padronização das variáveis, em pode-se observar o efeito da padronização sobre a dispersão das variáveis.




Figura 2.13: *Box-plot* para o problema Íris: (a) sem padronização; (b) com padronização.

O *box-plot* permite identificar apenas registros suspeitos de serem *outliers*, uma vez que a análise é feita para cada variável independentemente. Não se deve excluir os registros assinalados pelo *box-plot* como *outliers* em uma variável sem uma avaliação prévia dos valores nas outras variáveis.

A visualização do *box-plot* pode auxiliar na caracterização estatística do conjunto de dados, mas não é muito adequada para a detecção de *outliers*. Os métodos baseados em distâncias são mais efetivos, pois consideram todas as variáveis simultaneamente.

Um método simples e bastante eficaz identifica os *outliers* a partir da média ordenada $\hat{m}_i$ das distâncias de um registro $\mathbf{x}(i)$ para todos os outros, calculada a partir da matriz de distâncias $\mathbf{D}$. Os *outliers* são identificados por valores $\hat{m}_i > \delta$, onde o parâmetro δ é identificado por uma análise visual das distâncias médias ordenadas. A avaliação do limite para o corte pode ser evitada especificando-se uma porcentagem P_{out} de registros mais afastados para serem retirados, que é mais fácil de escolher. O procedimento é descrito no Algoritmo 2.1.

A detecção de *outliers* também pode ser realizada com a matriz de similaridades, podendo resultar diferente. Nesse caso, os valores médios m_i são calculados pela similaridade média, a ordenação é feita em ordem decrescente e o critério de detecção é $\hat{m}_i < \delta$ ou os P_{out} registros menos similares.

Algoritmo 2.1: Retirada de *outliers*

Entrada:	Matriz de distâncias $\mathbf{D}$, porcentagem P_{out} de <i>outliers</i> a ser retirada
Saída:	Índice de registros <i>outliers</i>
01	Início
02	Calcule das distâncias médias $m_i = \frac{1}{N} \sum_{j=1}^N d_{ij}$
03	Ordene as distâncias médias $\hat{\mathbf{m}} = \text{sort}(\mathbf{m})$, em ordem crescente
04	Retorna o índice dos P_{out} registros correspondentes aos maiores valores de $\hat{m}_i$
05	Fim

O procedimento de detecção de *outliers* pela distância é apresentado a seguir para o conjunto de dados *Pollution*.⁹¹ Esse é um problema clássico de regressão linear com 15

variáveis de entrada, uma variável de saída e apenas 60 registros. A presença de *outliers* no conjunto de dados é verificada na *data image* da Figura 2.14a, em que um registro (mais precisamente o registro $t = 8$) é bem diferente dos demais, uma vez que a distância desse registro para os demais apresenta uma tonalidade vermelha forte.




Figura 2.14: Matriz de distâncias euclidianas para o problema Pollution: (a) antes da retirada de outliers; (b) após a retirada de outliers.

A média ordenada das distâncias é mostrada na Figura 2.15a, na qual se verifica que quatro registros são identificados como *outliers*. A Figura 2.15b mostra os valores relativos de similaridade média calculados com a similaridade gaussiana. Após a retirada de *outliers* (pela distância euclidiana), a matriz de distâncias apresenta uma configuração mais homogênea, como mostrado no *data image* da Figura 2.14b.




Figura 2.15: Detecção de *outliers*: (a) médias de distâncias euclidianas em ordem crescente; (b) médias de similaridade gaussiana em ordem decrescente.

2.3.3 Valores ausentes

Um valor ausente ocorre em alguma variável quando o valor não pôde ser observado ou foi observado, mas não armazenado. O tratamento de valores ausentes é um assunto importante em ciência de dados, uma vez que conjuntos de dados reais frequentemente apresentam valores ausentes [232]. É importante ressaltar que valor ausente é diferente de valor zero, em que o valor observado é conhecido e igual a zero. A codificação dos valores ausentes na base de dados deve ser feita de forma que o código utilizado para valor ausente não seja confundido com um valor possível da variável. Em muitos conjuntos de dados, os valores ausentes são codificados pelo caractere ‘?’.

Há duas estratégias para o tratamento de valores ausentes: a eliminação do registro contendo valor(es) ausente(s) ou o preenchimento (ou imputação) dos dados ausentes. Na primeira estratégia, deve-se considerar o impacto da eliminação dos registros contendo valores ausentes. Para isso, é importante que seja feito um levantamento do número de valores ausentes em cada variável. Pode ocorrer que a maioria dos valores ausentes esteja em apenas uma variável e, nesse caso, a eliminação da variável pode ser uma alternativa.

A visualização de valores ausentes num conjunto de dados pode revelar alguma falha na aquisição de dados quando os valores ausentes apresentam algum padrão característico. O gráfico da Figura 2.16 apresenta a posição dos valores ausentes das 22 variáveis de entrada no conjunto de dados *Water Treatment Plant*.⁹² O eixo horizontal representa os registros, o eixo vertical representa as variáveis e os valores ausentes são representados em preto. O número de valores ausentes em cada variável é apresentado no gráfico da Figura 2.17. O conjunto de dados contém 527 registros, dos quais 115 (aproximadamente 22%) contêm algum valor ausente.




Figura 2.16: Visualização de valores ausentes.




Figura 2.17: Valores ausentes por variável.

No conjunto de dados *Water Treatment Plant*, a redução de 22% dos registros não inviabiliza completamente a análise e pode-se optar por retirar os registros com valores ausentes ou realizar a imputação de dados. Entretanto, há problemas em que não há opção à imputação de dados.

A dificuldade da imputação de dados é a introdução de uma informação nova que não representa necessariamente a realidade. Introduz-se um erro que pode ter um impacto significativo no desempenho do modelo. O assunto é complexo e há diversas técnicas de imputação de dados ausentes [525][498].

A técnica mais ingênua para a imputação de dados é a substituição do valor ausente pela média. Apesar de simples, essa solução não apresenta bons resultados, principalmente se o número de valores ausentes for grande. O mais recomendado é utilizar algum método preditivo a partir dos valores das demais variáveis. Entretanto, o desenvolvimento de modelos muito elaborados para a imputação de dados não é muito interessante sendo mais indicado utilizar uma solução simples.

Uma solução simples e robusta para a imputação de dados é utilizar o método dos k -vizinhos mais próximos, apresentado no Algoritmo 2.2. O algoritmo utiliza como base para a imputação de dados o conjunto de registros sem valores ausentes definido no passo 02. A estimativa dos valores ausentes é calculada pela média dos k -vizinhos mais próximos do conjunto de dados completos. A média dos vizinhos, calculada no passo 08 do algoritmo, pode ser uma média simples ou ponderada por valores proporcionais ao inverso da distância aos vizinhos. O algoritmo depende da escolha do número k de vizinhos. Recomenda-se a utilização de $k \geq 3$ vizinhos.

Algoritmo 2.2: Imputação de dados pelo método dos k -vizinhos mais próximos

Entrada:	Variáveis de entrada $\{\mathbf{x}(t), t = 1 \dots N\}$ contendo valores ausentes, número de vizinhos k
Saída:	Variáveis de entrada sem valores ausentes
01	Início
02	Defina $\{\mathbf{z}(t), t = 1 \dots N'\}$ o conjunto de dados completos
03	Para cada registro i contendo algum valor ausente
04	Defina $\mathbf{x}^*(i) \subset \mathbf{x}(i)$ o vetor cujas componentes não contêm valor ausente no registro i
05	Defina $\mathbf{z}^*(j) \subset \mathbf{z}(j)$ o vetor de registros completos com as mesmas componentes de $\mathbf{x}^*(i)$
06	Calcule as distâncias $d_{ij} = \text{dist}(\mathbf{x}^*(i), \mathbf{z}^*(j)), j = 1 \dots N'$
07	Ordene as distâncias $\hat{d}_{ij} = \text{sort}(d_{ij})$
08	Calcule os valores ausentes $\mathbf{x}(i)$ pela média das componentes dos k -vizinhos mais próximos
09	Fim Para
10	Retorna $\{\mathbf{x}(t), t = 1 \dots N\}$ sem valores ausentes;
11	Fim

A aplicação do Algoritmo 2.2 permite obter um conjunto de dados completo. Entretanto, a imputação de dados altera ligeiramente as características dos dados. No exemplo do conjunto de dados *Water Treatment Plant*, a Figura 2.18 apresenta a comparação dos histogramas da variável x_{11} , que contém o maior número de valores ausentes (cf. Figura 2.17), com imputação de dados e com a retirada de valores ausentes. A diferença entre os dois histogramas é pequena.

O método dos k -vizinhos mais próximos pode ser empregado em problemas preditivos, como classificação e regressão e tem sido muito utilizado em sistemas de recomendação chamados de filtragem colaborativa.




Figura 2.18: Histogramas da variável x_{11} do problema Waste Treatment Plant: (a) com imputação de dados; (b) com retirada de valores ausentes.

2.4 Transformações Lineares

Uma **transformação linear** [206] $\mathbf{T}: \mathcal{R}^n \rightarrow \mathcal{R}^m$ é definida por uma matriz de dimensão $n \times m$. A transformação $\mathbf{T}$, aplicada ao vetor $\mathbf{x} \in \mathcal{R}^n$, obtém como resultado (imagem) o vetor $\mathbf{z} \in \mathcal{R}^m$, onde $\mathbf{z} = \mathbf{x}\mathbf{T}$.

A utilização de matrizes para o cálculo de transformações lineares permite que uma transformação seja modificada por operações sobre a matriz. Por exemplo, se a matriz $\mathbf{T}$ admitir inversa, a matriz $\mathbf{T}^{-1}$ realiza a transformação inversa $\mathbf{x} = \mathbf{z}\mathbf{T}^{-1}$. A Figura 2.19 apresenta um exemplo de transformação linear e sua inversa.




Figura 2.19: Exemplo de transformação linear.

Uma **transformação linear ortogonal** $\mathbf{U}: \mathcal{R}^n \rightarrow \mathcal{R}^n$ é um tipo particular de transformação linear que realiza uma rotação do espaço de entrada. A transformação ortogonal é realizada por uma matriz ortogonal, cuja inversa é sua transposta: $\mathbf{U}^{-1} = \mathbf{U}^T$. Adici-

onalmente, os vetores formados pelas colunas de uma de matriz ortogonal são ortogonais entre si, ou seja, o produto escalar é igual a zero. A Figura 2.20 apresenta um exemplo de transformação ortogonal e sua inversa.




Figura 2.20: Exemplo de transformação linear ortogonal.

As transformações lineares têm inúmeras aplicações em engenharia. Em ciência de dados, uma transformação linear é utilizada para realizar uma mudança de coordenadas das variáveis de entrada, em geral de menor dimensionalidade, e com características mais apropriadas ao problema. As variáveis transformadas são combinações lineares das variáveis de entrada e, em geral, não podem ser interpretadas. Nesta seção, são apresentadas as principais técnicas de transformações lineares.

2.4.1 Análise de componentes principais

O objetivo da análise de componentes principais (ACP), também conhecida como transformação de Karhunen-Loève [521], é encontrar uma transformação linear que elimina a correlação entre as variáveis de entrada [366][449]. A ACP permite a redução da dimensionalidade do conjunto de dados pela eliminação da redundância provocada pela correlação entre as variáveis. A ACP é realizada por uma matriz de transformação linear ortogonal que, aplicada ao conjunto de dados, gera um novo conjunto de dados de variáveis transformadas não correlacionadas.

A formulação da ACP considera que todas as variáveis de entrada são numéricas, com distribuição normal. O cálculo da matriz de transformação deve ser realizado sobre dados centrados na origem do sistema de coordenadas, o que pode ser obtido pela padronização pelos *z-scores* (2.16). Nesse caso, a matriz de covariâncias estimada é igual à matriz de correlação e é calculada como $\hat{\Sigma} = \frac{1}{N-1} \mathbf{X}^T \mathbf{X}$, onde $\mathbf{X}$ é a matriz de dados de dimensão $N \times p$, contendo os registros das variáveis de entrada.

No conjunto de dados das variáveis transformados $\mathcal{Z} = \{\mathbf{z}(t), t = 1 \dots N\}$, cada registro é calculado como uma combinação linear dos registros correspondentes das variáveis originais, como $\mathbf{z}(t) = \mathbf{x}(t)\mathbf{P}$. A matriz de dados transformados é escrita como:

$$\mathbf{Z} = \mathbf{XP} \quad (2.17)$$

A matriz de transformação $\mathbf{P} \in \mathcal{R}^{p \times p}$ é uma matriz ortogonal calculada pela diagonalização da matriz de covariâncias das variáveis originais. Como resultado, a matriz de covariâncias das variáveis transformadas, $\mathbf{\Lambda} = \frac{1}{N-1}\mathbf{Z}^T\mathbf{Z}$, é diagonal. Escrevendo $\mathbf{\Lambda}$ com a matriz $\mathbf{Z}$ definida em (2.17), temos:*

$$\mathbf{\Lambda} = \frac{1}{N-1}\mathbf{Z}^T\mathbf{Z} = \frac{1}{N-1}(\mathbf{XP})^T(\mathbf{XP}) = \frac{1}{N-1}\mathbf{P}^T\mathbf{X}^T\mathbf{XP} = \mathbf{P}^T\mathbf{\hat{\Sigma}}\mathbf{P} \quad (2.18)$$

A matriz $\mathbf{P}$ é ortogonal, de forma que $\mathbf{P}^T\mathbf{P} = \mathbf{I}$, onde $\mathbf{I}$ é a matriz identidade. Multiplicando ambos os lados da equação $\mathbf{\Lambda} = \mathbf{P}^T\mathbf{\hat{\Sigma}}\mathbf{P}$ por $\mathbf{P}$, temos:

$$\mathbf{\hat{\Sigma}}\mathbf{P} = \mathbf{P}\mathbf{\Lambda} \quad (2.19)$$

A matriz $\mathbf{\Lambda}$ é diagonal, de forma que a equação (2.19) representa p equações $\mathbf{\hat{\Sigma}}\mathbf{p}_i = \lambda_i\mathbf{p}_i$, onde os vetores $\mathbf{p}_i$ são chamados de **autovetores**, e λ_i os **autovalores**. Na ACP, os autovetores da matriz de covariâncias das variáveis originais são chamados de **componentes principais**.

O problema de autovalores e autovetores como (2.19), também chamado de decomposição espectral, é um problema clássico que tem sido estudado desde o século XIX e tem aplicações em inúmeras áreas. Os algoritmos de solução do problema, em suas diversas variantes, estão disponíveis em bibliotecas como EISPACK⁹³ e ARPACK.⁹⁴

A decomposição espectral da matriz de covariâncias pela equação (2.19) fornece informações importantes sobre as características dos dados. Como a matriz de covariâncias é simétrica e definida positiva, os seus autovalores são todos positivos [206]. O maior autovalor λ_{max} é o valor máximo do cociente de Rayleigh:

$$\lambda_{max} = \frac{\mathbf{p}_{max}^T\mathbf{\hat{\Sigma}}\mathbf{p}_{max}}{\mathbf{p}_{max}^T\mathbf{p}_{max}} \geq \frac{\mathbf{v}^T\mathbf{\hat{\Sigma}}\mathbf{v}}{\mathbf{v}^T\mathbf{v}} \quad (2.20)$$

* Utilizando a propriedade de matrizes: $(\mathbf{AB})^T = \mathbf{B}^T\mathbf{A}^T$.

onde $\mathbf{v} \in \mathcal{R}^p$ é um vetor qualquer e $\mathbf{p}_{max}$ é o autovetor correspondente ao maior autovalor λ_{max} .

O cociente de Rayleigh mostra que o autovetor $\mathbf{p}_{max}$ representa a direção de maior variância da amostra (cf. Figura 2.21) e o autovalor λ_{max} mede a variância na direção de $\mathbf{p}_{max}$. Os demais autovetores são ortogonais e representam as outras direções de maior variância.

A matriz $\mathbf{P}$ realiza uma mudança de coordenadas no espaço de variáveis, transformando o conjunto de dados do problema em um novo conjunto de dados de variáveis transformadas pela equação (2.17). Não há correlação entre as variáveis transformadas, de forma que a matriz de covariâncias $\mathbf{\Lambda}$ é diagonal.

A Figura 2.21 apresenta um exemplo da transformação realizada pela matriz de transformação calculada como solução do problema (2.19). Nesse exemplo, o resultado obtido para a matriz $\mathbf{P}$ é a matriz de transformação mostrada na Figura 2.20.




Figura 2.21: Exemplo de transformação linear realizada pela ACP.

Uma propriedade da álgebra linear garante que o traço, isto é, a soma dos elementos da diagonal principal de uma matriz, não se altera pela aplicação de uma transformação linear ortogonal, de forma que:

$$\sum_{i=1}^p \hat{\sigma}_i^2 = \sum_{i=1}^p \lambda_i \quad (2.21)$$

onde $\hat{\sigma}_i^2$ é um elemento da diagonal de $\hat{\mathbf{\Sigma}}$, representa a variância da variável x_i , e λ_i é um elemento da diagonal de $\mathbf{\Lambda}$ que representa a variância da variável transformada z_i .


A equação (2.21) garante que a variância total do conjunto de dados não se altera com a transformação qualquer que seja o arranjo das colunas de $\mathbf{P}$. Na maioria das rotinas,

os autovetores são organizados de tal forma que $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$. Com isso, o primeiro autovetor $\mathbf{p}_1$ corresponde ao maior autovalor λ_1 , sendo, portanto, a direção de máxima variância dos dados e assim sucessivamente. Podemos, então, utilizar as $n < p$ primeiras colunas de $\mathbf{P}$ como a matriz de transformação $\hat{\mathbf{P}} \in \mathcal{R}^{p \times n}$ que vai produzir as variáveis transformadas $\hat{\mathbf{z}}(t) = \mathbf{x}(t)\hat{\mathbf{P}}$, $\hat{\mathbf{z}}(t) \in \mathcal{R}^n$, que explicam a maior parte da variância dos dados. O número n de componentes principais é escolhido de forma que sua variância total das variáveis transformadas, calculada como $\sum_{i=1}^n \lambda_i$, represente uma parcela importante (maior que 85%) da variância total das variáveis originais.


A ACP ajuda a entender o relacionamento entre as variáveis. A Figura 2.22 apresenta os resultados da ACP aplicados ao conjunto de dados Parkinson.⁹⁵ A Figura 2.22a apresenta a matriz de correlação e a Figura 2.22b, os dois componentes principais. Observe que o único elemento negativo do primeiro componente corresponde à variável x_{11} , que tem correlação negativa com todas as variáveis, sendo que as demais têm correlação positiva entre si. O segundo componente separa as variáveis $\{x_1, \dots, x_3\}$, com elementos positivos, das variáveis $\{x_4, \dots, x_9\}$, com elementos negativos, sendo que as variáveis dos dois grupos são bem correlacionadas entre si.

A Figura 2.22c apresenta os resultados dos autovalores no gráfico de Pareto, no qual os rótulos das barras são os valores dos autovalores. As variáveis foram padronizadas pelos *z-scores* de forma que $\hat{\sigma}_i^2 = 1$ e, portanto, $\sum_{i=1}^p \hat{\sigma}_i^2 = p$, ou seja, a variância total é igual ao número de variáveis. Na Figura 2.22c, observa-se que as $n = 7$ componentes principais representam mais que 95% da variância total dos dados. A Figura 2.22d apresenta o conjunto de dados transformados nas coordenadas transformadas pelos dois componentes principais.


As variáveis transformadas são combinações lineares das variáveis originais. Em alguns casos, é possível interpretar as componentes principais ou as variáveis transformadas, mas esse não é o objetivo principal da ACP e nem sempre há uma interpretação razoável no domínio do problema. A obtenção de transformações interpretáveis no domínio do problema é o objeto da análise de fatores [449].




(a)



(b)



(c)



(d)

Figura 2.22: Resultados da ACP no conjunto de dados Parkinson: (a) matriz de correlação; (b) autovetores associados aos dois maiores autovalores; (c) gráfico de Pareto dos autovalores; (d) dados projetados nas duas componentes principais.

A transformação realizada pela ACP não leva em consideração a informação das variáveis de saída. Há transformações lineares que utilizam as variáveis de saída em problemas de classificação e regressão. Em problemas de classificação, a análise discriminante linear (ADL), descrita na seção 2.4.3, resulta em variáveis transformadas em que a separação das classes é máxima. Em problemas de regressão, a análise de correlação canônica, descrita na seção 2.4.4, resulta em transformações lineares que maximizam a correlação entre as variáveis de entrada e saída.

Na próxima seção, apresentamos a decomposição em valores singulares como um método de cálculo alternativo da ACP, que também pode ser aplicada em outros tipos de problemas.

2.4.2 Decomposição em valores singulares

A decomposição em valores singulares (SVD, na sigla em inglês) de uma matriz $\mathbf{A} \in \mathcal{R}^{n \times m}$ é definida como:

$$\mathbf{A} = \mathbf{U}\mathbf{S}\mathbf{V}^T \quad (2.22)$$

onde $\mathbf{U} \in \mathcal{R}^{n \times n}$ e $\mathbf{V} \in \mathcal{R}^{m \times m}$ são matrizes ortogonais cujas colunas $\mathbf{u}_i, i = 1 \dots n$, e $\mathbf{v}_j, j = 1 \dots m$, são chamadas respectivamente de **vetores singulares** à esquerda e à direita; a matriz $\mathbf{S} \in \mathcal{R}^{n \times m}$ é diagonal e seus elementos são chamados de **valores singulares** de $\mathbf{A}$.

A matriz $\mathbf{S}$ tem $n - m$ (ou $m - n$) elementos nulos quando $n > m$ (ou $m > n$). As colunas de $\mathbf{U}$ (ou as linhas de $\mathbf{V}^T$) correspondentes aos elementos nulos de $\mathbf{S}$ formam a base do espaço nulo* da matriz $\mathbf{A}$ [206]. Alguns *softwares* apresentam o resultado do cálculo da SVD eliminando as linhas e colunas correspondentes aos valores singulares nulos, o que é chamado SVD reduzida. A Figura 2.23 apresenta uma ilustração da SVD nos casos de $n > m$ e $m < n$, onde as linhas tracejadas mostram as dimensões das matrizes resultantes da SVD reduzida.

Em geral, a SVD é calculada com os valores singulares em ordem não decrescente como $s_1 \geq s_2 \geq \dots \geq s_r \geq 0$, onde $r \leq \min(n, m)$ é o posto† da matriz $\mathbf{A}$. Uma aproximação de posto r da matriz $\mathbf{A}$ pode ser calculada utilizando apenas as r primeiras colunas de $\mathbf{U}$, $\mathbf{S}$ e $\mathbf{V}$.




Figura 2.23: Ilustração da SVD: (a) com $n > m$; (b) com $m > n$.

O cálculo da SVD é equivalente ao cálculo de decomposição espectral de matrizes simétricas. Utilizando a SVD da matriz de dados do problema $\mathbf{X} = \mathbf{U}\mathbf{S}\mathbf{V}^T$ para o cálculo da matriz de covariâncias, temos:

* O espaço nulo da matriz $\mathbf{A}$, denotado $\text{null}(\mathbf{A})$, é o conjunto de vetores $\{\mathbf{x}: \mathbf{A}\mathbf{x} = \mathbf{0}\}$ [206].

† O posto de uma matriz é o maior número de linhas ou colunas linearmente independentes [206].

$$\mathbf{X}^T \mathbf{X} = (\mathbf{U} \mathbf{S} \mathbf{V}^T)^T \mathbf{U} \mathbf{S} \mathbf{V}^T = \mathbf{V} \mathbf{S} \mathbf{U}^T \mathbf{U} \mathbf{S} \mathbf{V}^T = \mathbf{V} \mathbf{S}^2 \mathbf{V}^T \quad (2.23)$$

Comparando a equação (2.23) com a equação (2.19) escrita na forma $\hat{\Sigma} = \mathbf{P} \mathbf{A} \mathbf{P}^T$, pode-se concluir que os valores singulares $s_i = \sqrt{\lambda_i}$, $i = 1 \dots p$. Os vetores singulares à direita são iguais aos autovetores, isto é, $\mathbf{V} = \mathbf{P}$. A ACP pode ser calculada diretamente pela SVD da matriz $\mathbf{X}$, evitando o produto $\mathbf{X}^T \mathbf{X}$.

A SVD calcula uma decomposição ortogonal de uma matriz não quadrada de elementos reais. A SVD é utilizada para redução de dimensionalidade em recuperação de informação na técnica conhecida como índice de semântica latente [364].

2.4.3 Análise discriminante linear

ACP e SVD não utilizam a informação das variáveis de saída para o cálculo da transformação. Em problemas de classificação, é possível que a projeção realizada pela ACP não seja ótima no sentido de separação das classes. A Figura 2.24 apresenta um exemplo simples em que a projeção dos dados na direção do primeiro componente principal acaba misturando os dados.

A análise discriminante linear (ADL) calcula uma transformação linear que maximiza a separação entre as classes nas coordenadas das variáveis transformadas. A ADL também é chamada de discriminante linear de Fisher [146] devido aos trabalhos de Fisher em 1936 [183].




Figura 2.24: Exemplo de ACP num problema de classificação: (a) dados originais; (b) primeiro componente principal (CP1).

O cálculo da transformação é realizado a partir da decomposição da matriz de variâncias total em $\Sigma_T = \Sigma_B + \Sigma_W$, calculadas respectivamente como [146]:

$$\Sigma_{\mathbf{T}} = \sum_{t=1}^N (\mathbf{x}(t) - \bar{\mathbf{x}})^T (\mathbf{x}(t) - \bar{\mathbf{x}}) \quad (2.24)$$

$$\Sigma_{\mathbf{B}} = \sum_{i=1}^m N_i (\bar{\mathbf{x}}_i - \bar{\mathbf{x}})^T (\bar{\mathbf{x}}_i - \bar{\mathbf{x}}) \quad (2.25)$$

$$\Sigma_{\mathbf{W}} = \sum_{i=1}^m \sum_{\mathbf{x}(t) \in \mathcal{C}_i} (\mathbf{x}(t) - \bar{\mathbf{x}}_i)^T (\mathbf{x}(t) - \bar{\mathbf{x}}_i) \quad (2.26)$$

onde $\bar{\mathbf{x}} \in \mathcal{R}^p$ é o vetor de médias das variáveis, calculado para todos os registros; $\bar{\mathbf{x}}_i \in \mathcal{R}^p$ é o vetor de médias dos N_i registros da classe $\mathcal{C}_i$; $\mathcal{C}_i$ é o conjunto de registros da classe $\mathcal{C}_i$, isto é, $\mathcal{C}_i = \{\mathbf{x}(t) \in \mathcal{T} : y(t) = \mathcal{C}_i\}$, $i = 1 \dots m$, que contém N_i elementos; e m é o número de classes.

A matriz de variâncias total $\Sigma_{\mathbf{T}} = (N - 1)\hat{\Sigma}$, onde $\hat{\Sigma}$ é a estimativa da matriz de covariâncias definida pela equação (2.5). A matriz $\Sigma_{\mathbf{B}}$ mede a variância entre classes, ou seja, a separação entre as classes, e a matriz $\Sigma_{\mathbf{W}}$ mede a variância intraclases, ou seja, entre os registros da mesma classe.

A transformação da ADL é calculada de forma que o novo sistema de coordenadas produza dados com máxima variância entre classes e mínima variância intraclases. Em problemas de duas classes ($m = 2$), a direção $\mathbf{v}$ que maximiza a relação $\Sigma_{\mathbf{B}}/\Sigma_{\mathbf{W}}$ é obtida pela maximização do seguinte coeficiente de Rayleigh:

$$J(\mathbf{v}) = \frac{\mathbf{v}^T \Sigma_{\mathbf{B}} \mathbf{v}}{\mathbf{v}^T \Sigma_{\mathbf{W}} \mathbf{v}} \quad (2.27)$$

onde $\mathbf{v}$ é calculado como solução do problema de autovalor generalizado $\Sigma_{\mathbf{B}} \mathbf{v} = \lambda \Sigma_{\mathbf{W}} \mathbf{v}$. Esse resultado pode ser estendido a problemas de múltiplas classes ($m > 2$), resolvendo-se o seguinte problema de autovalor generalizado [146]:

$$\Sigma_{\mathbf{B}} \mathbf{V} = \Sigma_{\mathbf{W}} \mathbf{V} \mathbf{\Lambda} \quad (2.28)$$

onde $\mathbf{\Lambda}$ é a matriz diagonal dos autovalores generalizados, que contém apenas $m - 1$ elementos e $\mathbf{V}$ é a matriz dos $m - 1$ autovetores generalizados.

O conjunto de dados da variável transformada $\mathbf{Z}$, de dimensão $N \times m - 1$, é calculado pela transformação linear $\mathbf{Z} = \mathbf{XV}$.

A Figura 2.25 apresenta os resultados da ADL para o exemplo da Figura 2.24. Nesse caso, a direção calculada pela ADL é a mesma do segundo componente principal.




Figura 2.25: Resultado da ADL para os dados da Figura 2.24.

Em problemas linearmente separáveis, a ADL é uma solução ótima que permite uma boa aproximação com um número reduzido de componentes. O conjunto de dados *Wine*,⁹⁶ por exemplo, é um problema de classificação com 13 variáveis de entrada contendo os resultados de análises químicas em três categorias de vinhos de uma região da Itália. A Figura 2.26 mostra os resultados da ADL. A Figura 2.26a apresenta os dados transformados e os histogramas das $n = 2$ novas variáveis e a Figura 2.26b mostra os elementos de cada componente da matriz de transformação V .




Figura 2.26: Resultado da ADL no conjunto de dados Wine: (a) dados transformados; (b) componentes da matriz de transformação.

2.4.4 Análise de correlação canônica

Em problemas de classificação, a ADL calcula uma transformação linear que leva em consideração a informação das classes para definir um espaço de coordenadas onde a separação das classes é ótima. Em problemas de regressão, é possível obter um resultado semelhante com a análise de correlação canônica (ACC).

A ACC considera o problema em que há dois conjuntos de variáveis, que representam duas formas diferentes de observar o mesmo fenômeno. O objetivo é calcular duas transformações lineares, uma para cada variável, a partir da correlação cruzada entre as variáveis. Quando aplicadas aos conjuntos de dados iniciais, as transformações produzem novas variáveis que representam a melhor a correlação do conjunto de dados.

A formulação da ACC será apresentada nesta seção utilizando as matrizes de dados de entrada $\mathbf{X} \in \mathcal{R}^{N \times p}$ e saída $\mathbf{Y} \in \mathcal{R}^{N \times q}$ do conjunto de dados de treinamento, mas a ordem dos conjuntos de dados não interfere no processamento. A ACC realiza uma aproximação de menor dimensão da entrada e da saída de um problema de regressão.

A ACC produz novas variáveis $\mathbf{Z}_x = \mathbf{X}\mathbf{U}_x$ e $\mathbf{Z}_y = \mathbf{Y}\mathbf{U}_y$, chamadas de **variáveis canônicas**, ambas de dimensão* $n \leq \min(p, q)$. As transformações lineares $\mathbf{U}_x$ e $\mathbf{U}_y$ são calculadas de forma a maximizar a correlação entre as variáveis canônicas e cada transformação é calculada com os dados das duas variáveis.

Assim como na ACP, as variáveis devem ser padronizadas pelos *z-scores*, resultando em variáveis de média nula e desvio padrão unitário. As transformações lineares ortogonais não alteram as médias e os desvios padrão das variáveis transformadas, de forma que a matriz de correlação cruzada entre as variáveis canônicas é escrita como:

$$\mathbf{Z}_x^T \mathbf{Z}_y = \mathbf{U}_x^T \mathbf{X}^T \mathbf{Y} \mathbf{U}_y \quad (2.29)$$

onde $\mathbf{Z}_x, \mathbf{Z}_y \in \mathcal{R}^{N \times n}$ são as matrizes de dados das variáveis canônicas.

O cálculo das matrizes de transformação na ACC foi proposto inicialmente por Hotelling em 1936 [261]. Nesta seção, utilizamos a formulação proposta por Golub e Zha [207], que é baseada na decomposição ortogonal QR das matrizes de dados:

$$\mathbf{X} = \mathbf{Q}_x \mathbf{R}_x \quad (2.30)$$

* Formalmente, $n = \min(\text{rank}(\mathbf{X}), \text{rank}(\mathbf{Y}))$, onde rank é o posto da matriz.

$$\mathbf{Y} = \mathbf{Q}_y \mathbf{R}_y \quad (2.31)$$

onde as matrizes $\mathbf{Q}_x$ e $\mathbf{Q}_y$ são ortogonais e as matrizes $\mathbf{R}_x$ e $\mathbf{R}_y$ são triangulares superiores. Nesse caso, utilizamos a decomposição QR reduzida, em que a matriz $\mathbf{Q}_x$ ($\mathbf{Q}_y$) tem dimensão $N \times p$ ($N \times q$) e a matriz $\mathbf{R}_x$ ($\mathbf{R}_y$) tem dimensão $p \times p$ ($q \times q$).

Aplicando as decomposições QR definidas nas equações (2.30) e (2.31) na equação (2.29), a correlação cruzada entre os dois conjuntos de variáveis é escrita como:

$$\mathbf{\Lambda} = \mathbf{U}_x^T \mathbf{X}^T \mathbf{Y} \mathbf{U}_y = \mathbf{U}_x^T \mathbf{R}_x^T \mathbf{Q}_x^T \mathbf{Q}_y \mathbf{R}_y \mathbf{U}_y \quad (2.32)$$

A matriz de correlação $\mathbf{\Lambda}$ é diagonal e seus elementos são os valores singulares de $\mathbf{Q}_x^T \mathbf{Q}_y$ [206], chamados de correlações canônicas. As transformações lineares $\mathbf{U}_x$ e $\mathbf{U}_y$ são escritas a partir da SVD $\mathbf{Q}_x^T \mathbf{Q}_y = \mathbf{V}_x \mathbf{S} \mathbf{V}_y^T$. Aplicando o resultado da SVD na equação (2.32):

$$\mathbf{U}_x^T \mathbf{R}_x^T \mathbf{Q}_x^T \mathbf{Q}_y \mathbf{R}_y \mathbf{U}_y = \mathbf{U}_x^T \mathbf{R}_x^T \mathbf{V}_x \mathbf{S} \mathbf{V}_y^T \mathbf{R}_y \mathbf{U}_y \quad (2.33)$$

A ACC calcula a correlação cruzada $\mathbf{\Lambda} = \mathbf{S}$ de tal forma que $\mathbf{U}_x^T \mathbf{R}_x^T \mathbf{V}_x = \mathbf{I}$ e $\mathbf{V}_y^T \mathbf{R}_y \mathbf{U}_y = \mathbf{I}$, onde $\mathbf{I}$ representa a matriz identidade de dimensão do número de componentes canônicos n . As transformações lineares da ACC são calculadas como:

$$\mathbf{U}_x = \mathbf{R}_x^{-1} \mathbf{V}_x^T \quad (2.34)$$

$$\mathbf{U}_y = \mathbf{R}_y^{-1} \mathbf{V}_y \quad (2.35)$$

A formulação anterior é equivalente à maximização do traço da matriz $\mathbf{\Lambda}$ [207], impondo a restrição que as matrizes de transformação devem ser ortogonais.

A aplicação da ACC é mostrada no exemplo de elevação de temperatura adiabática do concreto, que será discutido na seção 3.4.2. O conjunto de dados apresenta 14 variáveis de entrada divididas em dois tipos: cinco variáveis que representam a composição do cimento utilizado e outras nove com os demais aditivos [18]. A elevação de temperatura é parametrizada por 3 variáveis de saída.

Os resultados da ACC são exibidos na Figura 2.27. O número de componentes canônicos neste caso é $n \leq \min(p, q) = 3$. A Figura 2.27a mostra os elementos da correlação cruzada $\mathbf{\Lambda}$. As variáveis canônicas de maior correlação são calculadas como $\mathbf{z}_{x1} = \mathbf{X} \mathbf{u}_{x1}$ e $\mathbf{z}_{y1} = \mathbf{Y} \mathbf{u}_{y1}$, onde $\mathbf{u}_{x1}$ e $\mathbf{u}_{y1}$ são os primeiros componentes de $\mathbf{U}_x$ e $\mathbf{U}_y$. A Figura 2.27c mostra o gráfico de projeção entre as variáveis $\mathbf{z}_{x1}$ e $\mathbf{z}_{y1}$. A Figura 2.27c e a Figura 2.27c mostram respectivamente os elementos dos vetores $\mathbf{u}_{x1}$ e $\mathbf{u}_{y1}$.




Figura 2.27: Resultados da ACC nos dados de elevação de temperatura do concreto:

(a) correlações canônicas; (b) gráfico de projeção das variáveis canônicas;

(c) primeiro componente de U_x ; (d) primeiro componente de U_y .

Esta seção apresentou os principais métodos para o cálculo de transformações lineares sobre o conjunto de dados. Esses métodos utilizam técnicas de cálculo matricial e mostram como pode ser útil a representação de um registro no conjunto de dados como um ponto do espaço vetorial.

As transformações lineares apresentadas nesta seção consideram que a amostra dos dados tem distribuição normal, o que nem sempre é verificado, e o resultado pode não ser representativo. Além disso, muitos problemas reais que contêm variáveis nominais e binárias, que também pode interferir nos resultados.

Aplicações de sumarização e visualização de dados são apresentadas a seguir, assim como a utilização de transformações lineares para validação de medidas.

2.5 Aplicações

2.5.1 Padrões de mobilidade

A universalização da telefonia celular e a difusão de dispositivos móveis conectados à internet transformaram o ser humano num sensor ambulante. O registro da atividade dos usuários fornece uma quantidade sem precedentes de dados, o que tem atraído o interesse de diversos pesquisadores de diferentes áreas [30][70].

Um projeto de pesquisa realizou o estudo de uma base de registros de chamadas por celular na região de código de área 21, que compreende toda a Região Metropolitana do Rio de Janeiro (RMRJ) (cf. detalhe da Figura 2.28). A base de dados utilizada do projeto continha apenas o registro de chamadas de voz realizadas, em que a identificação dos usuários foi criptografada. Há estudos que utilizam registros mais detalhados [53] como chamadas recebidas, mensagens de texto (SMS), registros de conexão com internet, dados processados diretamente pelas antenas ou registros de posicionamento via satélite (GPS) ou registros de redes sociais.

Os registros de chamadas de celulares (CDR)* permitem que o movimento das pessoas seja inferido pela posição da antena (célula) que processou a chamada. Em geral, pelo menos três antenas são posicionadas a 120° em cada torre, de forma que a cobertura por torre pode ser aproximada por um polígono de Voronoi.

A Figura 2.28 mostra a cobertura no Rio de Janeiro, com os polígonos de Voronoi das torres. O posicionamento das torres segue objetivos mercadológicos e técnicos, de forma que a distribuição resultante não é uniforme. Há maior concentração de antenas nas áreas de maior densidade populacional e nível socioeconômico, como o Centro, Tijuca e a Zona Sul. Outras áreas populosas, como Jacarepaguá, Campo Grande, Duque de Caxias e São Gonçalo, têm uma concentração menor de antenas. A geografia da cidade afeta a distribuição de antenas devido à presença de maciços montanhosos dentro da área urbana, como o maciço da Tijuca e o da Pedra Branca, visíveis na Figura 2.28.

* *Call Detail Records.*



Figura 2.28: Polígonos de Voronoi no Rio de Janeiro. No detalhe a cobertura da área 21.

Os dados foram coletados ao longo do ano de 2014, entre 31 de dezembro de 2013 e a 1º de janeiro de 2015, somando 2.1 bilhões de registros referentes a 2.9 milhões de assinantes. Apenas os dados de chamadas de voz realizadas foram disponibilizados para o estudo, o que limita consideravelmente a amostra.

Foi realizada uma modelagem da região de estudo pelo agrupamento de polígonos de Voronoi em áreas que aproximam unidades demográficas do IBGE. A identificação de residência presumida dos usuários permitiu a junção dos resultados de mobilidade com dados demográficos e socioeconômicos. Os dados de CDR foram utilizados para estimativa de matrizes origem-destino (OD) para cada dia para análise dos padrões de mobilidade na RMRJ [87][88]. Os resultados do processamento para cada dia estão disponíveis no Dataverse.⁹⁷

Os dois padrões de mobilidade mais comuns são mostrados na Figura 2.30 e na Figura 2.30 [88]. A Figura 2.30 apresenta o número de viagens estimadas entre o Centro (AP1) e Zona Sul (AP2) e representa o padrão casa-trabalho, com grande regularidade, maior número de viagens durante a semana e estimativas semelhantes na ida e na volta.

A Figura 2.30 mostra o número de viagens estimadas entre a Zona Sul (AP2) e Teresópolis, uma cidade turística na Região Serrana do Estado. Neste caso, o padrão é totalmente diferente, o maior número de viagens ocorre nos finais de semana, com picos nos feriados, e há uma defasagem entre a ida e a volta.




Figura 2.29: Número de viagens Centro (AP1) – Zona Sul (AP2). Fonte: reproduzido de [88].




Figura 2.30: Número de viagens Zona Sul (AP2) – Teresópolis. Fonte: reproduzido de [88].

Há diversos estudos de mobilidade a indicadores sociais a partir de dados de telefonia celular [117][526]. Os resultados obtidos mostram que os dados de registros de chamadas de celular podem ser uma alternativa de baixo custo para a modelagem de problemas complexos das cidades modernas.

Atualmente, há uma grande oferta de dados públicos e muitas cidades no mundo mantêm portais de dados abertos. No Rio de Janeiro, o portal data.rio⁹⁸ mantém uma base de dados pública para consulta. Nesse portal, é possível acessar em tempo real os dados de localização (GPS) dos ônibus municipais urbanos.

Um estudo sobre a velocidade dos ônibus na cidade foi feito pela Coppe/UFRJ em parceria com o Centro de Pesquisas da Dell-EMC. O resultado da velocidade média diária nas vias da cidade é mostrado na Figura 2.32, na qual os valores de velocidade são representados por uma escala de cores e a largura do traço representa o número de linhas de ônibus que passam na via. Pode-se verificar que as vias expressas apresentam as maiores velocidades médias (verde), enquanto as vias em áreas com maior densidade urbana têm velocidade reduzida (vermelho). As principais áreas de concentração

da cidade podem ser identificadas no mapa: zona Sul, Centro, Tijuca, Meier, Madureira, Jacarepaguá, Bangu, Campo Grande e Santa Cruz.

A visualização e caracterização estatística dos dados é uma etapa fundamental para o entendimento do problema. Os exemplos apresentados nesta seção ilustram exemplos de visualização de dados georreferenciados utilizando sistemas de informação geográfica⁹⁹ em conjunto com servidores de mapas na internet.




Figura 2.31: Velocidade média dos ônibus na cidade do Rio de Janeiro às 19:00.

A próxima seção mostra uma aplicação de transformações lineares para a validação de medidas em sistemas de diagnóstico.

2.5.2 Equações de paridade

O monitoramento de processos complexos é realizado com dados coletados por sensores cujo funcionamento deve ser continuamente verificado para evitar que alguma perturbação nas medidas seja confundida com uma falha no processo. O método de validação de medidas por equações de paridade utiliza a redundância de informações contida nas medidas para gerar indicadores de falha através de transformações lineares. A redundância pode ser direta, na qual existe mais de um sensor para uma mesma medida, ou indireta, quando as medidas produzidas por um conjunto de sensores devem

preservar alguma coerência entre seus valores. A análise de componentes principais (ACP) pode ser aplicada para a síntese de um sistema de validação de medidas por equações de paridade em sistemas lineares estáticos.

Considere um conjunto de p sensores, cujas medidas são representadas pelas componentes do vetor $\mathbf{x}(t) \in \mathcal{R}^p$. As medidas se relacionam com um conjunto de estados $\mathbf{z}(t) \in \mathcal{R}^n$ pela equação de medidas:

$$\mathbf{x}(t) = \mathbf{z}(t)\mathbf{C}^T + \Delta\mathbf{x}(t) + \mathbf{e}(t) \quad (2.36)$$

onde $\mathbf{C}$, de dimensão $p \times n$, é a matriz de medidas, $\Delta\mathbf{x}(t) \in \mathcal{R}^n$ representa falhas aditivas nos sensores e $\mathbf{e}(t) \in \mathcal{R}^n$ é um ruído de média nula e variância constante.

As medidas são padronizadas através dos *z-scores* (cf. equação (2.16)) e têm média nula e desvio padrão unitário. Há redundância de informações quando a dimensão do vetor de medidas $p > n$. Nesse caso, pode-se utilizar a informação redundante para detecção de falhas nos sensores.

Um método robusto e bastante conhecido para validação de sensores é baseado nas equações de paridade [201]. Essa técnica tem sido utilizada em diversas aplicações e consiste em projetar o vetor de medidas num espaço de dimensão $m = p - n$, chamado **espaço de paridades**. O vetor de paridades é calculado como:

$$\mathbf{u}(t) = \mathbf{x}(t)\mathbf{W} \quad (2.37)$$

onde $\mathbf{W}$, de dimensão $p \times m$, é a matriz de projeção e $\mathbf{u}(t) \in \mathcal{R}^m$, o vetor de paridade.

O vetor de paridades é um indicador de falhas que é nulo na ausência delas. Dessa forma, a matriz de projeção deve ser ortogonal à matriz de medidas:

$$\mathbf{C}^T\mathbf{W} = \mathbf{0} \quad (2.38)$$

Reescrevendo a equação (2.37) considerando a equação de medidas (2.36) e a restrição imposta pela equação (2.38), o vetor de paridade é calculado como:

$$\mathbf{u}(t) = (\mathbf{z}(t)\mathbf{C}^T + \Delta\mathbf{x}(t) + \mathbf{e}(t))\mathbf{W} = (\Delta\mathbf{x}(t) + \mathbf{e}(t))\mathbf{W} \quad (2.39)$$

Pela equação (2.39), pode-se perceber que o vetor de paridades representa apenas as falhas e incertezas (ruído) no processo, independentemente do valor dos estados. Assim, um evento externo que altera de forma consistente todas as medidas não altera significativamente o valor do vetor de paridade.

Cada linha da matriz $\mathbf{W}$ representa uma direção de falha no espaço de paridades. Uma perturbação aditiva numa medida provoca um acréscimo do vetor de paridade na direção correspondente. A identificação da falha é realizada comparando-se a direção do vetor de paridade com as direções definidas pela matriz de projeção.

Considere o exemplo de um sistema com redundância material em que $p = 4$ sensores são utilizados para observar os valores de $n = 2$ estados, com as seguintes matrizes de medidas e de projeção:

$$\mathbf{C}^T = \begin{bmatrix} 1.0 & 1.0 & 0.0 & 0.0 \\ 0.0 & 0.0 & 1.0 & 1.0 \end{bmatrix}, \quad \mathbf{W}^T = \begin{bmatrix} 0.5 & -0.5 & 0.5 & -0.5 \\ 0.5 & -0.5 & -0.5 & 0.5 \end{bmatrix} \quad (2.40)$$

O espaço de paridades e as direções de falha associadas a cada medida neste exemplo são mostrados na Figura 2.32. O parâmetro ξ representa uma tolerância para o módulo do vetor de paridade a fim de acomodar o ruído do processo (cf. equação (2.37)), de tal forma que a detecção é feita somente se $\|\mathbf{u}(t)\| > \xi$.




Figura 2.32: Direções de falha no espaço de paridades.

O método de equações de paridades garante a capacidade do sistema de detectar falhas simples, ou seja, falha aditiva em apenas uma medida. Em caso de falhas múltiplas, uma combinação de falhas pode anular o vetor de paridades e o vetor de perturbações deve representar assinaturas de falha. Dependendo da dimensão do vetor de paridades, pode não ser possível isolar todas as falhas. O método não se aplica em caso de falhas que afetam o comportamento do processo.

As matrizes de medida e de projeção do método de equações de paridade podem ser geradas a partir da ACP apresentada na seção 2.4.1. Considere um conjunto de registros do vetor de medidas $\mathcal{T} = \{\mathbf{x}(t), t = 1 \dots N\}$. A matriz de covariâncias estimada é calculada como $\hat{\mathbf{\Sigma}} = \frac{1}{N-1} \mathbf{X}^T \mathbf{X}$, onde $\mathbf{X}$, de dimensão $N \times p$, contém os registros das variáveis de entrada. A ACP é calculada pela diagonalização da matriz $\hat{\mathbf{\Sigma}}$ pela solução do problema de autovalor definido na equação (2.19):

$$\hat{\mathbf{\Sigma}} \mathbf{P} = \mathbf{P} \mathbf{\Lambda} \quad (2.41)$$

onde as colunas da matriz $\mathbf{P}$ são os autovetores (componentes principais) e os autovalores da matriz diagonal $\mathbf{\Lambda}$ representam a variância da variável transformada.

As variáveis transformadas pela ACP podem ser utilizadas para o cálculo de equações de paridades, considerando a matriz de componentes principais composta pelas matrizes de medida e de projeção como $\mathbf{P} = [\mathbf{C} \mid \mathbf{W}]$. As colunas da matriz de componentes principais, de dimensão $p \times p$, são ortogonais, de forma que a condição (2.38) é satisfeita. A síntese do sistema de validação de medidas pela ACP consiste em escolher as dimensões n e m dos espaços de estados e de paridade. Tendo em vista que $p = n + m$, quanto maior a redundância das medidas, menor a dimensão dos estados n e maior a dimensão do vetor de paridades m .

O valor do parâmetro ξ para a detecção de falhas pode ser estimado pela variância total não representada pelo vetor de estados e calculado pela soma dos autovalores correspondentes às componentes do vetor de paridade:

$$\xi = \sqrt{\sum_{i=n+1}^p \lambda_i} \quad (2.42)$$

onde λ_i é o autovalor da matriz $\mathbf{\Lambda}$ correspondente às colunas $i = n + 1, \dots, p$.

O método de equações de paridade foi utilizado para validação de medidas de deformações da Usina Hidrelétrica (UHE) de Funil¹⁰⁰ por extensômetros de concreto. O conjunto de dados cobria o período entre 20/07/1967 e 30/11/2005, num total de 2.161 registros. Os registros com valores ausentes foram eliminados para o cálculo das matrizes de medida e projeção, que foi realizado com os $N = 380$ registros completos de 21 variáveis.

O método de equações de paridade é imune à presença de valores ausentes, uma vez que apenas as perturbações medidas são consideradas no cálculo do vetor de paridade (cf. equação (2.39)). O resultado do método de equações de paridade é mostrado na Figura 2.33, na qual os registros em cinza representam os valores ausentes e, em preto, os registros identificados com falha. Observe que, em alguns casos, a ocorrência de falha está associada à retirada do sensor de operação.




Figura 2.33: Resultado da validação de sensores.

2.6 Comentários Finais

Este capítulo apresentou técnicas básicas utilizadas na etapa de pré-processamento do conjunto de dados. Um aprofundamento sobre a teoria das probabilidades e álgebra linear é uma base importante de inteligência computacional [146][298]. Há diversos livros que abordam o assunto, como Montgomery [400] e Heath [244] que apresenta uma visão dos conceitos de cálculo matricial. O livro de Heath tem também uma página na internet¹⁰¹ que fornece vários recursos associados ao tema.

As medidas de caracterização estatística apresentadas são as mais usuais e que estão presentes na maioria dos *softwares* e linguagens de programação. O assunto continua sendo explorado na literatura [490] e diferentes soluções disponíveis.¹⁰²

Alguns métodos de redução de dimensionalidade não foram abordados na seção 2.4, cujo foco é apenas em transformações lineares. Outras transformações conhecidas, como o *Local Linear Embedding* (LLE), a análise de componentes independentes (ICA),

entre outras, não foram apresentadas pois envolvem algoritmos não lineares. Uma discussão de diversos métodos lineares e não lineares, incluindo uma extensa revisão bibliográfica no assunto, pode ser encontrada em [357], disponível para *download*,¹⁰³ onde é possível obter uma biblioteca Matlab contendo a implementação dos métodos.

As técnicas de cálculo matricial têm sido cada vez mais empregadas em ciência de dados, especialmente para análise de grandes bases de dados, como a internet, e bases de dados multidimensionais [493][106]. Os métodos lineares são estendidos para o caso não linear utilizando métodos baseados em função de núcleo [478]. As funções de núcleo serão apresentadas no Capítulo 7 no contexto de aproximação de funções com modelos SVM. Livros recentes apresentam as funções de núcleo e a matriz de núcleo nos capítulos iniciais como forma de representação dos dados [593], uma vez que funções de núcleo podem ser utilizadas em registros que não têm uma representação vetorial.

Neste livro, os capítulos iniciais abordam os fundamentos e, por isso, apenas os métodos mais simples são apresentados. O próximo capítulo discute o modelo de regressão linear e o método dos mínimos quadrados. Os algoritmos preditivos não lineares para regressão e classificação são apresentados nos Capítulos 7, 8 e 9.