

3 REGRESSÃO LINEAR

A regressão linear é uma técnica clássica da estatística cujo objetivo é o ajuste de um modelo que relaciona uma ou mais variáveis de entrada, ou independentes, com uma ou mais variáveis de saída, ou dependentes. Em ciência de dados, a regressão (linear ou não linear) também é chamada de predição [232]. Em inteligência computacional, utiliza-se frequentemente o termo aproximação de funções [298].

O modelo de regressão linear permite que os desafios associados ao desenvolvimento de modelos complexos sejam apresentados de uma forma clara e analítica. Os conceitos introduzidos neste capítulo servirão de base para modelos não lineares apresentados nos Capítulos 7, 8 e 9. Na prática, o modelo linear é sempre o primeiro que o analista deve construir devido a sua simplicidade, baixo custo computacional e também para obter um limite inferior de desempenho para modelos não lineares. Não são raros os problemas em que a diferença de desempenho entre um modelo linear e outro modelo mais elaborado (como uma rede neural, por exemplo) seja menor que 5%. Entretanto, há casos em que a relação entre as variáveis de entrada e saída é intrinsecamente não linear e modelos mais complexos obtêm melhores resultados.

Neste capítulo, apresentamos o problema de regressão linear e sua solução através do método dos mínimos quadrados. Em seguida, abordamos o dilema entre *bias* e variância, que é essencial para o desenvolvimento de um bom modelo. As técnicas de regularização, ou suavização de modelos, são também discutidas neste capítulo. Finalmente, introduzimos as estatísticas para validação de modelos de regressão, que também serão utilizadas para avaliação de modelos não lineares.

3.1 O Problema de Regressão

Conforme apresentado no Capítulo 2, o conjunto de dados é representado neste livro por $\mathcal{T} = \{(\mathbf{x}(t), \mathbf{y}(t)), t = 1 \dots N\}$, onde cada registro é formado por pares ordenados $(\mathbf{x}(t), \mathbf{y}(t))$, sendo $\mathbf{x}(t) \in \mathcal{R}^p$ o vetor das variáveis de entrada e $\mathbf{y}(t) \in \mathcal{R}^q$ o vetor das variáveis de saída.

As variáveis de entrada não numéricas podem ser transformadas num conjunto de variáveis binárias chamadas variáveis indicadoras ou *dummy* [399]. As variáveis de saída não numéricas caracterizam o problema de classificação que será abordado no Capítulo 5. Nesse capítulo, a regressão linear é apresentada considerando variáveis de entrada numéricas e uma única variável de saída numérica, ou seja, $q = 1$ e $y(t) \in \mathcal{R}$. Os problemas de regressão de saídas múltiplas podem, na maioria dos casos, ser modelados por modelos independentes de saída simples.

No problema de regressão linear simples, uma única variável de entrada ($p = 1$) se relaciona linearmente com a variável de saída pela equação da reta $y(t) = ax(t) + b$ (cf. Figura 3.1). Na prática, a relação real não pode ser observada e os dados contêm perturbações de diversas origens, como erro de leitura, efeito de variáveis não observadas etc. Dessa forma, os registros observados, armazenados no conjunto de dados, contêm perturbações, como os pontos em azul na Figura 3.1. O modelo é ajustado a partir desses registros observados e, portanto, incorpora os erros de observação em seus parâmetros, sendo descrito por $\hat{y}(t) = \hat{a}x(t) + \hat{b}$, onde $\hat{y}(t)$ é o valor da variável de saída calculado pelo modelo e $\hat{a}$ e $\hat{b}$ são os parâmetros ajustados. O erro de ajuste ou **resíduo do modelo** é a diferença entre os valores observado e calculado pelo modelo da variável de saída, isto é, $e(t) = y(t) - \hat{y}(t)$, para cada registro do conjunto de treinamento.

O que se espera é que o modelo seja o mais próximo possível da relação real, pois sabemos que as perturbações têm origem aleatória. Assim, quanto mais próximo da relação real, melhor será o desempenho do modelo para a predição de novos dados, ou seja, registros diferentes dos que foram armazenados no conjunto de treinamento, mas gerados com a mesma distribuição.




Figura 3.1: Exemplo de regressão linear.

Na hipótese da relação entre a variável de entrada e saída ser linear, os parâmetros do modelo podem ser facilmente ajustados pela minimização do erro total no conjunto de treinamento. O problema é que, na prática, não se conhece ou não há elementos para determinar o tipo de função que relaciona as variáveis de entrada e saída. A variedade de *softwares* e alternativas de modelagem é tão grande que, frequentemente, o analista pode ajustar um modelo cuja complexidade é maior do que a complexidade da relação, como mostra a Figura 3.2a. Nesse caso, diz-se que ocorreu sobre ajuste, ou **overfitting**, no jargão de ciência de dados.




Figura 3.2: Exemplo de regressão linear com *overfitting*: (a) treinamento; (b) teste.

O *overfitting* é um efeito indesejado, pois, como as perturbações são aleatórias, uma nova amostra de teste pode produzir dados diferentes dos que foram utilizados para o

treinamento e, nesse caso, o erro produzido pelo modelo mais complexo é maior que aquele que seria obtido por um modelo mais próximo da relação ideal (cf. Figura 3.2b).

O raciocínio desenvolvido anteriormente para o modelo linear simples contém os elementos principais e resume o problema de regressão: como ajustar um modelo a partir de dados observados que seja o mais próximo possível da relação real entre as variáveis que geraram a amostra. A obtenção do modelo, portanto, depende da escolha adequada da forma da relação entre as variáveis de entrada e saída, que é a **estrutura** do modelo. Essa relação é geralmente representada por uma função matemática definida por um conjunto de parâmetros. O ajuste dos parâmetros do modelo é feito pela minimização do erro (ou resíduo) entre os valores observados e calculados pelo modelo da variável de saída no conjunto de treinamento. O método de ajuste de parâmetros da regressão linear é o método dos mínimos quadrados, apresentado na seção 3.1.2, mas antes definimos o modelo linear na próxima seção.

3.1.1 O Modelo linear

O modelo de regressão linear calcula uma estimativa $\hat{y}(t) \in \mathcal{R}$ da variável de saída a partir das variáveis de entrada $\mathbf{x}(t) \in \mathcal{R}^p$ e dos parâmetros do modelo como:

$$\hat{y}(t) = \hat{f}(\mathbf{x}(t), \boldsymbol{\theta}) = \hat{\mathbf{x}}(t)\boldsymbol{\theta}^T = \sum_{i=1}^n \hat{x}_i(t)\theta_i \quad (3.1)$$

onde os elementos do vetor $\hat{\mathbf{x}}(t) \in \mathcal{R}^n$ são chamados **regressores** do modelo e o vetor de **parâmetros** $\boldsymbol{\theta} = (\theta_1, \dots, \theta_n)$. A notação $\hat{f}(\mathbf{x}(t), \boldsymbol{\theta})$ indica que a previsão de $\hat{y}(t)$ calculada no ponto $\mathbf{x}(t)$ depende dos parâmetros $\boldsymbol{\theta}$.

O modelo $\hat{f}(\mathbf{x}(t), \boldsymbol{\theta})$ é uma aproximação da função real $y(t) = f(\mathbf{x}(t))$, que relaciona as variáveis de entrada com a saída observada, que em geral é desconhecida.

O termo “linear” de regressão linear indica que o modelo é linear nos parâmetros, ou seja, que o valor de saída é calculado como uma combinação linear dos regressores. No modelo linear simples, ou linear de primeira ordem, os regressores são as próprias variáveis de entrada e o modelo é um hiperplano. Nesse caso, o vetor de regressores é $\hat{\mathbf{x}}(t) = [1, \mathbf{x}(t)]$, onde o primeiro regressor é incluído para o ajuste do termo independente. O vetor de parâmetros tem dimensão $n = p + 1$ e o modelo escrito como:

$$\hat{y}(t) = \hat{f}(\mathbf{x}(t), \boldsymbol{\theta}) = \theta_0 + \sum_{i=1}^p x_i(t) \theta_i \quad (3.2)$$

A formulação da regressão linear é geral o suficiente para acomodar outras estruturas de modelos mais complexos. Nesse caso, a formulação do modelo é uma combinação linear dos regressores, mas seu resultado é uma função não linear. De uma forma geral, o vetor de regressores é escrito como $\hat{\mathbf{x}}(t) = (1, h_1(\mathbf{x}(t)), \dots, h_n(\mathbf{x}(t)))$, onde $h_i(\mathbf{x}(t))$ são chamadas funções de base [238], como será visto no Capítulo 7.

Um exemplo de modelo linear que resulta em funções não lineares é o modelo polinomial, em que $h_i(\mathbf{x}(t)) = \mathbf{x}(t)^i$. O modelo linear polinomial de grau r é escrito na forma:

$$\hat{y}(t) = f(\mathbf{x}(t), \boldsymbol{\theta}) = \theta_0 + \sum_{i=1}^r \mathbf{x}(t)^i \boldsymbol{\theta}_i^T \quad (3.3)$$

onde o vetor de regressores $\hat{\mathbf{x}}(t) = [1, \mathbf{x}(t), \mathbf{x}(t)^2, \dots, \mathbf{x}(t)^r]$, desprezando-se os termos cruzados; $\boldsymbol{\theta}_i = (\theta_{i1}, \dots, \theta_{ip})$ é o vetor de parâmetros de cada termo do polinômio e o vetor de parâmetros do modelo $\boldsymbol{\theta} = [\theta_0, \boldsymbol{\theta}_1, \dots, \boldsymbol{\theta}_r]$, que tem $n = (r \cdot p) + 1$ elementos.

O ajuste dos parâmetros do modelo linear é realizado pela minimização do erro médio quadrático. O algoritmo de ajuste mais simples para regressão linear é o método dos mínimos quadrados, apresentado a seguir.

3.1.2 Método dos mínimos quadrados

O resultado do modelo geralmente não é igual ao valor observado da variável de saída e haverá sempre um erro ou resíduo $e(t) = y(t) - \hat{y}(t)$ (cf. Figura 3.1). Uma citação atribuída a George Box diz que “todos os modelos estão errados, alguns são úteis”.

A qualidade de um modelo de dados é medida por uma função de avaliação que mede a discrepância entre o valor observado e o valor calculado pelo modelo [98]. A função de avaliação utilizada em problemas de regressão linear é o erro médio quadrático (EMQ), calculado no conjunto de treinamento:

$$\text{EMQ}(\boldsymbol{\theta}) = \frac{1}{N} \sum_{t=1}^N (y(t) - \hat{y}(t))^2 = \frac{1}{N} \sum_{t=1}^N (y(t) - \hat{f}(\mathbf{x}(t), \boldsymbol{\theta}))^2 \quad (3.4)$$

O EMQ é uma medida de distância entre o valor observado e o valor predito pelo modelo em cada registro do conjunto de treinamento. Estatisticamente, o EMQ pressupõe que o resíduo $e(t) = y(t) - \hat{y}(t)$ tem distribuição normal, de média nula e variância constante. Essa hipótese considera implicitamente que o processo que gerou os dados é estacionário, ou seja, que as características estatísticas permanecem estáveis. Nesse caso, a minimização do EMQ corresponde a maximizar a função de verossimilhança entre o modelo e a variável de saída [84][399], como será visto na seção 9.2.2

Se as hipóteses são satisfeitas, o ajuste dos parâmetros do modelo é realizado pela minimização do EMQ, o que caracteriza o **método dos mínimos quadrados** (MMQ). O MMQ produz os parâmetros de mínima variância [238]. Entretanto, nem sempre todas as hipóteses são satisfeitas, mas, mesmo assim, o MMQ obtém bons resultados.

A apresentação do MMQ é mais elegante considerando a matriz de saída $\mathbf{Y}$, cujos elementos são os valores das variáveis de saída de todos os registros do conjunto de treinamento, e a matriz $\hat{\mathbf{X}}$, cujas linhas contêm os regressores dos registros do conjunto de treinamento. Nesse caso, o EMQ é escrito como:

$$EMQ(\boldsymbol{\theta}) = \frac{1}{N} (\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}^T)^T (\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}^T) \quad (3.5)$$

$$\text{onde } \hat{\mathbf{X}} = \begin{bmatrix} \hat{x}_1(1) & \cdots & \hat{x}_n(1) \\ \vdots & \ddots & \vdots \\ \hat{x}_1(N) & \cdots & \hat{x}_n(N) \end{bmatrix}, \boldsymbol{\theta}^T = \begin{bmatrix} \theta_1 \\ \vdots \\ \theta_n \end{bmatrix} \text{ e, no caso de saída simples, } \mathbf{Y} = \begin{bmatrix} y(1) \\ \vdots \\ y(N) \end{bmatrix}.$$

Os parâmetros que minimizam o EMQ são calculados a partir da derivada do EMQ em relação a $\boldsymbol{\theta}$, escrita como:

$$\frac{\partial EMQ(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = -\frac{2}{N} \hat{\mathbf{X}}^T (\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}^T) \quad (3.6)$$

A solução é obtida igualando a derivada do EMQ a zero, o que resulta no seguinte sistema linear de equações, chamado de **equações normais** do MMQ:

$$\hat{\mathbf{X}}^T \hat{\mathbf{X}} \boldsymbol{\theta}^T = \hat{\mathbf{X}}^T \mathbf{Y} \quad (3.7)$$

Considerando que a matriz de regressores tem posto completo, isto é, $rank(\hat{\mathbf{X}}) = n$, a solução do sistema linear (3.6) pode ser calculada como

$$\boldsymbol{\theta}^* = (\hat{\mathbf{X}}^T \hat{\mathbf{X}})^{-1} \hat{\mathbf{X}}^T \mathbf{Y} \quad (3.8)$$

onde a matriz $(\hat{\mathbf{X}}^T \hat{\mathbf{X}})^{-1} \hat{\mathbf{X}}^T$ é chamada de **pseudoinversa** de $\hat{\mathbf{X}}$.

Os valores preditos pelo modelo para os registros do conjunto de treinamento podem ser calculados a partir da solução (3.8) como:

$$\hat{\mathbf{Y}} = \hat{\mathbf{X}} \boldsymbol{\theta}^* = \hat{\mathbf{X}} (\hat{\mathbf{X}}^T \hat{\mathbf{X}})^{-1} \hat{\mathbf{X}}^T \mathbf{Y} = \mathbf{H} \mathbf{Y} \quad (3.9)$$

A matriz $\mathbf{H} = \hat{\mathbf{X}} (\hat{\mathbf{X}}^T \hat{\mathbf{X}})^{-1} \hat{\mathbf{X}}^T$, de dimensão $N \times N$, é chamada de “matriz chapéu” [238][399], pois “coloca o chapéu” em $\mathbf{Y}$.

A solução do MMQ pela equação (3.8) é computacionalmente complexa, pois envolve o cálculo da inversa da matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$. Caso o posto da matriz de regressores não seja completo, a equação (3.8) pode se tornar instável numericamente. Há alternativas para o cálculo dos parâmetros do modelo linear que serão discutidas na seção 3.2.

3.1.3 Interpretação geométrica

O método dos mínimos quadrados tem uma interpretação geométrica mostrada na Figura 3.3. Suponha que cada registro observado da variável de saída representa uma coordenada no espaço N -dimensional, chamado de espaço amostral, de forma que o conjunto de registros da variável de saída define o vetor $\mathbf{Y} \in \mathcal{R}^N$. Cada coluna da matriz de regressores $\hat{\mathbf{X}} \in \mathcal{R}^{N \times n}$ também é um vetor no espaço amostral e as n colunas da matriz de regressores definem um subespaço de dimensão n , chamado subespaço do modelo, representado pela área em cinza na Figura 3.3.

Todos os modelos lineares $\hat{\mathbf{Y}} = \hat{\mathbf{X}} \boldsymbol{\theta}^T$, ou seja, todas as combinações lineares dos regressores, estão definidos no subespaço do modelo. A distância entre $\hat{\mathbf{Y}} = \hat{\mathbf{X}} \boldsymbol{\theta}^T$ e o vetor de observações $\mathbf{Y}$ é calculada como:

$$dist(\boldsymbol{\theta}) = \|\mathbf{Y} - \hat{\mathbf{X}} \boldsymbol{\theta}^T\| = \sqrt{(\mathbf{Y} - \hat{\mathbf{X}} \boldsymbol{\theta}^T)^T (\mathbf{Y} - \hat{\mathbf{X}} \boldsymbol{\theta}^T)} \quad (3.10)$$

A equação (3.10) mostra que o $EMQ(\boldsymbol{\theta}) = dist^2(\boldsymbol{\theta})/N$, de forma que a solução $\boldsymbol{\theta}^*$ que minimiza o EMQ produz o resíduo de menor norma L^2 . Dessa forma, o modelo deve ser ortogonal ao resíduo:

$$\hat{\mathbf{Y}}^T (\mathbf{Y} - \hat{\mathbf{X}} \boldsymbol{\theta}^*) = 0 \quad (3.11)$$

A equação (3.11) indica que o resíduo não deve ser correlacionado com os resultados do modelo. Na prática o EMQ não é nulo e a igualdade apresentada na equação (3.11)

não se verifica, mas esse resultado fornece um teste para validação do modelo de regressão linear. Outras estatísticas de validação serão discutidas na seção 3.3.

A Figura 3.3 mostra um exemplo da interpretação geométrica discutida no caso do de um modelo linear simples de uma amostra de dimensão $N = 3$ registros. O exemplo foi gerado com o conjunto de dados $\mathcal{T} = \{(0.2, 0.6), (0.5, 0.2), (0.7, 0.9)\}$. A matriz $\hat{\mathbf{X}} = [\mathbf{1}, \mathbf{X}]$ é a matriz de regressores que define o subespaço vetorial do modelo (em cinza), formado pelo vetor $\mathbf{1}$, cujos elementos são todos 1, e o vetor $\mathbf{X} = [0.2, 0.5, 0.7]^T$, cujos elementos são os registros da variável de entrada.

O resultado do ajuste do modelo pelo MMQ é o vetor de parâmetros $\boldsymbol{\theta}^* = [0.35, 0.44]^T$, que resulta na estimativa $\hat{\mathbf{Y}} = [0.44, 0.58, 0.67]^T$. Observe que o vetor de resíduos é ortogonal ao vetor de estimativas localizado no subespaço vetorial do modelo (em cinza).




Figura 3.3: Interpretação geométrica do método dos mínimos quadrados.

A interpretação geométrica também mostra intuitivamente que a dimensão do espaço de modelo não pode ser maior que a dimensão do espaço amostral, isto é, $n < N$. Caso contrário, o modelo seria mais complexo que a própria amostra. A modelagem pode ser entendida como um processo de compactação da informação em que os N registros da amostra são representados pelos n parâmetros do modelo.

A dimensão da amostra em relação à dimensão do modelo é uma questão importante e que tem grande influência na qualidade do modelo. Quanto maior o tamanho da amostra, melhor é o desempenho do MMQ. Na prática, o número de registros de uma amos-

tra pode não ser muito grande quando há um custo associado à observação dos registros. Para obter uma amostragem relativamente densa em espaços de alta dimensionalidade, o número de registros necessários aumenta exponencialmente com o número de variáveis de entrada. Em espaços de alta dimensão, os dados se tornam altamente esparsos. Hastie, Tibshirani e Friedman [238] mostram um exemplo em que consideram uma amostragem uniforme num hipercubo de lado unitário. Nesse caso, para um problema de dimensão $p = 10$, é necessário utilizar 80% de cada dimensão para capturar 10% dos dados. Esse efeito é conhecido na literatura como a “maldição da dimensionalidade” [98][238].

Na próxima seção, apresentamos um exemplo simples no qual se discute o efeito da escolha da estrutura do modelo no resultado da modelagem.

3.1.4 Exemplo sintético

Neste exemplo, o conjunto de dados foi gerado a partir da função $y = x^2$, adicionando uma perturbação aleatória de média nula e desvio padrão 0.2. A Figura 3.4a mostra o conjunto de dados e a função $y = x^2$ no domínio da amostra.

Foram gerados três modelos a partir desse conjunto de dados: um modelo linear simples ou polinomial de grau $r = 1$; um polinomial de grau $r = 2$; e um polinomial de grau $r = 10$. Como nesse problema a variável de entrada tem apenas uma dimensão, a expressão do modelo polinomial da equação (3.3) se reduz a $\hat{y}(t) = \theta_0 + \sum_{i=1}^r x^i \theta_i$ e o modelo tem $n = r + 1$ parâmetros.

Os resultados do ajuste de cada um desses modelos são mostrados, respectivamente, nas Figura 3.4b, Figura 3.4c e Figura 3.4d. O modelo linear simples não representa bem a relação real, que é mais complexa. No caso do modelo polinomial $r = 10$, a complexidade do modelo é muito superior à da relação e seu resultado foi corrompido pela presença do ruído. No caso do modelo polinomial de grau $r = 2$, o resultado do modelo é muito próximo da função $y = x^2$ utilizada para gerar a amostra, pois o modelo foi ajustado com a estrutura correta.

A Tabela 3.1 mostra os parâmetros ajustados para cada um dos modelos. Podemos observar que o modelo linear simples é praticamente a média da variável de saída. No caso do modelo polinomial de grau $r = 2$, os parâmetros ajustados pelo MMQ correspondem aos da relação real até a primeira casa decimal. No caso do modelo polinomial

de grau $r = 10$, alguns parâmetros têm valores muito grandes em relação à escala da variável de saída, o indica que o ajuste realizado por esse modelo não foi adequado.




Figura 3.4: Exemplo de ajuste de parâmetros pelo MMQ: (a) conjunto de dados; (b) modelo linear puro; (c) modelo polinomial de grau 2; (d) modelo polinomial de grau 10.

O exemplo apresentado na Figura 3.4 mostra que o *overfitting* ocorre quando a complexidade do modelo é inadequada para a amostra. Entretanto, o MMQ pode ajustar adequadamente um modelo, mesmo de complexidade inadequada, quando o conjunto de dados for suficientemente grande. A Figura 3.5 mostra o resultado do modelo polinomial de grau 10 no caso de uma amostra com $N = 200$ e $N = 400$ registros.

Podemos observar que, mesmo com a complexidade do modelo sendo maior que a da relação real, um modelo adequado é ajustado com maior número de registros. Dessa forma, o *overfitting* ocorre quando a complexidade do modelo é maior que a da relação e, adicionalmente, o tamanho da amostra é pequeno em relação à complexidade do mo-

delo que se pretende ajustar. Há técnicas de combinação de modelos (chamadas de *ensembles*) como o *Boosting* [185][186] que exploram a ponderação do conjunto de dados de treinamento para o aumento de desempenho dos modelos. A relação entre a complexidade do modelo e o tamanho da amostra será explorada no Capítulo 7.

Tabela 3.1: Parâmetros ajustados dos modelos da Figura 3.4

θ	$r = 1$	$r = 2$	$r = 10$
θ_0	0.4131	0.0104	-0.1394
θ_1	-0.0325	-0.0325	-0.8151
θ_2		1.0983	8.455
θ_3			6.2056
θ_4			-53.2585
θ_5			-15.7255
θ_6			132.2678
θ_7			16.2839
θ_8			-133.545
θ_9			-5.9739
θ_{10}			47.2605




Figura 3.5: Efeito do número de registros no modelo de grau 10: (a) $N = 200$; (b) $N = 400$.

No MMQ, mesmo com uma amostra reduzida, é possível controlar a complexidade do modelo e encontrar uma solução estável para o sistema linear (3.7) através de técnicas de regularização, apresentadas a seguir.

3.2 Regularização

O desenvolvimento de um modelo em ciência de dados é, essencialmente, um processo de escolha, muitas vezes chamado de treinamento ou “aprendizado” [98], que pode ser resumido nas seguintes etapas:

1. Pré-seleção de um conjunto de funções $\mathcal{F}$ que pode conter um elemento capaz de ajustar o mapeamento entrada-saída representado pelo conjunto de treinamento. Em geral, esse passo é definido pela escolha do **tipo** de modelo.
2. Definição de um conjunto de hipóteses ou conhecimento *a priori* que estabelece restrições à família de funções $\mathcal{F}$ como solução do problema. Essas restrições visam limitar o espaço de soluções a um subconjunto $\mathcal{F}^* \subseteq \mathcal{F}$ e, em alguns casos, podem ser definidas através de parâmetros. Esse passo é chamado de seleção da **estrutura** do modelo.
3. Definição de uma medida (ou função) de avaliação da qualidade de uma instância $f \in \mathcal{F}^*$. A função de avaliação é utilizada na formulação de um **problema de otimização** cuja solução define a aproximação ótima f^* .
4. Utilização de um algoritmo de otimização para o problema formulado em 3) cuja solução são os **parâmetros ajustados** do modelo.

No caso do exemplo sintético da seção 3.1.4, o passo (1) corresponde à seleção do modelo polinomial de grau r . No passo (2), foram selecionadas três estruturas de modelos através da escolha do grau do polinômio. O processo indutivo associado ao MMQ é a minimização do EMQ e a solução é definida pela equação (3.8). Ao longo deste livro, alternativas para cada um desses passos serão apresentadas para que se possa encontrar a melhor solução em diferentes problemas.

Atualmente, o analista tem à sua disposição uma grande variedade de modelos em *softwares* livres e comerciais. Em muitos casos, o problema de *overfitting* não se mostra tão óbvio quanto no exemplo apresentado pela Figura 3.4d. Dessa forma, é importante entender as causas de *overfitting* para construir bons modelos, ou seja, modelos com boa capacidade de generalização.

A regularização é uma técnica que permite reduzir a complexidade do modelo para a obtenção de um modelo mais estável que permita melhor generalização para dados

diferentes dos que foram utilizados no ajuste de parâmetros. As técnicas de regularização estão fortemente associadas à relação *bias* e variância, apresentada a seguir.

3.2.1 *Bias* e variância

A estimativa de um modelo com *overfitting* depende da amostra utilizada para o ajuste do modelo. A parcela do EMQ (cf. equação (3.4)) calculada para um ponto qualquer $\mathbf{x}(t)$ do conjunto de treinamento é uma estimativa do valor esperado* do erro quadrático nesse ponto quando o número de amostras $N \rightarrow \infty$ [187]:

$$\lim_{N \rightarrow \infty} (y(t) - \hat{f}(\mathbf{x}(t), \boldsymbol{\theta}))^2 = E \left((y_r(t) - \hat{f}(\mathbf{x}(t), \boldsymbol{\theta}))^2 \right) \quad (3.12)$$

onde $y_r(t) = E(y(t))$ é o valor da função real em $\mathbf{x}(t)$.

A equação (3.12) é válida para qualquer registro do conjunto de treinamento e podemos escrever $y_r(t) = y_r$ e $f(\mathbf{x}(t), \boldsymbol{\theta}) = \hat{y}$ para simplificar a notação. O valor esperado do erro quadrático em $\mathbf{x}(t)$ pode ser decomposto em dois fatores [238] como:

$$\begin{aligned} E((y_r - \hat{y})^2) &= (y_r - E(\hat{y}))^2 + E \left((\hat{y} - E(\hat{y}))^2 \right) \\ &= \text{bias}^2 + \text{variância} \end{aligned} \quad (3.13)$$

O termo $(y_r - E(\hat{y}))$ é chamado ***bias*** teórico do modelo e o termo $E \left((\hat{y} - E(\hat{y}))^2 \right)$ é chamado de ***variância*** teórica do modelo. O *bias* é, então, a diferença entre o valor real da função em $\mathbf{x}(t)$ e o valor esperado da aproximação naquele ponto. A variância é o valor esperado da diferença entre uma estimativa do modelo e o valor esperado de todas as estimativas.

Uma aproximação do cálculo do valor esperado pode ser feita pela média em várias realizações da variável aleatória, o que permite uma visualização do efeito do *bias* e da variância nos resultados do ajuste dos modelos do exemplo da Figura 3.4. Para isso, 10 amostras de $N = 20$ registros foram geradas a partir da função $y_r = x^2 + \varepsilon$, onde o ruído ε foi gerado por uma distribuição normal $\varepsilon \sim N(0, 0.2)$. O *bias* e a variância em todos os pontos foram calculados pela decomposição (3.13). Para se ter uma ideia desses valores para cada modelo, foi calculada a média para todos os pontos, uma vez que os

* O valor esperado é definido como $E(x) = \int_{-\infty}^{\infty} xp(x)dx$, onde $p(x)$ é a função densidade de probabilidades da variável aleatória. O valor esperado pode ser aproximado pela média aritmética de todas as realizações da variável aleatória [400].

valores da variável de entrada permanecem os mesmos para todas as amostras. O resultado é mostrado na Figura 3.6a para o modelo linear simples e na Figura 3.6b para o modelo polinomial de grau 10. Nos dois gráficos da Figura 3.6, a curva verde apresenta a função real $y_r = x^2$, os pontos das amostras são mostrados em azul, o modelo ajustado $\hat{y}$ com cada amostra em vermelho e a média dos modelos entre todas as amostras em preto.

Os dois casos apresentam uma estrutura inadequada, como já foi discutido. O modelo linear simples apresenta o *bias* elevado, mas uma variância pequena, enquanto o modelo de grau 10 apresenta um *bias* pequeno e uma alta variância, mostrando que é mais sensível à amostra que o primeiro.




Figura 3.6: *Bias* e variância: (a) modelo linear simples; (b) modelo de grau 10.

Os resultados dos modelos ajustados com a estrutura correta, ou seja, um polinômio de grau 2, são mostrados na Figura 3.7. Podemos observar que o modelo com a estrutura correta é capaz de minimizar simultaneamente o *bias* e a variância e que a média de todos os modelos aproxima bem a função real.

A simulação anterior permite concluir que o *bias* acontece quando a complexidade do modelo é inferior à da função real e que a variância é o efeito da instabilidade de modelos muito complexos em relação ao tamanho da amostra. O objetivo das técnicas de regularização é a redução da variância de um modelo de alta complexidade para que o modelo se torne adequado à complexidade do problema, mantendo o *bias* baixo.




Figura 3.7: *Bias* e variância no modelo de grau 2.

A Figura 3.8 mostra o conceito de regularização como uma forma de reduzir a variância do modelo. A Figura 3.8 utiliza os elementos da decomposição do erro quadrático em *bias* e variância na equação (3.13). O círculo cinza no centro da figura representa o conjunto de valores possíveis da amostra, cujo centro é o valor real da função y_r . O valor observado na amostra difere do valor real devido ao erro de observação $e_o = y - y_r$. A partir de uma estrutura de modelo definida, o ajuste pelo MMQ produz uma estimativa $\hat{y}$, cuja diferença em relação ao valor observado é o resíduo do modelo $e = y - \hat{y}$. Considerando todas as amostras possíveis, a variância do modelo $E((\hat{y} - E(\hat{y}))^2)$ é representada pelo círculo laranja maior. Com essa estrutura, o modelo produzido pelo MMQ, considerando uma amostra infinita de dados, é o valor esperado do modelo $E(\hat{y})$. O *bias* do modelo é a diferença entre o valor real e o valor esperado do modelo.

A técnica de regularização visa a uma redução do espaço do modelo, que vai produzir uma estimativa de complexidade reduzida $\hat{y}'$ para o valor observado y . Essa estimativa, apesar de apresentar um resíduo do modelo $e = y - \hat{y}'$ maior, está mais próxima do resultado que seria obtido com uma amostra infinita $E(\hat{y}')$, de forma que a variância da estimativa do modelo reduzido $E((\hat{y}' - E(\hat{y}'))^2)$ é menor. O *bias* da estimativa do modelo reduzido pode ser maior, mas a soma EMQ que considera *bias* e variância pode ser menor para o resultado do modelo reduzido que para o resultado do modelo inicial.




Figura 3.8: Conceito de regularização. Adaptado de [238].

O conceito de regularização descrito anteriormente será formalizado matematicamente em duas técnicas amplamente difundidas nas próximas seções.

3.2.2 Regularização de Tikhonov

Na regressão linear, o *overfitting* ocorre porque o modelo é muito complexo para o tamanho da amostra e o problema torna-se mal condicionado, ou seja, a solução do sistema linear (3.7) é muito sensível à amostra e torna-se instável. Para contornar esse problema, é necessário reduzir a complexidade do modelo, seja modificando diretamente a sua estrutura, seja aplicando algum tratamento numérico que permita o ajuste de um modelo menos complexo.

O método clássico de regularização foi proposto por Tikhonov para a solução de sistemas lineares mal condicionados [524]. Na estatística, o método de Tikhonov foi introduzido por Hoerl e Kennard [255] e chamado de *ridge regression*.

A regularização de Tikhonov é uma técnica de controle de complexidade do modelo através da aplicação de uma penalidade sobre o vetor de parâmetros. A solução é obtida pela minimização do erro médio quadrático regularizado (EMQR):

$$EMQR(\mu, \boldsymbol{\theta}) = \frac{1}{N} \sum_{t=1}^N (y(t) - \hat{f}(\mathbf{x}(t), \boldsymbol{\theta}))^2 + \mu \|\boldsymbol{\theta}\|^2 \quad (3.14)$$

onde $\mu \geq 0$ é o parâmetro de regularização que controla a aplicação da penalidade. Observe que, como $\mu \geq 0$, $EMQR(\mu, \boldsymbol{\theta}) \geq EMQ(\boldsymbol{\theta})$, o que é coerente com o raciocínio apresentado na Figura 3.8.

No modelo linear, o EMQR é escrito utilizando a notação vetorial como:

$$EMQR(\mu, \boldsymbol{\theta}) = \frac{1}{N} (\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}^T)^T (\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}^T) + \mu \boldsymbol{\theta}\boldsymbol{\theta}^T \quad (3.15)$$

onde $\hat{\mathbf{X}} = \begin{bmatrix} \hat{x}_1(1) & \cdots & \hat{x}_n(1) \\ \vdots & \ddots & \vdots \\ \hat{x}_1(N) & \cdots & \hat{x}_n(N) \end{bmatrix}$, $\boldsymbol{\theta}^T = \begin{bmatrix} \theta_1 \\ \vdots \\ \theta_n \end{bmatrix}$ e $\mathbf{Y} = \begin{bmatrix} y(1) \\ \vdots \\ y(N) \end{bmatrix}$, como na equação (3.5).

A minimização do EMQR seguindo o mesmo procedimento anterior resulta no sistema linear $(\hat{\mathbf{X}}^T \hat{\mathbf{X}} + \mu \mathbf{I}) \boldsymbol{\theta}^T = \hat{\mathbf{X}}^T \mathbf{Y}$, cuja solução é calculada como:

$$\boldsymbol{\theta}_\mu^* = (\hat{\mathbf{X}}^T \hat{\mathbf{X}} + \mu \mathbf{I})^{-1} \hat{\mathbf{X}}^T \mathbf{Y} \quad (3.16)$$

onde $\mathbf{I}$ é a matriz identidade.

A regularização de Tikhonov atua no condicionamento da matriz de coeficientes $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$ através do parâmetro de regularização μ .

O condicionamento de uma matriz $\mathbf{A}$ reflete a sensibilidade da solução de um sistema linear em que a matriz $\mathbf{A}$ é a matriz de coeficientes. Se a matriz $\mathbf{A}$ for mal condicionada, pequenas alterações no termo independente podem causar grandes variações na solução. O condicionamento de uma matriz quadrada $\mathbf{A}$ é medido pelo número de **condição**, definido como $\kappa(\mathbf{A}) = \|\mathbf{A}\| \|\mathbf{A}^{-1}\|$, e calculado a partir dos seus autovalores [206]:

$$\kappa(\mathbf{A}) = \frac{\lambda_{max}}{\lambda_{min}} \quad (3.17)$$

onde λ_{max} e λ_{min} são, respectivamente, o maior e o menor autovalor de $\mathbf{A}$.

A equação (3.17) mostra que, se $\lambda_{min} \rightarrow 0$, o número de condição da matriz $\kappa(\mathbf{A}) \rightarrow \infty$ e a matriz tende a ser singular. O menor autovalor $\lambda_{min} = 0$ indica que há colunas linearmente dependentes, ou seja, a matriz tem posto deficiente e o sistema linear é indeterminado. Um valor do número de condição grande, por exemplo, $\kappa(\mathbf{A}) > 1.000$, indica que o condicionamento da matriz é próximo do singular e que a solução do sistema linear é instável, sendo muito sensível a perturbações.

No caso da regressão linear, a matriz de coeficientes no MMQ (cf. equação (3.7)) é a matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$ e o termo independente, $\hat{\mathbf{X}}^T \mathbf{Y}$. A existência de regressores altamente correlacionados provoca o mau condicionamento da matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$ e resulta na instabilidade na solução, o que, no contexto do problema de regressão, significa *overfitting*. Em outras palavras, um modelo muito complexo (em relação ao tamanho da amostra) resulta em problemas de condicionamento na matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$ e instabilidade na solução. Esse efeito pode ser observado pelos valores do vetor de parâmetros $\boldsymbol{\theta}$ na solução para o modelo de grau 10 mostrado na Tabela 3.1.

Na regularização de Tikhonov, a adição de uma constante à diagonal principal da matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$ altera seu número de condição como:

$$\kappa(\mathbf{A}) = \frac{\lambda_{\max} + \mu}{\lambda_{\min} + \mu} \quad (3.18)$$

Dessa forma, mesmo que a matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$ seja singular e que $\lambda_{\min} = 0$, a matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}} + \mu \mathbf{I}$ será estável numericamente e a solução (3.16) poderá ser calculada adequadamente.

O controle do condicionamento da matriz de regressores foi a principal motivação para a introdução do método de Tikhonov na regressão linear [255]. Atualmente, o problema de regularização através da minimização do EMQR (3.14) tem sido tratado como uma técnica geral de controle da complexidade de modelos [98][238][478].

Na regularização de Tikhonov, o parâmetro de regularização deve ser informado ou calculado automaticamente [399]. Hoerl, Kennard e Baldwin [256] apresentam a seguinte proposta para o cálculo do parâmetro μ :

$$\mu = \frac{n}{(N - n)} \frac{\|\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}^T\|^2}{\|\boldsymbol{\theta}\|^2} \quad (3.19)$$

onde n é o número de parâmetros e $\boldsymbol{\theta}$ é a solução do MMQ sem regularização. O termo $\|\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}^T\|^2 / (N - n)$ é uma estimativa da variância do resíduo (cf. equação (3.30)).

A regularização de Tikhonov pode ser entendida num contexto de seleção de modelos através do ajuste do parâmetro de regularização μ , cuja variação permite uma regulação contínua de estrutura do modelo, o que pode ser interessante em alguns casos.

A Figura 3.9 apresenta o conjunto de dados do exemplo discutido na seção 3.1.4 com o resultado do ajuste do modelo polinomial de grau 10 pela minimização EMQR, com dois

valores para o parâmetro de regularização. A Figura 3.9a mostra o ajuste com o valor obtido pela equação (3.19) com $\mu = 1 \times 10^{-5}$ e a Figura 3.9b mostra o resultado obtido com o valor $\mu = 0.1$ escolhido de forma *ad hoc*.




Figura 3.9: Modelo de grau 10 com regularização: (a) $\mu = 1 \times 10^{-5}$; (b) $\mu = 0.1$.

A Tabela 3.2 mostra os valores dos parâmetros. O resultado obtido sem regularização ($\mu = 0.0$) foi incluído para facilitar a comparação.

Tabela 3.2: Parâmetros ajustados dos modelos da Figura 3.9

θ	$\mu = 0.0$	$\mu = 1 \times 10^{-5}$	$\mu = 0.1$
θ_0	-0.1394	-0.0556	0.0567
θ_1	-0.8151	-0.7044	-0.1218
θ_2	8.4550	4.2082	0.6766
θ_3	6.2056	4.7143	0.1997
θ_4	-53.2585	-18.5496	0.4438
θ_5	-15.7255	-10.2949	0.0189
θ_6	132.2678	33.0619	0.2380
θ_7	16.2839	8.9882	-0.0538
θ_8	-133.5450	-18.2708	-0.0253
θ_9	-5.9739	-2.7254	-0.0693
θ_{10}	47.2605	0.6354	-0.2803

A solução robusta do MMQ também pode ser obtida evitando as componentes associadas aos autovalores próximos de zero, através do método das componentes principais.

3.2.3 Regularização por componentes principais

Na seção 2.4.2, vimos que a decomposição em valores singulares (SVD) permite eliminar colunas linearmente dependentes de uma matriz através de uma transformação linear ortogonal. A SVD permite uma solução robusta de sistemas lineares considerando apenas as colunas linearmente independentes da matriz de coeficientes.

Considere a SVD da matriz de regressores $\hat{\mathbf{X}} = \mathbf{U}\mathbf{S}\mathbf{V}^T$ aplicada ao ajuste de parâmetros do MMQ pela equação (3.8):

$$\boldsymbol{\theta}^* = (\hat{\mathbf{X}}^T \hat{\mathbf{X}})^{-1} \hat{\mathbf{X}}^T \mathbf{Y} = (\mathbf{V} \mathbf{S}^2 \mathbf{V}^T)^{-1} \mathbf{V} \mathbf{S} \mathbf{U}^T \mathbf{Y} = \mathbf{V} \mathbf{S}^{-1} \mathbf{U}^T \mathbf{Y} \quad (3.20)$$

Uma solução estável do MMQ pode ser obtida utilizando apenas as $r \leq \text{rank}(\hat{\mathbf{X}})$ colunas linearmente independentes da matriz de regressores como:

$$\boldsymbol{\theta}_r^* = \sum_{i=1}^r \left(\frac{\mathbf{u}_i^T \mathbf{Y}}{s_i} \right) \mathbf{v}_i \quad (3.21)$$

onde $\mathbf{u}_i$ e $\mathbf{v}_i$ são as colunas de $\mathbf{U}$ e $\mathbf{V}$ e s_i é o valor singular correspondente.

A soma dos $r \leq \text{rank}(\hat{\mathbf{X}})$ termos associados aos maiores valores singulares evita a utilização de valores muito pequenos de s_i , que provocam a instabilidade da solução, como mostra a equação (3.21). Dessa forma, a solução (3.21) não utiliza todas as colunas de $\mathbf{U}$ e $\mathbf{V}$, tal forma que $\|\boldsymbol{\theta}_r^*\| < \|\boldsymbol{\theta}^*\|$. Ela pode, então, ser vista como a solução reduzida do MMQ e, portanto, uma técnica de regularização.

A decomposição SVD da matriz de regressores $\hat{\mathbf{X}}$ é equivalente à decomposição em autovaleores e autovetores da matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$, como foi visto na seção 2.4.2. A solução da equação (3.21) corresponde à aplicação do MMQ aos componentes principais da matriz de regressores, o que dá nome ao método.

A regularização por componentes principais também pode ser utilizada como uma forma de seleção de modelos pela variação do parâmetro $r \leq \text{rank}(\hat{\mathbf{X}})$. Em muitos softwares, a solução (3.21) é utilizada como uma solução robusta do sistema linear (3.16) com $r \approx \text{rank}(\hat{\mathbf{X}})$, o que fica transparente para o usuário.

Para comparação com os resultados anteriores, a Figura 3.10 apresenta os resultados do ajuste do modelo polinomial de grau 10 pelo método de componentes principais. A Figura 3.10a mostra o ajuste com o valor obtido com $r = \text{rank}(\hat{\mathbf{X}}) = 9$ e a Figura 3.10b, o resultado obtido com o valor $r = 5$ escolhido de forma *ad hoc*.




Figura 3.10: Modelo de grau 10 com regularização: (a) $r = 9$; (b) $r = 5$.

A Tabela 3.2 mostra os valores dos parâmetros. O resultado obtido sem regularização ($r = 11$) também foi incluído para facilitar a comparação.

Tabela 3.3: Parâmetros ajustados dos modelos da Figura 3.10

θ	$r = 11$	$r = 9$	$r = 5$
θ_0	-0.1394	-0.0408	0.0248
θ_1	-0.8151	-0.5505	-0.0447
θ_2	8.4550	3.3565	0.8601
θ_3	6.2056	2.6037	-0.0054
θ_4	-53.2585	-11.0903	0.4039
θ_5	-15.7255	-2.5260	0.0083
θ_6	132.2678	10.7787	0.1023
θ_7	16.2839	-1.5235	0.0146
θ_8	-133.5450	8.4170	-0.0871
θ_9	-5.9739	1.9788	0.0178
θ_{10}	47.2605	-10.3956	-0.2107

3.3 Validação de Modelos

A abordagem clássica para validação de modelos de regressão linear é o teste das hipóteses do MMQ [399]. O desempenho do modelo depende, principalmente, da escolha da melhor estrutura ou de parâmetros de regularização. Dessa forma, a seleção do modelo é feita a partir de estatísticas e procedimentos de validação.

As estatísticas de validação medem o desempenho do modelo num determinado conjunto de dados. A forma mais efetiva de avaliar a capacidade de predição do modelo é verificar as estatísticas de validação em dados diferentes daqueles utilizados para o ajuste dos parâmetros. A validação cruzada, utilizando as estatísticas de validação do modelo, é um método eficiente e prático para a avaliação da qualidade preditiva do modelo. As principais estatísticas de validação para regressão linear são apresentadas na próxima seção e a validação cruzada é apresentada na seção 3.3.2.

3.3.1 Estatísticas de validação

As estatísticas de validação são calculadas a partir do resíduo em cada registro:

$$e(t) = y(t) - \hat{y}(t), t = 1, \dots, N \quad (3.22)$$

A **análise de variância** do modelo é feita a partir da decomposição [399]:

$$\sum_{t=1}^N (y(t) - \bar{y})^2 = \sum_{t=1}^N (\hat{y}(t) - \bar{y})^2 + \sum_{t=1}^N (y(t) - \hat{y}(t))^2 \quad (3.23)$$

onde $\bar{y}$ representa a média da variável de saída.

A equação (3.23) pode ser escrita como $SS_T = SS_R + SS_{Res}$, onde SS_T é a soma de quadrados totais, que representa a variabilidade total da variável de saída; SS_R é a soma dos quadrados da regressão, que representa a porção da variabilidade total explicada pelo modelo; e SS_{Res} é a soma de quadrados dos resíduos, que representa a porção da variabilidade total que não pode ser explicada pelo modelo.

O **coeficiente de determinação** R^2 mede o percentual da variabilidade total que é explicada pelo modelo como [399]:

$$R^2 = \frac{SS_R}{SS_T} = \frac{\sum_{t=1}^N (\hat{y}(t) - \bar{y})^2}{\sum_{t=1}^N (y(t) - \bar{y})^2} = 1 - \frac{SS_{Res}}{SS_T} = 1 - \frac{\sum_{t=1}^N (y(t) - \hat{y}(t))^2}{\sum_{t=1}^N (y(t) - \bar{y})^2} \quad (3.24)$$

O coeficiente de determinação $R^2 \leq 1$ uma vez que SS_T é fixo e $SS_{Res} \leq SS_T$. O valor $R^2 \approx 1$ indica um resultado adequado pois a maior parte da variabilidade total é explicada pelo modelo. Intuitivamente, o coeficiente de determinação compara o erro do modelo estimado pelo erro da média da variável saída. Se o erro do modelo é da mesma ordem de grandeza do erro da média, o valor $R^2 \approx 0$ indica que o modelo não consegue

explicar as observações melhor que a média da variável de saída. Em alguns casos, o valor $R^2 < 0$ indica que o modelo é pior que a média da variável de saída.

O coeficiente de determinação é muito sensível aos valores mais altos da variável de saída uma vez que os erros são elevados ao quadrado. Para avaliação de valores menores, pode-se utilizar o coeficiente de determinação calculado sobre os logaritmos dos valores observados e preditos:

$$R_{log}^2 = 1 - \frac{\sum_{t=1}^N (\log(y(t)) - \log(\hat{y}(t)))^2}{\sum_{t=1}^N (\log(y(t)) - \overline{\log(y(t))})^2} \quad (3.25)$$

onde $\overline{\log(y(t))}$ é a média do logaritmo dos valores observados.

Uma estatística muito utilizada para avaliação de modelos é a raiz quadrada do EMQ, conhecida como RMS:*

$$RMS = \sqrt{\frac{1}{N} \sum_{t=1}^N e^2(t)} = \sqrt{\frac{1}{N} \sum_{t=1}^N (y(t) - \hat{y}(t))^2} \quad (3.26)$$

O resultado do RMS tem a mesma escala da variável de saída e pode ser analisado no contexto do problema.

Uma estatística de validação similar ao RMS é o erro absoluto médio (MAE)†:

$$MAE = \frac{1}{N} \sum_{t=1}^N |y(t) - \hat{y}(t)| \quad (3.27)$$

O erro absoluto médio percentual (MAPE)‡ é uma variante do MAE que apresenta os erros de forma relativa:

$$MAPE = \frac{1}{N} \sum_{t=1}^N \left| \frac{y(t) - \hat{y}(t)}{y(t)} \right| \quad (3.28)$$

A estatística MAPE é uma medida relativa e deve ser utilizada com cautela se a variável de saída for padronizada pela estimativa dos *z-scores*, pois pode resultar em erros de

* *Root Mean Square.*

† *Mean Absolute Error.*

‡ *Mean Absolute Percentual Error.*

arredondamento e, eventualmente, divisão por zero. Quando a variável de saída não contém o valor nulo, o resultado em forma percentual permite uma avaliação intuitiva da qualidade do modelo.

Uma estatística adimensional para avaliação do desempenho do modelo é a correlação entre os resultados do modelo e os valores observados da variável de saída:

$$\rho_{y\hat{y}} = \frac{\sum_{t=1}^N (y(t) - \bar{y})(\hat{y}(t) - \bar{\hat{y}})}{\sqrt{Var(y)}\sqrt{Var(\hat{y})}} \quad (3.29)$$

onde $\bar{\hat{y}} = \frac{1}{N} \sum_{t=1}^N \hat{y}(t)$ é a média dos resultados do modelo.

O valor de correlação $\rho_{y\hat{y}} \leq 1$; quanto mais próximo de 1, melhor a qualidade do modelo. O resultado de correlação também pode ser avaliado no gráfico de projeção entre o valor observado e o previsto da variável de saída.

Se a estrutura selecionada pelo modelo representa adequadamente a relação, uma estimativa da variância dos resíduos é calculada como:

$$Var(e) = \hat{\sigma}^2 = \frac{1}{N-n} \sum_{t=1}^N e^2(t) = \frac{1}{N-n} \sum_{t=1}^N (y(t) - \hat{y}(t))^2 \quad (3.30)$$

onde n é o número de regressores do modelo.

Quando a distribuição do resíduo pode ser representada adequadamente por uma distribuição normal, é possível calcular um intervalo de confiança do resultado do modelo para um valor de entrada arbitrário $\hat{\mathbf{x}}_0$ do vetor de regressores. A estimativa da variância do modelo no ponto $\hat{\mathbf{x}}_0$ é calculada como [399]:

$$Var(\hat{y}_0) = \hat{\sigma}^2 \hat{\mathbf{x}}_0^T (\hat{\mathbf{X}}^T \hat{\mathbf{X}})^{-1} \hat{\mathbf{x}}_0 \quad (3.31)$$

onde $\hat{y}_0$ é o valor do modelo no ponto $\hat{\mathbf{x}}_0$ e $\hat{\sigma}^2$ é a estimativa da variância do resíduo calculada pela equação (3.30).

O intervalo que contém o valor esperado da relação real $y_r = E(y_0)$, onde y_0 é o valor observado em $\hat{\mathbf{x}}_0$, com confiança estatística de $\xi\%$ é calculado como [399]:

$$\hat{y}_0 - t_{\xi,d} \sqrt{Var(\hat{y}_0)} \leq y_r \leq \hat{y}_0 + t_{\xi,d} \sqrt{Var(\hat{y}_0)} \quad (3.32)$$

onde $d = N - n$ é o número de graus de liberdade e $t_{\xi,d}$ é o valor da distribuição t de Student. A distribuição t pode ser aproximada pela normal para $d \geq 30$, de forma que o intervalo de confiança com 95% de significância pode ser aproximado por:

$$\hat{y}_0 - 2.0\sqrt{\text{Var}(\hat{y}_0)} \leq y_r \leq \hat{y}_0 + 2.0\sqrt{\text{Var}(\hat{y}_0)} \quad (3.33)$$

A Figura 3.11 mostra o resultado do modelo linear de duas das três variáveis de saída do problema *Contrete Slump*.¹⁰⁴ A Figura 3.11a mostra o resultado da variável de saída y_3 , em que o modelo tem um bom desempenho, e a Figura 3.11b, o resultado da variável y_1 , em que o desempenho do modelo não é bom.






Figura 3.11: Resultados do modelo linear do problema *Contrete Slump*: (a) y_3 ; (b) y_1 .

A Figura 3.12 mostra as estatísticas de validação correspondentes. As estatísticas R^2 e R_{log}^2 são apresentadas subtraídas da unidade para que o melhor modelo tenha sempre o menor valor. As barras vermelhas indicam o resultado da previsão realizada pela média e servem como referência.

A comparação da distribuição dos resíduos com a distribuição normal $N(0, \hat{\sigma}^2)$ permite avaliar graficamente a qualidade do modelo. Resíduos com distribuição normal indicam que o ajuste realizado pelo MMQ foi de boa qualidade. A Figura 3.13 mostra os histogramas dos resíduos e os gráficos de probabilidade normal dos resultados apresentados na Figura 3.12 e na Figura 3.11.




(a)




(b)


Figura 3.12: Resultados do modelo linear do problema *Concrete Slump*: (a) y_3 ; (b) y_1 .




(a)



(b)



(c)



(d)

Figura 3.13: Distribuição do resíduo no problema *Slump*: (a) e (b) y_3 ; (c) e (d) y_1 .

As estatísticas de validação calculadas diretamente sobre o conjunto de treinamento não são úteis para a escolha do melhor modelo, pois um modelo com *overfitting* tem bom desempenho no conjunto de treinamento. A avaliação da capacidade de predição do modelo diretamente sobre o conjunto de treinamento pode ser avaliada por estatísticas como os critérios de Akaike (AIC) [7] e de Schwartz (BIC) [481], cujos resultados nem sempre correspondem ao desempenho efetivo do modelo. Na prática, utiliza-se o procedimento de validação cruzada para estimar a capacidade de predição do modelo, como descrito a seguir.

3.3.2 Validação cruzada

A maneira mais simples de estimar o desempenho do modelo num conjunto de dados diferente do que foi utilizado para o ajuste é dividir o conjunto de dados $\mathcal{T}$ em dois subconjuntos: o conjunto de treinamento $\mathcal{T}_1$ e o conjunto de teste $\mathcal{T}_2$, respectivamente com N_1 e N_2 registros (tipicamente $N_1 = 2N/3$ e $N_2 = N/3$). O conjunto de treinamento é utilizado para o ajuste de parâmetros e o conjunto de teste é utilizado para estimar o desempenho do modelo. Essa abordagem supõe que os dois conjuntos são amostras representativas do processo, o que pode não acontecer se o conjunto de dados não for grande o suficiente. Além disso, as estatísticas de validação ficam muito dependentes da partição e uma permutação dos registros pode gerar variações importantes nas estatísticas de validação.

A validação cruzada é um procedimento simples que permite avaliar adequadamente o desempenho do modelo em dados diferentes do conjunto de treinamento. Na validação cruzada, o conjunto de dados é dividido em K subconjuntos e a validação é realizada em K ciclos: para cada ciclo o modelo é ajustado utilizando $K - 1$ subconjuntos e avaliado no subconjunto remanescente. O procedimento é descrito pelo Algoritmo 3.1, mostrado esquematicamente na Figura 3.14.

As estatísticas de validação podem ser calculadas sobre o resultado de cada ciclo $\hat{\mathbf{Y}}_i$ e o resultado é apresentado em termos de média e desvio padrão dos resultados em todos os ciclos. Em conjuntos de dados pequenos, as estatísticas de validação não são significativas quando calculadas sobre um subconjunto com N/K registros. Dessa forma, é preferível concatenar os resultados em cada ciclo num vetor de resultados $\hat{\mathbf{Y}}$, que tem o mesmo número de registros que o conjunto de treinamento, e calcular as estatísticas

de validação sobre esses resultados. Observe que todos os elementos do vetor $\hat{\mathbf{Y}}$ foram calculados com registros diferentes daqueles utilizados para o ajuste dos modelos.

Algoritmo 3.1: Validação cruzada de K ciclos

Entrada:	Conjunto de dados $\mathcal{T} = \{(\mathbf{x}(t), y(t)), t = 1 \dots N\}$ e número de ciclos K
Saída:	Vetor com resultados do modelo $\hat{\mathbf{Y}} = [\hat{y}(1), \dots, \hat{y}(N)]^T$
01	Início
02	Dividir o conjunto $\mathcal{T}$ em K subconjuntos $\mathcal{T}_i, i = 1, \dots, K$ aproximadamente iguais
03	Para $i = 1 \dots K$:
04	Definir o conjunto de treinamento $\mathcal{T}_{TR} = \bigcup_{j \neq i} \mathcal{T}_j$
05	Ajustar os parâmetros do modelo utilizando $\mathcal{T}_{TR}$
06	Estimar o resultado do modelo no conjunto $\mathcal{T}_{TE} = \mathcal{T}_i$
07	Armazenar o resultado no vetor $\hat{\mathbf{Y}}_i$
08	Fim Para
09	Concatenar resultados $\hat{\mathbf{Y}} = [\hat{\mathbf{Y}}_1^T, \dots, \hat{\mathbf{Y}}_K^T]^T$
10	Fim




Figura 3.14: Validação cruzada de K ciclos: Tr são os subconjuntos de treinamento, Te são os subconjunto de teste

Uma escolha importante na validação cruzada é o número de ciclos K . No caso particular de $K = N$, chamada de *leave-one-out* (LOO), em cada ciclo, $N - 1$ registros são utilizados para o treinamento e a estimativa do modelo é feita com apenas um registro.

Apesar do custo computacional, a validação cruzada LOO é a melhor estimativa de desempenho do modelo em dados diferentes do conjunto de dados disponível, mas é muito sensível à amostra e pode ter resultados diferentes para amostras diferentes [238]. A escolha mais usual é $K = 5$ ou $K = 10$, número de registros [238][63].

3.4 Aplicações

3.4.1 Conjunto de dados *Pollution*

O conjunto de dados *Pollution*¹⁰⁵ é um problema utilizado frequentemente como exemplo da aplicação da regularização de Tikhonov [375]. O conjunto de dados, que relaciona poluição do ar com mortalidade, contém 60 registros com os valores de 15 variáveis observados entre 1959 e 1961 em áreas metropolitanas dos EUA. A variável de saída representa a média de mortalidade nas áreas observadas no mesmo período.

A Figura 3.15 mostra o *box-plot* das variáveis padronizadas pelas estimativas dos *z-scores* e a matriz de correlação. Podemos observar a presença de variáveis bastante correlacionadas (x_{12} e x_{13}).




Figura 3.15: Conjunto de dados *Pollution*: (a) box-plot; (b) matriz de correlação.

A Figura 3.16 apresenta a visualização do gráfico de projeção e o *data image*. Podemos observar a existência de algumas variáveis com distribuições assimétricas (x_{12} a x_{13}) e a presença de pelo menos um registro *outlier*, representado pela linha e coluna em vermelho no *data image*.




Figura 3.16: Conjunto de dados *Pollution*: (a) gráficos de projeção; (b) *data image*.

A Figura 3.17 apresenta o gráfico de projeção e o *data image* do conjunto de dados após a remoção de 12% (sete registros) da base, como descrito na seção 2.3.2. Podemos observar pela Figura 3.17b um padrão mais homogêneo da similaridade entre os registros, ainda que um registro se mostre discrepante em relação aos demais.




Figura 3.17: Conjunto de dados *Pollution* sem *outliers*: (a) gráficos de projeção; (b) *data image*.

A Figura 3.18 apresenta os resultados obtidos em validação cruzada do modelo linear simples com os parâmetros ajustados pelo MMQ sem regularização, sem a remoção de *outliers*. Podemos observar que a distribuição do resíduo não é bem ajustada pela distribuição normal, o que pode ser um indício de que o ajuste realizado pelo MMQ não foi adequado.




Figura 3.18: Resultados do MMQ no conjunto de dados Pollution. (a) Estatísticas de validação; (b) correlação real $\times$ predito; (c) histograma do resíduo; (d) probabilidade normal do resíduo.

A Figura 3.19 mostra os resultados do modelo linear aplicado ao conjunto de dados sem *outliers*. Podemos observar que o gráfico de probabilidade normal do resíduo indica que o ajuste dos dados sem *outliers* foi de melhor qualidade que o anterior. O coeficiente de correlação entre o valor real e o valor predito também demonstra o melhor desempenho do modelo nos dados sem *outliers*.

Os valores das estatísticas de validação são resumidos na

Tabela 3.4. O resultado também não melhora com a utilização de modelos polinomiais de ordem superior. O modelo linear regularizado com parâmetro calculado pela equação (3.19) ajustado nos dados sem *outliers* não resultou numa variação importante das

estatísticas. Finalmente, utilizando o valor $\mu = 0.01$ para o parâmetro de regularização nos dados sem *outliers*, obtemos uma pequena melhora nas estatísticas.




Figura 3.19: Resultados do conjunto de dados *Pollution* sem *outliers*: (a) estatísticas de validação; (b) correlação real $\times$ predito; (c) histograma do resíduo; (d) probabilidade normal do resíduo.

Tabela 3.4: Comparação das estatísticas de validação

Modelo	RMS	MAPE	R^2
MMQ	0.2537	22.98%	0.4107
MMQ s/ <i>outliers</i>	0.2078	18.93%	0.6039
MMQ Reg. c/ <i>outliers</i>	0.2316	20.52%	0.5091
MMQ Reg. s/ <i>outliers</i>	0.2094	18.99%	0.5976
MMQ Reg. $\mu = 0.01$	0.2057	18.51%	0.6118

Nesse exemplo, a regularização e a retirada de *outliers* aumentam o desempenho do modelo linear, mas o efeito das duas técnicas combinadas não produz uma alteração significativa no resultado. A retirada de *outliers* melhora os resultados das estatísticas de validação nesse exemplo, pois a remoção de *outliers* foi realizada sobre todo o conjunto de dados, antes da validação cruzada.

É importante observar que, mesmo para um exemplo simples, o número de opções de modelos diferentes pode aumentar muito se todas as alternativas forem exploradas durante o processo de validação de modelos.

3.4.2 Previsão da elevação adiabática de temperatura do concreto

O estudo apresentado nesta seção foi realizado em parceria com o Departamento de Engenharia Civil da Eletrobrás Furnas [174][166]. O trabalho foi realizado a partir dos registros de ensaios de elevação adiabática de temperatura realizados no Laboratório de Concretos de Furnas com corpos de prova de amostras de concretos utilizados na construção das principais barragens de usinas hidrelétricas brasileiras [18].

O principal componente do concreto é o cimento, que, em contato com a água, produz reação exotérmica, ganhando, assim, resistência mecânica. O ensaio de elevação adiabática de temperatura do concreto é um experimento controlado que mede a elevação de temperatura produzida por um corpo de prova de concreto. A temperatura final do ensaio é uma função principalmente da formulação e da concentração do cimento utilizado. Entretanto, os demais componentes da mistura exercem influência na forma da função de elevação de temperatura, que é não linear.

O conhecimento do calor gerado pelo concreto é importante na construção de estruturas de grande porte, como barragens, por exemplo. Os esforços gerados pela dilatação do material devido à transferência de calor podem ser excessivos, podendo causar rachaduras na estrutura já construída durante a concretagem de um novo bloco.

Os esforços gerados pela dilatação do concreto podem ser calculados a partir de modelos numéricos da estrutura. Entretanto, a previsão da quantidade de calor gerada por modelos analíticos é complexa e os modelos existentes para a previsão do calor gerado

só podem ser utilizados em condições limitadas [174]. Modelos de inteligência computacional podem ser utilizados para a previsão de calor gerado pelas misturas utilizadas na composição do concreto no Brasil [166].

Os dados para o estudo foram cedidos pelo Laboratório de Concreto de Furnas [174] e apresenta 136 registros de 14 variáveis de entrada do problema, apresentadas na Tabela 3.5. As variáveis são de dois tipos: cinco variáveis descrevem a composição química do cimento utilizado no concreto e nove variáveis, os demais elementos utilizados na mistura e a temperatura inicial do ensaio.

Cada registro do conjunto de dados original apresenta a evolução de temperatura do corpo de prova. Os registros representam observações a cada hora nas primeiras 24 horas e diariamente até o 28º dia, resultando 52 registros de tempo. Tendo em vista o grande número de valores ausentes e a dificuldade em modelar um problema com 52 variáveis de saída, a elevação de temperatura foi aproximada por uma função não linear de três parâmetros, que são utilizados como variáveis de saída no modelo de regressão [174].

Tabela 3.5: Descrição das variáveis de entrada

Variável	Descrição	
x_1	Concentração de CaO	(%)
x_2	Concentração de Si_2O_2	(%)
x_3	Concentração de Al_2O_3	(%)
x_4	Concentração de Fe_2O_3	(%)
x_5	Concentração de SO_3	(%)
x_6	Consumo de cimento	(Kg/m ³)
x_7	Finura Blaine	(cm ² /g)
x_8	Adição de pozolana	(Kg/m ³)
x_9	Adição de escória	(Kg/m ³)
x_{10}	Adição de cinza volante	(Kg/m ³)
x_{11}	Consumo de água	(Kg/m ³)
x_{12}	Consumo de aditivos	(Kg/m ³)
x_{13}	Consumo de agregados	(Kg/m ³)
x_{14}	Temperatura inicial	(°C)

A Figura 3.20a mostra a matriz de distâncias entre os registros. A Figura 3.20b apresenta a matriz de correlação das variáveis, onde são destacadas as variáveis de composição do cimento, as concentrações dos aditivos e as variáveis de saída. Os aditivos que têm maiores correlações com as variáveis de saída são: consumo de cimento (x_6), consumo de água (x_{11}) e consumo de agregados (x_{13}).





Figura 3.20: Variáveis de entrada. (a) matriz de distâncias; (b) matriz de correlação.


Os resultados do ajuste feito pelo MMQ simples e com regularização são mostrados na Tabela 3.6. O método com regularização apresenta resultados ligeiramente melhores, principalmente para a variável de saída y_3 . A variável de saída y_1 , que representa a temperatura final do concreto após a hidratação, é a que apresentou os melhores resultados, tendo em vista que seu comportamento é bastante correlacionado com o consumo de cimento, conforme apresentado no exemplo da análise de correlação canônica na seção 2.4.4. Os resultados do modelo MMQ com regularização são apresentados na Figura 3.21 e ilustram os comentários acima.

Tabela 3.6: Comparação das estatísticas de validação


Saída	Modelo	RMS	MAPE	R^2
y_1	MMQ	0.1598	13.03%	0.7686
	MMQ Reg.	0.1573	13.07%	0.7756
y_2	MMQ	0.2178	16.21%	0.5700
	MMQ Reg.	0.2170	15.91%	0.5730
y_3	MMQ	0.2669	17.15%	0.3540
	MMQ Reg.	0.2591	16.45%	0.3911




(a)




(b)




(c)



(d)



(e)



(f)

Figura 3.21: Resultados: (a) e (b) y_1 ; (c) e (d) y_2 ; (e) e (f) y_3 .

Os resultados foram obtidos com as variáveis de saída padronizadas e servem para a escolha da melhor estrutura e/ou abordagem de ajuste. As previsões do modelo devem

ser calculadas na escala original das variáveis. Além disso, as variáveis de saída representam os parâmetros de uma função de aproximação da elevação adiabática. A Figura 3.22 mostra o melhor e o pior ajuste realizados pelo modelo MMQ com regularização em relação aos valores observados de elevação de temperatura. A curva em azul mostra a aproximação realizada com os parâmetros utilizados como variável de saída e a curva em vermelho mostra a aproximação realizada com os parâmetros previstos pelo modelo. Podemos verificar que o pior ajuste é bem distante dos valores observados. Na Figura 3.22, o tempo é mostrado em escala logarítmica para facilitar a visualização da elevação de temperatura nas primeiras horas da reação de hidratação.




Figura 3.22: Resultados: (a) melhor ajuste; (b) pior ajuste.

O modelo de elevação adiabática de temperatura é complexo e altamente não linear [174]. Resultados mais precisos foram obtidos com modelos de redes neurais [174] e sistemas *fuzzy* [166].

3.5 Comentários Finais

Neste capítulo, apresentamos os principais conceitos de regressão linear pelo método dos mínimos quadrados. As principais características do processo de modelagem discutidas neste capítulo estão presentes em qualquer modelo preditivo.

O conceito mais importante introduzido neste capítulo é de que o processo de modelagem é, essencialmente, de escolha. O desenvolvimento do modelo segue três etapas principais: identificação da estrutura; ajuste de parâmetros e validação. A escolha da

estrutura é a etapa mais importante e a que tem maior influência sobre o resultado. O ajuste de parâmetros implica a solução de um problema de otimização, que, na regressão linear, é feito pelo método dos mínimos quadrados (MMQ). Tendo em vista os problemas numéricos que surgem da modelagem de sistemas complexos com um número reduzido de observações, as técnicas de regularização são úteis para garantir a estabilidade dos resultados. A validação do modelo visa prever o seu comportamento em dados diferentes daqueles utilizados para o ajuste. O procedimento de validação cruzada é simples e efetivo para a obtenção de estatísticas de validação confiáveis.

Os resultados no problema *Pollution* mostram que a retirada de *outliers* resulta no aumento de desempenho dos modelos. É importante observar que esse procedimento deve ser utilizado com cautela, pois a retirada de valores extremos resulta na exclusão de valores com potencial para os maiores erros na regressão e, portanto, redução das estatísticas de validação. Entretanto, a retirada de *outliers* favorece que a distribuição do resíduo seja mais simétrica e, conseqüentemente, que as hipóteses do MMQ sejam confirmadas, resultando em modelos de melhor qualidade.

O problema de elevação adiabática de temperatura é complexo e ilustra como, na realidade, é importante realizar transformações nos dados existentes para a construção do conjunto de dados. Dessa forma, a capacidade do analista de encontrar alternativas é determinante para a obtenção de um bom resultado.

No próximo capítulo, os modelos lineares introduzidos neste capítulo serão utilizados para previsão de séries temporais e sistemas dinâmicos lineares.