

5 CLASSIFICAÇÃO

O objetivo da classificação supervisionada, ou simplesmente classificação, é o desenvolvimento de um **classificador**, isto é, um modelo capaz de prever a classe correta de um registro a partir dos valores das variáveis de entrada. A classificação pode ser entendida como um problema de decisão em que uma classe é escolhida de acordo com os valores dos atributos do problema, que são as variáveis de entrada.

Um modelo de classificação divide de forma explícita ou implícita o espaço de variáveis de entrada em regiões que são associadas às classes. A fronteira entre as regiões é chamada de **superfície de decisão**. A predição da classe é feita a partir da verificação da região correspondente ao registro que se deseja classificar. Em problemas reais, registros com valores similares de variáveis de entrada podem pertencer a classes diferentes devido ao efeito de variáveis não observadas, ruído etc. Esse tipo de registro é tratado como erro de classificação e o modelo é ajustado para minimizar esse erro. Em alguns casos, chamados desbalanceados, as classes não têm o mesmo número de registros, o que pode levar o modelo a realizar previsões enviesadas.

Este capítulo apresenta o problema de classificação a partir da teoria bayesiana de decisão, que permite uma formalização matematicamente simples e bastante elucidativa sobre as principais características do problema. Em seguida, apresentamos o método de discriminante linear em que a classificação é tratada como um problema de predição análogo à regressão linear e o modelo de regressão logística, muito conhecido na literatura. Este capítulo também apresenta as estatísticas mais utilizadas para avaliação da qualidade do modelo de classificação e alguns exemplos de aplicação.

5.1 Classificação Bayesiana

O teorema (ou regra) de Bayes¹¹⁵ foi criado pelo pastor Thomas Bayes e publicado em 1764, após sua morte, pelo amigo e filósofo Richard Price. O teorema de Bayes introduz a interpretação bayesiana da probabilidade como uma medida do “grau de conhecimento” sobre um evento em contraste com a interpretação baseada na frequência que mede a propensão de um evento ocorrer.

A apresentação do teorema de Bayes nesta seção é focada no problema de classificação e utiliza uma notação que evidencia os valores de probabilidade como função das variáveis do problema.

5.1.1 Decisão bayesiana

O problema de classificação é essencialmente uma decisão, uma vez que uma das classes deve ser escolhida em função dos valores das variáveis de entrada. A tomada de decisão no problema de classificação pode ser formalizada pelo **teorema de Bayes** [146][521], que relaciona o conhecimento prévio do problema na forma:

$$P(C_i|\mathbf{x}) = \frac{p(\mathbf{x}|C_i)P(C_i)}{p(\mathbf{x})} \quad (5.1)$$

onde $P(C_i|\mathbf{x})$ é a probabilidade de observar a classe C_i conhecendo a observação (evidência) dos valores das variáveis $\mathbf{x}$, chamada **probabilidade a posteriori**; $p(\mathbf{x}|C_i)$ representa a distribuição de probabilidades das variáveis $\mathbf{x}$ quando a classe observada é C_i , chamada de distribuição* de **probabilidade condicional**; e $P(C_i)$ é a probabilidade de ocorrência da classe C_i na ausência de qualquer observação, chamada de **probabilidade a priori**. O denominador $p(\mathbf{x}) = \sum_{i=1}^m p(\mathbf{x}|C_i)P(C_i)$ é a probabilidade de observar valores das variáveis $\mathbf{x}$, que funciona como um fator de padronização para que o resultado permaneça no intervalo $[0,1]$.

A equação (5.1) mostra de forma simples como a probabilidade de um evento é alterada pelo conhecimento de evidências relacionadas. O teorema de Bayes realiza uma “inversão” do conhecimento representado pela probabilidade condicional, o que mostra o raciocínio abdutivo¹¹⁶ do problema de classificação.

* Adotamos a notação com p minúsculo para representar uma função distribuição de probabilidades e P maiúsculo para representar um valor de probabilidades.

Considere, por exemplo, o raciocínio de um médico para o diagnóstico de uma doença a partir dos sintomas observados. O resultado do diagnóstico é determinado pela probabilidade *a posteriori*, isto é, o médico vai escolher, dentre as hipóteses plausíveis para o quadro observado, aquela que julgar mais provável. O conhecimento do médico é representado pela probabilidade condicional que estabelece a probabilidade de observação de um conjunto de sintomas $\mathbf{x}$ na presença de alguma doença C_i . A probabilidade *a priori* influi na decisão do médico, que, na observação dos mesmos sintomas, vai ter a tendência de decidir pela doença mais frequente.

A interpretação da equação (5.1) no contexto do problema de classificação fornece os elementos para o correto entendimento das características do problema e serve para o desenvolvimento de modelos de classificação.

Vamos considerar um exemplo simples, com apenas uma variável de entrada e duas classes. Inicialmente, vamos supor que as duas classes ocorrem com a mesma frequência, ou seja, têm a mesma probabilidade *a priori* $P(C_1) = P(C_2) = 0.5$. Vamos considerar também que as duas classes têm distribuição de probabilidade condicional normal $N(\mu, \sigma)$ de média μ e desvio padrão σ . Para o exemplo discutido a seguir, foram utilizadas as distribuições $p(x|C_1) = N(2.5, 2.5)$ e $p(x|C_2) = N(-1.5, 2.0)$.

A distribuição de probabilidade condicional para cada uma das classes e os valores de probabilidade *a posteriori* calculados pela regra de Bayes são mostrados na Figura 5.1. A função de probabilidade condicional $p(x|C_i)$ informa a probabilidade de observar um valor x sabendo-se que a classe é C_i . No exemplo, a média da distribuição $p(x|C_1)$ é maior que a média de $p(x|C_2)$.




Figura 5.1: Regra de Bayes: (a) probabilidade condicional; (b) probabilidade *a posteriori*.

No classificador bayesiano, o resultado do problema de classificação é obtido por uma **regra de decisão**, definida sobre os valores de probabilidade *a posteriori* das classes calculados pelo teorema de Bayes.

5.1.1.1 Decisão pelo mínimo erro de classificação

A decisão mais simples para a classificação bayesiana é feita pelo valor máximo de probabilidade *a posteriori*, que resulta na divisão do espaço das variáveis de entrada em duas regiões, cada uma associada a uma das classes, da seguinte forma:

$$\begin{aligned}\mathcal{R}_1 &= \{x \in \mathcal{R}, P(C_1|x) \geq P(C_2|x)\} \\ \mathcal{R}_2 &= \{x \in \mathcal{R}, P(C_2|x) > P(C_1|x)\}\end{aligned}\tag{5.2}$$

A Figura 5.1a mostra que valores da variável na região de sobreposição das funções de densidade condicional podem pertencer simultaneamente às duas classes com probabilidades diferentes. Dessa forma, considerando essa única variável, haverá um **erro de classificação**, calculado pela probabilidade de classificação incorreta como:

$$P(E) = \int_{\mathcal{R}_1} p(x|C_2)P(C_2)dx + \int_{\mathcal{R}_2} p(x|C_1)P(C_1)dx\tag{5.3}$$

O primeiro termo à direita da equação (5.3) representa o percentual de registros da classe C_2 que serão classificados como C_1 por estarem na região R_1 . Analogamente, o segundo termo representa o percentual de registros da classe C_1 que serão classificados como C_2 . O resultado da equação (5.3) para o exemplo da Figura 5.1 é mostrado na Figura 5.2, na qual as distribuições condicionais $p(x|C_i)$ são mostradas em linhas tracejadas e as distribuições $p(x|C_i)P(C_i)$, em linhas cheias.




Figura 5.2: Probabilidade de classificação incorreta.

É fácil mostrar que a classificação realizada pelas regiões $\mathcal{R}_1$ e $\mathcal{R}_2$ definidas nas equações (5.2) minimizam o erro definido pela equação (5.3) [521]. Observando a Figura 5.2, uma regra de decisão diferente de (5.2) resulta num aumento da área correspondente à equação (5.3), ou seja, da probabilidade de erro de classificação.

As regiões associadas às classes pela regra de decisão (5.2) seriam as mesmas se a decisão fosse realizada diretamente sobre a função de distribuição condicional, pois, no exemplo da Figura 5.2, as classes são equiprováveis. Quando a frequência relativa das classes é diferente, esse resultado não é válido e a região da classe mais frequente aumenta em relação à da menos frequente para refletir o efeito das classes mais frequentes. A Figura 5.3 mostra o resultado da probabilidade *a posteriori* quando as probabilidades *a priori* são diferentes. Observe o deslocamento do ponto de decisão em relação ao ponto de interseção das distribuições de probabilidade condicionais.

No ponto de decisão, ou seja, no valor limite entre as regiões $\mathcal{R}_1$ e $\mathcal{R}_2$, os valores de probabilidade *a posteriori* são iguais e $p(x|C_1)P(C_1) = p(x|C_2)P(C_2)$. Dessa forma, podemos escrever:

$$\frac{p(x|C_1)}{p(x|C_2)} = \frac{P(C_2)}{P(C_1)} \quad (5.4)$$




Figura 5.3: Regra de Bayes: (a) $P(C_1) > P(C_2)$; (b) $P(C_2) > P(C_1)$.

A equação (5.4) mostra que, no caso de problemas desbalanceados, a superfície de decisão é obtida quando a probabilidade condicional da classe menos frequente supera a probabilidade condicional da mais frequente na mesma razão do cociente das probabilidades *a priori*.

5.1.1.2 Decisão pelo mínimo risco condicional

No problema de duas classes em que uma é considerada positiva e outra, negativa, o resultado de um modelo de classificação pode ser apresentado pela **matriz de confusão** da Tabela 5.1. O resultado é chamado de verdadeiro positivo (VP) quando a classe positiva é predita corretamente pelo modelo ou verdadeiro negativo (VN) quando a classe negativa é predita corretamente. Os erros de classificação ocorrem de duas formas: se a classe positiva é predita quando a classe observada é negativa, o resultado é falso positivo (FP) (ou erro do Tipo I na nomenclatura de testes de hipóteses); o falso negativo (FN) (ou erro do Tipo II) acontece se a classe negativa é predita quando a classe observada é positiva.

Tabela 5.1: Matriz de confusão

	C_1 Predita	C_2 Predita
C_1 Real	VP	FN
C_2 Real	FP	VN

A matriz de confusão também será utilizada na seção 5.3 para avaliação de classificadores. Nesta seção, a matriz de confusão é utilizada para apresentar o conceito de risco de classificação incorreta.

Em muitas aplicações, principalmente quando as classes são desbalanceadas, o custo da classificação incorreta é diferente de acordo com o tipo de erro. Considere, por exemplo, um problema de diagnóstico médico a partir de um exame em que a classe positiva representa a presença de uma determinada doença grave. O erro FP consiste em alarmar o paciente desnecessariamente, enquanto o erro FN pode ter impacto importante no tratamento por atrasar a detecção da doença. Considerando que a probabilidade *a priori* de pacientes saudáveis é maior que a de pacientes portadores da doença, a classificação realizada de acordo com a regra (5.2) só detectaria a doença em casos nos quais as evidências fossem muito fortes.

O formalismo de decisão bayesiana permite representar o custo associado a cada decisão. O risco condicional associado a escolher uma classe C_i a partir da observação das evidências $\mathbf{x}$ é escrito como [146]:

$$R(C_i|\mathbf{x}) = \sum_{j=1}^m \lambda_{ij}P(C_j|\mathbf{x}) \quad (5.5)$$

onde λ_{ij} é o custo associado a escolher a classe C_i quando a classe correta é C_j .

No caso do problema de duas classes considerado anteriormente, o risco condicional associado a cada classe é calculado como:

$$\begin{aligned} R(C_1|x) &= \lambda_{11}P(C_1|x) + \lambda_{12}P(C_2|x) \\ R(C_2|x) &= \lambda_{21}P(C_1|x) + \lambda_{22}P(C_2|x) \end{aligned} \quad (5.6)$$

A decisão é calculada pelo menor risco condicional, que não é uma probabilidade. Considerando o risco de classificação correta nulo, $\lambda_{11} = \lambda_{22} = 0$, as regiões associadas às classes são calculadas como:

$$\begin{aligned} \mathcal{R}_1 &= \{x \in \mathcal{R}, \lambda_{21}P(C_1|x) \geq \lambda_{12}P(C_2|x)\} \\ \mathcal{R}_2 &= \{x \in \mathcal{R}, \lambda_{12}P(C_2|x) > \lambda_{21}P(C_1|x)\} \end{aligned} \quad (5.7)$$

A Figura 5.4 mostra a diferença da decisão de classificação calculada a partir do valor das probabilidades *a posteriori* (cf. equações (5.2)) ou pelo risco condicional (cf. equações (5.7)). No exemplo, as classes foram consideradas equiprováveis para facilitar a interpretação. Na Figura 5.4, as linhas tracejadas representam a distribuição de valores de probabilidade *a posteriori* e as linhas cheias, os valores de risco de classificação incorreta calculado pela equação (5.6).




Figura 5.4: Decisão pelo risco de classificação: (a) $\lambda_{12} > \lambda_{21}$; (b) $\lambda_{21} > \lambda_{12}$.

Quando o custo de classificação incorreta $\lambda_{12} > \lambda_{21}$, ou seja, o erro em favor da classe C_1 é mais grave, a região $\mathcal{R}_1$ calculada pela minimização do risco condicional (cf. equações (5.7)) é menor que a correspondente calculada pela minimização do erro de classificação (cf. equações (5.2)). Dessa forma, o limite de decisão se desloca visando reduzir a região associada à classe com maior custo de classificação incorreta. Caso contrário, quando $\lambda_{21} > \lambda_{12}$, o limite de decisão se desloca em favor da classe C_1 uma vez que o custo de classificação incorreta dessa classe é menor.

O erro de classificação calculado pela equação (5.3) é maior caso a decisão seja realizada pelo risco condicional, uma vez que a decisão pela probabilidade *a posteriori* é a que minimiza o erro de classificação. Entretanto, embora globalmente o erro seja maior, ele será menor na classe de maior custo de classificação incorreta.

A aplicação da decisão pelo mínimo risco condicional depende de estimativas dos valores de custo λ_{ij} . Em problemas em que o custo pode ser quantificado, os parâmetros são definidos facilmente. Entretanto, na maioria dos casos, os custos não podem ser especificados diretamente e os valores são estimados de forma *ad hoc*. Em problemas desbalanceados, os custos de classificação incorreta podem ser calculados para compensar o efeito do desbalanceamento.

O formalismo da classificação bayesiana é aplicado diretamente sobre dois modelos de classificação que são apresentados a seguir.

5.1.2 Classificador bayesiano simples

No problema de classificação, o conjunto de dados $\mathcal{T} = \{(\mathbf{x}(t), y(t)), t = 1 \dots N\}$, onde cada registro t é formado por pares ordenados $(\mathbf{x}(t), y(t))$, sendo $\mathbf{x}(t) \in \mathcal{R}^p$ o vetor das variáveis de entrada e a variável de saída $y(t) \in \mathcal{N}$, em que valor $y(t) = j$ associa o registro t à classe $C_j, j = 1, \dots, m$. É importante observar que os índices não representam uma relação de ordem entre as classes, apenas facilitam a representação das classes de forma simbólica.

O classificador bayesiano utiliza diretamente a regra de Bayes (5.1) para o cálculo da probabilidade *a posteriori* e realiza a decisão por uma das formas apresentadas anteriormente, geralmente pelo mínimo erro de classificação. No classificador **bayesiano simples** ou ingênuo (*naïf*), a distribuição de probabilidade condicional dos registros

do conjunto de treinamento é calculada, para cada classe, por uma estimativa que considera as variáveis de entrada independentes. Dessa forma, o classificador bayesiano simples não leva em consideração a covariância entre as variáveis e a distribuição de probabilidade condicional conjunta para cada classe é calculada como:

$$p(\mathbf{x}(t)|C_j) = \prod_{i=1}^p p(x_i(t)|C_j), \quad j = 1, \dots, m \quad (5.8)$$

No modelo mais comum, a probabilidade condicional de cada variável é estimada como uma distribuição normal monovariável $p(x_i(t)|C_j) \approx N(\hat{\mu}_{ij}, \hat{\sigma}_{ij}^2)$. Os parâmetros de média $\hat{\mu}_{ij}$ e de variância $\hat{\sigma}_{ij}^2$ são estimados no conjunto de treinamento como a média e a variância da variável $x_i(t)$ nos registros da classe C_j . Há variantes que utilizam outros modelos de distribuição condicional.¹¹⁷

A hipótese de independência entre as variáveis de entrada reduz consideravelmente o número de parâmetros a serem ajustados pelo classificador. A estimativa da matriz de covariâncias da distribuição normal multivariada (cf. equação (2.6)) requer $p(p + 1)/2$ parâmetros para cada classe, o que resulta num total de $p + p(p + 1)/2$ parâmetros, incluindo as médias. No classificador bayesiano simples, a hipótese de independência reduz o número de parâmetros a serem ajustado a apenas $2p$ para cada classe.

O ajuste de parâmetros do classificador bayesiano simples é muito eficiente. Para cada classe, para cada variável, calcula-se a média $\hat{\mu}_{ij}$ e a variância $\hat{\sigma}_{ij}^2$ estimadas – se a variável for numérica – ou então diretamente a frequência de cada valor nominal – quando a variável for categórica. A probabilidade *a priori* também é calculada diretamente pela frequência da classe.

Na avaliação, o resultado do classificador bayesiano simples é a probabilidade *a posteriori*, calculada diretamente pelo teorema de Bayes (cf. equação (5.1)), em que a probabilidade condicional conjunta é calculada pela equação (5.8). A decisão de classificação pode ser feita pela regra de mínimo erro de classificação ou de mínimo risco.

A Figura 5.5a mostra um exemplo sintético de um problema linearmente separável em $p = 2$ dimensões. A Figura 5.5b apresenta a superfície de decisão e as regiões associadas a cada classe pelo valor máximo de probabilidade *a posteriori*. As Figuras 5.5c e 5.5d mostram, respectivamente, as distribuições de probabilidade condicional normal ajustadas para cada uma das variáveis. Podemos perceber que, apesar de existir correlação

entre as variáveis, a diferença das médias das distribuições de probabilidade condicional permite ajustar um classificador capaz de gerar uma superfície de decisão eficiente.




Figura 5.5: Problema linearmente separável: (a) Conjunto de treinamento; (b) superfície de decisão; (c) distribuição $p(x_1|C_j)$; (d) distribuição $p(x_2|C_j)$.

A “economia” de parâmetros e a simplicidade do classificador bayesiano simples têm efeitos no seu desempenho. A Figura 5.6a mostra um exemplo um pouco mais complexo, no qual as classes não podem ser separadas por uma superfície linear – são, assim, chamadas de não separáveis linearmente. Nesse caso, a superfície de decisão gerada pelo classificador bayesiano simples, mostrada na Figura 5.6b, não permite separar as duas classes. O resultado pode ser entendido observando-se as distribuições condicionais nas Figura 5.6c e 5.6d, que mostram que a projeção dos dados em cada variável resulta em valores similares das médias e das variâncias das classes e, portanto, a distribuição conjunta das duas classes é muito parecida, de forma que a superfície de decisão gerada não é eficiente para separá-las.




Figura 5.6: Problema não separável linearmente: (a) conjunto de treinamento; (b) superfície de decisão; (c) distribuição $p(x_1|C_j)$; (d) distribuição $p(x_2|C_j)$.

A distribuição normal não é adequada para a representação da distribuição dos dados de cada classe no exemplo da Figura 5.6a. Entretanto, o problema principal é que o classificador bayesiano simples não é capaz de capturar a correlação existente entre as variáveis no conjunto de dados de cada classe. A Figura 5.7a mostra o mesmo conjunto de dados da Figura 5.6a após a transformação realizada pela análise de componentes principais (ACP), que elimina a correlação entre as variáveis. Nesse caso, o classificador bayesiano é capaz de separar as classes (cf. Figura 5.7b), mesmo que a distribuição normal não seja a melhor representação da distribuição das classes, como pode ser observado na Figura 5.7c e Figura 5.7d. Nesse caso, a diferença de variâncias das distribuições de probabilidade condicional permite gerar uma superfície de decisão correta.




Figura 5.7: Problema transformado pela ACP: (a) conjunto de treinamento; (b) superfície de decisão; (c) distribuição $p(x_1|C_j)$; (d) distribuição $p(x_2|C_j)$.

A utilização da ACP para eliminar a correlação dos dados nem sempre produz bons resultados, mas é um recurso que pode ser empregado na busca pelo melhor modelo de classificação. Na seção 5.4.1, os resultados do classificador bayesiano simples são comparados aos resultados de outros classificadores apresentados neste capítulo.

O classificador bayesiano simples é um classificador computacionalmente eficiente, que pode ser aplicado em problemas de grande dimensionalidade e permite combinar facilmente variáveis numéricas e categóricas. Um classificador bayesiano simples pode facilmente acomodar valores ausentes na avaliação, o que é um problema em diversos outros tipos de classificadores. O algoritmo básico, com algumas variações, pode ser encontrado em praticamente todos os *softwares* de ciência de dados. Apesar do seu desempenho regular, o classificador bayesiano tem muitas aplicações em ciência de dados [289], tendo se mostrado útil na classificação de documentos, em filtros de *spam*

[115] e na análise de sentimentos [348][427]. O bom desempenho do classificador bayesiano simples também o qualifica para utilização em *ensembles* [325], que combinam os resultados de vários modelos simples para melhorar o desempenho do classificador.

Em conjuntos de dados com registros suficientes para estimação das distribuições de probabilidade condicionais conjuntas, é possível utilizá-la na síntese do classificador, como descrito a seguir.

5.1.3 Classificador bayesiano quadrático

Um classificador realiza a predição da classe de um novo registro pela sua localização em relação às regiões associadas às classes. No caso de um problema com m classes, o resultado do classificador vai particionar o domínio das variáveis de entrada em m regiões. É possível generalizar regras de decisão como (5.2) e (5.7) pela definição de **funções discriminantes** em problemas de múltiplas classes. A classificação é feita pelo valor máximo da função discriminante como:

$$\mathbf{x}(t) \in C_i \rightarrow g_i(\mathbf{x}(t)) > g_j(\mathbf{x}(t)), \quad j = 1, \dots, m \quad (5.9)$$

No classificador bayesiano, a função discriminante pode ser calculada diretamente como $g_i(\mathbf{x}(t)) = P(C_i|\mathbf{x}(t))$ no caso de minimização da probabilidade de classificação incorreta ou como $g_i(\mathbf{x}(t)) = -R(C_i|\mathbf{x}(t))$ no caso de minimização do risco condicional, onde $R(C_i|\mathbf{x}(t))$ é definido em (5.5) e o sinal negativo é para manter coerência com a equação (5.9), uma vez que a decisão é tomada pelo menor risco de classificação. A escolha da função discriminante não é única e qualquer função monótona crescente de uma função discriminante $f(g_i(\mathbf{x}(t)))$ é também uma função discriminante.

A questão fundamental para a síntese de um classificador bayesiano é a escolha da função de distribuição de probabilidade condicional. No classificador bayesiano simples, a hipótese de independência resulta num classificador computacionalmente eficiente, mas de precisão apenas regular. O desempenho do classificador pode melhorar bastante se a distribuição condicional for mais bem estimada. Há métodos estatísticos, paramétricos e não paramétricos, para a estimativa de uma função de distribuição condicional [553]. A abordagem clássica é utilizar a distribuição normal multivariada como uma aproximação da distribuição condicional.

A hipótese de a probabilidade condicional ser uma distribuição normal permite a definição do classificador **bayesiano quadrático** [146][405], cuja função discriminante para a decisão pela minimização do erro de classificação é calculada como:

$$g_i(\mathbf{x}(t)) = \ln P(C_i|\mathbf{x}(t)) = \ln p(\mathbf{x}(t)|C_i) + \ln P(C_i), \quad i = 1, \dots, m \quad (5.10)$$

onde $p(\mathbf{x}(t)|C_i) = N(\hat{\boldsymbol{\mu}}_i, \hat{\boldsymbol{\Sigma}}_i)$ é a distribuição normal multivariada de médias $\hat{\boldsymbol{\mu}}_i$ e matriz de covariâncias $\hat{\boldsymbol{\Sigma}}_i$ estimadas a partir dos registros da classe C_i .

Substituindo a expressão da distribuição normal multivariada na equação (5.10):

$$g_i(\mathbf{x}(t)) = -\frac{1}{2}(\mathbf{x}(t) - \hat{\boldsymbol{\mu}}_i)\hat{\boldsymbol{\Sigma}}_i^{-1}(\mathbf{x}(t) - \hat{\boldsymbol{\mu}}_i)^T - \frac{1}{2}\ln 2\pi - \frac{1}{2}\ln|\hat{\boldsymbol{\Sigma}}_i| + \ln P(C_i) \quad (5.11)$$

O termo $-\frac{1}{2}\ln 2\pi$ é o mesmo para todas as classes e, por isso, não exerce influência na função discriminante, podendo ser eliminado.

A expressão da função discriminante calculada pela equação (5.11) é dominada por um termo quadrático e, por isso, o classificador bayesiano com distribuições normais multivariadas é chamado de classificador bayesiano quadrático. A Figura 5.8 mostra dois exemplos sintéticos de classes geradas por variáveis de distribuição normal e a superfície de decisão calculada pela função discriminante (5.11).




Figura 5.8: Exemplos de superfícies de decisão quadráticas.

O resultado do classificador bayesiano quadrático no conjunto de dados da Figura 5.6 é mostrado na Figura 5.9, na qual podemos observar que função discriminante é eficiente para a separação das classes.




Figura 5.9: Problema não separável linearmente: (a) conjunto de treinamento; (b) superfície de decisão pelo classificador bayesiano quadrático.

A estimativa dos parâmetros da equação normal para o cálculo da função discriminante como (5.11) pode se tornar inviável em problemas de alta dimensionalidade, uma vez que são necessários $p + p(p + 1)/2$ parâmetros para cada classe. Considere, por exemplo, o conjunto de dados *Wine*, com $p = 13$ variáveis de entrada, o que resulta em 104 parâmetros a serem estimados para cada classe. O conjunto de dados conta apenas 178 registros, dos quais 59 da classe C_1 , 71 da classe C_2 e 48 da classe C_3 , o que prejudica as estimativas de média e matriz de covariâncias.

Em problemas de alta dimensionalidade com reduzido número de registros, é possível utilizar a redução de dimensionalidade produzida por transformações lineares como a ACP e a ADL (análise discriminante linear). Aplicando a ADL no conjunto de dados *Wine*, o número de variáveis é reduzido para $\hat{p} = m - 1 = 2$, o que significa estimar apenas três parâmetros para a média e a matriz de covariâncias. A Figura 5.10 apresenta o resultado da superfície de decisão calculada pelo classificador bayesiano quadrático sobre o conjunto de dados *Wine* 2D, obtido após a transformação pela ADL do conjunto *Wine*. Podemos observar o contorno quadrático das funções discriminantes de cada classe.




Figura 5.10: Conjunto de dados *Wine* 2D: (a) conjunto de treinamento; (b) superfície de decisão pelo classificador bayesiano quadrático.

O classificador bayesiano com distribuições normais multivariadas gera uma função discriminante linear quando a matriz de covariâncias é a mesma para todas as classes e é estimada como a matriz de covariâncias dos dados, isto é, $\hat{\Sigma}_i = \hat{\Sigma}, i = 1, \dots, m$. Nesse caso, o termo quadrático da equação (5.11) pode ser ignorado (por ser o mesmo para todas as classes) e a função discriminante é escrita como:

$$g_i(\mathbf{x}(t)) = \mathbf{x}(t)\hat{\Sigma}^{-1}\hat{\boldsymbol{\mu}}_i^T - \frac{1}{2}\hat{\boldsymbol{\mu}}_i\hat{\Sigma}^{-1}\hat{\boldsymbol{\mu}}_i^T + \ln P(C_i) \quad (5.12)$$

A equação (5.12) pode ser escrita na forma de uma função linear como:

$$g_i(\mathbf{x}(t)) = \hat{\mathbf{x}}(t)\boldsymbol{\theta}_i^T \quad (5.13)$$

onde $\hat{\mathbf{x}}(t) = [1, \mathbf{x}(t)]$ é o vetor de regressores e $\boldsymbol{\theta}_i = [\theta_{i0}, \boldsymbol{\theta}_{i1}]$ é o vetor de parâmetros, cujos componentes $\theta_{i0} = -\frac{1}{2}\hat{\boldsymbol{\mu}}_i\hat{\Sigma}^{-1}\hat{\boldsymbol{\mu}}_i^T + \ln P(C_i)$ e $\boldsymbol{\theta}_{i1} = \hat{\Sigma}^{-1}\hat{\boldsymbol{\mu}}_i^T$.

O classificador bayesiano linear não requer um número considerável de parâmetros a serem estimados, pois apenas uma matriz de covariâncias é estimada para todas as classes. Entretanto, na prática, o desempenho pode ser pior que o classificador bayesiano simples.

Do ponto de vista conceitual, a equação (5.13) mostra que um classificador pode ser estimado diretamente por sua função discriminante, sem a necessidade de hipóteses sobre a função de distribuição de probabilidades condicional. Dessa forma, os modelos lineares podem ser aplicados à classificação, como apresentado a seguir.

5.2 Modelos Lineares de Classificação

A equação (5.13) mostra que um modelo linear pode ser utilizado para a aproximação da função discriminante num problema de classificação. Dessa forma, os problemas de classificação e de regressão são similares, diferindo apenas no tipo de variável de saída.

A síntese do classificador pode ser realizada diretamente pelo ajuste dos parâmetros de um modelo linear pelo método dos mínimos quadrados (MMQ), como apresentado nas seções 5.2.1 e 5.2.2. Entretanto, um modelo linear não permite a interpretação da função discriminante como um valor de probabilidade. Na regressão logística, apresentada na seção 5.2.3, o resultado do modelo linear é transformado por uma função exponencial que permite a interpretação do resultado como um valor de probabilidade.

5.2.1 Mínimos quadrados

O ajuste de parâmetros do modelo linear é feito a partir do conjunto de treinamento $\mathcal{T} = \{(\mathbf{x}(t), y(t)), t = 1 \dots N\}$, onde $\mathbf{x}(t) \in \mathcal{R}^p$ o vetor das variáveis de entrada e a saída $y(t) \in \mathcal{N}$, o índice das classes.

Para o ajuste da função discriminante, a variável de saída é transformada para refletir o resultado da função discriminante em (5.9). Essa transformação é feita pela definição de uma **variável indicadora** (“dummy”) bipolar $v_i(t) \in \{-1, 1\}$, como:*

$$v_i(t) = \begin{cases} +1, & \text{se } y(t) = i \\ -1, & \text{se } y(t) \neq i \end{cases} \quad i = 1, \dots, m \quad (5.14)$$

O vetor $\mathbf{v}(t) \in \{-1, 1\}^m$ é chamado de vetor de variáveis indicadoras, pois a posição do valor 1 no vetor indica a classe a que pertence o registro.

As funções discriminantes são calculadas pelo modelo linear como aproximações das variáveis indicadoras como:

$$\hat{v}_i(t) = g_i(\mathbf{x}(t), \boldsymbol{\theta}_i) = \hat{\mathbf{x}}(t) \boldsymbol{\theta}_i^T, \quad i = 1, \dots, m \quad (5.15)$$

As variáveis indicadoras estimadas $\hat{\mathbf{v}}(t) \in \mathcal{R}^m$ podem ser utilizadas para a classificação através da regra (5.9). Os parâmetros $\boldsymbol{\theta}_i$ são calculados, para cada classe, pela minimização do erro médio quadrático (EMQ):

* A variável indicadora binária $v_i(t) \in \{0, 1\}$ também pode ser utilizada.

$$EMQ(\theta_i) = \frac{1}{N} \sum_{t=1}^N (v_i(t) - \hat{v}_i(t))^2, \quad i = 1, \dots, m \quad (5.16)$$

A minimização do EMQ para cada classe é feita pelo MMQ da mesma forma que apresentada na seção 3.1.2. A relação *bias* x variância do modelo discutida na seção 3.2.1 e as técnicas de regularização apresentadas nas sessões 3.2.2 e 3.2.3 se aplicam igualmente ao modelo linear de classificação. A avaliação de classificadores, entretanto, é feita por estatísticas adicionais, discutidas na seção 5.3.

O modelo linear de classificação permite a síntese de um classificador por uma função discriminante linear nos parâmetros. No modelo linear polinomial, descrito na equação (3.3), a estrutura é definida pelo grau do polinômio. A Figura 5.11 apresenta dois exemplos de modelos polinomiais de classificação executados sobre os mesmos dados do exemplo mostrado na Figura 5.10: o conjunto de dados *Wine* após transformação pela ADL. A Figura 5.11a mostra o resultado do modelo linear, ou polinomial de grau 1, e a Figura 5.11b mostra o resultado do modelo quadrático ou polinomial de grau 2.




Figura 5.11: Superfícies de decisão no problema *Wine* 2D: (a) modelo linear; (b) modelo quadrático.

Os resultados da Figura 5.11 são ligeiramente diferentes entre si, mas há uma grande diferença entre o resultado da Figura 5.11b e o do classificador bayesiano quadrático, mostrado na Figura 5.10b. Em ambos os casos, o modelo é quadrático, mas, no classificador linear, a estrutura do modelo foi definida pela escolha do grau do polinômio, enquanto no classificador bayesiano, a estrutura do modelo foi definida pela hipótese de distribuição normal. O modelo linear foi ajustado pelo MMQ, enquanto o classificador bayesiano foi ajustado pelas médias e matrizes de covariâncias de cada classe.

O ajuste de parâmetros pelo MMQ obtém um classificador que realiza a decisão pela minimização do erro de classificação. Entretanto, em alguns problemas, é importante realizar a decisão pela minimização do risco condicional, que implica ponderar uma classe em relação à outra. É possível ponderar os registros de uma classe em relação a outra através do método dos mínimos quadrados ponderados descrito a seguir.

5.2.2 Mínimos quadrados ponderados

O método dos mínimos quadrados ponderados (MMQP) permite ajustar os parâmetros de um modelo linear na situação em que alguns registros são mais “importantes” que outros. O MMQP é utilizado na regressão linear para estabilizar a variância do conjunto de dados e reduzir a influência de *outliers* [399]. Em modelos lineares de classificação, o MMQP pode atribuir maior peso aos registros da classe de maior risco, permitindo que a decisão de classificação seja feita pela minimização do risco condicional.

A formulação do MMQP é feita a partir da definição de um vetor de pesos $\mathbf{w} \in \mathcal{R}^N$, em que cada elemento $w(t)$ representa o peso do registro $t \in \mathcal{T}$. Os parâmetros do modelo para cada classe θ_i são calculados pela minimização do **erro médio quadrático ponderado** (EMQP):

$$EMQP(\theta_i) = \frac{1}{N} \sum_{t=1}^N w(t) (v_i(t) - \hat{v}_i(t))^2, \quad i = 1, \dots, m \quad (5.17)$$

onde os valores de ponderação são os mesmos para o cálculo dos parâmetros de todas as classes, uma vez que a ponderação é aplicada aos registros.

Adotando a representação vetorial em que $\mathbf{V}_i = [v_i(1), \dots, v_i(N)]^T$ é a coluna i da matriz de saída, cujos elementos são os valores da variável indicadora da classe C_i , $\hat{\mathbf{X}}$ é a matriz de regressores (cf. equação (3.5)) e $\mathbf{W} = \text{diag}(\mathbf{w})$, a matriz diagonal em que cada elemento é o peso do registro correspondente, o EMQP pode ser escrito como:

$$EMQP(\theta_i) = \frac{1}{N} (\mathbf{V}_i - \hat{\mathbf{X}}\theta_i^T)^T \mathbf{W} (\mathbf{V}_i - \hat{\mathbf{X}}\theta_i^T), \quad i = 1, \dots, m \quad (5.18)$$

Derivando-se a expressão do EMQP na equação (5.18) e igualando a zero, obtemos a expressão das equações normais do MMQP, semelhante à equação (3.7):

$$\hat{\mathbf{X}}^T \mathbf{W} \hat{\mathbf{X}} \theta_i^T = \hat{\mathbf{X}}^T \mathbf{W} \mathbf{V}_i, \quad i = 1, \dots, m \quad (5.19)$$

A solução do sistema linear (5.19), considerando que a matriz* $\hat{\mathbf{X}}^T \mathbf{W} \hat{\mathbf{X}}$ tem posto completo, é calculada pela pseudoinversa como:

$$\theta_i^* = (\hat{\mathbf{X}}^T \mathbf{W} \hat{\mathbf{X}})^{-1} \hat{\mathbf{X}}^T \mathbf{W} \mathbf{v}_i, \quad i = 1, \dots, m \quad (5.20)$$

Os métodos de regularização discutidos na seção 3.2 se aplicam-se igualmente à solução do sistema linear da equação (5.19).

Na seção 3.1.3, foi visto que a solução calculada pelo EMQ produz melhor aproximação possível do conjunto de dados. Dessa forma, a solução calculada pelo MMQP terá um erro maior. Em problemas de classificação, a solução do MMQ corresponde à decisão pela minimização do erro de classificação na abordagem bayesiana, enquanto a solução do MMQP corresponde à minimização do risco condicional. Analogamente, o MMQP produz um erro global maior, mas terá um erro menor da classe mais importante.

Num problema de classificação desbalanceado, a classe minoritária é, em geral, a mais importante. Nesse caso, podemos definir a ponderação de cada registro pelo complemento do valor de probabilidade *a priori* da classe correspondente:

$$w(t) = 1 - \frac{N_i}{N} \quad \forall \mathbf{x}(t) \in C_i, \quad i = 1, \dots, m \quad (5.21)$$

onde N_i é o número de registros da classe C_i .

A ponderação realizada pela equação (5.21) é equivalente a eliminar o efeito da probabilidade *a priori* no classificador bayesiano. A probabilidade *a priori* influencia indiretamente o classificador ajustado pelo EMQ (cf. equação (5.16)), uma vez que a minimização do EMQ produz uma superfície de decisão que vai ser ajustada para incluir um número maior de registros da classe majoritária.

A Figura 5.12 mostra uma comparação dos resultados obtidos por um modelo quadrático ajustado pelo MMQ e pelo MMQP, com ponderações calculadas pela equação (5.21), nos dados do problema de Diabetes das índias Pima.¹¹⁸ Esse problema tem duas classes que representam o diagnóstico, positivo ou negativo, de diabetes em mulheres da etnia Pima a partir de atributos como número de filhos, pressão sanguínea etc. O

* A matriz de coeficientes $\hat{\mathbf{X}}^T \mathbf{W} \hat{\mathbf{X}} = (\mathbf{W} \hat{\mathbf{X}})^T \hat{\mathbf{X}}$. A matriz $\mathbf{W} \hat{\mathbf{X}}$ pode ser calculada diretamente a partir do vetor de pesos $\mathbf{w}^T$, multiplicando-se, elemento a elemento, as colunas da matriz de regressores $\hat{\mathbf{X}}$ pelo vetor de pesos $\mathbf{w}^T$, evitando-se, assim, o custo computacional e de alocação de memória do processamento dos elementos nulos da matriz diagonal $\mathbf{W}$.

conjunto de dados é desbalanceado e a classe negativa (C_1) tem 65% dos registros, enquanto a classe positiva (C_2) é atribuída a 35% dos registros. O conjunto de dados tem oito variáveis, mas a Figura 5.12 mostra os resultados calculados sobre as duas componentes principais para facilitar a visualização. Observe o aumento da região atribuída à classe positiva (em verde) no caso da solução calculada pelo MMQP.




Figura 5.12: Superfícies de decisão problema de Diabetes das índias Pima 2D: (a) MMQ; (b) MMQP.

Nos modelos lineares ajustados pelo MMQ e MMQP, a variável de saída é uma variável indicadora $v_i(t) \in \{-1, 1\}$, enquanto a aproximação do modelo linear $\hat{v}_i(t) \in \mathcal{R}$, que não pode ser interpretada a probabilidade *a posteriori* da classe. No modelo de regressão logística, descrito a seguir, o modelo linear é transformado para que resultado possa ser interpretado como um valor de probabilidade.

5.2.3 Regressão logística

A regressão logística, também conhecida como **modelo logit**, é um modelo de classificação encontrado em diversos *softwares* livres e comerciais, e em bibliotecas de linguagens de programação como R¹¹⁹ e Python.¹²⁰

A formulação clássica da regressão logística é obtida para o problema de classificação binária em que a saída observada é representada pela variável indicadora $v(t) \in \{0, 1\}$:

$$v(t) = \begin{cases} 1, & \text{se } \mathbf{x}(t) \in C \\ 0, & \text{se } \mathbf{x}(t) \notin C \end{cases} \quad (5.22)$$

O modelo é uma aproximação da probabilidade *a posteriori*, isto é, $g(\mathbf{x}, \boldsymbol{\theta}) \approx P(C|\mathbf{x})$, e a função discriminante é calculada pela função sigmoide, também conhecida por função logística ou logit (de onde o método deriva seu nome), aplicada ao modelo linear:

$$g(\mathbf{x}(t), \boldsymbol{\theta}) = \frac{1}{1 + \exp(-\hat{\mathbf{x}}(t)\boldsymbol{\theta}^T)} \quad (5.23)$$

onde $\hat{\mathbf{x}}(t) = [1, \mathbf{x}(t)]$ é o vetor de regressores e $\boldsymbol{\theta}$ é o vetor de parâmetros.

A Figura 5.13 mostra o comportamento da função sigmoide $g(z)$, na qual podemos observar que $\lim_{z \rightarrow +\infty} g(z) = 1$ e $\lim_{z \rightarrow -\infty} g(z) = 0$.




Figura 5.13: Função sigmoide ou logística.

A regressão logística é um modelo de classificação binária, cuja função discriminante é definida pela probabilidade *a posteriori* como:

$$\begin{aligned} P(v(t) = 1 | \mathbf{x}(t), \boldsymbol{\theta}) &= g(\mathbf{x}(t), \boldsymbol{\theta}) \\ P(v(t) = 0 | \mathbf{x}(t), \boldsymbol{\theta}) &= 1 - g(\mathbf{x}(t), \boldsymbol{\theta}) \end{aligned} \quad (5.24)$$

A equação acima pode ser escrita como uma distribuição de Bernoulli¹²¹:

$$P(v(t) | \mathbf{x}(t), \boldsymbol{\theta}) = \hat{v}(t)^{v(t)} (1 - \hat{v}(t))^{1-v(t)} \quad (5.25)$$

onde $\hat{v}(t) = g(\mathbf{x}(t), \boldsymbol{\theta})$ e $v(t) \in \{0, 1\}$.

O modelo de regressão logística é ajustado para maximizar a probabilidade (ou a função de verossimilhança) do modelo em representar os valores de observados:

$$L(\boldsymbol{\theta}) = \prod_{t=1}^N P(v(t) | \mathbf{x}(t), \boldsymbol{\theta}) \quad (5.26)$$

Aplicando a expressão (5.25) em (5.26), temos a expressão da função de verossimilhança da regressão logística:

$$L(\theta) = \prod_{t=1}^N \hat{v}(t)^{v(t)} (1 - \hat{v}(t))^{1-v(t)} \quad (5.27)$$

O produtório da equação (5.27) dificulta o ajuste de parâmetros e o resultado não se altera se o negativo do logaritmo da função de verossimilhança for utilizado para o ajuste de parâmetros como um problema de minimização:

$$l(\theta) = -\log(L(\theta)) = -\sum_{t=1}^N v(t) \log(\hat{v}(t)) + (1 - v(t)) \log(1 - \hat{v}(t)) \quad (5.28)$$

A Figura 5.14 mostra o resultado da função (5.28) calculada para um determinado registro. Quando $v(t) = 1$, mostrado na Figura 5.14a, $l(\theta) = -\log(\hat{v}(t))$, que aumenta exponencialmente à medida que $\hat{v}(t) \rightarrow 0$. No caso de $v(t) = 0$, mostrado na Figura 5.14b, $l(\theta) = -\log(1 - \hat{v}(t))$ que aumenta exponencialmente quando $\hat{v}(t) \rightarrow 1$.




Figura 5.14: Função de custo (5.28): (a) $v(t) = 1$; (b) $v(t) = 0$.

O negativo do logaritmo da função de verossimilhança (cf. equação (5.28)) é mais adequada para o ajuste de modelos de classificação que o EMQ pela solução de um problema de minimização. Os resultados da regressão logística e do modelo linear ajustado pelo MMQ são equivalentes, mas a regressão logística tem uma interpretação probabilística, que é mais adequada para a tomada de decisão. Entretanto, embora os parâmetros do modelo ocorram não linearmente na expressão da função sigmoide (5.23). Hastie e colaboradores [238] apresentam a solução baseada no método de Newton-Raphson, que resulta no algoritmo conhecido como mínimos quadrados iterativo ponderado [406]. O modelo de regressão logística também pode ser ajustado pelo método do gradiente como será apresentado na seção 9.1.2.

O modelo de regressão logística pode ser estendido para problemas de classificação de múltiplas classes [238][521] e para funções discriminantes não lineares [578]. No caso de múltiplas classes, o modelo é conhecido como **regressão softmax** e será discutido no Capítulo 9.

A Figura 5.15 apresenta o resultado de dois modelos de classificação sobre o conjunto de dados *Wine* 2D, formado pelo conjunto *Wine* após a ADL, discutido na Figura 5.10 e na Figura 5.11. A Figura 5.15a apresenta o resultado do classificador bayesiano simples; a Figura 5.15b mostra o resultado da regressão logística. Pode-se observar que o resultado da regressão logística é idêntico ao resultado do modelo de classificação linear ajustado pelo MMQ mostrado na Figura 5.11a.




Figura 5.15: Dados *Wine* 2D: (a) classificador bayesiano simples; (b) regressão logística.

Assim como na regressão, a escolha do melhor modelo deve ser feita a partir de estatísticas de validação calculadas em validação cruzada, como apresentado a seguir.

5.3 Avaliação de Classificadores

O problema de classificação é preditivo e, como no caso da regressão linear, é necessário evitar o *overfitting*. O processo de desenvolvimento de um modelo de classificação segue os mesmos passos delineados na seção 3.2, em que o objetivo da etapa de validação é a seleção do tipo e da estrutura do modelo mais adequados ao problema. As estatísticas são calculadas em validação cruzada para gerar um modelo com boa capacidade de generalização.

O modelo linear ajustado pelo MMQ segue as mesmas hipóteses da regressão linear e o classificador poderia ser avaliado pelas mesmas estatísticas de validação apresentadas na seção 3.3.1. Entretanto, o problema de classificação tem saídas discretas e, geralmente, não ordenadas que requerem estatísticas específicas. Esta seção apresenta uma descrição das estatísticas mais utilizadas para avaliação de classificadores.

5.3.1 Estatísticas de validação

As estatísticas de avaliação de classificadores são calculadas a partir da matriz de confusão, citada na seção 5.1.1 e apresentada na Tabela 5.2 para duas classes. A matriz de confusão é utilizada em estatística para representar as possíveis soluções de um teste de hipóteses. Em problemas de classificação, as linhas representam as classes observadas e as colunas, as classes preditas pelo modelo.

As estatísticas de validação são definidas para problemas de duas classes em que uma classe é chamada arbitrariamente de classe positiva e a outra, de classe negativa. Na Tabela 5.2, a classe C_1 é a classe positiva e a classe C_2 , a negativa.

Tabela 5.2: Matriz de confusão

	$\hat{C}_1$ (Predita)	$\hat{C}_2$ (Predita)
C_1 (Real)	VP	FN
C_2 (Real)	FP	VN

A matriz de confusão é preenchida com o número de registros correspondentes, obtidos, em geral, em validação cruzada, seguindo a seguinte terminologia:

- **Verdadeiros Positivos (VP):** é o número de registros da classe C_1 corretamente classificados pelo modelo como classe $\hat{C}_1$.
- **Falsos Negativos (FN):** é o número de registros da classe C_1 classificados pelo modelo como classe $\hat{C}_2$.
- **Falsos Positivos (FP):** é o número de registros da classe C_2 classificados pelo modelo como classe $\hat{C}_1$.
- **Verdadeiros Negativos (VN):** é o número de registros da classe C_2 corretamente classificados pelo modelo como classe $\hat{C}_2$.

A avaliação global do classificador é feita pela **acurácia** do modelo, que é sua taxa de classificação correta, calculada como:

$$ACC = \frac{VP + VN}{VP + FP + FN + VN} \quad (5.29)$$

O **erro global** de classificação é o complemento da acurácia:

$$ERR = 1 - ACC = \frac{FP + FN}{VP + FP + FN + VN} \quad (5.30)$$

O erro global destaca a diferença de desempenho de dois classificadores. Por exemplo, um modelo com acurácia de 96% tem o dobro do erro de outro modelo com 98% de acurácia.

As estatísticas globais de acurácia e erro não informam sobre o erro que o modelo está realizando para cada classe. Duas medidas frequentemente utilizadas em recuperação da informação podem ser utilizadas para avaliar o desempenho de classificadores [364]: **precisão** (PRE) e **recuperação** (REC), também chamada de sensibilidade ou *recall*. Estas medidas são definidas para cada classe como:

$$PRE(C_1) = \frac{VP}{VP + FP} \quad PRE(C_2) = \frac{VN}{VN + FN} \quad (5.31)$$

$$REC(C_1) = \frac{VP}{VP + FN} \quad REC(C_2) = \frac{VN}{VN + FP} \quad (5.32)$$

A precisão mede a capacidade de predição do modelo e a recuperação é sua capacidade de reconhecer os registros da classe correspondente. Em problemas de classificação com múltiplas classes, as medidas de precisão e *recall* são calculadas para cada classe considerando as demais como a classe negativa. As medidas de precisão e recuperação podem ser combinadas na chamada **medida F**, definida para a classe C_i como:

$$F(C_i) = \frac{2 PRE(C_i). REC(C_i)}{PRE(C_i) + REC(C_i)} \quad (5.33)$$

A medida F representa a média harmônica entre precisão e *recall*, e indica o desempenho em termos das duas estatísticas simultaneamente, podendo ser generalizada para variar entre a precisão e o *recall* através de um parâmetro [516].

Em problemas desbalanceados, as estatísticas de cada classe devem ser consideradas em conjunto para não levar a conclusões equivocadas. Por exemplo, considere um problema de duas classes, em que a probabilidade *a priori* $P(C_1) = 90\%$. Um classificador

que classifique todos os registros na classe majoritária (C_1) vai obter $PRE(C_1) = 0.9$ e $REC(C_1) = 1.0$, mas $PRE(C_2) = REC(C_2) = 0.0$ para a classe minoritária (C_2).

A estatística **kappa** é uma medida global que relaciona a probabilidade de concordância observada com a probabilidade de concordância esperada $P(E)$ [110]. Em modelos de classificação, a concordância observada é medida pela acurácia do classificador (5.29) e a concordância esperada é o resultado que seria obtido por um modelo aleatório em uma amostra de tamanho infinito. O coeficiente kappa (κ) é calculado como:

$$\kappa = \frac{ACC - P(E)}{1 - P(E)} \quad (5.34)$$

O valor $\kappa \leq 1$, sendo que $\kappa = 1$, indica a concordância completa; $\kappa = 0$ indica que $ACC = P(E)$, isto é, a acurácia é igual à concordância esperada. Um valor $\kappa < 0$ indica que o classificador tem um desempenho pior que um resultado puramente aleatório. Landis e Koch [327] sugerem que um valor de $\kappa \geq 0,8$ representa boa concordância e um resultado $0,6 \leq \kappa < 0,8$ representa uma concordância razoável. A probabilidade de concordância esperada $P(E)$ é calculada a partir da matriz de confusão, como:

$$P(E) = P(C_1)P(\hat{C}_1) + P(C_2)P(\hat{C}_2) \quad (5.35)$$

onde $P(C_1)$ é a probabilidade *a priori* da classe C_1 , $P(C_2)$ é a probabilidade *a priori* da classe C_2 , $P(\hat{C}_1)$ é o percentual de registros preditos como sendo da classe $\hat{C}_1$ pelo modelo e $P(\hat{C}_2)$, o percentual de registros preditos como classe $\hat{C}_2$.

Os termos da equação (5.35) são calculados como:

$$P(C_1) = \frac{VP + FN}{VP + FP + FN + VN} = \frac{N_1}{N} \quad (5.36)$$

$$P(C_2) = \frac{FP + VN}{VP + FP + FN + VN} = \frac{N_2}{N} \quad (5.37)$$

$$P(\hat{C}_1) = \frac{VP + FP}{VP + FP + FN + VN} = \frac{\hat{N}_1}{N} \quad (5.38)$$

$$P(\hat{C}_2) = \frac{FN + VN}{VP + FP + FN + VN} = \frac{\hat{N}_2}{N} \quad (5.39)$$

Os valores totais observados e preditos de cada classe são mostrados na Tabela 5.3.

Tabela 5.3: Totais observados e preditos de cada classe

	$\hat{C}_1$	$\hat{C}_2$	Total
C_1	VP	FN	N_1
C_2	FP	VN	N_2
Total	$\hat{N}_1$	$\hat{N}_2$	N

A avaliação de classificadores também é feita graficamente utilizando as taxas de verdadeiros positivos e de falsos positivos no chamado de espaço ROC, descrito a seguir.

5.3.2 Espaço ROC e AUC

Na seção 5.1.1, foi visto que, em caso de problemas desbalanceados, a decisão pelo mínimo erro de classificação favorece a classe majoritária. Em muitos problemas, a classe minoritária é a mais importante e, nesse caso, o erro global não pode ser utilizado para a escolha do classificador. A escolha do classificador em problemas desbalanceados deve favorecer a classe mais importante, aumentando a recuperação de registros de maior custo.

O efeito do desbalanceamento do problema sobre o resultado do classificador ajustado pelo mínimo erro de classificação é mostrado na Figura 5.16 que mostra o valor de $p(x|C_i)P(C_i)$ de cada para um problema de uma variável e duas classes. A situação em que as probabilidades *a priori* são iguais é mostrada na Figura 5.16a. Nesse caso, as taxas de FP e FN são definidas pela forma e posição das distribuições condicionais. No caso de problemas desbalanceados (Figura 5.16b), o ajuste do modelo pelo mínimo erro de classificação favorece a classe mais frequente (C_1), resultando num aumento da taxa de VP e consequente diminuição da taxa de VN. Quando a classe minoritária é a mais importante, o classificador deve favorecer a taxa de VN. Entretanto, o aumento da taxa de VN só pode ser obtido à custa de um aumento da taxa de FN, o que aumenta também o erro global, como foi discutido na seção 5.2.2.




Figura 5.16: Problemas desbalanceados: (a) $P(C_1) = P(C_2)$; (b) $P(C_1) > P(C_2)$.

O espaço ROC (do inglês *receiver operating characteristic*) foi desenvolvido por operadores de radar para caracterização do *trade-off* entre a taxa de detecção e a de falsos alarmes em ambientes com ruído [516][561]. Para avaliação de classificadores, as taxas de FP e VP obtidas por um classificador são utilizadas como coordenadas do espaço ROC, mostrado na Figura 5.17.




Figura 5.17: Espaço ROC.

A taxa de VP (TVP) é o *recall* da classe positiva $REC(C_1)$ em (5.32) e a taxa de FP (TFP) é o complemento da taxa de VN ($REC(C_2)$) chamada de **especificidade** (SPE). O valor de TFP é calculado como:

$$TFP = 1 - SPE = 1 - \frac{VN}{FP + VN} = \frac{FP}{FP + VN} \quad (5.40)$$

O espaço ROC mostra o desempenho do classificador relacionando o quanto ele acerta da classe positiva e o quanto deixa de errar da classe negativa. O modelo ideal é o ponto (0,1) do gráfico, com $TFP = 0$, ou seja, $SPE = REC(C_2) = 1$ e $REC(C_1) = 1$. Nesse caso o modelo tem 100% de aproveitamento, pois recupera todos os exemplos de ambas as classes. Classificadores na diagonal do espaço ROC têm $REC(C_1) = 1 - REC(C_2)$, são modelos com $\kappa = 0$, ou seja, têm desempenho equivalente a um modelo aleatório. Os classificadores abaixo da diagonal representam modelos com $\kappa < 0$.

A área sombreada na Figura 5.17 é uma medida de avaliação de classificadores chamada de área sob a curva ROC (AUC, na sigla em inglês). A medida AUC é calculada pela área do quadrilátero obtido ao se ligar as coordenadas do classificador aos pontos (0,0) e (1,1) (cf. Figura 5.17). Após algumas simplificações, o valor de AUC é calculado como a média entre a taxa de VP e VN:

$$AUC = \frac{REC(C_1) + REC(C_2)}{2} \quad (5.41)$$

O valor de AUC é calculado pela equação (5.41) para problemas de duas classes. Em problemas de múltiplas classes, um valor de AUC é calculado para cada classe, considerada a classe positiva, e o valor de AUC total do classificador é calculado pela média do AUC de cada classe ponderada pela estimativa de probabilidade *a priori* da classe correspondente [176]:

$$AUC = \sum_{i=1}^m AUC(C_i)P(C_i) \quad (5.42)$$

onde $AUC(C_i)$ é o valor calculado pela equação (5.41) considerando a classe C_i como positiva e $P(C_i)$ é a frequência relativa da classe C_i . Outras abordagens para o cálculo do valor total de AUC foram avaliadas por Hand e Till [235].

Um método gráfico de avaliação de modelos no espaço ROC é chamado de curva ROC, que apresenta uma curva contínua no espaço ROC para cada classe. O valor AUC nesse caso é calculado integrando-se a curva ROC pelo método dos trapézios. Entretanto, a curva ROC é independente da frequência das classes [176]. A medida de AUC obtida pela equação (5.41), além de mais eficiente, é sensível às frequências das classes sendo portanto mais adequada em problemas desbalanceados.

O resultado do valor AUC em problemas desbalanceados pode ser observado no conjunto de dados Diabetes das índias Pima, discutido na seção 5.2.2. Nesse problema, a classe positiva é a minoritária, representada por C_2 , com 35% dos registros. A Figura 5.18 mostra os resultados calculados em validação cruzada para os modelos quadráticos ajustados pelo MMQ e pelo MMQP utilizando todas as variáveis.

Na coluna da esquerda, a Figura 5.18a apresenta os resultados de precisão e *recall* de cada classe do classificador ajustado com o MMQ e a Figura 5.18c mostra o espaço ROC e o valor de AUC calculado pela equação (5.41) do mesmo modelo. Na coluna da direita, os mesmos resultados são apresentados para o modelo ajustado com o MMQP.




Figura 5.18: Resultados do problema Diabetes das índias Pima: (a) e (c) Modelo ajustado com MMQ; (b) e (d) modelo ajustado com MMQP.

No modelo ajustado pelo MMQP, a recuperação da classe positiva (C_2) é maior, resultando num valor maior de AUC. O modelo ajustado pelo MMQ obtém menor erro global, influenciado pelo desbalanceamento entre as classes, resultando numa taxa de recuperação maior da classe negativa (C_1).

5.4 Aplicações

Os modelos de classificação apresentados neste capítulo serão discutidos nesta seção em dois contextos diferentes. Na seção 5.4.1, os algoritmos são comparados numa série de conjuntos de dados *benchmark* para uma avaliação global do desempenho do algoritmo. Esse mesmo tipo de teste será repetido nos Capítulos 7 e 8 com os modelos de classificação de inteligência computacional. Na seção 5.4.2, apresentamos um estudo de caso sobre a análise de cancelamentos em um operador de telefonia.

5.4.1 Testes *benchmark*

O repositório da Universidade da Califórnia em Irvine (UCI)¹²² é uma referência na área de ciência de dados e contém diversos conjuntos de dados para avaliação de algoritmos em problemas reais.

Um conjunto de 10 *benchmarks* foi selecionado para a avaliação dos modelos apresentados neste capítulo:

- Bayes N: Classificador bayesiano simples (*naif*)
- Bayes Q: Classificador bayesiano multivariado (quadrático)
- Logit: Regressão logística
- M. Lin. 1: Modelo linear de primeira ordem
- M. Lin. 2: Modelo linear de segunda ordem

Os conjuntos de dados foram selecionados de forma a cobrir uma grande variedade de tipos de problemas de dimensões diferentes, tanto em termos de número de registros quanto de número de variáveis. A Tabela 5.4 apresenta o número de variáveis (p), o número de classes (m) e o número de registros (N) de cada problema.

A maioria dos *benchmarks* são problemas conhecidos na literatura. Os *benchmarks* *Wine* e *Diabetes das índias Pima* já foram utilizados neste capítulo como exemplos de aplicação dos modelos. Nesta avaliação, todos os *benchmarks* foram utilizados como dados brutos, ou seja, não foi feito nenhum pré-processamento que pudesse interferir

no desempenho dos modelos. Os algoritmos de ajuste de parâmetros também foram executados em sua forma padrão, ou seja, sem utilizar nenhuma ponderação para compensar o desbalanceamento das classes. Todos os testes foram realizados em validação cruzada de 10 ciclos, conforme o algoritmo descrito na seção 3.3.2.

Tabela 5.4: Conjuntos de dados *benchmark*

<i>Benchmark</i>	<i>p</i>	<i>m</i>	<i>N</i>
Íris ¹²³	4	3	150
Balance ¹²⁴	4	3	625
Diabetes ¹²⁵	8	2	768
Cancer ¹²⁶	9	2	286
Statlog Heart ¹²⁷	13	2	270
Wine ¹²⁸	13	3	178
Parkinson ¹²⁹	17	2	186
Ionosphere ¹³⁰	32	2	351
Spambase ¹³¹	57	2	4601
Sonar ¹³²	60	2	208

O desempenho dos modelos pode ser avaliado quantitativamente através das métricas de acurácia (ACC), definida na equação (5.29), e da área sobre a curva ROC (AUC), definida na equação (5.41). Os resultados são apresentados na Tabela 5.5, na qual os valores em negrito correspondem aos maiores valores de cada métrica para o respectivo *benchmark*.

Os resultados apresentados na Tabela 5.5 mostram que nenhum modelo é melhor em todos os testes, mas indicam que o modelo linear de segunda ordem (M. Lin. 2) obtém os melhores resultados na maioria das vezes. Além disso, os modelos quadráticos (Bayes Q e M. Lin. 2) obtiveram resultados melhores que seus correspondentes mais simples (Bayes N e M. Lin. 1) na maioria dos casos. O modelo de regressão logística (Logit) apresentou resultados próximos aos do modelo linear simples (M. Lin. 1).

É importante verificar se o melhor desempenho representa realmente um comportamento consistente do modelo ou é um resultado obtido em função de fatores aleatórios. Essa avaliação é feita por testes estatísticos não paramétricos [125][195] disponíveis em *softwares* estatísticos e no *software* livre KEEL,¹³³ utilizado nesta seção.

Tabela 5.5: Resultados dos testes *benchmark*

<i>Benchmark</i>	Bayes N		Bayes Q		Logit		M. Lin. 1		M. Lin. 2	
	<i>ACC</i>	<i>AUC</i>	<i>ACC</i>	<i>AUC</i>	<i>ACC</i>	<i>AUC</i>	<i>ACC</i>	<i>AUC</i>	<i>ACC</i>	<i>AUC</i>
Íris	94.67	0.9600	98.00	0.9850	82.67	0.8697	83.33	0.8747	95.33	0.9650
Balance	90.40	0.9079	91.68	0.9469	87.04	0.8755	87.04	0.8755	91.36	0.9171
Diabetes	71.88	0.7260	74.61	0.7054	76.69	0.7145	76.30	0.7089	77.21	0.7151
Cancer	94.58	0.9574	95.02	0.9559	96.05	0.9512	96.05	0.9512	97.22	0.9709
Statlog Heart	83.70	0.8392	82.59	0.8225	83.33	0.8275	84.07	0.8358	84.44	0.8375
Wine	97.19	0.9766	99.44	0.9958	98.88	0.9919	98.31	0.9881	99.44	0.9958
Parkinson	79.49	0.7026	80.51	0.8427	86.15	0.7889	86.15	0.7889	86.15	0.8099
Ionosphere	60.68	0.6933	86.89	0.8803	85.75	0.8138	86.04	0.8178	89.46	0.8602
Spambase	90.18	0.8911	82.53	0.8474	88.63	0.8686	88.63	0.8684	91.37	0.9006
Sonar	72.60	0.7159	71.15	0.6992	76.92	0.7656	75.96	0.7579	80.29	0.8010

O teste de hipóteses é uma técnica clássica de estatística que permite avaliar se um conjunto de evidências observadas confirma ou refuta uma hipótese. Nos testes de hipótese paramétricos, há um modelo da distribuição do processo e o teste é realizado sobre os parâmetros da distribuição. Nos testes chamados não paramétricos, não há um modelo da distribuição dos dados [501]. Na avaliação de classificadores, as hipóteses são formuladas da seguinte forma:

- Hipótese nula $\mathcal{H}_0$: os modelos apresentam resultados equivalentes;
- Hipótese alternativa $\mathcal{H}_1$: os modelos não apresentam resultados equivalentes.

A aceitação da hipótese nula significa que as diferenças de desempenho são devidas às particularidades de cada *benchmark* [195]. O resultado do teste de hipóteses (paramétrico ou não paramétrico) é o chamado **valor- p** , que mede a significância estatística das diferenças observadas na avaliação. O valor- p é interpretado como a probabilidade de observar o resultado obtido considerando que a hipótese nula é verdadeira. Em outras palavras, o valor- p representa a probabilidade do chamado erro Tipo I (ou falso negativo), de rejeitar a hipótese nula quando, de fato, ela é verdadeira. Quanto menor o valor- p , menor é a probabilidade de que a hipótese nula seja verdadeira. Tipicamente, a

hipótese nula é rejeitada se o valor- $p < 0.05$, que representa confiança estatística de 95% na hipótese alternativa.

Garcia e colaboradores [195] sugerem que os testes não paramétricos são mais indicados para avaliação de classificadores. O teste de Friedman, particularmente o chamado *Friedman aligned rank*, é recomendado quando um número relativamente pequeno de modelos (menor que cinco) são comparados. O teste ordena os resultados obtidos por cada modelo e utiliza as diferenças de ordem para o mesmo *benchmark* e as diferenças de ordem para o mesmo modelo em *benchmarks* diferentes [195].

Nesta seção, discutimos apenas os resultados do teste *Friedman aligned rank*. Uma discussão detalhada deste e outros métodos é feita por Garcia e colaboradores [195]. Os autores são do grupo de pesquisa responsável pelo desenvolvimento do *software* livre KEEL [9][10], utilizado para a realização dos testes. O *software* tem um módulo de testes não paramétricos, com várias opções de testes.

A Tabela 5.6 mostra os *rankings* de cada modelo, calculados pelo teste de Friedman a partir dos resultados da Tabela 5.5, e o valor- p correspondente a cada métrica de avaliação. O classificador calculado pelo discriminante linear de segunda ordem (M. Lin. 2) obteve o melhor *ranking* pelo teste de Friedman pelas duas métricas. O valor- p indica que as probabilidades de erro em considerar as diferenças significativas são, respectivamente, de 8,26% e 7,95% para as métricas de ACC e AUC.

Tabela 5.6: Resultados de teste *Friedman aligned rank*

	ACC	AUC
Bayes N	33.30	31.95
Bayes Q	28.55	23.80
Logit	26.45	31.25
M. Lin. 1	26.75	27.35
M. Lin. 2	12.45	13.15
Valor- p	0.0826	0.0795

O grande problema dos testes estatísticos é que, na grande maioria dos casos, não se pode ter 100% de certeza dos resultados. O que o teste estatístico mostra, com uma confiança estatística em torno de 92%, é que o modelo discriminante linear de segunda ordem apresenta um desempenho melhor que os demais. Esse resultado é coerente com o argumento teórico de que o MMQ é mais robusto que a estimativa de parâmetros

do classificador bayesiano. O teste de hipóteses quantifica esse resultado, que não fica evidente observando-se apenas o melhor resultado de cada *benchmark* na Tabela 5.5.

5.4.2 Análise de cancelamento em telefonia

Empresas que operam em ambiente competitivo estão sempre preocupadas em promover a fidelização dos clientes de maior valor em sua base, uma vez que a manutenção de um cliente tem menor custo que a captação de novos clientes. Em empresas que oferecem serviços de assinatura, como telefonia e TV paga, um termo muito difundido é a taxa de *churn*,¹³⁴ que se refere ao percentual de cancelamentos de assinaturas num determinado período. O desenvolvimento de modelos preditivos de cancelamentos é uma das áreas de aplicação mais ativas de ciência de dados [422][530].

Um exemplo interessante de análise de cancelamentos num operador de telefonia foi apresentado por Cister [107]. A base de dados é uma amostra de clientes considerados de alto valor: empresas com média de quatro linhas móveis e alto consumo. A base de dados original é um conjunto de dados em três dimensões: 1.171 clientes, 10 variáveis de consumo e 12 meses. A amostra de dados foi realizada entre agosto de 2004 e julho de 2005 [107].

A análise apresentada nesta seção foi realizada sobre a média das variáveis de consumo por cliente, uma vez que as variáveis de consumo representavam o faturamento de cada tipo de ligação realizado pelo cliente durante o mês. Dessa forma, foi possível eliminar a dimensão de consumo e trabalhar com uma tabela de clientes por mês, que, após a retirada de 2,5% de *outliers*, ficou com 1.141 registros. Uma análise preliminar do gráfico de linhas aplicado às médias e desvios padrão de cada variável (Figura 5.19) revelou que o comportamento nos seis primeiros meses da amostra foi praticamente constante, não havendo interesse para o modelo de predição. Com isso, foram selecionadas as variáveis correspondentes aos seis últimos meses, assinaladas na Figura 5.19, em que a variável x_1 representa o consumo médio seis meses antes do final da amostra (fevereiro de 2005) e a variável x_6 representa o consumo médio no último mês do estudo (julho de 2005).




Figura 5.19: Gráfico de linhas: médias e desvios padrão de cada variável por classe.

O objetivo do modelo é a predição dos clientes que abandonaram a companhia após o período da amostra. A classe C_1 representa os clientes que continuaram a assinatura e C_2 os clientes que cancelaram a assinatura que, nesse caso, é a classe de maior relevância. A Figura 5.19 mostra que o comportamento dos clientes que vieram a cancelar mudou consideravelmente a partir do nono mês da amostra, aumentando bruscamente e depois diminuindo até valores inferiores aos registrados até o mês oito. As causas dessa mudança de comportamento não foram divulgadas [107].

A Figura 5.20 mostra as principais características da base de dados. As distribuições das variáveis de consumo médio são razoavelmente assimétricas e as variáveis são bem correlacionadas entre si, à exceção da variável x_6 , que representa o consumo no último mês da amostra e que tem um comportamento bem diferente das demais variáveis.

Uma das principais características desse problema é o alto grau de desbalanceamento da base, uma vez que a classe dos clientes que cancelaram a assinatura (C_2) tem apenas 7,17% dos registros.

O objetivo nesta seção é avaliar os efeitos da ponderação para compensar o desbalanceamento das classes nos resultados dos modelos. Os modelos bayesianos e lineares discutidos na seção 5.4.1 foram utilizados na avaliação. Os modelos foram executados de duas formas: sem ponderação para compensar o efeito da probabilidade *a priori* e com ponderação. No caso dos modelos bayesianos, a ponderação corresponde a retirar o valor de probabilidade *a priori* do cálculo do valor de probabilidade *a posteriori*.





Figura 5.20: Características da base de cancelamentos.

Os resultados de acurácia (ACC) e AUC são apresentados na Tabela 5.7, na qual os valores máximos de cada métrica em cada tipo de teste estão em negrito. Podemos observar que, em todos os modelos, a ponderação resultou em diminuição de ACC e aumento de AUC.


Tabela 5.7: Resultados dos modelos

Modelo	Bayes N		Bayes Q		M. Lin. 1		M. Lin. 2	
	ACC	AUC	ACC	AUC	ACC	AUC	ACC	AUC
S. Pond.	92.82	0.5119	96.41	0.8272	92.91	0.5179	94.40	0.6300
C. Pond.	90.63	0.7960	88.18	0.8814	85.29	0.8658	90.19	0.8868


Os gráficos de precisão e *recall* para cada modelo com e sem ponderação são mostrados na Figura 5.21, na qual a coluna da esquerda representa os resultados sem ponderação e a coluna da direita, os resultados com ponderação. Podemos observar que a ponderação aumenta a taxa de recuperação (*recall*) da classe minoritária C_2 em todos os modelos, que provoca o aumento de AUC.




(a)




(b)




(c)




(d)




(e)



(f)



(g)



(h)

Figura 5.21: Precisão e *recall*, coluna da esquerda sem ponderação e coluna da direita com ponderação: (a) e (b) Bayes N; (c) e (d) Bayes Q; (e) e (f) M. Lin. 1; (g) e (h) M. Lin. 2.

Em problemas altamente desbalanceados como este, é importante utilizar as métricas adequadas para avaliação dos algoritmos. O classificador bayesiano simples e o modelo linear de primeira ordem, sem ponderação, obtiveram resultados de acurácia próximos à probabilidade *a priori* da classe majoritária C_1 (92,83%). Consequentemente, esses modelos obtiveram taxas de recuperação muito pequenas da classe minoritária C_2 que, neste exemplo, é a de maior relevância. Esse resultado foi identificado pelo valor de AUC próximo a 0.5 nos dois modelos.

5.5 Comentários Finais

O problema de reconhecimento de padrões é um problema clássico e há vários livros dedicados ao assunto [43][146][189][521][553]. É muito difícil condensar os tópicos mais importantes num único capítulo. O critério utilizado para a seleção dos assuntos apresentados foi a importância para a formulação do problema de classificação e a relevância para a fundamentação das técnicas de inteligência computacional que serão discutidas nos Capítulos 7, 8 e 9.

Alguns assuntos importantes não foram incluídos. Os modelos de árvore de decisão, por exemplo, que estão presentes em praticamente todos os livros de ciência de dados [232][516][561], não foram incluídos. Optou-se por uma fundamentação do problema de classificação baseada no teorema de Bayes. O leitor vai encontrar uma apresentação teórica completa dos modelos de classificação sob a ótica de aprendizado de máquina no excelente livro de Mitchel [392]. Uma discussão mais detalhada dos modelos de árvore de decisão é apresentada por Quinlan [446].

A formulação da regra de Bayes é bastante adequada para o entendimento do problema de classificação. Mesmo que o classificador não utilize diretamente o teorema de Bayes na sua formulação, os efeitos da probabilidade condicional e, principalmente, da probabilidade *a priori* estarão presentes em todo classificador que seja ajustado pela minimização do erro de classificação.

Nas redes bayesianas [121][125][247][263], a distribuição de probabilidades é definida para pares de variáveis selecionadas e o modelo é representado através de um grafo. O modelo de redes bayesianas busca um compromisso entre as propriedades teóricas do teorema de Bayes e a dificuldade de estimação de parâmetros em proble-

mas de alta dimensionalidade. Uma apresentação bastante completa do tema é encontrada no livro de Koller e Friedman [316] e no curso do Coursera.¹³⁵ A obtenção da estrutura do grafo não é tarefa trivial, embora existam algoritmos eficientes [125].

Em geral, para uma amostra de tamanho finito, o problema de identificar a distribuição de probabilidades do processo que gerou a amostra é mais complexo que encontrar uma função discriminante [98]. Dessa forma, os modelos de classificação mais modernos buscam diretamente encontrar a função discriminante com base nas observações disponíveis. A minimização do erro de classificação no conjunto de treinamento para um modelo de estrutura fixa é a abordagem mais comum. Nos modelos de máquina de vetor de suporte (SVM, na sigla em inglês) [478][532], o erro de classificação é limitado e o ajuste de parâmetros busca um modelo maximizando a margem de separação entre as classes, o que corresponde à minimização da estrutura do modelo. Esse tipo de modelo, que começou a se difundir na área de ciência de dados a partir de meados da década de 1990, será apresentado no Capítulo 7. Recentemente, redes neurais têm se destacado em problemas de classificação, principalmente em aplicações complexas como visão computacional e processamento de linguagem natural. As redes neurais serão apresentadas no Capítulo 9.

Há diversas abordagens para o tratamento de problemas desbalanceados na literatura [90][273]. A abordagem mais comum é a reamostragem de dados para compensar o desbalanceamento. O algoritmo SMOTE [89] realiza essa abordagem de forma eficiente e os resultados são bastante satisfatórios, principalmente quando utilizado com um modelo de árvore de decisão.

A avaliação de algoritmos por testes estatísticos não paramétricos tem se difundido nas áreas de inteligência computacional e ciência de dados [195]. Entretanto, é importante observar que o desempenho de um algoritmo sobre um conjunto de testes *benchmark* vale apenas para aquele conjunto e não significa que o algoritmo terá um desempenho melhor em todos os problemas. Na prática, a melhor abordagem é sempre a busca do melhor desempenho para o problema em questão, evitando alguma preferência *ad hoc* sobre um tipo particular de modelo.