

6 ANÁLISE DE AGRUPAMENTOS

O objetivo da análise de agrupamentos é a divisão do conjunto de dados em subconjuntos chamados de grupos. A análise de agrupamentos é um problema de aprendizado não supervisionado e frequentemente é chamada de classificação não supervisionada, uma vez que não existe uma variável de saída (ou variável alvo) a ser predita como na regressão ou na classificação, que são problemas de aprendizado supervisionado. A falta de supervisão dificulta a definição de uma função de avaliação da qualidade do resultado. Dessa forma, a análise de agrupamentos é essencialmente uma atividade descritiva, em que o papel do analista é preponderante para a qualidade do resultado.

As aplicações da análise de agrupamentos são bastante variadas. Na área de negócios, a segmentação da base de clientes é muito comum em grandes corporações [530]. Há também aplicações em praticamente todas as áreas com uso intensivo de dados, como, por exemplo, bioinformática [290][357], processamento de imagens [528], recuperação da informação [319], entre outras [284].

A análise de agrupamentos tem sido estudada em diferentes comunidades científicas e a literatura sobre algoritmos de agrupamento é muito diversificada. Há obras clássicas na estatística [146][194][238][521], em inteligência computacional [572][573] e ciência de dados [232][516]. Neste capítulo, apresentamos os algoritmos clássicos, que podem ser encontrados na maioria dos *softwares* e abordagens mais recentes baseadas na teoria de grafos.

6.1 O Problema de Análise de Agrupamentos

Um grupo é um conjunto de objetos com alguma característica comum que os identifica como elementos do grupo. O objetivo da análise de agrupamentos é identificar padrões que permitam separar um conjunto de dados em grupos. Os algoritmos de agrupamento encontram grupos ou subconjuntos de dados da amostra com características similares. Frequentemente, o problema envolve a análise e interpretação dos grupos encontrados.

Matematicamente, um grupo é um conjunto definido por uma propriedade característica compartilhada pelos seus elementos. Assim, dado um universo $\mathcal{X}$, os elementos do conjunto $\mathcal{A} \subseteq \mathcal{X}$ são definidos pela propriedade $\chi_{\mathcal{A}}(x)$, que, para todo elemento do universo $x \in \mathcal{X}$:

$$\chi_{\mathcal{A}}(x) = \begin{cases} 1, & \text{se } x \in \mathcal{A} \\ 0, & \text{se } x \notin \mathcal{A} \end{cases} \quad (6.1)$$

A equação (6.1) é a base do chamado axioma da separação [77], que estabelece as duas leis (ou axiomas) fundamentais da teoria dos conjuntos:

- a) a lei do **terceiro excluído**: $\mathcal{A} \cup \bar{\mathcal{A}} = \mathcal{X}$;
- b) a lei da **não contradição**: $\mathcal{A} \cap \bar{\mathcal{A}} = \emptyset$.

A noção de conjunto é estendida ao conceito de **partição**, particularmente útil em ciência de dados, em que o universo é subdividido em K subconjuntos disjuntos.

Na análise de agrupamentos, a partição do conjunto de dados (de treinamento) $\mathcal{T}$ em K subconjuntos é definida como $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$, de tal forma que as seguintes condições sejam satisfeitas:

- i. A união de todos os subconjuntos é o universo: $\bigcup_{i=1}^K \mathcal{C}_i = \mathcal{T}$;
- ii. Os subconjuntos não têm elementos em comum: $\mathcal{C}_i \cap \mathcal{C}_j = \emptyset$, $i \neq j$.

A descoberta de uma partição num conjunto de dados é computacionalmente complexa; a partição de um conjunto de dados com N registros em apenas dois subconjuntos, com N_1 e N_2 registros respectivamente, implica a avaliação de $N!/(N_1! N_2!)$ partições distintas. Por exemplo, um conjunto de dados de $N = 100$ registros pode ser dividido em dois subconjuntos de $N_1 = N_2 = 50$ registros de 10^{29} formas diferentes! Além da complexidade inerente ao problema, a da qualidade do agrupamento não é bem definida e, em geral, utiliza-se índices de validação (cf. seção 6.5).

Na análise de agrupamentos, um grupo é definido como um conjunto de registros similares entre si e dissimilares dos registros alocados em outros grupos. A escolha do melhor agrupamento num conjunto de dados é uma tarefa analítica que depende muito da interpretação dos grupos no contexto da aplicação. O conjunto de dados da Figura 6.1a pode ser dividido em dois grupos, como mostrado na Figura 6.1b, mas também em quatro ou seis grupos, como nas Figura 6.1c e d [516]. A decisão sobre a melhor solução vai depender muito da aplicação.




Figura 6.1: Diferentes agrupamentos sobre o mesmo conjunto de dados: (a) conjunto de dados; (b) dois grupos; (c) quatro grupos; (d) seis grupos. Fonte: [516].

Observando a Figura 6.1, percebemos que os grupos da Figura 6.1d estão contidos na Figura 6.1c, que, por sua vez, estão contidos na partição da Figura 6.1b. Dessa forma, uma solução para a dificuldade de avaliação da qualidade do agrupamento é realizá-lo de forma hierárquica, como nos algoritmos apresentados na seção 6.3.

Outra característica importante da análise de agrupamentos é que os grupos encontrados podem não corresponder às classes de um problema supervisionado. Isso não significa que o algoritmo de agrupamento tenha falhado, apenas que os padrões encontrados não correspondem às classes. Isso acontece porque os algoritmos de agrupamento utilizam informações dos registros e a classificação é usualmente uma informação externa aos registros. Dessa forma, o entendimento da análise de agrupamentos como “classificação não supervisionada” deve ser utilizado com cautela.

A Figura 6.2a mostra um conjunto de dados contendo claramente quatro grupos, embora esse mesmo conjunto tenha sido apresentado como um problema de duas classes no exemplo da Figura 5.6.




Figura 6.2: Exemplo de agrupamento: (a) conjunto de dados; (b) dados classificados.

Os algoritmos apresentados neste capítulo utilizam métricas de distância, como as definidas na seção 2.2.3, para variáveis numéricas. Há diversas outras, além de métricas para variáveis binárias e categóricas [194]. A escolha das métricas de distância ou similaridade pode tornar o problema ainda mais complexo, pois não há um critério universal para guiar tal escolha [232]. A abordagem mais simples para o tratamento de variáveis nominais é a sua transformação em variáveis indicadoras (cf. equação (5.14)) e a utilização de métricas definidas para as variáveis numéricas.

O algoritmo clássico em análise de agrupamentos é o algoritmo k-médias, em que os grupos são definidos a partir da distância de cada elemento ao centro do grupo. O k-médias é um algoritmo dos métodos de partição. Neste tipo de método, a métrica de distância determina o formato do grupo. A Figura 6.3 mostra um conjunto de pontos e regiões métricas de distância em relação ao centro, onde as regiões escuras representam valores menores. A distância euclidiana (norma L^2), mostrada na Figura 6.3b, gera grupos de forma esférica; a distância de Mahalanobis induz grupos elipsoides (Figura 6.3c); as distâncias de Manhattan (norma L^1) e de norma infinita (L^∞) geram hipercubos (Figura 6.3a e d). Dessa forma, a escolha da função de distância ou similaridade influencia o resultado do algoritmo de agrupamento.




Figura 6.3: Métricas de distância: (a) distância de Manhattan (L^1); (b) distância euclidiana (L^2); (c) distância de Mahalanobis; (d) norma infinita (L^∞).

A interseção entre dois grupos calculados na análise de agrupamentos também forma uma superfície de decisão, como no problema de classificação. Um conjunto de dados pode conter grupos que formam superfícies de decisão convexas ou não convexas, como ilustrado na Figura 6.4. Em grupos convexas, como o da Figura 6.4a, as superfícies de decisão podem ser aproximadas por funções lineares. Em agrupamentos não convexas, como na Figura 6.4b, a superfície de decisão é uma função não linear.

Algoritmos mais simples, como os métodos de partição apresentados na seção 6.2, geram agrupamentos convexas. Algoritmos capazes de gerar agrupamentos não convexas podem representar melhor as características do conjunto de dados. Os métodos hierárquicos, apresentados na seção 6.3, e os métodos baseados em grafos, descritos na seção 6.4, encontram grupos não convexas.




Figura 6.4: Forma de grupos: (a) convexa; (b) não convexa.

6.2 Métodos de Partição

Os métodos de partição buscam diretamente uma partição do conjunto de dados através da minimização de um critério de avaliação. O método de partição (e de agrupamento) mais amplamente utilizado é o algoritmo k-médias, em que o critério de custo é calculado em função do quadrado da distância entre os registros e as coordenadas dos centros, conforme descrito a seguir.

6.2.1 Algoritmo k-médias

O algoritmo k-médias é um algoritmo simples e eficiente que geralmente converge num número reduzido de iterações na maioria dos problemas. O algoritmo original foi proposto há mais de 50 anos* [285], mas continua sendo utilizado em diversas áreas e pode ser encontrado nos principais *softwares* e bibliotecas.

O objetivo do algoritmo k-médias é encontrar uma partição no conjunto de dados em K grupos $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$ através da minimização da seguinte função de avaliação:

$$J(\mathbf{\Omega}) = \sum_{t=1}^N \sum_{i=1}^K u_i(\mathbf{x}(t)) \|\mathbf{x}(t) - \mathbf{\omega}_i\|^2 \quad (6.2)$$

* O algoritmo é atribuído ao trabalho proposto por Lloyd em 1957 para representação digital de sinais analógicos, que só foi publicado em 1982 [353]. Entretanto, é muito difícil reconhecê-lo nesse artigo. O algoritmo na sua forma atual foi proposto por MacQueen em 1967 [359].

onde $\boldsymbol{\omega}_i = \frac{1}{\hat{N}_i} \sum_{\mathbf{x}(t) \in \mathcal{C}_i} \mathbf{x}(t)$ é o vetor com as coordenadas do centro do grupo $\mathcal{C}_i$ e a matriz $\boldsymbol{\Omega} = [\boldsymbol{\omega}_1^T, \dots, \boldsymbol{\omega}_K^T]$ representa os centros de todos os grupos.

A função $u_i(\mathbf{x}(t))$ na equação (6.2) define a pertinência de um registro $\mathbf{x}(t)$ ao grupo $\mathcal{C}_i$ (cf. equação (6.1)) como:

$$u_i(\mathbf{x}(t)) = \begin{cases} 1, & \text{se } \mathbf{x}(t) \in \mathcal{C}_i \\ 0, & \text{se } \mathbf{x}(t) \notin \mathcal{C}_i \end{cases} \quad (6.3)$$

A cardinalidade do grupo $\mathcal{C}_i$ é o número de registros do grupo, isto é, $|\mathcal{C}_i| = \hat{N}_i$, pode ser calculada pela soma dos valores de pertinência ao grupo como $\hat{N}_i = \sum_{t=1}^N u_i(\mathbf{x}(t))$.

A função de avaliação (6.2) pode ser interpretada pela decomposição da variância total dos dados como $\boldsymbol{\Sigma}_T = \boldsymbol{\Sigma}_W + \boldsymbol{\Sigma}_B$ [146][573], apresentada na seção 2.4.3.

A matriz de variância total $\boldsymbol{\Sigma}_T = (N - 1)\hat{\boldsymbol{\Sigma}}$, onde $\hat{\boldsymbol{\Sigma}}$ é a matriz de covariâncias estimada (cf. equação (2.5)), é calculada como:

$$\boldsymbol{\Sigma}_T = \sum_{t=1}^N (\mathbf{x}(t) - \bar{\mathbf{x}})^T (\mathbf{x}(t) - \bar{\mathbf{x}}) \quad (6.4)$$

onde $\bar{\mathbf{x}} = \frac{1}{N} \sum_{t=1}^N \mathbf{x}(t)$ é a média dos registros do conjunto de treinamento, que também pode ser calculada pela média ponderada dos centros de grupos como $\bar{\mathbf{x}} = \frac{1}{N} \sum_{i=1}^K \hat{N}_i \boldsymbol{\omega}_i$.

A matriz de variâncias intragrupos $\boldsymbol{\Sigma}_W$ e a matriz de variância entre grupos $\boldsymbol{\Sigma}_B$ são calculadas como (cf. seção 2.4.3):

$$\boldsymbol{\Sigma}_B = \sum_{i=1}^K N_i (\boldsymbol{\omega}_i - \bar{\mathbf{x}})^T (\boldsymbol{\omega}_i - \bar{\mathbf{x}}) \quad (6.5)$$

$$\boldsymbol{\Sigma}_W = \sum_{t=1}^N \sum_{i=1}^K u_i(\mathbf{x}(t)) (\mathbf{x}(t) - \boldsymbol{\omega}_i)^T (\mathbf{x}(t) - \boldsymbol{\omega}_i) \quad (6.6)$$

A função de avaliação (6.2) é soma dos elementos da diagonal principal (traço) da matriz de variância intragrupos $\boldsymbol{\Sigma}_W$, cuja minimização resulta na minimização da variância intragrupos $\boldsymbol{\Sigma}_W$ e, portanto, em grupos mais compactos. A variância total $\boldsymbol{\Sigma}_T$ não é função do agrupamento e se mantém constante, de forma que a minimização da variância intragrupos implica a maximização da variância entre grupos $\boldsymbol{\Sigma}_B$, ou seja, em grupos mais separados.

A minimização da função (6.2) é um problema NP-difícil [12][360]. O algoritmo k-médias aplica uma heurística gulosa para a solução eficiente do problema. Entretanto, o resultado depende muito da estrutura dos dados e uma solução de ótimo local pode ser encontrada, o que torna o resultado dependente da inicialização.

O algoritmo k-médias é descrito no Algoritmo 6.1. Sua execução é feita a partir de uma matriz de centros fornecida na inicialização que, em geral, é aleatória. A cada iteração, cada registro do conjunto de dados é alocado ao grupo mais próximo. Embora outras métricas de distância possam ser utilizadas dependendo da implementação, o algoritmo k-médias clássico utiliza a distância euclidiana. Após uma passagem por todo o conjunto de dados, o centro de cada grupo é atualizado como a média das coordenadas dos registros alocados ao grupo.

Algoritmo 6.1: Algoritmo k-médias

Entrada:	Conjunto de treinamento $\mathcal{T} = \{\mathbf{x}(t), t = 1 \dots N\}$, estimativa inicial de centros $\mathbf{\Omega} = [\omega_1^T, \dots, \omega_K^T]$
Saída:	Matriz de centros $\mathbf{\Omega} = [\omega_1^T, \dots, \omega_K^T]$
01	Início
02	$\varepsilon \leftarrow \infty$
03	Enquanto $\varepsilon > tol$
04	Para $t = 1, \dots, N$
05	$\mathbf{x}(t) \in \mathcal{C}_i \Leftrightarrow \omega_i = \operatorname{argmin}_j (\ \mathbf{x}(t) - \omega_j\ ^2)$
06	Fim Para
07	$\mathbf{\Omega}_0 \leftarrow \mathbf{\Omega}$
08	Atualizar $\mathbf{\Omega}$ com $\omega_i = \frac{\sum_{t=1}^N u_i(\mathbf{x}(t))\mathbf{x}(t)}{\sum_{t=1}^N u_i(\mathbf{x}(t))}, i = 1, \dots, K$
09	Calcular critério de parada $\varepsilon = \ \mathbf{\Omega}_0 - \mathbf{\Omega}\ $
10	Fim Enquanto
11	Retorna $\mathbf{\Omega} = [\omega_1^T, \dots, \omega_K^T]$
12	Fim

O critério de parada do algoritmo, calculado no passo 09, é a norma L^2 da diferença entre as matrizes dos centros calculados em duas iterações sucessivas. O algoritmo é

interrompido se não há mudanças significativas dos centros. O número máximo de iterações também pode ser utilizado como critério de parada.

A cada iteração, uma partição do conjunto de dados deve ser encontrada, de forma que, se algum grupo não tiver nenhum registro alocado no passo 05, uma ação precisa ser realizada para evitar erro de divisão por zero no passo 08. Dependendo do *software*, diferentes ações podem ser realizadas. No Matlab,¹³⁶ por exemplo, o usuário pode escolher entre uma mensagem de erro (*default*), a eliminação do grupo ou a geração de novas coordenadas aleatoriamente. A possibilidade de redefinição de centros aleatoriamente causa instabilidades ao algoritmo.

Em geral, o algoritmo k-médias converge rapidamente e a complexidade de cada iteração do algoritmo é estimada em $O(NKp)$, onde p é o número de variáveis, K o número de grupos e N o número de registros. Em problemas em que $Kp \ll N$, a complexidade do algoritmo é dominada por $O(N)$. Em problemas de grandes dimensões, a busca por um agrupamento com muitos grupos resulta em $Kp \approx N$ e a complexidade do algoritmo é $O(N^2)$. Em alocação de memória, a complexidade do algoritmo é definida pelo armazenamento do conjunto de dados como $O(Np) \approx O(N)$.

Há diversas variantes do algoritmo k-médias [194][229][285][573]. O algoritmo ISO-DATA,* proposto em 1967 [27], é uma variante do k-médias que, muitas vezes, é confundido com o próprio. O algoritmo ISODATA ajusta automaticamente o número de grupos, agrupando-os e subdividindo-os de acordo com limites especificados, e elimina aqueles com poucos registros. No algoritmo ISODATA, a escolha do número de grupos é substituída pela escolha dos parâmetros do algoritmo.

O resultado do algoritmo k-médias é muito sensível à presença de *outliers* e ruído no conjunto de dados. Um *outlier* será associado a algum grupo e contabilizado no cálculo da média, o que pode afastar os centros calculados dos centros do conjunto mais denso de registros. Algumas variantes do k-médias visam maior robustez a *outliers*, como os algoritmos k-medoids [300], PAM† e CLARA.‡ Nesse tipo de algoritmo, o centro do grupo é um registro do conjunto de treinamento, chamado *medoid*, que tem a menor distância média para todos os registros do grupo. Os algoritmos PAM e CLARA aplicam a mesma ideia de k-medoids, mas o segundo utiliza apenas uma amostra do conjunto de dados

* *Iterative Self-Organizing Data Analysis Technique*

† *Partition Around Medoids*

‡ *Clustering LARge Applications*

para reduzir a complexidade computacional [521]. O algoritmo CLARANS* [416] é uma variante dos *k-medoids* mais complexa que o CLARA que obtém melhores resultados [521]. Outra abordagem para a solução do problema de *outliers* é obtida pelos algoritmos chamados *k-medianas* [83][378], cujos centros de grupos também são registros do conjunto de treinamento.

Há trabalhos mais recentes com outras variantes do *k-médias*. No algoritmo *x-médias* [434], o número de grupos é otimizado a partir dos critérios AIC e BIC, utilizados para seleção de estrutura de modelos de regressão [238]. O algoritmo *k-médias esférico*¹³⁷ [126][602] utiliza a similaridade do cosseno como métrica, sendo indicado para problemas de alta dimensionalidade. Zhao e Karypis [600] discutem algumas alternativas à função de avaliação quadrática para o agrupamento de documentos. Algumas abordagens têm sido propostas para a inicialização do *k-médias*, como PCA-Part [508], CCIA [302] e o algoritmo *k-médias++* [21][421].

O algoritmo *fuzzy c-médias* é uma variante importante do *k-médias*, em que o conceito pertinência ao grupo é estendido por funções de pertinência *fuzzy*. O algoritmo *fuzzy c-médias* será apresentado no Capítulo 8.

O *k-médias* é um algoritmo simples e eficiente, mas apresenta algumas características e limitações, discutidas nos exemplos a seguir.

6.2.2 Exemplos

A forma dos grupos encontrados pelo algoritmo *k-médias* depende da métrica de distância utilizada (cf. Figura 6.3). Com a distância euclidiana, os grupos encontrados pelo *k-médias* têm formato hiper esférico, de modo que a superfície de decisão entre grupos é aproximada por uma função linear. Dessa forma, as regiões associadas aos grupos formam um diagrama de Voronoi¹³⁸ no espaço de variáveis de entrada. A Figura 6.5 apresenta os resultados do algoritmo *k-médias* sobre os dados de Diabetes das índias Pima, projetado no plano definido pela ACP. Podemos observar claramente as superfícies de decisão lineares entre os grupos.

* *Clustering LARge Applications based on RANdomized Search*

O algoritmo k-médias tem algumas limitações, tais como encontrar grupos de tamanhos muito diferentes [516] e grupos de forma não convexa. Entretanto, é possível utilizar o algoritmo para encontrar um número maior de grupos e, posteriormente, agregar grupos para obter formas não convexas.




Figura 6.5: Resultados no conjunto de dados Diabetes projetados em 2D pela ACP:

(a) $K = 3$ grupos; (b) $K = 7$ grupos.

A Figura 6.6 mostra os resultados do k-médias no conjunto de dados das duas luas. Na Figura 6.6a, o resultado do algoritmo com $K = 2$ mostra que não foi possível identificar os dois grupos. O resultado com $K = 6$ grupos é mostrado na Figura 6.6b permite verificar que é possível encontrar os grupos pela agregação de subgrupos. Essa solução é aplicada no desenvolvimento de modelos de base radial, apresentados no Capítulo 7.




Figura 6.6: Resultados no conjunto de dados duas luas: (a) $K = 2$ grupos; (b) $K = 6$ grupos.

A principal limitação do algoritmo k-médias é a dependência da estimativa inicial dos centros de grupos, que ocorre principalmente em problemas em que o número de grupos não corresponde à estrutura dos dados. A Figura 6.7 mostra os resultados sobrepostos dos centros de grupos calculados em 100 execuções do algoritmo k-médias sobre os dados do problema de quatro grupos. Com $K = 2$ grupos, a Figura 6.7a mostra que o algoritmo particiona os dados horizontalmente ou verticalmente. Com $K = 3$ ou $K = 5$ (Figuras 6.7b e d), soluções diferentes são encontradas em cada execução. No caso de $K = 4$ grupos (Figura 6.7c), todas as execuções convergem para a mesma solução, que corresponde aos centros dos grupos.




Figura 6.7: Resultados de centros encontrados pelo k-médias no conjunto de dados de quatro grupos: (a) $K = 2$ grupos; (b) $K = 3$ grupos; (c) $K = 4$ grupos; (d) $K = 5$ grupos.

A variação dos resultados do k-médias em execuções diferentes do algoritmo pode ser utilizada como um indicativo da qualidade do agrupamento. No exemplo da Figura 6.7, os dados têm quatro grupos muito bem definidos, de forma que o algoritmo k-médias

encontra sempre o mínimo global, independentemente da inicialização. Quando o número de grupos não corresponde às características do conjunto de dados, o algoritmo encontra um mínimo local e o resultado depende da inicialização. Celebi e colaboradores [80] apresentam um estudo sobre os principais métodos de inicialização do k-médias, mas não discutem a influência da escolha do número de grupos. Algumas medidas de validação para escolha do melhor agrupamento são apresentadas na seção 6.5.

6.3 Métodos Hierárquicos

Os algoritmos de agrupamento hierárquicos geram uma estrutura hierárquica de agrupamentos em que cada nível representa uma partição do conjunto de dados definida na seção 6.1. A estrutura de agrupamentos hierárquicos em diferentes níveis é representada como uma árvore binária, chamada **dendrograma***.

Os métodos hierárquicos podem ser classificados em aglomerativos ou divisivos. Nos algoritmos aglomerativos, a estrutura hierárquica é construída a partir dos registros, sendo cada registro definido como um grupo *singleton*. Dessa forma, a partição do nível mais baixo da hierarquia é definida como $\mathbb{C}_0 = \mathcal{T}$, com $K = N$ grupos. A partir dos grupos *singletons*, o algoritmo constrói a estrutura hierárquica $\mathbb{C}_0 \subseteq \mathbb{C}_1 \subseteq \dots \subseteq \mathbb{C}_{N-1}$, iterativamente, fundindo grupos das partições dos níveis anteriores até formar a partição $\mathbb{C}_{N-1}$, que corresponde a um único grupo contendo todo o conjunto de dados. Nos algoritmos divisivos, a estratégia é de cima para baixo; a partição inicial $\mathbb{C}_0$ corresponde a um único grupo e a estrutura hierárquica $\mathbb{C}_{N-1} \subseteq \mathbb{C}_{N-2} \subseteq \dots \subseteq \mathbb{C}_0$ [522].

Nesta seção, são apresentados os algoritmos hierárquicos aglomerativos, que são mais comuns e podem ser encontrados na maioria dos *softwares*. Algoritmos divisivos são obtidos aplicando-se recursivamente em cada grupo e diferentes abordagens são encontradas na literatura [194][573].

* A palavra dendrograma é de origem grega, pela composição de *dendron*, que significa árvore, e *gramma*, desenho ou escrita.

6.3.1 Algoritmos aglomerativos

Os algoritmos hierárquicos aglomerativos seguem o procedimento geral descrito pelo Algoritmo 6.2, cujo resultado é uma estrutura hierárquica, utilizada para gerar o dendrograma que representa os agrupamentos formados em cada nível.

Algoritmo 6.2: Algoritmo hierárquico (adaptado de [522])

Entrada:	Conjunto de treinamento $\mathcal{T} = \{\mathbf{x}(t), t = 1 \dots N\}$
Saída:	Partições hierárquicas $\mathbb{C}_0 \subseteq \mathbb{C}_1 \subseteq \dots \subseteq \mathbb{C}_{N-1}$
01	Início
02	Calcular a matriz de distâncias $\mathbf{D}$
03	Definir $\mathbb{C}_0 = \{\mathcal{C}_i = \mathbf{x}(i), i = 1, \dots, N\}$
04	$k = 1$
05	Enquanto $k < N - 1$
06	Selecionar $\{\mathcal{C}_i, \mathcal{C}_j\} \in \mathbb{C}_{k-1}$ como $\operatorname{argmin}(L(\mathcal{C}_i, \mathcal{C}_j))$
07	Gerar a nova partição $\mathbb{C}_k = \{\mathbb{C}_{k-1} - \{\mathcal{C}_i, \mathcal{C}_j\}\} \cup \{\mathcal{C}_i \cup \mathcal{C}_j\}$
08	$k \leftarrow k + 1$
09	Fim Enquanto
10	Retorna $\{\mathbb{C}_0, \mathbb{C}_1, \dots, \mathbb{C}_{N-1}\}$
11	Fim

Em cada iteração k do Algoritmo 6.2, no passo 07, um par de grupos $\{\mathcal{C}_i, \mathcal{C}_j\}$ é retirado da partição $\mathbb{C}_{k-1}$ e a união $\{\mathcal{C}_i \cup \mathcal{C}_j\}$ é incluída na partição $\mathbb{C}_k$. A função de ligação $L(\mathcal{C}_i, \mathcal{C}_j)$ no passo 06 é utilizada para selecionar os grupos a serem unidos. Diferentes funções de ligação resultam em diferentes agrupamentos. Na literatura, as principais estratégias para função de ligação são:

- Vizinho mais próximo (**single-link**): a distância entre os grupos é calculada pelos elementos mais próximos [495]:

$$L_{\min}(\mathcal{C}_i, \mathcal{C}_j) = \min_{\substack{\mathbf{v} \in \mathcal{C}_i \\ \mathbf{v} \in \mathcal{C}_j}} \operatorname{dist}(\mathbf{v}, \mathbf{v}) \quad (6.7)$$

- Vizinho mais distante (**complete-link**): a distância entre os grupos é calculada pela distância máxima entre seus elementos:

$$L_{max}(\mathcal{C}_i, \mathcal{C}_j) = \max_{\substack{\mathbf{v} \in \mathcal{C}_i \\ \mathbf{u} \in \mathcal{C}_j}} dist(\mathbf{v}, \mathbf{u}) \quad (6.8)$$

- Distâncias médias (**UPGMA**):* a distância entre os grupos é calculada pela distância média entre os elementos [499]:

$$L_{med}(\mathcal{C}_i, \mathcal{C}_j) = \frac{1}{|\mathcal{C}_i||\mathcal{C}_j|} \sum_{\mathbf{v} \in \mathcal{C}_i} \sum_{\mathbf{u} \in \mathcal{C}_j} dist(\mathbf{v}, \mathbf{u}) \quad (6.9)$$

onde $|\mathcal{C}_i|$ representa a cardinalidade, isto é, o número de elementos do grupo $\mathcal{C}_i$;

- Centroides (**UPGMC**):† a distância entre os grupos é calculada pela distância entre os centroides [499]:

$$L_{cen}(\mathcal{C}_i, \mathcal{C}_j) = dist(\bar{\mathbf{v}}, \bar{\mathbf{u}}) \quad (6.10)$$

onde $\bar{\mathbf{v}} = \frac{1}{|\mathcal{C}_i|} \sum_{\mathbf{v} \in \mathcal{C}_i} \mathbf{v}$ e $\bar{\mathbf{u}} = \frac{1}{|\mathcal{C}_j|} \sum_{\mathbf{u} \in \mathcal{C}_j} \mathbf{u}$.

Há também as variantes WPGMA e WPGMC, que são semelhantes, respectivamente, aos critérios de distância média (UPGMA) e de centroide (UPGMC), em que as distâncias são ponderadas pelo número de elementos em cada grupo [194]. Finalmente, o critério de Ward minimiza a variância dos grupos [551].

Os algoritmos hierárquicos aglomerativos, em geral, trabalham com a matriz de distâncias na memória, o que significa armazenar, pelo menos, $N(N - 1)/2$ valores.‡ A aplicação desse tipo de algoritmo em conjuntos de dados com número muito grande de registros pode causar problemas de memória.

6.3.2 Exemplos

Nesta seção, os algoritmos anteriores são avaliados em conjuntos de dados sintéticos e *benchmark*. Todos os exemplos foram executados utilizando a distância euclidiana, variando apenas a função de ligação.

A Figura 6.8 mostra os dendrogramas e as partições resultantes dos quatro algoritmos hierárquicos discutidos previamente no conjunto de dados sintético de quatro grupos (cf. Figura 6.2a). O nível inferior foi limitado a 25 grupos para facilitar a visualização.

* *Unweighted Pair Group Method with Average linkage*

† *Unweighted Pair Group Method with Centroid linkage*.

‡ Considerando que a matriz de distâncias é simétrica e armazenando apenas a matriz triangular.

Observe que, mesmo num exemplo simples como este, os resultados são ligeiramente diferentes, tanto em termos do dendrograma quanto da partição encontrada.

A Figura 6.9 apresenta os resultados dos algoritmos no conjunto de dados de duas luas apresentado (cf. Figura 6.4b). Este exemplo mostra a capacidade do algoritmo do vizinho mais próximo (*single-link*) de encontrar partições não convexas, o que não acontece no caso das demais funções de ligação.

A observação dos resultados na Figura 6.8 e na Figura 6.9 mostra que o dendrograma pode indicar o número de grupos presentes num conjunto de dados pelo número de ramos (traços verticais) entre os dois patamares (traços horizontais) mais distantes. O resultado dessa análise qualitativa é bem visível na Figura 6.8, indicando a presença de quatro grupos (exceto para o algoritmo *single-link*), e na Figura 6.9, indicando a presença de dois grupos.

6.4 Particionamento de grafos

A teoria dos grafos [55][129] é o ramo da matemática que estuda problemas que podem ser representados na forma de um **grafo**, isto é, um conjunto de vértices conectados por um conjunto de arestas. A teoria dos grafos é a base matemática para uma série de disciplinas na ciência da computação e a análise de rede complexas [414].


Um conjunto de dados pode ser representado como um grafo $G(\mathcal{V}, \mathcal{E})$, no qual o conjunto de vértices $\mathcal{V}$ representa os registros, isto é, $\mathcal{V} \equiv \mathcal{T} = \{\mathbf{x}(t), t = 1 \dots N\}$, e o conjunto de arestas é definido pela matriz de adjacências* $\mathbf{A} \in \mathcal{R}^{N \times N}$, em que cada elemento representa a similaridade entre um par de registros como:

$$a_{ij} = \begin{cases} \text{sim}(\mathbf{x}(i), \mathbf{x}(j)), & \text{se } i \neq j \\ 0, & \text{se } i = j \end{cases} \quad (6.11)$$


A matriz de similaridades é simétrica e, portanto, as arestas do grafo correspondente a um conjunto de dados são ponderadas e não direcionadas.

O grau de um vértice é o número de vizinhos do vértice. Em grafos ponderados, o grau é a soma do peso das arestas conectadas ao vértice.


* Aqui, seguimos a notação proposta por Newman [414], em que a matriz de adjacências binária é um caso particular da matriz de adjacências ponderada.




(a)




(b)




(c)




(d)




(e)



(f)




(g)




(h)


Figura 6.8: Resultados do agrupamento hierárquico nos dados de quatro grupos: (a) e (b) *single-link*; (c) e (d) *complete-link*; (e) e (f) distância média; (g) e (h) centroide.




(a)




(b)




(c)




(d)




(e)



(f)



(g)



(h)

Figura 6.9: Resultados do agrupamento hierárquico nos dados duas luas: (a) e (b) *single-link*; (c) e (d) *complete-link*; (e) e (f) distância média; (g) e (h) centroide.

A função de similaridade gaussiana é muito utilizada para representação de um conjunto de dados como um grafo e é definida como (cf. equação (2.14)):

$$sim_G(\mathbf{x}(i), \mathbf{x}(j)) = \exp\left(-\frac{\|\mathbf{x}(i) - \mathbf{x}(j)\|^2}{2\sigma^2}\right) \quad (6.12)$$

A Figura 6.10 mostra o exemplo de um grafo gerado a partir de um conjunto de dados de quatro grupos pela função de similaridade gaussiana (6.12) com $\sigma = 1/3$. Na Figura 6.10a, o grafo formado pela conexão dos registros em que os tons de cinza representam os valores das arestas; na Figura 6.10b, a matriz de adjacências.




Figura 6.10: Conjuntos de dados quatro grupos: (a) Grafo; (b) matriz de adjacências.

A função de similaridade do cosseno (cf. equação (2.13)) também é frequentemente utilizada, principalmente em aplicações de mineração de textos [468]. Há outras formas de representar um conjunto de dados como um grafo [356][473]. A função de similaridade gaussiana relaciona o particionamento em grafos com métodos baseados em funções de núcleo [182], discutidos no Capítulo 7.

Um corte num grafo conexo é um conjunto de arestas (ou vértices) cuja remoção desconecta um determinado par de vértices [414]. O corte em grafos é estudado principalmente em problemas em que o grafo representa um sistema onde há algum fluxo (de matéria, informação etc.) ao longo das arestas e a capacidade de fluxo é representada pelo valor (ou peso) da aresta. O corte mínimo é o conjunto de arestas que, se retiradas, desconecta um par de vértices e cuja soma dos pesos das arestas retiradas é mínima. O corte mínimo corresponde ao fluxo máximo entre o par de vértices [6].

O problema do corte mínimo num grafo pode ser associado ao problema de agrupamento para encontrar uma partição $\mathbb{C} = \{\mathcal{C}_1, \mathcal{C}_2\}$, tal que $\mathcal{C}_1 \cap \mathcal{C}_2 = \emptyset$ e $\mathcal{C}_1 \cup \mathcal{C}_2 = \mathcal{V}$, através da minimização da soma dos pesos das arestas entre os dois grupos calculada pela função de corte:

$$cut(\mathcal{C}_1, \mathcal{C}_2) = \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N a_{ij} u_1(\mathbf{x}(i)) u_2(\mathbf{x}(j)) \quad (6.13)$$

onde $a_{ij} \in \mathbf{A}$ são os elementos da matriz de adjacências, $u_i(\mathbf{x}(t))$ é a pertinência de um registro $\mathbf{x}(t)$ ao grupo $\mathcal{C}_i$ (cf. equação (6.3)) e o fator $\frac{1}{2}$ é incluído para evitar a contagem dupla da mesma aresta, uma vez que a matriz de adjacências $\mathbf{A}$ é simétrica.

Em grafos não direcionados, o critério de corte definido pela equação (6.13) admite uma solução trivial que corresponde a separar apenas um vértice cuja soma das suas arestas é mínima, isto é, o vértice de menor grau. Num grafo correspondente a um conjunto de dados, essa solução trivial significa separar um *outlier*. Para evitar esse problema, Shi e Malik [489] propõem minimizar a função de corte normalizado:

$$Ncut(\mathcal{C}_1, \mathcal{C}_2) = \frac{cut(\mathcal{C}_1, \mathcal{C}_2)}{cut(\mathcal{C}_1, \mathcal{V})} + \frac{cut(\mathcal{C}_2, \mathcal{C}_2)}{cut(\mathcal{C}_2, \mathcal{V})} \quad (6.14)$$

onde $cut(\mathcal{C}_k, \mathcal{V}) = \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N a_{ij} u_k(\mathbf{x}(i))$ e $\mathcal{V}$ é o conjunto de vértices do grafo.

A função de avaliação definida pela equação (6.14) evita a obtenção de um grupo em que as arestas do corte representam uma parcela importante da sua conectividade.

O corte mínimo pode ser ilustrado na Figura 6.10a, em que o agrupamento é definido pelo corte das arestas mais claras. Nesse caso, a medida de corte da equação (6.13) é generalizada para o caso de uma partição genérica $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$ como [468]:

$$cut(\mathcal{C}_1, \dots, \mathcal{C}_K) = \sum_{i=1}^K cut(\mathcal{C}_i, \bar{\mathcal{C}}_i) \quad (6.15)$$

onde $\bar{\mathcal{C}}_i = \mathcal{V} - \mathcal{C}_i$ é o complemento de $\mathcal{C}_i$, i.e. $\bar{\mathcal{C}}_i = \bigcup_{j \neq i}^K \mathcal{C}_j$.

Na literatura encontram-se outras variantes da medida de corte em grafos com características ligeiramente diferentes [130][468].

A teoria dos grafos tem sido explorada para o estudo de redes complexas [414]. O problema de particionamento de grafos na área de redes complexas é chamado de **detecção de comunidades** [412][414][468]. Numa rede social, por exemplo, os indivíduos representam os vértices do grafo e as arestas, as relações entre eles. As comunidades são formadas por grupos de indivíduos que compartilham características em comum e, por isso, têm mais relações entre si do que com indivíduos de outros grupos. Essa tendência é chamada de homofilia.

Newman apresenta uma medida para aferir o grau de homofilia de uma rede, chamada modularidade [411]-[413]. A medida de modularidade segue um raciocínio bem diferente da medida de corte em grafos (6.13). Em vez de avaliar o peso das arestas em grupos diferentes, a ideia é avaliar o peso das arestas no mesmo grupo e a medida reflete a fração de arestas que ligam vértices desse grupo. Entretanto, para evitar a solução trivial de considerar toda a rede como um só grupo, a medida de modularidade subtrai a fração de arestas esperada de uma rede cujas ligações ocorrem de forma aleatória. Em outras palavras, a modularidade mede o quanto a estrutura de comunidades encontrada na rede é diferente de um arranjo aleatório.

Matematicamente, a modularidade de uma partição $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$ é definida como:

$$Q(\mathcal{C}_1, \dots, \mathcal{C}_K) = \frac{1}{2E} \sum_{i=1}^N \sum_{j=1}^N \left(a_{ij} - \frac{d_i d_j}{2E} \right) \mathbf{u}_i \mathbf{u}_j^T \quad (6.16)$$

onde $d_i = \sum_j a_{ij}$ é o grau do vértice associado ao registro $\mathbf{x}(i)$ e $E = \sum_i d_i$ é o número total de arestas. O vetor $\mathbf{u}_i = (u_1(\mathbf{x}(i)), \dots, u_K(\mathbf{x}(i)))$ é aquele em que cada elemento é a pertinência do registro $\mathbf{x}(i)$ a cada um dos grupos (cf. equação (6.3)). O produto $\mathbf{u}_i \mathbf{u}_j^T = 1$ se os registros $\mathbf{x}(i)$ e $\mathbf{x}(j)$ estão no mesmo grupo; caso contrário, $\mathbf{u}_i \mathbf{u}_j^T = 0$.

Se os registros $\mathbf{x}(i)$ e $\mathbf{x}(j)$ estão no mesmo grupo, a modularidade da partição calculada pela equação (6.16) é a diferença entre o número total de arestas $\sum_{ij} a_{ij}$ e o número esperado de arestas numa rede aleatória $\sum_{ij} d_i d_j / 2E$ [413].

A modularidade pode ser escrita diretamente a partir da definição da matriz de modularidade $\mathbf{B}$, calculada como:

$$\mathbf{B} = \mathbf{A} - \frac{\mathbf{d}^T \mathbf{d}}{2E} \quad (6.17)$$

onde $\mathbf{d} = (d_1, \dots, d_N)$ é o vetor dos graus dos vértices (registros) correspondentes, em que cada elemento é calculado como $d_i = \sum_j a_{ij}$. Observe que, em geral, a matriz $\mathbf{A}$ é esparsa, mas $\mathbf{B}$ é uma matriz densa.

De uma forma geral, o problema de particionamento em grafos é um problema NP-difícil por razões análogas à complexidade do problema de particionamento de um conjunto de dados. Dessa forma, uma solução computacionalmente tratável para o problema é obtida por uma formulação aproximada, baseada na decomposição espectral de uma matriz derivada da matriz de adjacências do grafo $\mathbf{A}$, chamada de laplaciano [356][408]. Essa abordagem dá origem a diferentes algoritmos, apresentados a seguir.

6.4.1 Algoritmos de agrupamento espectral

Uma partição $\mathbb{C} = \{\mathcal{C}_1, \mathcal{C}_2\}$ num grafo pode ser representada por um vetor $\mathbf{v} \in \mathcal{R}^N$, que representa a partição através da variável indicadora:

$$v_i = \begin{cases} +1, & \text{se } \mathbf{x}(i) \in \mathcal{C}_1 \\ -1, & \text{se } \mathbf{x}(i) \in \mathcal{C}_2 \end{cases} \quad (6.18)$$

onde $\mathcal{C}_1 \cap \mathcal{C}_2 = \emptyset$ e $\mathcal{C}_1 \cup \mathcal{C}_2 =$.

A variável indicadora permite identificar se dois registros $\mathbf{x}(i)$ e $\mathbf{x}(j)$ estão no mesmo grupo como $u_1(\mathbf{x}(i))u_2(\mathbf{x}(j)) = \frac{1}{2}(1 - v_i v_j)$. Se os registros estão no mesmo grupo, $\frac{1}{2}(1 - v_i v_j) = 0$; caso contrário, $\frac{1}{2}(1 - v_i v_j) = 1$. Dessa forma, a medida de corte (6.13) pode ser escrita como:

$$cut(\mathcal{C}_1, \mathcal{C}_2) = \frac{1}{4} \sum_{i=1}^N \sum_{j=1}^N a_{ij} (1 - v_i v_j) \quad (6.19)$$

Considerando $\sum_{i=1}^N \sum_{j=1}^N a_{ij} = \sum_{i=1}^N d_i = \sum_{i=1}^N \sum_{j=1}^N d_i \delta_{ij}$ [414], onde $d_i = \sum_j a_{ij}$ é o grau do vértice e δ_{ij} , a função δ de Kronecker,* a equação (6.19) é reescrita como:

$$cut(\mathcal{C}_1, \mathcal{C}_2) = \frac{1}{4} \sum_{i=1}^N \sum_{j=1}^N (d_i \delta_{ij} - a_{ij}) v_i v_j \quad (6.20)$$

* A função δ de Kronecker é definida como: $\delta_{ij} = \begin{cases} 1, & \text{se } i = j \\ 0, & \text{se } i \neq j \end{cases}$.

A medida de corte escrita na forma (6.20) evidencia os valores $l_{ij} = (d_i \delta_{ij} - a_{ij})$, que são os elementos do **laplaciano** do grafo, definido como:

$$\mathbf{L} = \mathbf{D} - \mathbf{A} \quad (6.21)$$

onde $\mathbf{D}$ é uma matriz diagonal em que cada elemento $d_{ii} = \sum_j a_{ij}$ é o grau do vértice (registro) correspondente.

O laplaciano do grafo recebe esse nome devido a uma analogia com o operador laplaciano da equação da difusão [414]. O laplaciano tem grande importância nas propriedades topológicas de grafos [104][381].

A medida de corte (6.20) é escrita em função do laplaciano e da variável indicadora da partição $\mathbb{C} = \{\mathcal{C}_1, \mathcal{C}_2\}$ pela seguinte equação vetorial:

$$cut(\mathcal{C}_1, \mathcal{C}_2) = \frac{1}{4} \mathbf{v}^T \mathbf{L} \mathbf{v} \quad (6.22)$$

A minimização da função de corte definida pela equação (6.22) não é uma tarefa simples, considerando a restrição $v_i \in \{-1, 1\}$ imposta pela definição da variável indicadora na equação (6.18). Entretanto, uma solução aproximada $\hat{\mathbf{v}} \in \mathcal{R}^N$ pode ser calculada pela solução do problema de autovalor:

$$\mathbf{L} \mathbf{W} = \mathbf{W} \mathbf{\Lambda} \quad (6.23)$$

onde $\mathbf{\Lambda}$ é a matriz diagonal dos autovalores cujos elementos são ordenados de forma que $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_N$; $\mathbf{W} = [\mathbf{w}_1, \dots, \mathbf{w}_N]$ é a matriz dos autovetores em que cada coluna $\mathbf{w}_i \in \mathcal{R}^N$ é o autovetor correspondente ao autovalor λ_i .

O laplaciano é uma matriz positiva semi-definida,* de modo que todos os seus autovalores são números reais e positivos [206][414]. O laplaciano tem sempre um autovalor nulo, isto é, $\lambda_1 = 0$, que corresponde ao autovetor unitário $\mathbf{w}_1 = [1/\sqrt{N}, \dots, 1/\sqrt{N}]^T$ [414]. O número de autovalores nulos corresponde ao número de componentes conexas do grafo. Assim, se $\lambda_2 > 0$, o grafo é conexo, isto é, há apenas um componente e existe um caminho entre quaisquer pares de vértices. Quanto maior o autovalor λ_2 , maior a conectividade do grafo [179]. O segundo autovetor do laplaciano $\mathbf{w}_2$, correspondente ao segundo autovalor λ_2 , é conhecido como o autovetor de Fiedler [408], em homenagem ao matemático Miroslav Fiedler [179][180].

* Uma matriz $\mathbf{A}$ é positiva semi-definida se $\mathbf{x}^T \mathbf{A} \mathbf{x} \geq 0, \forall \mathbf{x}$.

Uma partição genérica $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$, segundo o corte mínimo (6.15), é obtida aplicando-se o algoritmo k-médias aos K autovetores correspondentes aos K menores autovaleiros da solução do problema (6.23). O algoritmo de agrupamento espectral básico é descrito pelo Algoritmo 6.3.

Algoritmo 6.3: Algoritmo de agrupamento espectral

Entrada:	Conjunto de treinamento $\mathcal{T} = \{\mathbf{x}(t), t = 1 \dots N\}$, parâmetro de dispersão σ e número de centros K
Saída:	Partição $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$
01	Início
02	Calcular a matriz $\mathbf{A}$, pela equação (6.11)
03	Calcular o laplaciano
04	Calcular a decomposição espectral do laplaciano
05	Calcular a matriz $\mathbf{Z}$ a partir dos autovetores do laplaciano
06	Calcular a partição $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$ pelo k-médias em $\mathbf{Z}$
07	Retorna $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$
08	Fim

Von Luxburg [356] sugere que a matriz de adjacências binária possa ser utilizada no passo 02, em que uma aresta é definida por um valor mínimo de similaridade ou por um número especificado de vizinhos. Entretanto, a forma mais usual é utilizar diretamente a matriz de similaridade nos algoritmos [408].

A partição $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$ obtida no passo 06 do Algoritmo 6.3 é definida no espaço de variáveis transformadas $\mathbf{Z}$ e, devido à transformação não linear realizada pelo cálculo da similaridade, o Algoritmo 6.3 pode encontrar uma partição não convexa no espaço de variáveis originais. O problema da inicialização aleatória do k-médias também é resolvido no algoritmo de agrupamento espectral. A matriz identidade pode ser utilizada na inicialização dos centros, uma vez que o algoritmo realiza uma partição de K grupos no espaço de variáveis transformadas, de K dimensões.

O algoritmo de agrupamento espectral descrito pelo Algoritmo 6.3 foi formulado em função da medida de corte mínimo, mas algumas variantes do algoritmo básico são obtidas segundo a medida de corte utilizada. As principais variantes são apresentadas a

seguir, começando pela formalização do próprio algoritmo de corte mínimo. Para facilitar a apresentação, a mesma notação será utilizada para denotar a matriz de autovalores $\mathbf{\Lambda}$ e a matriz de autovetores $\mathbf{W}$ em cada variante do algoritmo espectral. Essas matrizes são diferentes em função do problema formulado em cada algoritmo.

6.4.1.1 Algoritmo de corte mínimo

No algoritmo de corte mínimo [356][408], os passos 03 e 04 são calculados pelas equações (6.21) e (6.23). A matriz de dados transformados $\mathbf{Z} = [\mathbf{w}_1, \dots, \mathbf{w}_K]$, onde $\mathbf{w}_i$ são os autovetores calculados pela equação (6.23), ordenados pela ordem crescente de seus autovalores [356][408]. Os passos 03-05 do Algoritmo 6.3 para o corte mínimo são formulados no Algoritmo 6.3^a.

Algoritmo 6.3a: Corte mínimo

03	$\mathbf{L} = \mathbf{D} - \mathbf{A}$
04	$\mathbf{LW} = \mathbf{W}\mathbf{\Lambda}$
05	Ordenar $0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_N$, $\mathbf{Z} = [\mathbf{w}_1, \dots, \mathbf{w}_K]$

6.4.1.2 Algoritmo de corte mínimo normalizado de Shi e Malik

Uma variante do Algoritmo 6.3a para a minimização do corte mínimo normalizado (6.14) foi proposta por Shi e Malik [488][489]. Nesse caso, a decomposição espectral do passo 04 é calculada pela solução do problema de autovalor generalizado:

$$\mathbf{LW} = \mathbf{DWA} \quad (6.24)$$

onde $\mathbf{L}$ é o laplaciano (6.21) e $\mathbf{D}$ é a matriz diagonal de graus.

Shi e Malik [488] mostram que o sinal do segundo menor autovalor de (6.24) é uma aproximação da solução pelo corte mínimo normalizado (6.14). Para uma partição genérica em K grupos, os autores apresentam uma abordagem hierárquica divisiva em que, a cada iteração, uma nova partição pode ser encontrada pela aplicação recursiva do problema de autovalor (6.24) [489].

Na abordagem hierárquica divisiva, a definição do número de grupos é substituída por um critério de parada do algoritmo. Entretanto, essa abordagem pode se tornar instável, além de computacionalmente complexa [489].

Uma partição de K grupos pode ser obtida pela aplicação do Algoritmo 6.3, em que a matriz das variáveis transformadas é definida pelos autovetores correspondentes aos menores autovalores $\mathbf{Z} = [\mathbf{w}_1, \dots, \mathbf{w}_K]$. O algoritmo do corte mínimo normalizado é apresentado pelo Algoritmo 6.3b.

Algoritmo 6.3b: Corte mínimo normalizado [489]

03	$\mathbf{L} = \mathbf{D} - \mathbf{A}$
04	$\mathbf{LW} = \mathbf{DWA}$
05	Ordenar $0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_N$, $\mathbf{Z} = [\mathbf{w}_1, \dots, \mathbf{w}_K]$

O algoritmo de corte mínimo normalizado de Shi e Malik (Algoritmo 6.3b) tem o mesmo resultado do algoritmo de corte mínimo (Algoritmo 6.3a).

A equação (6.24) também pode ser escrita como:

$$\hat{\mathbf{L}}\hat{\mathbf{W}} = \hat{\mathbf{W}}\mathbf{A} \quad (6.25)$$

onde $\hat{\mathbf{L}} = \mathbf{D}^{-1/2}\mathbf{L}\mathbf{D}^{-1/2} = \mathbf{1} - \mathbf{D}^{-1/2}\mathbf{A}\mathbf{D}^{-1/2}$ e $\hat{\mathbf{W}} = \mathbf{D}^{1/2}\mathbf{W}$ [489]. A matriz $\hat{\mathbf{L}}$ é chamada de laplaciano simétrico [356] ou, ainda, laplaciano normalizado [408].

6.4.1.3 Algoritmo de corte mínimo normalizado de Ng, Jordan e Weiss

Uma variante do algoritmo de corte mínimo normalizado foi apresentada por Ng, Jordan e Weiss [415]. O laplaciano no passo 03 é substituído pela matriz $\hat{\mathbf{A}} = \mathbf{D}^{-1/2}\mathbf{A}\mathbf{D}^{-1/2}$, chamada de matriz de adjacências normalizada [104] ou matriz de adjacências reduzida [414]. Alguns autores sugerem que a decomposição espectral seja calculada com o Laplaciano normalizado $\hat{\mathbf{L}} = \mathbf{D}^{-1/2}\mathbf{L}\mathbf{D}^{-1/2}$ [356][408]. No artigo original [415], a decomposição espectral do passo 04 é calculada como:

$$\hat{\mathbf{A}}\mathbf{W} = \mathbf{W}\hat{\mathbf{\Lambda}} \quad (6.26)$$

A decomposição espectral (6.26) produz os mesmos autovetores $\mathbf{W}$ que (6.25) e autovalores $\hat{\mathbf{\Lambda}} = \mathbf{1} - \mathbf{\Lambda}$, onde $\mathbf{\Lambda}$ é a matriz de autovalores calculada em (6.25). Dessa forma, a solução do problema (6.26) corresponde à minimização de corte mínimo normalizado (6.14) com os autovalores em ordem não crescente $\hat{\lambda}_1 \geq \hat{\lambda}_2 \geq \dots \geq \hat{\lambda}_N$.

A matriz $\hat{\mathbf{A}}$ tem outras propriedades interessantes. Num grafo definido por uma matriz de adjacências binária, isto é, $a_{ij} \in \{0,1\}$, o maior autovalor $\hat{\lambda}_1 = 1$. O número de autovalores unitários corresponde ao número de componentes do grafo [104][342] e, em

grafos conexos, $\hat{\lambda}_2 < 1$ [104]. Num grafo com K componentes que definem uma partição $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$, o valor do corte mínimo $cut(\mathcal{C}_1, \dots, \mathcal{C}_K) = 0$ (cf. (6.15)) e a matriz $\hat{\mathbf{A}}$ tem K autovalores unitários: $\hat{\lambda}_i = 1, i = 1, \dots, K$. Essa propriedade permite utilizar o resultado da decomposição espectral (6.26) para uma estimativa do número de grupos de um conjunto de dados [342][168][170].

As variáveis transformadas são calculadas, para cada registro, pelos autovetores normalizados como:

$$\hat{\mathbf{z}}(t) = \left[\frac{w_1(t)}{\|\mathbf{z}(t)\|}, \dots, \frac{w_K(t)}{\|\mathbf{z}(t)\|} \right] \quad (6.27)$$

onde $\mathbf{z}(t) = [w_1(t), \dots, w_K(t)]$ e $w_i(t)$ é o elemento t do autovetor correspondente ao autovalor $\hat{\lambda}_i$, calculado na decomposição espectral (6.26).

A utilização das variáveis transformadas normalizadas no k-médias é equivalente à utilização do k-médias esférico nas variáveis transformadas sem normalização [468]. Na prática, a normalização (6.27) também pode ser aplicada aos demais algoritmos de corte mínimo. O algoritmo do corte normalizado de Ng, Jordan e Weiss é descrito no Algoritmo 6.3c.

Algoritmo 6.3c: Corte mínimo normalizado [415]

03	$\hat{\mathbf{A}} = \mathbf{D}^{-1/2} \mathbf{A} \mathbf{D}^{-1/2}$
04	$\hat{\mathbf{A}} \mathbf{W} = \mathbf{W} \hat{\mathbf{A}}$
05	Ordenar $1 = \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_N$, $\hat{\mathbf{z}}(t) = \left[\frac{w_1(t)}{\ \mathbf{z}(t)\ }, \dots, \frac{w_K(t)}{\ \mathbf{z}(t)\ } \right]$

A complexidade computacional do cálculo da matriz de similaridade é $O(N^2)$ e a complexidade do algoritmo de agrupamento espectral é dominada pelo cálculo do problema de autovalor, que é de $O(N^3)$. Em problemas que $K \ll N$, a complexidade pode ser reduzida a $O(N^2)$, uma vez que apenas os primeiros autovetores são necessários.

O algoritmo de agrupamento espectral pode separar grupos não convexos no espaço de variáveis de entrada do problema e, por isso, tem bons resultados em aplicações de agrupamento. Essas características motivaram o desenvolvimento de outras variantes do algoritmo [23][356][408][554]. Os algoritmos de agrupamento espectral são relacionados aos algoritmos baseados em função de núcleo [127][128][182][596].

6.4.1.4 Algoritmo de maximização da modularidade de Newman e Girvan

O problema de maximização da modularidade (cf. equação (6.16)) também tem solução aproximada pela decomposição espectral da matriz de modularidade $\mathbf{B}$. No caso de uma partição binária $\mathbb{C} = \{\mathcal{C}_1, \mathcal{C}_2\}$, o produto $\mathbf{u}_i \mathbf{u}_j^T$ é escrito em função variável indicadora (6.18) como $\mathbf{u}_i \mathbf{u}_j^T = \frac{1}{2}(v_i v_j + 1)$, de modo que $\frac{1}{2}(v_i v_j + 1) = 1$ se dois registros $\mathbf{x}(i)$ e $\mathbf{x}(j)$ estão no mesmo grupo e $\frac{1}{2}(v_i v_j + 1) = 0$ caso contrário.

A função de modularidade (6.16) é reescrita como:

$$Q(\mathcal{C}_1, \mathcal{C}_2) = \frac{1}{4E} \sum_{i=1}^N \sum_{j=1}^N b_{ij} (v_i v_j + 1) = \frac{1}{4E} \left(\sum_{i=1}^N \sum_{j=1}^N b_{ij} v_i v_j + \sum_{i=1}^N \sum_{j=1}^N b_{ij} \right) \quad (6.28)$$

onde b_{ij} são os elementos da matriz de modularidade $\mathbf{B}$ definida em (6.17). A soma das linhas (ou colunas) da matriz $\mathbf{B}$ é zero, de forma que o termo $\sum_{ij} b_{ij} = 0$. A função de modularidade pode ser escrita vetorialmente como:

$$Q(\mathcal{C}_1, \mathcal{C}_2) = \frac{1}{4E} \mathbf{v}^T \mathbf{B} \mathbf{v} \quad (6.29)$$

Uma aproximação para a solução do problema de maximização da modularidade (6.29) é obtida pela solução do problema de autovalor $\mathbf{B} \mathbf{w} = \mathbf{w} \lambda$, em que λ é o maior autovalor e $\hat{\mathbf{v}}$, o autovetor correspondente. O sinal dos elementos do autovetor correspondente ao maior autovalor é utilizado para a obtenção da partição $\mathbb{C} = \{\mathcal{C}_1, \mathcal{C}_2\}$:

$$\hat{v}_i = \begin{cases} +1, & \text{se } w_i \geq 0 \\ -1, & \text{se } w_i < 0 \end{cases} \quad (6.30)$$

Newman e Girvan [413] apresentam uma abordagem hierárquica divisiva para o particionamento do grafo em que, a cada iteração, o valor do ganho da função modularidade é avaliado e utilizado para a decisão sobre um novo particionamento. Vieira e colaboradores [541] apresentam um estudo de desempenho e o código dos principais algoritmos de detecção de comunidades baseados na função de modularidade.

6.4.2 Exemplos

A Figura 6.11 mostra, em cada linha, os resultados dos algoritmos 6.3a-c no conjunto de dados de duas luas utilizando o parâmetro $\sigma = 0.1$ no cálculo da função de similaridade. Na coluna da direita são apresentados os resultados do agrupamento e, na coluna da esquerda, as variáveis transformadas.




Figura 6.11: Resultados no conjunto de dados duas luas: à esquerda, os resultados do agrupamento e, à direita, as variáveis transformadas; nas linhas, os Algoritmos 6.3a-c.

Podemos observar que os algoritmos espectrais baseados no corte mínimo podem gerar grupos de forma não convexa e as três formulações produzem os mesmos resultados. Os resultados das variáveis transformadas utilizadas nos algoritmos de corte mínimo (6.3a) e corte mínimo normalizado (6.3b) também são idênticos. Uma aplicação

do algoritmo de maximização da modularidade para agrupamento de documentos será apresentada na seção 6.6.2.

Os resultados dos algoritmos de agrupamento espectral dependem do valor do parâmetro de dispersão σ no cálculo da função de similaridade gaussiana (6.12), além da informação do número de grupos K para o algoritmo k-médias. Entretanto, a inicialização do algoritmo k-médias é definida pela matriz identidade e o resultado do algoritmo espectral é determinístico.

Na análise de agrupamentos, a decisão sobre o melhor número de grupos depende de alguma medida de validação, como apresentado a seguir.

6.5 Validação de Grupos

Encontrar uma partição num conjunto de dados é um problema mal definido e diferentes agrupamentos podem ser obtidos do mesmo conjunto (cf. Figura 6.1). Não há uma medida absoluta de qualidade para o problema e o resultado do agrupamento deve ser avaliado no contexto da aplicação.

As medidas de validação de agrupamentos visam avaliar as características geométricas do agrupamento formado, sabendo-se que um bom agrupamento deve produzir grupos compactos e bem separados. É comum encontrar na literatura a divisão das medidas de validação de agrupamentos em três tipos [194][227][228][573], cujos principais índices são apresentados na sequência:

- **Medidas externas:** avaliam a qualidade do agrupamento em relação a uma informação externa sobre a estrutura de grupos (ou classes) do problema;
- **Medidas internas:** avaliam a qualidade do agrupamento a partir dos registros do conjunto de dados, em geral utilizando critérios geométricos;
- **Medidas relativas:** produzem índices calculados pela combinação de critérios (internos) que avaliam a qualidade de um agrupamento em relação a outros.

6.5.1 Medidas externas

As medidas externas avaliam a qualidade do agrupamento a partir de uma matriz de confusão como na avaliação de classificadores (cf. Tabela 5.2). Para avaliação de grupos, a matriz de confusão relaciona os grupos encontrados pelo algoritmo de agrupa-

mento com as classes do problema. A Tabela 6.1 mostra a matriz de confusão para avaliação de agrupamentos, onde $\{C_1, \dots, C_m\}$ é o conjunto de classes e $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$, uma partição de K grupos. Cada elemento n_{ij} na Tabela 6.1 representa o número de registros da classe C_i alocados no grupo $\mathcal{C}_j$. A soma das linhas corresponde ao número de elementos das classes e a soma das colunas, o número de elementos dos grupos.

Quando o número de grupos é igual ao número de classes, qualquer estatística de avaliação de classificadores (cf. seção 5.3.1) pode ser utilizada como medida de validação externa. Entretanto, é comum que o número de grupos seja diferente do número de classes e, nesse caso, as medidas externas avaliam o quanto o agrupamento encontrado corresponde à estrutura de classes conhecida.

Tabela 6.1: Matriz de confusão

	$\mathcal{C}_1$	...	$\mathcal{C}_K$	Total
C_1	n_{11}	...	n_{1K}	N_1
$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
C_m	n_{m1}	...	n_{mK}	N_m
Total	$\hat{N}_1$	...	$\hat{N}_K$	N

A **pureza** de um grupo é a porção dos registros de um grupo que pertence à classe que contém a maioria dos registros daquele grupo. A pureza é uma medida de homogeneidade do agrupamento: quanto maior a pureza, mais homogêneos são os grupos. A pureza de um grupo é calculada como:

$$pur(\mathcal{C}_j) = \max_{i=1, \dots, m} \left(\frac{n_{ij}}{\hat{N}_j} \right) \quad (6.31)$$

A pureza total ou pureza do agrupamento é calculada como a média da pureza dos grupos ponderada pelo número de registros de cada grupo:

$$PUR(\mathbb{C}) = \sum_{j=1}^K \frac{\hat{N}_j}{N} pur(\mathcal{C}_j) \quad (6.32)$$

A entropia de Shannon é uma medida clássica da teoria da informação que pode ser utilizada para avaliar a heterogeneidade do agrupamento: quanto menor a entropia, melhor o agrupamento. A **entropia** de um grupo é calculada como (cf. Tabela 6.1):

$$ent(\mathcal{C}_j) = -\frac{1}{\log_2 m} \sum_{i=1}^m \left(\frac{n_{ij}}{\hat{N}_j} \right) \log_2 \left(\frac{n_{ij}}{\hat{N}_j} \right) \quad (6.33)$$

A entropia do agrupamento é calculada como a média da entropia dos grupos ponderada pelo número de registros de cada grupo:

$$ENT(\mathbb{C}) = \sum_{j=1}^K \frac{\hat{N}_j}{N} ent(\mathcal{C}_j) \quad (6.34)$$

Há outras medidas externas para avaliação da qualidade de agrupamentos baseadas em contagem de pares e informação mútua [544]. Entretanto, nem sempre uma informação de classes é conhecida para a avaliação do agrupamento. Além disso, a estrutura de grupos pode não coincidir com a estrutura de classes, o que não significa que o agrupamento esteja inadequado (cf. Figura 6.2). Medidas internas e relativas são mais comuns em problemas de agrupamento.

6.5.2 Medidas internas

Medidas internas avaliam um agrupamento utilizando apenas as informações dos registros do conjunto de dados e o resultado do agrupamento. A função de avaliação de um algoritmo de agrupamento, por exemplo, é uma medida interna de avaliação. Em algoritmos hierárquicos, o coeficiente de correlação cofenética [572] é empregado para avaliação de agrupamentos.

Uma medida interna muito utilizada é o índice de partição (PI, na sigla em inglês), proposta por Bensaid e colaboradores [41] para avaliação de agrupamentos *fuzzy*. O índice PI, quando calculado com funções de pertinência binárias, é a razão entre o critério quadrático do k-médias e a soma ponderada das distâncias entre centros:

$$PI(\mathbb{C}) = \frac{\sum_{i=1}^K \sum_{t=1}^N u_i(\mathbf{x}(t))^2 \|\mathbf{x}(t) - \boldsymbol{\omega}_i\|^2}{\sum_{i=1}^K \sum_{j=1}^K N_i \|\boldsymbol{\omega}_i - \boldsymbol{\omega}_j\|^2} = \frac{tr(\boldsymbol{\Sigma}_W)}{\sum_{i=1}^K \sum_{j=1}^K N_i \|\boldsymbol{\omega}_i - \boldsymbol{\omega}_j\|^2} \quad (6.35)$$

onde $tr(\boldsymbol{\Sigma}_W)$ é o traço da matriz de variância intragrupos (cf. equação (6.6)).

Na avaliação de agrupamentos obtidos pelo algoritmo k-médias e suas variantes, o índice PI permite a escolha do melhor agrupamento de um conjunto de soluções obtidas com diversas inicializações aleatórias, mas com o mesmo número de grupos K .

Uma proposta para avaliação de agrupamentos é a visualização qualitativa da tendência de agrupamento (VAT)* [49][239]. A VAT é basicamente o *data image* do conjunto de dados com os registros ordenados segundo o resultado do agrupamento. Um bom agrupamento mostra um contraste mais intenso que um agrupamento de pior qualidade, para o mesmo conjunto de dados.

A Figura 6.12 mostra os resultados do agrupamento do conjunto de dados Íris com $K = 4$ grupos. Foram realizados 25 agrupamentos distintos e selecionados os de menor e maior valor de PI, que são apresentados, respectivamente, na coluna da esquerda e na da direita da Figura 6.12. Podemos observar que o resultado com menor valor de PI (à esquerda) resulta num contraste ligeiramente maior que o resultado com maior valor de PI (à direita).




Figura 6.12: *Data image* do resultado do agrupamento do conjunto de dados Iris com $K = 4$:

(a) resultado com menor PI; (b) resultado com maior PI.

A avaliação qualitativa pelo *data image* é muito subjetiva, sendo preferível a utilização de uma métrica quantitativa para a escolha do melhor agrupamento. As medidas relativas permitem avaliar o número de grupos, principalmente em algoritmos de partição.

* *Visual Assessment of (cluster) Tendency.*

6.5.3 Medidas relativas

Os métodos de partição, principalmente o k-médias e suas variantes, são os mais utilizados na prática e, nesse caso, as medidas relativas são empregadas para a descoberta do número de grupos. As medidas relativas são índices utilizados para comparação de diversas soluções do mesmo algoritmo, variando-se o número de grupos. No algoritmo k-médias, o resultado depende da inicialização e as medidas relativas podem variar para o mesmo número de grupos, sendo, portanto, uma função do agrupamento gerado pelo algoritmo e não somente do número de grupos.

Num estudo realizado em 1985, Milligan e Cooper [388] compararam 30 medidas de avaliação de agrupamento existentes na época. A medida que obteve o melhor resultado foi a proposta por Calinski e Harabasz [71] em 1974.

O índice Calinski-Harabasz (CH) de uma partição $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$ é calculado como:

$$CH(\mathbb{C}) = \frac{N - K}{K - 1} \frac{tr(\mathbf{\Sigma}_B)}{tr(\mathbf{\Sigma}_W)} \quad (6.36)$$

onde, $tr(\mathbf{\Sigma}_B)$ e $tr(\mathbf{\Sigma}_W)$ são, respectivamente, os traços das matrizes de variância entre grupos e intragrupos, definidas nas equações (6.5) e (6.6).

O índice CH é um critério de maximização, uma vez que o valor pequeno de $tr(\mathbf{\Sigma}_W)$ indica grupos coesos e um valor grande de $tr(\mathbf{\Sigma}_B)$, grupos separados.

Um índice semelhante, proposto por Pakhira, Bandyopadhyay e Maulik [423] em 2006, também é um critério de maximização calculado pelo produto de três termos:

$$PBM(\mathbb{C}) = \left(\frac{1}{K} \frac{E_1}{E_K} \frac{1}{D_{\max}} \right)^2 \quad (6.37)$$

onde $E_1 = \sum_{t=1}^N \|\mathbf{x}(t) - \bar{\mathbf{x}}\|$ é constante para um determinado conjunto de dados. O termo, $E_K = \sum_{t=1}^N \sum_{i=1}^K u_i(\mathbf{x}(t)) \|\mathbf{x}(t) - \mathbf{\omega}_i\|$, diminui com o aumento do número de grupos K e o termo $D_{\max} = \max_{i,j=1 \dots K} (\|\mathbf{\omega}_i - \mathbf{\omega}_j\|^2)$ aumenta com o número de grupos.

O índice PBM utiliza os valores de distâncias nas somas de E_1 e E_K , ao passo que as matrizes de variância utilizadas no índice CH são calculadas pela soma das diferenças ao quadrado (cf. equações (6.4)-(6.6)). A razão E_1/E_K favorece agrupamentos cuja variância intragrupos é a menor porção da variância total. O primeiro e o terceiro fatores

do índice PBM favorecem, respectivamente, agrupamentos com pequeno número de grupos e com centros separados.

Uma medida de avaliação relativa muito conhecida é o coeficiente de silhueta [462], que avalia a qualidade do agrupamento para cada registro como:

$$sw_i(t) = - \frac{(b_i(t) - a_i(t))}{\max_{t=1, \dots, N} (a_i(t), b_i(t))} \quad (6.38)$$

onde $a_i(t)$ é a média das distâncias entre o registro $\mathbf{x}(t)$ e todos os outros registros alocados ao mesmo grupo $\mathcal{C}_i$ e $b_i(t)$ é a menor distância média entre $\mathbf{x}(t)$ e os registros alocados aos demais grupos $\mathcal{C}_j \neq \mathcal{C}_i$.

O valor $a_i(t)$ é calculado para cada registro $\mathbf{x}(t) \in \mathcal{C}_i$ como a distância média para os demais elementos do grupo:

$$a_i(t) = \frac{1}{\bar{N}_i} \sum_{k=1}^N dist(\mathbf{x}(t), \mathbf{x}(k)), \quad \mathbf{x}(k) \in \mathcal{C}_i \quad (6.39)$$

O valor $b_i(t) = \min_j (\bar{a}_j(t))$, onde $\bar{a}_j(t)$ é a distância média de $\mathbf{x}(t)$ para os registros dos demais grupos $\mathcal{C}_j, j = 1, \dots, K, j \neq i$, calculada como:

$$\bar{a}_j(t) = \frac{1}{\bar{N}_j} \sum_{k=1}^N dist(\mathbf{x}(t), \mathbf{x}(k)), \quad \mathbf{x}(t) \in \mathcal{C}_j, j \neq i \quad (6.40)$$

O coeficiente de silhueta é definido no intervalo $-1 < sw_i(t) < 1$, sendo que o valor $sw_i(t) \approx 1$ é obtido quando $a_i(t) \approx 0$, o que indica que o registro está no centro de um agrupamento compacto. Quanto maior o valor do coeficiente de silhueta, melhor a posição do registro no agrupamento. O coeficiente de silhueta também pode ser utilizado numa etapa de refinamento, verificando-se seu valor caso o registro seja alocado em outro grupo.

O coeficiente de silhueta da partição $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$ é calculado como o valor médio do coeficiente de silhueta para todos os registros e todos os grupos:

$$SW(\mathbb{C}) = \frac{1}{KN} \sum_{i=1}^K \sum_{t=1}^N sw_i(t) \quad (6.41)$$

O índice proposto por Xie e Beni [570] para avaliação de agrupamentos *fuzzy* é uma medida de minimização que avalia a razão entre a variância intragrupos e a menor separação entre os grupos. O índice XB é similar ao PI e é calculado como:

$$XB(\mathbb{C}) = \frac{1}{N} \frac{\sum_{i=1}^K \sum_{t=1}^N u_i(\mathbf{x}(t))^2 \|\mathbf{x}(t) - \boldsymbol{\omega}_i\|^2}{D_{\min}} = \frac{1}{N} \frac{tr(\boldsymbol{\Sigma}_W)}{D_{\min}} \quad (6.42)$$

onde $D_{\min} = \min_{i,j=1 \dots K, i \neq j} (\|\boldsymbol{\omega}_i - \boldsymbol{\omega}_j\|^2)$.

As medidas relativas são geralmente aplicadas para a avaliação do número de grupos em algoritmos de partição. No caso do algoritmo k-médias e suas variantes, a questão da inicialização aleatória deve ser levada em consideração e uma avaliação estatística em diferentes execuções com o mesmo número de grupos é a abordagem mais indicada para uma avaliação isenta da influência da inicialização.

A Figura 6.13 apresenta *boxplot* dos resultados das medidas de validação aplicadas sobre os resultados de 10 execuções do algoritmo k-médias no conjunto de dados quatro grupos (cf. Figura 6.7). A linha azul representa a média das medidas em todas as simulações para cada valor de K . Neste exemplo, todas as medidas indicam o número de grupos $K = 4$, que é o valor com menor dispersão de resultados.

Os resultados apresentados na Figura 6.13 mostram o desempenho das medidas de avaliação num conjunto de dados com $p = 2$ variáveis e com uma estrutura de grupos muito bem definida (cf. Figura 6.7). Na prática, as medidas de validação podem apresentar resultados conflitantes.

A Figura 6.14 apresenta os resultados de 100 simulações das medidas de validação no conjunto de dados de Diabetes das índias Pima, que tem $p = 8$ variáveis. Nesse caso, as medidas CH e XB apontam uma estrutura com $K = 3$ grupos por apresentar os melhores valores dos índices e a menor dispersão. Os resultados do índice PBM e SW não são conclusivos com relação ao número de grupos, mas o agrupamento com $K = 3$ grupos também gera a menor dispersão dessas medidas.

Observe que o conjunto de dados de Diabetes das índias é um problema de classificação com $m = 2$ classes, mas é desbalanceado com 65% dos registros numa das classes. Este exemplo mostra que nem sempre a estrutura de grupos presente nos dados corresponde às classes do problema.




Figura 6.13: Resultados das medidas de validação: (a) CH; (b) PBM; (c) SW; (d) XB.

Mesmo um algoritmo simples como o k-médias acarreta num alto custo computacional quando executado com diferentes inicializações e para vários valores do parâmetro K , o que limita a análise em problemas de grande dimensionalidade. Entretanto, o algoritmo k-médias pode ser executado em paralelo [58][601] para viabilizar a busca do melhor particionamento utilizando medidas de validação. Modenesi e colaboradores [395]-[397] apresentam uma abordagem que integra a versão *fuzzy* do algoritmo k-médias (cf. Capítulo 8) com o cálculo do índice PBM de avaliação de grupos em processamento paralelo.

Um estudo abrangente sobre medidas relativas de validação de agrupamentos foi apresentado recentemente por Vendramin, Campello e Hruschka [538]. No artigo, os autores analisam e comparam 40 índices de validação em 1.080 conjuntos de dados diferentes. O artigo apresenta a descrição das medidas de validação acompanhada de análises de complexidade assintótica. A análise experimental é feita em duas partes: na

primeira, é reproduzido o mesmo procedimento empregado por Milligan e Cooper [388]; na segunda, a análise é estendida com conjuntos de dados maiores, com maior diversidade de número de grupos e de variáveis. Os resultados mostram que os índices CH, PBM e SW são os mais efetivos para encontrar o número de grupos presentes num conjunto de dados.




Figura 6.14: Resultados das medidas de validação: (a) CH; (b) PBM; (c) SW; (d) XB.

A validação de agrupamentos é um assunto recorrente na literatura e diversas medidas são encontradas na literatura [592][599]. Em geral, as medidas são avaliadas em conjuntos de dados sintéticos e de baixa dimensionalidade. A própria característica do problema de análise de agrupamentos dificulta a definição de uma média absoluta para avaliar a melhor solução.

6.6 Aplicações

A análise de agrupamentos tem aplicações em diversas áreas. Nesta seção, apresentamos duas aplicações em problemas reais em trabalhos de pesquisa realizados na Copppe/UFRJ [32][468].

6.6.1 Segmentação de imagens de satélite

Segmentação de uma imagem é a partição da imagem em regiões representadas por conjuntos de *pixels*. Essencialmente, a segmentação de imagens é uma aplicação de análise de agrupamentos na qual os registros são os *pixels* e as variáveis são características extraídas destes.


Nesta seção, apresentamos uma aplicação de segmentação de imagens para classificação das zonas inundáveis na Amazônia a partir de imagens de satélite obtidas por radares de abertura sintética (SAR, na sigla em inglês). As imagens SAR são úteis para monitorar florestas tropicais úmidas, pois são imunes à cobertura de nuvens. A interpretação de imagens SAR permite a discriminação de áreas de cobertura vegetal, florestas inundadas e corpos d'água.

Beisl [32] utilizou imagens SAR da região Amazônica registradas pelo satélite JERS-1 e obtidas no projeto de Mapeamento Global de Florestas Tropicais (GRFM, na sigla em inglês) em duas épocas distintas: a época de cheia, captadas em outubro de 1995 (Figura 6.15a), e a época de seca, em maio de 1996 (Figura 6.15b). Uma parte do trabalho foi feita para a determinação do traçado do poliduto Coari-Manaus, da Petrobras.


Beisl realizou o mapeamento das mudanças em toda a extensão da bacia do Solimões em função das variações no ciclo hidrológico do rio. O estudo relacionou os padrões de mudança com as características do ambiente, que haviam sido identificadas em estudos anteriores, para obter um mapa de sensibilidade da região ao derramamento de óleo.

Após o pré-processamento, os *frames* foram combinados para produzir as imagens mostradas na Figura 6.15. A imagem cobre boa parte da bacia do Solimões, com cerca de 600 km de extensão, onde Manaus aparece no alto à direita das imagens. As regiões mais escuras indicam a reflexão total do sinal do radar e indicam corpos d'água. As regiões de cinza mais escuro indicam o espalhamento do sinal pela copa das árvores e indicam regiões de floresta. As regiões de cinza mais claro indicam regiões de dupla

reflexão, em que o sinal reflete na água, mas parte do sinal retorna após refletir novamente em algum obstáculo, como árvores, o que caracteriza floresta inundada.



(a)



(b)

Figura 6.15: Imagens SAR da Amazônia: (a) em época de cheia (outubro de 1995); (b) em época de seca (maio de 1996). Fonte: [32].

Em imagens SAR, o conteúdo é apresentado em um canal e a imagem é representada pelo conjunto de dados $Z = \{z(t) \in \mathcal{R}, t = 1, \dots, N\}$, onde $z(t)$ é o valor do *pixel*. Beisl [32] utilizou uma transformação do conjunto de dados Z pela função de semi vario-grama, que relaciona um *pixel* a seus vizinhos pela relação:

$$x_h(t) = \frac{1}{2n} \sum_{i=1}^n (v_h(t, i) - z(t))^2 \quad (6.43)$$

onde h é um parâmetro que regula a extensão da vizinhança e n , o número de *pixels* de vizinhança e $v_h(t, i) = h(t, i)$ uma função de vizinhança.

A função de vizinhança é calculada num círculo de raio h centrado no *pixel* correspondente, como mostra a Figura 6.16 para $h = 6 \text{ pixels}$.





Figura 6.16: Função de vizinhança com $h = 6$.

As imagens foram segmentadas pelo algoritmo textural não supervisionado por semi variograma (USTC),* que utiliza a função semi variograma como um descritor de textura [390][391]. No método USTC, o agrupamento é realizado pelo algoritmo ISODATA [27] aplicado ao conjunto $\mathcal{T} = \{\mathbf{x}(t), t = 1 \dots N\}$, em que o vetor de variáveis tem dimensão $h + 2$ e as componentes são calculados pela função de semi variograma (6.43) como $\mathbf{x}(t) = [z(t), x_1(t), \dots, x_h(t), \sigma_h^2(t)]$, incluindo o valor do pixel central $z(t)$ e $\sigma_h^2(t)$ que é a variância calculada na região da função de vizinhança $h(t, i), i = 1 \dots n$.


O resultado obtido pelo algoritmo ISODATA é classificado por um especialista e os grupos são definidos para representar um significado temático. Beisl [32] utilizou quatro classes: água, vegetação inundada e floresta seca ou inundada. O resultado final é mostrado na Figura 6.17, na qual a região em verde representa floresta seca, a região em azul representa corpos d'água, a região em amarelo representa floresta inundada e a região em azul-claro, vegetação inundada.

Beisl utiliza o resultado da classificação de imagens obtida pelo método USTC para produzir mapas de sensibilidade ao derramamento de óleo [32]. O trabalho utiliza sistemas *fuzzy* para o cálculo do índice e os resultados são apresentados no Capítulo 8.

* *Unsupervised Semivariogram Textural Classifier*.



(a)



(b)

Figura 6.17: Resultados do USTC: (a) em época de cheia; (b) em época de seca. Fonte: [32].

6.6.2 Agrupamento de documentos

Estima-se que 85% das informações estão armazenadas na forma não estruturada, o que inclui imagens, gravações e, principalmente, texto. A mineração de textos utiliza técnicas de recuperação de informações, processamento de linguagem natural e algoritmos de inteligência computacional para a extração de conhecimento de coleções de documentos. A análise de agrupamentos de uma coleção de documentos permite a determinação dos principais assuntos da coleção e tem diversas aplicações, tendo em vista que a maior parte dos documentos não é categorizada.

A abordagem mais comum para a mineração de textos é aplicar uma etapa de pré-processamento para transformar a coleção de documentos numa tabela de dados, de forma que os algoritmos de mineração de dados possam ser aplicados [43][178][502]. O pré-processamento básico inclui a retirada de palavras irrelevantes (*stopwords*) e a redução ao termo raiz (*stemming*). Outras etapas mais elaboradas podem incluir o tratamento de polissemia (palavras diferentes utilizadas com o mesmo significado) e de homonímia (palavras iguais com significados diferentes), além da identificação de sintagmas nominais [437] e outras técnicas de processamento de linguagem natural [294].

Após o pré-processamento, cada documento é representado como um vetor em que os componentes representam os termos (palavras após o pré-processamento) presentes na coleção. Essa representação é chamada de modelo de espaço vetorial e é muito utilizada na área de recuperação de informações [43][467]. A coleção de documentos é, assim, transformada no conjunto de treinamento $\mathcal{T} = \{\mathbf{x}(t), t = 1 \dots N\}$, onde N é o número total de documentos e cada documento é representado pelo vetor $\mathbf{x}(t) \in \mathcal{R}^p$, onde p é o número total de termos da coleção.

As coordenadas associadas a cada documento no modelo de espaço vetorial podem ser calculadas pela frequência do termo no documento. Em geral, utiliza-se o valor chamado *tf-idf*, em que a frequência do termo no documento é ponderada pelo logaritmo do inverso da frequência do termo na coleção, o que evita que palavras muito citadas em toda a coleção tenham peso muito alto. Cada coordenada é calculada como:

$$x_i(t) = f_i(t) \log \frac{N}{N_i}, \quad i = 1, \dots, p \quad (6.44)$$

onde $f_i(t)$ é a frequência do termo i no documento t e N_i é o total de ocorrências do termo i em toda a coleção.

A ponderação pelo logaritmo do inverso da frequência reduz a importância de termos que aparecem em muitos documentos da coleção e, portanto, são menos importantes para diferenciar os documentos entre si. Há algumas variantes¹³⁹ ao *tf-idf* que podem apresentar resultados em aplicações específicas [372].

A representação pelo modelo de espaço vetorial gera um conjunto de dados de altíssima dimensionalidade. Dependendo do assunto, uma coleção pode conter milhares de termos, o que pode dificultar o cálculo de similaridade entre documentos. Há algumas abordagens de redução da dimensionalidade, das quais a mais conhecida é o índice de

semântica latente (LSI)* [43], cujo cálculo é semelhante à análise de componentes principais (ACP), apresentada na seção 2.4.1.

A aplicação de algoritmos de detecção de comunidades para o agrupamento de coleções de documentos foi estudada por Santos [468][469]. Nesta seção, reproduzimos os resultados obtidos no conjunto de resumos das teses e dissertações do Programa de Engenharia Civil¹⁴⁰ (PEC) da Coppe/UFRJ, publicados entre janeiro de 2004 e dezembro de 2008, totalizando 585 resumos. Após o pré-processamento, a coleção foi representada por um conjunto de 265 termos [468].

A coleção de documentos foi transformada num grafo para a aplicação do algoritmo de maximização da modularidade de Newman e Girvan [413]. A similaridade entre os registros foi utilizada para a definição da matriz de adjacências $\mathbf{A} \in \mathcal{R}^{N \times N}$, cujos elementos foram calculados como:

$$a_{ij} = \begin{cases} 1, & \text{se } i \neq j \text{ e } \text{sim}(\mathbf{x}(i), \mathbf{x}(j)) > \varepsilon \\ 0, & \text{caso contrário} \end{cases} \quad (6.45)$$

onde a função de similaridade $\text{sim}(\mathbf{x}(i), \mathbf{x}(j))$ é calculada pelo cosseno (cf. equação (2.13)) e $\varepsilon \in [0,1]$ é um parâmetro que determina um limite de similaridade para dois registros serem considerados próximos.

Cada valor do parâmetro ε na equação (6.45) define um grafo diferente que resulta num número diferente de comunidades [413]. A Tabela 6.2 mostra os resultados de modularidade (Q) e número de grupos (K) para diversos valores de ε na definição do grafo [468]. O resultado com $\varepsilon = 0.20$ foi escolhido porque o número de grupos gerados é coerente com a estrutura de áreas de pesquisa do PEC. O algoritmo foi aprimorado por uma etapa de refinamento que, a cada nova divisão, verifica se o resultado da modularidade pode ser melhorado alterando-se a alocação de cada documento a outro grupo [541]. Com essa etapa de refinamento, Santos encontrou sete grupos com $\varepsilon = 0.20$ com modularidade $Q = 0.5334$ [468].

O resultado do agrupamento é mostrado na Figura 6.18, gerada com o *software* livre Cytoscape.¹⁴¹ A Figura 6.18 foi gerada de forma que os vértices similares do grafo fiquem mais próximos, representando a coesão dos grupos.

* *Latent Semantic Index.*

Tabela 6.2: Modularidade para vários valores de ε . Fonte: [468]

ε	Q	K
0.10	0.3232	4
0.15	0.4236	5
0.20	0.4998	6
0.25	0.5468	9
0.30	0.6588	12
0.35	0.7167	13




Figura 6.18: Rede de documentos resultante da análise de agrupamentos. Fonte: [468][469].

Uma interpretação do resultado do agrupamento pode ser obtida observando-se os termos mais importantes em cada grupo. A seleção de termos é um caso particular do problema de seleção de variáveis [350][351]. Santos [468] utilizou uma abordagem simples, na qual a relevância de cada termo para cada grupo C_i é calculada como:

$$rel(i, j) = \sum_{t=1}^N x_j(t) u_i(\mathbf{x}(t)) \quad (6.46)$$

onde $u_i(\mathbf{x}(t))$ é a função de pertinência do documento t ao grupo $\mathcal{C}_i$.

Os 10 termos de maior relevância para cada grupo segundo o índice (6.46) são mostrados na Tabela 6.3 [468], na qual os grupos foram interpretados em relação às áreas de pesquisa do PEC. Observa-se que o agrupamento recuperou os assuntos das principais áreas de pesquisa do Programa. A área de Petróleo e Gás foi dividida em dois agrupamentos, que representam as duas linhas de pesquisa mais importantes da área: Geoquímica e Geofísica.

Tabela 6.3: Palavras de cada grupo. Fonte: [468]

Grupo	Termos Relevantes	Área de Pesquisa
$\mathcal{C}_1$	elemento, <i>riser</i> , estaca, linha, estrutura, finito, duto, acoplamento, método, contorno	Mecânica Computacional
$\mathcal{C}_2$	concreto, fibra, reforço, viga, agregado, misto, pavimento, resistência, armado, liga	Estrutura e Materiais
$\mathcal{C}_3$	aterro, resíduo, solo, ensaio, contaminar, sólido, geotecnia, rejeitar, argila, liga	Geotecnia / Meio Ambiente
$\mathcal{C}_4$	óleo, geoquímica, migrar, biomarcador, hidrocarboneto, maturar, biodegradável, bacia, amostra, sísmica	Petróleo e Gás (Geoquímica)
$\mathcal{C}_5$	classificação, redes, virtual, texto, dados, <i>fuzzy</i> , mineração, algoritmo, regra, agrupamento	Sistemas Computacionais
$\mathcal{C}_6$	reservatório, poço, fluxo, simulação, petróleo, fluido, produção, estimativa, otimização, rocha	Petróleo e Gás (Geofísica)
$\mathcal{C}_7$	bacia, hídrico, água, recursos, regra, gestão, cobrança, urbano, modelo, cheia	Recursos Hídricos / Meio Ambiente

6.7 Comentários Finais

O problema de análise de agrupamentos é extenso e alguns livros tratam exclusivamente do assunto [194][573]. O problema é mal definido, o que dificulta a formulação de estatísticas de validação. Há diversas abordagens distintas, sendo muito difícil uma cobertura completa do assunto.

Os tópicos incluídos neste capítulo foram escolhidos para servir como introdução ao tema e aos assuntos que serão tratados nos próximos capítulos. O algoritmo k-médias e os algoritmos hierárquicos aglomerativos apresentados, respectivamente, nas seções

6.2 e 6.3, são as abordagens clássicas, presentes em praticamente todos os *softwares* e bibliotecas. Os algoritmos baseados em grafos, apresentados na seção 6.4, têm sido utilizados em aplicações de mineração de textos e processamento de imagens.

A avaliação de agrupamentos depende muito do contexto e, quando disponível, a avaliação de grupos como classes deve ser feita com cuidado, pois nem sempre os dois conceitos são equivalentes. A relação entre classes e grupos fez surgir métodos chamados de classificação semi supervisionada [8][269][605], em que o conhecimento da classe de alguns registros é utilizado para guiar o algoritmo de agrupamento. Esses métodos têm aplicações em mineração de textos e bioinformática, onde um pequeno número de registros anotados é utilizado para a classificação de um conjunto maior não anotado.

As aplicações de mineração de textos e bioinformática trouxeram novos desafios para os algoritmos de análise de agrupamentos, principalmente devido ao problema da dimensionalidade. Nesse tipo de aplicação, os registros são descritos por vetores de grande dimensão, o que dificulta a análise de similaridade entre os registros, fundamental para o agrupamento. No estudo de caso apresentado na seção 6.6.2, a função cosseno é utilizada como métrica de similaridade e um algoritmo de detecção de comunidades em redes complexas realiza o agrupamento dos documentos. A combinação de técnicas de mineração de dados e de textos com análise de redes complexas também tem sido aplicada para a análise de redes sociais [4][376].

Este capítulo representa a transição entre os métodos clássicos e os métodos mais avançados, que serão apresentados nos próximos capítulos.