

# 2 PREPROCESAMIENTO

El preprocesamiento incluye selección, limpieza y transformación de datos. El objetivo de este paso es preparar el conjunto de datos que se utilizará para ajustar el modelo, llamado conjunto de entrenamiento. En general, la etapa de preprocesamiento consume del 60% al 80 % del tiempo de todo el proceso de minería de datos y proporciona información importante que guiará el análisis y ajuste de los modelos.

Este capítulo presenta los conjuntos de datos que se encuentran en las aplicaciones de ciencia de datos. A continuación, se presentan los principales conceptos estadísticos de los métodos exploratorios necesarios para la comprensión de los datos y, principalmente, para la adecuada interpretación de los resultados de la visualización. A continuación se presentan las técnicas de limpieza de datos y transformaciones lineales más importantes. Al final se presentan algunas aplicaciones que utilizan los conceptos discutidos en el capítulo.

## 2.1 Conjuntos de datos

Existe una diferencia entre datos, información y conocimiento [451]. Los datos son el registro de un hecho, la información es el hecho analizado en su contexto y el conocimiento, característica inherentemente humana, es la interpretación de la información en un contexto específico con vistas a su aplicación. Por ejemplo, el precio de una acción en un momento determinado en bolsa son datos; el cambio en el precio de las acciones es información; y la interpretación de esta información en el contexto de la situación económica actual para la toma de decisiones de inversión es conocimiento.

En la Figura 2.1 se muestra una metáfora humorística que enfatiza la importancia de presentar información.

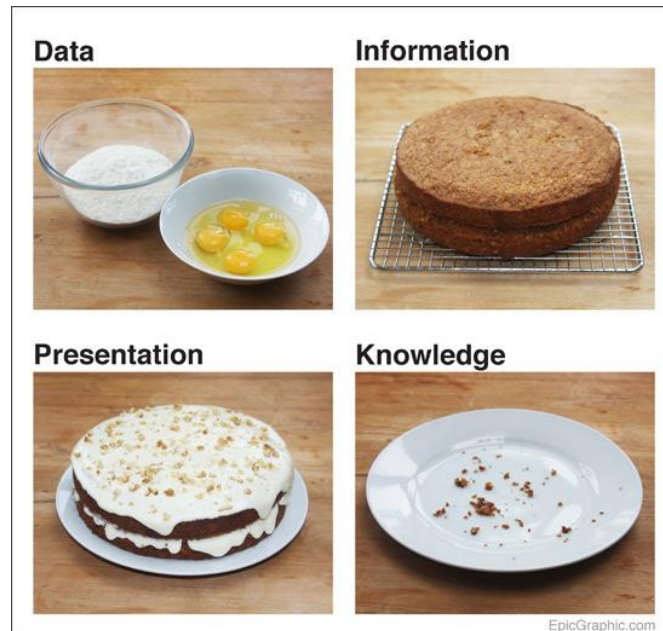


Figura 2.1: *Data Cake*. Fuente: epigraphics.com.87

Los datos utilizados en una aplicación pueden ser estructurados o no estructurados. Los datos estructurados son aquellos organizados en tablas, en las que las filas son los registros que representan las observaciones y las columnas, las variables o características observadas en cada registro, muchas veces llamados atributos. Los datos no estructurados son datos que, en su forma original, no están tabulados. Ejemplos de datos no estructurados son imágenes, sonidos, textos, estructuras gráficas, etc. En este libro, se considerarán principalmente modelos de datos estructurados. Los modelos de datos no estructurados, principalmente textos y estructuras en forma de gráficos (redes), han ido adquiriendo cada vez más importancia en la ciencia de datos [295].

Los datos estructurados se almacenan en bases de datos, desde donde se seleccionan para ajustar los modelos. En los sistemas corporativos, los datos se pueden almacenar en varias bases de datos diferentes. En este caso, la extracción de datos puede volverse extremadamente compleja y se realiza mediante procesos llamados ETL (*extract, transform and load*). En entornos más simples, la selección se realiza directamente desde la base de datos y el conjunto de datos se presenta en forma de tabla o archivo de datos.

En un conjunto de datos estructurados, cada línea o registro contiene los valores observados de un conjunto de variables. Las variables pueden ser continuas, discretas ordenadas o discretas desordenadas. Las variables continuas almacenan valores numéricos del tipo real; las variables discretas ordenadas almacenan valores enteros; mientras que las variables discretas desordenadas almacenan valores categóricos o nominales. Las variables binarias son un tipo especial de variables discretas que tienen sólo dos valores. Normalmente, un conjunto de datos puede contener variables de diferentes tipos. La mayoría de los algoritmos estadísticos y de inteligencia computacional trabajan con variables numéricas. En este caso, las variables categóricas se transforman en un conjunto de variables binarias llamadas variables indicadoras (o *dummy*).<sup>\*</sup> Existen algoritmos especializados en modelos de variables nominales; en general, esta área se conoce como aprendizaje simbólico [392][451].

En este libro, para facilitar el tratamiento matemático de los algoritmos, las variables se consideran numéricas (continuas o discretas) y las variables nominales se transforman en variables indicadoras binarias en el preprocesamiento.

Un conjunto de datos está representado por  $\mathcal{T} = \{(\mathbf{x}(t), \mathbf{y}(t)), t = 1 \dots N\}$ . Cada registro está formado por el par ordenado  $(\mathbf{x}(t), \mathbf{y}(t))$ , donde  $\mathbf{x}(t)$  es el vector <sup>†</sup> que contiene los valores de las variables de entrada y  $\mathbf{y}(t)$ , el vector que contiene los valores de las variables objetivo o de salida. Sin pérdida de generalidad, los vectores de variables de entrada y salida se escriben como  $\mathbf{x}(t) \in \mathcal{R}^p$  y  $\mathbf{y}(t) \in \mathcal{R}^q$ , donde  $p$  y  $q$  son, respectivamente, el número de variables de entrada y salida. Las variables nominales se codifican como variables indicadoras que, al igual que las variables enteras, son un subconjunto de variables reales.

Los problemas de salida múltiple ( $q > 1$ ) se pueden representar como problemas de salida simples múltiples si las variables de salida están desacopladas, es decir, el valor de una salida no interfiere con el valor de otra. En este caso, se desarrolla un modelo independiente para cada salida. En los problemas descriptivos, no hay variables de salida y el conjunto de datos contiene solo variables de entrada.

---

<sup>\*</sup> Uma variável nominal com  $n$  valores é codificada com  $n$  variáveis binárias chamadas variáveis indicadoras, em que cada variável indica a observação de um valor nominal da variável original.

<sup>†</sup> Vetores e matrizes são grafados em negrito, vetores em letras minúsculas e matrizes em letras maiúsculas. Valores escalares são grafados em itálico. Letras maiúsculas gravadas em cursiva, como  $\mathcal{A}, \mathcal{B}$  etc., indicam conjuntos. Letras gregas serão usadas para indicar parâmetros de modelos.

Algunos problemas presentan características especiales que interfieren con la interpretación del conjunto de datos. En problemas dinámicos, existe una dependencia intrínseca entre una observación y las observaciones precedentes. En este caso las variables son series de tiempo en las que los registros se presentan en secuencia y el índice  $t = 1 \dots N$  representa un instante de tiempo. Los problemas en los que el orden de las observaciones no es relevante se denominan estáticos, en cuyo caso cualquier permutación de los registros en el conjunto de datos produce el mismo resultado. En los problemas georreferenciados existe una dependencia espacial entre las observaciones y cada registro está asociado a dos (o tres) variables que representan las coordenadas de observación. Los llamados problemas espaciotemporales combinan estas dos características: contienen variables espaciales y los registros se almacenan en secuencia. Este libro no aborda específicamente problemas espaciales o espaciotemporales, sólo el modelado de sistemas dinámicos lineales en el Capítulo 4.

Para la presentación matemática de los algoritmos, el conjunto de datos se representa mediante matrices. La matriz de entrada (de variables) es la matriz  $\mathbf{X}$ , de dimensión  $N \times p$ , y la matriz de salida (de variables) es la matriz  $\mathbf{Y}$ , de dimensión  $N \times q$ . Las dimensiones de las matrices indican que los registros están organizados en líneas y, para cada registro, los vectores\* de variables de entrada y salida.

La notación presentada anteriormente se utilizará a lo largo del libro. Esta notación unifica y facilita la comprensión de algoritmos y la transposición de conceptos de modelos lineales a modelos no lineales.

La siguiente sección presenta el primer paso en la exploración de datos: caracterización y visualización de datos.

## 2.2 Caracterización estadística

La caracterización estadística de los datos es uno de los pasos más importantes en la ciencia de datos. Esta fase permite la comprensión de los datos y facilita el análisis de los resultados de los algoritmos.

---

\* Matematicamente, um vetor é uma lista de valores e pode ser tratado como linha ou coluna na multiplicação com matrizes. Neste livro são utilizados vetores linha.

Estadísticamente, un conjunto de datos se trata como una muestra de un proceso estocástico, es decir, un proceso cuyo comportamiento es impredecible, pero que puede describirse estadísticamente mediante una función de distribución de probabilidad. El concepto de muestra es muy importante en la ciencia de datos, ya que los modelos se ajustarán en función de una muestra y no del proceso estocástico. Esta es una diferencia importante entre el enfoque de inteligencia computacional y el enfoque estadístico, en el que generalmente se busca el modelado del proceso [98], basado en una hipótesis sobre la distribución de probabilidades.

La mayoría de los algoritmos de ciencia de datos asumen implícitamente que el proceso que generó la muestra representada por el conjunto de datos es estacionario, es decir, no varía con el tiempo. De esta forma, podemos utilizar un conjunto de datos recopilados en un momento determinado para hacer predicciones en otro momento, ya que el proceso sigue siendo el mismo entre el momento de la recopilación de la muestra y la predicción. Sin embargo, esta hipótesis puede no ser cierta y, en este caso, los modelos no tendrán buenos resultados de predicción. Este suele ser el caso cuando se modelan procesos altamente complejos, como los mercados financieros. La caracterización y modelado de problemas dinámicos se cubrirán en el Capítulo 4. En este capítulo, se presenta la caracterización y visualización de datos de problemas estáticos.

### 2.2.1 Análisis de una sola variable

El primer paso en la caracterización estadística de una muestra es el cálculo de las estadísticas de las variables. Un estadístico es cualquier función obtenida de una muestra. Las estadísticas de muestra, en general, se calculan para las variables de entrada del conjunto de datos, pero también se pueden calcular para las variables de salida. Las principales estadísticas son:

media, una medida del valor central de la muestra:

$$\mu \approx \bar{x}_i = \frac{1}{N} \sum_{t=1}^N x_i(t), i = 1 \dots p \quad (2.1)$$

varianza, una medida de la dispersión de la muestra:

$$Var(x_i) \approx \hat{\sigma}_i^2 = \frac{1}{N-1} \sum_{t=1}^N (x_i(t) - \bar{x}_i)^2, i = 1 \dots p \quad (2.2)$$

La desviación estándar estimada de la variable  $\hat{\sigma}_i \approx \sqrt{Var(x_i)}$  se utiliza comúnmente para caracterizar la dispersión de una variable, ya que su valor tiene la escala de la variable.

En muestras muy grandes de procesos estacionarios, la media muestral es una buena estimación de la media del proceso. Este resultado se conoce en estadística como la "ley de los grandes números". Asimismo, la varianza de la muestra converge a la varianza del proceso con el aumento en el número de registros de muestra. En conjuntos de datos pequeños, se debe tener cuidado al utilizar estas estadísticas como estimaciones de sus contrapartes de proceso.

La media y la varianza son los parámetros que definen la función de densidad de probabilidad normal  $N(\mu, \sigma^2)$ , calculada como:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \quad (2.3)$$

La Figura 2.2a presenta ejemplos de distribución normal con diferentes valores de media y desviación estándar ( $\sigma$ ). Cuanto mayor es la desviación estándar, mayor es la dispersión de los datos y, en consecuencia, menor es la probabilidad de la media. En la Figura 2.2b, las funciones de distribución de probabilidad acumulada de los ejemplos que se muestran en la Figura 2.2a.




Figura 2.2: Distribución normal: (a) función de densidad de probabilidad; (b) función de probabilidad acumulada. Fuente: Wikipedia.88

La función de distribución de probabilidad normal, o simplemente distribución normal, es muy importante en estadística. Uno de los principales resultados de la distribución normal es el teorema del límite central. El teorema establece que la distribución de la media de muestras de procesos estacionarios generadas con cualquier distribución, con media y varianza constantes, converge a una distribución normal con la media del proceso.

La distribución normal está representada matemáticamente por una función gaussiana que tiene varias propiedades y se utiliza en innumerables aplicaciones. En inteligencia computacional, la función gaussiana aparece como una función base para el desarrollo de varios tipos de modelos, como se presentará en el Capítulo 7.

Otras estadísticas importantes para la caracterización de datos son:

valores extremos: mínimo y máximo; la mediana: es el valor que divide el conjunto de datos en subconjuntos iguales, es decir, el 50% de los registros son mayores que la mediana, el 50% son menores que la mediana. La mediana es el percentil 50 de la muestra; el percentil  $P$  es el valor que divide el conjunto de datos de modo que  $P\%$  de los registros sean menores o iguales a este valor; el rango intercuartil es el intervalo entre el percentil 25 y el percentil 75, denominados respectivamente primer cuartil ( $Q1$ ) y tercer cuartil ( $Q3$ ), siendo la mediana el segundo cuartil ( $Q2$ ); la moda, calculada sólo para variables discretas, es el valor observado con mayor frecuencia.

La mediana es una medida de centralidad muestral que es insensible a distribuciones asimétricas. La media puede dar una idea engañosa del valor central de un conjunto de datos en presencia de valores atípicos (*outliers*) o distribuciones sesgadas. La comparación entre la media y la mediana permite detectar fácilmente asimetrías en la distribución de los datos. Las distribuciones asimétricas pueden generar modelos sesgados. Asimismo, las medidas de dispersión dependen de la forma de la distribución. La varianza muestral sólo tiene sentido en distribuciones simétricas; en el caso de distribuciones asimétricas se debe utilizar el rango intercuartil.

La Tabla 2.1 presenta los resultados de las estadísticas para las variables de entrada del conjunto de datos de la flor Iris. Comparando los valores medio y mediano

(percentil 50 ), se nota una asimetría en la distribución de la variable  $x_3$ . Al evaluar las estadísticas, es importante tener en cuenta la escala de las variables. En el caso de Iris Flowers, todas las variables representan una medida en centímetros y, por tanto, es posible comparar directamente los valores de diferentes variables. En el caso general, cuando las variables representan medidas diferentes, se recomienda que el análisis se realice sobre variables estandarizadas (cf. sección 2.3.1).

Tabla 2.1: Estadísticas básicas del problema Iris

|              | $x_1$ | $x_2$ | $x_3$ | $x_4$ |
|--------------|-------|-------|-------|-------|
| Mínimos      | 43,0  | 20,0  | 10,0  | 1,0   |
| Máximos      | 79,0  | 44,0  | 69,0  | 25,0  |
| Médias       | 58,4  | 30,6  | 37,6  | 12,0  |
| Desvios      | 8,3   | 4,4   | 17,7  | 7,6   |
| Percentil 25 | 51,0  | 28,0  | 16,0  | 3,0   |
| Percentil 50 | 58,0  | 30,0  | 43,5  | 13,0  |
| Percentil 75 | 64,0  | 33,0  | 51,0  | 18,0  |

En problemas de clasificación es interesante evaluar variables por clase. El gráfico de líneas permite una evaluación visual de las diferencias entre los registros de cada variable por clase y puede ayudar a identificar las variables más relevantes para la separación de clases. En el gráfico de líneas, cada variable es un valor en el eje horizontal y cada registro es una línea que conecta las variables en su valor correspondiente. La Figura 2.3 muestra un ejemplo de un gráfico de líneas para el conjunto de datos Iris con variables estandarizadas (consulte la sección 2.3.1). Podemos observar que las clases se pueden separar mejor en el plano formado por las variables  $x_3$  y  $x_4$ . Esta misma conclusión será confirmada por otros tipos de gráficos mostrados.




Figura 2.3: Gráficos lineales del problema del iris.



Existen varias funciones de distribución de probabilidad<sup>89</sup>, con aplicaciones en diferentes áreas. La distribución de cada variable se puede evaluar cualitativamente mediante histogramas o diagramas de frecuencia. Un histograma es una representación gráfica de la distribución de probabilidad de la variable (cf. Figura 2.4). Existen varios métodos estadísticos para ajustar la función de distribución de probabilidad [146][238], así como libros completos dedicados al tema [482][490].




Figura 2.4: Histogramas y ajuste de distribución.

Las técnicas de inteligencia computacional generalmente no toman en cuenta hipótesis sobre la distribución de probabilidad que generó la muestra. Sin embargo, el análisis de histogramas es esencial para comprender los datos y respaldar el análisis de los resultados del modelo. La evaluación visual de los histogramas puede revelar características indeseables en la distribución de datos, como asimetría y distribuciones multimodales (cf. Figura 2.5). En estos casos, las estimaciones de la media y la desviación estándar pueden perder completamente su significado.




Figura 2.5: Histogramas: (a) distribución asimétrica; (b) distribución multimodal.

En problemas de clasificación se pueden calcular histogramas por clase, lo que permite analizar la distribución de cada clase en el universo de la variable. Los histogramas separados por clases de las variables en el conjunto de datos Iris se muestran en la Figura 2.6. En este ejemplo, los datos están más mezclados en las variables  $x_1$  y  $x_2$  que en las variables  $x_3$  y  $x_4$ , como se ve en el gráfico lineal de la Figura 2.3. Las variables  $x_3$  y  $x_4$  presentan un comportamiento multimodal. Sin embargo, al separar por clases se verifica que cada concentración de datos corresponde a una clase, lo que puede ser de gran utilidad para construir clasificadores.




Figura 2.6: Histogramas de distribuciones de variables por clase en el problema Iris.

Es posible comprobar cualitativamente si una muestra fue generada mediante un proceso de distribución normal a través del gráfico de probabilidad normal. En este tipo de gráfico, si la muestra fue generada por un proceso de distribución normal, los puntos aparecen alineados; en el caso de una distribución no normal, hay una curvatura en el gráfico. La Figura 2.7 presenta los histogramas de una muestra de dos variables y las respectivas gráficas de distribución normal. Las figuras 2.7a y 2.7c muestran la distribución de una

variable que puede representarse mediante un proceso de distribución normal; Las figuras 2.7b y 2.7d muestran la distribución de una variable generada por un proceso que no corresponde a la distribución normal.




Figura 2.7: Histogramas y gráficos de probabilidad normal: (a) y (c) muestra generada por distribución normal; (b) y (d) muestra generada por distribución no normal.

### 2.2.2 Análisis multivariado

Analizar las características de cada variable es importante, pero también es necesario considerar las características multivariadas del proceso.

El principal estadístico multivariado estimado a partir de una muestra es la matriz de covarianza  $\hat{\Sigma} \in \mathcal{R}^{p \times p}$ , cuyos elementos  $\hat{\sigma}_{ij}^2 = Cov(x_i, x_j)$  se calculan como:

$$Cov(x_i, x_j) \approx \hat{\Sigma} = \frac{1}{N-1} \sum_{t=1}^N (x_i(t) - \bar{x}_i)(x_j(t) - \bar{x}_j), i = 1 \dots p, j = 1 \dots p \quad (2.4)$$

donde  $\bar{x}_i$  y  $\bar{x}_j$  son, respectivamente, los promedios calculados para cada variable.

La estimación de la matriz de covarianza se puede calcular directamente mediante la expresión vectorial:

$$\hat{\Sigma} = \frac{1}{N-1} \sum_{t=1}^N (\mathbf{x}(t) - \bar{\mathbf{x}})^T (\mathbf{x}(t) - \bar{\mathbf{x}}) \quad (2.5)$$

donde  $\bar{\mathbf{x}} \in \mathcal{R}^p$  es el vector de medias de las variables en el que cada componente es la media de cada variable definida por la ecuación (2.1).

Al igual que la varianza, la matriz de covarianza de la muestra converge con la matriz de covarianza del proceso cuando aumenta el número de registros de muestra. La matriz de covarianza es simétrica ( $\hat{\sigma}_{ij}^2 = \hat{\sigma}_{ji}^2$ ) y está definida positivamente; \* los elementos de la diagonal de la matriz de covarianza corresponden a las varianzas de las variables correspondientes, es decir,  $\hat{\sigma}_{ii}^2 = \hat{\sigma}_i^2$ , donde  $\hat{\sigma}_i^2$  se calcula mediante la ecuación (2.2).

La matriz de covarianza  $\Sigma$  y el vector de media variable  $\mu$  son los parámetros que determinan la función de distribución normal multivariada del proceso:

$$f(\mathbf{x}) = \frac{1}{\sqrt{2\pi|\Sigma|}} \exp\left(-\frac{1}{2}(\mathbf{x} - \mu)\Sigma^{-1}(\mathbf{x} - \mu)^T\right) \quad (2.6)$$

donde  $|\Sigma|$  es el determinante de la matriz de covarianza. En la práctica, la distribución normal se calcula mediante la ecuación (2.6) con la matriz de covarianza estimada  $\hat{\Sigma}$  y el vector medio estimado  $\bar{\mathbf{x}}$

La matriz de covarianza indica el grado de acoplamiento de cada par de variables. Si las variables son estadísticamente independientes, es decir, la variación de una variable no influye en la variación de la otra, los términos fuera de la diagonal de la matriz de covarianza son nulos, es decir,  $\hat{\sigma}_{ij}^2 = 0$ , a  $i \neq j$ . Cuando existe dependencia lineal entre variables, los elementos  $\hat{\sigma}_{ij}^2 > 0$  indican dependencia lineal positiva, cuando las variaciones son en la misma dirección, y  $\hat{\sigma}_{ij}^2 < 0$  indican dependencia lineal negativa, cuando las variaciones ocurren en direcciones opuestas.

La matriz de covarianza depende de la escala de las variables y, en general, es más apropiado utilizar valores estandarizados. coeficiente de correlación de Pearson, o simplemente

---

\* Una matriz  $\mathbf{A}$  é definida positiva se  $\mathbf{x}\mathbf{A}\mathbf{x}^T > 0, \forall \mathbf{x}$ .

coeficiente de correlación, es una medida estandarizada de la covarianza de dos variables y se calcula como:

$$\text{Corr}(x_i, x_j) \approx \hat{\rho}_{ij} = \frac{\text{Cov}(x_i, x_j)}{\sqrt{\text{Var}(x_i)\text{Var}(x_j)}} \quad (2.7)$$

El coeficiente de correlación varía en el intervalo  $[-1, 1]$  y cuanto más cercano esté el valor absoluto a 1, más correlacionadas están las variables, positiva o negativamente. La matriz de correlación es la matriz cuyos elementos son los coeficientes de correlación  $\hat{\rho}_{ij}$ .

Los gráficos de proyección, que se muestran en la Figura 2.8, ilustran la aparición de variables independientes con correlación positiva o negativa.




Figura 2.8: Gráfico de proyección de variables: (a)  $\hat{\rho}_{ij} = 0$ ; (b)  $\hat{\rho}_{ij} > 0$ ; (c)  $\hat{\rho}_{ij} < 0$ .

El coeficiente de correlación representa una medida de redundancia entre dos variables. Las variables totalmente correlacionadas (positiva o negativamente) representan esencialmente la misma información y una de ellas podría descartarse. Sin embargo, excepto en el caso de correlación total, no es posible decidir qué variable eliminar basándose únicamente en la información de correlación. El análisis de componentes principales (PCA), presentado en la sección 2.4.1, tiene como objetivo proyectar el conjunto de datos en un espacio de dimensiones inferiores de variables independientes.

Es importante señalar que el coeficiente de correlación solo mide la dependencia lineal, por lo tanto un resultado  $\hat{\rho}_{ij} = 0$  no representa que no exista relación entre las variables, solo que la relación no es lineal.

La correlación entre las variables también se puede visualizar a través de los gráficos de proyección de las variables en los planos bidimensionales formados por la combinación de todas

las variables de dos en dos. Esta gráfica, también llamada matriz *scatter plot*, presenta los histogramas en diagonal.

El gráfico de proyección para el conjunto de datos Iris se presenta en la Figura 2.9, en la que los colores indican las clases. El gráfico presenta información redundante ya que los gráficos de la diagonal superior son los mismos que los de la diagonal inferior con los ejes intercambiados. El gráfico de proyección también confirma que las clases están más separadas en el plano formado por las variables  $x_3$  y  $x_4$ .




Figura 2.9: Gráfico de proyección del conjunto de datos Iris.

Los gráficos de proyección son una herramienta de visualización importante, pero su uso requiere precauciones. Inicialmente, es importante señalar que cada gráfico presenta una proyección del espacio variable en un plano bidimensional. Por lo tanto, los datos, especialmente en los problemas de clasificación, parecen más variados de lo que realmente son. En problemas con una gran cantidad de variables, ver el gráfico de proyección se vuelve muy difícil. En problemas de este tipo es más apropiado utilizar una visualización cualitativa de la matriz de correlación, como se muestra en la Figura 2.10 para el caso del problema de la Ionosfera,<sup>90</sup> que tiene  $p = 32$  variables.




Figura 2.10: Visualización cualitativa de la matriz de correlación en el problema de la Ionosfera.

### 2.2.3 Matriz de distancia y similitud

El análisis multivariado presentado anteriormente se realiza principalmente a partir del cálculo de la matriz de correlación entre las variables. La correlación entre dos variables puede entenderse como una medida de similitud entre ellas. La evaluación de la similitud (o distancia) entre registros puede revelar características importantes del conjunto de datos, como la presencia de *outliers*, por ejemplo. Las medidas de distancia también se utilizan para completar los valores faltantes (consulte la sección 2.3.3) y en la mayoría de los algoritmos de análisis de conglomerados. En esta sección presentamos una introducción a las métricas de distancia en el caso de variables numéricas.

Una función de distancia es una métrica  $dist: \mathcal{R}^p \times \mathcal{R}^p \rightarrow \mathcal{R}$  si satisface las siguientes propiedades [516]:

- a) no negatividad:  $dist(\mathbf{v}, \mathbf{u}) \geq 0, \forall \mathbf{v}, \mathbf{u} \in \mathcal{R}^p$ ,  
 $dist(\mathbf{v}, \mathbf{u}) = 0, \forall \mathbf{v} = \mathbf{u}$ ; b) simetría:  
 $dist(\mathbf{v}, \mathbf{u}) = dist(\mathbf{u}, \mathbf{v}), \forall \mathbf{v}, \mathbf{u} \in \mathcal{R}^p$ ; c) desigualdad triangular:  
 $dist(\mathbf{v}, \mathbf{\xi}) \leq dist(\mathbf{v}, \mathbf{u}) + dist(\mathbf{u}, \mathbf{\xi}), \forall \mathbf{v}, \mathbf{u}, \mathbf{\xi} \in \mathcal{R}^p$ .

Las funciones de similitud también se utilizan en algoritmos de análisis y agrupamiento *outliers*. Una función de similitud  $sim: \mathcal{R}^p \times \mathcal{R}^p \rightarrow [0,1]$  satisface la propiedad de no negatividad, con  $sim(\mathbf{v}, \mathbf{u}) = 1$ , sólo si  $\mathbf{v} = \mathbf{u}$ , y la propiedad

de simetría. Sin embargo, no todas las funciones de similitud satisfacen la propiedad de desigualdad triangular y no pueden considerarse métricas.

En la ciencia de datos se utilizan varias funciones de distancia. Los más importantes son:

Distancia euclidiana (o norma  $L^2$ ): es la extensión de la fórmula de la geometría clásica a  $p$  dimensiones:

$$dist_E(\mathbf{v}, \mathbf{u}) = \|\mathbf{v} - \mathbf{u}\| = \sqrt{\sum_{i=1}^p (v_i - u_i)^2} \quad (2.8)$$

Distancia de Mahalanobis: es la distancia geométrica ponderada por la inversa de la matriz de covarianza estimada en el conjunto de datos:

$$dist_{\Sigma}(\mathbf{v}, \mathbf{u}) = \sqrt{(\mathbf{v} - \mathbf{u})\hat{\Sigma}^{-1}(\mathbf{v} - \mathbf{u})^T} \quad (2.9)$$

Distancia de Minkowski: es una generalización de la distancia euclidiana:

$$dist_r(\mathbf{v}, \mathbf{u}) = \left( \sum_{i=1}^p |v_i - u_i|^r \right)^{\frac{1}{r}} \quad (2.10)$$

Distancia Manhattan (norma  $L^1$ ): es un caso particular de la distancia Minkowski con  $r = 1$ :

$$dist_1(\mathbf{v}, \mathbf{u}) = \sum_{i=1}^p |v_i - u_i| = \sum_{i=1}^p \text{abs}(v_i - u_i) \quad (2.11)$$

Distancia de Chebyshev (norma  $L^\infty$ ): es la distancia de Minkowski con  $r \rightarrow \infty$ :

$$dist_\infty(\mathbf{v}, \mathbf{u}) = \lim_{r \rightarrow \infty} \left( \sum_{i=1}^p |v_i - u_i|^r \right)^{\frac{1}{r}} = \max_i (|v_i - u_i|) \quad (2.12)$$

Las funciones de similitud más utilizadas son:

similitud coseno:

$$sim_c(\mathbf{v}, \mathbf{u}) = \frac{\langle \mathbf{v}, \mathbf{u} \rangle}{\|\mathbf{v}\| \|\mathbf{u}\|} \quad (2.13)$$



donde  $\langle \mathbf{v}, \mathbf{v} \rangle = \mathbf{v} \mathbf{v}^T = \sum_{i=1}^p v_i v_i$  es el producto escalar y  $\|\mathbf{v}\| = \sqrt{\langle \mathbf{v}, \mathbf{v} \rangle}$  es la norma cuadrática ( $L^2$ ) de  $\mathbf{v}$ ;

Similitud gaussiana:

$$sim_G(\mathbf{v}, \mathbf{v}) = \exp\left(-\frac{\|\mathbf{v} - \mathbf{v}\|^2}{2\sigma^2}\right) \quad (2.14)$$

donde  $\sigma$  es un parámetro de dispersión.

Para cada función de distancia (o similitud), es posible calcular una matriz de distancias (o similitudes) a partir del conjunto de datos. En general, solo se utilizan las variables de entrada para la detección *outliers*, para completar los valores faltantes o para el análisis de conglomerados. Por tanto, la matriz de distancias calculada sobre el conjunto de entrenamiento  $\mathcal{T} = \{\mathbf{x}(t), t = 1 \dots N\}$  es la matriz  $\mathbf{D} \in \mathcal{R}^{N \times N}$ , en la que cada elemento  $d_{ij} = dist(\mathbf{x}(i), \mathbf{x}(j))$ . De manera similar, la matriz de similitud  $\mathbf{A} \in [0,1]^{N \times N}$  y cada elemento  $a_{ij} = sim(\mathbf{x}(i), \mathbf{x}(j))$ .

Considerando que la matriz de distancias (o similitud) es simétrica, el cálculo de los elementos de la matriz triangular implica operaciones  $N(N-1)/2$ . La complejidad computacional  $\mathcal{O}(N^2)$  puede ser un problema en el caso de  $N$  muy grande.

La visualización de la matriz de similitud (o distancia) permite el análisis de todo el conjunto de datos, independientemente del número de variables. El gráfico, denominado **data image**, es una matriz del número de registros en la que cada elemento es un valor en una escala de colores que representa la distancia o similitud entre los registros correspondientes. *data image* se utiliza para detectar *outliers* [365] y evaluar la calidad de los grupos [239].

La Figura 2.11 presenta un ejemplo de visualización del conjunto de datos Iris utilizando la distancia euclidiana y la similitud gaussiana. El conjunto de datos contiene 50 registros de cada clase y todos los registros están ordenados por clase. En la Figura 2.11, podemos observar la presencia de tres grupos de registros que son fuertemente similares entre sí, representados por los tres cuadrados azules (rojos) en la Figura 2.11a (Figura 2.11b), que representan valores bajos (altos) de distancias (similitudes). Observando el gráfico de proyección de la Figura 2.9, es posible verificar que, en el problema de Iris, la clase 1 (*Iris setosa*) está separada de las demás y que la clase 2 (*Iris versicolor*) y la clase 3 (*Iris virginica*)

están más cerca unos de otros. El mismo efecto se puede observar en los gráficos de la Figura 2.11, donde las clases 2 y 3 prácticamente forman un grupo de datos.




Figura 2.11: *Data image*. (a) distancia euclidiana; (b) Similitud gaussiana.

Existen otros gráficos que permiten analizar un conjunto de datos. De hecho, la visualización de datos es un área de investigación muy activa [490].

Después de la caracterización estadística, el conjunto de datos debe procesarse previamente para formar el conjunto de entrenamiento para ajustar los modelos, como se describe a continuación.

## 2.3 Limpieza de datos

El proceso de extracción de datos (cf. Figura 1.1) comienza con la selección del conjunto de datos sin procesar de la base de datos. El conjunto de datos sin procesar no es adecuado para ajustar modelos ya que puede contener variables irrelevantes, valores espurios (*outliers*) o faltantes, variables redundantes o algún otro tipo de problema específico.

Un análisis preliminar del conjunto de datos puede identificar si alguna variable de entrada no interfiere con el problema al tener todos valores idénticos ( $\hat{\sigma}_i = 0$ ). En este caso, se debe eliminar esta variable (en realidad una constante). Otro problema común es la presencia de una variable que simplemente identifica los registros, la cual tampoco contribuye al modelo, por lo que debe descartarse.

En esta sección, presentamos algunos procedimientos genéricos que se emplean como práctica estándar en ciencia de datos. Puede ser necesario un procesamiento más específico dependiendo de la aplicación.

### 2.3.1 Padronização de variáveis

El conjunto de datos brutos suele contener variables expresadas en diferentes escalas, lo que puede interferir con los resultados de los algoritmos. La estandarización es una transformación cuyo objetivo es producir variables de la misma escala.

Existen varias técnicas de estandarización. En el caso más simple, los valores de las variables se escalan en el intervalo  $[0,1]$ , por los valores máximo y mínimo:

$$\hat{x}_i(t) = \frac{x_i(t) - \min_{t=1 \dots N} (x_i(t))}{\max_{t=1 \dots N} (x_i(t)) - \min_{t=1 \dots N} (x_i(t))} \quad (2.15)$$

Este tipo de estandarización, sin embargo, no debe utilizarse en presencia de *outliers*, ya que el máximo o mínimo de alguna variable puede estar muy alejado de los demás valores, generando una distorsión en la escala de valores estandarizados. En presencia de *outliers*, el máximo y el mínimo pueden sustituirse por los valores del percentil 95º y el percentil 5º, respectivamente, o por otros valores más apropiados para representar los límites superior e inferior de la escala.

Existen otros tipos de estandarización que son robustos a *outliers*. La estandarización mediante estimación *z-score* se usa ampliamente y se calcula como:

$$\hat{x}_i(t) = \frac{x_i(t) - \bar{x}_i}{\hat{\sigma}_i} \quad (2.16)$$

En este caso, la variable estandarizada tiene media cero y desviación estándar unitaria. En algunos casos, suponiendo que la distribución de la variable puede modelarse mediante la distribución normal (2.3), se aplica  $3\hat{\sigma}_i$  en el denominador. Por tanto, si la distribución es verdaderamente normal, el 99,7% de los valores de la variable estandarizada estarán dentro del intervalo  $[-1, +1]$ . Esta estandarización es sólida para *outliers*, pero en distribuciones altamente asimétricas puede generar distorsión de escala, ya que utiliza estadísticas de media y desviación estándar, que son más apropiadas para distribuciones simétricas.

En distribuciones asimétricas, como la de la Figura 2.5a, es común aplicar la transformación logarítmica para obtener una distribución simétrica, que es más adecuada para el desarrollo de modelos. La transformación logarítmica no se puede aplicar si la variable contiene valores negativos o nulos. En este caso, simplemente agregue una constante mayor que el valor mínimo de la variable a todos los valores.

Las ecuaciones (2.15) y (2.16) son lineales y pueden invertirse si es necesario. Existen fórmulas de estandarización no lineales que no se pueden invertir.

### 2.3.2 detección *outliers*

Detectar y eliminar valores espurios (*outliers*) es un procedimiento importante ya que estos valores pueden dañar el rendimiento del modelo. Sin embargo, en problemas de detección de anomalías, como el fraude [54], por ejemplo, el descubrimiento de *outliers* es la solución al problema. Por tanto, el analista debe evaluar la aplicación y comprobar cuándo *outliers* es realmente no deseado.

Existen varios métodos para detectar *outliers* y la literatura sobre el tema es extensa [54][270]. En esta sección se exploran dos enfoques principales: el enfoque basado en la distribución y el enfoque basado en la distancia. El enfoque basado en la distribución es el enfoque clásico de la estadística, que requiere una hipótesis sobre la función de distribución de probabilidad de la muestra para determinar *outliers*. En el enfoque basado en la distancia, se utiliza una función de distancia o similitud para determinar los registros más distantes en el conjunto de datos, sin considerar la distribución que generó la muestra. El enfoque basado en la distribución generalmente se emplea en cada variable de forma independiente. El enfoque basado en la distancia considera todas las variables, pero implica el costo computacional de calcular la matriz de distancia.

El método más sencillo para detectar *outliers* es estimar una distribución normal para cada variable. La validez de la hipótesis de la distribución normal se puede verificar a partir de gráficos de distribución normal (ver Figura 2.7). Si se confirma la hipótesis, se sabe que, en una distribución normal, el 99,7% de los registros se encuentran dentro del intervalo  $[\mu - 3\sigma, \mu + 3\sigma]$ . *outliers* se identifican como registros que contienen valores fuera de este rango.

En caso de que la distribución de variables sea diferente a la distribución normal, se puede utilizar la herramienta gráfica conocida como **box-plot** para detectar posibles *outliers* a partir de los valores percentiles. La gráfica *box-plot* está formada por cuadros, como se muestra en la Figura 2.12, que se calculan para cada variable. El cuadro representa la llamada distancia intercuartil (IRQ), que es la diferencia entre el valor del percentil 75 o tercer cuartil ( $Q3$ ) y el valor del percentil 25 o primer cuartil ( $Q1$ ). desde la distancia

intercuartil representa el rango de valores de la variable en el que se encuentran el 50% de los registros. La línea roja dentro del cuadro representa la mediana (percentil 50) y permite identificar distribuciones asimétricas si no está ubicada en el centro del cuadro. La línea a la derecha del cuadro representa el rango  $[Q3, Q3 + 1,5IRQ]$  y la línea a la izquierda representa el rango  $[Q1 - 1,5IRQ, Q1]$ . Puede suceder que el valor más grande (o más pequeño) observado sea menor (o mayor) que el límite del rango y las líneas a la izquierda y a la derecha sean desiguales. Los valores fuera de estos rangos se marcan en rojo y pueden considerarse *outliers* para la variable correspondiente. Dependiendo de *software*, los cuadros pueden aparecer en vertical u horizontal y con todas las variables en un mismo gráfico o un gráfico para cada variable.




Figura 2.12: Valores para el edificio *box-plot*.

*box-plot* depende de la escala de las variables y si el problema contiene variables en diferentes escalas, es preferible su evaluación después de la estandarización. La Figura 2.13 presenta *box-plot* del problema Iris antes y después de la estandarización de variables, donde se puede observar el efecto de la estandarización sobre la dispersión de variables.




Figura 2.13: *Box-plot* para el problema Iris: (a) sin estandarización; (b) con estandarización.

*box-plot* permite identificar sólo registros sospechosos de ser *outliers*, ya que el análisis se realiza para cada variable de forma independiente. Los registros marcados por *box-plot* como *outliers* en una variable no deben eliminarse sin una evaluación previa de los valores en las otras variables.

Visualizar *box-plot* puede ayudar con la caracterización estadística del conjunto de datos, pero no es muy adecuado para detectar *outliers*. Los métodos basados en la distancia son más eficaces, ya que consideran todas las variables simultáneamente.

Un método sencillo y muy eficaz identifica *outliers* a partir del promedio ordenado  $\hat{m}_i$  de las distancias desde un registro  $\mathbf{x}(i)$  a todos los demás, calculado a partir de la matriz de distancias  $\mathbf{D}$ . Los *outliers* se identifican mediante valores  $\hat{m}_i > \delta$ , donde el parámetro  $\delta$  se identifica mediante un análisis visual de las distancias promedio ordenadas. La evaluación del límite de corte se puede evitar especificando un porcentaje  $P_{out}$  de los registros más lejanos que se eliminarán, que es más fácil de elegir. El procedimiento se describe en el Algoritmo 2.1.

La detección de *outliers* también se puede realizar con la matriz de similitud, lo que puede dar resultados diferentes. En este caso los valores promedio  $m_i$  se calculan por la similitud promedio, el ordenamiento se realiza en orden descendente y el criterio de detección es  $\hat{m}_i < \delta$  o los  $P_{out}$  registros menos similares.

Algoritmo 2.1: Retiro de *outliers*

|                 |                                                                                               |
|-----------------|-----------------------------------------------------------------------------------------------|
| <b>Entrada:</b> | Matriz de distâncias $\mathbf{D}$ , porcentagem $P_{out}$ de <i>outliers</i> a ser retirada   |
| <b>Saída:</b>   | Índice de registros <i>outliers</i>                                                           |
| 01              | <b>Início</b>                                                                                 |
| 02              | Calcule das distâncias médias $m_i = \frac{1}{N} \sum_{j=1}^N d_{ij}$                         |
| 03              | Ordene as distâncias médias $\hat{\mathbf{m}} = \text{sort}(\mathbf{m})$ , em ordem crescente |
| 04              | Retorna o índice dos $P_{out}$ registros correspondentes aos maiores valores de $\hat{m}_i$   |
| 05              | <b>Fim</b>                                                                                    |

El procedimiento para detectar *outliers* por distancia se presenta a continuación para el conjunto de datos *Pollution*.<sup>91</sup> Este es un problema clásico de regresión lineal con 15

variables de entrada, una variable de salida y sólo 60 registros. La presencia de *outliers* en el conjunto de datos se verifica en *data image* de la Figura 2.14a, en la que un registro (más precisamente el registro  $t = 8$ ) es muy diferente de los demás, ya que la distancia de este registro a los demás tiene un tono rojo fuerte.




Figura 2.14: Matriz de distancias euclidianas para el problema de la contaminación: (a) antes de eliminar los valores atípicos; (b) después de eliminar los valores atípicos.

El promedio ordenado de las distancias se muestra en la Figura 2.15a, en la que se puede observar que cuatro registros están identificados como *outliers*. La Figura 2.15b muestra los valores de similitud promedio relativos calculados con similitud gaussiana. Después de eliminar *outliers* (por distancia euclidiana), la matriz de distancias presenta una configuración más homogénea, como se muestra en *data image* de la Figura 2.14b.




Figura 2.15: Detección de *outliers*: (a) distancias euclidianas promedio en orden ascendente; (b) Promedios de similitud gaussiana en orden descendente.

### 2.3.3 Valores ausentes

Un valor faltante ocurre en alguna variable cuando el valor no se pudo observar o se observó pero no se almacenó. El manejo de valores faltantes es una cuestión importante en la ciencia de datos, ya que los conjuntos de datos reales a menudo tienen valores faltantes [232]. Es importante enfatizar que un valor faltante es diferente de un valor cero, en el cual el valor observado es conocido e igual a cero. La codificación de los valores faltantes en la base de datos debe realizarse de tal manera que el código utilizado para el valor faltante no se confunda con un posible valor de la variable. En muchos conjuntos de datos, los valores faltantes están codificados por el carácter '?'.

Hay dos estrategias para tratar los valores faltantes: eliminar el registro que contiene los valores faltantes o completar (o imputar) los datos faltantes. En la primera estrategia se debe considerar el impacto de eliminar registros que contienen valores faltantes. Para ello, es importante encuestar la cantidad de valores faltantes en cada variable. Puede suceder que la mayoría de los valores faltantes estén en una sola variable, en cuyo caso eliminar la variable puede ser una alternativa.

Visualizar valores faltantes en un conjunto de datos puede revelar una falla en la adquisición de datos cuando los valores faltantes muestran algún patrón característico. El gráfico de la Figura 2.16 muestra la posición de los valores faltantes de las 22 variables de entrada en el conjunto de datos *Water Treatment Plant*.<sup>92</sup> El eje horizontal representa los registros, el eje vertical representa las variables y los valores faltantes se representan en negro. El número de valores faltantes en cada variable se presenta en el gráfico de la Figura 2.17. El conjunto de datos contiene 527 registros, de los cuales 115 (aproximadamente el 22%) contienen algún valor faltante.




Figura 2.16: Visualización de valores faltantes.






Figura 2.17: Valores faltantes por variable.

En el conjunto de datos *Water Treatment Plant*, la reducción del 22 % en los registros no hace que el análisis sea completamente inviable y se puede optar por eliminar los registros con valores faltantes o realizar una imputación de datos. Sin embargo, existen problemas en los que no existe ninguna opción para la imputación de datos.

La dificultad con la imputación de datos es la introducción de nueva información que no necesariamente representa la realidad. Se introduce un error que puede tener un impacto significativo en el rendimiento del modelo. El tema es complejo y existen varias técnicas para imputar datos faltantes [525][498].

La técnica más ingenua para la imputación de datos es reemplazar el valor faltante con la media. Aunque sencilla, esta solución no presenta buenos resultados, especialmente si el número de valores faltantes es grande. La opción más recomendable es utilizar algún método predictivo en función de los valores del resto de variables. Sin embargo, el desarrollo de modelos muy elaborados para la imputación de datos no es muy interesante y es mejor utilizar una solución sencilla.

Una solución simple y sólida para la imputación de datos es utilizar el método de vecinos más cercanos  $k$ , presentado en el Algoritmo 2.2. El algoritmo utiliza como base para la imputación de datos el conjunto de registros sin valores faltantes definido en el paso 02. La estimación de los valores faltantes se calcula mediante el promedio de los vecinos más cercanos  $k$  del conjunto de datos completo. El promedio de los vecinos, calculado en el paso 08 del algoritmo, puede ser un promedio simple o ponderado por valores proporcionales a la inversa de la distancia a los vecinos. El algoritmo depende de elegir el número  $k$  de vecinos. Se recomienda utilizar vecinos  $k \geq 3$ .

Algoritmo 2.2: imputación de datos utilizando el método de vecinos más cercanos  $k$

|                 |                                                                                                                              |
|-----------------|------------------------------------------------------------------------------------------------------------------------------|
| <b>Entrada:</b> | Variáveis de entrada $\{\mathbf{x}(t), t = 1 \dots N\}$ contendo valores ausentes, número de vizinhos $k$                    |
| <b>Saída:</b>   | Variáveis de entrada sem valores ausentes                                                                                    |
| 01              | <b>Início</b>                                                                                                                |
| 02              | Defina $\{\mathbf{z}(t), t = 1 \dots N'\}$ o conjunto de dados completos                                                     |
| 03              | <b>Para</b> cada registro $i$ contendo algum valor ausente                                                                   |
| 04              | Defina $\mathbf{x}^*(i) \subset \mathbf{x}(i)$ o vetor cujas componentes não contêm valor ausente no registro $i$            |
| 05              | Defina $\mathbf{z}^*(j) \subset \mathbf{z}(j)$ o vetor de registros completos com as mesmas componentes de $\mathbf{x}^*(i)$ |
| 06              | Calcule as distâncias $d_{ij} = \text{dist}(\mathbf{x}^*(i), \mathbf{z}^*(j)), j = 1 \dots N'$                               |
| 07              | Ordene as distâncias $\hat{d}_{ij} = \text{sort}(d_{ij})$                                                                    |
| 08              | Calcule os valores ausentes $\mathbf{x}(i)$ pela média das componentes dos $k$ -vizinhos mais próximos                       |
| 09              | <b>Fim Para</b>                                                                                                              |
| 10              | Retorna $\{\mathbf{x}(t), t = 1 \dots N\}$ sem valores ausentes;                                                             |
| 11              | <b>Fim</b>                                                                                                                   |

La aplicación del Algoritmo 2.2 nos permite obtener un conjunto completo de datos. Sin embargo, la imputación de datos cambia ligeramente las características de los datos. En el ejemplo del conjunto de datos *Water Treatment Plant*, la Figura 2.18 presenta la comparación de los histogramas de la variable  $x_{11}$ , que contiene la mayor cantidad de valores faltantes (c.f. Figura 2.17), con la imputación de datos y la eliminación de valores faltantes. La diferencia entre los dos histogramas es pequeña.

El método de los  $k$  vecinos más cercanos se puede utilizar en problemas predictivos, como clasificación y regresión, y se ha utilizado ampliamente en sistemas de recomendación llamados filtrado colaborativo.




Figura 2.18: Histogramas de la variable  $x_{11}$  del problema Planta de Tratamiento de Residuos: (a) con imputación de datos; (b) con eliminación de los valores faltantes.

## 2.4 Transformaciones lineales

Una transformación lineal [206]  $\mathbf{T}: \mathcal{R}^n \rightarrow \mathcal{R}^m$  está definida por una matriz de dimensión  $n \times m$ . La transformación  $\mathbf{T}$ , aplicada al vector  $\mathbf{x} \in \mathcal{R}^n$ , obtiene como resultado (imagen) el vector  $\mathbf{z} \in \mathcal{R}^m$ , donde  $\mathbf{z} = \mathbf{x}\mathbf{T}$ .

El uso de matrices para calcular transformaciones lineales permite modificar una transformación mediante operaciones en la matriz. Por ejemplo, si la matriz  $\mathbf{T}$  admite inversa, la matriz  $\mathbf{z} \mathbf{T}^{-1}$  realiza la transformación inversa  $\mathbf{x} = \mathbf{z} \mathbf{T}^{-1}$ . La figura 2.19 presenta un ejemplo de una transformación lineal y su inversa.




Figura 2.19: Ejemplo de transformación lineal.

Una transformación lineal ortogonal  $\mathbf{U}: \mathcal{R}^n \rightarrow \mathcal{R}^n$  es un tipo particular de transformación lineal que realiza una rotación del espacio de entrada. La transformación ortogonal se realiza mediante una matriz ortogonal, cuya inversa es su transpuesta:  $\mathbf{U}^{-1} = \mathbf{U}^T$ . Agregar

Finalmente, los vectores formados por las columnas de una matriz ortogonal son ortogonal entre sí, es decir, el producto escalar es igual a cero. La figura 2.20 presenta un ejemplo de transformación ortogonal y su inversa.




Figura 2.20: Ejemplo de transformación lineal ortogonal.

Las transformaciones lineales tienen numerosas aplicaciones en ingeniería. En ciencia de datos se utiliza una transformación lineal para cambiar las coordenadas de las variables de entrada, generalmente de menor dimensionalidad, y con características más adecuadas al problema. Las variables transformadas son combinaciones lineales de las variables de entrada y, en general, no se pueden interpretar. En esta sección se presentan las principales técnicas de transformación lineal.

#### 2.4.1 Análisis de componentes principales

El objetivo del análisis de componentes principales (PCA), también conocido como transformación de Karhunen-Loève [521], es encontrar una transformación lineal que elimine la correlación entre las variables de entrada [366][449]. PCA permite reducir la dimensionalidad del conjunto de datos eliminando la redundancia provocada por la correlación entre variables. PCA se realiza mediante una matriz de transformación lineal ortogonal que, cuando se aplica al conjunto de datos, genera un nuevo conjunto de datos de variables transformadas no correlacionadas.

La formulación del PCA considera que todas las variables de entrada son numéricas, con distribución normal. El cálculo de la matriz de transformación debe realizarse sobre datos centrados en el origen del sistema de coordenadas, el cual se puede obtener estandarizando por *z-scores* (2.16). En este caso, la matriz de covarianza estimada es la misma que la matriz de correlación y se calcula como  $\hat{\Sigma} = \frac{1}{N-1} \mathbf{X}^T \mathbf{X}$ , donde  $\mathbf{X}$  es la matriz de datos de dimensión  $N \times p$ , que contiene los registros de las variables de entrada.

En el conjunto de datos de variables transformadas  $\mathcal{Z} = \{\mathbf{z}(t), t = 1 \dots N\}$ , cada registro se calcula como una combinación lineal de los registros correspondientes de las variables originales, como  $\mathbf{z}(t) = \mathbf{x}(t)\mathbf{P}$ . La matriz de datos transformada se escribe como:

$$\mathbf{Z} = \mathbf{XP} \quad (2.17)$$

La matriz de transformación  $\mathbf{P} \in \mathcal{R}^{p \times p}$  es una matriz ortogonal calculada diagonalizando la matriz de covarianza de las variables originales. Como resultado, la matriz de covarianza de las variables transformadas,  $\mathbf{\Lambda} = \frac{1}{N-1} \mathbf{Z}^T \mathbf{Z}$ , es diagonal. Escribiendo  $\mathbf{\Lambda}$  con la matriz  $\mathbf{Z}$  definida en (2.17), tenemos: \*

$$\mathbf{\Lambda} = \frac{1}{N-1} \mathbf{Z}^T \mathbf{Z} = \frac{1}{N-1} (\mathbf{XP})^T (\mathbf{XP}) = \frac{1}{N-1} \mathbf{P}^T \mathbf{X}^T \mathbf{XP} = \mathbf{P}^T \hat{\mathbf{\Sigma}} \mathbf{P} \quad (2.18)$$

La matriz  $\mathbf{P}$  es ortogonal, por lo que  $\mathbf{P}^T \mathbf{P} = \mathbf{I}$ , donde  $\mathbf{I}$  es la matriz identidad. Multiplicando ambos lados de la ecuación  $\mathbf{\Lambda} = \mathbf{P}^T \hat{\mathbf{\Sigma}} \mathbf{P}$  por  $\mathbf{P}$ , tenemos:

$$\hat{\mathbf{\Sigma}} \mathbf{P} = \mathbf{P} \mathbf{\Lambda} \quad (2.19)$$

La matriz  $\mathbf{\Lambda}$  es diagonal, por lo que la ecuación (2.19) representa las  $p$  ecuaciones  $\hat{\mathbf{\Sigma}} \mathbf{p}_i = \lambda_i \mathbf{p}_i$ , donde los vectores  $\mathbf{p}_i$  se denominan vectores propios y  $\lambda_i$  los valores propios. En PCA, los vectores propios de la matriz de covarianza de las variables originales se denominan componentes principales.

El problema de valores propios y vectores propios como (2.19), también llamado descomposición espectral, es un problema clásico que se ha estudiado desde el siglo XIX y tiene aplicaciones en numerosas áreas. Los algoritmos de resolución de problemas, en sus diversas variantes, están disponibles en bibliotecas como EISPACK<sup>93</sup> y ARPACK.<sup>94</sup>

La descomposición espectral de la matriz de covarianza utilizando la ecuación (2.19) proporciona información importante sobre las características de los datos. Como la matriz de covarianza es simétrica y definida positiva, sus valores propios son todos positivos [206]. El valor propio más grande  $\lambda_{max}$  es el valor máximo del cociente de Rayleigh:

$$\lambda_{max} = \frac{\mathbf{p}_{max}^T \hat{\mathbf{\Sigma}} \mathbf{p}_{max}}{\mathbf{p}_{max}^T \mathbf{p}_{max}} \geq \frac{\mathbf{v}^T \hat{\mathbf{\Sigma}} \mathbf{v}}{\mathbf{v}^T \mathbf{v}} \quad (2.20)$$

---

\* Utilizando a propiedad de matrices:  $(\mathbf{AB})^T = \mathbf{B}^T \mathbf{A}^T$ .

donde  $\mathbf{v} \in \mathcal{R}^p$  es cualquier vector y  $\mathbf{p}_{max}$  es el vector propio correspondiente al valor propio más grande  $\lambda_{max}$ .

El cociente de Rayleigh muestra que el vector propio  $\mathbf{p}_{max}$  representa la dirección de mayor varianza muestral (cf. Figura 2.21) y el valor propio  $\lambda_{max}$  mide la varianza en la dirección de  $\mathbf{p}_{max}$ . Los otros vectores propios son ortogonales y representan las otras direcciones de mayor varianza.

La matriz  $\mathbf{P}$  realiza un cambio de coordenadas en el espacio variable, transformando el conjunto de datos del problema en un nuevo conjunto de datos de variables transformadas por la ecuación (2.17). No existe correlación entre las variables transformadas, por lo que la matriz de covarianza  $\mathbf{\Lambda}$  es diagonal.

La Figura 2.21 presenta un ejemplo de la transformación realizada por la matriz de transformación calculada como solución al problema (2.19). En este ejemplo, el resultado obtenido para la matriz  $\mathbf{P}$  es la matriz de transformación que se muestra en la Figura 2.20.




Figura 2.21: Ejemplo de transformación lineal realizada por ACP.

Una propiedad del álgebra lineal garantiza que la traza, es decir, la suma de los elementos de la diagonal principal de una matriz, no cambia al aplicar una transformación lineal ortogonal, de modo que:

$$\sum_{i=1}^p \hat{\sigma}_i^2 = \sum_{i=1}^p \lambda_i \quad (2.21)$$

donde  $\hat{\sigma}_i^2$  es un elemento de la diagonal de  $\hat{\Sigma}$  que representa la varianza de la variable  $x_i$ , y  $\lambda_i$  es un elemento de la diagonal de  $\mathbf{\Lambda}$  que representa la varianza de la variable transformada  $z_i$ .

La ecuación (2.21) garantiza que la varianza total del conjunto de datos no cambia con la transformación independientemente de la disposición de las columnas  $\mathbf{P}$ . En la mayoría de las rutinas,

los vectores propios están organizados de manera que  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$ . Por lo tanto, el primer vector propio  $\mathbf{p}_1$  corresponde al valor propio más grande  $\lambda_1$ , siendo por lo tanto la dirección de la varianza máxima de los datos, y así sucesivamente. Luego podemos usar las primeras columnas  $n < p$  de  $\mathbf{P}$  como la matriz de transformación  $\hat{\mathbf{P}} \in \mathcal{R}^{p \times n}$  que producirá las variables transformadas  $\hat{\mathbf{z}}(t) = \mathbf{x}(t)\hat{\mathbf{P}} \in \mathcal{R}^n$ , que explican la mayor parte de la varianza de los datos. El número  $n$  de componentes principales se elige de modo que su varianza total de las variables transformadas, calculada como  $\sum_{i=1}^n \lambda_i$ , represente una porción importante (mayor al 85%) de la varianza total de las variables originales.

PCA ayuda a comprender la relación entre variables. La Figura 2.22 presenta los resultados de PCA aplicados al conjunto de datos de Parkinson.<sup>95</sup> La Figura 2.22a presenta la matriz de correlación y la Figura 2.22b, los dos componentes principales. Nótese que el único elemento negativo del primer componente corresponde a la variable  $x_{11}$ , que tiene correlación negativa con todas las variables, teniendo las demás correlación positiva entre sí. El segundo componente separa las variables  $\{x_1, \dots, x_3\}$ , con elementos positivos, de las variables  $\{x_4, \dots, x_9\}$ , con elementos negativos, estando las variables de los dos grupos bien correlacionadas entre sí.

La Figura 2.22c presenta los resultados de los valores propios en el diagrama de Pareto, en el que las etiquetas de las barras son los valores propios. Las variables fueron estandarizadas por *z-scores* de modo que  $\hat{\sigma}_i^2 = 1$  y, por lo tanto,  $\sum_{i=1}^p \hat{\sigma}_i^2 = p$ , es decir, la varianza total es igual al número de variables. En la Figura 2.22c, se observa que los componentes principales  $n = 7$  representan más del 95% de la varianza total de los datos. La Figura 2.22d presenta el conjunto de datos transformados en las coordenadas transformadas por los dos componentes principales.

Las variables transformadas son combinaciones lineales de las variables originales. En algunos casos, es posible interpretar los componentes principales o las variables transformadas, pero este no es el objetivo principal del PCA y no siempre existe una interpretación razonable en el dominio del problema. Obtener transformaciones interpretables en el dominio del problema es el objeto del análisis factorial [449].




Figura 2.22: Resultados de PCA en el conjunto de datos de Parkinson: (a) matriz de correlación; (b) vectores propios asociados con los dos valores propios más grandes; (c) Diagrama de valores propios; (d) datos proyectados sobre los dos componentes principales.

La transformación realizada por la ACP no toma en cuenta la información de las variables de entrada y salida. Existen transformaciones lineales que utilizan las variables de salida en problemas de clasificación y regresión. En problemas de clasificación, el análisis discriminante lineal (ADL), descrito en la sección 2.4.3, da como resultado variables transformadas en las que la separación de clases es máxima. En problemas de regresión, el análisis de correlación canónica, descrito en la sección 2.4.4, da como resultado transformaciones lineales que maximizan la correlación entre las variables de entrada y salida.

En la siguiente sección, presentamos la descomposición en valores singulares como un método de cálculo de PCA alternativo, que también se puede aplicar a otros tipos de problemas.



### 2.4.2 Decomposição em valores singulares

La descomposición en valores singulares (SVD) de una matriz  $\mathbf{A} \in \mathcal{R}^{n \times m}$  se define como:

$$\mathbf{A} = \mathbf{U}\mathbf{S}\mathbf{V}^T \quad (2.22)$$

donde  $\mathbf{U} \in \mathcal{R}^{n \times n}$  y  $\mathbf{V} \in \mathcal{R}^{m \times m}$  son matrices ortogonales cuyas columnas  $\mathbf{u}_i, i = 1 \dots n$  y  $\mathbf{v}_j, j = 1 \dots m$  se denominan respectivamente vectores singulares izquierdo y derecho; la matriz  $\mathbf{S} \in \mathcal{R}^{n \times m}$  es diagonal y sus elementos se llaman valores singulares de  $\mathbf{A}$ .

La matriz  $\mathbf{S}$  tiene  $n - m$  (o  $m - n$ ) elementos nulos cuando  $n > m$  (o  $m > n$ ). Las columnas de  $\mathbf{U}$  (o las filas de  $\mathbf{V}^T$ ) correspondientes a los elementos nulos de  $\mathbf{S}$  forman la base del espacio nulo\* de la matriz  $\mathbf{A}$  [206]. Algunos *softwares* presentan el resultado del cálculo de SVD eliminando las filas y columnas correspondientes a valores singulares nulos, lo que se denomina SVD reducido. La Figura 2.23 presenta una ilustración de la SVD en los casos de  $n > m$  y  $m < n$ , donde las líneas discontinuas muestran las dimensiones de las matrices resultantes de la SVD reducida.

En general, el SVD se calcula con los valores singulares en orden no decreciente como  $s_1 \geq s_2 \geq \dots \geq s_r \geq 0$ , donde  $r \leq \min(n, m)$  es el rango† de la matriz  $\mathbf{A}$ . Se puede calcular una aproximación de rango  $r$  de la matriz  $\mathbf{A}$  utilizando solo las primeras columnas  $r$  de  $\mathbf{U}$ ,  $\mathbf{S}$  y  $\mathbf{V}$ .




Figura 2.23: Ilustración de la SVD: (a) con  $n > m$ ; (b) con  $m > n$ .

El cálculo de SVD es equivalente al cálculo de la descomposición espectral de matrices simétricas. Usando el SVD de la matriz de datos del problema  $\mathbf{X} = \mathbf{U}\mathbf{S}\mathbf{V}^T$  para calcular la matriz de covarianza, tenemos:

\* O espaço nulo da matriz  $\mathbf{A}$ , denotado  $\text{null}(\mathbf{A})$ , é o conjunto de vetores  $\{\mathbf{x}: \mathbf{A}\mathbf{x} = \mathbf{0}\}$  [206].

† O posto de uma matriz é o maior número de linhas ou colunas linearmente independentes [206].

$$\mathbf{X}^T \mathbf{X} = (\mathbf{U} \mathbf{S} \mathbf{V}^T)^T \mathbf{U} \mathbf{S} \mathbf{V}^T = \mathbf{V} \mathbf{S} \mathbf{U}^T \mathbf{U} \mathbf{S} \mathbf{V}^T = \mathbf{V} \mathbf{S}^2 \mathbf{V}^T \quad (2.23)$$

Comparando la ecuación (2.23) con la ecuación (2.19) escrita en la forma  $\hat{\Sigma} = \mathbf{P} \mathbf{\Lambda} \mathbf{P}^T$ , se puede concluir que los valores singulares  $s_i = \sqrt{\lambda_i}$ ,  $i = 1 \dots p$ . Los vectores singulares derechos son iguales que los vectores propios, es decir,  $\mathbf{V} = \mathbf{P}$ . El PCA se puede calcular directamente mediante el SVD de la matriz  $\mathbf{X}$ , evitando el producto  $\mathbf{X}^T \mathbf{X}$ .

SVD calcula una descomposición ortogonal de una matriz no cuadrada de elementos reales. SVD se utiliza para la reducción de dimensionalidad en la recuperación de información en la técnica conocida como índice semántico latente [364].

### 2.4.3 Análisis discriminante lineal

ACP y SVD no utilizan la información de las variables de salida para calcular la transformación. En problemas de clasificación, es posible que la proyección realizada por la ACP no sea óptima en términos de separación de clases. La Figura 2.24 presenta un ejemplo simple en el que proyectar los datos en la dirección del primer componente principal termina mezclando los datos.

El análisis discriminante lineal (ADL) calcula una transformación lineal que maximiza la separación entre clases en las coordenadas de las variables transformadas. El ADL también se denomina discriminante lineal de Fisher [146] debido al trabajo de Fisher en 1936 [183].




Figura 2.24: Ejemplo de PCA en un problema de clasificación: (a) datos originales; (b) primer componente principal (CP1).

El cálculo de la transformación se realiza a partir de la descomposición de la matriz de varianza total en  $\Sigma_T = \Sigma_B + \Sigma_W$ , calculada respectivamente como [146]:

$$\Sigma_{\mathbf{T}} = \sum_{t=1}^N (\mathbf{x}(t) - \bar{\mathbf{x}})^T (\mathbf{x}(t) - \bar{\mathbf{x}}) \quad (2.24)$$

$$\Sigma_{\mathbf{B}} = \sum_{i=1}^m N_i (\bar{\mathbf{x}}_i - \bar{\mathbf{x}})^T (\bar{\mathbf{x}}_i - \bar{\mathbf{x}}) \quad (2.25)$$

$$\Sigma_{\mathbf{W}} = \sum_{i=1}^m \sum_{\mathbf{x}(t) \in \mathcal{C}_i} (\mathbf{x}(t) - \bar{\mathbf{x}}_i)^T (\mathbf{x}(t) - \bar{\mathbf{x}}_i) \quad (2.26)$$

donde  $\bar{\mathbf{x}} \in \mathcal{R}^p$  es el vector de medias variables, calculado para todos los registros;  $\bar{\mathbf{x}}_i \in \mathcal{R}^p$  es el vector de promedios de  $N_i$  registros de clase  $\mathcal{C}_i$ ;  $\mathcal{C}_i$  es el conjunto de registros de la clase  $\mathcal{C}_i$ , es decir,  $\mathcal{C}_i = \{\mathbf{x}(t) \in \mathcal{T} : y(t) = \mathcal{C}_i\}$ ,  $i = 1 \dots m$ , que contiene elementos  $N_i$ ; y  $m$  es el número de clases.

La matriz de varianza total  $\Sigma_{\mathbf{T}} = (N - 1)\hat{\Sigma}$  donde  $\hat{\Sigma}$  es la estimación de la matriz de covarianza definida por la ecuación (2.5). La matriz  $\Sigma_{\mathbf{B}}$  mide la varianza entre clases, es decir, la separación entre clases, y la matriz  $\Sigma_{\mathbf{W}}$  mide la varianza intraclase, es decir, entre registros de una misma clase.

La transformación ADL se calcula de modo que el nuevo sistema de coordenadas produzca datos con una variación máxima entre clases y una variación mínima dentro de clases. En problemas de dos clases ( $m = 2$ ), la dirección  $\mathbf{v}$  que maximiza la relación  $\Sigma_{\mathbf{B}}/\Sigma_{\mathbf{W}}$  se obtiene maximizando el siguiente coeficiente de Rayleigh:

$$J(\mathbf{v}) = \frac{\mathbf{v}^T \Sigma_{\mathbf{B}} \mathbf{v}}{\mathbf{v}^T \Sigma_{\mathbf{W}} \mathbf{v}} \quad (2.27)$$

donde  $\mathbf{v}$  se calcula como una solución al problema de valores propios generalizado  $\Sigma_{\mathbf{B}} \mathbf{v} = \lambda \Sigma_{\mathbf{W}} \mathbf{v}$ .

Este resultado se puede extender a problemas multiclase ( $m > 2$ ), resolviendo el siguiente problema de valores propios generalizado [146]:

$$\Sigma_{\mathbf{B}} \mathbf{V} = \Sigma_{\mathbf{W}} \mathbf{V} \mathbf{\Lambda} \quad (2.28)$$

donde  $\mathbf{\Lambda}$  es la matriz diagonal de valores propios generalizados, que contiene solo elementos  $m - 1$  y  $\mathbf{V}$  es la matriz de  $m - 1$  vectores propios generalizados.

El conjunto de datos de la variable transformada  $\mathbf{Z}$ , de dimensión  $N \times m - 1$ , se calcula mediante la transformación lineal  $\mathbf{Z} = \mathbf{XV}$ .

La Figura 2.25 presenta los resultados de ADL para el ejemplo de la Figura 2.24. En este caso, la dirección calculada por ADL es la misma que la del segundo componente principal.




Figura 2.25: Resultado de AVD para los datos de la Figura 2.24.

En problemas linealmente separables, ADL es una solución óptima que permite una buena aproximación con un número reducido de componentes. El conjunto de datos *Wine*,<sup>96</sup>, por ejemplo, es un problema de clasificación con 13 variables de entrada que contienen los resultados de análisis químicos en tres categorías de vinos de una región de Italia. La figura 2.26 muestra los resultados de AVD. La Figura 2.26a presenta los datos transformados y los histogramas de las nuevas variables  $n = 2$  y la Figura 2.26b muestra los elementos de cada componente de la matriz de transformación  $V$ .




Figura 2.26: Resultado de ADL en el conjunto de datos de Wine: (a) datos transformados; (b) componentes de la matriz de transformación.

#### 2.4.4 Análise de correlação canônica

En problemas de clasificación, ADL calcula una transformación lineal que tiene en cuenta la información de clase para definir un espacio de coordenadas donde la separación de clases es óptima. En problemas de regresión, es posible obtener un resultado similar con el análisis de correlación canónica (CCA).

ACC considera el problema en el que existen dos conjuntos de variables, que representan dos formas diferentes de observar un mismo fenómeno. El objetivo es calcular dos transformaciones lineales, una para cada variable, basadas en la correlación cruzada entre las variables. Cuando se aplican a conjuntos de datos iniciales, las transformaciones producen nuevas variables que representan mejor la correlación del conjunto de datos.

La formulación de ACC se presentará en esta sección utilizando las matrices de datos de entrada  $\mathbf{X} \in \mathcal{R}^{N \times p}$  y la salida  $\mathbf{Y} \in \mathcal{R}^{N \times q}$  del conjunto de datos de entrenamiento, pero el orden de los conjuntos de datos no interfiere con el procesamiento. ACC realiza una aproximación más pequeña de la entrada y salida de un problema de regresión.

ACC produce nuevas variables  $\mathbf{Z}_x = \mathbf{X}\mathbf{U}_x$  y  $\mathbf{Z}_y = \mathbf{Y}\mathbf{U}_y$ , llamadas variables canónicas, ambas de dimensión  $n \leq \min(p, q)$ . Las transformaciones lineales  $\mathbf{U}_x$  y  $\mathbf{U}_y$  se calculan para maximizar la correlación entre las variables canónicas y cada transformación se calcula con datos de las dos variables.

Al igual que en PCA, las variables deben estandarizarse mediante *z-scores*, lo que da como resultado variables con media cero y desviación estándar unitaria. Las transformaciones lineales ortogonales no cambian las medias y desviaciones estándar de las variables transformadas, por lo que la matriz de correlación cruzada entre las variables canónicas se escribe como:

$$\mathbf{Z}_x^T \mathbf{Z}_y = \mathbf{U}_x^T \mathbf{X}^T \mathbf{Y} \mathbf{U}_y \quad (2.29)$$

donde  $\mathbf{Z}_x, \mathbf{Z}_y \in \mathcal{R}^{N \times n}$  son las matrices de datos de las variables canónicas.

El cálculo de matrices de transformación en ACC fue propuesto inicialmente por Hotelling en 1936 [261]. En esta sección utilizamos la formulación propuesta por Golub y Zha [207], que se basa en la descomposición QR ortogonal de matrices de datos:

$$\mathbf{X} = \mathbf{Q}_x \mathbf{R}_x \quad (2.30)$$

---

\* Formalmente,  $n = \min(\text{rank}(\mathbf{X}), \text{rank}(\mathbf{Y}))$ , onde rank é o posto da matriz.

$$\mathbf{Y} = \mathbf{Q}_y \mathbf{R}_y \quad (2.31)$$

donde las matrices  $\mathbf{Q}_x$  y  $\mathbf{Q}_y$  son ortogonales y las matrices  $\mathbf{R}_x$  y  $\mathbf{R}_y$  son triangulares superiores. En este caso utilizamos la descomposición QR reducida, en la que la matriz  $\mathbf{Q}_x$  ( $\mathbf{Q}_y$ ) tiene dimensión  $N \times p$  ( $N \times q$ ) y la matriz  $\mathbf{R}_x$  ( $\mathbf{R}_y$ ) tiene dimensión  $p \times p$  ( $q \times q$ ).

Aplicando las descomposiciones QR definidas en las ecuaciones (2.30) y (2.31) a la ecuación (2.29), la correlación cruzada entre los dos conjuntos de variables se escribe como:

$$\mathbf{\Lambda} = \mathbf{U}_x^T \mathbf{X}^T \mathbf{Y} \mathbf{U}_y = \mathbf{U}_x^T \mathbf{R}_x^T \mathbf{Q}_x^T \mathbf{Q}_y \mathbf{R}_y \mathbf{U}_y \quad (2.32)$$

La matriz de correlaciones  $\mathbf{\Lambda}$  es diagonal y sus elementos son los valores singulares de  $\mathbf{Q}_x^T \mathbf{Q}_y$  [206], llamados correlaciones canónicas. Las transformaciones lineales  $\mathbf{U}_x$  y  $\mathbf{U}_y$  están escritas desde el SVD  $\mathbf{Q}_x^T \mathbf{Q}_y = \mathbf{V}_x \mathbf{S} \mathbf{V}_y^T$ . Aplicando el resultado de SVD a la ecuación (2.32):

$$\mathbf{U}_x^T \mathbf{R}_x^T \mathbf{Q}_x^T \mathbf{Q}_y \mathbf{R}_y \mathbf{U}_y = \mathbf{U}_x^T \mathbf{R}_x^T \mathbf{V}_x \mathbf{S} \mathbf{V}_y^T \mathbf{R}_y \mathbf{U}_y \quad (2.33)$$

ACC calcula la correlación cruzada  $\mathbf{\Lambda} = \mathbf{S}$  de modo que  $\mathbf{U}_x^T \mathbf{R}_x^T \mathbf{V}_x = \mathbf{I}$  y  $\mathbf{V}_y^T \mathbf{R}_y \mathbf{U}_y = \mathbf{I}$ , donde  $\mathbf{I}$  representa la matriz de identidad de dimensión del número de componentes canónicos  $n$ . Las transformaciones lineales ACC se calculan como:

$$\mathbf{U}_x = \mathbf{R}_x^{-1} \mathbf{V}_x^T \quad (2.34)$$

$$\mathbf{U}_y = \mathbf{R}_y^{-1} \mathbf{V}_y \quad (2.35)$$

La formulación anterior equivale a maximizar la traza de la matriz  $\mathbf{\Lambda}$  [207], imponiendo la restricción de que las matrices de transformación deben ser ortogonales.

La aplicación de ACC se muestra en el ejemplo del aumento de temperatura adiabático en el hormigón, que se analizará en la sección 3.4.2. El conjunto de datos presenta 14 variables de entrada divididas en dos tipos: cinco variables que representan la composición del cemento utilizado y otras nueve con otros aditivos [18]. El aumento de temperatura se parametriza mediante 3 variables de salida.

Los resultados del ACC se muestran en la Figura 2.27. El número de componentes canónicos en este caso es  $n \leq \min(p, q) = 3$ . La figura 2.27a muestra los elementos de la correlación cruzada  $\mathbf{\Lambda}$ . Las variables canónicas con mayor correlación se calculan como  $\mathbf{z}_{x1} = \mathbf{X} \mathbf{u}_{x1}$  y  $\mathbf{z}_{y1} = \mathbf{Y} \mathbf{u}_{y1}$ , donde  $\mathbf{u}_{x1}$  y  $\mathbf{u}_{y1}$  son los primeros componentes de  $\mathbf{U}_x$  y  $\mathbf{U}_y$ . La Figura 2.27c muestra el gráfico de proyección entre las variables  $\mathbf{z}_{x1}$  y  $\mathbf{z}_{y1}$ . La Figura 2.27c y la Figura 2.27c muestran respectivamente los elementos de los vectores  $\mathbf{u}_{x1}$  y  $\mathbf{u}_{y1}$ .




Figura 2.27: Resultados del ACC sobre datos concretos de aumento de temperatura: (a) correlaciones canónicas; (b) gráfico de proyección de variables canónicas; (c) primer componente de  $\mathbf{U}_x$ ; (d) primer componente de  $\mathbf{U}_y$ .

Esta sección presentó los principales métodos para calcular transformaciones lineales en el conjunto de datos. Estos métodos utilizan técnicas de cálculo matricial y muestran lo útil que puede ser representar un registro en el conjunto de datos como un punto en el espacio vectorial.

Las transformaciones lineales presentadas en esta sección consideran que la muestra de datos tiene una distribución normal, lo cual no siempre se verifica y el resultado puede no ser representativo. Además, muchos problemas reales contienen variables nominales y binarias, que también pueden interferir con los resultados.

A continuación se presentan aplicaciones de resumen y visualización de datos, así como el uso de transformaciones lineales para validar mediciones.

## 2.5 Aplicaciones

### 2.5.1 Patrones de movilidad

La universalización de los teléfonos móviles y la proliferación de dispositivos móviles conectados a Internet han transformado al ser humano en un sensor de marcha. El registro de la actividad del usuario proporciona una cantidad de datos sin precedentes, lo que ha atraído el interés de varios investigadores de diferentes áreas [30][70].

Un proyecto de investigación llevó a cabo el estudio de una base de datos de registros de llamadas de teléfonos celulares en la región con código de área 21, que comprende toda la Región Metropolitana de Río de Janeiro (RMRJ) (ver detalle en la Figura 2.28). La base de datos utilizada para el proyecto sólo contenía registros de llamadas de voz realizadas, en las que se cifraba la identificación del usuario. Hay estudios que utilizan registros más detallados [53] como llamadas recibidas, mensajes de texto (SMS), registros de conexión a internet, datos procesados directamente por antenas o registros de posicionamiento satelital (GPS) o registros de redes sociales.

Los registros de llamadas móviles (CDR)\* permiten inferir el movimiento de las personas a partir de la posición de la antena (celular) que procesó la llamada. En general, se colocan al menos tres antenas en 120° en cada torre, de modo que la cobertura por torre se pueda aproximar mediante un polígono de Voronoi.

La Figura 2.28 muestra la cobertura en Río de Janeiro, con los polígonos de las torres de Voronoi. El posicionamiento de las torres sigue objetivos técnicos y de marketing, por lo que la distribución resultante no es uniforme. Hay mayor concentración de antenas en zonas con mayor densidad poblacional y nivel socioeconómico, como el Centro, Tijuca y la Zona Sur. Otras zonas pobladas, como Jacarepaguá, Campo Grande, Duque de Caxias y São Gonçalo, tienen una menor concentración de antenas. La geografía de la ciudad afecta la distribución de las antenas debido a la presencia de macizos montañosos dentro del área urbana, como los macizos de Tijuca y Pedra Branca, visibles en la Figura 2.28.

---

\* *Call Detail Records.*





Figura 2.28: Polígonos de Voronoi en Río de Janeiro. En detalle la cobertura del área 21.

Los datos fueron recopilados a lo largo de 2014, entre el 31 de diciembre de 2013 y el 1 de enero de 2015, totalizando 2,1 mil millones de registros relacionados con 2,9 millones de suscriptores. Para el estudio sólo estuvieron disponibles los datos de las llamadas de voz realizadas, lo que limita considerablemente la muestra.

Se realizó una modelación de la región de estudio agrupando los polígonos de Voronoi en áreas que se aproximan a las unidades demográficas del IBGE. La identificación de la residencia presunta de los usuarios permitió combinar los resultados de movilidad con datos demográficos y socioeconómicos. Los datos del CDR se utilizaron para estimar matrices de origen-destino (OD) para cada día para analizar los patrones de movilidad en RMRJ [87][88]. Los resultados del procesamiento de cada día están disponibles en Dataverse.<sup>97</sup>

Los dos patrones de movilidad más comunes se muestran en la Figura 2.30 y la Figura 2.30 [88]. La Figura 2.30 muestra el número estimado de viajes entre la Zona Centro (AP1) y Zona Sur (AP2) y representa el patrón de trabajo a domicilio, con gran regularidad, mayor número de viajes durante la semana y estimaciones similares en el viaje de regreso.

La Figura 2.30 muestra el número estimado de viajes entre la Zona Sur (AP2) y Teresópolis, ciudad turística de la Región Montañosa del Estado. En este caso el patrón es completamente diferente, el mayor número de viajes se produce los fines de semana, con picos en festivales, y hay un retraso entre la ida y la vuelta.




Figura 2.29: Número de viajes Centro (AP1) – Zona Sur (AP2). Fuente: reproducido de [88].




Figura 2.30: Número de viajes Zona Sur (AP2) – Teresópolis. Fuente: reproducido de [88].

Existen varios estudios sobre movilidad e indicadores sociales basados en datos de teléfonos móviles [117][526]. Los resultados obtenidos muestran que los datos de los registros de llamadas de teléfonos móviles pueden ser una alternativa de bajo coste para modelar problemas complejos en las ciudades modernas.

Actualmente existe una gran oferta de datos públicos y muchas ciudades alrededor del mundo mantienen portales de datos abiertos. En Río de Janeiro, el portal [data.rio](http://data.rio)<sup>98</sup> mantiene una base de datos pública para consulta. En este portal es posible acceder a los datos de localización (GPS) de los autobuses municipales urbanos en tiempo real.

Un estudio sobre la velocidad de los autobuses en la ciudad fue realizado por Coppe/UFRJ en colaboración con el Centro de Investigación Dell-EMC. El resultado de la velocidad promedio diaria en las vías de la ciudad se muestra en la Figura 2.32, en la que los valores de velocidad se representan mediante una escala de colores y el ancho de la línea representa el número de líneas de colectivos que pasan por la vía. Se puede observar que las autopistas tienen las velocidades promedio más altas (verde), mientras que las carreteras en zonas de mayor densidad urbana tienen velocidades reducidas (rojo). Las principales áreas de concentración.

de la ciudad se pueden identificar en el mapa: zona Sur, Centro, Tijuca, Meier, Madureira, Jacarepaguá, Bangu, Campo Grande y Santa Cruz.

La visualización y caracterización estadística de los datos es un paso fundamental para comprender el problema. Los ejemplos presentados en esta sección ilustran ejemplos de visualización de datos georreferenciados utilizando sistemas de información geográfica<sup>99</sup> junto con servidores de mapas en Internet.




Figura 2.31: Velocidad promedio de los autobuses en la ciudad de Río de Janeiro a las 7:00 pm.

La siguiente sección muestra una aplicación de transformaciones lineales para validar mediciones en sistemas de diagnóstico.

### 2.5.2 Ecuaciones de paridad

El seguimiento de procesos complejos se realiza con datos recogidos por sensores cuyo funcionamiento debe ser controlado continuamente para evitar que cualquier perturbación en las mediciones se confunda con un fallo en el proceso. El método de validación de mediciones mediante ecuaciones de paridad utiliza la redundancia de información contenida en las mediciones para generar indicadores de falla a través de transformaciones lineales. La redundancia puede ser directa, en la que hay más de un sensor para una misma medida, o indirecta, cuando las medidas producidas por un conjunto de sensores deben ser

preservar cierta coherencia entre sus valores. El análisis de componentes principales (PCA) se puede aplicar para sintetizar un sistema de validación de medidas utilizando ecuaciones de paridad en sistemas lineales estáticos.

Considere un conjunto de sensores  $p$ , cuyas medidas están representadas por las componentes del vector  $\mathbf{x}(t) \in \mathcal{R}^p$ . Las medidas están relacionadas con un conjunto de estados  $\mathbf{z}(t) \in \mathcal{R}^n$  mediante la ecuación de medida:

$$\mathbf{x}(t) = \mathbf{z}(t)\mathbf{C}^T + \Delta\mathbf{x}(t) + \mathbf{e}(t) \quad (2.36)$$

donde  $\mathbf{C}$ , de dimensión  $p \times n$  es la matriz de medición,  $\Delta\mathbf{x}(t) \in \mathcal{R}^p$  representa fallas aditivas en los sensores y  $\mathbf{e}(t) \in \mathcal{R}^p$  es ruido con media cero y varianza constante.

Las mediciones están estandarizadas usando *z-scores* (cf. ecuación (2.16)) y tienen media cero y desviación estándar unitaria. Hay redundancia de información cuando la dimensión del vector de medición  $p > n$ . En este caso, se puede utilizar información redundante para detectar fallas en los sensores.

Un método robusto y bien conocido para la validación de sensores se basa en ecuaciones de paridad [201]. Esta técnica ha sido utilizada en varias aplicaciones y consiste en proyectar el vector de medida en un espacio de dimensión  $m = p - n$ , llamado espacio de paridad. El vector de paridad se calcula como:

$$\mathbf{u}(t) = \mathbf{x}(t)\mathbf{W} \quad (2.37)$$

donde  $\mathbf{W}$ , de dimensión  $p \times m$ , es la matriz de proyección y  $\mathbf{u}(t) \in \mathcal{R}^m$ , el vector de paridad.

El vector de paridad es un indicador de fallos que es nulo en su ausencia. Por tanto, la matriz de proyección debe ser ortogonal a la matriz de medición:

$$\mathbf{C}^T\mathbf{W} = \mathbf{0} \quad (2.38)$$

Reescribiendo la ecuación (2.37) considerando la ecuación de medición (2.36) y la restricción impuesta por la ecuación (2.38), el vector de paridad se calcula como:

$$\mathbf{u}(t) = (\mathbf{z}(t)\mathbf{C}^T + \Delta\mathbf{x}(t) + \mathbf{e}(t))\mathbf{W} = (\Delta\mathbf{x}(t) + \mathbf{e}(t))\mathbf{W} \quad (2.39)$$

De la ecuación (2.39), se puede ver que el vector de paridad representa solo las fallas e incertidumbres (ruido) en el proceso, independientemente del valor de los estados. Por tanto, un evento externo que cambia consistentemente todas las mediciones no cambia significativamente el valor del vector de paridad.

Cada fila de la matriz  $\mathbf{W}$  representa una dirección de falla en el espacio de paridad. Una perturbación aditiva en una medición provoca un aumento del vector de paridad en la dirección correspondiente. La identificación de fallas se realiza comparando la dirección del vector de paridad con las direcciones definidas por la matriz de proyección.

Considere el ejemplo de un sistema con redundancia de material en el que se utilizan sensores  $p = 4$  para observar los valores de los estados  $n = 2$ , con las siguientes matrices de medición y proyección:

$$\mathbf{C}^T = \begin{bmatrix} 1.0 & 1.0 & 0.0 & 0.0 \\ 0.0 & 0.0 & 1.0 & 1.0 \end{bmatrix}, \quad \mathbf{W}^T = \begin{bmatrix} 0.5 & -0.5 & +0.5 & -0.5 \\ 0.5 & -0.5 & -0.5 & +0.5 \end{bmatrix} \quad (2.40)$$

El espacio de paridad y las direcciones de falla asociadas con cada medición en este ejemplo se muestran en la Figura 2.32. El parámetro  $\xi$  representa una tolerancia para el módulo del vector de paridad con el fin de acomodar el ruido del proceso (cf. ecuación (2.37)), de modo que la detección se realiza sólo si  $\|\mathbf{u}(t)\| > \xi$ .




Figura 2.32: Direcciones de falla en el espacio de paridad.

El método de ecuaciones de paridad garantiza la capacidad del sistema para detectar fallas simples, es decir, fallas aditivas en una sola medición. En caso de fallas múltiples, una combinación de fallas puede anular el vector de paridad y el vector de perturbación debe representar firmas de fallas. Dependiendo del tamaño del vector de paridad, puede que no sea posible aislar todas las fallas. El método no aplica en caso de fallas que afecten el comportamiento del proceso.

Las matrices de medición y proyección del método de ecuaciones de paridad se pueden generar a partir del PCA presentado en la sección 2.4.1. Considere un conjunto de registros del vector de medición  $\mathcal{T} = \{\mathbf{x}(t), t = 1 \dots N\}$ . La matriz de covarianza estimada se calcula como  $\hat{\Sigma} = \frac{1}{N-1} \mathbf{X}^T \mathbf{X}$ , donde  $\mathbf{X}$ , de dimensión  $N \times p$ , contiene los registros de las variables de entrada. El ACP se calcula diagonalizando la matriz  $\hat{\Sigma}$  resolviendo el problema de valores propios definido en la ecuación (2.19):

$$\hat{\Sigma} \mathbf{P} = \mathbf{P} \mathbf{\Lambda} \quad (2.41)$$

donde las columnas de la matriz  $\mathbf{P}$  son los vectores propios (componentes principales) y los valores propios de la matriz diagonal  $\mathbf{\Lambda}$  representan la varianza de la variable transformada.

Las variables transformadas por PCA se pueden utilizar para calcular ecuaciones de paridad, considerando la matriz de componentes principales compuesta por las matrices de medición y proyección como  $\mathbf{P} = [\mathbf{C} \mid \mathbf{W}]$ . Las columnas de la matriz de componentes principales, de dimensión  $p \times p$ , son ortogonales, por lo que se cumple la condición (2.38). La síntesis del sistema de validación de mediciones de la ACP consiste en elegir las dimensiones  $n$  y  $m$  de los espacios de estado y de paridad. Considerando que  $p = n + m$ , cuanto mayor es la redundancia de las medidas, menor es la dimensión de los estados  $n$  y mayor es la dimensión del vector de paridad  $m$ .

El valor del parámetro  $\xi$  para la detección de fallas puede estimarse mediante la varianza total no representada por el vector de estado y calcularse mediante la suma de los valores propios correspondientes a los componentes del vector de paridad:

$$\xi = \sqrt{\sum_{i=n+1}^p \lambda_i} \quad (2.42)$$

donde  $\lambda_i$  es el valor propio de la matriz  $\mathbf{\Lambda}$  correspondiente a las columnas  $i = n + 1, \dots, p$ .

Se utilizó el método de ecuaciones de paridad para validar las mediciones de deformación de la Central Hidroeléctrica Funil (UHE) <sup>100</sup> utilizando galgas extensométricas de concreto. El conjunto de datos abarcó el período comprendido entre el 20/7/1967 y el 30/11/2005, con un total de 2.161 registros. Se eliminaron los registros con valores faltantes para el cálculo de matrices de medición y proyección, el cual se realizó con  $N = 380$  registros completos de 21 variables.

El método de las ecuaciones de paridad es inmune a la presencia de valores faltantes, ya que sólo las perturbaciones medidas se consideran en el cálculo del vector de paridad (cf. ecuación (2.39)). El resultado del método de ecuaciones de paridad se muestra en la Figura 2.33, en la que los registros en gris representan los valores faltantes y, en negro, los registros identificados como defectuosos. Tenga en cuenta que, en algunos casos, la aparición de una falla está asociada con la desactivación del sensor.




Figura 2.33: Resultado de la validación del sensor.

## 2.6 Comentarios finales

Este capítulo presentó las técnicas básicas utilizadas en la etapa de preprocesamiento del conjunto de datos. Una comprensión más profunda de la teoría de la probabilidad y el álgebra lineal es una base importante para la inteligencia computacional [146][298]. Hay varios libros que abordan el tema, como Montgomery [400] y Heath [244] que presentan una visión general de los conceptos del cálculo matricial. El libro de Heath también tiene un sitio web<sup>101</sup> que proporciona varios recursos asociados con el tema.

Las medidas de caracterización estadística presentadas son las más comunes y están presentes en la mayoría de los lenguajes de programación *softwares*. El tema continúa siendo explorado en la literatura [490] y hay diferentes soluciones disponibles.<sup>102</sup>

Algunos métodos de reducción de dimensionalidad no se trataron en la sección 2.4, que se centra únicamente en transformaciones lineales. Otras transformaciones conocidas, como *Local Linear Embedding* (LLE), análisis de componentes independientes (ICA),

entre otros, no se presentaron porque involucran algoritmos no lineales. Se puede encontrar una discusión de varios métodos lineales y no lineales, incluida una extensa revisión de la literatura sobre el tema, en [357], disponible para *download*,<sup>103</sup> donde es posible obtener una biblioteca Matlab que contiene la implementación de los métodos.

Las técnicas de cálculo matricial se han utilizado cada vez más en la ciencia de datos, especialmente para analizar grandes bases de datos, como Internet, y bases de datos multidimensionales [493][106]. Los métodos lineales se extienden al caso no lineal utilizando métodos basados en funciones del núcleo [478]. Las funciones del kernel se presentarán en el Capítulo 7 en el contexto de la aproximación de funciones con modelos SVM. Libros recientes presentan funciones del núcleo y la matriz del núcleo en los capítulos iniciales como una forma de representar datos [593], ya que las funciones del núcleo se pueden utilizar en registros que no tienen una representación vectorial.

En este libro, los capítulos iniciales cubren los fundamentos y, por lo tanto, sólo se presentan los métodos más simples. El siguiente capítulo analiza el modelo de regresión lineal y el método de mínimos cuadrados. Los algoritmos predictivos no lineales para regresión y clasificación se presentan en los Capítulos 7, 8 y 9.