

3 REGRESSÃO LINEAR

A regressão linear é uma técnica clássica da estatística cujo objetivo é o ajuste de um modelo que relaciona uma ou mais variáveis de entrada, ou independentes, com uma ou mais variáveis de saída, ou dependentes. Em ciência de dados, a regressão (linear ou não linear) também é chamada de predição [232]. Em inteligência computacional, utiliza-se frequentemente o termo aproximação de funções [298].

O modelo de regressão linear permite que os desafios associados ao desenvolvimento de modelos complexos sejam apresentados de uma forma clara e analítica. Os conceitos introduzidos neste capítulo servirão de base para modelos não lineares apresentados nos Capítulos 7, 8 e 9. Na prática, o modelo linear é sempre o primeiro que o analista deve construir devido a sua simplicidade, baixo custo computacional e também para obter um limite inferior de desempenho para modelos não lineares. Não são raros os problemas em que a diferença de desempenho entre um modelo linear e outro modelo mais elaborado (como uma rede neural, por exemplo) seja menor que 5%. Entretanto, há casos em que a relação entre as variáveis de entrada e saída é intrinsecamente não linear e modelos mais complexos obtêm melhores resultados.

Neste capítulo, apresentamos o problema de regressão linear e sua solução através do método dos mínimos quadrados. Em seguida, abordamos o dilema entre *bias* e variância, que é essencial para o desenvolvimento de um bom modelo. As técnicas de regularização, ou suavização de modelos, são também discutidas neste capítulo. Finalmente, introduzimos as estatísticas para validação de modelos de regressão, que também serão utilizadas para avaliação de modelos não lineares.

3 REGRESIÓN LINEAL

La regresión lineal es una técnica estadística clásica cuyo objetivo es ajustar un modelo que relaciona una o más variables de entrada o independientes con una o más variables de salida o dependientes. En ciencia de datos, la regresión (lineal o no lineal) también se denomina predicción [232]. En inteligencia computacional, el término aproximación de funciones se utiliza a menudo [298].

El modelo de regresión lineal permite presentar los desafíos asociados con el desarrollo de modelos complejos de forma clara y analítica. Los conceptos introducidos en este capítulo servirán como base para los modelos no lineales presentados en los Capítulos 7, 8 y 9. En la práctica, el modelo lineal es siempre el primero que el analista debe construir debido a su simplicidad, bajo costo computacional y también para obtener un límite de rendimiento más bajo para los modelos no lineales. No son raros los problemas en los que la diferencia de rendimiento entre un modelo lineal y otro más elaborado (como una red neuronal, por ejemplo) es inferior al 5%. Sin embargo, hay casos en los que la relación entre las variables de entrada y salida es intrínsecamente no lineal y modelos más complejos obtienen mejores resultados.

En este capítulo, presentamos el problema de regresión lineal y su solución utilizando el método de mínimos cuadrados. A continuación, abordamos el dilema entre *bias* y la varianza, que es esencial para desarrollar un buen modelo. En este capítulo también se analizan las técnicas de regularización o suavizado de modelos. Finalmente, presentamos estadísticas para validar modelos de regresión, que también se utilizarán para evaluar modelos no lineales.

3.1 O Problema de Regressão

Conforme apresentado no Capítulo 2, o conjunto de dados é representado neste livro por $\mathcal{T} = \{(\mathbf{x}(t), \mathbf{y}(t)), t = 1 \dots N\}$, onde cada registro é formado por pares ordenados $(\mathbf{x}(t), \mathbf{y}(t))$, sendo $\mathbf{x}(t) \in \mathcal{R}^p$ o vetor das variáveis de entrada e $\mathbf{y}(t) \in \mathcal{R}^q$ o vetor das variáveis de saída.

As variáveis de entrada não numéricas podem ser transformadas num conjunto de variáveis binárias chamadas variáveis indicadoras ou *dummy* [399]. As variáveis de saída não numéricas caracterizam o problema de classificação que será abordado no Capítulo 5. Nesse capítulo, a regressão linear é apresentada considerando variáveis de entrada numéricas e uma única variável de saída numérica, ou seja, $q = 1$ e $y(t) \in \mathcal{R}$. Os problemas de regressão de saídas múltiplas podem, na maioria dos casos, ser modelados por modelos independentes de saída simples.

No problema de regressão linear simples, uma única variável de entrada ($p = 1$) se relaciona linearmente com a variável de saída pela equação da reta $y(t) = ax(t) + b$ (cf. Figura 3.1). Na prática, a relação real não pode ser observada e os dados contêm perturbações de diversas origens, como erro de leitura, efeito de variáveis não observadas etc. Dessa forma, os registros observados, armazenados no conjunto de dados, contêm perturbações, como os pontos em azul na Figura 3.1. O modelo é ajustado a partir desses registros observados e, portanto, incorpora os erros de observação em seus parâmetros, sendo descrito por $\hat{y}(t) = \hat{a}x(t) + \hat{b}$, onde $\hat{y}(t)$ é o valor da variável de saída calculado pelo modelo e $\hat{a}$ e $\hat{b}$ são os parâmetros ajustados. O erro de ajuste ou **resíduo do modelo** é a diferença entre os valores observado e calculado pelo modelo da variável de saída, isto é, $e(t) = y(t) - \hat{y}(t)$, para cada registro do conjunto de treinamento.

O que se espera é que o modelo seja o mais próximo possível da relação real, pois sabemos que as perturbações têm origem aleatória. Assim, quanto mais próximo da relação real, melhor será o desempenho do modelo para a predição de novos dados, ou seja, registros diferentes dos que foram armazenados no conjunto de treinamento, mas gerados com a mesma distribuição.

3.1 El problema de la regresión

Como se presentó en el Capítulo 2, el conjunto de datos está representado en este libro por $\mathcal{T} = \{(\mathbf{x}(t), \mathbf{y}(t)), t = 1 \dots N\}$, donde cada registro está formado por pares ordenados $(\mathbf{x}(t), \mathbf{y}(t))$, siendo $\mathbf{x}(t) \in \mathcal{R}^p$ el vector de variables de entrada y $\mathbf{y}(t) \in \mathcal{R}^q$ el vector de variables de salida.

Las variables de entrada no numéricas se pueden transformar en un conjunto de variables binarias llamadas variables indicadoras o *dummy* [399]. Las variables de salida no numéricas caracterizan el problema de clasificación que se abordará en el Capítulo 5. En este capítulo, se presenta la regresión lineal considerando variables de entrada numéricas y una única variable de salida numérica, es decir, $q = 1$ y $y(t) \in \mathcal{R}$. En la mayoría de los casos, los problemas de regresión de productos múltiples pueden modelarse mediante modelos independientes de un solo producto.

En el problema de regresión lineal simple, una única variable de entrada ($p = 1$) se relaciona linealmente con la variable de salida mediante la ecuación en línea recta $y(t) = ax(t) + b$ (consulte la Figura 3.1). En la práctica, la relación real no se puede observar y los datos contienen perturbaciones de diversos orígenes, como errores de lectura, el efecto de variables no observadas, etc. Por lo tanto, los registros observados, almacenados en el conjunto de datos, contienen perturbaciones, como los puntos azules en la Figura 3.1. El modelo se ajusta en base a estos registros observados y, por tanto, incorpora errores de observación en sus parámetros, siendo descritos por $\hat{y}(t) = \hat{a}x(t) + \hat{b}$ donde $\hat{y}(t)$ es el valor de la variable de salida calculada por el modelo y $\hat{a}$ y $\hat{b}$ son los parámetros ajustados. El error de ajuste o residual del modelo es la diferencia entre los valores observados y calculados por el modelo de la variable de salida, es decir, $e(t) = y(t) - \hat{y}(t)$, para cada registro del conjunto de entrenamiento.

Lo que se espera es que el modelo se acerque lo más posible a la relación real, ya que sabemos que las perturbaciones tienen un origen aleatorio. Así, cuanto más cercana a la relación real, mejor será el rendimiento del modelo para predecir nuevos datos, es decir, registros diferentes a los almacenados en el conjunto de entrenamiento, pero generados con la misma distribución.




Figura 3.1: Exemplo de regressão linear.

Na hipótese da relação entre a variável de entrada e saída ser linear, os parâmetros do modelo podem ser facilmente ajustados pela minimização do erro total no conjunto de treinamento. O problema é que, na prática, não se conhece ou não há elementos para determinar o tipo de função que relaciona as variáveis de entrada e saída. A variedade de *softwares* e alternativas de modelagem é tão grande que, frequentemente, o analista pode ajustar um modelo cuja complexidade é maior do que a complexidade da relação, como mostra a Figura 3.2a. Nesse caso, diz-se que ocorreu sobre ajuste, ou **overfitting**, no jargão de ciência de dados.




Figura 3.2: Exemplo de regressão linear com *overfitting*: (a) treinamento; (b) teste.

O *overfitting* é um efeito indesejado, pois, como as perturbações são aleatórias, uma nova amostra de teste pode produzir dados diferentes dos que foram utilizados para o




Figura 3.1: Ejemplo de regresión lineal.

Suponiendo que la relación entre las variables de entrada y salida es lineal, los parámetros del modelo se pueden ajustar fácilmente minimizando el error total en el conjunto de entrenamiento. El problema es que, en la práctica, no se conocen o no existen elementos para determinar el tipo de función que relaciona las variables de entrada y salida. La variedad de *softwares* y alternativas de modelado es tan grande que el analista a menudo puede ajustar un modelo cuya complejidad es mayor que la complejidad de la relación, como se muestra en la Figura 3.2a. En este caso, se dice que se produjo un ajuste excesivo, o **overfitting** en la jerga de la ciencia de datos.




Figura 3.2: Ejemplo de regresión lineal con *overfitting*: (a) entrenamiento; (b) prueba.

overfitting es un efecto indeseable porque, como las perturbaciones son aleatorias, una nueva muestra de prueba puede producir datos diferentes a los utilizados para la prueba.

treinamento e, nesse caso, o erro produzido pelo modelo mais complexo é maior que aquele que seria obtido por um modelo mais próximo da relação ideal (cf. Figura 3.2b).

O raciocínio desenvolvido anteriormente para o modelo linear simples contém os elementos principais e resume o problema de regressão: como ajustar um modelo a partir de dados observados que seja o mais próximo possível da relação real entre as variáveis que geraram a amostra. A obtenção do modelo, portanto, depende da escolha adequada da forma da relação entre as variáveis de entrada e saída, que é a **estrutura** do modelo. Essa relação é geralmente representada por uma função matemática definida por um conjunto de parâmetros. O ajuste dos parâmetros do modelo é feito pela minimização do erro (ou resíduo) entre os valores observados e calculados pelo modelo da variável de saída no conjunto de treinamento. O método de ajuste de parâmetros da regressão linear é o método dos mínimos quadrados, apresentado na seção 3.1.2, mas antes definimos o modelo linear na próxima seção.

3.1.1 O Modelo linear

O modelo de regressão linear calcula uma estimativa $\hat{y}(t) \in \mathcal{R}$ da variável de saída a partir das variáveis de entrada $\mathbf{x}(t) \in \mathcal{R}^p$ e dos parâmetros do modelo como:

$$\hat{y}(t) = \hat{f}(\mathbf{x}(t), \boldsymbol{\theta}) = \hat{\mathbf{x}}(t)\boldsymbol{\theta}^T = \sum_{i=1}^n \hat{x}_i(t)\theta_i \quad (3.1)$$

onde os elementos do vetor $\hat{\mathbf{x}}(t) \in \mathcal{R}^n$ são chamados **regressores** do modelo e o vetor de **parâmetros** $\boldsymbol{\theta} = (\theta_1, \dots, \theta_n)$. A notação $\hat{f}(\mathbf{x}(t), \boldsymbol{\theta})$ indica que a previsão de $\hat{y}(t)$ calculada no ponto $\mathbf{x}(t)$ depende dos parâmetros $\boldsymbol{\theta}$.

O modelo $\hat{f}(\mathbf{x}(t), \boldsymbol{\theta})$ é uma aproximação da função real $y(t) = f(\mathbf{x}(t))$, que relaciona as variáveis de entrada com a saída observada, que em geral é desconhecida.

O termo “linear” de regressão linear indica que o modelo é linear nos parâmetros, ou seja, que o valor de saída é calculado como uma combinação linear dos regressores. No modelo linear simples, ou linear de primeira ordem, os regressores são as próprias variáveis de entrada e o modelo é um hiperplano. Nesse caso, o vetor de regressores é $\hat{\mathbf{x}}(t) = [1, \mathbf{x}(t)]$, onde o primeiro regressor é incluído para o ajuste do termo independente. O vetor de parâmetros tem dimensão $n = p + 1$ e o modelo escrito como:

entrenamiento y, en este caso, el error producido por el modelo más complejo es mayor que el que se obtendría con un modelo más cercano a la relación ideal (cf. Figura 3.2b).

El razonamiento desarrollado previamente para el modelo lineal simple contiene los elementos principales y resume el problema de regresión: cómo ajustar un modelo basado en datos observados que sea lo más cercano posible a la relación real entre las variables que generaron la muestra. La obtención del modelo, por tanto, depende de la elección adecuada de la forma de relación entre las variables de entrada y salida, que es la estructura del modelo. Esta relación suele estar representada por una función matemática definida por un conjunto de parámetros. El ajuste de los parámetros del modelo se realiza minimizando el error (o residual) entre los valores observados y calculados por el modelo de la variable de salida en el conjunto de entrenamiento. El método de ajuste de parámetros de regresión lineal es el método de mínimos cuadrados, presentado en la sección 3.1.2, pero primero definimos el modelo lineal en la siguiente sección.

3.1.1 El modelo lineal

El modelo de regresión lineal calcula una estimación $\hat{y}(t) \in \mathcal{R}$ de la variable de salida a partir de las variables de entrada $\mathbf{x}(t) \in \mathcal{R}^p$ y los parámetros del modelo como:

$$\hat{y}(t) = \hat{f}(\mathbf{x}(t), \boldsymbol{\theta}) = \hat{\mathbf{x}}(t)\boldsymbol{\theta}^T = \sum_{i=1}^n \hat{x}_i(t)\theta_i \quad (3.1)$$

donde los elementos del vector $\hat{\mathbf{x}}(t) \in \mathcal{R}^n$ se denominan regresores del modelo y el vector de parámetros $\boldsymbol{\theta} = (\theta_1, \dots, \theta_n)$. La notación $\hat{f}(\mathbf{x}(t), \boldsymbol{\theta})$ indica que la predicción de $\hat{y}(t)$ calculada en el punto $\mathbf{x}(t)$ depende de los parámetros $\boldsymbol{\theta}$.

El modelo $\hat{f}(\mathbf{x}(t), \boldsymbol{\theta})$ es una aproximación de la función real $y(t) = f(\mathbf{x}(t))$, que relaciona las variables de entrada con la salida observada, que generalmente es desconocida.

El término "lineal" en regresión lineal indica que el modelo es lineal en parámetros, es decir, que el valor de salida se calcula como una combinación lineal de los regresores. En el modelo lineal simple, o modelo lineal de primer orden, los regresores son las propias variables de entrada y el modelo es un hiperplano. En este caso, el vector de regresores es $\hat{\mathbf{x}}(t) = [1, \mathbf{x}(t)]$, donde se incluye el primer regresor para ajustar el término independiente. El vector de parámetros tiene dimensión $n = p + 1$ y el modelo se escribe como:

$$\hat{y}(t) = \hat{f}(\mathbf{x}(t), \boldsymbol{\theta}) = \theta_0 + \sum_{i=1}^p x_i(t) \theta_i \quad (3.2)$$

A formulação da regressão linear é geral o suficiente para acomodar outras estruturas de modelos mais complexos. Nesse caso, a formulação do modelo é uma combinação linear dos regressores, mas seu resultado é uma função não linear. De uma forma geral, o vetor de regressores é escrito como $\hat{\mathbf{x}}(t) = (1, h_1(\mathbf{x}(t)), \dots, h_n(\mathbf{x}(t)))$, onde $h_i(\mathbf{x}(t))$ são chamadas funções de base [238], como será visto no Capítulo 7.

Um exemplo de modelo linear que resulta em funções não lineares é o modelo polinomial, em que $h_i(\mathbf{x}(t)) = \mathbf{x}(t)^i$. O modelo linear polinomial de grau r é escrito na forma:

$$\hat{y}(t) = f(\mathbf{x}(t), \boldsymbol{\theta}) = \theta_0 + \sum_{i=1}^r \mathbf{x}(t)^i \boldsymbol{\theta}_i^T \quad (3.3)$$

onde o vetor de regressores $\hat{\mathbf{x}}(t) = [1, \mathbf{x}(t), \mathbf{x}(t)^2, \dots, \mathbf{x}(t)^r]$, desprezando-se os termos cruzados; $\boldsymbol{\theta}_i = (\theta_{i1}, \dots, \theta_{ip})$ é o vetor de parâmetros de cada termo do polinômio e o vetor de parâmetros do modelo $\boldsymbol{\theta} = [\theta_0, \boldsymbol{\theta}_1, \dots, \boldsymbol{\theta}_r]$, que tem $n = (r \cdot p) + 1$ elementos.

O ajuste dos parâmetros do modelo linear é realizado pela minimização do erro médio quadrático. O algoritmo de ajuste mais simples para regressão linear é o método dos mínimos quadrados, apresentado a seguir.

3.1.2 Método dos mínimos quadrados

O resultado do modelo geralmente não é igual ao valor observado da variável de saída e haverá sempre um erro ou resíduo $e(t) = y(t) - \hat{y}(t)$ (cf. Figura 3.1). Uma citação atribuída a George Box diz que “todos os modelos estão errados, alguns são úteis”.

A qualidade de um modelo de dados é medida por uma função de avaliação que mede a discrepância entre o valor observado e o valor calculado pelo modelo [98]. A função de avaliação utilizada em problemas de regressão linear é o erro médio quadrático (EMQ), calculado no conjunto de treinamento:

$$\text{EMQ}(\boldsymbol{\theta}) = \frac{1}{N} \sum_{t=1}^N (y(t) - \hat{y}(t))^2 = \frac{1}{N} \sum_{t=1}^N (y(t) - \hat{f}(\mathbf{x}(t), \boldsymbol{\theta}))^2 \quad (3.4)$$

$$\hat{y}(t) = \hat{f}(\mathbf{x}(t), \boldsymbol{\theta}) = \theta_0 + \sum_{i=1}^p x_i(t) \theta_i \quad (3.2)$$

La formulación de regresión lineal es lo suficientemente general como para dar cabida a otras estructuras de modelo más complejas. En este caso, la formulación del modelo es una combinación lineal de los regresores, pero su resultado es una función no lineal. En general, el vector de regresores se escribe como $\hat{\mathbf{x}}(t) = (1, h_1(\mathbf{x}(t)), \dots, h_n(\mathbf{x}(t)))$, donde $h_i(\mathbf{x}(t))$ se denominan funciones base [238], como se verá en el Capítulo 7.

Un ejemplo de modelo lineal que da como resultado funciones no lineales es el modelo polinomial, donde $h_i(\mathbf{x}(t)) = \mathbf{x}(t)^i$. El modelo lineal polinomial de grado r se escribe en la forma:

$$\hat{y}(t) = f(\mathbf{x}(t), \boldsymbol{\theta}) = \theta_0 + \sum_{i=1}^r \mathbf{x}(t)^i \boldsymbol{\theta}_i^T \quad (3.3)$$

donde el vector de regresores $\hat{\mathbf{x}}(t) = [1, \mathbf{x}(t), \mathbf{x}(t)^2, \dots, \mathbf{x}(t)^r]$, despreciando los términos cruzados; $\boldsymbol{\theta}_i = (\theta_{i1}, \dots, \theta_{ip})$ es el vector de parámetros de cada término del polinomio y el vector de parámetros del modelo $\boldsymbol{\theta} = [\theta_0, \boldsymbol{\theta}_1, \dots, \boldsymbol{\theta}_r]$, que tiene $n = (r \cdot p) + 1$ elementos.

El ajuste de los parámetros del modelo lineal se realiza minimizando el error cuadrático medio. El algoritmo de ajuste más simple para la regresión lineal es el método de mínimos cuadrados, que se presenta a continuación.

3.1.2 Método de mínimos cuadrados

El resultado del modelo generalmente no es igual al valor observado de la variable de salida y siempre habrá un error o residual $e(t) = y(t) - \hat{y}(t)$ (ver Figura 3.1). Una cita atribuida a George Box dice que “todos los modelos están equivocados, algunos son útiles”.

La calidad de un modelo de datos se mide mediante una función de evaluación que mide la discrepancia entre el valor observado y el valor calculado por el modelo [98]. La función de evaluación utilizada en problemas de regresión lineal es el error cuadrático medio (EMQ), calculado sobre el conjunto de entrenamiento:

$$\text{EMQ}(\boldsymbol{\theta}) = \frac{1}{N} \sum_{t=1}^N (y(t) - \hat{y}(t))^2 = \frac{1}{N} \sum_{t=1}^N (y(t) - \hat{f}(\mathbf{x}(t), \boldsymbol{\theta}))^2 \quad (3.4)$$

O EMQ é uma medida de distância entre o valor observado e o valor predito pelo modelo em cada registro do conjunto de treinamento. Estatisticamente, o EMQ pressupõe que o resíduo $e(t) = y(t) - \hat{y}(t)$ tem distribuição normal, de média nula e variância constante. Essa hipótese considera implicitamente que o processo que gerou os dados é estacionário, ou seja, que as características estatísticas permanecem estáveis. Nesse caso, a minimização do EMQ corresponde a maximizar a função de verossimilhança entre o modelo e a variável de saída [84][399], como será visto na seção 9.2.2

Se as hipóteses são satisfeitas, o ajuste dos parâmetros do modelo é realizado pela minimização do EMQ, o que caracteriza o **método dos mínimos quadrados** (MMQ). O MMQ produz os parâmetros de mínima variância [238]. Entretanto, nem sempre todas as hipóteses são satisfeitas, mas, mesmo assim, o MMQ obtém bons resultados.

A apresentação do MMQ é mais elegante considerando a matriz de saída $\mathbf{Y}$, cujos elementos são os valores das variáveis de saída de todos os registros do conjunto de treinamento, e a matriz $\hat{\mathbf{X}}$, cujas linhas contêm os regressores dos registros do conjunto de treinamento. Nesse caso, o EMQ é escrito como:

$$EMQ(\boldsymbol{\theta}) = \frac{1}{N} (\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}^T)^T (\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}^T) \quad (3.5)$$

$$\text{onde } \hat{\mathbf{X}} = \begin{bmatrix} \hat{x}_1(1) & \cdots & \hat{x}_n(1) \\ \vdots & \ddots & \vdots \\ \hat{x}_1(N) & \cdots & \hat{x}_n(N) \end{bmatrix}, \boldsymbol{\theta}^T = \begin{bmatrix} \theta_1 \\ \vdots \\ \theta_n \end{bmatrix} \text{ e, no caso de saída simples, } \mathbf{Y} = \begin{bmatrix} y(1) \\ \vdots \\ y(N) \end{bmatrix}.$$

Os parâmetros que minimizam o EMQ são calculados a partir da derivada do EMQ em relação a $\boldsymbol{\theta}$, escrita como:

$$\frac{\partial EMQ(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = -\frac{2}{N} \hat{\mathbf{X}}^T (\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}^T) \quad (3.6)$$

A solução é obtida igualando a derivada do EMQ a zero, o que resulta no seguinte sistema linear de equações, chamado de **equações normais** do MMQ:

$$\hat{\mathbf{X}}^T \hat{\mathbf{X}} \boldsymbol{\theta}^T = \hat{\mathbf{X}}^T \mathbf{Y} \quad (3.7)$$

Considerando que a matriz de regressores tem posto completo, isto é, $rank(\hat{\mathbf{X}}) = n$, a solução do sistema linear (3.6) pode ser calculada como

$$\boldsymbol{\theta}^* = (\hat{\mathbf{X}}^T \hat{\mathbf{X}})^{-1} \hat{\mathbf{X}}^T \mathbf{Y} \quad (3.8)$$

EMQ es una medida de la distancia entre el valor observado y el valor predicho por el modelo en cada registro del conjunto de entrenamiento. Estadísticamente, EMQ supone que el residuo $e(t) = y(t) - \hat{y}(t)$ tiene una distribución normal, media cero y varianza constante. Esta hipótesis considera implícitamente que el proceso que generó los datos es estacionario, es decir, que las características estadísticas se mantienen estables. En este caso, minimizar el EMQ corresponde a maximizar la función de verosimilitud entre el modelo y la variable de salida [84][399], como se verá en el apartado 9.2.2.

Si se cumplen las hipótesis, el ajuste de los parámetros del modelo se realiza minimizando el EMQ, que caracteriza el método de mínimos cuadrados (MMQ). El MMQ produce los parámetros de varianza mínima [238]. Sin embargo, no siempre se cumplen todas las hipótesis, pero aun así el MMQ obtiene buenos resultados.

La presentación MMQ es más elegante considerando la matriz de salida $\mathbf{Y}$, cuyos elementos son los valores de las variables de salida de todos los registros del conjunto de entrenamiento, y la matriz $\hat{\mathbf{X}}$ cuyas líneas contienen los regresores de los registros del conjunto de entrenamiento. En este caso, el EMQ se escribe como:

$$EMQ(\boldsymbol{\theta}) = \frac{1}{N} (\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}^T)^T (\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}^T) \quad (3.5)$$

onde $\hat{\mathbf{X}} = \begin{bmatrix} \hat{x}_1(1) & \cdots & \hat{x}_n(1) \\ \vdots & \ddots & \vdots \\ \hat{x}_1(N) & \cdots & \hat{x}_n(N) \end{bmatrix}$, $\boldsymbol{\theta}^T = \begin{bmatrix} \theta_1 \\ \vdots \\ \theta_n \end{bmatrix}$ e, no caso de saída simples, $\mathbf{Y} = \begin{bmatrix} y(1) \\ \vdots \\ y(N) \end{bmatrix}$.

Los parámetros que minimizan EMQ se calculan a partir de la derivada de EMQ respecto de $\boldsymbol{\theta}$, escrita como:

$$\frac{\partial EMQ(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = -\frac{2}{N} \hat{\mathbf{X}}^T (\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}^T) \quad (3.6)$$

La solución se obtiene igualando la derivada EMQ a cero, lo que da como resultado el siguiente sistema lineal de ecuaciones, llamado ecuaciones normales MMQ:

$$\hat{\mathbf{X}}^T \hat{\mathbf{X}} \boldsymbol{\theta}^T = \hat{\mathbf{X}}^T \mathbf{Y} \quad (3.7)$$

Considerando que la matriz de regresores tiene rango completo, es decir, $rank(\hat{\mathbf{X}}) = n$, la solución del sistema lineal (3.6) se puede calcular como

$$\boldsymbol{\theta}^* = (\hat{\mathbf{X}}^T \hat{\mathbf{X}})^{-1} \hat{\mathbf{X}}^T \mathbf{Y} \quad (3.8)$$

onde a matriz $(\hat{\mathbf{X}}^T \hat{\mathbf{X}})^{-1} \hat{\mathbf{X}}^T$ é chamada de **pseudoinversa** de $\hat{\mathbf{X}}$.

Os valores preditos pelo modelo para os registros do conjunto de treinamento podem ser calculados a partir da solução (3.8) como:

$$\hat{\mathbf{Y}} = \hat{\mathbf{X}} \boldsymbol{\theta}^* = \hat{\mathbf{X}} (\hat{\mathbf{X}}^T \hat{\mathbf{X}})^{-1} \hat{\mathbf{X}}^T \mathbf{Y} = \mathbf{H} \mathbf{Y} \quad (3.9)$$

A matriz $\mathbf{H} = \hat{\mathbf{X}} (\hat{\mathbf{X}}^T \hat{\mathbf{X}})^{-1} \hat{\mathbf{X}}^T$, de dimensão $N \times N$, é chamada de “matriz chapéu” [238][399], pois “coloca o chapéu” em $\mathbf{Y}$.

A solução do MMQ pela equação (3.8) é computacionalmente complexa, pois envolve o cálculo da inversa da matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$. Caso o posto da matriz de regressores não seja completo, a equação (3.8) pode se tornar instável numericamente. Há alternativas para o cálculo dos parâmetros do modelo linear que serão discutidas na seção 3.2.

3.1.3 Interpretação geométrica

O método dos mínimos quadrados tem uma interpretação geométrica mostrada na Figura 3.3. Suponha que cada registro observado da variável de saída representa uma coordenada no espaço N -dimensional, chamado de espaço amostral, de forma que o conjunto de registros da variável de saída define o vetor $\mathbf{Y} \in \mathcal{R}^N$. Cada coluna da matriz de regressores $\hat{\mathbf{X}} \in \mathcal{R}^{N \times n}$ também é um vetor no espaço amostral e as n colunas da matriz de regressores definem um subespaço de dimensão n , chamado subespaço do modelo, representado pela área em cinza na Figura 3.3.

Todos os modelos lineares $\hat{\mathbf{Y}} = \hat{\mathbf{X}} \boldsymbol{\theta}^T$, ou seja, todas as combinações lineares dos regressores, estão definidos no subespaço do modelo. A distância entre $\hat{\mathbf{Y}} = \hat{\mathbf{X}} \boldsymbol{\theta}^T$ e o vetor de observações $\mathbf{Y}$ é calculada como:

$$dist(\boldsymbol{\theta}) = \|\mathbf{Y} - \hat{\mathbf{X}} \boldsymbol{\theta}^T\| = \sqrt{(\mathbf{Y} - \hat{\mathbf{X}} \boldsymbol{\theta}^T)^T (\mathbf{Y} - \hat{\mathbf{X}} \boldsymbol{\theta}^T)} \quad (3.10)$$

A equação (3.10) mostra que o $EMQ(\boldsymbol{\theta}) = dist^2(\boldsymbol{\theta})/N$, de forma que a solução $\boldsymbol{\theta}^*$ que minimiza o EMQ produz o resíduo de menor norma L^2 . Dessa forma, o modelo deve ser ortogonal ao resíduo:

$$\hat{\mathbf{Y}}^T (\mathbf{Y} - \hat{\mathbf{X}} \boldsymbol{\theta}^*) = 0 \quad (3.11)$$

A equação (3.11) indica que o resíduo não deve ser correlacionado com os resultados do modelo. Na prática o EMQ não é nulo e a igualdade apresentada na equação (3.11)

donde la matriz $(\hat{\mathbf{X}}^T \hat{\mathbf{X}})^{-1} \hat{\mathbf{X}}^T$ se llama pseudoinversa de $\hat{\mathbf{X}}$

Los valores predichos por el modelo para los registros del conjunto de entrenamiento se pueden calcular a partir de la solución (3.8) como:

$$\hat{\mathbf{Y}} = \hat{\mathbf{X}} \boldsymbol{\theta}^* = \hat{\mathbf{X}} (\hat{\mathbf{X}}^T \hat{\mathbf{X}})^{-1} \hat{\mathbf{X}}^T \mathbf{Y} = \mathbf{H} \mathbf{Y} \quad (3.9)$$

La matriz $\mathbf{H} = \hat{\mathbf{X}} (\hat{\mathbf{X}}^T \hat{\mathbf{X}})^{-1} \hat{\mathbf{X}}^T$, de dimensión $N \times N$, se denomina “matriz del sombrero” [238][399], ya que “pone el sombrero” en $\mathbf{Y}$.

La solución MMQ usando la ecuación (3.8) es computacionalmente compleja, ya que implica calcular la inversa de la matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$. Si el rango de la matriz regresora no es completo, la ecuación (3.8) puede volverse numéricamente inestable. Existen alternativas para calcular los parámetros del modelo lineal que se discutirán en la sección 3.2.

3.1.3 Interpretación geométrica

El método de mínimos cuadrados tiene una interpretación geométrica que se muestra en la Figura 3.3. Supongamos que cada registro observado de la variable de salida representa una coordenada en el espacio de dimensión N , llamado espacio muestral, de modo que el conjunto de registros de la variable de salida define el vector $\mathbf{Y} \in \mathcal{R}^N$. Cada columna de la matriz regresora $\hat{\mathbf{X}} \in \mathcal{R}^{N \times n}$ es también un vector en el espacio muestral y las columnas n de la matriz regresora definen un subespacio de dimensión n , llamado subespacio modelo, representado por el área gris en la Figura 3.3.

Todos los modelos lineales $\hat{\mathbf{Y}} = \hat{\mathbf{X}} \boldsymbol{\theta}^T$, es decir, todas las combinaciones lineales de regresores, se definen en el subespacio del modelo. La distancia entre $\hat{\mathbf{Y}} = \hat{\mathbf{X}} \boldsymbol{\theta}^T$ y el vector de observación $\mathbf{Y}$ se calcula como:

$$dist(\boldsymbol{\theta}) = \|\mathbf{Y} - \hat{\mathbf{X}} \boldsymbol{\theta}^T\| = \sqrt{(\mathbf{Y} - \hat{\mathbf{X}} \boldsymbol{\theta}^T)^T (\mathbf{Y} - \hat{\mathbf{X}} \boldsymbol{\theta}^T)} \quad (3.10)$$

La ecuación (3.10) muestra que $EMQ(\boldsymbol{\theta}) = dist^2(\boldsymbol{\theta})/N$, de modo que la solución $\boldsymbol{\theta}^*$ que minimiza el EMQ produce el residuo de norma más baja L^2 . Por tanto, el modelo debe ser ortogonal al residuo:

$$\hat{\mathbf{Y}}^T (\mathbf{Y} - \hat{\mathbf{X}} \boldsymbol{\theta}^*) = 0 \quad (3.11)$$

La ecuación (3.11) indica que el residuo no debe correlacionarse con los resultados del modelo. En la práctica, EMQ no es nula y la igualdad presentada en la ecuación (3.11)

não se verifica, mas esse resultado fornece um teste para validação do modelo de regressão linear. Outras estatísticas de validação serão discutidas na seção 3.3.

A Figura 3.3 mostra um exemplo da interpretação geométrica discutida no caso do de um modelo linear simples de uma amostra de dimensão $N = 3$ registros. O exemplo foi gerado com o conjunto de dados $\mathcal{T} = \{(0.2, 0.6), (0.5, 0.2), (0.7, 0.9)\}$. A matriz $\hat{\mathbf{X}} = [\mathbf{1}, \mathbf{X}]$ é a matriz de regressores que define o subespaço vetorial do modelo (em cinza), formado pelo vetor $\mathbf{1}$, cujos elementos são todos 1, e o vetor $\mathbf{X} = [0.2, 0.5, 0.7]^T$, cujos elementos são os registros da variável de entrada.

O resultado do ajuste do modelo pelo MMQ é o vetor de parâmetros $\boldsymbol{\theta}^* = [0.35, 0.44]^T$, que resulta na estimativa $\hat{\mathbf{Y}} = [0.44, 0.58, 0.67]^T$. Observe que o vetor de resíduos é ortogonal ao vetor de estimativas localizado no subespaço vetorial do modelo (em cinza).




Figura 3.3: Interpretação geométrica do método dos mínimos quadrados.

A interpretação geométrica também mostra intuitivamente que a dimensão do espaço de modelo não pode ser maior que a dimensão do espaço amostral, isto é, $n < N$. Caso contrário, o modelo seria mais complexo que a própria amostra. A modelagem pode ser entendida como um processo de compactação da informação em que os N registros da amostra são representados pelos n parâmetros do modelo.

A dimensão da amostra em relação à dimensão do modelo é uma questão importante e que tem grande influência na qualidade do modelo. Quanto maior o tamanho da amostra, melhor é o desempenho do MMQ. Na prática, o número de registros de uma amos-

Esto no está verificado, pero este resultado proporciona una prueba para validar el modelo de regresión lineal. Otras estadísticas de validación se discutirán en la sección 3.3.

La figura 3.3 muestra un ejemplo de la interpretación geométrica analizada en el caso de un modelo lineal simple de una muestra de registros de dimensión $N = 3$. El ejemplo se generó con el conjunto de datos $\mathcal{T} = \{(0.2, 0.6), (0.5, 0.2), (0.7, 0.9)\}$. La matriz $\hat{\mathbf{X}} = [\mathbf{1}, \mathbf{X}]$ es la matriz de regresores que define el subespacio vectorial del modelo (en gris), formado por el vector $\mathbf{1}$, cuyos elementos son todos 1, y el vector $\mathbf{X} = [0.2, 0.5, 0.7]^T$, cuyos elementos son los registros de la variable de entrada.

El resultado del ajuste del modelo por MMQ es el vector de parámetros $\boldsymbol{\theta}^* = [0.35, 0.44]^T$, que da como resultado la estimación $\hat{\mathbf{Y}} = [0.44, 0.58, 0.67]^T$. Tenga en cuenta que el vector residual es ortogonal al vector de estimación ubicado en el subespacio vectorial del modelo (en gris).




Figura 3.3: Interpretación geométrica del método de mínimos cuadrados.

La interpretación geométrica también muestra intuitivamente que la dimensión del espacio modelo no puede ser mayor que la dimensión del espacio muestral, es decir, $n < N$. De lo contrario, el modelo sería más complejo que la muestra misma. El modelado puede entenderse como un proceso de compresión de información en el que los registros de muestra N están representados por los parámetros del modelo n .

El tamaño de la muestra en relación con el tamaño del modelo es un tema importante que tiene una gran influencia en la calidad del modelo. Cuanto mayor sea el tamaño de la muestra, mejor será el rendimiento del MMQ. En la práctica, el número de registros en una muestra

tra pode não ser muito grande quando há um custo associado à observação dos registros. Para obter uma amostragem relativamente densa em espaços de alta dimensionalidade, o número de registros necessários aumenta exponencialmente com o número de variáveis de entrada. Em espaços de alta dimensão, os dados se tornam altamente esparsos. Hastie, Tibshirani e Friedman [238] mostram um exemplo em que consideram uma amostragem uniforme num hipercubo de lado unitário. Nesse caso, para um problema de dimensão $p = 10$, é necessário utilizar 80% de cada dimensão para capturar 10% dos dados. Esse efeito é conhecido na literatura como a “maldição da dimensionalidade” [98][238].

Na próxima seção, apresentamos um exemplo simples no qual se discute o efeito da escolha da estrutura do modelo no resultado da modelagem.

3.1.4 Exemplo sintético

Neste exemplo, o conjunto de dados foi gerado a partir da função $y = x^2$, adicionando uma perturbação aleatória de média nula e desvio padrão 0.2. A Figura 3.4a mostra o conjunto de dados e a função $y = x^2$ no domínio da amostra.

Foram gerados três modelos a partir desse conjunto de dados: um modelo linear simples ou polinomial de grau $r = 1$; um polinomial de grau $r = 2$; e um polinomial de grau $r = 10$. Como nesse problema a variável de entrada tem apenas uma dimensão, a expressão do modelo polinomial da equação (3.3) se reduz a $\hat{y}(t) = \theta_0 + \sum_{i=1}^r x^i \theta_i$ e o modelo tem $n = r + 1$ parâmetros.

Os resultados do ajuste de cada um desses modelos são mostrados, respectivamente, nas Figura 3.4b, Figura 3.4c e Figura 3.4d. O modelo linear simples não representa bem a relação real, que é mais complexa. No caso do modelo polinomial $r = 10$, a complexidade do modelo é muito superior à da relação e seu resultado foi corrompido pela presença do ruído. No caso do modelo polinomial de grau $r = 2$, o resultado do modelo é muito próximo da função $y = x^2$ utilizada para gerar a amostra, pois o modelo foi ajustado com a estrutura correta.

A Tabela 3.1 mostra os parâmetros ajustados para cada um dos modelos. Podemos observar que o modelo linear simples é praticamente a média da variável de saída. No caso do modelo polinomial de grau $r = 2$, os parâmetros ajustados pelo MMQ correspondem aos da relação real até a primeira casa decimal. No caso do modelo polinomial

tra puede no ser muy grande cuando existe un costo asociado con la observación de los registros. Para obtener un muestreo relativamente denso en espacios de alta dimensión, la cantidad de registros necesarios aumenta exponencialmente con la cantidad de variables de entrada. En espacios de alta dimensión, los datos se vuelven muy escasos. Hastie, Tibshirani y Friedman [238] muestran un ejemplo en el que consideran un muestreo uniforme en un hipercubo con lado unitario. En este caso, para un problema de dimensión $p = 10$, es necesario utilizar el 80% de cada dimensión para capturar el 10% de los datos. Este efecto se conoce en la literatura como la “maldición de la dimensionalidad” [98][238].

En la siguiente sección, presentamos un ejemplo simple en el que se analiza el efecto de la elección de la estructura del modelo en el resultado del modelado.

3.1.4 Ejemplo sintético

En este ejemplo, el conjunto de datos se generó a partir de la función $y = x^2$, agregando una perturbación aleatoria con media cero y desviación estándar de 0,2. La Figura 3.4a muestra el conjunto de datos y la función $y = x^2$ en el dominio de muestra.

Se generaron tres modelos a partir de este conjunto de datos: un modelo lineal o polinómico simple de grado $r = 1$; un polinomio de grado $r = 2$; y un polinomio de grado $r = 10$. Como en este problema la variable de entrada tiene una sola dimensión, la expresión del modelo o polinomial en la ecuación (3.3) se reduce a $\hat{y}(t) = \theta_0 + \sum_{i=1}^r x^i \theta_i$ y el modelo tiene $n = r + 1$ parámetros.

Los resultados del ajuste de cada uno de estos modelos se muestran, respectivamente, en la Figura 3.4b, Figura 3.4c y Figura 3.4d. El modelo lineal simple no representa bien la relación real, que es más compleja. En el caso del modelo polinomial $r = 10$, la complejidad del modelo es mucho mayor que la de la relación y su resultado fue corrompido por la presencia de ruido. En el caso del modelo polinomial de grado $r = 2$, el resultado del modelo es muy cercano a la función $y = x^2$ utilizada para generar la muestra, ya que el modelo fue ajustado con la estructura correcta.

La Tabla 3.1 muestra los parámetros ajustados para cada uno de los modelos. Podemos observar que el modelo lineal simple es prácticamente el promedio de la variable de salida. En el caso del modelo polinómico de grado $r = 2$, los parámetros ajustados por MMQ corresponden a los de la relación real hasta el primer decimal. En el caso del modelo polinómico

de grau $r = 10$, alguns parâmetros têm valores muito grandes em relação à escala da variável de saída, o indica que o ajuste realizado por esse modelo não foi adequado.




Figura 3.4: Exemplo de ajuste de parâmetros pelo MMQ: (a) conjunto de dados; (b) modelo linear puro; (c) modelo polinomial de grau 2; (d) modelo polinomial de grau 10.

O exemplo apresentado na Figura 3.4 mostra que o *overfitting* ocorre quando a complexidade do modelo é inadequada para a amostra. Entretanto, o MMQ pode ajustar adequadamente um modelo, mesmo de complexidade inadequada, quando o conjunto de dados for suficientemente grande. A Figura 3.5 mostra o resultado do modelo polinomial de grau 10 no caso de uma amostra com $N = 200$ e $N = 400$ registros.

Podemos observar que, mesmo com a complexidade do modelo sendo maior que a da relação real, um modelo adequado é ajustado com maior número de registros. Dessa forma, o *overfitting* ocorre quando a complexidade do modelo é maior que a da relação e, adicionalmente, o tamanho da amostra é pequeno em relação à complexidade do mo-

grado $r = 10$, algunos parámetros tienen valores muy grandes en relación con la escala de la variable de salida, lo que indica que el ajuste realizado por este modelo no fue el adecuado.




Figura 3.4: Ejemplo de ajuste de parámetros por MMQ: (a) conjunto de datos; (b) modelo lineal puro; (c) modelo polinomial de grado 2; (d) modelo polinómico de grado 10.

El ejemplo presentado en la Figura 3.4 muestra que *overfitting* ocurre cuando la complejidad del modelo es inadecuada para la muestra. Sin embargo, MMQ puede ajustarse adecuadamente a un modelo, incluso de complejidad inadecuada, cuando el conjunto de datos es lo suficientemente grande. La Figura 3.5 muestra el resultado del modelo polinómico de grado 10 para el caso de una muestra con registros $N = 200$ y $N = 400$.

Podemos observar que, incluso siendo la complejidad del modelo mayor que la de la relación real, un modelo adecuado se ajusta con un mayor número de registros. Así, *overfitting* ocurre cuando la complejidad del modelo es mayor que la de la relación y, adicionalmente, el tamaño de la muestra es pequeño en relación con la complejidad del modelo.

delo que se pretende ajustar. Há técnicas de combinação de modelos (chamadas de *ensembles*) como o *Boosting* [185][186] que exploram a ponderação do conjunto de dados de treinamento para o aumento de desempenho dos modelos. A relação entre a complexidade do modelo e o tamanho da amostra será explorada no Capítulo 7.

Tabela 3.1: Parâmetros ajustados dos modelos da Figura 3.4

θ	$r = 1$	$r = 2$	$r = 10$
θ_0	0.4131	0.0104	-0.1394
θ_1	-0.0325	-0.0325	-0.8151
θ_2		1.0983	8.455
θ_3			6.2056
θ_4			-53.2585
θ_5			-15.7255
θ_6			132.2678
θ_7			16.2839
θ_8			-133.545
θ_9			-5.9739
θ_{10}			47.2605




Figura 3.5: Efeito do número de registros no modelo de grau 10: (a) $N = 200$; (b) $N = 400$.

No MMQ, mesmo com uma amostra reduzida, é possível controlar a complexidade do modelo e encontrar uma solução estável para o sistema linear (3.7) através de técnicas de regularização, apresentadas a seguir.

de lo que quieres ajustar. Existen técnicas de combinación de modelos (llamadas *ensembles*) como *Boosting* [185][186] que explotan la ponderación del conjunto de datos de entrenamiento para aumentar el rendimiento del modelo. La relación entre la complejidad del modelo y el tamaño de la muestra se explorará en el Capítulo 7.

Tabla 3.1: Parámetros ajustados de los modelos en la Figura 3.4

θ	$r = 1$	$r = 2$	$r = 10$
θ_0	0.4131	0.0104	-0.1394
θ_1	-0.0325	-0.0325	-0.8151
θ_2		1.0983	8.455
θ_3			6.2056
θ_4			-53.2585
θ_5			-15.7255
θ_6			132.2678
θ_7			16.2839
θ_8			-133.545
θ_9			-5.9739
θ_{10}			47.2605




Figura 3.5: Efecto del número de registros en el modelo de grado 10: (a) $N = 200$; (b) $N = 400$.

En MMQ, incluso con una muestra reducida, es posible controlar la complejidad del modelo y encontrar una solución estable para el sistema lineal (3.7) mediante técnicas de regularización, que se presentan a continuación.

3.2 Regularização

O desenvolvimento de um modelo em ciência de dados é, essencialmente, um processo de escolha, muitas vezes chamado de treinamento ou “aprendizado” [98], que pode ser resumido nas seguintes etapas:

1. Pré-seleção de um conjunto de funções $\mathcal{F}$ que pode conter um elemento capaz de ajustar o mapeamento entrada-saída representado pelo conjunto de treinamento. Em geral, esse passo é definido pela escolha do **tipo** de modelo.
2. Definição de um conjunto de hipóteses ou conhecimento *a priori* que estabelece restrições à família de funções $\mathcal{F}$ como solução do problema. Essas restrições visam limitar o espaço de soluções a um subconjunto $\mathcal{F}^* \subseteq \mathcal{F}$ e, em alguns casos, podem ser definidas através de parâmetros. Esse passo é chamado de seleção da **estrutura** do modelo.
3. Definição de uma medida (ou função) de avaliação da qualidade de uma instância $f \in \mathcal{F}^*$. A função de avaliação é utilizada na formulação de um **problema de otimização** cuja solução define a aproximação ótima f^* .
4. Utilização de um algoritmo de otimização para o problema formulado em 3) cuja solução são os **parâmetros ajustados** do modelo.

No caso do exemplo sintético da seção 3.1.4, o passo (1) corresponde à seleção do modelo polinomial de grau r . No passo (2), foram selecionadas três estruturas de modelos através da escolha do grau do polinômio. O processo indutivo associado ao MMQ é a minimização do EMQ e a solução é definida pela equação (3.8). Ao longo deste livro, alternativas para cada um desses passos serão apresentadas para que se possa encontrar a melhor solução em diferentes problemas.

Atualmente, o analista tem à sua disposição uma grande variedade de modelos em *softwares* livres e comerciais. Em muitos casos, o problema de *overfitting* não se mostra tão óbvio quanto no exemplo apresentado pela Figura 3.4d. Dessa forma, é importante entender as causas de *overfitting* para construir bons modelos, ou seja, modelos com boa capacidade de generalização.

A regularização é uma técnica que permite reduzir a complexidade do modelo para a obtenção de um modelo mais estável que permita melhor generalização para dados

3.2 Regularización

Desarrollar un modelo en ciencia de datos es esencialmente un proceso de elección, a menudo llamado entrenamiento o “aprendizaje” [98], que se puede resumir en los siguientes pasos:

1. Preselección de un conjunto de funciones $\mathcal{F}$ que pueden contener un elemento capaz de ajustar el mapeo entrada-salida representado por el conjunto de entrenamiento. En general, este paso se define por la elección del tipo de modelo.
2. Definición de un conjunto de hipótesis o conocimientos *a priori* que establezca restricciones a la familia de funciones $\mathcal{F}$ como solución al problema. Estas restricciones tienen como objetivo limitar el espacio de soluciones a un subconjunto $\mathcal{F}^* \subseteq \mathcal{F}$ y, en algunos casos, pueden definirse mediante parámetros. Este paso se llama selección de la estructura del modelo.
3. Definición de una medida (o función) para evaluar la calidad de una instancia $f \in \mathcal{F}^*$. La función de evaluación se utiliza en la formulación de un problema de optimización cuya solución define la aproximación óptima f^* .
4. Uso de un algoritmo de optimización para el problema formulado en 3) cuya solución son los parámetros ajustados del modelo.

En el caso del ejemplo sintético del apartado 3.1.4, el paso (1) corresponde a la selección del modelo polinomial de grado r . En el paso (2), se seleccionaron tres estructuras modelo eligiendo el grado del polinomio. El proceso inductivo asociado con MMQ es la minimización de EMQ y la solución está definida por la ecuación (3.8). A lo largo de este libro, se presentarán alternativas para cada uno de estos pasos, de modo que se pueda encontrar la mejor solución para diferentes problemas.

Actualmente, el analista tiene a su disposición una amplia variedad de modelos *softwares* gratuitos y comerciales. En muchos casos, el problema *overfitting* no es tan obvio como en el ejemplo presentado en la Figura 3.4d. Por tanto, es importante comprender las causas de *overfitting* para construir buenos modelos, es decir, modelos con buena capacidad de generalización.

La regularización es una técnica que permite reducir la complejidad del modelo para obtener un modelo más estable que permita una mejor generalización a los datos.

diferentes dos que foram utilizados no ajuste de parâmetros. As técnicas de regularização estão fortemente associadas à relação *bias* e variância, apresentada a seguir.

3.2.1 *Bias* e variância

A estimativa de um modelo com *overfitting* depende da amostra utilizada para o ajuste do modelo. A parcela do EMQ (cf. equação (3.4)) calculada para um ponto qualquer $\mathbf{x}(t)$ do conjunto de treinamento é uma estimativa do valor esperado* do erro quadrático nesse ponto quando o número de amostras $N \rightarrow \infty$ [187]:

$$\lim_{N \rightarrow \infty} (y(t) - \hat{f}(\mathbf{x}(t), \boldsymbol{\theta}))^2 = E \left((y_r(t) - \hat{f}(\mathbf{x}(t), \boldsymbol{\theta}))^2 \right) \quad (3.12)$$

onde $y_r(t) = E(y(t))$ é o valor da função real em $\mathbf{x}(t)$.

A equação (3.12) é válida para qualquer registro do conjunto de treinamento e podemos escrever $y_r(t) = y_r$ e $f(\mathbf{x}(t), \boldsymbol{\theta}) = \hat{y}$ para simplificar a notação. O valor esperado do erro quadrático em $\mathbf{x}(t)$ pode ser decomposto em dois fatores [238] como:

$$\begin{aligned} E((y_r - \hat{y})^2) &= (y_r - E(\hat{y}))^2 + E \left((\hat{y} - E(\hat{y}))^2 \right) \\ &= \text{bias}^2 + \text{variância} \end{aligned} \quad (3.13)$$

O termo $(y_r - E(\hat{y}))$ é chamado ***bias*** teórico do modelo e o termo $E \left((\hat{y} - E(\hat{y}))^2 \right)$ é chamado de ***variância*** teórica do modelo. O *bias* é, então, a diferença entre o valor real da função em $\mathbf{x}(t)$ e o valor esperado da aproximação naquele ponto. A variância é o valor esperado da diferença entre uma estimativa do modelo e o valor esperado de todas as estimativas.

Uma aproximação do cálculo do valor esperado pode ser feita pela média em várias realizações da variável aleatória, o que permite uma visualização do efeito do *bias* e da variância nos resultados do ajuste dos modelos do exemplo da Figura 3.4. Para isso, 10 amostras de $N = 20$ registros foram geradas a partir da função $y_r = x^2 + \varepsilon$, onde o ruído ε foi gerado por uma distribuição normal $\varepsilon \sim N(0, 0.2)$. O *bias* e a variância em todos os pontos foram calculados pela decomposição (3.13). Para se ter uma ideia desses valores para cada modelo, foi calculada a média para todos os pontos, uma vez que os

* O valor esperado é definido como $E(x) = \int_{-\infty}^{\infty} xp(x)dx$, onde $p(x)$ é a função densidade de probabilidades da variável aleatória. O valor esperado pode ser aproximado pela média aritmética de todas as realizações da variável aleatória [400].

diferentes a los utilizados en el ajuste de parámetros. Las técnicas de regularización están fuertemente asociadas con la relación *bias* y la varianza, que se presentan a continuación.

3.2.1 *Bias* y varianza

La estimación de un modelo con *overfitting* depende de la muestra utilizada para ajustar el modelo. La porción de EMQ (cf. ecuación (3.4)) calculada para cualquier punto $\mathbf{x}(t)$ del conjunto de entrenamiento es una estimación del valor esperado * del error al cuadrado en ese punto cuando el número de muestras $N \rightarrow \infty$ [187]:

$$\lim_{N \rightarrow \infty} (y(t) - \hat{f}(\mathbf{x}(t), \boldsymbol{\theta}))^2 = E \left((y_r(t) - \hat{f}(\mathbf{x}(t), \boldsymbol{\theta}))^2 \right) \quad (3.12)$$

donde $y_r(t) = E(y(t))$ es el valor de la función real en $\mathbf{x}(t)$.

La ecuación (3.12) es válida para cualquier registro del conjunto de entrenamiento y podemos escribir $y_r(t) = y_r$ y $f(\mathbf{x}(t), \boldsymbol{\theta}) = \hat{y}$ para simplificar la notación. El valor esperado del error al cuadrado en $\mathbf{x}(t)$ se puede descomponer en dos factores [238] como:

$$\begin{aligned} E((y_r - \hat{y})^2) &= (y_r - E(\hat{y}))^2 + E((\hat{y} - E(\hat{y}))^2) \\ &= \text{bias}^2 + \text{variância} \end{aligned} \quad (3.13)$$

El término $(y_r - E(\hat{y}))$ se llama modelo teórico ***bias*** y el término $E((\hat{y} - E(\hat{y}))^2)$ se llama varianza teórica del modelo. El *bias* es entonces la diferencia entre el valor real de la función en $\mathbf{x}(t)$ y el valor esperado de la aproximación en ese punto. La varianza es el valor esperado de la diferencia entre la estimación de un modelo y el valor esperado de todas las estimaciones.

Se puede realizar una aproximación del cálculo del valor esperado promediando varias realizaciones de la variable aleatoria, lo que permite visualizar el efecto de *bias* y la varianza sobre los resultados del ajuste de los modelos en el ejemplo de la Figura 3.4. Para esto se generaron 10 muestras de registros $N = 20$ a partir de la función $y_r = x^2 + \varepsilon$, donde el ruido ε fue generado por una distribución normal $\varepsilon \sim N(0, 0.2)$. La *bias* y la varianza en todos los puntos se calcularon mediante descomposición (3.13). Para tener una idea de estos valores para cada modelo, se calculó el promedio de todos los puntos, ya que el

* O valor esperado é definido como $E(x) = \int_{-\infty}^{\infty} xp(x)dx$, onde $p(x)$ é a função densidade de probabilidades da variável aleatória. O valor esperado pode ser aproximado pela média aritmética de todas as realizações da variável aleatória [400].

valores da variável de entrada permanecem os mesmos para todas as amostras. O resultado é mostrado na Figura 3.6a para o modelo linear simples e na Figura 3.6b para o modelo polinomial de grau 10. Nos dois gráficos da Figura 3.6, a curva verde apresenta a função real $y_r = x^2$, os pontos das amostras são mostrados em azul, o modelo ajustado $\hat{y}$ com cada amostra em vermelho e a média dos modelos entre todas as amostras em preto.

Os dois casos apresentam uma estrutura inadequada, como já foi discutido. O modelo linear simples apresenta o *bias* elevado, mas uma variância pequena, enquanto o modelo de grau 10 apresenta um *bias* pequeno e uma alta variância, mostrando que é mais sensível à amostra que o primeiro.




Figura 3.6: *Bias* e variância: (a) modelo linear simples; (b) modelo de grau 10.

Os resultados dos modelos ajustados com a estrutura correta, ou seja, um polinômio de grau 2, são mostrados na Figura 3.7. Podemos observar que o modelo com a estrutura correta é capaz de minimizar simultaneamente o *bias* e a variância e que a média de todos os modelos aproxima bem a função real.

A simulação anterior permite concluir que o *bias* acontece quando a complexidade do modelo é inferior à da função real e que a variância é o efeito da instabilidade de modelos muito complexos em relação ao tamanho da amostra. O objetivo das técnicas de regularização é a redução da variância de um modelo de alta complexidade para que o modelo se torne adequado à complexidade do problema, mantendo o *bias* baixo.

Los valores de las variables de entrada siguen siendo los mismos para todas las muestras. El resultado se muestra en la Figura 3.6a para el modelo lineal simple y en la Figura 3.6b para el modelo polinómico de grado 10. En los dos gráficos de la Figura 3.6, la curva verde presenta la función real $y_r = x^2$, los puntos de muestra se muestran en azul, el modelo ajustado $\hat{y}$ con cada muestra en rojo y el promedio de los modelos entre todas las muestras en negro.

Ambos casos presentan una estructura inadecuada, como ya se ha comentado. El modelo lineal simple presenta una *bias* alta, pero una varianza pequeña, mientras que el modelo de grado 10 presenta una *bias* pequeña y una varianza alta, mostrando que es más sensible a la muestra que el primero.




Figura 3.6: *Bias* y varianza: (a) modelo lineal simple; (b) modelo de grado 10.

Los resultados de los modelos ajustados con la estructura correcta, es decir, un polinomio de grado 2, se muestran en la Figura 3.7. Podemos observar que el modelo con la estructura correcta es capaz de minimizar simultáneamente *bias* y la varianza y que la media de todos los modelos se aproxima bien a la función real.

La simulación anterior nos permite concluir que *bias* ocurre cuando la complejidad del modelo es menor que la de la función real y que la varianza es efecto de la inestabilidad de modelos muy complejos en relación al tamaño de la muestra. El objetivo de las técnicas de regularización es reducir la varianza de un modelo de alta complejidad para que el modelo se vuelva adecuado a la complejidad del problema, manteniendo *bias* bajo.




Figura 3.7: *Bias* e variância no modelo de grau 2.

A Figura 3.8 mostra o conceito de regularização como uma forma de reduzir a variância do modelo. A Figura 3.8 utiliza os elementos da decomposição do erro quadrático em *bias* e variância na equação (3.13). O círculo cinza no centro da figura representa o conjunto de valores possíveis da amostra, cujo centro é o valor real da função y_r . O valor observado na amostra difere do valor real devido ao erro de observação $e_o = y - y_r$. A partir de uma estrutura de modelo definida, o ajuste pelo MMQ produz uma estimativa $\hat{y}$, cuja diferença em relação ao valor observado é o resíduo do modelo $e = y - \hat{y}$. Considerando todas as amostras possíveis, a variância do modelo $E((\hat{y} - E(\hat{y}))^2)$ é representada pelo círculo laranja maior. Com essa estrutura, o modelo produzido pelo MMQ, considerando uma amostra infinita de dados, é o valor esperado do modelo $E(\hat{y})$. O *bias* do modelo é a diferença entre o valor real e o valor esperado do modelo.

A técnica de regularização visa a uma redução do espaço do modelo, que vai produzir uma estimativa de complexidade reduzida $\hat{y}'$ para o valor observado y . Essa estimativa, apesar de apresentar um resíduo do modelo $e = y - \hat{y}'$ maior, está mais próxima do resultado que seria obtido com uma amostra infinita $E(\hat{y}')$, de forma que a variância da estimativa do modelo reduzido $E((\hat{y}' - E(\hat{y}'))^2)$ é menor. O *bias* da estimativa do modelo reduzido pode ser maior, mas a soma EMQ que considera *bias* e variância pode ser menor para o resultado do modelo reduzido que para o resultado do modelo inicial.




Figura 3.7: *Bias* y *varianza* en el modelo de grado 2.

La Figura 3.8 muestra el concepto de regularización como una forma de reducir la varianza del modelo. La figura 3.8 utiliza los elementos de la descomposición del error al cuadrado en *bias* y la varianza en la ecuación (3.13). El círculo gris en el centro de la figura representa el conjunto de valores posibles de la muestra, cuyo centro es el valor real de la función y_r . El valor observado en la muestra difiere del valor real debido al error de observación $e_o = y - y_r$. A partir de una estructura de modelo definida, el ajuste del MMQ produce una estimación $\hat{y}$ cuya diferencia con relación al valor observado es el residual del modelo $e = y - \hat{y}$. Considerando todas las muestras posibles, la varianza del modelo $E((\hat{y} - E(\hat{y}))^2)$ está representada por el círculo naranja más grande. Con esta estructura, el modelo producido por MMQ, considerando una muestra infinita de datos, es el valor esperado del modelo $E(\hat{y})$. El *bias* del modelo es la diferencia entre el valor real y el valor esperado del modelo.

La técnica de regularización tiene como objetivo reducir el espacio del modelo, lo que producirá una estimación de complejidad reducida $\hat{y}'$ para el valor observado y . Esta estimación, a pesar de presentar un residuo mayor del modelo $e = y - \hat{y}'$, se acerca más al resultado que se obtendría con una muestra infinita $E(\hat{y}')$, por lo que la varianza de la estimación del modelo reducido $E((\hat{y}' - E(\hat{y}'))^2)$ es menor. El *bias* de la estimación del modelo reducido puede ser mayor, pero la suma EMQ que considera *bias* y la varianza puede ser menor para el resultado del modelo reducido que para el resultado del modelo inicial.




Figura 3.8: Conceito de regularização. Adaptado de [238].

O conceito de regularização descrito anteriormente será formalizado matematicamente em duas técnicas amplamente difundidas nas próximas seções.

3.2.2 Regularização de Tikhonov

Na regressão linear, o *overfitting* ocorre porque o modelo é muito complexo para o tamanho da amostra e o problema torna-se mal condicionado, ou seja, a solução do sistema linear (3.7) é muito sensível à amostra e torna-se instável. Para contornar esse problema, é necessário reduzir a complexidade do modelo, seja modificando diretamente a sua estrutura, seja aplicando algum tratamento numérico que permita o ajuste de um modelo menos complexo.

O método clássico de regularização foi proposto por Tikhonov para a solução de sistemas lineares mal condicionados [524]. Na estatística, o método de Tikhonov foi introduzido por Hoerl e Kennard [255] e chamado de *ridge regression*.

A regularização de Tikhonov é uma técnica de controle de complexidade do modelo através da aplicação de uma penalidade sobre o vetor de parâmetros. A solução é obtida pela minimização do erro médio quadrático regularizado (EMQR):

$$EMQR(\mu, \boldsymbol{\theta}) = \frac{1}{N} \sum_{t=1}^N (y(t) - \hat{f}(\mathbf{x}(t), \boldsymbol{\theta}))^2 + \mu \|\boldsymbol{\theta}\|^2 \quad (3.14)$$




Figura 3.8: Concepto de regularización. Adaptado de [238].

El concepto de regularización descrito anteriormente se formalizará matemáticamente en dos técnicas ampliamente difundidas en las siguientes secciones.

3.2.2 Regularización de Tikhonov

En la regresión lineal, *overfitting* ocurre porque el modelo es demasiado complejo para el tamaño de la muestra y el problema queda mal condicionado, es decir, la solución del sistema lineal (3.7) es muy sensible a la muestra y se vuelve inestable. Para superar este problema es necesario reducir la complejidad del modelo, ya sea modificando directamente su estructura o aplicando algún tratamiento numérico que permita el ajuste de un modelo menos complejo.

Tikhonov propuso el método de regularización clásico para resolver sistemas lineales mal condicionados [524]. En estadística, el método de Tikhonov fue introducido por Hoerl y Kennard [255] y lo denominaron *ridge regression*.

La regularización de Tikhonov es una técnica para controlar la complejidad del modelo aplicando una penalización al vector de parámetros. La solución se obtiene minimizando el error cuadrático medio regularizado (EMQR):

$$EMQR(\mu, \boldsymbol{\theta}) = \frac{1}{N} \sum_{t=1}^N (y(t) - \hat{f}(\mathbf{x}(t), \boldsymbol{\theta}))^2 + \mu \|\boldsymbol{\theta}\|^2 \quad (3.14)$$

onde $\mu \geq 0$ é o parâmetro de regularização que controla a aplicação da penalidade. Observe que, como $\mu \geq 0$, $EMQR(\mu, \boldsymbol{\theta}) \geq EMQ(\boldsymbol{\theta})$, o que é coerente com o raciocínio apresentado na Figura 3.8.

No modelo linear, o EMQR é escrito utilizando a notação vetorial como:

$$EMQR(\mu, \boldsymbol{\theta}) = \frac{1}{N} (\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}^T)^T (\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}^T) + \mu \boldsymbol{\theta}\boldsymbol{\theta}^T \quad (3.15)$$

onde $\hat{\mathbf{X}} = \begin{bmatrix} \hat{x}_1(1) & \cdots & \hat{x}_n(1) \\ \vdots & \ddots & \vdots \\ \hat{x}_1(N) & \cdots & \hat{x}_n(N) \end{bmatrix}$, $\boldsymbol{\theta}^T = \begin{bmatrix} \theta_1 \\ \vdots \\ \theta_n \end{bmatrix}$ e $\mathbf{Y} = \begin{bmatrix} y(1) \\ \vdots \\ y(N) \end{bmatrix}$, como na equação (3.5).

A minimização do EMQR seguindo o mesmo procedimento anterior resulta no sistema linear $(\hat{\mathbf{X}}^T \hat{\mathbf{X}} + \mu \mathbf{I}) \boldsymbol{\theta}^T = \hat{\mathbf{X}}^T \mathbf{Y}$, cuja solução é calculada como:

$$\boldsymbol{\theta}_\mu^* = (\hat{\mathbf{X}}^T \hat{\mathbf{X}} + \mu \mathbf{I})^{-1} \hat{\mathbf{X}}^T \mathbf{Y} \quad (3.16)$$

onde $\mathbf{I}$ é a matriz identidade.

A regularização de Tikhonov atua no condicionamento da matriz de coeficientes $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$ através do parâmetro de regularização μ .

O condicionamento de uma matriz $\mathbf{A}$ reflete a sensibilidade da solução de um sistema linear em que a matriz $\mathbf{A}$ é a matriz de coeficientes. Se a matriz $\mathbf{A}$ for mal condicionada, pequenas alterações no termo independente podem causar grandes variações na solução. O condicionamento de uma matriz quadrada $\mathbf{A}$ é medido pelo número de **condição**, definido como $\kappa(\mathbf{A}) = \|\mathbf{A}\| \|\mathbf{A}^{-1}\|$, e calculado a partir dos seus autovalores [206]:

$$\kappa(\mathbf{A}) = \frac{\lambda_{\max}}{\lambda_{\min}} \quad (3.17)$$

onde $\lambda_{\max}$ e $\lambda_{\min}$ são, respectivamente, o maior e o menor autovalor de $\mathbf{A}$.

A equação (3.17) mostra que, se $\lambda_{\min} \rightarrow 0$, o número de condição da matriz $\kappa(\mathbf{A}) \rightarrow \infty$ e a matriz tende a ser singular. O menor autovalor $\lambda_{\min} = 0$ indica que há colunas linearmente dependentes, ou seja, a matriz tem posto deficiente e o sistema linear é indeterminado. Um valor do número de condição grande, por exemplo, $\kappa(\mathbf{A}) > 1.000$, indica que o condicionamento da matriz é próximo do singular e que a solução do sistema linear é instável, sendo muito sensível a perturbações.

donde $\mu \geq 0$ es el parámetro de regularización que controla la aplicación de la penalización. Tenga en cuenta que, al igual que $\mu \geq 0$, $EMQR(\mu, \boldsymbol{\theta}) \geq EMQ(\boldsymbol{\theta})$, lo cual es consistente con el razonamiento presentado en la Figura 3.8.

En el modelo lineal, el EMQR se escribe utilizando notación vectorial como:

$$EMQR(\mu, \boldsymbol{\theta}) = \frac{1}{N} (\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}^T)^T (\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}^T) + \mu \boldsymbol{\theta} \boldsymbol{\theta}^T \quad (3.15)$$

onde $\hat{\mathbf{X}} = \begin{bmatrix} \hat{x}_1(1) & \cdots & \hat{x}_n(1) \\ \vdots & \ddots & \vdots \\ \hat{x}_1(N) & \cdots & \hat{x}_n(N) \end{bmatrix}$, $\boldsymbol{\theta}^T = \begin{bmatrix} \theta_1 \\ \vdots \\ \theta_n \end{bmatrix}$ e $\mathbf{Y} = \begin{bmatrix} y(1) \\ \vdots \\ y(N) \end{bmatrix}$, como na equação (3.5).

Minimizando el EMQR siguiendo el mismo procedimiento anterior se obtiene el sistema lineal $(\hat{\mathbf{X}}^T \hat{\mathbf{X}} + \mu \mathbf{I}) \boldsymbol{\theta}^T = \hat{\mathbf{X}}^T \mathbf{Y}$, cuya solución se calcula como:

$$\boldsymbol{\theta}_\mu^* = (\hat{\mathbf{X}}^T \hat{\mathbf{X}} + \mu \mathbf{I})^{-1} \hat{\mathbf{X}}^T \mathbf{Y} \quad (3.16)$$

donde $\mathbf{I}$ es la matriz identidad.

La regularización de Tikhonov funciona para condicionar la matriz de coeficientes $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$ través del parámetro de regularización μ .

El condicionamiento de una matriz $\mathbf{A}$ refleja la sensibilidad de la solución de un sistema lineal en el que la matriz $\mathbf{A}$ es la matriz de coeficientes. Si la matriz $\mathbf{A}$ está mal condicionada, pequeños cambios en el término independiente pueden provocar grandes variaciones en la solución. El condicionamiento de una matriz cuadrada $\mathbf{A}$ se mide mediante el número de condición, definido como $\kappa(\mathbf{A}) = \|\mathbf{A}\| \|\mathbf{A}^{-1}\|$, y se calcula a partir de sus valores propios [206]:

$$\kappa(\mathbf{A}) = \frac{\lambda_{max}}{\lambda_{min}} \quad (3.17)$$

donde λ_{max} y λ_{min} son, respectivamente, el valor propio mayor y menor de $\mathbf{A}$.

La ecuación (3.17) muestra que si $\lambda_{min} \rightarrow 0$, el número de condición de la matriz $\kappa(\mathbf{A}) \rightarrow \infty$ y la matriz tiende a ser singular. El valor propio más pequeño $\lambda_{min} = 0$ indica que hay columnas linealmente dependientes, es decir, la matriz tiene un rango deficiente y el sistema lineal es indeterminado. Un valor grande del número de condición, por ejemplo, $\kappa(\mathbf{A}) > 1.000$, indica que el condicionamiento de la matriz es cercano al singular y que la solución del sistema lineal es inestable, siendo muy sensible a las perturbaciones.

No caso da regressão linear, a matriz de coeficientes no MMQ (cf. equação (3.7)) é a matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$ e o termo independente, $\hat{\mathbf{X}}^T \mathbf{Y}$. A existência de regressores altamente correlacionados provoca o mau condicionamento da matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$ e resulta na instabilidade na solução, o que, no contexto do problema de regressão, significa *overfitting*. Em outras palavras, um modelo muito complexo (em relação ao tamanho da amostra) resulta em problemas de condicionamento na matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$ e instabilidade na solução. Esse efeito pode ser observado pelos valores do vetor de parâmetros $\boldsymbol{\theta}$ na solução para o modelo de grau 10 mostrado na Tabela 3.1.

Na regularização de Tikhonov, a adição de uma constante à diagonal principal da matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$ altera seu número de condição como:

$$\kappa(\mathbf{A}) = \frac{\lambda_{\max} + \mu}{\lambda_{\min} + \mu} \quad (3.18)$$

Dessa forma, mesmo que a matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$ seja singular e que $\lambda_{\min} = 0$, a matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}} + \mu \mathbf{I}$ será estável numericamente e a solução (3.16) poderá ser calculada adequadamente.

O controle do condicionamento da matriz de regressores foi a principal motivação para a introdução do método de Tikhonov na regressão linear [255]. Atualmente, o problema de regularização através da minimização do EMQR (3.14) tem sido tratado como uma técnica geral de controle da complexidade de modelos [98][238][478].

Na regularização de Tikhonov, o parâmetro de regularização deve ser informado ou calculado automaticamente [399]. Hoerl, Kennard e Baldwin [256] apresentam a seguinte proposta para o cálculo do parâmetro μ :

$$\mu = \frac{n}{(N - n)} \frac{\|\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}^T\|^2}{\|\boldsymbol{\theta}\|^2} \quad (3.19)$$

onde n é o número de parâmetros e $\boldsymbol{\theta}$ é a solução do MMQ sem regularização. O termo $\|\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}^T\|^2 / (N - n)$ é uma estimativa da variância do resíduo (cf. equação (3.30)).

A regularização de Tikhonov pode ser entendida num contexto de seleção de modelos através do ajuste do parâmetro de regularização μ , cuja variação permite uma regulação contínua de estrutura do modelo, o que pode ser interessante em alguns casos.

A Figura 3.9 apresenta o conjunto de dados do exemplo discutido na seção 3.1.4 com o resultado do ajuste do modelo polinomial de grau 10 pela minimização EMQR, com dois

En el caso de la regresión lineal, la matriz de coeficientes en el MMQ (cf. ecuación (3.7)) es la matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$ y el término independiente, $\hat{\mathbf{X}}^T \mathbf{Y}$. La existencia de regresores altamente correlacionados causa un mal condicionamiento de la matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$ resulta en inestabilidad en la solución, lo que, en el contexto del problema de regresión, significa *overfitting*. En otras palabras, un modelo muy complejo (en relación al tamaño de la muestra) resulta en problemas de condicionamiento en la matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$ inestabilidad en la solución. Este efecto se puede observar mediante los valores del vector de parámetros $\boldsymbol{\theta}$ en la solución para el modelo de grado 10 que se muestra en la Tabla 3.1.

En la regularización de Tikhonov, agregar una constante a la diagonal principal de la matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$ cambia su número de condición como:

$$\kappa(\mathbf{A}) = \frac{\lambda_{\max} + \mu}{\lambda_{\min} + \mu} \quad (3.18)$$

De esta forma, incluso si la matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$ es singular y $\lambda_{\min} = 0$, la matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}} + \mu \mathbf{I}$ será numéricamente estable y la solución (3.16) podrá calcularse adecuadamente.

Controlar el condicionamiento de la matriz regresora fue la principal motivación para introducir el método de Tikhonov en la regresión lineal [255]. Actualmente, el problema de regularización mediante minimización EMQR (3.14) se ha tratado como una técnica general para controlar la complejidad del modelo [98][238][478].

En la regularización de Tikhonov, el parámetro de regularización debe informarse o calcularse automáticamente [399]. Hoerl, Kennard y Baldwin [256] presentan la siguiente propuesta para calcular el parámetro μ :

$$\mu = \frac{n}{(N - n)} \frac{\|\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}^T\|^2}{\|\boldsymbol{\theta}\|^2} \quad (3.19)$$

donde n es el número de parámetros y $\boldsymbol{\theta}$ es la solución MMQ sin regularización. El término $\|\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}^T\|^2 / (N - n)$ es una estimación de la varianza del residual (cf. ecuación (3.30)).

La regularización de Tikhonov puede entenderse en el contexto de la selección de modelos mediante el ajuste del parámetro de regularización μ , cuya variación permite una regulación continua de la estructura del modelo, lo que puede resultar interesante en algunos casos.

La Figura 3.9 presenta el conjunto de datos de ejemplo discutido en la sección 3.1.4 con el resultado de ajustar el modelo polinómico de grado 10 mediante minimización EMQR, con dos

valores para o parâmetro de regularização. A Figura 3.9a mostra o ajuste com o valor obtido pela equação (3.19) com $\mu = 1 \times 10^{-5}$ e a Figura 3.9b mostra o resultado obtido com o valor $\mu = 0.1$ escolhido de forma *ad hoc*.




Figura 3.9: Modelo de grau 10 com regularização: (a) $\mu = 1 \times 10^{-5}$; (b) $\mu = 0.1$.

A Tabela 3.2 mostra os valores dos parâmetros. O resultado obtido sem regularização ($\mu = 0.0$) foi incluído para facilitar a comparação.

Tabela 3.2: Parâmetros ajustados dos modelos da Figura 3.9

θ	$\mu = 0.0$	$\mu = 1 \times 10^{-5}$	$\mu = 0.1$
θ_0	-0.1394	-0.0556	0.0567
θ_1	-0.8151	-0.7044	-0.1218
θ_2	8.4550	4.2082	0.6766
θ_3	6.2056	4.7143	0.1997
θ_4	-53.2585	-18.5496	0.4438
θ_5	-15.7255	-10.2949	0.0189
θ_6	132.2678	33.0619	0.2380
θ_7	16.2839	8.9882	-0.0538
θ_8	-133.5450	-18.2708	-0.0253
θ_9	-5.9739	-2.7254	-0.0693
θ_{10}	47.2605	0.6354	-0.2803

A solução robusta do MMQ também pode ser obtida evitando as componentes associadas aos autovalores próximos de zero, através do método das componentes principais.

valores para el parámetro de regularización. La Figura 3.9a muestra el ajuste con el valor obtenido por la ecuación (3.19) con $\mu = 1 \times 10^{-5}$ y la Figura 3.9b muestra el resultado obtenido con el valor $\mu = 0.1$ elegido en la forma *ad hoc*.




Figura 3.9: Modelo de grado 10 con regularización: (a) $\mu = 1 \times 10^{-5}$; (b) $\mu = 0.1$.

La Tabla 3.2 muestra los valores de los parámetros. Se incluyó el resultado obtenido sin regularización ($\mu = 0.0$) para facilitar la comparación.

Tabla 3.2: Parámetros ajustados de los modelos en la Figura 3.9

θ	$\mu = 0.0$	$\mu = 1 \times 10^{-5}$	$\mu = 0.1$
θ_0	-0.1394	-0.0556	0.0567
θ_1	-0.8151	-0.7044	-0.1218
θ_2	8.4550	4.2082	0.6766
θ_3	6.2056	4.7143	0.1997
θ_4	-53.2585	-18.5496	0.4438
θ_5	-15.7255	-10.2949	0.0189
θ_6	132.2678	33.0619	0.2380
θ_7	16.2839	8.9882	-0.0538
θ_8	-133.5450	-18.2708	-0.0253
θ_9	-5.9739	-2.7254	-0.0693
θ_{10}	47.2605	0.6354	-0.2803

La solución MMQ robusta también se puede obtener evitando las componentes asociadas a valores propios cercanos a cero, mediante el método de componentes principales.

3.2.3 Regularização por componentes principais

Na seção 2.4.2, vimos que a decomposição em valores singulares (SVD) permite eliminar colunas linearmente dependentes de uma matriz através de uma transformação linear ortogonal. A SVD permite uma solução robusta de sistemas lineares considerando apenas as colunas linearmente independentes da matriz de coeficientes.

Considere a SVD da matriz de regressores $\hat{\mathbf{X}} = \mathbf{U}\mathbf{S}\mathbf{V}^T$ aplicada ao ajuste de parâmetros do MMQ pela equação (3.8):

$$\boldsymbol{\theta}^* = (\hat{\mathbf{X}}^T \hat{\mathbf{X}})^{-1} \hat{\mathbf{X}}^T \mathbf{Y} = (\mathbf{V}\mathbf{S}^2\mathbf{V}^T)^{-1} \mathbf{V}\mathbf{S}\mathbf{U}^T \mathbf{Y} = \mathbf{V}\mathbf{S}^{-1}\mathbf{U}^T \mathbf{Y} \quad (3.20)$$

Uma solução estável do MMQ pode ser obtida utilizando apenas as $r \leq \text{rank}(\hat{\mathbf{X}})$ colunas linearmente independentes da matriz de regressores como:

$$\boldsymbol{\theta}_r^* = \sum_{i=1}^r \left(\frac{\mathbf{u}_i^T \mathbf{Y}}{s_i} \right) \mathbf{v}_i \quad (3.21)$$

onde $\mathbf{u}_i$ e $\mathbf{v}_i$ são as colunas de $\mathbf{U}$ e $\mathbf{V}$ e s_i é o valor singular correspondente.

A soma dos $r \leq \text{rank}(\hat{\mathbf{X}})$ termos associados aos maiores valores singulares evita a utilização de valores muito pequenos de s_i , que provocam a instabilidade da solução, como mostra a equação (3.21). Dessa forma, a solução (3.21) não utiliza todas as colunas de $\mathbf{U}$ e $\mathbf{V}$, tal forma que $\|\boldsymbol{\theta}_r^*\| < \|\boldsymbol{\theta}^*\|$. Ela pode, então, ser vista como a solução reduzida do MMQ e, portanto, uma técnica de regularização.

A decomposição SVD da matriz de regressores $\hat{\mathbf{X}}$ é equivalente à decomposição em autovaleiros e autovetores da matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$, como foi visto na seção 2.4.2. A solução da equação (3.21) corresponde à aplicação do MMQ aos componentes principais da matriz de regressores, o que dá nome ao método.

A regularização por componentes principais também pode ser utilizada como uma forma de seleção de modelos pela variação do parâmetro $r \leq \text{rank}(\hat{\mathbf{X}})$. Em muitos softwares, a solução (3.21) é utilizada como uma solução robusta do sistema linear (3.16) com $r \approx \text{rank}(\hat{\mathbf{X}})$, o que fica transparente para o usuário.

Para comparação com os resultados anteriores, a Figura 3.10 apresenta os resultados do ajuste do modelo polinomial de grau 10 pelo método de componentes principais. A Figura 3.10a mostra o ajuste com o valor obtido com $r = \text{rank}(\hat{\mathbf{X}}) = 9$ e a Figura 3.10b, o resultado obtido com o valor $r = 5$ escolhido de forma *ad hoc*.

3.2.3 Regularização por componentes principais

En la sección 2.4.2, vimos que la descomposición en valores singulares (SVD) permite eliminar columnas linealmente dependientes de una matriz mediante una transformación lineal ortogonal. SVD permite una solución robusta de sistemas lineales considerando solo las columnas linealmente independientes de la matriz de coeficientes.

Considere la SVD de la matriz regresora $\hat{\mathbf{X}} = \mathbf{USV}^T$ aplicada al ajuste del parámetro MMQ mediante la ecuación (3.8):

$$\boldsymbol{\theta}^* = (\hat{\mathbf{X}}^T \hat{\mathbf{X}})^{-1} \hat{\mathbf{X}}^T \mathbf{Y} = (\mathbf{VS}^2 \mathbf{V}^T)^{-1} \mathbf{VSU}^T \mathbf{Y} = \mathbf{VS}^{-1} \mathbf{U}^T \mathbf{Y} \quad (3.20)$$

Se puede obtener una solución estable del MMQ utilizando solo las $r \leq \text{rank}(\hat{\mathbf{X}})$ columnas linealmente independientes de la matriz de regresor como:

$$\boldsymbol{\theta}_r^* = \sum_{i=1}^r \left(\frac{\mathbf{u}_i^T \mathbf{Y}}{s_i} \right) \mathbf{v}_i \quad (3.21)$$

donde $\mathbf{u}_i$ y $\mathbf{v}_i$ son las columnas de $\mathbf{U}$ y $\mathbf{V}$ y s_i es el valor singular correspondiente.

La suma de $r \leq \text{rank}(\hat{\mathbf{X}})$ términos asociados a los valores singulares más grandes evita el uso de valores muy pequeños de s_i , que provocan inestabilidad de la solución, como se muestra en la ecuación (3.21). Por lo tanto, la solución (3.21) no utiliza todas las columnas de $\mathbf{U}$ y $\mathbf{V}$, como por ejemplo $\|\boldsymbol{\theta}_r^*\| < \|\boldsymbol{\theta}^*\|$. Entonces puede verse como la solución reducida del MMQ y, por tanto, una técnica de regularización.

La descomposición SVD de la matriz regresora $\hat{\mathbf{X}}$ es equivalente a la descomposición en valores propios y vectores propios de la matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$ como se ve en la sección 2.4.2. La solución a la ecuación (3.21) corresponde a la aplicación del MMQ a los componentes principales de la matriz regresora, lo que da nombre al método.

La regularización por componentes principales también se puede utilizar como una forma de seleccionar modelos variando el parámetro $r \leq \text{rank}(\hat{\mathbf{X}})$. En muchos software, la solución (3.21) se utiliza como una solución robusta del sistema lineal (3.16) con $r \approx \text{rank}(\hat{\mathbf{X}})$, que es transparente para el usuario.

Para comparar con resultados anteriores, la Figura 3.10 presenta los resultados del ajuste del modelo polinómico de grado 10 utilizando el método de componentes principales. La Figura 3.10a muestra el ajuste con el valor obtenido con $r = \text{rank}(\hat{\mathbf{X}}) = 9$ y la Figura 3.10b, el resultado obtenido con el valor $r = 5$ elegido en la forma *ad hoc*.




Figura 3.10: Modelo de grau 10 com regularização: (a) $r = 9$; (b) $r = 5$.

A Tabela 3.2 mostra os valores dos parâmetros. O resultado obtido sem regularização ($r = 11$) também foi incluído para facilitar a comparação.

Tabela 3.3: Parâmetros ajustados dos modelos da Figura 3.10

θ	$r = 11$	$r = 9$	$r = 5$
θ_0	-0.1394	-0.0408	0.0248
θ_1	-0.8151	-0.5505	-0.0447
θ_2	8.4550	3.3565	0.8601
θ_3	6.2056	2.6037	-0.0054
θ_4	-53.2585	-11.0903	0.4039
θ_5	-15.7255	-2.5260	0.0083
θ_6	132.2678	10.7787	0.1023
θ_7	16.2839	-1.5235	0.0146
θ_8	-133.5450	8.4170	-0.0871
θ_9	-5.9739	1.9788	0.0178
θ_{10}	47.2605	-10.3956	-0.2107

3.3 Validação de Modelos

A abordagem clássica para validação de modelos de regressão linear é o teste das hipóteses do MMQ [399]. O desempenho do modelo depende, principalmente, da escolha da melhor estrutura ou de parâmetros de regularização. Dessa forma, a seleção do modelo é feita a partir de estatísticas e procedimentos de validação.




Figura 3.10: Modelo de grado 10 con regularización: (a) $r = 9$; (b) $r = 5$.

La Tabla 3.2 muestra los valores de los parámetros. También se incluyó el resultado obtenido o sin regularización ($r = 11$) para facilitar la comparación.

Tabla 3.3: Parámetros ajustados de los modelos en la Figura 3.10

θ	$r = 11$	$r = 9$	$r = 5$
θ_0	-0.1394	-0.0408	0.0248
θ_1	-0.8151	-0.5505	-0.0447
θ_2	8.4550	3.3565	0.8601
θ_3	6.2056	2.6037	-0.0054
θ_4	-53.2585	-11.0903	0.4039
θ_5	-15.7255	-2.5260	0.0083
θ_6	132.2678	10.7787	0.1023
θ_7	16.2839	-1.5235	0.0146
θ_8	-133.5450	8.4170	-0.0871
θ_9	-5.9739	1.9788	0.0178
θ_{10}	47.2605	-10.3956	-0.2107

3.3 Validación del modelo

El enfoque clásico para validar modelos de regresión lineal es probar las hipótesis del MM Q [399]. El rendimiento del modelo depende principalmente de la elección de la mejor estructura o parámetros de regularización. De esta forma, la selección del modelo se realiza en base a estadísticas y procedimientos de validación.

As estatísticas de validação medem o desempenho do modelo num determinado conjunto de dados. A forma mais efetiva de avaliar a capacidade de predição do modelo é verificar as estatísticas de validação em dados diferentes daqueles utilizados para o ajuste dos parâmetros. A validação cruzada, utilizando as estatísticas de validação do modelo, é um método eficiente e prático para a avaliação da qualidade preditiva do modelo. As principais estatísticas de validação para regressão linear são apresentadas na próxima seção e a validação cruzada é apresentada na seção 3.3.2.

3.3.1 Estatísticas de validação

As estatísticas de validação são calculadas a partir do resíduo em cada registro:

$$e(t) = y(t) - \hat{y}(t), t = 1, \dots, N \quad (3.22)$$

A **análise de variância** do modelo é feita a partir da decomposição [399]:

$$\sum_{t=1}^N (y(t) - \bar{y})^2 = \sum_{t=1}^N (\hat{y}(t) - \bar{y})^2 + \sum_{t=1}^N (y(t) - \hat{y}(t))^2 \quad (3.23)$$

onde $\bar{y}$ representa a média da variável de saída.

A equação (3.23) pode ser escrita como $SS_T = SS_R + SS_{Res}$, onde SS_T é a soma de quadrados totais, que representa a variabilidade total da variável de saída; SS_R é a soma dos quadrados da regressão, que representa a porção da variabilidade total explicada pelo modelo; e SS_{Res} é a soma de quadrados dos resíduos, que representa a porção da variabilidade total que não pode ser explicada pelo modelo.

O **coeficiente de determinação** R^2 mede o percentual da variabilidade total que é explicada pelo modelo como [399]:

$$R^2 = \frac{SS_R}{SS_T} = \frac{\sum_{t=1}^N (\hat{y}(t) - \bar{y})^2}{\sum_{t=1}^N (y(t) - \bar{y})^2} = 1 - \frac{SS_{Res}}{SS_T} = 1 - \frac{\sum_{t=1}^N (y(t) - \hat{y}(t))^2}{\sum_{t=1}^N (y(t) - \bar{y})^2} \quad (3.24)$$

O coeficiente de determinação $R^2 \leq 1$ uma vez que SS_T é fixo e $SS_{Res} \leq SS_T$. O valor $R^2 \approx 1$ indica um resultado adequado pois a maior parte da variabilidade total é explicada pelo modelo. Intuitivamente, o coeficiente de determinação compara o erro do modelo estimado pelo erro da média da variável saída. Se o erro do modelo é da mesma ordem de grandeza do erro da média, o valor $R^2 \approx 0$ indica que o modelo não consegue

Las estadísticas de validación miden el rendimiento del modelo en un conjunto de datos determinado. La forma más eficaz de evaluar la capacidad predictiva del modelo es comprobar las estadísticas de validación sobre datos diferentes a los utilizados para ajustar los parámetros. La validación cruzada, utilizando estadísticas de validación de modelos, es un método eficaz y práctico para evaluar la calidad predictiva del modelo. Las principales estadísticas de validación para la regresión lineal se presentan en la siguiente sección y la validación cruzada se presenta en la sección 3.3.2.

3.3.1 Estadísticas de validación

Las estadísticas de validación se calculan a partir del residual en cada registro:

$$e(t) = y(t) - \hat{y}(t), t = 1, \dots, N \quad (3.22)$$

El análisis de varianza del modelo se realiza mediante la descomposición [399]:

$$\sum_{t=1}^N (y(t) - \bar{y})^2 = \sum_{t=1}^N (\hat{y}(t) - \bar{y})^2 + \sum_{t=1}^N (y(t) - \hat{y}(t))^2 \quad (3.23)$$

donde $\bar{y}$ representa la media de la variable de salida.

La ecuación (3.23) se puede escribir como $SS_T = SS_R + SS_{Res}$, donde SS_T es la suma de cuadrados totales, que representa la variabilidad total de la variable de salida; SS_R es la suma de cuadrados de la regresión, que representa la porción de la variabilidad total explicada por el modelo; y SS_{Res} es la suma de cuadrados de los residuos, que representa la porción de la variabilidad total que no puede ser explicada por el modelo.

El coeficiente de determinación R^2 mide el porcentaje de la variabilidad total que el modelo explica como [399]:

$$R^2 = \frac{SS_R}{SS_T} = \frac{\sum_{t=1}^N (\hat{y}(t) - \bar{y})^2}{\sum_{t=1}^N (y(t) - \bar{y})^2} = 1 - \frac{SS_{Res}}{SS_T} = 1 - \frac{\sum_{t=1}^N (y(t) - \hat{y}(t))^2}{\sum_{t=1}^N (y(t) - \bar{y})^2} \quad (3.24)$$

El coeficiente de determinación $R^2 \leq 1$ ya que SS_T es fijo y $SS_{Res} \leq SS_T$. El valor $R^2 \approx 1$ indica un resultado adecuado ya que el modelo explica la mayor parte de la variabilidad total. Intuitivamente, el coeficiente de determinación compara el error del modelo estimado con el error de la media de la variable de salida. Si el error del modelo es del mismo orden de magnitud que el error medio, el valor $R^2 \approx 0$ indica que el modelo no puede

explicar as observações melhor que a média da variável de saída. Em alguns casos, o valor $R^2 < 0$ indica que o modelo é pior que a média da variável de saída.

O coeficiente de determinação é muito sensível aos valores mais altos da variável de saída uma vez que os erros são elevados ao quadrado. Para avaliação de valores menores, pode-se utilizar o coeficiente de determinação calculado sobre os logaritmos dos valores observados e preditos:

$$R_{log}^2 = 1 - \frac{\sum_{t=1}^N (\log(y(t)) - \log(\hat{y}(t)))^2}{\sum_{t=1}^N (\log(y(t)) - \overline{\log(y(t))})^2} \quad (3.25)$$

onde $\overline{\log(y(t))}$ é a média do logaritmo dos valores observados.

Uma estatística muito utilizada para avaliação de modelos é a raiz quadrada do EMQ, conhecida como RMS:*

$$RMS = \sqrt{\frac{1}{N} \sum_{t=1}^N e^2(t)} = \sqrt{\frac{1}{N} \sum_{t=1}^N (y(t) - \hat{y}(t))^2} \quad (3.26)$$

O resultado do RMS tem a mesma escala da variável de saída e pode ser analisado no contexto do problema.

Uma estatística de validação similar ao RMS é o erro absoluto médio (MAE)†:

$$MAE = \frac{1}{N} \sum_{t=1}^N |y(t) - \hat{y}(t)| \quad (3.27)$$

O erro absoluto médio percentual (MAPE)‡ é uma variante do MAE que apresenta os erros de forma relativa:

$$MAPE = \frac{1}{N} \sum_{t=1}^N \left| \frac{y(t) - \hat{y}(t)}{y(t)} \right| \quad (3.28)$$

A estatística MAPE é uma medida relativa e deve ser utilizada com cautela se a variável de saída for padronizada pela estimativa dos *z-scores*, pois pode resultar em erros de

* *Root Mean Square.*

† *Mean Absolute Error.*

‡ *Mean Absolute Percentual Error.*

explican las observaciones mejor que el promedio de la variable de salida. En algunos casos, el valor $R^2 < 0$ indica que el modelo es peor que el promedio de la variable de salida.

El coeficiente de determinación es muy sensible a valores más altos de la variable de salida ya que los errores están al cuadrado. Para evaluar valores más pequeños se puede utilizar el coeficiente de determinación calculado sobre los logaritmos de los valores observados y predichos:

$$R_{log}^2 = 1 - \frac{\sum_{t=1}^N (\log(y(t)) - \log(\hat{y}(t)))^2}{\sum_{t=1}^N (\log(y(t)) - \overline{\log(y(t))})^2} \quad (3.25)$$

donde $\overline{\log(y(t))}$ es la media del logaritmo de los valores observados.

Una estadística ampliamente utilizada para la evaluación de modelos es la raíz cuadrada del EMQ, conocida como RMS:^{*}

$$RMS = \sqrt{\frac{1}{N} \sum_{t=1}^N e^2(t)} = \sqrt{\frac{1}{N} \sum_{t=1}^N (y(t) - \hat{y}(t))^2} \quad (3.26)$$

El resultado RMS tiene la misma escala que la variable de salida y puede analizarse en el contexto del problema.

Una estadística de validación similar a RMS es el error absoluto medio (MAE)[†]:

$$MAE = \frac{1}{N} \sum_{t=1}^N |y(t) - \hat{y}(t)| \quad (3.27)$$

El error porcentual absoluto medio (MAPE)[‡] es una variante de MAE que presenta errores de forma relativa:

$$MAPE = \frac{1}{N} \sum_{t=1}^N \left| \frac{y(t) - \hat{y}(t)}{y(t)} \right| \quad (3.28)$$

La estadística MAPE es una medida relativa y debe usarse con precaución si la variable de salida está estandarizada por la estimación *z-scores*, ya que puede generar errores en

^{*} *Root Mean Square.*

[†] *Mean Absolute Error.*

[‡] *Mean Absolute Percentual Error.*

arredondamento e, eventualmente, divisão por zero. Quando a variável de saída não contém o valor nulo, o resultado em forma percentual permite uma avaliação intuitiva da qualidade do modelo.

Uma estatística adimensional para avaliação do desempenho do modelo é a correlação entre os resultados do modelo e os valores observados da variável de saída:

$$\rho_{y\hat{y}} = \frac{\sum_{t=1}^N (y(t) - \bar{y})(\hat{y}(t) - \bar{\hat{y}})}{\sqrt{Var(y)}\sqrt{Var(\hat{y})}} \quad (3.29)$$

onde $\bar{\hat{y}} = \frac{1}{N} \sum_{t=1}^N \hat{y}(t)$ é a média dos resultados do modelo.

O valor de correlação $\rho_{y\hat{y}} \leq 1$; quanto mais próximo de 1, melhor a qualidade do modelo. O resultado de correlação também pode ser avaliado no gráfico de projeção entre o valor observado e o previsto da variável de saída.

Se a estrutura selecionada pelo modelo representa adequadamente a relação, uma estimativa da variância dos resíduos é calculada como:

$$Var(e) = \hat{\sigma}^2 = \frac{1}{N-n} \sum_{t=1}^N e^2(t) = \frac{1}{N-n} \sum_{t=1}^N (y(t) - \hat{y}(t))^2 \quad (3.30)$$

onde n é o número de regressores do modelo.

Quando a distribuição do resíduo pode ser representada adequadamente por uma distribuição normal, é possível calcular um intervalo de confiança do resultado do modelo para um valor de entrada arbitrário $\hat{\mathbf{x}}_0$ do vetor de regressores. A estimativa da variância do modelo no ponto $\hat{\mathbf{x}}_0$ é calculada como [399]:

$$Var(\hat{y}_0) = \hat{\sigma}^2 \hat{\mathbf{x}}_0^T (\hat{\mathbf{X}}^T \hat{\mathbf{X}})^{-1} \hat{\mathbf{x}}_0 \quad (3.31)$$

onde $\hat{y}_0$ é o valor do modelo no ponto $\hat{\mathbf{x}}_0$ e $\hat{\sigma}^2$ é a estimativa da variância do resíduo calculada pela equação (3.30).

O intervalo que contém o valor esperado da relação real $y_r = E(y_0)$, onde y_0 é o valor observado em $\hat{\mathbf{x}}_0$, com confiança estatística de $\xi\%$ é calculado como [399]:

$$\hat{y}_0 - t_{\xi,d} \sqrt{Var(\hat{y}_0)} \leq y_r \leq \hat{y}_0 + t_{\xi,d} \sqrt{Var(\hat{y}_0)} \quad (3.32)$$

redondeo y, eventualmente, división por cero. Cuando la variable de salida no contiene un valor nulo, el resultado en forma porcentual permite una evaluación intuitiva de la calidad del modelo.

Una estadística adimensional para evaluar el desempeño del modelo es la correlación entre los resultados del modelo y los valores observados de la variable de salida:

$$\rho_{y\hat{y}} = \frac{\sum_{t=1}^N (y(t) - \bar{y})(\hat{y}(t) - \bar{\hat{y}})}{\sqrt{Var(y)}\sqrt{Var(\hat{y})}} \quad (3.29)$$

donde $\bar{\hat{y}} = \frac{1}{N} \sum_{t=1}^N \hat{y}(t)$ es el promedio de los resultados del modelo.

El valor de correlación $\rho_{y\hat{y}} \leq 1$; cuanto más cerca de 1, mejor será la calidad del modelo. El resultado de la correlación también se puede evaluar en el gráfico de proyección entre el valor observado y predicho de la variable de salida.

Si la estructura seleccionada por el modelo representa adecuadamente la relación, se calcula una estimación de la varianza de los residuos como:

$$Var(e) = \hat{\sigma}^2 = \frac{1}{N-n} \sum_{t=1}^N e^2(t) = \frac{1}{N-n} \sum_{t=1}^N (y(t) - \hat{y}(t))^2 \quad (3.30)$$

donde n es el número de regresores en el modelo.

Cuando la distribución residual puede representarse adecuadamente mediante una distribución normal, es posible calcular un intervalo de confianza del resultado del modelo para un valor de entrada arbitrario $\hat{\mathbf{x}}_0$ del vector de regresores. La estimación de la varianza del modelo en el punto $\hat{\mathbf{x}}_0$ se calcula como [399]:

$$Var(\hat{y}_0) = \hat{\sigma}^2 \hat{\mathbf{x}}_0^T (\hat{\mathbf{X}}^T \hat{\mathbf{X}})^{-1} \hat{\mathbf{x}}_0 \quad (3.31)$$

donde $\hat{y}_0$ es el valor del modelo en el punto $\hat{\mathbf{x}}_0$ y $\hat{\sigma}^2$ es la estimación de la varianza residual calculada mediante la ecuación (3.30).

El intervalo que contiene el valor esperado de la relación real $y_r = E(y_0)$, donde y_0 es el valor observado en $\hat{\mathbf{x}}_0$, con una confianza estadística de $\xi\%$, se calcula como [399]:

$$\hat{y}_0 - t_{\xi,d} \sqrt{Var(\hat{y}_0)} \leq y_r \leq \hat{y}_0 + t_{\xi,d} \sqrt{Var(\hat{y}_0)} \quad (3.32)$$

onde $d = N - n$ é o número de graus de liberdade e $t_{\xi,d}$ é o valor da distribuição t de Student. A distribuição t pode ser aproximada pela normal para $d \geq 30$, de forma que o intervalo de confiança com 95% de significância pode ser aproximado por:

$$\hat{y}_0 - 2.0\sqrt{\text{Var}(\hat{y}_0)} \leq y_r \leq \hat{y}_0 + 2.0\sqrt{\text{Var}(\hat{y}_0)} \quad (3.33)$$

A Figura 3.11 mostra o resultado do modelo linear de duas das três variáveis de saída do problema *Contrete Slump*.¹⁰⁴ A Figura 3.11a mostra o resultado da variável de saída y_3 , em que o modelo tem um bom desempenho, e a Figura 3.11b, o resultado da variável y_1 , em que o desempenho do modelo não é bom.




Figura 3.11: Resultados do modelo linear do problema *Contrete Slump*: (a) y_3 ; (b) y_1 .

A Figura 3.12 mostra as estatísticas de validação correspondentes. As estatísticas R^2 e R_{log}^2 são apresentadas subtraídas da unidade para que o melhor modelo tenha sempre o menor valor. As barras vermelhas indicam o resultado da previsão realizada pela média e servem como referência.

A comparação da distribuição dos resíduos com a distribuição normal $N(0, \hat{\sigma}^2)$ permite avaliar graficamente a qualidade do modelo. Resíduos com distribuição normal indicam que o ajuste realizado pelo MMQ foi de boa qualidade. A Figura 3.13 mostra os histogramas dos resíduos e os gráficos de probabilidade normal dos resultados apresentados na Figura 3.12 e na Figura 3.11.

donde $d = N - n$ es el número de grados de libertad y $t_{\xi,d}$ es el valor de la distribución t de Student. La distribución t puede aproximarse mediante la normal para $d \geq 30$, de modo que el intervalo de confianza con una significancia del 95 % puede aproximarse mediante:

$$\hat{y}_0 - 2.0\sqrt{\text{Var}(\hat{y}_0)} \leq y_r \leq \hat{y}_0 + 2.0\sqrt{\text{Var}(\hat{y}_0)} \quad (3.33)$$

La Figura 3.11 muestra el resultado del modelo lineal para dos de las tres variables de salida del problema *Contrete Slump*.¹⁰⁴ La Figura 3.11a muestra el resultado de la variable de salida y_3 , en la que el modelo se desempeña bien, y la Figura 3.11b, el resultado de la variable y_1 , en la que el modelo no se desempeña bien.






Figura 3.11: Resultados del modelo lineal del problema *Contrete Slump*: (a) y_3 ; (b) y_1 .

La Figura 3.12 muestra las estadísticas de validación correspondientes. Los estadísticos R^2 y R_{log}^2 se presentan restados de la unidad para que el mejor modelo siempre tenga el valor más bajo. Las barras rojas indican el resultado de la previsión realizada utilizando la media y sirven de referencia.

Comparar la distribución de residuos con la distribución normal $N(0, \hat{\sigma}^2)$ nos permite evaluar gráficamente la calidad del modelo. Los residuos con distribución normal indican que el ajuste realizado por el MMQ fue de buena calidad. La Figura 3.13 muestra los histogramas de los residuos y las gráficas de probabilidad normal de los resultados presentados en la Figura 3.12 y la Figura 3.11.




(a)




(b)


Figura 3.12: Resultados do modelo linear do problema *Concrete Slump*: (a) y_3 ; (b) y_1 .




(a)



(b)




(c)




(d)

Figura 3.13: Distribuição do resíduo no problema *Slump*: (a) e (b) y_3 ; (c) e (d) y_1 .




(a)




(b)


Figura 3.12: Resultados del modelo lineal del problema *Concrete Slump*: (a) y_3 ; (b) y_1 .




(a)



(b)



(c)



(d)

Figura 3.13: Distribución residual en el problema de Slump: (a) y (b) y_3 ; (c) y (d) y_1 .

As estatísticas de validação calculadas diretamente sobre o conjunto de treinamento não são úteis para a escolha do melhor modelo, pois um modelo com *overfitting* tem bom desempenho no conjunto de treinamento. A avaliação da capacidade de predição do modelo diretamente sobre o conjunto de treinamento pode ser avaliada por estatísticas como os critérios de Akaike (AIC) [7] e de Schwartz (BIC) [481], cujos resultados nem sempre correspondem ao desempenho efetivo do modelo. Na prática, utiliza-se o procedimento de validação cruzada para estimar a capacidade de predição do modelo, como descrito a seguir.

3.3.2 Validação cruzada

A maneira mais simples de estimar o desempenho do modelo num conjunto de dados diferente do que foi utilizado para o ajuste é dividir o conjunto de dados $\mathcal{T}$ em dois subconjuntos: o conjunto de treinamento $\mathcal{T}_1$ e o conjunto de teste $\mathcal{T}_2$, respectivamente com N_1 e N_2 registros (tipicamente $N_1 = 2N/3$ e $N_2 = N/3$). O conjunto de treinamento é utilizado para o ajuste de parâmetros e o conjunto de teste é utilizado para estimar o desempenho do modelo. Essa abordagem supõe que os dois conjuntos são amostras representativas do processo, o que pode não acontecer se o conjunto de dados não for grande o suficiente. Além disso, as estatísticas de validação ficam muito dependentes da partição e uma permutação dos registros pode gerar variações importantes nas estatísticas de validação.

A validação cruzada é um procedimento simples que permite avaliar adequadamente o desempenho do modelo em dados diferentes do conjunto de treinamento. Na validação cruzada, o conjunto de dados é dividido em K subconjuntos e a validação é realizada em K ciclos: para cada ciclo o modelo é ajustado utilizando $K - 1$ subconjuntos e avaliado no subconjunto remanescente. O procedimento é descrito pelo Algoritmo 3.1, mostrado esquematicamente na Figura 3.14.

As estatísticas de validação podem ser calculadas sobre o resultado de cada ciclo $\hat{\mathbf{Y}}_i$ e o resultado é apresentado em termos de média e desvio padrão dos resultados em todos os ciclos. Em conjuntos de dados pequenos, as estatísticas de validação não são significativas quando calculadas sobre um subconjunto com N/K registros. Dessa forma, é preferível concatenar os resultados em cada ciclo num vetor de resultados $\hat{\mathbf{Y}}$, que tem o mesmo número de registros que o conjunto de treinamento, e calcular as estatísticas

Las estadísticas de validación calculadas directamente en el conjunto de entrenamiento no son útiles para elegir el mejor modelo, ya que un modelo con *overfitting* funciona bien en el conjunto de entrenamiento. La evaluación de la capacidad de predicción del modelo directamente sobre el conjunto de entrenamiento se puede evaluar utilizando estadísticas como los criterios de Akaike (AIC) [7] y Schwartz (BIC) [481], cuyos resultados no siempre corresponden al desempeño efectivo del modelo. En la práctica, se utiliza el procedimiento de validación cruzada para estimar la capacidad de predicción del modelo, como se describe a continuación.

3.3.2 Validación cruzada

La forma más sencilla de estimar el rendimiento del modelo en un conjunto de datos diferente al utilizado para el ajuste es dividir el conjunto de datos $\mathcal{T}$ en dos subconjuntos: el conjunto de entrenamiento $\mathcal{T}_1$ y el conjunto de prueba $\mathcal{T}_2$, respectivamente con registros N_1 y N_2 (normalmente $N_1 = 2N/3$ y $N_2 = N/3$). El conjunto de entrenamiento se utiliza para ajustar los parámetros y el conjunto de prueba se utiliza para estimar el rendimiento del modelo. Este enfoque supone que los dos conjuntos son muestras representativas del proceso, lo que puede no suceder si el conjunto de datos no es lo suficientemente grande. Además, las estadísticas de validación dependen mucho de la partición y una permutación de registros puede generar variaciones importantes en las estadísticas de validación.

La validación cruzada es un procedimiento simple que le permite evaluar adecuadamente el rendimiento del modelo en datos diferentes del conjunto de entrenamiento. En la validación cruzada, el conjunto de datos se divide en K subconjuntos y la validación se realiza en K ciclos: para cada ciclo, el modelo se ajusta utilizando $K - 1$ subconjuntos y se evalúa en el subconjunto restante. El procedimiento se describe mediante el Algoritmo 3.1, que se muestra esquemáticamente en la Figura 3.14.

Las estadísticas de validación se pueden calcular sobre el resultado de cada ciclo $\hat{\mathbf{Y}}_i$ y el resultado se presenta en términos de la media y la desviación estándar de los resultados en todos los ciclos. En conjuntos de datos pequeños, las estadísticas de validación no son significativas cuando se calculan sobre un subconjunto con registros N/K . Por lo tanto, es preferible concatenar los resultados de cada ciclo en un vector de resultados $\hat{\mathbf{Y}}$ que tenga el mismo número de registros que el conjunto de entrenamiento, y calcular las estadísticas.

de validação sobre esses resultados. Observe que todos os elementos do vetor $\hat{\mathbf{Y}}$ foram calculados com registros diferentes daqueles utilizados para o ajuste dos modelos.

Algoritmo 3.1: Validação cruzada de K ciclos

Entrada:	Conjunto de dados $\mathcal{T} = \{(\mathbf{x}(t), y(t)), t = 1 \dots N\}$ e número de ciclos K
Saída:	Vetor com resultados do modelo $\hat{\mathbf{Y}} = [\hat{y}(1), \dots, \hat{y}(N)]^T$
01	Início
02	Dividir o conjunto $\mathcal{T}$ em K subconjuntos $\mathcal{T}_i, i = 1, \dots, K$ aproximadamente iguais
03	Para $i = 1 \dots K$:
04	Definir o conjunto de treinamento $\mathcal{T}_{TR} = \bigcup_{j \neq i} \mathcal{T}_j$
05	Ajustar os parâmetros do modelo utilizando $\mathcal{T}_{TR}$
06	Estimar o resultado do modelo no conjunto $\mathcal{T}_{TE} = \mathcal{T}_i$
07	Armazenar o resultado no vetor $\hat{\mathbf{Y}}_i$
08	Fim Para
09	Concatenar resultados $\hat{\mathbf{Y}} = [\hat{\mathbf{Y}}_1^T, \dots, \hat{\mathbf{Y}}_K^T]^T$
10	Fim




Figura 3.14: Validação cruzada de K ciclos: Tr são os subconjuntos de treinamento, Te são os subconjunto de teste

Uma escolha importante na validação cruzada é o número de ciclos K . No caso particular de $K = N$, chamada de *leave-one-out* (LOO), em cada ciclo, $N - 1$ registros são utilizados para o treinamento e a estimativa do modelo é feita com apenas um registro.

validación de estos resultados. Tenga en cuenta que todos los elementos del vector $\hat{\mathbf{y}}$ se calcularon con registros diferentes a los utilizados para ajustar los modelos.

Algoritmo 3.1: validación cruzada de ciclo K

Entrada:	Conjunto de dados $\mathcal{T} = \{(\mathbf{x}(t), y(t)), t = 1 \dots N\}$ e número de ciclos K
Saída:	Vetor com resultados do modelo $\hat{\mathbf{Y}} = [\hat{y}(1), \dots, \hat{y}(N)]^T$
01	Início
02	Dividir o conjunto $\mathcal{T}$ em K subconjuntos $\mathcal{T}_i, i = 1, \dots, K$ aproximadamente iguais
03	Para $i = 1 \dots K$:
04	Definir o conjunto de treinamento $\mathcal{T}_{TR} = \bigcup_{j \neq i} \mathcal{T}_j$
05	Ajustar os parâmetros do modelo utilizando $\mathcal{T}_{TR}$
06	Estimar o resultado do modelo no conjunto $\mathcal{T}_{TE} = \mathcal{T}_i$
07	Armazenar o resultado no vetor $\hat{\mathbf{Y}}_i$
08	Fim Para
09	Concatenar resultados $\hat{\mathbf{Y}} = [\hat{\mathbf{Y}}_1^T, \dots, \hat{\mathbf{Y}}_K^T]^T$
10	Fim




Figura 3.14: Validación cruzada de ciclos K : Tr son los subconjuntos de entrenamiento, Te son el subconjunto de prueba.

Una elección importante en la validación cruzada es el número de ciclos K . En el caso particular de $K = N$, llamado *leave-one-out* (LOO), en cada ciclo se utilizan registros $N - 1$ para el entrenamiento y la estimación del modelo se realiza con un solo registro.

Apesar do custo computacional, a validação cruzada LOO é a melhor estimativa de desempenho do modelo em dados diferentes do conjunto de dados disponível, mas é muito sensível à amostra e pode ter resultados diferentes para amostras diferentes [238]. A escolha mais usual é $K = 5$ ou $K = 10$, número de registros [238][63].

3.4 Aplicações

3.4.1 Conjunto de dados *Pollution*

O conjunto de dados *Pollution*¹⁰⁵ é um problema utilizado frequentemente como exemplo da aplicação da regularização de Tikhonov [375]. O conjunto de dados, que relaciona poluição do ar com mortalidade, contém 60 registros com os valores de 15 variáveis observados entre 1959 e 1961 em áreas metropolitanas dos EUA. A variável de saída representa a média de mortalidade nas áreas observadas no mesmo período.

A Figura 3.15 mostra o *box-plot* das variáveis padronizadas pelas estimativas dos *z-scores* e a matriz de correlação. Podemos observar a presença de variáveis bastante correlacionadas (x_{12} e x_{13}).




Figura 3.15: Conjunto de dados *Pollution*: (a) box-plot; (b) matriz de correlação.

A Figura 3.16 apresenta a visualização do gráfico de projeção e o *data image*. Podemos observar a existência de algumas variáveis com distribuições assimétricas (x_{12} a x_{13}) e a presença de pelo menos um registro *outlier*, representado pela linha e coluna em vermelho no *data image*.

A pesar del costo computacional, la validación cruzada LOO es la mejor estimación del desempeño del modelo en datos diferentes del conjunto de datos disponible, pero es muy sensible a las muestras y puede tener resultados diferentes para diferentes muestras [238]. La opción más común es $K = 5$ o $K = 10$, número de registros [238][63].

3.4 Aplicaciones

3.4.1 Conjunto de datos *Pollution*

El conjunto de datos *Pollution*¹⁰⁵ es un problema que se utiliza frecuentemente como ejemplo de la aplicación de la regularización de Tikhonov [375]. El conjunto de datos, que relaciona la contaminación del aire con la mortalidad, contiene 60 registros con los valores de 15 variables observadas entre 1959 y 1961 en áreas metropolitanas de Estados Unidos. La variable de salida representa la mortalidad promedio en las áreas observadas en el mismo período.

La Figura 3.15 muestra la *box-plot* de las variables estandarizadas por las estimaciones *z-scores* y la matriz de correlación. Podemos observar la presencia de variables altamente correlacionadas (x_{12} y x_{13}).




Figura 3.15: Conjunto de datos *Pollution*: (a) diagrama de caja; (b) matriz de correlación.

La Figura 3.16 muestra la visualización del gráfico de proyección y *data image*. Podemos observar la existencia de algunas variables con distribuciones asimétricas (x_{12} a x_{13}) y la presencia de al menos un registro *outlier*, representado por la línea roja y la columna en *data image*.




Figura 3.16: Conjunto de dados *Pollution*: (a) gráficos de projeção; (b) *data image*.

A Figura 3.17 apresenta o gráfico de projeção e o *data image* do conjunto de dados após a remoção de 12% (sete registros) da base, como descrito na seção 2.3.2. Podemos observar pela Figura 3.17b um padrão mais homogêneo da similaridade entre os registros, ainda que um registro se mostre discrepante em relação aos demais.




Figura 3.17: Conjunto de dados *Pollution* sem *outliers*: (a) gráficos de projeção; (b) *data image*.

A Figura 3.18 apresenta os resultados obtidos em validação cruzada do modelo linear simples com os parâmetros ajustados pelo MMQ sem regularização, sem a remoção de *outliers*. Podemos observar que a distribuição do resíduo não é bem ajustada pela distribuição normal, o que pode ser um indício de que o ajuste realizado pelo MMQ não foi adequado.




Figura 3.16: Conjunto de datos *Pollution*: (a) gráficos de proyección; (b) *data image*.

La Figura 3.17 presenta el gráfico de proyección y *data image* del conjunto de datos después de eliminar el 12% (siete registros) de la base, como se describe en la sección 2.3.2. Podemos observar en la Figura 3.17b un patrón más homogéneo de similitud entre registros, incluso si un registro parece discrepar en relación con los demás.




Figura 3.17: Conjunto de datos *Pollution* sin *outliers*: (a) gráficos de proyección; (b) *data image*.

La Figura 3.18 presenta los resultados obtenidos en la validación cruzada del modelo lineal simple con los parámetros ajustados por MMQ sin regularización, sin eliminar *outliers*. Podemos observar que la distribución del residual no está bien ajustada por la distribución normal, lo que puede ser un indicio de que el ajuste realizado por el MMQ no fue el adecuado.




Figura 3.18: Resultados do MMQ no conjunto de dados Pollution. (a) Estatísticas de validação; (b) correlação real $\times$ predito; (c) histograma do resíduo; (d) probabilidade normal do resíduo.

A Figura 3.19 mostra os resultados do modelo linear aplicado ao conjunto de dados sem *outliers*. Podemos observar que o gráfico de probabilidade normal do resíduo indica que o ajuste dos dados sem *outliers* foi de melhor qualidade que o anterior. O coeficiente de correlação entre o valor real e o valor predito também demonstra o melhor desempenho do modelo nos dados sem *outliers*.

Os valores das estatísticas de validação são resumidos na

Tabela 3.4. O resultado também não melhora com a utilização de modelos polinomiais de ordem superior. O modelo linear regularizado com parâmetro calculado pela equação (3.19) ajustado nos dados sem *outliers* não resultou numa variação importante das




Figura 3.18: Resultados del MMQ en el conjunto de datos de contaminación. (a) Estadísticas de validación; (b) correlación real x predicha; (c) histograma de residuos; (d) probabilidad normal del residuo.

La Figura 3.19 muestra los resultados del modelo lineal aplicado al conjunto de datos sin *outliers*. Podemos observar que la gráfica de probabilidad normal del residual indica que el ajuste de datos sin *outliers* era de mejor calidad que el anterior. El coeficiente de correlación entre el valor real y el valor predicho también demuestra el mejor rendimiento del modelo en datos sin *outliers*.

Los valores de las estadísticas de validación se resumen en

Tabla 3.4. El resultado tampoco mejora con el uso de modelos polinomiales de orden superior. El modelo lineal regularizado con un parámetro calculado por la ecuación (3.19) ajustado a datos sin *outliers* no resultó en una variación importante en

estatísticas. Finalmente, utilizando o valor $\mu = 0.01$ para o parâmetro de regularização nos dados sem *outliers*, obtemos uma pequena melhora nas estatísticas.




Figura 3.19: Resultados do conjunto de dados *Pollution* sem *outliers*: (a) estatísticas de validação; (b) correlação real $\times$ predito; (c) histograma do resíduo; (d) probabilidade normal do resíduo.

Tabela 3.4: Comparação das estatísticas de validação

Modelo	RMS	MAPE	R^2
MMQ	0.2537	22.98%	0.4107
MMQ s/ <i>outliers</i>	0.2078	18.93%	0.6039
MMQ Reg. c/ <i>outliers</i>	0.2316	20.52%	0.5091
MMQ Reg. s/ <i>outliers</i>	0.2094	18.99%	0.5976
MMQ Reg. $\mu = 0.01$	0.2057	18.51%	0.6118

estadística. Finalmente, utilizando el valor $\mu = 0.01$ para el parámetro de regularización sobre los datos sin *outliers*, obtenemos una pequeña mejora en las estadísticas.




Figura 3.19: Resultados del conjunto de datos *Pollution* sem *outliers*: (a) estadísticas de validación; (b) correlación real x predicha; (c) histograma de residuos; (d) probabilidad normal del residuo.

Tabla 3.4: Comparación de estadísticas de validación

Modelo	RMS	MAPE	R^2
MMQ	0.2537	22.98%	0.4107
MMQ s/ outliers	0.2078	18.93%	0.6039
MMQ Reg. c/outliers	0.2316	20.52%	0.5091
MMQ Reg. s/outliers	0.2094	18.99%	0.5976
MMQ Reg. $\mu = 0.01$	0.2057	18.51%	0.6118

Nesse exemplo, a regularização e a retirada de *outliers* aumentam o desempenho do modelo linear, mas o efeito das duas técnicas combinadas não produz uma alteração significativa no resultado. A retirada de *outliers* melhora os resultados das estatísticas de validação nesse exemplo, pois a remoção de *outliers* foi realizada sobre todo o conjunto de dados, antes da validação cruzada.

É importante observar que, mesmo para um exemplo simples, o número de opções de modelos diferentes pode aumentar muito se todas as alternativas forem exploradas durante o processo de validação de modelos.

3.4.2 Previsão da elevação adiabática de temperatura do concreto

O estudo apresentado nesta seção foi realizado em parceria com o Departamento de Engenharia Civil da Eletrobrás Furnas [174][166]. O trabalho foi realizado a partir dos registros de ensaios de elevação adiabática de temperatura realizados no Laboratório de Concretos de Furnas com corpos de prova de amostras de concretos utilizados na construção das principais barragens de usinas hidrelétricas brasileiras [18].

O principal componente do concreto é o cimento, que, em contato com a água, produz reação exotérmica, ganhando, assim, resistência mecânica. O ensaio de elevação adiabática de temperatura do concreto é um experimento controlado que mede a elevação de temperatura produzida por um corpo de prova de concreto. A temperatura final do ensaio é uma função principalmente da formulação e da concentração do cimento utilizado. Entretanto, os demais componentes da mistura exercem influência na forma da função de elevação de temperatura, que é não linear.

O conhecimento do calor gerado pelo concreto é importante na construção de estruturas de grande porte, como barragens, por exemplo. Os esforços gerados pela dilatação do material devido à transferência de calor podem ser excessivos, podendo causar rachaduras na estrutura já construída durante a concretagem de um novo bloco.

Os esforços gerados pela dilatação do concreto podem ser calculados a partir de modelos numéricos da estrutura. Entretanto, a previsão da quantidade de calor gerada por modelos analíticos é complexa e os modelos existentes para a previsão do calor gerado

En este ejemplo, la regularización y eliminación de *outliers* aumentan el rendimiento del modelo lineal, pero el efecto de las dos técnicas combinadas no produce un cambio significativo en el resultado. La eliminación de *outliers* mejora los resultados de las estadísticas de validación en este ejemplo, ya que la eliminación de *outliers* se realizó en todo el conjunto de datos, antes de la validación cruzada.

Es importante señalar que incluso para un ejemplo simple, el número de opciones de modelos diferentes puede aumentar considerablemente si se exploran todas las alternativas durante el proceso de validación del modelo.

3.4.2 Predicción del aumento de temperatura adiabático del hormigón.

El estudio presentado en esta sección fue realizado en colaboración con el Departamento de Ingeniería Civil de Eletrobrás Furnas [174][166]. El trabajo se realizó con base en registros de ensayos de aumento de temperatura adiabático realizados en el Laboratorio de Concretos de Furnas con probetas de muestras de concreto utilizadas en la construcción de las principales represas de las centrales hidroeléctricas brasileñas [18].

El principal componente del hormigón es el cemento, que al entrar en contacto con el agua produce una reacción exotérmica ganando así resistencia mecánica. La prueba adiabática de aumento de temperatura del hormigón es un experimento controlado que mide el aumento de temperatura producido por una muestra de hormigón. La temperatura final del ensayo es principalmente función de la formulación y concentración del cemento utilizado. Sin embargo, los otros componentes de la mezcla influyen en la forma de la función de aumento de temperatura, que no es lineal.

El conocimiento del calor generado por el hormigón es importante en la construcción de grandes estructuras, como presas, por ejemplo. Los esfuerzos generados por la expansión del material debido a la transferencia de calor pueden ser excesivos, pudiendo provocar grietas en la estructura ya construida durante el hormigonado de un nuevo bloque.

Los esfuerzos generados por la expansión del hormigón se pueden calcular a partir de modelos numéricos de la estructura. Sin embargo, predecir la cantidad de calor generado mediante modelos analíticos es complejo y los modelos existentes para predecir el calor generado

só podem ser utilizados em condições limitadas [174]. Modelos de inteligência computacional podem ser utilizados para a previsão de calor gerado pelas misturas utilizadas na composição do concreto no Brasil [166].

Os dados para o estudo foram cedidos pelo Laboratório de Concreto de Furnas [174] e apresenta 136 registros de 14 variáveis de entrada do problema, apresentadas na Tabela 3.5. As variáveis são de dois tipos: cinco variáveis descrevem a composição química do cimento utilizado no concreto e nove variáveis, os demais elementos utilizados na mistura e a temperatura inicial do ensaio.

Cada registro do conjunto de dados original apresenta a evolução de temperatura do corpo de prova. Os registros representam observações a cada hora nas primeiras 24 horas e diariamente até o 28º dia, resultando 52 registros de tempo. Tendo em vista o grande número de valores ausentes e a dificuldade em modelar um problema com 52 variáveis de saída, a elevação de temperatura foi aproximada por uma função não linear de três parâmetros, que são utilizados como variáveis de saída no modelo de regressão [174].

Tabela 3.5: Descrição das variáveis de entrada

Variável	Descrição	
x_1	Concentração de CaO	(%)
x_2	Concentração de Si_2O_2	(%)
x_3	Concentração de Al_2O_3	(%)
x_4	Concentração de Fe_2O_3	(%)
x_5	Concentração de SO_3	(%)
x_6	Consumo de cimento	(Kg/m ³)
x_7	Finura Blaine	(cm ² /g)
x_8	Adição de pozolana	(Kg/m ³)
x_9	Adição de escória	(Kg/m ³)
x_{10}	Adição de cinza volante	(Kg/m ³)
x_{11}	Consumo de água	(Kg/m ³)
x_{12}	Consumo de aditivos	(Kg/m ³)
x_{13}	Consumo de agregados	(Kg/m ³)
x_{14}	Temperatura inicial	(°C)

sólo pueden utilizarse en condiciones limitadas [174]. Los modelos de inteligencia computacional pueden usarse para predecir el calor generado por las mezclas utilizadas en la composición del concreto en Brasil [166].

Los datos para el estudio fueron proporcionados por el Laboratorio de Concreto de Furnas [174] y presentan 136 registros de 14 variables de entrada del problema, presentadas en la Tabla 3.5. Las variables son de dos tipos: cinco variables describen la composición química del cemento utilizado en el hormigón y nueve variables, los demás elementos utilizados en la mezcla y la temperatura inicial del ensayo.

Cada registro del conjunto de datos original presenta la evolución de la temperatura de la muestra. Los registros representan observaciones cada hora durante las primeras 24 horas y diariamente hasta el día 28, lo que da como resultado 52 registros de tiempo. Dada la gran cantidad de valores faltantes y la dificultad de modelar un problema con 52 variables de salida, el aumento de temperatura se aproximó mediante una función no lineal de tres parámetros, que se utilizan como variables de salida en el modelo de regresión [174].

Tabla 3.5: Descripción de las variables de entrada

Variável	Descrição	
x_1	Concentração de CaO	(%)
x_2	Concentração de Si_2O_2	(%)
x_3	Concentração de Al_2O_3	(%)
x_4	Concentração de Fe_2O_3	(%)
x_5	Concentração de SO_3	(%)
x_6	Consumo de cimento	(Kg/m ³)
x_7	Finura Blaine	(cm ² /g)
x_8	Adição de pozolana	(Kg/m ³)
x_9	Adição de escória	(Kg/m ³)
x_{10}	Adição de cinza volante	(Kg/m ³)
x_{11}	Consumo de água	(Kg/m ³)
x_{12}	Consumo de aditivos	(Kg/m ³)
x_{13}	Consumo de agregados	(Kg/m ³)
x_{14}	Temperatura inicial	(°C)

A Figura 3.20a mostra a matriz de distâncias entre os registros. A Figura 3.20b apresenta a matriz de correlação das variáveis, onde são destacadas as variáveis de composição do cimento, as concentrações dos aditivos e as variáveis de saída. Os aditivos que têm maiores correlações com as variáveis de saída são: consumo de cimento (x_6), consumo de água (x_{11}) e consumo de agregados (x_{13}).




Figura 3.20: Variáveis de entrada. (a) matriz de distâncias; (b) matriz de correlação.

Os resultados do ajuste feito pelo MMQ simples e com regularização são mostrados na Tabela 3.6. O método com regularização apresenta resultados ligeiramente melhores, principalmente para a variável de saída y_3 . A variável de saída y_1 , que representa a temperatura final do concreto após a hidratação, é a que apresentou os melhores resultados, tendo em vista que seu comportamento é bastante correlacionado com o consumo de cimento, conforme apresentado no exemplo da análise de correlação canônica na seção 2.4.4. Os resultados do modelo MMQ com regularização são apresentados na Figura 3.21 e ilustram os comentários acima.

Tabela 3.6: Comparação das estatísticas de validação

Saída	Modelo	RMS	MAPE	R^2
y_1	MMQ	0.1598	13.03%	0.7686
	MMQ Reg.	0.1573	13.07%	0.7756
y_2	MMQ	0.2178	16.21%	0.5700
	MMQ Reg.	0.2170	15.91%	0.5730
y_3	MMQ	0.2669	17.15%	0.3540
	MMQ Reg.	0.2591	16.45%	0.3911

La Figura 3.20a muestra la matriz de distancias entre registros. La Figura 3.20b presenta la matriz de correlación de variables, donde se destacan las variables de composición del cemento, concentraciones de aditivos y variables de producción. Los aditivos que tienen mayores correlaciones con las variables de salida son: consumo de cemento (x_6), consumo de agua (x_{11}) y consumo de agregados (x_{13}).





Figura 3.20: Variables de entrada. (a) matriz de distancias; (b) matriz de correlación.


Los resultados del ajuste realizado por el MMQ simple y con regularización se muestran en la Tabla 3.6. El método con regularización presenta resultados ligeramente mejores, especialmente para la variable de salida y_3 . La variable de salida y_1 , que representa la temperatura final del concreto después de la hidratación, es la que presentó mejores resultados, considerando que su comportamiento está altamente correlacionado con el consumo de cemento, como se presenta en el ejemplo del análisis de correlación canónica en la sección 2.4.4. Los resultados del modelo MMQ con regularización se presentan en la Figura 3.21 e ilustran los comentarios anteriores.

Tabla 3.6: Comparación de estadísticas de validación


Saída	Modelo	RMS	MAPE	R^2
y_1	MMQ	0.1598	13.03%	0.7686
	MMQ Reg.	0.1573	13.07%	0.7756
y_2	MMQ	0.2178	16.21%	0.5700
	MMQ Reg.	0.2170	15.91%	0.5730
y_3	MMQ	0.2669	17.15%	0.3540
	MMQ Reg.	0.2591	16.45%	0.3911




(a)




(b)




(c)



(d)




(e)




(f)

Figura 3.21: Resultados: (a) e (b) y_1 ; (c) e (d) y_2 ; (e) e (f) y_3 .


Os resultados foram obtidos com as variáveis de saída padronizadas e servem para a escolha da melhor estrutura e/ou abordagem de ajuste. As previsões do modelo devem




(a)




(b)




(c)



(d)



(e)



(f)

Figura 3.21: Resultados: (a) y (b) y_1 ; (c) y (d) y_2 ; (e) y (f) y_3 .

Los resultados se obtuvieron con variables de salida estandarizadas y se utilizan para elegir la mejor estructura y/o enfoque de ajuste. Las predicciones del modelo deben

ser calculadas na escala original das variáveis. Além disso, as variáveis de saída representam os parâmetros de uma função de aproximação da elevação adiabática. A Figura 3.22 mostra o melhor e o pior ajuste realizados pelo modelo MMQ com regularização em relação aos valores observados de elevação de temperatura. A curva em azul mostra a aproximação realizada com os parâmetros utilizados como variável de saída e a curva em vermelho mostra a aproximação realizada com os parâmetros previstos pelo modelo. Podemos verificar que o pior ajuste é bem distante dos valores observados. Na Figura 3.22, o tempo é mostrado em escala logarítmica para facilitar a visualização da elevação de temperatura nas primeiras horas da reação de hidratação.




Figura 3.22: Resultados: (a) melhor ajuste; (b) pior ajuste.

O modelo de elevação adiabática de temperatura é complexo e altamente não linear [174]. Resultados mais precisos foram obtidos com modelos de redes neurais [174] e sistemas *fuzzy* [166].

3.5 Comentários Finais

Neste capítulo, apresentamos os principais conceitos de regressão linear pelo método dos mínimos quadrados. As principais características do processo de modelagem discutidas neste capítulo estão presentes em qualquer modelo preditivo.

O conceito mais importante introduzido neste capítulo é de que o processo de modelagem é, essencialmente, de escolha. O desenvolvimento do modelo segue três etapas principais: identificação da estrutura; ajuste de parâmetros e validação. A escolha da

calcularse sobre la escala original de las variables. Además, las variables de salida representan los parámetros de una función de aproximación de elevación adiabática. La Figura 3.22 muestra los mejores y peores ajustes realizados por el modelo MMQ con regularización en relación a los valores de aumento de temperatura observados. La curva azul muestra la aproximación realizada con los parámetros utilizados como variable de salida y la curva roja muestra la aproximación realizada con los parámetros predichos por el modelo. Podemos ver que el peor ajuste está muy lejos de los valores observados. En la Figura 3.22, el tiempo se muestra en una escala logarítmica para facilitar la visualización del aumento de temperatura en las primeras horas de la reacción de hidratación.




Figura 3.22: Resultados: (a) mejor ajuste; (b) peor ajuste.

El modelo de aumento de temperatura adiabático es complejo y altamente no lineal [174]. Se obtuvieron resultados más precisos con modelos de redes neuronales [174] y sistemas *fuzzy* [166].

3.5 Comentarios finales

En este capítulo, presentamos los conceptos principales de la regresión lineal utilizando el método de mínimos cuadrados. Las principales características del proceso de modelado discutido en este capítulo están presentes en cualquier modelo predictivo.

El concepto más importante introducido en este capítulo es que el proceso de modelado es esencialmente de elección. El desarrollo del modelo sigue tres pasos principales: identificación de la estructura; ajuste y validación de parámetros. la elección de

estrutura é a etapa mais importante e a que tem maior influência sobre o resultado. O ajuste de parâmetros implica a solução de um problema de otimização, que, na regressão linear, é feito pelo método dos mínimos quadrados (MMQ). Tendo em vista os problemas numéricos que surgem da modelagem de sistemas complexos com um número reduzido de observações, as técnicas de regularização são úteis para garantir a estabilidade dos resultados. A validação do modelo visa predizer o seu comportamento em dados diferentes daqueles utilizados para o ajuste. O procedimento de validação cruzada é simples e efetivo para a obtenção de estatísticas de validação confiáveis.

Os resultados no problema *Pollution* mostram que a retirada de *outliers* resulta no aumento de desempenho dos modelos. É importante observar que esse procedimento deve ser utilizado com cautela, pois a retirada de valores extremos resulta na exclusão de valores com potencial para os maiores erros na regressão e, portanto, redução das estatísticas de validação. Entretanto, a retirada de *outliers* favorece que a distribuição do resíduo seja mais simétrica e, conseqüentemente, que as hipóteses do MMQ sejam confirmadas, resultando em modelos de melhor qualidade.

O problema de elevação adiabática de temperatura é complexo e ilustra como, na realidade, é importante realizar transformações nos dados existentes para a construção do conjunto de dados. Dessa forma, a capacidade do analista de encontrar alternativas é determinante para a obtenção de um bom resultado.

No próximo capítulo, os modelos lineares introduzidos neste capítulo serão utilizados para previsão de séries temporais e sistemas dinâmicos lineares.

La estructura es el paso más importante y el que mayor influencia tiene en el resultado. El ajuste de parámetros implica la solución de un problema de optimización, que, en regresión lineal, se realiza mediante el método de mínimos cuadrados (MMQ). Ante los problemas numéricos que surgen al modelar sistemas complejos con un número reducido de observaciones, las técnicas de regularización son útiles para garantizar la estabilidad de los resultados. La validación del modelo tiene como objetivo predecir su comportamiento sobre datos diferentes a los utilizados para el ajuste. El procedimiento de validación cruzada es simple y eficaz para obtener estadísticas de validación confiables.

Los resultados del problema *Pollution* muestran que eliminar *outliers* da como resultado un aumento en el rendimiento del modelo. Es importante señalar que este procedimiento debe usarse con precaución, ya que la eliminación de valores extremos da como resultado la exclusión de valores con potencial para los mayores errores en la regresión y, por lo tanto, una reducción en las estadísticas de validación. Sin embargo, la eliminación de *outliers* favorece que la distribución del residuo sea más simétrica y, en consecuencia, se confirman las hipótesis del MMQ, resultando en modelos de mejor calidad.

El problema del aumento de temperatura adiabático es complejo e ilustra cómo, en realidad, es importante realizar transformaciones en los datos existentes para construir el conjunto de datos. Por tanto, la capacidad del analista para encontrar alternativas es crucial para obtener un buen resultado.

En el próximo capítulo, los modelos lineales presentados en este capítulo se utilizarán para pronosticar series de tiempo y sistemas dinámicos lineales.