

3 REGRESIÓN LINEAL

La regresión lineal es una técnica estadística clásica cuyo objetivo es ajustar un modelo que relaciona una o más variables de entrada o independientes con una o más variables de salida o dependientes. En ciencia de datos, la regresión (lineal o no lineal) también se denomina predicción [232]. En inteligencia computacional, el término aproximación de funciones se utiliza a menudo [298].

El modelo de regresión lineal permite presentar los desafíos asociados con el desarrollo de modelos complejos de forma clara y analítica. Los conceptos introducidos en este capítulo servirán como base para los modelos no lineales presentados en los Capítulos 7, 8 y 9. En la práctica, el modelo lineal es siempre el primero que el analista debe construir debido a su simplicidad, bajo costo computacional y también para obtener un límite de rendimiento más bajo para los modelos no lineales. No son raros los problemas en los que la diferencia de rendimiento entre un modelo lineal y otro más elaborado (como una red neuronal, por ejemplo) es inferior al 5%. Sin embargo, hay casos en los que la relación entre las variables de entrada y salida es intrínsecamente no lineal y modelos más complejos obtienen mejores resultados.

En este capítulo, presentamos el problema de regresión lineal y su solución utilizando el método de mínimos cuadrados. A continuación, abordamos el dilema entre *bias* y la varianza, que es esencial para desarrollar un buen modelo. En este capítulo también se analizan las técnicas de regularización o suavizado de modelos. Finalmente, presentamos estadísticas para validar modelos de regresión, que también se utilizarán para evaluar modelos no lineales.

3.1 El problema de la regresión

Como se presentó en el Capítulo 2, el conjunto de datos está representado en este libro por $\mathcal{T} = \{(\mathbf{x}(t), \mathbf{y}(t)), t = 1 \dots N\}$, donde cada registro está formado por pares ordenados $(\mathbf{x}(t), \mathbf{y}(t))$, siendo $\mathbf{x}(t) \in \mathcal{R}^p$ el vector de variables de entrada y $\mathbf{y}(t) \in \mathcal{R}^q$ el vector de variables de salida.

Las variables de entrada no numéricas se pueden transformar en un conjunto de variables binarias llamadas variables indicadoras o *dummy* [399]. Las variables de salida no numéricas caracterizan el problema de clasificación que se abordará en el Capítulo 5. En este capítulo, se presenta la regresión lineal considerando variables de entrada numéricas y una única variable de salida numérica, es decir, $q = 1$ y $y(t) \in \mathcal{R}$. En la mayoría de los casos, los problemas de regresión de productos múltiples pueden modelarse mediante modelos independientes de un solo producto.

En el problema de regresión lineal simple, una única variable de entrada ($p = 1$) se relaciona linealmente con la variable de salida mediante la ecuación en línea recta $y(t) = ax(t) + b$ (consulte la Figura 3.1). En la práctica, la relación real no se puede observar y los datos contienen perturbaciones de diversos orígenes, como errores de lectura, el efecto de variables no observadas, etc. Por lo tanto, los registros observados, almacenados en el conjunto de datos, contienen perturbaciones, como los puntos azules en la Figura 3.1. El modelo se ajusta en base a estos registros observados y, por tanto, incorpora errores de observación en sus parámetros, siendo descritos por $\hat{y}(t) = \hat{a}x(t) + \hat{b}$ donde $\hat{y}(t)$ es el valor de la variable de salida calculada por el modelo y $\hat{a}$ y $\hat{b}$ son los parámetros ajustados. El error de ajuste o residual del modelo es la diferencia entre los valores observados y calculados por el modelo de la variable de salida, es decir, $e(t) = y(t) - \hat{y}(t)$, para cada registro del conjunto de entrenamiento.

Lo que se espera es que el modelo se acerque lo más posible a la relación real, ya que sabemos que las perturbaciones tienen un origen aleatorio. Así, cuanto más cercana a la relación real, mejor será el rendimiento del modelo para predecir nuevos datos, es decir, registros diferentes a los almacenados en el conjunto de entrenamiento, pero generados con la misma distribución.




Figura 3.1: Ejemplo de regresión lineal.

Suponiendo que la relación entre las variables de entrada y salida es lineal, los parámetros del modelo se pueden ajustar fácilmente minimizando el error total en el conjunto de entrenamiento. El problema es que, en la práctica, no se conocen o no existen elementos para determinar el tipo de función que relaciona las variables de entrada y salida. La variedad de *softwares* y alternativas de modelado es tan grande que el analista a menudo puede ajustar un modelo cuya complejidad es mayor que la complejidad de la relación, como se muestra en la Figura 3.2a. En este caso, se dice que se produjo un ajuste excesivo, o **overfitting** en la jerga de la ciencia de datos.




Figura 3.2: Ejemplo de regresión lineal con *overfitting*: (a) entrenamiento; (b) prueba.

overfitting es un efecto indeseable porque, como las perturbaciones son aleatorias, una nueva muestra de prueba puede producir datos diferentes a los utilizados para la prueba.

entrenamiento y, en este caso, el error producido por el modelo más complejo es mayor que el que se obtendría con un modelo más cercano a la relación ideal (cf. Figura 3.2b).

El razonamiento desarrollado previamente para el modelo lineal simple contiene los elementos principales y resume el problema de regresión: cómo ajustar un modelo basado en datos observados que sea lo más cercano posible a la relación real entre las variables que generaron la muestra. La obtención del modelo, por tanto, depende de la elección adecuada de la forma de relación entre las variables de entrada y salida, que es la estructura del modelo. Esta relación suele estar representada por una función matemática definida por un conjunto de parámetros. El ajuste de los parámetros del modelo se realiza minimizando el error (o residual) entre los valores observados y calculados por el modelo de la variable de salida en el conjunto de entrenamiento. El método de ajuste de parámetros de regresión lineal es el método de mínimos cuadrados, presentado en la sección 3.1.2, pero primero definimos el modelo lineal en la siguiente sección.

3.1.1 El modelo lineal

El modelo de regresión lineal calcula una estimación $\hat{y}(t) \in \mathcal{R}$ de la variable de salida a partir de las variables de entrada $\mathbf{x}(t) \in \mathcal{R}^p$ y los parámetros del modelo como:

$$\hat{y}(t) = \hat{f}(\mathbf{x}(t), \boldsymbol{\theta}) = \hat{\mathbf{x}}(t)\boldsymbol{\theta}^T = \sum_{i=1}^n \hat{x}_i(t)\theta_i \quad (3.1)$$

donde los elementos del vector $\hat{\mathbf{x}}(t) \in \mathcal{R}^n$ se denominan regresores del modelo y el vector de parámetros $\boldsymbol{\theta} = (\theta_1, \dots, \theta_n)$. La notación $\hat{f}(\mathbf{x}(t), \boldsymbol{\theta})$ indica que la predicción de $\hat{y}(t)$ calculada en el punto $\mathbf{x}(t)$ depende de los parámetros $\boldsymbol{\theta}$.

El modelo $\hat{f}(\mathbf{x}(t), \boldsymbol{\theta})$ es una aproximación de la función real $y(t) = f(\mathbf{x}(t))$, que relaciona las variables de entrada con la salida observada, que generalmente es desconocida.

El término "lineal" en regresión lineal indica que el modelo es lineal en parámetros, es decir, que el valor de salida se calcula como una combinación lineal de los regresores. En el modelo lineal simple, o modelo lineal de primer orden, los regresores son las propias variables de entrada y el modelo es un hiperplano. En este caso, el vector de regresores es $\hat{\mathbf{x}}(t) = [1, \mathbf{x}(t)]$, donde se incluye el primer regresor para ajustar el término independiente. El vector de parámetros tiene dimensión $n = p + 1$ y el modelo se escribe como:

$$\hat{y}(t) = \hat{f}(\mathbf{x}(t), \boldsymbol{\theta}) = \theta_0 + \sum_{i=1}^p x_i(t) \theta_i \quad (3.2)$$

La formulación de regresión lineal es lo suficientemente general como para dar cabida a otras estructuras de modelo más complejas. En este caso, la formulación del modelo es una combinación lineal de los regresores, pero su resultado es una función no lineal. En general, el vector de regresores se escribe como $\hat{\mathbf{x}}(t) = (1, h_1(\mathbf{x}(t)), \dots, h_n(\mathbf{x}(t)))$, donde $h_i(\mathbf{x}(t))$ se denominan funciones base [238], como se verá en el Capítulo 7.

Un ejemplo de modelo lineal que da como resultado funciones no lineales es el modelo polinomial, donde $h_i(\mathbf{x}(t)) = \mathbf{x}(t)^i$. El modelo lineal polinomial de grado r se escribe en la forma:

$$\hat{y}(t) = f(\mathbf{x}(t), \boldsymbol{\theta}) = \theta_0 + \sum_{i=1}^r \mathbf{x}(t)^i \boldsymbol{\theta}_i^T \quad (3.3)$$

donde el vector de regresores $\hat{\mathbf{x}}(t) = [1, \mathbf{x}(t), \mathbf{x}(t)^2, \dots, \mathbf{x}(t)^r]$, despreciando los términos cruzados; $\boldsymbol{\theta}_i = (\theta_{i1}, \dots, \theta_{ip})$ es el vector de parámetros de cada término del polinomio y el vector de parámetros del modelo $\boldsymbol{\theta} = [\theta_0, \boldsymbol{\theta}_1, \dots, \boldsymbol{\theta}_r]$, que tiene $n = (r \cdot p) + 1$ elementos.

El ajuste de los parámetros del modelo lineal se realiza minimizando el error cuadrático medio. El algoritmo de ajuste más simple para la regresión lineal es el método de mínimos cuadrados, que se presenta a continuación.

3.1.2 Método de mínimos cuadrados

El resultado del modelo generalmente no es igual al valor observado de la variable de salida y siempre habrá un error o residual $e(t) = y(t) - \hat{y}(t)$ (ver Figura 3.1). Una cita atribuida a George Box dice que “todos los modelos están equivocados, algunos son útiles”.

La calidad de un modelo de datos se mide mediante una función de evaluación que mide la discrepancia entre el valor observado y el valor calculado por el modelo [98]. La función de evaluación utilizada en problemas de regresión lineal es el error cuadrático medio (EMQ), calculado sobre el conjunto de entrenamiento:

$$\text{EMQ}(\boldsymbol{\theta}) = \frac{1}{N} \sum_{t=1}^N (y(t) - \hat{y}(t))^2 = \frac{1}{N} \sum_{t=1}^N (y(t) - \hat{f}(\mathbf{x}(t), \boldsymbol{\theta}))^2 \quad (3.4)$$

EMQ es una medida de la distancia entre el valor observado y el valor predicho por el modelo en cada registro del conjunto de entrenamiento. Estadísticamente, EMQ supone que el residuo $e(t) = y(t) - \hat{y}(t)$ tiene una distribución normal, media cero y varianza constante. Esta hipótesis considera implícitamente que el proceso que generó los datos es estacionario, es decir, que las características estadísticas se mantienen estables. En este caso, minimizar el EMQ corresponde a maximizar la función de verosimilitud entre el modelo y la variable de salida [84][399], como se verá en el apartado 9.2.2.

Si se cumplen las hipótesis, el ajuste de los parámetros del modelo se realiza minimizando el EMQ, que caracteriza el método de mínimos cuadrados (MMQ). El MMQ produce los parámetros de varianza mínima [238]. Sin embargo, no siempre se cumplen todas las hipótesis, pero aun así el MMQ obtiene buenos resultados.

La presentación MMQ es más elegante considerando la matriz de salida $\mathbf{Y}$, cuyos elementos son los valores de las variables de salida de todos los registros del conjunto de entrenamiento, y la matriz $\hat{\mathbf{X}}$ cuyas líneas contienen los regresores de los registros del conjunto de entrenamiento. En este caso, el EMQ se escribe como:

$$EMQ(\boldsymbol{\theta}) = \frac{1}{N} (\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}^T)^T (\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}^T) \quad (3.5)$$

onde $\hat{\mathbf{X}} = \begin{bmatrix} \hat{x}_1(1) & \cdots & \hat{x}_n(1) \\ \vdots & \ddots & \vdots \\ \hat{x}_1(N) & \cdots & \hat{x}_n(N) \end{bmatrix}$, $\boldsymbol{\theta}^T = \begin{bmatrix} \theta_1 \\ \vdots \\ \theta_n \end{bmatrix}$ e, no caso de saída simples, $\mathbf{Y} = \begin{bmatrix} y(1) \\ \vdots \\ y(N) \end{bmatrix}$.

Los parámetros que minimizan EMQ se calculan a partir de la derivada de EMQ respecto de $\boldsymbol{\theta}$, escrita como:

$$\frac{\partial EMQ(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = -\frac{2}{N} \hat{\mathbf{X}}^T (\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}^T) \quad (3.6)$$

La solución se obtiene igualando la derivada EMQ a cero, lo que da como resultado el siguiente sistema lineal de ecuaciones, llamado ecuaciones normales MMQ:

$$\hat{\mathbf{X}}^T \hat{\mathbf{X}} \boldsymbol{\theta}^T = \hat{\mathbf{X}}^T \mathbf{Y} \quad (3.7)$$

Considerando que la matriz de regresores tiene rango completo, es decir, $rank(\hat{\mathbf{X}}) = n$, la solución del sistema lineal (3.6) se puede calcular como

$$\boldsymbol{\theta}^* = (\hat{\mathbf{X}}^T \hat{\mathbf{X}})^{-1} \hat{\mathbf{X}}^T \mathbf{Y} \quad (3.8)$$

donde la matriz $(\hat{\mathbf{X}}^T \hat{\mathbf{X}})^{-1} \hat{\mathbf{X}}^T$ se llama pseudoinversa de $\hat{\mathbf{X}}$

Los valores predichos por el modelo para los registros del conjunto de entrenamiento se pueden calcular a partir de la solución (3.8) como:

$$\hat{\mathbf{Y}} = \hat{\mathbf{X}} \boldsymbol{\theta}^* = \hat{\mathbf{X}} (\hat{\mathbf{X}}^T \hat{\mathbf{X}})^{-1} \hat{\mathbf{X}}^T \mathbf{Y} = \mathbf{H} \mathbf{Y} \quad (3.9)$$

La matriz $\mathbf{H} = \hat{\mathbf{X}} (\hat{\mathbf{X}}^T \hat{\mathbf{X}})^{-1} \hat{\mathbf{X}}^T$, de dimensión $N \times N$, se denomina “matriz del sombrero” [238][399], ya que “pone el sombrero” en $\mathbf{Y}$.

La solución MMQ usando la ecuación (3.8) es computacionalmente compleja, ya que implica calcular la inversa de la matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$. Si el rango de la matriz regresora no es completo, la ecuación (3.8) puede volverse numéricamente inestable. Existen alternativas para calcular los parámetros del modelo lineal que se discutirán en la sección 3.2.

3.1.3 Interpretación geométrica

El método de mínimos cuadrados tiene una interpretación geométrica que se muestra en la Figura 3.3. Supongamos que cada registro observado de la variable de salida representa una coordenada en el espacio de dimensión N , llamado espacio muestral, de modo que el conjunto de registros de la variable de salida define el vector $\mathbf{Y} \in \mathcal{R}^N$. Cada columna de la matriz regresora $\hat{\mathbf{X}} \in \mathcal{R}^{N \times n}$ es también un vector en el espacio muestral y las columnas n de la matriz regresora definen un subespacio de dimensión n , llamado subespacio modelo, representado por el área gris en la Figura 3.3.

Todos los modelos lineales $\hat{\mathbf{Y}} = \hat{\mathbf{X}} \boldsymbol{\theta}^T$, es decir, todas las combinaciones lineales de regresores, se definen en el subespacio del modelo. La distancia entre $\hat{\mathbf{Y}} = \hat{\mathbf{X}} \boldsymbol{\theta}^T$ y el vector de observación $\mathbf{Y}$ se calcula como:

$$dist(\boldsymbol{\theta}) = \|\mathbf{Y} - \hat{\mathbf{X}} \boldsymbol{\theta}^T\| = \sqrt{(\mathbf{Y} - \hat{\mathbf{X}} \boldsymbol{\theta}^T)^T (\mathbf{Y} - \hat{\mathbf{X}} \boldsymbol{\theta}^T)} \quad (3.10)$$

La ecuación (3.10) muestra que $EMQ(\boldsymbol{\theta}) = dist^2(\boldsymbol{\theta})/N$, de modo que la solución $\boldsymbol{\theta}^*$ que minimiza el EMQ produce el residuo de norma más baja L^2 . Por tanto, el modelo debe ser ortogonal al residuo:

$$\hat{\mathbf{Y}}^T (\mathbf{Y} - \hat{\mathbf{X}} \boldsymbol{\theta}^*) = 0 \quad (3.11)$$

La ecuación (3.11) indica que el residuo no debe correlacionarse con los resultados del modelo. En la práctica, EMQ no es nula y la igualdad presentada en la ecuación (3.11)

Esto no está verificado, pero este resultado proporciona una prueba para validar el modelo de regresión lineal. Otras estadísticas de validación se discutirán en la sección 3.3.

La figura 3.3 muestra un ejemplo de la interpretación geométrica analizada en el caso de un modelo lineal simple de una muestra de registros de dimensión $N = 3$. El ejemplo se generó con el conjunto de datos $\mathcal{T} = \{(0.2, 0.6), (0.5, 0.2), (0.7, 0.9)\}$. La matriz $\hat{\mathbf{X}} = [\mathbf{1}, \mathbf{X}]$ es la matriz de regresores que define el subespacio vectorial del modelo (en gris), formado por el vector $\mathbf{1}$, cuyos elementos son todos 1, y el vector $\mathbf{X} = [0.2, 0.5, 0.7]^T$, cuyos elementos son los registros de la variable de entrada.

El resultado del ajuste del modelo por MMQ es el vector de parámetros $\boldsymbol{\theta}^* = [0.35, 0.44]^T$, que da como resultado la estimación $\hat{\mathbf{Y}} = [0.44, 0.58, 0.67]^T$. Tenga en cuenta que el vector residual es ortogonal al vector de estimación ubicado en el subespacio vectorial del modelo (en gris).




Figura 3.3: Interpretación geométrica del método de mínimos cuadrados.

La interpretación geométrica también muestra intuitivamente que la dimensión del espacio modelo no puede ser mayor que la dimensión del espacio muestral, es decir, $n < N$. De lo contrario, el modelo sería más complejo que la muestra misma. El modelado puede entenderse como un proceso de compresión de información en el que los registros de muestra N están representados por los parámetros del modelo n .

El tamaño de la muestra en relación con el tamaño del modelo es un tema importante que tiene una gran influencia en la calidad del modelo. Cuanto mayor sea el tamaño de la muestra, mejor será el rendimiento del MMQ. En la práctica, el número de registros en una muestra

tra puede no ser muy grande cuando existe un costo asociado con la observación de los registros. Para obtener un muestreo relativamente denso en espacios de alta dimensión, la cantidad de registros necesarios aumenta exponencialmente con la cantidad de variables de entrada. En espacios de alta dimensión, los datos se vuelven muy escasos. Hastie, Tibshirani y Friedman [238] muestran un ejemplo en el que consideran un muestreo uniforme en un hipercubo con lado unitario. En este caso, para un problema de dimensión $p = 10$, es necesario utilizar el 80% de cada dimensión para capturar el 10% de los datos. Este efecto se conoce en la literatura como la “maldición de la dimensionalidad” [98][238].

En la siguiente sección, presentamos un ejemplo simple en el que se analiza el efecto de la elección de la estructura del modelo en el resultado del modelado.

3.1.4 Ejemplo sintético

En este ejemplo, el conjunto de datos se generó a partir de la función $y = x^2$, agregando una perturbación aleatoria con media cero y desviación estándar de 0,2. La Figura 3.4a muestra el conjunto de datos y la función $y = x^2$ en el dominio de muestra.

Se generaron tres modelos a partir de este conjunto de datos: un modelo lineal o polinómico simple de grado $r = 1$; un polinomio de grado $r = 2$; y un polinomio de grado $r = 10$. Como en este problema la variable de entrada tiene una sola dimensión, la expresión del modelo o polinomial en la ecuación (3.3) se reduce a $\hat{y}(t) = \theta_0 + \sum_{i=1}^r x^i \theta_i$ y el modelo tiene $n = r + 1$ parámetros.

Los resultados del ajuste de cada uno de estos modelos se muestran, respectivamente, en la Figura 3.4b, Figura 3.4c y Figura 3.4d. El modelo lineal simple no representa bien la relación real, que es más compleja. En el caso del modelo polinomial $r = 10$, la complejidad del modelo es mucho mayor que la de la relación y su resultado fue corrompido por la presencia de ruido. En el caso del modelo polinomial de grado $r = 2$, el resultado del modelo es muy cercano a la función $y = x^2$ utilizada para generar la muestra, ya que el modelo fue ajustado con la estructura correcta.

La Tabla 3.1 muestra los parámetros ajustados para cada uno de los modelos. Podemos observar que el modelo lineal simple es prácticamente el promedio de la variable de salida. En el caso del modelo polinómico de grado $r = 2$, los parámetros ajustados por MMQ corresponden a los de la relación real hasta el primer decimal. En el caso del modelo polinómico

grado $r = 10$, algunos parámetros tienen valores muy grandes en relación con la escala de la variable de salida, lo que indica que el ajuste realizado por este modelo no fue el adecuado.




Figura 3.4: Ejemplo de ajuste de parámetros por MMQ: (a) conjunto de datos; (b) modelo lineal puro; (c) modelo polinomial de grado 2; (d) modelo polinómico de grado 10.

El ejemplo presentado en la Figura 3.4 muestra que *overfitting* ocurre cuando la complejidad del modelo es inadecuada para la muestra. Sin embargo, MMQ puede ajustarse adecuadamente a un modelo, incluso de complejidad inadecuada, cuando el conjunto de datos es lo suficientemente grande. La Figura 3.5 muestra el resultado del modelo polinómico de grado 10 para el caso de una muestra con registros $N = 200$ y $N = 400$.

Podemos observar que, incluso siendo la complejidad del modelo mayor que la de la relación real, un modelo adecuado se ajusta con un mayor número de registros. Así, *overfitting* ocurre cuando la complejidad del modelo es mayor que la de la relación y, adicionalmente, el tamaño de la muestra es pequeño en relación con la complejidad del modelo.

de lo que quieres ajustar. Existen técnicas de combinación de modelos (llamadas *ensembles*) como *Boosting* [185][186] que explotan la ponderación del conjunto de datos de entrenamiento para aumentar el rendimiento del modelo. La relación entre la complejidad del modelo y el tamaño de la muestra se explorará en el Capítulo 7.

Tabla 3.1: Parámetros ajustados de los modelos en la Figura 3.4

θ	$r = 1$	$r = 2$	$r = 10$
θ_0	0.4131	0.0104	-0.1394
θ_1	-0.0325	-0.0325	-0.8151
θ_2		1.0983	8.455
θ_3			6.2056
θ_4			-53.2585
θ_5			-15.7255
θ_6			132.2678
θ_7			16.2839
θ_8			-133.545
θ_9			-5.9739
θ_{10}			47.2605




Figura 3.5: Efecto del número de registros en el modelo de grado 10: (a) $N = 200$; (b) $N = 400$.

En MMQ, incluso con una muestra reducida, es posible controlar la complejidad del modelo y encontrar una solución estable para el sistema lineal (3.7) mediante técnicas de regularización, que se presentan a continuación.

3.2 Regularización

Desarrollar un modelo en ciencia de datos es esencialmente un proceso de elección, a menudo llamado entrenamiento o “aprendizaje” [98], que se puede resumir en los siguientes pasos:

1. Preselección de un conjunto de funciones $\mathcal{F}$ que pueden contener un elemento capaz de ajustar el mapeo entrada-salida representado por el conjunto de entrenamiento. En general, este paso se define por la elección del tipo de modelo.
2. Definición de un conjunto de hipótesis o conocimientos *a priori* que establezca restricciones a la familia de funciones $\mathcal{F}$ como solución al problema. Estas restricciones tienen como objetivo limitar el espacio de soluciones a un subconjunto $\mathcal{F}^* \subseteq \mathcal{F}$ y, en algunos casos, pueden definirse mediante parámetros. Este paso se llama selección de la estructura del modelo.
3. Definición de una medida (o función) para evaluar la calidad de una instancia $f \in \mathcal{F}^*$. La función de evaluación se utiliza en la formulación de un problema de optimización cuya solución define la aproximación óptima f^* .
4. Uso de un algoritmo de optimización para el problema formulado en 3) cuya solución son los parámetros ajustados del modelo.

En el caso del ejemplo sintético del apartado 3.1.4, el paso (1) corresponde a la selección del modelo polinomial de grado r . En el paso (2), se seleccionaron tres estructuras modelo eligiendo el grado del polinomio. El proceso inductivo asociado con MMQ es la minimización de EMQ y la solución está definida por la ecuación (3.8). A lo largo de este libro, se presentarán alternativas para cada uno de estos pasos, de modo que se pueda encontrar la mejor solución para diferentes problemas.

Actualmente, el analista tiene a su disposición una amplia variedad de modelos *softwares* gratuitos y comerciales. En muchos casos, el problema *overfitting* no es tan obvio como en el ejemplo presentado en la Figura 3.4d. Por tanto, es importante comprender las causas de *overfitting* para construir buenos modelos, es decir, modelos con buena capacidad de generalización.

La regularización es una técnica que permite reducir la complejidad del modelo para obtener un modelo más estable que permita una mejor generalización a los datos.

diferentes a los utilizados en el ajuste de parámetros. Las técnicas de regularización están fuertemente asociadas con la relación *bias* y la varianza, que se presentan a continuación.

3.2.1 *Bias* y varianza

La estimación de un modelo con *overfitting* depende de la muestra utilizada para ajustar el modelo. La porción de EMQ (cf. ecuación (3.4)) calculada para cualquier punto $\mathbf{x}(t)$ del conjunto de entrenamiento es una estimación del valor esperado * del error al cuadrado en ese punto cuando el número de muestras $N \rightarrow \infty$ [187]:

$$\lim_{N \rightarrow \infty} (y(t) - \hat{f}(\mathbf{x}(t), \boldsymbol{\theta}))^2 = E \left((y_r(t) - \hat{f}(\mathbf{x}(t), \boldsymbol{\theta}))^2 \right) \quad (3.12)$$

donde $y_r(t) = E(y(t))$ es el valor de la función real en $\mathbf{x}(t)$.

La ecuación (3.12) es válida para cualquier registro del conjunto de entrenamiento y podemos escribir $y_r(t) = y_r$ y $f(\mathbf{x}(t), \boldsymbol{\theta}) = \hat{y}$ para simplificar la notación. El valor esperado del error al cuadrado en $\mathbf{x}(t)$ se puede descomponer en dos factores [238] como:

$$\begin{aligned} E((y_r - \hat{y})^2) &= (y_r - E(\hat{y}))^2 + E((\hat{y} - E(\hat{y}))^2) \\ &= \text{bias}^2 + \text{variância} \end{aligned} \quad (3.13)$$

El término $(y_r - E(\hat{y}))$ se llama modelo teórico ***bias*** y el término $E((\hat{y} - E(\hat{y}))^2)$ se llama varianza teórica del modelo. El *bias* es entonces la diferencia entre el valor real de la función en $\mathbf{x}(t)$ y el valor esperado de la aproximación en ese punto. La varianza es el valor esperado de la diferencia entre la estimación de un modelo y el valor esperado de todas las estimaciones.

Se puede realizar una aproximación del cálculo del valor esperado promediando varias realizaciones de la variable aleatoria, lo que permite visualizar el efecto de *bias* y la varianza sobre los resultados del ajuste de los modelos en el ejemplo de la Figura 3.4. Para esto se generaron 10 muestras de registros $N = 20$ a partir de la función $y_r = x^2 + \varepsilon$, donde el ruido ε fue generado por una distribución normal $\varepsilon \sim N(0, 0.2)$. La *bias* y la varianza en todos los puntos se calcularon mediante descomposición (3.13). Para tener una idea de estos valores para cada modelo, se calculó el promedio de todos los puntos, ya que el

* O valor esperado é definido como $E(x) = \int_{-\infty}^{\infty} xp(x)dx$, onde $p(x)$ é a função densidade de probabilidades da variável aleatória. O valor esperado pode ser aproximado pela média aritmética de todas as realizações da variável aleatória [400].

Los valores de las variables de entrada siguen siendo los mismos para todas las muestras. El resultado se muestra en la Figura 3.6a para el modelo lineal simple y en la Figura 3.6b para el modelo polinómico de grado 10. En los dos gráficos de la Figura 3.6, la curva verde presenta la función real $y_r = x^2$, los puntos de muestra se muestran en azul, el modelo ajustado $\hat{y}$ con cada muestra en rojo y el promedio de los modelos entre todas las muestras en negro.

Ambos casos presentan una estructura inadecuada, como ya se ha comentado. El modelo lineal simple presenta una *bias* alta, pero una varianza pequeña, mientras que el modelo de grado 10 presenta una *bias* pequeña y una varianza alta, mostrando que es más sensible a la muestra que el primero.




Figura 3.6: *Bias* y varianza: (a) modelo lineal simple; (b) modelo de grado 10.

Los resultados de los modelos ajustados con la estructura correcta, es decir, un polinomio de grado 2, se muestran en la Figura 3.7. Podemos observar que el modelo con la estructura correcta es capaz de minimizar simultáneamente *bias* y la varianza y que la media de todos los modelos se aproxima bien a la función real.

La simulación anterior nos permite concluir que *bias* ocurre cuando la complejidad del modelo es menor que la de la función real y que la varianza es efecto de la inestabilidad de modelos muy complejos en relación al tamaño de la muestra. El objetivo de las técnicas de regularización es reducir la varianza de un modelo de alta complejidad para que el modelo se vuelva adecuado a la complejidad del problema, manteniendo *bias* bajo.




Figura 3.7: *Bias* y *varianza* en el modelo de grado 2.

La Figura 3.8 muestra el concepto de regularización como una forma de reducir la varianza del modelo. La figura 3.8 utiliza los elementos de la descomposición del error al cuadrado en *bias* y la varianza en la ecuación (3.13). El círculo gris en el centro de la figura representa el conjunto de valores posibles de la muestra, cuyo centro es el valor real de la función y_r . El valor observado en la muestra difiere del valor real debido al error de observación $e_o = y - y_r$. A partir de una estructura de modelo definida, el ajuste del MMQ produce una estimación $\hat{y}$ cuya diferencia con relación al valor observado es el residual del modelo $e = y - \hat{y}$. Considerando todas las muestras posibles, la varianza del modelo $E((\hat{y} - E(\hat{y}))^2)$ está representada por el círculo naranja más grande. Con esta estructura, el modelo producido por MMQ, considerando una muestra infinita de datos, es el valor esperado del modelo $E(\hat{y})$. El *bias* del modelo es la diferencia entre el valor real y el valor esperado del modelo.

La técnica de regularización tiene como objetivo reducir el espacio del modelo, lo que producirá una estimación de complejidad reducida $\hat{y}'$ para el valor observado y . Esta estimación, a pesar de presentar un residuo mayor del modelo $e = y - \hat{y}'$, se acerca más al resultado que se obtendría con una muestra infinita $E(\hat{y}')$, por lo que la varianza de la estimación del modelo reducido $E((\hat{y}' - E(\hat{y}'))^2)$ es menor. El *bias* de la estimación del modelo reducido puede ser mayor, pero la suma EMQ que considera *bias* y la varianza puede ser menor para el resultado del modelo reducido que para el resultado del modelo inicial.




Figura 3.8: Concepto de regularización. Adaptado de [238].

El concepto de regularización descrito anteriormente se formalizará matemáticamente en dos técnicas ampliamente difundidas en las siguientes secciones.

3.2.2 Regularización de Tikhonov

En la regresión lineal, *overfitting* ocurre porque el modelo es demasiado complejo para el tamaño de la muestra y el problema queda mal condicionado, es decir, la solución del sistema lineal (3.7) es muy sensible a la muestra y se vuelve inestable. Para superar este problema es necesario reducir la complejidad del modelo, ya sea modificando directamente su estructura o aplicando algún tratamiento numérico que permita el ajuste de un modelo menos complejo.

Tikhonov propuso el método de regularización clásico para resolver sistemas lineales mal condicionados [524]. En estadística, el método de Tikhonov fue introducido por Hoerl y Kennard [255] y lo denominaron *ridge regression*.

La regularización de Tikhonov es una técnica para controlar la complejidad del modelo aplicando una penalización al vector de parámetros. La solución se obtiene minimizando el error cuadrático medio regularizado (EMQR):

$$EMQR(\mu, \boldsymbol{\theta}) = \frac{1}{N} \sum_{t=1}^N (y(t) - \hat{f}(\mathbf{x}(t), \boldsymbol{\theta}))^2 + \mu \|\boldsymbol{\theta}\|^2 \quad (3.14)$$

donde $\mu \geq 0$ es el parámetro de regularización que controla la aplicación de la penalización. Tenga en cuenta que, al igual que $\mu \geq 0$, $EMQR(\mu, \boldsymbol{\theta}) \geq EMQ(\boldsymbol{\theta})$, lo cual es consistente con el razonamiento presentado en la Figura 3.8.

En el modelo lineal, el EMQR se escribe utilizando notación vectorial como:

$$EMQR(\mu, \boldsymbol{\theta}) = \frac{1}{N} (\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}^T)^T (\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}^T) + \mu \boldsymbol{\theta}\boldsymbol{\theta}^T \quad (3.15)$$

onde $\hat{\mathbf{X}} = \begin{bmatrix} \hat{x}_1(1) & \cdots & \hat{x}_n(1) \\ \vdots & \ddots & \vdots \\ \hat{x}_1(N) & \cdots & \hat{x}_n(N) \end{bmatrix}$, $\boldsymbol{\theta}^T = \begin{bmatrix} \theta_1 \\ \vdots \\ \theta_n \end{bmatrix}$ e $\mathbf{Y} = \begin{bmatrix} y(1) \\ \vdots \\ y(N) \end{bmatrix}$, como na equação (3.5).

Minimizando el EMQR siguiendo el mismo procedimiento anterior se obtiene el sistema lineal $(\hat{\mathbf{X}}^T \hat{\mathbf{X}} + \mu \mathbf{I}) \boldsymbol{\theta}^T = \hat{\mathbf{X}}^T \mathbf{Y}$, cuya solución se calcula como:

$$\boldsymbol{\theta}_\mu^* = (\hat{\mathbf{X}}^T \hat{\mathbf{X}} + \mu \mathbf{I})^{-1} \hat{\mathbf{X}}^T \mathbf{Y} \quad (3.16)$$

donde $\mathbf{I}$ es la matriz identidad.

La regularización de Tikhonov funciona para condicionar la matriz de coeficientes $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$ través del parámetro de regularización μ .

El condicionamiento de una matriz $\mathbf{A}$ refleja la sensibilidad de la solución de un sistema lineal en el que la matriz $\mathbf{A}$ es la matriz de coeficientes. Si la matriz $\mathbf{A}$ está mal condicionada, pequeños cambios en el término independiente pueden provocar grandes variaciones en la solución. El condicionamiento de una matriz cuadrada $\mathbf{A}$ se mide mediante el número de condición, definido como $\kappa(\mathbf{A}) = \|\mathbf{A}\| \|\mathbf{A}^{-1}\|$, y se calcula a partir de sus valores propios [206]:

$$\kappa(\mathbf{A}) = \frac{\lambda_{max}}{\lambda_{min}} \quad (3.17)$$

donde λ_{max} y λ_{min} son, respectivamente, el valor propio mayor y menor de $\mathbf{A}$.

La ecuación (3.17) muestra que si $\lambda_{min} \rightarrow 0$, el número de condición de la matriz $\kappa(\mathbf{A}) \rightarrow \infty$ y la matriz tiende a ser singular. El valor propio más pequeño $\lambda_{min} = 0$ indica que hay columnas linealmente dependientes, es decir, la matriz tiene un rango deficiente y el sistema lineal es indeterminado. Un valor grande del número de condición, por ejemplo, $\kappa(\mathbf{A}) > 1.000$, indica que el condicionamiento de la matriz es cercano al singular y que la solución del sistema lineal es inestable, siendo muy sensible a las perturbaciones.

En el caso de la regresión lineal, la matriz de coeficientes en el MMQ (cf. ecuación (3.7)) es la matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$ y el término independiente, $\hat{\mathbf{X}}^T \mathbf{Y}$. La existencia de regresores altamente correlacionados causa un mal condicionamiento de la matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$ resulta en inestabilidad en la solución, lo que, en el contexto del problema de regresión, significa *overfitting*. En otras palabras, un modelo muy complejo (en relación al tamaño de la muestra) resulta en problemas de condicionamiento en la matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$ inestabilidad en la solución. Este efecto se puede observar mediante los valores del vector de parámetros $\boldsymbol{\theta}$ en la solución para el modelo de grado 10 que se muestra en la Tabla 3.1.

En la regularización de Tikhonov, agregar una constante a la diagonal principal de la matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$ cambia su número de condición como:

$$\kappa(\mathbf{A}) = \frac{\lambda_{\max} + \mu}{\lambda_{\min} + \mu} \quad (3.18)$$

De esta forma, incluso si la matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$ es singular y $\lambda_{\min} = 0$, la matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}} + \mu \mathbf{I}$ será numéricamente estable y la solución (3.16) podrá calcularse adecuadamente.

Controlar el condicionamiento de la matriz regresora fue la principal motivación para introducir el método de Tikhonov en la regresión lineal [255]. Actualmente, el problema de regularización mediante minimización EMQR (3.14) se ha tratado como una técnica general para controlar la complejidad del modelo [98][238][478].

En la regularización de Tikhonov, el parámetro de regularización debe informarse o calcularse automáticamente [399]. Hoerl, Kennard y Baldwin [256] presentan la siguiente propuesta para calcular el parámetro μ :

$$\mu = \frac{n}{(N - n)} \frac{\|\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}^T\|^2}{\|\boldsymbol{\theta}\|^2} \quad (3.19)$$

donde n es el número de parámetros y $\boldsymbol{\theta}$ es la solución MMQ sin regularización. El término $\|\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}^T\|^2 / (N - n)$ es una estimación de la varianza del residual (cf. ecuación (3.30)).

La regularización de Tikhonov puede entenderse en el contexto de la selección de modelos mediante el ajuste del parámetro de regularización μ , cuya variación permite una regulación continua de la estructura del modelo, lo que puede resultar interesante en algunos casos.

La Figura 3.9 presenta el conjunto de datos de ejemplo discutido en la sección 3.1.4 con el resultado de ajustar el modelo polinómico de grado 10 mediante minimización EMQR, con dos

valores para el parámetro de regularización. La Figura 3.9a muestra el ajuste con el valor obtenido por la ecuación (3.19) con $\mu = 1 \times 10^{-5}$ y la Figura 3.9b muestra el resultado obtenido con el valor $\mu = 0.1$ elegido en la forma *ad hoc*.




Figura 3.9: Modelo de grado 10 con regularización: (a) $\mu = 1 \times 10^{-5}$; (b) $\mu = 0.1$.

La Tabla 3.2 muestra los valores de los parámetros. Se incluyó el resultado obtenido sin regularización ($\mu = 0.0$) para facilitar la comparación.

Tabla 3.2: Parámetros ajustados de los modelos en la Figura 3.9

θ	$\mu = 0.0$	$\mu = 1 \times 10^{-5}$	$\mu = 0.1$
θ_0	-0.1394	-0.0556	0.0567
θ_1	-0.8151	-0.7044	-0.1218
θ_2	8.4550	4.2082	0.6766
θ_3	6.2056	4.7143	0.1997
θ_4	-53.2585	-18.5496	0.4438
θ_5	-15.7255	-10.2949	0.0189
θ_6	132.2678	33.0619	0.2380
θ_7	16.2839	8.9882	-0.0538
θ_8	-133.5450	-18.2708	-0.0253
θ_9	-5.9739	-2.7254	-0.0693
θ_{10}	47.2605	0.6354	-0.2803

La solución MMQ robusta también se puede obtener evitando las componentes asociadas a valores propios cercanos a cero, mediante el método de componentes principales.

3.2.3 Regularização por componentes principais

En la sección 2.4.2, vimos que la descomposición en valores singulares (SVD) permite eliminar columnas linealmente dependientes de una matriz mediante una transformación lineal ortogonal. SVD permite una solución robusta de sistemas lineales considerando solo las columnas linealmente independientes de la matriz de coeficientes.

Considere la SVD de la matriz regresora $\hat{\mathbf{X}} = \mathbf{USV}^T$ aplicada al ajuste del parámetro MMQ mediante la ecuación (3.8):

$$\boldsymbol{\theta}^* = (\hat{\mathbf{X}}^T \hat{\mathbf{X}})^{-1} \hat{\mathbf{X}}^T \mathbf{Y} = (\mathbf{VS}^2 \mathbf{V}^T)^{-1} \mathbf{VSU}^T \mathbf{Y} = \mathbf{VS}^{-1} \mathbf{U}^T \mathbf{Y} \quad (3.20)$$

Se puede obtener una solución estable del MMQ utilizando solo las $r \leq \text{rank}(\hat{\mathbf{X}})$ columnas linealmente independientes de la matriz de regresor como:

$$\boldsymbol{\theta}_r^* = \sum_{i=1}^r \left(\frac{\mathbf{u}_i^T \mathbf{Y}}{s_i} \right) \mathbf{v}_i \quad (3.21)$$

donde $\mathbf{u}_i$ y $\mathbf{v}_i$ son las columnas de $\mathbf{U}$ y $\mathbf{V}$ y s_i es el valor singular correspondiente.

La suma de $r \leq \text{rank}(\hat{\mathbf{X}})$ términos asociados a los valores singulares más grandes evita el uso de valores muy pequeños de s_i , que provocan inestabilidad de la solución, como se muestra en la ecuación (3.21). Por lo tanto, la solución (3.21) no utiliza todas las columnas de $\mathbf{U}$ y $\mathbf{V}$, como por ejemplo $\|\boldsymbol{\theta}_r^*\| < \|\boldsymbol{\theta}^*\|$. Entonces puede verse como la solución reducida del MMQ y, por tanto, una técnica de regularización.

La descomposición SVD de la matriz regresora $\hat{\mathbf{X}}$ es equivalente a la descomposición en valores propios y vectores propios de la matriz $\hat{\mathbf{X}}^T \hat{\mathbf{X}}$ como se ve en la sección 2.4.2. La solución a la ecuación (3.21) corresponde a la aplicación del MMQ a los componentes principales de la matriz regresora, lo que da nombre al método.

La regularización por componentes principales también se puede utilizar como una forma de seleccionar modelos variando el parámetro $r \leq \text{rank}(\hat{\mathbf{X}})$. En muchos software, la solución (3.21) se utiliza como una solución robusta del sistema lineal (3.16) con $r \approx \text{rank}(\hat{\mathbf{X}})$, que es transparente para el usuario.

Para comparar con resultados anteriores, la Figura 3.10 presenta los resultados del ajuste del modelo polinómico de grado 10 utilizando el método de componentes principales. La Figura 3.10a muestra el ajuste con el valor obtenido con $r = \text{rank}(\hat{\mathbf{X}}) = 9$ y la Figura 3.10b, el resultado obtenido con el valor $r = 5$ elegido en la forma *ad hoc*.




Figura 3.10: Modelo de grado 10 con regularización: (a) $r = 9$; (b) $r = 5$.

La Tabla 3.2 muestra los valores de los parámetros. También se incluyó el resultado obtenido o sin regularización ($r = 11$) para facilitar la comparación.

Tabla 3.3: Parámetros ajustados de los modelos en la Figura 3.10

θ	$r = 11$	$r = 9$	$r = 5$
θ_0	-0.1394	-0.0408	0.0248
θ_1	-0.8151	-0.5505	-0.0447
θ_2	8.4550	3.3565	0.8601
θ_3	6.2056	2.6037	-0.0054
θ_4	-53.2585	-11.0903	0.4039
θ_5	-15.7255	-2.5260	0.0083
θ_6	132.2678	10.7787	0.1023
θ_7	16.2839	-1.5235	0.0146
θ_8	-133.5450	8.4170	-0.0871
θ_9	-5.9739	1.9788	0.0178
θ_{10}	47.2605	-10.3956	-0.2107

3.3 Validación del modelo

El enfoque clásico para validar modelos de regresión lineal es probar las hipótesis del MM Q [399]. El rendimiento del modelo depende principalmente de la elección de la mejor estructura o parámetros de regularización. De esta forma, la selección del modelo se realiza en base a estadísticas y procedimientos de validación.

Las estadísticas de validación miden el rendimiento del modelo en un conjunto de datos determinado. La forma más eficaz de evaluar la capacidad predictiva del modelo es comprobar las estadísticas de validación sobre datos diferentes a los utilizados para ajustar los parámetros. La validación cruzada, utilizando estadísticas de validación de modelos, es un método eficaz y práctico para evaluar la calidad predictiva del modelo. Las principales estadísticas de validación para la regresión lineal se presentan en la siguiente sección y la validación cruzada se presenta en la sección 3.3.2.

3.3.1 Estadísticas de validación

Las estadísticas de validación se calculan a partir del residual en cada registro:

$$e(t) = y(t) - \hat{y}(t), t = 1, \dots, N \quad (3.22)$$

El análisis de varianza del modelo se realiza mediante la descomposición [399]:

$$\sum_{t=1}^N (y(t) - \bar{y})^2 = \sum_{t=1}^N (\hat{y}(t) - \bar{y})^2 + \sum_{t=1}^N (y(t) - \hat{y}(t))^2 \quad (3.23)$$

donde $\bar{y}$ representa la media de la variable de salida.

La ecuación (3.23) se puede escribir como $SS_T = SS_R + SS_{Res}$, donde SS_T es la suma de cuadrados totales, que representa la variabilidad total de la variable de salida; SS_R es la suma de cuadrados de la regresión, que representa la porción de la variabilidad total explicada por el modelo; y SS_{Res} es la suma de cuadrados de los residuos, que representa la porción de la variabilidad total que no puede ser explicada por el modelo.

El coeficiente de determinación R^2 mide el porcentaje de la variabilidad total que el modelo explica como [399]:

$$R^2 = \frac{SS_R}{SS_T} = \frac{\sum_{t=1}^N (\hat{y}(t) - \bar{y})^2}{\sum_{t=1}^N (y(t) - \bar{y})^2} = 1 - \frac{SS_{Res}}{SS_T} = 1 - \frac{\sum_{t=1}^N (y(t) - \hat{y}(t))^2}{\sum_{t=1}^N (y(t) - \bar{y})^2} \quad (3.24)$$

El coeficiente de determinación $R^2 \leq 1$ ya que SS_T es fijo y $SS_{Res} \leq SS_T$. El valor $R^2 \approx 1$ indica un resultado adecuado ya que el modelo explica la mayor parte de la variabilidad total. Intuitivamente, el coeficiente de determinación compara el error del modelo estimado con el error de la media de la variable de salida. Si el error del modelo es del mismo orden de magnitud que el error medio, el valor $R^2 \approx 0$ indica que el modelo no puede

explican las observaciones mejor que el promedio de la variable de salida. En algunos casos, el valor $R^2 < 0$ indica que el modelo es peor que el promedio de la variable de salida.

El coeficiente de determinación es muy sensible a valores más altos de la variable de salida ya que los errores están al cuadrado. Para evaluar valores más pequeños se puede utilizar el coeficiente de determinación calculado sobre los logaritmos de los valores observados y predichos:

$$R_{log}^2 = 1 - \frac{\sum_{t=1}^N (\log(y(t)) - \log(\hat{y}(t)))^2}{\sum_{t=1}^N (\log(y(t)) - \overline{\log(y(t))})^2} \quad (3.25)$$

donde $\overline{\log(y(t))}$ es la media del logaritmo de los valores observados.

Una estadística ampliamente utilizada para la evaluación de modelos es la raíz cuadrada del EMQ, conocida como RMS:^{*}

$$RMS = \sqrt{\frac{1}{N} \sum_{t=1}^N e^2(t)} = \sqrt{\frac{1}{N} \sum_{t=1}^N (y(t) - \hat{y}(t))^2} \quad (3.26)$$

El resultado RMS tiene la misma escala que la variable de salida y puede analizarse en el contexto del problema.

Una estadística de validación similar a RMS es el error absoluto medio (MAE)[†]:

$$MAE = \frac{1}{N} \sum_{t=1}^N |y(t) - \hat{y}(t)| \quad (3.27)$$

El error porcentual absoluto medio (MAPE)[‡] es una variante de MAE que presenta errores de forma relativa:

$$MAPE = \frac{1}{N} \sum_{t=1}^N \left| \frac{y(t) - \hat{y}(t)}{y(t)} \right| \quad (3.28)$$

La estadística MAPE es una medida relativa y debe usarse con precaución si la variable de salida está estandarizada por la estimación *z-scores*, ya que puede generar errores en

^{*} *Root Mean Square.*

[†] *Mean Absolute Error.*

[‡] *Mean Absolute Percentual Error.*

redondeo y, eventualmente, división por cero. Cuando la variable de salida no contiene un valor nulo, el resultado en forma porcentual permite una evaluación intuitiva de la calidad del modelo.

Una estadística adimensional para evaluar el desempeño del modelo es la correlación entre los resultados del modelo y los valores observados de la variable de salida:

$$\rho_{y\hat{y}} = \frac{\sum_{t=1}^N (y(t) - \bar{y})(\hat{y}(t) - \bar{\hat{y}})}{\sqrt{Var(y)}\sqrt{Var(\hat{y})}} \quad (3.29)$$

donde $\bar{\hat{y}} = \frac{1}{N} \sum_{t=1}^N \hat{y}(t)$ es el promedio de los resultados del modelo.

El valor de correlación $\rho_{y\hat{y}} \leq 1$; cuanto más cerca de 1, mejor será la calidad del modelo. El resultado de la correlación también se puede evaluar en el gráfico de proyección entre el valor observado y predicho de la variable de salida.

Si la estructura seleccionada por el modelo representa adecuadamente la relación, se calcula una estimación de la varianza de los residuos como:

$$Var(e) = \hat{\sigma}^2 = \frac{1}{N-n} \sum_{t=1}^N e^2(t) = \frac{1}{N-n} \sum_{t=1}^N (y(t) - \hat{y}(t))^2 \quad (3.30)$$

donde n es el número de regresores en el modelo.

Cuando la distribución residual puede representarse adecuadamente mediante una distribución normal, es posible calcular un intervalo de confianza del resultado del modelo para un valor de entrada arbitrario $\hat{\mathbf{x}}_0$ del vector de regresores. La estimación de la varianza del modelo en el punto $\hat{\mathbf{x}}_0$ se calcula como [399]:

$$Var(\hat{y}_0) = \hat{\sigma}^2 \hat{\mathbf{x}}_0^T (\hat{\mathbf{X}}^T \hat{\mathbf{X}})^{-1} \hat{\mathbf{x}}_0 \quad (3.31)$$

donde $\hat{y}_0$ es el valor del modelo en el punto $\hat{\mathbf{x}}_0$ y $\hat{\sigma}^2$ es la estimación de la varianza residual calculada mediante la ecuación (3.30).

El intervalo que contiene el valor esperado de la relación real $y_r = E(y_0)$, donde y_0 es el valor observado en $\hat{\mathbf{x}}_0$, con una confianza estadística de $\xi\%$, se calcula como [399]:

$$\hat{y}_0 - t_{\xi,d} \sqrt{Var(\hat{y}_0)} \leq y_r \leq \hat{y}_0 + t_{\xi,d} \sqrt{Var(\hat{y}_0)} \quad (3.32)$$

donde $d = N - n$ es el número de grados de libertad y $t_{\xi,d}$ es el valor de la distribución t de Student. La distribución t puede aproximarse mediante la normal para $d \geq 30$, de modo que el intervalo de confianza con una significancia del 95 % puede aproximarse mediante:

$$\hat{y}_0 - 2.0\sqrt{\text{Var}(\hat{y}_0)} \leq y_r \leq \hat{y}_0 + 2.0\sqrt{\text{Var}(\hat{y}_0)} \quad (3.33)$$

La Figura 3.11 muestra el resultado del modelo lineal para dos de las tres variables de salida del problema *Contrete Slump*.¹⁰⁴ La Figura 3.11a muestra el resultado de la variable de salida y_3 , en la que el modelo se desempeña bien, y la Figura 3.11b, el resultado de la variable y_1 , en la que el modelo no se desempeña bien.






Figura 3.11: Resultados del modelo lineal del problema *Contrete Slump*: (a) y_3 ; (b) y_1 .

La Figura 3.12 muestra las estadísticas de validación correspondientes. Los estadísticos R^2 y R_{log}^2 se presentan restados de la unidad para que el mejor modelo siempre tenga el valor más bajo. Las barras rojas indican el resultado de la previsión realizada utilizando la media y sirven de referencia.

Comparar la distribución de residuos con la distribución normal $N(0, \hat{\sigma}^2)$ nos permite evaluar gráficamente la calidad del modelo. Los residuos con distribución normal indican que el ajuste realizado por el MMQ fue de buena calidad. La Figura 3.13 muestra los histogramas de los residuos y las gráficas de probabilidad normal de los resultados presentados en la Figura 3.12 y la Figura 3.11.




(a)




(b)


Figura 3.12: Resultados del modelo lineal del problema *Concrete Slump*: (a) y_3 ; (b) y_1 .




(a)



(b)



(c)



(d)

Figura 3.13: Distribución residual en el problema de Slump: (a) y (b) y_3 ; (c) y (d) y_1 .

Las estadísticas de validación calculadas directamente en el conjunto de entrenamiento no son útiles para elegir el mejor modelo, ya que un modelo con *overfitting* funciona bien en el conjunto de entrenamiento. La evaluación de la capacidad de predicción del modelo directamente sobre el conjunto de entrenamiento se puede evaluar utilizando estadísticas como los criterios de Akaike (AIC) [7] y Schwartz (BIC) [481], cuyos resultados no siempre corresponden al desempeño efectivo del modelo. En la práctica, se utiliza el procedimiento de validación cruzada para estimar la capacidad de predicción del modelo, como se describe a continuación.

3.3.2 Validación cruzada

La forma más sencilla de estimar el rendimiento del modelo en un conjunto de datos diferente al utilizado para el ajuste es dividir el conjunto de datos $\mathcal{T}$ en dos subconjuntos: el conjunto de entrenamiento $\mathcal{T}_1$ y el conjunto de prueba $\mathcal{T}_2$, respectivamente con registros N_1 y N_2 (normalmente $N_1 = 2N/3$ y $N_2 = N/3$). El conjunto de entrenamiento se utiliza para ajustar los parámetros y el conjunto de prueba se utiliza para estimar el rendimiento del modelo. Este enfoque supone que los dos conjuntos son muestras representativas del proceso, lo que puede no suceder si el conjunto de datos no es lo suficientemente grande. Además, las estadísticas de validación dependen mucho de la partición y una permutación de registros puede generar variaciones importantes en las estadísticas de validación.

La validación cruzada es un procedimiento simple que le permite evaluar adecuadamente el rendimiento del modelo en datos diferentes del conjunto de entrenamiento. En la validación cruzada, el conjunto de datos se divide en K subconjuntos y la validación se realiza en K ciclos: para cada ciclo, el modelo se ajusta utilizando $K - 1$ subconjuntos y se evalúa en el subconjunto restante. El procedimiento se describe mediante el Algoritmo 3.1, que se muestra esquemáticamente en la Figura 3.14.

Las estadísticas de validación se pueden calcular sobre el resultado de cada ciclo $\hat{\mathbf{Y}}_i$ y el resultado se presenta en términos de la media y la desviación estándar de los resultados en todos los ciclos. En conjuntos de datos pequeños, las estadísticas de validación no son significativas cuando se calculan sobre un subconjunto con registros N/K . Por lo tanto, es preferible concatenar los resultados de cada ciclo en un vector de resultados $\hat{\mathbf{Y}}$ que tenga el mismo número de registros que el conjunto de entrenamiento, y calcular las estadísticas.

validación de estos resultados. Tenga en cuenta que todos los elementos del vector $\hat{\mathbf{y}}$ se calcularon con registros diferentes a los utilizados para ajustar los modelos.

Algoritmo 3.1: validación cruzada de ciclo K

Entrada:	Conjunto de dados $\mathcal{T} = \{(\mathbf{x}(t), y(t)), t = 1 \dots N\}$ e número de ciclos K
Saída:	Vetor com resultados do modelo $\hat{\mathbf{Y}} = [\hat{y}(1), \dots, \hat{y}(N)]^T$
01	Início
02	Dividir o conjunto $\mathcal{T}$ em K subconjuntos $\mathcal{T}_i, i = 1, \dots, K$ aproximadamente iguais
03	Para $i = 1 \dots K$:
04	Definir o conjunto de treinamento $\mathcal{T}_{TR} = \bigcup_{j \neq i} \mathcal{T}_j$
05	Ajustar os parâmetros do modelo utilizando $\mathcal{T}_{TR}$
06	Estimar o resultado do modelo no conjunto $\mathcal{T}_{TE} = \mathcal{T}_i$
07	Armazenar o resultado no vetor $\hat{\mathbf{Y}}_i$
08	Fim Para
09	Concatenar resultados $\hat{\mathbf{Y}} = [\hat{\mathbf{Y}}_1^T, \dots, \hat{\mathbf{Y}}_K^T]^T$
10	Fim




Figura 3.14: Validación cruzada de ciclos K : Tr son los subconjuntos de entrenamiento, Te son el subconjunto de prueba.

Una elección importante en la validación cruzada es el número de ciclos K . En el caso particular de $K = N$, llamado *leave-one-out* (LOO), en cada ciclo se utilizan registros $N - 1$ para el entrenamiento y la estimación del modelo se realiza con un solo registro.

A pesar del costo computacional, la validación cruzada LOO es la mejor estimación del desempeño del modelo en datos diferentes del conjunto de datos disponible, pero es muy sensible a las muestras y puede tener resultados diferentes para diferentes muestras [238]. La opción más común es $K = 5$ o $K = 10$, número de registros [238][63].

3.4 Aplicaciones

3.4.1 Conjunto de datos *Pollution*

El conjunto de datos *Pollution*¹⁰⁵ es un problema que se utiliza frecuentemente como ejemplo de la aplicación de la regularización de Tikhonov [375]. El conjunto de datos, que relaciona la contaminación del aire con la mortalidad, contiene 60 registros con los valores de 15 variables observadas entre 1959 y 1961 en áreas metropolitanas de Estados Unidos. La variable de salida representa la mortalidad promedio en las áreas observadas en el mismo período.

La Figura 3.15 muestra la *box-plot* de las variables estandarizadas por las estimaciones *z-scores* y la matriz de correlación. Podemos observar la presencia de variables altamente correlacionadas (x_{12} y x_{13}).




Figura 3.15: Conjunto de datos *Pollution*: (a) diagrama de caja; (b) matriz de correlación.

La Figura 3.16 muestra la visualización del gráfico de proyección y *data image*. Podemos observar la existencia de algunas variables con distribuciones asimétricas (x_{12} a x_{13}) y la presencia de al menos un registro *outlier*, representado por la línea roja y la columna en *data image*.




Figura 3.16: Conjunto de datos *Pollution*: (a) gráficos de proyección; (b) *data image*.

La Figura 3.17 presenta el gráfico de proyección y *data image* del conjunto de datos después de eliminar el 12% (siete registros) de la base, como se describe en la sección 2.3.2. Podemos observar en la Figura 3.17b un patrón más homogéneo de similitud entre registros, incluso si un registro parece discrepar en relación con los demás.




Figura 3.17: Conjunto de datos *Pollution* sin *outliers*: (a) gráficos de proyección; (b) *data image*.

La Figura 3.18 presenta los resultados obtenidos en la validación cruzada del modelo lineal simple con los parámetros ajustados por MMQ sin regularización, sin eliminar *outliers*. Podemos observar que la distribución del residual no está bien ajustada por la distribución normal, lo que puede ser un indicio de que el ajuste realizado por el MMQ no fue el adecuado.




Figura 3.18: Resultados del MMQ en el conjunto de datos de contaminación. (a) Estadísticas de validación; (b) correlación real x predicha; (c) histograma de residuos; (d) probabilidad normal del residuo.

La Figura 3.19 muestra los resultados del modelo lineal aplicado al conjunto de datos sin *outliers*. Podemos observar que la gráfica de probabilidad normal del residual indica que el ajuste de datos sin *outliers* era de mejor calidad que el anterior. El coeficiente de correlación entre el valor real y el valor predicho también demuestra el mejor rendimiento del modelo en datos sin *outliers*.

Los valores de las estadísticas de validación se resumen en

Tabla 3.4. El resultado tampoco mejora con el uso de modelos polinomiales de orden superior. El modelo lineal regularizado con un parámetro calculado por la ecuación (3.19) ajustado a datos sin *outliers* no resultó en una variación importante en

estadística. Finalmente, utilizando el valor $\mu = 0.01$ para el parámetro de regularización sobre los datos sin *outliers*, obtenemos una pequeña mejora en las estadísticas.




Figura 3.19: Resultados del conjunto de datos *Pollution* sem *outliers*: (a) estadísticas de validación; (b) correlación real x predicha; (c) histograma de residuos; (d) probabilidad normal del residuo.

Tabla 3.4: Comparación de estadísticas de validación

Modelo	RMS	MAPE	R^2
MMQ	0.2537	22.98%	0.4107
MMQ s/ <i>outliers</i>	0.2078	18.93%	0.6039
MMQ Reg. c/ <i>outliers</i>	0.2316	20.52%	0.5091
MMQ Reg. s/ <i>outliers</i>	0.2094	18.99%	0.5976
MMQ Reg. $\mu = 0.01$	0.2057	18.51%	0.6118

En este ejemplo, la regularización y eliminación de *outliers* aumentan el rendimiento del modelo lineal, pero el efecto de las dos técnicas combinadas no produce un cambio significativo en el resultado. La eliminación de *outliers* mejora los resultados de las estadísticas de validación en este ejemplo, ya que la eliminación de *outliers* se realizó en todo el conjunto de datos, antes de la validación cruzada.

Es importante señalar que incluso para un ejemplo simple, el número de opciones de modelos diferentes puede aumentar considerablemente si se exploran todas las alternativas durante el proceso de validación del modelo.

3.4.2 Predicción del aumento de temperatura adiabático del hormigón.

El estudio presentado en esta sección fue realizado en colaboración con el Departamento de Ingeniería Civil de Eletrobrás Furnas [174][166]. El trabajo se realizó con base en registros de ensayos de aumento de temperatura adiabático realizados en el Laboratorio de Concretos de Furnas con probetas de muestras de concreto utilizadas en la construcción de las principales represas de las centrales hidroeléctricas brasileñas [18].

El principal componente del hormigón es el cemento, que al entrar en contacto con el agua produce una reacción exotérmica ganando así resistencia mecánica. La prueba adiabática de aumento de temperatura del hormigón es un experimento controlado que mide el aumento de temperatura producido por una muestra de hormigón. La temperatura final del ensayo es principalmente función de la formulación y concentración del cemento utilizado. Sin embargo, los otros componentes de la mezcla influyen en la forma de la función de aumento de temperatura, que no es lineal.

El conocimiento del calor generado por el hormigón es importante en la construcción de grandes estructuras, como presas, por ejemplo. Los esfuerzos generados por la expansión del material debido a la transferencia de calor pueden ser excesivos, pudiendo provocar grietas en la estructura ya construida durante el hormigonado de un nuevo bloque.

Los esfuerzos generados por la expansión del hormigón se pueden calcular a partir de modelos numéricos de la estructura. Sin embargo, predecir la cantidad de calor generado mediante modelos analíticos es complejo y los modelos existentes para predecir el calor generado

sólo pueden utilizarse en condiciones limitadas [174]. Los modelos de inteligencia computacional pueden usarse para predecir el calor generado por las mezclas utilizadas en la composición del concreto en Brasil [166].

Los datos para el estudio fueron proporcionados por el Laboratorio de Concreto de Furnas [174] y presentan 136 registros de 14 variables de entrada del problema, presentadas en la Tabla 3.5. Las variables son de dos tipos: cinco variables describen la composición química del cemento utilizado en el hormigón y nueve variables, los demás elementos utilizados en la mezcla y la temperatura inicial del ensayo.

Cada registro del conjunto de datos original presenta la evolución de la temperatura de la muestra. Los registros representan observaciones cada hora durante las primeras 24 horas y diariamente hasta el día 28, lo que da como resultado 52 registros de tiempo. Dada la gran cantidad de valores faltantes y la dificultad de modelar un problema con 52 variables de salida, el aumento de temperatura se aproximó mediante una función no lineal de tres parámetros, que se utilizan como variables de salida en el modelo de regresión [174].

Tabla 3.5: Descripción de las variables de entrada

Variável	Descrição	
x_1	Concentração de CaO	(%)
x_2	Concentração de Si_2O_2	(%)
x_3	Concentração de Al_2O_3	(%)
x_4	Concentração de Fe_2O_3	(%)
x_5	Concentração de SO_3	(%)
x_6	Consumo de cimento	(Kg/m ³)
x_7	Finura Blaine	(cm ² /g)
x_8	Adição de pozolana	(Kg/m ³)
x_9	Adição de escória	(Kg/m ³)
x_{10}	Adição de cinza volante	(Kg/m ³)
x_{11}	Consumo de água	(Kg/m ³)
x_{12}	Consumo de aditivos	(Kg/m ³)
x_{13}	Consumo de agregados	(Kg/m ³)
x_{14}	Temperatura inicial	(°C)

La Figura 3.20a muestra la matriz de distancias entre registros. La Figura 3.20b presenta la matriz de correlación de variables, donde se destacan las variables de composición del cemento, concentraciones de aditivos y variables de producción. Los aditivos que tienen mayores correlaciones con las variables de salida son: consumo de cemento (x_6), consumo de agua (x_{11}) y consumo de agregados (x_{13}).





Figura 3.20: Variables de entrada. (a) matriz de distancias; (b) matriz de correlación.


Los resultados del ajuste realizado por el MMQ simple y con regularización se muestran en la Tabla 3.6. El método con regularización presenta resultados ligeramente mejores, especialmente para la variable de salida y_3 . La variable de salida y_1 , que representa la temperatura final del concreto después de la hidratación, es la que presentó mejores resultados, considerando que su comportamiento está altamente correlacionado con el consumo de cemento, como se presenta en el ejemplo del análisis de correlación canónica en la sección 2.4.4. Los resultados del modelo MMQ con regularización se presentan en la Figura 3.21 e ilustran los comentarios anteriores.

Tabla 3.6: Comparación de estadísticas de validación


Saída	Modelo	RMS	MAPE	R^2
y_1	MMQ	0.1598	13.03%	0.7686
	MMQ Reg.	0.1573	13.07%	0.7756
y_2	MMQ	0.2178	16.21%	0.5700
	MMQ Reg.	0.2170	15.91%	0.5730
y_3	MMQ	0.2669	17.15%	0.3540
	MMQ Reg.	0.2591	16.45%	0.3911




(a)




(b)




(c)



(d)



(e)



(f)

Figura 3.21: Resultados: (a) y (b) y_1 ; (c) y (d) y_2 ; (e) y (f) y_3 .

Los resultados se obtuvieron con variables de salida estandarizadas y se utilizan para elegir la mejor estructura y/o enfoque de ajuste. Las predicciones del modelo deben

calcularse sobre la escala original de las variables. Además, las variables de salida representan los parámetros de una función de aproximación de elevación adiabática. La Figura 3.22 muestra los mejores y peores ajustes realizados por el modelo MMQ con regularización en relación a los valores de aumento de temperatura observados. La curva azul muestra la aproximación realizada con los parámetros utilizados como variable de salida y la curva roja muestra la aproximación realizada con los parámetros predichos por el modelo. Podemos ver que el peor ajuste está muy lejos de los valores observados. En la Figura 3.22, el tiempo se muestra en una escala logarítmica para facilitar la visualización del aumento de temperatura en las primeras horas de la reacción de hidratación.




Figura 3.22: Resultados: (a) mejor ajuste; (b) peor ajuste.

El modelo de aumento de temperatura adiabático es complejo y altamente no lineal [174]. Se obtuvieron resultados más precisos con modelos de redes neuronales [174] y sistemas *fuzzy* [166].

3.5 Comentarios finales

En este capítulo, presentamos los conceptos principales de la regresión lineal utilizando el método de mínimos cuadrados. Las principales características del proceso de modelado discutido en este capítulo están presentes en cualquier modelo predictivo.

El concepto más importante introducido en este capítulo es que el proceso de modelado es esencialmente de elección. El desarrollo del modelo sigue tres pasos principales: identificación de la estructura; ajuste y validación de parámetros. la elección de

La estructura es el paso más importante y el que mayor influencia tiene en el resultado. El ajuste de parámetros implica la solución de un problema de optimización, que, en regresión lineal, se realiza mediante el método de mínimos cuadrados (MMQ). Ante los problemas numéricos que surgen al modelar sistemas complejos con un número reducido de observaciones, las técnicas de regularización son útiles para garantizar la estabilidad de los resultados. La validación del modelo tiene como objetivo predecir su comportamiento sobre datos diferentes a los utilizados para el ajuste. El procedimiento de validación cruzada es simple y eficaz para obtener estadísticas de validación confiables.

Los resultados del problema *Pollution* muestran que eliminar *outliers* da como resultado un aumento en el rendimiento del modelo. Es importante señalar que este procedimiento debe usarse con precaución, ya que la eliminación de valores extremos da como resultado la exclusión de valores con potencial para los mayores errores en la regresión y, por lo tanto, una reducción en las estadísticas de validación. Sin embargo, la eliminación de *outliers* favorece que la distribución del residuo sea más simétrica y, en consecuencia, se confirman las hipótesis del MMQ, resultando en modelos de mejor calidad.

El problema del aumento de temperatura adiabático es complejo e ilustra cómo, en realidad, es importante realizar transformaciones en los datos existentes para construir el conjunto de datos. Por tanto, la capacidad del analista para encontrar alternativas es crucial para obtener un buen resultado.

En el próximo capítulo, los modelos lineales presentados en este capítulo se utilizarán para pronosticar series de tiempo y sistemas dinámicos lineales.