

5 CLASSIFICAÇÃO

O objetivo da classificação supervisionada, ou simplesmente classificação, é o desenvolvimento de um **classificador**, isto é, um modelo capaz de prever a classe correta de um registro a partir dos valores das variáveis de entrada. A classificação pode ser entendida como um problema de decisão em que uma classe é escolhida de acordo com os valores dos atributos do problema, que são as variáveis de entrada.

Um modelo de classificação divide de forma explícita ou implícita o espaço de variáveis de entrada em regiões que são associadas às classes. A fronteira entre as regiões é chamada de **superfície de decisão**. A predição da classe é feita a partir da verificação da região correspondente ao registro que se deseja classificar. Em problemas reais, registros com valores similares de variáveis de entrada podem pertencer a classes diferentes devido ao efeito de variáveis não observadas, ruído etc. Esse tipo de registro é tratado como erro de classificação e o modelo é ajustado para minimizar esse erro. Em alguns casos, chamados desbalanceados, as classes não têm o mesmo número de registros, o que pode levar o modelo a realizar previsões enviesadas.

Este capítulo apresenta o problema de classificação a partir da teoria bayesiana de decisão, que permite uma formalização matematicamente simples e bastante elucidativa sobre as principais características do problema. Em seguida, apresentamos o método de discriminante linear em que a classificação é tratada como um problema de predição análogo à regressão linear e o modelo de regressão logística, muito conhecido na literatura. Este capítulo também apresenta as estatísticas mais utilizadas para avaliação da qualidade do modelo de classificação e alguns exemplos de aplicação.

5 CLASIFICACIÓN

El objetivo de la clasificación supervisada, o simplemente clasificación, es el desarrollo de un clasificador, es decir, un modelo capaz de predecir la clase correcta de un registro en función de los valores de las variables de entrada. La clasificación puede entenderse como un problema de decisión en el que se elige una clase según los valores de los atributos del problema, que son las variables de entrada.

Un modelo de clasificación divide explícita o implícitamente el espacio de las variables de entrada en regiones asociadas con clases. La frontera entre regiones se llama superficie de decisión. La predicción de clase se realiza marcando la región correspondiente al registro que se desea clasificar. En problemas reales, registros con valores similares de variables de entrada pueden pertenecer a clases diferentes debido al efecto de variables no observadas, ruido, etc. Este tipo de registro se trata como un error de clasificación y el modelo se ajusta para minimizar este error. En algunos casos, llamados desequilibrados, las clases no tienen el mismo número de registros, lo que puede llevar al modelo a realizar predicciones sesgadas.

Este capítulo presenta el problema de clasificación basado en la teoría de decisión bayesiana, que permite una formalización matemáticamente simple y muy informativa de las principales características del problema. A continuación, presentamos el método discriminante lineal en el que la clasificación se trata como un problema de predicción análogo a la regresión lineal y al modelo de regresión logística, bien conocido en la literatura. Este capítulo también presenta las estadísticas más utilizadas para evaluar la calidad del modelo de clasificación y algunos ejemplos de aplicación.

5.1 Classificação Bayesiana

O teorema (ou regra) de Bayes¹¹⁵ foi criado pelo pastor Thomas Bayes e publicado em 1764, após sua morte, pelo amigo e filósofo Richard Price. O teorema de Bayes introduz a interpretação bayesiana da probabilidade como uma medida do “grau de conhecimento” sobre um evento em contraste com a interpretação baseada na frequência que mede a propensão de um evento ocorrer.

A apresentação do teorema de Bayes nesta seção é focada no problema de classificação e utiliza uma notação que evidencia os valores de probabilidade como função das variáveis do problema.

5.1.1 Decisão bayesiana

O problema de classificação é essencialmente uma decisão, uma vez que uma das classes deve ser escolhida em função dos valores das variáveis de entrada. A tomada de decisão no problema de classificação pode ser formalizada pelo **teorema de Bayes** [146][521], que relaciona o conhecimento prévio do problema na forma:

$$P(C_i|\mathbf{x}) = \frac{p(\mathbf{x}|C_i)P(C_i)}{p(\mathbf{x})} \quad (5.1)$$

onde $P(C_i|\mathbf{x})$ é a probabilidade de observar a classe C_i conhecendo a observação (evidência) dos valores das variáveis $\mathbf{x}$, chamada **probabilidade a posteriori**; $p(\mathbf{x}|C_i)$ representa a distribuição de probabilidades das variáveis $\mathbf{x}$ quando a classe observada é C_i , chamada de distribuição* de **probabilidade condicional**; e $P(C_i)$ é a probabilidade de ocorrência da classe C_i na ausência de qualquer observação, chamada de **probabilidade a priori**. O denominador $p(\mathbf{x}) = \sum_{i=1}^m p(\mathbf{x}|C_i)P(C_i)$ é a probabilidade de observar valores das variáveis $\mathbf{x}$, que funciona como um fator de padronização para que o resultado permaneça no intervalo $[0,1]$.

A equação (5.1) mostra de forma simples como a probabilidade de um evento é alterada pelo conhecimento de evidências relacionadas. O teorema de Bayes realiza uma “inversão” do conhecimento representado pela probabilidade condicional, o que mostra o raciocínio abdutivo¹¹⁶ do problema de classificação.

* Adotamos a notação com p minúsculo para representar uma função distribuição de probabilidades e P maiúsculo para representar um valor de probabilidades.

5.1 Clasificación bayesiana

El teorema (o regla) de Bayes¹¹⁵ fue creado por el pastor Thomas Bayes y publicado en 1764, después de su muerte, por su amigo y filósofo Richard Price. El teorema de Bayes introduce la interpretación bayesiana de la probabilidad como una medida del “grado de conocimiento” sobre un evento en contraste con la interpretación basada en la frecuencia que mide la propensión de un evento a ocurrir.

La presentación del teorema de Bayes en esta sección se centra en el problema de clasificación y utiliza una notación que resalta los valores de probabilidad en función de las variables del problema.

5.1.1 Decisión bayesiana

El problema de clasificación es esencialmente una decisión, ya que se debe elegir una de las clases en función de los valores de las variables de entrada. La toma de decisiones en el problema de clasificación puede formalizarse mediante el teorema de Bayes [146][521], que relaciona el conocimiento previo del problema en la forma:

$$P(C_i|\mathbf{x}) = \frac{p(\mathbf{x}|C_i)P(C_i)}{p(\mathbf{x})} \quad (5.1)$$

donde $P(C_i|\mathbf{x})$ es la probabilidad de observar la clase C_i conociendo la observación (evidencia) de los valores de las variables $\mathbf{x}$, llamada probabilidad **a posteriori**; $p(\mathbf{x}|C_i)$ representa la distribución de probabilidad de las variables $\mathbf{x}$ cuando la clase observada es C_i , llamada distribución de probabilidad condicional*; y $P(C_i)$ es la probabilidad de ocurrencia de la clase C_i en ausencia de cualquier observación, llamada probabilidad **a priori**. El denominador $p(\mathbf{x}) = \sum_{i=1}^m p(\mathbf{x}|C_i)P(C_i)$ es la probabilidad de observar valores de las variables $\mathbf{x}$, el cual funciona como factor de estandarización para que el resultado quede en el intervalo [0,1].

La ecuación (5.1) muestra de manera sencilla cómo cambia la probabilidad de un evento mediante el conocimiento de la evidencia relacionada. El teorema de Bayes realiza una “inversión” del conocimiento representado por la probabilidad condicional, lo que muestra el razonamiento abductivo¹¹⁶ del problema de clasificación.

* Adoptamos la notación con p minúsculo para representar una función distribución de probabilidades y P mayúsculo para representar un valor de probabilidades.

Considere, por exemplo, o raciocínio de um médico para o diagnóstico de uma doença a partir dos sintomas observados. O resultado do diagnóstico é determinado pela probabilidade *a posteriori*, isto é, o médico vai escolher, dentre as hipóteses plausíveis para o quadro observado, aquela que julgar mais provável. O conhecimento do médico é representado pela probabilidade condicional que estabelece a probabilidade de observação de um conjunto de sintomas $\mathbf{x}$ na presença de alguma doença C_i . A probabilidade *a priori* influi na decisão do médico, que, na observação dos mesmos sintomas, vai ter a tendência de decidir pela doença mais frequente.

A interpretação da equação (5.1) no contexto do problema de classificação fornece os elementos para o correto entendimento das características do problema e serve para o desenvolvimento de modelos de classificação.

Vamos considerar um exemplo simples, com apenas uma variável de entrada e duas classes. Inicialmente, vamos supor que as duas classes ocorrem com a mesma frequência, ou seja, têm a mesma probabilidade *a priori* $P(C_1) = P(C_2) = 0.5$. Vamos considerar também que as duas classes têm distribuição de probabilidade condicional normal $N(\mu, \sigma)$ de média μ e desvio padrão σ . Para o exemplo discutido a seguir, foram utilizadas as distribuições $p(x|C_1) = N(2.5, 2.5)$ e $p(x|C_2) = N(-1.5, 2.0)$.

A distribuição de probabilidade condicional para cada uma das classes e os valores de probabilidade *a posteriori* calculados pela regra de Bayes são mostrados na Figura 5.1. A função de probabilidade condicional $p(x|C_i)$ informa a probabilidade de observar um valor x sabendo-se que a classe é C_i . No exemplo, a média da distribuição $p(x|C_1)$ é maior que a média de $p(x|C_2)$.




Figura 5.1: Regra de Bayes: (a) probabilidade condicional; (b) probabilidade *a posteriori*.

Consideremos, por ejemplo, el razonamiento de un médico para diagnosticar una enfermedad basándose en los síntomas observados. El resultado del diagnóstico está determinado por la probabilidad *a posteriori*, es decir, el médico elegirá, entre las hipótesis plausibles para la condición observada, la que considere más probable. El conocimiento del médico está representado por la probabilidad condicional que establece la probabilidad de observar un conjunto de síntomas x ante la presencia de alguna enfermedad C_i . La probabilidad *a priori* influye en la decisión del médico, quien al observar los mismos síntomas tenderá a decidirse por la enfermedad más común.

La interpretación de la ecuación (5.1) en el contexto del problema de clasificación proporciona los elementos para la correcta comprensión de las características del problema y sirve para el desarrollo de modelos de clasificación.

Consideremos un ejemplo simple, con solo una variable de entrada y dos clases. Inicialmente, supongamos que las dos clases ocurren con la misma frecuencia, es decir, tienen la misma probabilidad *a priori* $P(C_1) = P(C_2) = 0.5$. Consideremos también que las dos clases tienen una distribución de probabilidad condicional normal $N(\mu, \sigma)$ de media μ y desviación estándar σ . Para el ejemplo que se analiza a continuación, se utilizaron las distribuciones $p(x|C_1) = N(2.5, 2.5)$ y $p(x|C_2) = N(-1.5, 2.0)$.

La distribución de probabilidad condicional para cada una de las clases y los valores de probabilidad *a posteriori* calculados mediante la regla de Bayes se muestran en la Figura 5.1. La función de probabilidad condicional $p(x|C_i)$ informa la probabilidad de observar un valor x sabiendo que la clase es C_i . En el ejemplo, la media de la distribución $p(x|C_1)$ es mayor que la media de $p(x|C_2)$.




Figura 5.1: Regla de Bayes: (a) probabilidad condicional; (b) probabilidad *a posteriori*.

No classificador bayesiano, o resultado do problema de classificação é obtido por uma **regra de decisão**, definida sobre os valores de probabilidade *a posteriori* das classes calculados pelo teorema de Bayes.

5.1.1.1 Decisão pelo mínimo erro de classificação

A decisão mais simples para a classificação bayesiana é feita pelo valor máximo de probabilidade *a posteriori*, que resulta na divisão do espaço das variáveis de entrada em duas regiões, cada uma associada a uma das classes, da seguinte forma:

$$\begin{aligned}\mathcal{R}_1 &= \{x \in \mathcal{R}, P(C_1|x) \geq P(C_2|x)\} \\ \mathcal{R}_2 &= \{x \in \mathcal{R}, P(C_2|x) > P(C_1|x)\}\end{aligned}\tag{5.2}$$

A Figura 5.1a mostra que valores da variável na região de sobreposição das funções de densidade condicional podem pertencer simultaneamente às duas classes com probabilidades diferentes. Dessa forma, considerando essa única variável, haverá um **erro de classificação**, calculado pela probabilidade de classificação incorreta como:

$$P(E) = \int_{\mathcal{R}_1} p(x|C_2)P(C_2)dx + \int_{\mathcal{R}_2} p(x|C_1)P(C_1)dx\tag{5.3}$$

O primeiro termo à direita da equação (5.3) representa o percentual de registros da classe C_2 que serão classificados como C_1 por estarem na região R_1 . Analogamente, o segundo termo representa o percentual de registros da classe C_1 que serão classificados como C_2 . O resultado da equação (5.3) para o exemplo da Figura 5.1 é mostrado na Figura 5.2, na qual as distribuições condicionais $p(x|C_i)$ são mostradas em linhas tracejadas e as distribuições $p(x|C_i)P(C_i)$, em linhas cheias.




Figura 5.2: Probabilidade de classificação incorreta.

En el clasificador bayesiano, el resultado del problema de clasificación se obtiene mediante una regla de decisión, definida sobre los valores de probabilidad *a posteriori* de las clases c calculadas por el teorema de Bayes.

5.1.1.1 Decisão pelo mínimo erro de classificação

La decisión más simple para la clasificación bayesiana se toma por el valor de probabilidad máxima *a posteriori*, que resulta en dividir el espacio de variables de entrada en dos regiones, cada una asociada con una de las clases, de la siguiente manera:

$$\begin{aligned}\mathcal{R}_1 &= \{x \in \mathcal{R}, P(C_1|x) \geq P(C_2|x)\} \\ \mathcal{R}_2 &= \{x \in \mathcal{R}, P(C_2|x) > P(C_1|x)\}\end{aligned}\tag{5.2}$$

La Figura 5.1a muestra que los valores de la variable en la región de superposición de las funciones de densidad condicionales pueden pertenecer simultáneamente a dos clases con diferentes probabilidades. Por tanto, considerando esta única variable, habrá un error de clasificación, calculado por la probabilidad de clasificación incorrecta como:

$$P(E) = \int_{\mathcal{R}_1} p(x|C_2)P(C_2)dx + \int_{\mathcal{R}_2} p(x|C_1)P(C_1)dx\tag{5.3}$$

El primer término a la derecha de la ecuación (5.3) representa el porcentaje de registros de la clase C_2 que se clasificarán como C_1 porque están en la región R_1 . De manera similar, el segundo término representa el porcentaje de registros de la clase C_1 que se clasificarán como C_2 . El resultado de la ecuación (5.3) para el ejemplo de la Figura 5.1 se muestra en la Figura 5.2, en la que las distribuciones condicionales $p(x|C_i)$ se muestran en líneas discontinuas y las distribuciones $p(x|C_i)P(C_i)$, en líneas continuas.




Figura 5.2: Probabilidad de clasificación errónea.

É fácil mostrar que a classificação realizada pelas regiões $\mathcal{R}_1$ e $\mathcal{R}_2$ definidas nas equações (5.2) minimizam o erro definido pela equação (5.3) [521]. Observando a Figura 5.2, uma regra de decisão diferente de (5.2) resulta num aumento da área correspondente à equação (5.3), ou seja, da probabilidade de erro de classificação.

As regiões associadas às classes pela regra de decisão (5.2) seriam as mesmas se a decisão fosse realizada diretamente sobre a função de distribuição condicional, pois, no exemplo da Figura 5.2, as classes são equiprováveis. Quando a frequência relativa das classes é diferente, esse resultado não é válido e a região da classe mais frequente aumenta em relação à da menos frequente para refletir o efeito das classes mais frequentes. A Figura 5.3 mostra o resultado da probabilidade *a posteriori* quando as probabilidades *a priori* são diferentes. Observe o deslocamento do ponto de decisão em relação ao ponto de interseção das distribuições de probabilidade condicionais.

No ponto de decisão, ou seja, no valor limite entre as regiões $\mathcal{R}_1$ e $\mathcal{R}_2$, os valores de probabilidade *a posteriori* são iguais e $p(x|C_1)P(C_1) = p(x|C_2)P(C_2)$. Dessa forma, podemos escrever:

$$\frac{p(x|C_1)}{p(x|C_2)} = \frac{P(C_2)}{P(C_1)} \quad (5.4)$$




Figura 5.3: Regra de Bayes: (a) $P(C_1) > P(C_2)$; (b) $P(C_2) > P(C_1)$.

A equação (5.4) mostra que, no caso de problemas desbalanceados, a superfície de decisão é obtida quando a probabilidade condicional da classe menos frequente supera a probabilidade condicional da mais frequente na mesma razão do cociente das probabilidades *a priori*.

Es fácil demostrar que la clasificación realizada por las regiones $\mathcal{R}_1$ y $\mathcal{R}_2$ definidas en las ecuaciones (5.2) minimiza el error definido por la ecuación (5.3) [521]. Observando la Figura 5.2, una regla de decisión diferente a (5.2) da como resultado un aumento en el área correspondiente a la ecuación (5.3), es decir, en la probabilidad de error de clasificación.

Las regiones asociadas con las clases por la regla de decisión (5.2) serían las mismas si la decisión se tomara directamente sobre la función de distribución condicional, ya que, en el ejemplo de la Figura 5.2, las clases son equiprobables. Cuando la frecuencia relativa de las clases es diferente, este resultado no es válido y la región de la clase más frecuente aumenta en relación con la de la menos frecuente para reflejar el efecto de las clases más frecuentes. La figura 5.3 muestra el resultado de la probabilidad *a posteriori* cuando las probabilidades *a priori* son diferentes. Observe el desplazamiento del punto de decisión con respecto al punto de intersección de las distribuciones de probabilidad condicional.

En el punto de decisión, es decir, en el valor límite entre las regiones $\mathcal{R}_1$ y $\mathcal{R}_2$, los valores de probabilidad *a posteriori* son iguales a $p(x|C_1)P(C_1) = p(x|C_2)P(C_2)$. De esta manera podemos escribir:

$$\frac{p(x|C_1)}{p(x|C_2)} = \frac{P(C_2)}{P(C_1)} \quad (5.4)$$




Figura 5.3: Regla de Bayes: (a) $P(C_1) > P(C_2)$; (b) $P(C_2) > P(C_1)$.

La ecuación (5.4) muestra que, en el caso de problemas desequilibrados, la superficie de decisión se obtiene cuando la probabilidad condicional de la clase menos frecuente excede la probabilidad condicional de la más frecuente por la misma razón del cociente de probabilidad *a priori*.

5.1.1.2 Decisão pelo mínimo risco condicional

No problema de duas classes em que uma é considerada positiva e outra, negativa, o resultado de um modelo de classificação pode ser apresentado pela **matriz de confusão** da Tabela 5.1. O resultado é chamado de verdadeiro positivo (VP) quando a classe positiva é predita corretamente pelo modelo ou verdadeiro negativo (VN) quando a classe negativa é predita corretamente. Os erros de classificação ocorrem de duas formas: se a classe positiva é predita quando a classe observada é negativa, o resultado é falso positivo (FP) (ou erro do Tipo I na nomenclatura de testes de hipóteses); o falso negativo (FN) (ou erro do Tipo II) acontece se a classe negativa é predita quando a classe observada é positiva.

Tabela 5.1: Matriz de confusão

	C_1 Predita	C_2 Predita
C_1 Real	VP	FN
C_2 Real	FP	VN

A matriz de confusão também será utilizada na seção 5.3 para avaliação de classificadores. Nesta seção, a matriz de confusão é utilizada para apresentar o conceito de risco de classificação incorreta.

Em muitas aplicações, principalmente quando as classes são desbalanceadas, o custo da classificação incorreta é diferente de acordo com o tipo de erro. Considere, por exemplo, um problema de diagnóstico médico a partir de um exame em que a classe positiva representa a presença de uma determinada doença grave. O erro FP consiste em alarmar o paciente desnecessariamente, enquanto o erro FN pode ter impacto importante no tratamento por atrasar a detecção da doença. Considerando que a probabilidade *a priori* de pacientes saudáveis é maior que a de pacientes portadores da doença, a classificação realizada de acordo com a regra (5.2) só detectaria a doença em casos nos quais as evidências fossem muito fortes.

O formalismo de decisão bayesiana permite representar o custo associado a cada decisão. O risco condicional associado a escolher uma classe C_i a partir da observação das evidências $\mathbf{x}$ é escrito como [146]:

5.1.1.2 Decisão pelo mínimo risco condicional

En el problema de dos clases en las que una se considera positiva y la otra negativa, el resultado de un modelo de clasificación se puede presentar mediante la matriz de confusión de la Tabla 5.1. El resultado se denomina verdadero positivo (VP) cuando el modelo predice correctamente la clase positiva o verdadero negativo (VN) cuando la clase negativa se predice correctamente. Los errores de clasificación ocurren de dos maneras: si se predice la clase positiva cuando la clase observada es negativa, el resultado es un falso positivo (FP) (o error de Tipo I en la nomenclatura de las pruebas de hipótesis); El falso negativo (FN) (o error de tipo II) ocurre si la clase negativa se predice cuando la clase observada es positiva.

Tabla 5.1: Matriz de confusión

	C_1 Predita	C_2 Predita
C_1 Real	VP	FN
C_2 Real	FP	VN

La matriz de confusión también se utilizará en la sección 5.3 para evaluar clasificadores. En esta sección se utiliza la matriz de confusión para presentar el concepto de riesgo de clasificación errónea.

En muchas aplicaciones, especialmente cuando las clases están desequilibradas, el costo de una clasificación errónea es diferente según el tipo de error. Consideremos, por ejemplo, un problema de diagnóstico médico basado en un examen en el que la clase positiva representa la presencia de una determinada enfermedad grave. El error FP consiste en alarmar innecesariamente al paciente, mientras que el error FN puede tener un impacto importante en el tratamiento al retrasar la detección de la enfermedad. Considerando que la probabilidad *a priori* de los pacientes sanos es mayor que la de los pacientes con la enfermedad, la clasificación realizada según la regla (5.2) sólo detectaría la enfermedad en los casos en los que la evidencia sea muy fuerte.

El formalismo de decisión bayesiano permite representar el costo asociado a cada decisión. El riesgo condicional asociado con la elección de una clase C_i a partir de la observación de la evidencia $\mathbf{x}$ se escribe como [146]:

$$R(C_i|\mathbf{x}) = \sum_{j=1}^m \lambda_{ij}P(C_j|\mathbf{x}) \quad (5.5)$$

onde λ_{ij} é o custo associado a escolher a classe C_i quando a classe correta é C_j .

No caso do problema de duas classes considerado anteriormente, o risco condicional associado a cada classe é calculado como:

$$\begin{aligned} R(C_1|x) &= \lambda_{11}P(C_1|x) + \lambda_{12}P(C_2|x) \\ R(C_2|x) &= \lambda_{21}P(C_1|x) + \lambda_{22}P(C_2|x) \end{aligned} \quad (5.6)$$

A decisão é calculada pelo menor risco condicional, que não é uma probabilidade. Considerando o risco de classificação correta nulo, $\lambda_{11} = \lambda_{22} = 0$, as regiões associadas às classes são calculadas como:

$$\begin{aligned} \mathcal{R}_1 &= \{x \in \mathcal{R}, \lambda_{21}P(C_1|x) \geq \lambda_{12}P(C_2|x)\} \\ \mathcal{R}_2 &= \{x \in \mathcal{R}, \lambda_{12}P(C_2|x) > \lambda_{21}P(C_1|x)\} \end{aligned} \quad (5.7)$$

A Figura 5.4 mostra a diferença da decisão de classificação calculada a partir do valor das probabilidades *a posteriori* (cf. equações (5.2)) ou pelo risco condicional (cf. equações (5.7)). No exemplo, as classes foram consideradas equiprováveis para facilitar a interpretação. Na Figura 5.4, as linhas tracejadas representam a distribuição de valores de probabilidade *a posteriori* e as linhas cheias, os valores de risco de classificação incorreta calculado pela equação (5.6).




Figura 5.4: Decisão pelo risco de classificação: (a) $\lambda_{12} > \lambda_{21}$; (b) $\lambda_{21} > \lambda_{12}$.

$$R(C_i|\mathbf{x}) = \sum_{j=1}^m \lambda_{ij}P(C_j|\mathbf{x}) \quad (5.5)$$

donde λ_{ij} es el costo asociado con la elección de la clase C_i cuando la clase correcta es C_j .

En el caso del problema de dos clases considerado anteriormente, el riesgo condicional asociado con cada clase se calcula como:

$$\begin{aligned} R(C_1|x) &= \lambda_{11}P(C_1|x) + \lambda_{12}P(C_2|x) \\ R(C_2|x) &= \lambda_{21}P(C_1|x) + \lambda_{22}P(C_2|x) \end{aligned} \quad (5.6)$$

La decisión se calcula según el riesgo condicional más bajo, que no es una probabilidad. Considerando el riesgo nulo de clasificación correcta, $\lambda_{11} = \lambda_{22} = 0$, las regiones asociadas a las clases se calculan como:

$$\begin{aligned} \mathcal{R}_1 &= \{x \in \mathcal{R}, \lambda_{21}P(C_1|x) \geq \lambda_{12}P(C_2|x)\} \\ \mathcal{R}_2 &= \{x \in \mathcal{R}, \lambda_{12}P(C_2|x) > \lambda_{21}P(C_1|x)\} \end{aligned} \quad (5.7)$$

La Figura 5.4 muestra la diferencia en la decisión de clasificación calculada a partir del valor de las probabilidades *a posteriori* (ver ecuaciones (5.2)) o del riesgo condicional (ver ecuaciones (5.7)). En el ejemplo, las clases se consideraron equiprobables para facilitar la interpretación. En la Figura 5.4, las líneas discontinuas representan la distribución de los valores de probabilidad *a posteriori* y las líneas continuas representan los valores de riesgo de clasificación incorrecta calculados mediante la ecuación (5.6).




Figura 5.4: Decisión por clasificación de riesgo: (a) $\lambda_{12} > \lambda_{21}$; (b) $\lambda_{21} > \lambda_{12}$.

Quando o custo de classificação incorreta $\lambda_{12} > \lambda_{21}$, ou seja, o erro em favor da classe C_1 é mais grave, a região $\mathcal{R}_1$ calculada pela minimização do risco condicional (cf. equações (5.7)) é menor que a correspondente calculada pela minimização do erro de classificação (cf. equações (5.2)). Dessa forma, o limite de decisão se desloca visando reduzir a região associada à classe com maior custo de classificação incorreta. Caso contrário, quando $\lambda_{21} > \lambda_{12}$, o limite de decisão se desloca em favor da classe C_1 uma vez que o custo de classificação incorreta dessa classe é menor.

O erro de classificação calculado pela equação (5.3) é maior caso a decisão seja realizada pelo risco condicional, uma vez que a decisão pela probabilidade *a posteriori* é a que minimiza o erro de classificação. Entretanto, embora globalmente o erro seja maior, ele será menor na classe de maior custo de classificação incorreta.

A aplicação da decisão pelo mínimo risco condicional depende de estimativas dos valores de custo λ_{ij} . Em problemas em que o custo pode ser quantificado, os parâmetros são definidos facilmente. Entretanto, na maioria dos casos, os custos não podem ser especificados diretamente e os valores são estimados de forma *ad hoc*. Em problemas desbalanceados, os custos de classificação incorreta podem ser calculados para compensar o efeito do desbalanceamento.

O formalismo da classificação bayesiana é aplicado diretamente sobre dois modelos de classificação que são apresentados a seguir.

5.1.2 Classificador bayesiano simples

No problema de classificação, o conjunto de dados $\mathcal{T} = \{(\mathbf{x}(t), y(t)), t = 1 \dots N\}$, onde cada registro t é formado por pares ordenados $(\mathbf{x}(t), y(t))$, sendo $\mathbf{x}(t) \in \mathcal{R}^p$ o vetor das variáveis de entrada e a variável de saída $y(t) \in \mathcal{N}$, em que valor $y(t) = j$ associa o registro t à classe $C_j, j = 1, \dots, m$. É importante observar que os índices não representam uma relação de ordem entre as classes, apenas facilitam a representação das classes de forma simbólica.

O classificador bayesiano utiliza diretamente a regra de Bayes (5.1) para o cálculo da probabilidade *a posteriori* e realiza a decisão por uma das formas apresentadas anteriormente, geralmente pelo mínimo erro de classificação. No classificador **bayesiano simples** ou ingênuo (*naïf*), a distribuição de probabilidade condicional dos registros

Cuando el costo de una clasificación incorrecta $\lambda_{12} > \lambda_{21}$, es decir, el error a favor de la clase C_1 es más grave, la región $\mathcal{R}_1$ calculada minimizando el riesgo condicional (cf. ecuaciones (5.7)) es menor que la correspondiente calculada minimizando el error de clasificación (cf. ecuaciones (5.2)). De esta manera, el límite de decisión se desplaza para reducir la región asociada con la clase con el mayor costo de clasificación incorrecta. De lo contrario, cuando $\lambda_{21} > \lambda_{12}$, el límite de decisión se desplaza a favor de la clase C_1 ya que el costo de clasificar erróneamente esta clase es menor.

El error de clasificación calculado por la ecuación (5.3) es mayor si la decisión se toma en base al riesgo condicional, ya que la decisión basada en la probabilidad *a posteriori* es la que minimiza el error de clasificación. Sin embargo, aunque el error es mayor en general, será menor en la clase con el mayor coste de clasificación errónea.

La aplicación de la decisión de riesgo mínimo condicional depende de estimaciones de los valores de costos λ_{ij} . En problemas donde el costo se puede cuantificar, los parámetros se definen fácilmente. Sin embargo, en la mayoría de los casos, los costos no se pueden especificar directamente y los valores se estiman de forma *ad hoc*. En problemas de desequilibrio, los costos de clasificación errónea se pueden calcular para compensar el efecto del desequilibrio.

El formalismo de clasificación bayesiano se aplica directamente a dos modelos de clasificación que se presentan a continuación.

5.1.2 Clasificador bayesiano simple

En el problema de clasificación se utiliza el conjunto de datos $\mathcal{T} = \{(\mathbf{x}(t), y(t)), t = 1 \dots N\}$, donde cada registro t está formado por pares ordenados $(\mathbf{x}(t), y(t))$, siendo $\mathbf{x}(t) \in \mathcal{R}^p$ el vector de variables de entrada y la variable de salida $y(t) \in \mathcal{N}$, donde el valor $y(t) = j$ asocia el registro t con la clase $C_j, j = 1, \dots, m$. Es importante señalar que los índices no representan una relación de orden entre clases, solo facilitan la representación de clases de forma simbólica.

El clasificador bayesiano utiliza directamente la regla de Bayes (5.1) para calcular la probabilidad *a posteriori* y toma la decisión de una de las formas presentadas anteriormente, generalmente utilizando el error de clasificación mínimo. En el clasificador bayesiano simple o ingenuo (*naïf*), la distribución de probabilidad condicional de los registros

do conjunto de treinamento é calculada, para cada classe, por uma estimativa que considera as variáveis de entrada independentes. Dessa forma, o classificador bayesiano simples não leva em consideração a covariância entre as variáveis e a distribuição de probabilidade condicional conjunta para cada classe é calculada como:

$$p(\mathbf{x}(t)|C_j) = \prod_{i=1}^p p(x_i(t)|C_j), \quad j = 1, \dots, m \quad (5.8)$$

No modelo mais comum, a probabilidade condicional de cada variável é estimada como uma distribuição normal monovariável $p(x_i(t)|C_j) \approx N(\hat{\mu}_{ij}, \hat{\sigma}_{ij}^2)$. Os parâmetros de média $\hat{\mu}_{ij}$ e de variância $\hat{\sigma}_{ij}^2$ são estimados no conjunto de treinamento como a média e a variância da variável $x_i(t)$ nos registros da classe C_j . Há variantes que utilizam outros modelos de distribuição condicional.¹¹⁷

A hipótese de independência entre as variáveis de entrada reduz consideravelmente o número de parâmetros a serem ajustados pelo classificador. A estimativa da matriz de covariâncias da distribuição normal multivariada (cf. equação (2.6)) requer $p(p + 1)/2$ parâmetros para cada classe, o que resulta num total de $p + p(p + 1)/2$ parâmetros, incluindo as médias. No classificador bayesiano simples, a hipótese de independência reduz o número de parâmetros a serem ajustado a apenas $2p$ para cada classe.

O ajuste de parâmetros do classificador bayesiano simples é muito eficiente. Para cada classe, para cada variável, calcula-se a média $\hat{\mu}_{ij}$ e a variância $\hat{\sigma}_{ij}^2$ estimadas – se a variável for numérica – ou então diretamente a frequência de cada valor nominal – quando a variável for categórica. A probabilidade *a priori* também é calculada diretamente pela frequência da classe.

Na avaliação, o resultado do classificador bayesiano simples é a probabilidade *a posteriori*, calculada diretamente pelo teorema de Bayes (cf. equação (5.1)), em que a probabilidade condicional conjunta é calculada pela equação (5.8). A decisão de classificação pode ser feita pela regra de mínimo erro de classificação ou de mínimo risco.

A Figura 5.5a mostra um exemplo sintético de um problema linearmente separável em $p = 2$ dimensões. A Figura 5.5b apresenta a superfície de decisão e as regiões associadas a cada classe pelo valor máximo de probabilidade *a posteriori*. As Figuras 5.5c e 5.5d mostram, respectivamente, as distribuições de probabilidade condicional normal ajustadas para cada uma das variáveis. Podemos perceber que, apesar de existir correlação

del conjunto de entrenamiento se calcula, para cada clase, mediante una estimación que considera las variables de entrada independientes. Así, el clasificador bayesiano simple no tiene en cuenta la covarianza entre variables y la distribución de probabilidad condicional conjunta para cada clase se calcula como:

$$p(\mathbf{x}(t)|C_j) = \prod_{i=1}^p p(x_i(t)|C_j), \quad j = 1, \dots, m \quad (5.8)$$

En el modelo más común, la probabilidad condicional de cada variable se estima como una distribución normal monovariante $p(x_i(t)|C_j) \approx N(\hat{\mu}_{ij}, \hat{\sigma}_{ij}^2)$. Los parámetros media $\hat{\mu}_{ij}$ y varianza $\hat{\sigma}_{ij}^2$ se estiman en el conjunto de entrenamiento como la media y varianza de la variable $x_i(t)$ en los registros de clase C_j . Hay variantes que utilizan otros modelos de distribución condicional.¹¹⁷

El supuesto de independencia entre las variables de entrada reduce considerablemente el número de parámetros que debe ajustar el clasificador. La estimación de la matriz de covarianza de la distribución normal multivariada (cf. ecuación (2.6)) requiere $p(p + 1)/2$ parámetros para cada clase, lo que da como resultado un total de $p + p(p + 1)/2$ parámetros, incluidas las medias. En el clasificador bayesiano simple, el supuesto de independencia reduce el número de parámetros que se ajustarán a solo $2p$ para cada clase.

El ajuste de parámetros del clasificador bayesiano simple es muy eficiente. Para cada clase, para cada variable, se calcula la media estimada $\hat{\mu}_{ij}$ y la varianza $\hat{\sigma}_{ij}^2$ -si la variable es numérica- o directamente la frecuencia de cada valor nominal -cuando la variable es categórica-. La probabilidad *a priori* también se calcula directamente a partir de la frecuencia de clase.

En la evaluación, el resultado del clasificador bayesiano simple es la probabilidad *a posteriori*, calculada directamente mediante el teorema de Bayes (cf. ecuación (5.1)), donde la probabilidad condicional conjunta se calcula mediante la ecuación (5.8). La decisión de clasificación se puede tomar utilizando la regla de mínimo error de clasificación o riesgo mínimo.

La Figura 5.5a muestra un ejemplo sintético de un problema linealmente separable en $p = 2$ dimensiones. La Figura 5.5b presenta la superficie de decisión y las regiones asociadas con cada clase por el valor de probabilidad máxima *a posteriori*. Las Figuras 5.5c y 5.5d muestran, respectivamente, las distribuciones de probabilidad condicional normal ajustadas para cada una de las variables. Podemos ver que, a pesar de existir una correlación

entre as variáveis, a diferença das médias das distribuições de probabilidade condicional permite ajustar um classificador capaz de gerar uma superfície de decisão eficiente.




Figura 5.5: Problema linearmente separável: (a) Conjunto de treinamento; (b) superfície de decisão; (c) distribuição $p(x_1|C_j)$; (d) distribuição $p(x_2|C_j)$.

A “economia” de parâmetros e a simplicidade do classificador bayesiano simples têm efeitos no seu desempenho. A Figura 5.6a mostra um exemplo um pouco mais complexo, no qual as classes não podem ser separadas por uma superfície linear – são, assim, chamadas de não separáveis linearmente. Nesse caso, a superfície de decisão gerada pelo classificador bayesiano simples, mostrada na Figura 5.6b, não permite separar as duas classes. O resultado pode ser entendido observando-se as distribuições condicionais nas Figura 5.6c e 5.6d, que mostram que a projeção dos dados em cada variável resulta em valores similares das médias e das variâncias das classes e, portanto, a distribuição conjunta das duas classes é muito parecida, de forma que a superfície de decisão gerada não é eficiente para separá-las.

entre las variables, la diferencia en las medias de las distribuciones de probabilidad condicional permite ajustar un clasificador capaz de generar una superficie de decisión eficiente.




Figura 5.5: Problema linealmente separable: (a) Conjunto de entrenamiento; (b) superficie de decisión; (c) distribución $p(x_1|C_j)$; (d) distribución $p(x_2|C_j)$.

La “economía” de parámetros y la simplicidad del clasificador bayesiano simple tienen efectos en su desempeño. La Figura 5.6a muestra un ejemplo ligeramente más complejo, en el que las clases no pueden separarse mediante una superficie lineal; por lo tanto, se las denomina separables no linealmente. En este caso, la superficie de decisión generada por el clasificador bayesiano simple, que se muestra en la Figura 5.6b, no permite separar las dos clases. El resultado se puede entender observando las distribuciones condicionales de las Figuras 5.6c y 5.6d, que muestran que la proyección de los datos en cada variable da como resultado valores similares de las medias y varianzas de las clases y, por lo tanto, la distribución conjunta de las dos clases es muy similar, de modo que la superficie de decisión generada no es eficiente para separarlas.




Figura 5.6: Problema não separável linearmente: (a) conjunto de treinamento; (b) superfície de decisão; (c) distribuição $p(x_1|C_j)$; (d) distribuição $p(x_2|C_j)$.

A distribuição normal não é adequada para a representação da distribuição dos dados de cada classe no exemplo da Figura 5.6a. Entretanto, o problema principal é que o classificador bayesiano simples não é capaz de capturar a correlação existente entre as variáveis no conjunto de dados de cada classe. A Figura 5.7a mostra o mesmo conjunto de dados da Figura 5.6a após a transformação realizada pela análise de componentes principais (ACP), que elimina a correlação entre as variáveis. Nesse caso, o classificador bayesiano é capaz de separar as classes (cf. Figura 5.7b), mesmo que a distribuição normal não seja a melhor representação da distribuição das classes, como pode ser observado na Figura 5.7c e Figura 5.7d. Nesse caso, a diferença de variâncias das distribuições de probabilidade condicional permite gerar uma superfície de decisão correta.




Figura 5.6: Problema separable no linealmente: (a) conjunto de entrenamiento;
 (b) superficie de decisi3n; (c) distribuci3n $p(x_1|C_j)$; (d) distribuci3n $p(x_2|C_j)$.

La distribuci3n normal no es adecuada para representar la distribuci3n de datos para cada clase en el ejemplo de la Figura 5.6a. Sin embargo, el principal problema es que el clasificador bayesiano simple no es capaz de capturar la correlaci3n entre las variables en el conjunto de datos de cada clase. La Figura 5.7a muestra el mismo conjunto de datos que la Figura 5.6a despu3s de la transformaci3n realizada por an3lisis de componentes principales (PCA), que elimina la correlaci3n entre las variables. En este caso, el clasificador bayesiano es capaz de separar las clases (cf. Figura 5.7b), incluso si la distribuci3n normal no es la mejor representaci3n de la distribuci3n de clases, como se puede ver en las Figuras 5.7c y 5.7d. En este caso, la diferencia de varianzas de las distribuciones de probabilidad condicional permite generar una superficie de decisi3n correcta.




Figura 5.7: Problema transformado pela ACP: (a) conjunto de treinamento; (b) superfície de decisão; (c) distribuição $p(x_1|C_j)$; (d) distribuição $p(x_2|C_j)$.

A utilização da ACP para eliminar a correlação dos dados nem sempre produz bons resultados, mas é um recurso que pode ser empregado na busca pelo melhor modelo de classificação. Na seção 5.4.1, os resultados do classificador bayesiano simples são comparados aos resultados de outros classificadores apresentados neste capítulo.

O classificador bayesiano simples é um classificador computacionalmente eficiente, que pode ser aplicado em problemas de grande dimensionalidade e permite combinar facilmente variáveis numéricas e categóricas. Um classificador bayesiano simples pode facilmente acomodar valores ausentes na avaliação, o que é um problema em diversos outros tipos de classificadores. O algoritmo básico, com algumas variações, pode ser encontrado em praticamente todos os *softwares* de ciência de dados. Apesar do seu desempenho regular, o classificador bayesiano tem muitas aplicações em ciência de dados [289], tendo se mostrado útil na classificação de documentos, em filtros de *spam*




Figura 5.7: Problema transformado por PCA: (a) conjunto de entrenamiento; (b) superficie de decisión; (c) distribución $p(x_1|C_j)$; (d) distribución $p(x_2|C_j)$.

Usar PCA para eliminar la correlación de datos no siempre produce buenos resultados, pero es un recurso que puede usarse en la búsqueda del mejor modelo de clasificación. En la sección 5.4.1, los resultados del clasificador bayesiano simple se comparan con los resultados de otros clasificadores presentados en este capítulo.

El clasificador bayesiano simple es un clasificador computacionalmente eficiente que se puede aplicar a problemas de grandes dimensiones y permite combinar fácilmente variables numéricas y categóricas. Un clasificador bayesiano simple puede acomodar fácilmente los valores faltantes en la evaluación, lo cual es un problema en muchos otros tipos de clasificadores. El algoritmo básico, con algunas variaciones, se puede encontrar prácticamente en todas las ciencias de datos *softwares*. A pesar de su rendimiento regular, el clasificador bayesiano tiene muchas aplicaciones en ciencia de datos [289], habiendo demostrado ser útil en la clasificación de documentos, en *spam*

[115] e na análise de sentimentos [348][427]. O bom desempenho do classificador bayesiano simples também o qualifica para utilização em *ensembles* [325], que combinam os resultados de vários modelos simples para melhorar o desempenho do classificador.

Em conjuntos de dados com registros suficientes para estimação das distribuições de probabilidade condicionais conjuntas, é possível utilizá-la na síntese do classificador, como descrito a seguir.

5.1.3 Classificador bayesiano quadrático

Um classificador realiza a predição da classe de um novo registro pela sua localização em relação às regiões associadas às classes. No caso de um problema com m classes, o resultado do classificador vai particionar o domínio das variáveis de entrada em m regiões. É possível generalizar regras de decisão como (5.2) e (5.7) pela definição de **funções discriminantes** em problemas de múltiplas classes. A classificação é feita pelo valor máximo da função discriminante como:

$$\mathbf{x}(t) \in C_i \rightarrow g_i(\mathbf{x}(t)) > g_j(\mathbf{x}(t)), \quad j = 1, \dots, m \quad (5.9)$$

No classificador bayesiano, a função discriminante pode ser calculada diretamente como $g_i(\mathbf{x}(t)) = P(C_i|\mathbf{x}(t))$ no caso de minimização da probabilidade de classificação incorreta ou como $g_i(\mathbf{x}(t)) = -R(C_i|\mathbf{x}(t))$ no caso de minimização do risco condicional, onde $R(C_i|\mathbf{x}(t))$ é definido em (5.5) e o sinal negativo é para manter coerência com a equação (5.9), uma vez que a decisão é tomada pelo menor risco de classificação. A escolha da função discriminante não é única e qualquer função monótona crescente de uma função discriminante $f(g_i(\mathbf{x}(t)))$ é também uma função discriminante.

A questão fundamental para a síntese de um classificador bayesiano é a escolha da função de distribuição de probabilidade condicional. No classificador bayesiano simples, a hipótese de independência resulta num classificador computacionalmente eficiente, mas de precisão apenas regular. O desempenho do classificador pode melhorar bastante se a distribuição condicional for mais bem estimada. Há métodos estatísticos, paramétricos e não paramétricos, para a estimativa de uma função de distribuição condicional [553]. A abordagem clássica é utilizar a distribuição normal multivariada como uma aproximação da distribuição condicional.

[115] y en análisis de sentimiento [348][427]. El buen desempeño del clasificador baseyiano o simple también lo califica para su uso en *ensembles* [325], que combina los resultados de varios modelos simples para mejorar el desempeño del clasificador.

En conjuntos de datos con registros suficientes para estimar distribuciones de probabilidad condicional conjuntas, es posible utilizarlos en la síntesis de clasificadores, como se describe a continuación.

5.1.3 Clasificador bayesiano cuadrático

Un clasificador predice la clase de un nuevo registro en función de su ubicación en relación con las regiones asociadas con las clases. En el caso de un problema con las clases m , el resultado del clasificador dividirá el dominio de las variables de entrada en regiones m . Es posible generalizar reglas de decisión como (5.2) y (5.7) definiendo funciones discriminantes en problemas de clases múltiples. La clasificación se realiza por el valor máximo de la función discriminante como:

$$\mathbf{x}(t) \in C_i \rightarrow g_i(\mathbf{x}(t)) > g_j(\mathbf{x}(t)), \quad j = 1, \dots, m \quad (5.9)$$

En el clasificador bayesiano la función discriminante se puede calcular directamente como $g_i(\mathbf{x}(t)) = P(C_i|\mathbf{x}(t))$ en el caso de minimizar la probabilidad de clasificación incorrecta o como $g_i(\mathbf{x}(t)) = -R(C_i|\mathbf{x}(t))$ en el caso de minimizar el riesgo condicional, donde $R(C_i|\mathbf{x}(t))$ se define en (5.5) y el signo negativo es para mantener coherencia con la ecuación (5.9), ya que la decisión se toma en base al menor riesgo de clasificación. La elección de la función discriminante no es única y cualquier función monótonamente creciente de una función discriminante $f(g_i(\mathbf{x}(t)))$ también es una función discriminante.

La cuestión fundamental para la síntesis de un clasificador bayesiano es la elección de la función de distribución de probabilidad condicional. En el clasificador bayesiano simple, el supuesto de independencia da como resultado un clasificador computacionalmente eficiente, pero con una precisión regular. El rendimiento del clasificador puede mejorar significativamente si se estima mejor la distribución condicional. Existen métodos estadísticos, paramétricos y no paramétricos, para estimar una función de distribución condicional [553]. El enfoque clásico consiste en utilizar la distribución normal multivariada como una aproximación de la distribución condicional.

A hipótese de a probabilidade condicional ser uma distribuição normal permite a definição do classificador **bayesiano quadrático** [146][405], cuja função discriminante para a decisão pela minimização do erro de classificação é calculada como:

$$g_i(\mathbf{x}(t)) = \ln P(C_i|\mathbf{x}(t)) = \ln p(\mathbf{x}(t)|C_i) + \ln P(C_i), \quad i = 1, \dots, m \quad (5.10)$$

onde $p(\mathbf{x}(t)|C_i) = N(\hat{\boldsymbol{\mu}}_i, \hat{\boldsymbol{\Sigma}}_i)$ é a distribuição normal multivariada de médias $\hat{\boldsymbol{\mu}}_i$ e matriz de covariâncias $\hat{\boldsymbol{\Sigma}}_i$ estimadas a partir dos registros da classe C_i .

Substituindo a expressão da distribuição normal multivariada na equação (5.10):

$$g_i(\mathbf{x}(t)) = -\frac{1}{2}(\mathbf{x}(t) - \hat{\boldsymbol{\mu}}_i)\hat{\boldsymbol{\Sigma}}_i^{-1}(\mathbf{x}(t) - \hat{\boldsymbol{\mu}}_i)^T - \frac{1}{2}\ln 2\pi - \frac{1}{2}\ln|\hat{\boldsymbol{\Sigma}}_i| + \ln P(C_i) \quad (5.11)$$

O termo $-\frac{1}{2}\ln 2\pi$ é o mesmo para todas as classes e, por isso, não exerce influência na função discriminante, podendo ser eliminado.

A expressão da função discriminante calculada pela equação (5.11) é dominada por um termo quadrático e, por isso, o classificador bayesiano com distribuições normais multivariadas é chamado de classificador bayesiano quadrático. A Figura 5.8 mostra dois exemplos sintéticos de classes geradas por variáveis de distribuição normal e a superfície de decisão calculada pela função discriminante (5.11).




Figura 5.8: Exemplos de superfícies de decisão quadráticas.

O resultado do classificador bayesiano quadrático no conjunto de dados da Figura 5.6 é mostrado na Figura 5.9, na qual podemos observar que função discriminante é eficiente para a separação das classes.

La hipótesis de que la probabilidad condicional es una distribución normal permite definir el clasificador bayesiano cuadrático [146][405], cuya función discriminante para la decisión de minimizar el error de clasificación se calcula como:

$$g_i(\mathbf{x}(t)) = \ln P(C_i|\mathbf{x}(t)) = \ln p(\mathbf{x}(t)|C_i) + \ln P(C_i), \quad i = 1, \dots, m \quad (5.10)$$

donde $p(\mathbf{x}(t)|C_i) = N(\hat{\boldsymbol{\mu}}_i, \hat{\boldsymbol{\Sigma}}_i)$ es la distribución normal multivariada de las medias $\hat{\boldsymbol{\mu}}_i$ y la matriz de covarianza $\hat{\boldsymbol{\Sigma}}_i$ estimada a partir de los registros de clase C_i .

Sustituyendo la expresión de la distribución normal multivariada en la ecuación (5.10):

$$g_i(\mathbf{x}(t)) = -\frac{1}{2}(\mathbf{x}(t) - \hat{\boldsymbol{\mu}}_i)\hat{\boldsymbol{\Sigma}}_i^{-1}(\mathbf{x}(t) - \hat{\boldsymbol{\mu}}_i)^T - \frac{1}{2}\ln 2\pi - \frac{1}{2}\ln|\hat{\boldsymbol{\Sigma}}_i| + \ln P(C_i) \quad (5.11)$$

El término $-\frac{1}{2}\ln 2\pi$ es el mismo para todas las clases y, por tanto, no influye en la función discriminante y puede eliminarse.

La expresión de la función discriminante calculada por la ecuación (5.11) está dominada por un término cuadrático y, por lo tanto, el clasificador bayesiano con distribuciones normales multivariadas se denomina clasificador bayesiano cuadrático. La Figura 5.8 muestra dos ejemplos sintéticos de clases generadas por variables distribuidas normalmente y la superficie de decisión calculada por la función discriminante (5.11).




Figura 5.8: Ejemplos de superficies de decisión cuadráticas.

El resultado del clasificador bayesiano cuadrático sobre el conjunto de datos de la Figura 5.6 se muestra en la Figura 5.9, en la que podemos observar que la función discriminante es eficiente para la separación de clases.




Figura 5.9: Problema não separável linearmente: (a) conjunto de treinamento; (b) superfície de decisão pelo classificador bayesiano quadrático.

A estimativa dos parâmetros da equação normal para o cálculo da função discriminante como (5.11) pode se tornar inviável em problemas de alta dimensionalidade, uma vez que são necessários $p + p(p + 1)/2$ parâmetros para cada classe. Considere, por exemplo, o conjunto de dados *Wine*, com $p = 13$ variáveis de entrada, o que resulta em 104 parâmetros a serem estimados para cada classe. O conjunto de dados conta apenas 178 registros, dos quais 59 da classe C_1 , 71 da classe C_2 e 48 da classe C_3 , o que prejudica as estimativas de média e matriz de covariâncias.

Em problemas de alta dimensionalidade com reduzido número de registros, é possível utilizar a redução de dimensionalidade produzida por transformações lineares como a ACP e a ADL (análise discriminante linear). Aplicando a ADL no conjunto de dados *Wine*, o número de variáveis é reduzido para $\hat{p} = m - 1 = 2$, o que significa estimar apenas três parâmetros para a média e a matriz de covariâncias. A Figura 5.10 apresenta o resultado da superfície de decisão calculada pelo classificador bayesiano quadrático sobre o conjunto de dados *Wine* 2D, obtido após a transformação pela ADL do conjunto *Wine*. Podemos observar o contorno quadrático das funções discriminantes de cada classe.




Figura 5.9: Problema separable no linealmente: (a) conjunto de entrenamiento; (b) superficie de decisión por el clasificador bayesiano cuadrático.

Estimar los parámetros de la ecuación normal para calcular la función discriminante como (5.11) puede volverse inviable en problemas de alta dimensión, ya que se requieren $p + p(p + 1)/2$ parámetros para cada clase. Considere, por ejemplo, el conjunto de datos *Wine*, con $p = 13$ variables de entrada, lo que da como resultado 104 parámetros que se estimarán para cada clase. El conjunto de datos contiene solo 178 registros, de los cuales 59 son de la clase C_1 , 71 de la clase C_2 y 48 de la clase C_3 , lo que perjudica las estimaciones de la matriz de media y covarianza.

En problemas de alta dimensión con un número reducido de registros, es posible utilizar la reducción de dimensionalidad producida por transformaciones lineales como PCA y ADL (análisis discriminante lineal). Al aplicar ADL al conjunto de datos *Wine*, el número de variables se reduce a $\hat{p} = m - 1 = 2$, lo que significa estimar solo tres parámetros para la media y la matriz de covarianza. La Figura 5.10 presenta el resultado de la superficie de decisión calculada por el clasificador bayesiano cuadrático sobre el conjunto de datos *Wine* 2D, obtenido después de la transformación ADL del conjunto de datos *Wine*. Podemos observar el contorno cuadrático de las funciones discriminantes de cada clase.




Figura 5.10: Conjunto de dados *Wine* 2D: (a) conjunto de treinamento; (b) superfície de decisão pelo classificador bayesiano quadrático.

O classificador bayesiano com distribuições normais multivariadas gera uma função discriminante linear quando a matriz de covariâncias é a mesma para todas as classes e é estimada como a matriz de covariâncias dos dados, isto é, $\hat{\Sigma}_i = \hat{\Sigma}, i = 1, \dots, m$. Nesse caso, o termo quadrático da equação (5.11) pode ser ignorado (por ser o mesmo para todas as classes) e a função discriminante é escrita como:

$$g_i(\mathbf{x}(t)) = \mathbf{x}(t)\hat{\Sigma}^{-1}\hat{\boldsymbol{\mu}}_i^T - \frac{1}{2}\hat{\boldsymbol{\mu}}_i\hat{\Sigma}^{-1}\hat{\boldsymbol{\mu}}_i^T + \ln P(C_i) \quad (5.12)$$

A equação (5.12) pode ser escrita na forma de uma função linear como:

$$g_i(\mathbf{x}(t)) = \hat{\mathbf{x}}(t)\boldsymbol{\theta}_i^T \quad (5.13)$$

onde $\hat{\mathbf{x}}(t) = [1, \mathbf{x}(t)]$ é o vetor de regressores e $\boldsymbol{\theta}_i = [\theta_{i0}, \boldsymbol{\theta}_{i1}]$ é o vetor de parâmetros, cujos componentes $\theta_{i0} = -\frac{1}{2}\hat{\boldsymbol{\mu}}_i\hat{\Sigma}^{-1}\hat{\boldsymbol{\mu}}_i^T + \ln P(C_i)$ e $\boldsymbol{\theta}_{i1} = \hat{\Sigma}^{-1}\hat{\boldsymbol{\mu}}_i^T$.

O classificador bayesiano linear não requer um número considerável de parâmetros a serem estimados, pois apenas uma matriz de covariâncias é estimada para todas as classes. Entretanto, na prática, o desempenho pode ser pior que o classificador bayesiano simples.

Do ponto de vista conceitual, a equação (5.13) mostra que um classificador pode ser estimado diretamente por sua função discriminante, sem a necessidade de hipóteses sobre a função de distribuição de probabilidades condicional. Dessa forma, os modelos lineares podem ser aplicados à classificação, como apresentado a seguir.




Figura 5.10: *Wine* Conjunto de datos 2D: (a) conjunto de entrenamiento; (b) superficie de decisión por el clasificador bayesiano cuadrático.

El clasificador bayesiano con distribuciones normales multivariadas genera una función discriminante lineal cuando la matriz de covarianza es la misma para todas las clases y se estima como la matriz de covarianza de los datos, es decir, $\hat{\Sigma}_i = \hat{\Sigma}$, $i = 1, \dots, m$. En este caso, el término cuadrático de la ecuación (5.11) puede ignorarse (ya que es el mismo para todas las clases) y la función discriminante se escribe como:

$$g_i(\mathbf{x}(t)) = \mathbf{x}(t)\hat{\Sigma}^{-1}\hat{\boldsymbol{\mu}}_i^T - \frac{1}{2}\hat{\boldsymbol{\mu}}_i\hat{\Sigma}^{-1}\hat{\boldsymbol{\mu}}_i^T + \ln P(C_i) \quad (5.12)$$

La ecuación (5.12) se puede escribir en forma de función lineal como:

$$g_i(\mathbf{x}(t)) = \hat{\mathbf{x}}(t)\boldsymbol{\theta}_i^T \quad (5.13)$$

donde $\hat{\mathbf{x}}(t) = [1, \mathbf{x}(t)]$ es el vector de regresores y $\boldsymbol{\theta}_i = [\theta_{i0}, \boldsymbol{\theta}_{i1}]$ es el vector de parámetros, cuyos componentes $\theta_{i0} = -\frac{1}{2}\hat{\boldsymbol{\mu}}_i\hat{\Sigma}^{-1}\hat{\boldsymbol{\mu}}_i^T + \ln P(C_i)$ y $\boldsymbol{\theta}_{i1} = \hat{\Sigma}^{-1}\hat{\boldsymbol{\mu}}_i^T$.

El clasificador bayesiano lineal no requiere estimar un número considerable de parámetros, ya que solo se estima una matriz de covarianza para todas las clases. Sin embargo, en la práctica, el rendimiento puede ser peor que el del clasificador bayesiano simple.

Desde un punto de vista conceptual, la ecuación (5.13) muestra que un clasificador puede estimarse directamente por su función discriminante, sin necesidad de hipótesis sobre la función de distribución de probabilidad condicional. De esta manera, se pueden aplicar modelos lineales a la clasificación, como se presenta a continuación.

5.2 Modelos Lineares de Classificação

A equação (5.13) mostra que um modelo linear pode ser utilizado para a aproximação da função discriminante num problema de classificação. Dessa forma, os problemas de classificação e de regressão são similares, diferindo apenas no tipo de variável de saída.

A síntese do classificador pode ser realizada diretamente pelo ajuste dos parâmetros de um modelo linear pelo método dos mínimos quadrados (MMQ), como apresentado nas seções 5.2.1 e 5.2.2. Entretanto, um modelo linear não permite a interpretação da função discriminante como um valor de probabilidade. Na regressão logística, apresentada na seção 5.2.3, o resultado do modelo linear é transformado por uma função exponencial que permite a interpretação do resultado como um valor de probabilidade.

5.2.1 Mínimos quadrados

O ajuste de parâmetros do modelo linear é feito a partir do conjunto de treinamento $\mathcal{T} = \{(\mathbf{x}(t), y(t)), t = 1 \dots N\}$, onde $\mathbf{x}(t) \in \mathcal{R}^p$ o vetor das variáveis de entrada e a saída $y(t) \in \mathcal{N}$, o índice das classes.

Para o ajuste da função discriminante, a variável de saída é transformada para refletir o resultado da função discriminante em (5.9). Essa transformação é feita pela definição de uma **variável indicadora** (“dummy”) bipolar $v_i(t) \in \{-1, 1\}$, como:*

$$v_i(t) = \begin{cases} +1, & \text{se } y(t) = i \\ -1, & \text{se } y(t) \neq i \end{cases} \quad i = 1, \dots, m \quad (5.14)$$

O vetor $\mathbf{v}(t) \in \{-1, 1\}^m$ é chamado de vetor de variáveis indicadoras, pois a posição do valor 1 no vetor indica a classe a que pertence o registro.

As funções discriminantes são calculadas pelo modelo linear como aproximações das variáveis indicadoras como:

$$\hat{v}_i(t) = g_i(\mathbf{x}(t), \boldsymbol{\theta}_i) = \hat{\mathbf{x}}(t) \boldsymbol{\theta}_i^T, \quad i = 1, \dots, m \quad (5.15)$$

As variáveis indicadoras estimadas $\hat{\mathbf{v}}(t) \in \mathcal{R}^m$ podem ser utilizadas para a classificação através da regra (5.9). Os parâmetros $\boldsymbol{\theta}_i$ são calculados, para cada classe, pela minimização do erro médio quadrático (EMQ):

* A variável indicadora binária $v_i(t) \in \{0, 1\}$ também pode ser utilizada.

5.2 Modelos de clasificación lineal

La ecuación (5.13) muestra que se puede utilizar un modelo lineal para aproximar la función discriminante en un problema de clasificación. Por lo tanto, los problemas de clasificación y regresión son similares y sólo difieren en el tipo de variable de salida.

La síntesis del clasificador se puede realizar directamente ajustando los parámetros de un modelo lineal utilizando el método de mínimos cuadrados (MMQ), como se presenta en las secciones 5.2.1 y 5.2.2. Sin embargo, un modelo lineal no permite interpretar la función discriminante como un valor de probabilidad. En la regresión logística, presentada en la sección 5.2.3, el resultado del modelo lineal se transforma mediante una función exponencial que permite interpretar el resultado como un valor de probabilidad.

5.2.1 Mínimos cuadrados

El ajuste de parámetros del modelo lineal se realiza a partir del conjunto de entrenamiento $\mathcal{T} = \{(\mathbf{x}(t), y(t)), t = 1 \dots N\}$, donde $\mathbf{x}(t) \in \mathcal{R}^p$ es el vector de variables de entrada y la salida $y(t) \in \mathcal{N}$ es el índice de clase.

Para ajustar la función discriminante, la variable de salida se transforma para reflejar el resultado de la función discriminante en (5.9). Esta transformación se realiza definiendo una variable indicadora ("dummy") bipolar $v_i(t) \in \{-1, 1\}$, como por ejemplo: *

$$v_i(t) = \begin{cases} +1, & \text{se } y(t) = i \\ -1, & \text{se } y(t) \neq i \end{cases} \quad i = 1, \dots, m \quad (5.14)$$

El vector $\mathbf{v}(t) \in \{-1, 1\}^m$ se denomina vector de variables indicadoras, ya que la posición del valor 1 en el vector indica la clase a la que pertenece el registro.

Las funciones discriminantes son calculadas por el modelo lineal como aproximaciones de las variables indicadoras como:

$$\hat{v}_i(t) = g_i(\mathbf{x}(t), \boldsymbol{\theta}_i) = \hat{\mathbf{x}}(t) \boldsymbol{\theta}_i^T, \quad i = 1, \dots, m \quad (5.15)$$

Las variables indicadoras estimadas $\hat{\mathbf{v}}(t) \in \mathcal{R}^m$ se pueden utilizar para la clasificación utilizando la regla (5.9). Los parámetros $\boldsymbol{\theta}_i$ se calculan, para cada clase, minimizando el error cuadrático medio (EMQ):

* A variável indicadora binária $v_i(t) \in \{0, 1\}$ também pode ser utilizada.

$$EMQ(\theta_i) = \frac{1}{N} \sum_{t=1}^N (v_i(t) - \hat{v}_i(t))^2, \quad i = 1, \dots, m \quad (5.16)$$

A minimização do EMQ para cada classe é feita pelo MMQ da mesma forma que apresentada na seção 3.1.2. A relação *bias* x variância do modelo discutida na seção 3.2.1 e as técnicas de regularização apresentadas nas sessões 3.2.2 e 3.2.3 se aplicam igualmente ao modelo linear de classificação. A avaliação de classificadores, entretanto, é feita por estatísticas adicionais, discutidas na seção 5.3.

O modelo linear de classificação permite a síntese de um classificador por uma função discriminante linear nos parâmetros. No modelo linear polinomial, descrito na equação (3.3), a estrutura é definida pelo grau do polinômio. A Figura 5.11 apresenta dois exemplos de modelos polinomiais de classificação executados sobre os mesmos dados do exemplo mostrado na Figura 5.10: o conjunto de dados *Wine* após transformação pela ADL. A Figura 5.11a mostra o resultado do modelo linear, ou polinomial de grau 1, e a Figura 5.11b mostra o resultado do modelo quadrático ou polinomial de grau 2.




Figura 5.11: Superfícies de decisão no problema *Wine* 2D: (a) modelo linear; (b) modelo quadrático.

Os resultados da Figura 5.11 são ligeiramente diferentes entre si, mas há uma grande diferença entre o resultado da Figura 5.11b e o do classificador bayesiano quadrático, mostrado na Figura 5.10b. Em ambos os casos, o modelo é quadrático, mas, no classificador linear, a estrutura do modelo foi definida pela escolha do grau do polinômio, enquanto no classificador bayesiano, a estrutura do modelo foi definida pela hipótese de distribuição normal. O modelo linear foi ajustado pelo MMQ, enquanto o classificador bayesiano foi ajustado pelas médias e matrizes de covariâncias de cada classe.

$$EMQ(\theta_i) = \frac{1}{N} \sum_{t=1}^N (v_i(t) - \hat{v}_i(t))^2, \quad i = 1, \dots, m \quad (5.16)$$

MMQ realiza la minimización de EMQ para cada clase de la misma manera que se presenta en la sección 3.1.2. La relación de varianza del modelo *bias x* analizada en la sección 3.2.1 y las técnicas de regularización presentadas en las secciones 3.2.2 y 3.2.3 se aplican igualmente al modelo de clasificación lineal. Sin embargo, la evaluación del clasificador se realiza mediante estadísticas adicionales, que se analizan en la sección 5.3.

El modelo de clasificación lineal permite la síntesis de un clasificador mediante una función discriminante lineal en los parámetros. En el modelo polinómico lineal, descrito en la ecuación (3.3), la estructura está definida por el grado del polinomio. La Figura 5.11 presenta dos ejemplos de modelos de clasificación polinómica ejecutados con los mismos datos que el ejemplo mostrado en la Figura 5.10: el conjunto de datos *Wine* después de la transformación mediante ADL. La figura 5.11a muestra el resultado del modelo lineal, o polinomio de grado 1, y la figura 5.11b muestra el resultado del modelo cuadrático o polinómico de grado 2.




Figura 5.11: Superficies de decisión en el problema 2D *Wine*: (a) modelo lineal; (b) modelo cuadrático.

Los resultados de la Figura 5.11 son ligeramente diferentes entre sí, pero hay una gran diferencia entre el resultado de la Figura 5.11b y el del clasificador bayesiano cuadrático, que se muestra en la Figura 5.10b. En ambos casos, el modelo es cuadrático, pero en el clasificador lineal, la estructura del modelo se definió por la elección del grado del polinomio, mientras que en el clasificador bayesiano, la estructura del modelo se definió por la hipótesis de distribución normal. El modelo lineal fue ajustado por el MMQ, mientras que el clasificador bayesiano fue ajustado por las matrices de medias y covarianzas de cada clase.

O ajuste de parâmetros pelo MMQ obtém um classificador que realiza a decisão pela minimização do erro de classificação. Entretanto, em alguns problemas, é importante realizar a decisão pela minimização do risco condicional, que implica ponderar uma classe em relação à outra. É possível ponderar os registros de uma classe em relação a outra através do método dos mínimos quadrados ponderados descrito a seguir.

5.2.2 Mínimos quadrados ponderados

O método dos mínimos quadrados ponderados (MMQP) permite ajustar os parâmetros de um modelo linear na situação em que alguns registros são mais “importantes” que outros. O MMQP é utilizado na regressão linear para estabilizar a variância do conjunto de dados e reduzir a influência de *outliers* [399]. Em modelos lineares de classificação, o MMQP pode atribuir maior peso aos registros da classe de maior risco, permitindo que a decisão de classificação seja feita pela minimização do risco condicional.

A formulação do MMQP é feita a partir da definição de um vetor de pesos $\mathbf{w} \in \mathcal{R}^N$, em que cada elemento $w(t)$ representa o peso do registro $t \in \mathcal{T}$. Os parâmetros do modelo para cada classe θ_i são calculados pela minimização do **erro médio quadrático ponderado** (EMQP):

$$EMQP(\theta_i) = \frac{1}{N} \sum_{t=1}^N w(t) (v_i(t) - \hat{v}_i(t))^2, \quad i = 1, \dots, m \quad (5.17)$$

onde os valores de ponderação são os mesmos para o cálculo dos parâmetros de todas as classes, uma vez que a ponderação é aplicada aos registros.

Adotando a representação vetorial em que $\mathbf{V}_i = [v_i(1), \dots, v_i(N)]^T$ é a coluna i da matriz de saída, cujos elementos são os valores da variável indicadora da classe C_i , $\hat{\mathbf{X}}$ é a matriz de regressores (cf. equação (3.5)) e $\mathbf{W} = \text{diag}(\mathbf{w})$, a matriz diagonal em que cada elemento é o peso do registro correspondente, o EMQP pode ser escrito como:

$$EMQP(\theta_i) = \frac{1}{N} (\mathbf{V}_i - \hat{\mathbf{X}}\theta_i^T)^T \mathbf{W} (\mathbf{V}_i - \hat{\mathbf{X}}\theta_i^T), \quad i = 1, \dots, m \quad (5.18)$$

Derivando-se a expressão do EMQP na equação (5.18) e igualando a zero, obtemos a expressão das equações normais do MMQP, semelhante à equação (3.7):

$$\hat{\mathbf{X}}^T \mathbf{W} \hat{\mathbf{X}} \theta_i^T = \hat{\mathbf{X}}^T \mathbf{W} \mathbf{V}_i, \quad i = 1, \dots, m \quad (5.19)$$

El ajuste de parámetros por MMQ obtiene un clasificador que toma la decisión minimizando el error de clasificación. Sin embargo, en algunos problemas es importante tomar la decisión minimizando el riesgo condicional, lo que implica sopesar una clase en relación con la otra. Es posible ponderar registros de una clase en relación con otra utilizando el método de mínimos cuadrados ponderados que se describe a continuación.

5.2.2 Mínimos cuadrados ponderados

El método de mínimos cuadrados ponderados (MMQP) permite ajustar los parámetros de un modelo lineal en situaciones donde algunos registros son más “importantes” que otros. MMQP se utiliza en regresión lineal para estabilizar la varianza del conjunto de datos y reducir la influencia de *outliers* [399]. En los modelos de clasificación lineal, MMQP puede asignar mayor peso a los registros en la clase de riesgo más alto, lo que permite tomar la decisión de clasificación minimizando el riesgo condicional.

La formulación MMQP se basa en la definición de un vector de pesos $\mathbf{w} \in \mathcal{R}^N$, donde cada elemento $w(t)$ representa el peso del registro $t \in \mathcal{T}$. Los parámetros del modelo para cada clase θ_i se calculan minimizando el error cuadrático medio ponderado (EMQP):

$$EMQP(\theta_i) = \frac{1}{N} \sum_{t=1}^N w(t) (v_i(t) - \hat{v}_i(t))^2, \quad i = 1, \dots, m \quad (5.17)$$

donde los valores de ponderación son los mismos para calcular los parámetros de todas las clases, ya que la ponderación se aplica a los registros.

Adoptando la representación vectorial en la que $\mathbf{V}_i = [v_i(1), \dots, v_i(N)]^T$ es la columna i de la matriz de salida, cuyos elementos son los valores de la variable indicadora de clase C_i , $\hat{\mathbf{X}}$ es la matriz de regresores (cf. ecuación (3.5)) y $\mathbf{W} = \text{diag}(\mathbf{w})$, la matriz diagonal en la que cada elemento es el peso del registro correspondiente, la EMQP se puede escribir como:

$$EMQP(\theta_i) = \frac{1}{N} (\mathbf{V}_i - \hat{\mathbf{X}}\theta_i^T)^T \mathbf{W} (\mathbf{V}_i - \hat{\mathbf{X}}\theta_i^T), \quad i = 1, \dots, m \quad (5.18)$$

Al derivar la expresión EMQP en la ecuación (5.18) y equipararla a cero, obtenemos la expresión de las ecuaciones MMQP normales, similar a la ecuación (3.7):

$$\hat{\mathbf{X}}^T \mathbf{W} \hat{\mathbf{X}} \theta_i^T = \hat{\mathbf{X}}^T \mathbf{W} \mathbf{V}_i, \quad i = 1, \dots, m \quad (5.19)$$

A solução do sistema linear (5.19), considerando que a matriz* $\hat{\mathbf{X}}^T \mathbf{W} \hat{\mathbf{X}}$ tem posto completo, é calculada pela pseudoinversa como:

$$\theta_i^* = (\hat{\mathbf{X}}^T \mathbf{W} \hat{\mathbf{X}})^{-1} \hat{\mathbf{X}}^T \mathbf{W} \mathbf{v}_i, \quad i = 1, \dots, m \quad (5.20)$$

Os métodos de regularização discutidos na seção 3.2 se aplicam-se igualmente à solução do sistema linear da equação (5.19).

Na seção 3.1.3, foi visto que a solução calculada pelo EMQ produz melhor aproximação possível do conjunto de dados. Dessa forma, a solução calculada pelo MMQP terá um erro maior. Em problemas de classificação, a solução do MMQ corresponde à decisão pela minimização do erro de classificação na abordagem bayesiana, enquanto a solução do MMQP corresponde à minimização do risco condicional. Analogamente, o MMQP produz um erro global maior, mas terá um erro menor da classe mais importante.

Num problema de classificação desbalanceado, a classe minoritária é, em geral, a mais importante. Nesse caso, podemos definir a ponderação de cada registro pelo complemento do valor de probabilidade *a priori* da classe correspondente:

$$w(t) = 1 - \frac{N_i}{N} \quad \forall \mathbf{x}(t) \in C_i, \quad i = 1, \dots, m \quad (5.21)$$

onde N_i é o número de registros da classe C_i .

A ponderação realizada pela equação (5.21) é equivalente a eliminar o efeito da probabilidade *a priori* no classificador bayesiano. A probabilidade *a priori* influencia indiretamente o classificador ajustado pelo EMQ (cf. equação (5.16)), uma vez que a minimização do EMQ produz uma superfície de decisão que vai ser ajustada para incluir um número maior de registros da classe majoritária.

A Figura 5.12 mostra uma comparação dos resultados obtidos por um modelo quadrático ajustado pelo MMQ e pelo MMQP, com ponderações calculadas pela equação (5.21), nos dados do problema de Diabetes das índias Pima.¹¹⁸ Esse problema tem duas classes que representam o diagnóstico, positivo ou negativo, de diabetes em mulheres da etnia Pima a partir de atributos como número de filhos, pressão sanguínea etc. O

* A matriz de coeficientes $\hat{\mathbf{X}}^T \mathbf{W} \hat{\mathbf{X}} = (\mathbf{W} \hat{\mathbf{X}})^T \hat{\mathbf{X}}$. A matriz $\mathbf{W} \hat{\mathbf{X}}$ pode ser calculada diretamente a partir do vetor de pesos $\mathbf{w}^T$, multiplicando-se, elemento a elemento, as colunas da matriz de regressores $\hat{\mathbf{X}}$ pelo vetor de pesos $\mathbf{w}^T$, evitando-se, assim, o custo computacional e de alocação de memória do processamento dos elementos nulos da matriz diagonal $\mathbf{W}$.

La solución del sistema lineal (5.19), considerando que la matriz $\hat{\mathbf{X}}^T \mathbf{W} \hat{\mathbf{X}}$ tiene rango completo, se calcula por la pseudoinversa como:

$$\theta_i^* = (\hat{\mathbf{X}}^T \mathbf{W} \hat{\mathbf{X}})^{-1} \hat{\mathbf{X}}^T \mathbf{W} \mathbf{v}_i, \quad i = 1, \dots, m \quad (5.20)$$

Los métodos de regularización discutidos en la sección 3.2 se aplican igualmente a la solución del sistema lineal de ecuaciones (5.19).

En la sección 3.1.3, se vio que la solución calculada por EMQ produce la mejor aproximación posible del conjunto de datos. De esta forma, la solución calculada por MMQP tendrá un error mayor. En problemas de clasificación, la solución MMQ corresponde a la decisión de minimizar el error de clasificación en el enfoque bayesiano, mientras que la solución MMQP corresponde a la minimización del riesgo condicional. De manera similar, MMQP produce un error global mayor, pero tendrá un error menor en la clase más importante.

En un problema de clasificación desequilibrado, la clase minoritaria suele ser la más importante. En este caso, podemos definir la ponderación de cada registro por el complemento del valor de probabilidad *a priori* de la clase correspondiente:

$$w(t) = 1 - \frac{N_i}{N} \quad \forall \mathbf{x}(t) \in C_i, \quad i = 1, \dots, m \quad (5.21)$$

donde N_i es el número de registros de clase C_i .

La ponderación realizada por la ecuación (5.21) equivale a eliminar el efecto de la probabilidad *a priori* en el clasificador bayesiano. La probabilidad *a priori* influye indirectamente en el clasificador ajustado por EMQ (cf. ecuación (5.16)), ya que la minimización de EMQ produce una superficie de decisión que se ajustará para incluir un mayor número de registros de la clase mayoritaria.

La Figura 5.12 muestra una comparación de los resultados obtenidos por un modelo cuadrático ajustado por el MMQ y el MMQP, con pesos calculados por la ecuación (5.21), sobre datos del problema de Diabetes de los Indios Pima.¹¹⁸ Este problema tiene dos clases que representan el diagnóstico, positivo o negativo, de diabetes en mujeres de la etnia Pima en función de atributos como número de hijos, presión arterial, etc.

* A matriz de coeficientes $\hat{\mathbf{X}}^T \mathbf{W} \hat{\mathbf{X}} = (\mathbf{W} \hat{\mathbf{X}})^T \hat{\mathbf{X}}$. A matriz $\mathbf{W} \hat{\mathbf{X}}$ pode ser calculada diretamente a partir do vetor de pesos $\mathbf{w}^T$, multiplicando-se, elemento a elemento, as colunas da matriz de regressores $\hat{\mathbf{X}}$ pelo vetor de pesos $\mathbf{w}^T$, evitando-se, assim, o custo computacional e de alocação de memória do processamento dos elementos nulos da matriz diagonal $\mathbf{W}$.

conjunto de dados é desbalanceado e a classe negativa (C_1) tem 65% dos registros, enquanto a classe positiva (C_2) é atribuída a 35% dos registros. O conjunto de dados tem oito variáveis, mas a Figura 5.12 mostra os resultados calculados sobre as duas componentes principais para facilitar a visualização. Observe o aumento da região atribuída à classe positiva (em verde) no caso da solução calculada pelo MMQP.




Figura 5.12: Superfícies de decisão problema de Diabetes das índias Pima 2D: (a) MMQ; (b) MMQP.

Nos modelos lineares ajustados pelo MMQ e MMQP, a variável de saída é uma variável indicadora $v_i(t) \in \{-1, 1\}$, enquanto a aproximação do modelo linear $\hat{v}_i(t) \in \mathcal{R}$, que não pode ser interpretada a probabilidade *a posteriori* da classe. No modelo de regressão logística, descrito a seguir, o modelo linear é transformado para que resultado possa ser interpretado como um valor de probabilidade.

5.2.3 Regressão logística

A regressão logística, também conhecida como **modelo logit**, é um modelo de classificação encontrado em diversos *softwares* livres e comerciais, e em bibliotecas de linguagens de programação como R¹¹⁹ e Python.¹²⁰

A formulação clássica da regressão logística é obtida para o problema de classificação binária em que a saída observada é representada pela variável indicadora $v(t) \in \{0, 1\}$:

$$v(t) = \begin{cases} 1, & \text{se } \mathbf{x}(t) \in C \\ 0, & \text{se } \mathbf{x}(t) \notin C \end{cases} \quad (5.22)$$

O modelo é uma aproximação da probabilidade *a posteriori*, isto é, $g(\mathbf{x}, \boldsymbol{\theta}) \approx P(C|\mathbf{x})$, e a função discriminante é calculada pela função sigmoide, também conhecida por função logística ou logit (de onde o método deriva seu nome), aplicada ao modelo linear:

El conjunto de datos está desequilibrado y la clase negativa (C_1) tiene el 65% de los registros, mientras que la clase positiva (C_2) está asignada al 35% de los registros. El conjunto de datos tiene ocho variables, pero la Figura 5.12 muestra los resultados calculados sobre los dos componentes principales para facilitar la visualización. Nótese el aumento en la región asignada a la clase positiva (en verde) en el caso de la solución calculada por MMQP.




Figura 5.12: Superficies de decisión para el problema de diabetes de los indios Pima 2D: (a) MMQ; (b) MMQP.

En los modelos lineales ajustados por MMQ y MMQP, la variable de salida es una variable indicadora $v_i(t) \in \{-1, 1\}$, mientras que en la aproximación del modelo lineal $\hat{v}_i(t) \in \mathcal{R}$, no se puede interpretar la probabilidad *a posteriori* de la clase. En el modelo de regresión logística, que se describe a continuación, el modelo lineal se transforma para que el resultado pueda interpretarse como un valor de probabilidad.

5.2.3 Regresión logística

La regresión logística, también conocida como modelo logit, es un modelo de clasificación que se encuentra en varias bibliotecas *softwares* gratuitas y comerciales, y en bibliotecas de lenguajes de programación como R¹¹⁹ y Python.¹²⁰

La formulación clásica de regresión logística se obtiene para el problema de clasificación binaria en el que el resultado observado está representado por la variable indicadora $v(t) \in \{0, 1\}$:

$$v(t) = \begin{cases} 1, & \text{se } \mathbf{x}(t) \in C \\ 0, & \text{se } \mathbf{x}(t) \notin C \end{cases} \quad (5.22)$$

El modelo es una aproximación de la probabilidad *a posteriori*, es decir, $g(\mathbf{x}, \boldsymbol{\theta}) \approx P(C|\mathbf{x})$, y la función discriminante se calcula mediante la función sigmoidea, también conocida como función logística o logit (de donde deriva su nombre el método), aplicada al modelo lineal :

$$g(\mathbf{x}(t), \boldsymbol{\theta}) = \frac{1}{1 + \exp(-\hat{\mathbf{x}}(t)\boldsymbol{\theta}^T)} \quad (5.23)$$

onde $\hat{\mathbf{x}}(t) = [1, \mathbf{x}(t)]$ é o vetor de regressores e $\boldsymbol{\theta}$ é o vetor de parâmetros.

A Figura 5.13 mostra o comportamento da função sigmoide $g(z)$, na qual podemos observar que $\lim_{z \rightarrow +\infty} g(z) = 1$ e $\lim_{z \rightarrow -\infty} g(z) = 0$.




Figura 5.13: Função sigmoide ou logística.

A regressão logística é um modelo de classificação binária, cuja função discriminante é definida pela probabilidade *a posteriori* como:

$$\begin{aligned} P(v(t) = 1 | \mathbf{x}(t), \boldsymbol{\theta}) &= g(\mathbf{x}(t), \boldsymbol{\theta}) \\ P(v(t) = 0 | \mathbf{x}(t), \boldsymbol{\theta}) &= 1 - g(\mathbf{x}(t), \boldsymbol{\theta}) \end{aligned} \quad (5.24)$$

A equação acima pode ser escrita como uma distribuição de Bernoulli¹²¹:

$$P(v(t) | \mathbf{x}(t), \boldsymbol{\theta}) = \hat{v}(t)^{v(t)} (1 - \hat{v}(t))^{1-v(t)} \quad (5.25)$$

onde $\hat{v}(t) = g(\mathbf{x}(t), \boldsymbol{\theta})$ e $v(t) \in \{0, 1\}$.

O modelo de regressão logística é ajustado para maximizar a probabilidade (ou a função de verossimilhança) do modelo em representar os valores de observados:

$$L(\boldsymbol{\theta}) = \prod_{t=1}^N P(v(t) | \mathbf{x}(t), \boldsymbol{\theta}) \quad (5.26)$$

Aplicando a expressão (5.25) em (5.26), temos a expressão da função de verossimilhança da regressão logística:

$$g(\mathbf{x}(t), \boldsymbol{\theta}) = \frac{1}{1 + \exp(-\hat{\mathbf{x}}(t)\boldsymbol{\theta}^T)} \quad (5.23)$$

donde $\hat{\mathbf{x}}(t) = [1, \mathbf{x}(t)]$ es el vector de regresores y $\boldsymbol{\theta}$ es el vector de parámetros.

La Figura 5.13 muestra el comportamiento de la función sigmoidea $g(z)$, en la que podemos observar que $\lim_{z \rightarrow +\infty} g(z) = 1$ y $\lim_{z \rightarrow -\infty} g(z) = 0$.




Figura 5.13: Función sigmoidea o logística.

La regresión logística es un modelo de clasificación binaria, cuya función discriminante está definida por la probabilidad *a posteriori* como:

$$\begin{aligned} P(v(t) = 1 | \mathbf{x}(t), \boldsymbol{\theta}) &= g(\mathbf{x}(t), \boldsymbol{\theta}) \\ P(v(t) = 0 | \mathbf{x}(t), \boldsymbol{\theta}) &= 1 - g(\mathbf{x}(t), \boldsymbol{\theta}) \end{aligned} \quad (5.24)$$

La ecuación anterior se puede escribir como una distribución de Bernoulli¹²¹:

$$P(v(t) | \mathbf{x}(t), \boldsymbol{\theta}) = \hat{v}(t)^{v(t)} (1 - \hat{v}(t))^{1-v(t)} \quad (5.25)$$

donde $\hat{v}(t) = g(\mathbf{x}(t), \boldsymbol{\theta})$ y $v(t) \in \{0, 1\}$.

El modelo de regresión logística se ajusta para maximizar la probabilidad (o función de verosimilitud) del modelo al representar los valores observados:

$$L(\boldsymbol{\theta}) = \prod_{t=1}^N P(v(t) | \mathbf{x}(t), \boldsymbol{\theta}) \quad (5.26)$$

Aplicando la expresión (5.25) a (5.26), tenemos la expresión de la función de verosimilitud de la regresión logística:

$$L(\theta) = \prod_{t=1}^N \hat{v}(t)^{v(t)} (1 - \hat{v}(t))^{1-v(t)} \quad (5.27)$$

O produtório da equação (5.27) dificulta o ajuste de parâmetros e o resultado não se altera se o negativo do logaritmo da função de verossimilhança for utilizado para o ajuste de parâmetros como um problema de minimização:

$$l(\theta) = -\log(L(\theta)) = -\sum_{t=1}^N v(t) \log(\hat{v}(t)) + (1 - v(t)) \log(1 - \hat{v}(t)) \quad (5.28)$$

A Figura 5.14 mostra o resultado da função (5.28) calculada para um determinado registro. Quando $v(t) = 1$, mostrado na Figura 5.14a, $l(\theta) = -\log(\hat{v}(t))$, que aumenta exponencialmente à medida que $\hat{v}(t) \rightarrow 0$. No caso de $v(t) = 0$, mostrado na Figura 5.14b, $l(\theta) = -\log(1 - \hat{v}(t))$ que aumenta exponencialmente quando $\hat{v}(t) \rightarrow 1$.




Figura 5.14: Função de custo (5.28): (a) $v(t) = 1$; (b) $v(t) = 0$.

O negativo do logaritmo da função de verossimilhança (cf. equação (5.28)) é mais adequada para o ajuste de modelos de classificação que o EMQ pela solução de um problema de minimização. Os resultados da regressão logística e do modelo linear ajustado pelo MMQ são equivalentes, mas a regressão logística tem uma interpretação probabilística, que é mais adequada para a tomada de decisão. Entretanto, embora os parâmetros do modelo ocorram não linearmente na expressão da função sigmoide (5.23). Hastie e colaboradores [238] apresentam a solução baseada no método de Newton-Raphson, que resulta no algoritmo conhecido como mínimos quadrados iterativo ponderado [406]. O modelo de regressão logística também pode ser ajustado pelo método do gradiente como será apresentado na seção 9.1.2.

$$L(\theta) = \prod_{t=1}^N \hat{v}(t)^{v(t)} (1 - \hat{v}(t))^{1-v(t)} \quad (5.27)$$

El producto de la ecuación (5.27) dificulta el ajuste de parámetros y el resultado no cambia si se utiliza el negativo del logaritmo de la función de verosimilitud para ajustar parámetros como un problema de minimización:

$$l(\theta) = -\log(L(\theta)) = -\sum_{t=1}^N v(t) \log(\hat{v}(t)) + (1 - v(t)) \log(1 - \hat{v}(t)) \quad (5.28)$$

La figura 5.14 muestra el resultado de la función (5.28) calculada para un registro determinado. Cuando $v(t) = 1$, como se muestra en la Figura 5.14a, $l(\theta) = -\log(\hat{v}(t))$, aumenta exponencialmente como $\hat{v}(t) \rightarrow 0$. En el caso de $v(t) = 0$, que se muestra en la figura 5.14b, $l(\theta) = -\log(1 - \hat{v}(t))$ aumenta exponencialmente cuando $\hat{v}(t) \rightarrow 1$.




Figura 5.14: Función de costos (5.28): (a) $v(t) = 1$; (b) $v(t) = 0$.

El negativo del logaritmo de la función de verosimilitud (cf. ecuación (5.28)) es más adecuada para ajustar modelos de clasificación que el EMQ para resolver un problema de minimización. Los resultados de la regresión logística y el modelo lineal ajustado por el MMQ son equivalentes, pero la regresión logística tiene una interpretación probabilística, que es más adecuada para la toma de decisiones. Sin embargo, aunque los parámetros del modelo ocurren de manera no lineal en la expresión de la función sigmoidea (5.23). Hastie y colaboradores [238] presentan una solución basada en el método de Newton-Raphson, que da como resultado el algoritmo conocido como mínimos cuadrados iterativos ponderados [406]. El modelo de regresión logística también se puede ajustar utilizando el método del gradiente como se presentará en la sección 9.1.2.

O modelo de regressão logística pode ser estendido para problemas de classificação de múltiplas classes [238][521] e para funções discriminantes não lineares [578]. No caso de múltiplas classes, o modelo é conhecido como **regressão softmax** e será discutido no Capítulo 9.

A Figura 5.15 apresenta o resultado de dois modelos de classificação sobre o conjunto de dados *Wine* 2D, formado pelo conjunto *Wine* após a ADL, discutido na Figura 5.10 e na Figura 5.11. A Figura 5.15a apresenta o resultado do classificador bayesiano simples; a Figura 5.15b mostra o resultado da regressão logística. Pode-se observar que o resultado da regressão logística é idêntico ao resultado do modelo de classificação linear ajustado pelo MMQ mostrado na Figura 5.11a.




Figura 5.15: Dados *Wine* 2D: (a) classificador bayesiano simples; (b) regressão logística.

Assim como na regressão, a escolha do melhor modelo deve ser feita a partir de estatísticas de validação calculadas em validação cruzada, como apresentado a seguir.

5.3 Avaliação de Classificadores

O problema de classificação é preditivo e, como no caso da regressão linear, é necessário evitar o *overfitting*. O processo de desenvolvimento de um modelo de classificação segue os mesmos passos delineados na seção 3.2, em que o objetivo da etapa de validação é a seleção do tipo e da estrutura do modelo mais adequados ao problema. As estatísticas são calculadas em validação cruzada para gerar um modelo com boa capacidade de generalização.

El modelo de regresión logística se puede extender a problemas de clasificación multiclase [238][521] y a funciones discriminantes no lineales [578]. En el caso de clases múltiples, el modelo se conoce como regresión softmax y se analizará en el Capítulo 9.

La Figura 5.15 presenta el resultado de dos modelos de clasificación en el conjunto de datos *Wine* 2D, formado por el conjunto *Wine* después de ADL, discutido en la Figura 5.10 y la Figura 5.11. La figura 5.15a presenta el resultado del clasificador bayesiano simple; La figura 5.15b muestra el resultado de la regresión logística. Se puede observar que el resultado de la regresión logística es idéntico al resultado del modelo de clasificación lineal ajustado por el MMQ que se muestra en la Figura 5.11a.




Figura 5.15: *Wine* Datos 2D: (a) clasificador bayesiano simple; (b) regresión logística.

Al igual que con la regresión, la elección del mejor modelo debe realizarse en función de las estadísticas de validación calculadas en validación cruzada, como se presenta a continuación.

5.3 Evaluación del Clasificador

El problema de clasificación es predictivo y, como en el caso de la regresión lineal, hay que evitar *overfitting*. El proceso de desarrollo de un modelo de clasificación sigue los mismos pasos descritos en la sección 3.2, donde el objetivo de la etapa de validación es seleccionar el tipo y estructura del modelo más apropiado al problema. Las estadísticas se calculan en validación cruzada para generar un modelo con buena capacidad de generalización.

O modelo linear ajustado pelo MMQ segue as mesmas hipóteses da regressão linear e o classificador poderia ser avaliado pelas mesmas estatísticas de validação apresentadas na seção 3.3.1. Entretanto, o problema de classificação tem saídas discretas e, geralmente, não ordenadas que requerem estatísticas específicas. Esta seção apresenta uma descrição das estatísticas mais utilizadas para avaliação de classificadores.

5.3.1 Estatísticas de validação

As estatísticas de avaliação de classificadores são calculadas a partir da matriz de confusão, citada na seção 5.1.1 e apresentada na Tabela 5.2 para duas classes. A matriz de confusão é utilizada em estatística para representar as possíveis soluções de um teste de hipóteses. Em problemas de classificação, as linhas representam as classes observadas e as colunas, as classes preditas pelo modelo.

As estatísticas de validação são definidas para problemas de duas classes em que uma classe é chamada arbitrariamente de classe positiva e a outra, de classe negativa. Na Tabela 5.2, a classe C_1 é a classe positiva e a classe C_2 , a negativa.

Tabela 5.2: Matriz de confusão

	$\hat{C}_1$ (Predita)	$\hat{C}_2$ (Predita)
C_1 (Real)	VP	FN
C_2 (Real)	FP	VN

A matriz de confusão é preenchida com o número de registros correspondentes, obtidos, em geral, em validação cruzada, seguindo a seguinte terminologia:

- **Verdadeiros Positivos (VP):** é o número de registros da classe C_1 corretamente classificados pelo modelo como classe $\hat{C}_1$.
- **Falsos Negativos (FN):** é o número de registros da classe C_1 classificados pelo modelo como classe $\hat{C}_2$.
- **Falsos Positivos (FP):** é o número de registros da classe C_2 classificados pelo modelo como classe $\hat{C}_1$.
- **Verdadeiros Negativos (VN):** é o número de registros da classe C_2 corretamente classificados pelo modelo como classe $\hat{C}_2$.

El modelo lineal ajustado por MMQ sigue las mismas hipótesis que la regresión lineal y el clasificador podría evaluarse utilizando las mismas estadísticas de validación presentadas en la sección 3.3.1. Sin embargo, el problema de clasificación tiene resultados discretos y generalmente desordenados que requieren estadísticas específicas. Esta sección presenta una descripción de las estadísticas más utilizadas para evaluar clasificadores.

5.3.1 Estadísticas de validación

Las estadísticas de evaluación del clasificador se calculan a partir de la matriz de confusión, mencionada en la sección 5.1.1 y presentada en la Tabla 5.2 para dos clases. La matriz de confusión se utiliza en estadística para representar las posibles soluciones de una prueba de hipótesis. En los problemas de clasificación, las líneas representan las clases observadas y las columnas representan las clases predichas por el modelo.

Las estadísticas de validación se definen para problemas de dos clases donde una clase se llama arbitrariamente clase positiva y la otra clase negativa. En la tabla 5.2, la clase C_1 es la clase positiva y la clase C_2 , es la negativa.

Tabla 5.2: Matriz de confusión

	$\hat{C}_1$ (Predita)	$\hat{C}_2$ (Predita)
C_1 (Real)	VP	FN
C_2 (Real)	FP	VN

La matriz de confusión se llena con el número de registros correspondientes, generalmente obtenidos mediante validación cruzada, siguiendo la siguiente terminología:

Verdaderos Positivos (VP): es el número de registros de la clase C_1 correctamente clasificados por el modelo como clase $\hat{C}_1$. Falsos Negativos (FN): es el número de registros de la clase C_1 clasificados por el modelo como clase $\hat{C}_2$. Falsos Positivos (FP): es el número de registros de la clase C_2 clasificados por el modelo como clase $\hat{C}_1$. Verdaderos Negativos (VN): es el número de registros de la clase C_2 correctamente clasificados por el modelo como clase $\hat{C}_2$.

A avaliação global do classificador é feita pela **acurácia** do modelo, que é sua taxa de classificação correta, calculada como:

$$ACC = \frac{VP + VN}{VP + FP + FN + VN} \quad (5.29)$$

O **erro global** de classificação é o complemento da acurácia:

$$ERR = 1 - ACC = \frac{FP + FN}{VP + FP + FN + VN} \quad (5.30)$$

O erro global destaca a diferença de desempenho de dois classificadores. Por exemplo, um modelo com acurácia de 96% tem o dobro do erro de outro modelo com 98% de acurácia.

As estatísticas globais de acurácia e erro não informam sobre o erro que o modelo está realizando para cada classe. Duas medidas frequentemente utilizadas em recuperação da informação podem ser utilizadas para avaliar o desempenho de classificadores [364]: **precisão** (PRE) e **recuperação** (REC), também chamada de sensibilidade ou *recall*. Estas medidas são definidas para cada classe como:

$$PRE(C_1) = \frac{VP}{VP + FP} \quad PRE(C_2) = \frac{VN}{VN + FN} \quad (5.31)$$

$$REC(C_1) = \frac{VP}{VP + FN} \quad REC(C_2) = \frac{VN}{VN + FP} \quad (5.32)$$

A precisão mede a capacidade de predição do modelo e a recuperação é sua capacidade de reconhecer os registros da classe correspondente. Em problemas de classificação com múltiplas classes, as medidas de precisão e *recall* são calculadas para cada classe considerando as demais como a classe negativa. As medidas de precisão e recuperação podem ser combinadas na chamada **medida F**, definida para a classe C_i como:

$$F(C_i) = \frac{2 PRE(C_i). REC(C_i)}{PRE(C_i) + REC(C_i)} \quad (5.33)$$

A medida F representa a média harmônica entre precisão e *recall*, e indica o desempenho em termos das duas estatísticas simultaneamente, podendo ser generalizada para variar entre a precisão e o *recall* através de um parâmetro [516].

Em problemas desbalanceados, as estatísticas de cada classe devem ser consideradas em conjunto para não levar a conclusões equivocadas. Por exemplo, considere um problema de duas classes, em que a probabilidade *a priori* $P(C_1) = 90\%$. Um classificador

La evaluación global del clasificador se realiza por la precisión del modelo, que es su tasa de clasificación correcta, calculada como:

$$ACC = \frac{VP + VN}{VP + FP + FN + VN} \quad (5.29)$$

El error de clasificación global es el complemento de la precisión:

$$ERR = 1 - ACC = \frac{FP + FN}{VP + FP + FN + VN} \quad (5.30)$$

El error global resalta la diferencia en el rendimiento de dos clasificadores. Por ejemplo, un modelo con un 96% de precisión tiene el doble de error que otro modelo con un 98% de precisión.

Las estadísticas globales de precisión y error no informan sobre el error que está cometiendo el modelo para cada clase. Se pueden utilizar dos medidas utilizadas frecuentemente en la recuperación de información para evaluar el desempeño de los clasificadores [364]: precisión (PRE) y recuperación (REC), también llamada sensibilidad o *re-call*. Estas medidas se definen para cada clase como:

$$PRE(C_1) = \frac{VP}{VP + FP} \quad PRE(C_2) = \frac{VN}{VN + FN} \quad (5.31)$$

$$REC(C_1) = \frac{VP}{VP + FN} \quad REC(C_2) = \frac{VN}{VN + FP} \quad (5.32)$$

La precisión mide la capacidad de predicción del modelo y la recuperación es su capacidad para reconocer registros de la clase correspondiente. En problemas de clasificación con múltiples clases, la precisión y las medidas *recall* se calculan para cada clase considerando las demás como clases negativas. Las medidas de precisión y recuperación se pueden combinar en la denominada medida F, definida para la clase C_i como:

$$F(C_i) = \frac{2 PRE(C_i).REC(C_i)}{PRE(C_i) + REC(C_i)} \quad (5.33)$$

La medida F representa la media armónica entre precisión y *recall*, e indica el rendimiento en términos de ambas estadísticas simultáneamente, y puede generalizarse para variar entre precisión y *recall* a través de un parámetro [516].

En problemas desequilibrados, las estadísticas de cada clase deben considerarse juntas para evitar llevar a conclusiones erróneas. Por ejemplo, considere un problema de dos clases, donde la probabilidad *a priori* $P(C_1) = 90\%$. un clasificador

que classifique todos os registros na classe majoritária (C_1) vai obter $PRE(C_1) = 0.9$ e $REC(C_1) = 1.0$, mas $PRE(C_2) = REC(C_2) = 0.0$ para a classe minoritária (C_2).

A estatística **kappa** é uma medida global que relaciona a probabilidade de concordância observada com a probabilidade de concordância esperada $P(E)$ [110]. Em modelos de classificação, a concordância observada é medida pela acurácia do classificador (5.29) e a concordância esperada é o resultado que seria obtido por um modelo aleatório em uma amostra de tamanho infinito. O coeficiente kappa (κ) é calculado como:

$$\kappa = \frac{ACC - P(E)}{1 - P(E)} \quad (5.34)$$

O valor $\kappa \leq 1$, sendo que $\kappa = 1$, indica a concordância completa; $\kappa = 0$ indica que $ACC = P(E)$, isto é, a acurácia é igual à concordância esperada. Um valor $\kappa < 0$ indica que o classificador tem um desempenho pior que um resultado puramente aleatório. Landis e Koch [327] sugerem que um valor de $\kappa \geq 0,8$ representa boa concordância e um resultado $0,6 \leq \kappa < 0,8$ representa uma concordância razoável. A probabilidade de concordância esperada $P(E)$ é calculada a partir da matriz de confusão, como:

$$P(E) = P(C_1)P(\hat{C}_1) + P(C_2)P(\hat{C}_2) \quad (5.35)$$

onde $P(C_1)$ é a probabilidade *a priori* da classe C_1 , $P(C_2)$ é a probabilidade *a priori* da classe C_2 , $P(\hat{C}_1)$ é o percentual de registros preditos como sendo da classe $\hat{C}_1$ pelo modelo e $P(\hat{C}_2)$, o percentual de registros preditos como classe $\hat{C}_2$.

Os termos da equação (5.35) são calculados como:

$$P(C_1) = \frac{VP + FN}{VP + FP + FN + VN} = \frac{N_1}{N} \quad (5.36)$$

$$P(C_2) = \frac{FP + VN}{VP + FP + FN + VN} = \frac{N_2}{N} \quad (5.37)$$

$$P(\hat{C}_1) = \frac{VP + FP}{VP + FP + FN + VN} = \frac{\hat{N}_1}{N} \quad (5.38)$$

$$P(\hat{C}_2) = \frac{FN + VN}{VP + FP + FN + VN} = \frac{\hat{N}_2}{N} \quad (5.39)$$

Os valores totais observados e preditos de cada classe são mostrados na Tabela 5.3.

que ordena todos los registros en la clase mayoritaria (C_1) obtendrá $PRE(C_1) = 0.9$ y $REC(C_1) = 1.0$, pero $PRE(C_2) = REC(C_2) = 0.0$ para la clase minoritaria (C_2).

La estadística kappa es una medida global que relaciona la probabilidad de acuerdo observado con la probabilidad de acuerdo esperado $P(E)$ [110]. En los modelos de clasificación, la concordancia observada se mide por la precisión del clasificador (5.29) y la concordancia esperada es el resultado que se obtendría mediante un modelo aleatorio en un tamaño de muestra infinito. El coeficiente kappa (κ) se calcula como:

$$\kappa = \frac{ACC - P(E)}{1 - P(E)} \quad (5.34)$$

El valor $\kappa \leq 1$, donde $\kappa = 1$, indica acuerdo total; $\kappa = 0$ indica que $ACC = P(E)$, es decir, la precisión es igual a la concordancia esperada. Un valor $\kappa < 0$ indica que el clasificador funciona peor que un resultado puramente aleatorio. Landis y Koch [327] sugieren que un valor de $\kappa \geq 0.8$ representa un buen acuerdo y un resultado de $0.6 \leq \kappa < 0.8$ representa un acuerdo razonable. La probabilidad de acuerdo esperada $P(E)$ se calcula a partir de la matriz de confusión como:

$$P(E) = P(C_1)P(\hat{C}_1) + P(C_2)P(\hat{C}_2) \quad (5.35)$$

donde $P(C_1)$ es la probabilidad *a priori* de la clase C_1 , $P(C_2)$ es la probabilidad *a priori* de la clase C_2 , $P(\hat{C}_1)$ es el porcentaje de registros predichos como de clase $\hat{C}_1$ por el modelo y $P(\hat{C}_2)$, el porcentaje de registros predichos como clase $\hat{C}_2$.

Los términos de la ecuación (5.35) se calculan como:

$$P(C_1) = \frac{VP + FN}{VP + FP + FN + VN} = \frac{N_1}{N} \quad (5.36)$$

$$P(C_2) = \frac{FP + VN}{VP + FP + FN + VN} = \frac{N_2}{N} \quad (5.37)$$

$$P(\hat{C}_1) = \frac{VP + FP}{VP + FP + FN + VN} = \frac{\hat{N}_1}{N} \quad (5.38)$$

$$P(\hat{C}_2) = \frac{FN + VN}{VP + FP + FN + VN} = \frac{\hat{N}_2}{N} \quad (5.39)$$

Los valores totales observados y pronosticados para cada clase se muestran en la Tabla 5.3.

Tabela 5.3: Totais observados e preditos de cada classe

	$\hat{C}_1$	$\hat{C}_2$	Total
C_1	VP	FN	N_1
C_2	FP	VN	N_2
Total	$\hat{N}_1$	$\hat{N}_2$	N

A avaliação de classificadores também é feita graficamente utilizando as taxas de verdadeiros positivos e de falsos positivos no chamado de espaço ROC, descrito a seguir.

5.3.2 Espaço ROC e AUC

Na seção 5.1.1, foi visto que, em caso de problemas desbalanceados, a decisão pelo mínimo erro de classificação favorece a classe majoritária. Em muitos problemas, a classe minoritária é a mais importante e, nesse caso, o erro global não pode ser utilizado para a escolha do classificador. A escolha do classificador em problemas desbalanceados deve favorecer a classe mais importante, aumentando a recuperação de registros de maior custo.

O efeito do desbalanceamento do problema sobre o resultado do classificador ajustado pelo mínimo erro de classificação é mostrado na Figura 5.16 que mostra o valor de $p(x|C_i)P(C_i)$ de cada para um problema de uma variável e duas classes. A situação em que as probabilidades *a priori* são iguais é mostrada na Figura 5.16a. Nesse caso, as taxas de FP e FN são definidas pela forma e posição das distribuições condicionais. No caso de problemas desbalanceados (Figura 5.16b), o ajuste do modelo pelo mínimo erro de classificação favorece a classe mais frequente (C_1), resultando num aumento da taxa de VP e consequente diminuição da taxa de VN. Quando a classe minoritária é a mais importante, o classificador deve favorecer a taxa de VN. Entretanto, o aumento da taxa de VN só pode ser obtido à custa de um aumento da taxa de FN, o que aumenta também o erro global, como foi discutido na seção 5.2.2.

Tabla 5.3: Totales observados y previstos para cada clase

	$\hat{C}_1$	$\hat{C}_2$	Total
C_1	VP	FN	N_1
C_2	FP	VN	N_2
Total	$\hat{N}_1$	$\hat{N}_2$	N

La evaluación de los clasificadores también se realiza gráficamente utilizando las tasas de verdaderos positivos y falsos positivos en el llamado espacio ROC, que se describe a continuación.

5.3.2 Espacio ROC y AUC

En el apartado 5.1.1 se vio que, en caso de problemas de desequilibrio, la decisión por el error de clasificación mínimo favorece a la clase mayoritaria. En muchos problemas, la clase minoritaria es la más importante y, en este caso, no se puede utilizar el error global para elegir el clasificador. La elección del clasificador en problemas desequilibrados debería favorecer la clase más importante, aumentando la recuperación de registros de mayor costo.

El efecto del desequilibrio del problema sobre el resultado del clasificador ajustado por el error de clasificación mínimo se muestra en la Figura 5.16, que muestra el valor de $p(x|C_i)P(C_i)$ cada uno para un problema de dos clases y una variable. La situación en la que las probabilidades *a priori* son iguales se muestra en la figura 5.16a. En este caso, las tasas FP y FN están definidas por la forma y posición de las distribuciones condicionales. En el caso de problemas desequilibrados (Figura 5.16b), ajustar el modelo por el error de clasificación mínimo favorece la clase más frecuente (C_1), lo que resulta en un aumento en la tasa de VP y una consecuente disminución en la tasa de VN. Cuando la clase minoritaria es la más importante, el clasificador debería favorecer la tasa VN. Sin embargo, un aumento en la tasa VN sólo puede obtenerse a expensas de un aumento en la tasa FN, lo que también aumenta el error global, como se analiza en la sección 5.2.2.




Figura 5.16: Problemas desbalanceados: (a) $P(C_1) = P(C_2)$; (b) $P(C_1) > P(C_2)$.

O espaço ROC (do inglês *receiver operating characteristic*) foi desenvolvido por operadores de radar para caracterização do *trade-off* entre a taxa de detecção e a de falsos alarmes em ambientes com ruído [516][561]. Para avaliação de classificadores, as taxas de FP e VP obtidas por um classificador são utilizadas como coordenadas do espaço ROC, mostrado na Figura 5.17.




Figura 5.17: Espaço ROC.

A taxa de VP (TVP) é o *recall* da classe positiva $REC(C_1)$ em (5.32) e a taxa de FP (TFP) é o complemento da taxa de VN ($REC(C_2)$) chamada de **especificidade** (SPE). O valor de TFP é calculado como:

$$TFP = 1 - SPE = 1 - \frac{VN}{FP + VN} = \frac{FP}{FP + VN} \quad (5.40)$$




Figura 5.16: Problemas de desequilibrio: (a) $P(C_1) = P(C_2)$; (b) $P(C_1) > P(C_2)$.

El espacio ROC (*receiver operating characteristic*) fue desarrollado por operadores de radar para caracterizar la diferencia *trade-off* entre la tasa de detección y la tasa de falsas alarmas en ambientes ruidosos [516][561]. Para evaluar clasificadores, las tasas de FP y VP obtenidas por un clasificador se utilizan como coordenadas del espacio ROC, como se muestra en la Figura 5.17.




Figura 5.17: Espacio ROC.

La tasa PV (TVP) es el *recall* de la clase positiva $REC(C_1)$ en (5.32) y la tasa FP (TFP) es el complemento de la tasa VN ($REC(C_2)$) llamada especificidad (SPE). El valor de TFP se calcula como:

$$TFP = 1 - SPE = 1 - \frac{VN}{FP + VN} = \frac{FP}{FP + VN} \quad (5.40)$$

O espaço ROC mostra o desempenho do classificador relacionando o quanto ele acerta da classe positiva e o quanto deixa de errar da classe negativa. O modelo ideal é o ponto (0,1) do gráfico, com $TFP = 0$, ou seja, $SPE = REC(C_2) = 1$ e $REC(C_1) = 1$. Nesse caso o modelo tem 100% de aproveitamento, pois recupera todos os exemplos de ambas as classes. Classificadores na diagonal do espaço ROC têm $REC(C_1) = 1 - REC(C_2)$, são modelos com $\kappa = 0$, ou seja, têm desempenho equivalente a um modelo aleatório. Os classificadores abaixo da diagonal representam modelos com $\kappa < 0$.

A área sombreada na Figura 5.17 é uma medida de avaliação de classificadores chamada de área sob a curva ROC (AUC, na sigla em inglês). A medida AUC é calculada pela área do quadrilátero obtido ao se ligar as coordenadas do classificador aos pontos (0,0) e (1,1) (cf. Figura 5.17). Após algumas simplificações, o valor de AUC é calculado como a média entre a taxa de VP e VN:

$$AUC = \frac{REC(C_1) + REC(C_2)}{2} \quad (5.41)$$

O valor de AUC é calculado pela equação (5.41) para problemas de duas classes. Em problemas de múltiplas classes, um valor de AUC é calculado para cada classe, considerada a classe positiva, e o valor de AUC total do classificador é calculado pela média do AUC de cada classe ponderada pela estimativa de probabilidade *a priori* da classe correspondente [176]:

$$AUC = \sum_{i=1}^m AUC(C_i)P(C_i) \quad (5.42)$$

onde $AUC(C_i)$ é o valor calculado pela equação (5.41) considerando a classe C_i como positiva e $P(C_i)$ é a frequência relativa da classe C_i . Outras abordagens para o cálculo do valor total de AUC foram avaliadas por Hand e Till [235].

Um método gráfico de avaliação de modelos no espaço ROC é chamado de curva ROC, que apresenta uma curva contínua no espaço ROC para cada classe. O valor AUC nesse caso é calculado integrando-se a curva ROC pelo método dos trapézios. Entretanto, a curva ROC é independente da frequência das classes [176]. A medida de AUC obtida pela equação (5.41), além de mais eficiente, é sensível às frequências das classes sendo portanto mais adequada em problemas desbalanceados.

El espacio ROC muestra el desempeño del clasificador relacionando cuánto acierta en la clase positiva y cuánto falla en la clase negativa. El modelo ideal es el punto (0,1) de la gráfica, con $TFP = 0$, es decir, $SPE = REC(C_2) = 1$ y $REC(C_1) = 1$. En este caso, el modelo tiene un éxito del 100%, ya que recupera todos los ejemplos de ambas clases. Los clasificadores en la diagonal del espacio ROC tienen $REC(C_1) = 1 - REC(C_2)$, son modelos con $\kappa = 0$, es decir, tienen un rendimiento equivalente a un modelo aleatorio. Los clasificadores debajo de la diagonal representan modelos con $\kappa < 0$.

El área sombreada en la Figura 5.17 es una medida de evaluación del clasificador llamada área bajo la curva ROC (AUC). La medida AUC se calcula mediante el área del cuadrilátero obtenida conectando las coordenadas del clasificador a los puntos (0,0) y (1,1) (cf. Figura 5.17). Después de algunas simplificaciones, el valor AUC se calcula como el promedio entre la tasa PV y VN:

$$AUC = \frac{REC(C_1) + REC(C_2)}{2} \quad (5.41)$$

El valor AUC se calcula mediante la ecuación (5.41) para problemas de dos clases. En problemas multiclase, se calcula un valor AUC para cada clase, considerando la clase positiva, y el valor AUC total del clasificador se calcula promediando el AUC de cada clase ponderado por la estimación de probabilidad *a priori* de la clase correspondiente [176]:

$$AUC = \sum_{i=1}^m AUC(C_i)P(C_i) \quad (5.42)$$

donde $AUC(C_i)$ es el valor calculado por la ecuación (5.41) considerando la clase C_i como positiva y $P(C_i)$ es la frecuencia relativa de la clase C_i . Hand and Till [235] evaluaron otros enfoques para calcular el valor AUC total.

Un método gráfico para evaluar modelos en el espacio ROC se llama curva ROC, que presenta una curva continua en el espacio ROC para cada clase. El valor AUC en este caso se calcula integrando la curva ROC utilizando el método trapezoidal. Sin embargo, la curva ROC es independiente de la frecuencia de clase [176]. La medida AUC obtenida por la ecuación (5.41), además de ser más eficiente, es sensible a las frecuencias de clase y por tanto es más adecuada en problemas de desequilibrio.

O resultado do valor AUC em problemas desbalanceados pode ser observado no conjunto de dados Diabetes das índias Pima, discutido na seção 5.2.2. Nesse problema, a classe positiva é a minoritária, representada por C_2 , com 35% dos registros. A Figura 5.18 mostra os resultados calculados em validação cruzada para os modelos quadráticos ajustados pelo MMQ e pelo MMQP utilizando todas as variáveis.

Na coluna da esquerda, a Figura 5.18a apresenta os resultados de precisão e *recall* de cada classe do classificador ajustado com o MMQ e a Figura 5.18c mostra o espaço ROC e o valor de AUC calculado pela equação (5.41) do mesmo modelo. Na coluna da direita, os mesmos resultados são apresentados para o modelo ajustado com o MMQP.




Figura 5.18: Resultados do problema Diabetes das índias Pima: (a) e (c) Modelo ajustado com MMQ; (b) e (d) modelo ajustado com MMQP.

El resultado del valor AUC en problemas desequilibrados se puede observar en el conjunto de datos Pima Indian Diabetes, que se analiza en la sección 5.2.2. En este problema, la clase positiva es la minoría, representada por C_2 , con el 35% de los registros. La Figura 5.18 muestra los resultados calculados en validación cruzada para los modelos cuadráticos ajustados por MMQ y MMQP utilizando todas las variables.

En la columna de la izquierda, la Figura 5.18a presenta la precisión y los resultados *recall* para cada clase del clasificador ajustado con el MMQ y la Figura 5.18c muestra el espacio ROC y el valor AUC calculado por la ecuación (5.41) del mismo modelo. En la columna de la derecha se presentan los mismos resultados para el modelo ajustado con el MMQP.




Figura 5.18: Resultados del problema Pima Indian Diabetes: (a) y (c) Modelo ajustado con MMQ; Modelo (b) y (d) ajustado con MMQP.

No modelo ajustado pelo MMQP, a recuperação da classe positiva (C_2) é maior, resultando num valor maior de AUC. O modelo ajustado pelo MMQ obtém menor erro global, influenciado pelo desbalanceamento entre as classes, resultando numa taxa de recuperação maior da classe negativa (C_1).

5.4 Aplicações

Os modelos de classificação apresentados neste capítulo serão discutidos nesta seção em dois contextos diferentes. Na seção 5.4.1, os algoritmos são comparados numa série de conjuntos de dados *benchmark* para uma avaliação global do desempenho do algoritmo. Esse mesmo tipo de teste será repetido nos Capítulos 7 e 8 com os modelos de classificação de inteligência computacional. Na seção 5.4.2, apresentamos um estudo de caso sobre a análise de cancelamentos em um operador de telefonia.

5.4.1 Testes *benchmark*

O repositório da Universidade da Califórnia em Irvine (UCI)¹²² é uma referência na área de ciência de dados e contém diversos conjuntos de dados para avaliação de algoritmos em problemas reais.

Um conjunto de 10 *benchmarks* foi selecionado para a avaliação dos modelos apresentados neste capítulo:

- Bayes N: Classificador bayesiano simples (*naif*)
- Bayes Q: Classificador bayesiano multivariado (quadrático)
- Logit: Regressão logística
- M. Lin. 1: Modelo linear de primeira ordem
- M. Lin. 2: Modelo linear de segunda ordem

Os conjuntos de dados foram selecionados de forma a cobrir uma grande variedade de tipos de problemas de dimensões diferentes, tanto em termos de número de registros quanto de número de variáveis. A Tabela 5.4 apresenta o número de variáveis (p), o número de classes (m) e o número de registros (N) de cada problema.

A maioria dos *benchmarks* são problemas conhecidos na literatura. Os *benchmarks* *Wine* e Diabetes das índias Pima já foram utilizados neste capítulo como exemplos de aplicação dos modelos. Nesta avaliação, todos os *benchmarks* foram utilizados como dados brutos, ou seja, não foi feito nenhum pré-processamento que pudesse interferir

En el modelo ajustado por MMQP, la recuperación de la clase positiva (C_2) es mayor, resultando en un valor de AUC mayor. El modelo ajustado por MMQ obtiene un menor error global, influenciado por el desequilibrio entre clases, resultando en una mayor tasa de recuperación para la clase negativa (C_1).

5.4 Aplicaciones

Los modelos de clasificación presentados en este capítulo se analizarán en esta sección en dos contextos diferentes. En la sección 5.4.1, los algoritmos se comparan en una serie de conjuntos de datos *benchmark* para una evaluación general del rendimiento del algoritmo. Este mismo tipo de prueba se repetirá en los Capítulos 7 y 8 con modelos de clasificación de inteligencia computacional. En el apartado 5.4.2 presentamos un caso de estudio sobre el análisis de cancelaciones en un operador telefónico.

5.4.1 Pruebas *benchmark*

El repositorio de la Universidad de California en Irvine (UCI)¹²² es una referencia en el área de ciencia de datos y contiene varios conjuntos de datos para evaluar algoritmos en problemas reales.

Se seleccionó un conjunto de 10 *benchmarks* para evaluar los modelos presentados en este capítulo:

Bayes N: Clasificador bayesiano simple (*naïf*) Bayes Q: Clasificador bayesiano multivariante (cuadrático) Logit: Regresión logística M. Lin. 1: Modelo lineal de primer orden M. Lin. 2: modelo lineal de segundo orden

Los conjuntos de datos fueron seleccionados para cubrir una amplia variedad de tipos de problemas de diferentes dimensiones, tanto en términos de número de registros como de variables. La Tabla 5.4 presenta el número de variables (p), el número de clases (m) y el número de registros (N) para cada problema.

La mayoría de los *benchmarks* son problemas conocidos en la literatura. *benchmarks* *Wine* y Diabetes de los indios Pima ya se han utilizado en este capítulo como ejemplos de aplicación de los modelos. En esta evaluación, todos los *benchmarks* se utilizaron como datos sin procesar, es decir, no se realizó ningún preprocesamiento que pudiera interferir

no desempenho dos modelos. Os algoritmos de ajuste de parâmetros também foram executados em sua forma padrão, ou seja, sem utilizar nenhuma ponderação para compensar o desbalanceamento das classes. Todos os testes foram realizados em validação cruzada de 10 ciclos, conforme o algoritmo descrito na seção 3.3.2.

Tabela 5.4: Conjuntos de dados *benchmark*

<i>Benchmark</i>	<i>p</i>	<i>m</i>	<i>N</i>
Íris ¹²³	4	3	150
Balance ¹²⁴	4	3	625
Diabetes ¹²⁵	8	2	768
Cancer ¹²⁶	9	2	286
Statlog Heart ¹²⁷	13	2	270
Wine ¹²⁸	13	3	178
Parkinson ¹²⁹	17	2	186
Ionosphere ¹³⁰	32	2	351
Spambase ¹³¹	57	2	4601
Sonar ¹³²	60	2	208

O desempenho dos modelos pode ser avaliado quantitativamente através das métricas de acurácia (ACC), definida na equação (5.29), e da área sobre a curva ROC (AUC), definida na equação (5.41). Os resultados são apresentados na Tabela 5.5, na qual os valores em **negrito** correspondem aos maiores valores de cada métrica para o respectivo *benchmark*.

Os resultados apresentados na Tabela 5.5 mostram que nenhum modelo é melhor em todos os testes, mas indicam que o modelo linear de segunda ordem (M. Lin. 2) obtém os melhores resultados na maioria das vezes. Além disso, os modelos quadráticos (Bayes Q e M. Lin. 2) obtiveram resultados melhores que seus correspondentes mais simples (Bayes N e M. Lin. 1) na maioria dos casos. O modelo de regressão logística (Logit) apresentou resultados próximos aos do modelo linear simples (M. Lin. 1).

É importante verificar se o melhor desempenho representa realmente um comportamento consistente do modelo ou é um resultado obtido em função de fatores aleatórios. Essa avaliação é feita por testes estatísticos não paramétricos [125][195] disponíveis em *softwares* estatísticos e no *software* livre KEEL,¹³³ utilizado nesta seção.

en el desempeño de los modelos. Los algoritmos de ajuste de parámetros también se ejecutaron en su forma estándar, es decir, sin utilizar ninguna ponderación para compensar el desequilibrio de las clases. Todas las pruebas se realizaron en validación cruzada de 10 ciclos, según el algoritmo descrito en la sección 3.3.2.

Tabla 5.4: *benchmark* Conjuntos de datos

<i>Benchmark</i>	<i>p</i>	<i>m</i>	<i>N</i>
Íris ¹²³	4	3	150
Balance ¹²⁴	4	3	625
Diabetes ¹²⁵	8	2	768
Cancer ¹²⁶	9	2	286
Statlog Heart ¹²⁷	13	2	270
Wine ¹²⁸	13	3	178
Parkinson ¹²⁹	17	2	186
Ionosphere ¹³⁰	32	2	351
Spambase ¹³¹	57	2	4601
Sonar ¹³²	60	2	208

El desempeño de los modelos se puede evaluar cuantitativamente a través de las métricas de precisión (ACC), definidas en la ecuación (5.29), y el área sobre la curva ROC (AUC), definida en la ecuación (5.41). Los resultados se presentan en la Tabla 5.5, en la que los valores en **negrita** corresponden a los valores más altos de cada métrica para la respectiva *benchmark*.

Los resultados presentados en la Tabla 5.5 muestran que ningún modelo es mejor en todas las pruebas, pero indican que el modelo lineal de segundo orden (M. Lin. 2) obtiene los mejores resultados la mayor parte del tiempo. Además, los modelos cuadráticos (Bayes Q y M. Lin. 2) obtuvieron mejores resultados que sus homólogos más simples (Bayes N y M. Lin. 1) en la mayoría de los casos. El modelo de regresión logística (Logit) presentó resultados cercanos a los del modelo lineal simple (M. Lin. 1).

Es importante comprobar si el mejor rendimiento realmente representa un comportamiento consistente del modelo o es un resultado obtenido debido a factores aleatorios. Esta evaluación se realiza mediante pruebas estadísticas no paramétricas [125][195] disponibles en *softwares* stats y en el *software* KEEL gratuito,¹³³ utilizado en esta sección.

Tabela 5.5: Resultados dos testes *benchmark*

<i>Benchmark</i>	Bayes N		Bayes Q		Logit		M. Lin. 1		M. Lin. 2	
	<i>ACC</i>	<i>AUC</i>	<i>ACC</i>	<i>AUC</i>	<i>ACC</i>	<i>AUC</i>	<i>ACC</i>	<i>AUC</i>	<i>ACC</i>	<i>AUC</i>
Íris	94.67	0.9600	98.00	0.9850	82.67	0.8697	83.33	0.8747	95.33	0.9650
Balance	90.40	0.9079	91.68	0.9469	87.04	0.8755	87.04	0.8755	91.36	0.9171
Diabetes	71.88	0.7260	74.61	0.7054	76.69	0.7145	76.30	0.7089	77.21	0.7151
Cancer	94.58	0.9574	95.02	0.9559	96.05	0.9512	96.05	0.9512	97.22	0.9709
Statlog Heart	83.70	0.8392	82.59	0.8225	83.33	0.8275	84.07	0.8358	84.44	0.8375
Wine	97.19	0.9766	99.44	0.9958	98.88	0.9919	98.31	0.9881	99.44	0.9958
Parkinson	79.49	0.7026	80.51	0.8427	86.15	0.7889	86.15	0.7889	86.15	0.8099
Ionosphere	60.68	0.6933	86.89	0.8803	85.75	0.8138	86.04	0.8178	89.46	0.8602
Spambase	90.18	0.8911	82.53	0.8474	88.63	0.8686	88.63	0.8684	91.37	0.9006
Sonar	72.60	0.7159	71.15	0.6992	76.92	0.7656	75.96	0.7579	80.29	0.8010

O teste de hipóteses é uma técnica clássica de estatística que permite avaliar se um conjunto de evidências observadas confirma ou refuta uma hipótese. Nos testes de hipótese paramétricos, há um modelo da distribuição do processo e o teste é realizado sobre os parâmetros da distribuição. Nos testes chamados não paramétricos, não há um modelo da distribuição dos dados [501]. Na avaliação de classificadores, as hipóteses são formuladas da seguinte forma:

- Hipótese nula $\mathcal{H}_0$: os modelos apresentam resultados equivalentes;
- Hipótese alternativa $\mathcal{H}_1$: os modelos não apresentam resultados equivalentes.

A aceitação da hipótese nula significa que as diferenças de desempenho são devidas às particularidades de cada *benchmark* [195]. O resultado do teste de hipóteses (paramétrico ou não paramétrico) é o chamado **valor- p** , que mede a significância estatística das diferenças observadas na avaliação. O valor- p é interpretado como a probabilidade de observar o resultado obtido considerando que a hipótese nula é verdadeira. Em outras palavras, o valor- p representa a probabilidade do chamado erro Tipo I (ou falso negativo), de rejeitar a hipótese nula quando, de fato, ela é verdadeira. Quanto menor o valor- p , menor é a probabilidade de que a hipótese nula seja verdadeira. Tipicamente, a

Tabla 5.5: resultados de la prueba *benchmark*

<i>Benchmark</i>	Bayes N		Bayes Q		Logit		M. Lin. 1		M. Lin. 2	
	<i>ACC</i>	<i>AUC</i>	<i>ACC</i>	<i>AUC</i>	<i>ACC</i>	<i>AUC</i>	<i>ACC</i>	<i>AUC</i>	<i>ACC</i>	<i>AUC</i>
Íris	94.67	0.9600	98.00	0.9850	82.67	0.8697	83.33	0.8747	95.33	0.9650
Balance	90.40	0.9079	91.68	0.9469	87.04	0.8755	87.04	0.8755	91.36	0.9171
Diabetes	71.88	0.7260	74.61	0.7054	76.69	0.7145	76.30	0.7089	77.21	0.7151
Cancer	94.58	0.9574	95.02	0.9559	96.05	0.9512	96.05	0.9512	97.22	0.9709
Statlog Heart	83.70	0.8392	82.59	0.8225	83.33	0.8275	84.07	0.8358	84.44	0.8375
Wine	97.19	0.9766	99.44	0.9958	98.88	0.9919	98.31	0.9881	99.44	0.9958
Parkinson	79.49	0.7026	80.51	0.8427	86.15	0.7889	86.15	0.7889	86.15	0.8099
Ionosphere	60.68	0.6933	86.89	0.8803	85.75	0.8138	86.04	0.8178	89.46	0.8602
Spambase	90.18	0.8911	82.53	0.8474	88.63	0.8686	88.63	0.8684	91.37	0.9006
Sonar	72.60	0.7159	71.15	0.6992	76.92	0.7656	75.96	0.7579	80.29	0.8010

La prueba de hipótesis es una técnica estadística clásica que permite evaluar si un conjunto de evidencia observada confirma o refuta una hipótesis. En las pruebas de hipótesis paramétricas, existe un modelo de distribución del proceso y la prueba se realiza sobre los parámetros de distribución. En las llamadas pruebas no paramétricas no existe ningún modelo de distribución de datos [501]. Al evaluar clasificadores, las hipótesis se formulan de la siguiente manera:

Hipótesis nula $\mathcal{H}_0$: los modelos presentan resultados equivalentes; Hipótesis alternativa $\mathcal{H}_1$: los modelos no presentan resultados equivalentes.

La aceptación de la hipótesis nula significa que las diferencias de rendimiento se deben a las particularidades de cada *benchmark* [195]. El resultado de la prueba de hipótesis (paramétrica o no paramétrica) es el llamado valor p , que mide la significancia estadística de las diferencias observadas en la evaluación. El valor p se interpreta como la probabilidad de observar el resultado obtenido considerando que la hipótesis nula es verdadera. En otras palabras, el valor p representa la probabilidad del llamado error Tipo I (o falso negativo), de rechazar la hipótesis nula cuando, en realidad, es cierta. Cuanto menor sea el valor de p , menor será la probabilidad de que la hipótesis nula sea cierta. Normalmente, el

hipótese nula é rejeitada se o valor- $p < 0.05$, que representa confiança estatística de 95% na hipótese alternativa.

Garcia e colaboradores [195] sugerem que os testes não paramétricos são mais indicados para avaliação de classificadores. O teste de Friedman, particularmente o chamado *Friedman aligned rank*, é recomendado quando um número relativamente pequeno de modelos (menor que cinco) são comparados. O teste ordena os resultados obtidos por cada modelo e utiliza as diferenças de ordem para o mesmo *benchmark* e as diferenças de ordem para o mesmo modelo em *benchmarks* diferentes [195].

Nesta seção, discutimos apenas os resultados do teste *Friedman aligned rank*. Uma discussão detalhada deste e outros métodos é feita por Garcia e colaboradores [195]. Os autores são do grupo de pesquisa responsável pelo desenvolvimento do *software* livre KEEL [9][10], utilizado para a realização dos testes. O *software* tem um módulo de testes não paramétricos, com várias opções de testes.

A Tabela 5.6 mostra os *rankings* de cada modelo, calculados pelo teste de Friedman a partir dos resultados da Tabela 5.5, e o valor- p correspondente a cada métrica de avaliação. O classificador calculado pelo discriminante linear de segunda ordem (M. Lin. 2) obteve o melhor *ranking* pelo teste de Friedman pelas duas métricas. O valor- p indica que as probabilidades de erro em considerar as diferenças significativas são, respectivamente, de 8,26% e 7,95% para as métricas de ACC e AUC.

Tabela 5.6: Resultados de teste *Friedman aligned rank*

	ACC	AUC
Bayes N	33.30	31.95
Bayes Q	28.55	23.80
Logit	26.45	31.25
M. Lin. 1	26.75	27.35
M. Lin. 2	12.45	13.15
Valor- p	0.0826	0.0795

O grande problema dos testes estatísticos é que, na grande maioria dos casos, não se pode ter 100% de certeza dos resultados. O que o teste estatístico mostra, com uma confiança estatística em torno de 92%, é que o modelo discriminante linear de segunda ordem apresenta um desempenho melhor que os demais. Esse resultado é coerente com o argumento teórico de que o MMQ é mais robusto que a estimativa de parâmetros

La hipótesis nula se rechaza si el valor es $-p < 0.05$, que representa un 95% de confianza estadística en la hipótesis alternativa.

García y colaboradores [195] sugieren que las pruebas no paramétricas son más adecuadas para evaluar clasificadores. La prueba de Friedman, particularmente la llamada *Friedman aligned rank*, se recomienda cuando se compara un número relativamente pequeño de modelos (menos de cinco). La prueba ordena los resultados obtenidos por cada modelo y utiliza las diferencias de orden para un mismo *benchmark* y las diferencias de orden para el mismo modelo en diferentes *benchmarks* [195].

En esta sección, analizamos únicamente los resultados de la prueba *Friedman aligned rank*. García y colegas [195] ofrecen una discusión detallada de este y otros métodos. Los autores pertenecen al grupo de investigación responsable del desarrollo del *software* KEEL [9][10] gratuito, utilizado para realizar las pruebas. *software* tiene un módulo de prueba no paramétrico, con varias opciones de prueba.

La Tabla 5.6 muestra el *rankings* de cada modelo, calculado mediante la prueba de Friedman a partir de los resultados de la Tabla 5.5, y el valor p correspondiente a cada métrica de evaluación. El clasificador calculado por el discriminante lineal de segundo orden (M. Lin. 2) obtuvo el mejor *ranking* mediante la prueba de Friedman para ambas métricas. El valor p indica que las probabilidades de error al considerar diferencias significativas son, respectivamente, 8,26 % y 7,95 % para las métricas ACC y AUC.

Tabla 5.6: *Friedman aligned rank* Resultados de la prueba

	ACC	AUC
Bayes N	33.30	31.95
Bayes Q	28.55	23.80
Logit	26.45	31.25
M. Lin. 1	26.75	27.35
M. Lin. 2	12.45	13.15
Valor- p	0.0826	0.0795

El gran problema de las pruebas estadísticas es que, en la gran mayoría de los casos, no se puede estar 100% seguro de los resultados. Lo que muestra la prueba estadística, con una confianza estadística de alrededor del 92%, es que el modelo discriminante lineal de segundo orden funciona mejor que los demás. Este resultado es consistente con el argumento teórico de que MMQ es más robusto que la estimación de parámetros.

do classificador bayesiano. O teste de hipóteses quantifica esse resultado, que não fica evidente observando-se apenas o melhor resultado de cada *benchmark* na Tabela 5.5.

5.4.2 Análise de cancelamento em telefonia

Empresas que operam em ambiente competitivo estão sempre preocupadas em promover a fidelização dos clientes de maior valor em sua base, uma vez que a manutenção de um cliente tem menor custo que a captação de novos clientes. Em empresas que oferecem serviços de assinatura, como telefonia e TV paga, um termo muito difundido é a taxa de *churn*,¹³⁴ que se refere ao percentual de cancelamentos de assinaturas num determinado período. O desenvolvimento de modelos preditivos de cancelamentos é uma das áreas de aplicação mais ativas de ciência de dados [422][530].

Um exemplo interessante de análise de cancelamentos num operador de telefonia foi apresentado por Cister [107]. A base de dados é uma amostra de clientes considerados de alto valor: empresas com média de quatro linhas móveis e alto consumo. A base de dados original é um conjunto de dados em três dimensões: 1.171 clientes, 10 variáveis de consumo e 12 meses. A amostra de dados foi realizada entre agosto de 2004 e julho de 2005 [107].

A análise apresentada nesta seção foi realizada sobre a média das variáveis de consumo por cliente, uma vez que as variáveis de consumo representavam o faturamento de cada tipo de ligação realizado pelo cliente durante o mês. Dessa forma, foi possível eliminar a dimensão de consumo e trabalhar com uma tabela de clientes por mês, que, após a retirada de 2,5% de *outliers*, ficou com 1.141 registros. Uma análise preliminar do gráfico de linhas aplicado às médias e desvios padrão de cada variável (Figura 5.19) revelou que o comportamento nos seis primeiros meses da amostra foi praticamente constante, não havendo interesse para o modelo de predição. Com isso, foram selecionadas as variáveis correspondentes aos seis últimos meses, assinaladas na Figura 5.19, em que a variável x_1 representa o consumo médio seis meses antes do final da amostra (fevereiro de 2005) e a variável x_6 representa o consumo médio no último mês do estudo (julho de 2005).

del clasificador bayesiano. La prueba de hipótesis cuantifica este resultado, que no es evidente al observar sólo el mejor resultado de cada *benchmark* en la Tabla 5.5.

5.4.2 Análisis de cancelación de telefonía

Las empresas que operan en un entorno competitivo siempre se preocupan por promover la lealtad entre los clientes de mayor valor de su base, ya que mantener un cliente es menos costoso que atraer nuevos clientes. En las empresas que ofrecen servicios de suscripción, como telefonía y televisión de pago, un término muy extendido es la tarifa *churn*,¹³⁴ que hace referencia al porcentaje de cancelaciones de suscripciones en un periodo determinado. El desarrollo de modelos de cancelación predictivos es una de las áreas de aplicación más activas de la ciencia de datos [422][530].

Cister [107] presentó un ejemplo interesante de análisis de cancelaciones en un operador telefónico. La base de datos es una muestra de clientes considerados de alto valor: empresas con una media de cuatro líneas móviles y alto consumo. La base de datos original es un conjunto de datos en tres dimensiones: 1.171 clientes, 10 variables de consumo y 12 meses. El muestreo de datos se llevó a cabo entre agosto de 2004 y julio de 2005 [107].

El análisis presentado en esta sección se realizó sobre el promedio de las variables de consumo por cliente, ya que las variables de consumo representaron los ingresos por cada tipo de llamada realizada por el cliente durante el mes. De esta manera se logró eliminar la dimensión de consumo y trabajar con una tabla de clientes por mes, que luego de quitar el 2,5% de *outliers* dejó 1.141 registros. Un análisis preliminar del gráfico de líneas aplicado a las medias y desviaciones estándar de cada variable (Figura 5.19) reveló que el comportamiento en los primeros seis meses de la muestra fue prácticamente constante, sin interés para el modelo de predicción. Con esto se seleccionaron las variables correspondientes a los últimos seis meses, como se muestra en la Figura 5.19, donde la variable x_1 representa el consumo promedio seis meses antes del final de la muestra (febrero de 2005) y la variable x_6 representa el consumo promedio en el último mes del estudio (julio de 2005).




Figura 5.19: Gráfico de linhas: médias e desvios padrão de cada variável por classe.

O objetivo do modelo é a predição dos clientes que abandonaram a companhia após o período da amostra. A classe C_1 representa os clientes que continuaram a assinatura e C_2 os clientes que cancelaram a assinatura que, nesse caso, é a classe de maior relevância. A Figura 5.19 mostra que o comportamento dos clientes que vieram a cancelar mudou consideravelmente a partir do nono mês da amostra, aumentando bruscamente e depois diminuindo até valores inferiores aos registrados até o mês oito. As causas dessa mudança de comportamento não foram divulgadas [107].

A Figura 5.20 mostra as principais características da base de dados. As distribuições das variáveis de consumo médio são razoavelmente assimétricas e as variáveis são bem correlacionadas entre si, à exceção da variável x_6 , que representa o consumo no último mês da amostra e que tem um comportamento bem diferente das demais variáveis.

Uma das principais características desse problema é o alto grau de desbalanceamento da base, uma vez que a classe dos clientes que cancelaram a assinatura (C_2) tem apenas 7,17% dos registros.

O objetivo nesta seção é avaliar os efeitos da ponderação para compensar o desbalanceamento das classes nos resultados dos modelos. Os modelos bayesianos e lineares discutidos na seção 5.4.1 foram utilizados na avaliação. Os modelos foram executados de duas formas: sem ponderação para compensar o efeito da probabilidade *a priori* e com ponderação. No caso dos modelos bayesianos, a ponderação corresponde a retirar o valor de probabilidade *a priori* do cálculo do valor de probabilidade *a posteriori*.




Figura 5.19: Gráfico de líneas: medias y desviaciones estándar de cada variable por clase.

El objetivo del modelo es la predicción de dos clientes que abandonarán la empresa después del período de demostración. La clase C_1 representa a los clientes que continuaron con su suscripción y a los clientes C_2 que cancelaron su suscripción, que, en este caso, es la clase más relevante. En el Gráfico 5.19 se muestra que el comportamiento de los clientes que cancelaron cambió considerablemente a partir del noveno mes de la muestra, aumentando fuertemente para luego disminuir a valores inferiores a los registrados hasta el octavo mes. Las causas de esta mudanza de comportamiento no fueron divulgadas [107].

A Figura 5.20 muestra las principales características de la base de datos. Las distribuciones de las variables de consumo medio son razonablemente asimétricas y las variables están bien correlacionadas entre sí, a excepción de la variable x_6 , que representa el consumo en el último mes de la muestra y que tiene un comportamiento muy diferente al resto de variables.

Una de las principales características de este problema es el alto grado de desequilibrio en la base de datos, ya que la clase de clientes que cancelaron su suscripción (C_2) tiene solo el 7,17% de los registros.

El objetivo de esta sección es evaluar los efectos de la ponderación para compensar el desequilibrio de clases en los resultados del modelo. Los modelos bayesianos y lineales discutidos en la sección 5.4.1 para el uso en la evaluación. Los modelos se ejecutaron de dos maneras: sin ponderación para compensar el efecto de la probabilidad *a priori* y con ponderación. En el caso de los modelos bayesianos, la ponderación corresponde a eliminar el valor de probabilidad *a priori* del cálculo del valor de probabilidad *a posteriori*.




Figura 5.20: Características da base de cancelamentos.

Os resultados de acurácia (ACC) e AUC são apresentados na Tabela 5.7, na qual os valores máximos de cada métrica em cada tipo de teste estão em negrito. Podemos observar que, em todos os modelos, a ponderação resultou em diminuição de ACC e aumento de AUC.

Tabela 5.7: Resultados dos modelos

Modelo	Bayes N		Bayes Q		M. Lin. 1		M. Lin. 2	
	ACC	AUC	ACC	AUC	ACC	AUC	ACC	AUC
S. Pond.	92.82	0.5119	96.41	0.8272	92.91	0.5179	94.40	0.6300
C. Pond.	90.63	0.7960	88.18	0.8814	85.29	0.8658	90.19	0.8868

Os gráficos de precisão e *recall* para cada modelo com e sem ponderação são mostrados na Figura 5.21, na qual a coluna da esquerda representa os resultados sem ponderação e a coluna da direita, os resultados com ponderação. Podemos observar que a ponderação aumenta a taxa de recuperação (*recall*) da classe minoritária C_2 em todos os modelos, que provoca o aumento de AUC.





Figura 5.20: Características de la base de cancelación.

Los resultados de precisión (ACC) y AUC se presentan en la Tabla 5.7, en la que los valores máximos para cada métrica en cada tipo de prueba están en negrita. Podemos observar que, en todos los modelos, la ponderación resultó en una disminución del ACC y un aumento del AUC.


Tabla 5.7: Resultados del modelo

Modelo	Bayes N		Bayes Q		M. Lin. 1		M. Lin. 2	
	ACC	AUC	ACC	AUC	ACC	AUC	ACC	AUC
S. Pond.	92.82	0.5119	96.41	0.8272	92.91	0.5179	94.40	0.6300
C. Pond.	90.63	0.7960	88.18	0.8814	85.29	0.8658	90.19	0.8868


La precisión y los gráficos *recall* para cada modelo con y sin ponderación se muestran en la Figura 5.21, donde la columna de la izquierda representa los resultados no ponderados y la columna de la derecha representa los resultados ponderados. Podemos observar que la ponderación aumenta la tasa de recuperación (*recall*) de la clase minoritaria C_2 en todos los modelos, lo que provoca un aumento en el AUC.




(a)




(b)




(c)




(d)




(e)



(f)




(g)




(h)


Figura 5.21: Precisão e *recall*, coluna da esquerda sem ponderação e coluna da direita com ponderação: (a) e (b) Bayes N; (c) e (d) Bayes Q; (e) e (f) M. Lin. 1; (g) e (h) M. Lin. 2.




(a)




(b)




(c)




(d)




(e)



(f)



(g)



(h)

Figura 5.21: Precisión y *recall*, columna izquierda sin ponderación y columna derecha con ponderación: (a) y (b) Bayes N; (c) y (d) Bayes Q; (e) y (f) M. Lin. 1; (g) y (h) M. Lin. 2.

Em problemas altamente desbalanceados como este, é importante utilizar as métricas adequadas para avaliação dos algoritmos. O classificador bayesiano simples e o modelo linear de primeira ordem, sem ponderação, obtiveram resultados de acurácia próximos à probabilidade *a priori* da classe majoritária C_1 (92,83%). Consequentemente, esses modelos obtiveram taxas de recuperação muito pequenas da classe minoritária C_2 que, neste exemplo, é a de maior relevância. Esse resultado foi identificado pelo valor de AUC próximo a 0.5 nos dois modelos.

5.5 Comentários Finais

O problema de reconhecimento de padrões é um problema clássico e há vários livros dedicados ao assunto [43][146][189][521][553]. É muito difícil condensar os tópicos mais importantes num único capítulo. O critério utilizado para a seleção dos assuntos apresentados foi a importância para a formulação do problema de classificação e a relevância para a fundamentação das técnicas de inteligência computacional que serão discutidas nos Capítulos 7, 8 e 9.

Alguns assuntos importantes não foram incluídos. Os modelos de árvore de decisão, por exemplo, que estão presentes em praticamente todos os livros de ciência de dados [232][516][561], não foram incluídos. Optou-se por uma fundamentação do problema de classificação baseada no teorema de Bayes. O leitor vai encontrar uma apresentação teórica completa dos modelos de classificação sob a ótica de aprendizado de máquina no excelente livro de Mitchel [392]. Uma discussão mais detalhada dos modelos de árvore de decisão é apresentada por Quinlan [446].

A formulação da regra de Bayes é bastante adequada para o entendimento do problema de classificação. Mesmo que o classificador não utilize diretamente o teorema de Bayes na sua formulação, os efeitos da probabilidade condicional e, principalmente, da probabilidade *a priori* estarão presentes em todo classificador que seja ajustado pela minimização do erro de classificação.

Nas redes bayesianas [121][125][247][263], a distribuição de probabilidades é definida para pares de variáveis selecionadas e o modelo é representado através de um grafo. O modelo de redes bayesianas busca um compromisso entre as propriedades teóricas do teorema de Bayes e a dificuldade de estimação de parâmetros em proble-

En problemas muy desequilibrados como este, es importante utilizar métricas adecuadas para evaluar los algoritmos. El clasificador bayesiano simple y el modelo lineal de primer orden, sin ponderación, obtuvieron resultados de precisión cercanos a la probabilidad *a priori* de la clase mayoritaria C_1 (92,83%). En consecuencia, estos modelos obtuvieron tasas de recuperación muy pequeñas de la clase minoritaria C_2 que, en este ejemplo, es la más relevante. Este resultado fue identificado por el valor de AUC cercano a 0,5 en ambos modelos.

5.5 Comentarios finales

El problema de reconocimiento de patrones es un problema clásico y existen varios libros dedicados al tema [43][146][189][521][553]. Es muy difícil condensar los temas más importantes en un solo capítulo. Los criterios utilizados para seleccionar los temas presentados fueron la importancia para la formulación del problema de clasificación y la relevancia para el fundamento de las técnicas de inteligencia computacional que se discutirán en los Capítulos 7, 8 y 9.

Algunos temas importantes no fueron incluidos. No se incluyeron los modelos de árboles de decisión, por ejemplo, que están presentes en prácticamente todos los libros de ciencia de datos [232][516][561]. Optamos por una justificación del problema de clasificación basada en el teorema de Bayes. El lector encontrará una presentación teórica completa de los modelos de clasificación desde la perspectiva del aprendizaje automático en el excelente libro de Mitchel [392]. Quinlan [446] presenta una discusión más detallada sobre los modelos de árboles de decisión.

La formulación de la regla de Bayes es bastante adecuada para comprender el problema de clasificación. Incluso si el clasificador no utiliza directamente el teorema de Bayes en su formulación, los efectos de la probabilidad condicional y, principalmente, de la probabilidad *a priori* estarán presentes en todo clasificador que se ajuste minimizando el error de clasificación.

En las redes bayesianas [121][125][247][263], la distribución de probabilidad se define para pares de variables seleccionadas y el modelo se representa mediante un gráfico. El modelo de red bayesiano busca un compromiso entre las propiedades teóricas del teorema de Bayes y la dificultad de estimar parámetros en problemas.

mas de alta dimensionalidade. Uma apresentação bastante completa do tema é encontrada no livro de Koller e Friedman [316] e no curso do Coursera.¹³⁵ A obtenção da estrutura do grafo não é tarefa trivial, embora existam algoritmos eficientes [125].

Em geral, para uma amostra de tamanho finito, o problema de identificar a distribuição de probabilidades do processo que gerou a amostra é mais complexo que encontrar uma função discriminante [98]. Dessa forma, os modelos de classificação mais modernos buscam diretamente encontrar a função discriminante com base nas observações disponíveis. A minimização do erro de classificação no conjunto de treinamento para um modelo de estrutura fixa é a abordagem mais comum. Nos modelos de máquina de vetor de suporte (SVM, na sigla em inglês) [478][532], o erro de classificação é limitado e o ajuste de parâmetros busca um modelo maximizando a margem de separação entre as classes, o que corresponde à minimização da estrutura do modelo. Esse tipo de modelo, que começou a se difundir na área de ciência de dados a partir de meados da década de 1990, será apresentado no Capítulo 7. Recentemente, redes neurais têm se destacado em problemas de classificação, principalmente em aplicações complexas como visão computacional e processamento de linguagem natural. As redes neurais serão apresentadas no Capítulo 9.

Há diversas abordagens para o tratamento de problemas desbalanceados na literatura [90][273]. A abordagem mais comum é a reamostragem de dados para compensar o desbalanceamento. O algoritmo SMOTE [89] realiza essa abordagem de forma eficiente e os resultados são bastante satisfatórios, principalmente quando utilizado com um modelo de árvore de decisão.

A avaliação de algoritmos por testes estatísticos não paramétricos tem se difundido nas áreas de inteligência computacional e ciência de dados [195]. Entretanto, é importante observar que o desempenho de um algoritmo sobre um conjunto de testes *benchmark* vale apenas para aquele conjunto e não significa que o algoritmo terá um desempenho melhor em todos os problemas. Na prática, a melhor abordagem é sempre a busca do melhor desempenho para o problema em questão, evitando alguma preferência *ad hoc* sobre um tipo particular de modelo.

pero de alta dimensionalidad. Una presentación muy completa del tema se encuentra en el libro de Koller y Friedman [316] y en el curso de Coursera.¹³⁵ Obtener la estructura del grafo no es una tarea trivial, aunque existen algoritmos eficientes [125].

En general, para una muestra de tamaño finito, el problema de identificar la distribución de probabilidad del proceso que generó la muestra es más complejo que encontrar una función discriminante [98]. Por tanto, la mayoría de los modelos de clasificación modernos buscan directamente encontrar la función discriminante basándose en las observaciones disponibles. Minimizar el error de clasificación en el conjunto de entrenamiento para un modelo de estructura fija es el enfoque más común. En los modelos de máquina de vectores de soporte (SVM) [478][532], el error de clasificación es limitado y el ajuste de parámetros busca un modelo que maximice el margen de separación entre clases, lo que corresponde a minimizar la estructura del modelo. Este tipo de modelo, que comenzó a difundirse en el área de la ciencia de datos a partir de mediados de los años 1990, se presentará en el Capítulo 7. Recientemente, las redes neuronales han destacado en problemas de clasificación, especialmente en aplicaciones complejas como la visión por computadora y el procesamiento del lenguaje natural. Las redes neuronales se presentarán en el Capítulo 9.

Existen varios enfoques para tratar los problemas de desequilibrio en la literatura [90][273]. El enfoque más común es volver a muestrear los datos para compensar el desequilibrio. El algoritmo SMOTE [89] realiza este enfoque de manera eficiente y los resultados son bastante satisfactorios, especialmente cuando se usa con un modelo de árbol de decisión.

La evaluación de algoritmos mediante pruebas estadísticas no paramétricas se ha generalizado en las áreas de inteligencia computacional y ciencia de datos [195]. Sin embargo, es importante tener en cuenta que el rendimiento de un algoritmo en un conjunto de pruebas *benchmark* solo se aplica a ese conjunto de pruebas y no significa que el algoritmo funcionará mejor en todos los problemas. En la práctica, el mejor enfoque es siempre buscar el mejor rendimiento para el problema en cuestión, evitando cualquier preferencia *ad hoc* sobre un tipo particular de modelo.