

5 CLASIFICACIÓN

El objetivo de la clasificación supervisada, o simplemente clasificación, es el desarrollo de un clasificador, es decir, un modelo capaz de predecir la clase correcta de un registro en función de los valores de las variables de entrada. La clasificación puede entenderse como un problema de decisión en el que se elige una clase según los valores de los atributos del problema, que son las variables de entrada.

Un modelo de clasificación divide explícita o implícitamente el espacio de las variables de entrada en regiones asociadas con clases. La frontera entre regiones se llama superficie de decisión. La predicción de clase se realiza marcando la región correspondiente al registro que se desea clasificar. En problemas reales, registros con valores similares de variables de entrada pueden pertenecer a clases diferentes debido al efecto de variables no observadas, ruido, etc. Este tipo de registro se trata como un error de clasificación y el modelo se ajusta para minimizar este error. En algunos casos, llamados desequilibrados, las clases no tienen el mismo número de registros, lo que puede llevar al modelo a realizar predicciones sesgadas.

Este capítulo presenta el problema de clasificación basado en la teoría de decisión bayesiana, que permite una formalización matemáticamente simple y muy informativa de las principales características del problema. A continuación, presentamos el método discriminante lineal en el que la clasificación se trata como un problema de predicción análogo a la regresión lineal y al modelo de regresión logística, bien conocido en la literatura. Este capítulo también presenta las estadísticas más utilizadas para evaluar la calidad del modelo de clasificación y algunos ejemplos de aplicación.

5.1 Clasificación bayesiana

El teorema (o regla) de Bayes¹¹⁵ fue creado por el pastor Thomas Bayes y publicado en 1764, después de su muerte, por su amigo y filósofo Richard Price. El teorema de Bayes introduce la interpretación bayesiana de la probabilidad como una medida del “grado de conocimiento” sobre un evento en contraste con la interpretación basada en la frecuencia que mide la propensión de un evento a ocurrir.

La presentación del teorema de Bayes en esta sección se centra en el problema de clasificación y utiliza una notación que resalta los valores de probabilidad en función de las variables del problema.

5.1.1 Decisión bayesiana

El problema de clasificación es esencialmente una decisión, ya que se debe elegir una de las clases en función de los valores de las variables de entrada. La toma de decisiones en el problema de clasificación puede formalizarse mediante el teorema de Bayes [146][521], que relaciona el conocimiento previo del problema en la forma:

$$P(C_i|\mathbf{x}) = \frac{p(\mathbf{x}|C_i)P(C_i)}{p(\mathbf{x})} \quad (5.1)$$

donde $P(C_i|\mathbf{x})$ es la probabilidad de observar la clase C_i conociendo la observación (evidencia) de los valores de las variables $\mathbf{x}$, llamada probabilidad **a posteriori**; $p(\mathbf{x}|C_i)$ representa la distribución de probabilidad de las variables $\mathbf{x}$ cuando la clase observada es C_i , llamada distribución de probabilidad condicional*; y $P(C_i)$ es la probabilidad de ocurrencia de la clase C_i en ausencia de cualquier observación, llamada probabilidad **a priori**. El denominador $p(\mathbf{x}) = \sum_{i=1}^m p(\mathbf{x}|C_i)P(C_i)$ es la probabilidad de observar valores de las variables $\mathbf{x}$, el cual funciona como factor de estandarización para que el resultado quede en el intervalo [0,1].

La ecuación (5.1) muestra de manera sencilla cómo cambia la probabilidad de un evento mediante el conocimiento de la evidencia relacionada. El teorema de Bayes realiza una “inversión” del conocimiento representado por la probabilidad condicional, lo que muestra el razonamiento abductivo¹¹⁶ del problema de clasificación.

* Adoptamos la notación con p minúsculo para representar una función distribución de probabilidades y P mayúsculo para representar un valor de probabilidades.

Consideremos, por ejemplo, el razonamiento de un médico para diagnosticar una enfermedad basándose en los síntomas observados. El resultado del diagnóstico está determinado por la probabilidad *a posteriori*, es decir, el médico elegirá, entre las hipótesis plausibles para la condición observada, la que considere más probable. El conocimiento del médico está representado por la probabilidad condicional que establece la probabilidad de observar un conjunto de síntomas x ante la presencia de alguna enfermedad C_i . La probabilidad *a priori* influye en la decisión del médico, quien al observar los mismos síntomas tenderá a decidirse por la enfermedad más común.

La interpretación de la ecuación (5.1) en el contexto del problema de clasificación proporciona los elementos para la correcta comprensión de las características del problema y sirve para el desarrollo de modelos de clasificación.

Consideremos un ejemplo simple, con solo una variable de entrada y dos clases. Inicialmente, supongamos que las dos clases ocurren con la misma frecuencia, es decir, tienen la misma probabilidad *a priori* $P(C_1) = P(C_2) = 0.5$. Consideremos también que las dos clases tienen una distribución de probabilidad condicional normal $N(\mu, \sigma)$ de media μ y desviación estándar σ . Para el ejemplo que se analiza a continuación, se utilizaron las distribuciones $p(x|C_1) = N(2.5, 2.5)$ y $p(x|C_2) = N(-1.5, 2.0)$.

La distribución de probabilidad condicional para cada una de las clases y los valores de probabilidad *a posteriori* calculados mediante la regla de Bayes se muestran en la Figura 5.1. La función de probabilidad condicional $p(x|C_i)$ informa la probabilidad de observar un valor x sabiendo que la clase es C_i . En el ejemplo, la media de la distribución $p(x|C_1)$ es mayor que la media de $p(x|C_2)$.




Figura 5.1: Regla de Bayes: (a) probabilidad condicional; (b) probabilidad *a posteriori*.

En el clasificador bayesiano, el resultado del problema de clasificación se obtiene mediante una regla de decisión, definida sobre los valores de probabilidad *a posteriori* de las clases c calculadas por el teorema de Bayes.

5.1.1.1 Decisão pelo mínimo erro de classificação

La decisión más simple para la clasificación bayesiana se toma por el valor de probabilidad máxima *a posteriori*, que resulta en dividir el espacio de variables de entrada en dos regiones, cada una asociada con una de las clases, de la siguiente manera:

$$\begin{aligned}\mathcal{R}_1 &= \{x \in \mathcal{R}, P(C_1|x) \geq P(C_2|x)\} \\ \mathcal{R}_2 &= \{x \in \mathcal{R}, P(C_2|x) > P(C_1|x)\}\end{aligned}\tag{5.2}$$

La Figura 5.1a muestra que los valores de la variable en la región de superposición de las funciones de densidad condicionales pueden pertenecer simultáneamente a dos clases con diferentes probabilidades. Por tanto, considerando esta única variable, habrá un error de clasificación, calculado por la probabilidad de clasificación incorrecta como:

$$P(E) = \int_{\mathcal{R}_1} p(x|C_2)P(C_2)dx + \int_{\mathcal{R}_2} p(x|C_1)P(C_1)dx\tag{5.3}$$

El primer término a la derecha de la ecuación (5.3) representa el porcentaje de registros de la clase C_2 que se clasificarán como C_1 porque están en la región R_1 . De manera similar, el segundo término representa el porcentaje de registros de la clase C_1 que se clasificarán como C_2 . El resultado de la ecuación (5.3) para el ejemplo de la Figura 5.1 se muestra en la Figura 5.2, en la que las distribuciones condicionales $p(x|C_i)$ se muestran en líneas discontinuas y las distribuciones $p(x|C_i)P(C_i)$, en líneas continuas.




Figura 5.2: Probabilidad de clasificación errónea.

Es fácil demostrar que la clasificación realizada por las regiones $\mathcal{R}_1$ y $\mathcal{R}_2$ definidas en las ecuaciones (5.2) minimiza el error definido por la ecuación (5.3) [521]. Observando la Figura 5.2, una regla de decisión diferente a (5.2) da como resultado un aumento en el área correspondiente a la ecuación (5.3), es decir, en la probabilidad de error de clasificación.

Las regiones asociadas con las clases por la regla de decisión (5.2) serían las mismas si la decisión se tomara directamente sobre la función de distribución condicional, ya que, en el ejemplo de la Figura 5.2, las clases son equiprobables. Cuando la frecuencia relativa de las clases es diferente, este resultado no es válido y la región de la clase más frecuente aumenta en relación con la de la menos frecuente para reflejar el efecto de las clases más frecuentes. La figura 5.3 muestra el resultado de la probabilidad *a posteriori* cuando las probabilidades *a priori* son diferentes. Observe el desplazamiento del punto de decisión con respecto al punto de intersección de las distribuciones de probabilidad condicional.

En el punto de decisión, es decir, en el valor límite entre las regiones $\mathcal{R}_1$ y $\mathcal{R}_2$, los valores de probabilidad *a posteriori* son iguales a $p(x|C_1)P(C_1) = p(x|C_2)P(C_2)$. De esta manera podemos escribir:

$$\frac{p(x|C_1)}{p(x|C_2)} = \frac{P(C_2)}{P(C_1)} \quad (5.4)$$




Figura 5.3: Regla de Bayes: (a) $P(C_1) > P(C_2)$; (b) $P(C_2) > P(C_1)$.

La ecuación (5.4) muestra que, en el caso de problemas desequilibrados, la superficie de decisión se obtiene cuando la probabilidad condicional de la clase menos frecuente excede la probabilidad condicional de la más frecuente por la misma razón del cociente de probabilidad *a priori*.

5.1.1.2 Decisão pelo mínimo risco condicional

En el problema de dos clases en las que una se considera positiva y la otra negativa, el resultado de un modelo de clasificación se puede presentar mediante la matriz de confusión de la Tabla 5.1. El resultado se denomina verdadero positivo (VP) cuando el modelo predice correctamente la clase positiva o verdadero negativo (VN) cuando la clase negativa se predice correctamente. Los errores de clasificación ocurren de dos maneras: si se predice la clase positiva cuando la clase observada es negativa, el resultado es un falso positivo (FP) (o error de Tipo I en la nomenclatura de las pruebas de hipótesis); El falso negativo (FN) (o error de tipo II) ocurre si la clase negativa se predice cuando la clase observada es positiva.

Tabla 5.1: Matriz de confusión

	C_1 Predita	C_2 Predita
C_1 Real	VP	FN
C_2 Real	FP	VN

La matriz de confusión también se utilizará en la sección 5.3 para evaluar clasificadores. En esta sección se utiliza la matriz de confusión para presentar el concepto de riesgo de clasificación errónea.

En muchas aplicaciones, especialmente cuando las clases están desequilibradas, el costo de una clasificación errónea es diferente según el tipo de error. Consideremos, por ejemplo, un problema de diagnóstico médico basado en un examen en el que la clase positiva representa la presencia de una determinada enfermedad grave. El error FP consiste en alarmar innecesariamente al paciente, mientras que el error FN puede tener un impacto importante en el tratamiento al retrasar la detección de la enfermedad. Considerando que la probabilidad *a priori* de los pacientes sanos es mayor que la de los pacientes con la enfermedad, la clasificación realizada según la regla (5.2) sólo detectaría la enfermedad en los casos en los que la evidencia sea muy fuerte.

El formalismo de decisión bayesiano permite representar el costo asociado a cada decisión. El riesgo condicional asociado con la elección de una clase C_i a partir de la observación de la evidencia $\mathbf{x}$ se escribe como [146]:

$$R(C_i|\mathbf{x}) = \sum_{j=1}^m \lambda_{ij}P(C_j|\mathbf{x}) \quad (5.5)$$

donde λ_{ij} es el costo asociado con la elección de la clase C_i cuando la clase correcta es C_j .

En el caso del problema de dos clases considerado anteriormente, el riesgo condicional asociado con cada clase se calcula como:

$$\begin{aligned} R(C_1|x) &= \lambda_{11}P(C_1|x) + \lambda_{12}P(C_2|x) \\ R(C_2|x) &= \lambda_{21}P(C_1|x) + \lambda_{22}P(C_2|x) \end{aligned} \quad (5.6)$$

La decisión se calcula según el riesgo condicional más bajo, que no es una probabilidad. Considerando el riesgo nulo de clasificación correcta, $\lambda_{11} = \lambda_{22} = 0$, las regiones asociadas a las clases se calculan como:

$$\begin{aligned} \mathcal{R}_1 &= \{x \in \mathcal{R}, \lambda_{21}P(C_1|x) \geq \lambda_{12}P(C_2|x)\} \\ \mathcal{R}_2 &= \{x \in \mathcal{R}, \lambda_{12}P(C_2|x) > \lambda_{21}P(C_1|x)\} \end{aligned} \quad (5.7)$$

La Figura 5.4 muestra la diferencia en la decisión de clasificación calculada a partir del valor de las probabilidades *a posteriori* (ver ecuaciones (5.2)) o del riesgo condicional (ver ecuaciones (5.7)). En el ejemplo, las clases se consideraron equiprobables para facilitar la interpretación. En la Figura 5.4, las líneas discontinuas representan la distribución de los valores de probabilidad *a posteriori* y las líneas continuas representan los valores de riesgo de clasificación incorrecta calculados mediante la ecuación (5.6).




Figura 5.4: Decisión por clasificación de riesgo: (a) $\lambda_{12} > \lambda_{21}$; (b) $\lambda_{21} > \lambda_{12}$.

Cuando el costo de una clasificación incorrecta $\lambda_{12} > \lambda_{21}$, es decir, el error a favor de la clase C_1 es más grave, la región $\mathcal{R}_1$ calculada minimizando el riesgo condicional (cf. ecuaciones (5.7)) es menor que la correspondiente calculada minimizando el error de clasificación (cf. ecuaciones (5.2)). De esta manera, el límite de decisión se desplaza para reducir la región asociada con la clase con el mayor costo de clasificación incorrecta. De lo contrario, cuando $\lambda_{21} > \lambda_{12}$, el límite de decisión se desplaza a favor de la clase C_1 ya que el costo de clasificar erróneamente esta clase es menor.

El error de clasificación calculado por la ecuación (5.3) es mayor si la decisión se toma en base al riesgo condicional, ya que la decisión basada en la probabilidad *a posteriori* es la que minimiza el error de clasificación. Sin embargo, aunque el error es mayor en general, será menor en la clase con el mayor coste de clasificación errónea.

La aplicación de la decisión de riesgo mínimo condicional depende de estimaciones de los valores de costos λ_{ij} . En problemas donde el costo se puede cuantificar, los parámetros se definen fácilmente. Sin embargo, en la mayoría de los casos, los costos no se pueden especificar directamente y los valores se estiman de forma *ad hoc*. En problemas de desequilibrio, los costos de clasificación errónea se pueden calcular para compensar el efecto del desequilibrio.

El formalismo de clasificación bayesiano se aplica directamente a dos modelos de clasificación que se presentan a continuación.

5.1.2 Clasificador bayesiano simple

En el problema de clasificación se utiliza el conjunto de datos $\mathcal{T} = \{(\mathbf{x}(t), y(t)), t = 1 \dots N\}$, donde cada registro t está formado por pares ordenados $(\mathbf{x}(t), y(t))$, siendo $\mathbf{x}(t) \in \mathcal{R}^p$ el vector de variables de entrada y la variable de salida $y(t) \in \mathcal{N}$, donde el valor $y(t) = j$ asocia el registro t con la clase $C_j, j = 1, \dots, m$. Es importante señalar que los índices no representan una relación de orden entre clases, solo facilitan la representación de clases de forma simbólica.

El clasificador bayesiano utiliza directamente la regla de Bayes (5.1) para calcular la probabilidad *a posteriori* y toma la decisión de una de las formas presentadas anteriormente, generalmente utilizando el error de clasificación mínimo. En el clasificador bayesiano simple o ingenuo (*naïf*), la distribución de probabilidad condicional de los registros

del conjunto de entrenamiento se calcula, para cada clase, mediante una estimación que considera las variables de entrada independientes. Así, el clasificador bayesiano simple no tiene en cuenta la covarianza entre variables y la distribución de probabilidad condicional conjunta para cada clase se calcula como:

$$p(\mathbf{x}(t)|C_j) = \prod_{i=1}^p p(x_i(t)|C_j), \quad j = 1, \dots, m \quad (5.8)$$

En el modelo más común, la probabilidad condicional de cada variable se estima como una distribución normal monovariante $p(x_i(t)|C_j) \approx N(\hat{\mu}_{ij}, \hat{\sigma}_{ij}^2)$. Los parámetros media $\hat{\mu}_{ij}$ y varianza $\hat{\sigma}_{ij}^2$ se estiman en el conjunto de entrenamiento como la media y varianza de la variable $x_i(t)$ en los registros de clase C_j . Hay variantes que utilizan otros modelos de distribución condicional.¹¹⁷

El supuesto de independencia entre las variables de entrada reduce considerablemente el número de parámetros que debe ajustar el clasificador. La estimación de la matriz de covarianza de la distribución normal multivariada (cf. ecuación (2.6)) requiere $p(p + 1)/2$ parámetros para cada clase, lo que da como resultado un total de $p + p(p + 1)/2$ parámetros, incluidas las medias. En el clasificador bayesiano simple, el supuesto de independencia reduce el número de parámetros que se ajustarán a solo $2p$ para cada clase.

El ajuste de parámetros del clasificador bayesiano simple es muy eficiente. Para cada clase, para cada variable, se calcula la media estimada $\hat{\mu}_{ij}$ y la varianza $\hat{\sigma}_{ij}^2$ -si la variable es numérica- o directamente la frecuencia de cada valor nominal -cuando la variable es categórica-. La probabilidad *a priori* también se calcula directamente a partir de la frecuencia de clase.

En la evaluación, el resultado del clasificador bayesiano simple es la probabilidad *a posteriori*, calculada directamente mediante el teorema de Bayes (cf. ecuación (5.1)), donde la probabilidad condicional conjunta se calcula mediante la ecuación (5.8). La decisión de clasificación se puede tomar utilizando la regla de mínimo error de clasificación o riesgo mínimo.

La Figura 5.5a muestra un ejemplo sintético de un problema linealmente separable en $p = 2$ dimensiones. La Figura 5.5b presenta la superficie de decisión y las regiones asociadas con cada clase por el valor de probabilidad máxima *a posteriori*. Las Figuras 5.5c y 5.5d muestran, respectivamente, las distribuciones de probabilidad condicional normal ajustadas para cada una de las variables. Podemos ver que, a pesar de existir una correlación

entre las variables, la diferencia en las medias de las distribuciones de probabilidad condicional permite ajustar un clasificador capaz de generar una superficie de decisión eficiente.




Figura 5.5: Problema linealmente separable: (a) Conjunto de entrenamiento; (b) superficie de decisión; (c) distribución $p(x_1|C_j)$; (d) distribución $p(x_2|C_j)$.

La “economía” de parámetros y la simplicidad del clasificador bayesiano simple tienen efectos en su desempeño. La Figura 5.6a muestra un ejemplo ligeramente más complejo, en el que las clases no pueden separarse mediante una superficie lineal; por lo tanto, se las denomina separables no linealmente. En este caso, la superficie de decisión generada por el clasificador bayesiano simple, que se muestra en la Figura 5.6b, no permite separar las dos clases. El resultado se puede entender observando las distribuciones condicionales de las Figuras 5.6c y 5.6d, que muestran que la proyección de los datos en cada variable da como resultado valores similares de las medias y varianzas de las clases y, por lo tanto, la distribución conjunta de las dos clases es muy similar, de modo que la superficie de decisión generada no es eficiente para separarlas.




Figura 5.6: Problema separable no linealmente: (a) conjunto de entrenamiento;
 (b) superficie de decisi3n; (c) distribuci3n $p(x_1|C_j)$; (d) distribuci3n $p(x_2|C_j)$.

La distribuci3n normal no es adecuada para representar la distribuci3n de datos para cada clase en el ejemplo de la Figura 5.6a. Sin embargo, el principal problema es que el clasificador bayesiano simple no es capaz de capturar la correlaci3n entre las variables en el conjunto de datos de cada clase. La Figura 5.7a muestra el mismo conjunto de datos que la Figura 5.6a despu3s de la transformaci3n realizada por an3lisis de componentes principales (PCA), que elimina la correlaci3n entre las variables. En este caso, el clasificador bayesiano es capaz de separar las clases (cf. Figura 5.7b), incluso si la distribuci3n normal no es la mejor representaci3n de la distribuci3n de clases, como se puede ver en las Figuras 5.7c y 5.7d. En este caso, la diferencia de varianzas de las distribuciones de probabilidad condicional permite generar una superficie de decisi3n correcta.




Figura 5.7: Problema transformado por PCA: (a) conjunto de entrenamiento; (b) superficie de decisión; (c) distribución $p(x_1|C_j)$; (d) distribución $p(x_2|C_j)$.

Usar PCA para eliminar la correlación de datos no siempre produce buenos resultados, pero es un recurso que puede usarse en la búsqueda del mejor modelo de clasificación. En la sección 5.4.1, los resultados del clasificador bayesiano simple se comparan con los resultados de otros clasificadores presentados en este capítulo.

El clasificador bayesiano simple es un clasificador computacionalmente eficiente que se puede aplicar a problemas de grandes dimensiones y permite combinar fácilmente variables numéricas y categóricas. Un clasificador bayesiano simple puede acomodar fácilmente los valores faltantes en la evaluación, lo cual es un problema en muchos otros tipos de clasificadores. El algoritmo básico, con algunas variaciones, se puede encontrar prácticamente en todas las ciencias de datos *softwares*. A pesar de su rendimiento regular, el clasificador bayesiano tiene muchas aplicaciones en ciencia de datos [289], habiendo demostrado ser útil en la clasificación de documentos, en *spam*

[115] y en análisis de sentimiento [348][427]. El buen desempeño del clasificador baseyiano o simple también lo califica para su uso en *ensembles* [325], que combina los resultados de varios modelos simples para mejorar el desempeño del clasificador.

En conjuntos de datos con registros suficientes para estimar distribuciones de probabilidad condicional conjuntas, es posible utilizarlos en la síntesis de clasificadores, como se describe a continuación.

5.1.3 Clasificador bayesiano cuadrático

Un clasificador predice la clase de un nuevo registro en función de su ubicación en relación con las regiones asociadas con las clases. En el caso de un problema con las clases m , el resultado del clasificador dividirá el dominio de las variables de entrada en regiones m . Es posible generalizar reglas de decisión como (5.2) y (5.7) definiendo funciones discriminantes en problemas de clases múltiples. La clasificación se realiza por el valor máximo de la función discriminante como:

$$\mathbf{x}(t) \in C_i \rightarrow g_i(\mathbf{x}(t)) > g_j(\mathbf{x}(t)), \quad j = 1, \dots, m \quad (5.9)$$

En el clasificador bayesiano la función discriminante se puede calcular directamente como $g_i(\mathbf{x}(t)) = P(C_i|\mathbf{x}(t))$ en el caso de minimizar la probabilidad de clasificación incorrecta o como $g_i(\mathbf{x}(t)) = -R(C_i|\mathbf{x}(t))$ en el caso de minimizar el riesgo condicional, donde $R(C_i|\mathbf{x}(t))$ se define en (5.5) y el signo negativo es para mantener coherencia con la ecuación (5.9), ya que la decisión se toma en base al menor riesgo de clasificación. La elección de la función discriminante no es única y cualquier función monótonamente creciente de una función discriminante $f(g_i(\mathbf{x}(t)))$ también es una función discriminante.

La cuestión fundamental para la síntesis de un clasificador bayesiano es la elección de la función de distribución de probabilidad condicional. En el clasificador bayesiano simple, el supuesto de independencia da como resultado un clasificador computacionalmente eficiente, pero con una precisión regular. El rendimiento del clasificador puede mejorar significativamente si se estima mejor la distribución condicional. Existen métodos estadísticos, paramétricos y no paramétricos, para estimar una función de distribución condicional [553]. El enfoque clásico consiste en utilizar la distribución normal multivariada como una aproximación de la distribución condicional.

La hipótesis de que la probabilidad condicional es una distribución normal permite definir el clasificador bayesiano cuadrático [146][405], cuya función discriminante para la decisión de minimizar el error de clasificación se calcula como:

$$g_i(\mathbf{x}(t)) = \ln P(C_i|\mathbf{x}(t)) = \ln p(\mathbf{x}(t)|C_i) + \ln P(C_i), \quad i = 1, \dots, m \quad (5.10)$$

donde $p(\mathbf{x}(t)|C_i) = N(\hat{\boldsymbol{\mu}}_i, \hat{\boldsymbol{\Sigma}}_i)$ es la distribución normal multivariada de las medias $\hat{\boldsymbol{\mu}}_i$ y la matriz de covarianza $\hat{\boldsymbol{\Sigma}}_i$ estimada a partir de los registros de clase C_i .

Sustituyendo la expresión de la distribución normal multivariada en la ecuación (5.10):

$$g_i(\mathbf{x}(t)) = -\frac{1}{2}(\mathbf{x}(t) - \hat{\boldsymbol{\mu}}_i)\hat{\boldsymbol{\Sigma}}_i^{-1}(\mathbf{x}(t) - \hat{\boldsymbol{\mu}}_i)^T - \frac{1}{2}\ln 2\pi - \frac{1}{2}\ln|\hat{\boldsymbol{\Sigma}}_i| + \ln P(C_i) \quad (5.11)$$

El término $-\frac{1}{2}\ln 2\pi$ es el mismo para todas las clases y, por tanto, no influye en la función discriminante y puede eliminarse.

La expresión de la función discriminante calculada por la ecuación (5.11) está dominada por un término cuadrático y, por lo tanto, el clasificador bayesiano con distribuciones normales multivariadas se denomina clasificador bayesiano cuadrático. La Figura 5.8 muestra dos ejemplos sintéticos de clases generadas por variables distribuidas normalmente y la superficie de decisión calculada por la función discriminante (5.11).




Figura 5.8: Ejemplos de superficies de decisión cuadráticas.

El resultado del clasificador bayesiano cuadrático sobre el conjunto de datos de la Figura 5.6 se muestra en la Figura 5.9, en la que podemos observar que la función discriminante es eficiente para la separación de clases.




Figura 5.9: Problema separable no linealmente: (a) conjunto de entrenamiento; (b) superficie de decisi3n por el clasificador bayesiano cuadr3tico.

Estimar los par3metros de la ecuaci3n normal para calcular la funci3n discriminante como (5.11) puede volverse inviable en problemas de alta dimensi3n, ya que se requieren $p + p(p + 1)/2$ par3metros para cada clase. Considere, por ejemplo, el conjunto de datos *Wine*, con $p = 13$ variables de entrada, lo que da como resultado 104 par3metros que se estimar3n para cada clase. El conjunto de datos contiene solo 178 registros, de los cuales 59 son de la clase C_1 , 71 de la clase C_2 y 48 de la clase C_3 , lo que perjudica las estimaciones de la matriz de media y covarianza.

En problemas de alta dimensi3n con un n3mero reducido de registros, es posible utilizar la reducci3n de dimensionalidad producida por transformaciones lineales como PCA y ADL (an3lisis discriminante lineal). Al aplicar ADL al conjunto de datos *Wine*, el n3mero de variables se reduce a $\hat{p} = m - 1 = 2$, lo que significa estimar solo tres par3metros para la media y la matriz de covarianza. La Figura 5.10 presenta el resultado de la superficie de decisi3n calculada por el clasificador bayesiano cuadr3tico sobre el conjunto de datos *Wine* 2D, obtenido despu3s de la transformaci3n ADL del conjunto de datos *Wine*. Podemos observar el contorno cuadr3tico de las funciones discriminantes de cada clase.




Figura 5.10: *Wine* Conjunto de datos 2D: (a) conjunto de entrenamiento; (b) superficie de decisión por el clasificador bayesiano cuadrático.

El clasificador bayesiano con distribuciones normales multivariadas genera una función discriminante lineal cuando la matriz de covarianza es la misma para todas las clases y se estima como la matriz de covarianza de los datos, es decir, $\hat{\Sigma}_i = \hat{\Sigma}$, $i = 1, \dots, m$. En este caso, el término cuadrático de la ecuación (5.11) puede ignorarse (ya que es el mismo para todas las clases) y la función discriminante se escribe como:

$$g_i(\mathbf{x}(t)) = \mathbf{x}(t)\hat{\Sigma}^{-1}\hat{\boldsymbol{\mu}}_i^T - \frac{1}{2}\hat{\boldsymbol{\mu}}_i\hat{\Sigma}^{-1}\hat{\boldsymbol{\mu}}_i^T + \ln P(C_i) \quad (5.12)$$

La ecuación (5.12) se puede escribir en forma de función lineal como:

$$g_i(\mathbf{x}(t)) = \hat{\mathbf{x}}(t)\boldsymbol{\theta}_i^T \quad (5.13)$$

donde $\hat{\mathbf{x}}(t) = [1, \mathbf{x}(t)]$ es el vector de regresores y $\boldsymbol{\theta}_i = [\theta_{i0}, \boldsymbol{\theta}_{i1}]$ es el vector de parámetros, cuyos componentes $\theta_{i0} = -\frac{1}{2}\hat{\boldsymbol{\mu}}_i\hat{\Sigma}^{-1}\hat{\boldsymbol{\mu}}_i^T + \ln P(C_i)$ y $\boldsymbol{\theta}_{i1} = \hat{\Sigma}^{-1}\hat{\boldsymbol{\mu}}_i^T$.

El clasificador bayesiano lineal no requiere estimar un número considerable de parámetros, ya que solo se estima una matriz de covarianza para todas las clases. Sin embargo, en la práctica, el rendimiento puede ser peor que el del clasificador bayesiano simple.

Desde un punto de vista conceptual, la ecuación (5.13) muestra que un clasificador puede estimarse directamente por su función discriminante, sin necesidad de hipótesis sobre la función de distribución de probabilidad condicional. De esta manera, se pueden aplicar modelos lineales a la clasificación, como se presenta a continuación.

5.2 Modelos de clasificación lineal

La ecuación (5.13) muestra que se puede utilizar un modelo lineal para aproximar la función discriminante en un problema de clasificación. Por lo tanto, los problemas de clasificación y regresión son similares y sólo difieren en el tipo de variable de salida.

La síntesis del clasificador se puede realizar directamente ajustando los parámetros de un modelo lineal utilizando el método de mínimos cuadrados (MMQ), como se presenta en las secciones 5.2.1 y 5.2.2. Sin embargo, un modelo lineal no permite interpretar la función discriminante como un valor de probabilidad. En la regresión logística, presentada en la sección 5.2.3, el resultado del modelo lineal se transforma mediante una función exponencial que permite interpretar el resultado como un valor de probabilidad.

5.2.1 Mínimos cuadrados

El ajuste de parámetros del modelo lineal se realiza a partir del conjunto de entrenamiento $\mathcal{T} = \{(\mathbf{x}(t), y(t)), t = 1 \dots N\}$, donde $\mathbf{x}(t) \in \mathcal{R}^p$ es el vector de variables de entrada y la salida $y(t) \in \mathcal{N}$ es el índice de clase.

Para ajustar la función discriminante, la variable de salida se transforma para reflejar el resultado de la función discriminante en (5.9). Esta transformación se realiza definiendo una variable indicadora ("dummy") bipolar $v_i(t) \in \{-1, 1\}$, como por ejemplo: *

$$v_i(t) = \begin{cases} +1, & \text{se } y(t) = i \\ -1, & \text{se } y(t) \neq i \end{cases} \quad i = 1, \dots, m \quad (5.14)$$

El vector $\mathbf{v}(t) \in \{-1, 1\}^m$ se denomina vector de variables indicadoras, ya que la posición del valor 1 en el vector indica la clase a la que pertenece el registro.

Las funciones discriminantes son calculadas por el modelo lineal como aproximaciones de las variables indicadoras como:

$$\hat{v}_i(t) = g_i(\mathbf{x}(t), \boldsymbol{\theta}_i) = \hat{\mathbf{x}}(t) \boldsymbol{\theta}_i^T, \quad i = 1, \dots, m \quad (5.15)$$

Las variables indicadoras estimadas $\hat{\mathbf{v}}(t) \in \mathcal{R}^m$ se pueden utilizar para la clasificación utilizando la regla (5.9). Los parámetros $\boldsymbol{\theta}_i$ se calculan, para cada clase, minimizando el error cuadrático medio (EMQ):

* A variável indicadora binária $v_i(t) \in \{0, 1\}$ também pode ser utilizada.

$$EMQ(\theta_i) = \frac{1}{N} \sum_{t=1}^N (v_i(t) - \hat{v}_i(t))^2, \quad i = 1, \dots, m \quad (5.16)$$

MMQ realiza la minimización de EMQ para cada clase de la misma manera que se presenta en la sección 3.1.2. La relación de varianza del modelo *bias x* analizada en la sección 3.2.1 y las técnicas de regularización presentadas en las secciones 3.2.2 y 3.2.3 se aplican igualmente al modelo de clasificación lineal. Sin embargo, la evaluación del clasificador se realiza mediante estadísticas adicionales, que se analizan en la sección 5.3.

El modelo de clasificación lineal permite la síntesis de un clasificador mediante una función discriminante lineal en los parámetros. En el modelo polinómico lineal, descrito en la ecuación (3.3), la estructura está definida por el grado del polinomio. La Figura 5.11 presenta dos ejemplos de modelos de clasificación polinómica ejecutados con los mismos datos que el ejemplo mostrado en la Figura 5.10: el conjunto de datos *Wine* después de la transformación mediante ADL. La figura 5.11a muestra el resultado del modelo lineal, o polinomio de grado 1, y la figura 5.11b muestra el resultado del modelo cuadrático o polinómico de grado 2.




Figura 5.11: Superficies de decisión en el problema 2D *Wine*: (a) modelo lineal; (b) modelo cuadrático.

Los resultados de la Figura 5.11 son ligeramente diferentes entre sí, pero hay una gran diferencia entre el resultado de la Figura 5.11b y el del clasificador bayesiano cuadrático, que se muestra en la Figura 5.10b. En ambos casos, el modelo es cuadrático, pero en el clasificador lineal, la estructura del modelo se definió por la elección del grado del polinomio, mientras que en el clasificador bayesiano, la estructura del modelo se definió por la hipótesis de distribución normal. El modelo lineal fue ajustado por el MMQ, mientras que el clasificador bayesiano fue ajustado por las matrices de medias y covarianzas de cada clase.

El ajuste de parámetros por MMQ obtiene un clasificador que toma la decisión minimizando el error de clasificación. Sin embargo, en algunos problemas es importante tomar la decisión minimizando el riesgo condicional, lo que implica sopesar una clase en relación con la otra. Es posible ponderar registros de una clase en relación con otra utilizando el método de mínimos cuadrados ponderados que se describe a continuación.

5.2.2 Mínimos cuadrados ponderados

El método de mínimos cuadrados ponderados (MMQP) permite ajustar los parámetros de un modelo lineal en situaciones donde algunos registros son más “importantes” que otros. MMQP se utiliza en regresión lineal para estabilizar la varianza del conjunto de datos y reducir la influencia de *outliers* [399]. En los modelos de clasificación lineal, MMQP puede asignar mayor peso a los registros en la clase de riesgo más alto, lo que permite tomar la decisión de clasificación minimizando el riesgo condicional.

La formulación MMQP se basa en la definición de un vector de pesos $\mathbf{w} \in \mathcal{R}^N$, donde cada elemento $w(t)$ representa el peso del registro $t \in \mathcal{T}$. Los parámetros del modelo para cada clase θ_i se calculan minimizando el error cuadrático medio ponderado (EMQP):

$$EMQP(\theta_i) = \frac{1}{N} \sum_{t=1}^N w(t) (v_i(t) - \hat{v}_i(t))^2, \quad i = 1, \dots, m \quad (5.17)$$

donde los valores de ponderación son los mismos para calcular los parámetros de todas las clases, ya que la ponderación se aplica a los registros.

Adoptando la representación vectorial en la que $\mathbf{V}_i = [v_i(1), \dots, v_i(N)]^T$ es la columna i de la matriz de salida, cuyos elementos son los valores de la variable indicadora de clase C_i , $\hat{\mathbf{X}}$ es la matriz de regresores (cf. ecuación (3.5)) y $\mathbf{W} = \text{diag}(\mathbf{w})$, la matriz diagonal en la que cada elemento es el peso del registro correspondiente, la EMQP se puede escribir como:

$$EMQP(\theta_i) = \frac{1}{N} (\mathbf{V}_i - \hat{\mathbf{X}}\theta_i^T)^T \mathbf{W} (\mathbf{V}_i - \hat{\mathbf{X}}\theta_i^T), \quad i = 1, \dots, m \quad (5.18)$$

Al derivar la expresión EMQP en la ecuación (5.18) y equipararla a cero, obtenemos la expresión de las ecuaciones MMQP normales, similar a la ecuación (3.7):

$$\hat{\mathbf{X}}^T \mathbf{W} \hat{\mathbf{X}} \theta_i^T = \hat{\mathbf{X}}^T \mathbf{W} \mathbf{V}_i, \quad i = 1, \dots, m \quad (5.19)$$

La solución del sistema lineal (5.19), considerando que la matriz $\hat{\mathbf{X}}^T \mathbf{W} \hat{\mathbf{X}}$ tiene rango completo, se calcula por la pseudoinversa como:

$$\theta_i^* = (\hat{\mathbf{X}}^T \mathbf{W} \hat{\mathbf{X}})^{-1} \hat{\mathbf{X}}^T \mathbf{W} \mathbf{v}_i, \quad i = 1, \dots, m \quad (5.20)$$

Los métodos de regularización discutidos en la sección 3.2 se aplican igualmente a la solución del sistema lineal de ecuaciones (5.19).

En la sección 3.1.3, se vio que la solución calculada por EMQ produce la mejor aproximación posible del conjunto de datos. De esta forma, la solución calculada por MMQP tendrá un error mayor. En problemas de clasificación, la solución MMQ corresponde a la decisión de minimizar el error de clasificación en el enfoque bayesiano, mientras que la solución MMQP corresponde a la minimización del riesgo condicional. De manera similar, MMQP produce un error global mayor, pero tendrá un error menor en la clase más importante.

En un problema de clasificación desequilibrado, la clase minoritaria suele ser la más importante. En este caso, podemos definir la ponderación de cada registro por el complemento del valor de probabilidad *a priori* de la clase correspondiente:

$$w(t) = 1 - \frac{N_i}{N} \quad \forall \mathbf{x}(t) \in C_i, \quad i = 1, \dots, m \quad (5.21)$$

donde N_i es el número de registros de clase C_i .

La ponderación realizada por la ecuación (5.21) equivale a eliminar el efecto de la probabilidad *a priori* en el clasificador bayesiano. La probabilidad *a priori* influye indirectamente en el clasificador ajustado por EMQ (cf. ecuación (5.16)), ya que la minimización de EMQ produce una superficie de decisión que se ajustará para incluir un mayor número de registros de la clase mayoritaria.

La Figura 5.12 muestra una comparación de los resultados obtenidos por un modelo cuadrático ajustado por el MMQ y el MMQP, con pesos calculados por la ecuación (5.21), sobre datos del problema de Diabetes de los Indios Pima.¹¹⁸ Este problema tiene dos clases que representan el diagnóstico, positivo o negativo, de diabetes en mujeres de la etnia Pima en función de atributos como número de hijos, presión arterial, etc.

* A matriz de coeficientes $\hat{\mathbf{X}}^T \mathbf{W} \hat{\mathbf{X}} = (\mathbf{W} \hat{\mathbf{X}})^T \hat{\mathbf{X}}$. A matriz $\mathbf{W} \hat{\mathbf{X}}$ pode ser calculada diretamente a partir do vetor de pesos $\mathbf{w}^T$, multiplicando-se, elemento a elemento, as colunas da matriz de regressores $\hat{\mathbf{X}}$ pelo vetor de pesos $\mathbf{w}^T$, evitando-se, assim, o custo computacional e de alocação de memória do processamento dos elementos nulos da matriz diagonal $\mathbf{W}$.

El conjunto de datos está desequilibrado y la clase negativa (C_1) tiene el 65% de los registros, mientras que la clase positiva (C_2) está asignada al 35% de los registros. El conjunto de datos tiene ocho variables, pero la Figura 5.12 muestra los resultados calculados sobre los dos componentes principales para facilitar la visualización. Nótese el aumento en la región asignada a la clase positiva (en verde) en el caso de la solución calculada por MMQP.




Figura 5.12: Superficies de decisión para el problema de diabetes de los indios Pima 2D: (a) MMQ; (b) MMQP.

En los modelos lineales ajustados por MMQ y MMQP, la variable de salida es una variable indicadora $v_i(t) \in \{-1, 1\}$, mientras que en la aproximación del modelo lineal $\hat{v}_i(t) \in \mathcal{R}$, no se puede interpretar la probabilidad *a posteriori* de la clase. En el modelo de regresión logística, que se describe a continuación, el modelo lineal se transforma para que el resultado pueda interpretarse como un valor de probabilidad.

5.2.3 Regresión logística

La regresión logística, también conocida como modelo logit, es un modelo de clasificación que se encuentra en varias bibliotecas *softwares* gratuitas y comerciales, y en bibliotecas de lenguajes de programación como R¹¹⁹ y Python.¹²⁰

La formulación clásica de regresión logística se obtiene para el problema de clasificación binaria en el que el resultado observado está representado por la variable indicadora $v(t) \in \{0, 1\}$:

$$v(t) = \begin{cases} 1, & \text{se } \mathbf{x}(t) \in C \\ 0, & \text{se } \mathbf{x}(t) \notin C \end{cases} \quad (5.22)$$

El modelo es una aproximación de la probabilidad *a posteriori*, es decir, $g(\mathbf{x}, \boldsymbol{\theta}) \approx P(C|\mathbf{x})$, y la función discriminante se calcula mediante la función sigmoidea, también conocida como función logística o logit (de donde deriva su nombre el método), aplicada al modelo lineal :

$$g(\mathbf{x}(t), \boldsymbol{\theta}) = \frac{1}{1 + \exp(-\hat{\mathbf{x}}(t)\boldsymbol{\theta}^T)} \quad (5.23)$$

donde $\hat{\mathbf{x}}(t) = [1, \mathbf{x}(t)]$ es el vector de regresores y $\boldsymbol{\theta}$ es el vector de parámetros.

La Figura 5.13 muestra el comportamiento de la función sigmoidea $g(z)$, en la que podemos observar que $\lim_{z \rightarrow +\infty} g(z) = 1$ y $\lim_{z \rightarrow -\infty} g(z) = 0$.




Figura 5.13: Función sigmoidea o logística.

La regresión logística es un modelo de clasificación binaria, cuya función discriminante está definida por la probabilidad *a posteriori* como:

$$\begin{aligned} P(v(t) = 1 | \mathbf{x}(t), \boldsymbol{\theta}) &= g(\mathbf{x}(t), \boldsymbol{\theta}) \\ P(v(t) = 0 | \mathbf{x}(t), \boldsymbol{\theta}) &= 1 - g(\mathbf{x}(t), \boldsymbol{\theta}) \end{aligned} \quad (5.24)$$

La ecuación anterior se puede escribir como una distribución de Bernoulli¹²¹:

$$P(v(t) | \mathbf{x}(t), \boldsymbol{\theta}) = \hat{v}(t)^{v(t)} (1 - \hat{v}(t))^{1-v(t)} \quad (5.25)$$

donde $\hat{v}(t) = g(\mathbf{x}(t), \boldsymbol{\theta})$ y $v(t) \in \{0, 1\}$.

El modelo de regresión logística se ajusta para maximizar la probabilidad (o función de verosimilitud) del modelo al representar los valores observados:

$$L(\boldsymbol{\theta}) = \prod_{t=1}^N P(v(t) | \mathbf{x}(t), \boldsymbol{\theta}) \quad (5.26)$$

Aplicando la expresión (5.25) a (5.26), tenemos la expresión de la función de verosimilitud de la regresión logística:

$$L(\theta) = \prod_{t=1}^N \hat{v}(t)^{v(t)} (1 - \hat{v}(t))^{1-v(t)} \quad (5.27)$$

El producto de la ecuación (5.27) dificulta el ajuste de parámetros y el resultado no cambia si se utiliza el negativo del logaritmo de la función de verosimilitud para ajustar parámetros como un problema de minimización:

$$l(\theta) = -\log(L(\theta)) = -\sum_{t=1}^N v(t) \log(\hat{v}(t)) + (1 - v(t)) \log(1 - \hat{v}(t)) \quad (5.28)$$

La figura 5.14 muestra el resultado de la función (5.28) calculada para un registro determinado. Cuando $v(t) = 1$, como se muestra en la Figura 5.14a, $l(\theta) = -\log(\hat{v}(t))$, aumenta exponencialmente como $\hat{v}(t) \rightarrow 0$. En el caso de $v(t) = 0$, que se muestra en la figura 5.14b, $l(\theta) = -\log(1 - \hat{v}(t))$ aumenta exponencialmente cuando $\hat{v}(t) \rightarrow 1$.




Figura 5.14: Función de costos (5.28): (a) $v(t) = 1$; (b) $v(t) = 0$.

El negativo del logaritmo de la función de verosimilitud (cf. ecuación (5.28)) es más adecuada para ajustar modelos de clasificación que el EMQ para resolver un problema de minimización. Los resultados de la regresión logística y el modelo lineal ajustado por el MMQ son equivalentes, pero la regresión logística tiene una interpretación probabilística, que es más adecuada para la toma de decisiones. Sin embargo, aunque los parámetros del modelo ocurren de manera no lineal en la expresión de la función sigmoidea (5.23). Hastie y colaboradores [238] presentan una solución basada en el método de Newton-Raphson, que da como resultado el algoritmo conocido como mínimos cuadrados iterativos ponderados [406]. El modelo de regresión logística también se puede ajustar utilizando el método del gradiente como se presentará en la sección 9.1.2.

El modelo de regresión logística se puede extender a problemas de clasificación multiclase [238][521] y a funciones discriminantes no lineales [578]. En el caso de clases múltiples, el modelo se conoce como regresión softmax y se analizará en el Capítulo 9.

La Figura 5.15 presenta el resultado de dos modelos de clasificación en el conjunto de datos *Wine* 2D, formado por el conjunto *Wine* después de ADL, discutido en la Figura 5.10 y la Figura 5.11. La figura 5.15a presenta el resultado del clasificador bayesiano simple; La figura 5.15b muestra el resultado de la regresión logística. Se puede observar que el resultado de la regresión logística es idéntico al resultado del modelo de clasificación lineal ajustado por el MMQ que se muestra en la Figura 5.11a.




Figura 5.15: *Wine* Datos 2D: (a) clasificador bayesiano simple; (b) regresión logística.

Al igual que con la regresión, la elección del mejor modelo debe realizarse en función de las estadísticas de validación calculadas en validación cruzada, como se presenta a continuación.

5.3 Evaluación del Clasificador

El problema de clasificación es predictivo y, como en el caso de la regresión lineal, hay que evitar *overfitting*. El proceso de desarrollo de un modelo de clasificación sigue los mismos pasos descritos en la sección 3.2, donde el objetivo de la etapa de validación es seleccionar el tipo y estructura del modelo más apropiado al problema. Las estadísticas se calculan en validación cruzada para generar un modelo con buena capacidad de generalización.

El modelo lineal ajustado por MMQ sigue las mismas hipótesis que la regresión lineal y el clasificador podría evaluarse utilizando las mismas estadísticas de validación presentadas en la sección 3.3.1. Sin embargo, el problema de clasificación tiene resultados discretos y generalmente desordenados que requieren estadísticas específicas. Esta sección presenta una descripción de las estadísticas más utilizadas para evaluar clasificadores.

5.3.1 Estadísticas de validación

Las estadísticas de evaluación del clasificador se calculan a partir de la matriz de confusión, mencionada en la sección 5.1.1 y presentada en la Tabla 5.2 para dos clases. La matriz de confusión se utiliza en estadística para representar las posibles soluciones de una prueba de hipótesis. En los problemas de clasificación, las líneas representan las clases observadas y las columnas representan las clases predichas por el modelo.

Las estadísticas de validación se definen para problemas de dos clases donde una clase se llama arbitrariamente clase positiva y la otra clase negativa. En la tabla 5.2, la clase C_1 es la clase positiva y la clase C_2 , es la negativa.

Tabla 5.2: Matriz de confusión

	$\hat{C}_1$ (Predita)	$\hat{C}_2$ (Predita)
C_1 (Real)	VP	FN
C_2 (Real)	FP	VN

La matriz de confusión se llena con el número de registros correspondientes, generalmente obtenidos mediante validación cruzada, siguiendo la siguiente terminología:

Verdaderos Positivos (VP): es el número de registros de la clase C_1 correctamente clasificados por el modelo como clase $\hat{C}_1$. Falsos Negativos (FN): es el número de registros de la clase C_1 clasificados por el modelo como clase $\hat{C}_2$. Falsos Positivos (FP): es el número de registros de la clase C_2 clasificados por el modelo como clase $\hat{C}_1$. Verdaderos Negativos (VN): es el número de registros de la clase C_2 correctamente clasificados por el modelo como clase $\hat{C}_2$.

La evaluación global del clasificador se realiza por la precisión del modelo, que es su tasa de clasificación correcta, calculada como:

$$ACC = \frac{VP + VN}{VP + FP + FN + VN} \quad (5.29)$$

El error de clasificación global es el complemento de la precisión:

$$ERR = 1 - ACC = \frac{FP + FN}{VP + FP + FN + VN} \quad (5.30)$$

El error global resalta la diferencia en el rendimiento de dos clasificadores. Por ejemplo, un modelo con un 96% de precisión tiene el doble de error que otro modelo con un 98% de precisión.

Las estadísticas globales de precisión y error no informan sobre el error que está cometiendo el modelo para cada clase. Se pueden utilizar dos medidas utilizadas frecuentemente en la recuperación de información para evaluar el desempeño de los clasificadores [364]: precisión (PRE) y recuperación (REC), también llamada sensibilidad o *re-call*. Estas medidas se definen para cada clase como:

$$PRE(C_1) = \frac{VP}{VP + FP} \quad PRE(C_2) = \frac{VN}{VN + FN} \quad (5.31)$$

$$REC(C_1) = \frac{VP}{VP + FN} \quad REC(C_2) = \frac{VN}{VN + FP} \quad (5.32)$$

La precisión mide la capacidad de predicción del modelo y la recuperación es su capacidad para reconocer registros de la clase correspondiente. En problemas de clasificación con múltiples clases, la precisión y las medidas *recall* se calculan para cada clase considerando las demás como clases negativas. Las medidas de precisión y recuperación se pueden combinar en la denominada medida F, definida para la clase C_i como:

$$F(C_i) = \frac{2 PRE(C_i).REC(C_i)}{PRE(C_i) + REC(C_i)} \quad (5.33)$$

La medida F representa la media armónica entre precisión y *recall*, e indica el rendimiento en términos de ambas estadísticas simultáneamente, y puede generalizarse para variar entre precisión y *recall* a través de un parámetro [516].

En problemas desequilibrados, las estadísticas de cada clase deben considerarse juntas para evitar llevar a conclusiones erróneas. Por ejemplo, considere un problema de dos clases, donde la probabilidad *a priori* $P(C_1) = 90\%$. un clasificador

que ordena todos los registros en la clase mayoritaria (C_1) obtendrá $PRE(C_1) = 0.9$ y $REC(C_1) = 1.0$, pero $PRE(C_2) = REC(C_2) = 0.0$ para la clase minoritaria (C_2).

La estadística kappa es una medida global que relaciona la probabilidad de acuerdo observado con la probabilidad de acuerdo esperado $P(E)$ [110]. En los modelos de clasificación, la concordancia observada se mide por la precisión del clasificador (5.29) y la concordancia esperada es el resultado que se obtendría mediante un modelo aleatorio en un tamaño de muestra infinito. El coeficiente kappa (κ) se calcula como:

$$\kappa = \frac{ACC - P(E)}{1 - P(E)} \quad (5.34)$$

El valor $\kappa \leq 1$, donde $\kappa = 1$, indica acuerdo total; $\kappa = 0$ indica que $ACC = P(E)$, es decir, la precisión es igual a la concordancia esperada. Un valor $\kappa < 0$ indica que el clasificador funciona peor que un resultado puramente aleatorio. Landis y Koch [327] sugieren que un valor de $\kappa \geq 0.8$ representa un buen acuerdo y un resultado de $0.6 \leq \kappa < 0.8$ representa un acuerdo razonable. La probabilidad de acuerdo esperada $P(E)$ se calcula a partir de la matriz de confusión como:

$$P(E) = P(C_1)P(\hat{C}_1) + P(C_2)P(\hat{C}_2) \quad (5.35)$$

donde $P(C_1)$ es la probabilidad *a priori* de la clase C_1 , $P(C_2)$ es la probabilidad *a priori* de la clase C_2 , $P(\hat{C}_1)$ es el porcentaje de registros predichos como de clase $\hat{C}_1$ por el modelo y $P(\hat{C}_2)$, el porcentaje de registros predichos como clase $\hat{C}_2$.

Los términos de la ecuación (5.35) se calculan como:

$$P(C_1) = \frac{VP + FN}{VP + FP + FN + VN} = \frac{N_1}{N} \quad (5.36)$$

$$P(C_2) = \frac{FP + VN}{VP + FP + FN + VN} = \frac{N_2}{N} \quad (5.37)$$

$$P(\hat{C}_1) = \frac{VP + FP}{VP + FP + FN + VN} = \frac{\hat{N}_1}{N} \quad (5.38)$$

$$P(\hat{C}_2) = \frac{FN + VN}{VP + FP + FN + VN} = \frac{\hat{N}_2}{N} \quad (5.39)$$

Los valores totales observados y pronosticados para cada clase se muestran en la Tabla 5.3.

Tabla 5.3: Totales observados y previstos para cada clase

	$\hat{C}_1$	$\hat{C}_2$	Total
C_1	VP	FN	N_1
C_2	FP	VN	N_2
Total	$\hat{N}_1$	$\hat{N}_2$	N

La evaluación de los clasificadores también se realiza gráficamente utilizando las tasas de verdaderos positivos y falsos positivos en el llamado espacio ROC, que se describe a continuación.

5.3.2 Espacio ROC y AUC

En el apartado 5.1.1 se vio que, en caso de problemas de desequilibrio, la decisión por el error de clasificación mínimo favorece a la clase mayoritaria. En muchos problemas, la clase minoritaria es la más importante y, en este caso, no se puede utilizar el error global para elegir el clasificador. La elección del clasificador en problemas desequilibrados debería favorecer la clase más importante, aumentando la recuperación de registros de mayor costo.

El efecto del desequilibrio del problema sobre el resultado del clasificador ajustado por el error de clasificación mínimo se muestra en la Figura 5.16, que muestra el valor de $p(x|C_i)P(C_i)$ cada uno para un problema de dos clases y una variable. La situación en la que las probabilidades *a priori* son iguales se muestra en la figura 5.16a. En este caso, las tasas FP y FN están definidas por la forma y posición de las distribuciones condicionales. En el caso de problemas desequilibrados (Figura 5.16b), ajustar el modelo por el error de clasificación mínimo favorece la clase más frecuente (C_1), lo que resulta en un aumento en la tasa de VP y una consecuente disminución en la tasa de VN. Cuando la clase minoritaria es la más importante, el clasificador debería favorecer la tasa VN. Sin embargo, un aumento en la tasa VN sólo puede obtenerse a expensas de un aumento en la tasa FN, lo que también aumenta el error global, como se analiza en la sección 5.2.2.




Figura 5.16: Problemas de desequilibrio: (a) $P(C_1) = P(C_2)$; (b) $P(C_1) > P(C_2)$.

El espacio ROC (*receiver operating characteristic*) fue desarrollado por operadores de radar para caracterizar la diferencia *trade-off* entre la tasa de detección y la tasa de falsas alarmas en ambientes ruidosos [516][561]. Para evaluar clasificadores, las tasas de FP y VP obtenidas por un clasificador se utilizan como coordenadas del espacio ROC, como se muestra en la Figura 5.17.




Figura 5.17: Espaço ROC.

La tasa PV (TVP) es el *recall* de la clase positiva $REC(C_1)$ en (5.32) y la tasa FP (TFP) es el complemento de la tasa VN ($REC(C_2)$) llamada especificidad (SPE). El valor de TFP se calcula como:

$$TFP = 1 - SPE = 1 - \frac{VN}{FP + VN} = \frac{FP}{FP + VN} \quad (5.40)$$

El espacio ROC muestra el desempeño del clasificador relacionando cuánto acierta en la clase positiva y cuánto falla en la clase negativa. El modelo ideal es el punto (0,1) de la gráfica, con $TFP = 0$, es decir, $SPE = REC(C_2) = 1$ y $REC(C_1) = 1$. En este caso, el modelo tiene un éxito del 100%, ya que recupera todos los ejemplos de ambas clases. Los clasificadores en la diagonal del espacio ROC tienen $REC(C_1) = 1 - REC(C_2)$, son modelos con $\kappa = 0$, es decir, tienen un rendimiento equivalente a un modelo aleatorio. Los clasificadores debajo de la diagonal representan modelos con $\kappa < 0$.

El área sombreada en la Figura 5.17 es una medida de evaluación del clasificador llamada área bajo la curva ROC (AUC). La medida AUC se calcula mediante el área del cuadrilátero obtenida conectando las coordenadas del clasificador a los puntos (0,0) y (1,1) (cf. Figura 5.17). Después de algunas simplificaciones, el valor AUC se calcula como el promedio entre la tasa PV y VN:

$$AUC = \frac{REC(C_1) + REC(C_2)}{2} \quad (5.41)$$

El valor AUC se calcula mediante la ecuación (5.41) para problemas de dos clases. En problemas multiclase, se calcula un valor AUC para cada clase, considerando la clase positiva, y el valor AUC total del clasificador se calcula promediando el AUC de cada clase ponderado por la estimación de probabilidad *a priori* de la clase correspondiente [176]:

$$AUC = \sum_{i=1}^m AUC(C_i)P(C_i) \quad (5.42)$$

donde $AUC(C_i)$ es el valor calculado por la ecuación (5.41) considerando la clase C_i como positiva y $P(C_i)$ es la frecuencia relativa de la clase C_i . Hand and Till [235] evaluaron otros enfoques para calcular el valor AUC total.

Un método gráfico para evaluar modelos en el espacio ROC se llama curva ROC, que presenta una curva continua en el espacio ROC para cada clase. El valor AUC en este caso se calcula integrando la curva ROC utilizando el método trapezoidal. Sin embargo, la curva ROC es independiente de la frecuencia de clase [176]. La medida AUC obtenida por la ecuación (5.41), además de ser más eficiente, es sensible a las frecuencias de clase y por tanto es más adecuada en problemas de desequilibrio.

El resultado del valor AUC en problemas desequilibrados se puede observar en el conjunto de datos Pima Indian Diabetes, que se analiza en la sección 5.2.2. En este problema, la clase positiva es la minoría, representada por C_2 , con el 35% de los registros. La Figura 5.18 muestra los resultados calculados en validación cruzada para los modelos cuadráticos ajustados por MMQ y MMQP utilizando todas las variables.

En la columna de la izquierda, la Figura 5.18a presenta la precisión y los resultados *recall* para cada clase del clasificador ajustado con el MMQ y la Figura 5.18c muestra el espacio ROC y el valor AUC calculado por la ecuación (5.41) del mismo modelo. En la columna de la derecha se presentan los mismos resultados para el modelo ajustado con el MMQP.




Figura 5.18: Resultados del problema Pima Indian Diabetes: (a) y (c) Modelo ajustado con MMQ; Modelo (b) y (d) ajustado con MMQP.

En el modelo ajustado por MMQP, la recuperación de la clase positiva (C_2) es mayor, resultando en un valor de AUC mayor. El modelo ajustado por MMQ obtiene un menor error global, influenciado por el desequilibrio entre clases, resultando en una mayor tasa de recuperación para la clase negativa (C_1).

5.4 Aplicaciones

Los modelos de clasificación presentados en este capítulo se analizarán en esta sección en dos contextos diferentes. En la sección 5.4.1, los algoritmos se comparan en una serie de conjuntos de datos *benchmark* para una evaluación general del rendimiento del algoritmo. Este mismo tipo de prueba se repetirá en los Capítulos 7 y 8 con modelos de clasificación de inteligencia computacional. En el apartado 5.4.2 presentamos un caso de estudio sobre el análisis de cancelaciones en un operador telefónico.

5.4.1 Pruebas *benchmark*

El repositorio de la Universidad de California en Irvine (UCI)¹²² es una referencia en el área de ciencia de datos y contiene varios conjuntos de datos para evaluar algoritmos en problemas reales.

Se seleccionó un conjunto de 10 *benchmarks* para evaluar los modelos presentados en este capítulo:

Bayes N: Clasificador bayesiano simple (*naïf*) Bayes Q: Clasificador bayesiano multivariante (cuadrático) Logit: Regresión logística M. Lin. 1: Modelo lineal de primer orden M. Lin. 2: modelo lineal de segundo orden

Los conjuntos de datos fueron seleccionados para cubrir una amplia variedad de tipos de problemas de diferentes dimensiones, tanto en términos de número de registros como de variables. La Tabla 5.4 presenta el número de variables (p), el número de clases (m) y el número de registros (N) para cada problema.

La mayoría de los *benchmarks* son problemas conocidos en la literatura. *benchmarks* *Wine* y Diabetes de los indios Pima ya se han utilizado en este capítulo como ejemplos de aplicación de los modelos. En esta evaluación, todos los *benchmarks* se utilizaron como datos sin procesar, es decir, no se realizó ningún preprocesamiento que pudiera interferir

en el desempeño de los modelos. Los algoritmos de ajuste de parámetros también se ejecutaron en su forma estándar, es decir, sin utilizar ninguna ponderación para compensar el desequilibrio de las clases. Todas las pruebas se realizaron en validación cruzada de 10 ciclos, según el algoritmo descrito en la sección 3.3.2.

Tabla 5.4: *benchmark* Conjuntos de datos

<i>Benchmark</i>	<i>p</i>	<i>m</i>	<i>N</i>
Íris ¹²³	4	3	150
Balance ¹²⁴	4	3	625
Diabetes ¹²⁵	8	2	768
Cancer ¹²⁶	9	2	286
Statlog Heart ¹²⁷	13	2	270
Wine ¹²⁸	13	3	178
Parkinson ¹²⁹	17	2	186
Ionosphere ¹³⁰	32	2	351
Spambase ¹³¹	57	2	4601
Sonar ¹³²	60	2	208

El desempeño de los modelos se puede evaluar cuantitativamente a través de las métricas de precisión (ACC), definidas en la ecuación (5.29), y el área sobre la curva ROC (AUC), definida en la ecuación (5.41). Los resultados se presentan en la Tabla 5.5, en la que los valores en **negrita** corresponden a los valores más altos de cada métrica para la respectiva *benchmark*.

Los resultados presentados en la Tabla 5.5 muestran que ningún modelo es mejor en todas las pruebas, pero indican que el modelo lineal de segundo orden (M. Lin. 2) obtiene los mejores resultados la mayor parte del tiempo. Además, los modelos cuadráticos (Bayes Q y M. Lin. 2) obtuvieron mejores resultados que sus homólogos más simples (Bayes N y M. Lin. 1) en la mayoría de los casos. El modelo de regresión logística (Logit) presentó resultados cercanos a los del modelo lineal simple (M. Lin. 1).

Es importante comprobar si el mejor rendimiento realmente representa un comportamiento consistente del modelo o es un resultado obtenido debido a factores aleatorios. Esta evaluación se realiza mediante pruebas estadísticas no paramétricas [125][195] disponibles en *softwares* stats y en el *software* KEEL gratuito,¹³³ utilizado en esta sección.

Tabla 5.5: resultados de la prueba *benchmark*

<i>Benchmark</i>	Bayes N		Bayes Q		Logit		M. Lin. 1		M. Lin. 2	
	<i>ACC</i>	<i>AUC</i>	<i>ACC</i>	<i>AUC</i>	<i>ACC</i>	<i>AUC</i>	<i>ACC</i>	<i>AUC</i>	<i>ACC</i>	<i>AUC</i>
Íris	94.67	0.9600	98.00	0.9850	82.67	0.8697	83.33	0.8747	95.33	0.9650
Balance	90.40	0.9079	91.68	0.9469	87.04	0.8755	87.04	0.8755	91.36	0.9171
Diabetes	71.88	0.7260	74.61	0.7054	76.69	0.7145	76.30	0.7089	77.21	0.7151
Cancer	94.58	0.9574	95.02	0.9559	96.05	0.9512	96.05	0.9512	97.22	0.9709
Statlog Heart	83.70	0.8392	82.59	0.8225	83.33	0.8275	84.07	0.8358	84.44	0.8375
Wine	97.19	0.9766	99.44	0.9958	98.88	0.9919	98.31	0.9881	99.44	0.9958
Parkinson	79.49	0.7026	80.51	0.8427	86.15	0.7889	86.15	0.7889	86.15	0.8099
Ionosphere	60.68	0.6933	86.89	0.8803	85.75	0.8138	86.04	0.8178	89.46	0.8602
Spambase	90.18	0.8911	82.53	0.8474	88.63	0.8686	88.63	0.8684	91.37	0.9006
Sonar	72.60	0.7159	71.15	0.6992	76.92	0.7656	75.96	0.7579	80.29	0.8010

La prueba de hipótesis es una técnica estadística clásica que permite evaluar si un conjunto de evidencia observada confirma o refuta una hipótesis. En las pruebas de hipótesis paramétricas, existe un modelo de distribución del proceso y la prueba se realiza sobre los parámetros de distribución. En las llamadas pruebas no paramétricas no existe ningún modelo de distribución de datos [501]. Al evaluar clasificadores, las hipótesis se formulan de la siguiente manera:

Hipótesis nula $\mathcal{H}_0$: los modelos presentan resultados equivalentes; Hipótesis alternativa $\mathcal{H}_1$: los modelos no presentan resultados equivalentes.

La aceptación de la hipótesis nula significa que las diferencias de rendimiento se deben a las particularidades de cada *benchmark* [195]. El resultado de la prueba de hipótesis (paramétrica o no paramétrica) es el llamado valor p , que mide la significancia estadística de las diferencias observadas en la evaluación. El valor p se interpreta como la probabilidad de observar el resultado obtenido considerando que la hipótesis nula es verdadera. En otras palabras, el valor p representa la probabilidad del llamado error Tipo I (o falso negativo), de rechazar la hipótesis nula cuando, en realidad, es cierta. Cuanto menor sea el valor de p , menor será la probabilidad de que la hipótesis nula sea cierta. Normalmente, el

La hipótesis nula se rechaza si el valor es $-p < 0.05$, que representa un 95% de confianza estadística en la hipótesis alternativa.

García y colaboradores [195] sugieren que las pruebas no paramétricas son más adecuadas para evaluar clasificadores. La prueba de Friedman, particularmente la llamada *Friedman aligned rank*, se recomienda cuando se compara un número relativamente pequeño de modelos (menos de cinco). La prueba ordena los resultados obtenidos por cada modelo y utiliza las diferencias de orden para un mismo *benchmark* y las diferencias de orden para el mismo modelo en diferentes *benchmarks* [195].

En esta sección, analizamos únicamente los resultados de la prueba *Friedman aligned rank*. García y colegas [195] ofrecen una discusión detallada de este y otros métodos. Los autores pertenecen al grupo de investigación responsable del desarrollo del *software* KEEL [9][10] gratuito, utilizado para realizar las pruebas. *software* tiene un módulo de prueba no paramétrico, con varias opciones de prueba.

La Tabla 5.6 muestra el *rankings* de cada modelo, calculado mediante la prueba de Friedman a partir de los resultados de la Tabla 5.5, y el valor p correspondiente a cada métrica de evaluación. El clasificador calculado por el discriminante lineal de segundo orden (M. Lin. 2) obtuvo el mejor *ranking* mediante la prueba de Friedman para ambas métricas. El valor p indica que las probabilidades de error al considerar diferencias significativas son, respectivamente, 8,26 % y 7,95 % para las métricas ACC y AUC.

Tabla 5.6: *Friedman aligned rank* Resultados de la prueba

	ACC	AUC
Bayes N	33.30	31.95
Bayes Q	28.55	23.80
Logit	26.45	31.25
M. Lin. 1	26.75	27.35
M. Lin. 2	12.45	13.15
Valor- p	0.0826	0.0795

El gran problema de las pruebas estadísticas es que, en la gran mayoría de los casos, no se puede estar 100% seguro de los resultados. Lo que muestra la prueba estadística, con una confianza estadística de alrededor del 92%, es que el modelo discriminante lineal de segundo orden funciona mejor que los demás. Este resultado es consistente con el argumento teórico de que MMQ es más robusto que la estimación de parámetros.

del clasificador bayesiano. La prueba de hipótesis cuantifica este resultado, que no es evidente al observar sólo el mejor resultado de cada *benchmark* en la Tabla 5.5.

5.4.2 Análisis de cancelación de telefonía

Las empresas que operan en un entorno competitivo siempre se preocupan por promover la lealtad entre los clientes de mayor valor de su base, ya que mantener un cliente es menos costoso que atraer nuevos clientes. En las empresas que ofrecen servicios de suscripción, como telefonía y televisión de pago, un término muy extendido es la tarifa *churn*,¹³⁴ que hace referencia al porcentaje de cancelaciones de suscripciones en un periodo determinado. El desarrollo de modelos de cancelación predictivos es una de las áreas de aplicación más activas de la ciencia de datos [422][530].

Cister [107] presentó un ejemplo interesante de análisis de cancelaciones en un operador telefónico. La base de datos es una muestra de clientes considerados de alto valor: empresas con una media de cuatro líneas móviles y alto consumo. La base de datos original es un conjunto de datos en tres dimensiones: 1.171 clientes, 10 variables de consumo y 12 meses. El muestreo de datos se llevó a cabo entre agosto de 2004 y julio de 2005 [107].

El análisis presentado en esta sección se realizó sobre el promedio de las variables de consumo por cliente, ya que las variables de consumo representaron los ingresos por cada tipo de llamada realizada por el cliente durante el mes. De esta manera se logró eliminar la dimensión de consumo y trabajar con una tabla de clientes por mes, que luego de quitar el 2,5% de *outliers* dejó 1.141 registros. Un análisis preliminar del gráfico de líneas aplicado a las medias y desviaciones estándar de cada variable (Figura 5.19) reveló que el comportamiento en los primeros seis meses de la muestra fue prácticamente constante, sin interés para el modelo de predicción. Con esto se seleccionaron las variables correspondientes a los últimos seis meses, como se muestra en la Figura 5.19, donde la variable x_1 representa el consumo promedio seis meses antes del final de la muestra (febrero de 2005) y la variable x_6 representa el consumo promedio en el último mes del estudio (julio de 2005).




Figura 5.19: Gráfico de líneas: medias y desviaciones estándar de cada variable por clase.

El objetivo del modelo es la predicción de dos clientes que abandonarán la empresa después del período de demostración. La clase C_1 representa a los clientes que continuaron con su suscripción y a los clientes C_2 que cancelaron su suscripción, que, en este caso, es la clase más relevante. En el Gráfico 5.19 se muestra que el comportamiento de los clientes que cancelaron cambió considerablemente a partir del noveno mes de la muestra, aumentando fuertemente para luego disminuir a valores inferiores a los registrados hasta el octavo mes. Las causas de esta mudanza de comportamiento no fueron divulgadas [107].

A Figura 5.20 muestra las principales características de la base de datos. Las distribuciones de las variables de consumo medio son razonablemente asimétricas y las variables están bien correlacionadas entre sí, a excepción de la variable x_6 , que representa el consumo en el último mes de la muestra y que tiene un comportamiento muy diferente al resto de variables.

Una de las principales características de este problema es el alto grado de desequilibrio en la base de datos, ya que la clase de clientes que cancelaron su suscripción (C_2) tiene solo el 7,17% de los registros.

El objetivo de esta sección es evaluar los efectos de la ponderación para compensar el desequilibrio de clases en los resultados del modelo. Los modelos bayesianos y lineales discutidos en la sección 5.4.1 para el uso en la evaluación. Los modelos se ejecutaron de dos maneras: sin ponderación para compensar el efecto de la probabilidad *a priori* y con ponderación. En el caso de los modelos bayesianos, la ponderación corresponde a eliminar el valor de probabilidad *a priori* del cálculo del valor de probabilidad *a posteriori*.





Figura 5.20: Características de la base de cancelación.

Los resultados de precisión (ACC) y AUC se presentan en la Tabla 5.7, en la que los valores máximos para cada métrica en cada tipo de prueba están en negrita. Podemos observar que, en todos los modelos, la ponderación resultó en una disminución del ACC y un aumento del AUC.


Tabla 5.7: Resultados del modelo

Modelo	Bayes N		Bayes Q		M. Lin. 1		M. Lin. 2	
	ACC	AUC	ACC	AUC	ACC	AUC	ACC	AUC
S. Pond.	92.82	0.5119	96.41	0.8272	92.91	0.5179	94.40	0.6300
C. Pond.	90.63	0.7960	88.18	0.8814	85.29	0.8658	90.19	0.8868


La precisión y los gráficos *recall* para cada modelo con y sin ponderación se muestran en la Figura 5.21, donde la columna de la izquierda representa los resultados no ponderados y la columna de la derecha representa los resultados ponderados. Podemos observar que la ponderación aumenta la tasa de recuperación (*recall*) de la clase minoritaria C_2 en todos los modelos, lo que provoca un aumento en el AUC.




(a)




(b)




(c)




(d)




(e)



(f)



(g)



(h)

Figura 5.21: Precisión y *recall*, columna izquierda sin ponderación y columna derecha con ponderación: (a) y (b) Bayes N; (c) y (d) Bayes Q; (e) y (f) M. Lin. 1; (g) y (h) M. Lin. 2.

En problemas muy desequilibrados como este, es importante utilizar métricas adecuadas para evaluar los algoritmos. El clasificador bayesiano simple y el modelo lineal de primer orden, sin ponderación, obtuvieron resultados de precisión cercanos a la probabilidad *a priori* de la clase mayoritaria C_1 (92,83%). En consecuencia, estos modelos obtuvieron tasas de recuperación muy pequeñas de la clase minoritaria C_2 que, en este ejemplo, es la más relevante. Este resultado fue identificado por el valor de AUC cercano a 0,5 en ambos modelos.

5.5 Comentarios finales

El problema de reconocimiento de patrones es un problema clásico y existen varios libros dedicados al tema [43][146][189][521][553]. Es muy difícil condensar los temas más importantes en un solo capítulo. Los criterios utilizados para seleccionar los temas presentados fueron la importancia para la formulación del problema de clasificación y la relevancia para el fundamento de las técnicas de inteligencia computacional que se discutirán en los Capítulos 7, 8 y 9.

Algunos temas importantes no fueron incluidos. No se incluyeron los modelos de árboles de decisión, por ejemplo, que están presentes en prácticamente todos los libros de ciencia de datos [232][516][561]. Optamos por una justificación del problema de clasificación basada en el teorema de Bayes. El lector encontrará una presentación teórica completa de los modelos de clasificación desde la perspectiva del aprendizaje automático en el excelente libro de Mitchel [392]. Quinlan [446] presenta una discusión más detallada sobre los modelos de árboles de decisión.

La formulación de la regla de Bayes es bastante adecuada para comprender el problema de clasificación. Incluso si el clasificador no utiliza directamente el teorema de Bayes en su formulación, los efectos de la probabilidad condicional y, principalmente, de la probabilidad *a priori* estarán presentes en todo clasificador que se ajuste minimizando el error de clasificación.

En las redes bayesianas [121][125][247][263], la distribución de probabilidad se define para pares de variables seleccionadas y el modelo se representa mediante un gráfico. El modelo de red bayesiano busca un compromiso entre las propiedades teóricas del teorema de Bayes y la dificultad de estimar parámetros en problemas.

pero de alta dimensionalidad. Una presentación muy completa del tema se encuentra en el libro de Koller y Friedman [316] y en el curso de Coursera.¹³⁵ Obtener la estructura del grafo no es una tarea trivial, aunque existen algoritmos eficientes [125].

En general, para una muestra de tamaño finito, el problema de identificar la distribución de probabilidad del proceso que generó la muestra es más complejo que encontrar una función discriminante [98]. Por tanto, la mayoría de los modelos de clasificación modernos buscan directamente encontrar la función discriminante basándose en las observaciones disponibles. Minimizar el error de clasificación en el conjunto de entrenamiento para un modelo de estructura fija es el enfoque más común. En los modelos de máquina de vectores de soporte (SVM) [478][532], el error de clasificación es limitado y el ajuste de parámetros busca un modelo que maximice el margen de separación entre clases, lo que corresponde a minimizar la estructura del modelo. Este tipo de modelo, que comenzó a difundirse en el área de la ciencia de datos a partir de mediados de los años 1990, se presentará en el Capítulo 7. Recientemente, las redes neuronales han destacado en problemas de clasificación, especialmente en aplicaciones complejas como la visión por computadora y el procesamiento del lenguaje natural. Las redes neuronales se presentarán en el Capítulo 9.

Existen varios enfoques para tratar los problemas de desequilibrio en la literatura [90][273]. El enfoque más común es volver a muestrear los datos para compensar el desequilibrio. El algoritmo SMOTE [89] realiza este enfoque de manera eficiente y los resultados son bastante satisfactorios, especialmente cuando se usa con un modelo de árbol de decisión.

La evaluación de algoritmos mediante pruebas estadísticas no paramétricas se ha generalizado en las áreas de inteligencia computacional y ciencia de datos [195]. Sin embargo, es importante tener en cuenta que el rendimiento de un algoritmo en un conjunto de pruebas *benchmark* solo se aplica a ese conjunto de pruebas y no significa que el algoritmo funcionará mejor en todos los problemas. En la práctica, el mejor enfoque es siempre buscar el mejor rendimiento para el problema en cuestión, evitando cualquier preferencia *ad hoc* sobre un tipo particular de modelo.