

6 ANÁLISE DE AGRUPAMENTOS

O objetivo da análise de agrupamentos é a divisão do conjunto de dados em subconjuntos chamados de grupos. A análise de agrupamentos é um problema de aprendizado não supervisionado e frequentemente é chamada de classificação não supervisionada, uma vez que não existe uma variável de saída (ou variável alvo) a ser predita como na regressão ou na classificação, que são problemas de aprendizado supervisionado. A falta de supervisão dificulta a definição de uma função de avaliação da qualidade do resultado. Dessa forma, a análise de agrupamentos é essencialmente uma atividade descritiva, em que o papel do analista é preponderante para a qualidade do resultado.

As aplicações da análise de agrupamentos são bastante variadas. Na área de negócios, a segmentação da base de clientes é muito comum em grandes corporações [530]. Há também aplicações em praticamente todas as áreas com uso intensivo de dados, como, por exemplo, bioinformática [290][357], processamento de imagens [528], recuperação da informação [319], entre outras [284].

A análise de agrupamentos tem sido estudada em diferentes comunidades científicas e a literatura sobre algoritmos de agrupamento é muito diversificada. Há obras clássicas na estatística [146][194][238][521], em inteligência computacional [572][573] e ciência de dados [232][516]. Neste capítulo, apresentamos os algoritmos clássicos, que podem ser encontrados na maioria dos *softwares* e abordagens mais recentes baseadas na teoria de grafos.

6 ANÁLISIS DE CLÚSTER

El objetivo del análisis de conglomerados es dividir el conjunto de datos en subconjuntos llamados grupos. El análisis de conglomerados es un problema de aprendizaje no supervisado y a menudo se denomina clasificación no supervisada, ya que no existe una variable de salida (o variable objetivo) para predecir como en la regresión o la clasificación, que son problemas de aprendizaje supervisados. La falta de supervisión dificulta definir una función para evaluar la calidad del resultado. Por tanto, el análisis de conglomerados es esencialmente una actividad descriptiva, en la que el papel del analista es preponderante para la calidad del resultado.

Las aplicaciones del análisis de conglomerados son bastante variadas. En el ámbito empresarial, la segmentación de la base de clientes es muy común en las grandes corporaciones [530]. También existen aplicaciones en prácticamente todas las áreas con uso intensivo de datos, como por ejemplo, bioinformática [290][357], procesamiento de imágenes [528], recuperación de información [319], entre otras [284].

El análisis de clusters ha sido estudiado en diferentes comunidades científicas y la literatura sobre algoritmos de clustering es muy diversa. Hay trabajos clásicos en estadística [146][194][238][521], inteligencia computacional [572][573] y ciencia de datos [232][516]. En este capítulo, presentamos los algoritmos clásicos, que se pueden encontrar en la mayoría de los enfoques *softwares* y más recientes basados en la teoría de grafos.

6.1 O Problema de Análise de Agrupamentos

Um grupo é um conjunto de objetos com alguma característica comum que os identifica como elementos do grupo. O objetivo da análise de agrupamentos é identificar padrões que permitam separar um conjunto de dados em grupos. Os algoritmos de agrupamento encontram grupos ou subconjuntos de dados da amostra com características similares. Frequentemente, o problema envolve a análise e interpretação dos grupos encontrados.

Matematicamente, um grupo é um conjunto definido por uma propriedade característica compartilhada pelos seus elementos. Assim, dado um universo $\mathcal{X}$, os elementos do conjunto $\mathcal{A} \subseteq \mathcal{X}$ são definidos pela propriedade $\chi_{\mathcal{A}}(x)$, que, para todo elemento do universo $x \in \mathcal{X}$:

$$\chi_{\mathcal{A}}(x) = \begin{cases} 1, & \text{se } x \in \mathcal{A} \\ 0, & \text{se } x \notin \mathcal{A} \end{cases} \quad (6.1)$$

A equação (6.1) é a base do chamado axioma da separação [77], que estabelece as duas leis (ou axiomas) fundamentais da teoria dos conjuntos:

- a) a lei do **terceiro excluído**: $\mathcal{A} \cup \bar{\mathcal{A}} = \mathcal{X}$;
- b) a lei da **não contradição**: $\mathcal{A} \cap \bar{\mathcal{A}} = \emptyset$.

A noção de conjunto é estendida ao conceito de **partição**, particularmente útil em ciência de dados, em que o universo é subdividido em K subconjuntos disjuntos.

Na análise de agrupamentos, a partição do conjunto de dados (de treinamento) $\mathcal{T}$ em K subconjuntos é definida como $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$, de tal forma que as seguintes condições sejam satisfeitas:

- i. A união de todos os subconjuntos é o universo: $\bigcup_{i=1}^K \mathcal{C}_i = \mathcal{T}$;
- ii. Os subconjuntos não têm elementos em comum: $\mathcal{C}_i \cap \mathcal{C}_j = \emptyset$, $i \neq j$.

A descoberta de uma partição num conjunto de dados é computacionalmente complexa; a partição de um conjunto de dados com N registros em apenas dois subconjuntos, com N_1 e N_2 registros respectivamente, implica a avaliação de $N!/(N_1! N_2!)$ partições distintas. Por exemplo, um conjunto de dados de $N = 100$ registros pode ser dividido em dois subconjuntos de $N_1 = N_2 = 50$ registros de 10^{29} formas diferentes! Além da complexidade inerente ao problema, a da qualidade do agrupamento não é bem definida e, em geral, utiliza-se índices de validação (cf. seção 6.5).

6.1 El problema del análisis de conglomerados

Un grupo es un conjunto de objetos con alguna característica común que los identifica como elementos del grupo. El objetivo del análisis de conglomerados es identificar patrones que permitan separar un conjunto de datos en grupos. Los algoritmos de agrupamiento encuentran grupos o subconjuntos de datos de muestra con características similares. Muchas veces el problema pasa por el análisis y la interpretación de los grupos encontrados.

Matemáticamente, un grupo es un conjunto definido por una propiedad característica compartida por sus elementos. Así, dado un universo $\mathcal{X}$, los elementos del conjunto $\mathcal{A} \subseteq \mathcal{X}$ están definidos por la propiedad $\chi_{\mathcal{A}}(x)$, que, para cada elemento del universo $x \in \mathcal{X}$:

$$\chi_{\mathcal{A}}(x) = \begin{cases} 1, & \text{se } x \in \mathcal{A} \\ 0, & \text{se } x \notin \mathcal{A} \end{cases} \quad (6.1)$$

La ecuación (6.1) es la base del llamado axioma de separación [77], que establece las dos leyes (o axiomas) fundamentales de la teoría de conjuntos:

- a) la ley del tercero excluido: $\mathcal{A} \cup \bar{\mathcal{A}} = \mathcal{X}$; b)
- la ley de la no contradicción: $\mathcal{A} \cap \bar{\mathcal{A}} = \emptyset$.

La noción de conjunto se extiende al concepto de partición, particularmente útil en ciencia de datos, en el que el universo se subdivide en K subconjuntos disjuntos.

En el análisis de conglomerados, la partición del conjunto de datos (de entrenamiento) $\mathcal{T}$ en subconjuntos K se define como $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$ de modo que se cumplan las siguientes condiciones:

- i. La unión de todos los subconjuntos es el universo: $\bigcup_{i=1}^K \mathcal{C}_i = \mathcal{T}$; ii. Los subconjuntos no tienen elementos en común: $\mathcal{C}_i \cap \mathcal{C}_j = \emptyset$, $i \neq j$.

Descubrir una partición en un conjunto de datos es computacionalmente complejo; la partición de un conjunto de datos con registros N en solo dos subconjuntos, con registros N_1 y N_2 respectivamente, implica la evaluación de particiones distintas $N!/(N_1!N_2!)$. Por ejemplo, un conjunto de datos de registros $N = 100$ se puede dividir en dos subconjuntos de registros $N_1 = N_2 = 50$ de diferentes maneras. Además de la complejidad inherente al problema, la calidad de la agrupación no está bien definida y, en general, se utilizan índices de validación (cf. apartado 6.5).

Na análise de agrupamentos, um grupo é definido como um conjunto de registros similares entre si e dissimilares dos registros alocados em outros grupos. A escolha do melhor agrupamento num conjunto de dados é uma tarefa analítica que depende muito da interpretação dos grupos no contexto da aplicação. O conjunto de dados da Figura 6.1a pode ser dividido em dois grupos, como mostrado na Figura 6.1b, mas também em quatro ou seis grupos, como nas Figura 6.1c e d [516]. A decisão sobre a melhor solução vai depender muito da aplicação.




Figura 6.1: Diferentes agrupamentos sobre o mesmo conjunto de dados: (a) conjunto de dados; (b) dois grupos; (c) quatro grupos; (d) seis grupos. Fonte: [516].

Observando a Figura 6.1, percebemos que os grupos da Figura 6.1d estão contidos na Figura 6.1c, que, por sua vez, estão contidos na partição da Figura 6.1b. Dessa forma, uma solução para a dificuldade de avaliação da qualidade do agrupamento é realizá-lo de forma hierárquica, como nos algoritmos apresentados na seção 6.3.

Outra característica importante da análise de agrupamentos é que os grupos encontrados podem não corresponder às classes de um problema supervisionado. Isso não significa que o algoritmo de agrupamento tenha falhado, apenas que os padrões encontrados não correspondem às classes. Isso acontece porque os algoritmos de agrupamento utilizam informações dos registros e a classificação é usualmente uma informação externa aos registros. Dessa forma, o entendimento da análise de agrupamentos como “classificação não supervisionada” deve ser utilizado com cautela.

A Figura 6.2a mostra um conjunto de dados contendo claramente quatro grupos, embora esse mesmo conjunto tenha sido apresentado como um problema de duas classes no exemplo da Figura 5.6.

En el análisis de conglomerados, un grupo se define como un conjunto de registros que son similares entre sí y diferentes de los registros asignados a otros grupos. Elegir la mejor agrupación en un conjunto de datos es una tarea analítica que depende en gran medida de la interpretación de los grupos en el contexto de la aplicación. El conjunto de datos de la Figura 6.1a se puede dividir en dos grupos, como se muestra en la Figura 6.1b, pero también en cuatro o seis grupos, como en las Figuras 6.1c y d [516]. Decidir cuál es la mejor solución dependerá en gran medida de la aplicación.




Figura 6.1: Diferentes agrupaciones en el mismo conjunto de datos: (a) conjunto de datos; (b) dos grupos; c) cuatro grupos; d) seis grupos. Fuente: [516].

Al observar la Figura 6.1, notamos que los grupos de la Figura 6.1d están contenidos en la Figura 6.1c, que, a su vez, están contenidos en la partición de la Figura 6.1b. Por tanto, una solución a la dificultad de evaluar la calidad del clustering es realizarlo de forma jerárquica, como en los algoritmos presentados en la sección 6.3.

Otra característica importante del análisis de conglomerados es que los grupos encontrados pueden no corresponder a las clases de un problema supervisado. Esto no significa que el algoritmo de agrupamiento haya fallado, sólo que los patrones encontrados no corresponden a las clases. Esto sucede porque los algoritmos de agrupación utilizan información de los registros y la clasificación suele ser información externa a los registros. Por lo tanto, debe utilizarse con cautela entender el análisis de conglomerados como “clasificación no supervisada”.

La figura 6.2a muestra un conjunto de datos que contiene claramente cuatro grupos, aunque este mismo conjunto se presentó como un problema de dos clases en el ejemplo de la figura 5.6.




Figura 6.2: Exemplo de agrupamento: (a) conjunto de dados; (b) dados classificados.

Os algoritmos apresentados neste capítulo utilizam métricas de distância, como as definidas na seção 2.2.3, para variáveis numéricas. Há diversas outras, além de métricas para variáveis binárias e categóricas [194]. A escolha das métricas de distância ou similaridade pode tornar o problema ainda mais complexo, pois não há um critério universal para guiar tal escolha [232]. A abordagem mais simples para o tratamento de variáveis nominais é a sua transformação em variáveis indicadoras (cf. equação (5.14)) e a utilização de métricas definidas para as variáveis numéricas.

O algoritmo clássico em análise de agrupamentos é o algoritmo k-médias, em que os grupos são definidos a partir da distância de cada elemento ao centro do grupo. O k-médias é um algoritmo dos métodos de partição. Neste tipo de método, a métrica de distância determina o formato do grupo. A Figura 6.3 mostra um conjunto de pontos e regiões métricas de distância em relação ao centro, onde as regiões escuras representam valores menores. A distância euclidiana (norma L^2), mostrada na Figura 6.3b, gera grupos de forma esférica; a distância de Mahalanobis induz grupos elipsoides (Figura 6.3c); as distâncias de Manhattan (norma L^1) e de norma infinita (L^∞) geram hipercubos (Figura 6.3a e d). Dessa forma, a escolha da função de distância ou similaridade influencia o resultado do algoritmo de agrupamento.




Figura 6.2: Ejemplo de agrupación: (a) conjunto de datos; (b) datos clasificados.

Los algoritmos presentados en este capítulo utilizan métricas de distancia, como las definidas en la sección 2.2.3, para variables numéricas. Hay varios otros, además de métricas para variables binarias y categóricas [194]. La elección de métricas de distancia o similitud puede hacer que el problema sea aún más complejo, ya que no existe un criterio universal que oriente dicha elección [232]. El enfoque más simple para tratar las variables nominales es su transformación en variables indicadoras (cf. ecuación (5.14)) y el uso de métricas definidas para las variables numéricas.

El algoritmo clásico en el análisis de conglomerados es el algoritmo k-medias, en el que los grupos se definen en función de la distancia de cada elemento al centro del grupo. El k-means es un algoritmo de métodos de partición. En este tipo de método, la métrica de distancia determina la forma del grupo. La Figura 6.3 muestra un conjunto de puntos y regiones métricas alejadas del centro, donde las regiones oscuras representan valores más pequeños. La distancia euclidiana (norma L^2), mostrada en la Figura 6.3b, genera grupos de forma esférica; la distancia de Mahalanobis induce grupos elipsoides (Figura 6.3c); Las distancias de Manhattan (norma L^1) y la norma infinita (L^∞) generan hipercubos (Figura 6.3a y d). Por tanto, la elección de la función de distancia o similitud influye en el resultado del algoritmo de agrupamiento.




Figura 6.3: Métricas de distância: (a) distância de Manhattan (L^1); (b) distância euclidiana (L^2); (c) distância de Mahalanobis; (d) norma infinita (L^∞).

A interseção entre dois grupos calculados na análise de agrupamentos também forma uma superfície de decisão, como no problema de classificação. Um conjunto de dados pode conter grupos que formam superfícies de decisão convexas ou não convexas, como ilustrado na Figura 6.4. Em grupos convexas, como o da Figura 6.4a, as superfícies de decisão podem ser aproximadas por funções lineares. Em agrupamentos não convexas, como na Figura 6.4b, a superfície de decisão é uma função não linear.

Algoritmos mais simples, como os métodos de partição apresentados na seção 6.2, geram agrupamentos convexas. Algoritmos capazes de gerar agrupamentos não convexas podem representar melhor as características do conjunto de dados. Os métodos hierárquicos, apresentados na seção 6.3, e os métodos baseados em grafos, descritos na seção 6.4, encontram grupos não convexas.




Figura 6.3: Métricas de distancia: (a) distancia desde Manhattan (L^1); (b) distancia euclidiana (L^2); (c) distancia de Mahalanobis; (d) norma infinita (L^∞).

La intersección entre dos grupos calculada en el análisis de conglomerados también forma una superficie de decisión, como en el problema de clasificación. Un conjunto de datos puede contener grupos que formen superficies de decisión convexas o no convexas, como se ilustra en la figura 6.4. En grupos convexas, como el de la figura 6.4a, las superficies de decisión se pueden aproximar mediante funciones lineales. En conglomerados no convexas, como en la figura 6.4b, la superficie de decisión es una función no lineal.

Los algoritmos más simples, como los métodos de partición presentados en la sección 6.2, generan clústeres convexas. Los algoritmos capaces de generar grupos no convexas pueden representar mejor las características del conjunto de datos. Los métodos jerárquicos, presentados en la sección 6.3, y los métodos basados en gráficos, descritos en la sección 6.4, encuentran grupos no convexas.




Figura 6.4: Forma de grupos: (a) convexa; (b) não convexa.

6.2 Métodos de Partição

Os métodos de partição buscam diretamente uma partição do conjunto de dados através da minimização de um critério de avaliação. O método de partição (e de agrupamento) mais amplamente utilizado é o algoritmo k-médias, em que o critério de custo é calculado em função do quadrado da distância entre os registros e as coordenadas dos centros, conforme descrito a seguir.

6.2.1 Algoritmo k-médias

O algoritmo k-médias é um algoritmo simples e eficiente que geralmente converge num número reduzido de iterações na maioria dos problemas. O algoritmo original foi proposto há mais de 50 anos* [285], mas continua sendo utilizado em diversas áreas e pode ser encontrado nos principais *softwares* e bibliotecas.

O objetivo do algoritmo k-médias é encontrar uma partição no conjunto de dados em K grupos $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$ através da minimização da seguinte função de avaliação:

$$J(\mathbf{\Omega}) = \sum_{t=1}^N \sum_{i=1}^K u_i(\mathbf{x}(t)) \|\mathbf{x}(t) - \mathbf{\omega}_i\|^2 \quad (6.2)$$

* O algoritmo é atribuído ao trabalho proposto por Lloyd em 1957 para representação digital de sinais analógicos, que só foi publicado em 1982 [353]. Entretanto, é muito difícil reconhecê-lo nesse artigo. O algoritmo na sua forma atual foi proposto por MacQueen em 1967 [359].




Figura 6.4: Forma de los grupos: (a) convexo; (b) no convexo.

6.2 Métodos de partición

Los métodos de partición buscan directamente una partición del conjunto de datos minimizando un criterio de evaluación. El método de partición (y agrupación) más utilizado es el algoritmo k-means, en el que el criterio de coste se calcula en función del cuadrado de la distancia entre los registros y las coordenadas de los centros, como se describe a continuación.

6.2.1 algoritmo k-medias

El algoritmo k-means es un algoritmo simple y eficiente que generalmente converge en un pequeño número de iteraciones en la mayoría de los problemas. El algoritmo original se propuso hace más de 50 años* [285], pero continúa utilizándose en varias áreas y se puede encontrar en las principales bibliotecas y *softwares*.

El objetivo del algoritmo k-means es encontrar una partición en el conjunto de datos en K grupos $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$ minimizando la siguiente función de evaluación:

$$J(\mathbf{\Omega}) = \sum_{t=1}^N \sum_{i=1}^K u_i(\mathbf{x}(t)) \|\mathbf{x}(t) - \mathbf{\omega}_i\|^2 \quad (6.2)$$

* O algoritmo é atribuído ao trabalho proposto por Lloyd em 1957 para representação digital de sinais analógicos, que só foi publicado em 1982 [353]. Entretanto, é muito difícil reconhecê-lo nesse artigo. O algoritmo na sua forma atual foi proposto por MacQueen em 1967 [359].

onde $\boldsymbol{\omega}_i = \frac{1}{\hat{N}_i} \sum_{\mathbf{x}(t) \in \mathcal{C}_i} \mathbf{x}(t)$ é o vetor com as coordenadas do centro do grupo $\mathcal{C}_i$ e a matriz $\boldsymbol{\Omega} = [\boldsymbol{\omega}_1^T, \dots, \boldsymbol{\omega}_K^T]$ representa os centros de todos os grupos.

A função $u_i(\mathbf{x}(t))$ na equação (6.2) define a pertinência de um registro $\mathbf{x}(t)$ ao grupo $\mathcal{C}_i$ (cf. equação (6.1)) como:

$$u_i(\mathbf{x}(t)) = \begin{cases} 1, & \text{se } \mathbf{x}(t) \in \mathcal{C}_i \\ 0, & \text{se } \mathbf{x}(t) \notin \mathcal{C}_i \end{cases} \quad (6.3)$$

A cardinalidade do grupo $\mathcal{C}_i$ é o número de registros do grupo, isto é, $|\mathcal{C}_i| = \hat{N}_i$, pode ser calculada pela soma dos valores de pertinência ao grupo como $\hat{N}_i = \sum_{t=1}^N u_i(\mathbf{x}(t))$.

A função de avaliação (6.2) pode ser interpretada pela decomposição da variância total dos dados como $\boldsymbol{\Sigma}_T = \boldsymbol{\Sigma}_W + \boldsymbol{\Sigma}_B$ [146][573], apresentada na seção 2.4.3.

A matriz de variância total $\boldsymbol{\Sigma}_T = (N - 1)\hat{\boldsymbol{\Sigma}}$, onde $\hat{\boldsymbol{\Sigma}}$ é a matriz de covariâncias estimada (cf. equação (2.5)), é calculada como:

$$\boldsymbol{\Sigma}_T = \sum_{t=1}^N (\mathbf{x}(t) - \bar{\mathbf{x}})^T (\mathbf{x}(t) - \bar{\mathbf{x}}) \quad (6.4)$$

onde $\bar{\mathbf{x}} = \frac{1}{N} \sum_{t=1}^N \mathbf{x}(t)$ é a média dos registros do conjunto de treinamento, que também pode ser calculada pela média ponderada dos centros de grupos como $\bar{\mathbf{x}} = \frac{1}{N} \sum_{i=1}^K \hat{N}_i \boldsymbol{\omega}_i$.

A matriz de variâncias intragrupos $\boldsymbol{\Sigma}_W$ e a matriz de variância entre grupos $\boldsymbol{\Sigma}_B$ são calculadas como (cf. seção 2.4.3):

$$\boldsymbol{\Sigma}_B = \sum_{i=1}^K N_i (\boldsymbol{\omega}_i - \bar{\mathbf{x}})^T (\boldsymbol{\omega}_i - \bar{\mathbf{x}}) \quad (6.5)$$

$$\boldsymbol{\Sigma}_W = \sum_{t=1}^N \sum_{i=1}^K u_i(\mathbf{x}(t)) (\mathbf{x}(t) - \boldsymbol{\omega}_i)^T (\mathbf{x}(t) - \boldsymbol{\omega}_i) \quad (6.6)$$

A função de avaliação (6.2) é soma dos elementos da diagonal principal (traço) da matriz de variância intragrupos $\boldsymbol{\Sigma}_W$, cuja minimização resulta na minimização da variância intragrupos $\boldsymbol{\Sigma}_W$ e, portanto, em grupos mais compactos. A variância total $\boldsymbol{\Sigma}_T$ não é função do agrupamento e se mantém constante, de forma que a minimização da variância intragrupos implica a maximização da variância entre grupos $\boldsymbol{\Sigma}_B$, ou seja, em grupos mais separados.

donde $\boldsymbol{\omega}_i = \frac{1}{\hat{N}_i} \sum_{\mathbf{x}(t) \in \mathcal{C}_i} \mathbf{x}(t)$ es el vector con las coordenadas del centro del grupo $\mathcal{C}_i$ y la matriz $\boldsymbol{\Omega} = [\boldsymbol{\omega}_1, \dots, \boldsymbol{\omega}_K]$ representa los centros de todos los grupos.

La función $u_i(\mathbf{x}(t))$ en la ecuación (6.2) define la pertenencia de un registro $\mathbf{x}(t)$ al grupo $\mathcal{C}_i$ (cf. ecuación (6.1)) como:

$$u_i(\mathbf{x}(t)) = \begin{cases} 1, & \text{se } \mathbf{x}(t) \in \mathcal{C}_i \\ 0, & \text{se } \mathbf{x}(t) \notin \mathcal{C}_i \end{cases} \quad (6.3)$$

La cardinalidad del grupo $\mathcal{C}_i$ es la cantidad de registros en el grupo, es decir, $|\mathcal{C}_i| = \hat{N}_i$, se puede calcular sumando los valores de membresía del grupo como $\hat{N}_i = \sum_{t=1}^N u_i(\mathbf{x}(t))$.

La función de evaluación (6.2) se puede interpretar descomponiendo la varianza total de los datos como $\boldsymbol{\Sigma}_T = \boldsymbol{\Sigma}_W + \boldsymbol{\Sigma}_B$ [146][573], presentado en la sección 2.4.3.

La matriz de varianza total $\boldsymbol{\Sigma}_T = (N-1)\hat{\boldsymbol{\Sigma}}$ donde $\hat{\boldsymbol{\Sigma}}$ es la matriz de covarianza estimada (cf. ecuación (2.5)), se calcula como:

$$\boldsymbol{\Sigma}_T = \sum_{t=1}^N (\mathbf{x}(t) - \bar{\mathbf{x}})^T (\mathbf{x}(t) - \bar{\mathbf{x}}) \quad (6.4)$$

donde $\bar{\mathbf{x}} = \frac{1}{N} \sum_{t=1}^N \mathbf{x}(t)$ es el promedio de los registros del conjunto de entrenamiento, que también se puede calcular mediante el promedio ponderado de los centros del grupo como $\bar{\mathbf{x}} = \frac{1}{N} \sum_{i=1}^K \hat{N}_i \boldsymbol{\omega}_i$.

La matriz de varianza intragrupo $\boldsymbol{\Sigma}_W$ y la matriz de varianza intergrupo $\boldsymbol{\Sigma}_B$ se calculan como (ver sección 2.4.3):

$$\boldsymbol{\Sigma}_B = \sum_{i=1}^K N_i (\boldsymbol{\omega}_i - \bar{\mathbf{x}})^T (\boldsymbol{\omega}_i - \bar{\mathbf{x}}) \quad (6.5)$$

$$\boldsymbol{\Sigma}_W = \sum_{t=1}^N \sum_{i=1}^K u_i(\mathbf{x}(t)) (\mathbf{x}(t) - \boldsymbol{\omega}_i)^T (\mathbf{x}(t) - \boldsymbol{\omega}_i) \quad (6.6)$$

La función de evaluación (6.2) es la suma de los elementos de la diagonal principal (guión) de la matriz de varianza intragrupo $\boldsymbol{\Sigma}_W$, cuya minimización da como resultado la minimización de la varianza intragrupo $\boldsymbol{\Sigma}_W$ y, por tanto, en grupos más compactos. La varianza total $\boldsymbol{\Sigma}_T$ no es función de la agrupación y permanece constante, de modo que minimizar la varianza intragrupo implica maximizar la varianza entre grupos $\boldsymbol{\Sigma}_B$, es decir, en grupos más separados.

A minimização da função (6.2) é um problema NP-difícil [12][360]. O algoritmo k-médias aplica uma heurística gulosa para a solução eficiente do problema. Entretanto, o resultado depende muito da estrutura dos dados e uma solução de ótimo local pode ser encontrada, o que torna o resultado dependente da inicialização.

O algoritmo k-médias é descrito no Algoritmo 6.1. Sua execução é feita a partir de uma matriz de centros fornecida na inicialização que, em geral, é aleatória. A cada iteração, cada registro do conjunto de dados é alocado ao grupo mais próximo. Embora outras métricas de distância possam ser utilizadas dependendo da implementação, o algoritmo k-médias clássico utiliza a distância euclidiana. Após uma passagem por todo o conjunto de dados, o centro de cada grupo é atualizado como a média das coordenadas dos registros alocados ao grupo.

Algoritmo 6.1: Algoritmo k-médias

Entrada:	Conjunto de treinamento $\mathcal{T} = \{\mathbf{x}(t), t = 1 \dots N\}$, estimativa inicial de centros $\mathbf{\Omega} = [\boldsymbol{\omega}_1^T, \dots, \boldsymbol{\omega}_K^T]$
Saída:	Matriz de centros $\mathbf{\Omega} = [\boldsymbol{\omega}_1^T, \dots, \boldsymbol{\omega}_K^T]$
01	Início
02	$\varepsilon \leftarrow \infty$
03	Enquanto $\varepsilon > tol$
04	Para $t = 1, \dots, N$
05	$\mathbf{x}(t) \in \mathcal{C}_i \Leftrightarrow \boldsymbol{\omega}_i = \underset{j}{\operatorname{argmin}} \left(\ \mathbf{x}(t) - \boldsymbol{\omega}_j\ ^2 \right)$
06	Fim Para
07	$\mathbf{\Omega}_0 \leftarrow \mathbf{\Omega}$
08	Atualizar $\mathbf{\Omega}$ com $\boldsymbol{\omega}_i = \frac{\sum_{t=1}^N u_i(\mathbf{x}(t))\mathbf{x}(t)}{\sum_{t=1}^N u_i(\mathbf{x}(t))}, i = 1, \dots, K$
09	Calcular critério de parada $\varepsilon = \ \mathbf{\Omega}_0 - \mathbf{\Omega}\ $
10	Fim Enquanto
11	Retorna $\mathbf{\Omega} = [\boldsymbol{\omega}_1^T, \dots, \boldsymbol{\omega}_K^T]$
12	Fim

O critério de parada do algoritmo, calculado no passo 09, é a norma L^2 da diferença entre as matrizes dos centros calculados em duas iterações sucessivas. O algoritmo é

La minimización de la función (6.2) es un problema NP-difícil [12][360]. El algoritmo k-means aplica una heurística codiciosa para resolver el problema de manera eficiente. Sin embargo, el resultado depende en gran medida de la estructura de datos y se puede encontrar una solución óptima local, lo que hace que el resultado dependa de la inicialización.

El algoritmo k-medias se describe en el Algoritmo 6.1. Se ejecuta utilizando una matriz de centros proporcionada en la inicialización, que generalmente es aleatoria. En cada iteración, cada registro del conjunto de datos se asigna al grupo más cercano. Aunque se pueden utilizar otras métricas de distancia según la implementación, el algoritmo clásico de k-medias utiliza la distancia euclidiana. Después de recorrer todo el conjunto de datos, el centro de cada grupo se actualiza como el promedio de las coordenadas de los registros asignados al grupo.

Algoritmo 6.1: Algoritmo K-Means

Entrada:	Conjunto de treinamento $\mathcal{T} = \{\mathbf{x}(t), t = 1 \dots N\}$, estimativa inicial de centros $\mathbf{\Omega} = [\boldsymbol{\omega}_1^T, \dots, \boldsymbol{\omega}_K^T]$
Saída:	Matriz de centros $\mathbf{\Omega} = [\boldsymbol{\omega}_1^T, \dots, \boldsymbol{\omega}_K^T]$
01	Início
02	$\varepsilon \leftarrow \infty$
03	Enquanto $\varepsilon > tol$
04	Para $t = 1, \dots, N$
05	$\mathbf{x}(t) \in \mathcal{C}_i \Leftrightarrow \boldsymbol{\omega}_i = \underset{j}{\operatorname{argmin}} \left(\ \mathbf{x}(t) - \boldsymbol{\omega}_j\ ^2 \right)$
06	Fim Para
07	$\mathbf{\Omega}_0 \leftarrow \mathbf{\Omega}$
08	Atualizar $\mathbf{\Omega}$ com $\boldsymbol{\omega}_i = \frac{\sum_{t=1}^N u_i(\mathbf{x}(t))\mathbf{x}(t)}{\sum_{t=1}^N u_i(\mathbf{x}(t))}, i = 1, \dots, K$
09	Calcular critério de parada $\varepsilon = \ \mathbf{\Omega}_0 - \mathbf{\Omega}\ $
10	Fim Enquanto
11	Retorna $\mathbf{\Omega} = [\boldsymbol{\omega}_1^T, \dots, \boldsymbol{\omega}_K^T]$
12	Fim

El criterio de parada del algoritmo, calculado en el paso 09, es la norma L^2 de la diferencia entre las matrices centrales calculadas en dos iteraciones sucesivas. El algoritmo es

interrompido se não há mudanças significativas dos centros. O número máximo de iterações também pode ser utilizado como critério de parada.

A cada iteração, uma partição do conjunto de dados deve ser encontrada, de forma que, se algum grupo não tiver nenhum registro alocado no passo 05, uma ação precisa ser realizada para evitar erro de divisão por zero no passo 08. Dependendo do *software*, diferentes ações podem ser realizadas. No Matlab,¹³⁶ por exemplo, o usuário pode escolher entre uma mensagem de erro (*default*), a eliminação do grupo ou a geração de novas coordenadas aleatoriamente. A possibilidade de redefinição de centros aleatoriamente causa instabilidades ao algoritmo.

Em geral, o algoritmo k-médias converge rapidamente e a complexidade de cada iteração do algoritmo é estimada em $O(NKp)$, onde p é o número de variáveis, K o número de grupos e N o número de registros. Em problemas em que $Kp \ll N$, a complexidade do algoritmo é dominada por $O(N)$. Em problemas de grandes dimensões, a busca por um agrupamento com muitos grupos resulta em $Kp \approx N$ e a complexidade do algoritmo é $O(N^2)$. Em alocação de memória, a complexidade do algoritmo é definida pelo armazenamento do conjunto de dados como $O(Np) \approx O(N)$.

Há diversas variantes do algoritmo k-médias [194][229][285][573]. O algoritmo ISO-DATA,* proposto em 1967 [27], é uma variante do k-médias que, muitas vezes, é confundido com o próprio. O algoritmo ISODATA ajusta automaticamente o número de grupos, agrupando-os e subdividindo-os de acordo com limites especificados, e elimina aqueles com poucos registros. No algoritmo ISODATA, a escolha do número de grupos é substituída pela escolha dos parâmetros do algoritmo.

O resultado do algoritmo k-médias é muito sensível à presença de *outliers* e ruído no conjunto de dados. Um *outlier* será associado a algum grupo e contabilizado no cálculo da média, o que pode afastar os centros calculados dos centros do conjunto mais denso de registros. Algumas variantes do k-médias visam maior robustez a *outliers*, como os algoritmos k-medoids [300], PAM† e CLARA.‡ Nesse tipo de algoritmo, o centro do grupo é um registro do conjunto de treinamento, chamado *medoid*, que tem a menor distância média para todos os registros do grupo. Os algoritmos PAM e CLARA aplicam a mesma ideia de k-medoids, mas o segundo utiliza apenas uma amostra do conjunto de dados

* *Iterative Self-Organizing Data Analysis Technique*

† *Partition Around Medoids*

‡ *Clustering LARge Applications*

interrumpido si no se producen cambios significativos en los centros. El número máximo de iteraciones también se puede utilizar como criterio de parada.

En cada iteración, se debe encontrar una partición del conjunto de datos, de modo que si algún grupo no tiene ningún registro asignado en el paso 05, se debe tomar una acción para evitar el error de división por cero en el paso 08. Dependiendo de *software*, se pueden realizar diferentes acciones. En Matlab, ¹³⁶ por ejemplo, el usuario puede elegir entre un mensaje de error (*default*), eliminar el grupo o generar nuevas coordenadas de forma aleatoria. La posibilidad de redefinir centros aleatoriamente provoca inestabilidades en el algoritmo.

En general, el algoritmo k-means converge rápidamente y la complejidad de cada iteración del algoritmo se estima en $O(NKp)$, donde p es el número de variables, K el número de grupos y N el número de registros. En problemas donde $Kp \ll N$, la complejidad del algoritmo está dominada por $O(N)$. En problemas grandes, la búsqueda de un cluster con muchos grupos da como resultado $Kp \approx N$ y la complejidad del algoritmo es $O(N^2)$. En la asignación de memoria, la complejidad del algoritmo se define almacenando el conjunto de datos como $O(Np) \approx O(N)$.

Existen varias variantes del algoritmo k-medias [194][229][285][573]. El algoritmo ISO-DATA,* propuesto en 1967 [27], es una variante de k-means que a menudo se confunde consigo mismo. El algoritmo ISODATA ajusta automáticamente el número de grupos, agrupándolos y subdividiéndolos según límites especificados, y elimina aquellos con pocos registros. En el algoritmo ISODATA, la elección del número de grupos se reemplaza por la elección de los parámetros del algoritmo.

El resultado del algoritmo k-means es muy sensible a la presencia de *outliers* y ruido en el conjunto de datos. Un *outlier* se asociará con algún grupo y se contará en el cálculo del promedio, lo que puede desviar los centros calculados de los centros del conjunto de registros más denso. Algunas variantes de k-means apuntan a una mayor robustez para *outliers*, como los algoritmos k-medoids [300], PAM† y CLARA‡. En este tipo de algoritmo, el centro del grupo es un registro del conjunto de entrenamiento, llamado *medoid*, que tiene la distancia promedio más pequeña a todos los registros del grupo. Los algoritmos PAM y CLARA aplican la misma idea que k-medoids, pero el segundo solo utiliza una muestra del conjunto de datos.

* *Iterative Self-Organizing Data Analysis Technique*

† *Partition Around Medoids*

‡ *Clustering LARge Applications*

para reduzir a complexidade computacional [521]. O algoritmo CLARANS* [416] é uma variante dos *k-medoids* mais complexa que o CLARA que obtém melhores resultados [521]. Outra abordagem para a solução do problema de *outliers* é obtida pelos algoritmos chamados *k-medianas* [83][378], cujos centros de grupos também são registros do conjunto de treinamento.

Há trabalhos mais recentes com outras variantes do *k-médias*. No algoritmo *x-médias* [434], o número de grupos é otimizado a partir dos critérios AIC e BIC, utilizados para seleção de estrutura de modelos de regressão [238]. O algoritmo *k-médias esférico*¹³⁷ [126][602] utiliza a similaridade do cosseno como métrica, sendo indicado para problemas de alta dimensionalidade. Zhao e Karypis [600] discutem algumas alternativas à função de avaliação quadrática para o agrupamento de documentos. Algumas abordagens têm sido propostas para a inicialização do *k-médias*, como PCA-Part [508], CCIA [302] e o algoritmo *k-médias++* [21][421].

O algoritmo *fuzzy c-médias* é uma variante importante do *k-médias*, em que o conceito pertinência ao grupo é estendido por funções de pertinência *fuzzy*. O algoritmo *fuzzy c-médias* será apresentado no Capítulo 8.

O *k-médias* é um algoritmo simples e eficiente, mas apresenta algumas características e limitações, discutidas nos exemplos a seguir.

6.2.2 Exemplos

A forma dos grupos encontrados pelo algoritmo *k-médias* depende da métrica de distância utilizada (cf. Figura 6.3). Com a distância euclidiana, os grupos encontrados pelo *k-médias* têm formato hiper esférico, de modo que a superfície de decisão entre grupos é aproximada por uma função linear. Dessa forma, as regiões associadas aos grupos formam um diagrama de Voronoi¹³⁸ no espaço de variáveis de entrada. A Figura 6.5 apresenta os resultados do algoritmo *k-médias* sobre os dados de Diabetes das índias Pima, projetado no plano definido pela ACP. Podemos observar claramente as superfícies de decisão lineares entre os grupos.

* *Clustering LARge Applications based on RANdomized Search*

para reducir la complejidad computacional [521]. El algoritmo CLARANS* [416] es una variante de *k-medoids* que es más complejo que CLARA y obtiene mejores resultados [521]. Otro enfoque para resolver el problema *outliers* se obtiene mediante algoritmos llamados *k-medianas* [83][378], cuyos centros de grupo son también registros del conjunto de entrenamiento.

Hay trabajos más recientes con otras variantes de *k-medias*. En el algoritmo *x-means* [434], el número de grupos se optimiza en función de los criterios AIC y BIC, utilizados para seleccionar la estructura de los modelos de regresión [238]. El algoritmo *k-means esférico*¹³⁷ [126][602] utiliza la similitud del coseno como métrica y se recomienda para problemas de alta dimensión. Zhao y Karypis [600] analizan algunas alternativas a la función de evaluación cuadrática para la agrupación de documentos. Se han propuesto algunos enfoques para inicializar *k-means*, como PCA-Part [508], CCIA [302] y el algoritmo *k-means ++* [21][421].

El algoritmo *c-means fuzzy* es una variante importante del *k-means*, en el que el concepto de pertenencia al grupo se amplía mediante funciones de pertenencia *fuzzy*. El algoritmo *c-means fuzzy* se presentará en el Capítulo 8.

k-means es un algoritmo simple y eficiente, pero tiene algunas características y limitaciones, que se analizan en los siguientes ejemplos.

6.2.2 Ejemplos

La forma de los grupos encontrados por el algoritmo *k-means* depende de la métrica de distancia utilizada (ver Figura 6.3). Con la distancia euclidiana, los grupos encontrados por *k-medias* tienen una forma hipersférica, de modo que la superficie de decisión entre grupos se aproxima mediante una función lineal. De esta forma, las regiones asociadas a los grupos forman un diagrama de Voronoi¹³⁸ en el espacio de variables de entrada. La Figura 6.5 presenta los resultados del algoritmo *k-means* sobre datos de diabetes de los indios Pima, diseñado según el plan definido por la ACP. Podemos observar claramente superficies de decisión lineales entre grupos.

* *Clustering LARge Applications based on RANdomized Search*

O algoritmo k-médias tem algumas limitações, tais como encontrar grupos de tamanhos muito diferentes [516] e grupos de forma não convexa. Entretanto, é possível utilizar o algoritmo para encontrar um número maior de grupos e, posteriormente, agregar grupos para obter formas não convexas.




Figura 6.5: Resultados no conjunto de dados Diabetes projetados em 2D pela ACP:

(a) $K = 3$ grupos; (b) $K = 7$ grupos.

A Figura 6.6 mostra os resultados do k-médias no conjunto de dados das duas luas. Na Figura 6.6a, o resultado do algoritmo com $K = 2$ mostra que não foi possível identificar os dois grupos. O resultado com $K = 6$ grupos é mostrado na Figura 6.6b permite verificar que é possível encontrar os grupos pela agregação de subgrupos. Essa solução é aplicada no desenvolvimento de modelos de base radial, apresentados no Capítulo 7.




Figura 6.6: Resultados no conjunto de dados duas luas: (a) $K = 2$ grupos; (b) $K = 6$ grupos.

El algoritmo k-means tiene algunas limitaciones, como encontrar grupos de tamaños muy diferentes [516] y grupos de forma no convexa. Sin embargo, es posible utilizar el algoritmo para encontrar un mayor número de grupos y, posteriormente, agregar grupos para obtener formas no convexas.




Figura 6.5: Resultados del conjunto de datos de Diabetes diseñado en 2D por ACP:

(a) grupos $K = 3$; (b) $K = 7$ grupos.

La Figura 6.6 muestra los resultados de k-medias en el conjunto de datos de dos lunas. En la Figura 6.6a, el resultado del algoritmo con $K = 2$ muestra que no fue posible identificar los dos grupos. El resultado con grupos $K = 6$ se muestra en la Figura 6.6b, lo que nos permite verificar que es posible encontrar los grupos agregando subgrupos. Esta solución se aplica en el desarrollo de modelos de base radial, presentados en el Capítulo 7.




Figura 6.6: Resultados del conjunto de datos de dos lunas: (a) grupos $K = 2$; (b) $K = 6$ grupos.

A principal limitação do algoritmo k-médias é a dependência da estimativa inicial dos centros de grupos, que ocorre principalmente em problemas em que o número de grupos não corresponde à estrutura dos dados. A Figura 6.7 mostra os resultados sobrepostos dos centros de grupos calculados em 100 execuções do algoritmo k-médias sobre os dados do problema de quatro grupos. Com $K = 2$ grupos, a Figura 6.7a mostra que o algoritmo particiona os dados horizontalmente ou verticalmente. Com $K = 3$ ou $K = 5$ (Figuras 6.7b e d), soluções diferentes são encontradas em cada execução. No caso de $K = 4$ grupos (Figura 6.7c), todas as execuções convergem para a mesma solução, que corresponde aos centros dos grupos.




Figura 6.7: Resultados de centros encontrados pelo k-médias no conjunto de dados de quatro grupos: (a) $K = 2$ grupos; (b) $K = 3$ grupos; (c) $K = 4$ grupos; (d) $K = 5$ grupos.

A variação dos resultados do k-médias em execuções diferentes do algoritmo pode ser utilizada como um indicativo da qualidade do agrupamento. No exemplo da Figura 6.7, os dados têm quatro grupos muito bem definidos, de forma que o algoritmo k-médias

La principal limitación del algoritmo k-means es la dependencia de la estimación inicial de los centros de grupo, lo que ocurre principalmente en problemas en los que el número de grupos no se corresponde con la estructura de datos. La figura 6.7 muestra los resultados superpuestos de los centros de grupo calculados en 100 ejecuciones del algoritmo k-means sobre los datos del problema de cuatro grupos. Con grupos $K = 2$, la Figura 6.7a muestra que el algoritmo divide los datos horizontal o verticalmente. Con $K = 3$ o $K = 5$ (Figuras 6.7b y 6.7d), se encuentran diferentes soluciones en cada ejecución. En el caso de grupos $K = 4$ (Figura 6.7c), todas las ejecuciones convergen a la misma solución, que corresponde a los centros de los grupos.




Figura 6.7: Resultados de los centros encontrados por k-medias en el conjunto de datos de cuatro grupos: (a) grupos $K = 2$; (b) grupos $K = 3$; (c) grupos $K = 4$; (d) $K = 5$ grupos.

La variación en las k-medias da como resultado diferentes ejecuciones del algoritmo y pueden usarse como una indicación de la calidad del agrupamiento. En el ejemplo de la Figura 6.7, los datos tienen cuatro grupos muy bien definidos, de modo que el algoritmo k-means

encontra sempre o mínimo global, independentemente da inicialização. Quando o número de grupos não corresponde às características do conjunto de dados, o algoritmo encontra um mínimo local e o resultado depende da inicialização. Celebi e colaboradores [80] apresentam um estudo sobre os principais métodos de inicialização do k-médias, mas não discutem a influência da escolha do número de grupos. Algumas medidas de validação para escolha do melhor agrupamento são apresentadas na seção 6.5.

6.3 Métodos Hierárquicos

Os algoritmos de agrupamento hierárquicos geram uma estrutura hierárquica de agrupamentos em que cada nível representa uma partição do conjunto de dados definida na seção 6.1. A estrutura de agrupamentos hierárquicos em diferentes níveis é representada como uma árvore binária, chamada **dendrograma***.

Os métodos hierárquicos podem ser classificados em aglomerativos ou divisivos. Nos algoritmos aglomerativos, a estrutura hierárquica é construída a partir dos registros, sendo cada registro definido como um grupo *singleton*. Dessa forma, a partição do nível mais baixo da hierarquia é definida como $\mathbb{C}_0 = \mathcal{T}$, com $K = N$ grupos. A partir dos grupos *singletons*, o algoritmo constrói a estrutura hierárquica $\mathbb{C}_0 \subseteq \mathbb{C}_1 \subseteq \dots \subseteq \mathbb{C}_{N-1}$, iterativamente, fundindo grupos das partições dos níveis anteriores até formar a partição $\mathbb{C}_{N-1}$, que corresponde a um único grupo contendo todo o conjunto de dados. Nos algoritmos divisivos, a estratégia é de cima para baixo; a partição inicial $\mathbb{C}_0$ corresponde a um único grupo e a estrutura hierárquica $\mathbb{C}_{N-1} \subseteq \mathbb{C}_{N-2} \subseteq \dots \subseteq \mathbb{C}_0$ [522].

Nesta seção, são apresentados os algoritmos hierárquicos aglomerativos, que são mais comuns e podem ser encontrados na maioria dos *softwares*. Algoritmos divisivos são obtidos aplicando-se recursivamente em cada grupo e diferentes abordagens são encontradas na literatura [194][573].

* A palavra dendrograma é de origem grega, pela composição de *dendron*, que significa árvore, e *gramma*, desenho ou escrita.

siempre encuentra el mínimo global, independientemente de la inicialización. Cuando el número de grupos no se corresponde con las características del conjunto de datos, el algoritmo encuentra un mínimo local y el resultado depende de la inicialización. Celebi y colaborador es [80] presentan un estudio sobre los principales métodos de inicialización de k-medias, pero no discuten la influencia de la elección del número de grupos. Algunas medidas de validación para elegir la mejor agrupación se presentan en la sección 6.5.

6.3 Métodos Jerárquicos

Los algoritmos de agrupamiento jerárquico generan una estructura jerárquica de clusters en la que cada nivel representa una partición del conjunto de datos definido en la sección 6.1. La estructura de clústeres jerárquicos en diferentes niveles se representa como un árbol binario, llamado dendrograma*.

Los métodos jerárquicos se pueden clasificar en aglomerativos o divisivos. En los algoritmos aglomerativos, la estructura jerárquica se construye a partir de los registros, y cada registro se define como un grupo *singleton*. De esta manera, la partición de nivel más bajo en la jerarquía se define como $\mathbb{C}_0 = \mathcal{T}$, con grupos $K = N$. A partir de los grupos *singletons*, el algoritmo construye la estructura jerárquica $\mathbb{C}_0 \subseteq \mathbb{C}_1 \subseteq \dots \subseteq \mathbb{C}_{N-1}$, fusionando de forma iterativa grupos de particiones de niveles anteriores hasta formar la partición $\mathbb{C}_{N-1}$, que corresponde a un único grupo que contiene todo el conjunto de datos. En los algoritmos divisivos, la estrategia es de arriba hacia abajo; la partición inicial $\mathbb{C}_0$ corresponde a un solo grupo y la estructura jerárquica $\mathbb{C}_{N-1} \subseteq \mathbb{C}_{N-2} \subseteq \dots \subseteq \mathbb{C}_0$ [522].

En esta sección, se presentan los algoritmos de aglomeración jerárquica, que son los más comunes y se pueden encontrar en la mayoría de los *softwares*. Los algoritmos divisivos se obtienen aplicándolos recursivamente a cada grupo y se encuentran diferentes enfoques en la literatura [194][573].

* A palavra dendrograma é de origem grega, pela composição de *dendron*, que significa árvore, e *gramma*, desenho ou escrita.

6.3.1 Algoritmos aglomerativos

Os algoritmos hierárquicos aglomerativos seguem o procedimento geral descrito pelo Algoritmo 6.2, cujo resultado é uma estrutura hierárquica, utilizada para gerar o dendrograma que representa os agrupamentos formados em cada nível.

Algoritmo 6.2: Algoritmo hierárquico (adaptado de [522])

Entrada:	Conjunto de treinamento $\mathcal{T} = \{\mathbf{x}(t), t = 1 \dots N\}$
Saída:	Partições hierárquicas $\mathbb{C}_0 \subseteq \mathbb{C}_1 \subseteq \dots \subseteq \mathbb{C}_{N-1}$
01	Início
02	Calcular a matriz de distâncias $\mathbf{D}$
03	Definir $\mathbb{C}_0 = \{\mathcal{C}_i = \mathbf{x}(i), i = 1, \dots, N\}$
04	$k = 1$
05	Enquanto $k < N - 1$
06	Selecionar $\{\mathcal{C}_i, \mathcal{C}_j\} \in \mathbb{C}_{k-1}$ como $\operatorname{argmin}(L(\mathcal{C}_i, \mathcal{C}_j))$
07	Gerar a nova partição $\mathbb{C}_k = \{\mathbb{C}_{k-1} - \{\mathcal{C}_i, \mathcal{C}_j\}\} \cup \{\mathcal{C}_i \cup \mathcal{C}_j\}$
08	$k \leftarrow k + 1$
09	Fim Enquanto
10	Retorna $\{\mathbb{C}_0, \mathbb{C}_1, \dots, \mathbb{C}_{N-1}\}$
11	Fim

Em cada iteração k do Algoritmo 6.2, no passo 07, um par de grupos $\{\mathcal{C}_i, \mathcal{C}_j\}$ é retirado da partição $\mathbb{C}_{k-1}$ e a união $\{\mathcal{C}_i \cup \mathcal{C}_j\}$ é incluída na partição $\mathbb{C}_k$. A função de ligação $L(\mathcal{C}_i, \mathcal{C}_j)$ no passo 06 é utilizada para selecionar os grupos a serem unidos. Diferentes funções de ligação resultam em diferentes agrupamentos. Na literatura, as principais estratégias para função de ligação são:

- Vizinho mais próximo (**single-link**): a distância entre os grupos é calculada pelos elementos mais próximos [495]:

$$L_{\min}(\mathcal{C}_i, \mathcal{C}_j) = \min_{\substack{\mathbf{v} \in \mathcal{C}_i \\ \mathbf{v} \in \mathcal{C}_j}} \operatorname{dist}(\mathbf{v}, \mathbf{v}) \quad (6.7)$$

- Vizinho mais distante (**complete-link**): a distância entre os grupos é calculada pela distância máxima entre seus elementos:

6.3.1 Algoritmos aglomerativos

Los algoritmos jerárquicos aglomerativos siguen el procedimiento general descrito en el Algoritmo 6.2, cuyo resultado es una estructura jerárquica, utilizada para generar el dendrograma que representa los clusters formados en cada nivel.

Algoritmo 6.2: Algoritmo jerárquico (adaptado de [522])

Entrada:	Conjunto de treinamento $\mathcal{T} = \{\mathbf{x}(t), t = 1 \dots N\}$
Saída:	Partições hierárquicas $\mathbb{C}_0 \subseteq \mathbb{C}_1 \subseteq \dots \subseteq \mathbb{C}_{N-1}$
01	Início
02	Calcular a matriz de distâncias $\mathbf{D}$
03	Definir $\mathbb{C}_0 = \{\mathcal{C}_i = \mathbf{x}(i), i = 1, \dots, N\}$
04	$k = 1$
05	Enquanto $k < N - 1$
06	Selecionar $\{\mathcal{C}_i, \mathcal{C}_j\} \in \mathbb{C}_{k-1}$ como $\operatorname{argmin}(L(\mathcal{C}_i, \mathcal{C}_j))$
07	Gerar a nova partição $\mathbb{C}_k = \{\mathbb{C}_{k-1} - \{\mathcal{C}_i, \mathcal{C}_j\}\} \cup \{\mathcal{C}_i \cup \mathcal{C}_j\}$
08	$k \leftarrow k + 1$
09	Fim Enquanto
10	Retorna $\{\mathbb{C}_0, \mathbb{C}_1, \dots, \mathbb{C}_{N-1}\}$
11	Fim

En cada iteración k del Algoritmo 6.2, en el paso 07, se elimina un par de grupos $\{\mathcal{C}_i, \mathcal{C}_j\}$ de la partición $\mathbb{C}_{k-1}$ y la unión $\{\mathcal{C}_i \cup \mathcal{C}_j\}$ se incluye en la partición $\mathbb{C}_k$. La función de enlace $L(\mathcal{C}_i, \mathcal{C}_j)$ en el paso 06 se utiliza para seleccionar los grupos a los que se unirá. Diferentes funciones de vinculación dan como resultado diferentes agrupaciones. En la literatura, las principales estrategias para la función de enlace son:

Vecino más cercano (**single-link**): la distancia entre grupos se calcula mediante los elementos más cercanos [495]:

$$L_{\min}(\mathcal{C}_i, \mathcal{C}_j) = \min_{\substack{\mathbf{v} \in \mathcal{C}_i \\ \mathbf{v} \in \mathcal{C}_j}} \operatorname{dist}(\mathbf{v}, \mathbf{v}) \quad (6.7)$$

Vecino más lejano (**complete-link**): la distancia entre grupos se calcula por la distancia máxima entre sus elementos:

$$L_{max}(\mathcal{C}_i, \mathcal{C}_j) = \max_{\substack{\mathbf{v} \in \mathcal{C}_i \\ \mathbf{u} \in \mathcal{C}_j}} dist(\mathbf{v}, \mathbf{u}) \quad (6.8)$$

- Distâncias médias (**UPGMA**):* a distância entre os grupos é calculada pela distância média entre os elementos [499]:

$$L_{med}(\mathcal{C}_i, \mathcal{C}_j) = \frac{1}{|\mathcal{C}_i||\mathcal{C}_j|} \sum_{\mathbf{v} \in \mathcal{C}_i} \sum_{\mathbf{u} \in \mathcal{C}_j} dist(\mathbf{v}, \mathbf{u}) \quad (6.9)$$

onde $|\mathcal{C}_i|$ representa a cardinalidade, isto é, o número de elementos do grupo $\mathcal{C}_i$;

- Centroides (**UPGMC**):† a distância entre os grupos é calculada pela distância entre os centroides [499]:

$$L_{cen}(\mathcal{C}_i, \mathcal{C}_j) = dist(\bar{\mathbf{v}}, \bar{\mathbf{u}}) \quad (6.10)$$

onde $\bar{\mathbf{v}} = \frac{1}{|\mathcal{C}_i|} \sum_{\mathbf{v} \in \mathcal{C}_i} \mathbf{v}$ e $\bar{\mathbf{u}} = \frac{1}{|\mathcal{C}_j|} \sum_{\mathbf{u} \in \mathcal{C}_j} \mathbf{u}$.

Há também as variantes WPGMA e WPGMC, que são semelhantes, respectivamente, aos critérios de distância média (UPGMA) e de centroide (UPGMC), em que as distâncias são ponderadas pelo número de elementos em cada grupo [194]. Finalmente, o critério de Ward minimiza a variância dos grupos [551].

Os algoritmos hierárquicos aglomerativos, em geral, trabalham com a matriz de distâncias na memória, o que significa armazenar, pelo menos, $N(N - 1)/2$ valores.‡ A aplicação desse tipo de algoritmo em conjuntos de dados com número muito grande de registros pode causar problemas de memória.

6.3.2 Exemplos

Nesta seção, os algoritmos anteriores são avaliados em conjuntos de dados sintéticos e *benchmark*. Todos os exemplos foram executados utilizando a distância euclidiana, variando apenas a função de ligação.

A Figura 6.8 mostra os dendrogramas e as partições resultantes dos quatro algoritmos hierárquicos discutidos previamente no conjunto de dados sintético de quatro grupos (cf. Figura 6.2a). O nível inferior foi limitado a 25 grupos para facilitar a visualização.

* *Unweighted Pair Group Method with Average linkage*

† *Unweighted Pair Group Method with Centroid linkage*.

‡ Considerando que a matriz de distâncias é simétrica e armazenando apenas a matriz triangular.

$$L_{max}(\mathcal{C}_i, \mathcal{C}_j) = \max_{\substack{\mathbf{v} \in \mathcal{C}_i \\ \mathbf{u} \in \mathcal{C}_j}} dist(\mathbf{v}, \mathbf{u}) \quad (6.8)$$

Distancias promedio (UPGMA):* la distancia entre los grupos se calcula por la distancia promedio entre los elementos [499]:

$$L_{med}(\mathcal{C}_i, \mathcal{C}_j) = \frac{1}{|\mathcal{C}_i||\mathcal{C}_j|} \sum_{\mathbf{v} \in \mathcal{C}_i} \sum_{\mathbf{u} \in \mathcal{C}_j} dist(\mathbf{v}, \mathbf{u}) \quad (6.9)$$

donde $|\mathcal{C}_i|$ representa la cardinalidad, es decir, el número de elementos del grupo $\mathcal{C}_i$;

Centroides (UPGMC):† la distancia entre grupos se calcula por la distancia entre los centroides [499]:

$$L_{cen}(\mathcal{C}_i, \mathcal{C}_j) = dist(\bar{\mathbf{v}}, \bar{\mathbf{u}}) \quad (6.10)$$

donde $\bar{\mathbf{v}} = \frac{1}{|\mathcal{C}_i|} \sum_{\mathbf{v} \in \mathcal{C}_i} \mathbf{v}$ y $\bar{\mathbf{u}} = \frac{1}{|\mathcal{C}_j|} \sum_{\mathbf{u} \in \mathcal{C}_j} \mathbf{u}$.

También existen variantes WPGMA y WPGMC, que son similares, respectivamente, a los criterios de distancia media (UPGMA) y centroide (UPGMC), en los que las distancias se ponderan por el número de elementos en cada grupo [194]. Finalmente, el criterio de Ward minimiza la varianza del grupo [551].

Los algoritmos jerárquicos aglomerativos, en general, funcionan con la matriz de distancias en la memoria, lo que significa almacenar al menos $N(N - 1)/2$ valores.‡ Aplicar este tipo de algoritmo a conjuntos de datos con una gran cantidad de registros puede causar problemas de memoria.

6.3.2 Ejemplos

En esta sección, los algoritmos anteriores se evalúan en conjuntos de datos sintéticos y *benchmark*. Todos los ejemplos se realizaron utilizando la distancia euclidiana, variando únicamente la función de enlace.

La Figura 6.8 muestra los dendrogramas y las particiones resultantes de los cuatro algoritmos jerárquicos discutidos anteriormente en el conjunto de datos sintéticos de cuatro grupos (ver Figura 6.2a). El nivel inferior se ha limitado a 25 grupos para facilitar la visualización.

* *Unweighted Pair Group Method with Average linkage*

† *Unweighted Pair Group Method with Centroid linkage*.

‡ Considerando que la matriz de distancias es simétrica e almacenando apenas la matriz triangular.

Observe que, mesmo num exemplo simples como este, os resultados são ligeiramente diferentes, tanto em termos do dendrograma quanto da partição encontrada.

A Figura 6.9 apresenta os resultados dos algoritmos no conjunto de dados de duas luas apresentado (cf. Figura 6.4b). Este exemplo mostra a capacidade do algoritmo do vizinho mais próximo (*single-link*) de encontrar partições não convexas, o que não acontece no caso das demais funções de ligação.

A observação dos resultados na Figura 6.8 e na Figura 6.9 mostra que o dendrograma pode indicar o número de grupos presentes num conjunto de dados pelo número de ramos (traços verticais) entre os dois patamares (traços horizontais) mais distantes. O resultado dessa análise qualitativa é bem visível na Figura 6.8, indicando a presença de quatro grupos (exceto para o algoritmo *single-link*), e na Figura 6.9, indicando a presença de dois grupos.

6.4 Particionamento de grafos

A teoria dos grafos [55][129] é o ramo da matemática que estuda problemas que podem ser representados na forma de um **grafo**, isto é, um conjunto de vértices conectados por um conjunto de arestas. A teoria dos grafos é a base matemática para uma série de disciplinas na ciência da computação e a análise de rede complexas [414].

Um conjunto de dados pode ser representado como um grafo $G(\mathcal{V}, \mathcal{E})$, no qual o conjunto de vértices $\mathcal{V}$ representa os registros, isto é, $\mathcal{V} \equiv \mathcal{T} = \{\mathbf{x}(t), t = 1 \dots N\}$, e o conjunto de arestas é definido pela matriz de adjacências* $\mathbf{A} \in \mathcal{R}^{N \times N}$, em que cada elemento representa a similaridade entre um par de registros como:

$$a_{ij} = \begin{cases} \text{sim}(\mathbf{x}(i), \mathbf{x}(j)), & \text{se } i \neq j \\ 0, & \text{se } i = j \end{cases} \quad (6.11)$$

A matriz de similaridades é simétrica e, portanto, as arestas do grafo correspondente a um conjunto de dados são ponderadas e não direcionadas.

O grau de um vértice é o número de vizinhos do vértice. Em grafos ponderados, o grau é a soma do peso das arestas conectadas ao vértice.

* Aqui, seguimos a notação proposta por Newman [414], em que a matriz de adjacências binária é um caso particular da matriz de adjacências ponderada.

Tenga en cuenta que incluso en un ejemplo simple como este, los resultados son ligeramente diferentes, tanto en términos del dendrograma como de la partición encontrada.

La Figura 6.9 presenta los resultados de los algoritmos en el conjunto de datos de dos lunas presentado (cf. Figura 6.4b). Este ejemplo muestra la capacidad del algoritmo vecino más cercano (*single-link*) para encontrar particiones no convexas, lo que no sucede en el caso de las otras funciones de conexión.

La observación de los resultados en la Figura 6.8 y la Figura 6.9 muestra que el dendrograma puede indicar el número de grupos presentes en un conjunto de datos por el número de ramas (líneas verticales) entre los dos niveles más distantes (líneas horizontales). El resultado de este análisis cualitativo es claramente visible en la Figura 6.8, que indica la presencia de cuatro grupos (excepto el algoritmo *single-link*), y en la Figura 6.9, que indica la presencia de dos grupos.

6.4 Partición de gráficos

La teoría de grafos [55][129] es la rama de las matemáticas que estudia problemas que pueden representarse en forma de gráfico, es decir, un conjunto de vértices conectados por un conjunto de aristas. La teoría de grafos es la base matemática de varias disciplinas de la informática y el análisis de redes complejas [414].


Un conjunto de datos se puede representar como un gráfico $G(\mathcal{V}, \mathcal{E})$, en el que el conjunto de vértices $\mathcal{V}$ representa los registros, es decir, $\mathcal{V} \equiv \mathcal{T} = \{\mathbf{x}(t), t = 1 \dots N\}$, y el conjunto de aristas está definido por la matriz de adyacencia $\mathbf{A} \in \mathcal{R}^{N \times N}$, en la que cada elemento representa la similitud entre un par de registros como:

$$a_{ij} = \begin{cases} \text{sim}(\mathbf{x}(i), \mathbf{x}(j)), & \text{se } i \neq j \\ 0, & \text{se } i = j \end{cases} \quad (6.11)$$


La matriz de similitud es simétrica y por tanto los bordes del gráfico correspondientes a un conjunto de datos son ponderados y no dirigidos.

El grado de un vértice es el número de vecinos del vértice. En gráficos ponderados, el grado es la suma del peso de las aristas conectadas al vértice.


* Aquí, seguimos a notação proposta por Newman [414], em que a matriz de adjacências binária é um caso particular da matriz de adjacências ponderada.




(a)




(b)




(c)




(d)




(e)



(f)




(g)




(h)


Figura 6.8: Resultados do agrupamento hierárquico nos dados de quatro grupos: (a) e (b) *single-link*; (c) e (d) *complete-link*; (e) e (f) distância média; (g) e (h) centroide.




(a)




(b)




(c)




(d)




(e)



(f)




(g)




(h)


Figura 6.8: Resultados de agrupamento jerárquico de dados de quatro grupos: (a) y (b) *single-link*; (c) y (d) *complete-link*; (e) y (f) distancia promedio; (g) y (h) centroide.




(a)




(b)




(c)




(d)




(e)



(f)




(g)




(h)


Figura 6.9: Resultados do agrupamento hierárquico nos dados duas luas: (a) e (b) *single-link*; (c) e (d) *complete-link*; (e) e (f) distância média; (g) e (h) centroide.




(a)




(b)




(c)




(d)




(e)



(f)



(g)



(h)

Figura 6.9: Resultados de agrupamento jerárquico em dados de duas lunas: (a) e (b) *single-link*; (c) e (d) *complete-link*; (e) e (f) distância promedio; (g) e (h) centróide.

A função de similaridade gaussiana é muito utilizada para representação de um conjunto de dados como um grafo e é definida como (cf. equação (2.14)):

$$sim_G(\mathbf{x}(i), \mathbf{x}(j)) = \exp\left(-\frac{\|\mathbf{x}(i) - \mathbf{x}(j)\|^2}{2\sigma^2}\right) \quad (6.12)$$

A Figura 6.10 mostra o exemplo de um grafo gerado a partir de um conjunto de dados de quatro grupos pela função de similaridade gaussiana (6.12) com $\sigma = 1/3$. Na Figura 6.10a, o grafo formado pela conexão dos registros em que os tons de cinza representam os valores das arestas; na Figura 6.10b, a matriz de adjacências.




Figura 6.10: Conjuntos de dados quatro grupos: (a) Grafo; (b) matriz de adjacências.

A função de similaridade do cosseno (cf. equação (2.13)) também é frequentemente utilizada, principalmente em aplicações de mineração de textos [468]. Há outras formas de representar um conjunto de dados como um grafo [356][473]. A função de similaridade gaussiana relaciona o particionamento em grafos com métodos baseados em funções de núcleo [182], discutidos no Capítulo 7.

Um corte num grafo conexo é um conjunto de arestas (ou vértices) cuja remoção desconecta um determinado par de vértices [414]. O corte em grafos é estudado principalmente em problemas em que o grafo representa um sistema onde há algum fluxo (de matéria, informação etc.) ao longo das arestas e a capacidade de fluxo é representada pelo valor (ou peso) da aresta. O corte mínimo é o conjunto de arestas que, se retiradas, desconecta um par de vértices e cuja soma dos pesos das arestas retiradas é mínima. O corte mínimo corresponde ao fluxo máximo entre o par de vértices [6].

La función de similitud gaussiana se usa ampliamente para representar un conjunto de datos como un gráfico y se define como (cf. ecuación (2.14)):

$$sim_G(\mathbf{x}(i), \mathbf{x}(j)) = \exp\left(-\frac{\|\mathbf{x}(i) - \mathbf{x}(j)\|^2}{2\sigma^2}\right) \quad (6.12)$$

La figura 6.10 muestra un ejemplo de una gráfica generada a partir de un conjunto de datos de cuatro grupos mediante la función de similitud gaussiana (6.12) con $\sigma = 1/3$. En la Figura 6.10a, el gráfico formado al conectar los registros en el que los tonos de gris representan los valores de los bordes; en la Figura 6.10b, la matriz de adyacencia.




Figura 6.10: Conjuntos de datos de cuatro grupos: (a) Gráfico; (b) matriz de adyacencia.

La función de similitud coseno (cf. ecuación (2.13)) también se utiliza con frecuencia, principalmente en aplicaciones de minería de textos [468]. Hay otras formas de representar un conjunto de datos como un gráfico [356][473]. La función de similitud gaussiana relaciona la partición de gráficos con métodos basados en funciones del núcleo [182], discutidos en el Capítulo 7.

Un corte en un gráfico conexo es un conjunto de aristas (o vértices) cuya eliminación desconecta un par de vértices dado [414]. El corte de gráficos se estudia principalmente en problemas en los que el gráfico representa un sistema donde hay algún flujo (de materia, información, etc.) a lo largo de los bordes y la capacidad de flujo está representada por el valor (o peso) del borde. El corte mínimo es el conjunto de aristas que, si se eliminan, desconectan un par de vértices y cuya suma de los pesos de las aristas eliminadas es mínima. El corte mínimo corresponde al flujo máximo entre el par de vértices [6].

O problema do corte mínimo num grafo pode ser associado ao problema de agrupamento para encontrar uma partição $\mathbb{C} = \{\mathcal{C}_1, \mathcal{C}_2\}$, tal que $\mathcal{C}_1 \cap \mathcal{C}_2 = \emptyset$ e $\mathcal{C}_1 \cup \mathcal{C}_2 = \mathcal{V}$, através da minimização da soma dos pesos das arestas entre os dois grupos calculada pela função de corte:

$$cut(\mathcal{C}_1, \mathcal{C}_2) = \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N a_{ij} u_1(\mathbf{x}(i)) u_2(\mathbf{x}(j)) \quad (6.13)$$

onde $a_{ij} \in \mathbf{A}$ são os elementos da matriz de adjacências, $u_i(\mathbf{x}(t))$ é a pertinência de um registro $\mathbf{x}(t)$ ao grupo $\mathcal{C}_i$ (cf. equação (6.3)) e o fator $\frac{1}{2}$ é incluído para evitar a contagem dupla da mesma aresta, uma vez que a matriz de adjacências $\mathbf{A}$ é simétrica.

Em grafos não direcionados, o critério de corte definido pela equação (6.13) admite uma solução trivial que corresponde a separar apenas um vértice cuja soma das suas arestas é mínima, isto é, o vértice de menor grau. Num grafo correspondente a um conjunto de dados, essa solução trivial significa separar um *outlier*. Para evitar esse problema, Shi e Malik [489] propõem minimizar a função de corte normalizado:

$$Ncut(\mathcal{C}_1, \mathcal{C}_2) = \frac{cut(\mathcal{C}_1, \mathcal{C}_2)}{cut(\mathcal{C}_1, \mathcal{V})} + \frac{cut(\mathcal{C}_2, \mathcal{C}_2)}{cut(\mathcal{C}_2, \mathcal{V})} \quad (6.14)$$

onde $cut(\mathcal{C}_k, \mathcal{V}) = \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N a_{ij} u_k(\mathbf{x}(i))$ e $\mathcal{V}$ é o conjunto de vértices do grafo.

A função de avaliação definida pela equação (6.14) evita a obtenção de um grupo em que as arestas do corte representam uma parcela importante da sua conectividade.

O corte mínimo pode ser ilustrado na Figura 6.10a, em que o agrupamento é definido pelo corte das arestas mais claras. Nesse caso, a medida de corte da equação (6.13) é generalizada para o caso de uma partição genérica $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$ como [468]:

$$cut(\mathcal{C}_1, \dots, \mathcal{C}_K) = \sum_{i=1}^K cut(\mathcal{C}_i, \bar{\mathcal{C}}_i) \quad (6.15)$$

onde $\bar{\mathcal{C}}_i = \mathcal{V} - \mathcal{C}_i$ é o complemento de $\mathcal{C}_i$, i.e. $\bar{\mathcal{C}}_i = \bigcup_{j \neq i}^K \mathcal{C}_j$.

Na literatura encontram-se outras variantes da medida de corte em grafos com características ligeiramente diferentes [130][468].

El problema de corte mínimo en un gráfico se puede asociar con el problema de agrupación para encontrar una partición $\mathbb{C} = \{\mathcal{C}_1, \mathcal{C}_2\}$, tal que $\mathcal{C}_1 \cap \mathcal{C}_2 = \emptyset$ y $\mathcal{C}_1 \cup \mathcal{C}_2 = \mathcal{V}$, minimizando la suma de los pesos de las aristas entre los dos grupos calculados por la función de corte:

$$cut(\mathcal{C}_1, \mathcal{C}_2) = \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N a_{ij} u_1(\mathbf{x}(i)) u_2(\mathbf{x}(j)) \quad (6.13)$$

donde $a_{ij} \in \mathbf{A}$ son los elementos de la matriz de adyacencia, $u_i(\mathbf{x}(t))$ es la pertenencia de un registro $\mathbf{x}(t)$ al grupo $\mathcal{C}_i$ (cf. ecuación (6.3)) y se incluye el factor $\frac{1}{2}$ para evitar el doble conteo de un mismo borde, ya que la matriz de adyacencia $\mathbf{A}$ es simétrica.

En grafos no dirigidos, el criterio de corte definido por la ecuación (6.13) admite una solución trivial que corresponde a separar sólo un vértice cuya suma de sus aristas sea mínima, es decir, el vértice de menor grado. En un gráfico correspondiente a un conjunto de datos, esta solución trivial significa separar un *outlier*. Para evitar este problema, Shi y Malik [489] proponen minimizar la función de corte normalizada:

$$Ncut(\mathcal{C}_1, \mathcal{C}_2) = \frac{cut(\mathcal{C}_1, \mathcal{C}_2)}{cut(\mathcal{C}_1, \mathcal{V})} + \frac{cut(\mathcal{C}_2, \mathcal{C}_1)}{cut(\mathcal{C}_2, \mathcal{V})} \quad (6.14)$$

donde $cut(\mathcal{C}_k, \mathcal{V}) = \sum_{i=1}^N \sum_{j=1}^N a_{ij} u_k(\mathbf{x}(i))$ y $\mathcal{V}$ es el conjunto de vértices del gráfico.

La función de evaluación definida por la ecuación (6.14) evita obtener un grupo en el que los bordes cortados representen una porción importante de su conectividad.

El corte mínimo se puede ilustrar en la Figura 6.10a, donde la agrupación se define cortando los bordes más claros. En este caso, la medida de corte en la ecuación (6.13) se generaliza al caso de una partición genérica $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$ como [468]:

$$cut(\mathcal{C}_1, \dots, \mathcal{C}_K) = \sum_{i=1}^K cut(\mathcal{C}_i, \bar{\mathcal{C}}_i) \quad (6.15)$$

donde $\bar{\mathcal{C}}_i = \mathcal{V} - \mathcal{C}_i$ es el complemento de $\mathcal{C}_i$, es decir, $\bar{\mathcal{C}}_i = \bigcup_{j=1, j \neq i}^K \mathcal{C}_j$.

En la literatura existen otras variantes de la medida de corte del gráfico con características ligeramente diferentes [130][468].

A teoria dos grafos tem sido explorada para o estudo de redes complexas [414]. O problema de particionamento de grafos na área de redes complexas é chamado de **detecção de comunidades** [412][414][468]. Numa rede social, por exemplo, os indivíduos representam os vértices do grafo e as arestas, as relações entre eles. As comunidades são formadas por grupos de indivíduos que compartilham características em comum e, por isso, têm mais relações entre si do que com indivíduos de outros grupos. Essa tendência é chamada de homofilia.

Newman apresenta uma medida para aferir o grau de homofilia de uma rede, chamada modularidade [411]-[413]. A medida de modularidade segue um raciocínio bem diferente da medida de corte em grafos (6.13). Em vez de avaliar o peso das arestas em grupos diferentes, a ideia é avaliar o peso das arestas no mesmo grupo e a medida reflete a fração de arestas que ligam vértices desse grupo. Entretanto, para evitar a solução trivial de considerar toda a rede como um só grupo, a medida de modularidade subtrai a fração de arestas esperada de uma rede cujas ligações ocorrem de forma aleatória. Em outras palavras, a modularidade mede o quanto a estrutura de comunidades encontrada na rede é diferente de um arranjo aleatório.

Matematicamente, a modularidade de uma partição $\mathcal{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$ é definida como:

$$Q(\mathcal{C}_1, \dots, \mathcal{C}_K) = \frac{1}{2E} \sum_{i=1}^N \sum_{j=1}^N \left(a_{ij} - \frac{d_i d_j}{2E} \right) \mathbf{u}_i \mathbf{u}_j^T \quad (6.16)$$

onde $d_i = \sum_j a_{ij}$ é o grau do vértice associado ao registro $\mathbf{x}(i)$ e $E = \sum_i d_i$ é o número total de arestas. O vetor $\mathbf{u}_i = (u_1(\mathbf{x}(i)), \dots, u_K(\mathbf{x}(i)))$ é aquele em que cada elemento é a pertinência do registro $\mathbf{x}(i)$ a cada um dos grupos (cf. equação (6.3)). O produto $\mathbf{u}_i \mathbf{u}_j^T = 1$ se os registros $\mathbf{x}(i)$ e $\mathbf{x}(j)$ estão no mesmo grupo; caso contrário, $\mathbf{u}_i \mathbf{u}_j^T = 0$.

Se os registros $\mathbf{x}(i)$ e $\mathbf{x}(j)$ estão no mesmo grupo, a modularidade da partição calculada pela equação (6.16) é a diferença entre o número total de arestas $\sum_{ij} a_{ij}$ e o número esperado de arestas numa rede aleatória $\sum_{ij} d_i d_j / 2E$ [413].

A modularidade pode ser escrita diretamente a partir da definição da matriz de modularidade $\mathbf{B}$, calculada como:

$$\mathbf{B} = \mathbf{A} - \frac{\mathbf{d}^T \mathbf{d}}{2E} \quad (6.17)$$

Se ha explorado la teoría de grafos para estudiar redes complejas [414]. El problema de la partición de gráficos en el área de redes complejas se denomina detección de comunidades [412][414][468]. En una red social, por ejemplo, los individuos representan los vértices del gráfico y los bordes representan las relaciones entre ellos. Las comunidades están formadas por grupos de individuos que comparten características comunes y, por tanto, tienen más relaciones entre sí que con individuos de otros grupos. Esta tendencia se llama homofilia.

Newman presenta una medida para evaluar el grado de homofilia de una red, llamada modularidad [411]-[413]. La medida de modularidad sigue un razonamiento muy diferente al de la medida de corte del gráfico (6.13). En lugar de evaluar el peso de las aristas en diferentes grupos, la idea es evaluar el peso de las aristas en el mismo grupo y la medida refleja la fracción de aristas que conectan los vértices en ese grupo. Sin embargo, para evitar la solución trivial de considerar toda la red como un solo grupo, la medida de modularidad resta la fracción de aristas esperadas de una red cuyas conexiones ocurren aleatoriamente. En otras palabras, la modularidad mide en qué medida la estructura comunitaria encontrada en la red es diferente de una disposición aleatoria.

Matemáticamente, la modularidad de una partición $\mathcal{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$ se define como:

$$Q(\mathcal{C}_1, \dots, \mathcal{C}_K) = \frac{1}{2E} \sum_{i=1}^N \sum_{j=1}^N \left(a_{ij} - \frac{d_i d_j}{2E} \right) \mathbf{u}_i \mathbf{u}_j^T \quad (6.16)$$

donde $d_i = \sum_j a_{ij}$ es el grado del vértice asociado con el registro $\mathbf{x}(i)$ y $E = \sum_i d_i$ es el número total de aristas. El vector $\mathbf{u}_i = (u_1(\mathbf{x}(i)), \dots, u_K(\mathbf{x}(i)))$ es aquel en el que cada elemento es la pertenencia del registro $\mathbf{x}(i)$ a cada uno de los grupos (cf. ecuación (6.3)). El producto $\mathbf{u}_i \mathbf{u}_j^T = 1$ si los registros $\mathbf{x}(i)$ y $\mathbf{x}(j)$ están en el mismo grupo; en caso contrario $\mathbf{u}_i \mathbf{u}_j^T = 0$.

Si los registros $\mathbf{x}(i)$ y $\mathbf{x}(j)$ están en el mismo grupo, la modularidad de la partición calculada a mediante la ecuación (6.16) es la diferencia entre el número total de aristas $\sum_{ij} a_{ij}$ y el número esperado de aristas en una red aleatoria $\sum_{ij} d_i d_j / 2E$ [413].

La modularidad se puede escribir directamente a partir de la definición de la matriz de modularidad $\mathbf{B}$, calculada como:

$$\mathbf{B} = \mathbf{A} - \frac{\mathbf{d}^T \mathbf{d}}{2E} \quad (6.17)$$

onde $\mathbf{d} = (d_1, \dots, d_N)$ é o vetor dos graus dos vértices (registros) correspondentes, em que cada elemento é calculado como $d_i = \sum_j a_{ij}$. Observe que, em geral, a matriz $\mathbf{A}$ é esparsa, mas $\mathbf{B}$ é uma matriz densa.

De uma forma geral, o problema de particionamento em grafos é um problema NP-difícil por razões análogas à complexidade do problema de particionamento de um conjunto de dados. Dessa forma, uma solução computacionalmente tratável para o problema é obtida por uma formulação aproximada, baseada na decomposição espectral de uma matriz derivada da matriz de adjacências do grafo $\mathbf{A}$, chamada de laplaciano [356][408]. Essa abordagem dá origem a diferentes algoritmos, apresentados a seguir.

6.4.1 Algoritmos de agrupamento espectral

Uma partição $\mathbb{C} = \{\mathcal{C}_1, \mathcal{C}_2\}$ num grafo pode ser representada por um vetor $\mathbf{v} \in \mathcal{R}^N$, que representa a partição através da variável indicadora:

$$v_i = \begin{cases} +1, & \text{se } \mathbf{x}(i) \in \mathcal{C}_1 \\ -1, & \text{se } \mathbf{x}(i) \in \mathcal{C}_2 \end{cases} \quad (6.18)$$

onde $\mathcal{C}_1 \cap \mathcal{C}_2 = \emptyset$ e $\mathcal{C}_1 \cup \mathcal{C}_2 =$.

A variável indicadora permite identificar se dois registros $\mathbf{x}(i)$ e $\mathbf{x}(j)$ estão no mesmo grupo como $u_1(\mathbf{x}(i))u_2(\mathbf{x}(j)) = \frac{1}{2}(1 - v_i v_j)$. Se os registros estão no mesmo grupo, $\frac{1}{2}(1 - v_i v_j) = 0$; caso contrário, $\frac{1}{2}(1 - v_i v_j) = 1$. Dessa forma, a medida de corte (6.13) pode ser escrita como:

$$cut(\mathcal{C}_1, \mathcal{C}_2) = \frac{1}{4} \sum_{i=1}^N \sum_{j=1}^N a_{ij} (1 - v_i v_j) \quad (6.19)$$

Considerando $\sum_{i=1}^N \sum_{j=1}^N a_{ij} = \sum_{i=1}^N d_i = \sum_{i=1}^N \sum_{j=1}^N d_i \delta_{ij}$ [414], onde $d_i = \sum_j a_{ij}$ é o grau do vértice e δ_{ij} , a função δ de Kronecker,* a equação (6.19) é reescrita como:

$$cut(\mathcal{C}_1, \mathcal{C}_2) = \frac{1}{4} \sum_{i=1}^N \sum_{j=1}^N (d_i \delta_{ij} - a_{ij}) v_i v_j \quad (6.20)$$

* A função δ de Kronecker é definida como: $\delta_{ij} = \begin{cases} 1, & \text{se } i = j \\ 0, & \text{se } i \neq j \end{cases}$.

donde $\mathbf{d} = (d_1, \dots, d_N)$ es el vector de los grados de los vértices (registros) correspondientes, donde cada elemento se calcula como $d_i = \sum_j a_{ij}$. Tenga en cuenta que, en general, la matriz $\mathbf{A}$ es escasa, pero $\mathbf{B}$ es una matriz densa.

En general, el problema de partición de gráficos es un problema NP-difícil por razones análogas a la complejidad del problema de partición de conjuntos de datos. Así, una solución computacionalmente manejable al problema se obtiene mediante una formulación aproximada, basada en la descomposición espectral de una matriz derivada de la matriz de adyacencia del gráfico $\mathbf{A}$, llamada Laplaciana [356][408]. Este enfoque da lugar a diferentes algoritmos, que se presentan a continuación.

6.4.1 Algoritmos de agrupamiento espectral

Una partición $\mathcal{C} = \{\mathcal{C}_1, \mathcal{C}_2\}$ en un gráfico se puede representar mediante un vector $\mathbf{v} \in \mathcal{R}^N$, que representa la partición a través de la variable indicadora:

$$v_i = \begin{cases} +1, & \text{se } \mathbf{x}(i) \in \mathcal{C}_1 \\ -1, & \text{se } \mathbf{x}(i) \in \mathcal{C}_2 \end{cases} \quad (6.18)$$

donde $\mathcal{C}_1 \cap \mathcal{C}_2 = \emptyset$ y $\mathcal{C}_1 \cup \mathcal{C}_2 =$.

La variable indicadora permite identificar si dos registros $\mathbf{x}(i)$ y $\mathbf{x}(j)$ están en el mismo grupo que $u_1(\mathbf{x}(i))u_2(\mathbf{x}(j)) = \frac{1}{2}(1 - v_i v_j)$. Si los registros están en el mismo grupo, $\frac{1}{2}(1 - v_i v_j) = 0$; en caso contrario $\frac{1}{2}(1 - v_i v_j) = 1$. Por tanto, la medida de corte (6.13) se puede escribir como:

$$cut(\mathcal{C}_1, \mathcal{C}_2) = \frac{1}{4} \sum_{i=1}^N \sum_{j=1}^N a_{ij} (1 - v_i v_j) \quad (6.19)$$

Considerando $\sum_{i=1}^N \sum_{j=1}^N a_{ij} = \sum_{i=1}^N d_i = \sum_{i=1}^N \sum_{j=1}^N d_i \delta_{ij}$ [414], donde $d_i = \sum_j a_{ij}$ es el grado del vértice y δ_{ij} , la función de Kronecker δ ,* ecuación (6.19) se reescribe como:

$$cut(\mathcal{C}_1, \mathcal{C}_2) = \frac{1}{4} \sum_{i=1}^N \sum_{j=1}^N (d_i \delta_{ij} - a_{ij}) v_i v_j \quad (6.20)$$

* A função δ de Kronecker é definida como: $\delta_{ij} = \begin{cases} 1, & \text{se } i = j \\ 0, & \text{se } i \neq j \end{cases}$.

A medida de corte escrita na forma (6.20) evidencia os valores $l_{ij} = (d_i \delta_{ij} - a_{ij})$, que são os elementos do **laplaciano** do grafo, definido como:

$$\mathbf{L} = \mathbf{D} - \mathbf{A} \quad (6.21)$$

onde $\mathbf{D}$ é uma matriz diagonal em que cada elemento $d_{ii} = \sum_j a_{ij}$ é o grau do vértice (registro) correspondente.

O laplaciano do grafo recebe esse nome devido a uma analogia com o operador laplaciano da equação da difusão [414]. O laplaciano tem grande importância nas propriedades topológicas de grafos [104][381].

A medida de corte (6.20) é escrita em função do laplaciano e da variável indicadora da partição $\mathbb{C} = \{\mathcal{C}_1, \mathcal{C}_2\}$ pela seguinte equação vetorial:

$$cut(\mathcal{C}_1, \mathcal{C}_2) = \frac{1}{4} \mathbf{v}^T \mathbf{L} \mathbf{v} \quad (6.22)$$

A minimização da função de corte definida pela equação (6.22) não é uma tarefa simples, considerando a restrição $v_i \in \{-1, 1\}$ imposta pela definição da variável indicadora na equação (6.18). Entretanto, uma solução aproximada $\hat{\mathbf{v}} \in \mathcal{R}^N$ pode ser calculada pela solução do problema de autovalor:

$$\mathbf{L} \mathbf{W} = \mathbf{W} \mathbf{\Lambda} \quad (6.23)$$

onde $\mathbf{\Lambda}$ é a matriz diagonal dos autovalores cujos elementos são ordenados de forma que $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_N$; $\mathbf{W} = [\mathbf{w}_1, \dots, \mathbf{w}_N]$ é a matriz dos autovetores em que cada coluna $\mathbf{w}_i \in \mathcal{R}^N$ é o autovetor correspondente ao autovalor λ_i .

O laplaciano é uma matriz positiva semi-definida,* de modo que todos os seus autovalores são números reais e positivos [206][414]. O laplaciano tem sempre um autovalor nulo, isto é, $\lambda_1 = 0$, que corresponde ao autovetor unitário $\mathbf{w}_1 = [1/\sqrt{N}, \dots, 1/\sqrt{N}]^T$ [414]. O número de autovalores nulos corresponde ao número de componentes conexas do grafo. Assim, se $\lambda_2 > 0$, o grafo é conexo, isto é, há apenas um componente e existe um caminho entre quaisquer pares de vértices. Quanto maior o autovalor λ_2 , maior a conectividade do grafo [179]. O segundo autovetor do laplaciano $\mathbf{w}_2$, correspondente ao segundo autovalor λ_2 , é conhecido como o autovetor de Fiedler [408], em homenagem ao matemático Miroslav Fiedler [179][180].

* Uma matriz $\mathbf{A}$ é positiva semi-definida se $\mathbf{x}^T \mathbf{A} \mathbf{x} \geq 0, \forall \mathbf{x}$.

La medida de corte escrita en la forma (6.20) resalta los valores $l_{ij} = (d_i \delta_{ij} - a_{ij})$, que son los elementos del laplaciano del gráfico, definidos como:

$$\mathbf{L} = \mathbf{D} - \mathbf{A} \quad (6.21)$$

donde $\mathbf{D}$ es una matriz diagonal en la que cada elemento $d_{ii} = \sum_j a_{ij}$ es el grado del vértice (registro) correspondiente.

El laplaciano del gráfico recibe su nombre debido a una analogía con el operador laplaciano de la ecuación de difusión [414]. El laplaciano tiene gran importancia en las propiedades topológicas de los grafos [104][381].

La medida de corte (6.20) se escribe como una función del laplaciano y de la variable indicadora de partición $\mathbb{C} = \{\mathcal{C}_1, \mathcal{C}_2\}$ mediante la siguiente ecuación vectorial:

$$cut(\mathcal{C}_1, \mathcal{C}_2) = \frac{1}{4} \mathbf{v}^T \mathbf{L} \mathbf{v} \quad (6.22)$$

Minimizar la función de corte definida por la ecuación (6.22) no es una tarea sencilla, considerando la restricción $v_i \in \{-1, 1\}$ impuesta por la definición de la variable indicadora en la ecuación (6.18). Sin embargo, se puede calcular una solución aproximada $\hat{\mathbf{v}} \in \mathcal{R}^N$ resolviendo el problema de valores propios:

$$\mathbf{L} \mathbf{W} = \mathbf{W} \mathbf{\Lambda} \quad (6.23)$$

donde $\mathbf{\Lambda}$ es la matriz diagonal de valores propios cuyos elementos están ordenados de manera que $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_N$; $\mathbf{W} = [\mathbf{w}_1, \dots, \mathbf{w}_N]$ es la matriz de vectores propios en la que cada columna $\mathbf{w}_i \in \mathcal{R}^N$ es el vector propio correspondiente al valor propio λ_i .

El laplaciano es una matriz positiva semidefinida,* de modo que todos sus valores propios son números reales y positivos [206][414]. El laplaciano siempre tiene un valor propio cero, es decir, $\lambda_1 = 0$, que corresponde al vector propio unitario $\mathbf{w}_1 = [1/\sqrt{N}, \dots, 1/\sqrt{N}]$ [414]. El número de valores propios nulos corresponde al número de componentes conectados del gráfico. Por lo tanto, si $\lambda_2 > 0$, el gráfico es conexo, es decir, solo hay un componente y hay un camino entre cualquier par de vértices. Cuanto mayor sea el valor propio λ_2 , mayor será la conectividad del gráfico [179]. El segundo vector propio del laplaciano $\mathbf{w}_2$, correspondiente al segundo valor propio λ_2 , se conoce como vector propio de Fiedler [408], llamado así en honor al matemático Miroslav Fiedler [179][180].

* Una matriz $\mathbf{A}$ es positiva semi-definida si $\mathbf{x}^T \mathbf{A} \mathbf{x} \geq 0, \forall \mathbf{x}$.

Uma partição genérica $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$, segundo o corte mínimo (6.15), é obtida aplicando-se o algoritmo k-médias aos K autovetores correspondentes aos K menores autovaleiros da solução do problema (6.23). O algoritmo de agrupamento espectral básico é descrito pelo Algoritmo 6.3.

Algoritmo 6.3: Algoritmo de agrupamento espectral

Entrada:	Conjunto de treinamento $\mathcal{T} = \{\mathbf{x}(t), t = 1 \dots N\}$, parâmetro de dispersão σ e número de centros K
Saída:	Partição $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$
01	Início
02	Calcular a matriz $\mathbf{A}$, pela equação (6.11)
03	Calcular o laplaciano
04	Calcular a decomposição espectral do laplaciano
05	Calcular a matriz $\mathbf{Z}$ a partir dos autovetores do laplaciano
06	Calcular a partição $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$ pelo k-médias em $\mathbf{Z}$
07	Retorna $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$
08	Fim

Von Luxburg [356] sugere que a matriz de adjacências binária possa ser utilizada no passo 02, em que uma aresta é definida por um valor mínimo de similaridade ou por um número especificado de vizinhos. Entretanto, a forma mais usual é utilizar diretamente a matriz de similaridade nos algoritmos [408].

A partição $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$ obtida no passo 06 do Algoritmo 6.3 é definida no espaço de variáveis transformadas $\mathbf{Z}$ e, devido à transformação não linear realizada pelo cálculo da similaridade, o Algoritmo 6.3 pode encontrar uma partição não convexa no espaço de variáveis originais. O problema da inicialização aleatória do k-médias também é resolvido no algoritmo de agrupamento espectral. A matriz identidade pode ser utilizada na inicialização dos centros, uma vez que o algoritmo realiza uma partição de K grupos no espaço de variáveis transformadas, de K dimensões.

O algoritmo de agrupamento espectral descrito pelo Algoritmo 6.3 foi formulado em função da medida de corte mínimo, mas algumas variantes do algoritmo básico são obtidas segundo a medida de corte utilizada. As principais variantes são apresentadas a

Una partición genérica $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$, según el corte mínimo (6.15), se obtiene aplicando el algoritmo k-medias a los vectores propios K correspondientes a los valores propios K más pequeños de la solución del problema (6.23). El algoritmo básico de agrupamiento espectral se describe en el Algoritmo 6.3.

Algoritmo 6.3: Algoritmo de agrupamiento espectral

Entrada:	Conjunto de treinamento $\mathcal{T} = \{\mathbf{x}(t), t = 1 \dots N\}$, parâmetro de dispersão σ e número de centros K
Saída:	Partição $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$
01	Início
02	Calcular a matriz $\mathbf{A}$, pela equação (6.11)
03	Calcular o laplaciano
04	Calcular a decomposição espectral do laplaciano
05	Calcular a matriz $\mathbf{Z}$ a partir dos autovetores do laplaciano
06	Calcular a partição $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$ pelo k-médias em $\mathbf{Z}$
07	Retorna $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$
08	Fim

Von Luxburg [356] sugiere que la matriz de adyacencia binaria se puede utilizar en el paso 02, donde un borde se define por un valor mínimo de similitud o por un número específico de vecinos. Sin embargo, la forma más común es utilizar directamente la matriz de similitud en los algoritmos [408].

La partición $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$ obtenida en el paso 06 del Algoritmo 6.3 se define en el espacio o variable transformado $\mathbf{Z}$ y, debido a la transformación no lineal realizada por el cálculo de similitud, el Algoritmo 6.3 puede encontrar una partición no convexa en el espacio variable original. El problema de la inicialización aleatoria de k-medias también se resuelve en el algoritmo de agrupamiento espectral. La matriz identidad se puede utilizar para inicializar los centros, ya que el algoritmo realiza una partición de K grupos en el espacio de variables transformadas, de K dimensiones.

El algoritmo de agrupamiento espectral descrito por el Algoritmo 6.3 fue formulado en base a la medida de corte mínima, pero algunas variantes del algoritmo básico se obtienen según la medida de corte utilizada. Las principales variantes se presentan a continuación.

seguir, começando pela formalização do próprio algoritmo de corte mínimo. Para facilitar a apresentação, a mesma notação será utilizada para denotar a matriz de autovalores $\mathbf{\Lambda}$ e a matriz de autovetores $\mathbf{W}$ em cada variante do algoritmo espectral. Essas matrizes são diferentes em função do problema formulado em cada algoritmo.

6.4.1.1 Algoritmo de corte mínimo

No algoritmo de corte mínimo [356][408], os passos 03 e 04 são calculados pelas equações (6.21) e (6.23). A matriz de dados transformados $\mathbf{Z} = [\mathbf{w}_1, \dots, \mathbf{w}_K]$, onde $\mathbf{w}_i$ são os autovetores calculados pela equação (6.23), ordenados pela ordem crescente de seus autovalores [356][408]. Os passos 03-05 do Algoritmo 6.3 para o corte mínimo são formulados no Algoritmo 6.3^a.

Algoritmo 6.3a: Corte mínimo

03	$\mathbf{L} = \mathbf{D} - \mathbf{A}$
04	$\mathbf{LW} = \mathbf{W}\mathbf{\Lambda}$
05	Ordenar $0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_N$, $\mathbf{Z} = [\mathbf{w}_1, \dots, \mathbf{w}_K]$

6.4.1.2 Algoritmo de corte mínimo normalizado de Shi e Malik

Uma variante do Algoritmo 6.3a para a minimização do corte mínimo normalizado (6.14) foi proposta por Shi e Malik [488][489]. Nesse caso, a decomposição espectral do passo 04 é calculada pela solução do problema de autovalor generalizado:

$$\mathbf{LW} = \mathbf{DWA} \quad (6.24)$$

onde $\mathbf{L}$ é o laplaciano (6.21) e $\mathbf{D}$ é a matriz diagonal de graus.

Shi e Malik [488] mostram que o sinal do segundo menor autovalor de (6.24) é uma aproximação da solução pelo corte mínimo normalizado (6.14). Para uma partição genérica em K grupos, os autores apresentam uma abordagem hierárquica divisiva em que, a cada iteração, uma nova partição pode ser encontrada pela aplicação recursiva do problema de autovalor (6.24) [489].

Na abordagem hierárquica divisiva, a definição do número de grupos é substituída por um critério de parada do algoritmo. Entretanto, essa abordagem pode se tornar instável, além de computacionalmente complexa [489].

A continuación, comenzando con la formalización del propio algoritmo de corte mínimo. Para facilitar la presentación, se utilizará la misma notación para denotar la matriz de valores propios $\mathbf{\Lambda}$ y la matriz de vectores propios $\mathbf{W}$ en cada variante del algoritmo espectral. Estas matrices son diferentes según el problema formulado en cada algoritmo.

6.4.1.1 Algoritmo de corte mínimo

En el algoritmo de corte mínimo [356][408], los pasos 03 y 04 se calculan mediante las ecuaciones (6.21) y (6.23). La matriz de datos transformada $\mathbf{Z} = [\mathbf{w}_1, \dots, \mathbf{w}_K]$, donde $\mathbf{w}_i$ son los vectores propios calculados mediante la ecuación (6.23), ordenados por el orden creciente de sus valores propios [356][408]. Los pasos 03-05 del Algoritmo 6.3 para el corte mínimo se formulan en el Algoritmo 6.3a.

Algoritmo 6.3a: Corte mínimo

03	$\mathbf{L} = \mathbf{D} - \mathbf{A}$
04	$\mathbf{LW} = \mathbf{W}\mathbf{\Lambda}$
05	Ordenar $0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_N$, $\mathbf{Z} = [\mathbf{w}_1, \dots, \mathbf{w}_K]$

6.4.1.2 Algoritmo de corte mínimo normalizado de Shi e Malik

Shi y Malik [488][489] propusieron una variante del algoritmo 6.3a para minimizar el corte mínimo normalizado (6.14). En este caso, la descomposición espectral del paso 04 se calcula resolviendo el problema de valores propios generalizado:

$$\mathbf{LW} = \mathbf{DWA} \quad (6.24)$$

donde $\mathbf{L}$ es el laplaciano (6.21) y $\mathbf{D}$ es la matriz diagonal de grados.

Shi y Malik [488] muestran que el signo del segundo valor propio más pequeño de (6.24) es una aproximación de la solución mediante el límite mínimo normalizado (6.14). Para una partición genérica en grupos K , los autores presentan un enfoque jerárquico divisivo en el que, en cada iteración, se puede encontrar una nueva partición aplicando recursivamente el problema de valores propios (6.24) [489].

En el enfoque jerárquico divisivo, la definición del número de grupos se reemplaza por un criterio de parada del algoritmo. Sin embargo, este enfoque puede volverse inestable y computacionalmente complejo [489].

Uma partição de K grupos pode ser obtida pela aplicação do Algoritmo 6.3, em que a matriz das variáveis transformadas é definida pelos autovetores correspondentes aos menores autovalores $\mathbf{Z} = [\mathbf{w}_1, \dots, \mathbf{w}_K]$. O algoritmo do corte mínimo normalizado é apresentado pelo Algoritmo 6.3b.

Algoritmo 6.3b: Corte mínimo normalizado [489]

03	$\mathbf{L} = \mathbf{D} - \mathbf{A}$
04	$\mathbf{LW} = \mathbf{DWA}$
05	Ordenar $0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_N$, $\mathbf{Z} = [\mathbf{w}_1, \dots, \mathbf{w}_K]$

O algoritmo de corte mínimo normalizado de Shi e Malik (Algoritmo 6.3b) tem o mesmo resultado do algoritmo de corte mínimo (Algoritmo 6.3a).

A equação (6.24) também pode ser escrita como:

$$\hat{\mathbf{L}}\hat{\mathbf{W}} = \hat{\mathbf{W}}\mathbf{A} \quad (6.25)$$

onde $\hat{\mathbf{L}} = \mathbf{D}^{-1/2}\mathbf{L}\mathbf{D}^{-1/2} = \mathbf{1} - \mathbf{D}^{-1/2}\mathbf{A}\mathbf{D}^{-1/2}$ e $\hat{\mathbf{W}} = \mathbf{D}^{1/2}\mathbf{W}$ [489]. A matriz $\hat{\mathbf{L}}$ é chamada de laplaciano simétrico [356] ou, ainda, laplaciano normalizado [408].

6.4.1.3 Algoritmo de corte mínimo normalizado de Ng, Jordan e Weiss

Uma variante do algoritmo de corte mínimo normalizado foi apresentada por Ng, Jordan e Weiss [415]. O laplaciano no passo 03 é substituído pela matriz $\hat{\mathbf{A}} = \mathbf{D}^{-1/2}\mathbf{A}\mathbf{D}^{-1/2}$, chamada de matriz de adjacências normalizada [104] ou matriz de adjacências reduzida [414]. Alguns autores sugerem que a decomposição espectral seja calculada com o Laplaciano normalizado $\hat{\mathbf{L}} = \mathbf{D}^{-1/2}\mathbf{L}\mathbf{D}^{-1/2}$ [356][408]. No artigo original [415], a decomposição espectral do passo 04 é calculada como:

$$\hat{\mathbf{A}}\mathbf{W} = \mathbf{W}\hat{\mathbf{\Lambda}} \quad (6.26)$$

A decomposição espectral (6.26) produz os mesmos autovetores $\mathbf{W}$ que (6.25) e autovalores $\hat{\mathbf{\Lambda}} = \mathbf{1} - \mathbf{\Lambda}$, onde $\mathbf{\Lambda}$ é a matriz de autovalores calculada em (6.25). Dessa forma, a solução do problema (6.26) corresponde à minimização de corte mínimo normalizado (6.14) com os autovalores em ordem não crescente $\hat{\lambda}_1 \geq \hat{\lambda}_2 \geq \dots \geq \hat{\lambda}_N$.

A matriz $\hat{\mathbf{A}}$ tem outras propriedades interessantes. Num grafo definido por uma matriz de adjacências binária, isto é, $a_{ij} \in \{0,1\}$, o maior autovalor $\hat{\lambda}_1 = 1$. O número de autovalores unitários corresponde ao número de componentes do grafo [104][342] e, em

Se puede obtener una partición de grupos K aplicando el Algoritmo 6.3, en el que la matriz de variables transformadas está definida por los vectores propios correspondientes a los valores propios más pequeños $\mathbf{Z} = [\mathbf{w}_1, \dots, \mathbf{w}_K]$. El algoritmo de corte mínimo normalizado se presenta en el algoritmo 6.3b.

Algoritmo 6.3b: Corte mínimo normalizado [489]

03	$\mathbf{L} = \mathbf{D} - \mathbf{A}$
04	$\mathbf{LW} = \mathbf{DWA}$
05	Ordenar $0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_N$, $\mathbf{Z} = [\mathbf{w}_1, \dots, \mathbf{w}_K]$

El algoritmo de corte mínimo normalizado de Shi y Malik (Algoritmo 6.3b) tiene el mismo resultado que el algoritmo de corte mínimo (Algoritmo 6.3a).

La ecuación (6.24) también se puede escribir como:

$$\hat{\mathbf{L}}\hat{\mathbf{W}} = \hat{\mathbf{W}}\mathbf{A} \quad (6.25)$$

donde $\hat{\mathbf{L}} = \mathbf{D}^{-1/2}\mathbf{L}\mathbf{D}^{-1/2} = \mathbf{1} - \mathbf{D}^{-1/2}\mathbf{A}\mathbf{D}^{-1/2}$ y $\hat{\mathbf{W}} = \mathbf{D}^{1/2}\mathbf{W}$ [489]. La matriz $\hat{\mathbf{L}}$ se denomina laplaciana simétrica [356] o incluso laplaciana normalizada [408].

6.4.1.3 Algoritmo de corte mínimo normalizado de Ng, Jordan e Weiss

Ng, Jordan y Weiss [415] presentaron una variante del algoritmo de corte mínimo normalizado. El laplaciano en el paso 03 se reemplaza por la matriz $\hat{\mathbf{A}} = \mathbf{D}^{-1/2}\mathbf{A}\mathbf{D}^{-1/2}$, llamada matriz de adyacencia normalizada [104] o matriz de adyacencia reducida [414]. Algunos autores sugieren que la descomposición espectral se calcule con el laplaciano normalizado $\hat{\mathbf{L}} = \mathbf{D}^{-1/2}\mathbf{L}\mathbf{D}^{-1/2}$ [356][408]. En el artículo original [415], la descomposición espectral del paso 04 se calcula como:

$$\hat{\mathbf{A}}\mathbf{W} = \mathbf{W}\hat{\mathbf{A}} \quad (6.26)$$

La descomposición espectral (6.26) produce los mismos vectores propios $\mathbf{W}$ que (6.25) y valores propios $\hat{\mathbf{\Lambda}} = \mathbf{1} - \mathbf{\Lambda}$, donde $\mathbf{\Lambda}$ es la matriz de valores propios calculada en (6.25). Así, la solución al problema (6.26) corresponde a la minimización de corte mínimo normalizada (6.14) con los valores propios en orden no creciente $\hat{\lambda}_1 \geq \hat{\lambda}_2 \geq \dots \geq \hat{\lambda}_N$.

La matriz $\hat{\mathbf{A}}$ tiene otras propiedades interesantes. En un gráfico definido por una matriz de adyacencia binaria, es decir, $a_{ij} \in \{0,1\}$, el valor propio más grande $\hat{\lambda}_1 = 1$. El número de valores propios unitarios corresponde al número de componentes del gráfico [104][342] y, en

grafos conexos, $\hat{\lambda}_2 < 1$ [104]. Num grafo com K componentes que definem uma partição $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$, o valor do corte mínimo $cut(\mathcal{C}_1, \dots, \mathcal{C}_K) = 0$ (cf. (6.15)) e a matriz $\hat{\mathbf{A}}$ tem K autovalores unitários: $\hat{\lambda}_i = 1, i = 1, \dots, K$. Essa propriedade permite utilizar o resultado da decomposição espectral (6.26) para uma estimativa do número de grupos de um conjunto de dados [342][168][170].

As variáveis transformadas são calculadas, para cada registro, pelos autovetores normalizados como:

$$\hat{\mathbf{z}}(t) = \left[\frac{w_1(t)}{\|\mathbf{z}(t)\|}, \dots, \frac{w_K(t)}{\|\mathbf{z}(t)\|} \right] \quad (6.27)$$

onde $\mathbf{z}(t) = [w_1(t), \dots, w_K(t)]$ e $w_i(t)$ é o elemento t do autovetor correspondente ao autovalor $\hat{\lambda}_i$, calculado na decomposição espectral (6.26).

A utilização das variáveis transformadas normalizadas no k-médias é equivalente à utilização do k-médias esférico nas variáveis transformadas sem normalização [468]. Na prática, a normalização (6.27) também pode ser aplicada aos demais algoritmos de corte mínimo. O algoritmo do corte normalizado de Ng, Jordan e Weiss é descrito no Algoritmo 6.3c.

Algoritmo 6.3c: Corte mínimo normalizado [415]

03	$\hat{\mathbf{A}} = \mathbf{D}^{-1/2} \mathbf{A} \mathbf{D}^{-1/2}$
04	$\hat{\mathbf{A}} \mathbf{W} = \mathbf{W} \hat{\mathbf{A}}$
05	Ordenar $1 = \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_N$, $\hat{\mathbf{z}}(t) = \left[\frac{w_1(t)}{\ \mathbf{z}(t)\ }, \dots, \frac{w_K(t)}{\ \mathbf{z}(t)\ } \right]$

A complexidade computacional do cálculo da matriz de similaridade é $O(N^2)$ e a complexidade do algoritmo de agrupamento espectral é dominada pelo cálculo do problema de autovalor, que é de $O(N^3)$. Em problemas que $K \ll N$, a complexidade pode ser reduzida a $O(N^2)$, uma vez que apenas os primeiros autovetores são necessários.

O algoritmo de agrupamento espectral pode separar grupos não convexos no espaço de variáveis de entrada do problema e, por isso, tem bons resultados em aplicações de agrupamento. Essas características motivaram o desenvolvimento de outras variantes do algoritmo [23][356][408][554]. Os algoritmos de agrupamento espectral são relacionados aos algoritmos baseados em função de núcleo [127][128][182][596].

gráficos conectados, $\hat{\lambda}_2 < 1$ [104]. En un gráfico con K componentes que definen una partición $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$, el valor del corte mínimo $cut(\mathcal{C}_1, \dots, \mathcal{C}_K) = 0$ (cf. (6.15)) y la matriz $\hat{\mathbf{A}}$ tiene K valores propios unitarios: $\hat{\lambda}_i = 1, i = 1, \dots, K$. Esta propiedad permite utilizar el resultado de la descomposición espectral (6.26) para estimar el número de grupos en un conjunto de datos [342][168][170].

Las variables transformadas se calculan, para cada registro, mediante vectores propios normalizados como:

$$\hat{\mathbf{z}}(t) = \left[\frac{w_1(t)}{\|\mathbf{z}(t)\|}, \dots, \frac{w_K(t)}{\|\mathbf{z}(t)\|} \right] \quad (6.27)$$

donde $\mathbf{z}(t) = [w_1(t), \dots, w_K(t)]$ y $w_i(t)$ es el elemento t del vector propio correspondiente al valor propio $\hat{\lambda}_i$, calculado en la descomposición espectral (6.26).

El uso de variables transformadas normalizadas en k-medias es equivalente al uso de k-medias esféricas en variables transformadas sin normalización [468]. En la práctica, la normalización (6.27) también se puede aplicar a otros algoritmos de corte mínimo. El algoritmo de corte normalizado de Ng, Jordan y Weiss se describe en el Algoritmo 6.3c.

Algoritmo 6.3c: Corte mínimo normalizado [415]

03	$\hat{\mathbf{A}} = \mathbf{D}^{-1/2} \mathbf{A} \mathbf{D}^{-1/2}$
04	$\hat{\mathbf{A}} \mathbf{W} = \mathbf{W} \hat{\mathbf{A}}$
05	Ordenar $1 = \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_N$, $\hat{\mathbf{z}}(t) = \left[\frac{w_1(t)}{\ \mathbf{z}(t)\ }, \dots, \frac{w_K(t)}{\ \mathbf{z}(t)\ } \right]$

La complejidad computacional del cálculo de la matriz de similitud es $O(N^2)$ y la complejidad del algoritmo de agrupamiento espectral está dominada por el cálculo del problema de valores propios, que es $O(N^3)$. En problemas que $K \ll N$, la complejidad se puede reducir a $O(N^2)$ ya que solo se necesitan los primeros vectores propios.

El algoritmo de agrupamiento espectral puede separar grupos no convexos en el espacio de variables de entrada del problema y, por lo tanto, tiene buenos resultados en aplicaciones de agrupamiento. Estas características motivaron el desarrollo de otras variantes del algoritmo [23][356][408][554]. Los algoritmos de agrupamiento espectral están relacionados con los algoritmos basados en funciones del núcleo [127][128][182][596].

6.4.1.4 Algoritmo de maximização da modularidade de Newman e Girvan

O problema de maximização da modularidade (cf. equação (6.16)) também tem solução aproximada pela decomposição espectral da matriz de modularidade $\mathbf{B}$. No caso de uma partição binária $\mathbb{C} = \{\mathcal{C}_1, \mathcal{C}_2\}$, o produto $\mathbf{u}_i \mathbf{u}_j^T$ é escrito em função variável indicadora (6.18) como $\mathbf{u}_i \mathbf{u}_j^T = \frac{1}{2}(v_i v_j + 1)$, de modo que $\frac{1}{2}(v_i v_j + 1) = 1$ se dois registros $\mathbf{x}(i)$ e $\mathbf{x}(j)$ estão no mesmo grupo e $\frac{1}{2}(v_i v_j + 1) = 0$ caso contrário.

A função de modularidade (6.16) é reescrita como:

$$Q(\mathcal{C}_1, \mathcal{C}_2) = \frac{1}{4E} \sum_{i=1}^N \sum_{j=1}^N b_{ij} (v_i v_j + 1) = \frac{1}{4E} \left(\sum_{i=1}^N \sum_{j=1}^N b_{ij} v_i v_j + \sum_{i=1}^N \sum_{j=1}^N b_{ij} \right) \quad (6.28)$$

onde b_{ij} são os elementos da matriz de modularidade $\mathbf{B}$ definida em (6.17). A soma das linhas (ou colunas) da matriz $\mathbf{B}$ é zero, de forma que o termo $\sum_{ij} b_{ij} = 0$. A função de modularidade pode ser escrita vetorialmente como:

$$Q(\mathcal{C}_1, \mathcal{C}_2) = \frac{1}{4E} \mathbf{v}^T \mathbf{B} \mathbf{v} \quad (6.29)$$

Uma aproximação para a solução do problema de maximização da modularidade (6.29) é obtida pela solução do problema de autovalor $\mathbf{B} \mathbf{w} = \lambda \mathbf{w}$, em que λ é o maior autovalor e $\hat{\mathbf{v}}$, o autovetor correspondente. O sinal dos elementos do autovetor correspondente ao maior autovalor é utilizado para a obtenção da partição $\mathbb{C} = \{\mathcal{C}_1, \mathcal{C}_2\}$:

$$\hat{v}_i = \begin{cases} +1, & \text{se } w_i \geq 0 \\ -1, & \text{se } w_i < 0 \end{cases} \quad (6.30)$$

Newman e Girvan [413] apresentam uma abordagem hierárquica divisiva para o particionamento do grafo em que, a cada iteração, o valor do ganho da função modularidade é avaliado e utilizado para a decisão sobre um novo particionamento. Vieira e colaboradores [541] apresentam um estudo de desempenho e o código dos principais algoritmos de detecção de comunidades baseados na função de modularidade.

6.4.2 Exemplos

A Figura 6.11 mostra, em cada linha, os resultados dos algoritmos 6.3a-c no conjunto de dados de duas luas utilizando o parâmetro $\sigma = 0.1$ no cálculo da função de similaridade. Na coluna da direita são apresentados os resultados do agrupamento e, na coluna da esquerda, as variáveis transformadas.

6.4.1.4 Algoritmo de maximização da modularidade de Newman e Girvan

El problema de maximizar la modularidad (cf. ecuación (6.16)) también tiene una solución aproximada mediante la descomposición espectral de la matriz de modularidad $\mathbf{B}$. En el caso de una partición binaria $\mathbb{C} = \{\mathcal{C}_1, \mathcal{C}_2\}$, el producto $\mathbf{u}_i \mathbf{u}_j^T$ se escribe en la función de variable indicadora (6.18) como $\mathbf{u}_i \mathbf{u}_j^T = \frac{1}{2}(v_i v_j + 1)$, de modo que $\frac{1}{2}(v_i v_j + 1) = 1$ si dos registros $\mathbf{x}(i)$ y $\mathbf{x}(j)$ están en el mismo grupo y $\frac{1}{2}(v_i v_j + 1) = 0$ en caso contrario.

-

La función de modularidad (6.16) se reescribe como:

$$Q(\mathcal{C}_1, \mathcal{C}_2) = \frac{1}{4E} \sum_{i=1}^N \sum_{j=1}^N b_{ij} (v_i v_j + 1) = \frac{1}{4E} \left(\sum_{i=1}^N \sum_{j=1}^N b_{ij} v_i v_j + \sum_{i=1}^N \sum_{j=1}^N b_{ij} \right) \quad (6.28)$$

donde b_{ij} son los elementos de la matriz de modularidad $\mathbf{B}$ definida en (6.17). La suma de las filas (o columnas) de la matriz $\mathbf{B}$ es cero, por lo que el término $\sum_{ij} b_{ij} = 0$. La función de modularidad se puede escribir vectorialmente como:

$$Q(\mathcal{C}_1, \mathcal{C}_2) = \frac{1}{4E} \mathbf{v}^T \mathbf{B} \mathbf{v} \quad (6.29)$$

Una aproximación a la solución del problema de maximización de modularidad (6.29) se obtiene resolviendo el problema de valores propios $\mathbf{B} \mathbf{w} = \lambda \mathbf{w}$, donde λ es el valor propio más grande y $\hat{\mathbf{v}}$ el vector propio correspondiente. El signo de los elementos del vector propio correspondiente al mayor valor propio se utiliza para obtener la partición $\mathbb{C} = \{\mathcal{C}_1, \mathcal{C}_2\}$:

$$\hat{v}_i = \begin{cases} +1, & \text{se } w_i \geq 0 \\ -1, & \text{se } w_i < 0 \end{cases} \quad (6.30)$$

Newman y Girvan [413] presentan un enfoque jerárquico divisivo para la partición de gráficos en el que, en cada iteración, el valor de ganancia de la función de modularidad se evalúa y se utiliza para decidir sobre una nueva partición. Vieira y colaboradores [541] presentan un estudio de rendimiento y el código de los principales algoritmos de detección de comunidades basados en la función de modularidad.

6.4.2 Ejemplos

La Figura 6.11 muestra, en cada línea, los resultados de los algoritmos 6.3a-c en el conjunto de datos de dos lunas utilizando el parámetro $\sigma = 0.1$ en el cálculo de la función de similitud. Los resultados de agrupación se presentan en la columna de la derecha y las variables transformadas se presentan en la columna de la izquierda.




Figura 6.11: Resultados no conjunto de dados duas luas: à esquerda, os resultados do agrupamento e, à direita, as variáveis transformadas; nas linhas, os Algoritmos 6.3a-c.

Podemos observar que os algoritmos espectrais baseados no corte mínimo podem gerar grupos de forma não convexa e as três formulações produzem os mesmos resultados. Os resultados das variáveis transformadas utilizadas nos algoritmos de corte mínimo (6.3a) e corte mínimo normalizado (6.3b) também são idênticos. Uma aplicação




Figura 6.11: Resultados en el conjunto de datos de dos lunas: a la izquierda, los resultados del agrupamiento y , a la derecha, las variables transformadas; en las líneas, Algoritmos 6.3a-c.

Podemos observar que los algoritmos espectrales basados en el corte mínimo pueden generar grupos de forma no convexa y las tres formulaciones producen los mismos resultados. Los resultados de las variables transformadas utilizadas en los algoritmos de corte mínimo (6.3a) y de corte mínimo normalizado (6.3b) también son idénticos. una aplicacion

do algoritmo de maximização da modularidade para agrupamento de documentos será apresentada na seção 6.6.2.

Os resultados dos algoritmos de agrupamento espectral dependem do valor do parâmetro de dispersão σ no cálculo da função de similaridade gaussiana (6.12), além da informação do número de grupos K para o algoritmo k-médias. Entretanto, a inicialização do algoritmo k-médias é definida pela matriz identidade e o resultado do algoritmo espectral é determinístico.

Na análise de agrupamentos, a decisão sobre o melhor número de grupos depende de alguma medida de validação, como apresentado a seguir.

6.5 Validação de Grupos

Encontrar uma partição num conjunto de dados é um problema mal definido e diferentes agrupamentos podem ser obtidos do mesmo conjunto (cf. Figura 6.1). Não há uma medida absoluta de qualidade para o problema e o resultado do agrupamento deve ser avaliado no contexto da aplicação.

As medidas de validação de agrupamentos visam avaliar as características geométricas do agrupamento formado, sabendo-se que um bom agrupamento deve produzir grupos compactos e bem separados. É comum encontrar na literatura a divisão das medidas de validação de agrupamentos em três tipos [194][227][228][573], cujos principais índices são apresentados na sequência:

- **Medidas externas:** avaliam a qualidade do agrupamento em relação a uma informação externa sobre a estrutura de grupos (ou classes) do problema;
- **Medidas internas:** avaliam a qualidade do agrupamento a partir dos registros do conjunto de dados, em geral utilizando critérios geométricos;
- **Medidas relativas:** produzem índices calculados pela combinação de critérios (internos) que avaliam a qualidade de um agrupamento em relação a outros.

6.5.1 Medidas externas

As medidas externas avaliam a qualidade do agrupamento a partir de uma matriz de confusão como na avaliação de classificadores (cf. Tabela 5.2). Para avaliação de grupos, a matriz de confusão relaciona os grupos encontrados pelo algoritmo de agrupa-

del algoritmo de maximización de modularidad para la agrupación de documentos se presentará en la sección 6.6.2.

Los resultados de los algoritmos de agrupamiento espectral dependen del valor del parámetro de dispersión σ en el cálculo de la función de similitud gaussiana (6.12), además de la información sobre el número de grupos K para el algoritmo k-medias. Sin embargo, la inicialización del algoritmo k-medias está definida por la matriz de identidad y el resultado del algoritmo espectral es determinista.

En el análisis de conglomerados, la decisión sobre el mejor número de grupos depende de alguna medida de validación, como se presenta a continuación.

6.5 Validación de grupo

Encontrar una partición en un conjunto de datos es un problema mal definido y se pueden obtener diferentes agrupaciones del mismo conjunto (cf. Figura 6.1). No existe una medida absoluta de calidad para el problema y el resultado de la agrupación debe evaluarse en el contexto de la aplicación.

Las medidas de validación de clusters tienen como objetivo evaluar las características geométricas del cluster formado, sabiendo que un buen cluster debe producir grupos compactos y bien separados. Es común encontrar en la literatura la división de las medidas de validación de clusters en tres tipos [194][227][228][573], cuyos principales índices se presentan a continuación:

Medidas externas: evaluar la calidad del agrupamiento en relación con información externa sobre la estructura de los grupos (o clases) del problema; Medidas internas: evaluar la calidad de la agrupación a partir de los registros del conjunto de datos, generalmente utilizando criterios geométricos; Medidas relativas: producir índices calculados combinando criterios (internos) que evalúan la calidad de una agrupación en relación con otras.

6.5.1 Medidas externas

Las medidas externas evalúan la calidad del agrupamiento basándose en una matriz de confusión como en la evaluación de clasificadores (cf. Tabla 5.2). Para evaluar grupos, la matriz de confusión relaciona los grupos encontrados por el algoritmo de clustering.

mento com as classes do problema. A Tabela 6.1 mostra a matriz de confusão para avaliação de agrupamentos, onde $\{C_1, \dots, C_m\}$ é o conjunto de classes e $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$, uma partição de K grupos. Cada elemento n_{ij} na Tabela 6.1 representa o número de registros da classe C_i alocados no grupo $\mathcal{C}_j$. A soma das linhas corresponde ao número de elementos das classes e a soma das colunas, o número de elementos dos grupos.

Quando o número de grupos é igual ao número de classes, qualquer estatística de avaliação de classificadores (cf. seção 5.3.1) pode ser utilizada como medida de validação externa. Entretanto, é comum que o número de grupos seja diferente do número de classes e, nesse caso, as medidas externas avaliam o quanto o agrupamento encontrado corresponde à estrutura de classes conhecida.

Tabela 6.1: Matriz de confusão

	$\mathcal{C}_1$	...	$\mathcal{C}_K$	Total
C_1	n_{11}	...	n_{1K}	N_1
$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
C_m	n_{m1}	...	n_{mK}	N_m
Total	$\hat{N}_1$	...	$\hat{N}_K$	N

A **pureza** de um grupo é a porção dos registros de um grupo que pertence à classe que contém a maioria dos registros daquele grupo. A pureza é uma medida de homogeneidade do agrupamento: quanto maior a pureza, mais homogêneos são os grupos. A pureza de um grupo é calculada como:

$$pur(\mathcal{C}_j) = \max_{i=1, \dots, m} \left(\frac{n_{ij}}{\hat{N}_j} \right) \quad (6.31)$$

A pureza total ou pureza do agrupamento é calculada como a média da pureza dos grupos ponderada pelo número de registros de cada grupo:

$$PUR(\mathbb{C}) = \sum_{j=1}^K \frac{\hat{N}_j}{N} pur(\mathcal{C}_j) \quad (6.32)$$

ment con las clases de problemas. La Tabla 6.1 muestra la matriz de confusión para la evaluación de conglomerados, donde $\{C_1, \dots, C_m\}$ es el conjunto de clases y $\mathbb{C} = \{C_1, \dots, C_K\}$, una partición de K grupos. Cada elemento n_{ij} en la Tabla 6.1 representa el número de registros de clase C_i asignados en el grupo C_j . La suma de las filas corresponde al número de elementos de las clases y la suma de las columnas corresponde al número de elementos de los grupos.

Cuando el número de grupos es igual al número de clases, cualquier estadística de evaluación del clasificador (ver sección 5.3.1) se puede utilizar como medida de validación externa. Sin embargo, es común que el número de grupos sea diferente al número de clases y, en este caso, medidas externas evalúan en qué medida el agrupamiento encontrado corresponde a la estructura de clases conocida.

Tabla 6.1: Matriz de confusión

	C_1	...	C_K	Total
C_1	n_{11}	...	n_{1K}	N_1
$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
C_m	n_{m1}	...	n_{mK}	N_m
Total	$\hat{N}_1$	...	$\hat{N}_K$	N

La pureza de un grupo es la porción de los registros de un grupo que pertenecen a la clase que contiene la mayoría de los registros de ese grupo. La pureza es una medida de la homogeneidad del grupo: cuanto mayor es la pureza, más homogéneos son los grupos. La pureza de un grupo se calcula como:

$$pur(C_j) = \max_{i=1, \dots, m} \left(\frac{n_{ij}}{\hat{N}_j} \right) \quad (6.31)$$

La pureza total o pureza del racimo se calcula como la pureza promedio de los grupos ponderada por el número de registros en cada grupo:

$$PUR(\mathbb{C}) = \sum_{j=1}^K \frac{\hat{N}_j}{N} pur(C_j) \quad (6.32)$$

A entropia de Shannon é uma medida clássica da teoria da informação que pode ser utilizada para avaliar a heterogeneidade do agrupamento: quanto menor a entropia, melhor o agrupamento. A **entropia** de um grupo é calculada como (cf. Tabela 6.1):

$$ent(\mathcal{C}_j) = -\frac{1}{\log_2 m} \sum_{i=1}^m \left(\frac{n_{ij}}{\hat{N}_j} \right) \log_2 \left(\frac{n_{ij}}{\hat{N}_j} \right) \quad (6.33)$$

A entropia do agrupamento é calculada como a média da entropia dos grupos ponderada pelo número de registros de cada grupo:

$$ENT(\mathbb{C}) = \sum_{j=1}^K \frac{\hat{N}_j}{N} ent(\mathcal{C}_j) \quad (6.34)$$

Há outras medidas externas para avaliação da qualidade de agrupamentos baseadas em contagem de pares e informação mútua [544]. Entretanto, nem sempre uma informação de classes é conhecida para a avaliação do agrupamento. Além disso, a estrutura de grupos pode não coincidir com a estrutura de classes, o que não significa que o agrupamento esteja inadequado (cf. Figura 6.2). Medidas internas e relativas são mais comuns em problemas de agrupamento.

6.5.2 Medidas internas

Medidas internas avaliam um agrupamento utilizando apenas as informações dos registros do conjunto de dados e o resultado do agrupamento. A função de avaliação de um algoritmo de agrupamento, por exemplo, é uma medida interna de avaliação. Em algoritmos hierárquicos, o coeficiente de correlação cofenética [572] é empregado para avaliação de agrupamentos.

Uma medida interna muito utilizada é o índice de partição (PI, na sigla em inglês), proposta por Bensaid e colaboradores [41] para avaliação de agrupamentos *fuzzy*. O índice PI, quando calculado com funções de pertinência binárias, é a razão entre o critério quadrático do k-médias e a soma ponderada das distâncias entre centros:

$$PI(\mathbb{C}) = \frac{\sum_{i=1}^K \sum_{t=1}^N u_i(\mathbf{x}(t))^2 \|\mathbf{x}(t) - \boldsymbol{\omega}_i\|^2}{\sum_{i=1}^K \sum_{j=1}^K N_i \|\boldsymbol{\omega}_i - \boldsymbol{\omega}_j\|^2} = \frac{tr(\boldsymbol{\Sigma}_W)}{\sum_{i=1}^K \sum_{j=1}^K N_i \|\boldsymbol{\omega}_i - \boldsymbol{\omega}_j\|^2} \quad (6.35)$$

onde $tr(\boldsymbol{\Sigma}_W)$ é o traço da matriz de variância intragrupos (cf. equação (6.6)).

La entropía de Shannon es una medida clásica de la teoría de la información que se puede utilizar para evaluar la heterogeneidad de los conglomerados: cuanto menor es la entropía, mejor es el conglomerado. La entropía de un grupo se calcula como (cf. Tabla 6.1):

$$ent(\mathcal{C}_j) = -\frac{1}{\log_2 m} \sum_{i=1}^m \left(\frac{n_{ij}}{\hat{N}_j} \right) \log_2 \left(\frac{n_{ij}}{\hat{N}_j} \right) \quad (6.33)$$

La entropía del clúster se calcula como la entropía promedio de los grupos ponderada por el número de registros en cada grupo:

$$ENT(\mathbb{C}) = \sum_{j=1}^K \frac{\hat{N}_j}{N} ent(\mathcal{C}_j) \quad (6.34)$$

Existen otras medidas externas para evaluar la calidad de los conglomerados basadas en el recuento de pares y la información mutua [544]. Sin embargo, no siempre se conoce la información de clase para evaluar la agrupación. Además, la estructura del grupo puede no coincidir con la estructura de clases, lo que no significa que la agrupación sea inadecuada (cf. Figura 6.2). Las medidas internas y relativas son más comunes en los problemas de agrupación.

6.5.2 Medidas internas

Las medidas internas evalúan un grupo utilizando únicamente información de los registros del conjunto de datos y el resultado del grupo. La función de evaluación de un algoritmo de clustering, por ejemplo, es una medida de evaluación interna. En algoritmos jerárquicos, el coeficiente de correlación cofenética [572] se utiliza para evaluar conglomerados.

Una medida interna ampliamente utilizada es el índice de partición (PI), propuesto por Bensaid y colaboradores [41] para evaluar conglomerados *fuzzy*. El índice PI, cuando se calcula con funciones de pertenencia binarias, es la relación entre el criterio de k-medias cuadráticas y la suma ponderada de las distancias entre centros:

$$PI(\mathbb{C}) = \frac{\sum_{i=1}^K \sum_{t=1}^N u_i(\mathbf{x}(t))^2 \|\mathbf{x}(t) - \boldsymbol{\omega}_i\|^2}{\sum_{i=1}^K \sum_{j=1}^K N_i \|\boldsymbol{\omega}_i - \boldsymbol{\omega}_j\|^2} = \frac{tr(\boldsymbol{\Sigma}_W)}{\sum_{i=1}^K \sum_{j=1}^K N_i \|\boldsymbol{\omega}_i - \boldsymbol{\omega}_j\|^2} \quad (6.35)$$

donde $tr(\boldsymbol{\Sigma}_W)$ es la traza de la matriz de varianza intragrupo (cf. ecuación (6.6)).

Na avaliação de agrupamentos obtidos pelo algoritmo k-médias e suas variantes, o índice PI permite a escolha do melhor agrupamento de um conjunto de soluções obtidas com diversas inicializações aleatórias, mas com o mesmo número de grupos K .

Uma proposta para avaliação de agrupamentos é a visualização qualitativa da tendência de agrupamento (VAT)* [49][239]. A VAT é basicamente o *data image* do conjunto de dados com os registros ordenados segundo o resultado do agrupamento. Um bom agrupamento mostra um contraste mais intenso que um agrupamento de pior qualidade, para o mesmo conjunto de dados.

A Figura 6.12 mostra os resultados do agrupamento do conjunto de dados Íris com $K = 4$ grupos. Foram realizados 25 agrupamentos distintos e selecionados os de menor e maior valor de PI, que são apresentados, respectivamente, na coluna da esquerda e na da direita da Figura 6.12. Podemos observar que o resultado com menor valor de PI (à esquerda) resulta num contraste ligeiramente maior que o resultado com maior valor de PI (à direita).




Figura 6.12: *Data image* do resultado do agrupamento do conjunto de dados Iris com $K = 4$:

(a) resultado com menor PI; (b) resultado com maior PI.

A avaliação qualitativa pelo *data image* é muito subjetiva, sendo preferível a utilização de uma métrica quantitativa para a escolha do melhor agrupamento. As medidas relativas permitem avaliar o número de grupos, principalmente em algoritmos de partição.

* *Visual Assessment of (cluster) Tendency.*

Al evaluar los clusters obtenidos por el algoritmo k-means y sus variantes, el índice PI permite elegir el mejor cluster de un conjunto de soluciones obtenidas con varias inicializaciones aleatorias, pero con el mismo número de grupos K .

Una propuesta para evaluar los conglomerados es la visualización cualitativa de la tendencia del conglomerado (IVA)* [49][239]. El IVA es básicamente la *data image* del conjunto de datos con los registros ordenados según el resultado de la agrupación. Un buen grupo muestra un contraste más intenso que un grupo pobre para el mismo conjunto de datos.

La Figura 6.12 muestra los resultados de agrupar el conjunto de datos Iris con grupos $K = 4$. Se realizaron 25 agrupamientos diferentes y se seleccionaron aquellos con valores de PI más bajos y más altos, los cuales se presentan, respectivamente, en las columnas izquierda y derecha de la Figura 6.12. Podemos ver que el resultado con el valor de PI más bajo (a la izquierda) da como resultado un contraste ligeramente mayor que el resultado con el valor de PI más alto (a la derecha).




Figura 6.12: *Data image* del resultado de agrupar el conjunto de datos Iris con $K = 4$: (a) resultado con el IP más bajo; (b) resultado con el IP más alto.

La valoración cualitativa de *data image* es muy subjetiva, siendo preferible utilizar una métrica cuantitativa para elegir la mejor agrupación. Las medidas relativas permiten evaluar el número de grupos, especialmente en algoritmos de partición.

* *Visual Assessment of (cluster) Tendency.*

6.5.3 Medidas relativas

Os métodos de partição, principalmente o k-médias e suas variantes, são os mais utilizados na prática e, nesse caso, as medidas relativas são empregadas para a descoberta do número de grupos. As medidas relativas são índices utilizados para comparação de diversas soluções do mesmo algoritmo, variando-se o número de grupos. No algoritmo k-médias, o resultado depende da inicialização e as medidas relativas podem variar para o mesmo número de grupos, sendo, portanto, uma função do agrupamento gerado pelo algoritmo e não somente do número de grupos.

Num estudo realizado em 1985, Milligan e Cooper [388] compararam 30 medidas de avaliação de agrupamento existentes na época. A medida que obteve o melhor resultado foi a proposta por Calinski e Harabasz [71] em 1974.

O índice Calinski-Harabasz (CH) de uma partição $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$ é calculado como:

$$CH(\mathbb{C}) = \frac{N - K}{K - 1} \frac{tr(\mathbf{\Sigma}_B)}{tr(\mathbf{\Sigma}_W)} \quad (6.36)$$

onde, $tr(\mathbf{\Sigma}_B)$ e $tr(\mathbf{\Sigma}_W)$ são, respectivamente, os traços das matrizes de variância entre grupos e intragrupos, definidas nas equações (6.5) e (6.6).

O índice CH é um critério de maximização, uma vez que o valor pequeno de $tr(\mathbf{\Sigma}_W)$ indica grupos coesos e um valor grande de $tr(\mathbf{\Sigma}_B)$, grupos separados.

Um índice semelhante, proposto por Pakhira, Bandyopadhyay e Maulik [423] em 2006, também é um critério de maximização calculado pelo produto de três termos:

$$PBM(\mathbb{C}) = \left(\frac{1}{K} \frac{E_1}{E_K} \frac{1}{D_{\max}} \right)^2 \quad (6.37)$$

onde $E_1 = \sum_{t=1}^N \|\mathbf{x}(t) - \bar{\mathbf{x}}\|$ é constante para um determinado conjunto de dados. O termo, $E_K = \sum_{t=1}^N \sum_{i=1}^K u_i(\mathbf{x}(t)) \|\mathbf{x}(t) - \boldsymbol{\omega}_i\|$, diminui com o aumento do número de grupos K e o termo $D_{\max} = \max_{i,j=1 \dots K} (\|\boldsymbol{\omega}_i - \boldsymbol{\omega}_j\|^2)$ aumenta com o número de grupos.

O índice PBM utiliza os valores de distâncias nas somas de E_1 e E_K , ao passo que as matrizes de variância utilizadas no índice CH são calculadas pela soma das diferenças ao quadrado (cf. equações (6.4)-(6.6)). A razão E_1/E_K favorece agrupamentos cuja variância intragrupos é a menor porção da variância total. O primeiro e o terceiro fatores

6.5.3 Medidas relativas

Los métodos de partición, principalmente k-medias y sus variantes, son los más utilizados en la práctica y, en este caso, se utilizan medidas relativas para descubrir el número de grupos. Las medidas relativas son índices que se utilizan para comparar diferentes soluciones de un mismo algoritmo, variando el número de grupos. En el algoritmo k-means, el resultado depende de la inicialización y las medidas relativas pueden variar para el mismo número de grupos, siendo por tanto función de la agrupación generada por el algoritmo y no sólo del número de grupos.

En un estudio realizado en 1985, Milligan y Cooper [388] compararon 30 medidas de evaluación de conglomerados que existían en ese momento. La medida que mejor resultado obtuvo fue la propuesta por Calinski y Harabasz [71] en 1974.

El índice Calinski-Harabasz (CH) de una partición $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$ se calcula como:

$$CH(\mathbb{C}) = \frac{N - K}{K - 1} \frac{tr(\mathbf{\Sigma}_B)}{tr(\mathbf{\Sigma}_W)} \quad (6.36)$$

donde, $tr(\mathbf{\Sigma}_B)$ y $tr(\mathbf{\Sigma}_W)$ son, respectivamente, las trazas de las matrices de varianza entre grupos e intragrupos, definidas en las ecuaciones (6.5) y (6.6).

El índice CH es un criterio de maximización, ya que un valor pequeño de $tr(\mathbf{\Sigma}_W)$ indica grupos cohesivos y un valor grande de $tr(\mathbf{\Sigma}_B)$ grupos separados.

Un índice similar, propuesto por Pakhira, Bandyopadhyay y Maulik [423] en 2006, es también un criterio de maximización calculado por el producto de tres términos:

$$PBM(\mathbb{C}) = \left(\frac{1}{K} \frac{E_1}{E_K} \frac{1}{D_{\max}} \right)^2 \quad (6.37)$$

donde $E_1 = \sum_{t=1}^N \|\mathbf{x}(t) - \bar{\mathbf{x}}\|$ es constante para un conjunto de datos determinado. El término $E_K = \sum_{t=1}^N \sum_{i=1}^K u_i(\mathbf{x}(t)) \|\mathbf{x}(t) - \boldsymbol{\omega}_i\|$, disminuye con el aumento del número de grupos K y el término $D_{\max} = \max_{i,j=1 \dots K} (\|\boldsymbol{\omega}_i - \boldsymbol{\omega}_j\|^2)$ aumenta con el número de grupos.

El índice PBM utiliza los valores de distancia en las sumas de E_1 y E_K , mientras que las matrices de varianza utilizadas en el índice CH se calculan mediante la suma de las diferencias al cuadrado (véanse las ecuaciones (6.4)-(6.6)). La relación E_1/E_K favorece a los conglomerados cuya varianza intragrupo es la porción más pequeña de la varianza total. El primer y tercer factor.

do índice PBM favorecem, respectivamente, agrupamentos com pequeno número de grupos e com centros separados.

Uma medida de avaliação relativa muito conhecida é o coeficiente de silhueta [462], que avalia a qualidade do agrupamento para cada registro como:

$$sw_i(t) = - \frac{(b_i(t) - a_i(t))}{\max_{t=1, \dots, N} (a_i(t), b_i(t))} \quad (6.38)$$

onde $a_i(t)$ é a média das distâncias entre o registro $\mathbf{x}(t)$ e todos os outros registros alocados ao mesmo grupo $\mathcal{C}_i$ e $b_i(t)$ é a menor distância média entre $\mathbf{x}(t)$ e os registros alocados aos demais grupos $\mathcal{C}_j \neq \mathcal{C}_i$.

O valor $a_i(t)$ é calculado para cada registro $\mathbf{x}(t) \in \mathcal{C}_i$ como a distância média para os demais elementos do grupo:

$$a_i(t) = \frac{1}{\bar{N}_i} \sum_{k=1}^N dist(\mathbf{x}(t), \mathbf{x}(k)), \quad \mathbf{x}(k) \in \mathcal{C}_i \quad (6.39)$$

O valor $b_i(t) = \min_j (\bar{a}_j(t))$, onde $\bar{a}_j(t)$ é a distância média de $\mathbf{x}(t)$ para os registros dos demais grupos $\mathcal{C}_j, j = 1, \dots, K, j \neq i$, calculada como:

$$\bar{a}_j(t) = \frac{1}{\bar{N}_j} \sum_{k=1}^N dist(\mathbf{x}(t), \mathbf{x}(k)), \quad \mathbf{x}(t) \in \mathcal{C}_j, j \neq i \quad (6.40)$$

O coeficiente de silhueta é definido no intervalo $-1 < sw_i(t) < 1$, sendo que o valor $sw_i(t) \approx 1$ é obtido quando $a_i(t) \approx 0$, o que indica que o registro está no centro de um agrupamento compacto. Quanto maior o valor do coeficiente de silhueta, melhor a posição do registro no agrupamento. O coeficiente de silhueta também pode ser utilizado numa etapa de refinamento, verificando-se seu valor caso o registro seja alocado em outro grupo.

O coeficiente de silhueta da partição $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$ é calculado como o valor médio do coeficiente de silhueta para todos os registros e todos os grupos:

$$SW(\mathbb{C}) = \frac{1}{KN} \sum_{i=1}^K \sum_{t=1}^N sw_i(t) \quad (6.41)$$

del índice PBM favorecen, respectivamente, conglomerados con un pequeño número de grupos y con centros separados.

Una medida de evaluación relativa bien conocida es el coeficiente de silueta [462], que evalúa la calidad de agrupación de cada registro como:

$$sw_i(t) = - \frac{(b_i(t) - a_i(t))}{\max_{t=1, \dots, N} (a_i(t), b_i(t))} \quad (6.38)$$

donde $a_i(t)$ es la distancia promedio entre el registro $\mathbf{x}(t)$ y todos los demás registros asignados al mismo grupo $\mathcal{C}_i$ y $b_i(t)$ es la distancia promedio más pequeña entre $\mathbf{x}(t)$ y los registros asignados a los otros grupos $\mathcal{C}_j \neq \mathcal{C}_i$.

El valor $a_i(t)$ se calcula para cada registro $\mathbf{x}(t) \in \mathcal{C}_i$ como la distancia promedio a los demás elementos del grupo:

$$a_i(t) = \frac{1}{\bar{N}_i} \sum_{k=1}^N dist(\mathbf{x}(t), \mathbf{x}(k)), \quad \mathbf{x}(k) \in \mathcal{C}_i \quad (6.39)$$

El valor $b_i(t) = \min_j (\bar{a}_j(t))$, donde $\bar{a}_j(t)$ es la distancia promedio desde $\mathbf{x}(t)$ a los registros de los otros grupos $\mathcal{C}_j, j = 1, \dots, K, j \neq i$, calculado como:

$$\bar{a}_j(t) = \frac{1}{\bar{N}_j} \sum_{k=1}^N dist(\mathbf{x}(t), \mathbf{x}(k)), \quad \mathbf{x}(t) \in \mathcal{C}_j, j \neq i \quad (6.40)$$

El coeficiente de silueta se define en el rango $-1 < sw_i(t) < 1$ y el valor $sw_i(t) \approx 1$ se obtiene cuando $a_i(t) \approx 0$, lo que indica que el registro está en el centro de un grupo compacto. Cuanto mayor sea el valor del coeficiente de silueta, mejor será la posición del registro en la agrupación. El coeficiente de silueta también se puede utilizar en una etapa de refinamiento, comprobando su valor si el registro está asignado a otro grupo.

El coeficiente de silueta para la partición $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$ se calcula como el valor promedio del coeficiente de silueta para todos los registros y todos los grupos:

$$SW(\mathbb{C}) = \frac{1}{KN} \sum_{i=1}^K \sum_{t=1}^N sw_i(t) \quad (6.41)$$

O índice proposto por Xie e Beni [570] para avaliação de agrupamentos *fuzzy* é uma medida de minimização que avalia a razão entre a variância intragrupos e a menor separação entre os grupos. O índice XB é similar ao PI e é calculado como:

$$XB(\mathbb{C}) = \frac{1}{N} \frac{\sum_{i=1}^K \sum_{t=1}^N u_i(\mathbf{x}(t))^2 \|\mathbf{x}(t) - \boldsymbol{\omega}_i\|^2}{D_{\min}} = \frac{1}{N} \frac{tr(\boldsymbol{\Sigma}_W)}{D_{\min}} \quad (6.42)$$

onde $D_{\min} = \min_{i,j=1,\dots,K, i \neq j} (\|\boldsymbol{\omega}_i - \boldsymbol{\omega}_j\|^2)$.

As medidas relativas são geralmente aplicadas para a avaliação do número de grupos em algoritmos de partição. No caso do algoritmo k-médias e suas variantes, a questão da inicialização aleatória deve ser levada em consideração e uma avaliação estatística em diferentes execuções com o mesmo número de grupos é a abordagem mais indicada para uma avaliação isenta da influência da inicialização.

A Figura 6.13 apresenta *boxplot* dos resultados das medidas de validação aplicadas sobre os resultados de 10 execuções do algoritmo k-médias no conjunto de dados quatro grupos (cf. Figura 6.7). A linha azul representa a média das medidas em todas as simulações para cada valor de K . Neste exemplo, todas as medidas indicam o número de grupos $K = 4$, que é o valor com menor dispersão de resultados.

Os resultados apresentados na Figura 6.13 mostram o desempenho das medidas de avaliação num conjunto de dados com $p = 2$ variáveis e com uma estrutura de grupos muito bem definida (cf. Figura 6.7). Na prática, as medidas de validação podem apresentar resultados conflitantes.

A Figura 6.14 apresenta os resultados de 100 simulações das medidas de validação no conjunto de dados de Diabetes das índias Pima, que tem $p = 8$ variáveis. Nesse caso, as medidas CH e XB apontam uma estrutura com $K = 3$ grupos por apresentar os melhores valores dos índices e a menor dispersão. Os resultados do índice PBM e SW não são conclusivos com relação ao número de grupos, mas o agrupamento com $K = 3$ grupos também gera a menor dispersão dessas medidas.

Observe que o conjunto de dados de Diabetes das índias é um problema de classificação com $m = 2$ classes, mas é desbalanceado com 65% dos registros numa das classes. Este exemplo mostra que nem sempre a estrutura de grupos presente nos dados corresponde às classes do problema.

El índice propuesto por Xie y Beni [570] para evaluar conglomerados *fuzzy* es una medida de minimización que evalúa la relación entre la varianza intragrupo y la separación más pequeña entre grupos. El índice XB es similar al PI y se calcula como:

$$XB(\mathbb{C}) = \frac{1}{N} \frac{\sum_{i=1}^K \sum_{t=1}^N u_i(\mathbf{x}(t))^2 \|\mathbf{x}(t) - \boldsymbol{\omega}_i\|^2}{D_{\min}} = \frac{1}{N} \frac{tr(\boldsymbol{\Sigma}_W)}{D_{\min}} \quad (6.42)$$

donde $D_{\min} = \min_{i,j=1\dots K, i \neq j} (\|\boldsymbol{\omega}_i - \boldsymbol{\omega}_j\|^2)$.

Generalmente se aplican medidas relativas para evaluar el número de grupos en algoritmos de partición. En el caso del algoritmo k-means y sus variantes, se debe tener en cuenta la cuestión de la inicialización aleatoria y una evaluación estadística en diferentes ejecuciones con el mismo número de grupos es el enfoque más adecuado para una evaluación libre de la influencia de la inicialización.

La Figura 6.13 presenta *boxplot* de los resultados de las medidas de validación aplicadas a los resultados de 10 ejecuciones del algoritmo k-means en el conjunto de datos de cuatro grupos (cf. Figura 6.7). La línea azul representa el promedio de las mediciones en todas las simulaciones para cada valor de K . En este ejemplo, todas las mediciones indican el número de grupos $K = 4$, que es el valor con menor dispersión de resultados.

Los resultados presentados en la Figura 6.13 muestran el desempeño de las medidas de evaluación en un conjunto de datos con $p = 2$ variables y una estructura de grupo muy bien definida (ver Figura 6.7). En la práctica, las medidas de validación pueden presentar resultados contradictorios.

La Figura 6.14 presenta los resultados de 100 simulaciones de las mediciones de validación en el conjunto de datos Pima Indian Diabetes, que tiene variables $p = 8$. En este caso las medidas CH y XB indican una estructura con grupos $K = 3$ al presentar los mejores valores de índice y la menor dispersión. Los resultados de los índices PBM y SW no son concluyentes con respecto al número de grupos, pero la agrupación con grupos $K = 3$ también genera la menor dispersión de estas medidas.

Tenga en cuenta que el conjunto de datos de India Diabetes es un problema de clasificación con clases $m = 2$, pero está desequilibrado con el 65 % de los registros en una de las clases. Este ejemplo muestra que la estructura de grupo presente en los datos no siempre corresponde a las clases de problemas.




Figura 6.13: Resultados das medidas de validação: (a) CH; (b) PBM; (c) SW; (d) XB.

Mesmo um algoritmo simples como o k-médias acarreta num alto custo computacional quando executado com diferentes inicializações e para vários valores do parâmetro K , o que limita a análise em problemas de grande dimensionalidade. Entretanto, o algoritmo k-médias pode ser executado em paralelo [58][601] para viabilizar a busca do melhor particionamento utilizando medidas de validação. Modenesi e colaboradores [395]-[397] apresentam uma abordagem que integra a versão *fuzzy* do algoritmo k-médias (cf. Capítulo 8) com o cálculo do índice PBM de avaliação de grupos em processamento paralelo.

Um estudo abrangente sobre medidas relativas de validação de agrupamentos foi apresentado recentemente por Vendramin, Campello e Hruschka [538]. No artigo, os autores analisam e comparam 40 índices de validação em 1.080 conjuntos de dados diferentes. O artigo apresenta a descrição das medidas de validação acompanhada de análises de complexidade assintótica. A análise experimental é feita em duas partes: na




Figura 6.13: Resultados de las medidas de validación: (a) CH; (b) gestión de residuos públicos; (c) S

Incluso un algoritmo simple como k-means implica un alto costo computacional cuando se ejecuta con diferentes inicializaciones y para varios valores del parámetro K , lo que limita el análisis de problemas de grandes dimensiones. Sin embargo, el algoritmo k-means se puede ejecutar en paralelo [58][601] para permitir la búsqueda de la mejor partición utilizando medidas de validación. Modenesi y colaboradores [395]-[397] presentan un enfoque que integra la versión *fuzzy* del algoritmo k-means (cf. Capítulo 8) con el cálculo del índice PBM para evaluar grupos en procesamiento paralelo.

Vendramin, Campello y Hruschka [538] presentaron recientemente un estudio exhaustivo sobre medidas relativas de validación de conglomerados. En el artículo, los autores analizan y comparan 40 índices de validación en 1.080 conjuntos de datos diferentes. El artículo presenta una descripción de las medidas de validación acompañadas de análisis de complejidad asintótica. El análisis experimental se realiza en dos partes: en

primeira, é reproduzido o mesmo procedimento empregado por Milligan e Cooper [388]; na segunda, a análise é estendida com conjuntos de dados maiores, com maior diversidade de número de grupos e de variáveis. Os resultados mostram que os índices CH, PBM e SW são os mais efetivos para encontrar o número de grupos presentes num conjunto de dados.




Figura 6.14: Resultados das medidas de validação: (a) CH; (b) PBM; (c) SW; (d) XB.

A validação de agrupamentos é um assunto recorrente na literatura e diversas medidas são encontradas na literatura [592][599]. Em geral, as medidas são avaliadas em conjuntos de dados sintéticos e de baixa dimensionalidade. A própria característica do problema de análise de agrupamentos dificulta a definição de uma média absoluta para avaliar a melhor solução.

en primer lugar, se reproduce el mismo procedimiento utilizado por Milligan y Cooper [388]; en el segundo, se amplía el análisis con conjuntos de datos más grandes, con mayor diversidad en el número de grupos y variables. Los resultados muestran que los índices CH, PBM y SW son los más efectivos para encontrar el número de grupos presentes en un conjunto de datos.




Figura 6.14: Resultados de las medidas de validación: (a) CH; (b) gestión de residuos públicos; (c) S; (d) XB.

La validación de conglomerados es un tema recurrente en la literatura y en ella se encuentran varias medidas [592][599]. En general, las medidas se evalúan en conjuntos de datos sintéticos de baja dimensión. La propia característica del problema del análisis de conglomerados hace difícil definir un promedio absoluto para evaluar la mejor solución.

6.6 Aplicações

A análise de agrupamentos tem aplicações em diversas áreas. Nesta seção, apresentamos duas aplicações em problemas reais em trabalhos de pesquisa realizados na Copppe/UFRJ [32][468].

6.6.1 Segmentação de imagens de satélite

Segmentação de uma imagem é a partição da imagem em regiões representadas por conjuntos de *pixels*. Essencialmente, a segmentação de imagens é uma aplicação de análise de agrupamentos na qual os registros são os *pixels* e as variáveis são características extraídas destes.

Nesta seção, apresentamos uma aplicação de segmentação de imagens para classificação das zonas inundáveis na Amazônia a partir de imagens de satélite obtidas por radares de abertura sintética (SAR, na sigla em inglês). As imagens SAR são úteis para monitorar florestas tropicais úmidas, pois são imunes à cobertura de nuvens. A interpretação de imagens SAR permite a discriminação de áreas de cobertura vegetal, florestas inundadas e corpos d'água.

Beisl [32] utilizou imagens SAR da região Amazônica registradas pelo satélite JERS-1 e obtidas no projeto de Mapeamento Global de Florestas Tropicais (GRFM, na sigla em inglês) em duas épocas distintas: a época de cheia, captadas em outubro de 1995 (Figura 6.15a), e a época de seca, em maio de 1996 (Figura 6.15b). Uma parte do trabalho foi feita para a determinação do traçado do poliduto Coari-Manaus, da Petrobras.

Beisl realizou o mapeamento das mudanças em toda a extensão da bacia do Solimões em função das variações no ciclo hidrológico do rio. O estudo relacionou os padrões de mudança com as características do ambiente, que haviam sido identificadas em estudos anteriores, para obter um mapa de sensibilidade da região ao derramamento de óleo.

Após o pré-processamento, os *frames* foram combinados para produzir as imagens mostradas na Figura 6.15. A imagem cobre boa parte da bacia do Solimões, com cerca de 600 km de extensão, onde Manaus aparece no alto à direita das imagens. As regiões mais escuras indicam a reflexão total do sinal do radar e indicam corpos d'água. As regiões de cinza mais escuro indicam o espalhamento do sinal pela copa das árvores e indicam regiões de floresta. As regiões de cinza mais claro indicam regiões de dupla

6.6 Aplicaciones

El análisis de conglomerados tiene aplicaciones en varias áreas. En esta sección presentamos dos aplicaciones a problemas reales en trabajos de investigación realizados en Coppe/UFRJ [32][468].

6.6.1 Segmentación de imágenes de satélite

La segmentación de una imagen es la partición de la imagen en regiones representadas por conjuntos de *pixels*. Esencialmente, la segmentación de imágenes es una aplicación de análisis de conglomerados en la que los registros son *pixels* y las variables son características extraídas de ellos.


En esta sección, presentamos una aplicación de segmentación de imágenes para clasificar zonas de inundación en la Amazonía a partir de imágenes satelitales obtenidas por radar de apertura sintética (SAR). Las imágenes SAR son útiles para monitorear los bosques tropicales, ya que son inmunes a la nubosidad. La interpretación de imágenes SAR permite la discriminación de áreas de cobertura vegetal, bosques inundables y cuerpos de agua.

Beisl [32] utilizó imágenes SAR de la región amazónica registradas por el satélite JERS-1 y obtenidas en el proyecto Global Tropical Forest Mapping (GRFM) en dos momentos diferentes: la temporada de inundaciones, capturada en octubre de 1995 (Figura 6.15a), y la estación seca, en mayo de 1996 (Figura 6.15b). Parte de los trabajos se realizaron para determinar el trazado del poliducto Coari-Manaos, de Petrobras.


Beisl cartografió los cambios a lo largo de toda la cuenca del Solimões debido a las variaciones en el ciclo hidrológico del río. El estudio relacionó los patrones de cambio con las características del medio ambiente, que habían sido identificadas en estudios anteriores, para obtener un mapa de la sensibilidad de la región al derrame de petróleo.

Después del preprocesamiento, los *frames* se combinaron para producir las imágenes que se muestran en la Figura 6.15. La imagen cubre gran parte de la cuenca del Solimões, de unos 600 km de longitud, donde Manaus aparece en la parte superior derecha de las imágenes. Las regiones más oscuras indican el reflejo total de la señal del radar e indican masas de agua. Las regiones de color gris más oscuro indican la propagación de la señal a través de la copa de los árboles e indican regiones forestales. Las regiones grises más claras indican regiones de doble

reflexão, em que o sinal reflete na água, mas parte do sinal retorna após refletir novamente em algum obstáculo, como árvores, o que caracteriza floresta inundada.



(a)



(b)


Figura 6.15: Imagens SAR da Amazônia: (a) em época de cheia (outubro de 1995); (b) em época de seca (maio de 1996). Fonte: [32].

Em imagens SAR, o conteúdo é apresentado em um canal e a imagem é representada pelo conjunto de dados $Z = \{z(t) \in \mathcal{R}, t = 1, \dots, N\}$, onde $z(t)$ é o valor do *pixel*. Beisl [32] utilizou uma transformação do conjunto de dados Z pela função de semi vario-grama, que relaciona um *pixel* a seus vizinhos pela relação:


$$x_h(t) = \frac{1}{2n} \sum_{i=1}^n (v_h(t, i) - z(t))^2 \quad (6.43)$$

onde h é um parâmetro que regula a extensão da vizinhança e n , o número de *pixels* de vizinhança e $v_h(t, i) = h(t, i)$ uma função de vizinhança.

Reflexión, en la que la señal se refleja en el agua, pero parte de la señal regresa después de reflejarse nuevamente en un obstáculo, como árboles, lo que caracteriza a un bosque inundado.



(a)



(b)

Figura 6.15: Imágenes SAR del Amazonas: (a) durante la temporada de inundaciones (o octubre de 1995); (b) en una estación seca (mayo de 1996). Fuente: [32].

En las imágenes SAR, el contenido se presenta en un canal y la imagen está representada por el conjunto de datos $Z = \{z(t) \in \mathcal{R}, t = 1, \dots, N\}$, donde $z(t)$ es el valor de *pixel*. Beisl [32] utilizó una transformación del conjunto de datos Z mediante la función de semivariograma, que relaciona un *pixel* con sus vecinos mediante la relación:

$$x_h(t) = \frac{1}{2n} \sum_{i=1}^n (v_h(t, i) - z(t))^2 \quad (6.43)$$

donde h es un parámetro que regula la extensión de vecindad y n , el número de vecindad *pixels* y $v_h(t, i) = h(t, i)$ una función de vecindad.

A função de vizinhança é calculada num círculo de raio h centrado no *pixel* correspondente, como mostra a Figura 6.16 para $h = 6 \text{ pixels}$.




Figura 6.16: Função de vizinhança com $h = 6$.

As imagens foram segmentadas pelo algoritmo textural não supervisionado por semi variograma (USTC),* que utiliza a função semi variograma como um descritor de textura [390][391]. No método USTC, o agrupamento é realizado pelo algoritmo ISODATA [27] aplicado ao conjunto $\mathcal{T} = \{\mathbf{x}(t), t = 1 \dots N\}$, em que o vetor de variáveis tem dimensão $h + 2$ e as componentes são calculados pela função de semi variograma (6.43) como $\mathbf{x}(t) = [z(t), x_1(t), \dots, x_h(t), \sigma_h^2(t)]$, incluindo o valor do pixel central $z(t)$ e $\sigma_h^2(t)$ que é a variância calculada na região da função de vizinhança $h(t, i), i = 1 \dots n$.

O resultado obtido pelo algoritmo ISODATA é classificado por um especialista e os grupos são definidos para representar um significado temático. Beisl [32] utilizou quatro classes: água, vegetação inundada e floresta seca ou inundada. O resultado final é mostrado na Figura 6.17, na qual a região em verde representa floresta seca, a região em azul representa corpos d'água, a região em amarelo representa floresta inundada e a região em azul-claro, vegetação inundada.

Beisl utiliza o resultado da classificação de imagens obtida pelo método USTC para produzir mapas de sensibilidade ao derramamento de óleo [32]. O trabalho utiliza sistemas *fuzzy* para o cálculo do índice e os resultados são apresentados no Capítulo 8.

* *Unsupervised Semivariogram Textural Classifier*.

La función de vecindad se calcula sobre un círculo de radio h centrado en el *pixel* correspondiente, como se muestra en la Figura 6.16 para $h = 6 \text{ pixels}$.





Figura 6.16: Función de vecindad con $h = 6$.

Las imágenes fueron segmentadas mediante el algoritmo textural de semivariograma no supervisado (USTC), * que utiliza la función de semivariograma como descriptor de textura [390][391]. En el método USTC, la agrupación se realiza mediante el algoritmo ISODATA [27] aplicado al conjunto $\mathcal{T} = \{\mathbf{x}(t), t = 1 \dots N\}$, en el cual el vector de variables tiene dimensión $h + 2$ y los componentes se calculan mediante la función semivariograma (6.43) como $\mathbf{x}(t) = [z(t), x_1(t), \dots, x_h(t), \sigma_h^2(t)]$, incluyendo el valor del píxel central $z(t)$ y $\sigma_h^2(t)$ que es la varianza calculada en la región de la función de vecindad $h(t, i), i = 1 \dots n$.


El resultado obtenido por el algoritmo ISODATA es clasificado por un experto y se definen los grupos para representar un significado temático. Beisl [32] utilizó cuatro clases: agua, vegetación inundada y bosque seco o inundado. El resultado final se muestra en la Figura 6.17, en la que la región en verde representa bosque seco, la región en azul representa cuerpos de agua, la región en amarillo representa bosque inundado y la región en azul claro representa vegetación inundada.

Beisl utiliza el resultado de la clasificación de imágenes obtenida por el método de la USTC para producir mapas de sensibilidad a derrames de petróleo [32]. El trabajo utiliza sistemas *fuzzy* para calcular el índice y los resultados se presentan en el Capítulo 8.

* *Unsupervised Semivariogram Textural Classifier*.



(a)




(b)


Figura 6.17: Resultados do USTC: (a) em época de cheia; (b) em época de seca. Fonte: [32].

6.6.2 Agrupamento de documentos

Estima-se que 85% das informações estão armazenadas na forma não estruturada, o que inclui imagens, gravações e, principalmente, texto. A mineração de textos utiliza técnicas de recuperação de informações, processamento de linguagem natural e algoritmos de inteligência computacional para a extração de conhecimento de coleções de documentos. A análise de agrupamentos de uma coleção de documentos permite a determinação dos principais assuntos da coleção e tem diversas aplicações, tendo em vista que a maior parte dos documentos não é categorizada.



(a)



(b)

Figura 6.17: Resultados de la USTC: (a) en temporada de inundaciones; (b) en tiempos de sequía. Fuente: [32].

6.6.2 Agrupación de documentos

Se estima que el 85% de la información se almacena de forma no estructurada, lo que incluye imágenes, grabaciones y, principalmente, texto. La minería de textos utiliza técnicas de recuperación de información, procesamiento del lenguaje natural y algoritmos de inteligencia computacional para extraer conocimiento de colecciones de documentos. El análisis de conglomerados de una colección de documentos permite determinar los principales temas de la colección y tiene varias aplicaciones, considerando que la mayoría de los documentos no están categorizados.

A abordagem mais comum para a mineração de textos é aplicar uma etapa de pré-processamento para transformar a coleção de documentos numa tabela de dados, de forma que os algoritmos de mineração de dados possam ser aplicados [43][178][502]. O pré-processamento básico inclui a retirada de palavras irrelevantes (*stopwords*) e a redução ao termo raiz (*stemming*). Outras etapas mais elaboradas podem incluir o tratamento de polissemia (palavras diferentes utilizadas com o mesmo significado) e de homonímia (palavras iguais com significados diferentes), além da identificação de sintagmas nominais [437] e outras técnicas de processamento de linguagem natural [294].

Após o pré-processamento, cada documento é representado como um vetor em que os componentes representam os termos (palavras após o pré-processamento) presentes na coleção. Essa representação é chamada de modelo de espaço vetorial e é muito utilizada na área de recuperação de informações [43][467]. A coleção de documentos é, assim, transformada no conjunto de treinamento $\mathcal{T} = \{\mathbf{x}(t), t = 1 \dots N\}$, onde N é o número total de documentos e cada documento é representado pelo vetor $\mathbf{x}(t) \in \mathcal{R}^p$, onde p é o número total de termos da coleção.

As coordenadas associadas a cada documento no modelo de espaço vetorial podem ser calculadas pela frequência do termo no documento. Em geral, utiliza-se o valor chamado *tf-idf*, em que a frequência do termo no documento é ponderada pelo logaritmo do inverso da frequência do termo na coleção, o que evita que palavras muito citadas em toda a coleção tenham peso muito alto. Cada coordenada é calculada como:

$$x_i(t) = f_i(t) \log \frac{N}{N_i}, \quad i = 1, \dots, p \quad (6.44)$$

onde $f_i(t)$ é a frequência do termo i no documento t e N_i é o total de ocorrências do termo i em toda a coleção.

A ponderação pelo logaritmo do inverso da frequência reduz a importância de termos que aparecem em muitos documentos da coleção e, portanto, são menos importantes para diferenciar os documentos entre si. Há algumas variantes¹³⁹ ao *tf-idf* que podem apresentar resultados em aplicações específicas [372].

A representação pelo modelo de espaço vetorial gera um conjunto de dados de altíssima dimensionalidade. Dependendo do assunto, uma coleção pode conter milhares de termos, o que pode dificultar o cálculo de similaridade entre documentos. Há algumas abordagens de redução da dimensionalidade, das quais a mais conhecida é o índice de

El enfoque más común para la minería de textos es aplicar un paso de preprocesamiento para transformar la colección de documentos en una tabla de datos para que se puedan aplicar algoritmos de minería de datos [43][178][502]. El preprocesamiento básico incluye eliminar palabras irrelevantes (*stopwords*) y reducirlas al término raíz (*stemming*). Otros pasos más elaborados pueden incluir el tratamiento de la polisemia (diferentes palabras utilizadas con el mismo significado) y la homonimia (mismas palabras con diferentes significados), además de la identificación de frases nominales [437] y otras técnicas de procesamiento del lenguaje natural [294].

Después del preprocesamiento, cada documento se representa como un vector en el que los componentes representan los términos (palabras después del preprocesamiento) presentes en la colección. Esta representación se denomina modelo de espacio vectorial y se utiliza ampliamente en el área de recuperación de información [43][467]. La colección de documentos se transforma así en el conjunto de entrenamiento $\mathcal{T} = \{\mathbf{x}(t), t = 1 \dots N\}$, donde N es el número total de documentos y cada documento está representado por el vector $\mathbf{x}(t) \in \mathcal{R}^p$, donde p es el número total de términos de la colección.

Las coordenadas asociadas con cada documento en el modelo de espacio vectorial se pueden calcular mediante la frecuencia del término en el documento. Por lo general se utiliza el valor denominado *tf-idf*, en el que la frecuencia del término en el documento se pondera por el logaritmo del inverso de la frecuencia del término en la colección, lo que evita que palabras que se citan con frecuencia a lo largo de la colección tengan un peso demasiado alto. Cada coordenada se calcula como:

$$x_i(t) = f_i(t) \log \frac{N}{N_i}, \quad i = 1, \dots, p \quad (6.44)$$

donde $f_i(t)$ es la frecuencia del término i en el documento t y N_i es el número total de apariciones del término i en toda la colección.

La ponderación por el logaritmo de la frecuencia inversa reduce la importancia de los términos que aparecen en muchos documentos de la colección y, por tanto, son menos importantes para diferenciar los documentos entre sí. Existen algunas variantes¹³⁹ a *tf-idf* que pueden presentar resultados en aplicaciones específicas [372].

La representación mediante el modelo de espacio vectorial genera un conjunto de datos de muy alta dimensionalidad. Dependiendo del tema, una colección puede contener miles de términos, lo que puede dificultar el cálculo de la similitud entre documentos. Existen algunos enfoques de reducción de dimensionalidad, el más conocido de los cuales es el índice de

semântica latente (LSI)* [43], cujo cálculo é semelhante à análise de componentes principais (ACP), apresentada na seção 2.4.1.

A aplicação de algoritmos de detecção de comunidades para o agrupamento de coleções de documentos foi estudada por Santos [468][469]. Nesta seção, reproduzimos os resultados obtidos no conjunto de resumos das teses e dissertações do Programa de Engenharia Civil¹⁴⁰ (PEC) da Coppe/UFRJ, publicados entre janeiro de 2004 e dezembro de 2008, totalizando 585 resumos. Após o pré-processamento, a coleção foi representada por um conjunto de 265 termos [468].

A coleção de documentos foi transformada num grafo para a aplicação do algoritmo de maximização da modularidade de Newman e Girvan [413]. A similaridade entre os registros foi utilizada para a definição da matriz de adjacências $\mathbf{A} \in \mathcal{R}^{N \times N}$, cujos elementos foram calculados como:

$$a_{ij} = \begin{cases} 1, & \text{se } i \neq j \text{ e } \text{sim}(\mathbf{x}(i), \mathbf{x}(j)) > \varepsilon \\ 0, & \text{caso contrário} \end{cases} \quad (6.45)$$

onde a função de similaridade $\text{sim}(\mathbf{x}(i), \mathbf{x}(j))$ é calculada pelo cosseno (cf. equação (2.13)) e $\varepsilon \in [0,1]$ é um parâmetro que determina um limite de similaridade para dois registros serem considerados próximos.

Cada valor do parâmetro ε na equação (6.45) define um grafo diferente que resulta num número diferente de comunidades [413]. A Tabela 6.2 mostra os resultados de modularidade (Q) e número de grupos (K) para diversos valores de ε na definição do grafo [468]. O resultado com $\varepsilon = 0.20$ foi escolhido porque o número de grupos gerados é coerente com a estrutura de áreas de pesquisa do PEC. O algoritmo foi aprimorado por uma etapa de refinamento que, a cada nova divisão, verifica se o resultado da modularidade pode ser melhorado alterando-se a alocação de cada documento a outro grupo [541]. Com essa etapa de refinamento, Santos encontrou sete grupos com $\varepsilon = 0.20$ com modularidade $Q = 0.5334$ [468].

O resultado do agrupamento é mostrado na Figura 6.18, gerada com o *software* livre Cytoscape.¹⁴¹ A Figura 6.18 foi gerada de forma que os vértices similares do grafo fiquem mais próximos, representando a coesão dos grupos.

* *Latent Semantic Index.*

semántica latente (LSI)* [43], cuyo cálculo es similar al análisis de componentes principales (PCA), presentado en la sección 2.4.1.

Santos [468][469] estudió la aplicación de algoritmos de detección de comunidades para agrupar colecciones de documentos. En esta sección reproducimos los resultados obtenidos en el conjunto de resúmenes de tesis y disertaciones del Programa de Ingeniería Civil¹⁴⁰ (PEC) de la Coppe/UFRJ, publicados entre enero de 2004 y diciembre de 2008, totalizando 585 resúmenes. Después del preprocesamiento, la colección quedó representada por un conjunto de 265 términos [468].

La colección de documentos se transformó en un gráfico para aplicar el algoritmo de maximización de modularidad de Newman y Girvan [413]. La similitud entre los registros se utilizó para definir la matriz de adyacencia $\mathbf{A} \in \mathcal{R}^{N \times N}$, cuyos elementos se calcularon como:

$$a_{ij} = \begin{cases} 1, & \text{se } i \neq j \text{ e } \text{sim}(\mathbf{x}(i), \mathbf{x}(j)) > \varepsilon \\ 0, & \text{caso contrário} \end{cases} \quad (6.45)$$

donde la función de similitud $\text{sim}(\mathbf{x}(i), \mathbf{x}(j))$ se calcula mediante el coseno (cf. ecuación (2.13)) y $\varepsilon \in [0,1]$ es un parámetro que determina un umbral de similitud para que dos registros se consideren cercanos.

Cada valor del parámetro ε en la ecuación (6.45) define una gráfica diferente que da como resultado un número diferente de comunidades [413]. La Tabla 6.2 muestra los resultados de modularidad (Q) y número de grupos (K) para diferentes valores de ε en la definición del gráfico [468]. Se eligió el resultado con $\varepsilon = 0.20$ porque el número de grupos generados es coherente con la estructura de las áreas de investigación del PEC. El algoritmo se mejoró mediante un paso de refinamiento que, con cada nueva división, verifica si el resultado de modularidad se puede mejorar cambiando la asignación de cada documento a otro grupo [541]. Con este paso de refinamiento, Santos encontró siete grupos con $\varepsilon = 0.20$ con modularidad $Q = 0.5334$ [468].

El resultado de la agrupación se muestra en la Figura 6.18, generada con el Cytoscape gratuito *software*.¹⁴¹ La figura 6.18 se generó de modo que los vértices similares del gráfico estén más cerca entre sí, lo que representa la cohesión de los grupos.

* *Latent Semantic Index.*

Tabela 6.2: Modularidade para vários valores de ε . Fonte: [468]

ε	Q	K
0.10	0.3232	4
0.15	0.4236	5
0.20	0.4998	6
0.25	0.5468	9
0.30	0.6588	12
0.35	0.7167	13




Figura 6.18: Rede de documentos resultante da análise de agrupamentos. Fonte: [468][469].

Uma interpretação do resultado do agrupamento pode ser obtida observando-se os termos mais importantes em cada grupo. A seleção de termos é um caso particular do problema de seleção de variáveis [350][351]. Santos [468] utilizou uma abordagem simples, na qual a relevância de cada termo para cada grupo C_i é calculada como:

$$rel(i, j) = \sum_{t=1}^N x_j(t) u_i(\mathbf{x}(t)) \quad (6.46)$$

Tabla 6.2: Modularidad para varios valores de ε . Fuente: [468]

ε	Q	K
0.10	0.3232	4
0.15	0.4236	5
0.20	0.4998	6
0.25	0.5468	9
0.30	0.6588	12
0.35	0.7167	13




Figura 6.18: Red de documentos resultante del análisis de conglomerados. Fuente: [468][469].

Se puede obtener una interpretación del resultado de la agrupación observando los términos más importantes de cada grupo. La selección de términos es un caso particular del problema de selección de variables [350][351]. Santos [468] utilizó un enfoque simple, en el que la relevancia de cada término para cada grupo $\mathcal{C}_i$ se calcula como:

$$rel(i, j) = \sum_{t=1}^N x_j(t) u_i(\mathbf{x}(t)) \quad (6.46)$$

onde $u_i(\mathbf{x}(t))$ é a função de pertinência do documento t ao grupo $\mathcal{C}_i$.

Os 10 termos de maior relevância para cada grupo segundo o índice (6.46) são mostrados na Tabela 6.3 [468], na qual os grupos foram interpretados em relação às áreas de pesquisa do PEC. Observa-se que o agrupamento recuperou os assuntos das principais áreas de pesquisa do Programa. A área de Petróleo e Gás foi dividida em dois agrupamentos, que representam as duas linhas de pesquisa mais importantes da área: Geoquímica e Geofísica.

Tabela 6.3: Palavras de cada grupo. Fonte: [468]

Grupo	Termos Relevantes	Área de Pesquisa
$\mathcal{C}_1$	elemento, <i>riser</i> , estaca, linha, estrutura, finito, duto, acoplamento, método, contorno	Mecânica Computacional
$\mathcal{C}_2$	concreto, fibra, reforço, viga, agregado, misto, pavimento, resistência, armado, liga	Estrutura e Materiais
$\mathcal{C}_3$	aterro, resíduo, solo, ensaio, contaminar, sólido, geotecnia, rejeitar, argila, liga	Geotecnia / Meio Ambiente
$\mathcal{C}_4$	óleo, geoquímica, migrar, biomarcador, hidrocarboneto, maturar, biodegradável, bacia, amostra, sísmica	Petróleo e Gás (Geoquímica)
$\mathcal{C}_5$	classificação, redes, virtual, texto, dados, <i>fuzzy</i> , mineração, algoritmo, regra, agrupamento	Sistemas Computacionais
$\mathcal{C}_6$	reservatório, poço, fluxo, simulação, petróleo, fluido, produção, estimativa, otimização, rocha	Petróleo e Gás (Geofísica)
$\mathcal{C}_7$	bacia, hídrico, água, recursos, regra, gestão, cobrança, urbano, modelo, cheia	Recursos Hídricos / Meio Ambiente

6.7 Comentários Finais

O problema de análise de agrupamentos é extenso e alguns livros tratam exclusivamente do assunto [194][573]. O problema é mal definido, o que dificulta a formulação de estatísticas de validação. Há diversas abordagens distintas, sendo muito difícil uma cobertura completa do assunto.

Os tópicos incluídos neste capítulo foram escolhidos para servir como introdução ao tema e aos assuntos que serão tratados nos próximos capítulos. O algoritmo k-médias e os algoritmos hierárquicos aglomerativos apresentados, respectivamente, nas seções

donde $u_i(\mathbf{x}(t))$ es la función de pertenencia del documento t al grupo $\mathcal{C}_i$.

Los 10 términos más relevantes para cada grupo según el índice (6.46) se muestran en la Tabla 6.3 [468], en la que los grupos fueron interpretados en relación con las áreas de investigación del PEC. Se observa que la agrupación recuperó temas de las principales áreas de investigación del Programa. El área de Petróleo y Gas se dividió en dos grupos, que representan las dos líneas de investigación más importantes del área: Geoquímica y Geofísica.

Tabla 6.3: Palabras de cada grupo. Fuente: [468]

Grupo	Termos Relevantes	Área de Pesquisa
$\mathcal{C}_1$	elemento, <i>riser</i> , estaca, linha, estrutura, finito, duto, acoplamento, método, contorno	Mecânica Computacional
$\mathcal{C}_2$	concreto, fibra, reforço, viga, agregado, misto, pavimento, resistência, armado, liga	Estrutura e Materiais
$\mathcal{C}_3$	aterro, resíduo, solo, ensaio, contaminar, sólido, geotecnia, rejeitar, argila, liga	Geotecnia / Meio Ambiente
$\mathcal{C}_4$	óleo, geoquímica, migrar, biomarcador, hidrocarboneto, madurar, biodegradável, bacia, amostra, sísmica	Petróleo e Gás (Geoquímica)
$\mathcal{C}_5$	classificação, redes, virtual, texto, dados, <i>fuzzy</i> , mineração, algoritmo, regra, agrupamento	Sistemas Computacionais
$\mathcal{C}_6$	reservatório, poço, fluxo, simulação, petróleo, fluido, produção, estimativa, otimização, rocha	Petróleo e Gás (Geofísica)
$\mathcal{C}_7$	bacia, hídrico, água, recursos, regra, gestão, cobrança, urbano, modelo, cheia	Recursos Hídricos / Meio Ambiente

6.7 Comentarios finales

El problema del análisis de conglomerados es extenso y algunos libros tratan exclusivamente del tema [194][573]. El problema está mal definido, lo que dificulta la formulación de estas dísticas de validación. Hay varios enfoques diferentes, lo que hace muy difícil cubrir completamente el tema.

Los temas incluidos en este capítulo fueron elegidos para que sirvieran como introducción al tema y a los temas que se cubrirán en los siguientes capítulos. El algoritmo k-means y los algoritmos de aglomeración jerárquica presentados, respectivamente, en secciones

6.2 e 6.3, são as abordagens clássicas, presentes em praticamente todos os *softwares* e bibliotecas. Os algoritmos baseados em grafos, apresentados na seção 6.4, têm sido utilizados em aplicações de mineração de textos e processamento de imagens.

A avaliação de agrupamentos depende muito do contexto e, quando disponível, a avaliação de grupos como classes deve ser feita com cuidado, pois nem sempre os dois conceitos são equivalentes. A relação entre classes e grupos fez surgir métodos chamados de classificação semi supervisionada [8][269][605], em que o conhecimento da classe de alguns registros é utilizado para guiar o algoritmo de agrupamento. Esses métodos têm aplicações em mineração de textos e bioinformática, onde um pequeno número de registros anotados é utilizado para a classificação de um conjunto maior não anotado.

As aplicações de mineração de textos e bioinformática trouxeram novos desafios para os algoritmos de análise de agrupamentos, principalmente devido ao problema da dimensionalidade. Nesse tipo de aplicação, os registros são descritos por vetores de grande dimensão, o que dificulta a análise de similaridade entre os registros, fundamental para o agrupamento. No estudo de caso apresentado na seção 6.6.2, a função cosseno é utilizada como métrica de similaridade e um algoritmo de detecção de comunidades em redes complexas realiza o agrupamento dos documentos. A combinação de técnicas de mineração de dados e de textos com análise de redes complexas também tem sido aplicada para a análise de redes sociais [4][376].

Este capítulo representa a transição entre os métodos clássicos e os métodos mais avançados, que serão apresentados nos próximos capítulos.

6.2 y 6.3 son los enfoques clásicos, presentes en prácticamente todas las *softwares* y librerías. Los algoritmos basados en gráficos, presentados en la sección 6.4, se han utilizado en aplicaciones de procesamiento de imágenes y minería de texto.

La evaluación de agrupaciones depende en gran medida del contexto y, cuando esté disponible, la evaluación de grupos como clases debe hacerse con cuidado, ya que los dos conceptos no siempre son equivalentes. La relación entre clases y grupos dio lugar a métodos llamados clasificación semi-supervisada [8][269][605], en los que se utiliza el conocimiento de la clase de algunos registros para guiar el algoritmo de agrupación. Estos métodos tienen aplicaciones en minería de textos y bioinformática, donde se utiliza una pequeña cantidad de registros anotados para clasificar un conjunto más grande sin anotaciones.

Las aplicaciones de minería de textos y bioinformática han traído nuevos desafíos a los algoritmos de análisis de conglomerados, principalmente debido al problema de la dimensionalidad. En este tipo de aplicaciones, los registros se describen mediante vectores grandes, lo que dificulta el análisis de similitud entre registros, fundamental para la agrupación. En el estudio de caso presentado en la sección 6.6.2, la función coseno se utiliza como métrica de similitud y un algoritmo de detección de comunidad en redes complejas realiza la agrupación de documentos. La combinación de técnicas de minería de datos y textos con análisis de redes complejas también se ha aplicado al análisis de redes sociales [4][376].

Este capítulo representa la transición entre los métodos clásicos y los métodos más avanzados, que se presentarán en los próximos capítulos.