

6 ANÁLISIS DE CLÚSTER

El objetivo del análisis de conglomerados es dividir el conjunto de datos en subconjuntos llamados grupos. El análisis de conglomerados es un problema de aprendizaje no supervisado y a menudo se denomina clasificación no supervisada, ya que no existe una variable de salida (o variable objetivo) para predecir como en la regresión o la clasificación, que son problemas de aprendizaje supervisados. La falta de supervisión dificulta definir una función para evaluar la calidad del resultado. Por tanto, el análisis de conglomerados es esencialmente una actividad descriptiva, en la que el papel del analista es preponderante para la calidad del resultado.

Las aplicaciones del análisis de conglomerados son bastante variadas. En el ámbito empresarial, la segmentación de la base de clientes es muy común en las grandes corporaciones [530]. También existen aplicaciones en prácticamente todas las áreas con uso intensivo de datos, como por ejemplo, bioinformática [290][357], procesamiento de imágenes [528], recuperación de información [319], entre otras [284].

El análisis de clusters ha sido estudiado en diferentes comunidades científicas y la literatura sobre algoritmos de clustering es muy diversa. Hay trabajos clásicos en estadística [146][194][238][521], inteligencia computacional [572][573] y ciencia de datos [232][516]. En este capítulo, presentamos los algoritmos clásicos, que se pueden encontrar en la mayoría de los enfoques *softwares* y más recientes basados en la teoría de grafos.

6.1 El problema del análisis de conglomerados

Un grupo es un conjunto de objetos con alguna característica común que los identifica como elementos del grupo. El objetivo del análisis de conglomerados es identificar patrones que permitan separar un conjunto de datos en grupos. Los algoritmos de agrupamiento encuentran grupos o subconjuntos de datos de muestra con características similares. Muchas veces el problema pasa por el análisis y la interpretación de los grupos encontrados.

Matemáticamente, un grupo es un conjunto definido por una propiedad característica compartida por sus elementos. Así, dado un universo $\mathcal{X}$, los elementos del conjunto $\mathcal{A} \subseteq \mathcal{X}$ están definidos por la propiedad $\chi_{\mathcal{A}}(x)$, que, para cada elemento del universo $x \in \mathcal{X}$:

$$\chi_{\mathcal{A}}(x) = \begin{cases} 1, & \text{se } x \in \mathcal{A} \\ 0, & \text{se } x \notin \mathcal{A} \end{cases} \quad (6.1)$$

La ecuación (6.1) es la base del llamado axioma de separación [77], que establece las dos leyes (o axiomas) fundamentales de la teoría de conjuntos:

- a) la ley del tercero excluido: $\mathcal{A} \cup \bar{\mathcal{A}} = \mathcal{X}$; b)
- la ley de la no contradicción: $\mathcal{A} \cap \bar{\mathcal{A}} = \emptyset$.

La noción de conjunto se extiende al concepto de partición, particularmente útil en ciencia de datos, en el que el universo se subdivide en K subconjuntos disjuntos.

En el análisis de conglomerados, la partición del conjunto de datos (de entrenamiento) $\mathcal{T}$ en subconjuntos K se define como $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$ de modo que se cumplan las siguientes condiciones:

- i. La unión de todos los subconjuntos es el universo: $\bigcup_{i=1}^K \mathcal{C}_i = \mathcal{T}$; ii. Los subconjuntos no tienen elementos en común: $\mathcal{C}_i \cap \mathcal{C}_j = \emptyset$, $i \neq j$.

Descubrir una partición en un conjunto de datos es computacionalmente complejo; la partición de un conjunto de datos con registros N en solo dos subconjuntos, con registros N_1 y N_2 respectivamente, implica la evaluación de particiones distintas $N!/(N_1!N_2!)$. Por ejemplo, un conjunto de datos de registros $N = 100$ se puede dividir en dos subconjuntos de registros $N_1 = N_2 = 50$ de diferentes maneras. Además de la complejidad inherente al problema, la calidad de la agrupación no está bien definida y, en general, se utilizan índices de validación (cf. apartado 6.5).

En el análisis de conglomerados, un grupo se define como un conjunto de registros que son similares entre sí y diferentes de los registros asignados a otros grupos. Elegir la mejor agrupación en un conjunto de datos es una tarea analítica que depende en gran medida de la interpretación de los grupos en el contexto de la aplicación. El conjunto de datos de la Figura 6.1a se puede dividir en dos grupos, como se muestra en la Figura 6.1b, pero también en cuatro o seis grupos, como en las Figuras 6.1c y d [516]. Decidir cuál es la mejor solución dependerá en gran medida de la aplicación.




Figura 6.1: Diferentes agrupaciones en el mismo conjunto de datos: (a) conjunto de datos; (b) dos grupos; c) cuatro grupos; d) seis grupos. Fuente: [516].

Al observar la Figura 6.1, notamos que los grupos de la Figura 6.1d están contenidos en la Figura 6.1c, que, a su vez, están contenidos en la partición de la Figura 6.1b. Por tanto, una solución a la dificultad de evaluar la calidad del clustering es realizarlo de forma jerárquica, como en los algoritmos presentados en la sección 6.3.

Otra característica importante del análisis de conglomerados es que los grupos encontrados pueden no corresponder a las clases de un problema supervisado. Esto no significa que el algoritmo de agrupamiento haya fallado, sólo que los patrones encontrados no corresponden a las clases. Esto sucede porque los algoritmos de agrupación utilizan información de los registros y la clasificación suele ser información externa a los registros. Por lo tanto, debe utilizarse con cautela entender el análisis de conglomerados como “clasificación no supervisada”.

La figura 6.2a muestra un conjunto de datos que contiene claramente cuatro grupos, aunque este mismo conjunto se presentó como un problema de dos clases en el ejemplo de la figura 5.6.




Figura 6.2: Ejemplo de agrupación: (a) conjunto de datos; (b) datos clasificados.

Los algoritmos presentados en este capítulo utilizan métricas de distancia, como las definidas en la sección 2.2.3, para variables numéricas. Hay varios otros, además de métricas para variables binarias y categóricas [194]. La elección de métricas de distancia o similitud puede hacer que el problema sea aún más complejo, ya que no existe un criterio universal que oriente dicha elección [232]. El enfoque más simple para tratar las variables nominales es su transformación en variables indicadoras (cf. ecuación (5.14)) y el uso de métricas definidas para las variables numéricas.

El algoritmo clásico en el análisis de conglomerados es el algoritmo k-medias, en el que los grupos se definen en función de la distancia de cada elemento al centro del grupo. El k-means es un algoritmo de métodos de partición. En este tipo de método, la métrica de distancia determina la forma del grupo. La Figura 6.3 muestra un conjunto de puntos y regiones métricas alejadas del centro, donde las regiones oscuras representan valores más pequeños. La distancia euclidiana (norma L^2), mostrada en la Figura 6.3b, genera grupos de forma esférica; la distancia de Mahalanobis induce grupos elipsoides (Figura 6.3c); Las distancias de Manhattan (norma L^1) y la norma infinita (L^∞) generan hipercubos (Figura 6.3a y d). Por tanto, la elección de la función de distancia o similitud influye en el resultado del algoritmo de agrupamiento.




Figura 6.3: Métricas de distancia: (a) distancia desde Manhattan (L^1); (b) distancia euclidiana (L^2); (c) distancia de Mahalanobis; (d) norma infinita (L^∞).

La intersección entre dos grupos calculada en el análisis de conglomerados también forma una superficie de decisión, como en el problema de clasificación. Un conjunto de datos puede contener grupos que formen superficies de decisión convexas o no convexas, como se ilustra en la figura 6.4. En grupos convexas, como el de la figura 6.4a, las superficies de decisión se pueden aproximar mediante funciones lineales. En conglomerados no convexas, como en la figura 6.4b, la superficie de decisión es una función no lineal.

Los algoritmos más simples, como los métodos de partición presentados en la sección 6.2, generan clústeres convexas. Los algoritmos capaces de generar grupos no convexas pueden representar mejor las características del conjunto de datos. Los métodos jerárquicos, presentados en la sección 6.3, y los métodos basados en gráficos, descritos en la sección 6.4, encuentran grupos no convexas.




Figura 6.4: Forma de los grupos: (a) convexo; (b) no convexo.

6.2 Métodos de partición

Los métodos de partición buscan directamente una partición del conjunto de datos minimizando un criterio de evaluación. El método de partición (y agrupación) más utilizado es el algoritmo k-means, en el que el criterio de coste se calcula en función del cuadrado de la distancia entre los registros y las coordenadas de los centros, como se describe a continuación.

6.2.1 algoritmo k-medias

El algoritmo k-means es un algoritmo simple y eficiente que generalmente converge en un pequeño número de iteraciones en la mayoría de los problemas. El algoritmo original se propuso hace más de 50 años* [285], pero continúa utilizándose en varias áreas y se puede encontrar en las principales bibliotecas y *softwares*.

El objetivo del algoritmo k-means es encontrar una partición en el conjunto de datos en K grupos $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$ minimizando la siguiente función de evaluación:

$$J(\Omega) = \sum_{t=1}^N \sum_{i=1}^K u_i(\mathbf{x}(t)) \|\mathbf{x}(t) - \boldsymbol{\omega}_i\|^2 \quad (6.2)$$

* O algoritmo é atribuído ao trabalho proposto por Lloyd em 1957 para representação digital de sinais analógicos, que só foi publicado em 1982 [353]. Entretanto, é muito difícil reconhecê-lo nesse artigo. O algoritmo na sua forma atual foi proposto por MacQueen em 1967 [359].

donde $\boldsymbol{\omega}_i = \frac{1}{\hat{N}_i} \sum_{\mathbf{x}(t) \in \mathcal{C}_i} \mathbf{x}(t)$ es el vector con las coordenadas del centro del grupo $\mathcal{C}_i$ y la matriz $\boldsymbol{\Omega} = [\boldsymbol{\omega}_1, \dots, \boldsymbol{\omega}_K]$ representa los centros de todos los grupos.

La función $u_i(\mathbf{x}(t))$ en la ecuación (6.2) define la pertenencia de un registro $\mathbf{x}(t)$ al grupo $\mathcal{C}_i$ (cf. ecuación (6.1)) como:

$$u_i(\mathbf{x}(t)) = \begin{cases} 1, & \text{se } \mathbf{x}(t) \in \mathcal{C}_i \\ 0, & \text{se } \mathbf{x}(t) \notin \mathcal{C}_i \end{cases} \quad (6.3)$$

La cardinalidad del grupo $\mathcal{C}_i$ es la cantidad de registros en el grupo, es decir, $|\mathcal{C}_i| = \hat{N}_i$, se puede calcular sumando los valores de membresía del grupo como $\hat{N}_i = \sum_{t=1}^N u_i(\mathbf{x}(t))$.

La función de evaluación (6.2) se puede interpretar descomponiendo la varianza total de los datos como $\boldsymbol{\Sigma}_T = \boldsymbol{\Sigma}_W + \boldsymbol{\Sigma}_B$ [146][573], presentado en la sección 2.4.3.

La matriz de varianza total $\boldsymbol{\Sigma}_T = (N - 1)\hat{\boldsymbol{\Sigma}}$ donde $\hat{\boldsymbol{\Sigma}}$ es la matriz de covarianza estimada (cf. ecuación (2.5)), se calcula como:

$$\boldsymbol{\Sigma}_T = \sum_{t=1}^N (\mathbf{x}(t) - \bar{\mathbf{x}})^T (\mathbf{x}(t) - \bar{\mathbf{x}}) \quad (6.4)$$

donde $\bar{\mathbf{x}} = \frac{1}{N} \sum_{t=1}^N \mathbf{x}(t)$ es el promedio de los registros del conjunto de entrenamiento, que también se puede calcular mediante el promedio ponderado de los centros del grupo como $\bar{\mathbf{x}} = \frac{1}{N} \sum_{i=1}^K \hat{N}_i \boldsymbol{\omega}_i$.

La matriz de varianza intragrupo $\boldsymbol{\Sigma}_W$ y la matriz de varianza intergrupo $\boldsymbol{\Sigma}_B$ se calculan como (ver sección 2.4.3):

$$\boldsymbol{\Sigma}_B = \sum_{i=1}^K N_i (\boldsymbol{\omega}_i - \bar{\mathbf{x}})^T (\boldsymbol{\omega}_i - \bar{\mathbf{x}}) \quad (6.5)$$

$$\boldsymbol{\Sigma}_W = \sum_{t=1}^N \sum_{i=1}^K u_i(\mathbf{x}(t)) (\mathbf{x}(t) - \boldsymbol{\omega}_i)^T (\mathbf{x}(t) - \boldsymbol{\omega}_i) \quad (6.6)$$

La función de evaluación (6.2) es la suma de los elementos de la diagonal principal (guión) de la matriz de varianza intragrupo $\boldsymbol{\Sigma}_W$, cuya minimización da como resultado la minimización de la varianza intragrupo $\boldsymbol{\Sigma}_W$ y, por tanto, en grupos más compactos. La varianza total $\boldsymbol{\Sigma}_T$ no es función de la agrupación y permanece constante, de modo que minimizar la varianza intragrupo implica maximizar la varianza entre grupos $\boldsymbol{\Sigma}_B$, es decir, en grupos más separados.

La minimización de la función (6.2) es un problema NP-difícil [12][360]. El algoritmo k-means aplica una heurística codiciosa para resolver el problema de manera eficiente. Sin embargo, el resultado depende en gran medida de la estructura de datos y se puede encontrar una solución óptima local, lo que hace que el resultado dependa de la inicialización.

El algoritmo k-medias se describe en el Algoritmo 6.1. Se ejecuta utilizando una matriz de centros proporcionada en la inicialización, que generalmente es aleatoria. En cada iteración, cada registro del conjunto de datos se asigna al grupo más cercano. Aunque se pueden utilizar otras métricas de distancia según la implementación, el algoritmo clásico de k-medias utiliza la distancia euclidiana. Después de recorrer todo el conjunto de datos, el centro de cada grupo se actualiza como el promedio de las coordenadas de los registros asignados al grupo.

Algoritmo 6.1: Algoritmo K-Means

Entrada:	Conjunto de treinamento $\mathcal{T} = \{\mathbf{x}(t), t = 1 \dots N\}$, estimativa inicial de centros $\mathbf{\Omega} = [\boldsymbol{\omega}_1^T, \dots, \boldsymbol{\omega}_K^T]$
Saída:	Matriz de centros $\mathbf{\Omega} = [\boldsymbol{\omega}_1^T, \dots, \boldsymbol{\omega}_K^T]$
01	Início
02	$\varepsilon \leftarrow \infty$
03	Enquanto $\varepsilon > tol$
04	Para $t = 1, \dots, N$
05	$\mathbf{x}(t) \in \mathcal{C}_i \Leftrightarrow \boldsymbol{\omega}_i = \underset{j}{\operatorname{argmin}} \left(\ \mathbf{x}(t) - \boldsymbol{\omega}_j\ ^2 \right)$
06	Fim Para
07	$\mathbf{\Omega}_0 \leftarrow \mathbf{\Omega}$
08	Atualizar $\mathbf{\Omega}$ com $\boldsymbol{\omega}_i = \frac{\sum_{t=1}^N u_i(\mathbf{x}(t))\mathbf{x}(t)}{\sum_{t=1}^N u_i(\mathbf{x}(t))}, i = 1, \dots, K$
09	Calcular critério de parada $\varepsilon = \ \mathbf{\Omega}_0 - \mathbf{\Omega}\ $
10	Fim Enquanto
11	Retorna $\mathbf{\Omega} = [\boldsymbol{\omega}_1^T, \dots, \boldsymbol{\omega}_K^T]$
12	Fim

El criterio de parada del algoritmo, calculado en el paso 09, es la norma L^2 de la diferencia entre las matrices centrales calculadas en dos iteraciones sucesivas. El algoritmo es

interrumpido si no se producen cambios significativos en los centros. El número máximo de iteraciones también se puede utilizar como criterio de parada.

En cada iteración, se debe encontrar una partición del conjunto de datos, de modo que si algún grupo no tiene ningún registro asignado en el paso 05, se debe tomar una acción para evitar el error de división por cero en el paso 08. Dependiendo de *software*, se pueden realizar diferentes acciones. En Matlab, ¹³⁶ por ejemplo, el usuario puede elegir entre un mensaje de error (*default*), eliminar el grupo o generar nuevas coordenadas de forma aleatoria. La posibilidad de redefinir centros aleatoriamente provoca inestabilidades en el algoritmo.

En general, el algoritmo k-means converge rápidamente y la complejidad de cada iteración del algoritmo se estima en $O(NKp)$, donde p es el número de variables, K el número de grupos y N el número de registros. En problemas donde $Kp \ll N$, la complejidad del algoritmo está dominada por $O(N)$. En problemas grandes, la búsqueda de un cluster con muchos grupos da como resultado $Kp \approx N$ y la complejidad del algoritmo es $O(N^2)$. En la asignación de memoria, la complejidad del algoritmo se define almacenando el conjunto de datos como $O(Np) \approx O(N)$.

Existen varias variantes del algoritmo k-medias [194][229][285][573]. El algoritmo ISO-DATA,* propuesto en 1967 [27], es una variante de k-means que a menudo se confunde consigo mismo. El algoritmo ISODATA ajusta automáticamente el número de grupos, agrupándolos y subdividiéndolos según límites especificados, y elimina aquellos con pocos registros. En el algoritmo ISODATA, la elección del número de grupos se reemplaza por la elección de los parámetros del algoritmo.

El resultado del algoritmo k-means es muy sensible a la presencia de *outliers* y ruido en el conjunto de datos. Un *outlier* se asociará con algún grupo y se contará en el cálculo del promedio, lo que puede desviar los centros calculados de los centros del conjunto de registros más denso. Algunas variantes de k-means apuntan a una mayor robustez para *outliers*, como los algoritmos k-medoids [300], PAM† y CLARA.‡ En este tipo de algoritmo, el centro del grupo es un registro del conjunto de entrenamiento, llamado *medoid*, que tiene la distancia promedio más pequeña a todos los registros del grupo. Los algoritmos PAM y CLARA aplican la misma idea que k-medoids, pero el segundo solo utiliza una muestra del conjunto de datos.

* *Iterative Self-Organizing Data Analysis Technique*

† *Partition Around Medoids*

‡ *Clustering LARge Applications*

para reducir la complejidad computacional [521]. El algoritmo CLARANS* [416] es una variante de *k-medoids* que es más complejo que CLARA y obtiene mejores resultados [521]. Otro enfoque para resolver el problema *outliers* se obtiene mediante algoritmos llamados *k-medianas* [83][378], cuyos centros de grupo son también registros del conjunto de entrenamiento.

Hay trabajos más recientes con otras variantes de *k-medias*. En el algoritmo *x-means* [434], el número de grupos se optimiza en función de los criterios AIC y BIC, utilizados para seleccionar la estructura de los modelos de regresión [238]. El algoritmo *k-means esférico*¹³⁷ [126][602] utiliza la similitud del coseno como métrica y se recomienda para problemas de alta dimensión. Zhao y Karypis [600] analizan algunas alternativas a la función de evaluación cuadrática para la agrupación de documentos. Se han propuesto algunos enfoques para inicializar *k-means*, como PCA-Part [508], CCIA [302] y el algoritmo *k-means ++* [21][421].

El algoritmo *c-means fuzzy* es una variante importante del *k-means*, en el que el concepto de pertenencia al grupo se amplía mediante funciones de pertenencia *fuzzy*. El algoritmo *c-means fuzzy* se presentará en el Capítulo 8.

k-means es un algoritmo simple y eficiente, pero tiene algunas características y limitaciones, que se analizan en los siguientes ejemplos.

6.2.2 Ejemplos

La forma de los grupos encontrados por el algoritmo *k-means* depende de la métrica de distancia utilizada (ver Figura 6.3). Con la distancia euclidiana, los grupos encontrados por *k-medias* tienen una forma hipersférica, de modo que la superficie de decisión entre grupos se aproxima mediante una función lineal. De esta forma, las regiones asociadas a los grupos forman un diagrama de Voronoi¹³⁸ en el espacio de variables de entrada. La Figura 6.5 presenta los resultados del algoritmo *k-means* sobre datos de diabetes de los indios Pima, diseñado según el plan definido por la ACP. Podemos observar claramente superficies de decisión lineales entre grupos.

* *Clustering LARge Applications based on RANdomized Search*

El algoritmo k-means tiene algunas limitaciones, como encontrar grupos de tamaños muy diferentes [516] y grupos de forma no convexa. Sin embargo, es posible utilizar el algoritmo para encontrar un mayor número de grupos y, posteriormente, agregar grupos para obtener formas no convexas.




Figura 6.5: Resultados del conjunto de datos de Diabetes diseñado en 2D por ACP:

(a) grupos $K = 3$; (b) $K = 7$ grupos.

La Figura 6.6 muestra los resultados de k-medias en el conjunto de datos de dos lunas. En la Figura 6.6a, el resultado del algoritmo con $K = 2$ muestra que no fue posible identificar los dos grupos. El resultado con grupos $K = 6$ se muestra en la Figura 6.6b, lo que nos permite verificar que es posible encontrar los grupos agregando subgrupos. Esta solución se aplica en el desarrollo de modelos de base radial, presentados en el Capítulo 7.




Figura 6.6: Resultados del conjunto de datos de dos lunas: (a) grupos $K = 2$; (b) $K = 6$ grupos.

La principal limitación del algoritmo k-means es la dependencia de la estimación inicial de los centros de grupo, lo que ocurre principalmente en problemas en los que el número de grupos no se corresponde con la estructura de datos. La figura 6.7 muestra los resultados superpuestos de los centros de grupo calculados en 100 ejecuciones del algoritmo k-means sobre los datos del problema de cuatro grupos. Con grupos $K = 2$, la Figura 6.7a muestra que el algoritmo divide los datos horizontal o verticalmente. Con $K = 3$ o $K = 5$ (Figuras 6.7b y 6.7d), se encuentran diferentes soluciones en cada ejecución. En el caso de grupos $K = 4$ (Figura 6.7c), todas las ejecuciones convergen a la misma solución, que corresponde a los centros de los grupos.




Figura 6.7: Resultados de los centros encontrados por k-medias en el conjunto de datos de cuatro grupos: (a) grupos $K = 2$; (b) grupos $K = 3$; (c) grupos $K = 4$; (d) $K = 5$ grupos.

La variación en las k-medias da como resultado diferentes ejecuciones del algoritmo y pueden usarse como una indicación de la calidad del agrupamiento. En el ejemplo de la Figura 6.7, los datos tienen cuatro grupos muy bien definidos, de modo que el algoritmo k-means

siempre encuentra el mínimo global, independientemente de la inicialización. Cuando el número de grupos no se corresponde con las características del conjunto de datos, el algoritmo encuentra un mínimo local y el resultado depende de la inicialización. Celebi y colaborador es [80] presentan un estudio sobre los principales métodos de inicialización de k-medias, pero no discuten la influencia de la elección del número de grupos. Algunas medidas de validación para elegir la mejor agrupación se presentan en la sección 6.5.

6.3 Métodos Jerárquicos

Los algoritmos de agrupamiento jerárquico generan una estructura jerárquica de clusters en la que cada nivel representa una partición del conjunto de datos definido en la sección 6.1. La estructura de clústeres jerárquicos en diferentes niveles se representa como un árbol binario, llamado dendrograma*.

Los métodos jerárquicos se pueden clasificar en aglomerativos o divisivos. En los algoritmos aglomerativos, la estructura jerárquica se construye a partir de los registros, y cada registro se define como un grupo *singleton*. De esta manera, la partición de nivel más bajo en la jerarquía se define como $\mathbb{C}_0 = \mathcal{T}$, con grupos $K = N$. A partir de los grupos *singletons*, el algoritmo construye la estructura jerárquica $\mathbb{C}_0 \subseteq \mathbb{C}_1 \subseteq \dots \subseteq \mathbb{C}_{N-1}$, fusionando de forma iterativa grupos de particiones de niveles anteriores hasta formar la partición $\mathbb{C}_{N-1}$, que corresponde a un único grupo que contiene todo el conjunto de datos. En los algoritmos divisivos, la estrategia es de arriba hacia abajo; la partición inicial $\mathbb{C}_0$ corresponde a un solo grupo y la estructura jerárquica $\mathbb{C}_{N-1} \subseteq \mathbb{C}_{N-2} \subseteq \dots \subseteq \mathbb{C}_0$ [522].

En esta sección, se presentan los algoritmos de aglomeración jerárquica, que son los más comunes y se pueden encontrar en la mayoría de los *softwares*. Los algoritmos divisivos se obtienen aplicándolos recursivamente a cada grupo y se encuentran diferentes enfoques en la literatura [194][573].

* A palavra dendrograma é de origem grega, pela composição de *dendron*, que significa árvore, e *gramma*, desenho ou escrita.

6.3.1 Algoritmos aglomerativos

Los algoritmos jerárquicos aglomerativos siguen el procedimiento general descrito en el Algoritmo 6.2, cuyo resultado es una estructura jerárquica, utilizada para generar el dendrograma que representa los clusters formados en cada nivel.

Algoritmo 6.2: Algoritmo jerárquico (adaptado de [522])

Entrada:	Conjunto de treinamento $\mathcal{T} = \{\mathbf{x}(t), t = 1 \dots N\}$
Saída:	Partições hierárquicas $\mathbb{C}_0 \subseteq \mathbb{C}_1 \subseteq \dots \subseteq \mathbb{C}_{N-1}$
01	Início
02	Calcular a matriz de distâncias $\mathbf{D}$
03	Definir $\mathbb{C}_0 = \{\mathcal{C}_i = \mathbf{x}(i), i = 1, \dots, N\}$
04	$k = 1$
05	Enquanto $k < N - 1$
06	Selecionar $\{\mathcal{C}_i, \mathcal{C}_j\} \in \mathbb{C}_{k-1}$ como $\operatorname{argmin}(L(\mathcal{C}_i, \mathcal{C}_j))$
07	Gerar a nova partição $\mathbb{C}_k = \{\mathbb{C}_{k-1} - \{\mathcal{C}_i, \mathcal{C}_j\}\} \cup \{\mathcal{C}_i \cup \mathcal{C}_j\}$
08	$k \leftarrow k + 1$
09	Fim Enquanto
10	Retorna $\{\mathbb{C}_0, \mathbb{C}_1, \dots, \mathbb{C}_{N-1}\}$
11	Fim

En cada iteración k del Algoritmo 6.2, en el paso 07, se elimina un par de grupos $\{\mathcal{C}_i, \mathcal{C}_j\}$ de la partición $\mathbb{C}_{k-1}$ y la unión $\{\mathcal{C}_i \cup \mathcal{C}_j\}$ se incluye en la partición $\mathbb{C}_k$. La función de enlace $L(\mathcal{C}_i, \mathcal{C}_j)$ en el paso 06 se utiliza para seleccionar los grupos a los que se unirá. Diferentes funciones de vinculación dan como resultado diferentes agrupaciones. En la literatura, las principales estrategias para la función de enlace son:

Vecino más cercano (**single-link**): la distancia entre grupos se calcula mediante los elementos más cercanos [495]:

$$L_{\min}(\mathcal{C}_i, \mathcal{C}_j) = \min_{\substack{\mathbf{v} \in \mathcal{C}_i \\ \mathbf{v} \in \mathcal{C}_j}} \operatorname{dist}(\mathbf{v}, \mathbf{v}) \quad (6.7)$$

Vecino más lejano (**complete-link**): la distancia entre grupos se calcula por la distancia máxima entre sus elementos:

$$L_{max}(\mathcal{C}_i, \mathcal{C}_j) = \max_{\substack{\mathbf{v} \in \mathcal{C}_i \\ \mathbf{u} \in \mathcal{C}_j}} dist(\mathbf{v}, \mathbf{u}) \quad (6.8)$$

Distancias promedio (UPGMA):* la distancia entre los grupos se calcula por la distancia promedio entre los elementos [499]:

$$L_{med}(\mathcal{C}_i, \mathcal{C}_j) = \frac{1}{|\mathcal{C}_i||\mathcal{C}_j|} \sum_{\mathbf{v} \in \mathcal{C}_i} \sum_{\mathbf{u} \in \mathcal{C}_j} dist(\mathbf{v}, \mathbf{u}) \quad (6.9)$$

donde $|\mathcal{C}_i|$ representa la cardinalidad, es decir, el número de elementos del grupo $\mathcal{C}_i$;

Centroides (UPGMC):† la distancia entre grupos se calcula por la distancia entre los centroides [499]:

$$L_{cen}(\mathcal{C}_i, \mathcal{C}_j) = dist(\bar{\mathbf{v}}, \bar{\mathbf{u}}) \quad (6.10)$$

donde $\bar{\mathbf{v}} = \frac{1}{|\mathcal{C}_i|} \sum_{\mathbf{v} \in \mathcal{C}_i} \mathbf{v}$ y $\bar{\mathbf{u}} = \frac{1}{|\mathcal{C}_j|} \sum_{\mathbf{u} \in \mathcal{C}_j} \mathbf{u}$.

También existen variantes WPGMA y WPGMC, que son similares, respectivamente, a los criterios de distancia media (UPGMA) y centroide (UPGMC), en los que las distancias se ponderan por el número de elementos en cada grupo [194]. Finalmente, el criterio de Ward minimiza la varianza del grupo [551].

Los algoritmos jerárquicos aglomerativos, en general, funcionan con la matriz de distancias en la memoria, lo que significa almacenar al menos $N(N - 1)/2$ valores.‡ Aplicar este tipo de algoritmo a conjuntos de datos con una gran cantidad de registros puede causar problemas de memoria.

6.3.2 Ejemplos

En esta sección, los algoritmos anteriores se evalúan en conjuntos de datos sintéticos y *benchmark*. Todos los ejemplos se realizaron utilizando la distancia euclidiana, variando únicamente la función de enlace.

La Figura 6.8 muestra los dendrogramas y las particiones resultantes de los cuatro algoritmos jerárquicos discutidos anteriormente en el conjunto de datos sintéticos de cuatro grupos (ver Figura 6.2a). El nivel inferior se ha limitado a 25 grupos para facilitar la visualización.

* *Unweighted Pair Group Method with Average linkage*

† *Unweighted Pair Group Method with Centroid linkage*.

‡ Considerando que la matriz de distancias es simétrica e almacenando apenas la matriz triangular.

Tenga en cuenta que incluso en un ejemplo simple como este, los resultados son ligeramente diferentes, tanto en términos del dendrograma como de la partición encontrada.

La Figura 6.9 presenta los resultados de los algoritmos en el conjunto de datos de dos lunas presentado (cf. Figura 6.4b). Este ejemplo muestra la capacidad del algoritmo vecino más cercano (*single-link*) para encontrar particiones no convexas, lo que no sucede en el caso de las otras funciones de conexión.

La observación de los resultados en la Figura 6.8 y la Figura 6.9 muestra que el dendrograma puede indicar el número de grupos presentes en un conjunto de datos por el número de ramas (líneas verticales) entre los dos niveles más distantes (líneas horizontales). El resultado de este análisis cualitativo es claramente visible en la Figura 6.8, que indica la presencia de cuatro grupos (excepto el algoritmo *single-link*), y en la Figura 6.9, que indica la presencia de dos grupos.

6.4 Partición de gráficos

La teoría de grafos [55][129] es la rama de las matemáticas que estudia problemas que pueden representarse en forma de gráfico, es decir, un conjunto de vértices conectados por un conjunto de aristas. La teoría de grafos es la base matemática de varias disciplinas de la informática y el análisis de redes complejas [414].


Un conjunto de datos se puede representar como un gráfico $G(\mathcal{V}, \mathcal{E})$, en el que el conjunto de vértices $\mathcal{V}$ representa los registros, es decir, $\mathcal{V} \equiv \mathcal{T} = \{\mathbf{x}(t), t = 1 \dots N\}$, y el conjunto de aristas está definido por la matriz de adyacencia $\mathbf{A} \in \mathcal{R}^{N \times N}$, en la que cada elemento representa la similitud entre un par de registros como:

$$a_{ij} = \begin{cases} \text{sim}(\mathbf{x}(i), \mathbf{x}(j)), & \text{se } i \neq j \\ 0, & \text{se } i = j \end{cases} \quad (6.11)$$


La matriz de similitud es simétrica y por tanto los bordes del gráfico correspondientes a un conjunto de datos son ponderados y no dirigidos.

El grado de un vértice es el número de vecinos del vértice. En gráficos ponderados, el grado es la suma del peso de las aristas conectadas al vértice.


* Aquí, seguimos a notação proposta por Newman [414], em que a matriz de adjacências binária é um caso particular da matriz de adjacências ponderada.




(a)




(b)




(c)




(d)




(e)



(f)




(g)




(h)


Figura 6.8: Resultados de agrupamento jerárquico de dados de quatro grupos: (a) y (b) *single-link*; (c) y (d) *complete-link*; (e) y (f) distancia promedio; (g) y (h) centroide.




(a)




(b)




(c)




(d)




(e)



(f)



(g)



(h)

Figura 6.9: Resultados de agrupamento jerárquico em dados de duas lunas: (a) e (b) *single-link*; (c) e (d) *complete-link*; (e) e (f) distância promedio; (g) e (h) centróide.

La función de similitud gaussiana se usa ampliamente para representar un conjunto de datos como un gráfico y se define como (cf. ecuación (2.14)):

$$sim_G(\mathbf{x}(i), \mathbf{x}(j)) = \exp\left(-\frac{\|\mathbf{x}(i) - \mathbf{x}(j)\|^2}{2\sigma^2}\right) \quad (6.12)$$

La figura 6.10 muestra un ejemplo de una gráfica generada a partir de un conjunto de datos de cuatro grupos mediante la función de similitud gaussiana (6.12) con $\sigma = 1/3$. En la Figura 6.10a, el gráfico formado al conectar los registros en el que los tonos de gris representan los valores de los bordes; en la Figura 6.10b, la matriz de adyacencia.




Figura 6.10: Conjuntos de datos de cuatro grupos: (a) Gráfico; (b) matriz de adyacencia.

La función de similitud coseno (cf. ecuación (2.13)) también se utiliza con frecuencia, principalmente en aplicaciones de minería de textos [468]. Hay otras formas de representar un conjunto de datos como un gráfico [356][473]. La función de similitud gaussiana relaciona la partición de gráficos con métodos basados en funciones del núcleo [182], discutidos en el Capítulo 7.

Un corte en un gráfico conexo es un conjunto de aristas (o vértices) cuya eliminación desconecta un par de vértices dado [414]. El corte de gráficos se estudia principalmente en problemas en los que el gráfico representa un sistema donde hay algún flujo (de materia, información, etc.) a lo largo de los bordes y la capacidad de flujo está representada por el valor (o peso) del borde. El corte mínimo es el conjunto de aristas que, si se eliminan, desconectan un par de vértices y cuya suma de los pesos de las aristas eliminadas es mínima. El corte mínimo corresponde al flujo máximo entre el par de vértices [6].

El problema de corte mínimo en un gráfico se puede asociar con el problema de agrupación para encontrar una partición $\mathbb{C} = \{\mathcal{C}_1, \mathcal{C}_2\}$, tal que $\mathcal{C}_1 \cap \mathcal{C}_2 = \emptyset$ y $\mathcal{C}_1 \cup \mathcal{C}_2 = \mathcal{V}$, minimizando la suma de los pesos de las aristas entre los dos grupos calculados por la función de corte:

$$cut(\mathcal{C}_1, \mathcal{C}_2) = \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N a_{ij} u_1(\mathbf{x}(i)) u_2(\mathbf{x}(j)) \quad (6.13)$$

donde $a_{ij} \in \mathbf{A}$ son los elementos de la matriz de adyacencia, $u_i(\mathbf{x}(t))$ es la pertenencia de un registro $\mathbf{x}(t)$ al grupo $\mathcal{C}_i$ (cf. ecuación (6.3)) y se incluye el factor $\frac{1}{2}$ para evitar el doble conteo de un mismo borde, ya que la matriz de adyacencia $\mathbf{A}$ es simétrica.

En grafos no dirigidos, el criterio de corte definido por la ecuación (6.13) admite una solución trivial que corresponde a separar sólo un vértice cuya suma de sus aristas sea mínima, es decir, el vértice de menor grado. En un gráfico correspondiente a un conjunto de datos, esta solución trivial significa separar un *outlier*. Para evitar este problema, Shi y Malik [489] proponen minimizar la función de corte normalizada:

$$Ncut(\mathcal{C}_1, \mathcal{C}_2) = \frac{cut(\mathcal{C}_1, \mathcal{C}_2)}{cut(\mathcal{C}_1, \mathcal{V})} + \frac{cut(\mathcal{C}_2, \mathcal{C}_1)}{cut(\mathcal{C}_2, \mathcal{V})} \quad (6.14)$$

donde $cut(\mathcal{C}_k, \mathcal{V}) = \sum_{i=1}^N \sum_{j=1}^N a_{ij} u_k(\mathbf{x}(i))$ y $\mathcal{V}$ es el conjunto de vértices del gráfico.

La función de evaluación definida por la ecuación (6.14) evita obtener un grupo en el que los bordes cortados representen una porción importante de su conectividad.

El corte mínimo se puede ilustrar en la Figura 6.10a, donde la agrupación se define cortando los bordes más claros. En este caso, la medida de corte en la ecuación (6.13) se generaliza al caso de una partición genérica $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$ como [468]:

$$cut(\mathcal{C}_1, \dots, \mathcal{C}_K) = \sum_{i=1}^K cut(\mathcal{C}_i, \bar{\mathcal{C}}_i) \quad (6.15)$$

donde $\bar{\mathcal{C}}_i = \mathcal{V} - \mathcal{C}_i$ es el complemento de $\mathcal{C}_i$, es decir, $\bar{\mathcal{C}}_i = \bigcup_{j=1, j \neq i}^K \mathcal{C}_j$.

En la literatura existen otras variantes de la medida de corte del gráfico con características ligeramente diferentes [130][468].

Se ha explorado la teoría de grafos para estudiar redes complejas [414]. El problema de la partición de gráficos en el área de redes complejas se denomina detección de comunidades [412][414][468]. En una red social, por ejemplo, los individuos representan los vértices del gráfico y los bordes representan las relaciones entre ellos. Las comunidades están formadas por grupos de individuos que comparten características comunes y, por tanto, tienen más relaciones entre sí que con individuos de otros grupos. Esta tendencia se llama homofilia.

Newman presenta una medida para evaluar el grado de homofilia de una red, llamada modularidad [411]-[413]. La medida de modularidad sigue un razonamiento muy diferente al de la medida de corte del gráfico (6.13). En lugar de evaluar el peso de las aristas en diferentes grupos, la idea es evaluar el peso de las aristas en el mismo grupo y la medida refleja la fracción de aristas que conectan los vértices en ese grupo. Sin embargo, para evitar la solución trivial de considerar toda la red como un solo grupo, la medida de modularidad resta la fracción de aristas esperadas de una red cuyas conexiones ocurren aleatoriamente. En otras palabras, la modularidad mide en qué medida la estructura comunitaria encontrada en la red es diferente de una disposición aleatoria.

Matemáticamente, la modularidad de una partición $\mathcal{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$ se define como:

$$Q(\mathcal{C}_1, \dots, \mathcal{C}_K) = \frac{1}{2E} \sum_{i=1}^N \sum_{j=1}^N \left(a_{ij} - \frac{d_i d_j}{2E} \right) \mathbf{u}_i \mathbf{u}_j^T \quad (6.16)$$

donde $d_i = \sum_j a_{ij}$ es el grado del vértice asociado con el registro $\mathbf{x}(i)$ y $E = \sum_i d_i$ es el número total de aristas. El vector $\mathbf{u}_i = (u_1(\mathbf{x}(i)), \dots, u_K(\mathbf{x}(i)))$ es aquel en el que cada elemento es la pertenencia del registro $\mathbf{x}(i)$ a cada uno de los grupos (cf. ecuación (6.3)). El producto $\mathbf{u}_i \mathbf{u}_j^T = 1$ si los registros $\mathbf{x}(i)$ y $\mathbf{x}(j)$ están en el mismo grupo; en caso contrario $\mathbf{u}_i \mathbf{u}_j^T = 0$.

Si los registros $\mathbf{x}(i)$ y $\mathbf{x}(j)$ están en el mismo grupo, la modularidad de la partición calculada a mediante la ecuación (6.16) es la diferencia entre el número total de aristas $\sum_{ij} a_{ij}$ y el número esperado de aristas en una red aleatoria $\sum_{ij} d_i d_j / 2E$ [413].

La modularidad se puede escribir directamente a partir de la definición de la matriz de modularidad $\mathbf{B}$, calculada como:

$$\mathbf{B} = \mathbf{A} - \frac{\mathbf{d}^T \mathbf{d}}{2E} \quad (6.17)$$

donde $\mathbf{d} = (d_1, \dots, d_N)$ es el vector de los grados de los vértices (registros) correspondientes, donde cada elemento se calcula como $d_i = \sum_j a_{ij}$. Tenga en cuenta que, en general, la matriz $\mathbf{A}$ es escasa, pero $\mathbf{B}$ es una matriz densa.

En general, el problema de partición de gráficos es un problema NP-difícil por razones análogas a la complejidad del problema de partición de conjuntos de datos. Así, una solución computacionalmente manejable al problema se obtiene mediante una formulación aproximada, basada en la descomposición espectral de una matriz derivada de la matriz de adyacencia del gráfico $\mathbf{A}$, llamada Laplaciana [356][408]. Este enfoque da lugar a diferentes algoritmos, que se presentan a continuación.

6.4.1 Algoritmos de agrupamiento espectral

Una partición $\mathcal{C} = \{\mathcal{C}_1, \mathcal{C}_2\}$ en un gráfico se puede representar mediante un vector $\mathbf{v} \in \mathcal{R}^N$, que representa la partición a través de la variable indicadora:

$$v_i = \begin{cases} +1, & \text{se } \mathbf{x}(i) \in \mathcal{C}_1 \\ -1, & \text{se } \mathbf{x}(i) \in \mathcal{C}_2 \end{cases} \quad (6.18)$$

donde $\mathcal{C}_1 \cap \mathcal{C}_2 = \emptyset$ y $\mathcal{C}_1 \cup \mathcal{C}_2 =$.

La variable indicadora permite identificar si dos registros $\mathbf{x}(i)$ y $\mathbf{x}(j)$ están en el mismo grupo que $u_1(\mathbf{x}(i))u_2(\mathbf{x}(j)) = \frac{1}{2}(1 - v_i v_j)$. Si los registros están en el mismo grupo, $\frac{1}{2}(1 - v_i v_j) = 0$; en caso contrario $\frac{1}{2}(1 - v_i v_j) = 1$. Por tanto, la medida de corte (6.13) se puede escribir como:

$$cut(\mathcal{C}_1, \mathcal{C}_2) = \frac{1}{4} \sum_{i=1}^N \sum_{j=1}^N a_{ij} (1 - v_i v_j) \quad (6.19)$$

Considerando $\sum_{i=1}^N \sum_{j=1}^N a_{ij} = \sum_{i=1}^N d_i = \sum_{i=1}^N \sum_{j=1}^N d_i \delta_{ij}$ [414], donde $d_i = \sum_j a_{ij}$ es el grado del vértice y δ_{ij} , la función de Kronecker δ ,* ecuación (6.19) se reescribe como:

$$cut(\mathcal{C}_1, \mathcal{C}_2) = \frac{1}{4} \sum_{i=1}^N \sum_{j=1}^N (d_i \delta_{ij} - a_{ij}) v_i v_j \quad (6.20)$$

* A função δ de Kronecker é definida como: $\delta_{ij} = \begin{cases} 1, & \text{se } i = j \\ 0, & \text{se } i \neq j \end{cases}$.

La medida de corte escrita en la forma (6.20) resalta los valores $l_{ij} = (d_i \delta_{ij} - a_{ij})$, que son los elementos del laplaciano del gráfico, definidos como:

$$\mathbf{L} = \mathbf{D} - \mathbf{A} \quad (6.21)$$

donde $\mathbf{D}$ es una matriz diagonal en la que cada elemento $d_{ii} = \sum_j a_{ij}$ es el grado del vértice (registro) correspondiente.

El laplaciano del gráfico recibe su nombre debido a una analogía con el operador laplaciano de la ecuación de difusión [414]. El laplaciano tiene gran importancia en las propiedades topológicas de los grafos [104][381].

La medida de corte (6.20) se escribe como una función del laplaciano y de la variable indicadora de partición $\mathbb{C} = \{\mathcal{C}_1, \mathcal{C}_2\}$ mediante la siguiente ecuación vectorial:

$$cut(\mathcal{C}_1, \mathcal{C}_2) = \frac{1}{4} \mathbf{v}^T \mathbf{L} \mathbf{v} \quad (6.22)$$

Minimizar la función de corte definida por la ecuación (6.22) no es una tarea sencilla, considerando la restricción $v_i \in \{-1, 1\}$ impuesta por la definición de la variable indicadora en la ecuación (6.18). Sin embargo, se puede calcular una solución aproximada $\hat{\mathbf{v}} \in \mathcal{R}^N$ resolviendo el problema de valores propios:

$$\mathbf{L} \mathbf{W} = \mathbf{W} \mathbf{\Lambda} \quad (6.23)$$

donde $\mathbf{\Lambda}$ es la matriz diagonal de valores propios cuyos elementos están ordenados de manera que $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_N$; $\mathbf{W} = [\mathbf{w}_1, \dots, \mathbf{w}_N]$ es la matriz de vectores propios en la que cada columna $\mathbf{w}_i \in \mathcal{R}^N$ es el vector propio correspondiente al valor propio λ_i .

El laplaciano es una matriz positiva semidefinida,* de modo que todos sus valores propios son números reales y positivos [206][414]. El laplaciano siempre tiene un valor propio cero, es decir, $\lambda_1 = 0$, que corresponde al vector propio unitario $\mathbf{w}_1 = [1/\sqrt{N}, \dots, 1/\sqrt{N}]$ [414]. El número de valores propios nulos corresponde al número de componentes conectados del gráfico. Por lo tanto, si $\lambda_2 > 0$, el gráfico es conexo, es decir, solo hay un componente y hay un camino entre cualquier par de vértices. Cuanto mayor sea el valor propio λ_2 , mayor será la conectividad del gráfico [179]. El segundo vector propio del laplaciano $\mathbf{w}_2$, correspondiente al segundo valor propio λ_2 , se conoce como vector propio de Fiedler [408], llamado así en honor al matemático Miroslav Fiedler [179][180].

* Una matriz $\mathbf{A}$ es positiva semi-definida si $\mathbf{x}^T \mathbf{A} \mathbf{x} \geq 0, \forall \mathbf{x}$.

Una partición genérica $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$, según el corte mínimo (6.15), se obtiene aplicando el algoritmo k-medias a los vectores propios K correspondientes a los valores propios K más pequeños de la solución del problema (6.23). El algoritmo básico de agrupamiento espectral se describe en el Algoritmo 6.3.

Algoritmo 6.3: Algoritmo de agrupamiento espectral

Entrada:	Conjunto de treinamento $\mathcal{T} = \{\mathbf{x}(t), t = 1 \dots N\}$, parâmetro de dispersão σ e número de centros K
Saída:	Partição $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$
01	Início
02	Calcular a matriz $\mathbf{A}$, pela equação (6.11)
03	Calcular o laplaciano
04	Calcular a decomposição espectral do laplaciano
05	Calcular a matriz $\mathbf{Z}$ a partir dos autovetores do laplaciano
06	Calcular a partição $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$ pelo k-médias em $\mathbf{Z}$
07	Retorna $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$
08	Fim

Von Luxburg [356] sugiere que la matriz de adyacencia binaria se puede utilizar en el paso 02, donde un borde se define por un valor mínimo de similitud o por un número específico de vecinos. Sin embargo, la forma más común es utilizar directamente la matriz de similitud en los algoritmos [408].

La partición $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$ obtenida en el paso 06 del Algoritmo 6.3 se define en el espacio o variable transformado $\mathbf{Z}$ y, debido a la transformación no lineal realizada por el cálculo de similitud, el Algoritmo 6.3 puede encontrar una partición no convexa en el espacio variable original. El problema de la inicialización aleatoria de k-medias también se resuelve en el algoritmo de agrupamiento espectral. La matriz identidad se puede utilizar para inicializar los centros, ya que el algoritmo realiza una partición de K grupos en el espacio de variables transformadas, de K dimensiones.

El algoritmo de agrupamiento espectral descrito por el Algoritmo 6.3 fue formulado en base a la medida de corte mínima, pero algunas variantes del algoritmo básico se obtienen según la medida de corte utilizada. Las principales variantes se presentan a continuación.

A continuación, comenzando con la formalización del propio algoritmo de corte mínimo. Para facilitar la presentación, se utilizará la misma notación para denotar la matriz de valores propios $\mathbf{\Lambda}$ y la matriz de vectores propios $\mathbf{W}$ en cada variante del algoritmo espectral. Estas matrices son diferentes según el problema formulado en cada algoritmo.

6.4.1.1 Algoritmo de corte mínimo

En el algoritmo de corte mínimo [356][408], los pasos 03 y 04 se calculan mediante las ecuaciones (6.21) y (6.23). La matriz de datos transformada $\mathbf{Z} = [\mathbf{w}_1, \dots, \mathbf{w}_K]$, donde $\mathbf{w}_i$ son los vectores propios calculados mediante la ecuación (6.23), ordenados por el orden creciente de sus valores propios [356][408]. Los pasos 03-05 del Algoritmo 6.3 para el corte mínimo se formulan en el Algoritmo 6.3a.

Algoritmo 6.3a: Corte mínimo

03	$\mathbf{L} = \mathbf{D} - \mathbf{A}$
04	$\mathbf{LW} = \mathbf{W}\mathbf{\Lambda}$
05	Ordenar $0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_N$, $\mathbf{Z} = [\mathbf{w}_1, \dots, \mathbf{w}_K]$

6.4.1.2 Algoritmo de corte mínimo normalizado de Shi e Malik

Shi y Malik [488][489] propusieron una variante del algoritmo 6.3a para minimizar el corte mínimo normalizado (6.14). En este caso, la descomposición espectral del paso 04 se calcula resolviendo el problema de valores propios generalizado:

$$\mathbf{LW} = \mathbf{DWA} \quad (6.24)$$

donde $\mathbf{L}$ es el laplaciano (6.21) y $\mathbf{D}$ es la matriz diagonal de grados.

Shi y Malik [488] muestran que el signo del segundo valor propio más pequeño de (6.24) es una aproximación de la solución mediante el límite mínimo normalizado (6.14). Para una partición genérica en grupos K , los autores presentan un enfoque jerárquico divisivo en el que, en cada iteración, se puede encontrar una nueva partición aplicando recursivamente el problema de valores propios (6.24) [489].

En el enfoque jerárquico divisivo, la definición del número de grupos se reemplaza por un criterio de parada del algoritmo. Sin embargo, este enfoque puede volverse inestable y computacionalmente complejo [489].

Se puede obtener una partición de grupos K aplicando el Algoritmo 6.3, en el que la matriz de variables transformadas está definida por los vectores propios correspondientes a los valores propios más pequeños $\mathbf{Z} = [\mathbf{w}_1, \dots, \mathbf{w}_K]$. El algoritmo de corte mínimo normalizado se presenta en el algoritmo 6.3b.

Algoritmo 6.3b: Corte mínimo normalizado [489]

03	$\mathbf{L} = \mathbf{D} - \mathbf{A}$
04	$\mathbf{LW} = \mathbf{DWA}$
05	Ordenar $0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_N$, $\mathbf{Z} = [\mathbf{w}_1, \dots, \mathbf{w}_K]$

El algoritmo de corte mínimo normalizado de Shi y Malik (Algoritmo 6.3b) tiene el mismo resultado que el algoritmo de corte mínimo (Algoritmo 6.3a).

La ecuación (6.24) también se puede escribir como:

$$\hat{\mathbf{L}}\hat{\mathbf{W}} = \hat{\mathbf{W}}\mathbf{A} \quad (6.25)$$

donde $\hat{\mathbf{L}} = \mathbf{D}^{-1/2}\mathbf{L}\mathbf{D}^{-1/2} = \mathbf{1} - \mathbf{D}^{-1/2}\mathbf{A}\mathbf{D}^{-1/2}$ y $\hat{\mathbf{W}} = \mathbf{D}^{1/2}\mathbf{W}$ [489]. La matriz $\hat{\mathbf{L}}$ se denomina laplaciana simétrica [356] o incluso laplaciana normalizada [408].

6.4.1.3 Algoritmo de corte mínimo normalizado de Ng, Jordan e Weiss

Ng, Jordan y Weiss [415] presentaron una variante del algoritmo de corte mínimo normalizado. El laplaciano en el paso 03 se reemplaza por la matriz $\hat{\mathbf{A}} = \mathbf{D}^{-1/2}\mathbf{A}\mathbf{D}^{-1/2}$, llamada matriz de adyacencia normalizada [104] o matriz de adyacencia reducida [414]. Algunos autores sugieren que la descomposición espectral se calcule con el laplaciano normalizado $\hat{\mathbf{L}} = \mathbf{D}^{-1/2}\mathbf{L}\mathbf{D}^{-1/2}$ [356][408]. En el artículo original [415], la descomposición espectral del paso 04 se calcula como:

$$\hat{\mathbf{A}}\mathbf{W} = \mathbf{W}\hat{\mathbf{A}} \quad (6.26)$$

La descomposición espectral (6.26) produce los mismos vectores propios $\mathbf{W}$ que (6.25) y valores propios $\hat{\mathbf{\Lambda}} = \mathbf{1} - \mathbf{\Lambda}$, donde $\mathbf{\Lambda}$ es la matriz de valores propios calculada en (6.25). Así, la solución al problema (6.26) corresponde a la minimización de corte mínimo normalizada (6.14) con los valores propios en orden no creciente $\hat{\lambda}_1 \geq \hat{\lambda}_2 \geq \dots \geq \hat{\lambda}_N$.

La matriz $\hat{\mathbf{A}}$ tiene otras propiedades interesantes. En un gráfico definido por una matriz de adyacencia binaria, es decir, $a_{ij} \in \{0,1\}$, el valor propio más grande $\hat{\lambda}_1 = 1$. El número de valores propios unitarios corresponde al número de componentes del gráfico [104][342] y, en

gráficos conectados, $\hat{\lambda}_2 < 1$ [104]. En un gráfico con K componentes que definen una partición $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$, el valor del corte mínimo $cut(\mathcal{C}_1, \dots, \mathcal{C}_K) = 0$ (cf. (6.15)) y la matriz $\hat{\mathbf{A}}$ tiene K valores propios unitarios: $\hat{\lambda}_i = 1, i = 1, \dots, K$. Esta propiedad permite utilizar el resultado de la descomposición espectral (6.26) para estimar el número de grupos en un conjunto de datos [342][168][170].

Las variables transformadas se calculan, para cada registro, mediante vectores propios normalizados como:

$$\hat{\mathbf{z}}(t) = \left[\frac{w_1(t)}{\|\mathbf{z}(t)\|}, \dots, \frac{w_K(t)}{\|\mathbf{z}(t)\|} \right] \quad (6.27)$$

donde $\mathbf{z}(t) = [w_1(t), \dots, w_K(t)]$ y $w_i(t)$ es el elemento t del vector propio correspondiente al valor propio $\hat{\lambda}_i$, calculado en la descomposición espectral (6.26).

El uso de variables transformadas normalizadas en k-medias es equivalente al uso de k-medias esféricas en variables transformadas sin normalización [468]. En la práctica, la normalización (6.27) también se puede aplicar a otros algoritmos de corte mínimo. El algoritmo de corte normalizado de Ng, Jordan y Weiss se describe en el Algoritmo 6.3c.

Algoritmo 6.3c: Corte mínimo normalizado [415]

03	$\hat{\mathbf{A}} = \mathbf{D}^{-1/2} \mathbf{A} \mathbf{D}^{-1/2}$
04	$\hat{\mathbf{A}} \mathbf{W} = \mathbf{W} \hat{\mathbf{A}}$
05	Ordenar $1 = \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_N, \hat{\mathbf{z}}(t) = \left[\frac{w_1(t)}{\ \mathbf{z}(t)\ }, \dots, \frac{w_K(t)}{\ \mathbf{z}(t)\ } \right]$

La complejidad computacional del cálculo de la matriz de similitud es $O(N^2)$ y la complejidad del algoritmo de agrupamiento espectral está dominada por el cálculo del problema de valores propios, que es $O(N^3)$. En problemas que $K \ll N$, la complejidad se puede reducir a $O(N^2)$ ya que solo se necesitan los primeros vectores propios.

El algoritmo de agrupamiento espectral puede separar grupos no convexos en el espacio de variables de entrada del problema y, por lo tanto, tiene buenos resultados en aplicaciones de agrupamiento. Estas características motivaron el desarrollo de otras variantes del algoritmo [23][356][408][554]. Los algoritmos de agrupamiento espectral están relacionados con los algoritmos basados en funciones del núcleo [127][128][182][596].

6.4.1.4 Algoritmo de maximização da modularidade de Newman e Girvan

El problema de maximizar la modularidad (cf. ecuación (6.16)) también tiene una solución aproximada mediante la descomposición espectral de la matriz de modularidad $\mathbf{B}$. En el caso de una partición binaria $\mathbb{C} = \{\mathcal{C}_1, \mathcal{C}_2\}$, el producto $\mathbf{u}_i \mathbf{u}_j^T$ se escribe en la función de variable indicadora (6.18) como $\mathbf{u}_i \mathbf{u}_j^T = \frac{1}{2}(v_i v_j + 1)$, de modo que $\frac{1}{2}(v_i v_j + 1) = 1$ si dos registros $\mathbf{x}(i)$ y $\mathbf{x}(j)$ están en el mismo grupo y $\frac{1}{2}(v_i v_j + 1) = 0$ en caso contrario.

-

La función de modularidad (6.16) se reescribe como:

$$Q(\mathcal{C}_1, \mathcal{C}_2) = \frac{1}{4E} \sum_{i=1}^N \sum_{j=1}^N b_{ij} (v_i v_j + 1) = \frac{1}{4E} \left(\sum_{i=1}^N \sum_{j=1}^N b_{ij} v_i v_j + \sum_{i=1}^N \sum_{j=1}^N b_{ij} \right) \quad (6.28)$$

donde b_{ij} son los elementos de la matriz de modularidad $\mathbf{B}$ definida en (6.17). La suma de las filas (o columnas) de la matriz $\mathbf{B}$ es cero, por lo que el término $\sum_{ij} b_{ij} = 0$. La función de modularidad se puede escribir vectorialmente como:

$$Q(\mathcal{C}_1, \mathcal{C}_2) = \frac{1}{4E} \mathbf{v}^T \mathbf{B} \mathbf{v} \quad (6.29)$$

Una aproximación a la solución del problema de maximización de modularidad (6.29) se obtiene resolviendo el problema de valores propios $\mathbf{B} \mathbf{w} = \lambda \mathbf{w}$, donde λ es el valor propio más grande y $\hat{\mathbf{v}}$ el vector propio correspondiente. El signo de los elementos del vector propio correspondiente al mayor valor propio se utiliza para obtener la partición $\mathbb{C} = \{\mathcal{C}_1, \mathcal{C}_2\}$:

$$\hat{v}_i = \begin{cases} +1, & \text{se } w_i \geq 0 \\ -1, & \text{se } w_i < 0 \end{cases} \quad (6.30)$$

Newman y Girvan [413] presentan un enfoque jerárquico divisivo para la partición de gráficos en el que, en cada iteración, el valor de ganancia de la función de modularidad se evalúa y se utiliza para decidir sobre una nueva partición. Vieira y colaboradores [541] presentan un estudio de rendimiento y el código de los principales algoritmos de detección de comunidades basados en la función de modularidad.

6.4.2 Ejemplos

La Figura 6.11 muestra, en cada línea, los resultados de los algoritmos 6.3a-c en el conjunto de datos de dos lunas utilizando el parámetro $\sigma = 0.1$ en el cálculo de la función de similitud. Los resultados de agrupación se presentan en la columna de la derecha y las variables transformadas se presentan en la columna de la izquierda.




Figura 6.11: Resultados en el conjunto de datos de dos lunas: a la izquierda, los resultados del agrupamiento y , a la derecha, las variables transformadas; en las líneas, Algoritmos 6.3a-c.

Podemos observar que los algoritmos espectrales basados en el corte mínimo pueden generar grupos de forma no convexa y las tres formulaciones producen los mismos resultados. Los resultados de las variables transformadas utilizadas en los algoritmos de corte mínimo (6.3a) y de corte mínimo normalizado (6.3b) también son idénticos. una aplicacion

del algoritmo de maximización de modularidad para la agrupación de documentos se presentará en la sección 6.6.2.

Los resultados de los algoritmos de agrupamiento espectral dependen del valor del parámetro de dispersión σ en el cálculo de la función de similitud gaussiana (6.12), además de la información sobre el número de grupos K para el algoritmo k-medias. Sin embargo, la inicialización del algoritmo k-medias está definida por la matriz de identidad y el resultado del algoritmo espectral es determinista.

En el análisis de conglomerados, la decisión sobre el mejor número de grupos depende de alguna medida de validación, como se presenta a continuación.

6.5 Validación de grupo

Encontrar una partición en un conjunto de datos es un problema mal definido y se pueden obtener diferentes agrupaciones del mismo conjunto (cf. Figura 6.1). No existe una medida absoluta de calidad para el problema y el resultado de la agrupación debe evaluarse en el contexto de la aplicación.

Las medidas de validación de clusters tienen como objetivo evaluar las características geométricas del cluster formado, sabiendo que un buen cluster debe producir grupos compactos y bien separados. Es común encontrar en la literatura la división de las medidas de validación de clusters en tres tipos [194][227][228][573], cuyos principales índices se presentan a continuación:

Medidas externas: evaluar la calidad del agrupamiento en relación con información externa sobre la estructura de los grupos (o clases) del problema; Medidas internas: evaluar la calidad de la agrupación a partir de los registros del conjunto de datos, generalmente utilizando criterios geométricos; Medidas relativas: producir índices calculados combinando criterios (internos) que evalúan la calidad de una agrupación en relación con otras.

6.5.1 Medidas externas

Las medidas externas evalúan la calidad del agrupamiento basándose en una matriz de confusión como en la evaluación de clasificadores (cf. Tabla 5.2). Para evaluar grupos, la matriz de confusión relaciona los grupos encontrados por el algoritmo de clustering.

ment con las clases de problemas. La Tabla 6.1 muestra la matriz de confusión para la evaluación de conglomerados, donde $\{C_1, \dots, C_m\}$ es el conjunto de clases y $\mathbb{C} = \{C_1, \dots, C_K\}$, una partición de K grupos. Cada elemento n_{ij} en la Tabla 6.1 representa el número de registros de clase C_i asignados en el grupo C_j . La suma de las filas corresponde al número de elementos de las clases y la suma de las columnas corresponde al número de elementos de los grupos.

Cuando el número de grupos es igual al número de clases, cualquier estadística de evaluación del clasificador (ver sección 5.3.1) se puede utilizar como medida de validación externa. Sin embargo, es común que el número de grupos sea diferente al número de clases y, en este caso, medidas externas evalúan en qué medida el agrupamiento encontrado corresponde a la estructura de clases conocida.

Tabla 6.1: Matriz de confusión

	C_1	...	C_K	Total
C_1	n_{11}	...	n_{1K}	N_1
$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
C_m	n_{m1}	...	n_{mK}	N_m
Total	$\hat{N}_1$	...	$\hat{N}_K$	N

La pureza de un grupo es la porción de los registros de un grupo que pertenecen a la clase que contiene la mayoría de los registros de ese grupo. La pureza es una medida de la homogeneidad del grupo: cuanto mayor es la pureza, más homogéneos son los grupos. La pureza de un grupo se calcula como:

$$pur(C_j) = \max_{i=1, \dots, m} \left(\frac{n_{ij}}{\hat{N}_j} \right) \quad (6.31)$$

La pureza total o pureza del racimo se calcula como la pureza promedio de los grupos ponderada por el número de registros en cada grupo:

$$PUR(\mathbb{C}) = \sum_{j=1}^K \frac{\hat{N}_j}{N} pur(C_j) \quad (6.32)$$

La entropía de Shannon es una medida clásica de la teoría de la información que se puede utilizar para evaluar la heterogeneidad de los conglomerados: cuanto menor es la entropía, mejor es el conglomerado. La entropía de un grupo se calcula como (cf. Tabla 6.1):

$$ent(\mathcal{C}_j) = -\frac{1}{\log_2 m} \sum_{i=1}^m \left(\frac{n_{ij}}{\hat{N}_j} \right) \log_2 \left(\frac{n_{ij}}{\hat{N}_j} \right) \quad (6.33)$$

La entropía del clúster se calcula como la entropía promedio de los grupos ponderada por el número de registros en cada grupo:

$$ENT(\mathbb{C}) = \sum_{j=1}^K \frac{\hat{N}_j}{N} ent(\mathcal{C}_j) \quad (6.34)$$

Existen otras medidas externas para evaluar la calidad de los conglomerados basadas en el recuento de pares y la información mutua [544]. Sin embargo, no siempre se conoce la información de clase para evaluar la agrupación. Además, la estructura del grupo puede no coincidir con la estructura de clases, lo que no significa que la agrupación sea inadecuada (cf. Figura 6.2). Las medidas internas y relativas son más comunes en los problemas de agrupación.

6.5.2 Medidas internas

Las medidas internas evalúan un grupo utilizando únicamente información de los registros del conjunto de datos y el resultado del grupo. La función de evaluación de un algoritmo de clustering, por ejemplo, es una medida de evaluación interna. En algoritmos jerárquicos, el coeficiente de correlación cofenética [572] se utiliza para evaluar conglomerados.

Una medida interna ampliamente utilizada es el índice de partición (PI), propuesto por Bensaid y colaboradores [41] para evaluar conglomerados *fuzzy*. El índice PI, cuando se calcula con funciones de pertenencia binarias, es la relación entre el criterio de k-medias cuadráticas y la suma ponderada de las distancias entre centros:

$$PI(\mathbb{C}) = \frac{\sum_{i=1}^K \sum_{t=1}^N u_i(\mathbf{x}(t))^2 \|\mathbf{x}(t) - \boldsymbol{\omega}_i\|^2}{\sum_{i=1}^K \sum_{j=1}^K N_i \|\boldsymbol{\omega}_i - \boldsymbol{\omega}_j\|^2} = \frac{tr(\boldsymbol{\Sigma}_W)}{\sum_{i=1}^K \sum_{j=1}^K N_i \|\boldsymbol{\omega}_i - \boldsymbol{\omega}_j\|^2} \quad (6.35)$$

donde $tr(\boldsymbol{\Sigma}_W)$ es la traza de la matriz de varianza intragrupo (cf. ecuación (6.6)).

Al evaluar los clusters obtenidos por el algoritmo k-means y sus variantes, el índice PI permite elegir el mejor cluster de un conjunto de soluciones obtenidas con varias inicializaciones aleatorias, pero con el mismo número de grupos K .

Una propuesta para evaluar los conglomerados es la visualización cualitativa de la tendencia del conglomerado (IVA)* [49][239]. El IVA es básicamente la *data image* del conjunto de datos con los registros ordenados según el resultado de la agrupación. Un buen grupo muestra un contraste más intenso que un grupo pobre para el mismo conjunto de datos.

La Figura 6.12 muestra los resultados de agrupar el conjunto de datos Iris con grupos $K = 4$. Se realizaron 25 agrupamientos diferentes y se seleccionaron aquellos con valores de PI más bajos y más altos, los cuales se presentan, respectivamente, en las columnas izquierda y derecha de la Figura 6.12. Podemos ver que el resultado con el valor de PI más bajo (a la izquierda) da como resultado un contraste ligeramente mayor que el resultado con el valor de PI más alto (a la derecha).




Figura 6.12: *Data image* del resultado de agrupar el conjunto de datos Iris con $K = 4$: (a) resultado con el IP más bajo; (b) resultado con el IP más alto.

La valoración cualitativa de *data image* es muy subjetiva, siendo preferible utilizar una métrica cuantitativa para elegir la mejor agrupación. Las medidas relativas permiten evaluar el número de grupos, especialmente en algoritmos de partición.

* *Visual Assessment of (cluster) Tendency.*

6.5.3 Medidas relativas

Los métodos de partición, principalmente k-medias y sus variantes, son los más utilizados en la práctica y, en este caso, se utilizan medidas relativas para descubrir el número de grupos. Las medidas relativas son índices que se utilizan para comparar diferentes soluciones de un mismo algoritmo, variando el número de grupos. En el algoritmo k-means, el resultado depende de la inicialización y las medidas relativas pueden variar para el mismo número de grupos, siendo por tanto función de la agrupación generada por el algoritmo y no sólo del número de grupos.

En un estudio realizado en 1985, Milligan y Cooper [388] compararon 30 medidas de evaluación de conglomerados que existían en ese momento. La medida que mejor resultado obtuvo fue la propuesta por Calinski y Harabasz [71] en 1974.

El índice Calinski-Harabasz (CH) de una partición $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$ se calcula como:

$$CH(\mathbb{C}) = \frac{N - K}{K - 1} \frac{tr(\mathbf{\Sigma}_B)}{tr(\mathbf{\Sigma}_W)} \quad (6.36)$$

donde, $tr(\mathbf{\Sigma}_B)$ y $tr(\mathbf{\Sigma}_W)$ son, respectivamente, las trazas de las matrices de varianza entre grupos e intragrupos, definidas en las ecuaciones (6.5) y (6.6).

El índice CH es un criterio de maximización, ya que un valor pequeño de $tr(\mathbf{\Sigma}_W)$ indica grupos cohesivos y un valor grande de $tr(\mathbf{\Sigma}_B)$ grupos separados.

Un índice similar, propuesto por Pakhira, Bandyopadhyay y Maulik [423] en 2006, es también un criterio de maximización calculado por el producto de tres términos:

$$PBM(\mathbb{C}) = \left(\frac{1}{K} \frac{E_1}{E_K} \frac{1}{D_{\max}} \right)^2 \quad (6.37)$$

donde $E_1 = \sum_{t=1}^N \|\mathbf{x}(t) - \bar{\mathbf{x}}\|$ es constante para un conjunto de datos determinado. El término $E_K = \sum_{t=1}^N \sum_{i=1}^K u_i(\mathbf{x}(t)) \|\mathbf{x}(t) - \boldsymbol{\omega}_i\|$, disminuye con el aumento del número de grupos K y el término $D_{\max} = \max_{i,j=1 \dots K} (\|\boldsymbol{\omega}_i - \boldsymbol{\omega}_j\|^2)$ aumenta con el número de grupos.

El índice PBM utiliza los valores de distancia en las sumas de E_1 y E_K , mientras que las matrices de varianza utilizadas en el índice CH se calculan mediante la suma de las diferencias al cuadrado (véanse las ecuaciones (6.4)-(6.6)). La relación E_1/E_K favorece a los conglomerados cuya varianza intragrupo es la porción más pequeña de la varianza total. El primer y tercer factor.

del índice PBM favorecen, respectivamente, conglomerados con un pequeño número de grupos y con centros separados.

Una medida de evaluación relativa bien conocida es el coeficiente de silueta [462], que evalúa la calidad de agrupación de cada registro como:

$$sw_i(t) = - \frac{(b_i(t) - a_i(t))}{\max_{t=1, \dots, N} (a_i(t), b_i(t))} \quad (6.38)$$

donde $a_i(t)$ es la distancia promedio entre el registro $\mathbf{x}(t)$ y todos los demás registros asignados al mismo grupo $\mathcal{C}_i$ y $b_i(t)$ es la distancia promedio más pequeña entre $\mathbf{x}(t)$ y los registros asignados a los otros grupos $\mathcal{C}_j \neq \mathcal{C}_i$.

El valor $a_i(t)$ se calcula para cada registro $\mathbf{x}(t) \in \mathcal{C}_i$ como la distancia promedio a los demás elementos del grupo:

$$a_i(t) = \frac{1}{\bar{N}_i} \sum_{k=1}^N dist(\mathbf{x}(t), \mathbf{x}(k)), \quad \mathbf{x}(k) \in \mathcal{C}_i \quad (6.39)$$

El valor $b_i(t) = \min_j (\bar{a}_j(t))$, donde $\bar{a}_j(t)$ es la distancia promedio desde $\mathbf{x}(t)$ a los registros de los otros grupos $\mathcal{C}_j, j = 1, \dots, K, j \neq i$, calculado como:

$$\bar{a}_j(t) = \frac{1}{\bar{N}_j} \sum_{k=1}^N dist(\mathbf{x}(t), \mathbf{x}(k)), \quad \mathbf{x}(t) \in \mathcal{C}_j, j \neq i \quad (6.40)$$

El coeficiente de silueta se define en el rango $-1 < sw_i(t) < 1$ y el valor $sw_i(t) \approx 1$ se obtiene cuando $a_i(t) \approx 0$, lo que indica que el registro está en el centro de un grupo compacto. Cuanto mayor sea el valor del coeficiente de silueta, mejor será la posición del registro en la agrupación. El coeficiente de silueta también se puede utilizar en una etapa de refinamiento, comprobando su valor si el registro está asignado a otro grupo.

El coeficiente de silueta para la partición $\mathbb{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$ se calcula como el valor promedio del coeficiente de silueta para todos los registros y todos los grupos:

$$SW(\mathbb{C}) = \frac{1}{KN} \sum_{i=1}^K \sum_{t=1}^N sw_i(t) \quad (6.41)$$

El índice propuesto por Xie y Beni [570] para evaluar conglomerados *fuzzy* es una medida de minimización que evalúa la relación entre la varianza intragrupo y la separación más pequeña entre grupos. El índice XB es similar al PI y se calcula como:

$$XB(\mathbb{C}) = \frac{1}{N} \frac{\sum_{i=1}^K \sum_{t=1}^N u_i(\mathbf{x}(t))^2 \|\mathbf{x}(t) - \boldsymbol{\omega}_i\|^2}{D_{\min}} = \frac{1}{N} \frac{tr(\boldsymbol{\Sigma}_W)}{D_{\min}} \quad (6.42)$$

donde $D_{\min} = \min_{i,j=1\dots K, i \neq j} (\|\boldsymbol{\omega}_i - \boldsymbol{\omega}_j\|^2)$.

Generalmente se aplican medidas relativas para evaluar el número de grupos en algoritmos de partición. En el caso del algoritmo k-means y sus variantes, se debe tener en cuenta la cuestión de la inicialización aleatoria y una evaluación estadística en diferentes ejecuciones con el mismo número de grupos es el enfoque más adecuado para una evaluación libre de la influencia de la inicialización.

La Figura 6.13 presenta *boxplot* de los resultados de las medidas de validación aplicadas a los resultados de 10 ejecuciones del algoritmo k-means en el conjunto de datos de cuatro grupos (cf. Figura 6.7). La línea azul representa el promedio de las mediciones en todas las simulaciones para cada valor de K . En este ejemplo, todas las mediciones indican el número de grupos $K = 4$, que es el valor con menor dispersión de resultados.

Los resultados presentados en la Figura 6.13 muestran el desempeño de las medidas de evaluación en un conjunto de datos con $p = 2$ variables y una estructura de grupo muy bien definida (ver Figura 6.7). En la práctica, las medidas de validación pueden presentar resultados contradictorios.

La Figura 6.14 presenta los resultados de 100 simulaciones de las mediciones de validación en el conjunto de datos Pima Indian Diabetes, que tiene variables $p = 8$. En este caso las medidas CH y XB indican una estructura con grupos $K = 3$ al presentar los mejores valores de índice y la menor dispersión. Los resultados de los índices PBM y SW no son concluyentes con respecto al número de grupos, pero la agrupación con grupos $K = 3$ también genera la menor dispersión de estas medidas.

Tenga en cuenta que el conjunto de datos de India Diabetes es un problema de clasificación con clases $m = 2$, pero está desequilibrado con el 65 % de los registros en una de las clases. Este ejemplo muestra que la estructura de grupo presente en los datos no siempre corresponde a las clases de problemas.




Figura 6.13: Resultados de las medidas de validación: (a) CH; (b) gestión de residuos públicos; (c) S

Incluso un algoritmo simple como k-means implica un alto costo computacional cuando se ejecuta con diferentes inicializaciones y para varios valores del parámetro K , lo que limita el análisis de problemas de grandes dimensiones. Sin embargo, el algoritmo k-means se puede ejecutar en paralelo [58][601] para permitir la búsqueda de la mejor partición utilizando medidas de validación. Modenesi y colaboradores [395]-[397] presentan un enfoque que integra la versión *fuzzy* del algoritmo k-means (cf. Capítulo 8) con el cálculo del índice PBM para evaluar grupos en procesamiento paralelo.

Vendramin, Campello y Hruschka [538] presentaron recientemente un estudio exhaustivo sobre medidas relativas de validación de conglomerados. En el artículo, los autores analizan y comparan 40 índices de validación en 1.080 conjuntos de datos diferentes. El artículo presenta una descripción de las medidas de validación acompañadas de análisis de complejidad asintótica. El análisis experimental se realiza en dos partes: en

en primer lugar, se reproduce el mismo procedimiento utilizado por Milligan y Cooper [388]; en el segundo, se amplía el análisis con conjuntos de datos más grandes, con mayor diversidad en el número de grupos y variables. Los resultados muestran que los índices CH, PBM y SW son los más efectivos para encontrar el número de grupos presentes en un conjunto de datos.




Figura 6.14: Resultados de las medidas de validación: (a) CH; (b) gestión de residuos públicos; (c) S

La validación de conglomerados es un tema recurrente en la literatura y en ella se encuentran varias medidas [592][599]. En general, las medidas se evalúan en conjuntos de datos sintéticos de baja dimensión. La propia característica del problema del análisis de conglomerados hace difícil definir un promedio absoluto para evaluar la mejor solución.

6.6 Aplicaciones

El análisis de conglomerados tiene aplicaciones en varias áreas. En esta sección presentamos dos aplicaciones a problemas reales en trabajos de investigación realizados en Coppe/UFRJ [32][468].

6.6.1 Segmentación de imágenes de satélite

La segmentación de una imagen es la partición de la imagen en regiones representadas por conjuntos de *pixels*. Esencialmente, la segmentación de imágenes es una aplicación de análisis de conglomerados en la que los registros son *pixels* y las variables son características extraídas de ellos.


En esta sección, presentamos una aplicación de segmentación de imágenes para clasificar zonas de inundación en la Amazonía a partir de imágenes satelitales obtenidas por radar de apertura sintética (SAR). Las imágenes SAR son útiles para monitorear los bosques tropicales, ya que son inmunes a la nubosidad. La interpretación de imágenes SAR permite la discriminación de áreas de cobertura vegetal, bosques inundables y cuerpos de agua.

Beisl [32] utilizó imágenes SAR de la región amazónica registradas por el satélite JERS-1 y obtenidas en el proyecto Global Tropical Forest Mapping (GRFM) en dos momentos diferentes: la temporada de inundaciones, capturada en octubre de 1995 (Figura 6.15a), y la estación seca, en mayo de 1996 (Figura 6.15b). Parte de los trabajos se realizaron para determinar el trazado del poliducto Coari-Manaos, de Petrobras.


Beisl cartografió los cambios a lo largo de toda la cuenca del Solimões debido a las variaciones en el ciclo hidrológico del río. El estudio relacionó los patrones de cambio con las características del medio ambiente, que habían sido identificadas en estudios anteriores, para obtener un mapa de la sensibilidad de la región al derrame de petróleo.

Después del preprocesamiento, los *frames* se combinaron para producir las imágenes que se muestran en la Figura 6.15. La imagen cubre gran parte de la cuenca del Solimões, de unos 600 km de longitud, donde Manaus aparece en la parte superior derecha de las imágenes. Las regiones más oscuras indican el reflejo total de la señal del radar e indican masas de agua. Las regiones de color gris más oscuro indican la propagación de la señal a través de la copa de los árboles e indican regiones forestales. Las regiones grises más claras indican regiones de doble

Reflexión, en la que la señal se refleja en el agua, pero parte de la señal regresa después de reflejarse nuevamente en un obstáculo, como árboles, lo que caracteriza a un bosque inundado.



(a)



(b)

Figura 6.15: Imágenes SAR del Amazonas: (a) durante la temporada de inundaciones (o octubre de 1995); (b) en una estación seca (mayo de 1996). Fuente: [32].

En las imágenes SAR, el contenido se presenta en un canal y la imagen está representada por el conjunto de datos $Z = \{z(t) \in \mathcal{R}, t = 1, \dots, N\}$, donde $z(t)$ es el valor de *pixel*. Beisl [32] utilizó una transformación del conjunto de datos Z mediante la función de semivariograma, que relaciona un *pixel* con sus vecinos mediante la relación:

$$x_h(t) = \frac{1}{2n} \sum_{i=1}^n (v_h(t, i) - z(t))^2 \quad (6.43)$$

donde h es un parámetro que regula la extensión de vecindad y n , el número de vecindad *pixels* y $v_h(t, i) = h(t, i)$ una función de vecindad.

La función de vecindad se calcula sobre un círculo de radio h centrado en el *pixel* correspondiente, como se muestra en la Figura 6.16 para $h = 6 \text{ pixels}$.





Figura 6.16: Función de vecindad con $h = 6$.

Las imágenes fueron segmentadas mediante el algoritmo textural de semivariograma no supervisado (USTC), * que utiliza la función de semivariograma como descriptor de textura [390][391]. En el método USTC, la agrupación se realiza mediante el algoritmo ISODATA [27] aplicado al conjunto $\mathcal{T} = \{\mathbf{x}(t), t = 1 \dots N\}$, en el cual el vector de variables tiene dimensión $h + 2$ y los componentes se calculan mediante la función semivariograma (6.43) como $\mathbf{x}(t) = [z(t), x_1(t), \dots, x_h(t), \sigma_h^2(t)]$, incluyendo el valor del píxel central $z(t)$ y $\sigma_h^2(t)$ que es la varianza calculada en la región de la función de vecindad $h(t, i), i = 1 \dots n$.


El resultado obtenido por el algoritmo ISODATA es clasificado por un experto y se definen los grupos para representar un significado temático. Beisl [32] utilizó cuatro clases: agua, vegetación inundada y bosque seco o inundado. El resultado final se muestra en la Figura 6.17, en la que la región en verde representa bosque seco, la región en azul representa cuerpos de agua, la región en amarillo representa bosque inundado y la región en azul claro representa vegetación inundada.

Beisl utiliza el resultado de la clasificación de imágenes obtenida por el método de la USTC para producir mapas de sensibilidad a derrames de petróleo [32]. El trabajo utiliza sistemas *fuzzy* para calcular el índice y los resultados se presentan en el Capítulo 8.

* *Unsupervised Semivariogram Textural Classifier*.



(a)



(b)

Figura 6.17: Resultados de la USTC: (a) en temporada de inundaciones; (b) en tiempos de sequía. Fuente: [32].

6.6.2 Agrupación de documentos

Se estima que el 85% de la información se almacena de forma no estructurada, lo que incluye imágenes, grabaciones y, principalmente, texto. La minería de textos utiliza técnicas de recuperación de información, procesamiento del lenguaje natural y algoritmos de inteligencia computacional para extraer conocimiento de colecciones de documentos. El análisis de conglomerados de una colección de documentos permite determinar los principales temas de la colección y tiene varias aplicaciones, considerando que la mayoría de los documentos no están categorizados.

El enfoque más común para la minería de textos es aplicar un paso de preprocesamiento para transformar la colección de documentos en una tabla de datos para que se puedan aplicar algoritmos de minería de datos [43][178][502]. El preprocesamiento básico incluye eliminar palabras irrelevantes (*stopwords*) y reducirlas al término raíz (*stemming*). Otros pasos más elaborados pueden incluir el tratamiento de la polisemia (diferentes palabras utilizadas con el mismo significado) y la homonimia (mismas palabras con diferentes significados), además de la identificación de frases nominales [437] y otras técnicas de procesamiento del lenguaje natural [294].

Después del preprocesamiento, cada documento se representa como un vector en el que los componentes representan los términos (palabras después del preprocesamiento) presentes en la colección. Esta representación se denomina modelo de espacio vectorial y se utiliza ampliamente en el área de recuperación de información [43][467]. La colección de documentos se transforma así en el conjunto de entrenamiento $\mathcal{T} = \{\mathbf{x}(t), t = 1 \dots N\}$, donde N es el número total de documentos y cada documento está representado por el vector $\mathbf{x}(t) \in \mathcal{R}^p$, donde p es el número total de términos de la colección.

Las coordenadas asociadas con cada documento en el modelo de espacio vectorial se pueden calcular mediante la frecuencia del término en el documento. Por lo general se utiliza el valor denominado *tf-idf*, en el que la frecuencia del término en el documento se pondera por el logaritmo del inverso de la frecuencia del término en la colección, lo que evita que palabras que se citan con frecuencia a lo largo de la colección tengan un peso demasiado alto. Cada coordenada se calcula como:

$$x_i(t) = f_i(t) \log \frac{N}{N_i}, \quad i = 1, \dots, p \quad (6.44)$$

donde $f_i(t)$ es la frecuencia del término i en el documento t y N_i es el número total de apariciones del término i en toda la colección.

La ponderación por el logaritmo de la frecuencia inversa reduce la importancia de los términos que aparecen en muchos documentos de la colección y, por tanto, son menos importantes para diferenciar los documentos entre sí. Existen algunas variantes¹³⁹ a *tf-idf* que pueden presentar resultados en aplicaciones específicas [372].

La representación mediante el modelo de espacio vectorial genera un conjunto de datos de muy alta dimensionalidad. Dependiendo del tema, una colección puede contener miles de términos, lo que puede dificultar el cálculo de la similitud entre documentos. Existen algunos enfoques de reducción de dimensionalidad, el más conocido de los cuales es el índice de

semántica latente (LSI)* [43], cuyo cálculo es similar al análisis de componentes principales (PCA), presentado en la sección 2.4.1.

Santos [468][469] estudió la aplicación de algoritmos de detección de comunidades para agrupar colecciones de documentos. En esta sección reproducimos los resultados obtenidos en el conjunto de resúmenes de tesis y disertaciones del Programa de Ingeniería Civil¹⁴⁰ (PEC) de la Coppe/UFRJ, publicados entre enero de 2004 y diciembre de 2008, totalizando 585 resúmenes. Después del preprocesamiento, la colección quedó representada por un conjunto de 265 términos [468].

La colección de documentos se transformó en un gráfico para aplicar el algoritmo de maximización de modularidad de Newman y Girvan [413]. La similitud entre los registros se utilizó para definir la matriz de adyacencia $\mathbf{A} \in \mathcal{R}^{N \times N}$, cuyos elementos se calcularon como:

$$a_{ij} = \begin{cases} 1, & \text{se } i \neq j \text{ e } \text{sim}(\mathbf{x}(i), \mathbf{x}(j)) > \varepsilon \\ 0, & \text{caso contrário} \end{cases} \quad (6.45)$$

donde la función de similitud $\text{sim}(\mathbf{x}(i), \mathbf{x}(j))$ se calcula mediante el coseno (cf. ecuación (2.13)) y $\varepsilon \in [0,1]$ es un parámetro que determina un umbral de similitud para que dos registros se consideren cercanos.

Cada valor del parámetro ε en la ecuación (6.45) define una gráfica diferente que da como resultado un número diferente de comunidades [413]. La Tabla 6.2 muestra los resultados de modularidad (Q) y número de grupos (K) para diferentes valores de ε en la definición del gráfico [468]. Se eligió el resultado con $\varepsilon = 0.20$ porque el número de grupos generados es coherente con la estructura de las áreas de investigación del PEC. El algoritmo se mejoró mediante un paso de refinamiento que, con cada nueva división, verifica si el resultado de modularidad se puede mejorar cambiando la asignación de cada documento a otro grupo [541]. Con este paso de refinamiento, Santos encontró siete grupos con $\varepsilon = 0.20$ con modularidad $Q = 0.5334$ [468].

El resultado de la agrupación se muestra en la Figura 6.18, generada con el Cytoscape gratuito *software*.¹⁴¹ La figura 6.18 se generó de modo que los vértices similares del gráfico estén más cerca entre sí, lo que representa la cohesión de los grupos.

* *Latent Semantic Index.*

Tabla 6.2: Modularidad para varios valores de ε . Fuente: [468]

ε	Q	K
0.10	0.3232	4
0.15	0.4236	5
0.20	0.4998	6
0.25	0.5468	9
0.30	0.6588	12
0.35	0.7167	13




Figura 6.18: Red de documentos resultante del análisis de conglomerados. Fuente: [468][469].

Se puede obtener una interpretación del resultado de la agrupación observando los términos más importantes de cada grupo. La selección de términos es un caso particular del problema de selección de variables [350][351]. Santos [468] utilizó un enfoque simple, en el que la relevancia de cada término para cada grupo $\mathcal{C}_i$ se calcula como:

$$rel(i, j) = \sum_{t=1}^N x_j(t) u_i(\mathbf{x}(t)) \quad (6.46)$$

donde $u_i(\mathbf{x}(t))$ es la función de pertenencia del documento t al grupo $\mathcal{C}_i$.

Los 10 términos más relevantes para cada grupo según el índice (6.46) se muestran en la Tabla 6.3 [468], en la que los grupos fueron interpretados en relación con las áreas de investigación del PEC. Se observa que la agrupación recuperó temas de las principales áreas de investigación del Programa. El área de Petróleo y Gas se dividió en dos grupos, que representan las dos líneas de investigación más importantes del área: Geoquímica y Geofísica.

Tabla 6.3: Palabras de cada grupo. Fuente: [468]

Grupo	Termos Relevantes	Área de Pesquisa
$\mathcal{C}_1$	elemento, <i>riser</i> , estaca, linha, estrutura, finito, duto, acoplamento, método, contorno	Mecânica Computacional
$\mathcal{C}_2$	concreto, fibra, reforço, viga, agregado, misto, pavimento, resistência, armado, liga	Estrutura e Materiais
$\mathcal{C}_3$	aterro, resíduo, solo, ensaio, contaminar, sólido, geotecnia, rejeitar, argila, liga	Geotecnia / Meio Ambiente
$\mathcal{C}_4$	óleo, geoquímica, migrar, biomarcador, hidrocarboneto, madurar, biodegradável, bacia, amostra, sísmica	Petróleo e Gás (Geoquímica)
$\mathcal{C}_5$	classificação, redes, virtual, texto, dados, <i>fuzzy</i> , mineração, algoritmo, regra, agrupamento	Sistemas Computacionais
$\mathcal{C}_6$	reservatório, poço, fluxo, simulação, petróleo, fluido, produção, estimativa, otimização, rocha	Petróleo e Gás (Geofísica)
$\mathcal{C}_7$	bacia, hídrico, água, recursos, regra, gestão, cobrança, urbano, modelo, cheia	Recursos Hídricos / Meio Ambiente

6.7 Comentarios finales

El problema del análisis de conglomerados es extenso y algunos libros tratan exclusivamente del tema [194][573]. El problema está mal definido, lo que dificulta la formulación de estas dísticas de validación. Hay varios enfoques diferentes, lo que hace muy difícil cubrir completamente el tema.

Los temas incluidos en este capítulo fueron elegidos para que sirvieran como introducción al tema y a los temas que se cubrirán en los siguientes capítulos. El algoritmo k-means y los algoritmos de aglomeración jerárquica presentados, respectivamente, en secciones

6.2 y 6.3 son los enfoques clásicos, presentes en prácticamente todas las *softwares* y librerías. Los algoritmos basados en gráficos, presentados en la sección 6.4, se han utilizado en aplicaciones de procesamiento de imágenes y minería de texto.

La evaluación de agrupaciones depende en gran medida del contexto y, cuando esté disponible, la evaluación de grupos como clases debe hacerse con cuidado, ya que los dos conceptos no siempre son equivalentes. La relación entre clases y grupos dio lugar a métodos llamados clasificación semi-supervisada [8][269][605], en los que se utiliza el conocimiento de la clase de algunos registros para guiar el algoritmo de agrupación. Estos métodos tienen aplicaciones en minería de textos y bioinformática, donde se utiliza una pequeña cantidad de registros anotados para clasificar un conjunto más grande sin anotaciones.

Las aplicaciones de minería de textos y bioinformática han traído nuevos desafíos a los algoritmos de análisis de conglomerados, principalmente debido al problema de la dimensionalidad. En este tipo de aplicaciones, los registros se describen mediante vectores grandes, lo que dificulta el análisis de similitud entre registros, fundamental para la agrupación. En el estudio de caso presentado en la sección 6.6.2, la función coseno se utiliza como métrica de similitud y un algoritmo de detección de comunidad en redes complejas realiza la agrupación de documentos. La combinación de técnicas de minería de datos y textos con análisis de redes complejas también se ha aplicado al análisis de redes sociales [4][376].

Este capítulo representa la transición entre los métodos clásicos y los métodos más avanzados, que se presentarán en los próximos capítulos.