

Capítulo 1 — Introducción

Inteligencia Computacional para Ciencia de Datos

Resumen de estudio

Concepto clave

La **inteligencia computacional** es un conjunto de paradigmas computacionales para el desarrollo y aplicación de sistemas inteligentes en problemas complejos del mundo real. Incluye métodos estadísticos, aprendizaje de máquina, sistemas *fuzzy*, redes neuronales, máquinas de vectores de soporte y algoritmos evolutivos, frecuentemente integrados en abordajes híbridos. La **ciencia de datos** es la disciplina que reúne matemáticas, estadística, computación e ingeniería con el conocimiento del dominio de cada aplicación para extraer modelos y conocimiento a partir de datos.

1 De la inteligencia artificial a la inteligencia computacional

La pregunta filosófica “¿puede pensar una máquina?”, formulada por Wittgenstein en los años 1920 y operacionalizada por Alan Turing en 1950 con el célebre **test de Turing**, marca el inicio de la reflexión sobre el comportamiento inteligente en máquinas. La inteligencia artificial (IA) nace a fines de los 1950 de la integración entre lógica, ciencias de la computación y neurofisiología. Tempranamente se distinguen dos corrientes:

- **Simbolista:** lógicos matemáticos que construyen demostradores de teoremas y, más tarde, *sistemas expertos* basados en reglas y hechos.
- **Conexionista:** investigadores que simulan el procesamiento cerebral mediante neuronas artificiales. El *Perceptrón* de Rosenblatt (1957) es el hito inicial, pero sus limitaciones como clasificador lineal estancan el área.

El redescubrimiento del algoritmo de **retropropagación del error** en 1986 (artículo de Rumelhart, Hinton y Williams en *Nature*) rehabilita los modelos conexionistas y permite el ajuste de redes neuronales multicapa para problemas no lineales complejos, como el reconocimiento de dígitos manuscritos. En las décadas de 1980–1990 surgen nuevos paradigmas: **sistemas fuzzy**, **máquinas de vectores de soporte (SVM)**, **algoritmos genéticos**. Su integración se conoció como *soft computing* o *inteligencia computacional*, hoy englobando también los métodos clásicos de estadística y *machine learning*. A partir de 2012, el éxito de las **redes neuronales profundas** (*deep learning*), ejecutadas sobre GPU, alcanza o supera el desempeño humano en tareas de visión computacional y procesamiento de lenguaje natural.

En paralelo, la explosión de datos digitales (Internet, dispositivos móviles desde 2007, sensores e *Internet of Things*) dio origen al término *big data* (2010) y consolidó el ecosistema actual de la ciencia de datos, dominado por lenguajes abiertos (Python, R) y bibliotecas libres (scikit-learn, Pandas, TensorFlow).

2 Ciencia de datos y proceso de descubrimiento de conocimiento

En el método científico clásico, hipótesis teóricas dan origen a modelos verificados por la observación. La ciencia de datos *invierte parcialmente* ese flujo: el objetivo es inducir modelos

directamente de los datos, en general recolectados sin planificación experimental, y por ende sujetos a ruido, incertidumbre y sesgo muestral. Un modelo es siempre una representación *indirecta* del proceso real, válida sólo en el dominio de la muestra que lo generó.

Concepto clave

KDD — Knowledge Discovery in Databases: proceso cíclico que va desde la selección de datos hasta la interpretación de los modelos, pasando por limpieza, transformación, modelado y validación. Si los objetivos no se alcanzan, se vuelve a etapas anteriores con nuevos datos o herramientas.

Las etapas típicas del proceso son:

- (1) **Selección de datos:** elección del subconjunto y de las variables relevantes (con participación de especialistas del dominio).
- (2) **Pre-procesamiento:** limpieza, tratamiento de valores faltantes, detección de *outliers*, estandarización y transformaciones lineales (Capítulo 2).
- (3) **Modelado:** ajuste de modelos predictivos o descriptivos (Capítulos 3–9).
- (4) **Evaluación:** estadísticas de validación, validación cruzada, comparación entre modelos.
- (5) **Interpretación e implementación:** comunicación de los resultados e integración a la plataforma operacional.

Los términos *minería de datos* y *ciencia de datos* se usan con frecuencia como sinónimos. El autor sugiere la siguiente distinción: *ciencia de datos* se refiere al cuerpo de conocimiento necesario; *minería de datos* al proceso concreto de construir modelos a partir de datos.

3 Modelos: definiciones y taxonomía

Un **modelo** es, en este libro, una representación matemática simplificada de un sistema o proceso real, obtenida a partir de los datos de una muestra. Según la naturaleza del conocimiento empleado se distinguen:

- **Modelos de conocimiento (analíticos):** derivados de las leyes fundamentales de la física o del conocimiento humano formalizado.
- **Modelos de comportamiento (entrada/salida):** inducidos directamente a partir de observaciones; es el caso típico de la ciencia de datos.

Según el objetivo, las aplicaciones se dividen en **predictivas** (con variables de salida a estimar) y **descriptivas** (sin variable-objetivo, se busca una representación de los datos). La taxonomía de algoritmos de aprendizaje es igualmente fundamental:

Paradigma	Idea
Supervisado	Pares $(\mathbf{x}, y)$ disponibles; se ajusta $f : \mathbf{x} \mapsto y$. Incluye regresión y clasificación.
No supervisado	Sólo $\mathbf{x}$; se busca estructura (grupos, reglas de asociación, representación latente).
Semi-supervisado	Pequeña fracción de los datos rotulada; se usa la parte no rotulada para mejorar el modelo.
Por refuerzo	El modelo (agente) interactúa con un ambiente y se ajusta mediante señales de recompensa.

3.1 Regresión

Dadas variables de entrada $\mathbf{x} \in \mathbb{R}^p$ y una salida numérica $y \in \mathbb{R}$, la regresión busca una función

$$\hat{y} = f(\mathbf{x}; \boldsymbol{\theta})$$

cuyo **error de predicción** $e = y - \hat{y}$ se minimice en algún sentido (típicamente cuadrático). En la regresión lineal, $f(\mathbf{x}) = \boldsymbol{\theta}^\top \mathbf{x}$, eventualmente con regresores no lineales (*features*) de las entradas. La precisión del modelo se evalúa en datos de prueba, distintos del conjunto de entrenamiento. Estos tópicos se desarrollan en los Capítulos 3 (regresión lineal) y 4 (series temporales y sistemas dinámicos).

3.2 Clasificación

En la clasificación, o **reconocimiento de patrones**, la salida es una clase $y \in \{C_1, \dots, C_K\}$, generalmente discreta y no ordenada. El clasificador puede verse como una búsqueda de **funciones discriminantes**, lineales o no, que dividen el espacio de entrada en regiones asociadas a cada clase. Se distingue entre clases *linealmente separables*, *separables no linealmente* y *no separables*; en este último caso, el error mínimo (*tasa de Bayes*) es estrictamente positivo. El ejemplo histórico es el conjunto Iris de Fisher (1936), con cuatro variables numéricas y tres clases.

3.3 Análisis de agrupamientos (*clustering*)

Sin variable de salida, se busca particionar los datos en grupos de registros similares. El gran desafío es la **validación**, pues sin rótulos no hay error de clasificación a minimizar; se usan índices que reflejan propiedades geométricas (compacidad intra-cluster, separación inter-cluster) cuya interpretación depende fuertemente del analista y del especialista del dominio. El número de grupos suele ser parámetro de entrada del algoritmo. Las principales abordajes (partición, jerárquicas, espectral) se tratan en el Capítulo 6.

3.4 Otros problemas y técnicas

- **Reglas de asociación:** encuentran co-ocurrencias frecuentes entre ítems (canasta de mercado, sistemas de recomendación).
- **Aprendizaje de la representación:** nuevos métodos no supervisados que producen representaciones latentes útiles para otras tareas (Capítulo 9).
- **Ensembles:** combinación de múltiples modelos para elevar el desempeño predictivo, técnica ganadora en competencias como el Premio Netflix.

4 Recursos: bibliografía, repositorios y software

Referencias teóricas. Hastie, Tibshirani & Friedman (*Elements of Statistical Learning*); Bishop (*Pattern Recognition and Machine Learning*); Duda, Hart & Stork (*Pattern Classification*); Theodoridis & Koutroumbas; Webb. Para temas específicos: Haykin (redes neuronales), Pedrycz & Gomide (*fuzzy*), Schölkopf & Smola (SVM y métodos de núcleo), Vapnik (teoría del aprendizaje estadístico), Goodfellow, Bengio & Courville (*Deep Learning*, 2016). Para minería de datos: Han & Kamber; Tan, Steinbach & Kumar; Aggarwal; Zaki & Meira.

Recursos en línea. Cursos abiertos (Coursera, Stanford, MIT; notablemente el curso de *Machine Learning* de Andrew Ng); el portal KDnuggets (P. Piatetsky-Shapiro); repositorios de datos como el *UCI Machine Learning Repository* y la plataforma de competencias Kaggle. Eventos de referencia: KDD, ICDM, NeurIPS, ICML; en el área de IC, el WCCI (FUZZ-IEEE, IJCNN, IEEE CEC).

Software. El ecosistema se divide en tres capas:

- **Comerciales integrados:** SAS, IBM SPSS Modeler, Statistica; Oracle y Microsoft SQL Server Data Mining (minería dentro de la base de datos); Azure ML, Amazon ML (nube).
- **Libres con interfaz gráfica:** Weka (Waikato, 1997, en Java), RapidMiner, KNIME, Orange (Python/C++).
- **Lenguajes abiertos con bibliotecas:** **Python** (NumPy, SciPy, Pandas, scikit-learn) y **R** son, según las encuestas de KDnuggets, los más utilizados actualmente. **Matlab** sigue fuerte en ingeniería.

5 Comentarios finales

El capítulo introductorio fija el vocabulario y el panorama de la disciplina. Tres ideas deben retenerse para los próximos capítulos:

1. Un modelo de ciencia de datos es **inseparable de la muestra** que lo generó; su validez se limita al dominio muestreado.
2. El proceso KDD es **iterativo**: pre-procesamiento, modelado y validación se retroalimentan hasta alcanzar los objetivos de la aplicación.
3. La inteligencia computacional es **plural**: combina estadística, aprendizaje de máquina, redes neuronales, sistemas *fuzzy* y optimización. La elección del método debe guiarse por el problema, los datos disponibles y la necesidad de interpretabilidad.

Los capítulos siguientes desarrollan este programa: el Capítulo 2 trata el **pre-procesamiento**; los Capítulos 3 y 4, la **regresión** clásica y dinámica; el Capítulo 5, la **clasificación**; el Capítulo 6, el **análisis de agrupamientos**; y los Capítulos 7–9 los modelos no lineales de inteligencia computacional propiamente dichos.