

Capítulo 2 — Pre-procesamiento

Caracterización estadística, limpieza y transformaciones lineales

Resumen de estudio

Concepto clave

El pre-procesamiento abarca la **selección, limpieza y transformación** de los datos, y suele consumir entre 60 % y 80 % del tiempo de un proyecto de minería de datos. Su producto es el *conjunto de entrenamiento*: una matriz $\mathbf{X} \in \mathbb{R}^{N \times p}$ (con eventual matriz de salida $\mathbf{Y} \in \mathbb{R}^{N \times q}$) cuyas variables estén libres de *outliers*, valores faltantes, escalas incompatibles y redundancias graves.

1 Conjuntos de datos y notación

Un conjunto de datos estructurado es una tabla de N registros y p (o $p + q$) variables. Las variables pueden ser *continuas*, *discretas ordenadas* o *categorías (nominales)*; estas últimas se codifican generalmente como variables indicadoras (*dummy*) binarias para que puedan ser procesadas por algoritmos numéricos. El texto adopta la notación:

$$\mathcal{T} = \{(\mathbf{x}(t), \mathbf{y}(t)), t = 1, \dots, N\}, \quad \mathbf{x}(t) \in \mathbb{R}^p, \mathbf{y}(t) \in \mathbb{R}^q,$$

con vectores en minúsculas-negrita, matrices en mayúsculas-negrita, escalares en cursiva, conjuntos en letras caligráficas. Los problemas pueden ser *estáticos* (el orden de los registros es irrelevante), *dinámicos* (series temporales), *georreferenciados* o *espacio-temporales*. El capítulo se concentra en el caso estático.

2 Caracterización estadística

2.1 Análisis univariable

Para cada variable x_i se estiman medidas de centralidad y dispersión:

$$\bar{x}_i = \frac{1}{N} \sum_{t=1}^N x_i(t), \quad \hat{\sigma}_i^2 = \frac{1}{N-1} \sum_{t=1}^N (x_i(t) - \bar{x}_i)^2,$$

además de mínimo, máximo, mediana, percentiles P_{25} y P_{75} (cuartiles Q_1, Q_3), rango intercuartílico ($\text{IRQ} = Q_3 - Q_1$) y moda. La **media** puede ser engañosa en distribuciones asimétricas o con *outliers*; la **mediana** es robusta. La discrepancia entre media y mediana ya sugiere asimetría.

La distribución normal $N(\mu, \sigma^2)$, con densidad

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right),$$

es fundamental: por el *teorema central del límite*, las medias muestrales de procesos estacionarios convergen en distribución a una normal, independientemente de la distribución original. La función gaussiana reaparece como *función de base* en modelos RBF y SVM (Capítulo 7).

El análisis visual emplea **histogramas** (incluyendo histogramas por clase, en problemas de clasificación), **box-plots** y el **gráfico de probabilidad normal** (la linealidad indica normalidad). Histogramas multimodales pueden reflejar mezcla de clases o subpoblaciones.

2.2 Análisis multivariado

La estadística multivariada-clave es la **matriz de covarianzas**

$$\hat{\Sigma} = \frac{1}{N-1} \sum_{t=1}^N (\mathbf{x}(t) - \bar{\mathbf{x}})^\top (\mathbf{x}(t) - \bar{\mathbf{x}}) \in \mathbb{R}^{p \times p},$$

simétrica y definida positiva, con $\hat{\sigma}_{ii}^2 = \hat{\sigma}_i^2$ en la diagonal.

La versión estandarizada es la **matriz de correlación** de Pearson, con elementos

$$\hat{\rho}_{ij} = \frac{\text{Cov}(x_i, x_j)}{\sqrt{\text{Var}(x_i) \text{Var}(x_j)}} \in [-1, 1].$$

Valores absolutos próximos a 1 indican dependencia lineal (redundancia). Importante: $\hat{\rho}_{ij} = 0$ excluye apenas dependencia *lineal*, no relación no lineal. La visualización típica es la *scatter plot matrix*, o, para muchas variables, un mapa de color de la matriz de correlación.

2.3 Distancias y similitudes

Para detectar *outliers*, imputar valores faltantes o hacer *clustering*, se calcula la matriz $\mathbf{D} \in \mathbb{R}^{N \times N}$ con $d_{ij} = \text{dist}(\mathbf{x}(i), \mathbf{x}(j))$. Las principales métricas (*cualesquiera* que satisfagan no negatividad, simetría y desigualdad triangular) son:

Euclidiana (L_2)	$\sqrt{\sum_i (\nu_i - v_i)^2}$
Manhattan (L_1)	$\sum_i \nu_i - v_i $
Chebyshev (L_∞)	$\max_i \nu_i - v_i $
Minkowski (L_r)	$(\sum_i \nu_i - v_i ^r)^{1/r}$
Mahalanobis	$\sqrt{(\boldsymbol{\nu} - \mathbf{v})^\top \hat{\Sigma}^{-1} (\boldsymbol{\nu} - \mathbf{v})}$

Similitudes clásicas: coseno $\text{sin}_C(\boldsymbol{\nu}, \mathbf{v}) = \langle \boldsymbol{\nu}, \mathbf{v} \rangle / (\|\boldsymbol{\nu}\| \|\mathbf{v}\|)$ y gaussiana $\text{sin}_G = \exp(-\|\boldsymbol{\nu} - \mathbf{v}\|^2 / (2\sigma^2))$. La visualización de la matriz de similitudes como *data image* (mapa de calor) revela grupos y *outliers* incluso en alta dimensión.

3 Limpieza de datos

3.1 Estandarización

Min-max: $\hat{x}_i(t) = (x_i(t) - \text{mín}) / (\text{máx} - \text{mín}) \in [0, 1]$. Sensible a *outliers*; sustituir por P_5 y P_{95} si es necesario.

z-score: $\hat{x}_i(t) = (x_i(t) - \bar{x}_i) / \hat{\sigma}_i$. Resulta en media nula y varianza unitaria; más robusto. En distribuciones muy asimétricas conviene aplicar antes la transformación logarítmica $\log(x + c)$.

3.2 Detección de outliers

Dos familias de métodos:

- **Por distribución:** bajo hipótesis de normalidad, rechazar registros fuera de $[\mu - 3\sigma, \mu + 3\sigma]$. Visualmente: *box-plot*, con regla $[Q_1 - 1,5 \text{ IRQ}, Q_3 + 1,5 \text{ IRQ}]$. Actúa *variable a variable*; sólo señala sospechas.
- **Por distancia:** se ordenan las distancias medias $\bar{d}_i = \frac{1}{N} \sum_j d_{ij}$ y se descartan los $P_{out} \%$ registros más alejados (Algoritmo 2.1). Considera todas las variables simultáneamente; costo $\mathcal{O}(N^2)$.

Aplicación

En detección de fraudes o anomalías, los *outliers* **son** el objeto de interés y no deben removerse.

3.3 Valores faltantes

Deben distinguirse del valor cero. Estrategias:

1. **Eliminar** registros (o variables) con valores faltantes — viable cuando la pérdida es pequeña o se concentra en pocas columnas;
2. **Imputar**: sustituir por la media (ingenuo, pierde varianza) o, mejor, por los k -vecinos más próximos (Algoritmo 2.2): para cada registro incompleto, se busca el subespacio de las variables disponibles, se calculan distancias a los registros completos y se imputa la media (eventualmente ponderada por el inverso de la distancia) de los $k \geq 3$ vecinos.

La imputación introduce información artificial; debe medirse el impacto sobre las estadísticas de las variables afectadas.

4 Transformaciones lineales

Una transformación lineal es una matriz $\mathbf{T} : \mathbb{R}^n \rightarrow \mathbb{R}^m$. Cuando $\mathbf{T}$ es *ortogonal* ($\mathbf{T}^\top \mathbf{T} = \mathbf{I}$), la transformación preserva normas y ángulos: se trata de una rotación del espacio.

4.1 Análisis de Componentes Principales (ACP)**Concepto clave**

Encontrar una rotación ortogonal $\mathbf{P}$ tal que las variables transformadas $\mathbf{Z} = \mathbf{XP}$ sean **decorrelacionadas** y ordenadas por varianza decreciente. Las columnas de $\mathbf{P}$ son las *componentes principales* (o autovectores de la matriz de covarianzas).

La diagonalización de la matriz de covarianzas da origen al problema de autovalores

$$\hat{\Sigma} \mathbf{p}_i = \lambda_i \mathbf{p}_i, \quad \hat{\Sigma} \mathbf{P} = \mathbf{P} \Lambda,$$

con $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p)$ y $\lambda_1 \geq \dots \geq \lambda_p \geq 0$. El **cociente de Rayleigh**

$$\lambda_{\max} = \max_{\mathbf{v} \neq 0} \frac{\mathbf{v}^\top \hat{\Sigma} \mathbf{v}}{\mathbf{v}^\top \mathbf{v}}$$

muestra que la primera componente es la **dirección de máxima varianza**; las demás son las direcciones ortogonales subsecuentes de máxima varianza.

La invariancia de la traza bajo rotaciones ortogonales garantiza $\sum_i \hat{\sigma}_i^2 = \sum_i \lambda_i$, de modo que la fracción de varianza explicada por las n primeras componentes es $\sum_{i=1}^n \lambda_i / \sum_{i=1}^p \lambda_i$. Típicamente se elige n tal que esa fracción sea $\geq 85\%$. Se reduce así la dimensionalidad preservando lo esencial de la estructura lineal.

Pre-requisito: centrar/estandarizar las variables (z -scores) antes del cálculo, pues la ACP es sensible a la escala. También supone que los datos sean aproximadamente gaussianos.

4.2 Descomposición en Valores Singulares (SVD)

Para cualquier matriz $\mathbf{A} \in \mathbb{R}^{n \times m}$ existe la factorización

$$\mathbf{A} = \mathbf{U} \mathbf{S} \mathbf{V}^\top,$$

con $\mathbf{U}, \mathbf{V}$ ortogonales y $\mathbf{S}$ diagonal con valores singulares $s_1 \geq \dots \geq s_r \geq 0$. Aplicada a la matriz de datos $\mathbf{X}$, se obtiene $\mathbf{X}^\top \mathbf{X} = \mathbf{V} \mathbf{S}^2 \mathbf{V}^\top$, es decir, $\mathbf{V} = \mathbf{P}$ y $s_i = \sqrt{\lambda_i}$. La SVD permite calcular la ACP sin formar el producto $\mathbf{X}^\top \mathbf{X}$, ganando estabilidad numérica, y tiene aplicaciones propias en *Latent Semantic Indexing* (LSI) y *recuperación de información*.

4.3 Análisis Discriminante Lineal (ADL)

La ACP ignora la variable de salida; en clasificación, la mejor proyección puede *no* ser la de mayor varianza. El ADL (Fisher, 1936) busca la transformación $\mathbf{V}$ que maximiza la separación entre clases minimizando la dispersión intra-clases, vía descomposición de la varianza total

$$\Sigma_T = \Sigma_B + \Sigma_W,$$

en varianza *between* e *within* clases. Se resuelve el problema de autovalor generalizado

$$\Sigma_B \mathbf{V} = \Sigma_W \mathbf{V} \Lambda,$$

generando como máximo $m - 1$ direcciones discriminantes (con m clases). Los datos proyectados son $\mathbf{Z} = \mathbf{X} \mathbf{V}$.

4.4 Análisis de Correlación Canónica (ACC)

Aborda problemas de regresión con dos conjuntos de variables, $\mathbf{X} \in \mathbb{R}^{N \times p}$ e $\mathbf{Y} \in \mathbb{R}^{N \times q}$. Calcula simultáneamente dos transformaciones $\mathbf{U}_x, \mathbf{U}_y$ que maximizan la correlación cruzada entre las variables canónicas $\mathbf{Z}_x = \mathbf{X} \mathbf{U}_x$ y $\mathbf{Z}_y = \mathbf{Y} \mathbf{U}_y$. Algorítmicamente, se factorizan $\mathbf{X} = \mathbf{Q}_x \mathbf{R}_x$ e $\mathbf{Y} = \mathbf{Q}_y \mathbf{R}_y$ (descomposición QR) y se calcula la SVD de $\mathbf{Q}_x^\top \mathbf{Q}_y$; las correlaciones canónicas son los valores singulares.

5 Aplicaciones ilustrativas

Aplicación

Patrones de movilidad urbana: a partir de 2,1 mil millones de registros de llamadas (*Call Detail Records*, CDR) en la Región Metropolitana de Río de Janeiro (2014), fue posible estimar matrices origen–destino e identificar dos patrones claros — viajes *casa-trabajo* (Centro–Zona Sur, picos en días hábiles, simétrico ida/vuelta) y viajes *turísticos* (Zona Sur–Teresópolis, picos en fines de semana y feriados, desfase ida/vuelta).

Aplicación

Validación de sensores por ecuaciones de paridad: en un sistema lineal estático con p sensores y n estados ($p > n$), las columnas de la matriz de componentes principales se descomponen como $\mathbf{P} = [\mathbf{C} \mid \mathbf{W}]$. El vector de paridades $\mathbf{u}(t) = \mathbf{x}(t) \mathbf{W}$, satisfaciendo $\mathbf{C}^\top \mathbf{W} = \mathbf{0}$, se anula en ausencia de fallas e indica direcciones típicas de falla cuando es perturbado. Un umbral $\xi = \sqrt{\sum_{i=n+1}^p \lambda_i}$ acomoda el ruido. Aplicado a la hidroeléctrica de Funil, detectó fallas en extensómetros incluso con muchos valores faltantes.

6 Comentarios finales

1. Invertir tiempo en la **caracterización y visualización** de los datos es la mejor garantía de un modelado exitoso en las etapas siguientes.
2. Las **transformaciones lineales** (ACP, SVD, ADL, ACC) son herramientas universales para reducir dimensionalidad, decorrelacionar variables o alinear la representación con la tarea supervisada. Todas dependen fuertemente de una **estandarización** previa.
3. Los métodos basados en **distancias y similitudes** son lo suficientemente generales para resolver otros problemas (limpieza, *outliers*, imputación) que aparecen repetidamente en el libro.
4. Existen extensiones no lineales de los mismos principios (ICA, LLE, ACP por funciones de núcleo); el capítulo se limita al caso lineal, que es la base obligatoria para los modelos no lineales de los Capítulos 7–9.