

Capítulo 3 — Regresión Lineal

Mínimos cuadrados, regularización y validación de modelos

Resumen de estudio

Concepto clave

La **regresión lineal** ajusta un modelo $\hat{y}(t) = f(\mathbf{x}(t); \boldsymbol{\theta})$ que relaciona variables de entrada $\mathbf{x} \in \mathbb{R}^p$ con una variable de salida numérica $y \in \mathbb{R}$. “Lineal” se refiere a la *linealidad en los parámetros*, no necesariamente en los regresores: el modelo polinomial y las funciones de base también caen en esta categoría. Es el primer modelo a ajustar en cualquier aplicación — simple, barato, interpretable y, en muchos problemas reales, su diferencia frente a un modelo no lineal es inferior al 5 %.

1 El problema de regresión y el modelo lineal

La relación real $y = f(\mathbf{x})$ es desconocida; se observan pares $(\mathbf{x}(t), y(t))$ contaminados por ruido. El modelo aproxima esa relación por

$$\hat{y}(t) = \hat{\mathbf{x}}(t) \boldsymbol{\theta}^\top = \sum_{i=1}^n \hat{x}_i(t) \theta_i,$$

donde $\hat{\mathbf{x}}(t) \in \mathbb{R}^n$ es el vector de **regresores** y $\boldsymbol{\theta} = (\theta_1, \dots, \theta_n)$ los parámetros.

Casos típicos:

- **Lineal simple (1^{er} orden):** $\hat{\mathbf{x}} = [1, \mathbf{x}]$, el modelo es un hiperplano, $n = p + 1$.
- **Polinomial de grado r :** $\hat{\mathbf{x}} = [1, \mathbf{x}, \mathbf{x}^2, \dots, \mathbf{x}^r]$, $n = rp + 1$ despreciando términos cruzados.
- **Funciones de base $h_i(\mathbf{x})$:** permiten cualquier no linealidad fija en las entradas, manteniendo el ajuste lineal en los θ_i (Capítulo 7).

El residuo en el registro t es $e(t) = y(t) - \hat{y}(t)$. El *overfitting* (sobreajuste) ocurre cuando la complejidad del modelo excede lo que la muestra soporta: el modelo pasa a representar el ruido. La Figura 3.4 del libro muestra cómo un polinomio de grado 10 ajustado a $N = 20$ puntos generados por $y = x^2 + \varepsilon$ adquiere parámetros de magnitud absurda (hasta ~ 130) y pierde capacidad de generalización.

2 Método de Mínimos Cuadrados (MMC)

La función de evaluación clásica es el **error cuadrático medio**

$$\text{ECM}(\boldsymbol{\theta}) = \frac{1}{N} \sum_{t=1}^N (y(t) - \hat{y}(t))^2 = \frac{1}{N} (\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}^\top)^\top (\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}^\top).$$

Bajo la hipótesis de residuos con distribución normal, media nula y varianza constante (estacionariedad), **minimizar el ECM equivale a maximizar la verosimilitud**; el MMC entrega parámetros de mínima varianza (Gauss–Markov).

Anulando $\partial \text{ECM} / \partial \boldsymbol{\theta} = -\frac{2}{N} \hat{\mathbf{X}}^\top (\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}^\top)$ se llega a las **ecuaciones normales**

$$\hat{\mathbf{X}}^\top \hat{\mathbf{X}} \boldsymbol{\theta}^\top = \hat{\mathbf{X}}^\top \mathbf{Y}, \implies \boldsymbol{\theta}^* = (\hat{\mathbf{X}}^\top \hat{\mathbf{X}})^{-1} \hat{\mathbf{X}}^\top \mathbf{Y},$$

con matriz pseudoinversa $\hat{\mathbf{X}}^+ = (\hat{\mathbf{X}}^\top \hat{\mathbf{X}})^{-1} \hat{\mathbf{X}}^\top$ y matriz sombrero $\mathbf{H} = \hat{\mathbf{X}} \hat{\mathbf{X}}^+$ tal que $\hat{\mathbf{Y}} = \mathbf{H} \mathbf{Y}$.

2.1 Interpretación geométrica

Cada columna de $\hat{\mathbf{X}}$ es un vector en $\mathbb{R}^N$; las n columnas generan un *subespacio del modelo*. El MMC **proyecta ortogonalmente** $\mathbf{Y}$ sobre ese subespacio, dejando el residuo ortogonal al modelo:

$$\hat{\mathbf{Y}}^\top (\mathbf{Y} - \hat{\mathbf{X}} \boldsymbol{\theta}^*) = \mathbf{0}.$$

Consecuencia: la dimensión del modelo debe cumplir $n < N$, en caso contrario el modelo es más complejo que la muestra. La **maldición de la dimensionalidad** (Bellman) hace que, en alta dimensión, el número de muestras necesarias para una cobertura razonable crezca exponencialmente.

3 Sesgo, varianza y regularización

3.1 Descomposición sesgo-varianza

Para una entrada fija $\mathbf{x}$ con valor real $y_r = \mathbb{E}(y)$,

$$\mathbb{E}((y_r - \hat{y})^2) = \underbrace{(y_r - \mathbb{E}(\hat{y}))^2}_{\text{sesgo}^2} + \underbrace{\mathbb{E}((\hat{y} - \mathbb{E}(\hat{y}))^2)}_{\text{varianza}}.$$

- Modelo **demasiado simple**: *sesgo alto*, *varianza baja* (*underfitting*).
- Modelo **demasiado complejo para la muestra**: *sesgo bajo*, *varianza alta* (*overfitting*).

La regularización busca **cambiar un poco de sesgo por mucha reducción de varianza**, mejorando el error esperado.

3.2 Regularización de Tikhonov (*ridge regression*)

Se penaliza la norma del vector de parámetros minimizando

$$\text{ECMR}(\mu, \boldsymbol{\theta}) = \frac{1}{N} \|\mathbf{Y} - \hat{\mathbf{X}} \boldsymbol{\theta}^\top\|^2 + \mu \|\boldsymbol{\theta}\|^2, \quad \mu \geq 0.$$

La solución es $\boldsymbol{\theta}_\mu^* = (\hat{\mathbf{X}}^\top \hat{\mathbf{X}} + \mu \mathbf{I})^{-1} \hat{\mathbf{X}}^\top \mathbf{Y}$.

El efecto es **numérico**: el número de condición de la matriz de los coeficientes cambia de $\kappa = \lambda_{\text{máx}}/\lambda_{\text{mín}}$ a $(\lambda_{\text{máx}} + \mu)/(\lambda_{\text{mín}} + \mu)$, garantizando estabilidad incluso cuando $\hat{\mathbf{X}}^\top \hat{\mathbf{X}}$ es singular o casi singular (regresores muy correlacionados). Hoerl, Kennard y Baldwin sugieren $\mu = \frac{n}{N-n} \|\mathbf{Y} - \hat{\mathbf{X}} \boldsymbol{\theta}^\top\|^2 / \|\boldsymbol{\theta}\|^2$.

3.3 Regularización por componentes principales

Si $\hat{\mathbf{X}} = \mathbf{U} \mathbf{S} \mathbf{V}^\top$ es la SVD,

$$\boldsymbol{\theta}_r^* = \sum_{i=1}^r \frac{\mathbf{u}_i^\top \mathbf{Y}}{s_i} \mathbf{v}_i, \quad r \leq \text{rank}(\hat{\mathbf{X}}).$$

Truncar en los r mayores valores singulares **descarta las direcciones inestables** (asociadas a s_i minúsculos), produciendo una solución de menor norma y mejor condicionada. Equivale a aplicar el MMC sólo en las componentes principales de la matriz de regresores.

4 Validación de modelos

4.1 Estadísticas sobre el residuo

La descomposición $SST = SSR + SSR_{\text{res}}$ separa variabilidad total, explicada y residual. Se definen:

$$\begin{aligned} R^2 &= 1 - \frac{SSR_{\text{res}}}{SST} = 1 - \frac{\sum (y(t) - \hat{y}(t))^2}{\sum (y(t) - \bar{y})^2}, \\ \text{RMS} &= \sqrt{\frac{1}{N} \sum e^2(t)}, \\ \text{MAE} &= \frac{1}{N} \sum |e(t)|, \\ \text{MAPE} &= \frac{1}{N} \sum |e(t)/y(t)|, \\ \rho_{y\hat{y}} &= \text{Corr}(y, \hat{y}). \end{aligned}$$

$R^2 \approx 1$ es deseable; $R^2 \leq 0$ indica que el modelo es peor que la media. Para variables con gran amplitud, usar $R^2_{\log}$.

La **varianza de los residuos** se estima por $\hat{\sigma}^2 = \frac{1}{N-n} \sum e^2(t)$ (denominador $N - n$ por grados de libertad). Bajo normalidad, intervalo de confianza al 95 % para la predicción en $\hat{\mathbf{x}}_0$:

$$\hat{y}_0 \pm 2\sqrt{\hat{\sigma}^2 \hat{\mathbf{x}}_0^\top (\hat{\mathbf{X}}^\top \hat{\mathbf{X}})^{-1} \hat{\mathbf{x}}_0}.$$

La normalidad de los residuos se diagnostica por histograma y gráfico de probabilidad normal.

4.2 Validación cruzada

Calcular las estadísticas en el propio conjunto de entrenamiento favorece modelos con *overfitting*. Criterios penalizados como AIC y BIC ayudan pero no siempre aciertan. La solución práctica es la **validación cruzada de K ciclos** (Algoritmo 3.1):

1. Particionar $\mathcal{T}$ en K subconjuntos aproximadamente iguales.
2. Para cada $i = 1, \dots, K$: ajustar el modelo en $\mathcal{T} \setminus \mathcal{T}_i$ y evaluar en $\mathcal{T}_i$.
3. Concatenar las predicciones $\hat{\mathbf{Y}}_i$ y calcular las estadísticas globales.

Casos especiales: *leave-one-out* ($K = N$) es el estimador más preciso pero el más caro y sensible a la muestra; valores típicos $K = 5$ o $K = 10$ ofrecen buen compromiso.

5 Aplicaciones

Aplicación

Pollution (contaminación del aire y mortalidad, EE.UU., 1959–1961, 60 registros, 15 variables). La eliminación de *outliers* (12 %) eleva R^2 de 0,41 a 0,60. La regularización de Tikhonov con $\mu = 0,01$ sobre los datos sin *outliers* produce el mejor modelo: $R^2 = 0,61$, $\text{RMS} = 0,206$, $\text{MAPE} = 18,5\%$. La combinación “eliminación de *outliers* + regularización” confirma la intuición de la descomposición sesgo-varianza.

Aplicación

Elevación adiabática de temperatura del hormigón (Eletrobrás Furnas, 136 registros, 14 entradas físico-químicas, 3 salidas paramétricas). La variable y_1 (temperatura final) es la más fácil ($R^2 = 0,78$); y_3 es la más difícil ($R^2 = 0,39$). La regularización mejora ligeramente todos los indicadores. El problema es intrínsecamente no lineal; modelos basados en redes

neuronales y sistemas *fuzzy* (Capítulos 8–9) entregan predicciones más precisas.

6 Comentarios finales

1. Modelar es **elegir**: estructura $\rightarrow$ ajuste de parámetros $\rightarrow$ validación. La elección de la estructura es la etapa de mayor impacto.
2. El MMC es elegante y óptimo bajo sus hipótesis, pero inestable cuando n es grande comparado con N ; la **regularización** (Tikhonov o componentes principales) es la defensa estándar.
3. Siempre validar en datos **no vistos** (validación cruzada). Las estadísticas sobre el conjunto de entrenamiento pueden enmascarar *overfitting*.
4. La eliminación de *outliers* puede mejorar mucho el ajuste, pero debe aplicarse con cautela: se descartan justamente los registros más difíciles.
5. El capítulo siguiente (4) extiende este arsenal a las *series temporales* y los *sistemas dinámicos lineales* (AR, MA, ARMA, ARX, ARMAX, OE, Box & Jenkins, ecuaciones de estado).