

# Capítulo 5 — Clasificación

## Decisión bayesiana, modelos lineales y evaluación de clasificadores

Resumen de estudio

### Concepto clave

La **clasificación supervisada** construye un modelo capaz de predecir la clase correcta  $C_j$  de un registro a partir de su vector de variables de entrada  $\mathbf{x} \in \mathbb{R}^p$ . El clasificador particiona (implícita o explícitamente) el espacio de entrada en regiones asociadas a las clases; la frontera entre regiones es la *superficie de decisión*. Los errores aparecen cuando registros próximos pertenecen a clases distintas (ruido, variables no observadas, solapamiento intrínseco). El capítulo formaliza la clasificación a partir de la **teoría bayesiana de decisión** y muestra cómo derivar, desde este marco, modelos lineales (mínimos cuadrados, regresión logística).

## 1 Clasificación Bayesiana

### 1.1 Decisión bayesiana

El Teorema de Bayes relaciona la *probabilidad a posteriori* con la *distribución condicional* y la *probabilidad a priori*:

$$P(C_i | \mathbf{x}) = \frac{p(\mathbf{x} | C_i) P(C_i)}{p(\mathbf{x})}, \quad p(\mathbf{x}) = \sum_{i=1}^m p(\mathbf{x} | C_i) P(C_i).$$

Interpretación: el conocimiento del problema (probabilidad condicional) es *invertido* por la observación  $\mathbf{x}$  — razonamiento abductivo.

**Decisión por mínimo error.** Se asigna  $\mathbf{x}$  a la clase de mayor posteriori. Las regiones  $\mathcal{R}_i = \{\mathbf{x} : P(C_i | \mathbf{x}) \geq P(C_j | \mathbf{x}) \forall j\}$  **minimizan** la probabilidad de error  $P(E) = \sum_i \int_{\mathcal{R}_j} p(\mathbf{x} | C_i) P(C_i) d\mathbf{x}$ . En el punto de frontera:  $p(\mathbf{x} | C_1)/p(\mathbf{x} | C_2) = P(C_2)/P(C_1)$  — la clase más frecuente “empuja” la frontera contra la menos frecuente.

**Decisión por mínimo riesgo condicional.** Cuando los errores tienen costos  $\lambda_{ij}$  asimétricos (p.ej., diagnóstico de enfermedad grave: un falso negativo es mucho peor que un falso positivo),

$$R(C_i | \mathbf{x}) = \sum_j \lambda_{ij} P(C_j | \mathbf{x}),$$

y se decide por el *menor riesgo*. En problemas desbalanceados, los costos pueden usarse para compensar la frecuencia de las clases.

### 1.2 Clasificador bayesiano simple (naïve Bayes)

Asume **independencia condicional** entre las variables dada la clase:

$$p(\mathbf{x}(t) | C_j) = \prod_{i=1}^p p(x_i(t) | C_j), \quad \text{usualmente } p(x_i | C_j) \sim N(\hat{\mu}_{ij}, \hat{\sigma}_{ij}^2).$$

Se estiman apenas  $2p$  parámetros por clase (vs.  $p + p(p + 1)/2$  de la normal multivariada). Ajuste muy rápido, lidia bien con variables numéricas y categóricas mezcladas, tolerante a valores faltantes.

**Limitación:** no captura correlaciones. Cuando las clases son linealmente separables y las variables están poco correlacionadas, el desempeño es bueno (Figura 5.5). En problemas *no* linealmente separables con fuerte correlación intra-clase, el clasificador falla (Figura 5.6); aplicar ACP previamente puede decorrelacionar y salvar el modelo (Figura 5.7).

Aplicaciones típicas: clasificación de documentos, filtros de *spam*, análisis de sentimientos, componente en *ensembles*.

### 1.3 Clasificador bayesiano cuadrático

Adopta  $p(\mathbf{x} \mid C_i) = N(\hat{\boldsymbol{\mu}}_i, \hat{\boldsymbol{\Sigma}}_i)$  multivariada **sin** hipótesis de independencia. La función discriminante es

$$g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \hat{\boldsymbol{\mu}}_i)\hat{\boldsymbol{\Sigma}}_i^{-1}(\mathbf{x} - \hat{\boldsymbol{\mu}}_i)^\top - \frac{1}{2}\ln|\hat{\boldsymbol{\Sigma}}_i| + \ln P(C_i),$$

dominada por término cuadrático: *superficies de decisión cuadráticas* (cónicas). Cuando  $\hat{\boldsymbol{\Sigma}}_i = \hat{\boldsymbol{\Sigma}}$  para todas las clases, el término cuadrático es común y el clasificador se vuelve **lineal**:

$$g_i(\mathbf{x}) = \hat{\mathbf{x}} \boldsymbol{\theta}_i^\top, \quad \boldsymbol{\theta}_{i,1} = \hat{\boldsymbol{\Sigma}}^{-1} \hat{\boldsymbol{\mu}}_i^\top.$$

En alta dimensión con pocos registros, es prudente reducir dimensionalidad (ACP/ADL) antes de estimar las covarianzas — por ejemplo, en *Wine* (13 variables, 178 registros), el ADL reduce a 2 variables ( $m - 1 = 2$ ) y estabiliza el ajuste.

## 2 Modelos Lineales de Clasificación

### 2.1 Mínimos cuadrados (MMC)

Se define la **variable indicadora bipolar**  $v_i(t) = +1$  si  $y(t) = i$ ,  $-1$  en caso contrario. El modelo lineal estima  $\hat{v}_i(t) = \hat{\mathbf{x}}(t)\boldsymbol{\theta}_i^\top$  minimizando el ECM:

$$\boldsymbol{\theta}_i^* = (\hat{\mathbf{X}}^\top \hat{\mathbf{X}})^{-1} \hat{\mathbf{X}}^\top \mathbf{V}_i.$$

Toda la maquinaria del Capítulo 3 (regularización de Tikhonov, PCA, sesgo-varianza) se aplica directamente. El modelo lineal de grado 1 genera frontera hiperplana; grado 2, frontera cuadrática.

### 2.2 Mínimos cuadrados ponderados (MMCP)

Se atribuye peso  $w(t)$  a cada registro:

$$\boldsymbol{\theta}_i^* = (\hat{\mathbf{X}}^\top \mathbf{W} \hat{\mathbf{X}})^{-1} \hat{\mathbf{X}}^\top \mathbf{W} \mathbf{V}_i, \quad \mathbf{W} = \text{diag}(\mathbf{w}).$$

Para neutralizar el desbalanceo, se sugiere  $w(t) = 1 - N_i/N$  para  $\mathbf{x}(t) \in C_i$  (peso inverso a la frecuencia). Equivale, en la visión bayesiana, a remover la influencia de la *priori*  $P(C_i)$ . Resultado: error global mayor, pero mejor recuperación de la clase minoritaria.

### 2.3 Regresión logística

La función discriminante es la **sigmoide** aplicada al modelo lineal:

$$g(\mathbf{x}, \boldsymbol{\theta}) = \frac{1}{1 + \exp(-\hat{\mathbf{x}} \boldsymbol{\theta}^\top)} \approx P(C \mid \mathbf{x}),$$

lo que devuelve una *interpretación probabilística*. Modelando  $P(v = 1 \mid \mathbf{x})$  como Bernoulli, la verosimilitud es

$$L(\boldsymbol{\theta}) = \prod_{t=1}^N \hat{v}(t)^{v(t)} (1 - \hat{v}(t))^{1-v(t)},$$

y el ajuste minimiza la **log-verosimilitud negativa** (entropía cruzada binaria):

$$\ell(\boldsymbol{\theta}) = - \sum_{t=1}^N [v(t) \log \hat{v}(t) + (1 - v(t)) \log(1 - \hat{v}(t))].$$

Como  $\boldsymbol{\theta}$  aparece no linealmente, se resuelve por Newton–Raphson (algoritmo IRLS, *iteratively reweighted least squares*) o por gradiente. La extensión multiclase es la **regresión softmax** (Capítulo 9).

### 3 Evaluación de Clasificadores

#### 3.1 Estadísticas a partir de la matriz de confusión

|       | $\hat{C}_1$ | $\hat{C}_2$ | total |
|-------|-------------|-------------|-------|
| $C_1$ | VP          | FN          | $N_1$ |
| $C_2$ | FP          | VN          | $N_2$ |
| total | $\hat{N}_1$ | $\hat{N}_2$ | $N$   |

- **Exactitud:**  $\text{ACC} = (\text{VP} + \text{VN})/N$ .
- **Error:**  $\text{ERR} = 1 - \text{ACC}$ .
- **Precisión**  $\text{PRE}(C_1) = \text{VP}/(\text{VP} + \text{FP})$ : confiabilidad de una predicción positiva.
- **Recall/sensibilidad**  $\text{REC}(C_1) = \text{VP}/(\text{VP} + \text{FN})$ : proporción de positivos reales capturados.
- **Medida F:**  $F(C_i) = 2 \text{PRE} \cdot \text{REC}/(\text{PRE} + \text{REC})$  — media armónica.
- **Estadística kappa**  $\kappa = (\text{ACC} - P(E))/(1 - P(E))$ , con  $P(E) = P(C_1)P(\hat{C}_1) + P(C_2)P(\hat{C}_2)$ . Mide acuerdo por encima del esperado por azar ( $\kappa \geq 0,8$  excelente,  $0,6\text{--}0,8$  razonable,  $\leq 0$  peor que aleatorio).

#### 3.2 Espacio ROC y AUC

Ejes:  $\text{TFP} = \text{FP}/(\text{FP} + \text{VN})$  y  $\text{TVP} = \text{REC}(C_1)$ . El punto  $(0, 1)$  es el clasificador ideal; la diagonal corresponde a  $\kappa = 0$ . El **área bajo la curva ROC** (resumida en un único punto) es

$$\text{AUC} = \frac{\text{REC}(C_1) + \text{REC}(C_2)}{2}.$$

Para múltiples clases, ponderar por las *prioris*:  $\text{AUC} = \sum_i \text{AUC}(C_i)P(C_i)$ . La AUC es la métrica recomendada en problemas *desbalanceados*, pues la exactitud tiende a favorecer la clase mayoritaria.

### 4 Aplicaciones

**Aplicación**

**Benchmarks UCI** (10 conjuntos: Iris, Balance, Diabetes Pima, Cancer, Statlog Heart, Wine, Parkinson, Ionosphere, Spambase, Sonar). Comparados Bayes Naïve, Bayes Cuadrático, regresión logística, modelo lineal de 1<sup>er</sup> y 2<sup>do</sup> orden en validación cruzada de 10 ciclos. El **modelo lineal de 2<sup>do</sup> orden** (M. Lin. 2) obtiene el mejor *ranking* por el test no paramétrico de Friedman *aligned rank* ( $p \approx 0,08$  tanto en ACC como en AUC), confirmando que el MMC es más robusto que la estimación de parámetros del clasificador bayesiano en conjuntos pequeños.

**Aplicación**

**Análisis de *churn* en telefonía** (Cister, 2007). Base con 1 141 clientes corporativos de alto valor, 6 meses de consumo medio ( $x_1, \dots, x_6$ ). Sólo el 7,17 % canceló (clase  $C_2$ , *minoritaria y más relevante*). **Sin ponderación**, el modelo bayesiano simple alcanza  $ACC = 92,82\%$  pero  $AUC = 0,51$  — prácticamente aleatorio, pues acierta todo en la clase mayoritaria. **Con ponderación** por el complemento de la *priori*, ACC baja pero AUC sube a 0,79–0,89, recuperando la clase de cancelaciones. Lección: en problemas altamente desbalanceados, ACC *engaña*; usar AUC y *recall* de la clase minoritaria.

## 5 Comentarios finales

1. La regla de Bayes es el esqueleto conceptual de la clasificación: aunque el clasificador final no sea explícitamente bayesiano, los efectos de la *priori* y de la distribución condicional impregnan cualquier modelo ajustado por minimización del error.
2. En general, **estimar la función discriminante** (modelos lineales, logística, SVM, redes neuronales) es más fácil que estimar las distribuciones condicionales completas en alta dimensión.
3. La **validación cruzada** y la elección cuidadosa de métricas (AUC,  $\kappa$ , F) son indispensables en problemas desbalanceados.
4. Tópicos correlativos no cubiertos: árboles de decisión (Quinlan), redes bayesianas (Koller & Friedman), SVM (Vapnik) y redes neuronales profundas — éstas tratadas en los Capítulos 7, 8 y 9.
5. Para el desbalance, además de ponderar registros, hay técnicas de **re-muestreo** como el algoritmo SMOTE, muy eficaz en conjunto con árboles de decisión.