

Capítulo 6 — Análisis de Agrupamientos

Particionales, jerárquicos, espectrales y validación

Resumen de estudio

Concepto clave

El **análisis de agrupamientos** (*clustering*) divide el conjunto de datos $\mathcal{T} = \{\mathbf{x}(t)\}_{t=1}^N$ en K subconjuntos disjuntos $\mathcal{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$, de modo que los registros del mismo grupo sean *similares entre sí* y *disímiles* respecto de los demás grupos. Es un problema **no supervisado**: no hay variable-objetivo, lo que hace intrínsecamente difícil su evaluación. Incluso un conjunto pequeño admite una explosión combinatoria de particiones ($N = 100$ registros en dos grupos de 50 producen $\sim 10^{29}$ particiones), y la “mejor” partición depende siempre del contexto de la aplicación.

1 El problema

Una partición satisface $\bigcup_i \mathcal{C}_i = \mathcal{T}$ y $\mathcal{C}_i \cap \mathcal{C}_j = \emptyset$ para $i \neq j$. La **forma de los grupos** la determina la métrica de distancia elegida (Figura 6.3): la Euclidiana (L_2) genera esferas; la Mahalanobis, elipsoides; Manhattan (L_1) y L_∞ , hipercubos. Los grupos *convexos* (separables por hiperplanos) los obtienen métodos particionales simples; los grupos *no convexos* requieren métodos jerárquicos del tipo *single-link* o métodos espectrales.

Atención: los grupos hallados *no* tienen por qué coincidir con clases pre-existentes. “Clasificación no supervisada” es una metáfora útil pero peligrosa.

2 Métodos de partición: k -medias

Se minimiza la suma de distancias cuadráticas a los centros:

$$J(\mathbf{\Omega}) = \sum_{t=1}^N \sum_{i=1}^K u_i(\mathbf{x}(t)) \|\mathbf{x}(t) - \boldsymbol{\omega}_i\|^2, \quad \boldsymbol{\omega}_i = \frac{1}{\hat{N}_i} \sum_{\mathbf{x}(t) \in \mathcal{C}_i} \mathbf{x}(t),$$

con $u_i(\mathbf{x}) = 1$ si $\mathbf{x} \in \mathcal{C}_i$, 0 en caso contrario. Esto equivale a minimizar $\text{tr}(\mathbf{\Sigma}_W)$ y, como $\mathbf{\Sigma}_T = \mathbf{\Sigma}_W + \mathbf{\Sigma}_B$ es constante, **maximizar simultáneamente** $\text{tr}(\mathbf{\Sigma}_B)$ — es decir, grupos compactos y bien separados.

Algoritmo (Lloyd/MacQueen).

1. Inicializar $\mathbf{\Omega} = [\boldsymbol{\omega}_1, \dots, \boldsymbol{\omega}_K]$ (aleatorio, *k-means++*, PCA-Part, CCIA...).
2. Asignar cada $\mathbf{x}(t)$ al centro más próximo ($\arg \min_j \|\mathbf{x}(t) - \boldsymbol{\omega}_j\|$).
3. Recalcular cada centro como media de los registros asignados.
4. Iterar hasta $\|\mathbf{\Omega} - \mathbf{\Omega}_0\| < \text{tol}$.

Complejidad $O(NKp)$ por iteración; muy eficiente cuando $Kp \ll N$.

Limitaciones. Problema NP-difícil, heurística *voraz*: cae en mínimos locales. Sensible a (i) inicialización, (ii) presencia de *outliers*, (iii) grupos de tamaños desiguales o no convexos. Cuando el número de grupos coincide con la estructura real, las inicializaciones convergen a la misma solución; cuando no, soluciones distintas en cada ejecución indican que K está mal elegido.

Variantes. ISODATA (ajusta K automáticamente), k -medoids/PAM/CLARA/CLARANS (centro = registro real, robusto a *outliers*), k -medians, x -means (escoge K por AIC/BIC), k -medias esférico (similitud del coseno, alta dimensión), *fuzzy c*-medias (Capítulo 8).

3 Métodos jerárquicos

Construyen una cadena de particiones $\mathbb{C}_0 \subseteq \mathbb{C}_1 \subseteq \dots \subseteq \mathbb{C}_{N-1}$ visualizada como árbol binario (**dendrograma**). Los **aglomerativos** (más comunes) inician con N *singletons* y fusionan el par más próximo; los **divisivos** hacen el camino inverso.

La función de **ligadura** entre grupos define el resultado:

- *Single-link* (vecino más próximo): $L_{\min}(\mathcal{C}_i, \mathcal{C}_j) = \min \text{dist}(\nu, \nu)$ — captura grupos no convexos, sensible a “cadenas”.
- *Complete-link* (vecino más lejano): $L_{\max} = \max \text{dist}$ — grupos compactos.
- *UPGMA* (promedio): $L_{\text{med}} = \frac{1}{|\mathcal{C}_i||\mathcal{C}_j|} \sum \sum \text{dist}$.
- *UPGMC* (centroides): $L_{\text{cen}} = \text{dist}(\bar{\nu}, \bar{\nu})$.
- *Ward*: minimiza la varianza intragrupos en cada fusión.

El número adecuado de grupos se estima por la mayor distancia entre dos niveles sucesivos del dendrograma. Costo de memoria $O(N^2)$ por la matriz de distancias — inviable para N muy grande.

4 Particionamiento de grafos y métodos espectrales

Se representa $\mathcal{T}$ como grafo $G(\mathcal{V}, \mathcal{E})$ con $\mathcal{V} \equiv \mathcal{T}$ y matriz de adyacencias $\mathbf{A}$ ponderada por la similitud. Función usual: gaussiana $\text{sim}_G(\mathbf{x}(i), \mathbf{x}(j)) = \exp(-\|\mathbf{x}(i) - \mathbf{x}(j)\|^2/2\sigma^2)$ o coseno (texto).

Corte mínimo. Para partición $\{\mathcal{C}_1, \mathcal{C}_2\}$, $\text{cut}(\mathcal{C}_1, \mathcal{C}_2) = \frac{1}{2} \sum_{i,j} a_{ij} u_1(i) u_2(j)$. Solución trivial: aislar el vértice de menor grado (*outlier*). El **corte normalizado de Shi–Malik** corrige:

$$N_{\text{cut}} = \frac{\text{cut}(\mathcal{C}_1, \mathcal{C}_2)}{\text{cut}(\mathcal{C}_1, \mathcal{V})} + \frac{\text{cut}(\mathcal{C}_2, \mathcal{C}_1)}{\text{cut}(\mathcal{C}_2, \mathcal{V})}.$$

Laplaciano. $\mathbf{L} = \mathbf{D} - \mathbf{A}$ con $\mathbf{D} = \text{diag}(d_1, \dots, d_N)$, $d_i = \sum_j a_{ij}$. Es semi-definido positivo; tiene autovalor $\lambda_1 = 0$ con multiplicidad igual al número de componentes conexas. El segundo autovector (*Fiedler*) revela el mejor corte.

Algoritmo de agrupamiento espectral.

1. Construir $\mathbf{A}$ con la función de similitud.
2. Calcular un laplaciano: $\mathbf{L} = \mathbf{D} - \mathbf{A}$ (corte mínimo), generalizado $\mathbf{LW} = \mathbf{DWA}$ (Shi–Malik), o $\hat{\mathbf{A}} = \mathbf{D}^{-1/2} \mathbf{A} \mathbf{D}^{-1/2}$ (Ng–Jordan–Weiss).
3. Descomposición espectral; tomar los K autovectores asociados a los K menores autovalores (o K mayores en NJW).

4. Aplicar k -medias a la matriz $\mathbf{Z}$ formada por esos autovectores (en NJW, normalizar cada fila).

La transformación no lineal (similitud gaussiana) permite separar grupos no convexos en el espacio original. La inicialización del k -medias se vuelve determinista (matriz identidad). Costo dominado por $O(N^3)$ de la descomposición.

Modularidad (Newman–Girvan). Mide cuánto se aleja la partición de la esperada en una red aleatoria:

$$Q = \frac{1}{2E} \sum_{ij} \left(a_{ij} - \frac{d_i d_j}{2E} \right) \mathbf{u}_i \mathbf{u}_j^\top, \quad \mathbf{B} = \mathbf{A} - \mathbf{d}^\top \mathbf{d} / (2E).$$

Maximizar Q es el problema central de la *detección de comunidades* en redes complejas; se resuelve por descomposición espectral de $\mathbf{B}$ o por enfoques jerárquicos divisivos.

5 Validación de grupos

5.1 Externas

(requieren rótulos de clases)

- **Pureza:** $\text{pur}(\mathcal{C}_j) = \max_i n_{ij} / \hat{N}_j$ (homogeneidad); $\text{PUR} = \sum_j (\hat{N}_j / N) \text{pur}(\mathcal{C}_j)$.
- **Entropía** (Shannon): $\text{ent}(\mathcal{C}_j) = -\frac{1}{\log_2 m} \sum_i (n_{ij} / \hat{N}_j) \log_2 (n_{ij} / \hat{N}_j)$ — menor es mejor.

5.2 Internas

(sólo usan datos y partición)

- **PI (Bensaid):** $\text{tr}(\mathbf{\Sigma}_W) / \sum_{ij} N_i \|\omega_i - \omega_j\|^2$.
- **VAT:** *data image* reordenado — diagnóstico visual cualitativo.

5.3 Relativas

(elección de K)

- **Calinski–Harabasz:** $\text{CH} = \frac{N-K}{K-1} \frac{\text{tr}(\mathbf{\Sigma}_B)}{\text{tr}(\mathbf{\Sigma}_W)}$ (max).
- **PBM:** $(\frac{1}{K} \frac{E_1}{E_K} \frac{1}{D_{\max}})^2$ (max).
- **Silueta:** $sw_i(t) = (b_i(t) - a_i(t)) / \max(a_i, b_i)$, con a_i distancia media intragrupo y b_i menor media entregrupos. $SW \in (-1, 1)$, próximo a 1 es ideal.
- **Xie–Beni:** $\text{tr}(\mathbf{\Sigma}_W) / (N \cdot D_{\min})$ (min).

Vendramin, Campello & Hruschka (estudio con 1 080 datasets) concluyen que **CH**, **PBM** y **SW** son los índices más efectivos para descubrir K . Se recomienda ejecutar el k -medias múltiples veces para cada K y analizar la dispersión de los índices vía *box-plot*.

6 Aplicaciones

Aplicación

Segmentación de imágenes SAR de la Amazonía (Beisl, Coppe/UFRJ). Imágenes del satélite JERS-1 en las épocas de creciente (oct./1995) y de seca (mayo/1996) sobre la cuenca

del Solimões. Pre-procesamiento por función *semivariograma* caracteriza la textura local. El agrupamiento por ISODATA (variante de *k*-medias) seguido de clasificación por especialista produce cuatro clases temáticas: agua, bosque seco, bosque inundado y vegetación inundada. El resultado alimenta mapas de sensibilidad ambiental al derrame de petróleo (poliducto Coari–Manaus, Petrobras).

Aplicación

Agrupamiento de documentos (Santos, Coppe/UFRJ). 585 resúmenes de tesis del PEC/Coppe (2004–2008); el pre-procesamiento (*stopwords*, *stemming*) reduce a 265 términos; ponderación *tf-idf*. Se construye un grafo con similitud del coseno y umbral ε ; se aplica el algoritmo de **maximización de la modularidad** de Newman–Girvan con etapa de refinamiento. En $\varepsilon = 0,20$, $Q = 0,5334$ y 7 comunidades coherentes con las áreas de investigación del Programa: Mecánica Computacional, Estructuras, Geotecnia, Petróleo (Geoquímica y Geofísica), Sistemas Computacionales y Recursos Hídricos.

7 Comentarios finales

1. El *clustering* es un **problema mal planteado**: ninguna medida es absoluta, el criterio final es siempre interpretativo.
2. ***k*-medias y jerárquicos aglomerativos** son los enfoques clásicos, en cualquier software. Los métodos **espectrales** brillan con grupos no convexos y en alta dimensión (textos, imágenes).
3. **No confundir grupos con clases**: la coincidencia es circunstancial. Los métodos *semi-supervisados* usan rótulos parciales para guiar el agrupamiento.
4. En minería de textos y bioinformática, la **alta dimensionalidad** obliga a usar similitudes específicas (coseno) y técnicas de reducción (LSI, ACP).
5. Próximos capítulos: *fuzzy c*-medias (Capítulo 8), funciones de base radial (Capítulo 7), redes neuronales (Capítulo 9) amplían aún más el arsenal.