

Análisis en Componentes Principales

Javier Trejos

Escuela de Matemática – CIMPA
Universidad de Costa Rica
II ciclo 2020

Esquema

Análisis en
Componentes
Principales

Javier Trejos

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo

Elementos
principales

Representaciones
Gráficas

Indices de
Calidad

Interpretación
de Resultados

- 1 Introducción
- 2 Objetivo del ACP
- 3 Solución del ACP
- 4 ACP normado
- 5 Ejemplo
- 6 Elementos principales
- 7 Representaciones Gráficas
- 8 Indices de Calidad
- 9 Interpretación de Resultados

Análisis en Componentes Principales

Introducción

Análisis en
Componentes
Principales

Javier Trejos

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo

Elementos
principales

Representaciones
Gráficas

Indíces de
Calidad

Interpretación
de Resultados

- Se dispone de una tabla de datos $\mathbf{X}$ de p variables cuantitativas medidas sobre n individuos

Análisis en Componentes Principales

Introducción

Análisis en
Componentes
Principales

Javier Trejos

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo

Elementos
principales

Representaciones
Gráficas

Indíces de
Calidad

Interpretación
de Resultados

- Se dispone de una tabla de datos $\mathbf{X}$ de p variables cuantitativas medidas sobre n individuos
- ACP: técnica de reducción de las dimensiones

Análisis en Componentes Principales

Introducción

Análisis en
Componentes
Principales

Javier Trejos

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo

Elementos
principales

Representaciones
Gráficas

Indíces de
Calidad

Interpretación
de Resultados

- Se dispone de una tabla de datos $\mathbf{X}$ de p variables cuantitativas medidas sobre n individuos
- ACP: técnica de reducción de las dimensiones
- Pearson (1900): encontrar la recta de mejor ajuste en 2 dimensiones

Análisis en Componentes Principales

Introducción

Análisis en
Componentes
Principales

Javier Trejos

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo

Elementos
principales

Representaciones
Gráficas

Indíces de
Calidad

Interpretación
de Resultados

- Se dispone de una tabla de datos $\mathbf{X}$ de p variables cuantitativas medidas sobre n individuos
- ACP: técnica de reducción de las dimensiones
- Pearson (1900): encontrar la recta de mejor ajuste en 2 dimensiones
- Hotelling (1933): encontrar variables sintéticas independientes de máxima varianza

Análisis en Componentes Principales

Introducción

Análisis en
Componentes
Principales

Javier Trejos

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo

Elementos
principales

Representaciones
Gráficas

Índices de
Calidad

Interpretación
de Resultados

- Se dispone de una tabla de datos $\mathbf{X}$ de p variables cuantitativas medidas sobre n individuos
- ACP: técnica de reducción de las dimensiones
- Pearson (1900): encontrar la recta de mejor ajuste en 2 dimensiones
- Hotelling (1933): encontrar variables sintéticas independientes de máxima varianza
- Pagès (1970): reducir la dimensión del espacio de representación de los individuos perdiendo el mínimo de información

Análisis en Componentes Principales

Introducción

Análisis en
Componentes
Principales

Javier Trejos

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo

Elementos
principales

Representaciones
Gráficas

Índices de
Calidad

Interpretación
de Resultados

- Se dispone de una tabla de datos $\mathbf{X}$ de p variables cuantitativas medidas sobre n individuos
- ACP: técnica de reducción de las dimensiones
- Pearson (1900): encontrar la recta de mejor ajuste en 2 dimensiones
- Hotelling (1933): encontrar variables sintéticas independientes de máxima varianza
- Pagès (1970): reducir la dimensión del espacio de representación de los individuos perdiendo el mínimo de información
- Los objetivos son duales y equivalentes

Análisis en Componentes Principales

Situación

Análisis en
Componentes
Principales

Javier Trejos

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo


Elementos
principales

Representaciones
Gráficas

Indíces de
Calidad

Interpretación
de Resultados

Se tiene una tabla de datos cuantitativos $n \times p$.



Análisis en Componentes Principales

Objetivo

Se quiere:

- obtener una representación en **pocas dimensiones** de los objetos, perdiendo el mínimo de información;

Análisis en
Componentes
Principales

Javier Trejos

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo

Elementos
principales

Representaciones
Gráficas

Indíces de
Calidad

Interpretación
de Resultados

Análisis en Componentes Principales

Objetivo

Se quiere:

- obtener una representación en **pocas dimensiones** de los objetos, perdiendo el mínimo de información;
- obtener (pocas) **variables sintéticas**, basadas en las variables originales y no correlacionadas entre ellas;

Análisis en
Componentes
Principales

Javier Trejos

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo

Elementos
principales

Representaciones
Gráficas

Indíces de
Calidad


Interpretación
de Resultados

Análisis en Componentes Principales


Objetivo

Se quiere:

- obtener una representación en **pocas dimensiones** de los objetos, perdiendo el mínimo de información;
- obtener (pocas) **variables sintéticas**, basadas en las variables originales y no correlacionadas entre ellas;
- son objetivos equivalentes (y duales).



Plano principal:



Objetivo del ACP

- Sean la **nube de puntos** $\mathcal{N} = (\mathbf{X}, \mathbf{M}, \mathbf{D}_p)$, con $\mathbf{M}$ la métrica $p \times p$ sobre el espacio de individuos y $\mathbf{D}_p$ la métrica de pesos (matriz diagonal $n \times n$) sobre el espacio de variables

Análisis en
Componentes
Principales

Javier Trejos

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo

Elementos
principales

Representaciones
Gráficas

Indíces de
Calidad

Interpretación
de Resultados

Objetivo del ACP

Análisis en
Componentes
Principales

Javier Trejos

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo

Elementos
principales

Representaciones
Gráficas

Índices de
Calidad

Interpretación
de Resultados

- Sean la **nube de puntos** $\mathcal{N} = (\mathbf{X}, \mathbf{M}, \mathbf{D}_p)$, con $\mathbf{M}$ la métrica $p \times p$ sobre el espacio de individuos y $\mathbf{D}_p$ la métrica de pesos (matriz diagonal $n \times n$) sobre el espacio de variables
- Supondremos que las variables $\mathbf{x}^j$ están **centradas**
- Se busca un espacio de dimensión q , menor que p , de manera que las posiciones relativas de los puntos-individuos sean lo más similares posibles a sus posiciones en el espacio $\mathbb{R}^p$

Objetivo del ACP

Análisis en
Componentes
Principales

Javier Trejos

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo

Elementos
principales

Representaciones
Gráficas

Índices de
Calidad

Interpretación
de Resultados

- Sean la **nube de puntos** $\mathcal{N} = (\mathbf{X}, \mathbf{M}, \mathbf{D}_p)$, con $\mathbf{M}$ la métrica $p \times p$ sobre el espacio de individuos y $\mathbf{D}_p$ la métrica de pesos (matriz diagonal $n \times n$) sobre el espacio de variables
- Supondremos que las variables $\mathbf{x}^j$ están **centradas**
- Se busca un espacio de dimensión q , menor que p , de manera que las posiciones relativas de los puntos-individuos sean lo más similares posibles a sus posiciones en el espacio $\mathbb{R}^p$
- Esto significa que hay una **pérdida mínima de información** al proyectar los n individuos sobre un espacio de dimensión menor

Objetivo del ACP

Análisis en
Componentes
Principales

Javier Trejos

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo

Elementos
principales

Representaciones
Gráficas

Índices de
Calidad

Interpretación
de Resultados

- Sean la **nube de puntos** $\mathcal{N} = (\mathbf{X}, \mathbf{M}, \mathbf{D}_p)$, con $\mathbf{M}$ la métrica $p \times p$ sobre el espacio de individuos y $\mathbf{D}_p$ la métrica de pesos (matriz diagonal $n \times n$) sobre el espacio de variables
- Supondremos que las variables $\mathbf{x}^j$ están **centradas**
- Se busca un espacio de dimensión q , menor que p , de manera que las posiciones relativas de los puntos-individuos sean lo más similares posibles a sus posiciones en el espacio $\mathbb{R}^p$
- Esto significa que hay una **pérdida mínima de información** al proyectar los n individuos sobre un espacio de dimensión menor
- De esta forma, su **dispersión** en el espacio proyectado $\mathbb{R}^q$ debe ser **máxima**, de manera que la forma de la nube se asemeje lo mejor posible a su forma original.

Objetivo del ACP

Objetivo dual

- Se puede plantear de otra forma el objetivo del ACP, esta vez **desde el punto de vista de las variables**
- Dada la tabla $\mathbf{X}_{n \times p}$, se busca un conjunto de q **variables sintéticas** $\mathbf{c}^1, \mathbf{c}^2, \dots, \mathbf{c}^q$, donde $q < p$ (las *componentes principales*), tal que:
 - 1 Cada componente principal $\mathbf{c}^k$ debe ser **combinación lineal** de las variables originales $\mathbf{x}^j$; esto significa que la *información* contenida en las $\mathbf{x}^j$ también está reflejada en las $\mathbf{c}^k$.
 - 2 Las componentes principales deben ser **no correlacionadas dos a dos**; esto significa que las $\mathbf{c}^k$ no tienen información redundante.
 - 3 Las componentes principales deben tener **varianza máxima**; esto significa que contendrán el máximo de información posible.
- Todo lo anterior se puede deducir del objetivo inicial: reducción de la dimensión del espacio de individuos

Objetivo del ACP

Ejemplo: Tabla de notas escolares

Sea la tabla de datos de notas escolares, que contiene las notas obtenidas por 10 estudiantes en cinco materias.

Todas las notas están en la escala de 0 a 10.

Estudiante	Matemáticas	Ciencias	Español	Historia	Ed. Física
Lucía	7.0	6.5	9.2	8.6	8.0
Pedro	7.5	9.4	7.3	7.0	7.0
Inés	7.6	9.2	8.0	8.0	7.5
Luis	5.0	6.5	6.5	7.0	9.0
Andrés	6.0	6.0	7.8	8.9	7.3
Ana	7.8	9.6	7.7	8.0	6.5
Carlos	6.3	6.4	8.2	9.0	7.2
José	7.9	9.7	7.5	8.0	6.0
Sonia	6.0	6.0	6.5	5.5	8.7
María	6.8	7.2	8.7	9.0	7.0

Solución del ACP

Análisis en
Componentes
Principales

Javier Trejos

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo

Elementos
principales

Representaciones
Gráficas

Índices de
Calidad

Interpretación
de Resultados

- La solución del Análisis en Componentes Principales se obtiene al diagonalizar la matriz de correlaciones $\mathbf{R}$, es decir, el cálculo de sus valores y vectores propios.
- Llamaremos **A.C.P. normado** el caso en que se usan los datos centrados y estandarizados, lo que corresponde a usar la métrica de los inversos de las varianzas, en cuyo caso la solución se obtiene al diagonalizar $\mathbf{R}$,
- y llamaremos **A.C.P. general** cuando la métrica $\mathbf{M}$ es cualquiera, en cuyo caso la solución se obtiene al diagonalizar $\mathbf{VM}$, producto de la métrica y la matriz de varianzas–covarianzas.

Solución del ACP

ACP normado

- Dada la tabla de datos $\mathbf{X}_{n \times p}$, procedemos a *centrar y estandarizar* las variables, de forma que en adelante todas tienen media cero y varianza 1.
- Estamos en presencia de la **nube de puntos** $\mathcal{N} = (\mathbf{X}, \mathbf{I}_p, \mathbf{D}_p)$, donde $\mathbf{I}_p$ es la identidad $p \times p$ y $\mathbf{D}_p$ es la métrica diagonal de pesos.
- En este contexto, la matriz de covarianzas $\mathbf{V}$ y la matriz de correlaciones $\mathbf{R}$ coinciden.
- Se tiene $I(\mathcal{N}) = \text{traza}(\mathbf{V}) = \text{traza} \mathbf{R} = p$
- Se busca el subespacio H de $\mathbb{R}^p$ tal que la **proyección** de los individuos se represente lo mejor posible en H .
- Esto significa que la **inercia** de la nube de los puntos proyectados debe ser **máxima**
- Cualquier individuo $\mathbf{x}_i$ en $\mathbb{R}^p$ puede ser presentado como $\mathbf{x}_i = \text{Pr}_H(\mathbf{x}_i) + \text{Pr}_{H^\perp}(\mathbf{x}_i) = \mathbf{a}_i + \mathbf{b}_i$, donde $\mathbf{a}_i = \text{Pr}_H(\mathbf{x}_i) \in H$ y $\mathbf{b}_i = \text{Pr}_{H^\perp}(\mathbf{x}_i) \in H^\perp$

Solución del ACP

ACP normado

Análisis en
Componentes
Principales

Javier Trejos

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo

Elementos
principales

Representaciones
Gráficas

Índices de
Calidad

Interpretación
de Resultados




Figura: Proyección de un punto-individuo sobre un subespacio y su complemento ortogonal.

Solución del ACP

ACP normado

- En vista de la perpendicularidad entre $\mathbf{a}_i$ y $\mathbf{b}_i$, por el *teorema de Pitágoras* se tiene que:

$$\|\mathbf{x}_i\|^2 = \|\mathbf{a}_i\|^2 + \|\mathbf{b}_i\|^2$$

- Luego

$$p_i \|\mathbf{x}_i\|^2 = p_i \|\mathbf{a}_i\|^2 + p_i \|\mathbf{b}_i\|^2,$$

de donde

$$\sum_{i=1}^n p_i \|\mathbf{x}_i\|^2 = \sum_{i=1}^n p_i \|\mathbf{a}_i\|^2 + \sum_{i=1}^n p_i \|\mathbf{b}_i\|^2.$$

- Si definimos la *proximidad* entre $\mathcal{N}$ y el subespacio H como

$$I_H(\mathcal{N}) = \sum_{i=1}^n p_i \|\mathbf{x}_i - \mathbf{a}_i\|^2 = \sum_{i=1}^n p_i \|\mathbf{b}_i\|^2$$

entonces el objetivo del A.C.P. será encontrar H tal que

$I_H(\mathcal{N})$ sea *mínima*


Solución del ACP

ACP normado

- Poniendo $I_{H^\perp}(\mathcal{N}) = \sum_{i=1}^n p_i \|\mathbf{a}_i\|^2$, entonces es claro que

$$I(\mathcal{N}) = I_H(\mathcal{N}) + I_{H^\perp}(\mathcal{N}), \quad (1)$$

- Por lo que $I_{H^\perp}(\mathcal{N})$ es *máxima* cuando $I_H(\mathcal{N})$ es *mínima*.



Solución del ACP

ACP normado

- Se prueba el **teorema de inclusión**: el espacio óptimo de dimensión k está contenido en el espacio óptimo de dimensión $k + 1$.
- Esto permite seguir como estrategia
 - 1 la búsqueda del espacio óptimo de *dimensión uno*,
 - 2 enseguida del espacio óptimo de *dimensión dos* que contenga al anterior. Para ello, será suficiente hallar el espacio óptimo de dimensión uno, ortogonal al primer espacio encontrado, y así se genera el espacio óptimo de dimensión 2, mediante la suma directa de los dos espacios encontrados.
- Es sabido que un espacio de dimensión uno es generado por un vector: ponemos $\Delta_{\mathbf{u}}$ el espacio generado por el vector $\mathbf{u}$.
- Tomaremos los vectores que generan estos espacios de norma 1.

Solución del ACP

ACP normado

Análisis en
Componentes
Principales

Javier Trejos

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo

Elementos
principales

Representaciones
Gráficas

Índices de
Calidad

Interpretación
de Resultados

- Se tiene que $I_{\Delta_{\mathbf{u}}}(\mathcal{N})$ es mínima si $I_{\Delta_{\mathbf{u}}^{\perp}}(\mathcal{N})$ es máxima.
- Es más fácil el cálculo de $I_{\Delta_{\mathbf{u}}^{\perp}}(\mathcal{N})$.
- Por lo tanto, se buscará el vector $\mathbf{u}$ de norma 1 tal que $I_{\Delta_{\mathbf{u}}^{\perp}}(\mathcal{N})$ sea máxima.
- Así, podemos decir que buscamos:
 - 1 El vector $\mathbf{u}_1$ tal que $\|\mathbf{u}_1\| = 1$ e $I_{\Delta_{\mathbf{u}_1}^{\perp}}(\mathcal{N})$ sea máxima.
 - 2 El vector $\mathbf{u}_2$ tal que $\|\mathbf{u}_2\| = 1$, $\mathbf{u}_1 \perp \mathbf{u}_2$ e $I_{\Delta_{\mathbf{u}_2}^{\perp}}(\mathcal{N})$ sea máxima.
 - 3 El vector $\mathbf{u}_3$ tal que $\|\mathbf{u}_3\| = 1$, $\mathbf{u}_1 \perp \mathbf{u}_3$, $\mathbf{u}_2 \perp \mathbf{u}_3$ e $I_{\Delta_{\mathbf{u}_3}^{\perp}}(\mathcal{N})$ sea máxima.
 - 4 Etc.

Solución del ACP

ACP normado

Proposición

Si $\mathbf{u}$ es un vector de $\mathbb{R}^p$ con norma 1, entonces

$$I_{\Delta_{\mathbf{u}}^{\perp}}(\mathcal{N}) = \mathbf{u}^t \mathbf{R} \mathbf{u}.$$

DEMOSTRACIÓN: Sea $\mathbf{x}_i$ un individuo, es decir, una fila de la tabla de datos $\mathbf{X}$. Sean $\mathbf{a}_i = \text{Pr}_{\Delta_{\mathbf{u}}}(\mathbf{x}_i)$ su proyección sobre $\Delta_{\mathbf{u}}$ y $\mathbf{b}_i = \text{Pr}_{\Delta_{\mathbf{u}}^{\perp}}(\mathbf{x}_i)$ su proyección sobre $\Delta_{\mathbf{u}}^{\perp}$, de manera que $\mathbf{x}_i = \mathbf{a}_i + \mathbf{b}_i$.

Como $\mathbf{a}_i$ es la proyección sobre la recta generada por $\mathbf{u}$, entonces existe un coeficiente c_i tal que $\mathbf{a}_i = c_i \mathbf{u}$. Es más, se sabe que

$$c_i = \langle \mathbf{x}_i, \mathbf{u} \rangle = \mathbf{x}_i^t \mathbf{u}$$

ya que la métrica es la identidad $\mathbf{I}_p$ y $\|\mathbf{u}\| = 1$.

Solución del ACP

ACP normado

Proposición

Si $\mathbf{u}$ es un vector de $\mathbb{R}^p$ con norma 1, entonces

$$I_{\Delta_{\mathbf{u}}^{\perp}}(\mathcal{N}) = \mathbf{u}^t \mathbf{R} \mathbf{u}.$$

DEMOSTRACIÓN: (Cont.) Por lo tanto

$$\begin{aligned} I_{\Delta_{\mathbf{u}}^{\perp}}(\mathcal{N}) &= \sum_{i=1}^n p_i \|\mathbf{a}_i\|^2 = \sum_{i=1}^n p_i \|c_i \mathbf{u}\|^2 \\ &= \sum_{i=1}^n p_i c_i^2 = \sum_{i=1}^n p_i \mathbf{x}_i^t \mathbf{u} \mathbf{x}_i^t \mathbf{u} \\ &= \mathbf{u}^t \left(\sum_{i=1}^n p_i \mathbf{x}_i \mathbf{x}_i^t \right) \mathbf{u} = \mathbf{u}^t \mathbf{X}^t \mathbf{D}_p \mathbf{X} \mathbf{u} \\ &= \mathbf{u}^t \mathbf{R} \mathbf{u}. \quad \blacksquare \end{aligned}$$

Solución del ACP

ACP normado: El primer Eje

- El primer eje que se busca, $\mathbf{u}_1$, genera la recta $\Delta_{\mathbf{u}_1}$ tal que $\|\mathbf{u}_1\| = 1$ e $I_{\Delta_{\mathbf{u}_1}^\perp}(\mathcal{N}) = \mathbf{u}_1^t \mathbf{R} \mathbf{u}_1$ es **máxima**.
- Para ello, se plantea el **problema de maximización con restricciones**:

$$\begin{aligned} \text{Maximizar} \quad & F(\mathbf{u}) = I_{\Delta_{\mathbf{u}}^\perp}(\mathcal{N}) = \mathbf{u}^t \mathbf{R} \mathbf{u} \\ \text{sujeto a} \quad & \|\mathbf{u}\|^2 = \mathbf{u}^t \mathbf{u} = 1. \end{aligned}$$

Usando la técnica de *multiplicadores de Lagrange*, si

$$\begin{aligned} L(\mathbf{u}, \lambda) &= F(\mathbf{u}) - \lambda(\|\mathbf{u}\|^2 - 1) \\ &= \mathbf{u}^t \mathbf{R} \mathbf{u} - \lambda(\mathbf{u}^t \mathbf{u} - 1), \end{aligned}$$

entonces

$$\frac{\partial L}{\partial \mathbf{u}} = 2\mathbf{R}\mathbf{u} - 2\lambda\mathbf{u} = \mathbf{0},$$

por lo que

$$\mathbf{R}\mathbf{u} = \lambda\mathbf{u}.$$

Solución del ACP

ACP normado: El primer Eje

Análisis en
Componentes
Principales

Javier Trejos

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo

Elementos
principales

Representaciones
Gráficas

Índices de
Calidad

Interpretación
de Resultados

$\mathbf{R}\mathbf{u} = \lambda\mathbf{u}$ significa que $\mathbf{u}$ es **vector propio**¹ de $\mathbf{R}$, asociado al valor propio λ .

Es más,

$$F(\mathbf{u}) = \mathbf{u}^t \mathbf{R} \mathbf{u} = \mathbf{u}^t (\lambda \mathbf{u}) = \lambda \mathbf{u}^t \mathbf{u} = \lambda.$$

Por lo tanto, F se maximiza cuando λ es máximo.

Al vector propio $\mathbf{u}_1$ asociado al mayor valor propio λ_1 de $\mathbf{R}$ se le llama el **primer eje** del A.C.P. de la nube $\mathcal{N}$.

¹Recuérdese que un escalar λ se llama *valor propio* de una matriz $\mathbf{A}$ si existe un vector $\mathbf{v} \neq \mathbf{0}$ tal que $\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$; al vector $\mathbf{v}$ se le llama *vector propio* de $\mathbf{A}$ asociado a λ . Al proceso de obtener todos los valores y vectores propios de una matriz se le llama *diagonalización* de la matriz.

Solución del ACP

ACP normado: El segundo Eje

Análisis en
Componentes
Principales

Javier Trejos

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo

Elementos
principales

Representaciones
Gráficas

Índices de
Calidad

Interpretación
de Resultados

- El segundo eje buscado, $\mathbf{u}_2$, debe combinarse con $\mathbf{u}_1$ y formar un subespacio de dimensión 2 (es decir, un plano), tal que la inercia proyectada de la nube $\mathcal{N}$ sea máxima.
- Por el teorema de inclusión, como ya tenemos el espacio óptimo Δ_{u_1} de dimensión 1 y sabemos que éste está incluido en el espacio óptimo de dimensión 2, entonces basta con encontrar el vector $\mathbf{u}$ —ortogonal a $\mathbf{u}_1$ — con $I_{\Delta_{\mathbf{u}}^\perp}(\mathcal{N})$ máxima.
- Esto es,

$$\begin{array}{ll} \text{Maximizar} & F(\mathbf{u}) = I_{\Delta_{\mathbf{u}}^\perp}(\mathcal{N}) = \mathbf{u}^t \mathbf{R} \mathbf{u} \\ \text{sujeto a} & \|\mathbf{u}\|^2 = \mathbf{u}^t \mathbf{u} = 1, \\ & \mathbf{u}_1 \perp \mathbf{u}. \end{array}$$

Solución del ACP

ACP normado: El segundo Eje

Análisis en
Componentes
Principales

Javier Trejos

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo

Elementos
principales

Representaciones
Gráficas

Índices de
Calidad

Interpretación
de Resultados

Por ello, planteamos el problema de optimización con *multiplicadores de Lagrange* en que buscamos el vector $\mathbf{u}$ que maximiza L :

$$\begin{aligned} L(\mathbf{u}, \lambda, \mu) &= F(\mathbf{u}) - \lambda(\|\mathbf{u}\|^2 - 1) - \mu(\langle \mathbf{u}_1, \mathbf{u} \rangle - 0) \\ &= \mathbf{u}^t \mathbf{R} \mathbf{u} - \lambda(\mathbf{u}^t \mathbf{u} - 1) - \mu \mathbf{u}^t \mathbf{u}_1, \end{aligned}$$

de donde

$$\frac{\partial L}{\partial \mathbf{u}} = 2\mathbf{R}\mathbf{u} - 2\lambda\mathbf{u} - \mu\mathbf{u}_1 = \mathbf{0}. \quad (2)$$

Solución del ACP

ACP normado: El segundo Eje

Premultiplicando por $\mathbf{u}_1^t$:

$$\mathbf{u}_1^t \mathbf{R} \mathbf{u} = \lambda \mathbf{u}_1^t \mathbf{u} + \mu \mathbf{u}_1^t \mathbf{u}_1$$

y como

$$\mathbf{u}_1^t \mathbf{R} \mathbf{u} = \mathbf{u}_1^t \mathbf{R} \mathbf{u}_1 = \mathbf{u}_1^t (\lambda_1 \mathbf{u}_1),$$

entonces

$$\lambda_1 \mathbf{u}_1^t \mathbf{u} = 0 + \mu,$$

de donde $\mu = 0$, ya que $\mathbf{u}_1^t \mathbf{u} = 0$. Por lo tanto, en la ecuación (2) se debe cumplir

$$2\mathbf{R} \mathbf{u} - 2\lambda \mathbf{u} = \mathbf{0}$$

es decir

$$\mathbf{R} \mathbf{u} = \lambda \mathbf{u}.$$

Esto significa que $\mathbf{u}$ también es *vector propio* de $\mathbf{R}$.

Solución del ACP

ACP normado: El segundo Eje

Análisis en
Componentes
Principales

Javier Trejos

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo

Elementos
principales

Representaciones
Gráficas

Índices de
Calidad

Interpretación
de Resultados

Como de nuevo $F(\mathbf{u}) = I_{\Delta_{\mathbf{u}}^{\perp}}(\mathcal{N}) = \lambda$ y este valor debe ser máximo, entonces λ es el segundo valor propio de $\mathbf{R}$ (dados en orden decreciente), denotado λ_2 . Así, el **segundo eje** del A.C.P. de $\mathcal{N}$ es el vector propio $\mathbf{u}_2$ de $\mathbf{R}$ asociado a λ_2 .

El **primer plano principal** H_1 está generado por los dos primeros ejes principales:

$$H_1 = \Delta_{\mathbf{u}_1} \oplus \Delta_{\mathbf{u}_2}$$

y tiene inercia $I_{H_1^{\perp}}(\mathcal{N}) = \lambda_1 + \lambda_2$.

Solución del ACP

ACP normado: Eje siguientes

Análisis en
Componentes
Principales

Javier Trejos

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo

Elementos
principales

Representaciones
Gráficas

Índices de
Calidad

Interpretación
de Resultados

- En general, siguiendo el mismo procedimiento anterior, los **ejes principales** del A.C.P. de la nube $\mathcal{N} = (\mathbf{X}, \mathbf{I}_p, \mathbf{D}_p)$ están generados por los vectores propios de la matriz de correlaciones $\mathbf{R}$ asociados a los valores propios de ésta, dados en orden decreciente:

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$$

asociados respectivamente a $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_p$.

- Seleccionando cualquier par de ejes principales, se puede generar un **plano principal**.

Solución del ACP

Diagonalización de $\mathbf{R}$

Análisis en
Componentes
Principales

Javier Trejos

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo

Elementos
principales

Representaciones
Gráficas

Indíces de
Calidad

Interpretación
de Resultados

- Obsérvese que la matriz $\mathbf{R}$ es simétrica y positiva.
- Por lo tanto, tiene p valores propios reales.
- Como es semidefinida positiva, estos valores propios son mayores o iguales que cero, pero su suma es p .
- La solución al problema del A.C.P. se obtiene al **diagonalizar** la matriz $\mathbf{R}$.

Ejemplo de ACP

Tabla de notas escolares

Análisis en
Componentes
Principales

Javier Trejos

Estudiante	Matemáticas	Ciencias	Español	Historia	Ed. Física
Lucía	7.0	6.5	9.2	8.6	8.0
Pedro	7.5	9.4	7.3	7.0	7.0
Inés	7.6	9.2	8.0	8.0	7.5
Luis	5.0	6.5	6.5	7.0	9.0
Andrés	6.0	6.0	7.8	8.9	7.3
Ana	7.8	9.6	7.7	8.0	6.5
Carlos	6.3	6.4	8.2	9.0	7.2
José	7.9	9.7	7.5	8.0	6.0
Sonia	6.0	6.0	6.5	5.5	8.7
María	6.8	7.2	8.7	9.0	7.0

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo

Elementos
principales

Representaciones
Gráficas

Índices de
Calidad

Interpretación
de Resultados

Ejemplo ACP

Las notas escolares

Análisis en
Componentes
Principales

Javier Trejos

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo

Elementos
principales

Representaciones
Gráficas

Índices de
Calidad

Interpretación
de Resultados

■ Matriz de correlaciones:

Materia	Matem.	Ciencias	Español	Historia	Ed. Física
Matemáticas	1.00	0.85	0.38	0.21	-0.79
Ciencias	0.85	1.00	-0.02	-0.02	-0.69
Español	0.38	-0.02	1.00	0.82	-0.37
Historia	0.21	-0.02	0.82	1.00	-0.51
Educ. Física	-0.79	-0.69	-0.37	-0.51	1.00

Tabla: Correlaciones entre las materias de la tabla de notas escolares.

Ejemplo ACP

Las notas escolares

■ Matriz de correlaciones:

Materia	Matem.	Ciencias	Español	Historia	Ed. Física
Matemáticas	1.00	0.85	0.38	0.21	-0.79
Ciencias	0.85	1.00	-0.02	-0.02	-0.69
Español	0.38	-0.02	1.00	0.82	-0.37
Historia	0.21	-0.02	0.82	1.00	-0.51
Educ. Física	-0.79	-0.69	-0.37	-0.51	1.00

Tabla: Correlaciones entre las materias de la tabla de notas escolares.

■ Valores propios:

$$\lambda_1 = 2.89, \lambda_2 = 1.63, \lambda_3 = 0.35, \lambda_4 = 0.12, \lambda_5 = 0.01.$$

Solución de ACP

Vectores Principales

Análisis en
Componentes
Principales

Javier Trejos

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo

Elementos
principales

Representaciones
Gráficas

Índices de
Calidad

Interpretación
de Resultados

Al calcular los q valores propios mayores de la matriz $\mathbf{R}$, denotados $\lambda_1, \lambda_2, \dots, \lambda_q$ (ordenados en orden decreciente), se obtienen los llamados **vectores principales** $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_q$, donde

- $\mathbf{u}_1$ es un vector propio normado de $\mathbf{R}$ asociado al valor propio λ_1 ,
- $\mathbf{u}_2$ es un vector propio normado de $\mathbf{R}$ asociado al valor propio λ_2 ,
- $\vdots$
- $\mathbf{u}_k$ es un vector propio normado de $\mathbf{R}$ asociado al valor propio λ_k .

Solución de ACP

Componentes Principales

Análisis en
Componentes
Principales

Javier Trejos

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo

Elementos
principales

Representaciones
Gráficas

Indices de
Calidad

Interpretación
de Resultados

- Las **componentes principales** serán las variables asociadas a estos ejes principales.

Solución de ACP

Componentes Principales

Análisis en
Componentes
Principales

Javier Trejos

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo

Elementos
principales

Representaciones
Gráficas

Índices de
Calidad

Interpretación
de Resultados

- Las **componentes principales** serán las variables asociadas a estos ejes principales.
- Así, en el A.C.P. normado se define:
 $\mathbf{c}^1 = \mathbf{X}\mathbf{u}_1$ la *primera componente principal*,
 $\mathbf{c}^2 = \mathbf{X}\mathbf{u}_2$ la *segunda componente principal*,
 $\vdots$
 $\mathbf{c}^k = \mathbf{X}\mathbf{u}_k$ la *k-ésima componente principal*, etc.
- Por su definición, es claro que las componentes principales son combinación lineal de las variables originales (que son las columnas de $\mathbf{X}$).
- Por esta razón, su media también es cero.

Ejemplo de ACP

Las Notas Escolares: Componentes Principales

Estudiante	Primera componente c^1	Segunda componente c^2
Lucía	-0.32	-1.77
Pedro	-0.67	1.64
Inés	-1.00	0.52
Luis	3.17	0.26
Andrés	0.49	-1.37
Ana	-1.71	1.02
Carlos	-0.07	-1.46
José	-2.01	1.28
Sonia	3.04	1.25
María	-0.92	-1.37

Solución del ACP

Propiedades de las componentes principales

Las componentes principales tienen las siguientes **propiedades**:

- 1 Son centradas: $\bar{\mathbf{c}}^k = 0$, para todo $k = 1, \dots, p$.
- 2 $\mathbf{c}^k$ tiene varianza λ_k : $\text{var}(\mathbf{c}^k) = \lambda_k$, para todo $k = 1, \dots, p$.
- 3 Cada pareja de ellas tiene correlación cero:
 $\forall k, l : r(\mathbf{c}^k, \mathbf{c}^l) = 0$, para todo $k, l = 1, \dots, p$.

Análisis en
Componentes
Principales

Javier Trejos

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo

Elementos
principales

Representaciones
Gráficas

Índices de
Calidad

Interpretación
de Resultados

Solución del ACP

Propiedades de las componentes principales

Las componentes principales tienen las siguientes **propiedades**:

- 1 Son centradas: $\bar{\mathbf{c}}^k = 0$, para todo $k = 1, \dots, p$.
- 2 $\mathbf{c}^k$ tiene varianza λ_k : $\text{var}(\mathbf{c}^k) = \lambda_k$, para todo $k = 1, \dots, p$.
- 3 Cada pareja de ellas tiene correlación cero:
 $\forall k, l: r(\mathbf{c}^k, \mathbf{c}^l) = 0$, para todo $k, l = 1, \dots, p$.

Se puede comprobar que, efectivamente, para las componentes principales $\mathbf{c}^1$ y $\mathbf{c}^2$ de la Tabla de Notas Escolares, éstas tienen media cero y que tienen correlación nula. Además, que la varianza de $\mathbf{c}^1$ es 2.89 y la de $\mathbf{c}^2$ es 1.63, que también son los dos primeros valores propios de la matriz de correlaciones.

Representaciones Gráficas

Gráficos complementarios

Análisis en
Componentes
Principales

Javier Trejos

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo

Elementos
principales

Representaciones
Gráficas

Índices de
Calidad

Interpretación
de Resultados

Gráficos más importantes:

- Los **planos principales**, formados por las coordenadas de los individuos en las componentes principales; aquí se pueden apreciar las principales agrupaciones y dispersiones de los individuos; el primer plano principal está generado por c^1 y c^2 .
- Los **círculos de correlaciones**, obtenidos a partir de las correlaciones entre las variables originales y las componentes principales normalizadas; aquí se pueden apreciar las agrupaciones de variables y su comportamiento respecto de las componentes principales.

Representaciones Gráficas

Planos Principales




Figura: Primer plano principal para la tabla de notas escolares, generado por las dos primeras componentes principales.

Representaciones Gráficas

Círculo de Correlaciones

Análisis en
Componentes
Principales

Javier Trejos

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo

Elementos
principales

Representaciones
Gráficas

Índices de
Calidad

Interpretación
de Resultados

Materia	Componente 1 c^1	Componente 2 c^2
Matemáticas	-0.90	0.35
Ciencias	-0.72	0.65
Español	-0.61	-0.72
Historia	-0.60	-0.75
Educación Física	0.91	-0.12

Círculo de Correlaciones

↑Eje 2 (32.57%)




Figura: Círculo de correlaciones para la tabla de notas escolares generado por las dos primeras componentes principales.

Resultados del ACP

Indices de Calidad

- **Calidad global:** porcentaje de inercia


$$\text{Calidad global del primer plano: } \frac{\lambda_1 + \lambda_2}{I(\mathcal{N})} \times 100$$

	Valor propio	Porcentaje de inercia	Inercia acumulada
1	2.89	57.86%	(57.86%)
2	1.63	32.57%	(90.44%)
3	0.35	6.93%	(97.37%)
4	0.12	2.45%	(99.82%)
5	0.01	0.18%	(100.00%)

Resultados del ACP

Indices de Calidad

- **Calidad particular:** caso de los individuos – calidad de la proyección (distancia entre el punto original y el punto proyectado) – **coseno cuadrado**



$$\cos \alpha = \frac{\|\text{Pr}(\mathbf{a})\|}{\|\mathbf{a}\|}.$$

Elevando al cuadrado:

$$\cos^2 \alpha = \frac{\|\text{Pr}(\mathbf{a})\|^2}{\|\mathbf{a}\|^2}.$$

Interpretación de Resultados del ACP

Análisis en
Componentes
Principales

Javier Trejos

Introducción

Objetivo del
ACP

Solución del
ACP

ACP normado

Ejemplo

Elementos
principales

Representaciones
Gráficas

Índices de
Calidad

Interpretación
de Resultados

La interpretación tiene mucho de arte y de experiencia.

Algunas ideas:

- Tratar de **etiquetar** a las componentes principales $\mathbf{c}^k$:
 - Examinar los **cosenos cuadrados** de los individuos:
$$\cos^2(\mathbf{x}_i) \geq 50\% \text{ en } \mathbf{c}^k$$
 - Examinar las **comunalidades** de las variables:
$$|r(\mathbf{x}^j, \mathbf{c}^k)| \geq 0.7$$
- Examinar las **correlaciones** en el círculo, según sea el comportamiento de los ángulos entre las variables
- Examinar las **agrupaciones** en un plano
- Los cosenos cuadrados de los individuos en un plano permiten determinar a los que más contribuyen a la inercia
- Se pueden usar **elementos suplementarios** (variables, individuos)