

***Curso de Fundamentos de Aprendizaje
Profundo
Introducción***

Dr. Gonzalo Acuña L.

Marzo 2019

Temario

- ◆ I. Motivación
- ◆ II. La neurona biológica
- ◆ III. La neurona artificial
- ◆ IV. Aprendizaje
- ◆ V. Redes Neuronas Artificiales
- ◆ VI. Aprendizaje Profundo
- ◆ VII. Aplicaciones
- ◆ VIII. Reseña Histórica



I. Motivación

- ◆ Gran facilidad de seres cognitivos para llevar a cabo tareas como:
 - ◆ Reconocimiento de formas
 - ◆ Procesamiento de voz, imágenes, etc.
- ↓ Dificultad de computadores tipo Von Neumann para desempeñar adecuadamente esas tareas.
- ↓ Interés (al igual que en la evolución técnica anterior) en “copiar” el “secreto” de los seres cognitivos.

↓ Por lo anterior pareció importante comprender y emular los mecanismos asociados al éxito de los seres cognitivos:

- ▣ Paralelismo y alta conectividad

- ▣ Complejidad


📄 Nace una de las ramas de la Inteligencia Artificial: **Redes Neuronales Artificiales**

Computacional

- ◆ Nuevo paradigma (no-algorítmico) para el procesamiento de la información (neurocomputación): de aprendizaje y adaptación, procesamiento distribuido y paralelo.
- ◆ Nuevas herramientas (computadores más rápidos, más baratos)
 - ◆ Entusiasmo inicial, edad media y renacimiento.

- ◆ Actualmente aplicaciones en todas las áreas
 - ◆ En aproximación: control, automatización
modelamiento, predicción, identificación
 - ◆ En clasificación: reconocimiento patrones,
extracción de características, cuantización
- ◆ En el futuro: mayor prudencia y más apoyo
teórico. Problemas abiertos:
generalización...

II. La Neuron Biológica



- ◆ **Potencial de reposo** (- 60 mV)
- ◆ Potencial de receptor (información exterior)
→ depolarización → + 10 mV
- ◆ Propagación pasiva en membrana
(amplitud y duración proporcionales a estímulo)
- ◆ Si importante → potencial acción


- ◆ **Potencial de acción** (+ 100 mV)
- ◆ Tren de potenciales de frecuencia proporcional a amplitud y duración de potencial receptor.
- ◆ Propagación activa en axón, desde cono axónico hasta sinapsis.
- ◆ Na^+ adentro. Después: K^+ afuera.


- ◆ **Sinapsis** (Ramón y Cajal, s. XIX)
- ◆ Retardo en la transmisión de impulso →
modulación por neurotransmisores
→ plasticidad
- ◆ Tipos sinapsis: axón-dendrita; axón soma;
axón-axón.
- ◆ Tipos sinapsis: excitatoria, inhibitoria.

◆ **Interconexión**

◆ 10^{10} neuronas

◆ Algunas neuronas con hasta 100.000 sinapsis







III. Neurona artificial

- ◆ Autómata caracterizado por:
 - ◆ Un estado interno
 - ◆ Señales de entrada
 - ◆ Funciones de agrupamiento y activación

- ◆ Tipos de neuronas:
 - ◆ Producto punto
 - ◆ Distancia



◆ Modelo de McCulloch y Pitts (1943)




◆ $a = x_1 w_1 + x_2 w_2 + \dots$

◆ Si $a > \Theta$ $y=1$


◆ Si $a < \Theta$ $y=0$

◆ Con este modelo se puede construir cualquier función lógica (Booleana)


◆ Con pesos convenientemente determinados se podría simular cualquier computador digital



Answermath.com - Neural Nets - fig 3.





AND de 4 entradas





All weights = 1 and all outputs = 1 if active; 0 otherwise

Funciones de Activación










Rectifier Linear Unit (ReLU)




IV. Aprendizaje

- ◆ Capacidad de una neurona (o red neuronal) para ajustar las conexiones (pesos) de modo de obtener una respuesta deseada o que satisfaga ciertos criterios

- ◆ **Regla de Hebb (1949)**
- ◆ Cuando una neurona i repetida y persistentemente excita a una neurona j algún proceso de crecimiento o metabólico se produce en una o ambas neuronas de modo que la eficiencia de excitación de i sobre j aumenta. → activación simultanea o síncrona

◆ Regla de Hebb (1949)



$$◆ w_{ij_new} = w_{ij_old} + \alpha x_i y_j$$

V. Redes de Neuronas Artificiales (RNA)

- ↓ Consisten en un conjunto de neuronas interconectados entre sí
- ↓ Queda completamente caracterizado por:
 - ↓ Número de neuronas
 - ↓ Arquitectura de interconexión
 - ↓ Valor de los pesos
 - ↓ Funciones de agrupamiento y activación

- ↓ Las RNA pueden trabajar en dos modos:
 - ↓ Aprendizaje: adapta sus pesos; su arquitectura; sus funciones de agrupamiento y activación
 - ↓ Reconocimiento o simulación: se usa la RNA para procesar información

- ↓ Aprendizaje de RNA:
 - ↓ Supervisado (vía ejemplos)
 - ↓ No-Supervisado





Figure - 1 A simple 2x3x1 NN. The lines connecting the neurons represent the weights. Also shown are the bias nodes used to shift the neuron transfer function and improves the network performance.



Entrenamiento Problema	Supervisado	No-Supervisado
Memorias Asociativas	Hopfield	
Clasificación Predicción Interpolación	Adaline- Perceptron MLP – TDNN LVQ – RBF	
Cuantización	LVQ	Kohonen ART

Entrenamiento Problema	Supervisado	No-Supervisado
Memorias Asociativas	Hopfield	
Clasificación Predicción Interpolación	Adaline- Perceptron MLP – TDNN LVQ – RBF	
Cuantización	LVQ	Kohonen ART

VI. Aprendizaje Profundo

Artificial Intelligence


Any technique which enables computers to mimic human behavior.

Machine Learning


Subset of AI techniques which use statistical methods to enable machines to improve with experiences.

Deep Learning

Subset of ML which make the computation of multi-layer neural networks feasible.




Simple Neural Network



● Input Layer


Deep Learning Neural Network



● Hidden Layer

● Output Layer


TRADITIONAL MACHINE LEARNING




DEEP LEARNING




Convolutional NN (CNN)




Long Short Term Memory (LSTM)




Autoencoders




Generative Adversarial Neural Nets (GAN)




Transformers



VII Aplicaciones





AI APPLICATIONS



Image Classification Object Detection


COMPUTER VISION





Voice Recognition Language Translation


SPEECH & AUDIO






Recommendation Engines Sentiment Analysis

NATURAL LANGUAGE PROCESSING



VIII *Reseña Histórica*



S. McCulloch - W. Pitts



F. Rosenblatt



B. Widrow - M. Hoff



M. Minsky - S. Papert




D. Rumelhart - G. Hinton - R. Williams




V. Vapnik - C. Cortes




G. Hinton - S. Ruslan




- Adjustable Weights
- Weights are not Learned




- Learnable Weights and Threshold




- XOR Problem



- Solution to nonlinearly separable problems
- Big computation, local optima and overfitting



- Limitations of learning prior knowledge
- Kernel function: Human Intervention



- Hierarchical feature Learning

Deep Learning Timeline

