

Universidad de Santiago de Chile

Departamento de Ingeniería Informática

Fundamentos Aprendizaje Profundo Perceptron

Dr. Gonzalo Acuña L.

Marzo 2019

I . Introducción

- Hay un problema transversal que es el de la “*aproximación de funciones*” que en el caso de sistemas estáticos puede diferenciarse en al menos otros dos subproblemas:
 - Clasificación
 - Regresión



- Clasificación:
 - Se trata de aproximar una función que represente la probabilidad de pertenencia de un cierto objeto -caracterizado por un conjunto de variables de entrada, continuas o discretas- a una clase determinada (salida con valores discretos). Ejemplo: reconocimiento de caracteres.

$$y = f(x, w)$$


Gonzalo Acuña L
USACH-DIINF

a

b



$$\frac{\text{Alto}}{\text{Ancho}} = r$$



- **Clasificación y funciones discriminantes**
- Cómo se puede realizar una clasificación?
 - Mediante el uso de funciones discriminantes que están definidas en el espacio de vectores que se desea clasificar y producen un valor real que se puede comparar.

- Se tiene una función (g_i) por clase (s_i)
- La regla de clasificación es:
$$u \in s_i \text{ si } g_i(u) > g_j(u); j \neq i$$
- Para problemas de dos clases se puede reducir a una función: $g(u) = g_1(u) - g_2(u)$, luego $u \in s_1$ si $g(u) > 0$ y $u \in s_2$ si no.

- Regresión:
 - Se trata de aproximar la función generadora (desconocida) de un cierto proceso mediante otra que mapee elementos del conjunto de variables de entrada pertinentes en otros del conjunto de variables de salida. Usualmente aquí se trata con valores continuos.

$$y = f(x, w)$$


II. Perceptron

Frank Rosenblatt, 1957




- In a 1958 New York Times article, Rosenblatt conveys an ambitious (prescient?) vision of the future of machine learning. The article refers to Rosenblatt's perceptron as “the embryo of an electronic computer that [the Navy] expects will be able to walk, talk, see, write, reproduce itself and be conscious of its existence.”

- Idea base: Entender capacidad de organismos para reconocimiento perceptivo recuerdo y pensamiento:
 - Cómo la información del mundo físico es percibida y/o detectada por un sistema biológico ?
 - De qué forma la información es almacenada o recordada ?
 - Cómo la información almacenada en la memoria influye para el reconocimiento y el comportamiento ?





**SENSORY RECEPTOR
ON
PROJECTION AREA**

A - UNITS



- Red de “3 capas” la última de ellas con función de transferencia de tipo umbral lógico diseñada para tarea de clasificación
- retina - células de asociación – unidad de decisión







- **Clasificación lineal mediante Perceptron**


- El Perceptron realiza una *función discriminante lineal*:

$$g(u) = a_1 u_1 + a_2 u_2 + \dots + a_n u_n + a_{n+1} = a \cdot u$$

El valor asociado a $g(u) = 0$ corresponde a la frontera, un hiperplano, que separa las dos clases.

- Los perceptrones son adecuados sólo para clases linealmente separables.
- El problema de aprendizaje se reduce a encontrar un hiperplano que separa a las clases.






$$a = X_0 \omega_0 + X_1 \omega_1 = \theta$$

$$\Rightarrow X_1 = -\frac{\omega_0}{\omega_1} X_0 + \frac{\theta}{\omega_1}$$

Si $\theta = 0$

$$\Rightarrow \begin{bmatrix} x_0 & x_1 \end{bmatrix} \begin{bmatrix} \omega_0 \\ \omega_1 \end{bmatrix} = 0$$

$\Rightarrow x \perp w !!$



REGLA DE APRENDIZAJE

$y(x) = \text{Ø} (W \cdot \bar{X})$: Salida del perceptron

$\hat{y}(x) =$ Salida deseada $\in \{1, -1\}$

$\Delta_{W_k} =$	$\eta \cdot (\hat{y}(x_k) - y(x_k)) \cdot x_k$
$W_{K+1} =$	$W_K + \Delta W_K$

ó

$$\Delta_{W_K} = \begin{cases} 0 & \text{si la salida es correcta} \\ + 2 \eta \cdot x_k & \text{Si } \hat{y}(x_k) = 1, y(x_k) = -1 \\ - 2\eta \cdot x_k & \text{Si } \hat{y}(x_k) = -1, y(x_k) = 1 \end{cases}$$

$n > 0$; $\{X_1, \dots, X_k\}$: Secuencia de entrada

- Convergencia del algoritmo de aprendizaje del Perceptron:

Está demostrada para problemas linealmente separables y lo logra en un número finito de pasos (*Haykin, Neural Networks and Learning Machines, 2009*)

$$W^T X > 0 \quad X \in \mathcal{C}_1$$

$$W^T X \leq 0 \quad X \in \mathcal{C}_2$$

Si hay error:

$$W(m+1) = W(m) - \overset{1}{\cancel{\eta}} X(m) \quad X \in \mathcal{C}_2$$

$$W(m+1) = W(m) + \overset{1}{\cancel{\eta}} X(m) \quad X \in \mathcal{C}_1$$

$$W(0) = 0 \quad 1$$

Supongamos $W^T X < 0$ y $X \in \mathcal{C}_1$

$$\Rightarrow W(m+1) = X(1) + X(2) + \dots + X(m)$$

Supongamos una configuración de parámetros W_0 que clasifica correctamente $X(1) \dots X(m)$

Definimos $\alpha = \min_{x(m) \in \mathcal{S}_1} w_0^T x(m)$

$$\Rightarrow w_0^T w(m+1) = w_0^T x(1) + w_0^T x(2) + \dots + w_0^T x(n)$$

$$\Rightarrow w_0^T w(m+1) \geq n \alpha$$

Por desigualdad Cauchy-Schwarz:

$$\|w_0\|^2 \|w(m+1)\|^2 \geq n^2 \alpha^2$$

$$\Rightarrow \|w(m+1)\|^2 \geq \frac{n^2 \alpha^2}{\|w_0\|^2}$$

Recomenzando:

$$w(m+1) = w(m) + x(m) \quad \forall m$$

$$\|w(k+1)\|^2 = \|w(k)\|^2 + \|x(k)\|^2 + 2w^T(k)x(k)$$

pero como se supone que
 $x \in \mathcal{C}_1$ fue mal clasificado,
 entonces $w^T(k)x(k) < 0$

$$\Rightarrow \|w(k+1)\|^2 \leq \|w(k)\|^2 + \|x(k)\|^2$$

$$\text{o } \|w(k+1)\|^2 - \|w(k)\|^2 \leq \|x(k)\|^2$$

Dado que: $w(0) = 0$

$$\Rightarrow \|w(k+1)\|^2 \leq \sum_{h=1}^n \|x(h)\|^2 \leq n\beta$$

$$\text{con } \beta = \max_{x(h) \in \mathcal{C}_1} \|x(h)\|^2$$

Hay contradicción !!
 $\Rightarrow$ Hay un $M_{\max}$ que
 satisface ambas
 condiciones.


$\Rightarrow M_{max}$ es la solución de la ec:

$$\frac{M_{max}^2 \alpha^2}{\|w_0\|^2} = M_{max} \beta$$

$$\Rightarrow M_{max} = \frac{\beta \|w_0\|^2}{\alpha^2}$$

$\Rightarrow$ se demuestra que, para $\eta = 1$, $w(0) = 0$, y dado que existe solución w_0 , la adaptación de los pesos termina a lo mas en la iteración M_{max} .

- Espacio de salida para compuerta AND



- Espacio de salida para compuerta XOR
- $\Rightarrow$ necesidad de capa oculta

