

Universidad de Santiago de Chile

Departamento de Ingeniería Informática

Fundamentos Aprendizaje Profundo Adaline

Dr. Gonzalo Acuña L.


Marzo 2019


Temario


- I. El problema de regresión lineal y mínimos cuadrados
- II. Máxima Verosimilitud
- III. Entropía e Información
- IV. Adaline




I. - El problema de regresión lineal y los mínimos cuadrados







THE REDISCOVERY OF CERES



THE ASTEROID CERES

The great German mathematician Carl Fredrich Gauss accepted the challenge

He developed the first crude method of determining an orbit without hypothesis as to the period or eccentricity of the elliptical orbit



CARL FREDRICH GAUSS

The first minor planet (asteroid) Ceres was found sweeping around the sun on January 1, 1801.

However, it was lost in the sun's rays after only 41 days . . .

. . . and there was every reason to believe it would never be recognized again.

THE LEAST SQUARES EQUATIONS IN MATRIX NOTATION

$$\{\Delta u_j\} = \left(\sum_{i=1}^Q \left[\frac{\partial r^i}{\partial u} \right]^T [W] \left[\frac{\partial r^i}{\partial u} \right] \right)^{-1} \cdot \left(\sum_{i=1}^Q \left[\frac{\partial r^i}{\partial u} \right]^T [W] \{\Delta r^i\} \right)$$

WITH HIS HELP, CERES WAS REDISCOVERED
ON THE LAST DAY OF THE YEAR!

Estimación por Mínimos Cuadrados

$$\begin{aligned} e'e &= (Y - X\beta)'(Y - X\beta) = (Y' - \beta'X')(Y - X\beta) = \\ &= Y'Y - \beta'X'Y - Y'X\beta + \beta'X'X\beta = \\ &= Y'Y - 2\beta'X'Y + \beta'X'X\beta \end{aligned}$$

1 Condición: $\frac{\partial e'e}{\partial \hat{\beta}} = -2'X'Y + 2'X'X\hat{\beta} = 0$

Sistema de ecuaciones normales: $X'X\hat{\beta} = X'Y$

$$\hat{\beta} = (X'X)^{-1}X'Y$$

Ejemplo : Energía Eólica

Velocidad Viento (x_1)	Personas al interior edificio (x_2)	Requerimiento Energía (y)
100	2	5
50	42	25
45	31	22
60	35	18


Modelo : $y = \theta_0 + \theta_1 x_1 + \theta_2 x_2$

$$X = \begin{bmatrix} 1 & 100 & 2 \\ 1 & 50 & 42 \\ 1 & 45 & 31 \\ 1 & 60 & 35 \end{bmatrix} \quad Y = \begin{bmatrix} 5 \\ 25 \\ 22 \\ 18 \end{bmatrix}$$


$$\theta = (X^T X)^{-1} X^T Y$$

$$\Rightarrow \theta = \begin{bmatrix} 24,98 \\ -0,21 \\ 0,21 \end{bmatrix}$$

II.- Máximo de Verosimilitud (Maximum Likelihood)



Standard normal distribution
(Mean = 0 Standard deviation = 1)



$$y = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

μ = Mean

σ = Standard Deviation

$\pi \approx 3.14159 \dots$

$e \approx 2.71828 \dots$

Máxima Verosimilitud:

Ejemplo:

Sopongamos 3

datos, $y_1 = 1$; $y_2 = 0,5$; $y_3 = 1,5$.

Independientes, gaussianos,
con media desconocida y
varianza 1.



$$y_i \sim N(\theta, 1) = \theta + N(0, 1)$$

$\Rightarrow$ Verosimilitud:

$$P(y_1, y_2, y_3 | \theta) = P(y_1 | \theta) P(y_2 | \theta) P(y_3 | \theta)$$

Consideremos ahora dos
adivinanzas para θ : $\nearrow 1,0$
 $\searrow 2,5$

¿Cuál de las dos con más
probabilidad (verosimilitud)
generará los datos?




Verosimilitud para Regresión lineal

Cada salida y_i está distribuida normalmente con media $x_i^T \theta$ y varianza σ^2 :

$$y_i = \mathcal{N}(x_i^T \theta, \sigma^2) = x_i^T \theta + \mathcal{N}(0, \sigma^2)$$

$$\begin{aligned} p(y/X, \theta, \sigma) &= \prod_{i=1}^n p(y_i / x_i, \theta, \sigma) \\ &= \prod_{i=1}^n (2\pi\sigma^2)^{-1/2} e^{-\frac{1}{2\sigma^2} (y_i - x_i^T \theta)^2} \\ &= (2\pi\sigma^2)^{-n/2} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - x_i^T \theta)^2} \\ &= (2\pi\sigma^2)^{-n/2} e^{-\frac{1}{2\sigma^2} (y - X\theta)^T (y - X\theta)} \end{aligned}$$

$J(\theta)$ ←



La máxima verosimilitud
se obtiene derivando el
 $\log(\text{verosimilitud})$:

$$p(y/X, \theta, \sigma) = (2\pi\sigma^2)^{-n/2} e^{-\frac{1}{2\sigma^2} (y - X\theta)^T (y - X\theta)}$$

$$l(\theta) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} (y - X\theta)^T (y - X\theta)$$

$$\Rightarrow \frac{\partial}{\partial \theta} \frac{1}{2\sigma^2} (y - X\theta)^T (y - X\theta) = 0$$


$$\Rightarrow \theta_{MV} = (X^T X)^{-1} X^T y$$

IGUAL QUE MÍNIMOS
CUADRADOS !!

Entropía

$$H(x) = \sum_x p(x/\theta) \log p(x/\theta)$$

Medida de incertidumbre




El punto es INFORMACIÓN

IV.- Redes Monocapa: Adaline




- **Historia: Widrow - Hoff, 1960**
- **Al igual que en el caso del Perceptron, se desarrolló en forma independiente para resolver el problema de clasificación**
- **Adecuado cuando las clases son linealmente separables**




Regla Delta o LMS (Least Mean Squared)

- 1.- Inspirada por la necesidad de diseñar un Filtro de Wiener en la práctica, contando sólo con información de entrada-salida.
- 2.- Paso 1: Crear una función del Error $J=f(e)$. Normalmente una cuadrática.
- 3.- Paso 2: Encontrar el mínimo de J jugando sobre el valor de los pesos w del Adaline.



How to Learn Perceptron?

Delta Learning Rule



$$v_{jk}^{(\tau+1)} = v_{jk}^{\tau} + \Delta v_{jk}$$

$$\Delta v_{jk} = -\eta \frac{\partial E}{\partial v_{jk}}$$

$v_{jk}^{(\tau+1)}$	new weight
v_{jk}^{τ}	current weight
η	learning rate
E	Error Function

- Widrow y Hoff descubrieron que el gradiente, útil para ir adaptando los pesos siguiendo una regla de gradiente descendente, podía ser estimado fácilmente a partir del error “instantáneo” (no medio - como lo exige el método mínimos cuadrados) y el vector de entrada al Adaline.

Regla de Widrow-Hoff


- Basada en el **DESCENSO DE GRADIENTE**
- η **Factor de Aprendizaje**

$$\Delta \mathbf{w} = -\eta \nabla_{\mathbf{w}} E(\mathbf{w})$$

$$\Delta w_i = -\eta \frac{\partial E(\mathbf{w})}{\partial w_i} = \eta \sum_{k=1}^p (\mathbf{d}^k - \mathbf{w}^T \mathbf{x}^k)^2 x_i^k$$

- Si los cambios se hacen individualmente para cada patrón de entrada:

$$\Delta w_i = \eta (\mathbf{d}^k - \mathbf{w}^T \mathbf{x}^k) x_i^k$$



Error cuadrático

$$E = \sum_{s \in S} E^s = \frac{1}{2} \sum_{s \in S} |\hat{y}^s - y^s|^2$$

con

$\hat{y}_s$: vector de valores de salida deseados

y_s : vector de salida de la red

E : $\frac{1}{2} \sum_{s \in S} |\hat{y}_s - y_s|^2$ medida del error cuadrático.

Para la muestra

S : conjunto de muestras (entrenamiento)

$$y(t) = W \cdot X(t)$$

$$J = \frac{1}{2} (d(t) - y(t))^2$$

$$\frac{\partial J}{\partial w_i} = \sum_{j=1}^N -(d - w_j X_j) X_i$$

$$\Rightarrow W(t+1) = W(t) + \alpha (d(t) - y(t)) X(t)$$

Programa

CONFERENCISTAS:

Conferencistas de Plenarias:

- [Dr. Bernard Widrow](#), Stanford University
- [Dr. Russell Eberhart](#), Indiana University Purdue University Indianapolis (IUPUI)
- [Dr. Jacek Zurada](#), U. of Louisville, president IEEE Computational Intelligence Society
- [Dr. Theodore Cohn](#), University of California, Berkeley, EEUU

[UP]

Conferencistas de Tutoriales:

- Dr. Kazumi Saito, NTT Communication Science Lab., Kyoto, Japón
- Dr. Michael Packianather, Manufacturing Engineering Centre, Cardiff University, Reino Unido
- Dr. Aureli Soria, Fraunhofer IPK-Berlin, Alemania
- Dr. Javier Ruiz del Solar, DIE, Universidad de Chile
- Dr. Pablo Estévez, DIE, Universidad de Chile
- Dr. Aldo Cipriano, DIE, Pontificia Universidad Católica de Chile
- Dr. Pablo Zegers, Universidad de Los Andes, Chile
- Dr. Claudio Held, DIE, Universidad de Chile
- Dr. Doris Sáez, DIE, Universidad de Chile
- Dr. Richard Weber, DIE, Universidad de Chile

[UP]

Concurso de Posters:

Durante la escuela de verano se desarrollará una competencia de posters, los competidores deben ser graduados o alumnos de postgrado que presenten sus trabajos de investigación/tesis en Inteligencia Computacional.

El primer premio ganará un certificado y US\$200.

Más información.

[UP]

Programa:

Diciembre 2004	Lunes 13
09:00 - 0 9:30	Ceremonia de Apertura
09:30 - 11:00	Plenaria 1, "Neural Networks and Signal Processing", Dr. Bernard Widrow
11:00 - 11:30	Coffee Break
11:30 - 13:00	Plenaria 2, "Particle Swarm Optimization", Dr. Russell Eberhart
13:00 - 14:30	Lunch (*)
14:30 - 16:00	T1-A "Neural network paradigm and its application", Dr. Michael Packianather
**	T2-A "Aspectos teóricos y prácticos de lógica difusa", Dr. Claudio Held & Dr. Doris Sáez
16:00 - 16:30	Coffee Break
16:30 - 18:00	T1-B "Neural network paradigm and its application", Dr. Michael Packianather