

Universidad de Santiago de Chile

Departamento de Ingeniería Informática

Fundamentos Aprendizaje Profundo Perceptron Multicapa

Dr. Gonzalo Acuña L.


Marzo 2019


Temario

- I. Perceptron Multicapa
- II. Método de Retropropagación del Error
- III. Retropropagación usando gradiente descendente
- IV. Mejoras a Gradiente Descendente




I.- Perceptron Multicapa






$$\theta_1 := \theta_1 - \alpha \frac{\partial}{\partial \theta_1} J(\theta_1)$$

If α is too small, gradient descent can be slow.




$$J = e^2(n) = (d(n) - wx(n))^2$$

$$\begin{aligned}\frac{dJ}{dw} &= 2(d(n) - wx(n)) \frac{d(d(n) - wx(n))}{dw} \\ &= -2e(n)x(n)\end{aligned}$$




Multi Layer Perceptron




Redes Multicapas

Definición :

Red en la que sus neuronas están ordenadas en capas o estratos sucesivos. Cada capa recibe entradas desde la capa previa (o entrada externa) y envía sus salidas a la capa siguiente. No hay conexiones internas en cada capa.








II.- Método de Retropropagación del Error

Rumelhart y McClelland: la hipótesis conexionista

Gonzalo Acuña L
USACH-DIINF






Gonzalo Acuña L
USACH-DIINF

$$J = \frac{1}{2} \bar{Z} e^2$$

Mínimos
cuadrados





Backpropagation

Gonzalo Acuña L
USACH-DIINF

Modificación de los
pesos de la Red

Retropropagación
del error





$$\therefore y = \frac{1}{1 + e^{-a}}$$

$$a = \sum_i x_i w_i$$

$$\Rightarrow y = \frac{1}{1 + e^{-(x_1 w_1 + x_2 w_2 + x_3 w_3 + w_4)}}$$

$$e = y_d - \hat{y} = y_d - \frac{1}{1 + e^{- (x_1 w_1 + x_2 w_2 + x_3 w_3 + w_4)}}$$

Gonzalo Acuña L
USACH-DIINF


$$\Rightarrow J = \frac{1}{2} e^2$$

$$= \frac{1}{2} \left[y_d - \frac{1}{1 + e^{- (x_1 w_1 + x_2 w_2 + x_3 w_3 + w_4)}} \right]^2$$



Retropropagación

Gonzalo Acuña L
USACH-DIINF



$$w_{t+1} = w_t + \eta d_t = w_t + \eta \left(-\frac{\partial J_t}{\partial w} \right)$$

- Ejemplo:

$$J = \frac{1}{2}(y_t - d_t)^2 = \frac{1}{2} \left[f(\underbrace{O_1 w'_{11} + O_2 w'_{21} + w'_{31}}_{a'_1}) - d_t \right]^2$$

- Capa Salida:

$$\frac{\partial J}{\partial w_{11}} = (y_t - d_t) \cdot f' \cdot O_1 = \underbrace{(y_t - d_t) y_t (1 - y_t)}_{\delta'_t} O_1$$

Sea $f(x) = \frac{1}{1 + e^{-x}}$

$$\Rightarrow f'(x) = \frac{\partial (1 + e^{-x})^{-1}}{\partial x} = -(1 + e^{-x})^{-2} \cdot (-e^{-x})$$


$$= \frac{e^{-x}}{(1 + e^{-x})^2} = \frac{1 + e^{-x} - 1}{(1 + e^{-x})^2}$$

$$= \frac{1}{1 + e^{-x}} - \frac{1}{(1 + e^{-x})^2} = y - y^2$$

$$\Rightarrow f'(x) = y(1 - y)$$

$$\delta' = e \cdot f'$$

Gonzalo Acuña L
USACH-DIINF



$$\Rightarrow \frac{\partial J}{\partial w_{11}} = \sigma_1 \cdot e \cdot f'$$

$f(a) = a$ (Función de transferencia lineal)

$$\Rightarrow \frac{\partial J}{\partial w_{11}} = \sigma_1 \cdot e \Rightarrow w_{11 \text{ new}} = w_{11 \text{ old}} + \alpha \cdot \sigma_1 \cdot e$$

(Adalvne)

- Capa Escondida:

$$\frac{\partial J}{\partial w_{11}} = \frac{\partial J}{\partial a'} \cdot \frac{\partial a'}{\partial O_1} \cdot \frac{\partial O_1}{\partial w_{11}} \quad (\text{Regla de la cadena})$$

$$= \underbrace{(y_t - d_t) y_t (1 - y_t)}_{\delta'_t} \cdot w'_{11} \cdot O_1 (1 - O_1) X_1$$

$$= \underbrace{\delta'_t \cdot w'_{11} \cdot O_1 \cdot (1 - O_1)}_{\delta_t} X_1$$

$\Rightarrow \frac{\partial J}{\partial w} = \underbrace{\delta \cdot w'}_{\text{"error"}} \cdot f' \cdot X$
retropropagado

- Si varias salidas:

$$= \underbrace{\sum_k \delta'_k w'_{jk} \cdot O_1 (1 - O_1)}_{\delta_t} \cdot X_1$$

$$J = \frac{1}{2} e^2 = \frac{1}{2} (y - d)^2 = \frac{1}{2} (\underbrace{f(a')}_y - d)^2$$

$$\Rightarrow \frac{\partial J}{\partial a'} = (\underbrace{f(a')}_y - d) \cdot f' \cdot 1$$

para

$$f(a') = \frac{1}{1 + e^{-a'}}$$

$$\Rightarrow \frac{\partial J}{\partial a'} = (y - d) \cdot \underbrace{y(1 - y)}_{f'}$$

Gonzalo Acuña L
USACH-DIINF

$$a' = o_1 w_{11}' + o_2 w_{21}' + w_{31}'$$

$$\Rightarrow \frac{\partial a'}{\partial o_1} = w_{11}'$$

Gonzalo Acuña L
USACH-DIINF

$$o_1 = f(a) = f(x_1 w_{11} + x_2 w_{21} + w_{31})$$

$$\Rightarrow \frac{\partial o_1}{\partial w_{11}} = f' \frac{\partial a}{\partial w_{11}} = f' \cdot x_1$$

Gonzalo Acuña L
USACH-DIINF

$$= \underbrace{\sigma_1 (1 - o_1)}_{f'}$$

para $f(a) = \frac{1}{1 + e^{-a}}$




$$\Leftarrow \delta = \underbrace{\delta' w_{11}'}_{\text{"error"}} \cdot f'$$

$$\Downarrow \frac{\partial J}{\partial w_{11}} = x \cdot \delta$$


$$\Leftarrow \delta' = e \cdot f'$$

$$\Downarrow \frac{\partial J}{\partial w_{11}'} = \delta_1 \cdot \delta'$$




$$\Downarrow \frac{\partial J}{\partial w'} = \sigma \cdot \delta'$$

$$\dots \Downarrow \frac{\partial J}{\partial w} = x - \sigma$$



Gonzalo Acuña L
USACH-DIINF

Arquitectura Backpropagation




Gonzalo Acuña L
USACH-DIINF

Respirando

- Retropropagación nos otorga una manera descentralizada y expedita de calcular **GRADIENTES**
- Por qué gradientes?



$$w_{k+1} = w_k + a \cdot d$$
$$- \frac{\partial J}{\partial w_i}$$






$$\frac{\partial J}{\partial w_i} = x_i \cdot \underbrace{f' \cdot e_j}_{\delta_i}$$

$$e_j = w_j \cdot \delta_j$$

$$\frac{\partial J}{\partial w_i} = x_i f' e_j$$





III.- Retropropagación usando gradiente descendente

Gonzalo Acuña L
USACH-DIINF

- Ventajas:
 - Implementación simple
 - Método estándar que generalmente funciona bien
- Desventajas:
 - Lento e ineficiente
 - Puede quedar atrapado en mínimos locales entregando resultados sub-óptimos

- Métodos de Gradiente

- En General:

$$w_{k+1} = w_k + \underbrace{a}_{\substack{\text{amplitud} \\ \text{paso búsqueda}}} \cdot \underbrace{d}_{\text{dirección}}$$

$$\text{Gradiente : } w_{k+1} = w_k + \underbrace{a}_{\uparrow} \underbrace{d}_{\sim} (-\nabla w)$$

Problema: Convergencia lenta. Tendencia a quedar atrapada en mínimos locales

- Ejemplo:


$$J(w) = w^2 \quad y \quad \alpha = 1$$

$$\text{Si: } w_k = 1 \Rightarrow w_{k+1} = 1 + 1 \cdot (-2w_k) = -1$$

$$w_{k+2} = -1 + 1 \cdot (-2w_k) = 1$$

$\vdots$



etc...




IV.- Mejoras a Gradiente Descendente


Gonzalo Acuña L
USACH-DIINF

- Momentum
 - Añade porcentaje del último movimiento al actual






suitable step size



too small step size




too large step size

↓ La opción de calcular en forma elegante y eficiente el gradiente permite tratar el problema de optimización con toda la batería de métodos de optimización que proporciona la optimización en sistemas no-lineales.

Métodos de optimización

- Gradiente Conjugado
- Quasi-Newton
- Simulated Annealing
- Algoritmos genéticos
- ...etc



$$\text{Min } J = \frac{1}{2} \sum_{i=tsh}^{tk} [Y_i - \hat{Y}_i]^2$$

Gonzalo Acuña L
USACH-DIINF

¿Deterministas o Estocásticos?

Gradiente Conjugado

Gonzalo Acuña L
USACH-DIINF



$$d_k = -\nabla J_{wk} + \beta d_{k-1}$$

Fletcher y Reeves...

Gonzalo Acuña L
USACH-DIINF

- Etapa de inicialización:
 - Seleccionar un punto de partida x_0
 - Calcular $d_0 = -g_0 = -\nabla f(x_0)$
- Etapa iterativa
 - Determinar λ_k que minimiza $x_{k+1} = x_k + \lambda_k \cdot d_k$
en la dirección d_k
 - Calcular $d_{k+1} = -g_{k+1} + \beta_k \cdot d_k$ donde $\beta_k = \frac{g_{k+1}^T \cdot g_{k+1}}{g_k^T \cdot g_k}$

- Es una extensión del método de gradiente conjugado a funciones cualquiera (**no necesariamente cuadráticas**) y **sin la utilización explícita del Hesiano**.

Métodos 2º orden tipo Newton

Gonzalo Acuña L
USACH-DIINF

- Taylor de $J(w)$:

$$J(w) = J_0 + (w - w_0)\nabla J(w_0) + \frac{1}{2}(w - w_0)H(w - w_0) + \dots \quad (1)$$

$$\nabla J = \frac{\partial J}{\partial w_i} \quad H_{ij} = \frac{\partial^2 J}{\partial w_i \partial w_j}$$


Derivando (1):

$$\nabla J(w) = \nabla J(w_0) + H(w - w_0) + \dots \quad (2)$$

$$\Rightarrow \text{mínimo} \Rightarrow \nabla J(w) = 0$$

$$\Rightarrow 0 = \nabla J(w_0) + H(w - w_0)$$

$$\Rightarrow w = w_0 - H^{-1}\nabla J(w_0)$$



- Ejemplo:

$$J(w) = w^2; \quad w_0 = 1$$

$$\frac{\partial J}{\partial w} = 2w; \quad \frac{\partial^2 J}{\partial w^2} = 2$$

$$\Rightarrow w_1 = 1 + \frac{1}{2}(-2w)_1 = 0$$

$$w_2 = 0 + \frac{1}{2}(-2w)_0 = 0$$

- Quasi-Newton:

- H^{-1} se aproxima en forma recursiva.
- BFGS $\rightarrow$ Broyden, Fletcher, Goldfarb, Shanno


Broyden, Fletcher, Goldfarb, Shanno



Métodos Quasi-Newton

$$x_{k+1} = x_k - \alpha_k \cdot [\nabla^2 f(x_k)]^{-1} \cdot g_k$$

G_k es una aproximación convenientemente elegida de $\dots \nabla^2 f(x_k)$



- Hay muchas formas de actualizar la matriz G o su inversa S y que satisfacen los criterios para anteriores.

$$G_{k+1} = G_k + \frac{(q_k - G_k \cdot p_k) \cdot (q_k - G_k \cdot p_k)^T}{p_k^T \cdot (q_k - G_k \cdot p_k)}$$

$$S_{k+1} = S_k + \frac{(p_k - S_k \cdot q_k) \cdot (p_k - S_k \cdot q_k)^T}{q_k^T \cdot (p_k - S_k \cdot q_k)}$$

Levenberg - Marquardt

- Modificación de Gauss-Newton

$$w_{k+1} = w_k - [J_k^T J_k + \mu_k I]^{-1} J_k^T r_k$$

*Aproximación
Hessiano*

- Ventajas:
 - Bien definido aunque J no sea de rango pleno
 - Globalmente convergente

✖ Сейчас не удается отобразить рисунок.

Levenberg-Marquardt method



- Problems in Newton method:
 - Bad convergence / divergence when far from optimum
 - What to do when $\mathbf{H}$ singular / not positive definite?
- Remedy: use modified $\mathbf{H}$: $\tilde{\mathbf{H}} = \mathbf{H} + \beta \mathbf{I}$
with β such that $\mathbf{H}$ positive definite
- Levenberg-Marquardt method: start with large β_k , and decrease gradually:

β large: $\mathbf{s}_k = -(\mathbf{H} + \beta_k \mathbf{I})^{-1} \nabla f \approx -\nabla f$ Steepest descent

β small: $\mathbf{s}_k = -(\mathbf{H} + \beta_k \mathbf{I})^{-1} \nabla f \approx -\mathbf{H}^{-1} \nabla f$ Newton

Name	Update
(Full) Newton Descent	$\mathbf{v}^{(k+1)} \leftarrow \mathbf{v}^{(k)} - H^{-1}G$
Quasi-Newton Descent	$\mathbf{v}^{(k+1)} \leftarrow \mathbf{v}^{(k)} - \tilde{H}^{-1}G$
Steepest Descent	$\mathbf{v}^{(k+1)} \leftarrow \mathbf{v}^{(k)} - \lambda G$
Levenberg Marquardt	$\mathbf{v}^{(k+1)} \leftarrow \mathbf{v}^{(k)} - ((\mathbf{1} + \lambda \mathbf{I})\tilde{H})^{-1}\mathbf{G}$

