

Análisis de Componentes Principales

(ACP / PCA)

Resumen intensivo de 1 hora

Fórmulas matemáticas + Resolución paso a paso

Inteligencia Computacional
Magíster en Ingeniería Informática
Universidad de Santiago de Chile

Prof. Max Chacón Pacheco
Ayudante: Sebastián Chávez Orellana
Primer semestre 2026

Índice

1. Plan de estudio (60 minutos)	2
2. Idea central de PCA (5 min)	2
3. Fórmulas matemáticas fundamentales (15 min)	2
3.1. Paso 1 — Centrado (y opcionalmente estandarización)	2
3.2. Paso 2 — Matriz de covarianza (o correlación)	3
3.3. Paso 3 — Descomposición espectral	3
3.4. Paso 4 — Loadings y Scores	3
3.5. Paso 5 — Varianza explicada	4
3.6. Criterios para elegir el número de componentes	4
3.7. Reconstrucción	4
4. Interpretación geométrica (10 min)	4
4.1. Biplot: scores + loadings en un mismo gráfico	5
4.2. Reglas de interpretación del biplot	5
4.3. Coseno del ángulo entre loadings	5
5. Plantilla universal para resolver ejercicios (5 min)	5
6. Resolución paso a paso de los ejercicios (25 min)	6
6.1. P1 — Consumo alimenticio de familias francesas	6
6.2. P2 — Billetes falsos suizos	7
6.3. P3 — Servicios hospitalarios de Andalucía	7
6.4. P4 — Sector lechero venezolano	8
6.5. P5 — Neoplasias (tumores)	8
6.6. P6 — Barómetro Merco (50 empresas)	9
6.7. P7 — Clasificación de neuronas (6 tipos)	9
7. Tips de examen (5 min)	10
8. Tabla resumen de fórmulas (1 carilla)	11

1. Plan de estudio (60 minutos)

Tiempo	Tema	Objetivo
0–10 min	Intuición + fórmulas base	Entender qué hace PCA y por qué
10–25 min	Derivación matemática	Covarianza $\rightarrow$ autovalores $\rightarrow$ componentes
25–35 min	Interpretación geométrica	Loadings, scores, biplot, ángulos
35–55 min	Resolución de ejercicios	Plantilla universal P1–P7
55–60 min	Tips de examen	Errores comunes y atajos

2. Idea central de PCA (5 min)

¿Qué hace PCA?

PCA encuentra un nuevo sistema de coordenadas (rotación de los ejes originales) tal que:

- El **primer eje (PC1)** captura la máxima varianza de los datos.
- El **segundo eje (PC2)** captura la máxima varianza *restante*, siendo ortogonal a PC1.
- Así sucesivamente para PC3, PC4, ...

Objetivo: reducir dimensionalidad conservando la mayor cantidad posible de información (varianza).

Insumos: matriz de datos $X \in \mathbb{R}^{n \times p}$ con n observaciones y p variables.

Salidas: autovalores λ_k , autovectores $\mathbf{v}_k$, scores T , loadings W .

3. Fórmulas matemáticas fundamentales (15 min)

3.1. Paso 1 — Centrado (y opcionalmente estandarización)

Centrado y estandarización

Sea $X \in \mathbb{R}^{n \times p}$. La media por columna es:

$$\boldsymbol{\mu} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \in \mathbb{R}^p$$

La matriz centrada:

$$X_c = X - \mathbf{1}_n \boldsymbol{\mu}^T$$

Si las variables tienen *escalas distintas* (lo más común en problemas reales), se estandariza:

$$X_{\text{std}}[i, j] = \frac{X[i, j] - \mu_j}{\sigma_j}, \quad \sigma_j = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X[i, j] - \mu_j)^2}$$

3.2. Paso 2 — Matriz de covarianza (o correlación)

Matriz de covarianza/correlación

$$\Sigma = \frac{1}{n-1} X_c^T X_c \in \mathbb{R}^{p \times p}$$

Es simétrica y positiva semidefinida. Si los datos están **estandarizados**, entonces Σ es la **matriz de correlación** R .

Elementos:

$$\Sigma_{jk} = \text{Cov}(X_j, X_k), \quad R_{jk} = \frac{\text{Cov}(X_j, X_k)}{\sigma_j \sigma_k}$$

3.3. Paso 3 — Descomposición espectral

Problema de autovalores

Se resuelve:

$$\Sigma \mathbf{v}_k = \lambda_k \mathbf{v}_k, \quad k = 1, \dots, p$$

con la restricción $\|\mathbf{v}_k\| = 1$ y $\mathbf{v}_j^T \mathbf{v}_k = 0$ si $j \neq k$.

Los autovalores se ordenan de mayor a menor:

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$$

Forma matricial (diagonalización):

$$\Sigma = V \Lambda V^T, \quad V = [\mathbf{v}_1 | \mathbf{v}_2 | \dots | \mathbf{v}_p], \quad \Lambda = \text{diag}(\lambda_1, \dots, \lambda_p)$$

3.4. Paso 4 — Loadings y Scores

Loadings (cargas) y Scores (proyecciones)

Matriz de loadings (autovectores ordenados):

$$W = [\mathbf{v}_1 | \mathbf{v}_2 | \dots | \mathbf{v}_q] \in \mathbb{R}^{p \times q}$$

Scores (proyección de los datos en el nuevo sistema):

$$T = X_c \cdot W \in \mathbb{R}^{n \times q}$$

Cada fila t_i es la representación de la observación i -ésima en q componentes.

Propiedad clave: la varianza del score k -ésimo es exactamente λ_k :

$$\text{Var}(T_{\cdot, k}) = \lambda_k$$

3.5. Paso 5 — Varianza explicada

Métricas de calidad del análisis

Proporción de varianza explicada por la componente k :

$$\text{var_ratio}_k = \frac{\lambda_k}{\sum_{j=1}^p \lambda_j}$$

Varianza acumulada (con las primeras q componentes):

$$\text{var_acum}(q) = \frac{\sum_{k=1}^q \lambda_k}{\sum_{j=1}^p \lambda_j}$$

Porcentaje de pérdida de información:

$$\text{pérdida}(q) = 1 - \text{var_acum}(q) = \frac{\sum_{k=q+1}^p \lambda_k}{\sum_{j=1}^p \lambda_j}$$

Caso especial con matriz de correlación: si se estandarizó, $\sum_j \lambda_j = p$ (número de variables), entonces:

$$\text{var_ratio}_k = \frac{\lambda_k}{p}$$

3.6. Criterios para elegir el número de componentes

Tres criterios clásicos

1. **Criterio de Kaiser:** retener componentes con $\lambda_k > 1$ (sólo si se trabajó con matriz de correlación).
2. **Umbral de varianza:** retener componentes hasta cubrir 70–90 % de la varianza total.
3. **Scree plot:** graficar λ_k vs k y buscar el "codo" (cambio abrupto de pendiente).

3.7. Reconstrucción

Reconstrucción de los datos originales

Con q componentes:

$$\hat{X}_c = T \cdot W^T = X_c W W^T$$

Error de reconstrucción (MSE):

$$\text{MSE}(q) = \frac{1}{np} \sum_{i,j} (X_c - \hat{X}_c)^2 = \frac{1}{p} \sum_{k=q+1}^p \lambda_k$$

4. Interpretación geométrica (10 min)

4.1. Biplot: scores + loadings en un mismo gráfico

Construcción del biplot

Scores (puntos): se grafican $T = X_c W$ directamente sobre los ejes PC1, PC2.

Loadings escalados (flechas): se escalan por $\sqrt{\lambda_k}$ para hacerlos visibles:

$$L_{\text{scaled}} = W \cdot \text{diag}(\sqrt{\lambda_1}, \sqrt{\lambda_2})$$

Cada fila $L_i \in \mathbb{R}^2$ es una flecha desde el origen que representa a la variable i -ésima.

4.2. Reglas de interpretación del biplot

Observación visual	Interpretación
Flecha larga	La variable contribuye mucho a esa componente
Flecha corta cerca del origen	Variable poco representada por PC1–PC2
Dos flechas paralelas (ángulo ≈ 0)	Variables correlacionadas positivamente
Dos flechas opuestas (ángulo ≈ 180)	Variables anticorrelacionadas
Flechas perpendiculares (≈ 90)	Variables no correlacionadas
Punto cercano a una flecha	La observación tiene valor alto en esa variable

4.3. Coseno del ángulo entre loadings

Correlación aproximada en el biplot

Para dos variables i y j con loadings $\mathbf{w}_i, \mathbf{w}_j \in \mathbb{R}^2$:

$$\cos(\theta_{ij}) = \frac{\mathbf{w}_i \cdot \mathbf{w}_j}{\|\mathbf{w}_i\| \|\mathbf{w}_j\|} \approx \text{corr}(X_i, X_j)$$

5. Plantilla universal para resolver ejercicios (5 min)

Receta de 7 pasos — sirve para TODOS los ejercicios P1–P7

Paso 1: Calcular varianza explicada / pérdida

$$\text{var_acum}(2) = \frac{\lambda_1 + \lambda_2}{\sum_k \lambda_k}, \quad \text{pérdida} = 1 - \text{var_acum}(2)$$

Paso 2: Graficar variables originales en el plano PC1–PC2

Cada variable i va al punto $(w_{i,1}, w_{i,2})$. Dibujar flechas desde el origen.

Paso 3: Interpretar cada componente

Mirar qué variables tienen *coeficientes grandes en valor absoluto* en esa componente.

- Si todas tienen el mismo signo $\rightarrow$ es una componente de "tamaño." "magnitud global".
- Si hay signos opuestos $\rightarrow$ es una componente de contraste. entre dos grupos de variables.

Paso 4: Clasificar las observaciones

Ver en qué cuadrante cae cada punto y qué variables apuntan a ese cuadrante.

Paso 5: Asociar variables a observaciones

Una observación cercana a una flecha tiene valores altos de esa variable.

Paso 6: Identificar correlaciones entre variables (ángulos entre flechas).**Paso 7: Concluir / responder la pregunta concreta** del enunciado.**6. Resolución paso a paso de los ejercicios (25 min)****6.1. P1 — Consumo alimenticio de familias francesas****P1 · Datos del problema**

Variables (7): Pan, Verduras, Frutas, Carnes, Aves, Lácteos, Vinos.

Sujetos: familias clasificadas por trabajo (MA, EM, PF) y número de hijos (2–5).

Autovalores: $\lambda = (4,339, 1,829, 0,625, 0,502, 0,393, 0,099, 0,083)$.

$\sum \lambda_k = 7,870 \approx 7$ (confirma análisis sobre matriz de correlación).

(a) Pérdida de información con 2 componentes:

$$\text{var_acum}(2) = \frac{4,339 + 1,829}{7,87} = \frac{6,168}{7,87} = 0,7837$$

$$\text{pérdida} = 1 - 0,7837 = 0,2163 = 21,6 \%$$

(b) Caracterización por inspección:

Mirando el plano:

- Cuadrante III ($CP1 < 0, CP2 < 0$): solo Profesionales (PF) → mayor poder adquisitivo.
- Cuadrante I ($CP1 > 0, CP2 > 0$): trabajadores manuales (MA) → menor poder adquisitivo.
- **CP1** discrimina por **nivel socioeconómico**.

(c)+(d) Loadings en el plano:

Cada variable i se ubica en ($\text{Componente1}_i, \text{Componente2}_i$):

Variable	CP1	CP2	Posición
Pan	-0.497	0.841	Cuad. II (arriba-izq)
Verduras	-0.972	0.131	Eje CP1 negativo
Frutas	-0.931	-0.277	Cuad. III
Carnes	-0.963	-0.190	Cuad. III
Aves	-0.912	-0.265	Cuad. III
Lácteos	-0.584	0.707	Cuad. II
Vinos	0.425	0.649	Cuad. I

Asociación componente ↔ productos:

- **CP1 (negativo):** alimentos "costosos" (carnes, aves, frutas, verduras).
- **CP2 (positivo):** alimentos "básicos / hogareños" (pan, lácteos) y vinos.

(e) Relación productos ↔ familias:

- **Profesionales (PF)** (Cuad. III): consumen carnes, aves, frutas, verduras.
- **Empleados (EM):** consumen más pan y lácteos (familias con hijos pequeños).
- **Manuales (MA):** mayor consumo de vinos.

6.2. P2 — Billetes falsos suizos

P2 · Datos

Variables (6): LON, LD, AI, AD, AMI, AMS.

Autovalores: 2,58, 1,34, 0,76, 0,56, 0,50, 0,26. Suma = 6,00.

(a) **Porcentaje de validez (varianza explicada con 2 CP):**

$$\text{var_acum}(2) = \frac{2,58 + 1,34}{6,00} = \frac{3,92}{6,00} = \boxed{65,33\%}$$

(b) **Interpretación de componentes:**

- **CP1:** todas las cargas positivas, las mayores son AMS (0.560), AI (0.445), AD (0.411) → **anchos / márgenes internos**.
- **CP2:** dominada por LON (0.799) y LD (0.345) → **tamaño / longitud del billete**.

(c) **Billetes originales:**

- **Círculos** (papel) en cuadrante I (CP1>0, CP2>0): grandes y con buenos márgenes.
- **Cuadrados** (plástico) en cuadrante IV (CP1>0, CP2<0): buenos márgenes pero más pequeños.

(d) **Diferencias entre falsificaciones:**

Los triángulos (falsos) se dividen en dos sub-grupos sobre el eje CP1 negativo:

- Falsos arriba (CP2>0): intentan imitar a los **de papel** (grandes).
- Falsos abajo (CP2<0): intentan imitar a los **de plástico** (pequeños).

Característica común: ambos tienen **márgenes pobres** (CP1 negativo).

(e) **Análisis de monedas vs billetes:**

$$\text{var_acum}_{\text{monedas}}(2) = \frac{1,96 + 1,54}{1,96 + 1,54 + 1,09 + 0,73 + 0,40 + 0,28} = \frac{3,50}{6,00} = \boxed{58,33\%}$$

Menor precisión que con billetes (65.33 %). Diferencia ≈ 7 puntos, aceptable pero menos informativo.

6.3. P3 — Servicios hospitalarios de Andalucía

P3 · Datos

Variables (7): NI, MO, RE, NE, ICM, ES, IF.

Autovalores conocidos: $\lambda_1 = 2,558$, $\lambda_2 = 1,829$.

(a) **Validez:**

Como no se conoce $\sum_k \lambda_k$ completo, asumiendo que el resto suma aprox $p - (\lambda_1 + \lambda_2) = 7 - 4,387 = 2,613$ (correlación):

$$\text{var_acum}(2) = \frac{4,387}{7} \approx \boxed{62,7\%}$$

(b)+(c) **Variables en el plano e interpretación:**

- **CP1:** cargas positivas altas en **NI** (0.860), **ES** (0.820), **IF** (0.663); negativas en ICM, ES, RE. → **Demanda / volumen de atención**.
- **CP2:** positivas en **MO** (0.747), **RE** (0.670), **ICM** (0.635) → **Gravedad / complejidad clínica**.

(d) Clasificación de servicios:

Servicio	Cuadrante	Interpretación
Medicina Interna	I (alto CP1, alto CP2)	Alta demanda + alta complejidad
Psiquiatría, Hematología, Neurología	II	Baja demanda, alta complejidad/reingresos
Otorrino, Cardio, Oftalmo	III	Bajo volumen, baja gravedad
Cirugía, Trauma, Urología, Pediatría, Gineco	IV	Alto volumen, baja complejidad (ambulatorios)

(e) Servicios con mayor carga:

- *Cuantitativa* (más pacientes, CP1 alto): Medicina Interna, Ginecología, Pediatría.
- *Cualitativa* (mayor complejidad, CP2 alto): Medicina Interna, Psiquiatría, Hematología.

(f) Servicios más eficientes: Cirugía y Traumatología (alto IF, demanda moderada, baja mortalidad).

6.4. P4 — Sector lechero venezolano**P4 · Datos**

Variables (6): SUP, VACA, SANI, INST, MAQ, PROM.

Autovalores: $\lambda_1 = 1,794$, $\lambda_2 = 1,341$.

Vectores ya escalados por $\sqrt{\lambda_k}$ (¡importante!).

Validez:

$$\text{var_acum}(2) = \frac{1,794 + 1,341}{6} = \frac{3,135}{6} = \boxed{52,25\%}$$

Caracterización de componentes:

- **CP1:** cargas positivas en SUP (0.79), VACA (0.76), MAQ (0.53) → **tamaño de la hacienda** (escala productiva).
- **CP2:** cargas negativas en SANI (−0,48), INST (−0,48), PROM (−0,80) → **nivel de tecnificación / industrialización** (a más negativo, más industrializada).

Identificación de los 8 tipos de haciendas (A–H):

Posición en el plano	Tipo
A, C (CP1 alto, CP2 medio)	Haciendas grandes tipo matadero
B (CP1 alto, CP2 muy negativo)	Hacienda lechera tecnificada
D, E (cerca del origen)	Multipropósito
F (cuadrante I positivo)	Crianza, pastoreo y engorde
G, H (CP1 negativo, CP2 positivo)	Haciendas pequeñas/poco productivas

6.5. P5 — Neoplasias (tumores)**P5 · Datos**

Variables (4): Largo, Regular, Ancho, Irregulares.

Autovalores: $\lambda_1 = 1,7034$, $\lambda_2 = 1,2560$.

(a) Pérdida de información:

$$\text{var_acum}(2) = \frac{1,7034 + 1,2560}{4} = \frac{2,9594}{4} = 73,99 \%$$

$$\boxed{\text{pérdida} = 26,01 \%}$$

(b) Loadings:

- Largo (0,52, -0,38)
- Regular (-0,27, -0,92)
- Ancho (0,58, -0,02)
- Irregulares (0,56, -0,07)

(c) Interpretación:

- **CP1:** Largo + Ancho + Irregulares con signos positivos → **tamaño + irregularidad** del tumor.
- **CP2:** dominada por Regular (-0,92) → **regularidad de núcleos celulares**.

(d) Grupos visibles: 2 grupos claros separados por CP1=0 (izquierda vs derecha).

(e) Tumores benignos: los del **lado izquierdo** (CP1<0), tumores pequeños y con núcleos regulares.

6.6. P6 — Barómetro Merco (50 empresas)**P6 · Datos**

Variables (6): REF, CPS, CCCL, ERSC, DGPI, IDI.

Autovalores: $\lambda = (2,15, 1,32, 1,18, 0,77)$ (parciales).

(a) Varianza explicada (suponiendo total ≈ 6):

$$\text{var}(2) = \frac{2,15 + 1,32}{6} = 57,8 \%, \quad \text{var}(3) = \frac{4,65}{6} = 77,5 \%, \quad \text{var}(4) = \frac{5,42}{6} = 90,3 \%$$

(b) Caracterización:

- **CP1:** cargas altas en CCCL (0.582), ERSC (0.626), DGPI (0.626) → **responsabilidad social + dimensión internacional**.
- **CP2:** dominada por REF (0.743) e IDI (0.629) → **rentabilidad e innovación**.
- **CP3:** dominada por CPS (0.855) → **calidad del producto/servicio**.
- **CP4:** CCCL (0.439) → **calidad laboral interna**.

(c) Identificación de grupos A–H: ubicar cada uno por su posición en los dos planos (CP1–CP2 y CP3–CP4) y combinar las interpretaciones de cada componente.

6.7. P7 — Clasificación de neuronas (6 tipos)

P7 · Datos

Variables (4): Cantidad D, Arborización D, Largo Axón, Tamaño Soma.

Autovalores: $\lambda_1 = 1,8$, $\lambda_2 = 0,9$, $\lambda_3 = 0,3$. Total = 3.

Validez con 2 componentes:

$$\text{var_acum}(2) = \frac{1,8 + 0,9}{3} = \frac{2,7}{3} = \boxed{90\%}$$

Caracterización:

- **CP1:** cargas altas y positivas en Cantidad D (0.948), Arborización D (0.925), Largo Axón (0.769) → **complejidad dendrítica + extensión axonal**.
- **CP2:** Largo Axón (0.629) positivo, Cantidad D (−0,215) negativo → contraste **axón largo vs muchas dendritas**.
- **CP3:** dominado por Tamaño Soma (0.789) → **tamaño del cuerpo celular**.

Caracterización de los 6 tipos de neuronas (A–F):

Tipo	CP1	CP2	Caracterización
A	-0.60	+1.60	Pocas dendritas, axón largo
B	-1.10	+0.01	Simples, sin dendritas significativas
C	-0.51	+0.81	Axón moderado, pocas dendritas
D	+0.40	+0.95	Mixtas: dendritas y axón largo
E	+1.20	-0.55	Muchas dendritas, axón corto (inter-neuronas)
F	+1.30	+0.63	Las más complejas: muchas dendritas y axón largo

7. Tips de examen (5 min)

Errores comunes que cuestan puntos

1. **Confundir $\sum \lambda_k$:** si los datos están *estandarizados*, $\sum \lambda_k = p$ (número de variables). Si no, hay que sumar todos los λ entregados.
2. **Olvidar que las cargas pueden venir ya escaladas** (P4 dice "ponderados por $\sqrt{\lambda}$ "): en ese caso *no* se debe re-escalar para el biplot.
3. **Interpretación incorrecta del signo:** el signo de una componente es arbitrario, lo que importa es el *patrón* de signos relativos entre variables.
4. **Decir "PCA reduce variables": NO;** PCA crea *nuevas* variables (combinaciones lineales). Se eligen menos de las p originales.
5. **No comentar la pérdida de información:** siempre dar el porcentaje con 2 componentes.

Atajos de cálculo

- Cuando todas las cargas de CP1 tienen el *mismo signo* → es componente de "tamaño/magnitud global".
- Cuando hay *signos opuestos* → es componente de contraste.^{entre dos grupos}.
- Calcular varianza acumulada **antes** que interpretar componentes (te dice si vale la pena el

análisis).

- Usar el criterio de Kaiser ($\lambda > 1$) sólo cuando se trabaja con matriz de **correlación**.

8. Tabla resumen de fórmulas (1 carilla)

Concepto	Fórmula
Centrado	$X_c = X - \mathbf{1}_n \boldsymbol{\mu}^T$
Estandarización	$X_{\text{std}}[i, j] = (X[i, j] - \mu_j) / \sigma_j$
Covarianza	$\Sigma = \frac{1}{n-1} X_c^T X_c$
Autovalores/vectores	$\Sigma \mathbf{v}_k = \lambda_k \mathbf{v}_k$
Loadings	$W = [\mathbf{v}_1 \cdots \mathbf{v}_q]$
Scores	$T = X_c W$
Varianza explicada CPk	$\lambda_k / \sum_j \lambda_j$
Varianza acumulada	$\sum_{k=1}^q \lambda_k / \sum_j \lambda_j$
Pérdida de información	$1 - \text{var_acum}(q)$
Loadings escalados (biplot)	$L = W \text{diag}(\sqrt{\lambda_1}, \sqrt{\lambda_2})$
Correlación entre variables	$\cos \theta_{ij} = \mathbf{w}_i \cdot \mathbf{w}_j / (\ \mathbf{w}_i\ \ \mathbf{w}_j\)$
Reconstrucción	$\hat{X}_c = T W^T$
Error reconstrucción	$\text{MSE}(q) = \frac{1}{p} \sum_{k>q} \lambda_k$