

Reglas de Asociación

Guía didáctica desde cero hasta resolver ejercicios

Inteligencia Computacional
Magíster en Ingeniería Informática · USACH
Prof. Max Chacón

Objetivo: entender qué son las reglas de asociación y resolver sin angustia los ejercicios del Capítulo IV (oficial) y la Guía 4 (ayudante Marcelo Álvarez).

Índice

1. ¿De qué se trata todo esto? (en 3 minutos)	2
1.1. Las dos preguntas clave	2
2. Las fórmulas que TIENES que dominar	2
2.1. Cómo se leen los símbolos (super importante para no entender mal)	3
3. Monotonicidad: ¿por qué importa?	3
3.1. Definiciones formales	3
4. Algoritmo Apriori en 5 pasos	4
4.1. Combinatoria que genera (representación gráfica)	4
5. Plantilla universal para resolver ejercicios	4
6. Ejercicios resueltos — Guía oficial Cap. IV	5
6.1. P1: simplificar una medida y reconocer a qué se parece	5
6.2. P2: monotonicidad de la medida Gini	5
6.3. P3: niños alérgicos + invierno $\Rightarrow$ IRA	6
6.4. P4: suscriptores Mercurio + Estrategia $\Rightarrow$ viajan	7
7. Ejercicios resueltos — Guía 4 (ayudante Marcelo)	7
7.1. G1: medidas de calidad y monotonicidad	7
7.2. G2: identificar dos medidas	8
7.3. G3: algoritmo Apriori	9
7.4. G4: clientes Jumbo (carne molida + tortillas + palta)	9
7.5. G5: nutricionista, descanso + proteínas $\Rightarrow$ recuperación	10
8. Tabla resumen — Una carilla para llevar al examen	11
9. Errores comunes y tips finales	11

1. ¿De qué se trata todo esto? (en 3 minutos)

Imagina un supermercado. Cada cliente lleva una canasta con productos. Quieres descubrir **patrones** tipo:

“Cuando alguien compra pañales, también compra cerveza.”

Esto es una **regla de asociación**, que escribimos como pañales $\Rightarrow$ cerveza o, más general:

$$A \Rightarrow B$$

donde A es el *antecedente* (lo que ya está en la canasta) y B es el *consecuente* (lo que se predice que también estará).

Intuición

Una regla de asociación NO es una causalidad ni una implicación lógica. Es solo una observación: “*cuando aparece A, suele aparecer B*”. El método sirve para **cualquier contexto binario**: pacientes (síntoma $\Rightarrow$ enfermedad), estudiantes (asistencia $\Rightarrow$ aprobar), redes sociales (tag $\Rightarrow$ tag), etc.

1.1. Las dos preguntas clave

1. ¿Qué tan frecuente es la regla? $\rightarrow$ **Soporte**.
2. ¿Qué tan confiable es? $\rightarrow$ **Confianza**.

2. Las fórmulas que TIENES que dominar

Sea n el número total de transacciones (filas de la BD). Para una regla $A \Rightarrow B$:

Las 4 medidas fundamentales

Soporte: fracción de transacciones donde aparecen A y B juntos.

$$\text{sop}(A \Rightarrow B) = P(A \cap B) = \frac{\#(A \cap B)}{n}$$

Confianza: probabilidad condicional de B dado A .

$$\text{conf}(A \Rightarrow B) = P(B | A) = \frac{P(A \cap B)}{P(A)} = \frac{\#(A \cap B)}{\#(A)}$$

Lift (interés): qué tanto mejor es la regla que el azar.

$$\text{lift}(A \Rightarrow B) = \frac{P(A \cap B)}{P(A)P(B)} = \frac{\text{conf}(A \Rightarrow B)}{P(B)}$$

$\text{lift} > 1$ correlación positiva, $\text{lift} = 1$ independencia, $\text{lift} < 1$ negativa.

Convicción: mide cuánto se aleja la regla de la independencia (penaliza conf baja).

$$\text{conv}(A \Rightarrow B) = \frac{P(A)P(\neg B)}{P(A \cap \neg B)} = \frac{1 - P(B)}{1 - \text{conf}(A \Rightarrow B)}$$

$\text{conv} \rightarrow \infty$ regla perfecta; $\text{conv} = 1$ independencia.

Versión del Prof. Chacón

En la guía del curso aparece la **convicción** escrita con n explícito:

$$\text{conv}(A \Rightarrow B) = \frac{n - \text{sop}(B)}{n [1 - \text{conf}(A \Rightarrow B)]}$$

¡Ojo! Aquí $\text{sop}(B)$ está como *conteo absoluto* (no como fracción). Si usas fracciones, simplifica a la versión $\frac{1 - P(B)}{1 - \text{conf}}$.

2.1. Cómo se leen los símbolos (super importante para no entender mal)

Símbolo	Lectura	Cómo se calcula
$P(A)$	“proba de A ”	$\#A/n$
$P(A \cap B)$	“ A y B ”	$\#(A \text{ y } B)/n$
$P(B A)$	“ B dado A ”	$\#(A \text{ y } B)/\#A$
$\neg B$	“no B ”	$1 - \#B/n$
$\hat{P}$	“estimador” de P	lo mismo, frecuencia relativa

3. Monotonicidad: ¿por qué importa?

El gran problema combinatorio. Si tienes 10 ítems, posibles itemsets: $2^{10} = 1024$. Con 30 ítems: $> 10^9$. *No puedes evaluarlos todos.*

La solución es la **propiedad anti-monótona del soporte**, descubierta por Agrawal (algoritmo Apriori, 1994):

Principio Apriori

Si un itemset X **no es frecuente** (no supera el $\text{sop}_{\min}$), entonces **ningún superset** $Y \supseteq X$ puede serlo.

$$X \subseteq Y \implies \text{sop}(Y) \leq \text{sop}(X)$$

Intuición

Si solo el 5 % de la gente compra caviar, entonces “caviar + champaña + cigarro” como mucho lo compra el 5 %. Si tu umbral mínimo es 10 %, **poda** (descartas) todas las ramas que incluyan caviar. Eso es la *poda Apriori*.

3.1. Definiciones formales

- Una medida M es **monótona** si $X \subseteq Y \implies M(X) \leq M(Y)$.
- Una medida M es **anti-monótona** si $X \subseteq Y \implies M(X) \geq M(Y)$.
- Si no cumple ninguna de las dos, decimos que **no es monótona**.


El soporte es anti-monótono. La confianza **no es monótona** en general. Esa es la razón por la que Apriori filtra primero por soporte y solo después calcula confianza.

4. Algoritmo Apriori en 5 pasos

Receta Apriori

1. **Fijar** $\text{sop}_{\min}$ y $\text{conf}_{\min}$.
2. **Generar** L_1 = itemsets de 1 elemento con $\text{sop} \geq \text{sop}_{\min}$.
3. **Iterar** para $k = 2, 3, \dots$:
 - a) *Join*: combinar L_{k-1} consigo mismo para formar candidatos C_k .
 - b) *Prune*: eliminar candidatos cuyo subset $(k - 1)$ no esté en L_{k-1} (poda anti-monótona).
 - c) Escanear la BD y quedarse con $L_k = \{X \in C_k : \text{sop}(X) \geq \text{sop}_{\min}\}$.
4. **Parar** cuando $L_k = \emptyset$.
5. **Generar reglas** desde cada itemset frecuente X : para cada partición no vacía $X = A \cup B$, evaluar $\text{conf}(A \Rightarrow B)$. Conservar si $\geq \text{conf}_{\min}$.

4.1. Combinatoria que genera (representación gráfica)



Sin poda: se generan $2^n - 1$ itemsets (lattice completo). **Con Apriori:** si por ejemplo $\{A\}$ es infrecuente, se podan AB, AC, AD y todos sus descendientes.

5. Plantilla universal para resolver ejercicios

Casi todos los problemas siguen este patrón:

Receta de resolución (memorízala)

1. **Identificar** variables binarias relevantes y darles nombre corto (MERCURIO, IRA, etc.).
2. **Construir** tabla 0/1 con n transacciones (10 suele alcanzar).
3. **Definir** la regla $A \Rightarrow B$ que se pide evaluar.
4. **Contar** en la tabla: $\#A$, $\#B$, $\#(A \cap B)$.
5. **Calcular** soporte = $\#(A \cap B)/n$ y confianza = $\#(A \cap B)/\#A$.
6. Si piden **convicción** o **lift**, calcular $P(B)$ y aplicar fórmula.
7. **Comparar** la regla simple vs. la regla extendida (agregar un ítem al antecedente): ¿la confianza sube o baja?
8. **Concluir** si se cumple la hipótesis (umbrales pedidos).

6. Ejercicios resueltos — Guía oficial Cap. IV

6.1. P1: simplificar una medida y reconocer a qué se parece

P1 (Cap. IV) — Simplificación algebraica

Expresar y simplificar:

$$X = n \frac{\text{conf}(A \Rightarrow B)}{\text{sop}(A \Rightarrow B)} \left[1 - \frac{\text{sop}(A \Rightarrow B) \text{conf}(A \Rightarrow B)}{\text{sop}(A \Rightarrow B)} \right]$$

Paso 1 — simplificar el corchete. Adentro, $\text{sop} / \text{sop} = 1$:

$$[1 - \text{conf}(A \Rightarrow B)]$$

Paso 2 — reescribir. Usando $\text{conf} = P(A \cap B)/P(A)$ y $\text{sop} = P(A \cap B)$:

$$\frac{\text{conf}}{\text{sop}} = \frac{P(A \cap B)/P(A)}{P(A \cap B)} = \frac{1}{P(A)}$$

Paso 3 — resultado.

Resultado P1

$$X = \frac{n}{P(A)} [1 - \text{conf}(A \Rightarrow B)] = \frac{n}{\text{sop}(A)} [1 - \text{conf}(A \Rightarrow B)]$$

¿A qué medida se parece? Comparemos con **convicción**:

$$\text{conv}(A \Rightarrow B) = \frac{n - \text{sop}(B)}{n [1 - \text{conf}(A \Rightarrow B)]}$$

Ambas tienen el factor $[1 - \text{conf}]$ en el denominador (o numerador inverso). X es *conceptualmente recíproca* de la convicción: cuando la regla es perfecta ($\text{conf} = 1$), $X = 0$ (no hay error), mientras que $\text{conv} \rightarrow \infty$. Por eso X se interpreta como una medida de **error o residuo** de la regla.

6.2. P2: monotonidad de la medida Gini

P2 (Cap. IV) — Gini parcial

$$\text{gini}(A \Rightarrow B) = P(A) [1 - P(B | A)]^2 + [1 - P(B | A)]^2$$

Determinar monotonidad respecto al soporte (conf. constante) y a la confianza (soporte constante).

Reescritura. Como $P(B | A) = \text{conf}$ y $P(A) = \text{sop}(A)$:

$$\text{gini} = [\text{sop}(A) + 1] [1 - \text{conf}(A \Rightarrow B)]^2$$

Caso 1: confianza constante, soporte varía. El factor $[1 - \text{conf}]^2$ es una constante positiva K . Entonces:

$$\text{gini} = K \cdot [\text{sop}(A) + 1]$$

$\Rightarrow$ **monótona creciente** en el soporte. (La guía dice “anti-monótona” pensando en disminución del Gini como medida de pureza; depende de la convención. Lo concreto: si $\text{sop} \uparrow$, entonces $\text{gini} \uparrow$.)

Comprobación numérica:

$$\text{conf} = 0,5, \text{ sop} = 0,2 : (0,2 + 1)(1 - 0,5)^2 = 1,2 \cdot 0,25 = 0,300$$

$$\text{conf} = 0,5, \text{ sop} = 0,1 : (0,1 + 1)(1 - 0,5)^2 = 1,1 \cdot 0,25 = 0,275$$

Caso 2: soporte constante, confianza varía.

$$\text{gini} = C \cdot [1 - \text{conf}]^2, \quad C = \text{sop}(A) + 1$$

⇒ **monótona decreciente** en la confianza (**anti-monótona**).

Comprobación numérica con sop = 0,2:

$$\text{conf} = 0,5 : 1,2 \cdot (0,5)^2 = 0,300$$

$$\text{conf} = 0,4 : 1,2 \cdot (0,6)^2 = 0,432$$

$$\text{conf} = 0,3 : 1,2 \cdot (0,7)^2 = 0,588$$

Tip de examen

Conclusión práctica: el Gini **premia reglas de alta confianza** (Gini chico = pureza alta) y **crece con el soporte**.

6.3. P3: niños alérgicos + invierno ⇒ IRA

P3 (Cap. IV) — Confianza que aumenta al agregar contexto

Construir una BD donde $\text{conf}(\text{ALERG} \Rightarrow \text{IRA})$ aumenta cuando se agrega la variable INVIERNO al antecedente.

Variables (binarias):

- ALERG = 1 si el niño es alérgico.
- IRA = 1 si ingresó a sala IRA.
- INVIERNO = 1 si es invierno.

Base de datos propuesta (10 pacientes):

ID	ALERG	IRA	INVIERNO
1	1	1	1
2	1	1	1
3	1	0	0
4	0	0	0
5	1	0	0
6	1	1	1
7	0	0	1
8	1	1	1
9	0	0	0
10	1	1	1

Conteos clave:

- #ALERG = 7 (filas 1,2,3,5,6,8,10).
- # (ALERG ∩ IRA) = 5 (filas 1,2,6,8,10).

- $\#(\text{ALERG} \cap \text{INVIERNO}) = 5$ (filas 1,2,6,8,10).
- $\#(\text{ALERG} \cap \text{INVIERNO} \cap \text{IRA}) = 5$ (mismas).

Regla simple:

$$\text{conf}(\text{ALERG} \Rightarrow \text{IRA}) = \frac{5}{7} \approx 0,714 = 71,4 \%$$

Regla extendida con invierno:

$$\text{conf}(\text{ALERG} \wedge \text{INVIERNO} \Rightarrow \text{IRA}) = \frac{5}{5} = 100 \%$$

Intuición

La confianza sube de 71 % a 100 %. Esto valida la hipótesis del médico: *el invierno es un factor que vuelve la regla casi determinista*. Lo importante en este tipo de ejercicios es construir la BD a mano de modo que el denominador (transacciones con todo el antecedente) sea *menor* pero con todos sus casos cumpliendo el consecuente.

6.4. P4: suscriptores Mercurio + Estrategia $\Rightarrow$ viajan

P4 (Cap. IV) — Validar hipótesis con $\text{sop} > 10 \%$, $\text{conf} > 50 \%$

Mostrar BD que cumpla: $\text{MERCURIO} \wedge \text{ESTRATEGIA} \Rightarrow \text{EXTRANJERO} \vee \text{SUR}$ con $\text{conf} > 50 \%$ y $\text{sop} > 10 \%$.

BD (10 personas):

ID	MERC	ESTR	EXTR	SUR
1	1	1	1	1
2	1	1	1	0
3	1	1	0	1
4	1	1	1	1
5	1	1	0	0
6	1	0	1	1
7	0	1	0	0
8	0	0	0	1
9	1	1	1	1
10	0	0	0	0

Conteos:

- $\#(\text{MERC} \cap \text{ESTR}) = 6$ (filas 1,2,3,4,5,9).
- De esas, con $\text{EXTR} \vee \text{SUR} = 5$ (filas 1,2,3,4,9; fila 5 no tiene ni una ni otra).

$$\text{conf} = \frac{5}{6} \approx 83 \% > 50 \% \checkmark$$

$$\text{sop} = \frac{5}{10} = 50 \% > 10 \% \checkmark$$

Conclusión: la hipótesis del analista se valida con esta muestra.

7. Ejercicios resueltos — Guía 4 (ayudante Marcelo)

7.1. G1: medidas de calidad y monotonicidad

G1 — Conceptual

Explicar para qué se usan las medidas de calidad y qué significa monotonicidad.

Respuesta modelo:

Las medidas de calidad **cuantifican qué tan “buena” o “interesante” es una regla**. Sirven para:

1. **Filtrar** reglas triviales o ruidosas (umbral de soporte/confianza).
2. **Ordenar** reglas de mayor a menor relevancia para el negocio.
3. **Detectar** si la asociación es real o producto de la frecuencia individual (lift, convicción).

La **monotonicidad** es la propiedad que indica cómo evoluciona la medida al *agregar ítems* al itemset:

- **Monótona:** $X \subseteq Y \Rightarrow M(X) \leq M(Y)$ (crece al agregar).
- **Anti-monótona:** $X \subseteq Y \Rightarrow M(X) \geq M(Y)$ (decrece al agregar).

Es **crucial** porque permite **podar** el espacio de búsqueda. Si una medida es anti-monótona y un itemset no la cumple, ninguno de sus supersets la cumplirá tampoco $\Rightarrow$ se descartan sin evaluar. Ejemplo: el **soporte** es anti-monótono y por eso Apriori funciona.

7.2. G2: identificar dos medidas**G2 — Identificación**

$$\text{Medida}_1(A \Rightarrow B) = \frac{P(A) [1 - P(B)]}{P(A) - P(A \cap B)}, \quad \text{Medida}_2(A \Rightarrow B) = n [\hat{P}(A \cap B) - \hat{P}(A) \hat{P}(B)]$$

Identificar y determinar monotonicidad.

Medida 1 — manipulación: usar que $P(A) - P(A \cap B) = P(A \cap \neg B)$:

$$\text{Medida}_1 = \frac{P(A) P(\neg B)}{P(A \cap \neg B)}$$

Medida 1 = Convicción

$$\text{Medida}_1 = \text{conv}(A \Rightarrow B)$$

Monotonicidad: la convicción **no es monótona** en general.

- Cuando $\text{conf} \rightarrow 1$, $\text{conv} \rightarrow \infty$ (regla perfecta).
- Cuando A y B son independientes, $\text{conv} = 1$.
- Agregar ítems al antecedente puede subirla (si especializa) o bajarla.

Medida 2 — identificación: la cantidad $P(A \cap B) - P(A)P(B)$ es exactamente el **leverage** (también llamado *covarianza binaria*). Multiplicada por n es la *estadística de novedad*:

Medida 2 = Leverage $\times n$

$$\text{Medida}_2 = n \cdot \text{Leverage}(A \Rightarrow B) = n [P(A \cap B) - P(A)P(B)]$$

Interpretación: mide cuántas transacciones *de más* (respecto a la independencia) cumplen $A \cap B$. Si A, B son independientes $\Rightarrow \text{Medida}_2 = 0$.

Monotonidad: **no es monótona ni anti-monótona** en el itemset. Sin embargo, para soporte fijo es *creciente* con la confianza (porque sube $P(A \cap B)$), y para confianza fija es *creciente* con el soporte (mismo argumento).

7.3. G3: algoritmo Apriori

G3 — Apriori (Agrawal)

(a) Algoritmo de búsqueda y problema computacional. (b) Criterios para optimizar. (c) Combinatoria gráfica.

(a) **Algoritmo de búsqueda: búsqueda en anchura (BFS)** por niveles sobre el *lattice* (retículo) de itemsets, ordenados por cardinalidad ($L_1, L_2, \dots$).

Problema computacional: la cantidad de itemsets posibles es $2^n - 1$ con n ítems. Crecimiento **exponencial** $\Rightarrow$ infactible para $n > 30$ sin poda. Además, cada nivel requiere un *escaneo completo* de la BD.

(b) **Criterios para optimizar:**

- **Soporte mínimo** ($\text{sop}_{\min}$): umbral para considerar un itemset frecuente.
- **Confianza mínima** ($\text{conf}_{\min}$): umbral para conservar una regla.
- **Propiedad anti-monótona del soporte:** si un itemset no es frecuente, ninguno de sus supersets lo será.

La decisión de no seguir generando reglas en una rama se llama **poda** (*pruning*) o **poda Apriori**.

(c) **Combinatoria gráfica:** ya mostrada en la sección 4 (lattice de itemsets).

7.4. G4: clientes Jumbo (carne molida + tortillas + palta)

G4 — La palta aumenta la confianza

Construir BD donde $\text{conf}(\text{carne} \Rightarrow \text{tortillas})$ *aumenta* al agregar palta al antecedente.

Variables: CARNE, TORTILLA, PALTA (binarias).

TID	CARNE	TORTILLA	PALTA
1	1	1	1
2	1	1	1
3	1	0	0
4	1	1	1
5	1	0	0
6	0	1	0
7	1	1	1
8	0	0	1
9	1	0	0
10	1	1	1

Conteos:

- $\# \text{CARNE} = 8$ (todas menos 6 y 8).
- $\#(\text{CARNE} \cap \text{TORT}) = 5$ (filas 1,2,4,7,10).

- $\#(\text{CARNE} \cap \text{PALTA}) = 5$ (filas 1,2,4,7,10).
- $\#(\text{CARNE} \cap \text{PALTA} \cap \text{TORT}) = 5$ (mismas filas).

Reglas:

$$\text{conf}(\text{CARNE} \Rightarrow \text{TORT}) = \frac{5}{8} = 62,5\%$$

$$\text{conf}(\text{CARNE} \wedge \text{PALTA} \Rightarrow \text{TORT}) = \frac{5}{5} = 100\%$$

Conclusión: agregar palta al antecedente sube la confianza de 62,5 % a 100 %. La palta *especializa* el patrón: probablemente sea un combo de tacos.

7.5. G5: nutricionista, descanso + proteínas $\Rightarrow$ recuperación

G5 — La confianza disminuye al generalizar + convicción

Construir BD donde la regla *específica* tenga alta confianza pero al *generalizar* (quitar una condición) la confianza baje. Calcular la convicción.

Variables: PROT (suplemento de proteínas), DESC (descanso suficiente), REC (recuperación efectiva).

TID	PROT	DESC	REC
1	1	1	1
2	1	1	1
3	1	1	1
4	1	0	0
5	1	0	0
6	1	0	1
7	0	1	1
8	0	1	0
9	0	0	0
10	1	1	1

Regla específica: $\text{PROT} \wedge \text{DESC} \Rightarrow \text{REC}$.

- $\#(\text{PROT} \cap \text{DESC}) = 4$ (filas 1,2,3,10).
- $\#(\text{PROT} \cap \text{DESC} \cap \text{REC}) = 4$ (mismas).

$$\text{conf}(\text{PROT} \wedge \text{DESC} \Rightarrow \text{REC}) = \frac{4}{4} = 100\%$$

Regla generalizada (quitamos DESC): $\text{PROT} \Rightarrow \text{REC}$.

- $\#\text{PROT} = 7$ (filas 1,2,3,4,5,6,10).
- $\#(\text{PROT} \cap \text{REC}) = 5$ (filas 1,2,3,6,10).

$$\text{conf}(\text{PROT} \Rightarrow \text{REC}) = \frac{5}{7} \approx 71,4\%$$

La confianza bajó de 100 % a 71 % al generalizar. Esto confirma que el descanso es un factor determinante.

Convicción de la regla específica. Usando $n = 10$, $\text{sop}(\text{REC}) = 6/10 = 0,6$, $\text{conf} = 1$:

$$\text{conv} = \frac{1 - P(\text{REC})}{1 - \text{conf}} = \frac{1 - 0,6}{1 - 1} = \frac{0,4}{0}$$

Atención: convicción infinita

Cuando $\text{conf} = 1$ *exactamente*, la convicción tiende a **infinito** (división por cero). Esto es la *interpretación correcta*: la regla es *lógicamente perfecta* sobre la muestra (sin contraejemplos). Para evitar el infinito en cálculos numéricos, se suele reportar simplemente $\text{conv} \rightarrow \infty$ o tomar una versión con suavizado de Laplace.

Convicción de la regla generalizada $\text{PROT} \Rightarrow \text{REC}$, con la fórmula del curso:

$$\text{conv} = \frac{n - \text{sop}(\text{REC})}{n[1 - \text{conf}]} = \frac{10 - 6}{10(1 - 5/7)} = \frac{4}{10 \cdot 2/7} = \frac{4 \cdot 7}{20} = 1,4$$

Equivalentemente con probabilidades: $\frac{1 - 0,6}{1 - 0,714} = \frac{0,4}{0,286} \approx 1,4$. $\text{conv} > 1$ indica que la regla es mejor que el azar, aunque **moderadamente**.

8. Tabla resumen — Una carilla para llevar al examen

Cheat-sheet Reglas de Asociación

Medidas básicas (n = total transacciones):

$$\text{sop}(A \Rightarrow B) = \frac{\#(A \cap B)}{n} \quad \text{conf}(A \Rightarrow B) = \frac{\#(A \cap B)}{\#A}$$

Medidas de interés:

$$\text{lift} = \frac{\text{conf}}{P(B)} \quad \text{conv} = \frac{1 - P(B)}{1 - \text{conf}} = \frac{n - \text{sop}(B)}{n[1 - \text{conf}]}$$

Leverage: $P(A \cap B) - P(A)P(B)$

Jaccard: $\frac{\#(A \cap B)}{\#(A \cup B)}$

Monotonidad clave:

- Soporte: **anti-monótono** (base de Apriori).
- Confianza: **no monótona**.
- Lift, convicción: **no monótonas**.

Apriori en 1 línea: BFS por niveles + poda anti-monótona del soporte + generación de reglas filtrada por $\text{conf}_{\text{mín}}$.

Valores de referencia:

$$\text{lift} = 1 \text{ indep.} \quad \text{lift} > 1 \text{ positivo} \quad \text{conv} = 1 \text{ indep.} \quad \text{conv} \rightarrow \infty \text{ perfecta}$$

9. Errores comunes y tips finales

Cinco errores típicos en el examen

1. **Confundir soporte y confianza:** soporte usa n en el denominador, confianza usa $\#A$.
2. **Calcular convicción con $\text{conf} = 1$:** da infinito, escríbelo así.
3. **Olvidar que el soporte es de la regla completa:** $\text{sop}(A \Rightarrow B) = P(A \cap B)$, NO solo $P(A)$.

4. **Asumir monotonidad de la confianza:** es *falso*. Por eso Apriori filtra primero por soporte.
5. **Decir “Apriori es DFS”:** es **BFS** por niveles. Los algoritmos DFS son FP-Growth y Eclat.

Última intuición: cuándo subir y bajar el antecedente

- **Agregar ítem al antecedente** ($A \rightarrow A \wedge C$): el soporte *siempre baja o se mantiene* (anti-monotonía). La confianza puede subir o bajar. Se busca subirla $\rightarrow$ se llama *especialización*.
- **Quitar ítem del antecedente** (generalizar): el soporte sube, la confianza tiende a bajar (porque “mezclamos” casos menos puros).

“Una regla con $\text{sop} = 90\%$ y $\text{conf} = 30\%$ es trivial. Una con $\text{sop} = 1\%$ y $\text{conf} = 99\%$ es interesante pero rara. El arte está en encontrar reglas con ambos altos.”