

Guía de Ejercicios Resueltos — PEP 1

Inteligencia Computacional · USACH · Prof. Max Chacón

Unidades 1–4 · Bloque A

Formato: lápiz y papel (sin computador)

Unidad 1 — Introducción y KDD

Ejercicio 1.1 — Etapas del KDD

Enunciado: Describa las 5 etapas del proceso KDD según Fayyad (1996) y proporcione un ejemplo de cada una para un dataset clínico de pacientes diabéticos.

Resolución:

Etapa	Descripción	Ejemplo (Diabetes)
1. Selección	Identificar datos relevantes del repositorio	Extraer registros de pacientes con HbA1c, glucosa, IMC de los últimos 5 años
2. Pre-procesamiento	Limpieza, tratamiento de faltantes	Imputar glucosa faltante con la mediana; eliminar registros duplicados
3. Transformación	Normalización, reducción, construcción de features	Estandarizar variables ($\mu=0$, $\sigma=1$); calcular PCA para visualización
4. Minería de datos	Aplicar el algoritmo	Árbol de decisión C4.5 para clasificar Diabético/No Diabético
5. Evaluación	Validar y traducir a conocimiento	Validación cruzada 10-fold; accuracy=87%; regla "si glucosa>140 y IMC>30 → riesgo alto"

Nota de examen: el KDD es **iterativo**. La retroalimentación entre etapas es parte de la respuesta esperada.

Ejercicio 1.2 — OLTP vs OLAP

Enunciado: Un hospital opera con un sistema de fichas clínicas electrónicas (cada consulta genera transacciones) y adicionalmente quiere analizar tendencias de enfermedades en los últimos 10 años. Clasifique ambas necesidades como OLTP u OLAP y justifique.

Resolución:

- **Fichas clínicas electrónicas** → **OLTP**: operaciones frecuentes de lectura/escritura individual (una consulta = una transacción), requieren baja latencia y diseño normalizado.
- **Análisis de tendencias históricas** → **OLAP / Data Warehouse**: consultas de agregación sobre grandes volúmenes históricos (por ejemplo, GROUP BY año, diagnóstico), latencia de segundos aceptable, diseño en estrella.

Ejercicio 1.3 — Tipos de aprendizaje

Enunciado: Clasifique los siguientes problemas según el tipo de supervisión:

- a) Dado un conjunto de imágenes de células sin etiquetar, encontrar grupos de formas similares.
- b) Con muestras etiquetadas de tumores (benigno/maligno), construir un predictor.
- c) Dado un historial de medicamentos y resultado, aprender qué dosis prescribir.

Resolución:

Problema	Tipo	Justificación
(a) Agrupar imágenes sin etiquetas	No supervisado	No hay variable de respuesta <i>y</i>
(b) Predecir benigno/maligno	Supervisado	Etiquetas disponibles en entrenamiento
(c) Aprender dosis óptima	Refuerzo	La señal es una recompensa (resultado) diferida

Unidad 2 — PCA

Ejercicio 2.1 — Autovalores y varianza explicada

Enunciado: Dada la siguiente matriz de covarianza de 2 variables:

$$\mathbf{S} = \begin{pmatrix} 4 & 2 \\ 2 & 3 \end{pmatrix}$$

- a) Calcule los autovalores.
- b) Calcule los autovectores correspondientes (norma unitaria).
- c) ¿Qué porcentaje de la varianza total explica la primera componente principal?

Resolución:

a) Autovalores. Resolver $\det(\mathbf{S} - \lambda\mathbf{I}) = 0$:

$$(4 - \lambda)(3 - \lambda) - 4 = 0$$

$$\lambda^2 - 7\lambda + 8 = 0$$

$$\lambda = \frac{7 \pm \sqrt{49 - 32}}{2} = \frac{7 \pm \sqrt{17}}{2}$$

$$\lambda_1 = \frac{7 + \sqrt{17}}{2} \approx 5.561, \quad \lambda_2 = \frac{7 - \sqrt{17}}{2} \approx 1.439$$

b) Autovectores.

Para $\lambda_1 \approx 5.561$: resolver $(\mathbf{S} - \lambda_1\mathbf{I})\mathbf{v} = 0$:

$$\begin{pmatrix} -1.561 & 2 \\ 2 & -2.561 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \mathbf{0}$$

De la primera fila: $v_1 = \frac{2}{1.561}v_2 \approx 1.281 v_2$.

Normalizar: $\|\mathbf{v}\| = 1 \Rightarrow v_2 = 1/\sqrt{1 + 1.281^2} \approx 0.615, v_1 \approx 0.788$.

$$\mathbf{v}_1 \approx (0.788, 0.615)^\top$$

Para λ_2 : $\mathbf{v}_2 = (-0.615, 0.788)^\top$ (ortogonal a $\mathbf{v}_1$).

c) Varianza explicada:

$$VE_1 = \frac{\lambda_1}{\lambda_1 + \lambda_2} = \frac{5.561}{7} \approx \boxed{79.4\%}$$

Ejercicio 2.2 — Criterio de Kaiser y scree plot

Enunciado: Un dataset con 6 variables tiene autovalores (sobre la matriz de correlación): $\lambda = (2.8, 1.5, 0.9, 0.4, 0.2, 0.1)$.

- ¿Cuántas componentes retiene el criterio de Kaiser?
- ¿Cuántas componentes se necesitan para explicar al menos el 85% de la varianza?
- Trace el scree plot y señale el "codo".

Resolución:


a) Kaiser: retener $\lambda_k > 1$. Los autovalores 2.8 y 1.5 superan 1 → **retener 2 componentes**.

b) Varianza total = $2.8 + 1.5 + 0.9 + 0.4 + 0.2 + 0.1 = 6.0$ (siempre 6 sobre **R**).

CP	λ_k	VEA
1	2.8	46.7%
2	1.5	71.7%
3	0.9	86.7% ← ✓
4	0.4	93.3%

Para $\geq 85\%$: **3 componentes**.

c) Scree plot:



El "codo" está entre CP2 y CP3 (la pendiente se aplana notoriamente). Consistente con Kaiser (k=2) o con el criterio de varianza (k=3 para 85%).

Ejercicio 2.3 — Interpretación de biplot

Enunciado: En un biplot de las dos primeras componentes, la flecha de la variable "radio medio" apunta casi en la dirección de PC1 con magnitud alta, mientras que "simetría" forma un ángulo cercano a 90° con "radio medio". ¿Qué concluye?

Resolución:

- "Radio medio" **define** la PC1 (alto loading en PC1, bajo en PC2).
- Un ángulo de ~90° entre "radio medio" y "simetría" indica **baja correlación** entre estas variables en los datos originales.
- Las flechas largas indican variables bien representadas (alta comunalidad) en el plano PC1-PC2.

Unidad 3 — Reglas de Asociación

Ejercicio 3.1 — Cálculo de métricas

Enunciado: Dada la base con 6 transacciones:

TID	Ítems
1	leche, pan, huevo
2	leche, mantequilla
3	pan, mantequilla
4	leche, pan, mantequilla
5	leche, pan
6	pan, huevo

Calcule soporte, confianza, lift y conviction para la regla $\{pan\} \Rightarrow \{leche\}$.

Resolución:

- $s(\{pan\}) = 5/6$ (TIDs 1,3,4,5,6)
- $s(\{leche\}) = 4/6$ (TIDs 1,2,4,5)
- $s(\{pan, leche\}) = 3/6$ (TIDs 1,4,5)

$$\text{soporte} = 3/6 = \boxed{0.50}$$

$$\text{confianza} = \frac{s(\{pan, leche\})}{s(\{pan\})} = \frac{3/6}{5/6} = \frac{3}{5} = \boxed{0.60}$$

$$\text{lift} = \frac{c(\{pan\} \Rightarrow \{leche\})}{s(\{leche\})} = \frac{0.60}{4/6} = \frac{0.60}{0.667} = \boxed{0.90}$$

$$\text{conviction} = \frac{1 - s(\{leche\})}{1 - c} = \frac{1 - 0.667}{1 - 0.60} = \frac{0.333}{0.40} = \boxed{0.833}$$

Interpretación: $\text{lift} < 1 \rightarrow$ la presencia de pan *reduce* ligeramente la probabilidad de leche. La regla no es informativamente útil a pesar de su confianza del 60%.

Ejercicio 3.2 — Apriori paso a paso

Enunciado: Con el dataset del Ejercicio 3.1 y $s_{\min} = 0.50$, ejecute el algoritmo Apriori para encontrar todos los itemsets frecuentes.

Resolución:

L_1 (soporte $\geq 0.50 = 3/6$):

Itemset	Soporte
{leche}	4/6 = 0.667 ✓
{pan}	5/6 = 0.833 ✓
{huevo}	2/6 = 0.333 ✗
{mantequilla}	3/6 = 0.500 ✓

$$L_1 = \{\{leche\}, \{pan\}, \{mantequilla\}\}$$

C_2 (por unión de pares de L_1):

Itemset	Soporte
{leche, pan}	3/6 = 0.500 ✓
{leche, mantequilla}	2/6 = 0.333 ✗
{pan, mantequilla}	2/6 = 0.333 ✗

$$L_2 = \{\{leche, pan\}\}$$

C_3 : ningún candidato válido (L_2 tiene solo un elemento de tamaño 2).

Itemsets frecuentes totales: $\{\{leche\}, \{pan\}, \{mantequilla\}, \{leche, pan\}\}$

Ejercicio 3.3 — Propiedad anti-monotónica

Enunciado: Explique por qué si $\{A, B, C\}$ es infrecuente con $s_{\min} = 0.20$, ningún superconjunto de $\{A, B, C\}$ puede ser frecuente.

Resolución:

Por la propiedad de anti-monotonicidad del soporte: para cualquier $S' \supseteq S$:

$$s(S') \leq s(S)$$

Demostración: toda transacción que contiene $S' \supseteq S$ también contiene S , pero no viceversa. Por tanto $|\{T : S' \subseteq T\}| \leq |\{T : S \subseteq T\}|$ y al dividir por $|\mathcal{D}|$, $s(S') \leq s(S)$.

Si $s(\{A, B, C\}) < s_{\min}$, entonces para cualquier $S' \supset \{A, B, C\}$ se tiene $s(S') \leq s(\{A, B, C\}) < s_{\min}$. Todos los superconjuntos son **infrecuentes** → Apriori los **poda** sin siquiera contarlos.

Unidad 4 — Clustering

Ejercicio 4.1 — Clustering jerárquico manual

Enunciado: Dado el conjunto de puntos en $\mathbb{R}^2$:

$P_1(1, 1)$, $P_2(2, 1)$, $P_3(4, 3)$, $P_4(5, 4)$, $P_5(5, 5)$.

Use **linkage completo** con distancia euclidiana para construir el dendrograma paso a paso. Indique el corte que da 2 clusters.

Resolución:

Matriz de distancias iniciales (Euclideana, valores redondeados):

	P_1	P_2	P_3	P_4	P_5
P_1	—	1.00	3.61	5.00	5.66
P_2	—	—	2.83	4.24	5.00
P_3	—	—	—	1.41	2.24
P_4	—	—	—	—	1.00
P_5	—	—	—	—	—

Paso 1: mínima distancia $\rightarrow d(P_1, P_2) = 1.00$ ó $d(P_4, P_5) = 1.00$ (empate). Unir $\{P_4, P_5\}$ a altura 1.00.

Actualizar con **complete linkage**:

$d(\{P_4, P_5\}, P_3) = \max(1.41, 2.24) = 2.24$, $d(\{P_4, P_5\}, P_2) = \max(4.24, 5.00) = 5.00$,
 $d(\{P_4, P_5\}, P_1) = \max(5.00, 5.66) = 5.66$.


Paso 2: mínima $\rightarrow d(P_1, P_2) = 1.00$. Unir $\{P_1, P_2\}$ a altura 1.00.

Actualizar: $d(\{P_1, P_2\}, P_3) = \max(3.61, 2.83) = 3.61$, $d(\{P_1, P_2\}, \{P_4, P_5\}) = \max(5.00, 5.66) = 5.66$.

Paso 3: mínima $\rightarrow d(\{P_4, P_5\}, P_3) = 2.24$. Unir $\{P_3, P_4, P_5\}$ a altura 2.24.

Paso 4: unir $\{P_1, P_2\}$ con $\{P_3, P_4, P_5\}$ a altura 5.66.

Dendrograma:



Corte a altura 3: 2 clusters $\rightarrow \{P_1, P_2\}$ y $\{P_3, P_4, P_5\}$.

Ejercicio 4.2 — k-means paso a paso

Enunciado: Con los puntos $A(1, 1)$, $B(2, 3)$, $C(4, 2)$, $D(5, 4)$, $E(1, 4)$, $k = 2$, centroides iniciales $\mu_1 = (1, 1)$, $\mu_2 = (5, 4)$:

Ejecute **2 iteraciones** de k-means (distancia euclidiana).

Resolución:

Iteración 1 — Asignación:

Punto	$d(\cdot, \mu_1)$	$d(\cdot, \mu_2)$	Cluster
A(1,1)	0.00	5.66	1
B(2,3)	2.24	3.61	1
C(4,2)	3.16	2.24	2
D(5,4)	5.66	0.00	2
E(1,4)	3.00	4.12	1

$$C_1 = \{A, B, E\}, C_2 = \{C, D\}$$

Iteración 1 — Actualización:

$$\mu_1 = \left(\frac{1 + 2 + 1}{3}, \frac{1 + 3 + 4}{3} \right) = (1.33, 2.67)$$

$$\mu_2 = \left(\frac{4 + 5}{2}, \frac{2 + 4}{2} \right) = (4.50, 3.00)$$

Iteración 2 — Asignación:

Punto	$d(\cdot, \mu_1)$	$d(\cdot, \mu_2)$	Cluster
A(1,1)	1.75	4.03	1
B(2,3)	0.75	2.55	1
C(4,2)	2.75	1.12	2
D(5,4)	4.32	1.12	2

Punto	$d(\cdot, \mu_1)$	$d(\cdot, \mu_2)$	Cluster
E(1,4)	1.53	3.54	1

Sin cambios → **converge**. Clusters finales: $\{A, B, E\}$ y $\{C, D\}$.

Ejercicio 4.3 — Índice Silhouette

Enunciado: Con los clusters del Ejercicio 4.2, calcule el coeficiente Silhouette para el punto B(2,3).

Resolución:

$$C_1 = \{A(1, 1), B(2, 3), E(1, 4)\}, C_2 = \{C(4, 2), D(5, 4)\}.$$

$a(B)$ = distancia media de B a los otros puntos de C_1 :

$$a(B) = \frac{d(B, A) + d(B, E)}{2} = \frac{\sqrt{1+4} + \sqrt{1+1}}{2} = \frac{2.236 + 1.414}{2} = 1.825$$

$b(B)$ = distancia media de B al cluster vecino más cercano (C_2):

$$b(B) = \frac{d(B, C) + d(B, D)}{2} = \frac{\sqrt{4+1} + \sqrt{9+1}}{2} = \frac{2.236 + 3.162}{2} = 2.699$$

$$s(B) = \frac{b(B) - a(B)}{\max\{a(B), b(B)\}} = \frac{2.699 - 1.825}{2.699} = \boxed{0.324}$$

Interpretación: $s(B) \approx 0.32 \rightarrow$ el punto está razonablemente bien asignado a su cluster, pero sin una separación muy clara.

Checklist final PEP 1

Asegúrate de poder responder de memoria:

- ☐ Las 5 etapas KDD con ejemplos.
- ☐ Diferencia dato / información / conocimiento / meta-conocimiento.
- ☐ OLTP vs OLAP (características técnicas).
- ☐ Derivar la ecuación de autovalores de PCA desde el problema variacional.
- ☐ Calcular autovalores de una 2×2 a mano.

- ☐ Criterio de Kaiser y varianza explicada.
- ☐ Definición formal de soporte, confianza, lift y conviction.
- ☐ Propiedad anti-monotónica y su impacto en Apriori.
- ☐ Ejecutar Apriori a mano (5–6 transacciones).
- ☐ Criterios de enlace (single/complete/average/Ward) y sus características.
- ☐ k-means: una iteración completa de asignación y actualización.
- ☐ Calcular Silhouette para un punto específico.