

Unidad 1 — Introducción y Proceso KDD

Curso: Inteligencia Computacional · USACH · Prof. Max Chacón

Fuente primaria:

data/processed/clases/Presentaciones_Prof_Max/capitulo-i-inteligencia-computacional_introducción/

Complementario: Han, J. — *Data Mining: Concepts and Techniques*, 3rd ed., Cap. 1.

Carga: 3 h teoría · evalúa en **PEP 1**

1. Objetivos de aprendizaje

- Distinguir **dato** → **información** → **conocimiento** → **meta-conocimiento**.
- Identificar las etapas del proceso de descubrimiento de conocimiento en bases de datos (KDD).
- Diferenciar bases de datos **operacionales (OLTP)** vs **analíticas (OLAP / DW)**.
- Tipificar problemas de aprendizaje: **supervisado**, **no supervisado**, **semi-supervisado**, **por refuerzo**.
- Comparar modelos lineales (regresión) con aprendizaje no lineal.


2. Definiciones fundamentales

Concepto	Definición operacional (Chacón, Cap. I)
Dato	Hecho o medida que describe una característica de un objeto/evento.
Información	Datos procesados y presentados en forma útil para un observador.
Conocimiento	Información procesada que permite emitir juicios y conclusiones.
Meta-conocimiento	Reglas que permiten obtener conocimiento.
Minería de Datos	Conjunto de técnicas para extraer información/conocimiento desde BBDD.

Concepto	Definición operacional (Chacón, Cap. I)
KDD	Proceso <i>no trivial</i> de identificación de patrones válidos, novedosos, potencialmente útiles y comprensibles a partir de los datos (Frawley et al., 1989; Fayyad et al., 1996).

Pirámide informacional: Datos → Información → Conocimiento → Meta-conocimiento. Reducción en cantidad, aumento en valor.

3. El proceso KDD (Fayyad, 1996)



Etapas detalladas

- 1. **Selección:** identificar el subconjunto de datos relevantes (filas y columnas).
- 2. **Pre-procesamiento:** limpieza, manejo de faltantes, ruido, outliers, integración de fuentes.
- 3. **Transformación:** normalización, discretización, reducción de dimensionalidad (p.ej. PCA), generación de nuevas variables.
- 4. **Minería de Datos:** aplicación del algoritmo (clasificación, regresión, clustering, reglas de asociación, etc.).
- 5. **Evaluación / Interpretación:** métricas de calidad, validación estadística, visualización, traducción a conocimiento accionable.

Nota: KDD es **iterativo**. La retroalimentación entre etapas es la regla, no la excepción.

4. Tipología de problemas

4.1 Por tipo de supervisión

Tipo	Etiqueta y	Ejemplo	Métodos clásicos
Supervisado	Sí	Diagnóstico (benigno/maligno)	Bayes, árboles, MLP, SVM

Tipo	Etiqueta y	Ejemplo	Métodos clásicos
No supervisado	No	Segmentación de pacientes	k-means, jerárquico, DBSCAN, PCA
Semi-supervisado	Parcial	Pocas etiquetas + muchos no-etiquetados	Self-training, label propagation
Refuerzo	Recompensa	Control de glucosa, robótica	Q-learning, policy gradient

4.2 Por tarea

- **Predictivas:** clasificación (categórica), regresión (numérica), pronóstico de series temporales.
- **Descriptivas:** agrupamiento, reglas de asociación, detección de anomalías, resumen.

5. OLTP vs OLAP

Característica	OLTP (operacional)	OLAP / Data Warehouse
Propósito	Transacciones diarias	Análisis y decisión
Diseño	Normalizado (3FN)	Estrella / copo de nieve
Operación dominante	INSERT / UPDATE	SELECT agregadas
Latencia	ms	s a min
Volumen	GB	TB–PB
Historial	Reciente	Histórico amplio

6. Comparación con regresión lineal clásica

La regresión lineal asume:

$$y = \beta_0 + \sum_{j=1}^p \beta_j x_j + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2)$$

con linealidad, homocedasticidad, independencia y normalidad del error. Los métodos de **aprendizaje no lineal** (árboles, MLP, RBF, SVM-kernel) **relajan** estos supuestos a costa de mayor complejidad, riesgo de sobreajuste y menor interpretabilidad.

Criterio	Regresión lineal	Aprendizaje no lineal
Interpretabilidad	Alta	Variable a baja
Hipótesis sobre datos	Fuertes	Débiles
Capacidad de modelar	Limitada	Alta
Riesgo overfitting	Bajo	Alto
Datos requeridos	Pocos	Muchos

7. Hipótesis comunes en aprendizaje

- **i.i.d.:** muestras independientes e idénticamente distribuidas.
- **Estacionariedad:** la distribución generadora no cambia entre entrenamiento y prueba.
- **Representatividad:** la muestra refleja la población objetivo.
- **No-redundancia / mínima colinealidad** entre atributos (importante para regresión lineal y PCA).

Violaciones típicas en bioinformática: *covariate shift*, *class imbalance*, datos longitudinales no independientes.

8. Ejemplo guiado: pipeline KDD mínimo

Notebook: [00_intro_kdd.ipynb](#)

Dataset: **Wisconsin Breast Cancer** (`sklearn.datasets.load_breast_cancer`).

Etapas:

1. **Selección:** 30 atributos numéricos, 569 instancias, 2 clases (M/B).
2. **Pre-procesamiento:** `StandardScaler` (media 0, varianza 1).
3. **Transformación:** PCA a 2 componentes (anticipo de Unidad 2).
4. **Minería:** regresión logística como baseline.
5. **Evaluación:** accuracy, matriz de confusión, ROC.

9. Conceptos clave para PEP 1

- KDD $\neq$ Data Mining: KDD es el **proceso completo**; DM es **una etapa**.
- Las etapas del KDD se preguntan en orden y con sus objetivos.
- Diferencia precisa OLTP/OLAP.
- Pirámide informacional (de menor a mayor abstracción y de mayor a menor cantidad).
- La definición formal de Fayyad (1996) suele preguntarse textual.

10. Lecturas y referencias

- Capítulo I, Prof. Chacón — base obligatoria.
- Han, Kamber, Pei — *Data Mining*, Cap. 1 (búsqueda con `book_explorer.py "data/raw/Libros/Data Mining*.pdf" --search "knowledge discovery"`).
- Fayyad, U.; Piatetsky-Shapiro, G.; Smyth, P. (1996). *From Data Mining to Knowledge Discovery in Databases*. AI Magazine, 17(3).