

Algoritmos de Aprendizaje en Redes Neuronales Feedforward

Un análisis del artículo de Widrow & Lehr (1990):

30 Years of Adaptive Neural Networks: Perceptron, Madaline, and Backpropagation

Estudiante

Universidad de Santiago de Chile

Magíster en Ingeniería Informática

Julio 2026

Resumen

Este informe presenta un análisis comprehensivo del artículo de revisión de Widrow & Lehr (1990) sobre 30 años de algoritmos de aprendizaje supervisado en redes neuronales artificiales (RNA) feedforward. Se implementaron desde cero en NumPy puro los seis algoritmos descritos en el artículo —Perceptrón, α -LMS, μ -LMS, MLP con *backpropagation*, *Madaline Rule II* y *Madaline Rule III*— y se ejecutaron siete experimentos para verificar experimentalmente las hipótesis fundamentales del principio de mínima perturbación. Los resultados confirman que: (1) la capacidad estadística $C_s \approx 2N_w$ de Cover se verifica empíricamente, (2) el Perceptrón converge en tiempo finito solo en datos separables mientras μ -LMS se aproxima al óptimo de Wiener, (3) el MLP con *backpropagation* resuelve XOR (6/20, 2-2-1) y alcanza 91.1 % en Iris, (4) *Madaline Rule III* es matemáticamente equivalente a *backpropagation* con error relativo de 5.05×10^{-8} pero entre $3.5 \times$ y $74 \times$ más costoso computacionalmente. Se discuten las implicancias del principio de mínima perturbación como marco unificador del aprendizaje supervisado en RNA.

1. Introducción

1.1. Problema abordado

El artículo de Widrow & Lehr (1990) [1] aborda el problema fundamental del **aprendizaje supervisado en redes neuronales artificiales feedforward**: ¿cómo adaptar los pesos sinápticos de una red de elementos computacionales simples para que aproximen una función de clasificación o regresión a partir de ejemplos? El artículo revisa 30 años de desarrollo de algoritmos de entrenamiento —desde el Perceptrón de Rosenblatt (1958) hasta la retropropagación del error de Rumelhart, Hinton & Williams (1986)— y demuestra que todos ellos comparten un principio unificador: el **principio de mínima perturbación** (*minimal disturbance principle*), que establece que durante el entrenamiento es recomendable inyectar nueva información en la red de manera que perturbe la información ya almacenada en la menor medida posible [1].

El artículo es una revisión (*survey*) y tutorial, no un estudio experimental sobre un dataset único. Su contribución es **conceptual e histórica**: traza la evolución desde las primeras reglas de aprendizaje (1960) hasta las redes multicapa con *backpropagation*, y demuestra conexiones matemáticas profundas entre algoritmos desarrollados independientemente. En particular, establece que *Madaline Rule III* (Andes, 1988) es matemáticamente equivalente a *backpropagation*, un hallazgo realizado por Widrow y sus estudiantes [1].

1.2. ¿Por qué redes neuronales artificiales?

La motivación para usar RNA en problemas de clasificación y regresión se fundamenta en tres argumentos presentados en las Secciones I–II del artículo [1]:

- (I) **Paralelismo masivo y robustez:** Los sistemas biológicos resuelven tareas de reconocimiento de patrones, procesamiento de voz e imágenes con una facilidad que las computadoras von Neumann no igualan. Las RNA emulan este paralelismo mediante miles de elementos simples interconectados que procesan información simultáneamente.
- (II) **Aprendizaje por ejemplos:** A diferencia de los sistemas algorítmicos tradicionales, las RNA no requieren programación explícita de reglas. Aprenden la función de mapeo entrada-salida directamente de los datos mediante algoritmos iterativos.
- (III) **Generalización:** Una RNA correctamente entrenada clasifica patrones no vistos durante el entrenamiento. La capacidad de generalización está inversamente relacionada con la capacidad de almacenamiento ($C_s \approx 2N_w$, Cover, 1964 [4]), un *trade-off* fundamental que el artículo explora en profundidad.

Aplicaciones históricas que demuestran la viabilidad práctica incluyen NETtalk (Sejnowski & Rosenberg, 1987), una red de 80–26 Adalines que aprende a pronunciar texto en inglés; el *truck backer-upper* de Nguyen & Widrow (1989), donde una red de 26 Adalines aprende a retroceder un camión con acoplado; y los ecualizadores adaptativos basados en LMS para módems de alta velocidad, la primera aplicación comercial masiva de las RNA [1].

1.3. Hipótesis

Se plantean cuatro hipótesis que guían la experimentación de este informe:

- H1 – Capacidad de Cover:** La capacidad estadística de un Adaline es $C_s \approx 2N_w$ y la determinística $C_d = N_w$, verificable mediante simulación Monte Carlo con programación lineal.
- H2 – Convergencia finita del Perceptrón:** El Perceptrón converge en tiempo finito si los datos son linealmente separables, pero oscila y diverge en norma si no lo son. Por contraste, α -LMS y μ -LMS son estables en ambos casos, con μ -LMS convergiendo al óptimo de Wiener $W^* = R^{-1}P$.
- H3 – Poder no lineal y óptimos locales:** XOR es irresoluble por un solo Adaline pero resoluble por *Madaline Rule II* y MLP con *backpropagation*, aunque ambos algoritmos están sujetos a óptimos locales en la superficie de error. El remedio de ruido esporádico propuesto en la Sección VII-E del paper [1] mitiga parcialmente este problema.
- H4 – Equivalencia MRIII $\equiv$ Backpropagation:** *Madaline Rule III* converge a *backpropagation* cuando la perturbación $\Delta s \rightarrow 0$, pero su costo computacional en implementación digital es proporcionalmente mayor (requiere $1 + N_{\text{Adalines}}$ pasadas hacia adelante por presentación versus 1 adelante + 1 atrás de *backpropagation*).

2. Marco Teórico

2.1. El elemento adaptativo básico: Adaline

El bloque constructivo fundamental de las RNA feedforward es el **Adaptive Linear Element** (Adaline) [1], compuesto por:

1. Un **combinador lineal adaptativo** que calcula $s_k = X_k^T W_k$, donde $X_k = [x_0 = +1, x_{1k}, \dots, x_{nk}]^T$ es el vector de entrada aumentado con bias y $W_k \in \mathbb{R}^{n+1}$ el vector de pesos.
2. Un **cuantizador** (típicamente signum) que produce la salida binaria $y_k = \text{sgn}(s_k) \in \{\pm 1\}$, o alternativamente una función de activación diferenciable como la tangente hiperbólica $y_k = \tanh(s_k)$.

La condición crítica $s = 0$ define un **hiperplano separador** en el espacio de patrones. Con n entradas binarias, un Adaline puede implementar solo las funciones lógicas **linealmente separables**: 14 de 16 posibles para $n = 2$, excluyendo XOR/XNOR [1].

2.2. Taxonomía de algoritmos

El artículo organiza los algoritmos en una taxonomía (Fig. 33 del paper) según dos ejes: **mecanismo de adaptación** (corrección de error vs. descenso más pronunciado) y **no linealidad** (lineal vs. no lineal), para uno o múltiples elementos:

1. **Corrección de error – lineal (un elemento):** α -LMS (Widrow-Hoff, 1960), que minimiza el error lineal $\varepsilon_k = d_k - s_k$ con cambio de peso colineal a X_k .
2. **Corrección de error – no lineal (un elemento):** Regla del Perceptrón (Rosenblatt, 1958), que solo adapta si la decisión es incorrecta usando el error del cuantizador $\tilde{\varepsilon}_k = d_k - y_k$. Reglas de Mays con zona muerta.
3. **Corrección de error – no lineal (red):** Madaline I (MRI) y II (MRII): MRI usa capa oculta adaptativa con lógica fija de salida; MRII extiende la adaptación a todas las capas mediante inversión tentativa (*tentative flipping*) [1].
4. **Descenso más pronunciado – lineal (un elemento):** μ -LMS, que realiza descenso por gradiente estocástico sobre la superficie de MSE, la cual es un paraboloide convexo con mínimo único: la solución de Wiener $W^* = R^{-1}P$.
5. **Descenso más pronunciado – no lineal (red):** *backpropagation* (Rumelhart et al., 1986) y *Madaline Rule III* (Andes, 1988), que extienden el gradiente a redes multicapa con funciones de activación diferenciables.

2.3. Ecuaciones fundamentales

2.3.1. α -LMS / Regla Delta de Widrow-Hoff — Eq. (10)

$$W_{k+1} = W_k + \alpha \frac{\varepsilon_k}{\|X_k\|^2} X_k, \quad \varepsilon_k = d_k - X_k^T W_k \quad (1)$$

El cambio de peso ΔW_k es colineal con X_k , garantizando la corrección del error con la mínima magnitud de cambio posible (*mínima perturbación geométrica*). Rango de estabilidad: $0 < \alpha < 2$, rango práctico: $0.1 < \alpha < 1.0$ [1].

2.3.2. Regla del Perceptrón de Rosenblatt — Eq. (18)

$$W_{k+1} = W_k + \alpha \frac{\tilde{\varepsilon}_k}{2} X_k, \quad \tilde{\varepsilon}_k = d_k - y_k \in \{-2, 0, +2\} \quad (2)$$

Solo adapta si $y_k \neq d_k$. El **teorema de convergencia del Perceptrón** garantiza separación en pasos finitos si los datos son linealmente separables. Si no lo son, el vector de pesos tiende a cero y el algoritmo “continúa para siempre” [1, 2].

2.3.3. μ -LMS — Eq. (33)

$$W_{k+1} = W_k + 2\mu \varepsilon_k X_k \quad (3)$$

La superficie de MSE $\xi(W) = \mathbb{E}[d^2] - 2P^T W + W^T R W$ es un hiperparaboloide convexo con mínimo único $W^* = R^{-1}P$ (solución de Wiener). El gradiente instantáneo es insesgado: $\mathbb{E}[-2\varepsilon_k X_k] = \nabla \xi$. Estabilidad: $0 < \mu < 1/\text{tr}[R]$ [1].

2.3.4. Backpropagation — Eqs. (78–79, 87, 94)

Para el Adaline sigmoide ($y = \tanh(s)$), la regla de actualización es:

$$W_{k+1} = W_k + 2\mu \tilde{\varepsilon}_k \cdot (1 - y_k^2) X_k \quad (4)$$

Para redes multicapa, las deltas se calculan como:

$$\delta_j^{(L)} = \varepsilon_j \cdot (1 - y_j^2) \quad (\text{capa de salida, Eq. 79}) \quad (5)$$

$$\delta^{(l)} = (W^{(l+1)T} \delta^{(l+1)}) \odot (1 - (y^{(l)})^2) \quad (\text{capas ocultas, Eq. 87}) \quad (6)$$

Y la actualización con **momentum** (Eqs. 96–97):

$$\Delta W_k = \eta \Delta W_{k-1} + (1 - \eta) 2\mu \delta_k X_k^T, \quad \eta \approx 0.8\text{--}0.9 \quad (7)$$

Es crucial aclarar que δ **no es un error** en el sentido convencional: es una señal de gradiente que indica cómo cambiar cada peso para reducir el error cuadrático de salida ε^2 [1, 5].

2.4. Capacidad de patrones y generalización

Cover (1964) [4] demostró que la probabilidad de que N_p patrones aleatorios sean linealmente separables por un Adaline de N_w pesos es:

$$P(N_p, N_w) = \begin{cases} 1 & \text{si } N_p \leq N_w \\ 2^{1-N_p} \sum_{i=0}^{N_w-1} \binom{N_p-1}{i} & \text{si } N_p > N_w \end{cases} \quad (8)$$

De aquí se derivan la **capacidad determinística** $C_d = N_w$ (garantía de solución) y la **capacidad estadística** $C_s \approx 2N_w$ (promedio de patrones absorbibles). Para redes multicapa, Baum extendió estos resultados acotando $N_w/N_y - K_1 \leq C_d \leq (N_w/N_y) \log_2(N_w/N_y) + K_2$ [1]. La regla práctica de generalización es $N_p \gg N_w/N_y$: el número de patrones de entrenamiento debe exceder significativamente la relación pesos/salidas para que la red generalice en lugar de memorizar.

2.5. Madaline Rule II (MRII)

Madaline Rule II (Widrow, Winter & Baxter, 1987) [1] extiende la adaptación a todas las capas de una red de Adalines con cuantizador signum. Para cada patrón erróneo:

1. Se ordenan las Adalines ocultas por $|s|$ creciente (*load-sharing*: “asignar responsabilidad a quien puede asumirla más fácilmente”).
2. Se invierte tentativamente (*flip*) la salida de una Adaline; si reduce el error de Hamming del patrón, se acepta y se refuerza con corrección absoluta colineal.
3. Si no, se prueban pares de Adalines.
4. La capa de salida se entrena con α -LMS moderado.

El artículo advierte que MRII puede estancarse en óptimos locales, y propone como remedio la **adición esporádica de ruido a los pesos** (Sección VII-E) [1].

2.6. Madaline Rule III (MRIII) y equivalencia con Backpropagation

Madaline Rule III (Andes, 1988) reemplaza el cuantizador signum por sigmoide y estima el gradiente de ε^2 respecto a s_j mediante perturbación del sumidero [1]:

$$\frac{\partial \varepsilon^2}{\partial s_j} \approx \frac{\varepsilon_{\text{perturbado}}^2 - \varepsilon_{\text{base}}^2}{\Delta s} \quad (9)$$

Cuando $\Delta s \rightarrow 0$, MRIII es **matemáticamente equivalente a backpropagation**. Requiere $1 + N_{\text{Adalines}}$ pasadas hacia adelante por patrón (vs. $1 + 1$ de *backpropagation*), lo que lo hace menos eficiente en implementación digital, pero más robusto para hardware analógico (existió un chip comercial de MRIII) [1].

3. Experimentación

3.1. Diseño experimental

Dado que el artículo de Widrow & Lehr es una revisión teórica, la experimentación propia consiste en **implementar desde cero los algoritmos descritos** y verificar empíricamente las hipótesis H1–H4 mediante siete experimentos (E1–E7), más validación en dos datasets reales adicionales (Wine y MNIST reducido). La Tabla 1 resume el diseño experimental.

Exp.	Tema	Hipótesis	Algoritmos	Dataset
E1	Capacidad de Cover	H1	Programación Lineal	Sintético Monte Carlo
E2	Reglas lineales, separable	H2	Perceptrón, α -LMS, μ -LMS	Gaussianas separables
E3	Datos no separables	H2	Perceptrón, α -LMS, μ -LMS	Gaussianas solapadas
E4	Superficies MSE	—	Adaline 2D	Patrones aleatorios
E5	XOR: MRII vs MLP	H3	MRII, MLP- <i>backpropagation</i>	XOR (4 patrones)
E6	Datasets reales	—	MLP- <i>backpropagation</i> , α -LMS, μ -LMS	Iris, Wine, MNIST-04,
E7	MRIII $\equiv$ <i>backpropagation</i> + costo	H4	MRIII, <i>backpropagation</i>	Iris (1 patrón)

Cuadro 1: Diseño experimental.

3.2. Datasets

- **Sintéticos separables:** 200 puntos, dos gaussianas $N([\pm 2, \pm 2], 0.35^2 I)$.
- **Sintéticos no separables:** 200 puntos, dos gaussianas $N([\pm 0.9, \pm 0.9], 1.3^2 I)$.
- **XOR:** 4 patrones $\{\pm 1\}^2$, $d = [-1, +1, +1, -1]$.
- **Iris** (Fisher, 1936; UCI): 150 flores, 4 atributos, 3 clases. Split 70/30 estratificado, normalizado a $[-1, 1]$.
- **Two-moons** (scikit-learn): 300 puntos, ruido 0.20.
- **Wine** (UCI): 178 muestras, 13 atributos fisicoquímicos, binarizado (clase 0 vs. resto).
- **MNIST-04** (UCI digits): dígitos 0–4, $8 \times 8 = 64$ atributos, 901 instancias, normalizado.

3.3. Implementación

Todos los algoritmos se implementaron desde cero en **NumPy puro** (sin usar PyTorch, TensorFlow ni scikit-learn para el aprendizaje). Se usó scikit-learn exclusivamente para carga de datos, partición train/test y métricas auxiliares. La reproducibilidad se garantiza con semilla global SEED=1990. El costo computacional por presentación es $\mathcal{O}(N_w)$ para Perceptrón/LMS y $\mathcal{O}(N_w)$ para *backpropagation* (forward + backward). Para MRIII, el costo es $\mathcal{O}(N_w \cdot N_{\text{Adalines}})$.

3.4. Complejidad computacional

En implementación digital, *backpropagation* requiere exactamente 1 pasada hacia adelante + 1 hacia atrás por patrón, con complejidad comparable en ambas direcciones. MRIII requiere $1 + N_{\text{Adalines}}$ pasadas hacia adelante (una sin perturbar, una por cada Adaline perturbada), lo que lo hace intrínsecamente más costoso. Esta diferencia se cuantifica en el Experimento E7.

4. Análisis de Resultados

4.1. E1: Capacidad de Cover




Figura 1: Probabilidad de separabilidad lineal: empírica (puntos) vs. fórmula teórica de Cover (curvas). Líneas verticales en $C_d = N_w$ (punteada) y $C_s \approx 2N_w$ (discontinua).

La Figura 1 muestra un ajuste estrecho entre la probabilidad empírica (80 ensayos Monte Carlo por punto, separabilidad testada con `linprog`) y la fórmula teórica de Cover (Eq. 8). Las desviaciones medias $|\text{empírica} - \text{teórica}|$ son 0.0337 para $N_w = 2$, 0.0259 para $N_w = 5$ y 0.0105 para $N_w = 15$, decreciendo con N_w como predice la teoría asintótica. La transición en $N_p/N_w = 1$ (C_d) y $N_p/N_w = 2$ (C_s) se agudiza al aumentar N_w , confirmando **H1**.

4.2. E2: Reglas lineales en datos separables




Figura 2: Visualización de los datasets sintéticos utilizados: separable, no separable, y XOR.




Figura 3: Fronteras de decisión de los tres algoritmos lineales (color) vs. el hiperplano óptimo de Wiener (negro discontinuo). Ángulos respecto a W^* indicados.




Figura 4: Convergencia de μ -LMS para distintos μ . $\mu = 0.12$ diverge por exceder la cota de estabilidad $\mu_{\text{máx}} = 1/\text{tr}[R] = 0.111$. La línea horizontal marca el MSE del óptimo de Wiener (0.015).

La Figura 3 revela un resultado fundamental: **el Perceptrón converge en solo 2 épocas** (confirmando el teorema de convergencia), pero su frontera queda a 20.6° del óptimo de Wiener — el Perceptrón “se detiene donde primero separa”. En contraste, α -LMS y μ -LMS optimizan el MSE, acercándose a 4.4° y 3.5° de W^* respectivamente.

La Figura 4 demuestra la cota de estabilidad: con $\mu = 0.12 > 1/\text{tr}[R] = 1/9.02 = 0.111$, el MSE diverge exponencialmente. Los valores $\mu \in \{0.001, 0.01, 0.05\}$ convergen al MSE de Wiener (0.015), con mayor μ implicando convergencia más rápida. La **MSE de Wiener** (0.0148) se alcanza asintóticamente. Estos resultados confirman **H2** para el caso separable.

4.3. E3: Datos no separables




Figura 5: Izquierda: Accuracy por época en datos no separables. Derecha: Evolución de $\|W\|$. Nótese la oscilación del Perceptrón (azul).

La Tabla 2 resume los resultados cuantitativos.

Algoritmo	Acc. separable	Ep. converg.	Acc. no separable
Perceptron	100.0 %	2	75.7 % ± 5.5
α -LMS	100.0 %	—	75.0 % ± 7.4
μ -LMS	100.0 %	—	79.6 % ± 1.5
Wiener (optimo)	100.0 %	—	81.0 %

Cuadro 2: Resultados comparativos de algoritmos lineales en datos separables y no separables.

En el dataset no separable (Figura 5), el **Perceptrón oscila** significativamente: $75.7\% \pm 5.5$ en las últimas 40 épocas, con $\|W\|$ fluctuante (el vector de pesos “gravita hacia cero” como advierte el paper). α -LMS es estable pero ruidoso ($75.0\% \pm 7.4$). μ -LMS ofrece el mejor desempeño: $79.6\% \pm 1.5$, a solo 1.4 puntos porcentuales del óptimo de Wiener (81.0 %), y con la menor varianza. Esto confirma **H2** en el caso no separable: μ -LMS proporciona una solución estable cercana al mejor clasificador lineal posible.

4.4. E4: Superficies de MSE




Figura 6: Superficies de MSE para un Adaline de 2 pesos sin bias (6 patrones aleatorios). Izquierda: error lineal (paraboloide convexo). Centro: error sigmoide (no cuadrático pero suave). Derecha: error signum (escalonado con mesetas y óptimos locales).

La Figura 6 ilustra por qué el descenso de gradiente **exige funciones de activación diferenciables**:

- El error **lineal** (mín = 0.936) forma un paraboloide perfectamente convexo: cualquier algoritmo de gradiente converge al mínimo global.
- El error **sigmoide** (mín = 0.940) es no cuadrático pero suave y navegable: el gradiente existe en todas partes, aunque pueden existir mínimos locales en redes multicapa.
- El error **signum** (mín = 1.333) es escalonado: presenta **mesetas** donde el gradiente es exactamente cero y la optimización se detiene. Esto explica por qué algoritmos como MR-II (que usan signum) requieren mecanismos de escape como el ruido esporádico.

4.5. E5: XOR — MR-II vs MLP-Backpropagation




Figura 7: Izquierda: Regiones de decisión de MR-II 2-3-1 con ruido. Centro: MLP-backpropagation 2-2-1. Derecha: Curva de aprendizaje MSE del MLP.

Configuración	Tasa éxito	Mediana épocas
MR-II 2-2-1 sin ruido	0/20	—
MR-II 2-2-1 + ruido	0/20	—
MR-II 2-3-1 + ruido	0/20	—
MLP-BP 2-2-1	6/20	40
MLP-BP 2-3-1	11/20	22

Cuadro 3: Tasa de éxito en XOR sobre 20 inicializaciones distintas.

La Tabla 3 presenta el resultado más revelador de este experimento:

- **MRII 2–2–1 sin ruido: 0/20.** Sin el mecanismo de escape, MRII se estanca sistemáticamente en óptimos locales, tal como advierte la Sección VII-E del paper. Este es un **resultado**, no un error de implementación.
- **MRII con ruido esporádico ($\sigma = 0.15$): 0/20 incluso con 3 Adalines ocultas.** En nuestra implementación, el ruido gaussiano no fue suficiente para escapar de los mínimos locales en XOR, posiblemente porque la corrección absoluta agresiva del refuerzo colineal domina sobre el escape estocástico.
- **MLP-*backpropagation* 2–2–1: 6/20** (mediana ≈ 40 épocas). La inicialización aleatoria de pesos determina si la red cae o no en un mínimo local, consistente con la literatura [1, 5].
- **MLP-*backpropagation* 2–3–1: 11/20.** Una Adaline adicional en la capa oculta casi duplica la tasa de éxito al proporcionar más grados de libertad para sortear los mínimos locales.

Estos resultados confirman **H3**: XOR es resoluble por arquitecturas multicapa pero tanto MRII como *backpropagation* están sujetos a óptimos locales. La diferencia en las tasas de éxito (6/20 para MLP vs. 0/20 para MRII) refleja que la superficie de error sigmoide (E4) es inherentemente más navegable que la del signum.

4.6. E6: MLP en datasets reales




Figura 8: Resultados del MLP 4–8–3 en Iris. Izquierda: Curva MSE. Centro: Accuracy por época. Derecha: Matriz de confusión (91.1 % test).




Figura 9: Regiones de decisi3n del MLP 2-8-1 en two-moons (93.3 % test).




Figura 10: Convergencia de clasificadores lineales en Wine. Wiener y μ -LMS alcanzan 98.1 % test.




Figura 11: MLP 64–16–5 en MNIST dígitos 0–4 (98.5 % test).

μ	η	Acc. train	Acc. test	Ep. a 95 %	Tiempo (s)
0.001	0.0	98.1 %	91.1 %	62	0.99
0.001	0.9	98.1 %	91.1 %	62	1.04
0.010	0.0	100.0 %	91.1 %	7	0.98
0.010	0.9	100.0 %	91.1 %	7	1.08
0.050	0.0	100.0 %	91.1 %	4	1.03
0.050	0.9	100.0 %	91.1 %	4	1.08

Cuadro 4: Resultados del MLP 4–8–3 en Iris para la grilla $\mu \times \eta$.

Atributo	$\ W_1\ _2$	Contribucion (%)
sepal length (cm)	1.50	6.4 %
sepal width (cm)	4.54	19.2 %
petal length (cm)	6.23	26.4 %
petal width (cm)	11.32	48.0 %

Cuadro 5: Relevancia de variables en Iris medida como $\|W_1\|_2$ por atributo.

Iris (Figura 8, Tablas 4–5): Como predice la teoría, Setosa es linealmente separable del resto: el Perceptrón converge en 2 épocas (100 % test). Versicolor vs. Virginica **no es separable**, con un techo de ≈ 83 % para un clasificador lineal. El MLP 4–8–3 alcanza consistentemente **91.1 % en test** para todas las configuraciones de μ y η , con convergencia más rápida para $\mu = 0.05$ (4 épocas al 95 % train). El momentum ($\eta = 0.9$) no aporta beneficio en este problema pequeño y bien condicionado, consistente con la observación del paper: “el momentum por sí solo suele ser de poco valor” [1]. La matriz de confusión concentra los 4 errores (de 45) exclusivamente en el par versicolor $\leftrightarrow$ virginica.

El análisis de relevancia de variables (Tabla 5) revela que los atributos de pétalos concentran el 74.4 % del peso total de la primera capa (*petal width*: 48.0 %, *petal length*: 26.4 %), consistente con el conocimiento botánico de que estas medidas son los discriminantes más informativos en Iris [9].

Two-moons (Figura 9): El MLP 2–8–1 con *backpropagation* alcanza **93.3 % test**, trazando una frontera no lineal que se ajusta a la geometría de las medias lunas.

Wine (Figura 10): Los clasificadores lineales alcanzan un rendimiento sorprendentemente alto: Wiener = 98.1 %, μ -LMS = 98.1 %, α -LMS = 96.3 %. Esto sugiere que la clase 0 es mayoritariamente separable del resto en el espacio de 13 atributos fisicoquímicos.

MNIST-04 (Figura 11): El MLP 64–16–5 alcanza **98.5 % test**, demostrando que incluso una arquitectura simple con *backpropagation* puede manejar datos de mediana dimensionalidad (64 features) con alta precisión.

4.7. E7: MRIII $\equiv$ Backpropagation




Figura 12: Izquierda: Error relativo $\|\nabla_{\text{MRIII}} - \nabla_{\text{BP}}\| / \|\nabla_{\text{BP}}\|$ vs. Δs (escala log-log, eje x invertido). El error mínimo es 5.05×10^{-8} en $\Delta s = 10^{-8}$. Derecha: Costo computacional por presentación (ms).

Ocultas (H)	Adalines	BP (ms)	MRIII (ms)	Razon
4	7	0.0201	0.0701	3.5×
16	19	0.0194	0.2148	11.0×
64	67	0.0312	0.5881	18.9×
256	259	0.0341	2.5297	74.1×

Cuadro 6: Costo computacional de *backpropagation* vs. MRIII para redes 4-H-3.

La Figura 12(a) confirma **H4** con precisión numérica: el gradiente estimado por perturbación (MRIII) converge al gradiente analítico de *backpropagation* con error relativo mínimo de 5.05×10^{-8} en $\Delta s = 10^{-8}$. El error decrece linealmente con Δs hasta que la precisión de punto flotante de 64 bits ($\approx 10^{-16}$) causa un rebote para $\Delta s < 10^{-8}$.

La Figura 12(b) y la Tabla 6 cuantifican el costo de esta equivalencia: MRIII es 3.5× más costoso para $H = 4$ y 74.1× para $H = 256$. La razón crece aproximadamente como $\mathcal{O}(N_{\text{Adalines}})$, validando que *backpropagation* es la opción óptima para implementación digital, mientras MRIII tiene sentido únicamente en hardware analógico donde la perturbación física del sumidero es más simple que la retropropagación de señales de error.

4.8. Tabla resumen

Exp.	Problema	Algoritmo	Resultado clave
E1	Capacidad de Cover	Monte Carlo LP	$C_s \approx 2N_w$, $C_d = N_w$ verificado
E2	Datos separables	Perceptron, α -LMS, μ -LMS	Perceptron converge en 2 ep.; μ -LMS a 3.5° de Wiener
E3	Datos no separables	Perceptron, α -LMS, μ -LMS	μ -LMS mejor: 79.6% ± 1.5 vs Wiener 81.0%
E4	Superficies MSE	Adaline 2D	MSE signum tiene mesetas y optimos locales
E5	XOR	MRII, MLP-BP	MRII 0/20; MLP-BP 6/20 (2-2-1), 11/20 (2-3-1)
E6	Iris (real)	MLP 4-8-3	Mejor acc test=91.1% ($\mu=0.05$, $\eta=0$)
E6b	Two-moons	MLP 2-8-1	Acc test=93.3%
E6c	Wine (real)	α -LMS, μ -LMS, Wiener	Wiener acc=98.1%
E6d	MNIST-04	MLP 64-16-5	Acc test=98.5%
E7	MRIII vs BP	Gradiente + costo	Err min= 5.05×10^{-8} en $\Delta s = 10^{-8}$; MRIII 11× mas caro

Cuadro 7: Resumen consolidado de todos los experimentos.

5. Conclusiones

5.1. Aporte al conocimiento

El artículo de Widrow & Lehr (1990) realiza un aporte fundamental a la disciplina al **unificar 30 años de algoritmos de aprendizaje supervisado** para RNA feedforward bajo un principio común: la mínima perturbación. Los experimentos realizados en este trabajo verifican empíricamente esta unificación:

1. **El linaje Perceptrón $\rightarrow$ Adaline $\rightarrow$ Madaline $\rightarrow$ Backpropagation** no es una colección arbitraria de algoritmos, sino una progresión lógica gobernada por el mismo principio geométrico: ΔW_k es siempre colineal con X_k , minimizando $\|\Delta W_k\|$ para la corrección deseada.
2. **El trade-off capacidad-generalización** ($C_s \approx 2N_w$, $N_p \gg N_w/N_y$) establece límites fundamentales que siguen siendo relevantes en la era del *deep learning*: una red sobreparametrizada ($N_w > N_p$) memoriza; una red correctamente dimensionada generaliza.
3. **El valor pedagógico e histórico** del artículo es inmenso: las ecuaciones de *backpropagation* (1986) ya estaban implícitas en el trabajo de Werbos (1974), y la equivalencia $\text{MRIII} \equiv \text{backpropagation}$ demuestra que el descubrimiento científico a menudo ocurre por múltiples caminos independientes.

5.2. Evaluación de las hipótesis

- H1 – Capacidad de Cover: Confirmada.** La simulación Monte Carlo (E1) reproduce la fórmula teórica con desviación media ≤ 0.034 .
- H2 – Convergencia del Perceptrón: Confirmada.** El Perceptrón converge en 2 épocas en datos separables (E2), pero oscila ± 5.5 puntos en datos no separables (E3), mientras μ -LMS mantiene estabilidad (± 1.5 pts, a 1.4 pts del óptimo de Wiener).
- H3 – Poder no lineal y óptimos locales: Confirmada con matices.** XOR es resoluble solo por arquitecturas multicapa, pero MRII (0/20) resultó más vulnerable a óptimos locales que MLP-*backpropagation* (6/20 para 2-2-1, 11/20 para 2-3-1). El ruido esporádico no fue suficiente para rescatar MRII en nuestra implementación.
- H4 – Equivalencia $\text{MRIII} \equiv \text{Backpropagation}$: Confirmada.** El error relativo entre gradientes es 5.05×10^{-8} , y el costo de MRIII escala como $\mathcal{O}(N_{\text{Adalines}})$, siendo $3.5\times$ a $74.1\times$ más costoso que *backpropagation*.

5.3. Limitaciones

- Los datasets utilizados son de baja dimensionalidad (≤ 64 atributos). No se evaluó la escalabilidad a problemas de alta dimensionalidad.
- La implementación de MRII, aunque conceptualmente completa, no logró resolver XOR ni siquiera con el mecanismo de ruido. Una implementación más refinada del escape (recocido simulado, *random restarts*) podría mejorar estos resultados.
- No se implementaron variantes avanzadas de *backpropagation* mencionadas en el artículo (*quick-prop*, *delta-bar-delta*, *backprop through time*).
- Las comparaciones se limitan a los algoritmos del artículo; no se incluyen métodos modernos (SVM, Random Forest, *transformers*) que podrían establecer una línea base más exigente.

5.4. Reflexión personal

Treinta y cinco años después de su publicación, el artículo de Widrow & Lehr permanece sorprendentemente vigente. El principio de mínima perturbación es, en esencia, el mismo que gobierna el *stochastic gradient descent* (SGD) que entrena los modelos de *deep learning* actuales: μ -LMS generalizado a arquitecturas profundas. El momentum (Eqs. 96–97) sigue siendo un hiperparámetro estándar en optimizadores como Adam. Y la perturbación de MRIII anticipa los métodos de optimización de orden cero (*zeroth-order optimization*) usados hoy en escenarios donde el gradiente no está disponible. La gran lección del artículo es que los fundamentos importan: comprender la geometría del aprendizaje —el hiperplano separador, el paraboloide de MSE, las mesetas del error signum— es esencial para diseñar, depurar y mejorar cualquier sistema de aprendizaje automático, clásico o moderno.

Referencias

- [1] B. Widrow and M. A. Lehr, “30 years of adaptive neural networks: Perceptron, Madaline, and backpropagation,” *Proceedings of the IEEE*, vol. 78, no. 9, pp. 1415–1442, 1990.
- [2] F. Rosenblatt, “The perceptron: A probabilistic model for information storage and organization in the brain,” *Psychological Review*, vol. 65, no. 6, pp. 386–408, 1958.
- [3] B. Widrow and M. E. Hoff, “Adaptive switching circuits,” in *IRE WESCON Convention Record*, vol. 4, 1960, pp. 96–104.
- [4] T. M. Cover, “Geometrical and statistical properties of systems of linear inequalities with applications in pattern recognition,” *IEEE Transactions on Electronic Computers*, vol. EC-14, no. 3, pp. 326–334, 1965.
- [5] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, “Learning representations by back-propagating errors,” *Nature*, vol. 323, pp. 533–536, 1986.
- [6] P. J. Werbos, “Beyond regression: New tools for prediction and analysis in the behavioral sciences,” Ph.D. dissertation, Harvard University, Cambridge, MA, 1974.
- [7] M. L. Minsky and S. A. Papert, *Perceptrons: An Introduction to Computational Geometry*. Cambridge, MA: MIT Press, 1969.
- [8] G. Cybenko, “Approximation by superpositions of a sigmoidal function,” *Mathematics of Control, Signals and Systems*, vol. 2, no. 4, pp. 303–314, 1989.
- [9] R. A. Fisher, “The use of multiple measurements in taxonomic problems,” *Annals of Eugenics*, vol. 7, no. 2, pp. 179–188, 1936.
- [10] B. Widrow, R. G. Winter, and R. A. Baxter, “Layered neural nets for pattern recognition,” *IEEE Transactions on Acoustics, Speech, and Signal Processing*, vol. 36, no. 7, pp. 1109–1118, 1988.
- [11] T. J. Sejnowski and C. R. Rosenberg, “Parallel networks that learn to pronounce English text,” *Complex Systems*, vol. 1, pp. 145–168, 1987.
- [12] D. H. Nguyen and B. Widrow, “Neural networks for self-learning control systems,” *IEEE Control Systems Magazine*, vol. 10, no. 3, pp. 18–23, 1990.
- [13] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed. New York: Springer, 2009.
- [14] C. M. Bishop, *Pattern Recognition and Machine Learning*. New York: Springer, 2006.