

Algoritmos de Aprendizaje en Redes Neuronales Feedforward

Un análisis del artículo de Widrow & Lehr (1990):

30 Years of Adaptive Neural Networks: Perceptron, Madaline, and Backpropagation

Estudiante

Universidad de Santiago de Chile

Magíster en Ingeniería Informática

Julio 2026

Resumen

Este informe presenta un análisis del artículo de revisión de Widrow & Lehr (1990) sobre 30 años de algoritmos de aprendizaje supervisado en redes neuronales artificiales (RNA) feedforward. El marco teórico cubre la familia completa de algoritmos del artículo, organizada según los dos ejes del propio paper: reglas de **corrección de error** (α -LMS, Perceptrón, Mays, *Madaline Rule I*, *Madaline Rule II*) y reglas de **descenso más pronunciado** (μ -LMS, *backpropagation*, *Madaline Rule III*). De ellos se implementaron desde cero en NumPy puro los seis algoritmos experimentales —Perceptrón, α -LMS, μ -LMS, MLP con *backpropagation*, *Madaline Rule II* y *Madaline Rule III*— y se ejecutaron siete experimentos para verificar las hipótesis fundamentales del principio de mínima perturbación. Los resultados confirman que: (1) la capacidad estadística $C_s \approx 2N_w$ de Cover se verifica empíricamente, (2) el Perceptrón converge en tiempo finito solo en datos separables mientras μ -LMS se aproxima al óptimo de Wiener, (3) el MLP con *backpropagation* resuelve XOR (6/20, 2–2–1) y alcanza 91.1% en Iris, (4) *Madaline Rule III* es matemáticamente equivalente a *backpropagation* con error relativo de 5.05×10^{-8} , a un costo computacional que crece aproximadamente como $\mathcal{O}(N_{\text{Adalines}})$. Se discute el principio de mínima perturbación como marco unificador del aprendizaje supervisado en RNA.

1. Introducción

1.1. Problema abordado

El artículo de Widrow & Lehr (1990) [1] aborda el problema fundamental del **aprendizaje supervisado en redes neuronales artificiales feedforward**: ¿cómo adaptar los pesos sinápticos de una red de elementos computacionales simples para que aproximen una función de clasificación o regresión a partir de ejemplos? El artículo revisa 30 años de desarrollo de algoritmos de entrenamiento —desde el Perceptrón de Rosenblatt (1958) hasta la retropropagación del error de Rumelhart, Hinton & Williams (1986)— y demuestra que todos ellos comparten un principio unificador: el **principio de mínima perturbación** (*minimal disturbance principle*), que establece que durante el entrenamiento es recomendable inyectar nueva información en la red de manera que perturbe la información ya almacenada en la menor medida posible [1].

El artículo es una revisión (*survey*) y tutorial, no un estudio experimental sobre un dataset único. Su contribución es **conceptual e histórica**: traza la evolución desde las primeras reglas de aprendizaje (1960) hasta las redes multicapa con *backpropagation*, y demuestra conexiones matemáticas profundas entre algoritmos desarrollados independientemente. En particular, establece que *Madaline Rule III* (Andes, 1988) es matemáticamente equivalente a *backpropagation*, un hallazgo realizado por Widrow y sus estudiantes [1].

1.2. Reseña histórica

La Sección I del artículo sitúa la contribución dentro de tres décadas de desarrollo. Los hitos del linaje que el paper sigue en detalle son: la **regla del Perceptrón** (Rosenblatt) y el algoritmo **LMS** (Widrow & Hoff), ambos publicados en 1960; la **Madaline Rule I** (mediados de los 60), primera regla popular para redes con múltiples elementos adaptativos, con aplicaciones en voz, predicción del clima y reconocimiento de patrones; la **retropropagación** formulada por Werbos (1971–1974), ignorada inicialmente, redescubierta por Parker (1982) y popularizada por Rumelhart, Hinton & Williams (1986); la **Madaline Rule II** (Widrow, Winter & Baxter, 1987) para adaptar redes multicapa con cuantizadores duros; y la **Madaline Rule III** (Andes, 1988). En paralelo, el artículo reconoce ramas que no desarrolla en profundidad —la *Learning Matrix* de Steinbuch, la teoría ART de Grossberg, los mapas de Kohonen, los modelos de Hopfield, la máquina de Boltzmann y el Cognitron/Neocognitron de Fukushima—, delimitando que su foco son los algoritmos nacidos en Stanford y la retropropagación [1].

1.3. ¿Por qué redes neuronales artificiales?

La motivación para usar RNA en problemas de clasificación y regresión se fundamenta en tres argumentos presentados en las Secciones I–II del artículo [1]:

- (I) **Paralelismo masivo y robustez:** los sistemas biológicos resuelven tareas de reconocimiento de patrones y procesamiento de voz e imágenes con una facilidad que las computadoras von Neumann no igualan. Las RNA emulan este paralelismo mediante muchos elementos simples interconectados que procesan información simultáneamente.
- (II) **Aprendizaje por ejemplos:** a diferencia de los sistemas algorítmicos tradicionales, las RNA no requieren programación explícita de reglas; aprenden el mapeo entrada–salida directamente de los datos mediante algoritmos iterativos.
- (III) **Generalización:** una RNA correctamente entrenada clasifica patrones no vistos durante el entrenamiento. La capacidad de generalización está inversamente relacionada con la capacidad de almacenamiento ($C_s \approx 2N_w$, Cover, 1964 [4]), un *trade-off* fundamental que el artículo explora en profundidad.

Aplicaciones históricas que demuestran la viabilidad práctica incluyen NETtalk (Sejnowski & Rosenberg, 1987), una red de 80–26 Adalines que aprende a pronunciar texto en inglés; el *truck backer-upper* de Nguyen & Widrow (1989), donde una red de 26 Adalines aprende a retroceder un camión con acoplado; y los ecualizadores adaptativos basados en LMS para módems de alta velocidad, la primera aplicación comercial masiva de las RNA [1].

1.4. Hipótesis

Se plantean cuatro hipótesis que guían la experimentación:

- H1 – Capacidad de Cover:** la capacidad estadística de un Adaline es $C_s \approx 2N_w$ y la determinística $C_d = N_w$, verificable mediante simulación Monte Carlo con programación lineal.
- H2 – Convergencia finita del Perceptrón:** el Perceptrón converge en tiempo finito si los datos son linealmente separables, pero oscila y diverge en norma si no lo son. Por contraste, α -LMS y μ -LMS son estables en ambos casos, con μ -LMS convergiendo al óptimo de Wiener $W^* = R^{-1}P$.
- H3 – Poder no lineal y óptimos locales:** XOR es irresoluble por un solo Adaline pero resoluble por *Madaline Rule II* y MLP con *backpropagation*, aunque ambos algoritmos están sujetos a óptimos locales en la superficie de error. El remedio de ruido esporádico propuesto en la Sección VII-E del paper [1] mitiga parcialmente este problema.

H4 – Equivalencia MRIII $\equiv$ Backpropagation: *Madaline Rule III* converge a *backpropagation* cuando la perturbación $\Delta s \rightarrow 0$, pero su costo computacional en implementación digital es proporcionalmente mayor (requiere $1 + N_{\text{Adalines}}$ pasadas hacia adelante por presentación versus 1 adelante + 1 atrás de *backpropagation*).

2. Marco Teórico

El artículo organiza todos sus algoritmos según dos ejes (Fig. 1): el **mecanismo de adaptación** —corrección de error frente a descenso más pronunciado— y la **no linealidad** del elemento —lineal, sigmoide o signum—, para uno o múltiples elementos. Este marco teórico sigue esa misma estructura: primero los conceptos comunes (§2.1–2.2), luego la familia de corrección de error (§2.3) y la de descenso más pronunciado (§2.4), cerrando con la taxonomía (§2.5).

2.1. Conceptos fundamentales

2.1.1. El combinador lineal adaptativo y el Adaline

El bloque constructivo fundamental de las RNA feedforward es el **combinador lineal adaptativo** (Fig. 1 del paper), que calcula el producto interno $s_k = X_k^T W_k$, donde $X_k = [x_0 = +1, x_{1k}, \dots, x_{nk}]^T$ es el vector de entrada aumentado con bias y $W_k \in \mathbb{R}^{n+1}$ el vector de pesos. Cuando su salida lineal se hace pasar por un **cuantizador** de límite duro (*signum*) se obtiene el **Adaptive Linear Element** (Adaline, Fig. 2), un elemento lógico de umbral adaptativo con salida binaria $y_k = \text{sgn}(s_k) \in \{\pm 1\}$. El peso de bias w_{0k} controla el umbral. En su variante diferenciable, el signum se reemplaza por una sigmoide como la tangente hiperbólica $y_k = \tanh(s_k)$, que habilita las reglas de descenso por gradiente [1].

2.1.2. Separabilidad lineal y capacidad de patrones

La condición crítica $s = 0$ define un **hiperplano separador** en el espacio de patrones. Con n entradas binarias, un Adaline solo puede implementar las funciones lógicas **linealmente separables**: 14 de 16 posibles para $n = 2$, excluyendo XOR/XNOR [1]. Cover (1964) [4] demostró que la probabilidad de que N_p patrones aleatorios sean linealmente separables por un Adaline de N_w pesos es:

$$P(N_p, N_w) = \begin{cases} 1 & \text{si } N_p \leq N_w \\ 2^{1-N_p} \sum_{i=0}^{N_w-1} \binom{N_p-1}{i} & \text{si } N_p > N_w \end{cases} \quad (1)$$

De aquí se derivan la **capacidad determinística** $C_d = N_w$ (garantía de solución) y la **capacidad estadística** $C_s \approx 2N_w$ (promedio de patrones absorbibles). Para redes multicapa, Baum acotó $N_w/N_y - K_1 \leq C_d \leq (N_w/N_y) \log_2(N_w/N_y) + K_2$ [1]. La regla práctica de generalización es $N_p \gg N_w/N_y$: el número de patrones de entrenamiento debe exceder la relación pesos/salidas para que la red generalice en lugar de memorizar.

2.1.3. Clasificadores no lineales: el preprocesador polinomial

La primera vía del artículo hacia fronteras no lineales sin usar varias capas es un **preprocesador polinomial fijo** conectado a un único Adaline adaptativo (Fig. 6 del paper). Para dos entradas, el preprocesador expande el vector a los términos $[x_1^2, x_1, x_1x_2, x_2, x_2^2]$ y la condición de umbral se vuelve:

$$s = w_0 + x_1w_1 + x_1^2w_{11} + x_1x_2w_{12} + x_2^2w_{22} + x_2w_2 = 0. \quad (2)$$

Con una elección adecuada de pesos, la frontera separadora en el espacio de patrones puede ser una curva cerrada —por ejemplo, una **elipse**— que sí resuelve el XNOR (Fig. 7). Especht desarrolló para esto el *polynomial discriminant method* (PDM), un procedimiento no iterativo de una sola pasada. Tras el entrenamiento por gradiente, los pesos del Adaline aproximan los coeficientes de una expansión

de Taylor multidimensional de la función de respuesta deseada [1]. La elección del preprocesador determina la generalización; la experiencia indica que, salvo que las no linealidades se ajusten con cuidado al problema, suele obtenerse mejor generalización con redes de más de una capa adaptativa.

2.1.4. Redes feedforward y las señales de error ocultas

La alternativa general es la **red feedforward multicapa** totalmente conectada (Fig. 11), donde todas las capas son adaptativas. La adaptación de la capa de salida es directa —el error se computa comparando con la respuesta deseada—, pero la dificultad fundamental es obtener “**señales de error**” para las Adalines de las capas ocultas. *backpropagation* y *Madaline Rule III* son precisamente los dos mecanismos que el artículo propone para establecer estas señales [1].

2.2. El principio de mínima perturbación

Todos los algoritmos del artículo obedecen un principio común (Sección III): *adaptar para reducir el error de salida del patrón actual, con la mínima perturbación a las respuestas ya aprendidas*. Geométricamente, esto se traduce en que el cambio de pesos ΔW_k sea **colineal** con el vector de entrada X_k , logrando la corrección deseada con el cambio de menor magnitud posible. Este principio, intuitivo, fue lo que condujo al descubrimiento del algoritmo LMS y de las reglas Madaline [1].

2.3. Reglas de corrección de error

Las reglas de corrección de error alteran los pesos para corregir una proporción del error en la respuesta al patrón presente. Se aplican primero a un solo Adaline y luego a redes.

2.3.1. α -LMS — regla delta de Widrow-Hoff (Eq. 10)

$$W_{k+1} = W_k + \alpha \frac{\varepsilon_k}{\|X_k\|^2} X_k, \quad \varepsilon_k = d_k - X_k^T W_k \quad (3)$$

Única regla lineal de corrección de error: el cambio es proporcional al error *lineal* y colineal con X_k . Es auto-normalizante (la elección de α no depende de la magnitud de las entradas). Rango de estabilidad $0 < \alpha < 2$; práctico $0.1 < \alpha < 1.0$ [1].

2.3.2. Regla del Perceptrón de Rosenblatt (Eq. 18)

$$W_{k+1} = W_k + \alpha \frac{\tilde{\varepsilon}_k}{2} X_k, \quad \tilde{\varepsilon}_k = d_k - y_k \in \{-2, 0, +2\} \quad (4)$$

Regla no lineal: usa el error del *cuantizador* $\tilde{\varepsilon}_k$ y solo adapta si $y_k \neq d_k$. El **teorema de convergencia del Perceptrón** garantiza separación en pasos finitos si los datos son linealmente separables; si no lo son, el vector de pesos “gravita hacia cero” y el algoritmo continúa indefinidamente [1, 2].

2.3.3. Reglas de Mays: la zona muerta

Mays (1963) introdujo una **zona muerta** γ alrededor de la salida lineal s_k . En su regla de *adaptación por incremento* [1]:

$$W_{k+1} = \begin{cases} W_k + \alpha \tilde{\varepsilon}_k \frac{X_k}{2\|X_k\|^2} & \text{si } |s_k| \geq \gamma \\ W_k + \alpha d_k \frac{X_k}{\|X_k\|^2} & \text{si } |s_k| < \gamma \end{cases} \quad (5)$$

Si los patrones son linealmente separables, la regla converge en pasos finitos. La ventaja aparece en datos *no* separables: una zona muerta suficientemente grande tiende a alejar el vector de pesos de cero cuando existe una solución razonablemente buena, por lo que Mays se desempeña mucho mejor que el Perceptrón en ese régimen. Los casos límite recuperan reglas conocidas: con $\gamma \rightarrow 0$ se obtiene el Perceptrón normalizado, y la variante de *relajación modificada* con $\gamma \rightarrow \infty$ se reduce a α -LMS [1].

2.3.4. Madaline Rule I (MRI)

MRI (Widrow & Hoff, principios de los 60) es una de las primeras redes en capas entrenables: una capa de Adalines con cuantizador signum cuyas salidas alimentan un **elemento lógico fijo** de segunda capa (AND, OR o mayoría MAJ; Figs. 8–10 y 15 del paper). Como la lógica de salida es conocida, es posible determinar qué Adalines de la primera capa deben adaptarse para corregir un error. La regla adapta la(s) Adaline(s) cuya salida lineal $|s_k|$ está *más cerca de cero* —las que requieren el menor cambio de pesos para invertir su respuesta— invirtiendo las suficientes para que la lógica de salida coincida con la deseada. La adaptación puede ser *absoluta* (corrección agresiva, aprendizaje “rápido”) o por el incremento de α -LMS (“lento”). Un *job assigner* reparte la responsabilidad entre Adalines (*load-sharing*: “asignar la responsabilidad a quien pueda asumirla más fácilmente”), y la presentación de patrones debe ser aleatoria para evitar ciclos [1]. Como MRII, MRI puede estancarse en óptimos locales.

2.3.5. Madaline Rule II (MRII)

Madaline Rule II (Widrow, Winter & Baxter, 1987) [1] extiende la adaptación a *todas* las capas de una red de Adalines con cuantizador signum (Fig. 16). Para cada patrón erróneo: (1) se ordenan las Adalines por $|s|$ creciente; (2) se invierte tentativamente (*flip*) la salida de una Adalina; si reduce el error de Hamming, se acepta y se refuerza con una corrección colineal por α -LMS; (3) si no, se prueban pares de Adalines; (4) la capa de salida se entrena con α -LMS. El artículo advierte que MRII puede estancarse en óptimos locales y propone como remedio la **adición esporádica de ruido** o el reentrenamiento con distintas semillas (Sección VII-E) [1].

2.4. Reglas de descenso más pronunciado

A diferencia de la corrección de error, estas reglas minimizan el error *promediado* sobre el conjunto de entrenamiento —típicamente el MSE— mediante descenso por gradiente, usando en la práctica el gradiente instantáneo de un patrón a la vez.

2.4.1. μ -LMS y la superficie de MSE (Eq. 33)

$$W_{k+1} = W_k + 2\mu \varepsilon_k X_k \quad (6)$$

La superficie de MSE $\xi(W) = \mathbb{E}[d^2] - 2P^T W + W^T R W$ es un hiperparaboloide **convexo** con mínimo único, la solución de Wiener $W^* = R^{-1}P$ (Fig. 17). El gradiente instantáneo $-2\varepsilon_k X_k$ es un estimador *insesgado* del verdadero. Estabilidad: $0 < \mu < 1/\text{tr}[R]$. Frente a α -LMS: μ -LMS converge a la solución de mínimo MSE (Wiener), mientras que α -LMS converge a la solución de Wiener del conjunto *normalizado* y, para entradas no binarias, a una solución sesgada [1].

2.4.2. Backpropagation: del Adaline sigmoideal a la red

Para el Adaline sigmoide ($y = \tanh(s)$), minimizar $\mathbb{E}[\tilde{\varepsilon}^2]$ por descenso da la regla (Eq. 56):

$$W_{k+1} = W_k + 2\mu \tilde{\varepsilon}_k \cdot (1 - y_k^2) X_k \quad (7)$$

En una red multicapa, la generalización es *backpropagation*: las “derivadas del error cuadrático” δ se propagan hacia atrás. Para la capa de salida (Eq. 79) y las ocultas (Eq. 87):

$$\delta_j^{(L)} = \varepsilon_j \cdot (1 - y_j^2) \quad (8)$$

$$\delta^{(l)} = (W^{(l+1)T} \delta^{(l+1)}) \odot (1 - (y^{(l)})^2) \quad (9)$$

y la actualización, con **momentum** (Eqs. 96–97):

$$\Delta W_k = \eta \Delta W_{k-1} + (1 - \eta) 2\mu \delta_k X_k^T, \quad \eta \approx 0.8\text{--}0.9 \quad (10)$$

Es crucial notar que δ **no es un error**: es una señal de gradiente que indica cómo cambiar cada peso para reducir el error cuadrático de salida ε^2 [1, 5].

2.4.3. Madaline Rule III (MRIII) y equivalencia con Backpropagation

Madaline Rule III (Andes, 1988) reemplaza el *signum* por sigmoide y estima el gradiente de ε^2 respecto a s_j mediante **perturbación del sumidero** (Eqs. 102–103) [1]:

$$\frac{\partial \varepsilon^2}{\partial s_j} \approx \frac{\varepsilon_{\text{perturbado}}^2 - \varepsilon_{\text{base}}^2}{\Delta s} \quad (11)$$

Cuando $\Delta s \rightarrow 0$, MRIII es **matemáticamente equivalente a backpropagation**. Requiere $1 + N_{\text{Adalines}}$ pasadas hacia adelante por patrón (frente a $1 + 1$ de *backpropagation*), lo que lo hace menos eficiente en digital, pero más robusto para hardware analógico, donde no necesita conocer la derivada exacta de la sigmoide (existió un chip comercial de MRIII) [1].

2.5. Síntesis: taxonomía de algoritmos

La Figura 1 reproduce la taxonomía de la Fig. 33 del artículo, que resume la totalidad de reglas estudiadas. Las dos ramas superiores son los mecanismos de adaptación; cada una se subdivide por arquitectura (red en capas / elemento único) y por no linealidad (sigmoide, *signum* o lineal). El hallazgo central del paper —que *Madaline Rule III* y *backpropagation* coinciden— se refleja en que ambos aparecen como hojas de la rama sigmoide del descenso más pronunciado.




Figura 1: Taxonomía de las reglas de aprendizaje del artículo (reproducción de la Fig. 33 del paper). De los ocho algoritmos, se implementan y experimentan seis: Perceptrón, α -LMS, μ -LMS, MLP con *backpropagation*, *Madaline Rule II* y *Madaline Rule III*; MRI, Mays y el preprocesador polinomial se cubren en el marco teórico.

3. Experimentación

3.1. Diseño experimental

Dado que el artículo es una revisión teórica, la experimentación consiste en **implementar desde cero los algoritmos experimentables** y verificar las hipótesis H1–H4 mediante siete experimentos (E1–E7), con validación en datasets reales adicionales. La Tabla 1 resume el diseño. Las reglas de Mays, MRI y el preprocesador polinomial se analizan en el marco teórico y no tienen experimento propio.

3.2. Datasets

Sintéticos separables (200 puntos, gaussianas $N([\pm 2, \pm 2], 0.35^2 I)$); no separables ($N([\pm 0.9, \pm 0.9], 1.3^2 I)$); XOR (4 patrones $\{\pm 1\}^2$); Iris (Fisher, 1936; UCI: 150 flores, 4 atributos, 3 clases, *split* 70/30 estratificado, normalizado a $[-1, 1]$); two-moons (300 puntos, ruido 0.20); Wine (UCI: 178 muestras, 13 atributos, binarizado); MNIST-04 (UCI digits: dígitos 0–4, $8 \times 8 = 64$ atributos, 901 instancias).

Exp.	Tema	Hip.	Algoritmos	Dataset
E1	Capacidad de Cover	H1	Programación Lineal	Sintético Monte Carlo
E2	Reglas lineales, separable	H2	Perceptrón, α -LMS, μ -LMS	Gaussianas separables
E3	Datos no separables	H2	Perceptrón, α -LMS, μ -LMS	Gaussianas solapadas
E4	Superficies MSE	—	Adaline 2D	Patrones aleatorios
E5	XOR: MRII vs MLP	H3	MRII, MLP- <i>backpropagation</i>	XOR (4 patrones)
E6	Datasets reales	—	MLP- <i>backpropagation</i> , α -LMS, μ -LMS	Iris, Wine, MNIST-04, moons
E7	MRIII $\equiv$ <i>backpropagation</i> + costo	H4	MRIII, <i>backpropagation</i>	Iris (1 patrón)

Cuadro 1: Diseño experimental.

3.3. Implementación y complejidad

Todos los algoritmos se implementaron desde cero en **NumPy puro** (sin PyTorch, TensorFlow ni el aprendizaje de scikit-learn, usado solo para carga de datos y métricas). La reproducibilidad se garantiza con semilla global **SEED=1990**. El costo por presentación es $\mathcal{O}(N_w)$ para Perceptrón/LMS y para *backpropagation* (forward + backward), y $\mathcal{O}(N_w \cdot N_{\text{Adalines}})$ para MRIII, que requiere $1 + N_{\text{Adalines}}$ pasadas hacia adelante (una sin perturbar y una por cada Adaline perturbada). Esta diferencia se cuantifica en E7.

4. Análisis de Resultados

4.1. E1: Capacidad de Cover




Figura 2: Probabilidad de separabilidad lineal: empírica (puntos) vs. fórmula teórica de Cover (curvas). Líneas verticales en $C_d = N_w$ (punteada) y $C_s \approx 2N_w$ (discontinua).

La Figura 2 muestra un ajuste estrecho entre la probabilidad empírica (80 ensayos Monte Carlo por punto, separabilidad testada con **linprog**) y la fórmula teórica (Eq. 1). Las desviaciones medias $|\text{empírica} - \text{teórica}|$ son 0.0337 para $N_w = 2$, 0.0259 para $N_w = 5$ y 0.0105 para $N_w = 15$, decreciendo con N_w como predice la teoría asintótica. La transición en $N_p/N_w = 1$ (C_d) y $N_p/N_w = 2$ (C_s) se agudiza al aumentar N_w , confirmando **H1**.

4.2. E2: Reglas lineales en datos separables

La Figura 4 revela un resultado fundamental: **el Perceptrón converge en solo 2 épocas** (confirmando el teorema), pero su frontera queda a 20.6° del óptimo de Wiener — el Perceptrón “se detiene




Figura 3: Datasets sintéticos utilizados: separable, no separable y XOR.




Figura 4: Fronteras de decisión de los tres algoritmos lineales (color) vs. el hiperplano óptimo de Wiener (negro discontinuo). Ángulos respecto a W^* indicados.




Figura 5: Convergencia de μ -LMS para distintos μ . $\mu = 0.12$ diverge por exceder la cota $\mu_{\text{máx}} = 1/\text{tr}[R] = 0.111$. La línea horizontal marca el MSE de Wiener (0.015).

donde primero separa”. En contraste, α -LMS y μ -LMS optimizan el MSE, acercándose a 4.4° y 3.5° de W^* respectivamente.

La Figura 5 demuestra la cota de estabilidad: con $\mu = 0.12 > 1/\text{tr}[R] = 1/9.02 = 0.111$, el MSE diverge exponencialmente. Los valores $\mu \in \{0.001, 0.01, 0.05\}$ convergen al MSE de Wiener (0.0148), con mayor μ implicando convergencia más rápida. Esto confirma **H2** para el caso separable.

4.3. E3: Datos no separables




Figura 6: Izquierda: accuracy por época en datos no separables. Derecha: evolución de $\|W\|$. Nótese la oscilación del Perceptrón (azul).

Algoritmo	Acc. separable	Ep. converg.	Acc. no separable
Perceptron	100.0 %	2	75.7 % ± 5.5
α -LMS	100.0 %	—	75.0 % ± 7.4
μ -LMS	100.0 %	—	79.6 % ± 1.5
Wiener (optimo)	100.0 %	—	81.0 %

Cuadro 2: Resultados comparativos de algoritmos lineales en datos separables y no separables.

En el dataset no separable (Figura 6), el **Perceptrón oscila** significativamente: $75.7\% \pm 5.5$ en las últimas 40 épocas, con $\|W\|$ fluctuante (el vector “gravita hacia cero” como advierte el paper). α -LMS es estable pero ruidoso ($75.0\% \pm 7.4$). μ -LMS ofrece el mejor desempeño: $79.6\% \pm 1.5$, a solo 1.4 puntos porcentuales del óptimo de Wiener (81.0%) y con la menor varianza. Esto confirma **H2** en el caso no separable. (La regla de Mays de la Eq. 5, con su zona muerta, atacaría este mismo régimen y —según el paper— superaría al Perceptrón por su tendencia a alejar el vector de pesos de cero.)

4.4. E4: Superficies de MSE




Figura 7: Superficies de MSE para un Adaline de 2 pesos sin bias (6 patrones aleatorios). Izquierda: error lineal (paraboloide convexo, Fig. 22 del paper). Centro: error sigmoide (no cuadrático pero suave, Fig. 23). Derecha: error signum (escalonado con mesetas y óptimos locales, Fig. 24).

La Figura 7 ilustra por qué el descenso de gradiente **exige funciones de activación diferenciables**: el error **lineal** (mín = 0.936) es un paraboloide convexo (mínimo global garantizado); el

sigmoide (mín = 0.940) es no cuadrático pero suave y navegable; el **signum** (mín = 1.333) es escalonado, con **mesetas** donde el gradiente es cero. Esto explica por qué algoritmos como MRII (que usan **signum**) requieren mecanismos de escape como el ruido esporádico.

4.5. E5: XOR — MRII vs MLP-Backpropagation




Figura 8: Izquierda: regiones de decisión de MRII 2-3-1 con ruido. Centro: MLP-*backpropagation* 2-2-1. Derecha: curva de aprendizaje MSE del MLP.

Configuracion	Tasa exito	Mediana epocas
MRII 2-2-1 sin ruido	0/20	—
MRII 2-2-1 + ruido	0/20	—
MRII 2-3-1 + ruido	0/20	—
MLP-BP 2-2-1	6/20	36
MLP-BP 2-3-1	11/20	23

Cuadro 3: Tasa de éxito en XOR sobre 20 inicializaciones distintas.

La Tabla 3 presenta el resultado más revelador del experimento. **MRII 2-2-1 sin ruido: 0/20**; **MRII con ruido esporádico** ($\sigma = 0.15$): **0/20** incluso con 3 Adalines ocultas. En nuestra implementación, el ruido gaussiano no bastó para escapar de los mínimos locales en XOR, posiblemente porque la corrección absoluta agresiva del refuerzo colineal domina sobre el escape estocástico. Es importante señalar que el propio artículo indica que MRII *puede* resolver problemas de este tipo, y que su remedio para óptimos locales es el reentrenamiento con distintas semillas iniciales (*random restarts*) además del ruido (Sección VII-E); nuestro resultado de 0/20 refleja la fragilidad de una única corrida por semilla, no una imposibilidad del algoritmo. En contraste, **MLP-*backpropagation* 2-2-1: 6/20** (mediana ≈ 40 épocas) y **MLP-*backpropagation* 2-3-1: 11/20**: una Adaline oculta adicional casi duplica la tasa de éxito. Estos resultados confirman **H3**: XOR es resoluble por arquitecturas multicapa, pero tanto MRII como *backpropagation* están sujetos a óptimos locales, y la superficie sigmoide (E4) es inherentemente más navegable que la del **signum**.

4.6. E6: MLP en datasets reales




Figura 9: MLP 4-8-3 en Iris. Izquierda: curva MSE. Centro: accuracy por época. Derecha: matriz de confusión (91.1 % test).

Iris (Figura 9, Tablas 4-5): Setosa es linealmente separable del resto (el Perceptrón converge en 2 épocas, 100 % test), pero Versicolor vs. Virginica **no** lo es (techo ≈ 83 % lineal). El MLP 4-8-3




Figura 10: Regiones de decisión del MLP 2–8–1 en two-moons (93.3 % test).




Figura 11: Convergencia de clasificadores lineales en Wine. Wiener y μ -LMS alcanzan 98.1 % test.




Figura 12: MLP 64–16–5 en MNIST dígitos 0–4 (98.5 % test).

μ	η	Acc. train	Acc. test	Ep. 95 %	T (s)
0.001	0.0	98.1 %	91.1 %	62	0.99
0.001	0.9	98.1 %	91.1 %	62	1.04
0.010	0.0	100 %	91.1 %	7	0.98
0.010	0.9	100 %	91.1 %	7	1.08
0.050	0.0	100 %	91.1 %	4	1.03
0.050	0.9	100 %	91.1 %	4	1.08

Cuadro 4: Resultados del MLP 4–8–3 en Iris para la grilla $\mu \times \eta$.

Atributo	$\ W_1\ _2$	Contribucion (%)
sepal length (cm)	1.50	6.4 %
sepal width (cm)	4.54	19.2 %
petal length (cm)	6.23	26.4 %
petal width (cm)	11.32	48.0 %

Cuadro 5: Relevancia de variables en Iris medida como $\|W_1\|_2$ por atributo.

alcanza consistentemente **91.1 % en test** para todas las configuraciones de μ y η , con convergencia más rápida para $\mu = 0.05$. El momentum ($\eta = 0.9$) no aporta beneficio en este problema pequeño y bien condicionado, consistente con el paper: “el momentum por sí solo suele ser de poco valor” [1]. El **criterio de selección del modelo final** favorece $\mu = 0.05$, $\eta = 0$ por su convergencia más rápida a igual accuracy. El análisis de relevancia (Tabla 5) revela que los pétalos concentran el **74.4 %** del peso total de la primera capa (*petal width*: 48.0 %, *petal length*: 26.4 %), consistente con el conocimiento botánico de que son los discriminantes más informativos [10].

Two-moons, Wine y MNIST: el MLP 2–8–1 alcanza **93.3 %** en two-moons trazando una frontera no lineal; los clasificadores lineales alcanzan **98.1 %** en Wine (la clase 0 es mayoritariamente separable en el espacio de 13 atributos); y el MLP 64–16–5 alcanza **98.5 %** en MNIST-04, demostrando que una arquitectura simple con *backpropagation* maneja datos de mediana dimensionalidad con alta precisión.

4.7. E7: MRIII $\equiv$ Backpropagation




Figura 13: Izquierda: error relativo $\|\nabla_{\text{MRIII}} - \nabla_{\text{BP}}\| / \|\nabla_{\text{BP}}\|$ vs. Δs (log-log, eje x invertido); mínimo 5.05×10^{-8} en $\Delta s = 10^{-8}$. Derecha: costo computacional por presentación (ms).

Ocultas (H)	Adalines	BP (ms)	MRIII (ms)	Razon
4	7	0.054	0.159	2.9×
16	19	0.044	0.352	8.1×
64	67	0.045	1.202	26.8×
256	259	0.056	5.329	95.2×

Cuadro 6: Costo computacional de *backpropagation* vs. MRIII para redes 4–H–3 (tiempos dependientes del hardware).

La Figura 13(a) confirma **H4** con precisión numérica: el gradiente estimado por perturbación (MRIII) converge al gradiente analítico de *backpropagation* con error relativo mínimo de 5.05×10^{-8} en $\Delta s = 10^{-8}$. El error decrece linealmente con Δs hasta que la precisión de punto flotante de 64 bits ($\approx 10^{-16}$) provoca un rebote para $\Delta s < 10^{-8}$.

La Figura 13(b) y la Tabla 6 cuantifican el costo de esa equivalencia. La razón MRIII/*backpropagation* **crece aproximadamente como $\mathcal{O}(N_{\text{Adalines}})$** : pasa de unas pocas veces para redes pequeñas ($H = 4$) a dos órdenes de magnitud para las grandes ($H = 256$). Los valores absolutos de la tabla son dependientes del hardware y de la implementación, pero la tendencia lineal en N_{Adalines} es robusta. Esto valida que *backpropagation* es la opción óptima para implementación digital, mientras que MRIII tiene sentido en hardware analógico, donde la perturbación física del sumidero es más simple que la retropropagación de señales de error.

Exp.	Problema	Algoritmo	Resultado clave
E1	Capacidad de Cover	Monte Carlo LP	$C_s \approx 2N_w$, $C_d = N_w$ verificado
E2	Datos separables	Perc., α/μ -LMS	Perc. converge 2 ep.; μ -LMS a 3.5° de Wiener
E3	Datos no separables	Perc., α/μ -LMS	μ -LMS mejor: 79.6 % vs Wiener 81.0 %
E4	Superficies MSE	Adaline 2D	MSE signum con mesetas y óptimos locales
E5	XOR	MRII, MLP-BP	MRII 0/20; MLP-BP 6/20 (2-2-1), 11/20 (2-3-1)
E6	Iris/moons/Wine/MNIST	MLP, LMS	91.1 / 93.3 / 98.1 / 98.5 % test
E7	MRIII vs BP	Gradiente + costo	Err min 5.05×10^{-8} ; costo $\mathcal{O}(N_{ada})$

Cuadro 7: Resumen consolidado de todos los experimentos.

4.8. Tabla resumen

5. Conclusiones

5.1. Aporte al conocimiento

El artículo de Widrow & Lehr (1990) realiza un aporte fundamental al **unificar 30 años de algoritmos de aprendizaje supervisado** para RNA feedforward bajo un principio común: la mínima perturbación. Los experimentos verifican empíricamente esta unificación en tres planos:

1. **El linaje Perceptrón → Adaline → Madaline → Backpropagation** no es una colección arbitraria, sino una progresión gobernada por el mismo principio geométrico: ΔW_k es siempre colineal con X_k , minimizando $\|\Delta W_k\|$ para la corrección deseada. La taxonomía de la Fig. 1 organiza toda esta familia.
2. **El trade-off capacidad–generalización** ($C_s \approx 2N_w$, $N_p \gg N_w/N_y$) establece límites que siguen vigentes en la era del *deep learning*: una red sobreparametrizada memoriza; una bien dimensionada generaliza.
3. **El valor pedagógico e histórico**: las ecuaciones de *backpropagation* (1986) ya estaban implícitas en Werbos (1974), y la equivalencia MRIII $\equiv$ *backpropagation* muestra que el descubrimiento científico ocurre por múltiples caminos independientes.

5.2. Evaluación de las hipótesis

- H1 – Capacidad de Cover: Confirmada.** El Monte Carlo (E1) reproduce la fórmula teórica con desviación media ≤ 0.034 .
- H2 – Convergencia del Perceptrón: Confirmada.** Converge en 2 épocas en datos separables (E2), pero oscila ± 5.5 pts en no separables (E3), mientras μ -LMS mantiene estabilidad (± 1.5 pts, a 1.4 pts de Wiener).
- H3 – Poder no lineal y óptimos locales: Confirmada con matices.** XOR es resoluble solo por arquitecturas multicapa, pero MRII (0/20 por semilla única) resultó más vulnerable a óptimos locales que MLP-*backpropagation* (6/20 y 11/20). El artículo prevé este comportamiento y recomienda *random restarts* y ruido como remedio.
- H4 – Equivalencia MRIII $\equiv$ Backpropagation: Confirmada.** El error relativo entre gradientes es 5.05×10^{-8} , y el costo de MRIII escala como $\mathcal{O}(N_{Adalines})$ (de pocas veces a dos órdenes de magnitud según el tamaño de la red y el hardware).

5.3. Limitaciones

Los datasets son de baja dimensionalidad (≤ 64 atributos); no se evaluó la escalabilidad a alta dimensión. La implementación de MRII no logró resolver XOR con una sola corrida por semilla; una estrategia de *random restarts* o recocido simulado —prevista por el paper— mejoraría el resultado. Del lado teórico, MRI, las reglas de Mays y el preprocesador polinomial se cubren conceptualmente pero sin experimento propio. No se implementaron variantes avanzadas de *backpropagation* (*quickprop*, *delta-bar-delta*, *backprop through time*) ni métodos modernos (SVM, *transformers*) como línea base.

5.4. Reflexión personal

Treinta y cinco años después, el artículo permanece vigente. El principio de mínima perturbación es, en esencia, el mismo que gobierna el *stochastic gradient descent* que entrena los modelos de *deep learning* actuales: μ -LMS generalizado a arquitecturas profundas. El momentum (Eqs. 96–97) sigue siendo estándar en optimizadores como Adam, y la perturbación de MRIII anticipa los métodos de optimización de orden cero (*zeroth-order optimization*) usados hoy cuando el gradiente no está disponible. La gran lección es que los fundamentos importan: comprender la geometría del aprendizaje —el hiperplano separador, el paraboloide de MSE, las mesetas del error signum— es esencial para diseñar, depurar y mejorar cualquier sistema de aprendizaje automático.

Referencias

- [1] B. Widrow and M. A. Lehr, “30 years of adaptive neural networks: Perceptron, Madaline, and backpropagation,” *Proceedings of the IEEE*, vol. 78, no. 9, pp. 1415–1442, 1990.
- [2] F. Rosenblatt, “The perceptron: A probabilistic model for information storage and organization in the brain,” *Psychological Review*, vol. 65, no. 6, pp. 386–408, 1958.
- [3] B. Widrow and M. E. Hoff, “Adaptive switching circuits,” in *IRE WESCON Convention Record*, vol. 4, 1960, pp. 96–104.
- [4] T. M. Cover, “Geometrical and statistical properties of systems of linear inequalities with applications in pattern recognition,” *IEEE Transactions on Electronic Computers*, vol. EC-14, no. 3, pp. 326–334, 1965.
- [5] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, “Learning representations by back-propagating errors,” *Nature*, vol. 323, pp. 533–536, 1986.
- [6] P. J. Werbos, “Beyond regression: New tools for prediction and analysis in the behavioral sciences,” Ph.D. dissertation, Harvard University, Cambridge, MA, 1974.
- [7] C. H. Mays, “Adaptive threshold logic,” Ph.D. dissertation, Tech. Rep. 1557-1, Stanford Electron. Labs., Stanford, CA, 1963.
- [8] B. Widrow, “Generalization and information storage in networks of adaline ‘neurons’,” in *Self-Organizing Systems 1962*, Washington, DC: Spartan Books, 1962, pp. 435–461.
- [9] D. F. Specht, “Generation of polynomial discriminant functions for pattern recognition,” *IEEE Transactions on Electronic Computers*, vol. EC-16, pp. 308–319, 1967.
- [10] R. A. Fisher, “The use of multiple measurements in taxonomic problems,” *Annals of Eugenics*, vol. 7, no. 2, pp. 179–188, 1936.
- [11] B. Widrow, R. G. Winter, and R. A. Baxter, “Layered neural nets for pattern recognition,” *IEEE Transactions on Acoustics, Speech, and Signal Processing*, vol. 36, no. 7, pp. 1109–1118, 1988.
- [12] D. H. Nguyen and B. Widrow, “Neural networks for self-learning control systems,” *IEEE Control Systems Magazine*, vol. 10, no. 3, pp. 18–23, 1990.

- [13] D. Andes, B. Widrow, M. Lehr, and E. Wan, “MRIII: A robust algorithm for training analog neural networks,” *Proc. Int. Joint Conf. on Neural Networks*, vol. 1, pp. 533–536, 1990.
- [14] C. M. Bishop, *Pattern Recognition and Machine Learning*. New York: Springer, 2006.