

30 Years of Adaptive Neural Networks: Perceptron, Madaline, and Backpropagation

Widrow et al.

Carissa Bush, Vidya Srinivas, Po-Chun Huang, Ming Hung Chen

- Los conceptos de aprendizaje de máquina (*machine learning*) existen hace décadas.
- Muchas ideas fueron descubiertas, y redescubiertas independientemente.
- Muchas ideas fueron inspiradas biológicamente.
- Todo comenzó con conceptos simples.

El Combinador Lineal Adaptativo

- Produce una suma ponderada de las entradas.
- Cada entrada tiene un peso asociado.
- Los pesos pueden ser discretos o continuos.
- Los pesos pueden ser adaptados.

$$y = \sum_i w_i x_i = W^T X$$


Clasificación Binaria

- La tarea objetivo es clasificar patrones de entrada en dos grupos: positivo y negativo.

Separabilidad Lineal

- Un conjunto de patrones de entrada es **linealmente separable** si existe una línea (o hiperplano) que puede separar puntos con etiquetas positivas de puntos con etiquetas negativas.

Un Clasificador Lineal Adaptativo: Adaline



- Realiza tareas de clasificación binaria.
- Es capaz de realizar fronteras de separación lineales.
- Estas fronteras clasifican perfectamente conjuntos de datos linealmente separables.

Realizando Fronteras de Separación No Lineales

- Cuando los datos no son linealmente separables en el espacio original, se necesitan técnicas no lineales.
- Dos enfoques principales:
 - ① Mapas de características (*feature maps*): proyectar a un espacio de mayor dimensión.
 - ② Combinaciones no lineales de fronteras lineales (Madaline, redes feedforward).

Clasificadores No Lineales: Mapas de Características

- Si los patrones de entrada no son separables en el espacio original, se mapean a un espacio de mayor dimensión donde sí son linealmente separables.

Vector de entrada $\rightarrow$ Mapa de Características $\rightarrow$ Adaline $\rightarrow \pm 1$

- Sea ϕ nuestro mapa de características.
- Ejemplo: $\phi : \mathbb{R} \rightarrow \mathbb{R}^2$, donde $\phi(x) = (x, x^2)$.

Ejemplo de Mapa de Características

Espacio original (1D): puntos 1, 2, 3 no separables linealmente.


Espacio mapeado (2D):

- $1 \rightarrow (1, 1)$
- $2 \rightarrow (2, 4)$
- $3 \rightarrow (3, 9)$

Frontera lineal en el espacio mapeado: $x_1^2 - 4x_1 + 3.5 = 0$.

Clasificadores No Lineales: Madaline I

- Si los patrones no son separables en el espacio original, se usa una combinación no lineal de fronteras de separación lineales.



Clasificadores No Lineales: Redes Feedforward

- Combina múltiples Adalines en capas y alimenta las salidas de una capa a las entradas de la siguiente.
- Diferentes capas pueden tener diferentes funciones de activación.

Clasificadores No Lineales: Adaptación

- Se puede calcular la señal de error en el vector de salida.
- La adaptación de la capa de salida es posible.
- ¿Qué hacemos con la adaptación de las capas ocultas?
- → Retro-propagación del error (*backpropagation*).

Reglas de Corrección de Error (EC)

- Alteran los pesos de una red para corregir el error en la respuesta de salida al patrón de entrada presente.

Reglas de Descenso más Empinado (SD)

- Alteran los pesos de una red mediante descenso de gradiente.
- Reducen el error promediado sobre todos los patrones de entrada.

Reglas de Corrección de Error: Elemento Umbral Único

- Cada nuevo patrón de entrada inicia un nuevo ciclo de adaptación.
- El objetivo es actualizar los pesos para reducir el error.
- Las reglas lineales hacen correcciones directamente proporcionales al error.
- Las reglas no lineales hacen correcciones que no son directamente proporcionales al error.

Patrón de entrada $\rightarrow$ Adaline $\rightarrow$ Regla EC $\rightarrow$ Error $\rightarrow$ Pesos actualizados

EC Elemento Umbral Único: α -LMS

- La actualización de pesos es independiente de la magnitud del patrón de entrada (auto-normalizante).
- La elección de α controla la estabilidad y velocidad de convergencia.

$$\mathbf{W}_{k+1} = \mathbf{W}_k + \alpha \frac{\varepsilon_k \mathbf{X}_k}{\|\mathbf{X}_k\|^2}$$

$$\varepsilon_k = d_k - \mathbf{W}_k^T \mathbf{X}_k$$

$$\Delta \varepsilon_k = -\alpha \varepsilon_k$$

- Rango típico: $0.1 < \alpha < 1$.
- Pesos inicializados usualmente en 0.

EC Elemento Umbral Único: Regla del Perceptrón

- Suma o resta patrones de entrada a los pesos para corregir el error.
- Garantiza convergencia para cualquier conjunto de patrones linealmente separable.
- Sin garantías de convergencia para patrones no linealmente separables.

$$W_{k+1} = W_k + \alpha \frac{\tilde{\varepsilon}_k}{2} X_k$$

donde $\tilde{\varepsilon}_k = d_k - y_k$ es el error del cuantizador (error binario).

- Todas las respuestas deseadas son $+1$ o -1 .
- Define una “zona muerta” (*dead zone*) o margen alrededor de 0, denotada por $\pm\gamma$.

Regla de Adaptación por Incremento


- Patrón fuera del margen: se adapta por la regla del Perceptrón.
- Patrón dentro del margen: se adapta por una variante normalizada del Perceptrón de incremento fijo.

Regla de Adaptación por Relajación Modificada

- Patrón fuera del margen y correctamente clasificado: no se modifica.
- Patrón dentro del margen o mal clasificado: variante normalizada del Perceptrón.
- Si $\gamma \rightarrow \infty$, se convierte en α -LMS.

Madaline Rule I (MRI)

- Permite la adaptación de un elemento de la primera capa porque el elemento lógico es fijo.
- La segunda capa consiste en un único elemento lógico de umbral fijo (OR, AND, voto mayoritario, etc.).



Madaline Rule I: Adaptación

- Los pesos de los Adalines se inicializan con valores aleatorios pequeños.
- El vector de pesos puede adaptarse mediante cualquiera de las reglas de corrección de error para un solo elemento:
 - Invertir la salida del Adaline.
 - α -LMS.
 - Perceptrón.
- **Idea principal:** asignar responsabilidad al Adaline o Adalines que pueden asumirla más fácilmente.

Madaline Rule I: Características

- Un asignador de trabajo (*job assigner*) asigna la responsabilidad.
- El reparto de carga (*load sharing*) es importante.
- La secuencia de presentación de patrones debe ser aleatoria.
- El proceso de adaptación puede atascarse en óptimos locales.
- Obedece el principio de mínima perturbación.

Madaline Rule II (MRII)

- Extendido desde MRI.
- Usado para redes binarias multicapa.
- Los pesos se inicializan con valores aleatorios pequeños.
- Los patrones de entrenamiento se presentan en secuencia aleatoria.
- Puede atascarse en óptimos locales.

Madaline Rule II: Adaptación

- El objetivo es reducir el error de Hamming.
- Si la red produce un error, adaptar la primera capa:
 - ① **Adaptación de prueba:** invertir la salida binaria.
 - ② Agregar una perturbación Δs sin adaptación.
 - ③ Si el error de salida se reduce, remover Δs y adaptar los Adalines seleccionados mediante α -LMS.
 - ④ Si el error no se reduce, no hay adaptación de pesos.
- Agotar todos los Adalines en la primera capa.
- Repetir para todas las capas.

Reglas de Descenso más Empinado: Motivación

- Las reglas de corrección de error corrigen una proporción del error para el patrón actual.
- Las reglas de descenso más empinado buscan minimizar el error cuadrático medio (MSE) sobre todos los patrones.

$$W_{k+1} = W_k + \mu(-\nabla_k)$$

donde μ controla la estabilidad y velocidad de convergencia, y ∇_k es el gradiente en $W = W_k$.

Reglas de Descenso más Empinado: μ -LMS

- Se usa un gradiente crudo en lugar del gradiente real.
- El gradiente instantáneo se determina a partir de un solo patrón de entrada.
- μ es la constante de aprendizaje que determina estabilidad y tasa de convergencia.

$$\hat{\nabla}_k = \frac{\partial \varepsilon_k^2}{\partial \mathbf{W}_k} = -2\varepsilon_k \mathbf{X}_k$$
$$\mathbf{W}_{k+1} = \mathbf{W}_k + 2\mu\varepsilon_k \mathbf{X}_k$$

Comparación: α -LMS vs μ -LMS

α -LMS	μ -LMS
Gradiente instantáneo LMS	Gradiente instantáneo LMS
Auto-normalizante	No auto-normalizante
Más difícil de analizar	Más fácil de analizar
Convergencia más rápida	Convergencia más lenta
Puede converger a punto sesgado	Converge en media al mínimo (Wiener)

Descenso más Empinado: Adaline con Sigmoides

- Se extiende el Adaline para usar una función sigmoide en lugar de la función signum.
- $y_k = \text{sgm}(s_k)$ donde $s_k = W_k^T X_k$.

$$\tilde{\varepsilon}_k = d_k - y_k$$

$$\hat{\nabla}_k = -2\tilde{\varepsilon}_k \text{sgm}'(s_k) X_k$$

$$W_{k+1} = W_k + 2\mu\tilde{\varepsilon}_k \text{sgm}'(s_k) X_k$$

Retro-propagación (Backpropagation)

Proceso:

- 1 Entrada $\rightarrow$ Salida (propagación hacia adelante).
- 2 Encontrar los errores en la salida.
- 3 Propagar los efectos de los errores hacia atrás a través de la red para asociar una “derivada del error cuadrático” (δ) con cada Adaline.
- 4 Usar δ para determinar el gradiente.
- 5 Actualizar los pesos basados en el gradiente.
- 6 Repetir para todas las capas.

Ejemplo de Backpropagation

- Para una red feedforward de 3 capas:

$$a^{(1)} = X$$

$$a^{(2)} = \text{sgm}((W^{(1)})^T a^{(1)})$$

$$a^{(3)} = \text{sgm}((W^{(2)})^T a^{(2)})$$

$$a^{(4)} = \text{sgm}((W^{(3)})^T a^{(3)})$$

$$\delta_j^{(4)} = a_j^{(4)} - y_j \quad (\text{error de salida})$$

$$\delta^{(3)} = W^{(3)} \delta^{(4)} .* \text{sgm}'(W^{(2)} a^{(2)})$$

$$\delta^{(2)} = W^{(2)} \delta^{(3)} .* \text{sgm}'(W^{(1)} a^{(1)})$$

Redes Multi-Elemento: Madaline Rule III

- Motivación: el algoritmo de backpropagation requiere implementación precisa de la función sigmoide en hardware.
- MRIII usa una perturbación Δs en lugar de la derivada de la sigmoide.

$$\hat{\nabla}_k = \frac{\partial \tilde{\varepsilon}_k^2}{\partial W_k} \approx \frac{\Delta \tilde{\varepsilon}_k^2}{\Delta s} X_k \approx 2\tilde{\varepsilon}_k \frac{\Delta \tilde{\varepsilon}_k}{\Delta s} X_k$$

- MRIII es matemáticamente equivalente a backpropagation si Δs es pequeño.
- MRIII es robusto incluso con implementación analógica.

MRIII vs Backpropagation

- MRIII es esencialmente equivalente a Backpropagation:
 - Mismos argumentos para cada uno de los elementos Adaline.
 - El Δs (perturbación) es pequeño.
 - La adaptación se aplica a todos los elementos de la red a la vez.

MR II

Discontinuo y no lineal
No es posible usar gradientes instantáneos
Problemas con mínimos locales

MR III

Todos los Adalines se adaptan
Los que tienen sumas analógicas más cercanas a cero se adaptan más fuerte

¿Qué se sigue usando hoy?

- Diferentes métodos son mejores en diferentes aplicaciones.

Se usa menos:

- Clasificación lineal.
- Elementos únicos.
- Una sola capa.

Se usa más:

- Multi-capas.
- Multi-elemento.
- Retro-propagación (*backpropagation*).

¿Preguntas?

¿Preguntas?

Espacio original (1D): puntos 1, 2, 3.

Mapa de características: $\phi(x) = (x, x^2)$

- $1 \rightarrow (1, 1)$
- $2 \rightarrow (2, 4)$
- $3 \rightarrow (3, 9)$

Frontera lineal en espacio mapeado: $x_1^2 - 4x_1 + 3.5 = 0$

- Sea $P^T \triangleq \mathbb{E}[d_k X_k^T]$, $R \triangleq \mathbb{E}[X_k X_k^T]$.
- El gradiente del MSE: $\nabla_k = -2P + 2RW_k$.
- Igualando a cero: $W^* = R^{-1}P$ (vector de pesos de Wiener).
- μ -LMS evita calcular R^{-1} y P usando el gradiente instantáneo.
- Para $0 < \mu < 1/\lambda_{\text{máx}}$, el algoritmo converge en media a W^* .