

Artificial Neural Networks of The Perceptron, Madaline, and Backpropagation Family

Bernard Widrow & Micheal A. Lehr

Presentado por Xuanchong Li

Stanford

Contenido (Outline)

Historia de los Algoritmos (1960s–1990s)

- **1960:** Algoritmo Least Mean Square (LMS) — Widrow y su estudiante; Regla del Perceptrón — Rosenblatt.
- **Mid 1960s:** Madaline (Multiple Adaptive Linear Elements) Rule I (MRI). Aplicaciones en voz, predicción del clima, reconocimiento de patrones (Widrow y su estudiante).
- **1971:** Backpropagation — Werbos. Inicialmente ignorado, redescubierto en 1982 por Parker; se hizo famoso con el trabajo de Rumelhart, Hinton y Williams.
- **1987:** Madaline Rule II (MRII) — Widrow y su estudiante. Para adaptar redes de múltiples capas.
- **1988:** Madaline Rule III (MRIII) — David Andes. Widrow y su estudiante descubrieron que es matemáticamente equivalente a backpropagation.

Contenido

Combinador Lineal Adaptativo

- Produce una suma ponderada de las entradas:

$$y = \sum_{i=0}^n w_i x_i = W^T X$$

- Los pesos pueden ser adaptados mediante aprendizaje.
- Es el bloque constructivo fundamental de las redes neuronales adaptativas.

- **Adaline** (Adaptive Linear Element): bloque constructivo básico usado en redes neuronales.
- Elemento lógico de umbral adaptativo: combinador lineal adaptativo + cuantizador duro (*hard-limiting quantizer*).

$$y = \text{sgn}(W^T X)$$

- Separa el espacio de entrada mediante un hiperplano.

Preprocesador Polinomial

- Red de preprocesamiento fija + un único elemento adaptativo.
- La elección de la función de preprocesamiento es crítica.
- Vector de características inicial: $[x_1, x_2]$.
- Después del preprocesador: $[x_1^2, x_1, x_1x_2, x_2, x_2^2]$.
- Puede proporcionar una variedad de funciones no lineales con un solo elemento Adaline.

- Una de las primeras redes neuronales en capas entrenables.
- Una capa de ADALINEs + dispositivo lógico fijo (AND, OR, MAJ).

$$\underset{\text{Primera capa}}{\mathbf{X}} \rightarrow [\text{Adaline}_1, \dots, \text{Adaline}_n] \rightarrow \underset{\text{Segunda capa}}{\text{Lógica Fija}} \rightarrow \pm 1$$

Red Feedforward

- Todas las capas son adaptativas.
- Ejemplo: red feedforward adaptativa de tres capas totalmente conectada.
- Capa de entrada $\rightarrow$ Capas ocultas $\rightarrow$ Capa de salida.
- La información fluye en una sola dirección (sin ciclos).

El Principio de Mínima Perturbación

Principio de Mínima Perturbación

Adaptar para reducir el error de salida para el patrón de entrenamiento actual, con mínima perturbación a las respuestas ya aprendidas.

- Está detrás de cada algoritmo de aprendizaje en el paper.
- Condujo al descubrimiento del algoritmo LMS y las reglas Madaline.

Dos Clases de Reglas

Reglas de Corrección de Error (EC)

Alteran los pesos de una red para corregir una cierta proporción del error en la respuesta de salida al patrón de entrada presente.

Reglas de Descenso más Empinado (SD)

Alteran los pesos durante cada presentación de patrón por descenso de gradiente con el objetivo de reducir el error cuadrático medio, promediado sobre todos los patrones de entrenamiento.

Regla Lineal

Altera los pesos del elemento de umbral adaptativo con cada presentación de patrón para hacer una corrección de error proporcional al error mismo.

$$W_{k+1} = W_k + \alpha \frac{\varepsilon_k X_k}{\|X_k\|^2}$$

$$\varepsilon_k = d_k - W_k^T X_k$$

$$\Delta \varepsilon_k = -\alpha \varepsilon_k$$

- Pesos inicializados usualmente en 0.
- Tasa de aprendizaje: $0.1 < \alpha < 1$, controla estabilidad y velocidad de convergencia.
- **Auto-normalizante:** la elección de α no depende de la magnitud de las señales de entrada.

Reglas No Lineales: Perceptrón

- Algoritmo no lineal: el cambio de pesos es colineal con el vector del patrón de entrada y el error lineal.
- Sigue la regla de Corrección de Error.

$$W_{k+1} = W_k + \alpha \frac{\tilde{\varepsilon}_k}{2} X_k$$

donde $\tilde{\varepsilon}_k = d_k - y_k$ (error del cuantizador, ± 2 o 0).

α -LMS

α controla estabilidad y convergencia

Respuestas binarias y continuas

Puede **fallar** en separar conjuntos linealmente separables

No conduce a soluciones no razonables con datos no separables

Perceptrón

α no afecta estabilidad, solo tiempo de convergencia si $W_0 \neq 0$

Solo respuestas binarias

Separa **cualquier** conjunto linealmente separable

No converge y no produce buena solución con datos no separables

- Regla de corrección de error no lineal.
- Introduce la “zona muerta” γ (*deadzone*).
- Separa cualquier conjunto linealmente separable.
- Para conjuntos no linealmente separables, el algoritmo de May funciona mucho mejor que el Perceptrón porque una zona muerta suficientemente grande tiende a hacer que el vector de pesos se adapte lejos de cero cuando existe una solución razonablemente buena.

Dos variantes

- Regla de Adaptación por Incremento.
- Regla de Adaptación por Relajación Modificada.

Madaline Rule I (MRI)

- Si ocurre un error, se elige el ADALINE con menor $|s_k|$ para adaptar.
- Los pesos se inicializan con valores aleatorios pequeños.
- Actualización del vector de pesos: puede cambiarse agresivamente usando corrección absoluta o adaptarse por el pequeño incremento determinado por α -LMS.

Principio

Asignar responsabilidad al Adaline o Adalines que pueden asumirla más fácilmente.

- La secuencia de presentación de patrones debe ser aleatoria.

MRI — Ejemplo (1/4)

Adaline	$s = W^T X$	$\text{sgn}(s)$	
W_1	0.2	+1	$\rightarrow \text{MAJ} \rightarrow -1$
W_2	0.8	+1	
W_3	-0.1	-1	
W_4	-0.3	-1	
W_5	-0.4	-1	

- Salida deseada $d = -1$. ¡Correcto!

Mismo X , diferente d :

Adaline	$s = W^T X$	$\text{sgn}(s)$	
W_1	0.2	+1	$\rightarrow \text{MAJ} \rightarrow -1$
W_2	0.8	+1	
W_3	-0.1	-1	
W_4	-0.3	-1	
W_5	-0.4	-1	

- Salida deseada $d = +1$. ¡Error! Mayoría da -1 .
- Se elige el Adaline con menor $|s_k|$: W_3 ($|s| = 0.1$).

Se adapta W_3 para invertir su salida:

Adaline	$s = W^T X$	$\text{sgn}(s)$	
W_1	0.2	+1	$\rightarrow \text{MAJ} \rightarrow +1$
W_2	0.8	+1	
W'_3	0.4	+1	
W_4	-0.3	-1	
W_5	-0.4	-1	

- Salida deseada $d = +1$. ¡Correcto ahora!

Segundo intento — perturbando W_2 :

Adaline	$s = W^T X$	$\text{sgn}(s)$	
W_1	0.2	+1	$\rightarrow \text{MAJ} \rightarrow -1$
W'_2	-0.05	-1	
W_3	-0.1	-1	
W_4	-0.3	-1	
W_5	-0.4	-1	

- Salida deseada $d = +1$. ¡Sigue mal! Se necesitan múltiples adaptaciones.

Adaptando W'_2 y W'_3 juntos:

Adaline	$s = W^T X$	$\text{sgn}(s)$	
W_1	0.2	+1	$\rightarrow \text{MAJ} \rightarrow +1$
W'_2	0.1	+1	
W'_3	0.4	+1	
W_4	-0.3	-1	
W_5	-0.4	-1	

Madaline Rule II (MRII)

- Los pesos en ambas capas son adaptativos.
- Los pesos se inicializan con valores aleatorios pequeños.
- Secuencia de presentación de patrones aleatoria.

Adaptación de los Adalines de la primera capa

- 1 Seleccionar la menor magnitud de salida lineal $|s_k|$.
- 2 Realizar una “adaptación de prueba” agregando una perturbación Δs de amplitud adecuada para invertir su salida binaria.
- 3 Si el error de salida se reduce, remover Δs y cambiar el peso del Adaline seleccionado usando α -LMS.
- 4 Perturbar y actualizar otros Adalines con salida s_k suficientemente pequeña.
- 5 Después de agotar posibilidades en la primera capa, pasar a la siguiente y proceder de manera similar.
- 6 Seleccionar aleatoriamente un nuevo patrón y repetir.

Descenso más Empinado: Elemento Umbral Único

- **Objetivo:** reducir el error promediado sobre el conjunto de entrenamiento (no solo una proporción del error en cada presentación).
- El error más común: error cuadrático medio (MSE).

$$W_{k+1} = W_k + \mu(-\nabla_k)$$

- μ : controla estabilidad y velocidad de convergencia.
- En la práctica, trabaja con un dato a la vez, minimizando el MSE de forma aproximada.

Reglas Lineales: Derivación del μ -LMS

- La regla de descenso más empinado es lineal si los cambios de peso son proporcionales al error lineal.

$$\begin{aligned}\varepsilon_k^2 &= (d_k - \mathbf{X}_k^T \mathbf{W}_k)^2 \\ \mathbb{E}[\varepsilon_k^2] &= \mathbb{E}[d_k^2] - 2\mathbb{E}[d_k \mathbf{X}_k^T] \mathbf{W}_k + \mathbf{W}_k^T \mathbb{E}[\mathbf{X}_k \mathbf{X}_k^T] \mathbf{W}_k\end{aligned}$$

- Definiendo $\mathbf{P}^T \triangleq \mathbb{E}[d_k \mathbf{X}_k^T]$, $\mathbf{R} \triangleq \mathbb{E}[\mathbf{X}_k \mathbf{X}_k^T]$:

$$\nabla_k = \frac{\partial \mathbb{E}[\varepsilon_k^2]}{\partial \mathbf{W}_k} = -2\mathbf{P} + 2\mathbf{R}\mathbf{W}_k$$

- Solución óptima (Wiener): $\mathbf{W}^* = \mathbf{R}^{-1}\mathbf{P}$.
- Pero calcular $\mathbf{R}^{-1}$ y $\mathbf{P}$ es costoso...

Algoritmo μ -LMS

- Obtiene una estimación precisa de W^* sin calcular R^{-1} y P .
- Usa el gradiente instantáneo:

$$\hat{\nabla}_k = \frac{\partial \varepsilon_k^2}{\partial W_k} = -2\varepsilon_k X_k$$

- Es un estimador insesgado del gradiente verdadero.

$$W_{k+1} = W_k + \mu(-\hat{\nabla}_k) = W_k + 2\mu\varepsilon_k X_k$$

- μ controla estabilidad y velocidad de convergencia.
- Los datos de entrenamiento deben presentarse en orden aleatorio.

$$\alpha\text{-LMS: } W_{k+1} = W_k + \alpha \frac{\varepsilon_k X_k}{\|X_k\|^2}$$

$$\mu\text{-LMS: } W_{k+1} = W_k + 2\mu\varepsilon_k X_k$$

- α -LMS es auto-normalizante; μ -LMS es un algoritmo lineal de coeficiente constante.
- En la práctica, α -LMS usualmente converge más rápido que μ -LMS.
- μ -LMS converge a la solución de mínimo MSE (solución de Wiener); α -LMS converge a una solución sesgada.
- Con conjunto de entrenamiento normalizado ($\tilde{X}_k = X_k/\|X_k\|$, $\tilde{d}_k = d_k/\|X_k\|$), α -LMS logra la solución de mínimo MSE.

Adaline con Sigmoides

- Extensión del Adaline para usar una función sigmoide en lugar de la signum.
- $y_k = \text{sgm}(s_k)$ donde $s_k = W_k^T X_k$.

$\mathbf{X} \rightarrow \text{Combinador Lineal} \rightarrow s_k \rightarrow \text{Sigmoide} \rightarrow y_k$

Backpropagation para Adaline con Sigmoides

- Sea $\tilde{\varepsilon}_k = d_k - y_k$ (error con sigmoide).
- Gradiente instantáneo:

$$\hat{\nabla}_k = -2\tilde{\varepsilon}_k \text{sgm}'(s_k)X_k$$

- Actualización de pesos:

$$W_{k+1} = W_k + \mu(-\hat{\nabla}_k) = W_k + 2\mu\tilde{\varepsilon}_k \text{sgm}'(s_k)X_k$$

MRIII para Adaline con Sigmoide

Motivación

El algoritmo de backpropagation requiere implementación precisa de la función sigmoide en hardware. MRIII no depende de una implementación exacta de la derivada.

- Se agrega una pequeña perturbación Δs a s_k y se registra el efecto en y_k y ε_k .

$$\hat{\nabla}_k = \frac{\partial \tilde{\varepsilon}_k^2}{\partial W_k} = \frac{\partial \tilde{\varepsilon}_k^2}{\partial s_k} \cdot \frac{\partial s_k}{\partial W_k} \approx \frac{\Delta \tilde{\varepsilon}_k^2}{\Delta s} X_k \approx 2\tilde{\varepsilon}_k \frac{\Delta \tilde{\varepsilon}_k}{\Delta s} X_k$$

Conclusión

Backpropagation y MRIII son matemáticamente equivalentes si Δs es pequeño. MRIII es robusto incluso con implementación analógica.

Intuición

Propagar el error hacia atrás desde la capa de salida hasta la primera capa.

Para un vector de patrón de entrada X :

- 1 Barrer hacia adelante para obtener el vector de respuesta de salida Y .
- 2 Calcular los errores en cada salida.
- 3 Barrer los efectos de los errores hacia atrás a través de la red para asociar una “derivada del error cuadrático” δ con cada Adaline.
- 4 Calcular un gradiente a partir de cada δ .
- 5 Actualizar los pesos de cada Adaline basado en el gradiente correspondiente.

- Misma idea que MRIII para Adaline con sigmoide.
- Se mide el error cuadrático total de salida:

$$\varepsilon^2 = (d_1 - y_1)^2 + (d_2 - y_2)^2 = \varepsilon_1^2 + \varepsilon_2^2$$

- Aproximación del gradiente mediante perturbación:

$$\frac{\Delta(\varepsilon^2)}{\Delta s} = \frac{\Delta(\varepsilon_1^2 + \varepsilon_2^2)}{\Delta s} \approx \frac{\partial \varepsilon^2}{\partial s}$$

$$W_{k+1} = W_k - \mu \frac{\Delta \varepsilon_k^2}{\Delta s} X_k$$

Principio

Una red neuronal debe ser invariante a traslación, rotación y cambio de escala del patrón de entrada.

- Invarianza a traslación arriba-abajo, izquierda-derecha.
- Los roles de los distintos Adalines se intercambian.
- Los pesos “clave” (W_1) pueden elegirse aleatoriamente o fabricarse.
- La invarianza a rotación y escala se puede obtener de la misma manera.

- **1960–1990:** Tres décadas de evolución de redes neuronales adaptativas.
- **Conceptos clave:** Combinador lineal adaptativo, Adaline, Madaline, redes feedforward.
- **Reglas de aprendizaje:**
 - Corrección de error: α -LMS, Perceptrón, May, MRI, MRII.
 - Descenso más empinado: μ -LMS, Backpropagation, MRIII.
- **Principio unificador:** Mínima perturbación.
- **Equivalencia:** MRIII $\equiv$ Backpropagation (cuando Δs es pequeño).
- **Invarianza:** Traslación, rotación y escala mediante arquitectura adecuada.