

Artificial Neural Networks for The Perceptron, Madaline, and Backpropagation Family

Bernard Widrow & Michael A. Lehr

Presentado por Zhiyong Cheng

2014-09-08

Contenido (Outline)

- Historia del desarrollo de algoritmos.
- Conceptos fundamentales.
- Algoritmos:
 - Reglas de corrección de error:
 - Elemento único: lineal y no lineal.
 - Redes en capas: no lineal.
 - Descenso de gradiente:
 - Elemento único: lineal y no lineal.
 - Redes en capas: no lineal.

- **1960:** Dos de las reglas más tempranas e importantes para entrenar elementos adaptativos:
 - Algoritmo LMS (Widrow y su estudiante).
 - Regla del Perceptrón (Rosenblatt).
- Facilitaron el rápido desarrollo de redes neuronales en los primeros años:
 - Madaline Rule I (MRI): primera regla de aprendizaje popular para redes neuronales con múltiples elementos adaptativos.
 - Aplicaciones: reconocimiento de voz y patrones, predicción del clima, etc.
- **Avance decisivo:** algoritmo de entrenamiento por retro-propagación (*backpropagation*):
 - Desarrollado por Werbos en 1971, publicado en 1974.
 - Redescubierto por Parker en 1982, reportado en 1984.
 - Rumelhart, Hinton y Williams también lo redescubrieron y lo hicieron ampliamente conocido.

- **MRI**: cuantizadores duros (*hard-limiting*, $y = \text{sgn}(x)$); fácil de calcular.
- **Backpropagation**: función sigmoide.
- **MRI** → **MRII** (Widrow y Winter, 1987).
- **MRII** → **MRIII** (David Andes, U.S. Naval Weapons Center, China Lake, CA, 1988):
 - Reemplaza cuantizadores duros por función sigmoide.
 - Widrow y su estudiante descubren primero que MRIII es equivalente a backpropagation.

Combinador Lineal Adaptativo

- Entradas: x_1, x_2, x_3 (más x_0 , sesgo).
- Salida: $y = \mathbf{X}_k^T \mathbf{W}_k$.
- Capa de entrada $\rightarrow$ Capa de salida.

$$\begin{matrix} x_0 \\ x_1 \\ x_2 \\ x_3 \end{matrix} \rightarrow \sum \rightarrow y$$

Elemento Lineal Adaptativo (Adaline) — Clasificador Lineal

- Combinador lineal + cuantizador signum.
- $y = \text{sgn}(X_k^T W_k)$.
- Separa el espacio mediante un hiperplano.

$$\begin{matrix} x_0 \\ x_1 \\ x_2 \\ x_3 \end{matrix} \rightarrow \sum \rightarrow \text{sgn}(\cdot) \rightarrow y$$

Figuras tomadas del curso online de Andrew Ng

- Funciones discriminantes polinomiales.
- Red neuronal feedforward multi-elemento.

Figuras tomadas del curso online de Andrew Ng

Función Discriminante Polinomial

- Vector de características inicial: $[x_1, x_2]$.
- Después del preprocesador: $[x_1^2, x_1, x_1x_2, x_2, x_2^2]$.
- Nuevo vector de características: $[x'_1, x'_2, x'_3, x'_4, x'_5]$.

Ventajas

- Puede proporcionar una variedad de funciones no lineales con un solo elemento Adaline.
- Converge más rápido que las redes neuronales en capas.
- Solución global única.

Desventaja

Las redes neuronales en capas pueden obtener mejor generalización.

Redes Neuronales en Capas: Madaline I

- Múltiples elementos Adaline en la primera capa.
- Dispositivos lógicos fijos en la segunda capa (OR, AND, voto mayoritario, etc.).

$$X \rightarrow [\text{Adaline}_1, \dots, \text{Adaline}_n] \rightarrow \text{Lógica Fija} \rightarrow \pm 1$$

Primera capa *Segunda capa*

- Todas las capas son adaptativas.
- Múltiples capas ocultas entre entrada y salida.

Capa 1 (entrada) → Capa 2 (oculta) → Capa 3 (oculta) → Capa 4 (salida)

Principio de Mínima Perturbación

Adaptar para reducir el error de salida para el patrón de entrenamiento actual, con mínima perturbación a las respuestas ya aprendidas.

- Condujo al descubrimiento del algoritmo LMS y las reglas Madaline.
- **Adaline único:** α -LMS, μ -LMS, reglas de May, regla del Perceptrón.
- **Madaline simple:** MRI.
- **Madaline multi-capa:** MRII, MRIII y algoritmo de backpropagation.

Reglas de Corrección de Error

Alteran los pesos para corregir una cierta proporción del error en la respuesta de salida al patrón de entrada presente.

- α -LMS: $W_{k+1} = W_k + \alpha \frac{\varepsilon_k X_k}{\|X_k\|^2}$
- Corrección de error: $\Delta \varepsilon_k = -\alpha \varepsilon_k$

Reglas de Gradiente (Descenso más Empinado)

Alteran los pesos durante cada presentación de patrón por descenso de gradiente con el objetivo de reducir el error cuadrático medio, promediado sobre todos los patrones.

- μ -LMS: $W_{k+1} = W_k + 2\mu \varepsilon_k X_k$

- Actualización de pesos: $W_{k+1} = W_k + \alpha \frac{\varepsilon_k X_k}{\|X_k\|^2}$
- Error: $\varepsilon_k = d_k - W_k^T X_k$
- Cambio de error por el cambio de peso:

$$\Delta \varepsilon_k = \Delta(d_k - W_k^T X_k) = -X_k^T \Delta W_k$$

$$\Delta W_k = W_{k+1} - W_k = \alpha \frac{\varepsilon_k X_k}{\|X_k\|^2}$$

$$\Delta \varepsilon_k = -\alpha \frac{\varepsilon_k X_k^T X_k}{\|X_k\|^2} = -\alpha \varepsilon_k$$

- Tasa de aprendizaje: $0.1 < \alpha < 1$.

- **Error del cuantizador:** $\tilde{\varepsilon}_k = d_k - y_k$ (donde $y_k = \text{sgn}(s_k)$).
- **Actualización de pesos:** $W_{k+1} = W_k + \alpha \frac{\tilde{\varepsilon}_k}{2} X_k$
- Para $\alpha = 1$:
 - Si $\tilde{\varepsilon}_k > 0$ (i.e., $d_k = 1, y_k = -1$): $W_{k+1} = W_k + X_k$.
 - Si $\tilde{\varepsilon}_k < 0$ (i.e., $d_k = -1, y_k = 1$): $W_{k+1} = W_k - X_k$.

- **Valor de α :**
 - α -LMS: controla estabilidad y velocidad de convergencia.
 - Perceptrón: no afecta la estabilidad; solo afecta el tiempo de convergencia si el vector de pesos inicial es no nulo.
- **Tipo de respuesta:**
 - α -LMS: respuestas binarias y continuas.
 - Perceptrón: solo respuestas binarias deseadas.
- **Patrones linealmente separables:**
 - Perceptrón: separa cualquier conjunto linealmente separable.
 - α -LMS: puede fallar en separar conjuntos linealmente separables.
- **Patrones no linealmente separables:**
 - Perceptrón: no converge; a menudo no produce una solución de bajo error.
 - α -LMS: no conduce a soluciones de peso no razonables.

- Separan cualquier conjunto linealmente separable.
- Para conjuntos no linealmente separables, la regla de May funciona mucho mejor que el Perceptrón porque una zona muerta suficientemente grande tiende a hacer que el vector de pesos se adapte lejos de cero cuando existe una solución razonablemente buena.

Variantes

- Regla de Adaptación por Incremento.
- Regla de Adaptación por Relajación Modificada.

- **Primera capa:** elementos Adaline con cuantizador duro.
- **Segunda capa:** un único elemento lógico de umbral fijo (OR, AND, MAJ).

$$X \rightarrow [\text{Adaline}_1, \dots, \text{Adaline}_n] \rightarrow \text{Lógica Fija} \rightarrow \pm 1$$

MRI — Ejemplo 1 (Sin error)

Adaline	$s = W^T X$	$\text{sgn}(s)$	
W_1	0.2	+1	→ MAJ → -1
W_2	0.8	+1	
W_3	-0.1	-1	
W_4	-0.3	-1	
W_5	-0.4	-1	

- Salida deseada $d = -1$. ¡**Correcto!** No se requiere adaptación.

MRI — Ejemplo 2 (Error detectado)

Mismo X , pero $d = +1$	Adaline	$s = W^T X$	$\text{sgn}(s)$	
	W_1	0.2	+1	
	W_2	0.8	+1	
	W_3	-0.1	-1	$\rightarrow \text{MAJ} \rightarrow -1$
	W_4	-0.3	-1	
	W_5	-0.4	-1	

- Salida deseada $d = +1$, pero la salida es -1 . **¡Error!**
- Se elige el Adaline con menor $|s_k|$: W_3 ($|s| = 0.1$, el más cercano a cero).

MRI — Ejemplo 3 (Adaptación de W_3)

Se adapta W_3 para invertir su salida:

Adaline	$s = W^T X$	$\text{sgn}(s)$	
W_1	0.2	+1	→ MAJ → +1
W_2	0.8	+1	
W'_3	0.4	+1	
W_4	-0.3	-1	
W_5	-0.4	-1	

- ¡Mayoría ahora es +1! Salida deseada $d = +1$. ¡Correcto!

MRI — Intento alternativo (perturbando W_2)

Perturbando W_2 :	Adaline	$s = W^T X$	$\text{sgn}(s)$	$\rightarrow \text{MAJ} \rightarrow -1$
	W_1	0.2	+1	
	W'_2	-0.05	-1	
	W_3	-0.1	-1	
	W_4	-0.3	-1	
	W_5	-0.4	-1	

- Salida deseada $d = +1$, pero salida sigue siendo -1 . ¡No funciona!
- Se necesita adaptar más de un Adaline.

MRI — Adaptación de W'_2 y W'_3

Adaline	$s = W^T X$	$\text{sgn}(s)$	
W_1	0.2	+1	→ MAJ → +1
W'_2	0.1	+1	
W'_3	0.4	+1	
W_4	-0.3	-1	
W_5	-0.4	-1	

- ¡Ahora sí! Mayoría +1, $d = +1$. ¡Correcto!

- Los pesos se inicializan con valores aleatorios pequeños.
- Actualización del vector de pesos: puede cambiarse agresivamente usando corrección absoluta o adaptarse por el pequeño incremento determinado por α -LMS.
- **Principio:** asignar responsabilidad al Adaline o Adalines que pueden asumirla más fácilmente.
- La secuencia de presentación de patrones debe ser aleatoria.

Madaline Rule II (MRII) — Arquitectura

- Arquitectura típica de Madaline II de dos capas.
- Ambas capas son adaptativas.

Madaline Rule II (MRII) — Algoritmo

- Pesos inicializados con valores aleatorios pequeños.
- Secuencia de presentación de patrones aleatoria.

Adaptación de los Adalines de la primera capa

- 1 Seleccionar la menor magnitud de salida lineal $|s_k|$.
- 2 Realizar una “adaptación de prueba” agregando una perturbación Δs de amplitud adecuada para invertir su salida binaria.
- 3 Si el error de salida se reduce, remover Δs y cambiar el peso del Adaline seleccionado usando α -LMS.
- 4 Perturbar y actualizar otros Adalines en la primera capa con salida s_k “suficientemente pequeña” (se pueden invertir pares, tríos, etc.).
- 5 Después de agotar posibilidades en la primera capa, pasar a la siguiente capa.
- 6 Seleccionar aleatoriamente un nuevo patrón de entrenamiento y repetir.

- **Descenso más empinado:** medir el gradiente de la función de error cuadrático medio y alterar el vector de pesos en la dirección negativa del gradiente medido.

$$W_{k+1} = W_k + \mu(-\nabla_k)$$

- μ : controla estabilidad y tasa de convergencia.
- ∇_k : valor del gradiente en un punto de la superficie MSE correspondiente a $W = W_k$.

- Error lineal instantáneo: $\varepsilon_k = d_k - \mathbf{W}_k^T \mathbf{X}_k$.
- Gradiente instantáneo: $\hat{\nabla}_k = \frac{\partial \varepsilon_k^2}{\partial \mathbf{W}_k} = -2\varepsilon_k \mathbf{X}_k$
- Actualización de pesos: $\mathbf{W}_{k+1} = \mathbf{W}_k + \mu(-\hat{\nabla}_k) = \mathbf{W}_k + 2\mu\varepsilon_k \mathbf{X}_k$

$$\varepsilon_k^2 = (d_k - \mathbf{X}_k^T \mathbf{W}_k)^2 = d_k^2 - 2d_k \mathbf{X}_k^T \mathbf{W}_k + \mathbf{W}_k^T (\mathbf{X}_k \mathbf{X}_k^T) \mathbf{W}_k$$

$$\begin{aligned}\nabla_k &= \frac{\partial \varepsilon_k^2}{\partial \mathbf{W}_k} = -2d_k \mathbf{X}_k + 2(\mathbf{X}_k \mathbf{X}_k^T) \mathbf{W}_k \\ &= -2\mathbf{X}_k (d_k - \mathbf{X}_k^T \mathbf{W}_k) = -2\varepsilon_k \mathbf{X}_k\end{aligned}$$

- μ controla estabilidad y tasa de convergencia.
- d_k y $\mathbf{X}_k$ son independientes de $\mathbf{W}_k$.

- Con μ pequeño y K pequeño (pocas presentaciones de entrenamiento):
 - El cambio total de peso durante la presentación de K patrones es proporcional a la derivada del error cuadrático medio.
- ε es la función de error cuadrático medio (MSE).

- Se minimiza el cuadrado medio del error sigmoide $\tilde{\epsilon}_k$:

$$\tilde{\epsilon}_k = d_k - y_k = d_k - \text{sgm}(s_k)$$

$$s_k \rightarrow \text{Sigmoide} \rightarrow y_k \quad \rightarrow \quad \tilde{\epsilon}_k = d_k - y_k$$

- Estimación del gradiente instantáneo:

$$\begin{aligned}\tilde{\epsilon}_k &= d_k - \text{sgm}(s_k) \\ \frac{\partial \tilde{\epsilon}_k^2}{\partial W_k} &= \frac{\partial \tilde{\epsilon}_k^2}{\partial s_k} \cdot \frac{\partial s_k}{\partial W_k} \\ &= -2\tilde{\epsilon}_k \text{sgm}'(s_k) X_k\end{aligned}$$

- Actualización: $W_{k+1} = W_k + 2\mu \tilde{\epsilon}_k \text{sgm}'(s_k) X_k$

Motivación

La función sigmoide y su derivada pueden no realizarse con precisión cuando se implementan con hardware analógico.

- Se usa una perturbación en lugar de la derivada de la sigmoide.
- Se agrega una pequeña señal de perturbación Δs a la suma s_k .
- Se observa el efecto de esta perturbación sobre la salida y_k y el error $\tilde{\epsilon}_k$.

$$\frac{\partial \tilde{\epsilon}_k^2}{\partial s_k} \approx \frac{\tilde{\epsilon}_k^2(s_k + \Delta s) - \tilde{\epsilon}_k^2(s_k)}{\Delta s} = \frac{\Delta \tilde{\epsilon}_k^2}{\Delta s}$$

$$\hat{\nabla}_k = \frac{\partial \tilde{\epsilon}_k^2}{\partial W_k} \approx \frac{\Delta \tilde{\epsilon}_k^2}{\Delta s} X_k$$

- Alternativamente:

$$\frac{\Delta \tilde{\epsilon}_k^2}{\Delta s} \approx 2\tilde{\epsilon}_k \frac{\Delta \tilde{\epsilon}_k}{\Delta s}$$

- Actualización de pesos:

$$W_{k+1} = W_k - \mu \frac{\Delta \tilde{\epsilon}_k^2}{\Delta s} X_k \quad \text{o} \quad W_{k+1} = W_k - 2\mu \tilde{\epsilon}_k \frac{\Delta \tilde{\epsilon}_k}{\Delta s} X_k$$

Backpropagation vs MRIII (Elemento Único)

- Matemáticamente equivalentes si la perturbación Δs es pequeña.
- Agregar la perturbación Δs causa un cambio en $\tilde{\epsilon}_k$ igual a:

$$\Delta \tilde{\epsilon}_k = \tilde{\epsilon}_k(s_k + \Delta s) - \tilde{\epsilon}_k(s_k) \approx \frac{\partial \tilde{\epsilon}_k}{\partial s_k} \Delta s$$

- Cuando $\Delta s \rightarrow 0$:

$$\frac{\Delta \tilde{\epsilon}_k}{\Delta s} \rightarrow \frac{\partial \tilde{\epsilon}_k}{\partial s_k} = -\text{sgm}'(s_k)$$

- MRIII $\equiv$ Backpropagation.

¿Cómo funciona backpropagation?

Para un vector de patrón de entrada X :

- 1 Barrer hacia adelante a través del sistema para obtener un vector de respuesta de salida Y .
- 2 Calcular los errores en cada salida.
- 3 Barrer los efectos de los errores hacia atrás a través de la red para asociar una “derivada del error cuadrático” δ con cada Adaline.
- 4 Calcular un gradiente a partir de cada δ .
- 5 Actualizar los pesos de cada Adaline basado en el gradiente correspondiente.

Backpropagation: Propagación hacia Adelante

$$a^{(1)} = X$$

$$a^{(2)} = \text{sgm}((W^{(1)})^T a^{(1)})$$

$$a^{(3)} = \text{sgm}((W^{(2)})^T a^{(2)})$$

$$a^{(4)} = \text{sgm}((W^{(3)})^T a^{(3)})$$

Figuras tomadas del curso online de Andrew Ng

Backpropagation: Retro-propagación del Error

- Para cada unidad de salida en la capa 4:

$$\delta_j^{(4)} = a_j^{(4)} - y_j$$

- Retro-propagación:

$$\delta^{(3)} = W^{(3)} \delta^{(4)} \text{ .* sgm}'(W^{(2)} a^{(2)})$$

$$\delta^{(2)} = W^{(2)} \delta^{(3)} \text{ .* sgm}'(W^{(1)} a^{(1)})$$

Intuición

$\delta_j^{(l)}$ = “error” del nodo j en la capa l .

Figuras tomadas del curso online de Andrew Ng

Backpropagation: Gradiente Instantáneo para un Adaline

- Gradiente instantáneo para un elemento Adaline:

$$\hat{\nabla}_k = \frac{\partial \varepsilon^2}{\partial W_k}$$

- Definiendo $\delta_k = \frac{\partial \varepsilon^2}{\partial s_k}$:

$$\hat{\nabla}_k = \delta_k X_k$$

- Y la actualización:

$$W_{k+1} = W_k - \mu \delta_k X_k$$

- Error cuadrático total de salida:

$$\varepsilon^2 = (d_1 - y_1)^2 + (d_2 - y_2)^2 + \dots$$

- Se proporciona una perturbación agregando Δs a un Adaline seleccionado; la perturbación se propaga a través de la red, causando un cambio en la suma de los cuadrados de los errores.
- Gradiente instantáneo:

$$\hat{\nabla}_k = \frac{\partial \varepsilon_k^2}{\partial W_k} \approx \frac{\Delta \varepsilon_k^2}{\Delta s} X_k$$

- Actualización de pesos:

$$W_{k+1} = W_k - \mu \frac{\Delta \varepsilon_k^2}{\Delta s} X_k$$

- B. Widrow and M.E. Hoff, Jr. *Adaptive switching circuits*. Technical Report 1553-1, Stanford Electron. Labs., Stanford, CA, June 30, 1960.
- K. Senne. *Adaptive Linear Discrete-time estimation*. PhD thesis, Technical Report SEL-68-090, Stanford Electron. Labs., Stanford, CA, June 1968.
- S. Grossberg. *Nonlinear neural networks: principles, mechanisms, and architectures*. Neural Networks 1.1 (1988): 17–61.
- S. Cross, R. Harrison, and R. Kennedy. *Introduction to neural networks*. The Lancet 346.8982 (1995): 1075–1079.
- Andrew Ng's Machine Learning course on Coursera.
- LMS tutorials: <http://homepages.cae.wisc.edu/~ece539/resources/tutorials/LMS.pdf>