

30 Años de Redes Neuronales Adaptativas

Perceptrón, Madaline y Backpropagation (Widrow & Lehr, 1990)

Iván Fernández G.

Magíster en Ingeniería Informática — Universidad de Santiago de Chile
Inteligencia Computacional 2026-1 | Prof. Gonzalo Acuña Leiva

Julio 2026

Contenido

- 1 Introducción e historia
- 2 Conceptos fundamentales
- 3 Reglas de aprendizaje
- 4 Experimentos
- 5 Conclusiones

Introducción e historia

El problema: aprendizaje supervisado en RNA feedforward

¿Qué aborda el artículo?

Cómo **adaptar los pesos** de una red de elementos simples para que aproxime una función de clasificación o regresión a partir de ejemplos. Es una **revisión** (*survey*) de 30 años de reglas de aprendizaje, desde el Perceptrón (1958) hasta *backpropagation* (1986).

¿Por qué redes neuronales?

- **Paralelismo masivo**: muchos elementos simples resolviendo en conjunto.
- **Aprendizaje por ejemplos**: sin programar reglas explícitas.
- **Generalización**: clasifican patrones no vistos.

Nota

Aplicaciones históricas: **NETtalk**, el *truck backer-upper* y los ecualizadores LMS de módems (primer uso comercial masivo).

Treinta años de evolución (1960–1990)

Línea de tiempo

- **1960** — Algoritmo LMS (Widrow & Hoff) y regla del Perceptrón (Rosenblatt), desarrollados de forma independiente.
- **Mediados 60s** — Madaline Rule I (MRI): primera red en capas entrenable; voz, clima, patrones.
- **1971–1974** — Backpropagation (Werbos); ignorada, redescubierta por Parker (1982) y popularizada por Rumelhart, Hinton & Williams (1986).
- **1987** — Madaline Rule II (MRII): adapta redes multicapa con cuantizadores duros.
- **1988** — Madaline Rule III (MRIII, Andes); Widrow *et al.* descubren que es **equivalente a backpropagation**.

Nota

El artículo delimita su foco a los algoritmos de Stanford y a *backprop*; deja fuera ART, Hopfield, Boltzmann, Kohonen y el Neocognitron.

El hilo conductor: principio de mínima perturbación

Idea clave

Adaptar para reducir el error del patrón actual, con la mínima perturbación a las respuestas ya aprendidas.

Consecuencia geométrica

El cambio de pesos ΔW_k es siempre **colineal** con el vector de entrada X_k : se logra la corrección deseada con el cambio de **menor magnitud posible**.

$$\Delta W_k \parallel X_k \implies \min \|\Delta W_k\|$$

- Es el principio que condujo al descubrimiento de LMS y de las reglas Madaline.
- **Todos** los algoritmos del artículo obedecen esta idea.

Conceptos fundamentales

El bloque básico: combinador lineal y Adaline





Fig. 2 del artículo: el Adaline con entrada de respuesta deseada

d_k .

Ecuaciones

Combinador lineal (producto interno):

$$s_k = X_k^T W_k$$

Adaline con cuantizador duro:

$$y_k = \text{sgn}(s_k) \in \{\pm 1\}$$

Variante diferenciable:

$$y_k = \tanh(s_k)$$

- **Adaline** = *Adaptive Linear Element*: bloque de casi toda RNA.


Separabilidad lineal: el límite del Adaline

Un Adaline solo resuelve funciones separables

Con $n = 2$ entradas binarias implementa **14 de 16** funciones lógicas. Las dos imposibles: **XOR** y **XNOR**.


$$\begin{array}{ll} (+1, +1) \rightarrow +1 & (+1, -1) \rightarrow -1 \\ (-1, +1) \rightarrow -1 & (-1, -1) \rightarrow +1 \end{array}$$

No existe una recta que separe estos cuatro puntos.




Consecuencia

La incapacidad de realizar *todas* las funciones no es un defecto fatal: **limita la capacidad y por eso mejora la generalización**. Para XOR se necesita **no linealidad**: preprocesamiento o varias capas.



Capacidad de patrones: el teorema de Cover

E1: Capacidad de Cover -- Validacion Monte Carlo



Probabilidad de separabilidad

$$P(N_p, N_w) = 2^{1-N_p} \sum_{i=0}^{N_w-1} \binom{N_p-1}{i}, \quad N_p > N_w$$

- Capacidad determinística: $C_d = N_w$ (garantía).
- Capacidad estadística: $C_s \approx 2N_w$ (promedio).
- Baum extendió la cota a redes multicapa.

Idea clave

Trade-off capacidad-generalización: en-

Clasificadores no lineales (I): preprocesador polinomial

Un solo Adaline + preprocesador fijo

Expandiendo la entrada a términos polinomiales $[x_1^2, x_1, x_1x_2, x_2, x_2^2]$, la condición de umbral se vuelve:

$$s = w_0 + x_1w_1 + x_1^2w_{11} + x_1x_2w_{12} + x_2^2w_{22} + x_2w_2 = 0$$

- La frontera puede ser una **elipse** $\Rightarrow$ **resuelve XNOR/XOR** con un único elemento.
- Método PDM de Specht: entrenamiento no iterativo (una pasada).
- Los pesos aproximan coeficientes de una *serie de Taylor* de la respuesta deseada.




Fig. 6: Adaline con entradas expandidas por un preprocesador polinomial fijo.

Capacidad de Cover: las curvas originales del artículo




Fig. 5 del artículo: P_{sep} en función de N_p/N_w para distintos N_w .

Lectura de las curvas

- En $N_p/N_w = 1$ (es decir $N_p = N_w$) la separación está garantizada: $C_d = N_w$.
- En $N_p/N_w = 2$ la probabilidad es 0.5: define $C_s \approx 2N_w$.
- Al crecer N_w , la transición se vuelve **abrupta**: $C_s \approx 2N_w$ es un estimador cada vez más preciso.

Idea clave

Mi `fig_cover` (lámina anterior) reproduce empírica

Clasificadores no lineales (II): Madaline I y redes feedforward

Madaline I (MRI)

- Capa de Adalines (*signum*) → lógica fija de salida (AND, OR o mayoría).
- Primera red en capas entrenable.
- *Load-sharing*: “asignar la responsabilidad a quien pueda asumirla más fácilmente”.

Red feedforward

- **Todas** las capas son adaptativas.
- Salida: error directo y fácil de adaptar.
- **Dificultad clave**: obtener señales de error para las capas **ocultas**.

Idea clave

Backpropagation y *Madaline Rule III* son precisamente los dos mecanismos que resuelven el problema de las señales de error en capas ocultas.

Las arquitecturas originales: de Madaline I a la red multicapa




Fig. 15: Madaline I — capa de Adalines *signum* + lógica fija (mayoría).




Fig. 11: red *feedforward* de tres capas totalmente conectada.

Nota

El salto conceptual

En Madaline I solo la primera capa es adaptativa; en la red feedforward moderna lo

Reglas de aprendizaje


Dos familias de reglas y su taxonomía

Corrección de error

Corrigen una proporción del error en la respuesta al patrón presente.

Descenso más pronunciado

Minimizan el MSE promediado sobre todo el conjunto, por gradiente.



Reproducción de la Fig. 33 del artículo.




Fig. 33. Learning rules.

Regla delta de Widrow-Hoff (única regla lineal de corrección)

$$W_{k+1} = W_k + \alpha \frac{\varepsilon_k}{\|X_k\|^2} X_k, \quad \varepsilon_k = d_k - X_k^T W_k$$

- Corrección proporcional al error lineal ε_k .
- ΔW_k colineal con X_k (mínima perturbación).
- **Auto-normalizante**: α no depende de la magnitud de las entradas.

Nota

Estabilidad $0 < \alpha < 2$; rango práctico $0.1 < \alpha < 1.0$. El cambio en el error es $\Delta \varepsilon_k = -\alpha \varepsilon_k$.

Corrección de error no lineal: regla del Perceptrón

Rosenblatt

$$W_{k+1} = W_k + \alpha \frac{\tilde{\varepsilon}_k}{2} X_k, \quad \tilde{\varepsilon}_k = d_k - y_k \in \{-2, 0, +2\}$$

- Usa el error del cuantizador $\tilde{\varepsilon}_k$; **solo adapta** si $y_k \neq d_k$.
- **Teorema de convergencia**: separa en pasos finitos si los **datos son linealmente separables**.
- Si **no** lo son, el vector de pesos “gravita hacia cero” y el algoritmo continúa indefinidamente.




Fig. 13: el α -Perceptrón de Rosenblatt — primera capa

α -LMS vs. Perceptrón

α -LMS	Perceptrón
α controla estabilidad y convergencia	α solo afecta el tiempo si $W_0 \neq 0$
Respuestas binarias y continuas	Solo respuestas binarias
Puede fallar en separar un conjunto separable	Separa cualquier conjunto separable
No da soluciones absurdas con datos no separables	No converge con datos no separables

Nota

Objetivos distintos: α -LMS reduce el *error lineal*; el Perceptrón busca *separar*.

Reglas de Mays: la “zona muerta”

Adaptación por incremento con zona muerta γ

$$W_{k+1} = \begin{cases} W_k + \alpha \tilde{\varepsilon}_k \frac{X_k}{2\|X_k\|^2} & |s_k| \geq \gamma \\ W_k + \alpha d_k \frac{X_k}{\|X_k\|^2} & |s_k| < \gamma \end{cases}$$

- Si es separable: converge en pasos finitos (como el Perceptrón).
- Si **no** lo es: una zona muerta grande aleja el vector de pesos de cero $\Rightarrow$ **mejor que el Perceptrón**.
- Casos límite: $\gamma \rightarrow 0$ recupera el Perceptrón; $\gamma \rightarrow \infty$ (relajación) recupera α -LMS.

Redes multicapa por corrección de error: Madaline Rule II

MRII (Widrow, Winter & Baxter, 1987) — adapta *todas* las capas

Para cada patrón erróneo:

- 1 Ordenar las Adalines por $|s|$ creciente (mínima perturbación).
- 2 Flip tentativo de la salida de una Adalina; si reduce el **error de Hamming**, se acepta.
- 3 Reforzar con corrección colineal por α -LMS; si no, probar *pares* de Adalines.
- 4 Entrenar la capa de salida con α -LMS.




Fig. 16 del artículo: arquitectura MRII de dos capas: la perturbación Δs prueba el *flip* de cada Adalina.

Descenso más pronunciado lineal: μ -LMS y la superficie de MSE

Regla μ -LMS

$$W_{k+1} = W_k + 2\mu \varepsilon_k X_k$$

Superficie de MSE (paraboloide **convexo**):

$$\xi(W) = \mathbb{E}[d^2] - 2P^T W + W^T R W$$


Mínimo único: solución de Wiener

$$W^* = R^{-1}P$$


- Gradiente instantáneo $-2\varepsilon_k X_k$: estimador **insesgado** del verdadero.
- Estabilidad: $0 < \mu < 1/\text{tr}[R]$.
- Frente a α -LMS: μ -LMS converge al **mínimo MSE** (Wiener); α -LMS, a una solución sesgada.

Por qué el gradiente exige activaciones diferenciables


Error lineal (paraboloide convexo)
Min=0.9359



Error sigmoide (no cuadrático)
Min=0.9401



Error signum (escalonado, mesetas)
Min=1.3333



Nota

Lineal: paraboloide convexo, mínimo global garantizado.

Nota

Sigmoide: suave y navegable; posibles mínimos locales.

Signum

Escalonado, con **mesetas** de gradiente nulo: el descenso se detiene.

Las superficies de error originales (Figs. 22–24)




Fig. 22: error lineal.




Fig. 23: error sigmoide.




Fig. 24: error signum.

Idea clave

Las tres superficies provienen del **mismo** Adaline de dos pesos, variando solo la no linealidad de salida. El paraboloide liso (lineal) se degrada a un tazón suave con mínimos locales (sigmoide) y finalmente a un relieve **escalonado** intratable por gradiente (signum). Es la justificación visual de por qué backprop y MRNN usan sigmoides.

Descenso más pronunciado no lineal: Backpropagation

Propagación del error hacia atrás

Salida (Eq. 79) y capas ocultas (Eq. 87):

$$\delta_j^{(L)} = \varepsilon_j (1 - y_j^2), \quad \delta^{(l)} = (W^{(l+1)T} \delta^{(l+1)}) \odot (1 - (y^{(l)})^2)$$


Actualización con **momentum**:

$$\Delta W_k = \eta \Delta W_{k-1} + (1 - \eta) 2\mu \delta_k X_k^T, \quad \eta \approx 0.8-0.9$$

Idea clave

δ **no es un error**: es una *señal de gradiente* que indica cómo mover cada peso para reducir el error cuadrático de salida ε^2 .

La arquitectura de backpropagation del artículo (Fig. 25)



Detalle de una Adalina en backpropagation (Fig. 26)




Fig. 26. Detail of linear combiner and associated circuitry in backpropagation network.

Fig. 26: combinador lineal con su circuitería de retropropagación y actualización LMS.

Qué muestra el detalle

- Cada Adalina guarda una **copia** de sus pesos para el camino de retorno.
- El bloque **LMS** aplica $\Delta W = 2\mu \delta X$ una vez que llega δ desde aguas abajo.
- Los pesos deben transportar señal en **ambos sentidos** $\Rightarrow$ difícil en hardware analógico.

Idea clave

Justo esta complejidad de doble sentido es la que **MR33 elimina** usando perturbación.

Madaline Rule III $\equiv$ Backpropagation

MRIII (Andes, 1988): gradiente por perturbación del sumidero

Se perturba la suma s_j en Δs y se mide el efecto sobre ε^2 :

$$\frac{\partial \varepsilon^2}{\partial s_j} \approx \frac{\varepsilon_{\text{perturbado}}^2 - \varepsilon_{\text{base}}^2}{\Delta s}$$

Idea clave

Cuando $\Delta s \rightarrow 0$, MRIII es **matemáticamente equivalente a backpropagation**.

- No requiere conocer la derivada de la sigmoide.
- **Robusto** para hardware analógico (existió un chip comercial).
- Costo: $1 + N_{\text{Adalines}}$ pasadas hacia adelante (más caro en digital).



Experimentos

Implementación

- Seis algoritmos **desde cero en NumPy puro**.
- *scikit-learn* solo para datos y métricas.
- Reproducible: SEED=1990.

Hipótesis


- H1: $C_s \approx 2N_w$, $C_d = N_w$.
- H2: Perceptrón converge solo si es separable; μ -LMS $\rightarrow$ Wiener.
- H3: XOR solo por multicapa; óptimos locales.
- H4: MRIL $\equiv$ backprop.

Nota


Siete experimentos (E1–E7) sobre datos sintéticos y reales (Iris, Wine, MNIST-04, two-moons).

E1–E3: capacidad de Cover y reglas lineales

E1: Capacidad de Cover -- Validacion Monte Carlo



E1: empírico (puntos) vs. teoría de Cover.




E2: fronteras vs. óptimo de Wiener.

Resultados

H1 confirmada (desviación media ≤ 0.034). **H2 confirmada**: el Perceptrón converge en 2

E5: XOR — MRll vs. MLP-Backpropagation




Configuración	Éxito
MRll 2-2-1 sin ruido	0/20
MRll 2-3-1 + ruido	0/20
MLP-BP 2-2-1	6/20
MLP-BP 2-3-1	11/20


H3 confirmada

XOR solo por multicapa; tanto MRll como *backprop* sufren óptimos locales. La superficie sigmoide es más navegable que la del signum.

E6–E7: datasets reales y equivalencia $\text{MRll} \equiv \text{Backprop}$



E6: MLP 4-8-3 en Iris (91.1% test).



E7: error del gradiente y costo.

Resultados

Iris 91.1%, two-moons 93.3%, Wine 98.1%, MNIST-04 98.5%. **H4 confirmada:** el gradiente de MRll converge al de *backprop* con error relativo mínimo de 5.05×10^{-8} ; su costo crece como $\mathcal{O}(N_{\text{Adalines}})$.

Conclusiones

Aporte del artículo

- **Unifica 30 años** de algoritmos bajo un principio común: la **mínima perturbación**.
- El linaje Perceptrón $\rightarrow$ Adaline $\rightarrow$ Madaline $\rightarrow$ Backprop es una **progresión lógica**, no una colección arbitraria.
- La equivalencia $\text{MRIII} \equiv \text{backprop}$ muestra que un descubrimiento llega por caminos independientes.

Evaluación de hipótesis

H1–H4 confirmadas. Matiz en H3: MRII resultó más frágil ante óptimos locales que el MLP (0/20 por semilla única), tal como el propio artículo anticipa.

Vigencia: por qué sigue importando hoy

Los fundamentos siguen vivos

- El SGD del *deep learning* es μ -LMS generalizado a redes profundas.
- El **momentum** (Eqs. 96–97) sigue en optimizadores como Adam.
- La perturbación de MR11 anticipa la **optimización de orden cero** (cuando no hay gradiente).

Idea clave

Comprender la **geometría del aprendizaje** —hiperplano separador, paraboloide de MSE, mesetas del signum— es esencial para diseñar y depurar cualquier sistema de ML.

Gracias

¿Preguntas?

30 Years of Adaptive Neural Networks: Perceptron, Madaline, and Backpropagation
B. Widrow & M. A. Lehr, Proceedings of the IEEE, 78(9), 1990.