

30 Años de Redes Neuronales Adaptativas

Perceptrón, Madaline y Backpropagation (Widrow & Lehr, 1990)

Iván Fernández G.

Magíster en Ingeniería Informática — Universidad de Santiago de Chile
Inteligencia Computacional 2026-1 | Prof. Gonzalo Acuña Leiva

Julio 2026

Contenido

- 1 Introducción e historia
- 2 Conceptos fundamentales
- 3 Reglas de aprendizaje
- 4 Experimentos
- 5 Conclusiones

Introducción e historia

El problema: aprendizaje supervisado en RNA feedforward

¿Qué aborda el artículo?

Cómo **adaptar los pesos** de una red de elementos simples para que aproxime una función de clasificación o regresión a partir de ejemplos. Es una **revisión** (*survey*) de 30 años de reglas de aprendizaje, desde el Perceptrón (1958) hasta *backpropagation* (1986).

¿Por qué redes neuronales?

- **Paralelismo masivo**: muchos elementos simples resolviendo en conjunto.
- **Aprendizaje por ejemplos**: sin programar reglas explícitas.
- **Generalización**: clasifican patrones no vistos.

Nota

Aplicaciones históricas: **NETtalk**, el *truck backer-upper* y los ecualizadores LMS de módems (primer uso comercial masivo).

Treinta años de evolución (1960–1990)

Línea de tiempo

- **1960** — Algoritmo LMS (Widrow & Hoff) y regla del Perceptrón (Rosenblatt), desarrollados de forma independiente.
- **Mediados 60s** — Madaline Rule I (MRI): primera red en capas entrenable; voz, clima, patrones.
- **1971–1974** — Backpropagation (Werbos); ignorada, redescubierta por Parker (1982) y popularizada por Rumelhart, Hinton & Williams (1986).
- **1987** — Madaline Rule II (MRII): adapta redes multicapa con cuantizadores duros.
- **1988** — Madaline Rule III (MRIII, Andes); Widrow *et al.* descubren que es **equivalente a backpropagation**.

Nota

El artículo delimita su foco a los algoritmos de Stanford y a *backprop*; deja fuera ART, Hopfield, Boltzmann, Kohonen y el Neocognitron.

El hilo conductor: principio de mínima perturbación

Idea clave

Adaptar para reducir el error del patrón actual, con la mínima perturbación a las respuestas ya aprendidas.

Consecuencia geométrica

El cambio de pesos ΔW_k es siempre **colineal** con el vector de entrada X_k : se logra la corrección deseada con el cambio de **menor magnitud posible**.

$$\Delta W_k \parallel X_k \implies \min \|\Delta W_k\|$$

- Es el principio que condujo al descubrimiento de LMS y de las reglas Madaline.
- **Todos** los algoritmos del artículo obedecen esta idea.

Conceptos fundamentales

El bloque básico: combinador lineal y Adaline





Fig. 2 del artículo (original) sobre la reconstrucción.

Ecuaciones

Combinador lineal (producto interno):

$$s_k = X_k^T W_k$$

Cuantizador duro: $y_k = \text{sgn}(s_k) \in \{\pm 1\}$.

Variante diferenciable: $y_k = \tanh(s_k)$.

Nota

El bias w_0 (+1) fija el umbral; $s = 0$ define el **hiperplano separador**.

Separabilidad lineal: el límite del Adaline

Un Adaline solo resuelve funciones separables

Con $n = 2$ entradas binarias implementa **14 de 16** funciones lógicas. Las dos imposibles: XOR y XNOR.

$(+1, +1) \rightarrow +1$	$(+1, -1) \rightarrow -1$
$(-1, +1) \rightarrow -1$	$(-1, -1) \rightarrow +1$

Consecuencia

No poder realizar *todas* las funciones no es un defecto fatal: **limita la capacidad y por eso mejora la generalización**. Para XOR se necesita **no linealidad**.





Fig. 4 del artículo: la condición $s = 0$ como *recta separadora* en el espacio de patrones. Ninguna recta separa XOR.

Capacidad de patrones: el teorema de Cover

E1: Capacidad de Cover -- Validacion Monte Carlo



Probabilidad de separabilidad

$$P(N_p, N_w) = 2^{1-N_p} \sum_{i=0}^{N_w-1} \binom{N_p-1}{i}, \quad N_p > N_w$$

- Capacidad determinística: $C_d = N_w$ (garantía).
- Capacidad estadística: $C_s \approx 2N_w$ (promedio).
- Baum extendió la cota a redes multicapa.

Idea clave



Trade-off capacidad-generalización: en-

Clasificadores no lineales (I): preprocesador polinomial

Con un preprocesador fijo que expande la entrada a términos polinomiales $[x_1^2, x_1, x_1x_2, x_2, x_2^2]$, la condición de umbral $s = 0$ se vuelve:

$$s = w_0 + x_1w_1 + x_1^2w_{11} + x_1x_2w_{12} + x_2^2w_{22} + x_2w_2 = 0$$

- Frontera elíptica $\Rightarrow$ **resuelve XNOR/XOR** con un solo elemento; los pesos aproximan una *serie de Taylor* (método PDM de Specht, no iterativo).



Capacidad de Cover: las curvas originales del artículo




Fig. 5: P_{sep} vs. N_p/N_w para distintos N_w .

Lectura de las curvas

- $N_p/N_w = 1$: separación garantizada, $C_d = N_w$.
- $N_p/N_w = 2$: probabilidad 0.5, define $C_s \approx 2N_w$.
- Al crecer N_w la transición se vuelve **abrupta**.

Idea clave

Mi `fig_cover` reproduce empíricamente estas curvas: coinciden con la teoría de 1964.

Clasificadores no lineales (II): Madaline I y redes feedforward

Madaline I (MRI)

- Capa de Adalines (*signum*) → lógica fija de salida (AND, OR o mayoría).
- Primera red en capas entrenable.
- *Load-sharing*: “asignar la responsabilidad a quien pueda asumirla más fácilmente”.

Red feedforward

- **Todas** las capas son adaptativas.
- Salida: error directo y fácil de adaptar.
- **Dificultad clave**: obtener señales de error para las capas **ocultas**.

Idea clave

Backpropagation y *Madaline Rule III* son precisamente los dos mecanismos que resuelven el problema de las señales de error en capas ocultas.

Las arquitecturas originales: de Madaline I a la red multicapa




Fig. 15: Madaline I — Adalines *sigum* + lógica fija (mayoría).

Nota

El “*job assigner*” reparte la responsabilidad usando la salida lineal.




Fig. 11: red *feedforward* de tres capas totalmente conectada.

El salto conceptual

En Madaline I solo la **primera** capa es adaptativa; en la red moderna, **todas**.

Reglas de aprendizaje


Dos familias de reglas y su taxonomía

Corrección de error

Corrigen una proporción del error en la respuesta al patrón presente.

Descenso más pronunciado

Minimizan el MSE promediado sobre todo el conjunto, por gradiente.



Reproducción fiel de la Fig. 33 del artículo.

Regla delta de Widrow-Hoff (única regla lineal de corrección)

$$W_{k+1} = W_k + \alpha \frac{\varepsilon_k}{\|X_k\|^2} X_k, \quad \varepsilon_k = d_k - X_k^T W_k$$

- Corrección proporcional al error lineal ε_k .
- ΔW_k colineal con X_k (mínima perturbación).
- **Auto-normalizante**: α no depende de la magnitud de las entradas.

Nota

Estabilidad $0 < \alpha < 2$; rango práctico $0.1 < \alpha < 1.0$. El cambio en el error es $\Delta \varepsilon_k = -\alpha \varepsilon_k$.

Corrección de error no lineal: regla del Perceptrón

Rosenblatt

$$W_{k+1} = W_k + \alpha \frac{\tilde{\varepsilon}_k}{2} X_k, \quad \tilde{\varepsilon}_k = d_k - y_k \in \{-2, 0, +2\}$$

- Usa el error del cuantizador $\tilde{\varepsilon}_k$; **solo adapta** si $y_k \neq d_k$.
- **Teorema de convergencia**: separa en pasos finitos si los **datos son linealmente separables**.
- Si **no** lo son, el vector de pesos “gravita hacia cero” y el algoritmo continúa indefinidamente.




Fig. 13: el α -Perceptrón de Rosenblatt — primera capa

α -LMS vs. Perceptrón

α -LMS	Perceptrón
α controla estabilidad y convergencia	α solo afecta el tiempo si $W_0 \neq 0$
Respuestas binarias y continuas	Solo respuestas binarias
Puede fallar en separar un conjunto separable	Separa cualquier conjunto separable
No da soluciones absurdas con datos no separables	No converge con datos no separables

Nota

Objetivos distintos: α -LMS reduce el *error lineal*; el Perceptrón busca *separar*.

Reglas de Mays: la “zona muerta”

Adaptación por incremento con zona muerta γ

$$W_{k+1} = \begin{cases} W_k + \alpha \tilde{\varepsilon}_k \frac{X_k}{2\|X_k\|^2} & |s_k| \geq \gamma \\ W_k + \alpha d_k \frac{X_k}{\|X_k\|^2} & |s_k| < \gamma \end{cases}$$

- Si es separable: converge en pasos finitos (como el Perceptrón).
- Si **no** lo es: una zona muerta grande aleja el vector de pesos de cero $\Rightarrow$ **mejor que el Perceptrón**.
- Casos límite: $\gamma \rightarrow 0$ recupera el Perceptrón; $\gamma \rightarrow \infty$ (relajación) recupera α -LMS.

Redes multicapa por corrección de error: Madaline Rule II

MRII (Widrow, Winter & Baxter, 1987) — adapta *todas* las capas


Para cada patrón erróneo:

- 1 Ordenar las Adalines por $|s|$ creciente (mínima perturbación).
- 2 Flip tentativo de la salida de una Adalina; si reduce el **error de Hamming**, se acepta.
- 3 Reforzar con corrección colineal por α -LMS; si no, probar *pares* de Adalines.
- 4 Entrenar la capa de salida con α -LMS.

Limitación

MRII puede **estancarse en óptimos locales**. Remedio del artículo: ruido esporádico en los pesos o reentrenar con distintas semillas (*random restarts*).

La arquitectura Madaline II del artículo (Fig. 16)



Red MR II de dos capas, **ambas adaptativas**. La perturbación Δs inyectada en el sumidero de cada Adalina prueba el *flip* de su salida; si reduce el error de Hamming a la salida, el cambio se refuerza con α -LMS.

Descenso más pronunciado lineal: μ -LMS y la superficie de MSE

Regla μ -LMS

$$W_{k+1} = W_k + 2\mu \varepsilon_k X_k$$

Superficie de MSE (paraboloide **convexo**):

$$\xi(W) = \mathbb{E}[d^2] - 2P^T W + W^T R W$$


Mínimo único: solución de Wiener

$$W^* = R^{-1}P$$


- Gradiente instantáneo $-2\varepsilon_k X_k$: estimador **insesgado** del verdadero.
- Estabilidad: $0 < \mu < 1/\text{tr}[R]$.
- Frente a α -LMS: μ -LMS converge al **mínimo MSE** (Wiener); α -LMS, a una solución sesgada.

Por qué el gradiente exige activaciones diferenciables


Error lineal (paraboloide convexo)
Min=0.9359



Error sigmoide (no cuadrático)
Min=0.9401



Error signum (escalonado, mesetas)
Min=1.3333



Nota

Lineal: paraboloide convexo, mínimo global garantizado.

Nota

Sigmoide: suave y navegable; posibles mínimos locales.

Signum

Escalonado, con **mesetas** de gradiente nulo: el descenso se detiene.

Las superficies de error originales (Figs. 22–24)




Fig. 22: error lineal.




Fig. 23: error sigmoide.




Fig. 24: error signum.

Idea clave

Las tres provienen del **mismo** Adaline de dos pesos: el paraboloide liso (lineal) se degrada a un tazón con mínimos locales (sigmoide) y a un relieve **escalonado** intratable por gradiente (signum). Por eso backprop y MRIII usan sigmoides.

Descenso más pronunciado no lineal: Backpropagation

Propagación del error hacia atrás

Salida (Eq. 79) y capas ocultas (Eq. 87):

$$\delta_j^{(L)} = \varepsilon_j (1 - y_j^2), \quad \delta^{(l)} = (W^{(l+1)T} \delta^{(l+1)}) \odot (1 - (y^{(l)})^2)$$


Actualización con **momentum**:

$$\Delta W_k = \eta \Delta W_{k-1} + (1 - \eta) 2\mu \delta_k X_k^T, \quad \eta \approx 0.8-0.9$$

Idea clave

δ **no es un error**: es una *señal de gradiente* que indica cómo mover cada peso para reducir el error cuadrático de salida ε^2 .

La arquitectura de backpropagation del artículo (Fig. 25)



Trazo **continuo** = barrido hacia adelante ($X \rightarrow Y$); trazo **punteado** = barrido hacia atrás que transporta los δ .
El barrido de retorno tiene la **misma complejidad** que el de ida (sin multiplicaciones de peso en la primera capa).

Detalle de una Adalina en backpropagation (Fig. 26)




Fig. 26. Detail of linear combiner and associated circuitry in backpropagation network.

Fig. 26: combinador con su circuitería de retropropagación y LMS.

Qué muestra el detalle

- Cada Adalina guarda una copia de sus pesos para el retorno.
- El bloque **LMS** aplica $\Delta W = 2\mu \delta X$ al llegar δ .
- Los pesos transportan señal en **ambos sentidos** $\Rightarrow$ difícil en analógico.

Idea clave

Esa complejidad de doble sentido es la que **MRIII elimina** usando perturbación.

Madaline Rule III $\equiv$ Backpropagation

MRIII (Andes, 1988): gradiente por perturbación del sumidero

Se perturba la suma s_j en Δs y se mide el efecto sobre ε^2 :


$$\frac{\partial \varepsilon^2}{\partial s_j} \approx \frac{\varepsilon_{\text{perturbado}}^2 - \varepsilon_{\text{base}}^2}{\Delta s}$$

Idea clave

Cuando $\Delta s \rightarrow 0$, MRIII es **matemáticamente equivalente a backpropagation**.

- No requiere conocer la derivada de la sigmoide.
- **Robusto** para hardware analógico (existió un chip comercial).
- Costo: $1 + N_{\text{Adalines}}$ pasadas hacia adelante (más caro en digital).

MRIII en la red: la misma arquitectura, con sigmoides (Fig. 28)



MRIII $\leftrightarrow$ MRII

La arquitectura es **idéntica** a la de MRII (Fig. 16), pero cada cuantizador *signum* se reemplaza por una **sigmoide**.

Idea clave

Ese único cambio hace que el gradiente por perturbación **coincida con backpropagation**, manteniendo la robustez para hardware analógico.

Experimentos

Diseño experimental e hipótesis

Implementación

- Seis algoritmos **desde cero en NumPy puro**.
- *scikit-learn* solo para datos y métricas.
- Reproducible: SEED=1990.

Hipótesis

- H1: $C_s \approx 2N_w$, $C_d = N_w$.
- H2: Perceptrón converge solo si es separable; μ -LMS $\rightarrow$ Wiener.
- H3: XOR solo por multicapa; óptimos locales.
- H4: MR111 $\equiv$ backprop.

Nota


Siete experimentos (E1–E7) sobre datos sintéticos y reales (Iris, Wine, MNIST-04, two-moons).

Experimentos y datasets en detalle

Exp.	Qué evalúa	Hip.
E1	Capacidad de un Adaline con patrones binarios aleatorios	H1
E2	Reglas lineales: fronteras vs. Wiener (separable)	H2
E3	Reglas lineales sobre datos no separables	H2
E4	Convergencia de reglas de corrección (α -LMS, Perc., Mays)	H2
E5	XOR: MR II vs. MLP-backpropagation	H3
E6	Generalización sobre datasets reales	H3
E7	Equivalencia del gradiente MR III $\equiv$ backprop	H4


Conjuntos de datos

- **Sintéticos:** binarios (E1), gaussianos sep./no sep. (E2–E3), XOR (E5).
- **two-moons:** no lineal 2D (93.3%).
- **Iris:** 4 rasgos, 3 clases (91.1%).
- **Wine:** 13 rasgos, 3 clases (98.1%).
- **MNIST-04:** dígitos 0–4 (98.5%).




Panorama de los conjuntos de prueba usados en los experimentos.

E1–E3: capacidad de Cover y reglas lineales



E1: empírico (puntos) vs. teoría de Cover.




E2: fronteras vs. óptimo de Wiener.

Resultados

H1 confirmada (desviación media ≤ 0.034). **H2 confirmada**: el Perceptrón converge en 2

E5: XOR — MRll vs. MLP-Backpropagation




Configuración	Éxito
MRll 2-2-1 sin ruido	0/20
MRll 2-3-1 + ruido	0/20
MLP-BP 2-2-1	6/20
MLP-BP 2-3-1	11/20


H3 confirmada

XOR solo por multicapa; tanto MRll como *backprop* sufren óptimos locales. La superficie sigmoide es más navegable que la del signum.

E6–E7: datasets reales y equivalencia $\text{MRll} \equiv \text{Backprop}$



E6: MLP 4-8-3 en Iris (91.1% test).



E7: error del gradiente y costo.

Resultados

Iris 91.1%, two-moons 93.3%, Wine 98.1%, MNIST-04 98.5%. **H4 confirmada:** el gradiente de MRll converge al de *backprop* con error relativo mínimo de 5.05×10^{-8} ; su costo crece como $\mathcal{O}(N_{\text{Adalines}})$.

Conclusiones

Aporte del artículo

- **Unifica 30 años** de algoritmos bajo un principio común: la **mínima perturbación**.
- El linaje Perceptrón → Adaline → Madaline → Backprop es una **progresión lógica**, no una colección arbitraria.
- La equivalencia $MR_{III} \equiv \text{backprop}$ muestra que un descubrimiento llega por caminos independientes.

Evaluación de hipótesis

H1–H4 confirmadas. Matiz en H3: MR_{II} resultó más frágil ante óptimos locales que el MLP (0/20 por semilla única), tal como el propio artículo anticipa.

Vigencia: por qué sigue importando hoy

Los fundamentos siguen vivos

- El SGD del *deep learning* es μ -LMS generalizado a redes profundas.
- El **momentum** (Eqs. 96–97) sigue en optimizadores como Adam.
- La perturbación de MR11 anticipa la **optimización de orden cero** (cuando no hay gradiente).

Idea clave

Comprender la **geometría del aprendizaje** —hiperplano separador, paraboloide de MSE, mesetas del signum— es esencial para diseñar y depurar cualquier sistema de ML.

Gracias

¿Preguntas?

30 Years of Adaptive Neural Networks: Perceptron, Madaline, and Backpropagation
B. Widrow & M. A. Lehr, Proceedings of the IEEE, 78(9), 1990.