

30 Años de Redes Neuronales Adaptativas

Perceptrón, Madaline y Backpropagation (Widrow & Lehr, 1990)

Iván Fernández G.

Magíster en Ingeniería Informática - Universidad de Santiago de Chile
Inteligencia Computacional 2026-1 | Prof. Gonzalo Acuña Leiva

Julio 2026

- 1 Introducción e historia
 - Motivación y línea histórica
- 2 Conceptos fundamentales
 - Adaline, separabilidad y arquitecturas
- 3 Reglas de aprendizaje
 - Corrección de error y descenso de gradiente
- 4 Experimentos
 - Diseño y resultados
- 5 Conclusiones
 - Síntesis

Contexto y línea histórica (1960–1990)

¿Qué aborda el artículo?

Una **revisión** de 30 años de reglas de aprendizaje supervisado para redes *feedforward*: cómo adaptar los pesos de elementos simples para clasificar o hacer regresión a partir de ejemplos, con **generalización** a patrones no vistos.

- **1960** - LMS (Widrow & Hoff) y regla del Perceptrón (Rosenblatt), independientes.
- **Mediados 60s** - Madaline I (MRI): primera red en capas entrenable.
- **1971–86** - Backpropagation (Werbos; popularizada por Rumelhart, Hinton & Williams).
- **1987–88** - MRII y MRIII (Andes): esta última, **equivalente a backprop**.

Nota

Aplicaciones emblemáticas: **NET-talk**, el *truck backer-upper* y los ecualizadores LMS de módems (primer uso comercial masivo).

El hilo conductor: principio de mínima perturbación

Idea clave

Adaptar para reducir el error del patrón actual, con la mínima perturbación a las respuestas ya aprendidas.

Consecuencia geométrica

El cambio de pesos ΔW_k es siempre **colineal** con la entrada X_k : la corrección deseada se logra con el cambio de **menor magnitud posible**.

$$\Delta W_k \parallel X_k \implies \min \|\Delta W_k\|$$

- Condujo al descubrimiento de LMS y de las reglas Madaline.
- **Todos** los algoritmos del artículo obedecen esta idea; es el eje que los unifica.

El bloque básico: combinador lineal y Adaline




Fig. 2 del artículo: Adaline (combinador + cuantizador).

Ecuaciones

Producto interno:

$$s_k = X_k^T W_k$$

Cuantizador duro:

$$y_k = \text{sgn}(s_k) \in \{\pm 1\}.$$

Variante diferenciable: $y_k = \tanh(s_k)$.

Nota

El bias w_0 ($+1$) fija el umbral;
 $s = 0$ define el **hiperplano se-
parador**.

Separabilidad lineal y capacidad de patrones




Fig. 4: $s = 0$ como recta separadora. Ninguna recta separa XOR.

Límite del Adaline

Con $n = 2$ entradas implementa **14 de 16** funciones lógicas; imposibles: XOR y XNOR (no separables) $\Rightarrow$ exigen **no linealidad**.

- Capacidad determinística: $C_d = N_w$ (garantía).
- Capacidad estadística (Cover): $C_s \approx 2N_w$ (promedio); Baum la extendió a redes.
- No realizar *todas* las funciones **limita la capacidad y mejora la generalización**.

De Madaline I a la red multicapa: el problema de las capas ocultas




Fig. 15: Madaline I - Adalines *signum* + lógica fija (solo 1.^a capa adaptativa).




Fig. 11: red *feedforward* moderna - todas las capas adaptativas.

Idea clave

La dificultad clave es obtener señales de error para las capas **ocultas**. *Backpropagation* y *Madaline Rule III* son precisamente los dos mecanismos que la resuelven.


Dos familias de reglas y su taxonomía (Fig. 33)

Corrección de error

Corrigen una **proporción** del error en el patrón presente (*ad hoc*, útil con no linealidades duras).

Descenso más pronunciado

Minimizan el **MSE** promediado por gradiente sobre todo el conjunto.



Reproducción fiel de la Fig. 33 del artículo.

Corrección de error de un elemento: α -LMS y Perceptrón

α -LMS (Widrow-Hoff, lineal)

$$W_{k+1} = W_k + \alpha \frac{\varepsilon_k}{\|X_k\|^2} X_k, \quad \varepsilon_k = d_k - X_k^T W_k$$


Perceptrón (Rosenblatt, no lineal)

$$W_{k+1} = W_k + \alpha \frac{\tilde{\varepsilon}_k}{2} X_k, \quad \tilde{\varepsilon}_k = d_k - y_k$$

Corrección $\propto$ error **lineal**; auto-normalizante; $0 < \alpha < 2$. Usa el error del **cuantizador**; solo adapta si $y_k \neq d_k$.

- **Perceptrón**: converge en pasos finitos **si** los datos son separables; si no, oscila y el peso “gravita a cero”.
- **α -LMS**: estable siempre, pero su objetivo es reducir el error lineal, no *separar*.
- **Reglas de Mays**: introducen una **zona muerta** γ ; con datos no separables suelen superar al Perceptrón.

Corrección de error multicapa: Madaline Rule II (Fig. 16)



MRII (Widrow, Winter & Baxter, 1987)

Ambas capas adaptativas. Por cada patrón erróneo:

- 1 Ordenar Adalines por $|s|$ (mínima perturbación).
- 2 Flip tentativo: si reduce el **error de Hamming**, se acepta y se refuerza con α -LMS.
- 3 Si no, probar *pares*; capa de salida por α -LMS.

Limitación

Cuantizadores duros $\Rightarrow$ **óptimos locales**. Remedio: ruido esporádico o *random restarts*.

Descenso de gradiente lineal: μ -LMS y la superficie de MSE

Regla μ -LMS

$$W_{k+1} = W_k + 2\mu \varepsilon_k X_k$$

Superficie de MSE (paraboloide **convexo**):

$$\xi(W) = \mathbb{E}[d^2] - 2P^T W + W^T R W$$

Mínimo único (solución de Wiener):

$$W^* = R^{-1}P.$$

Note that the MSE is a quadratic function of the weights. It is a convex hyperparaboloidal surface, a function that never goes negative. Figure 17 shows a typical MSE surface





Fig. 17: MSE del combinador lineal.


- Gradiente instantáneo $-2\varepsilon_k X_k$: estimador insesgado.
- μ -LMS $\rightarrow$ mínimo MSE (Wiener); α -LMS, a solución sesgada.

Por qué el gradiente exige activaciones diferenciables (Figs. 22–24)


Error lineal (paraboloide convexo)
Min=0.9359



Error sigmoide (no cuadrático)
Min=0.9401



Error signum (escalonado, mesetas)
Min=1.3333



Nota

Lineal: paraboloide convexo, mínimo global garantizado.


Nota

Sigmoide: suave y navegable; posibles mínimos locales.

Signum

Mesetas de gradiente nulo: el descenso se detiene.

Descenso de gradiente no lineal: Backpropagation (Fig. 25)



Trazo continuo = ida ($X \rightarrow Y$); punteado = retorno de los δ .

Propagación del error

Salida y capas ocultas:

$$\delta_j^{(L)} = \epsilon_j(1 - y_j^2)$$


$$\delta^{(l)} = (W^{(l+1)T} \delta^{(l+1)}) \odot (1 - (y^{(l)})^2)$$

Update (+ momentum $\eta \approx 0.9$): $\Delta W_k = 2\mu \delta_k X_k^T$.

Idea clave

δ no es un error: es una señal de gradiente para reducir ϵ^2 de salida.

Madaline Rule III $\equiv$ Backpropagation (Fig. 28)



Misma arquitectura que MRII, pero con sigmoides.

MRIII (Andes, 1988)

Gradiente por perturbación del sumidero, sin la derivada de la sigmoide:

$$\frac{\partial \epsilon^2}{\partial s_j} \approx \frac{\epsilon_{\text{pert}}^2 - \epsilon_{\text{base}}^2}{\Delta s}$$

Idea clave

Con $\Delta s \rightarrow 0$, MRIII es **matemáticamente equivalente a backpropagation**; **robusto** en hardware analógico (existió un chip comercial).

Objetivo

Validar **numéricamente** las afirmaciones del artículo. Todo implementado desde cero en NumPy (*scikit-learn* solo para cargar datos y métricas). Datos: sintéticos (separable, no separable, XOR) y reales (Iris, Wine, MNIST-04, two-moons).

Hip.	Descripción
------	-------------

- | | |
|----|---|
| H1 | Un Adaline de N_w pesos almacena en promedio $C_s \approx 2N_w$ patrones ($C_d = N_w$ garantizado). |
| H2 | El Perceptrón converge solo si hay separabilidad; α/μ -LMS estables, con μ -LMS $\rightarrow$ Wiener $R^{-1}P$. |
| H3 | Los problemas no separables (XOR) exigen multicapa; la superficie sigmoide es más navegable que la signum. |
| H4 | El gradiente de MRIII (perturbación) coincide con el de backprop cuando $\Delta s \rightarrow 0$. |
-

E1 — Capacidad de Cover (H1)





Fig. 5 del artículo (teoría, 1965).




Reconstrucción empírica (Monte Carlo).

Idea clave

H1 confirmada: desviación media ≤ 0.034 entre empírico y teoría. Se verifica $C_d = N_w$ (en $N_p/N_w = 1$) y $C_s \approx 2N_w$ (probabilidad 0.5).

E2-E3 — Reglas lineales vs. óptimo de Wiener (H2)




Fronteras aprendidas por cada regla vs. Wiener (datos separables).

Idea clave

H2 confirmada. **Separable:** el Perceptrón converge (2 épocas) pero queda a 20.6° de Wiener; μ -LMS a solo 3.5° . **No separable:** el Perceptrón oscila; μ -LMS es el mejor (79.6 % vs. Wiener 81.0 %) y de menor varianza.

E5 — XOR: MRIL vs. MLP-Backpropagation (H3)




Datos: XOR (4 patrones, no separable).

Configuración	Éxito
MRIL 2-2-1	0/20
MRIL 2-3-1 + ruido	0/20
MLP-BP 2-2-1	6/20
MLP-BP 2-3-1	11/20

H3 confirmada

Solo la multicapa resuelve XOR; MRIL y backprop sufren óptimos locales.

E6 — Generalización a datos reales (H3)





MLP-backprop sobre **two-moons**: frontera curva imposible para un lineal.

Dataset	Modelo	Test
two-moons	MLP-BP	93.3 %
Iris	MLP-BP	91.1 %
Wine	μ -LMS/Wiener	98.1 %
MNIST-04	MLP-BP	98.5 %

Idea clave

H3 confirmada: la no linealidad generaliza a datos reales y **escala** a mayor dimensión (MNIST-04, 64 rasgos).

E7 — Equivalencia MRIII $\equiv$ Backpropagation (H4)



Gradiente de MRIII (perturbación) vs. el analítico de backprop, y su costo.

Idea clave

H4 confirmada: el gradiente de MRIII converge al de backprop con error relativo mínimo de 5.05×10^{-8} ; el costo crece como $\mathcal{O}(N_{\text{Adalines}})$.

Aporte del artículo

- **Unifica 30 años** de algoritmos bajo un principio común: la **mínima perturbación**.
- El linaje Perceptrón → Adaline → Madaline → Backprop es una **progresión lógica**.
- La equivalencia **MRIII $\equiv$ backprop** muestra que un mismo descubrimiento llega por caminos independientes.

Evaluación de hipótesis

H1–H4 confirmadas. Matiz en H3: MRII resultó más frágil ante óptimos locales que el MLP (0/20 con semilla única), tal como el propio artículo anticipa.

Gracias

30 Years of Adaptive Neural Networks: Perceptron, Madaline, and Backpropagation
B. Widrow & M. A. Lehr, Proceedings of the IEEE, 78(9), 1990.