

30 Años de Redes Neuronales Adaptativas

Perceptrón, Madaline y Backpropagation (Widrow & Lehr, 1990)

Iván Fernández G.

Magíster en Ingeniería Informática - Universidad de Santiago de Chile
Inteligencia Computacional 2026-1 | Prof. Gonzalo Acuña Leiva

Julio 2026

- 1 Introducción e historia
 - Motivación y línea histórica
- 2 Conceptos fundamentales
 - Adaline, separabilidad y arquitecturas
- 3 Reglas de aprendizaje
 - Corrección de error y descenso de gradiente
- 4 Experimentos
 - Diseño y resultados
- 5 Conclusiones
 - Síntesis

Contexto y línea histórica (1960–1990)

¿Qué aborda el artículo?

Una **revisión** de 30 años de reglas de aprendizaje supervisado para redes *feedforward*: cómo adaptar los pesos de elementos simples para clasificar o hacer regresión a partir de ejemplos, con **generalización** a patrones no vistos.

- **1960** - LMS (Widrow & Hoff) y regla del Perceptrón (Rosenblatt), independientes.
- **Mediados 60s** - Madaline I (MRI): primera red en capas entrenable.
- **1971–86** - Backpropagation (Werbos; popularizada por Rumelhart, Hinton & Williams).
- **1987–88** - MRII y MRIII (Andes): esta última, **equivalente a backprop**.

Nota

Aplicaciones emblemáticas: **NETtalk**, el *truck backer-upper* y los ecualizadores LMS de módems (primer uso comercial masivo).

El hilo conductor: principio de mínima perturbación

Idea clave

Adaptar para reducir el error del patrón actual, con la mínima perturbación a las respuestas ya aprendidas.

Consecuencia geométrica

El cambio de pesos ΔW_k es siempre **colineal** con la entrada X_k : la corrección deseada se logra con el cambio de **menor magnitud posible**.

$$\Delta W_k \parallel X_k \implies \min \|\Delta W_k\|$$

- Condujo al descubrimiento de LMS y de las reglas Madaline.
- **Todos** los algoritmos del artículo obedecen esta idea; es el eje que los unifica.

El bloque básico: combinador lineal y Adaline




Fig. 2 del artículo: Adaline (combinador + cuantizador).

Ecuaciones

Producto interno:

$$s_k = X_k^T W_k$$

Cuantizador duro:

$$y_k = \text{sgn}(s_k) \in \{\pm 1\}.$$

Variante diferenciable: $y_k = \tanh(s_k)$.

Nota

El bias w_0 (+1) fija el umbral;
 $s = 0$ define el **hiperplano separador**.




Fig. 4: $s = 0$ como recta separadora. Ninguna recta separa XOR.

Límite del Adaline

Con $n = 2$ entradas implementa **14 de 16** funciones lógicas; imposibles: XOR y XNOR (no separables) $\Rightarrow$ exigen **no linealidad**.

- Capacidad determinística: $C_d = N_w$ (garantía).
- Capacidad estadística (Cover): $C_s \approx 2N_w$ (promedio); Baum la extendió a redes.
- No realizar *todas* las funciones **limita la capacidad y mejora la generalización**.

De Madaline I a la red multicapa: el problema de las capas ocultas




Fig. 15: Madaline I - Adalines *signum* + lógica fija (solo 1.^a capa adaptativa).




Fig. 11: red *feedforward* moderna - todas las capas adaptativas.

Idea clave

La dificultad clave es obtener señales de error para las capas **ocultas**. *Backpropagation* y *Madaline Rule III* son precisamente los dos mecanismos que la resuelven.


Dos familias de reglas y su taxonomía (Fig. 33)

Corrección de error

Corrigen una proporción del error en el patrón presente (*ad hoc*, útil con no linealidades duras).

Descenso más pronunciado

Minimizan el MSE promediado por gradiente sobre todo el conjunto.



Reproducción fiel de la Fig. 33 del artículo.

Corrección de error de un elemento: α -LMS y Perceptrón

α -LMS (Widrow-Hoff, lineal)

$$W_{k+1} = W_k + \alpha \frac{\varepsilon_k}{\|X_k\|^2} X_k, \quad \varepsilon_k = d_k - X_k^T W_k$$


Perceptrón (Rosenblatt, no lineal)

$$W_{k+1} = W_k + \alpha \frac{\tilde{\varepsilon}_k}{2} X_k, \quad \tilde{\varepsilon}_k = d_k - y_k$$

Corrección $\propto$ error **lineal**; auto-normalizante; $0 < \alpha < 2$. Usa el error del **cuantizador**; solo adapta si $y_k \neq d_k$.

- **Perceptrón**: converge en pasos finitos **si** los datos son separables; si no, oscila y el peso “gravita a cero”.
- **α -LMS**: estable siempre, pero su objetivo es reducir el error lineal, no *separar*.
- **Reglas de Mays**: introducen una **zona muerta** γ ; con datos no separables suelen superar al Perceptrón.

Corrección de error multicapa: Madaline Rule II (Fig. 16)



MRII (Widrow, Winter & Baxter, 1987)

Ambas capas adaptativas. Por cada patrón erróneo:

- 1 Ordenar Adalines por $|s|$ (mínima perturbación).
- 2 Flip tentativo: si reduce el **error de Hamming**, se acepta y se refuerza con α -LMS.
- 3 Si no, probar *pares*; capa de salida por α -LMS.

Limitación

Cuantizadores duros $\Rightarrow$ **óptimos locales**. Remedio: ruido esporádico o *random restarts*.

Descenso de gradiente lineal: μ -LMS y la superficie de MSE

Regla μ -LMS

$$W_{k+1} = W_k + 2\mu \varepsilon_k X_k$$

Superficie de MSE (paraboloide **convexo**):

$$\xi(W) = \mathbb{E}[d^2] - 2P^T W + W^T R W$$

Mínimo único (solución de Wiener):

$$W^* = R^{-1}P.$$

Note that the MSE is a quadratic function of the weights. It is a convex hyperparaboloidal surface, a function that never goes negative. Figure 17 shows a typical MSE surface





Fig. 17: MSE del combinador lineal.


- Gradiente instantáneo $-2\varepsilon_k X_k$: estimador insesgado.
- μ -LMS $\rightarrow$ mínimo MSE (Wiener); α -LMS, a solución sesgada.

Por qué el gradiente exige activaciones diferenciables (Figs. 22–24)


Error lineal (paraboloide convexo)
Min=0.9359



Error sigmoide (no cuadrático)
Min=0.9401



Error signum (escalonado, mesetas)
Min=1.3333



Nota

Lineal: paraboloide convexo, mínimo global garantizado.


Nota

Sigmoide: suave y navegable; posibles mínimos locales.

Signum

Mesetas de gradiente nulo: el descenso se detiene.

Descenso de gradiente no lineal: Backpropagation (Fig. 25)



Propagación del error

Salida y capas ocultas:

$$\delta_j^{(L)} = \epsilon_j(1 - y_j^2)$$

$$\delta^{(l)} = (W^{(l+1)T} \delta^{(l+1)}) \odot (1 - (y^{(l)})^2)$$


Update (+ momentum $\eta \approx 0.9$): $\Delta W_k = 2\mu \delta_k X_k^T$.

Idea clave

δ no es un error: es una señal de gradiente para reducir ϵ^2 de salida.

Trazo continuo = ida ($X \rightarrow Y$); punteado = retorno de los δ .

Madaline Rule III $\equiv$ Backpropagation (Fig. 28)



Misma arquitectura que MRII, pero con sigmoides.

MRIII (Andes, 1988)

Gradiente por perturbación del sumidero, sin la derivada de la sigmoide:

$$\frac{\partial \epsilon^2}{\partial s_j} \approx \frac{\epsilon_{\text{pert}}^2 - \epsilon_{\text{base}}^2}{\Delta s}$$

Idea clave

Con $\Delta s \rightarrow 0$, MRIII es **matemáticamente equivalente a backpropagation**; robusto en hardware analógico (existió un chip comercial).

Objetivo

Validar **numéricamente** las afirmaciones del artículo. Todo implementado desde cero en NumPy (*scikit-learn* solo para cargar datos y métricas). Datos: sintéticos (separable, no separable, XOR) y reales (Iris, Wine, MNIST-04, two-moons).

Hip. Descripción

- | | |
|----|---|
| H1 | Un Adaline de N_w pesos almacena en promedio $C_s \approx 2N_w$ patrones ($C_d = N_w$ garantizado). |
| H2 | El Perceptrón converge solo si hay separabilidad; α/μ -LMS estables, con μ -LMS $\rightarrow$ Wiener $R^{-1}P$. |
| H3 | Los problemas no separables (XOR) exigen multicapa; la superficie sigmoide es más navegable que la signum. |
| H4 | El gradiente de MR3 (perturbación) coincide con el de backprop cuando $\Delta s \rightarrow 0$. |
-

E1 — Capacidad de Cover (H1)





Fig. 5 del artículo (teoría, 1965).




Reconstrucción empírica (Monte Carlo).

Idea clave

H1 confirmada: desviación media ≤ 0.034 entre empírico y teoría. Se verifica $C_d = N_w$ (en $N_p/N_w = 1$) y $C_s \approx 2N_w$ (probabilidad 0.5).

E2-E3 — Reglas lineales vs. óptimo de Wiener (H2)




Fronteras aprendidas por cada regla vs. Wiener (datos separables).

Idea clave

H2 confirmada. Separable: el Perceptrón converge (2 épocas) pero queda a 20.6° de Wiener; μ -LMS a solo 3.5° . No separable: el Perceptrón oscila; μ -LMS es el mejor (79.6% vs. Wiener 81.0%) y de menor varianza.

E5 — XOR: MRIL vs. MLP-Backpropagation (H3)




Datos: XOR (4 patrones, no separable).

Configuración	Éxito
MRIL 2-2-1	0/20
MRIL 2-3-1 + ruido	0/20
MLP-BP 2-2-1	6/20
MLP-BP 2-3-1	11/20

H3 confirmada

Solo la multicapa resuelve XOR; MRIL y backprop sufren óptimos locales.

E6 — Generalización a datos reales (H3)





MLP-backprop sobre **two-moons**: frontera curva imposible para un lineal.

Dataset	Modelo	Test
two-moons	MLP-BP	93.3%
Iris	MLP-BP	91.1%
Wine	μ -LMS/Wiener	98.1%
MNIST-04	MLP-BP	98.5%

Idea clave

H3 confirmada: la no linealidad generaliza a datos reales y **escala** a mayor dimensión (MNIST-04, 64 rasgos).

E7 — Equivalencia MRIII $\equiv$ Backpropagation (H4)



Gradiente de MRIII (perturbación) vs. el analítico de backprop, y su costo.

Idea clave

H4 confirmada: el gradiente de MRIII converge al de backprop con error relativo mínimo de 5.05×10^{-8} ; el costo crece como $\mathcal{O}(N_{\text{Adalines}})$.

Aporte del artículo

- **Unifica 30 años** de algoritmos bajo un principio común: la **mínima perturbación**.
- El linaje Perceptrón → Adaline → Madaline → Backprop es una **progresión lógica**.
- La equivalencia $MR_{III} \equiv \text{backprop}$ muestra que un mismo descubrimiento llega por caminos independientes.

Evaluación de hipótesis

H1–H4 confirmadas. Matiz en H3: MR_{II} resultó más frágil ante óptimos locales que el MLP (0/20 con semilla única), tal como el propio artículo anticipa.

Gracias

30 Years of Adaptive Neural Networks: Perceptron, Madaline, and Backpropagation
B. Widrow & M. A. Lehr, Proceedings of the IEEE, 78(9), 1990.